

原始瓦瑟斯坦模仿学习

Robert Dadashi^{*1}, 莱昂纳德·于瑟诺^{1,2}, Matthieu Geist¹, Olivier Pietquin¹

¹Google Research, Brain Team

²Univ. de Lille, CNRS, Inria Scool, UMR 9189 CRISTAL

摘要

模仿学习 (Imitation Learning, IL) 方法旨在使智能体的行为与专家行为相匹配。本文提出一种基于概念简单算法的新颖模仿学习方法：原始瓦瑟斯坦模仿学习 (Primal Wasserstein Imitation Learning, PWIL)，该方法与专家和智能体状态-动作分布之间的瓦瑟斯坦距离的原始形式相关联。我们提出一种离线推导的奖励函数，与近期通过与环境交互学习奖励函数的对抗性模仿学习算法不同，该奖励函数几乎无需微调。我们证明，在 MuJoCo 领域的多种连续控制任务中，该方法能够在智能体交互和专家与环境交互方面以样本高效的方式恢复专家行为。最后，我们证明所训练智能体的行为与专家行为在瓦瑟斯坦距离上相匹配，而非使用常用的性能代理指标。

1 引言

强化学习 (Reinforcement Learning, RL) 已在游戏 (Tesauro, 1995; Mnih et al., 2015; Silver et al., 2016) 和机器人 (Abbeel & Ng, 2004; Andrychowicz et al., 2020) 等多个困难任务中取得成功。然而，强化学习依赖于奖励函数的存在，而奖励函数可能难以指定或过于稀疏而无法实际使用。模仿学习 (Imitation Learning, IL) 是一种适用于奖励难以指定的环境的范式：我们通过从专家生成的固定数量示范中学习策略来完成任务。

模仿学习方法通常可分为两种范式：行为克隆 (Behavioral Cloning, BC) (Pomerleau, 1991; Bagnell et al., 2007; Ross & Bagnell, 2010) 和逆强化学习 (Inverse Reinforcement Learning, IRL) (Russell, 1998; Ng et al., 2000)。在行为克隆中，我们通过直接学习在某种意义上与专家行为相匹配的策略来恢复专家行为。在逆强化学习中，我们假设示范来自一个相对于未知奖励函数最优行动的智能体，我们试图恢复该奖励函数，随后在其上训练智能体。尽管逆强化学习方法引入了一个中间问题（即恢复环境奖励），但它们对分布偏移 (Pomerleau, 1991) 较不敏感，能够泛化到具有不同动态的环境 (Piot et al., 2013)，并且可以从次优示范中恢复接近最优的智能体 (Brown et al., 2019; Jacq et al., 2019)。

然而，逆强化学习方法通常基于奖励估计与强化学习交替进行的迭代过程，这可能导致样本效率低下。早期的逆强化学习方法 (Ng 等, 2000; Abbeel 和 Ng, 2004; Ziebart 等, 2008) 需要多次调用马尔可夫决策过程求解器 (Puterman, 2014)，而近期的对抗式模仿学习方法 (Finn 等, 2016; Ho 和 Ermon, 2016; Fu 等, 2018) 则将奖励函数的学习与智能体的学习过程交织进行。对抗式模仿学习方法基于类似于生成对抗网络 (GANs) (Goodfellow 等, 2014) 的对抗训练范式，其中学习到的奖励函数可视为判别器的混淆度，该判别器学习区分专家转移与非专家转移。这些方法非常适合模仿学习问题，因为它们隐式地最小化专家状态-动作分布与学习智能体状态-动作分布之间的 f -散度 (Ghasemipour 等, 2019; Ke 等, 2019)。然而，生成器 (策略) 与判别器 (奖励函数) 之间的交互使其成为一个极小极大优化问题，因此带来了实际挑战，可能包括训练不稳定、对超参数敏感以及样本效率低下。* 通讯作者: Robert Dadashi, dadashi@google.com。

在本文中，我们使用 Wasserstein 距离作为专家与智能体状态-动作分布之间的度量。与 f -散度不同，Wasserstein 距离是一个真正的距离，它是平滑的，并且基于其所作用的度量空间的几何结构。Wasserstein 距离通过其对偶形式在生成对抗网络方法中获得了广泛关注（Arjovsky 等，2017），但该对偶形式也带来了挑战（见第 5 节）。本文方法的新颖之处在于，我们考虑通过原始形式来最小化 Wasserstein 距离。关键的是，原始形式避免了极小极大优化问题，并且几乎不需要精细调参。

我们引入了一种离线计算的奖励函数，该函数基于 Wasserstein 距离原始形式的上界。由于 Wasserstein 距离需要状态-动作对之间的距离，我们展示了对于运动任务可以手工定义该距离，而对于手部操作任务可以从像素中学习该距离。推断出的奖励函数是非平稳的，类似于对抗式模仿学习方法，但它不会在智能体与环境交互时被重新评估，因此我们定义的奖励函数是离线计算的。我们提出了一种真实距离来比较专家行为和智能体行为，而不是使用常见的性能代理指标（即相对于所考虑任务真实回报的性能，因为该回报通常未知）。我们的方法在恢复专家行为方面与现有最先进方法相当，但基于的超参数显著更少；它甚至在演示数据极少的极端情况下也能运行，并且是第一个仅用单个（子采样）演示就能使 Humanoid 运行的方法。

2 背景与符号

马尔可夫决策过程。我们将环境描述为具有有限时间范围的回合制马尔可夫决策过程（Markov Decision Process, MDP）（Sutton & Barto, 2018） $(\mathcal{S}, \mathcal{A}, \mathcal{P}, r, \gamma, \rho_0, T)$ ，其中 $\mathcal{S}$ 是状态空间，

$\mathcal{A}$ 是动作空间， $\mathcal{P}$ 是转移核， r 是奖励函数， γ 是折扣因子， ρ_0 是初始状态分布， T 是时间范围。我们将 $\mathcal{S}$ 和 $\mathcal{A}$ 的维度分别记为 $|\mathcal{S}|$ 和 $|\mathcal{A}|$ 。策略 π 是从状态到动作分布的映射；我们将所有策略的空间记为 Π 。在强化学习中，目标是学习一个策略 π^* ，使其遇到的折扣奖励的期望和最大化，即期望回报。根据上下文，我们可能使用成本 c 的概念而不是奖励 r （Puterman, 2014），这本质上将策略的目标从最大化回报转变为最小化累积成本。

状态-动作分布。假设策略 π 在一个回合中访问连续的状态和动作 $s_1, a_1, \dots, s_T, a_T$ ，我们将经验状态-动作分布 $\hat{\rho}_\pi$ 定义为： $\hat{\rho}_\pi = \frac{1}{T} \sum_{t=1}^T \delta_{s_t, a_t}$ ，其中 δ_{s_t, a_t} 是以 (s_t, a_t) 为中心的狄拉克分布。类似地，假设我们有一组大小为 D 的专家演示 $\mathcal{D} = \{s^e, a^e\}_{e=1}^D$ ，则相关的经验专家状态-动作分布 $\hat{\rho}_e$ 定义为： $\hat{\rho}_e = \frac{1}{D} \sum_{(s,a) \in \mathcal{D}} \delta_{s,a}$ 。

Wasserstein 距离。假设我们有一个度量空间 (M, d) ，其中 M 是一个集合， d 是 M 上的度量。假设我们有 μ 和 ν 两个在 M 上具有有限矩的分布，则 p 阶 Wasserstein 距离（Villani, 2008）定义为 $W_p^p(\mu, \nu) = \inf_{\theta \in \Theta(\mu, \nu)} \int_{M \times M} d(x, y)^p d\theta(x, y)$ ，其中 $\Theta(\mu, \nu)$ 是 μ 和 ν 之间所有耦合的集合。在本文的其余部分，我们只考虑具有有限支撑的分布。支撑基数为 T 和 D 的两个分布之间的耦合是一个大小为 $T \times D$ 的双随机矩阵。我们用 Θ 表示所有大小为 $T \times D$ 的双随机矩阵的集合：

$$\Theta = \left\{ \theta \in \mathbb{R}_+^{T \times D} \mid \forall j \in [1 : D], \sum_{i'=1}^T \theta[i', j] = \frac{1}{D}, \forall i \in [1 : T], \sum_{j'=1}^D \theta[i, j'] = \frac{1}{T} \right\}.$$

状态-动作对分布之间的 Wasserstein 距离需要在空间 $(\mathcal{S}, \mathcal{A})$ 中定义一个度量 d 。在 MDP 中定义度量并非易事（Ferns et al., 2004; Mahadevan & Maggioni, 2007）；我们在第 4.4 节展示了一个从示范中学习度量的例子。目前，我们假设存在一个度量 $d : (\mathcal{S}, \mathcal{A}) \times (\mathcal{S}, \mathcal{A}) \mapsto \mathbb{R}^+$ 。

3 方法

我们提出我们方法的理论动机：最小化智能体与专家状态-动作分布之间的 Wasserstein 距离。我们引入一个基于 Wasserstein 距离原始形式的上界的奖励，该上界由最优耦合条件的松弛推导而来，

并给出相应的算法：原始 Wasserstein 模仿学习（PWIL）。

3.1 WASSERSTEIN 距离最小化

我们方法的核心是最小化我们试图训练的策略的状态-动作分布 $\hat{\rho}_\pi$ 与专家的状态-动作分布 $\hat{\rho}_e$ 之间的 Wasserstein 距离。换句话说，我们的目标是优化以下问题：

$$\inf_{\pi \in \Pi} \mathcal{W}_p^p(\hat{\rho}_\pi, \hat{\rho}_e) = \inf_{\pi \in \Pi} \inf_{\theta \in \Theta} \sum_{i=1}^T \sum_{j=1}^D d((s_i^\pi, a_i^\pi), (s_j^e, a_j^e))^p \theta[i, j]. \quad (1)$$

在本文的其余部分，我们仅考虑 1-瓦瑟斯坦距离（ $p = 1$ ，见方程 1），并将阶数 p 影响的深入研究留作未来工作。我们可以用推土机类来解释瓦瑟斯坦距离（Villani, 2008）。将专家的状态-动作对视为质量为 D^{-1} 的 D 个洞，将策略的状态-动作对视为质量为 T^{-1} 的土堆。耦合 θ 是土堆与洞之间的运输策略，其中 $\theta[i, j]$ 表示应将土堆 i 的多少土运往洞 j 。最优耦合是使推土机将所有土堆运至洞所行驶距离最小化的策略。注意，要计算最优耦合，我们需要知道所有土堆的位置。在强化学习背景下，这意味着能够访问由 π 生成的完整轨迹。从现在起，我们将 θ_π^* 记为策略 π 的最优耦合，并将其代入方程（1）：

$$\begin{aligned} \theta_\pi^* &= \arg \min_{\theta \in \Theta} \sum_{i=1}^T \sum_{j=1}^D d((s_i^\pi, a_i^\pi), (s_j^e, a_j^e)) \theta[i, j] \\ \inf_{\pi \in \Pi} \mathcal{W}_1(\hat{\rho}_\pi, \hat{\rho}_e) &= \inf_{\pi \in \Pi} \sum_{i=1}^T c_{i,\pi}^* \quad \text{含} \quad c_{i,\pi}^* = \sum_{j=1}^D d((s_i^\pi, a_i^\pi), (s_j^e, a_j^e)) \theta_\pi^*[i, j]. \end{aligned} \quad (2)$$

在方程（2）中，我们引入了 $c_{i,\pi}^*$ ，将其解释为使用强化学习最小化的代价。由于 $c_{i,\pi}^*$ 依赖于最优耦合 θ_π^* ，我们只能在回合结束时定义 $c_{i,\pi}^*$ 。如果智能体以在线方式学习或任务时间跨度较大，这可能存在问题。因此，我们引入瓦瑟斯坦距离的一个上界，该上界基于次优耦合策略，产生一个可在线计算的代价。

3.2 贪心耦合

在本节中，我们引入贪心耦合 $\theta^g \in \Theta$ ，递归定义为 $1 \leq i \leq T$ 如下：

$$\begin{aligned} \theta_\pi^g[i, :] &= \arg \min_{\theta[i, :] \in \Theta_i} \sum_{j=1}^D d((s_i^\pi, a_i^\pi), (s_j^e, a_j^e)) \theta[i, j] \\ \text{含} \quad \Theta_i &= \left\{ \theta[i, :] \in \mathbb{R}_+^D \mid \underbrace{\sum_{j'=1}^D \theta[i, j']}_{\text{constraint}(a)} = \frac{1}{T}, \forall k \in [1 : D], \underbrace{\sum_{i'=1}^{i-1} \theta_g[i', k] + \theta[i, k]}_{\text{constraint}(b)} \leq \frac{1}{D} \right\}. \end{aligned} \quad (3)$$

与方程（1）类似，方程（3）也可以用推土机类来解释。与方程（1）中假设已知 T 个土堆位置不同，我们现在考虑它们按顺序出现，推土机需要在新土堆出现时立即将其运至洞中。为此，我们计算到所有洞的距离，并将新土堆运至最近的剩余可用洞，因此具有贪心性质。在方程（3）中，约束（a）意味着第 i 个时间步出现的所有土都必须被运走，约束（b）意味着我们不能超过洞的容量 $\frac{1}{D}$ 。我们在图 1 中展示了贪心耦合与最优耦合的区别，并在算法 1 中提供了推导贪心耦合的伪代码。




图 1: 展示了 a) 贪婪耦合与 b) 最优耦合之间差异的示意图。我们给出一个马尔可夫决策过程 (MDP)，其中省略了对动作的依赖。状态空间为 $\mathbb{R}$ ，关联的度量是欧氏距离。我们标注策略访问的状态： $s_1^\pi, s_2^\pi, s_3^\pi$ ，以及专家访问的状态： s_1^e, s_2^e, s_3^e 。当策略遇到状态 s_2^π 时，由于我们尚不知道 s_3^π ，贪婪耦合策略将其与 s_2^e 耦合，而最优耦合策略则会将其与 s_3^e 耦合。注意，贪婪耦合的总代价（省略常数耦合乘法因子）为 7，而最优耦合的总代价为 5。这凸显了最优耦合需要了解整个策略轨迹才能推导出来。

我们现在可以利用贪婪耦合定义 Wasserstein 距离的一个上界（因为根据定义它是次优的）：

$$\begin{aligned} \inf_{\pi \in \Pi} \mathcal{W}_1(\hat{\rho}_\pi, \hat{\rho}_e) &= \inf_{\pi \in \Pi} \sum_{i=1}^T \sum_{j=1}^D d((s_i^\pi, a_i^\pi), (s_j^e, a_j^e)) \theta_\pi^*[i, j] \\ &\leq \inf_{\pi \in \Pi} \sum_{i=1}^T \sum_{j=1}^D d((s_i^\pi, a_i^\pi), (s_j^e, a_j^e)) \theta_\pi^q[i, j]. \end{aligned} \quad (4)$$

在第 4 节中，我们通过实验验证了这个上界。我们在每个时间步 i 从方程 (1) 推断出一个代价：

$$c_{i,\pi}^q = \sum_{j=1}^D d((s_i^\pi, a_i^\pi), (s_j^e, a_j^e)) \theta_\pi^q[i, j]. \quad (5)$$

注意，方程 (3) 中定义的贪婪耦合 $\theta_\pi^q[t, \cdot]$ 依赖于策略 π 之前访问的所有状态-动作对，这使得代价 $c_{i,\pi}^q$ 是非平稳的，类似于对抗性模仿学习方法。我们可以从代价中推断出奖励， $r_{i,\pi} = f(c_{i,\pi}^q)$ ，其中 f 是一个单调递减函数。这个奖励函数是一个情节历史依赖的奖励函数 $r(s_0, a_0, \dots, s_t, a_t)$ ，其中 r 由专家演示唯一确定（因此被称为离线推导）。关键在于，我们定义了一个希望最大化的奖励函数，而没有引入内部最小化问题（对抗性模仿学习方法中则存在此问题）。

我们现在可以基于这个奖励函数推导出一个算法（算法 1）。所提出的算法以伪代码形式编写，适用于一个通用智能体 A ，该智能体实现策略 π_A ，观察元组 (s, a, r, s') ，并可能更新其组件。单步奖励计算的算法运行时间复杂度为 $\mathcal{O}((|S| + |A|)D + \frac{D^2}{T})$ （详见附录 E.2），因此在整个回合中计算奖励的复杂度为 $\mathcal{O}((|S| + |A|)DT + D^2)$ 。注意，当 $T = D$ 时，计算贪婪耦合只需在专家演示集合中查找与智能体状态-动作对距离最小的专家状态-动作对，然后从专家演示集合中弹出该最小化专家状态-动作对。

算法 1 引入了一个具有自我观察和更新能力的智能体，其设计直接受到 ACME 智能体形式化方法的启发（Hoffman 等，2020），并且具有足够的通用性来描述广泛的智能体。我们在第 E.1 节中给出了该算法的示例运行过程。

4 实验

在本节中，我们基于 ACME 框架（Hoffman 等，2020）介绍 PWIL 的实现并进行实证评估。我们在 MuJoCo 运动任务上测试 PWIL，并将其与最先进的类 GAIL 算法 DAC（Kostrikov 等，2019）以及常见的 BC 基线进行比较。由于 DAC 基于 TD3（Fujimoto 等，2018），而 TD3 是 DDPG（Lillicrap 等，2016）的一种变体，因此我们使用基于 DDPG 的智能体 D4PG（Barth-Maron 等，2018）进行公平比较。我们还提供了一个概念验证实验，该实验涉及开门任务，其中演示不包含动作且基于像素，因此必须学习 MDP 的度量。

Algorithm 1 PWIL: Primal Wasserstein Imitation Learning

Input: Expert demonstrations $\mathcal{D} = \{s_j^e, a_j^e\}_{j \in [1:D]}$, Agent A , number of episodes N
for $k = 1$ **to** N **do**
 Copy expert demonstrations with weight: $\mathcal{D}' := \{s_j^e, a_j^e, w_j^e\}_{j \in [1:D]}$, with $w_j^e = \frac{1}{D}$
 Reset environment, initial state s
for $i = 1$ **to** T **do**
 Take action $a := \pi_A(s)$, observe next state s'
 Initialize weight $w^\pi := \frac{1}{T}$, cost $c := 0$
while $w^\pi > 0$ **do**
 Compute $s^e, a^e, w^e := \arg \min_{(s^e, a^e, w^e) \in \mathcal{D}'} d((s, a), (s^e, a^e))$
if $w^\pi \geq w^e$ **then**
 $c := c + w^e d((s, a), (s^e, a^e))$
 $w^\pi := w^\pi - w^e$
 $\mathcal{D}'.\text{pop}(s^e, a^e, w^e)$
else
 $c := c + w^\pi d((s, a), (s^e, a^e))$
 $w^e := w^e - w^\pi$
 $w^\pi := 0$
 $r := f(c)$
 A observes (s, a, r, s') , updates itself

在此设置中，我们使用 SAC 作为直接强化学习方法。我们回答以下问题：1) PWIL 能否恢复专家行为？2) PWIL 的样本效率如何？

3) PWIL 是否真正最小化了智能体与专家分布之间的 Wasserstein 距离？4) PWIL 能否扩展到基于视觉的观测，其中 MDP 度量的定义并不直接？我们还通过消融实验展示了 PWIL 对其多个组成部分的依赖性。实验的完整描述见附录 A。我们提供了实验代码和训练智能体的视频，网址为：
<https://sites.google.com/view/wasserstein-imitation>。

4.1 实现

我们遵循与生成对抗模仿学习和判别器-行为克隆相同的评估协议，在 OpenAI Gym MuJoCo 套件 (Todorov 等人, 2012; Brockman 等人, 2016) 的六个环境中测试了原始 Wasserstein 模仿学习：Reacher-v2、Ant-v2、Humanoid-v2、Walker2d-v2、HalfCheetah-v2 和 Hopper-v2。对于每个环境，使用在这些环境的实际奖励上训练的 D4PG 智能体收集多个演示（选择该智能体是因为它是 ACME 框架中的基础智能体）。我们以 20 倍因子对演示进行子采样：在回合开始时以随机偏移量每 20 个转换中选取一个（Reacher 除外，因为其回合长度为 50，我们不进行子采样）。子采样的目的是模拟低数据状态，使得纯行为克隆方法遭受行为漂移，从而无法达到专家水平。我们使用多个演示数量进行实验：{1, 4, 11}（与判别器-行为克隆的评估协议一致）。我们方法的核心是状态-动作对之间的度量。我们使用标准化欧氏距离，即观测和动作拼接上的 L2 距离，沿每个维度按专家演示的逆标准差加权。根据方程 (5) 中定义的成本 c_i ，我们定义以下奖励：

$$r_i = \alpha \exp\left(-\frac{\beta T}{\sqrt{|\mathcal{S}| + |\mathcal{A}|}} c_i\right). \quad (6)$$

对于所有环境，我们使用 $\alpha = 5$ 和 $\beta = 5$ 。状态空间和动作空间 $\sqrt{\frac{T}{|\mathcal{S}| + |\mathcal{A}|}}$ 的维度和任务时间范围的缩放因子。我们选择 $f : x \mapsto \exp(-x)$ 作为单调递减函数。

我们将所提方法与最先进的模仿学习算法进行了对比测试：判别器-行为克隆 (DAC) 和行为克隆 (BC)。判别器-行为克隆基于生成对抗模仿学习 (GAIL)：它区分专家状态与非专家状态，并使用离策略算法双延迟深度确定性策略梯度 (TD3) ——深度确定性策略梯度 (DDPG) 的一种变体——而非在策略算法信任区域策略优化 (TRPO) (Schulman

等人，2015 年）。我们使用了作者提供的开源代码。原始 DAC 论文中未研究人形机器人环境。由于作者提供的超参数性能不佳，我们在第 A.2 节中进行了详尽的搜索，并展示了找到的最佳超参数的结果。

对于本文方法，我们使用一个 D4PG 智能体（详见附录 A），并在附录 C 中提供了使用不同直接强化学习智能体的额外实验。我们通过用具有最大奖励的专家状态-动作对填充回放缓冲区来初始化回放缓冲区 α （然而，请注意我们使用了子采样轨迹，这使得它成为对实际轨迹回放的近似）。我们在 10 个随机种子上，以 100 万次环境交互为极限（Humanoid 为 250 万次）训练 PWIL 和 DAC。每 1 万步环境交互，我们对每个种子执行 10 个回合的无探索噪声策略回放，并在图 2 中报告相对于环境原始奖励的性能。

4.2 结果

在图 2 中，与 DAC 相比，PWIL 在 Hopper、Ant、HalfCheetah 和 Humanoid 上的最终性能有所提升，在 Walker2d 上性能相似，而在 Reacher 上表现较差。在 Humanoid 上，尽管我们进行了详尽的超参数搜索（见 A.2 节），DAC 的性能仍然很差，这体现了类 GAIL 方法的脆弱性。相反，即使只有一次演示，PWIL 也具有接近最优的性能。

在样本效率方面，DAC 在 HalfCheetah、Ant 和 Reacher 上优于 PWIL，在 Hopper 和 Walker2d 上性能相似。请注意，PWIL 的消融版本在 HalfCheetah 和 Ant 上比 DAC 更具样本效率（B 节）。这似乎与类 GAIL 方法样本效率低下的说法相矛盾。然而，DAC 中定义的奖励函数需要仔细调整（例如架构、优化器、正则化器、学习率调度），这需要实验周期，因此伴随着大量的环境交互。

值得注意的是，PWIL 是第一种能够在 Humanoid 上持续学习策略的方法，即使只有一次演示，平均得分也超过 7000，这意味着智能体实际上可以奔跑（其他工作认为 Humanoid 达到 5000 分即为“解决”，这对应于站立）。




图 2：评估策略在 10 次回放和 10 个随机种子上，每 1 万步环境交互报告的平均回报和标准差。回报以环境原始奖励计算。第一行：1 次演示，第二行：11 次演示。

Wasserstein 距离。在图 3 中，我们展示了 PWIL 和 DAC 在整个学习过程中与专家示范之间的 Wasserstein 距离。该距离在一个回合结束时使用传输单纯形法（Bonneel 等人，2011）进行评估；我们使用了 Flamary & Courty (2017) 的实现。对于这两种方法，我们注意到距离在学习过程中逐渐减小。在所有环境中，PWIL 导致的 Wasserstein 距离均小于 DAC，除了 HalfCheetah 中两者相近，以及 Reacher 中 PWIL 的距离更大。这并不令人意外，因为 PWIL 的目标是最小化 Wasserstein 距离。PWIL 根据专家与智能体状态-动作分布之间 Wasserstein 距离的上界定义奖励，我们也将该上界包含在

图 3 中。注意我们的上界是“经验紧致的”，这验证了选择贪心




图 3: 评估策略的状态-动作分布与专家状态-动作分布之间 Wasserstein 距离的均值, 基于 10 次回放和 10 个随机种子。智能体使用 11 条示范进行训练。对于 PWIL, 我们包含了基于方程 (4) 中定义的贪心耦合的 Wasserstein 距离上界。

耦合作为最优耦合的近似。我们强调, 无论使用何种方法, 在无法获得任务实际奖励的真实模仿学习场景中, 这一距离都是有用的。

4.3 消融实验

在本节中, 我们展示了 PWIL 在存在消融情况下的评估性能, 并在图 4 中报告最终性能。所有消融的学习曲线见附录 B。我们保持原始 PWIL 智能体的超参数不变。




图 4: PWIL 及其变体在 1M 环境交互标记处 (Humanoid 为 2.5M) 评估性能的均值和标准差。结果基于 10 个随机种子, 每个种子 10 个回合计算。

原始 Wasserstein 模仿学习 (PWIL) -状态。在此版本的原始瓦瑟斯坦模仿学习 (Primal Wasserstein Imitation Learning, PWIL) 中, 本文不假设能够获取专家所采取的动作。因此, 本文尝试匹配智能体的状态分布与专家的状态分布 (而非状态-动作分布)。该设置被称为从观察中学习 (Learning from Observation, LfO) (Torabi 等人, 2018; Edwards 等人, 2019)。奖励的定义与 PWIL 类似, 但使用状态距离而非状态-动作距离。注意, 在此版本中, 由于无法获取动作, 本文无法用专家状态-动作对预填充回放缓冲区。值得注意的是, **PWIL-state** 在所有环境中均恢复了非平凡的行为。

原始瓦瑟斯坦模仿学习 (PWIL) -L2。在此版本的 PWIL 中, 本文使用状态-动作对之间的欧氏距离, 而非标准化欧氏距离。换言之, 本文未按专家演示沿每个维度的逆标准差对状态-动作距离进行加权。除 Hopper-v2 外, 所有环境的性能均显著下降。这表明 PWIL 的性能对马尔可夫决策过程 (MDP) 度量的质量较为敏感。

原始瓦瑟斯坦模仿学习 (PWIL) -nofill。在此版本中, 本文未用专家转移预填充回放缓冲区。这导致性能下降, 对于 Walker 和 Ant 而言下降显著。这并不意外, 因为许多模仿学习方法利用了回放缓冲区中专家转移的思想 (Reddy 等人, 2020; Hester 等人, 2018)。

原始瓦瑟斯坦模仿学习 (PWIL) -support。在此版本的 PWIL 中, 本文将奖励定义为以下代价的函数:

$$\forall i \in [1 : T], c_{i,\pi} = \inf_{\theta_1, \dots, \theta_D \in \mathbb{R}} \sum_{j=1}^D d((s_i^\pi, a_i^\pi), (s_j^e, a_j^e)) \theta_j.$$

我们可以在第 3 节的背景下将此代价解释为将质量为 1 的土堆 T 移入容量无限的坑中的问题。因此, 它让人联想到将模仿学习视为一种支撑的方法

估计问题 (Wang 等人, 2019; Brantley 等人, 2020)。这导致 Ant、Walker 和 HalfCheetah 的性能显著下降。

4.4 开门任务：基于像素观测的奖励

在本节中，我们证明 PWIL 可扩展到基于视觉的设置，其中马尔可夫决策过程 (MDP) 度量需要学习。我们使用 Rajeswaran 等人 (2018) 的开门任务，人类演示由 Haptix (Kumar & Todorov, 2015) 生成。任务目标是让受控手打开门 (图 5)，门的位置在每个回合都会变化。我们添加了门被打开时的提前终止约束 (从而抑制生存激励)。我们假设只能访问演示的高维视觉渲染，而无法访问内部状态 (因此无法访问动作，即仅从观察学习 (LfO) 设置)。



图 5: 开门任务的可视化渲染。

因此，PWIL 奖励是通过当前状态视觉渲染与演示视觉渲染之间的距离来定义的。该距离通过自监督学习离线习得：我们利用时间循环一致性学习 (Temporal Cycle-Consistency Learning, TCC) (Dwibedi 等人, 2019) 构建帧的嵌入；TCC 通过对来自多个示例 (此处为演示) 的任务视频帧来构建嵌入。因此，习得的距离是嵌入之间的 L2 距离。该距离在 Rajeswaran 等人 (2018) 提供的 25 个人类演示上学习，随后被重新用于定义 PWIL 奖励。根据方程 (5) 中定义的成本 c_i ，我们定义如下奖励： $r_i = \alpha \exp(-\beta T c_i)$ ，其中 $\alpha = 5, \beta = 1$ 。我们使用 SAC (Haarnoja 等人, 2018a) 作为前向强化学习算法，在该任务上它比 D4PG 更稳健。我们在 150 万环境步上训练智能体，并在图 6 中展示我们确实恢复了专家行为并一致地解决了任务。




图 6: 我们展示了 PWIL 在门环境上的评估性能的平均值和标准差。指标每 1 万环境步计算一次，并在 10 个随机种子和 10 次回放上聚合。左图：智能体的模仿回报。中图：嵌入空间中与专家演示之间的 Wasserstein 距离。右图：智能体的成功率，即智能体成功打开门的回合比例。

5 相关工作

对抗式模仿学习。 与我们的方法类似，对抗式模仿学习方法旨在使用不同的相似性度量来匹配智能体的状态-动作分布与专家分布。例如，GAIL (Ho & Ermon, 2016) 考虑 Shannon-Jensen 散度，而 AIRL (Fu et al., 2018) 考虑 Kullback-Leibler 散度。在 GAN 的背景下，Arjovsky 等人 (2017) 表明，通过 Kantorovich-Rubinstein 对偶性 (Villani, 2008) 用 Wasserstein 距离替换 f 散度可以带来更好的训练稳定性，许多模仿学习方法已经利用了这一点 (Li et al., 2017; Lacotte et al., 2019; Kostrikov et al., 2019; Xiao et al., 2019; Liu et al., 2020; Pacchiano et al., 2020)。然而，Kantorovich-Rubinstein 对偶性仅对 W_1 距离成立 (Peyré et al., 2019)，其实现伴随着许多实际近似 (例如，权重裁剪以确保 Lipschitz 连续性)。尽管这些方法通过其对偶形式基于 Wasserstein 距离，但它们与我们的方法截然不同，因为它们依赖于极小极大优化问题。DAC (Kostrikov et al., 2019) 证明了对抗式模仿学习

方法虽然基于 GAIL, 但可以是样本高效的。然而, 它们依赖于精心调整的判别器 (例如网络架构、正则化策略、计划学习率), 这需要与环境交互。相比之下, 我们提出的奖励函数仅依赖于两个超参数。

专家支持估计。模仿学习中的另一类研究思路是估计专家的状态-动作支撑集, 并定义一个奖励函数以鼓励智能体保持在专家的支撑集上 (Piot 等, 2014; Schroecker 与 Isbell, 2017; Wang 等, 2019; Brantley 等, 2020; Reddy 等, 2020)。需要注意的是, 智能体可能停留在专家的支撑集上, 却未能恢复其状态-动作分布。软 Q 模仿学习 (Soft Q Imitation Learning, Reddy 等, 2020) 为所有专家转移分配奖励 1, 为专家遇到的所有转移分配奖励 0; 该方法通过在基于价值的智能体的回放缓冲区中平衡专家转移与智能体转移来学习恢复专家行为。随机专家蒸馏 (Random Expert Distillation, Wang 等, 2019) 通过一个在专家转移上训练的神经网络来估计支撑集, 该网络的目标是一个固定的随机神经网络。分歧正则化模仿学习 (Disagreement Regularized Imitation Learning, Brantley 等, 2020) 通过一组行为克隆智能体的方差来估计专家支撑集, 并使用基于到专家支撑集的距离以及与行为克隆策略的 KL 散度的奖励。PWIL 与这些方法不同, 因为它基于到专家支撑集的距离, 并且该支撑集通过“弹出”机制收缩, 以强制智能体访问整个支撑集。我们在消融实验中表明, “弹出”机制对于恢复专家行为是必不可少的 (参见 PWIL-support)。

基于轨迹的模仿学习。与开门实验类似, Aytar 等 (2018) 离线学习一个嵌入, 并根据嵌入空间中到单条示范的距离来强化奖励。然而, 该方法更适合确定性环境, 因为他们使用单条轨迹供智能体复现, 而开门实验表明 PWIL 能够泛化, 因为门和把手的位置是随机选取的。Peng 等 (2018) 强化一个时序奖励函数 (在时间 t 的奖励基于智能体状态与专家在时间 t 的状态之间的距离)。与 PWIL 不同, 该模仿奖励函数被添加到任务相关的奖励函数上; 到专家示范的距离是在观测空间中手工挑选的维度上定义的; 时序约束使其难以泛化到具有随机初始状态的环境。

离线奖励估计。现有方法在无需与环境交互的情况下推导奖励函数 (Boularias 等人, 2011; Klein 等人, 2013; 2012; Piot 等人, 2016)。它们通常需要对奖励结构做出强假设 (例如在某些预定义特征上具有线性)。PWIL 也在离线情况下推导奖励, 且不依赖结构假设, 然而它是非平稳的, 因为它依赖于该回合中访问的状态-动作。

最大均值差异 (Maximum Mean Discrepancy, MMD) - 模仿学习 (Imitation Learning, IL)。生成式矩匹配模仿学习 (Kim & Park, 2018) 假设在马尔可夫决策过程中存在一个度量, 并旨在最小化智能体与专家之间的最大均值差异 (MMD)。然而, MMD (如同 Wasserstein 距离) 需要智能体的完整轨迹, 并且不像贪心耦合那样具有自然的松弛形式。GMMIL 基于在线策略智能体, 这使得其样本效率显著低于 PWIL。我们未能实现基于离线策略智能体的 MMD 版本。

6 结论

在这项工作中, 我们将模仿学习表述为一个分布匹配问题, 并引入一个基于智能体与专家状态-动作分布之间 Wasserstein 距离上界的奖励函数。许多 IL 方法是在合成任务上开发的, 在这些任务中, IL 方法的评估可以通过任务的实际回报来完成。我们强调, 在我们的工作中, 我们提出了一种直接衡量专家与智能体之间相似性的度量, 因此可以在真实的 IL 环境中使用, 即在无法指定任务奖励的环境中。

我们引入的奖励函数是离线学习的, 即它不需要通过与环境交互来更新。它需要很少的调参 (2 个超参数), 并且在所有考虑的环境中, 即使是在具有挑战性的 Humanoid 环境中, 仅需 1 次演示就能恢复接近专家的性能。最后, 我们的方法扩展到更难的基于视觉的环境, 基于使用自监督学习从专家演示中离线学习的度量。

致谢

我们感谢 Zafarali Ahmed、Adrien Ali Taiga、Gabriel Dulac-Arnold、Johan Ferret、Alexis Jacq 和 Saurabh Kumar 对手稿早期版本提出的反馈。我们感谢 Debidatta Dwibedi 和 Ilya Kostrikov 的有益讨论。

参考文献

- Pieter Abbeel and Andrew Y Ng. Apprenticeship learning via inverse reinforcement learning. In *International Conference on Machine Learning*, 2004.
- OpenAI: Marcin Andrychowicz, Bowen Baker, Maciek Chociej, Rafal Jozefowicz, Bob McGrew, Jakub Pachocki, Arthur Petron, Matthias Plappert, Glenn Powell, Alex Ray, et al. Learning dexterous in-hand manipulation. *The International Journal of Robotics Research*, 2020.
- Martin Arjovsky, Soumith Chintala, and Léon Bottou. Wasserstein generative adversarial networks. In *International Conference on Machine Learning*, 2017.
- Yusuf Aytar, Tobias Pfaff, David Budden, Thomas Paine, Ziyu Wang, and Nando de Freitas. Playing hard exploration games by watching youtube. In *Advances in Neural Information Processing Systems*, 2018.
- Jimmy Lei Ba, Jamie Ryan Kiros, and Geoffrey E Hinton. Layer normalization. *arXiv preprint arXiv:1607.06450*, 2016.
- JA Bagnell, Joel Chestnutt, David M Bradley, and Nathan D Ratliff. Boosting structured prediction for imitation learning. In *Advances in Neural Information Processing Systems*, 2007.
- Gabriel Barth-Maron, Matthew W Hoffman, David Budden, Will Dabney, Dan Horgan, Dhruva Tb, Alistair Muldal, Nicolas Heess, and Timothy Lillicrap. Distributed distributional deterministic policy gradients. *International Conference on Learning Representations*, 2018.
- Marc G Bellemare, Will Dabney, and Rémi Munos. A distributional perspective on reinforcement learning. In *International Conference on Machine Learning*, 2017.
- Nicolas Bonneel, Michiel Van De Panne, Sylvain Paris, and Wolfgang Heidrich. Displacement interpolation using lagrangian mass transport. In *Proceedings of the 2011 SIGGRAPH Asia Conference*, 2011.
- Abdeslam Boularias, Jens Kober, and Jan Peters. Relative entropy inverse reinforcement learning. In *International Conference on Artificial Intelligence and Statistics*, 2011.
- Kianté Brantley, Wen Sun, and Mikael Henaff. Disagreement-regularized imitation learning. In *International Conference on Learning Representations*, 2020.
- Greg Brockman, Vicki Cheung, Ludwig Pettersson, Jonas Schneider, John Schulman, Jie Tang, and Wojciech Zaremba. Openai gym, 2016.
- Daniel Brown, Wonjoon Goo, Prabhat Nagarajan, and Scott Niekum. Extrapolating beyond sub-optimal demonstrations via inverse reinforcement learning from observations. In *International Conference on Machine Learning*, 2019.
- Djork-Arné Clevert, Thomas Unterthiner, and Sepp Hochreiter. Fast and accurate deep network learning by exponential linear units (elus). *International Conference on Learning Representations*, 2016.
- Debidatta Dwibedi, Yusuf Aytar, Jonathan Tompson, Pierre Sermanet, and Andrew Zisserman. Temporal cycle-consistency learning. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2019.
- Ashley Edwards, Himanshu Sahni, Yannick Schroecker, and Charles Isbell. Imitating latent policies from observation. In *International Conference on Machine Learning*, 2019.

- Norm Ferns, Prakash Panangaden, and Doina Precup. Metrics for finite markov decision processes. In *Conference on Uncertainty in Artificial Intelligence*, 2004.
- Chelsea Finn, Sergey Levine, and Pieter Abbeel. Guided cost learning: Deep inverse optimal control via policy optimization. In *International Conference on Machine Learning*, 2016.
- Rémi Flamary and Nicolas Courty. Pot python optimal transport library. *GitHub*: <https://github.com/rflamary/POT>, 2017.
- Justin Fu, Katie Luo, and Sergey Levine. Learning robust rewards with adversarial inverse reinforcement learning. *International Conference on Learning Representations*, 2018.
- Scott Fujimoto, Herke Hoof, and David Meger. Addressing function approximation error in actor-critic methods. In *International Conference on Machine Learning*, 2018.
- Seyed Kamyar Seyed Ghasemipour, Richard Zemel, and Shixiang Gu. A divergence minimization perspective on imitation learning methods. *Conference on Robot Learning*, 2019.
- Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial nets. In *Advances in Neural Information Processing Systems*, 2014.
- Tuomas Haarnoja, Aurick Zhou, Pieter Abbeel, and Sergey Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *International Conference on Machine Learning*, 2018a.
- Tuomas Haarnoja, Aurick Zhou, Kristian Hartikainen, George Tucker, Sehoon Ha, Jie Tan, Vikash Kumar, Henry Zhu, Abhishek Gupta, Pieter Abbeel, et al. Soft actor-critic algorithms and applications. *arXiv preprint arXiv:1812.05905*, 2018b.
- Todd Hester, Matej Vecerik, Olivier Pietquin, Marc Lanctot, Tom Schaul, Bilal Piot, Dan Horgan, John Quan, Andrew Sendonaris, Ian Osband, et al. Deep q-learning from demonstrations. In *AAAI Conference on Artificial Intelligence*, 2018.
- Jonathan Ho and Stefano Ermon. Generative adversarial imitation learning. In *Advances in Neural Information Processing Systems*, 2016.
- Matt Hoffman, Bobak Shahriari, John Aslanides, Gabriel Barth-Maron, Feryal Behbahani, Tamara Norman, Abbas Abdolmaleki, Albin Cassirer, Fan Yang, Kate Baumli, et al. Acme: A research framework for distributed reinforcement learning. *arXiv preprint arXiv:2006.00979*, 2020.
- Alexis Jacq, Matthieu Geist, Ana Paiva, and Olivier Pietquin. Learning from a learner. In *International Conference on Machine Learning*, 2019.
- Liyiming Ke, Matt Barnes, Wen Sun, Gilwoo Lee, Sanjiban Choudhury, and Siddhartha Srinivasa. Imitation learning as f -divergence minimization. *arXiv preprint arXiv:1905.12888*, 2019.
- Kee-Eung Kim and Hyun Soo Park. Imitation learning via kernel mean embedding. In *AAAI Conference on Artificial Intelligence*, 2018.
- Diederik P Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *International Conference on Learning Representations*, 2015.
- Edouard Klein, Matthieu Geist, Bilal Piot, and Olivier Pietquin. Inverse reinforcement learning through structured classification. In *Advances in Neural Information Processing Systems*, 2012.
- Edouard Klein, Bilal Piot, Matthieu Geist, and Olivier Pietquin. A cascaded supervised learning approach to inverse reinforcement learning. In *Joint European conference on machine learning and knowledge discovery in databases*, 2013.
- Ilya Kostrikov, Kumar Krishna Agrawal, Debidatta Dwibedi, Sergey Levine, and Jonathan Tompson. Discriminator-actor-critic: Addressing sample inefficiency and reward bias in adversarial imitation learning. *International Conference on Learning Representations*, 2019.

- V. Kumar and E. Todorov. Mujoco haptix: A virtual reality system for hand manipulation. In *2015 IEEE-RAS 15th International Conference on Humanoid Robots (Humanoids)*, 2015.
- Jonathan Lacotte, Mohammad Ghavamzadeh, Yinlam Chow, and Marco Pavone. Risk-sensitive generative adversarial imitation learning. In *International Conference on Artificial Intelligence and Statistics*, 2019.
- Yunzhu Li, Jiaming Song, and Stefano Ermon. Infogail: Interpretable imitation learning from visual demonstrations. In *Advances in Neural Information Processing Systems*, 2017.
- Timothy P Lillicrap, Jonathan J Hunt, Alexander Pritzel, Nicolas Heess, Tom Erez, Yuval Tassa, David Silver, and Daan Wierstra. Continuous control with deep reinforcement learning. *International Conference on Learning Representations*, 2016.
- Fangchen Liu, Zhan Ling, Tongzhou Mu, and Hao Su. State alignment-based imitation learning. *International Conference on Learning Representations*, 2020.
- Sridhar Mahadevan and Mauro Maggioni. Proto-value functions: A laplacian framework for learning representation and control in markov decision processes. *Journal of Machine Learning Research*, 2007.
- Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A Rusu, Joel Veness, Marc G Bellemare, Alex Graves, Martin Riedmiller, Andreas K Fidjeland, Georg Ostrovski, et al. Human-level control through deep reinforcement learning. *Nature*, 2015.
- Andrew Y Ng, Stuart J Russell, et al. Algorithms for inverse reinforcement learning. In *International Conference on Machine Learning*, 2000.
- Aldo Pacchiano, Jack Parker-Holder, Yunhao Tang, Krzysztof Choromanski, Anna Choromanska, and Michael Jordan. Learning to score behaviors for guided policy optimization. In *International Conference on Machine Learning*, 2020.
- Xue Bin Peng, Pieter Abbeel, Sergey Levine, and Michiel van de Panne. Deepmimic: Example-guided deep reinforcement learning of physics-based character skills. *ACM Transactions on Graphics (TOG)*, 2018.
- Gabriel Peyré, Marco Cuturi, et al. Computational optimal transport. *Foundations and Trends in Machine Learning*, 2019.
- Bilal Piot, Matthieu Geist, and Olivier Pietquin. Learning from demonstrations: Is it worth estimating a reward function? In *Joint European Conference on Machine Learning and Knowledge Discovery in Databases*, 2013.
- Bilal Piot, Matthieu Geist, and Olivier Pietquin. Boosted and reward-regularized classification for apprenticeship learning. In *International conference on autonomous agents and multi-agent systems*, 2014.
- Bilal Piot, Matthieu Geist, and Olivier Pietquin. Bridging the gap between imitation learning and inverse reinforcement learning. *IEEE transactions on neural networks and learning systems*, 2016.
- Dean A Pomerleau. Efficient training of artificial neural networks for autonomous navigation. *Neural computation*, 1991.
- Martin L Puterman. *Markov decision processes: discrete stochastic dynamic programming*. John Wiley & Sons, 2014.
- Aravind Rajeswaran, Vikash Kumar, Abhishek Gupta, Giulia Vezzani, John Schulman, Emanuel Todorov, and Sergey Levine. Learning complex dexterous manipulation with deep reinforcement learning and demonstrations. In *Proceedings of Robotics: Science and Systems (RSS)*, 2018.
- Siddharth Reddy, Anca D Dragan, and Sergey Levine. Sqil: imitation learning via regularized behavioral cloning. *International Conference on Learning Representations*, 2020.
- Stéphane Ross and Drew Bagnell. Efficient reductions for imitation learning. In *International Conference on Artificial Intelligence and Statistics*, 2010.

- Stuart Russell. Learning agents for uncertain environments. In *Conference on Computational learning theory*, 1998.
- Yannick Schroecker and Charles L Isbell. State aware imitation learning. In *Advances in Neural Information Processing Systems*, 2017.
- John Schulman, Sergey Levine, Pieter Abbeel, Michael Jordan, and Philipp Moritz. Trust region policy optimization. In *International Conference on Machine Learning*, 2015.
- David Silver, Aja Huang, Chris J Maddison, Arthur Guez, Laurent Sifre, George Van Den Driessche, Julian Schrittwieser, Ioannis Antonoglou, Veda Panneershelvam, Marc Lanctot, et al. Mastering the game of go with deep neural networks and tree search. *Nature*, 2016.
- Richard S Sutton and Andrew G Barto. *Reinforcement learning: An introduction*. 2018.
- Gerald Tesauro. Temporal difference learning and td-gammon. *Communications of the ACM*, 1995.
- Emanuel Todorov, Tom Erez, and Yuval Tassa. Mujoco: A physics engine for model-based control. In *International Conference on Intelligent Robots and Systems*, 2012.
- Faraz Torabi, Garrett Warnell, and Peter Stone. Behavioral cloning from observation. In *International Joint Conference on Artificial Intelligence*, 2018.
- Cédric Villani. *Optimal transport: old and new*. 2008.
- Ruohan Wang, Carlo Ciliberto, Pierluigi Vito Amadori, and Yiannis Demiris. Random expert distillation: Imitation learning via expert policy support estimation. In *International Conference on Machine Learning*, 2019.
- Huang Xiao, Michael Herman, Joerg Wagner, Sebastian Ziesche, Jalal Etesami, and Thai Hong Linh. Wasserstein adversarial imitation learning. *arXiv preprint arXiv:1906.08113*, 2019.
- Brian D Ziebart, Andrew L Maas, J Andrew Bagnell, and Anind K Dey. Maximum entropy inverse reinforcement learning. In *AAAI Conference on Artificial Intelligence*, 2008.

A 运动实验

A.1 PWIL 实现

我们使用的智能体是 D4PG (Barth-Maron 等人, 2018)。我们采用 ACME 框架 (Hoffman 等人, 2020) 中的默认架构。

演员网络架构是一个 4 层神经网络：第一层大小为 256，使用双曲正切函数 ($\tanh$) 激活和层归一化 (Ba 等人, 2016)；第二层和第三层大小为 256，使用 elu 激活 (Clevert 等人, 2016)；最后一层大小为动作空间的维度，使用双曲正切函数激活并缩放到环境的动作范围。为了确保充分的探索，我们在最后一层之上添加一个标准差为 $\sigma = 0.2$ 的高斯噪声层，并将其裁剪到环境的动作范围。我们在评估智能体时不使用探索噪声。

对于评论家网络，我们使用一个 4 层神经网络：第一层大小为 512，使用双曲正切函数激活和层归一化；第二层大小为 512，使用 elu 激活；第三层大小为 256，使用 elu 激活；最后一层维度为 201，使用 Softmax 函数激活。这 201 个神经元代表在范围 $[-150, 150]$ 内等距支撑的分布权重，作为类别分布 (Bellemare 等人, 2017)。我们使用 Adam 优化器 (Kingma & Ba, 2015)，演员网络的学习率为 $\lambda_a = 5 \times 10^{-5}$ ，评论家网络的学习率为 $\lambda_c = 7 \times 10^{-5}$ 。我们使用批大小为 256。我们裁剪评论家和演员的梯度，将其 L2 范数限制在 40。

我们使用大小为 10^6 的重放缓冲区，折扣因子为 $\theta = 0.99$ ，以及 n 步回报，其中 $n = 5$ 。我们用来示范集的 50000 个状态-动作对预填充重放缓冲区（这意味着我们将相同的专家转移多次放入缓冲区）。我们每与环境交互 $k = 4$ 次就对演员和评论家进行一次更新。超参数搜索详见表 1。

Parameters	Values
λ_a	$10^{-5}, 5 \times 10^{-5}, 7 \times 10^{-5}, 10^{-4}$
λ_c	$10^{-5}, 5 \times 10^{-5}, 7 \times 10^{-5}, 10^{-4}$
σ	0.1, 0.2, 0.3
k	2, 4, 8, 16

表 1: DDPG 超参数搜索。

对于奖励函数，我们确实对 α 和 β 进行了超参数搜索，使用的取值如 $\alpha, \beta \in \{1, 5, 10\}$ 下：和

A.2 DAC 实现

我们使用了 Kostrikov 等人 (2019) 提供的 DAC 开源实现。对于 Humanoid (论文中未报告)，我们进行了表 2 所述的大规模超参数搜索。在 729 个实验中，有 7 个在 250 万训练环境步数时平均性能超过 1000。

Actor learning rate (lr)	Critic lr	Discriminator lr	WGAN regularizer	Exploration noise	Decay lr
0.001 , 0.0005, 0.0001	0.001, 0.0005 , 0.0001	0.001 , 0.0005, 0.0001	5, 10 , 20	0.1 , 0.2, 0.3	0.3, 0.5, 0.8

表 2: Humanoid 上 11 次演示的超参数搜索。（测试/最佳）

A.3 BC 实现

我们使用了一个三层神经网络，第一层大小为 128，采用修正线性单元 (relu) 激活，第二层大小为 64，最后一层大小为动作空间维度，采用双曲正切函数 ($\tanh$) 激活并缩放到环境的动作范围。我们发现，使用专家演示观测值的均值和标准差对观测进行归一化有助于提升性能。我们使用均方误差作为损失函数，并采用 Adam 优化器训练网络。我们对学习率和批大小进行了超参数搜索。

$\{10^{-5}, 10^{-4}, 10^{-3}\}$ $\{128, 256\}$.

A.4 PWIL 学习曲线

本文展示了 PWIL 的学习曲线，分别以方程 6 中定义的奖励以及任务原始奖励为衡量标准。




图 7: 智能体模仿回报的均值与标准差。我们在 1M 步内每 10k 环境步执行 10 次回放，共使用 10 个随机种子。此处回报基于方程 (6) 定义的奖励。第一行: 1 条演示，中间行: 4 条演示，最后一行: 11 条演示。




图 8: 评估策略在原始环境回报上的均值与标准差，基于 10 次回放和 10 个随机种子，在 1M 步内每 10k 环境步报告一次。第一行: 1 条演示，中间行: 4 条演示，最后一行: 11 条演示。




图 9: 评估策略的状态-动作分布与专家状态-动作分布之间 Wasserstein 距离的均值与标准差, 基于 10 次回放和 10 个随机种子, 每 10k 环境步报告一次。我们包含了基于方程 (4) 中贪婪耦合定义的 Wasserstein 距离上限。第一行: 1 条演示, 中间行: 4 条演示, 最后一行: 11 条演示。

B 消融实验

本文展示了 PWIL 在消融条件下的学习曲线。




图 10: PWIL 不同变体的评估性能, 基于 10 次回放和 10 个随机种子, 在 1M 步内每 10k 环境步报告一次。回报基于环境原始奖励。第一行: 1 条演示, 中间行: 4 条演示, 最后一行: 11 条演示。

C 直接强化学习算法的影响

在本节中，我们研究直接强化学习方法对 PWIL 在运动任务上性能的影响。我们将 PWIL 与 D4PG 结合的性能，与 PWIL 与 TD3 和 SAC 结合的性能进行比较。我们使用了 SAC 和 TD3 的自定义实现，该实现是对作者实现的复现。对于 SAC，我们使用了相同的默认超参数；对于 TD3，我们移除了延迟策略更新，这带来了更好的性能。我们在与 D4PG 相同的奖励函数上评估这两种方法。我们移除了 SAC 的重放缓冲区预热。对于 TD3，我们发现每个环境需要不同的预热才能获得良好性能（与 D4PG 不同）：对于 Reacher、Hopper 和 Walker2d，我们使用了 1000 个状态-动作对，而对于 Humanoid、Ant 和 HalfCheetah 则没有预热。




图 11: PWIL-D4PG、PWIL-SAC 和 PWIL-TD3 在 100 万环境交互步数（Humanoid 为 250 万步）时的评估性能均值和标准差。结果基于 10 个随机种子，每个种子 10 个回合计算。我们在图 11 中展示，PWIL-SAC 和 PWIL-TD3 在 Hopper、Ant、HalfCheetah 和 Reacher 上均恢复了专家级性能。对于 Walker2d，性能标准差较大，因为某些种子导致接近最优的专家性能，而某些种子导致性能较差。值得注意的是，我们对 SAC 和 TD3 的默认版本进行了最少的超参数调优，这可能解释了性能上的差异。

D 开门实验

在本节中，我们介绍第 4.4 节中实验的细节。

D.1 环境

默认的开门环境具有 200 个时间步的固定时间范围。当门被打开时，我们向环境添加一个提前终止条件，以证明 PWIL 可以扩展到没有生存激励的任务。请注意，与 AIRL (Fu 等人, 2018) 类似，提前终止状态被视为吸收状态。因此，如果专家提前到达终止状态，其状态分布在这些状态上具有较大权重，这导致 PWIL 智能体同样提前到达终止状态。使用虚拟现实系统 (Kumar & Todorov (2015)) 从人类收集了 25 个演示。

D.2 嵌入

由于我们假设只能获取演示的视觉渲染 (分辨率为 84×84)，因此构建了一个低维潜空间。我们采用自监督学习方法 TCC 来学习该潜空间。我们使用了 Dwibedi 等人 (2019) 中详述的该算法的分类版本 (第 3.2 节)。

编码网络结构如下：一个卷积层，包含 128 个大小为 8、步长为 4 的滤波器，一个修正线性单元激活函数，一个卷积层，包含 64 个大小为 4、步长为 2 的滤波器，一个修正线性单元激活函数，一个卷积层，包含 64 个大小为 3、步长为 1 的滤波器，一个修正线性单元激活函数，一个大小为 128 的线性层，一个修正线性单元激活函数，以及一个大小为 32 的输出层。

我们将演示划分为包含 20 个演示的训练集和包含 5 个演示的验证集。与 Dwibedi 等人 (2019) 类似，我们选择在验证集上根据肯德尔 τ 分数最大化对齐度的编码网络。

我们对批大小 $\{1, 4, 16, 32\}$ 、子采样比率 $\{1, 4, 8\}$ 和学习率 $\{10^{-2}, 10^{-3}, 10^{-4}\}$ (使用 Adam 优化器) 进行了超参数搜索。表现最佳的编码器在训练集上的平均肯德尔 τ 分数为 0.98，在验证集上为 0.91。




图 12: 编码网络在训练集和验证集上的肯德尔 τ 分数。一次迭代对应 1000 次梯度更新。

D.3 智能体

在此设置中，我们发现 SAC 比 D4PG 能取得更好的结果。下面详述 SAC 的实现。

行动者是一个 3 层网络，输出具有对角协方差矩阵的正态分布的参数。我们强制协方差矩阵的各项大于 10^{-3} 。第一层大小为 256，使用修正线性单元激活函数，第二层大小为 256，使用修正线性单元激活函数，最后一层大小为 48 (动作空间大小为 24)。

评论家是一个三层网络。我们将环境的状态和动作的拼接作为输入。有两个大小为 256 的隐藏层，使用修正线性单元激活。我们确实使用了孪生评论家。

我们使用自适应温度 α ，如 Haarnoja 等人 (2018b) 所述。


对于这三个损失，我们使用 Adam 优化器，并对评论家网络使用 Polyak 平均，速率为 τ 。我们对学习率 $\lambda_a, \lambda_c, \lambda_\alpha$ 在 $\{10^{-4}, 3 \times 10^{-4}\}$ ，到 $\tau \{0.01, 0.005\}$ 范围内、批大小 $\{64, 128, 256\}$ 以及每次演员、评论家和温度更新之间与环境交互的次数 $\{1, 4, 8\}$ 进行了超参数搜索。

E 算法细节

E.1 概要

我们在图 13 中展示了 PWIL 的一个示例概要。

Start episode.



End episode.

图 13: PWIL 示例流程。我们不再依赖动作。示例任务具有一个时间范围 $T = 2$ ，演示集包含 $D = 4$ 个元素。我们取 $f : c \mapsto \exp(-c)$ 。

E.2 运行时间

本节详细说明 PWIL 的运行时间。单步奖励计算包括计算当前观测（维度为 $|\mathcal{S}| + |\mathcal{A}|$ 的向量）与 D 个向量（专家观测）之间的距离，其复杂度为 $\mathcal{O}((|\mathcal{S}| + |\mathcal{A}|)D)$ 。下一步是获取这些距离的最小值（复杂度为 $\mathcal{O}(D)$ ），循环执行 $\lceil \frac{D}{T} \rceil$ 次（算法执行 while 循环的次数）。因此，单步奖励计算的复杂度为 $\mathcal{O}((|\mathcal{S}| + |\mathcal{A}|)D + \frac{D^2}{T})$ ，一个回合的奖励计算复杂度为 $\mathcal{O}((|\mathcal{S}| + |\mathcal{A}|)DT + D^2)$ 。