

基于 Sinkhorn 距离的模仿学习

Georgios Papagiannis^{1,*} and Yunpeng Li²

¹Imperial College London

²University of Surrey

g.papagiannis21@imperial.ac.uk, yunpeng.li@surrey.ac.uk

摘要。模仿学习算法已被解释为发散最小化问题的变体。比较专家与学习者之间占用测度的能力对于从示范中学习的有效性至关重要。本文通过将模仿学习表述为占用测度之间 Sinkhorn 距离的最小化，提出了可处理的解决方案。该表述结合了最优传输度量在比较非重叠分布方面的宝贵特性，以及在对抗学习特征空间中定义的余弦距离代价。这导致了一个高度判别性的评论家网络和最优传输计划，随后指导模仿学习。我们使用奖励度量和 Sinkhorn 距离度量在多个 MuJoCo 实验上评估了所提出的方法。有关实现和复现结果，请参阅以下仓库 <https://github.com/gpapagiannis/sinkhorn-imitation>。

1 引言

强化学习 (RL) 的最新发展使智能体能够在复杂任务上达到最先进的性能，从学习玩游戏 [33,38,18] 到灵巧操作 [24]，前提是提供了定义良好的奖励函数。然而，在实际场景中设计这样的奖励函数以封装期望目标通常并非易事。模仿学习 (IL) [20] 旨在通过专家示范来表述学习行为的问题，并在自动驾驶和手术任务自动化等多个应用领域显示出前景 [2,21,43,23,13]。模仿学习的主要方法包括行为克隆 (BC) 和逆强化学习 (IRL)。BC 通过将任务转化为监督回归问题来模仿专家行为 [23,30]。虽然实现简单，但由于协变量偏移和专家轨迹中的高样本相关性，它已知存在样本效率低和泛化性能差的问题 [27,26]。诸如数据集聚合 (DAgger) [26] 和用于增强机器人轨迹的扰动 (DART) [17] 等算法缓解了这一问题。然而，它们需要不断向专家查询正确的动作。逆强化学习则旨在恢复一个奖励函数，随后用于训练学习者的策略 [42,19]。IRL 方法已显示出显著更好的结果 [2,5,40,22,1,16]，包括在样本效率方面

* 在萨里大学就读期间完成的工作

2 G. Papagiannis 和 Y. Li

专家示范。然而，逆向强化学习本身是一个不适定问题——多个奖励函数可以刻画同一种特定的专家行为，因此需要施加额外的约束以恢复唯一解 [19,42,41]。此外，奖励恢复与策略训练之间的交替优化过程导致计算成本增加。

另一方面，对抗式模仿学习绕过了逆向强化学习中显式奖励推断的步骤，直接学习与专家策略相匹配的策略。生成对抗模仿学习（GAIL）[11] 通过基于生成对抗网络（GAN）的训练过程，最小化学习者与专家占用测度之间的 Jensen-Shannon（JS）散度。GAIL 是作为奖励正则化最大熵逆向强化学习框架 [42] 的一个变体而提出的，其中不同的奖励正则化项导致不同的模仿学习方法。GAIL 已被多种其他方法扩展，旨在通过离线强化学习 [31,4,36,15,14] 提高其在环境交互方面的样本效率。近期进展 [9] 提供了一个统一的概率视角，将不同的模仿学习方法解释为 f -散度最小化问题，并表明逆向强化学习方法的状态边缘匹配目标正是其性能优于行为克隆的主要原因。尽管这些方法在经验上取得了成功，但它们继承了 f -散度和对抗训练中的相同问题，例如基于 GAN 的训练中的训练不稳定性 [10]，以及 JS 散度和 Kullback-Leibler（KL）散度中的模式覆盖行为 [9,12]。

另一种方法是利用基于最优传输的度量来构建模仿学习问题。最优传输（Optimal Transport, OT）理论 [37] 提供了一种灵活而强大的工具，通过基于底层空间度量的分布耦合来比较概率分布。Wasserstein 对抗模仿学习（Wasserstein Adversarial Imitation Learning, WAIL）[39] 被提出用于最小化学习者与专家占用测度之间 Wasserstein 距离的对偶形式，类似于 Wasserstein GAN[3] 的训练。Wasserstein 距离的几何性质带来了训练中的数值稳定性和对不相交测度的鲁棒性。然而，对偶形式的解是难以处理的；在神经网络实现中需要近似来施加所需的 Lipschitz 条件 [28]。[7] 引入了原始 Wasserstein 模仿学习（Primal Wasserstein Imitation Learning, PWIL），它使用基于学习者与专家状态-动作分布之间 Wasserstein 距离上界推导出的奖励代理。虽然 PWIL 能实现成功的模仿，但尚不清楚它如何继承 OT 的理论性质，因为占用测度之间的传输映射是次优的，基于一种贪婪耦合策略，其近似误差难以量化。

本文提出 Sinkhorn 模仿学习（Sinkhorn Imitation Learning, SIL），这是一种基于最优传输的模仿学习的可解方案，通过利用占用测度的耦合和 Sinkhorn 距离 [6] 的计算效率，继承了 OT 的理论性质。我们的主要贡献包括：（i）提出并论证了一种模仿学习训练流程，该流程最小化专家与学习者占用测度之间的 Sinkhorn 距离；（ii）利用一组可训练且具有高判别力的最优传输基础度量推导出奖励代理；（iii）通过在 MuJoCo 模拟器 [35] 上的实验证明，SIL 获得了

与最先进方法相当的结果，在多个实验设置中，在常用的奖励度量和 Sinkhorn 距离方面均优于基线方法。本文其余部分组织如下。第 2 节提供本工作所需的背景知识。第 3 节介绍所提出的 Sinkhorn 模仿学习

(SIL) 框架。第 4 节详细介绍了在多个 MuJoCo 环境中评估 SIL 性能的实验。我们在第 5 节总结全文并讨论未来的研究方向。

2 背景

2.1 模仿学习

符号说明。我们考虑一个马尔可夫决策过程 (MDP)，其定义为一个 $\{\mathcal{S}, \mathcal{A}, \mathcal{P}, r, \gamma\}$ 元组，其中 $\mathcal{S}$ 是状态集合， $\mathcal{A}$ 是智能体可对环境采取的可能动作集合， $\mathcal{P} : \mathcal{S} \times \mathcal{A} \times \mathcal{S} \rightarrow [0, 1]$ 是转移概率矩阵， $r : \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ 是奖励函数， $\gamma \in (0, 1)$ 是折扣因子。智能体的行为由随机策略 $\pi : \mathcal{S} \rightarrow \text{Prob}(\mathcal{A})$ 定义， Π 是所有此类策略的集合。我们使用 $\pi_E, \pi \in \Pi$ 分别指代专家策略和学习者策略。策略 π 的性能测度定义为 $\mathcal{J} = \mathbb{E}_\pi[r(s, a)] = \mathbb{E}[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t) | \mathcal{P}, \pi]$ ，其中 $s_t \in \mathcal{S}$ 是智能体在时间步 t 观察到的状态。在不引起混淆的情况下，我们也使用 $r((s, a)_\pi)$ 来明确表示 $(s, a)_\pi \sim \pi \cdot \tau_E$ 和 τ_π 分别表示专家策略和学习者策略在与环境交互过程中采样的状态-动作对集合，也称为轨迹。由策略 π 通过环境交互生成的状态-动作对分布，也称为占用

measure $\rho_\pi : \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$, is defined as $\rho_\pi(s, a) = (1 - \gamma)\pi(a|s) \sum_{t=0}^{\infty} \gamma^t P_\pi[s_t = s]$

其中 $P_\pi[s_t = s]$ 表示在时间步 t 遵循策略 π 时状态为 s 的概率。

生成对抗模仿学习。Ho 和 Ermon[11] 通过引入奖励正则化器 $\psi(r) : \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ 扩展了最大熵逆强化学习框架：

$$\text{IRL}_\psi(\pi_E) := \arg \max_r -\psi(r) + \min_{\pi \in \Pi} (-\mathcal{H}^{\text{causal}}(\pi) - \mathbb{E}_\pi[r(s, a)]) + \mathbb{E}_{\pi_E}[r(s, a)], \quad (1)$$

where $\mathcal{H}^{\text{causal}}(\pi) := \mathbb{E}_{\rho_\pi}[-\log \pi(a|s)] / (1 - \gamma)$ [41]. The process of RL following 逆强化学习 (IRL) 可以表述为占用度量匹配问题 [11]：

$$\text{RL} \circ \text{IRL}_\psi(\pi_E) := \arg \min_{\pi \in \Pi} -\mathcal{H}^{\text{causal}}(\pi) + \psi^*(\rho_\pi - \rho_E), \quad (2)$$

其中 ψ^* 对应于奖励正则化项 $\psi(r)$ 的凸共轭。正则化最大熵逆强化学习框架绕过了代价高昂的奖励推断步骤，通过匹配专家的占用度量来学习如何模仿专家。奖励正则化项的不同实现方式会导致不同的模仿学习框架。特定正则化项的选择产生了生成对抗模仿学习 (GAIL) 框架，该框架最小化学习者与专家占用度量之间的 Jensen-Shannon 散度 [11]。

4 G. Papagiannis 和 Y. Li

f-散度最大熵逆强化学习。最近，Ghasemipour 等人 [9] 证明，训练学习者策略 π 以最小化两个占用度量之间的距离，可以推广为最小化 ρ_E 与 ρ_π 之间的任意 f-散度，记为 $D_f(\rho_E \parallel \rho_\pi)$ 。f 的不同选择会产生不同的散度最小化模仿学习算法 [9]，并可计算为：

$$\max_{T_\omega} \mathbb{E}_{(s,a) \sim \rho_E} [T_\omega(s, a)] - \mathbb{E}_{(s,a) \sim \rho_\pi} [f^*(T_\omega(s, a))], \quad (3)$$

其中 $T_\omega : \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ 和 f^* 是所选 f-散度的凸共轭。学习者策略根据奖励代理 $f^*(T_\omega(s, a))$ 进行优化。

2.2 最优传输

尽管散度最小化方法在经验上取得了成功，但在高维情况下仍难以评估 [34]，原因在于对不同超参数的敏感性以及训练难度取决于所评估的分布 [28]。最优传输（OT）理论 [37] 通过考虑底层度量空间，提供了比较退化分布的有效方法。设 $P_k(I)$ 为波兰度量空间 (I, d) 上具有有限 k 阶矩的 Borel 概率测度集合。给定两个概率测度 $p, q \in P_k(I)$ ， k -Wasserstein 度量定义为 [37]：

$$\mathcal{W}_k(p, q)_c = \left(\inf_{\zeta \in \Omega(p, q)} \int_I c(x, y)^k d\zeta(x, y) \right)^{\frac{1}{k}}, \quad (4)$$

其中 $\Omega(p, q)$ 表示边缘分布分别为 p 和 q 的联合概率分布集合。 $c(x, y)$ 表示将样本 $x \sim p$ 传输到 $y \sim q$ 的代价。使总传输代价最小的联合分布 ζ 称为最优传输计划。

辛克霍恩距离（Sinkhorn Distances）。方程（4）的解在实际中对于高维分布通常难以计算。卡图里（Cuturi）[6] 提出了最优传输公式的正则化形式，能够高效计算瓦瑟斯坦度量（Wasserstein metric）。 p 与 q 之间的辛克霍恩距离 $\mathcal{W}_s^\beta(p, q)_c$ 定义为：

$$\mathcal{W}_s^\beta(p, q)_c = \inf_{\zeta_\beta \in \Omega_\beta(p, q)} \mathbb{E}_{x, y \sim \zeta_\beta} [c(x, y)], \quad (5)$$

其中 $\Omega_\beta(p, q)$ 表示 $\Omega(p, q)$ 中所有熵至少为 $\mathcal{H}(p) + \mathcal{H}(q) - \beta$ 的联合分布集合， $\mathcal{H}(\cdot)$ 计算分布的熵。该距离在两个分布 p 和 q 上评估，在对抗模仿学习（adversarial IL）背景下，它们分别对应学习者和专家策略的状态-动作分布。

3 SIL：辛克霍恩模仿学习（Sinkhorn Imitation Learning）

我们考虑训练学习者策略 π 以模仿专家的问题，通过匹配其状态-动作分布 ρ_E ，以最小化它们的辛克霍恩距离。为了

促进学习流程的开发，我们首先讨论如何使用辛克霍恩距离评估占用测度 (occupancy measures) 之间的相似性。考虑学习者 π 与环境交互并生成一条状态-动作对轨迹 $\tau_\pi \sim \pi$ ，该轨迹表征其占用测度。专家演示轨迹 $\tau_E \sim \pi_E$ 也可作为专家轨迹使用。 τ_π 与 τ_E 样本之间的最优传输计划 ζ_β 可以通过辛克霍恩算法 [6] 获得。根据方程 (5)，我们可以如下评估 τ_π 与 τ_E 的辛克霍恩距离：

$$\mathcal{W}_s^\beta(\tau_\pi, \tau_E)_c = \sum_{(s,a)_\pi \in \tau_\pi} \sum_{(s,a)_{\pi_E} \in \tau_E} c((s,a)_\pi, (s,a)_{\pi_E}) \zeta_\beta((s,a)_\pi, (s,a)_{\pi_E}). \quad (6)$$

奖励代理 (Reward Proxy)。我们现在引入一个适合训练学习者策略的奖励代理， $(\tau_\pi, \tau_E)_c$ 该策略最小化 $\mathcal{W}_s^\beta$ 以匹配专家的占用测度。

学习者轨迹中每个样本 $(s,a)_\pi$ 的奖励函数 $v_c((s,a)_\pi)$ 定义为：

$$v_c((s,a)_\pi) := - \sum_{(s,a)_{\pi_E} \in \tau_E} c((s,a)_\pi, (s,a)_{\pi_E}) \zeta_\beta((s,a)_\pi, (s,a)_{\pi_E}). \quad (7)$$

在 $r((s,a)_\pi) := v_c((s,a)_\pi)$ 下，学习者策略 $\mathcal{J} = \mathbb{E}_\pi[r((s,a)_\pi)]$ 的优化目标对应于最小化式 (6) 中定义的学习者与专家轨迹之间的辛克霍恩距离。因此，通过使用奖励 $v_c((s,a)_\pi)$ 最大化优化目标 $\mathcal{J}$ ，学习者被训练以最小化学习者与专家示范者占用测度之间的辛克霍恩距离。

对抗性奖励代理。式 (7) 中指定的奖励只有在学习者生成完整轨迹后才能获得。最优传输 $\text{plan } \zeta_\beta((s,a)_\pi, (s,a)_{\pi_E})$

然后根据 τ_π 和 τ_E 中出现的样本对每个样本 $(s,a)_\pi \in \tau_\pi$ 的传输代价进行加权。 $v_c((s,a)_\pi)$ 对 τ_π 和 τ_E 中所有状态-动作对的依赖可能导致同一状态-动作对根据其采样轨迹的不同而被赋予显著不同的奖励。这种依赖可能导致最大化优化目标 $\mathcal{J}$ （等价于最小化学习者与专家占用测度之间的辛克霍恩距离）变得困难。第 4 节的消融实验提供了经验证据。为了向学习者策略提供判别信号并辅助优化过程，我们考虑对抗性地训练一个批评者，通过增加非专家状态-动作对到专家分布的传输代价来惩罚它们，灵感来自 OT-GAN 框架 [29] 中对抗性训练的传输基础度量。由 w 参数化的批评者 $c_w((s,a)_\pi, (s,a)_{\pi_E})$ 定义如下：

$$c_w((s,a)_\pi, (s,a)_{\pi_E}) = 1 - \frac{f_w((s,a)_\pi) \cdot f_w((s,a)_{\pi_E})}{\|f_w((s,a)_\pi)\|_2 \|f_w((s,a)_{\pi_E})\|_2}, \quad (8)$$

其中 $\cdot$ 表示两个向量之间的内积。 $f_w(\cdot) : \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}^d$ 将环境的观测空间 $\mathcal{S} \times \mathcal{A}$ 映射到对抗性学习的特征空间

Algorithm 1: Sinkhorn imitation learning (SIL)

-
- Input:** Set of expert trajectories $\{\tau_E\} \sim \pi_E$, Sinkhorn regularization parameter β , initial learner’s policy parameters θ_0 , initial critic network parameters w_0 , number of training iterations K
- 1: **for** iteration $k = 0$ to K **do**
 - 2: Sample a set of trajectories $\{\tau_{\pi_{\theta_k}}\}_k \sim \pi_{\theta_k}$.
 - 3: Create a set of trajectory pairs $\{(\tau_{\pi_{\theta_k}}, \tau_E)\}_k$ by randomly matching trajectories from the learner’s set to the expert’s.
 - 4: For each pair in $\{(\tau_{\pi_{\theta_k}}, \tau_E)\}_k$, calculate $\mathcal{W}_s^\beta(\tau_{\pi_{\theta_k}}, \tau_E)_{c_w}$ using the Sinkhorn algorithm (Equation (5)) and transport cost as in Equation (8), in order to update the reward proxy $v_{c_{w_k}}((s, a)_{\pi_{\theta_k}})$ for each state action pair.
 - 5: Update w_k to maximize $\mathcal{W}_s^\beta(\tau_{\pi_{\theta_k}}, \tau_E)_{c_w}$ using gradient ascent with the gradient:

$$\nabla_{w_k} \frac{1}{m} \sum_{\{(\tau_{\pi_{\theta_k}}, \tau_E)\}_k} \mathcal{W}_s^\beta(\tau_{\pi_{\theta_k}}, \tau_E)_{c_w}, \quad (10)$$

where m is the number of trajectory pairs.

- 6: Update policy parameter θ_k using TRPO and reward $v_{c_{w_k}}((s, a)_{\pi_{\theta_k}})$ updated in Step 4.
- 7: **end for**

Output: Learned policy π_{θ_k} .

$\mathbb{R}^d$ 其中 d 是特征维度。通过将式 (7) 中的传输代价 $c(\cdot, \cdot)$ 替换为由式 (8) 定义的 $c_w(\cdot, \cdot)$ ，得到对抗性奖励代理 $v_{c_w}((s, a)_\pi)$ 。SIL 通过求解以下极小极大优化问题来学习 π ：

$$\arg \min_{\pi} \max_w \mathcal{W}_s^\beta(\rho_\pi, \rho_E)_{c_w}. \quad (9)$$

备注 1。对于 SIL，运输代价的对抗训练部分并不像 GAIL[11] 和 WAIL[39] 那样是距离度量近似过程的一部分。Sinkhorn 距离直接通过 Sinkhorn 迭代过程 [6] 计算，其中运输代价由方程 (8) 定义。

算法。所提出的 Sinkhorn 模仿学习 (SIL) 框架的伪代码在算法 1 中给出。在每次迭代中，我们随机将学习器生成的每条轨迹与专家的一条轨迹匹配，并计算它们之间的 Sinkhorn 距离。这种实现选择的原因是为了在演示数量可能增加的情况下保持恒定的计算复杂度。然后，我们交替进行一步更新评论家网络 c_w 以最大化学习器与专家轨迹之间的 Sinkhorn 距离，以及一步策略更新以最小化使用学习到的奖励代理的占用测度之间的距离。由于 SIL 依赖完整的环境轨迹来计算 Sinkhorn 距离，它本质上是一种在线策略方法。因此，在我们的实验中，我们使用信赖域策略优化 (TRPO) [32] 来训练模仿策略。

3.1 与正则化最大熵逆强化学习的联系。

我们现在展示在给定特定 $\psi(r)$ 选择的情况下，SIL 如何被解释为正则化最大熵逆强化学习框架 [11] 的一种变体。

定义 1。 考虑学习者的策略和专家演示，以及它们诱导的占用测度 ρ_π 和 ρ_E 。我们定义以下奖励正则化项：

$$\psi_{\mathcal{W}}(r) := -\mathcal{W}_s^\beta(\rho_\pi, \rho_E)_{c_w} + \mathbb{E}_{\rho_\pi}[r(s, a)] - \mathbb{E}_{\rho_E}[r(s, a)] . \quad (11)$$

命题 1。 方程 (11) 中定义的奖励正则化器 $\psi_{\mathcal{W}}(r)$ 导致熵正则化的最大熵逆强化学习算法。当 $r((s, a)_\pi) = v_{c_w}((s, a)_\pi)$ 时，

$$RL \circ IRL_{\psi_{\mathcal{W}}}(\pi_E) = \arg \min_{\pi \in \Pi} -\mathcal{H}^{causal}(\pi) + \sup_w \mathcal{W}_s^\beta(\rho_\pi, \rho_E)_{c_w} . \quad (12)$$

方程 (12) 对应于更新评论家网络以最大化学习者与专家占用测度之间的辛克霍恩距离的过程，随后是寻找策略 π 以最小化该距离的过程。添加的项 $\mathcal{H}^{causal}(\pi)$ 被视为正则化参数。

证明。考虑有限状态-动作空间中可能的奖励集合 $\mathcal{R} := \{r : \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}\}$ ，如 [11] 和 [9] 中所述。联合状态-动作分布 ρ_π 和 ρ_E 表示为 $[0, 1]^{\mathcal{S} \times \mathcal{A}}$ 中的向量。定义 $\psi_{\mathcal{W}}(r) := -\mathcal{W}_s^\beta(\rho_\pi, \rho_E) + \mathbb{E}_{\rho_\pi}[r(s, a)] - \mathbb{E}_{\rho_E}[r(s, a)]$ ，其中 $\mathcal{W}_s^\beta(\rho_\pi, \rho_E)$ 是通过方程 (8) 中定义的传输成本 c_w 获得的。给定 $r(s, a) = v_{c_w}(s, a)$ ，并回顾函数 g 的凸共轭为 $g^*(y) = \sup_{x \in \text{dom}(g)} (y^T x - g(x))$ ，我们得到

$$\begin{aligned} \psi_{\mathcal{W}}^*(\rho_\pi - \rho_E) &= \sup_{r \in \mathcal{R}} [(\rho_\pi - \rho_E)^T r - \psi_{\mathcal{W}}(r)] = \sup_{r \in \mathcal{R}} \left[\sum_{\mathcal{S} \times \mathcal{A}} (\rho_\pi(s, a) - \rho_E(s, a)) \cdot r(s, a) \right. \\ &\quad \left. + \mathcal{W}_s^\beta(\rho_\pi, \rho_E) - \sum_{\mathcal{S} \times \mathcal{A}} (\rho_\pi(s, a) - \rho_E(s, a)) \cdot r(s, a) \right] = \\ &= \sup_{r \in \mathcal{R}} \mathcal{W}_s^\beta(\rho_\pi, \rho_E) = \sup_{v_{c_w} \in \mathcal{R}} \mathcal{W}_s^\beta(\rho_\pi, \rho_E) = \sup_w \mathcal{W}_s^\beta(\rho_\pi, \rho_E) . \end{aligned} \quad (13)$$

根据方程 (2)，

$$\begin{aligned} RL \circ IRL_{\psi}(\pi_E) &= \arg \min_{\pi \in \Pi} -\mathcal{H}^{causal}(\pi) + \psi_{\mathcal{W}}^*(\rho_\pi - \rho_E) \\ &= \arg \min_{\pi \in \Pi} -\mathcal{H}^{causal}(\pi) + \sup_w \mathcal{W}_s^\beta(\rho_\pi, \rho_E) . \end{aligned} \quad (14)$$

4 实验

为了实证评估辛克霍恩模仿学习算法，我们在 [9] 中研究的四个 MuJoCo [35] 环境（即 Hopper-v2、Walker2d-v2、Ant-v2 和 HalfCheetah-v2）以及 Humanoid-v2 环境中，将 SIL 与 BC 进行基准比较。由于 SIL 需要完整轨迹，因此它是一种同策略方法，因此还纳入了两种同策略对抗性模仿学习算法，即 GAIL [11] 和 AIRL [8]，作为基线。所有算法都根据通过环境交互获得的真实奖励度量，以及学习策略样本与专家演示之间的辛克霍恩距离进行评估。最初，我们使用 TRPO [32] 训练策略以获得专家性能。专家策略用于生成专家演示集。获得的专家策略的性能见表 1。为了研究 SIL 在从不同长度的轨迹集中学习时的鲁棒性，我们在 $\{2, 4, 8, 16, 32\}$ 的集合上训练算法，对于 Humanoid-v2 则在 $\{8, 16, 32\}$ 的集合上训练。所有轨迹都从随机偏移开始按 20 倍进行子采样，这是 [11,9,8] 中常见的做法。SIL、GAIL 和 AIRL 训练 250 次迭代，每次迭代允许大约 50,000 次环境交互。对于 Humanoid-v2，我们训练算法 350 次迭代。所有报告的结果对应于在 50 个回合上测试学习者策略后获得的性能度量。

环境专家性能	
Hopper-v2	3354.74 ± 1.87
HalfCheetah-v2	4726.53 ± 133.12
Walker2d-v2	3496.44 ± 8.79
Ant-v2	6303.36 ± 97.71
Humanoid-v2	5063.11 ± 337.50

表 1: 使用 TRPO 训练的提供示范的专家策略性能。

4.1 实现细节

对抗性评论家。评论家网络由 2 层多层感知机架构组成，每层 128 个单元，采用修正线性单元激活。对于每个实验，我们报告使用以下学习率 $\{0.0004, 0.0005, 0.0006, 0.0007, 0.0008, 0.0009\}$ 和输出维度 $\{5, 10, 30\}$ 训练评论家后的最佳性能结果。尽管评论家网络输出维度的不同选择可能在不同环境中为所提出的 SIL 算法带来更好的结果，但未进一步尝试微调评论家的输出。我们注意到，在大多数实验设置中，候选值池中评论家输出维度为 30 且学习率为 0.0005 时取得最佳结果。

奖励代理 (Reward Proxy)。在获得方程 (7) 和 (8) 中定义的 $\bar{v}_{c_w}$ 值后，我们将 $\bar{v}_{c_w}$ 加上 $\frac{1}{2}$ ，其中 L 是轨迹长度，并将奖励缩放 $\frac{1}{2}$ 。通过这样做，我们将 $\bar{v}_{c_w}$ 的范围设置为 $0 \leq \bar{v}_{c_w} \leq 4$ ，这被证明对需要生存奖励的环境有效。我们跟踪运行标准差以归一化奖励。

策略架构与训练。对于专家策略与学习者策略，本文采用相同的架构，即由两个各含 128 个单元并采用修正线性单元 (ReLU) 激活函数的双层多层感知机 (MLP) 组成。所有模仿学习算法均使用该架构。对于所有对抗式模仿学习算法，在获得专家性能的同时，本文使用信赖域策略优化 (Trust Region Policy Optimization) [32] 训练策略。最后，通过跟踪运行均值与标准差对环境观测进行归一化。

生成对抗模仿学习 (GAIL) 与对抗式逆强化学习 (AIRL)。为提升基准算法 GAIL 与 AIRL 在半猎豹-v2 (HalfCheetah-v2) 环境中的性能，本文使用行为克隆初始化策略。

计算资源。实验在一台配备英特尔

(R) 至强 (R) 金牌 5218 中央处理器 (2.3 GHz)、16GB 内存以及一块拥有 22GB 显存的 RTX 6000 图形卡的计算机上运行。

4.2 结果

辛克霍恩度量。我们首先使用辛克霍恩度量评估模仿学习方法之间的性能。由于我们的目标是评估模仿学习算法与专家占用测度的匹配程度，辛克霍恩距离为学习者与专家轨迹之间的相似性提供了一种有效的度量，相比之下，奖励度量在实际场景中往往不可用。我们报告在测试和评估期间使用固定的基于余弦距离的传输成本计算的占用测度之间的辛克霍恩距离：

$$c((s, a)_\pi, (s, a)_{\pi_E}) = 1 - \frac{[s, a]_\pi \cdot [s, a]_{\pi_E}}{\| [s, a]_\pi \|_2 \| [s, a]_{\pi_E} \|_2}, \quad (15)$$

其中 $[s, a]_\pi$ 表示策略 π 的状态-动作拼接向量， $\| \cdot \|_2$ 计算 L2 范数。表 2 报告了学习策略生成的轨迹与专家提供的演示之间评估的辛克霍恩度量。较小的辛克霍恩距离对应于学习者与专家生成轨迹之间更高的相似性。SIL、AIRL 和 GAIL 在大多数环境中获得了可比的性能。所提出的 SIL 算法在 HalfCheetah-v2 和 Ant-v2 环境的几乎所有实验中均优于基线，而 AIRL 在 Hopper-v2 和 Walker2d-v2 环境中取得了优越的性能。另一方面，当在 Hopper-v2、HalfCheetah-v2 和 Ant-v2 环境中仅提供 2 条专家轨迹时，GAIL 在辛克霍恩距离方面表现相对较差。正如预期的那样，行为克隆在几乎所有实验设置中均未能获得有竞争力的性能，尤其是在提供少量专家演示时。

10 G. Papagiannis 和 Y. Li




图 1: 在 SIL 训练期间, 通过从学习者策略中随机采样动作并使用固定的余弦传输成本评估的辛克霍恩距离的均值和标准差。

环境	轨迹数	BC	GAIL	AIRL	SIL
Hopper-v2	2	0.467 ± 0.009	0.098 ± 0.003	0.069 ± 0.001	0.073 ± 0.001
	4	0.408 ± 0.080	0.120 ± 0.010	0.066 ± 0.009	0.082 ± 0.010
	8	0.300 ± 0.029	0.074 ± 0.004	0.068 ± 0.006	0.071 ± 0.005
	16	0.182 ± 0.042	0.106 ± 0.008	0.074 ± 0.010	0.078 ± 0.012
	32	0.157 ± 0.084	0.071 ± 0.008	0.072 ± 0.009	0.089 ± 0.008
HalfCheetah-v2	2	1.043 ± 0.058	0.940 ± 0.181	0.577 ± 0.157	0.546 ± 0.138
	4	0.791 ± 0.096	0.633 ± 0.095	0.630 ± 0.091	0.620 ± 0.101
	8	0.841 ± 0.071	0.702 ± 0.095	0.708 ± 0.054	0.700 ± 0.052
	16	0.764 ± 0.166	0.670 ± 0.128	0.671 ± 0.112	0.688 ± 0.131
	32	0.717 ± 0.129	0.695 ± 0.113	0.699 ± 0.091	0.685 ± 0.083
Walker2d-v2	2	0.474 ± 0.023	0.067 ± 0.008	0.034 ± 0.005	0.080 ± 0.004
	4	0.694 ± 0.011	0.067 ± 0.006	0.036 ± 0.002	0.079 ± 0.005
	8	0.335 ± 0.004	0.069 ± 0.005	0.036 ± 0.003	0.063 ± 0.003
	16	0.199 ± 0.013	0.061 ± 0.004	0.037 ± 0.005	0.102 ± 0.007
	32	0.196 ± 0.098	0.052 ± 0.003	0.042 ± 0.004	0.147 ± 0.003
Ant-v2	2	0.843 ± 0.033	0.344 ± 0.068	0.164 ± 0.006	0.158 ± 0.008
	4	0.684 ± 0.159	0.165 ± 0.119	0.163 ± 0.008	0.157 ± 0.014
	8	0.996 ± 0.029	0.159 ± 0.016	0.164 ± 0.019	0.155 ± 0.012
	16	0.724 ± 0.149	0.225 ± 0.106	0.173 ± 0.062	0.165 ± 0.022
	32	0.452 ± 0.094	0.176 ± 0.029	0.172 ± 0.020	0.173 ± 0.018
Humanoid-v2	8	0.336 ± 0.089	0.386 ± 0.011	1.015 ± 0.015	0.379 ± 0.296
	16	0.290 ± 0.086	0.428 ± 0.027	1.034 ± 0.017	0.182 ± 0.011
	32	0.182 ± 0.028	0.162 ± 0.144	1.026 ± 0.015	0.250 ± 0.180

表 2: BC、GAIL、AIRL 和 SIL 的专家演示与模仿者策略样本之间辛克霍恩距离的均值和标准差。固定的余弦传输成本仅用于评估（距离越小表示性能越好）。

此外, 当提供 8 条和 16 条轨迹时, SIL 在 Humanoid-v2 环境中优于 GAIL 和 AIRL, 其中 SIL 在专家演示和环境交互方面均表现出显著提高的样本效率。

环境	轨迹数	BC	GAIL	AIRL	SIL
Hopper-v2	2	391.38 $\pm$ 42.98	3341.27 $\pm$ 38.96	3353.33 $\pm$ 2.05	3376.70 $\pm$ 2.45
	4	659.51 $\pm$ 166.32	3206.85 $\pm$ 1.56	3353.75 $\pm$ 1.67	3325.66 $\pm$ 4.24
	8	1094.39 $\pm$ 145.93	3216.93 $\pm$ 3.08	3369.17 $\pm$ 3.04	3335.31 $\pm$ 2.66
	16	2003.71 $\pm$ 655.85	3380.97 $\pm$ 2.16	3338.07 $\pm$ 2.14	3376.55 $\pm$ 2.65
	32	2330.82 $\pm$ 1013.71	3333.93 $\pm$ 1.47	3361.56 $\pm$ 1.93	3326.52 $\pm$ 3.62
HalfCheetah-v2	2	-60.80 $\pm$ 23.12	764.91 $\pm$ 546.47	4467.83 $\pm$ 61.13	4664.65 $\pm$ 91.73
	4	1018.68 $\pm$ 236.13	5183.67 $\pm$ 118.74	4578.84 $\pm$ 102.92	4505.88 $\pm$ 130.50
	8	1590.73 $\pm$ 279.05	4902.46 $\pm$ 721.43	4686.22 $\pm$ 147.89	4818.82 $\pm$ 251.27
	16	2434.30 $\pm$ 733.29	4519.49 $\pm$ 157.99	4783.79 $\pm$ 197.27	4492.37 $\pm$ 134.35
	32	3598.98 $\pm$ 558.70	4661.17 $\pm$ 147.21	4633.48 $\pm$ 116.89	4795.68 $\pm$ 191.90
Walker2d-v2	2	591.92 $\pm$ 32.77	3509.37 $\pm$ 8.08	3497.80 $\pm$ 9.64	3566.32 $\pm$ 16.11
	4	314.77 $\pm$ 9.21	3537.63 $\pm$ 4.14	3496.61 $\pm$ 10.94	3523.73 $\pm$ 21.91
	8	808.37 $\pm$ 5.28	3394.15 $\pm$ 4.74	3488.68 $\pm$ 10.67	3420.13 $\pm$ 16.38
	16	1281.80 $\pm$ 81.11	3444.96 $\pm$ 23.99	3459.84 $\pm$ 8.25	3557.51 $\pm$ 11.67
	32	1804.74 $\pm$ 1154.36	3427.61 $\pm$ 9.79	3495.04 $\pm$ 17.18	3203.32 $\pm$ 23.65
Ant-v2	2	845.14 $\pm$ 172.37	3443.87 $\pm$ 716.61	5190.89 $\pm$ 67.94	4981.70 $\pm$ 50.89
	4	897.54 $\pm$ 2.14	4912.92 $\pm$ 606.99	5182.42 $\pm$ 65.70	5020.71 $\pm$ 89.74
	8	991.92 $\pm$ 2.92	5112.21 $\pm$ 102.23	5083.30 $\pm$ 77.48	5112.55 $\pm$ 62.87
	16	1014.14 $\pm$ 447.66	4854.87 $\pm$ 895.63	5034.80 $\pm$ 331.64	4935.33 $\pm$ 87.15
	32	2197.20 $\pm$ 487.00	5009.60 $\pm$ 247.43	5013.36 $\pm$ 119.12	4581.27 $\pm$ 123.75
Humanoid-v2	8	1462.47 $\pm$ 1139.19	1249.26 $\pm$ 187.71	3897.47 $\pm$ 1047.03	4456.09 $\pm$ 2707.92
	16	2100.93 $\pm$ 1116.79	496.11 $\pm$ 113.28	4396.01 $\pm$ 433.63	6380.37 $\pm$ 40.35
	32	4807.86 $\pm$ 1903.08	6252.73 $\pm$ 570.72	1884.92 $\pm$ 764.89	5593.19 $\pm$ 1967.86

表 3: BC、GAIL、AIRL 和 SIL 模仿策略在奖励度量性能上的均值与标准差。

在 Humanoid-v2 环境中使用 32 条轨迹训练时, GAIL 优于其他方法。有趣的是, 在 Humanoid-v2 环境中仅提供 8 条轨迹时, BC 在辛克霍恩距离上取得了更优的性能, 但如表 3 所示, 其在奖励度量上的性能较低。

奖励度量。为了更好地理解辛克霍恩距离度量下的性能变化如何转化为真实奖励, 表 3 展示了与表 2 相同实验中学习策略所获得的奖励。虽然所有对抗性模仿学习算法与专家策略相比都表现出相似的奖励值, 但我们观察到在 Ant-v2 上, SIL 通常比 AIRL 获得更低的奖励。此外, 在 Walker2d-v2 上, AIRL 获得的奖励低于 SIL 和 GAIL。然而, 如表 2 所示, 当使用辛克霍恩距离评估时, SIL 和 AIRL 在这些环境中均取得了更优的性能。结果表明, 使用真实的相似性度量 (如辛克霍恩距离) 来评估模仿学习算法的性能可能更可靠, 因为我们的目标是匹配状态-动作分布。

训练稳定性。表 2 显示, SIL 在持续最小化辛克霍恩距离的同时, 对专家演示长度的变化具有鲁棒性。图 1 描绘了

12 G. Papagiannis 和 Y. Li




图 2: 消融实验。在训练 SIL 过程中, 针对三组不同数量的轨迹, Sinkhorn 距离的均值和标准差。评论家网络的更新已被替换为方程 (15) 中定义的固定余弦传输代价。

Environments	Metric	2	8	32
Hopper-v2	Reward	264.72 ± 1.28	520.88 ± 29.83	9.44 ± 0.31
	Sinkhorn	0.036 ± 0.007	0.552 ± 0.008	0.777 ± 0.007
HalfCheetah-v2	Reward	-1643.98 ± 198.31	-844.52 ± 267.42	-1220.92 ± 217.86
	Sinkhorn	0.670 ± 0.141	0.841 ± 0.035	0.424 ± 0.031
Walker2d-v2	Reward	60.64 ± 7.92	-2.39 ± 14.05	-11.38 ± 1.22
	Sinkhorn	0.538 ± 0.006	0.487 ± 0.005	0.466 ± 0.009
Ant-v2	Reward	1482.03 ± 480.99	607.87 ± 87.09	114.22 ± 123.24
	Sinkhorn	0.398 ± 0.090	0.419 ± 0.025	0.424 ± 0.031
		8	16	32
Humanoid-v2	Reward	447.87 ± 31.26	505.47 ± 67.62	335.48 ± 65.14
	Sinkhorn	0.760 ± 0.011	0.789 ± 0.013	0.835 ± 0.012

表 4: 使用方程 (15) 中定义的固定余弦传输代价重新训练 SIL 后, 奖励和 Sinkhorn 度量性能的均值和标准差。

在 SIL 训练过程中, 学习者与专家占用测度之间 Sinkhorn 距离的演变。尽管在 Humanoid-v2 环境中使用 2 条或 32 条专家轨迹时 Walker2d-v2 上观察到训练不稳定, SIL 仍成功学会模仿专家演示者。我们推测, 在这些设置下, 通过进一步超参数调优 (如第 5 节所讨论) 可以提高训练稳定性, 这留作未来工作。SIL 的训练稳定性在 Hopper-v2、Ant-v2 和 HalfCheetah-v2 环境中是明显的。

消融实验。 为了研究使用固定传输代价最小化占用测度之间 Sinkhorn 距离的效果, 我们在 Hopper-v2、HalfCheetah-v2、Walker2d-v2 和 Ant-v2 环境中使用 $\{2, 8, 32\}$ 组轨迹重复实验。对于 Humanoid-v2, 我们在 $\{8, 16, 32\}$ 组上进行实验。在此消融实验中, 我们不再在对抗学习特征空间中训练评论家网络, 而是根据方程 (7) 分配一个奖励代理, 该代理使用方程 (15) 中引入的固定余弦传输代价。

图 2 描绘了在将评论家网络的对抗目标替换为固定传输代价后，SIL 训练过程中占用测度之间 Sinkhorn 距离的演变。虽然训练过程更稳定，但在 Sinkhorn 距离度量（图 1 和图 2）和奖励度量（见表 4）方面均未能取得良好性能。结果表明，评论家网络的训练目标是所提算法的关键部分，它为学习者策略提供了足够强的信号以匹配专家的状态-动作分布。

5 结论

本文提出了辛克霍恩模仿学习（Sinkhorn Imitation Learning, SIL），一种基于最优传输的模仿学习解决方案，通过将专家状态-动作分布匹配问题形式化为最小化其辛克霍恩距离。我们利用一个对抗训练的判别器，将状态-动作观测映射到对抗学习的特征空间。判别器的使用为学习者策略提供了判别信号，以促进对专家示范者行为的模仿。在 5 个 MuJoCo 环境上的实验表明，SIL 与基线方法相比表现出具有竞争力的性能。辛克霍恩模仿学习框架可以在多个方向上扩展，以解决当前的局限性，我们计划在未来工作中进行研究。目前，SIL 的公式使其仅兼容在线策略强化学习方法，因为计算辛克霍恩距离需要完整的轨迹。虽然与其他在线策略对抗模仿学习基准相比，SIL 是高效的，但与离线策略对抗模仿学习方法相比，它仍需要更多的环境交互来学习。因此，将 SIL 扩展为兼容离线策略强化学习算法是一个有趣的未来方向，与先前工作 [7,14,15,25] 一致，以产生一种既继承最优传输理论优势又具有样本效率的方法。此外，在所有研究的实验中，SIL 的性能是在固定判别器网络结构下报告的。因此，网络架构在引导模仿学习中的作用尚不清楚。研究不同判别器网络架构对训练稳定性和计算效率的影响，以及其与状态-动作空间维度的关系，将具有实际意义。另一个有趣的研究领域是扩展当前框架，在构建最优传输耦合及随后的奖励代理时纳入轨迹的时间依赖性。我们预计这将是提高基于最优传输的对抗模仿学习框架的样本效率和泛化性能的一个有前景的方向。

参考文献

1. Abbeel, P., Dolgov, D., Ng, A.Y., Thrun, S.: Apprenticeship learning for motion planning with application to parking lot navigation. In: Proc. IEEE/RSJ International Conference on Intelligent Robots and Systems. pp. 1083–1090 (2008)
2. Abbeel, P., Coates, A., Ng, A.Y.: Autonomous helicopter aerobatics through apprenticeship learning. The International Journal of Robotics Research **29**(13), 1608–1639 (2010)

3. Arjovsky, M., Chintala, S., Bottou, L.: Wasserstein generative adversarial networks. In: Proc. International Conference on Machine Learning (ICML). pp. 214–223. Sydney, Australia (2017)
4. Blondé, L., Kalousis, A.: Sample-efficient imitation learning via generative adversarial nets. In: Proc. International Conference on Artificial Intelligence and Statistics (AISTATS). Okinawa, Japan (2019)
5. Coates, A., Abbeel, P., Ng, A.Y.: Learning for control from multiple demonstrations. In: Proc. International Conference on Machine Learning (ICML). p. 144–151. Helsinki, Finland (2008)
6. Cuturi, M.: Sinkhorn distances: Lightspeed computation of optimal transport. In: Proc. Advances in Neural Information Processing Systems (NeurIPS). pp. 2292–2300. Lake Tahoe, Nevada, USA (2013)
7. Dadashi, R., Hussenot, L., Geist, M., Pietquin, O.: Primal wasserstein imitation learning. In: Proc. International Conference on Learning Representations (ICLR) (2021)
8. Fu, J., Luo, K., Levine, S.: Learning robust rewards with adversarial inverse reinforcement learning. In: Proc. International Conference on Learning Representations (ICLR). Vancouver, Canada (2018)
9. Ghasemipour, S.K.S., Zemel, R., Gu, S.: A divergence minimization perspective on imitation learning methods. In: Proc. Conference on Robot Learning (CoRL). Osaka, Japan (2019)
10. Goodfellow, I., et al.: Generative adversarial nets. In: Proc. Advances in Neural Information Processing Systems (NeurIPS). pp. 2672–2680. Montréal, Canada (2014)
11. Ho, J., Ermon, S.: Generative adversarial imitation learning. In: Proc. Advances in Neural Information Processing Systems (NeurIPS). pp. 4565–4573. Barcelona, Spain (2016)
12. Ke, L., Barnes, M., Sun, W., Lee, G., Choudhury, S., Srinivasa, S.S.: Imitation learning as f-divergence minimization. arXiv:1905.12888 (2019)
13. Kober, J., Peters, J.: Learning motor primitives for robotics. In: Proc. IEEE International Conference on Robotics and Automation. pp. 2112–2118. Kobe, Japan (2009)
14. Kostrikov, I., Agrawal, K.K., Levine, S., Tompson, J.: Discriminator-actor-critic: Addressing sample inefficiency and reward bias in adversarial imitation learning. In: Proc. International Conference on Learning Representations (ICLR). New Orleans, USA (2019)
15. Kostrikov, I., Nachum, O., Tompson, J.: Imitation learning via off-policy distribution matching. In: Proc. International Conference on Learning Representations (ICLR) (2020)
16. Kuderer, M., Kretschmar, H., Burgard, W.: Teaching mobile robots to cooperatively navigate in populated environments. In: Proc. IEEE/RSJ International Conference on Intelligent Robots and Systems. pp. 3138–3143 (2013)
17. Laskey, M., Lee, J., Fox, R., Dragan, A., Goldberg, K.: Dart: Noise injection for robust imitation learning. In: Proc. Conference on Robot Learning (CoRL). Mountain View, USA (2017)
18. Mnih, V., Kavukcuoglu, K., Silver, D., et al.: Human-level control through deep reinforcement learning. *Nature* **518**, 529–533 (2015)
19. Ng, A.Y., Russell, S.: Algorithms for inverse reinforcement learning. In: Proc. International Conference on Machine Learning (ICML). pp. 663–670. Stanford, CA, USA (2000)
20. Osa, T., Pajarinen, J., Neumann, G., Bagnell, J.A., Abbeel, P., Peters, J.: An Algorithmic Perspective on Imitation Learning. Now Foundations and Trends (2018)
21. Osa, T., Sugita, N., Mitsuishi, M.: Online trajectory planning in dynamic environments for surgical task automation. In: Proc. Robotics: Science and Systems. Berkley, CA, USA (2014)
22. Park, D., Noseworthy, M., Paul, R., Roy, S., Roy, N.: Inferring task goals and constraints using bayesian nonparametric inverse reinforcement learning. In: Proc. Conference on Robot Learning (CoRL). Osaka, Japan (2019)
23. Pomerleau, D.A.: Alvin: An autonomous land vehicle in a neural network. In: Proc. Advances in Neural Information Processing Systems (NeurIPS). pp. 305–313 (1989)

24. Rajeswaran, A., Kumar, V., Gupta, A., Vezzani, G., Schulman, J., Todorov, E., Levine, S.: Learning complex dexterous manipulation with deep reinforcement learning and demonstrations. In: Proc. Robotics: Science and Systems (RSS). Pittsburgh, Pennsylvania (2018)
25. Reddy, S., Dragan, A.D., Levine, S.: SQIL: imitation learning via reinforcement learning with sparse rewards. In: Proc. International Conference on Learning Representations (ICLR) (2020)
26. Ross, S., Gordon, G., Bagnell, J.: A reduction of imitation learning and structured prediction to no-regret online learning. In: Proc. Conference on Artificial Intelligence and Statistics. pp. 627–635. Fort Lauderdale, FL, USA (2011)
27. Ross, S., Bagnell, A.: Efficient reductions for imitation learning. In: Proc. International Conference on Artificial Intelligence and Statistics. pp. 661–668. Chia Laguna Resort, Sardinia, Italy (13–15 May 2010)
28. Salimans, T., Goodfellow, I., Zaremba, W., Cheung, V., Radford, A., Chen, X., Chen, X.: Improved techniques for training GANs. In: Proc. Advances in Neural Information Processing Systems (NeurIPS). pp. 2234–2242. Barcelona, Spain (2016)
29. Salimans, T., Zhang, H., Radford, A., Metaxas, D.N.: Improving GANs using optimal transport. In: Proc. International Conference on Learning Representation (ICLR). Vancouver, Canada (2018)
30. Sammut, C., Hurst, S., Kedzier, D., Michie, D.: Learning to fly. In: Proc. International Conference on Machine Learning (ICML). pp. 385–393. Aberdeen, Scotland, United Kingdom (1992)
31. Sasaki, F., Yohira, T., Kawaguchi, A.: Sample efficient imitation learning for continuous control. In: Proc. International Conference on Learning Representations (ICLR) (2019)
32. Schulman, J., Levine, S., Abbeel, P., Jordan, M., Moritz, P.: Trust region policy optimization. In: Proc. International Conference on Machine Learning (ICML). pp. 1889–1897. Lille, France (2015)
33. Silver, D., et al.: Mastering the game of go with deep neural networks and tree search. *Nature* **529**, 484–503 (2016)
34. Sriperumbudur, B.K., Gretton, A., Fukumizu, K., Lanckriet, G.R.G., Schölkopf, B.: A note on integral probability metrics and ϕ -divergences. arXiv:0901.2698 (2009)
35. Todorov, E., Erez, T., Tassa, Y.: Mujoco: A physics engine for model-based control. In: Proc. IEEE/RSJ International Conference on Intelligent Robots and Systems., pp. 5026–5033 (2012)
36. Torabi, F., Geiger, S., Warnell, G., Stone, P.: Sample-efficient adversarial imitation learning from observation. arXiv:1906.07374 (2019)
37. Villani, C.: Optimal Transport: old and new, vol. 338. Berlin, Germany: Springer Science & Business Media (2008)
38. Vinyals, O., et al.: Grandmaster level in StarCraft II using multi-agent reinforcement learning. *Nature* **575**, 350–354 (2019)
39. Xiao, H., Herman, M., Wagner, J., Ziesche, S., Etesami, J., Linh, T.H.: Wasserstein adversarial imitation learning. arXiv:1906.08113 (2019)
40. Zhu, Y., Wang, Z., Merel, J., Rusu, A.A., Erez, T., Cabi, S., Tunyasuvunakool, S., Kramár, J., Hadsell, R., de Freitas, N., Heess, N.: Reinforcement and imitation learning for diverse visuomotor skills. arXiv:1802.09564 (2018)
41. Ziebart, B., Bagnell, A.J.: Modeling interaction via the principle of maximum causal entropy. In: Proc. International Conference on Machine Learning (ICML). pp. 1255–1262. Haifa, Israel (2010)
42. Ziebart, B., Mass, A., Bagnell, A.J., Dey, A.K.: Maximum entropy inverse reinforcement learning. In: Proc. AAAI Conference on Artificial intelligence. pp. 1433–1438 (2008)
43. Zucker, M., Ratliff, N., Stolle, M., Chestnutt, J., Bagnell, J.A., Atkeson, C.G., Kuffner, J.: Optimization and learning for rough terrain legged locomotion. *The International Journal of Robotics Research* **30**(2), 175–191 (2011)