

# 用于仿真到现实领域自适应的仿射传输

Anton Mallasto<sup>\*,1</sup> Karol Arndt<sup>\*,2</sup> Markus Heinonen<sup>1</sup> Samuel Kaski<sup>1,3</sup> Ville Kyrki<sup>2</sup>

**摘要**——样本高效的领域自适应是机器人学中的一个开放问题。本文提出仿射传输——一种最优传输的变体，它通过仿射变换对源域和目标域之间状态转移分布的映射进行建模。首先，推导仿射传输框架；然后，通过普鲁克对齐扩展基本框架，以建模任意仿射变换。在多个 OpenAI Gym 仿真到仿真实验以及一个机器人击打冰球使其滑动并停在目标位置的仿真到现实领域自适应任务中评估了该方法。在每个实验中，评估了在每对动力学域之间迁移时的结果。结果表明，与使用原始、未自适应的动力学模型相比，仿射传输能显著降低模型自适应误差。

强化学习 (RL) 近期的成功推动了其在机器人学中日益广泛的应用 [1]。然而，在真实机器人数据上训练强化学习智能体成本高昂，原因在于设备磨损和运行速度缓慢。相反，策略通常在仿真环境中训练，这显著更便宜且更安全。遗憾的是，仿真环境无法完美模拟现实，例如，感官数据可能不同，系统动力学也可能不同。为弥合这一差距，仿真到现实迁移尝试利用真实世界数据来适应在仿真中训练的智能体。

领域自适应 [2]、[3] 是仿真到现实迁移的常用工具，其中在源域（参见仿真）上训练的模型被迁移到可用数据较少的目标域（参见真实机器人）[4]。近年来，最优传输

(OT) 已成为领域自适应中日益流行的工具 [5]、[6]、[7]。

最优传输通过将样本间的代价函数提升为两个分布之间的发散，为概率测度的研究提供了一个几何框架。这一提升通过学习一个传输计划（两个边缘分布的联合分布）来实现，该计划最小化将一个分布的质量传输到另一个分布的总代价。然后，传输计划可用于例如映射

从一个分布到另一个分布，并构建两个分布样本之间的关系。

最优传输在领域自适应中的应用依赖于所构建的关系：如果一个分布（源域）以最小代价转变为另一个分布（目标域），这种关系就告诉我们各个样本是如何变化的。例如，可以计算离散分布之间的传输计划，通过重心投影将源样本映射到目标，如 [5] 所做。这里的缺点是，为了映射新样本，需要求解一个优化问题。另一方面，可以直接学习分布之间的传输映射 [8]，这更接近本文所采用的方法。

我们提出仿射传输 (AT) 框架，通过考虑两个分布的正态近似之间的最优传输，简化了最优传输框架。这样，我们可以以闭式形式廉价地计算传输映射，并可直接应用于新样本。仿射传输与领域自适应中的相关性对齐方法密切相关，例如 CORAL[9]，其中计算线性变换以最小化协方差矩阵之间的 Frobenius 范数。实际上，这种变换将两个正态近似相互映射，但并非像仿射传输那样以最小总传输代价进行。Zhang 等人 [10] 更进一步，在再生核希尔伯特空间 (RKHS) 中使用最优传输方法进行协方差对齐。我们的工作将这种方法应用于仿真到真实环境。此外，本研究建立在 [10] 的基础上，将方法形式化为仿射传输，评估仿射传输与最优传输何时等价，并进一步提供传输后的源分布与目标分布接近程度的误差界。基于理论结果，我们还提供了一个评分函数，描述两个域在仿射差异上的接近程度。

贡献可总结如下：

- 本文将基于最优传输的相关性对齐形式化为仿射传输，并给出了最优传输与仿射传输等价的理论条件，同时提供了二者差异的上界。
- 本文将仿射传输应用于仿真到现实的任务中，相较于未进行迁移的情况，展现出明显的性能提升。

## 一、背景

**最优传输。** 设  $(X, d)$  为配备下半连续代价函数  $c: X \times X \rightarrow \mathbb{R}$  的度量空间

**预印本。** 进行中的工作。\* 同等贡献。本研究得到芬兰科学院基金 317020 和 328399 的支持。我们感谢阿尔托科学信息技术项目提供的计算资源。1 阿尔托大学计算机科学系，芬兰埃斯波 2 阿尔托大学电气工程与自动化系智能机器人组，芬兰埃斯波 3 曼彻斯特大学计算机科学系，英国曼彻斯特 first.last@aalto.fi

$\mathbb{R}_{\geq 0}$ ，例如欧氏距离，两个概率  $c(x, y) = \|x - y\|$ 。Then, 测度  $\nu_0, \nu_1 \in \mathcal{P}(X)$  之间的最优传输问题由康托罗维奇问题给出

$$\text{OT}_c(\nu_0, \nu_1) = \min_{\gamma \in \text{ADM}(\nu_0, \nu_1)} \mathbb{E}_{\gamma}[c], \quad (1)$$

其中  $\text{ADM}(\nu_0, \nu_1)$  为具有边缘分布  $\nu_0$  和  $\nu_1$  的联合概率集合， $\mathbb{E}_{\nu}[f]$  表示  $f$  在  $\nu$  下的期望值。使 (1) 式最小化的最优  $\gamma$  称为最优传输计划。记  $\mathcal{L}(X)$  为随机变量  $X$  的分布律，则最优传输问题可推广至随机变量  $X, Y$ ，形式为

$$\text{OT}_c(X, Y) \triangleq \text{OT}_c(\mathcal{L}(X), \mathcal{L}(Y)). \quad (2)$$

假设所考虑的测度中至少有一个是绝对连续的，则康托罗维奇问题等价于蒙日问题

$$\text{OT}_c(\mu, \nu) = \min_{T: T_{\#}\mu = \nu} \mathbb{E}_{X \sim \mu}[c(X, T(X))], \quad (3)$$

其中使目标函数最小化的  $T$  称为最优传输映射， $T_{\#}\mu$  表示前推测度，等价于  $T(X)$  的分布律，其中  $X \sim \mu$ 。

**瓦瑟斯坦距离 (Wasserstein distance)**。设  $X$  为  $\mathbb{R}^d$  上的随机变量，满足  $\mathbb{E}[\|X - x_0\|^2] < \infty$  对某个  $x_0 \in \mathbb{R}^d$  成立，因此对任意  $x \in \mathbb{R}^d$  也成立。我们将这类随机变量记为  $\mathcal{P}_2(\mathbb{R}^d)$ 。则  $X, Y \in \mathcal{P}_2(\mathbb{R}^d)$  之间的 2-瓦瑟斯坦距离  $W_2$  定义为

$$W_2(X, Y) = \text{OT}_{d^2}(X, Y)^{\frac{1}{2}}, \quad (4)$$

其中  $d(x, y) = \|x - y\|$ 。此情形下的最优传输映射由以下定理刻画：定理 1 (诺特-史密斯最优性准则 [11])：设。进一步假设  $T(x) = \nabla \phi(x)$  对某个凸函数成立， $X \in \mathcal{P}_2(\mathbb{R}^d)$  立，且  $T(X) \in \mathcal{P}_2(\mathbb{R}^d)$ 。则  $T$  是  $\mu$  与  $T_{\#}\mu$  之间的唯一最优传输映射。

在处理 2-瓦瑟斯坦情形时，我们可以不失一般性地假设分布已中心化，因为

$$W_2^2(X, Y) = W_2^2(X - \mathbb{E}[X], Y - \mathbb{E}[Y]) + \|\mathbb{E}[X] - \mathbb{E}[Y]\|^2, \quad (5)$$

将 2-瓦瑟斯坦距离分解为两个独立项：均值间的  $L^2$  距离与中心化测度间的 2-瓦瑟斯坦距离。此外，若  $X - \mathbb{E}[X]$  与  $Y - \mathbb{E}[Y]$  之间存在最优传输映射  $T'$ ，则

$$T(x) = T'(x - \mathbb{E}[X]) + \mathbb{E}[Y], \quad (6)$$

是  $X$  与  $Y$  之间的最优传输映射。

2-瓦瑟斯坦距离存在闭式解的罕见情形之一是两个多元高斯分布  $\nu_i = \mathcal{N}(\mu_i, \Sigma_i), i = 1, 2$  之间，其距离由 [12], [13], [14], [15] 给出

$$W_2^2(\nu_1, \nu_2) = \|\mu_1 - \mu_2\|^2 + \text{Tr}(\Sigma_1) + \text{Tr}(\Sigma_2) - 2\text{Tr}\left(\Sigma_2^{\frac{1}{2}}\Sigma_1\Sigma_2^{\frac{1}{2}}\right)^{\frac{1}{2}}. \quad (7)$$

此外， $\nu_1$  与  $\nu_2$  之间的最优传输映射由下式给出 affine map

$$F(x) = Ax + b, \quad A = \Sigma_2^{\frac{1}{2}}\left(\Sigma_2^{-\frac{1}{2}}\Sigma_1\Sigma_2^{-\frac{1}{2}}\right)^{-\frac{1}{2}}\Sigma_2^{\frac{1}{2}}, \quad (8) \\ b = \mu_2 - A\mu_1,$$

其中  $\Sigma^{\frac{1}{2}}$  表示矩阵平方根。当限制在高斯分布集合上时，2-瓦瑟斯坦距离源自黎曼度量 [16]。高斯分布对 2-瓦瑟斯坦距离的特殊性还源于以下定理。

定理 2 (盖尔布吕克界 [17])：设  $X, Y \in \mathcal{P}_2(\mathbb{R}^d)$  和  $N_X, N_Y$  为具有相同均值和协方差的正态近似。则，

$$W_2(N_X, N_Y) \leq W_2(X, Y). \quad (9)$$

**仿真到现实迁移。** 假设源域具有动力学模型  $g_s : \mathcal{S} \times \mathcal{A} \rightarrow \mathcal{S}$ ，将状态-动作对映射到下一状态，对应的目标域具有动力学模型  $g_t$ 。在典型设置中，源域由仿真给出，目标域由真实世界数据给出。然后，假设存在一个底层迁移映射，使得给定状态和动作对  $(s_i, a_i), i = 1, \dots, N$ ，

$$T^* T^*(s, a, g_s(s, a)) = g_t(s, a). \text{ Now,}$$

从两个域收集数据作为三元组集合

$X_s = \{(s_i, a_i, g_s(s_i, a_i))\}_{i=1}^N$ ，类似地对于  $X_t$ 。目标是利用这两个数据集推断  $T^*$ 。

**最优传输的局限性。** 当我们应用最优传输来推断映射  $T$  (实际上是在由  $X_t$  和  $X_s$  定义的经验测度之间) 时，由于最优传输的性质，出现了一些限制，由布伦尼尔分解定理形式化：定理 3 (布伦尼尔分解 [18])：设  $\Omega \subset \mathbb{R}^n$  为有界光滑域， $T : \Omega \rightarrow \mathbb{R}^n$  为不将正体积映射为零体积的博雷尔映射。则， $T$  唯一分解为

$$T = t \circ u, \quad (10)$$

其中  $u : \Omega \rightarrow \Omega$  是保体积的， $t = \nabla \psi$  是凸函数  $\psi : \mathbb{R}^n \rightarrow \mathbb{R}$  的梯度。

在线性世界中，这转化为矩阵的极分解：给定可逆矩阵  $A$ ，我们可以唯一地将其写为  $A = PU$ ，其中  $F$  是对称正定的， $U$  是正交的。

根据定理 1，对于 2-瓦瑟斯坦距离，最优传输映射恰为凸映射的梯度。因此，我们只能学习  $f$  在体积保持函数意义下的最优传输。

## 二、仿射传输

在下文中，我们定义仿射传输 (Affine Transport, AT) 框架，这是最优传输的一种简化形式，我们将把它应用于仿真到现实问题。其动机在于计算成本低、具有闭式解且易于实现，并能提供理论保证。

**仿射传输。** 用  $N_X$  表示随机变量  $X$  的正态近似。那么，源分布  $X$  和目标分布  $Y$  之间的仿射传输映射 (AT 映射)

$T_{\text{aff}}$  由  $N_X$  和  $N_Y$  之间的最优传输映射给出，即仿射变换

$$\begin{aligned} T_{\text{aff}}(x) &= Ax + b \\ A &= \Sigma(Y)^{\frac{1}{2}} \left( \Sigma(Y)^{\frac{1}{2}} \Sigma(X) \Sigma(Y)^{\frac{1}{2}} \right)^{-\frac{1}{2}} \Sigma(Y)^{\frac{1}{2}} \quad (11) \\ b &= \mu(Y) - A\mu(X), \end{aligned}$$

其中  $\Sigma(X)$  是协方差矩阵， $\mu(X)$  是均值。如果需要，我们将 AT 映射记为  $T_{\text{aff}}[X, Y]$  以强调源和目标。

**与最优传输的联系。** 自然，如果  $X$  和  $Y$  已经是高斯分布，则 AT 映射和最优传输映射完全相同。但还有其他 AT 与最优传输重合的情况吗？有，当  $Y$  是  $X$  的正半定仿射变换时。在下文中，我们考虑中心化分布和线性映射，但由于 (5) 和 (6)，结果可以扩展到非中心化情形，只需将线性映射替换为仿射映射。我们从 Knott-Smith 最优性准则的一个推论开始。

**推论 1：** 设  $X, Y \in \mathcal{P}_2(\mathbb{R}^d)$  为中心化的，并假设  $Y = TX$ ，其中  $T$  为半正定矩阵。则  $T$  是从  $X$  到  $Y$  的最优传输映射。

**证明：** 将定理 1 应用于凸  $\phi(x) = x^T T x$ ，其中  $T$  为半正定。 ■

下一个结果则陈述了仿射传输 (AT) 与最优传输 (OT) 何时一致。此外，它允许在  $X$  与  $Y$  相差一个仿射变换的条件下，利用正态近似以闭式形式计算任意  $X$  与  $Y$  之间的 2-瓦瑟斯坦距离。

**定理 4：** 设  $X, Y \in \mathcal{P}_2(\mathbb{R}^d)$  为中心化的，且  $Y = TX$  对于正定矩阵  $T$  成立。则  $T$  也是  $N_X$  与  $N_Y$  之间的最优传输映射，且  $W_2(N_X, N_Y) = W_2(X, Y)$ 。即  $\text{is}, T = T_{\text{aff}}[X, Y]$ 。

**证明：** 推论 1 指出  $T$  是一个最优传输映射，且

$$\Sigma(TN_X) = T\Sigma(X)T = \Sigma(Y). \quad (12)$$

因此， $TN_X = N_Y$ ，且由定理 1， $T$  是  $N_X$  与  $N_Y$  之间的最优传输映射。最后，我们计算

$$\begin{aligned} W_2^2(N_X, N_Y) &= \text{Tr}[\Sigma(X)] + \text{Tr}[T\Sigma(X)T] \\ &\quad - 2\text{Tr}[T^{\frac{1}{2}}\Sigma(X)T^{\frac{1}{2}}] \\ &= \arg \min_{T: T(X)=Y} \mathbb{E}_X[\|X - T(X)\|^2] \quad (13) \\ &= W_2^2(X, Y). \end{aligned}$$

**仿射传输的误差界。** 若  $X$  与  $Y$  之间的变换比仿射变换更复杂，那么  $T$  仿射  $X$  与  $Y$  的匹配程度如何？我们在下文回答此问题，首先对 2-瓦瑟斯坦距离之差进行界定

关于  $X, Y$  及其正态近似之间的 2-瓦瑟斯坦距离。

**命题 1：** 设  $X, Y \in \mathcal{P}_2(\mathbb{R}^d)$  和  $N_X, N_Y$  为其正态近似。则有以下界

$$|W_2(N_X, N_Y) - W_2(X, Y)| \leq \frac{2\text{Tr}[(\Sigma(X)\Sigma(Y))^{\frac{1}{2}}]}{\sqrt{\text{Tr}[\Sigma(X)] + \text{Tr}[\Sigma(Y)]}}. \quad (14)$$

**证明：** 由定理 2，可得  $W_2(N_X, N_Y) \leq$ 。另一方面， $W_2(X, Y)$

$$\begin{aligned} W_2^2(X, Y) &= \min_{\gamma \in \text{ADM}(X, Y)} \int_{\mathbb{R}^d \times \mathbb{R}^d} \|x - y\|^2 d\gamma(x, y) \\ &\leq \int_{\mathbb{R}^d \times \mathbb{R}^d} (\|x\|^2 + \|y\|^2) d\gamma(x, y) \quad (15) \\ &= \text{Tr}[\Sigma(X)] + \text{Tr}[\Sigma(Y)]. \end{aligned}$$

结合上述不等式，得到

$$\begin{aligned} |W_2(N_X, N_Y) - W_2(X, Y)| \\ \leq \left| \sqrt{\text{Tr}[\Sigma(X)] + \text{Tr}[\Sigma(Y)]} - W_2(N_X, N_Y) \right|. \quad (16) \end{aligned}$$

Let  $a = \text{Tr}[\Sigma(X)] + \text{Tr}[\Sigma(Y)]$ ，因此  $W_2^2(N_X, N_Y) = a - b$ ，where  $b = 2\text{Tr}[(\Sigma(X)\Sigma(Y))^{\frac{1}{2}}]$ 。Then the RHS of (16) can be written as

$$\left| \sqrt{a} - \sqrt{a-b} \right| = \frac{|a - (a-b)|}{\sqrt{a} + \sqrt{a-b}} \leq \frac{b}{\sqrt{a}}, \quad (17)$$

其中不等式由  $W_2(N_X, N_Y) = \sqrt{a-b}$  的正性推出。这便证明了该结论。 ■

**命题 1** 蕴含了随机变量正态近似的如下 2-瓦瑟斯坦界。

**推论 2：** 设  $X \in \mathcal{P}_2(\mathbb{R}^d)$  及  $N_X$  为其法线 approximation. Then

$$W_2(N_X, X) \leq \sqrt{2\text{Tr}[\Sigma(X)]^{\frac{1}{2}}}. \quad (18)$$

**证明：** 对  $X = X$  和  $Y = N_X$  应用命题 1。 ■

最后，我们给出 AT 的如下误差界，该界仅依赖于目标。

**命题 2：** 设  $X, Y \in \mathcal{P}_2(\mathbb{R}^d)$  和  $T$  为从  $X$  到  $Y$  的 AT 映射。则

$$W_2(T_{\text{aff}}X, Y) \leq \sqrt{2\text{Tr}[\Sigma(Y)]^{\frac{1}{2}}}. \quad (19)$$

**证明：** 通过直接计算

$$\begin{aligned} W_2^2(T_{\text{aff}}X, Y) &\leq \text{Tr}[\Sigma(T_{\text{aff}}X)] + \text{Tr}[\Sigma(Y)] \\ &= 2\text{Tr}[\Sigma(Y)]. \end{aligned} \quad (20)$$

**命题 2** 给出的界使我们能够定义如下亲和度得分

$$\rho_{\text{aff}}(X, Y) = 1 - \frac{W_2(T_{\text{aff}}X, Y)}{\sqrt{2\text{Tr}[\Sigma(Y)]^{\frac{1}{2}}}}, \quad (21)$$




图 1: 蓝色冰球在 `isotr_low_offc` 设置下模拟的仿真到现实迁移示意图。

描述  $Y$  与  $X$  的正定仿射变换之间的差异程度, 当  $X$  和  $Y$  相差一个仿射变换时,  $0 \leq \rho$  仿射  $(X, Y) \leq 1$ , 和  $\rho$  仿射  $(X, Y) = 1$ , 而当  $T$  仿射  $X$  和  $Y$  之间的最优传输计划为独立分布时,  $\rho$  仿射  $(X, Y) = 0$ 。

**用于领域自适应的仿射传输。** 现在, 给定源数据和目标数据  $X_s$  和  $X_t$ , 我们可以直接应用仿射传输并使用  $T$  仿射  $[X_s, X_t]$  作为迁移映射。然而, 如第一节所述, 这种方式只能学习到保体积测度下的底层迁移映射。

More concretely, if  $X_t = T^*(X_s)$ , where  $T^*(x) = A^*x + b^*$  是仿射的, 我们可以写出极分解  $A^* = PU$ 。如果正交矩阵

$U$  是单位矩阵, 则仿射传输恢复底层迁移映射  $A^*$ 。否则, 我们需要一种方法来考虑正交部分。这促使我们通过应用普罗克鲁斯特对齐 [19] 来“预处理”数据: 给定矩阵  $A, B$ , 找到正交矩阵  $R$  使得

$$R = \arg \min_{R: R^T R = I} \|RA - B\|. \quad (22)$$

在实践中  $R$  易于计算。令  $M = BA^T$  具有奇异值分解  $M = V_1 D V_2^T$ , 则  $R = V_1 V_2^T$ 。应用普罗克鲁斯特对齐和仿射传输得到的迁移学习方法总结在算法 1 中。注意, 尽管我们确实恢复了一对正定矩阵和正交矩阵, 但无法保证  $(T \text{ 仿射 }, R) = (P, U)$ , 即我们不一定恢复底层迁移映射的极分解。

---

#### Algorithm 1: Sim-to-Learn Transfer with AT

---

**Input** : Source  $X_s$ , target  $X_t$ . Matrices with columns of the form  $(s_i, a_i, g(s_i, a_i))$ .

**Output** : Transfer map  $T$ .

$V_1, D, V_2^T \leftarrow \text{SVD}(X_t, X_s^T)$ ;

$R \leftarrow V_1 V_2^T$ ;

$T' \leftarrow T_{\text{aff}}[RX_s, X_t]$ ;

$T \leftarrow T' \circ R$ ;

---




图 2: 用于评估的不同关节长度的蚂蚁 (a、b、c) 和跳跃者 (d、e、f) 环境

### III. 实验

#### A. 健身房环境

为了评估该方法对领域自适应的适用性, 我们使用了来自 OpenAI Gym 的 Hopper 和 HalfCheetah 环境 [20]。在这些环境中, 我们随机化每个连杆的质量和长度, 随机反转每个关节的方向, 并禁用随机关节。Hopper 的状态空间是 11 维的, 包含每个自由度的位置和速度 (3 个关节各自的旋转角度、整个系统的旋转以及 2 个平移), 动作空间是 3 维的, 由施加到每个关节的力矩组成。Ant 的状态空间结构相似, 具有 27 维状态空间和 8 维动作空间。两个状态空间都忽略了智能体在世界中的绝对位置 (Hopper 中的  $x$  位置以及 Ant 中的  $x$  和  $y$ ), 但包含沿这些轴的速度。

领域自适应是通过对各种环境参数应用随机化来完成的; 更具体地说, 我们随机化连杆质量、关节长度 (如图 2 所示), 并通过禁用或反转某些关节的方向。随机化范围见表 I。


该评估的结果 (使用 Hopper 和 Ant 环境) 如图 4 和图 3 所示。基于这些结果, 我们可以观察到, 使用仿射传输尽管简单, 却显著改善了状态预测性能, 其中最大的相对降低出现在反转域中。

#### B. 冰球


我们使用描述机器人手用棍子击打冰球、试图使冰球到达特定点的数据进行实验。我们有模拟数据  $X_{\text{sim}}$  和真实数据  $X_{\text{real}}$ , 它们由四元组  $(x, y, z_0, z_1)$  组成, 其中  $(x, y)$  是冰球的最终位置,  $(z_0, z_1)$  是编码动作的隐变量, 在模拟和真实情况下是相同的。在真实环境中, 我们使用两种不同的冰球, 一个蓝色的和一个红色的。在模拟情况下, 我们使用冰球

| Conditions | Relative size | Relative mass | Inverted joints | Disabled joints |
|------------|---------------|---------------|-----------------|-----------------|
| Normal     | 1             | 1             | None            | None            |
| Light      | 1             | 0.5           | None            | None            |
| Heavy      | 1             | 2.0           | None            | None            |
| Long       | 1.5           | 1             | None            | None            |
| Short      | 0.5           | 1             | None            | None            |
| Some inv.  | 1             | 1             | 2, 4, 6, ...    | None            |
| Inverted   | 1             | 1             | All             | None            |
| Some off   | 1             | 1             | None            | 2, 4, 6, ...    |


表 I: MuJoCo 环境的随机化范围



(a)




(b)




(c)


图 3: Ant 环境中的结果: 自适应前 (a)、 $\rho$  仿射值 (b) 以及自适应后的误差 (c)



(a)



(b)



(c)

图 4: Hopper 环境中的结果: 自适应前 (a)、 $\rho$  仿射值 (b) 以及自适应后的误差 (c)

具有 11 种不同的各向同性。在表 II 中, 我们展示了仿真数据与真实数据之间的先验 2-瓦瑟斯坦距离、仿射变换后数据与真实数据之间的 2-瓦瑟斯坦距离, 以及  $\rho$  仿射 ( $X_{\text{sim}}, X_{\text{real}}$ ) 得分。该变换如图 1 所示。

在图 5 中, 我们改变用于学习仿真到真实 (Sim2Real) 的真实和仿真数据点的数量, 这些数据点共享相同的动作。

传输映射  $T_{\text{aff}}$ 。

## 四、结论

本文引入了仿射传输, 并证明其可用于通过以下方式改进动力学模型性能:




图 5: 在不同仿真中, 随着用于计算仿射传输映射的真实数据点数量的变化, 仿射传输的逐点传输误差。阴影区域表示  $2\sigma$  偏差。

在机器人任务中的领域自适应, 无论是在仿真中还是从仿真到现实。该方法在低维状态和动作空间中表现良好, 例如冰球的情况; 然而, 在更高维空间中, 例如 Hopper 的情况, 它难以泛化到新数据。总体而言, 该方法可作为通过最优传输进行领域自适应进一步研究的基线。

虽然该方法成功地适应了动态模型, 但拟合的局部特性使其在强化学习中的使用可能存在问题。在这种情况下, 在离线数据集上拟合的传输映射, 潜在的分布偏移可能会将强化学习算法拉向在模型下看起来不错、但仅仅因为这些转移在自适应数据集中未被观察到的解。最简单的解决方案是在线更新传输映射; 然而, 这将试图拟合一个全局仿射模型, 该模型可能过于简单而无法捕捉。

在除最简单情况外的所有情形中, 源域与目标域之间的真实关系难以刻画。更精细的解决方案会尝试从一开始就防止分布偏移的发生; 在这种情况下, 离线强化学习 (Offline Reinforcement Learning) 背景下研究的方法可能被证明是有用的 [21], [22]。

#### 致谢

本工作得到了芬兰科学院的支持 (旗舰计划: 芬兰人工智能中心 FCAI, 以及资助项目 294238、319264、292334、334600、328400)。我们感谢阿尔托科学 IT 项目提供的计算资源。

#### 参考文献

- [1] J. Kober, J. A. Bagnell, and J. Peters, “Reinforcement learning in robotics: A survey,” *The International Journal of Robotics Research*, vol. 32, no. 11, pp. 1238–1274, 2013.

| Blue Puck          | Sim2Real Error  | Sim Error       | $\rho_{\text{aff}}$ |
|--------------------|-----------------|-----------------|---------------------|
| isotr_low          | 0.08 $\pm$ 0.07 | 0.72 $\pm$ 0.37 | 0.93                |
| isotr_lowmed       | 0.08 $\pm$ 0.07 | 0.19 $\pm$ 0.15 | 0.93                |
| isotr_med          | 0.08 $\pm$ 0.07 | 0.17 $\pm$ 0.12 | 0.93                |
| isotr_medhi        | 0.09 $\pm$ 0.08 | 0.28 $\pm$ 0.19 | 0.92                |
| isotr_high         | 0.10 $\pm$ 0.08 | 0.33 $\pm$ 0.21 | 0.92                |
| isotr_low_offc     | 0.08 $\pm$ 0.07 | 0.73 $\pm$ 0.43 | 0.93                |
| isotr_high_offc    | 0.15 $\pm$ 0.10 | 0.46 $\pm$ 0.26 | 0.88                |
| heavy_anisotr_lowx | 0.09 $\pm$ 0.07 | 0.36 $\pm$ 0.20 | 0.92                |
| heavy_anisotr_lowy | 0.09 $\pm$ 0.08 | 0.33 $\pm$ 0.20 | 0.92                |
| low_anisotr_lowx   | 0.08 $\pm$ 0.07 | 0.16 $\pm$ 0.11 | 0.93                |
| heavy_anisotr_lowy | 0.08 $\pm$ 0.08 | 0.18 $\pm$ 0.16 | 0.93                |
| Red Puck           | Sim2Real Error  | Sim Error       | $\rho_{\text{aff}}$ |
| isotr_low          | 0.07 $\pm$ 0.06 | 0.69 $\pm$ 0.39 | 0.92                |
| isotr_lowmed       | 0.07 $\pm$ 0.06 | 0.18 $\pm$ 0.17 | 0.93                |
| isotr_med          | 0.07 $\pm$ 0.06 | 0.18 $\pm$ 0.12 | 0.93                |
| isotr_medhi        | 0.08 $\pm$ 0.06 | 0.29 $\pm$ 0.16 | 0.93                |
| isotr_high         | 0.08 $\pm$ 0.07 | 0.35 $\pm$ 0.19 | 0.92                |
| isotr_low_offc     | 0.07 $\pm$ 0.06 | 0.69 $\pm$ 0.43 | 0.92                |
| isotr_high_offc    | 0.10 $\pm$ 0.07 | 0.48 $\pm$ 0.22 | 0.91                |
| heavy_anisotr_lowx | 0.08 $\pm$ 0.06 | 0.36 $\pm$ 0.21 | 0.92                |
| heavy_anisotr_lowy | 0.07 $\pm$ 0.06 | 0.33 $\pm$ 0.19 | 0.93                |
| low_anisotr_lowx   | 0.07 $\pm$ 0.06 | 0.18 $\pm$ 0.11 | 0.93                |
| heavy_anisotr_lowy | 0.07 $\pm$ 0.06 | 0.19 $\pm$ 0.15 | 0.93                |

表二：仿真到真实 (Sim2Real) 与仿真 (Simulation) 的预测状态逐点误差，以及仿真  $X$  与真实  $Y$  数据集之间估计的亲密度得分  $\rho_{\text{aff}}(X, Y)$ 。

- [2] G. Wilson and D. J. Cook, “A survey of unsupervised deep domain adaptation,” *ACM Transactions on Intelligent Systems and Technology (TIST)*, vol. 11, no. 5, pp. 1–46, 2020.
- [3] I. Redko, E. Morvant, A. Habrard, M. Sebban, and Y. Bennani, “A survey on domain adaptation theory: learning bounds and theoretical guarantees,” *arXiv e-prints*, pp. arXiv–2004, 2020.
- [4] W. Zhao, J. P. Queralta, and T. Westerlund, “Sim-to-real transfer in deep reinforcement learning for robotics: a survey,” in *2020 IEEE Symposium Series on Computational Intelligence (SSCI)*, pp. 737–744, IEEE, 2020.
- [5] N. Courty, R. Flamary, D. Tuia, and A. Rakotomamonjy, “Optimal transport for domain adaptation,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 39, no. 9, pp. 1853–1865, 2017.
- [6] N. Courty, R. Flamary, A. Habrard, and A. Rakotomamonjy, “Joint distribution optimal transportation for domain adaptation,” *Advances in Neural Information Processing Systems*, vol. 30, pp. 3730–3739, 2017.
- [7] I. Redko, A. Habrard, and M. Sebban, “Theoretical analysis of domain adaptation with optimal transport,” in *Joint European Conference on Machine Learning and Knowledge Discovery in Databases*, pp. 737–753, Springer, 2017.
- [8] V. Seguy, B. B. Damodaran, R. Flamary, N. Courty, A. Rolet, and M. Blondel, “Large-scale optimal transport and mapping estimation,” *arXiv preprint arXiv:1711.02283*, 2017.
- [9] B. Sun, J. Feng, and K. Saenko, “Return of frustratingly easy domain adaptation,” *arXiv preprint arXiv:1511.05547*, 2015.
- [10] Z. Zhang, M. Wang, Y. Huang, and A. Nehorai, “Aligning infinite-dimensional covariance matrices in reproducing kernel hilbert spaces for domain adaptation,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 3437–3445, 2018.
- [11] C. S. Smith and M. Knott, “Note on the optimal transportation of distributions,” *Journal of Optimization Theory and Applications*, vol. 52, no. 2, pp. 323–329, 1987.
- [12] C. R. Givens, R. M. Shortt, et al., “A class of Wasserstein metrics for probability distributions,” *The Michigan Mathematical Journal*, vol. 31, no. 2, pp. 231–240, 1984.
- [13] D. Dowson and B. Landau, “The Fréchet distance between multivariate normal distributions,” *Journal of multivariate analysis*, vol. 12, no. 3, pp. 450–455, 1982.
- [14] I. Olkin and F. Pukelsheim, “The distance between two random vectors with given dispersion matrices,” *Linear Algebra and its Applications*, vol. 48, pp. 257–263, 1982.
- [15] M. Knott and C. S. Smith, “On the optimal mapping of distributions,” *Journal of Optimization Theory and Applications*, vol. 43, no. 1, pp. 39–49, 1984.
- [16] A. Takatsu et al., “Wasserstein geometry of gaussian measures,” *Osaka Journal of Mathematics*, vol. 48, no. 4, pp. 1005–1026, 2011.
- [17] M. Gelbrich, “On a formula for the l2 wasserstein metric between measures on euclidean and hilbert spaces,” *Mathematische Nachrichten*, vol. 147, no. 1, pp. 185–203, 1990.
- [18] Y. Brenier, “Polar factorization and monotone rearrangement of vector-valued functions,” *Communications on pure and applied mathematics*, vol. 44, no. 4, pp. 375–417, 1991.
- [19] D. G. Kendall, “A survey of the statistical theory of shape,” *Statistical Science*, pp. 87–99, 1989.
- [20] G. Brockman, V. Cheung, L. Pettersson, J. Schneider, J. Schulman, J. Tang, and W. Zaremba, “Openai gym,” *CoRR*, vol. abs/1606.01540, 2016.
- [21] T. Yu, G. Thomas, L. Yu, S. Ermon, J. Y. Zou, S. Levine, C. Finn, and T. Ma, “Mopo: Model-based offline policy optimization,” in *Advances in Neural Information Processing Systems* (H. Larochelle, M. Ranzato, R. Hadsell, M. F. Balcan, and H. Lin, eds.), vol. 33, pp. 14129–14142, Curran Associates, Inc., 2020.
- [22] S. Levine, A. Kumar, G. Tucker, and J. Fu, “Offline reinforcement learning: Tutorial, review, and perspectives on open problems,” *CoRR*, vol. abs/2005.01643, 2020.