

基于最优传输的跨域模仿学习

Arnaud Fickinger^{13*} Samuel Cohen²³ Stuart Russell¹ Brandon Amos³

¹Berkeley AI Research ²University College London ³Facebook AI

摘要

跨域模仿学习研究如何利用一个智能体的专家演示来训练具有不同身体结构或形态的模仿智能体。比较专家智能体和模仿智能体之间的轨迹和平稳分布具有挑战性，因为它们存在于不同的系统上，甚至可能具有不同的维度。我们提出格罗莫夫-瓦瑟斯坦模仿学习（GWIL），这是一种跨域模仿方法，利用格罗莫夫-瓦瑟斯坦距离来对齐和比较智能体不同空间中的状态。我们的理论正式刻画了 GWIL 保持最优性的场景，揭示了其可能性和局限性。我们展示了 GWIL 在非平凡的连续控制领域中的有效性，这些领域从专家域的简单刚性变换到状态-动作空间的任意变换。¹

1 引言

强化学习（RL）方法在多个领域取得了令人瞩目的成果，例如 Berner 等人（2019）；Kober 等人（2013）；Levine 等人（2016）；Vinyals 等人（2019）。然而，当前强化学习方法的有效性训练奖励的质量高度相关。对于许多现实世界任务，设计密集且信息丰富的奖励需要大量的工程努力。为了减轻这种努力，模仿学习（IL）提出直接从专家演示中学习。当前大多数模仿学习方法仅适用于专家和智能体共享相同身体结构和转移动力学、且处于相同状态和动作空间的最简单设置。特别是，这些方法需要来自智能体域的专家演示。因此，我们可能会重新考虑模仿学习的效用，因为它似乎只是将问题从设计信息丰富的奖励转移到了提供专家演示，而不是解决问题。然而，如果我们放宽当前模仿学习方法的限制性设置，那么真正减轻工程努力的自然模仿场景就会出现。实际上，不要求相同的动力学将使智能体能够模仿具有不同形态的人类和机器人，从而大大扩展模仿学习的适用性，并减轻对域内专家演示的需求。

这种专家演示来自另一领域的宽松设定，已成为一个新兴领域，其假设更为现实（Gupta et al., 2017; Liu et al., 2019; Sermanet et al., 2018; Kim et al., 2020; Raychaudhuri et al., 2021），我们称之为跨域模仿学习（Cross-Domain Imitation Learning）。这些工作的常见策略是学习专家域与智能体域之间的映射。为此，它们需要访问代理任务，在这些任务中，专家和智能体在各自领域内均表现最优。在某些结构性假设下，学习到的映射能够将专家域中的轨迹转换到智能体域，同时保持最优性。尽管这些方法确实放宽了模仿学习的典型设定，但要求代理任务严重限制了跨域模仿学习的适用性。例如，它排除了模仿从未见过的专家以及迁移到新机器人的情况。

在本文中，我们放宽了跨域模仿学习的假设，并提出了一个无需代理任务的基准和方法。为此，我们摒弃了以往工作的视角，将跨域模仿学习形式化为一个最优传输（Optimal Transport）问题。我们提出了一种方法，

*arnaud.fickinger@berkeley.edu, arnaudfickinger@fb.com₁ 项目网站含视频和代码: <https://arnaudfickinger.github.io/gwil/>




图 1: 格罗莫夫-瓦瑟斯坦距离 (Gromov-Wasserstein Distance) 使我们能够比较具有不同动力学和状态-动作空间的两个智能体的平稳状态-动作分布。我们将其用作跨域模仿学习的伪奖励。




图 2: 同构策略 (定义 2) 在平稳分布的状态-动作空间内具有相同的成对距离。在欧几里得空间中, 等距变换保持这些成对距离, 包括旋转、平移和反射。

我们称之为格罗莫夫-瓦瑟斯坦模仿学习 (Gromov Wasserstein Imitation Learning, GWIL), 该方法利用格罗莫夫-瓦瑟斯坦距离来解决该基准。我们正式刻画了 GWIL 保持最优性的场景 (定理 1), 揭示了其可能性与局限性。我们构建的用于通过强化学习优化最优传输量的代理奖励, 推广了先前假设均匀占用测度的工作 (Dadashi et al., 2020; Papagiannis & Li, 2020), 并具有独立的研究价值。我们的实验表明, 在非平凡的连续控制环境中, GWIL 仅凭来自另一领域的单次演示即可学习到最优行为, 且无需任何代理任务。

2 相关工作

模仿学习。行为克隆 (Behavioral Cloning) 是模仿学习的早期方法 (Pomerleau, 1988; 1991), 其本质是通过监督学习训练分类器或回归器以复现专家的示范。另一关键方法是逆强化学习 (Inverse Reinforcement Learning) (Ng & Russell, 2000; Abbeel & Ng, 2004; Abbeel et al., 2010), 旨在通过学习一个奖励函数, 使得观测到的示范在该奖励函数下是最优的, 随后可利用该奖励函数通过强化学习训练智能体。为绕过学习专家奖励函数的需求, Ho & Ermon (2016) 证明逆强化学习是占用测度匹配问题的对偶形式, 并提出一种对抗目标, 其优化过程可近似恢复专家的状态-动作占用测度, 同时给出一种实用算法, 该算法使用生成对抗网络 (Goodfellow et al., 2014)。尽管近期许多工作致力于改进该算法以缓解极小极大优化带来的训练不稳定性, 原始瓦瑟斯坦模仿学习 (Primal Wasserstein Imitation Learning, PWIL) (Dadashi et al., 2020) 和辛克霍恩模仿学习 (Sinkhorn Imitation Learning, SIL) (Papagiannis & Li, 2020) 将模仿学习视为占用测度之间的最优传输问题, 从而完全消除极小极大目标, 并在样本效率上优于对抗方法。Heess et al. (2017); Peng et al. (2018); Zhu et al. (2018); Aytar et al. (2018) 将模仿学习扩展到非平凡设定下复杂的类人运动与游戏行为。本文工作是 Dadashi et al. (2020); Papagiannis & Li (2020) 从瓦瑟斯坦设定到格罗莫夫-瓦瑟斯坦设定的扩展。这使我们超越了专家与模仿者处于同一领域的局限, 进入不同空间中智能体之间的跨领域设定。

跨领域与跨形态的迁移学习。在强化学习中, 不同领域间知识迁移的工作通常学习状态空间与动作空间之间的映射。Ammar et al. (2015) 使用无监督流形对齐来寻找具有相似状态之间的线性映射

局部几何结构，但假设能够获取手工设计的特征。近期在跨视角和跨具身不匹配的迁移学习方面的工作，无需手工特征即可学习状态映射，但假设能够获取来自两个领域的成对且时间对齐的演示（Gupta 等人，2017；Liu 等人，2018；Sermanet 等人，2018）。此外，Kim 等人（2020）；Raychaudhuri 等人（2021）提出了从非成对且非对齐的任务中学习状态映射的方法。所有这些方法都需要代理任务，即来自两个领域的一组专家演示对，这限制了这些方法在现实世界场景中的适用性。Stadie 等人（2017）提出将对抗学习和领域混淆相结合，在无需代理任务的情况下在智能体领域学习策略，但他们的方法仅适用于视角不匹配较小的情况。Zakka 等人（2021）采用目标驱动的视角，旨在模仿任务进展而非匹配细粒度的结构细节，以在物理机器人之间进行迁移。相比之下，本文的方法既不依赖于在智能体之间学习显式的跨领域潜空间，也不依赖于代理任务。格罗莫夫-瓦瑟斯坦距离使我们能够直接比较不同的空间，而无需共享空间。据我们所知，现有的基准任务假设能够获取来自两个智能体的一组演示，而本文的实验仅假设能够获取专家演示。最后，其他领域自适应和迁移学习设置使用了格罗莫夫-瓦瑟斯坦变体，例如用于词嵌入空间之间的迁移（Alvarez-Melis 和 Jaakkola，2018）以及图像空间之间的迁移（Vayer 等人，2020b）。

3 预备知识

度量马尔可夫决策过程。 一个无限时域折扣马尔可夫决策过程（MDP）是一个元组 $(S, A, R, P, p_0, \gamma)$ ，其中 S 和 A 分别是状态空间和动作空间， $P: S \times A \rightarrow \Delta(S)$ 是转移函数， $R: S \times A \rightarrow \mathbb{R}$ 是奖励函数， $p_0 \in \Delta(S)$ 是初始状态分布， γ 是折扣因子。我们为 MDP 配备一个距离 $d: S \times A \rightarrow \mathbb{R}^+$ ，并将元组 $(S, A, R, P, p_0, \gamma, d)$ 称为度量 MDP。

格罗莫夫-瓦瑟斯坦距离。 设 $(\mathcal{X}, d_{\mathcal{X}}, \mu_{\mathcal{X}})$ 和 $(\mathcal{Y}, d_{\mathcal{Y}}, \mu_{\mathcal{Y}})$ 为两个度量测度空间，其中 $d_{\mathcal{X}}, d_{\mathcal{Y}}$ 为距离， $\mu_{\mathcal{X}}, \mu_{\mathcal{Y}}$ 为各自空间 $\mathcal{X}$ 上的测度。最优传输（Optimal Transport）（Villani, 2009; Peyré et al., 2019）研究如何比较测度。本文将使用度量测度空间之间的格罗莫夫-瓦瑟斯坦距离（Gromov-Wasserstein Distance）（Mémoli, 2011），该距离已在 Sturm (2012); Peyré et al. (2016); Vayer (2020) 中得到理论推广和进一步研究，其定义为

$$\mathcal{GW}((\mathcal{X}, d_{\mathcal{X}}, \mu_{\mathcal{X}}), (\mathcal{Y}, d_{\mathcal{Y}}, \mu_{\mathcal{Y}}))^2 = \min_{u \in \mathcal{U}(\mu_{\mathcal{X}}, \mu_{\mathcal{Y}})} \sum_{\mathcal{X}^2 \times \mathcal{Y}^2} |d_{\mathcal{X}}(x, x') - d_{\mathcal{Y}}(y, y')|^2 u_{x,y} u_{x',y'}, \quad (1)$$

其中 $\mathcal{U}(\mu_{\mathcal{X}}, \mu_{\mathcal{Y}})$ 是由以下定义的测度原子之间耦合的集合

$$\mathcal{U}(\mu_{\mathcal{X}}, \mu_{\mathcal{Y}}) = \left\{ u \in \mathbb{R}^{\mathcal{X} \times \mathcal{Y}} \left| \forall x \in \mathcal{X}, \sum_{y \in \mathcal{Y}} u_{x,y} = \mu_{\mathcal{X}}(x), \forall y \in \mathcal{Y}, \sum_{x \in \mathcal{X}} u_{x,y} = \mu_{\mathcal{Y}}(y) \right. \right\}.$$

$\mathcal{GW}$ 通过比较每个空间内的成对距离来比较两个度量测度空间的结构，以找到空间之间的最佳等距映射。图 1 在度量测度空间 $(S_E \times A_E, d_E, \rho_{\pi_E})$ 和 $(S_A \times A_A, d_A, \rho_{\pi_A})$ 的情形下说明了该距离。

4 基于最优传输的跨域模仿学习

4.1 比较来自任意不同马尔可夫决策过程的策略

对于作用于度量马尔可夫决策过程 (S, A, R, P, γ, d) 的平稳策略 π ，占用测度为：

$$\rho_{\pi}: S \times A \rightarrow \mathbb{R} \quad \rho(s, a) = \pi(a|s) \sum_{t=0}^{\infty} \gamma^t P(s_t = s | \pi).$$

本文根据占用测度来比较来自任意不同马尔可夫决策过程的策略。

² 为便于阅读，本文使用离散空间，但展示了连续空间中的实证结果。

定义 1 (策略同构类之间的格罗莫夫-瓦瑟斯坦距离)³。给定分别作用于 S 和 A 的专家策略 π_E 与智能体策略 π_A ，我们将 π_E 与 π_A 之间的格罗莫夫-瓦瑟斯坦距离定义为度量测度空间 $(S_E \times A_E, d_E, \rho_{\pi_E})$ 与 $(S_A \times A_A, d_A, \rho_{\pi_A})$ 之间的格罗莫夫-瓦瑟斯坦距离 $GW(\pi_E, \pi_A)$ 。

$$GW(\pi, \pi') = GW((S_E \times A_E, d_E, \rho_{\pi_E}), (S_A \times A_A, d_A, \rho_{\pi_A})). \quad (2)$$

我们现在通过比较状态-动作边缘分布来定义策略之间的同构，并证明 GW 定义了它们之间的距离。图 2 展示了简单的同构策略。

Definition 2 (Isomorphic policies). *Two policies π_E and π_A are isomorphic if there exists a bijection $\phi : \text{supp}[\rho_{\pi_E}] \rightarrow \text{supp}[\rho_{\pi_A}]$ that satisfies for all $(s_E, a_E), (s_E', a_E') \in \text{supp}[\rho_{\pi_E}]$ and $(s_A, a_A) \in \text{supp}[\rho_{\pi_A}]$:*

$$d_E((s_E, a_E), (s_E', a_E')) = d_A(\phi(s_E, a_E), \phi(s_E', a_E')) \quad (3)$$

$$\rho_{\pi_A}(s_A, a_A) = \rho_{\pi_E}(\phi^{-1}(s_E, a_E)) \quad (4)$$

换言之， ϕ 是 $(\text{supp}[\rho_{\pi_E}], d_E)$ 与 $(\text{supp}[\rho_{\pi_A}], d_A)$ 之间的等距映射，且 ρ_{π_A} 是前推测度 $\phi_{\#}(\rho_{\pi_E})$ 。

命题 1。 GW 在所有策略同构类的集合上定义了一个度量。

证明。根据定义 1， $GW(\pi_E, \pi_A) = 0$ 当且仅当 $GW((S_E, d_E, \rho_{\pi_E}), (S_A, d_A, \rho_{\pi_A})) = 0$ 。根据 Mémoli (2011, 定理 5.1)，这成立当且仅当存在等距映射 $\phi : \text{supp}[\rho_{\pi_E}] \rightarrow \text{supp}[\rho_{\pi_A}]$ 使得 $\rho_{\pi_A} = \phi_{\#}(\rho_{\pi_E})$ 。根据定义 2，这成立当且仅当 π_A 与 π_E 同构。对称性和三角不等式由 Mémoli (2011, 定理 5.1) 得出。□

下一个定理 5 给出了一个充分条件，通过最小化 GW ，在智能体域中恢复最优策略⁶，精确到等距映射。

定理 1。 考虑两个马尔可夫决策过程 (MDP)

$$M_E = (S_E, A_E, R_E, P_E, p_E, \gamma) \quad M_A = (S_A, A_A, R_A, P_A, p_A, \gamma).$$

并假设存在四个距离 $d_E^S, d_E^A, d_A^S, d_A^A$ ，分别定义在 S_E, A_E, S_A 和 A_A 上，以及两个等距映射 $\phi : (S_E, d_E^S) \rightarrow (S_A, d_A^S)$ 和 $\psi : (A_E, d_E^A) \rightarrow (A_A, d_A^A)$ 并且对于所有 $(s_E, a_E) \in S_E \times A_E$ ，以下三个条件成立：

$$R(s_E, a_E) = R_A(\phi(s_E), \psi(a_E)) \quad (5)$$

$$P_{E, s_E, a_E}(s'_E) = P_{A, \phi(s_E), \psi(a_E)}(\phi(s'_E)) \quad (6)$$

$$p_E(s_E) = p_A(\phi(s_E)). \quad (7)$$

考虑 M_E 中的最优策略 π_E^* 。假设 π_{GW} 最小化 $GW(\pi_E^*, \pi_{GW})$ 含

$$d_E : (s_E, a_E) \mapsto d_E^S(s_E) + d_E^A(a_E) \quad d_A : (s_A, a_A) \mapsto d_A^S(s_A) + d_A^A(a_A).$$

且 π_{GW} 同构于 M_A 中的一个最优策略。

证明。考虑占用测度 ρ^* 由下式给出 $\rho^* : S_A \times A_A \rightarrow \mathbb{R}$

$$(s_A, a_A) \mapsto \rho_{\pi_E^*}(\phi^{-1}(s_A), \psi^{-1}(a_A)).$$

我们首先证明 ρ^* 在 M_A 中是可行的。存在一个策略 π_A^* 作用于 M_A ，其占用测度为 ρ^*

(a)。然后我们证明 π_A^* 在 M_A 中是最优的 (b)，并且同构于 π_E^* (c)。最后我们证明 π_{GW} 同构于 π_A^* ，从而完成证明 (d)。

³ 我们稍后将证明它实际上不是策略上的距离，而是策略同构类上的距离。⁴ 我们总是在底层度量马尔可夫决策过程的背景下考虑策略，因此只要 $d_E \neq d_A$ ，作用于 (S, A, R, P, T, d_E) 的每个策略都不同于作用于 (S, A, R, P, T, d_A) 的每个策略。这保证了格罗莫夫-瓦瑟斯坦距离满足不可区分者的同一性。⁵ 为了可读性，我们的证明在有限状态-动作空间中进行，并且可以直接扩展到无限空间。⁶ 策略在马尔可夫决策过程 (S, A, R, P, γ, d) 中是最优的，如果它最大化期望回报 $\mathbb{E} \sum_{t=0}^{\infty} \gamma^t R(s_t, a_t)$ 。

(a) Consider $s_A \in S_A$. By definition of ρ_A^* ,

$$\sum_{a_A \in A_A} \rho_A^*(s_A) = \sum_{a_A \in A_A} \rho_{\pi_E^*}(\phi^{-1}(s_A), \psi^{-1}(a_A)) = \sum_{a_E \in A_E} \rho_{\pi_E^*}(\phi^{-1}(s_A), a_E).$$

由于 $\rho_{\pi_E^*}$ 在 M 中是可行的, 根据普特曼 (2014, 定理 6.9.1) 可得

$$\sum_{a_E \in A_E} \rho_{\pi_E^*}(\phi^{-1}(s_A), a_E) = p_E(\phi^{-1}(s_A)) + \gamma \sum_{s_E \in S_E, a_E \in A_E} P_{E s_E, a_E}(\phi^{-1}(s_A)) + \rho_{\pi_E^*}(s_E, a_E).$$

By conditions 6 and 7 and by definition of ρ_A^* ,

$$\begin{aligned} & p_E(\phi^{-1}(s_A)) + \gamma \sum_{s_E \in S_E, a_E \in A_E} P_{E s_E, a_E}(\phi^{-1}(s_A)) + \rho_{\pi_E^*}(s_E, a_E) \\ &= p_A(s_A) + \gamma \sum_{s_E \in S_E, a_E \in A_E} P_{A \phi(s_E), \psi(a_E)}(s_A) + \rho_A^*(\phi(s_E), \psi(a_E)) \\ &= p_A(s_A) + \gamma \sum_{s'_A \in S_A, a_A \in A_A} P_{A s'_A, a_A}(s_A) + \rho_A^*(s'_A, a_A). \end{aligned}$$

由此可得

$$\sum_{a_A \in A_A} \rho_A^*(s_A) = p_A(s_A) + \gamma \sum_{s'_A \in S_A, a_A \in A_A} P_{A s'_A, a_A}(s_A) + \rho_A^*(s'_A, a_A).$$

因此, 根据普特曼 (2014, 定理 6.9.1), ρ_A^* 在 M_A , i.e 中是可行的。存在一个策略 π_A^* 作用于 M_A , 其占用测度为 ρ_A^* 。

(b) 根据条件 7 及 ρ_A^* 的定义, π_A^* 的期望回报为 in M_A

$$\begin{aligned} & \sum_{s_A \in S_A, a_A \in A_A} \rho_A^*(s_A, a_A) R_A(s_A, a_A) \\ &= \sum_{s_A \in S_A, a_A \in A_A} \rho_E^*(\phi^{-1}(s_A), \psi^{-1}(a_A)) R_E(\phi^{-1}(s_A), \psi^{-1}(a_A)) \\ &= \sum_{s_E \in S_E, a_E \in A_E} \rho_E^*(s_E, a_E) R_E(s_E, a_E) \end{aligned}$$

考虑 M' 中的任意策略 π_A 。根据条件 7, π_A 的期望回报为

$$\sum_{s_A \in S_A, a_A \in A_A} \rho_{\pi_A}(s_A, a_A) R_A(s_A, a_A) = \sum_{s_E \in S_E, a_E \in A_E} \rho_{\pi_A}(\phi(s_E), \psi(a_E)) R_E(s_E, a_E).$$

利用我们证明 ρ_A^* 在 M' 中可行时所用的相同论证, 可以证明

$$(s_E, a_E) \mapsto \rho_{\pi_A}(\phi(s_E), \psi(a_E))$$

在 M 中可行。由 π_E^* 在 M 中的最优性可得

$$\begin{aligned} \sum_{s_E \in S_E, a_E \in A_E} \rho_{\pi_A}(\phi(s_E), \psi(a_E)) R_E(s_E, a_E) &\leq \sum_{s_E \in S_E, a_E \in A_E} \rho_{\pi_E^*}(\phi(s_E), \psi(a_E)) R_E(s_E, a_E) \\ &= \sum_{s_A \in S_A, a_A \in A_A} \rho_A^*(s_A, a_A) R_A(s_A, a_A). \end{aligned}$$

由此可知 π_A^* 在 M' 中是最优的

(c) 注意

$$\xi : (s_E, a_E) \mapsto (\phi(s_E), \psi(a_E))$$

是 $(S_E \times A_E, d_E)$ 与 $(S_A \times A_A, d_A)$ 之间的等距映射, 其中 d_E 与 d_A 分别由和给出。此外, 根据定义, $\rho_A^*(\phi(s_E), \psi(a_E)) \mapsto \rho_E^*(s_E, a_E) \mapsto d_E^S(s_E) + d_E^A(a_E)$ 同构于 $(s_A, a_A) \mapsto d_A^S(s_A) + d_A^A(a_A)$ 。

Algorithm 1 Gromov-Wasserstein imitation learning from a single expert demonstration.

Inputs: expert demonstration τ , metrics on the expert (d_E) and agent (d_A) space
Initialize the imitation agent's policy π_θ and value estimates V_θ
while Unconverged **do**
 Collect an episode τ'
 Compute $\mathcal{GW}(\tau, \tau')$
 Set pseudo-rewards r with eq. (9)
 Update π_θ and V_θ to optimize the pseudo-rewards
end while

(d) 回顾定理陈述中 π_{GW} 是 $\mathcal{GW}(\pi_E^*, \pi_{GW})$ 的极小化元。由于 π_A^* 同构于 π_E^* ，由命题 1 可得 $\mathcal{GW}(\pi_E^*, \pi_A^*) = 0$ 。因此 $\mathcal{GW}(\pi_E^*, \pi_{GW})$ 必为 0。由命题 1 可知存在一个等距映射

$$\chi : (\text{supp}[\rho_E^*], d_E) \rightarrow (\text{supp}[\rho_{\pi_{GW}}], d_A)$$

使得 $\rho_{\pi_{GW}} = \chi_\#(\rho_E^*)$ 。注意到 $\chi \circ \xi^{-1}|_{\text{supp}[\rho_A^*]}$ 是从 $(\text{supp}[\rho_A^*], d_A)$ 到 $(\text{supp}[\rho_{\pi_{GW}}], d_A)$ 的等距映射，且 $\rho_{\pi_{GW}} = (\chi \circ \xi^{-1}|_{\text{supp}[\rho_A^*]})_\#(\rho_A^*)$ 。根据定义 2 可知， π_{GW} 同构于 π_A^* ，即 M_A 中的最优策略，证毕。□

注 1. 定理 1 展示了本文方法的可能性与局限性。该定理表明，即使对专家领域的状态空间和动作空间施加任意等距变换，本文方法仍能恢复最优策略。重要的是，无需事先知晓这些等距变换，因此本文方法适用于广泛的场景。我们将通过实验证明，在环境非等距甚至维度不同的其他场景中，本文方法也能取得显著效果。然而，本文方法的局限性在于，它只能恢复到等距变换意义下的最优策略。在实践中，通过在不同随机种子上运行本文方法，能够在智能体领域中找到最优策略。

4.2 格罗莫夫-瓦瑟斯坦模仿学习

最小化专家与智能体之间的 $\mathcal{GW}$ 需要对转移动态求导，而通常无法获得这些动态。本文引入一种适合训练智能体策略的奖励代理，通过强化学习最小化 $\mathcal{GW}$ 。图 1 展示了该方法。为便于阅读，将专家状态和动作变量 (s_E, a_E) 合并为单一变量 z_E ，智能体的状态-动作对也做类似处理。此外，定义 $Z_E = S_E \times A_E$ 和 $Z_A = S_A \times A_A$ 。

定义 3. 给定专家策略 π_E 和智能体策略 π_A ，智能体的格罗莫夫-瓦瑟斯坦奖励定义为 $r_{\mathcal{GW}} : \text{supp}[\rho_{\pi_A}] \rightarrow \mathbb{R}$ ，由 $r_{\mathcal{GW}}(z_A) = -\frac{1}{\sum_{\substack{z_E \in Z_E \\ z'_E \in Z_E}} \sum_{z'_A \in Z_A}} \rho_\pi(z_A) |d_E(z_E, z'_E) - d_A(z_A, z'_A)|^2 u_{z_E, z_A}^* u_{z'_E, z'_A}^*$ 给出，其中 u^* 是使目标 1 最小化的耦合。命题 2。若 π_A 最小化 $\mathcal{GW}(\pi_E, \pi_A)$ ，则 π_A 是定义 3 中奖励 $r_{\mathcal{GW}}$ 下的最优策略。

证明。假设 π_A 最小化 $\mathcal{GW}(\pi_E, \pi_A)$ ，则根据定义 1 π_A 最大化

$$\begin{aligned} &= - \sum_{\substack{z_E \in Z_E \\ z'_E \in Z_E \\ z_A \in Z_A \\ z'_A \in Z_A}} |d_E(z_E, z'_E) - d_A(z_A, z'_A)|^2 u_{z_A, z_E}^* u_{z'_A, z'_E}^* \\ &= - \sum_{z_A \in \text{supp}[\rho_{\pi_A}]} \frac{\rho_{\pi_A}(z_A)}{\rho_{\pi_A}(z_A)} \sum_{\substack{z_E \in Z_E \\ z'_E \in Z_E \\ z'_A \in Z_A}} |d_E(z_E, z'_E) - d_A(z_A, z'_A)|^2 u_{z_A, z_E}^* u_{z'_A, z'_E}^* \end{aligned}$$

因此，根据普特曼 (2014, 定理 6.9.4)， π_A 是奖励 $r_{\mathcal{GW}}$ 下的最优策略。□

在实践中，我们通过 π 来近似占用测度，其中 $\hat{\rho}_\pi(s, a) = \frac{1}{T} \sum_{t=1}^T \mathbb{1}(s = s_t \wedge a = a_t)$ ，而 $\tau = (s_1, a_1, \dots, s_T, a_T)$ 是用 π 收集的有限轨迹。假设轨迹中所有状态-动作对都不同，⁷ $\hat{\rho}$ 是均匀分布。给定专家轨迹 τ_E 和智能体轨迹 τ_A ⁸，经验占用测度之间的（平方）格罗莫夫-瓦瑟斯坦距离为

$$\mathcal{GW}^2(\tau_E, \tau_A) = \min_{\theta \in \Theta^{T_E \times T_A}} \sum_{\substack{1 \leq i, i' \leq T_E \\ 1 \leq j, j' \leq T_A}} |d_E((s_i^E, a_i^E), (s_{i'}^E, a_{i'}^E)) - d_A((s_j^A, s_{j'}^A), (s_{j'}^A, a_{j'}^A))|^2 \theta_{i,j} \theta_{i',j'} \quad (8)$$

其中 Θ 是由以下均匀测度原子之间的耦合集合所定义的集合：

$$\Theta^{T \times T'} = \left\{ \theta \in \mathbb{R}^{T \times T'} \left| \forall i \in [T], \sum_{j \in [T']} \theta_{i,j} = 1/T, \forall j \in [T'], \sum_{i \in [T]} \theta_{i,j} = 1/T' \right. \right\}.$$

在这种情况下，轨迹中每个状态-动作对的奖励由下式给出：

$$r(s_j^A, s_{j'}^A) = -T_A \sum_{\substack{1 \leq i, i' \leq T_E \\ 1 \leq j' \leq T_A}} |d_E((s_i^E, a_i^E), (s_{i'}^E, a_{i'}^E)) - d_A((s_j^A, s_{j'}^A), (s_{j'}^A, a_{j'}^A))|^2 \theta_{i,j}^* \theta_{i',j'}^* \quad (9)$$

其中 θ^* 是使目标 8 最小化的耦合。

在实践中，我们省略因子 T_A ，因为它对轨迹中所有状态-动作对都是相同的。

备注 2。我们的奖励代理构造适用于任意占用测度，并扩展了先前通过强化学习优化最优传输量的工作，这些工作假设占用测度为轨迹形式的均匀分布，以避免对转移动态求导（Dadashi 等人，2020；Papagiannis 和 Li，2020）。

计算伪奖励。我们使用 Peyré 等人（2016，命题 1）计算格罗莫夫-瓦瑟斯坦距离，并使用 Peyré 等人（2016，命题 2）计算其梯度。为了计算最小化 8 的耦合，我们采用 Ferradans 等人（2013）中的条件梯度方法。

优化伪奖励。我们从 $\mathcal{GW}$ 中为模仿智能体获得的伪奖励使我们能够将模仿学习问题转化为强化学习问题（Sutton & Barto, 2018），以找到由伪奖励诱导的马尔可夫决策过程的最优策略。我们考虑具有连续状态-动作空间的智能体，因此使用软演员-评论家算法（Haarnoja 等人，2018）进行策略优化。算法 1 总结了在给定单条专家轨迹来近似专家占用测度的情况下 GWIL 的流程。

5 实验

我们为跨域模仿学习方法提出了一个基准集，包含 3 个任务，旨在回答以下问题：

1. 当智能体域是专家域的刚性变换时，GWIL 能否恢复最优行为？是的，我们在第 5.1 节中用迷宫证明了这一点。
2. 当智能体具有与专家不同的状态和动作空间时，GWIL 能否恢复最优行为？是的，我们在第 5.2 节中展示了小车-杆和摆之间略有不同的状态-动作空间，并在第 5.3 节中展示了行走器和猎豹之间显著不同的空间。

为了回答这三个问题，我们使用在 Mujoco（Todorov 等人，2012）和 DeepMind 控制套件（Tassa 等人，2018）中实现的模拟连续控制任务。我们包含了视频

⁷ 我们可以将时间步添加到状态中，以区分轨迹中两个相同的状态-动作对。⁸ 注意，等式（6）中定义的格罗莫夫-瓦瑟斯坦距离不依赖于轨迹的时间顺序。




图 3: 给定专家域中的单条专家轨迹 (a), GWIL 无需任何外部奖励即可在智能体域 (b) 中恢复最优策略, 正如定理 1 所预测。绿点表示初始状态位置, 回合在智能体到达红色方块表示的目标时结束。




图 4: 给定摆锤域中的单条专家轨迹 (上图), GWIL 无需任何外部奖励即可在智能体域 (小车杆, 下图) 中恢复最优行为。

在我们的项目网站上学习到的策略⁹。在所有设置中, 我们在专家和智能体空间内使用欧几里得度量 (Euclidean Metric) 来计算 d_E 和 d_A 。

5.1 智能体域是专家域的刚性变换

我们通过使用 Hejna 等人 (2020) 的 PointMass Maze 环境, 评估模仿学习 (IL) 方法迁移到专家域刚性变换的能力。智能体域通过对专家迷宫应用反射 (Reflection) 得到。该任务满足定理 1 的条件, 其中 ϕ 为通过中心水平面的反射, ψ 为动作空间中通过 x 轴的反射。因此, 根据定理 1, 智能体的最优策略应与使用 GWIL 训练的策略同构。通过观察迷宫的几何结构, 显然最优策略的等距类中的每个策略都是最优的。因此, 我们期望 GWIL 能在智能体域中恢复最优策略。图 3 显示 GWIL 确实恢复了最优策略。

5.2 智能体与专具有略有不同的状态和动作空间

我们在此评估模仿学习方法迁移到非刚性变换的能力, 但描述映射仍应通过观察域而显而易见。这种变换的一个很好的例子是摆锤与小车杆之间的变换。摆锤是我们的专家域, 而小车杆构成我们的智能体域。专家在摆起任务上训练。尽管变换不是刚性的, GWIL 仍能在智能体域中恢复最优行为, 如图 4 所示。注意摆锤和小车杆不具有相同的状态-动作

⁹<https://arnaudfickinger.github.io/gwil/>




图 5: 给定猎豹域中的单条专家轨迹（上图），GWIL 在智能体域（步行者）中恢复了最优策略等距类的两个元素：向前移动是最优的（中图），向后移动是次优的（下图）。有趣的是，得到的步行者行为像猎豹。

空间维度：钟摆具有 3 个维度，而倒立摆小车具有 5 个维度。因此，GWIL 确实可以应用于不同维度问题之间的迁移。

5.3 智能体与专家具有显著不同的状态和动作空间

本文在此评估模仿学习方法在领域间非平凡变换下的迁移能力。此类变换的一个典型例子是 DeepMind 控制套件中两种任意不同的形态，如猎豹和步行者。猎豹构成专家领域，步行者构成智能体领域。专家在奔跑任务上进行训练。

尽管这两个领域之间的映射并非平凡，仅最小化 Gromov-Wasserstein 距离就能使步行者通过模仿猎豹有趣地学会前后移动。由于猎豹和步行者最优策略（向前移动）的等距类包含一个次优元素（向后移动），我们期望 GWIL 能够恢复这两条轨迹之一。实际上，如图 5 所示，根据所使用的随机种子，GWIL 会产生一个模仿猎豹向前移动的步行者或一个模仿猎豹向后移动的步行者。

6 结论

本文工作表明，最优传输距离是跨不可比空间进行跨域模仿的有用基础工具。未来方向包括探索：

1. 扩展到更复杂的环境和智能体，目标是将复杂任务的大量高维演示的结构迁移到智能体中。
2. 当有其他智能体的专家演示可用时，使用 GW 帮助智能体在奖励极其稀疏的环境中进行探索。
3. GW 与其他最优传输距离的比较，这些距离适用于两个度量马尔可夫决策过程（MDP）之间，例如 Alvarez-Melis 等人（2019）提出的方法，它们在空间连接方式和耦合不变性方面具有更大的灵活性。
4. 考虑 MDP 时间结构的度量，如 Zhou & Torre (2009); Vayer 等人 (2020a); Cohen 等人 (2021) 基于动态时间规整（Müller, 2007）构建的度量。Gromov-Wasserstein 忽略了轨迹内的时间信息和顺序。

参考文献

- Pieter Abbeel and Andrew Y Ng. Apprenticeship learning via inverse reinforcement learning. In *Proceedings of the twenty-first international conference on Machine learning*, pp. 1, 2004.
- Pieter Abbeel, Adam Coates, and Andrew Y Ng. Autonomous helicopter aerobatics through apprenticeship learning. *The International Journal of Robotics Research*, 29(13):1608–1639, 2010.
- David Alvarez-Melis and Tommi S. Jaakkola. Gromov-wasserstein alignment of word embedding spaces. In *Empirical Methods in Natural Language Processing*, 2018.
- David Alvarez-Melis, Stefanie Jegelka, and Tommi S. Jaakkola. Towards optimal transport with global invariances. In Kamalika Chaudhuri and Masashi Sugiyama (eds.), *Proceedings of the Twenty-Second International Conference on Artificial Intelligence and Statistics*, volume 89 of *Proceedings of Machine Learning Research*, pp. 1870–1879. PMLR, 16–18 Apr 2019. URL <https://proceedings.mlr.press/v89/alvarez-melis19a.html>.
- Haitham Bou Ammar, Eric Eaton, Paul Ruvolo, and Matthew E Taylor. Unsupervised cross-domain transfer in policy gradient reinforcement learning via manifold alignment. In *Twenty-Ninth AAAI Conference on Artificial Intelligence*, 2015.
- Yusuf Aytar, Tobias Pfaff, David Budden, Tom Le Paine, Ziyu Wang, and Nando de Freitas. Playing hard exploration games by watching youtube. *arXiv preprint arXiv:1805.11592*, 2018.
- Christopher Berner, Greg Brockman, Brooke Chan, Vicki Cheung, Przemysław Dębiak, Christy Dennison, David Farhi, Quirin Fischer, Shariq Hashme, Chris Hesse, et al. Dota 2 with large scale deep reinforcement learning. *arXiv preprint arXiv:1912.06680*, 2019.
- Samuel Cohen, Giulia Luise, Alexander Terenin, Brandon Amos, and Marc Deisenroth. Aligning time series on incomparable spaces. In *International Conference on Artificial Intelligence and Statistics*, pp. 1036–1044. PMLR, 2021.
- Robert Dadashi, Léonard Hussenot, Matthieu Geist, and Olivier Pietquin. Primal wasserstein imitation learning. *arXiv preprint arXiv:2006.04678*, 2020.
- Sira Ferradans, Nicolas Papadakis, Julien Rabin, Gabriel Peyré, and Jean-François Aujol. Regularized discrete optimal transport. In *International Conference on Scale Space and Variational Methods in Computer Vision*, pp. 428–439. Springer, 2013.
- Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial nets. *Advances in neural information processing systems*, 27, 2014.
- Abhishek Gupta, Coline Devin, YuXuan Liu, Pieter Abbeel, and Sergey Levine. Learning invariant feature spaces to transfer skills with reinforcement learning. *arXiv preprint arXiv:1703.02949*, 2017.
- Tuomas Haarnoja, Aurick Zhou, Kristian Hartikainen, George Tucker, Sehoon Ha, Jie Tan, Vikash Kumar, Henry Zhu, Abhishek Gupta, Pieter Abbeel, et al. Soft actor-critic algorithms and applications. *arXiv preprint arXiv:1812.05905*, 2018.
- Nicolas Heess, Dhruva TB, Srinivasan Sriram, Jay Lemmon, Josh Merel, Greg Wayne, Yuval Tassa, Tom Erez, Ziyu Wang, SM Eslami, et al. Emergence of locomotion behaviours in rich environments. *arXiv preprint arXiv:1707.02286*, 2017.
- Donald Hejna, Lerrel Pinto, and Pieter Abbeel. Hierarchically decoupled imitation for morphological transfer. In *International Conference on Machine Learning*, pp. 4159–4171. PMLR, 2020.
- Jonathan Ho and S. Ermon. Generative adversarial imitation learning. In *NIPS*, 2016.
- Kuno Kim, Yihong Gu, Jiaming Song, Shengjia Zhao, and Stefano Ermon. Domain adaptive imitation learning. In *International Conference on Machine Learning*, pp. 5286–5295. PMLR, 2020.
- Jens Kober, J Andrew Bagnell, and Jan Peters. Reinforcement learning in robotics: A survey. *The International Journal of Robotics Research*, 32(11):1238–1274, 2013.

- Sergey Levine, Chelsea Finn, Trevor Darrell, and Pieter Abbeel. End-to-end training of deep visuomotor policies. *The Journal of Machine Learning Research*, 17(1):1334–1373, 2016.
- Fangchen Liu, Zhan Ling, Tongzhou Mu, and Hao Su. State alignment-based imitation learning. *arXiv preprint arXiv:1911.10947*, 2019.
- YuXuan Liu, Abhishek Gupta, Pieter Abbeel, and Sergey Levine. Imitation from observation: Learning to imitate behaviors from raw video via context translation. In *2018 IEEE International Conference on Robotics and Automation (ICRA)*, pp. 1118–1125. IEEE, 2018.
- Facundo Mémoli. Gromov–wasserstein distances and the metric approach to object matching. *Foundations of computational mathematics*, 11(4):417–487, 2011.
- Meinard Müller. Dynamic time warping. *Information retrieval for music and motion*, pp. 69–84, 2007.
- Andrew Y. Ng and Stuart J. Russell. Algorithms for inverse reinforcement learning. In *Proceedings of the Seventeenth International Conference on Machine Learning, ICML ’00*, pp. 663–670, San Francisco, CA, USA, 2000. Morgan Kaufmann Publishers Inc. ISBN 1558607072.
- Georgios Papagiannis and Yunpeng Li. Imitation learning with sinkhorn distances. *arXiv preprint arXiv:2008.09167*, 2020.
- Xue Bin Peng, Pieter Abbeel, Sergey Levine, and Michiel van de Panne. Deepmimic: Example-guided deep reinforcement learning of physics-based character skills. *ACM Transactions on Graphics (TOG)*, 37(4):1–14, 2018.
- Gabriel Peyré, Marco Cuturi, and Justin Solomon. Gromov-wasserstein averaging of kernel and distance matrices. In *International Conference on Machine Learning*, pp. 2664–2672. PMLR, 2016.
- Gabriel Peyré, Marco Cuturi, et al. Computational optimal transport: With applications to data science. *Foundations and Trends® in Machine Learning*, 11(5-6):355–607, 2019.
- D. Pomerleau. Alvin: An autonomous land vehicle in a neural network. In *NIPS*, 1988.
- D. Pomerleau. Efficient training of artificial neural networks for autonomous navigation. *Neural Computation*, 3:88–97, 1991.
- Martin L Puterman. *Markov decision processes: discrete stochastic dynamic programming*. John Wiley & Sons, 2014.
- Dripta S Raychaudhuri, Sujoy Paul, Jeroen van Baar, and Amit K Roy-Chowdhury. Cross-domain imitation from observations. *arXiv preprint arXiv:2105.10037*, 2021.
- Pierre Sermanet, Corey Lynch, Yevgen Chebotar, Jasmine Hsu, Eric Jang, Stefan Schaal, Sergey Levine, and Google Brain. Time-contrastive networks: Self-supervised learning from video. In *2018 IEEE international conference on robotics and automation (ICRA)*, pp. 1134–1141. IEEE, 2018.
- Bradly C Stadie, Pieter Abbeel, and Ilya Sutskever. Third-person imitation learning. *arXiv preprint arXiv:1703.01703*, 2017.
- Karl-Theodor Sturm. The space of spaces: curvature bounds and gradient flows on the space of metric measure spaces. *arXiv preprint arXiv:1208.0434*, 2012.
- Richard S Sutton and Andrew G Barto. *Reinforcement learning: An introduction*. MIT press, 2018.
- Yuval Tassa, Yotam Doron, Alistair Muldal, Tom Erez, Yazhe Li, Diego de Las Casas, David Budden, Abbas Abdolmaleki, Josh Merel, Andrew Lefrancq, et al. Deepmind control suite. *arXiv preprint arXiv:1801.00690*, 2018.
- Emanuel Todorov, Tom Erez, and Yuval Tassa. Mujoco: A physics engine for model-based control. In *2012 IEEE/RSJ International Conference on Intelligent Robots and Systems*, pp. 5026–5033. IEEE, 2012.

- Titouan Vayer. A contribution to optimal transport on incomparable spaces. *arXiv preprint arXiv:2011.04447*, 2020.
- Titouan Vayer, L. Chapel, N. Courty, Rémi Flamary, Yann Soullard, and R. Tavenard. Time series alignment with global invariances. *ArXiv*, abs/2002.03848, 2020a.
- Titouan Vayer, Ievgen Redko, Rémi Flamary, and Nicolas Courty. Co-optimal transport. In H. Larochelle, M. Ranzato, R. Hadsell, M. F. Balcan, and H. Lin (eds.), *Advances in Neural Information Processing Systems*, volume 33, pp. 17559–17570. Curran Associates, Inc., 2020b. URL <https://proceedings.neurips.cc/paper/2020/file/cc384c68ad503482fb24e6d1e3b512ae-Paper.pdf>.
- Cédric Villani. *Optimal transport: old and new*, volume 338. Springer, 2009.
- Oriol Vinyals, Igor Babuschkin, Wojciech M Czarnecki, Michaël Mathieu, Andrew Dudzik, Junyoung Chung, David H Choi, Richard Powell, Timo Ewalds, Petko Georgiev, et al. Grandmaster level in starcraft ii using multi-agent reinforcement learning. *Nature*, 575(7782):350–354, 2019.
- Kevin Zakka, Andy Zeng, Pete Florence, Jonathan Tompson, Jeannette Bohg, and Debidatta Dwibedi. Xirl: Cross-embodiment inverse reinforcement learning. *arXiv preprint arXiv:2106.03911*, 2021.
- Feng Zhou and Fernando Torre. Canonical time warping for alignment of human behavior. *Advances in neural information processing systems*, 22:2286–2294, 2009.
- Yuke Zhu, Ziyu Wang, Josh Merel, Andrei Rusu, Tom Erez, Serkan Cabi, Saran Tunyasuvunakool, János Kramár, Raia Hadsell, Nando de Freitas, et al. Reinforcement and imitation learning for diverse visuomotor skills. *arXiv preprint arXiv:1802.09564*, 2018.

A 代理奖励的优化

在本节中，我们证明方程 9 中引入的代理奖励构成了一个易于使用标准强化学习算法优化的学习信号。图 6 展示了在 3 个环境中 5 个不同随机种子下的代理奖励曲线。我们观察到，在每个环境中，SAC 学习器都能快速且一致地收敛到渐近的回合回报。因此，有理由认为方程 9 中引入的代理奖励在其他跨域模仿设置中同样易于优化。




图 6: 方程 9 中引入的代理奖励提供了一个易于使用标准强化学习算法优化的学习信号。

B 迁移到稀疏奖励环境

本节展示，当学习者仅能获取来自另一领域的一条专家演示时，GWIL 如何促进稀疏奖励环境下的学习。我们将 GWIL 与一个基线学习者进行比较，后者仅能获取同一领域的一条演示，并如 Dadashi 等人 (2020) 所做的那样最小化 Wasserstein 距离。在这些实验中，两个智能体除了各自的最优传输代理奖励外，还获得稀疏奖励信号。我们在两个稀疏奖励环境中进行实验。在第一个环境中，智能体控制迷宫中的质点，只有到达迷宫终点才能获得非零奖励。在第二个环境中，即稀疏版 cartpole，智能体控制一个 cartpole，只有连续 10 个时间步保持 cartpole 直立才能获得非零奖励。注意，SAC 智能体在这两个环境中均未能学到任何有意义的行为。图 7 显示，在稀疏迷宫环境中，GWIL 与基线学习者具有竞争力，尽管 GWIL 只能获取来自另一领域的演示，而基线学习者能获取同一领域的演示。因此，有理由认为 GWIL 能高效且可靠地从专家领域提取有用信息，从而在其他跨域模仿设置中也应表现良好。



图 7：在稀疏奖励环境中，GWIL 获得的性能与最小化到同一领域专家 Wasserstein 距离的基线学习者相当。

C GWIL 的可扩展性

本节展示了本文所实现的 GWIL 在墙钟时间方面具有良好的性能。值得注意的是，本文方法的瓶颈在于最优耦合的计算，该计算仅取决于轨迹中的时间步数，而与专家和智能体的维度无关。因此，本文方法自然能够随问题维度进行扩展。此外，尽管本文在实验中未使用任何熵正则化项，但已有研究引入熵正则化方法以使 Gromov-Wasserstein 能够扩展到要求较高的机器学习任务中，并且这些方法可以轻松地整合到本文的代码中，以进一步提升可扩展性。图 8 比较了 GWIL 在迷宫环境中与上一节介绍的基线学习器所花费的时间。结果表明，使用 Gromov-Wasserstein 进行模仿所需的时间与使用 Wasserstein 进行模仿所需的时间处于同一数量级。图 9 比较了使用 GWIL 模仿猎豹的行走者达到行走速度（即水平速度为 1）所需的墙钟时间，与训练用于奔跑的 SAC 行走者所需的墙钟时间。结果表明，模仿猎豹的 GWIL 行走者比训练用于奔跑的 SAC 智能体更快达到行走速度。尽管 SAC 智能体除了奔跑外还优化了站立，但 GWIL 在墙钟时间方面能够与 SAC 竞争并非显而易见。这些结果带来了希望，即 GWIL 有潜力扩展到

更复杂的问题（可能借助额外的熵正则化项），并成为一种通过类比进行学习的有用方法。




图 8：在稀疏迷宫环境中，GWIL 所需的墙钟时间与在同一领域中最小化与专家之间 Wasserstein 距离的基线学习器处于同一数量级。




图 9：模仿猎豹的 GWIL 行走者在墙钟时间方面比训练用于奔跑的 SAC 行走者更快达到行走速度。