

观察与匹配：利用正则化最优传输加速模仿学习

Siddhant Halдар¹

Vaibhav Mathur

Denis Yarats

Lerrel Pinto

New York University

rot-robot.github.io

摘要：

模仿学习在高效学习复杂决策问题的策略方面展现出巨大潜力。当前最先进的算法通常采用逆强化学习（IRL），即给定一组专家演示，智能体交替推断奖励函数及相应的最优策略。然而，此类逆强化学习方法在处理复杂控制问题时往往需要大量的在线交互。本文提出正则化最优传输（ROT），这是一种新颖的模仿学习算法，建立在基于最优传输的轨迹匹配最新进展之上。我们的核心技术洞见在于，自适应地结合轨迹匹配奖励与行为克隆，即使仅使用少量演示也能显著加速模仿过程。我们在 DeepMind 控制套件、OpenAI 机器人套件和 Meta-World 基准中的 20 个视觉控制任务上进行了实验，结果表明，与先前最先进的方法相比，达到专家性能 90% 所需的模仿时间平均缩短了 7.8 $\times$ 。在真实世界机器人操作中，仅使用一次演示和一小时在线训练，ROT 在 14 项任务上实现了 90.1% 的平均成功率。

Keywords: Imitation Learning, Manipulation, Robotics




图 1：（上）正则化最优传输（ROT）是一种新颖的模仿学习算法，它自适应地结合离线行为克隆与基于在线轨迹匹配的奖励。这使得在各种模拟和真实机器人任务中能够显著加快模仿速度，同时兼容高维视觉观测。（下）在我们的 xArm 机器人上，ROT 仅需单次人类演示和不到一小时的在线训练即可学习视觉策略。

¹ 通讯作者: siddhanthaldar@nyu.edu

1 引言

模仿学习 (Imitation Learning, IL) [1, 2, 3] 拥有丰富的历史, 可划分为两大范式: 行为克隆 (Behavior Cloning, BC) [1] 与逆强化学习 (Inverse Reinforcement Learning, IRL) [4]。行为克隆利用监督学习获得一个策略, 该策略在给定演示中的观测时最大化采取演示动作的似然。尽管这允许无需在线交互即可训练, 但在在线推演过程中会遭受分布不匹配的问题 [5]。另一方面, 逆强化学习从演示轨迹中推断底层奖励函数, 随后采用强化学习通过在线环境推演来优化策略。这产生了一个即使在没有任务特定奖励的情况下也能稳健解决演示任务的策略 [6, 7]。尽管功能强大, 逆强化学习方法存在一个显著缺点——它们需要大量昂贵的与环境在线交互。原因有三: (a) 推断的奖励函数通常高度非平稳, 这损害了相关行为策略的学习 [7]; (b) 即使奖励是平稳的, 策略学习仍需要有效的探索来最大化奖励 [8]; (c) 当应用强先验 (如使用行为克隆进行预训练) 来加速策略学习时, 随后的策略更新会导致分布偏移, 从而破坏训练的稳定性 [9, 10]。综合来看, 这些问题在经验基准上表现出来, 逆强化学习方法在困难控制任务上的效率远低于普通强化学习方法 [11]。在本文中, 我们提出了用于模仿学习的正则化最优传输 (Regularized Optimal Transport, ROT), 这是一种概念简单、兼容高维观测、且与标准逆强化学习方法相比所需额外超参数极少的新方法。为了解决逆强化学习中奖励非平稳性的挑战, ROT 建立在近期利用最优传输 (Optimal Transport, OT) [12, 13, 11] 进行奖励计算的进展之上, 这些方法使用非参数轨迹匹配函数。为了缓解探索的挑战, 我们使用行为克隆在专家演示上预训练逆强化学习行为策略。这减少了我们的模仿智能体从头开始探索的需要。然而, 即使采用基于最优传输的奖励计算和预训练策略, 我们仅在经验性能上获得边际收益。原因在于逆强化学习策略梯度的高方差 [14, 15] 常常抹去离线行为克隆预训练所取得的进展。这一现象在在线强化学习 [16] 和离线强化学习 [9] 方法中均已被观察到。受这些工作中提出的解决方案启发, 我们通过正则化逆强化学习策略以保持接近预训练的行为克隆策略来稳定在线学习过程。为了实现这一点, 我们开发了一种新的自适应加权方案, 称为软 Q 过滤 (soft Q-filtering), 它自动设置正则化——在训练初期优先保持接近行为克隆策略, 后期优先探索。与先前的策略正则化方案 [16, 17] 相比, 软 Q 过滤不需要手动指定衰减计划。为了证明 ROT 的有效性, 我们在 DM Control [18]、OpenAI Robotics [19] 和 Meta-world [20] 的 20 个模拟任务以及 xArm 上的 14 个机器人操作任务 (见图 1) 上进行了大量实验。我们的主要发现总结如下。

1. ROT 超越了先前最先进的模仿方法, 在模拟视觉控制基准上达到专家性能的 90%, 且比我们最强的基线更快 $7.8\times$ 。
2. 在真实世界任务中, 仅使用一次人类演示和一小时训练, ROT 在随机机器人初始化和图像观测条件下实现了 90.1% 的平均成功率。这一结果显著高于行为克隆 (36.1%) 和对抗性逆强化学习 (14.6%)。
3. ROT 超过了使用奖励训练的最先进强化学习的性能, 同时接近将强化学习与演示相结合的方法 (第 4.5 节和附录 H.3)。与标准强化学习方法不同, ROT 不需要手工指定奖励函数。
4. 消融研究证明了 ROT 中每个组件的重要性, 特别是软 Q 过滤在稳定训练中的作用, 以及在线学习期间基于最优传输的奖励的必要性 (第 4.4 节和附录 H.4)。

开源代码和演示数据已公开发布在我们的项目网站上。我们训练策略的视频可在此查看: rot-robot.github.io。




图 2: 给定一次演示以避开灰色障碍物并到达目标位置, 行为克隆无法解决该任务 (a)。使用基于最优传输的奖励对该行为克隆策略进行微调也未能解决该任务 (b)。ROT 通过基于最优传输的逆强化学习与行为克隆的自适应正则化成功解决了该任务 (c)。即使 ROT 智能体随机初始化, 它也能够解决该任务 (d)。

2 Background

在详细描述我们的方法之前, 我们简要介绍基于最优传输的模仿学习背景, 这是我们方法的骨干。与强化学习相关的形式化遵循先前工作的惯例 [8, 11], 并在附录 A 中描述。

基于最优传输的模仿学习 模仿学习的目标是在能够访问专家策略 π^e 或由专家策略生成的轨迹 $\mathcal{T}^e$ 的条件下, 学习一个行为策略 π^b 。尽管存在多种对专家访问程度不同的设定 [21], 本文工作所处的设定是智能体仅能访问基于观测的轨迹, i.e. $\mathcal{T}^e \equiv \{(o_t, a_t)_{t=1}^T\}_{n=1}^N$ 。其中 N 和 T 分别表示轨迹回放次数和回合时间步数。逆强化学习 [4, 22] 通过基于专家轨迹 $\mathcal{T}^e$ 推断奖励函数 r^e 来解决模仿学习问题。随后, 利用推断出的奖励 r^e , 通过策略优化推导出行为策略 π^b 。为了计算 r^e , 一系列基于最优传输的模仿学习新方法 [12, 13, 11] 被提出。直观上, 专家轨迹 $\mathcal{T}^e$ 与行为轨迹 $\mathcal{T}^b$ 之间的接近程度可以通过测量从 $\mathcal{T}^b \rightarrow \mathcal{T}^e$ 的概率质量最优传输来计算。因此, 给定成本矩阵 $C_{t,t'} = c(o_t^b, o_{t'}^e)$ 以及行为轨迹 o^b 与专家轨迹 o^e 之间的最优对齐 μ^* , 每个观测的奖励信号可以通过以下方程计算:

$$r^{OT}(o_t^b) = - \sum_{t'=1}^T C_{t,t'} \mu_{t,t'}^* \quad (1)$$

最优传输公式的详细说明见附录 A。

基于演员-评论家的奖励最大化 给定通过最优传输计算得到的奖励, 可以通过离线策略学习高效地最大化奖励 [7]。本文采用深度确定性策略梯度 (DDPG) [23] 作为基础强化学习优化器, 它是一种演员-评论家算法, 同时学习确定性策略 π_ϕ 和 Q 函数 Q_θ 。然而, 与原始 DDPG 中最小化一步贝尔曼残差不同, 本文使用 Yarats 等人 [8] 提出的近期 n 步 DDPG 版本, 该版本在视觉控制问题上取得了高性能。

3 正则化最优传输

模仿学习中的一个根本性挑战是平衡模仿示范动作的能力与从示范状态分布之外的状态恢复的能力。行为克隆通过监督学习专注于模仿示范动作, 而逆强化学习专注于获得能够从任意状态恢复的策略。正则化最优传输通过自适应地结合这两个目标, 融合了两者的优点。从预训练策略进行在线微调所面临的挑战已被

如图 2 所述，更多细节见附录 B.1。ROT 分两个阶段运行。第一阶段，使用专家示范数据上的行为克隆目标训练随机初始化的策略。该“行为克隆预训练”策略随后作为第二阶段的初始化。第二阶段，策略被允许访问环境，并可使用逆强化学习目标进行训练。为加速逆强化学习训练，行为克隆损失以自适应权重加入目标。各组成部分的细节如下，更多算法细节见附录 C。

3.1 第一阶段：行为克隆预训练

行为克隆对应于求解式 2 所示的最大似然问题。此处 $\mathcal{T}^e$ 指专家示范。当用固定方差的正态分布参数化时，该目标可表述为回归问题：给定输入 s^e, π^{BC} ，需要输出 a^e 。

$$\mathcal{L}^{BC} = \mathbb{E}_{(s^e, a^e) \sim \mathcal{T}^e} \|a^e - \pi^{BC}(s^e)\|^2 \quad (2)$$

训练后，它使 π^{BC} 能够模仿示范中观测对应的动作。然而，在环境中展开时，动作预测的微小误差可能导致智能体访问示范中未出现的状态 [5]。这种分布不匹配常导致 π^{BC} 在经验基准上失败 [16, 11]（见附录 B 中图 ?? (a)）。

3.2 第二阶段：基于逆强化学习的在线微调

给定预训练的 π^{BC} 模型，我们开始在环境中对策略 $\pi^b \equiv \pi^{ROT}$ 进行在线“微调”。由于没有显式任务奖励，我们使用第 2 节描述的基于最优传输的轨迹匹配获得的奖励。这些基于最优传输的奖励 r^{OI} 使得可以使用标准强化学习优化器来最大化来自 $\pi^b \equiv \pi^{ROT}$ 的累积奖励。本文使用 n 步 DDPG [23]，这是一种基于确定性演员-评论家的方法，在连续控制中提供高性能 [8]。

带正则化的微调 π^{BC} 易受在线展开过程中误差累积引起的分布偏移影响 [5]，直接微调 π^{BC} 也会导致性能不佳（参见图 2）。为解决此问题，我们借鉴引导强化学习 [16] 和离线强化学习 [9] 的先前工作，通过将 π^{ROT} 与式 3 所示的行为克隆损失相结合来正则化其训练。

$$\pi^{ROT} = \operatorname{argmax}_{\pi} \left[(1 - \lambda(\pi)) \mathbb{E}_{(s, a) \sim \mathcal{D}_{\beta}} [Q(s, a)] - \alpha \lambda(\pi) \mathbb{E}_{(s^e, a^e) \sim \mathcal{T}^e} \|a^e - \pi(s^e)\|^2 \right] \quad (3)$$

此处， $Q(s, a)$ 表示来自评论家的 Q 值，该值在演员-评论家策略优化过程中利用基于最优传输的奖励进行优化。 α 是一个固定权重，而 $\lambda(\pi)$ 是一个依赖于策略的自适应权重，用于控制两个损失项的贡献。 $\mathcal{D}_{\beta}$ 指的是用于在线采样的回放缓冲区。

基于软 Q 滤波的自适应正则化 尽管先前工作 [16, 17] 为 $\lambda(\pi)$ 使用手工调整的时间表，本文提出一种新的自适应方案，无需调参。具体做法是比较当前策略 π^{ROT} 与预训练策略 π^{BC} 在从回放缓冲区采样的在线轨迹数据批次 $\mathcal{D}_{\beta}$ 上的性能。更准确地说，给定行为策略 $\pi^{BC}(s)$ 、当前策略 $\pi^{ROT}(s)$ 、Q 函数 $Q(s, a)$ 和回放缓冲区 $\mathcal{D}_{\beta}$ ，我们将 λ 设置为：

$$\lambda(\pi^{ROT}) = \mathbb{E}_{(s, \cdot) \sim \mathcal{D}_{\beta}} \left[\mathbb{1}_{Q(s, \pi^{BC}(s)) > Q(s, \pi^{ROT}(s))} \right] \quad (4)$$

因此，行为克隆 (BC) 正则化的强度取决于当前策略相对于行为策略的性能。该过滤策略受 Nair 等人 [24] 的启发，其中我们使用软连续权重而非二元硬分配。与手动调整衰减策略的实验比较见第 4.4 节。

基于图像观测的考量 由于我们关注的是将 ROT 应用于高维视觉观测，因此需要额外的机制来确保兼容性。遵循基于图像的强化学习和模仿学习中的先前工作 [8, 11]，我们对视觉观测执行数据增强，然后将其输入到卷积神经网络编码器中。与 Cohen 等人 [11] 类似，我们使用一个目标

采用带 Polyak 平均的编码器以获取用于最优传输奖励计算的表征。此举对于降低因编码器与正则化最优传输模仿过程同步学习所导致的非平稳性而言是必要的。更多实现细节与训练流程见附录 C。

4 实验

我们的实验旨在回答以下问题：（a）ROT 在模仿学习中的效率如何？（b）ROT 在真实世界任务中的表现如何？（c）ROT 中 IRL 方法的选择有多重要？（d）软 Q 过滤是否改进了模仿学习？（e）ROT 与标准基于奖励的强化学习相比如何？更多结果和分析见附录 H。

模拟任务 我们在 DeepMind Control 套件 [18, 25] 的 10 个任务、OpenAI Robotics 套件 [26] 的 3 个任务以及 Meta-world 套件 [27] 的 7 个任务上进行了实验。对于 DeepMind Control 任务，我们使用 DrQ-v2 [8] 训练专家策略，并为每个任务收集 10 条演示。对于 OpenAI Robotics 任务，我们训练了一个基于状态的 DrQ-v2，并结合后见经验回放 [28]，为每个任务收集 50 条演示。对于 Meta-world 任务，我们使用其开源实现 [27] 中的单个硬编码专家演示。完整的环境细节见附录 D，演示和初始化条件的变化细节见附录 E。

机器人任务 我们针对 14 个操作任务中的每一个的真实世界设置如图 4 所示。我们使用配备 xArm 夹爪的 Ufactory xArm 7 机器人作为真实世界实验的机器人平台。然而，我们的方法不依赖于特定的机器人硬件。观测来自固定相机的 RGB 图像。在此设置中，我们仅使用人类操作员通过操纵杆收集的单个专家演示，并将在线训练限制在固定的 1 小时内。每个任务的描述和评估流程见附录 F。

主要基线 我们将 ROT 与几种重要的模仿学习方法的基线进行了比较。基线的完整描述见附录 G，其中两个最强基线的简要描述如下：

1. 对抗性 IRL (DAC)：判别器-演员-评论家 [7] 是一种最先进的对抗性模仿学习方法 [6, 29, 7]。DAC 优于先前的工作，如 GAIL [6] 和 AIRL [30]，因此它作为我们的主要对抗性模仿基线。
2. 轨迹匹配逆强化学习（最优传输）：辛霍恩模仿学习 [12, 13] 是一种最先进的

轨迹匹配模仿学习方法 [31]，通过辛霍恩-克诺普算法 [32, 33] 近似最优传输匹配。由于 ROT 源自类似的最优传输基础，我们使用 SIL 作为主要的状态匹配模仿基线。

4.1 ROT 在模仿学习中的效率如何？

基于图像的模仿任务中 ROT 的性能在部分环境上如图 3 所示。除一项任务外，ROT 的训练速度显著快于先前工作。要达到专家性能的 90%，ROT 在 DeepMind Control 任务上平均快 $8.7\times$ ，在 OpenAI Robotics 任务上快 $2.1\times$ ，在 Meta-world 任务上快 $8.9\times$ 。我们还发现 ROT 的改进在较难的任务上最为明显，这些任务位于图 3 的最右列。附录 H.1 展示了全部 20 个模拟任务的结果，以及基于状态设置中表现出类似改进的实验。

4.2 ROT 在真实世界任务中的表现如何？

我们在 xArm 机器人上设计了一组 14 个操作任务，以比较 ROT 与 BC 以及我们最强的基线 RDAC 的性能。RDAC 是一种对抗性逆强化学习方法，结合了 DAC [7] 与我们的预训练和正则化方案。BC 策略使用监督学习在人类操作员收集的单个专家演示上进行训练。ROT 和 RDAC 通过 1 小时的在线训练微调预训练的 BC 策略，相当于 $\sim 6k$ 环境步数。由于只有一个演示，我们的任务设计为具有随机初始化但固定目标。注意，单个演示仅展示了从一种初始条件解决任务。在 20 种不同初始条件下的评估结果如图 4 所示。我们观察到 ROT




图 3: 9 个选定环境上的基于像素的连续控制学习。阴影区域表示 5 个种子下的 ± 1 标准差。我们注意到 ROT 的样本效率显著高于先前工作。




图 4: (上) ROT 在 14 个机器人操作任务集上进行评估。(下) 每个任务的成功率通过在机器人上从不同初始条件运行 20 条轨迹来计算。




图 5: 关于基础逆强化学习方法选择的消融分析。我们发现，尽管对抗性方法受益于正则化行为克隆，但相比 ROT，其增益较小。此外，我们还发现 ROT 能够超越需要显式任务奖励的普通强化学习。

在所有任务上，20 条评估轨迹的平均成功率为 90.1%，而行为克隆为 36.1%，正则化判别器-演员-评论家为 14.6%。行为克隆表现不佳可归因于在线推演中误差累积和不同初始条件导致的分布不匹配。正则化判别器-演员-评论家表现不佳可归因于训练初期学习缓慢。关于正则化判别器-演员-评论家在模拟环境中的更详细评估见第 4.3 节。

4.3 逆强化学习方法的选择在 ROT 中有多重要？

在 ROT 中，我们基于最优传输的逆强化学习而非对抗性逆强化学习。这是因为对抗性逆强化学习方法需要迭代奖励学习，这会产生高度非平稳的奖励函数用于策略优化。在图 5 中，我们将 ROT 与使用我们的预训练和自适应行为克隆正则化技术的对抗性逆强化学习方法（正则化判别器-演员-评论家）进行比较。我们发现，我们的软 Q 滤波方法确实改进了先前最先进的对抗性逆强化学习（图 5 中正则化判别器-演员-评论家与判别器-演员-评论家对比）。然而，我们基于最优传输的方法（ROT）更稳定，平均而言学习效率更高。

4.4 软 Q 滤波是否改善模仿？

为理解软 Q 滤波的重要性，本文将 ROT 与所提正则化方案的两种变体进行比较：(a) 固定调优的行为克隆正则化权重（忽略式 3 中的 $\lambda(\pi)$ ）；(b) 精心设计的线性衰减调度，其中 $\lambda(\pi)$ 在前 20k 环境步中从 1.0 变化至 0.0 [16]。如图 6（及附录 H.2）所示，ROT 与手工调优的衰减调度效率相当，在某些情况下甚至更优，同时无需手工调优其正则化权重。本文推测这一改进主要源于自适应加权的更好稳定性，这体现在元世界任务上显著更小的标准差。




图 6: 各种行为克隆正则化方案与本文自适应软 Q 滤波正则化的效果对比。

4.5 ROT 与标准基于奖励的强化学习相比如何？

本文将 ROT 的性能与 DrQ-v2[8] 进行比较，后者是基于图像的强化学习的最先进算法。与 ROT 运行的无奖励设置不同，DrQ-v2 可以访问环境奖励。图 5 中的结果表明，ROT 轻松超越了 DrQ-v2。这清楚地证明了在可获得专家演示的领域中，模仿学习相对于基于奖励的强化学习的有效性。本文还与使用与 ROT 相同预训练和正则化方案的演示辅助 DrQ-v2 智能体变体进行了比较（参见附录 H.3）。有趣的是，本文发现基于软 Q 滤波的正则化可以加速带有任务奖励的强化学习，这体现在演示辅助 DrQ-v2 变体的高性能上。

5 相关工作

模仿学习 (Imitation Learning)

智能体从专家策略学习

或从专家策略派生的演示中学习，而无需访问环境奖励。模仿学习可大致分为行为克隆 (Behavior Cloning) [1, 21] 和逆强化学习 (Inverse Reinforcement Learning) [4, 22]。行为克隆仅从离线演示中学习，但在分布外样本上表现不佳 [5]；而逆强化学习侧重于通过在线交互学习鲁棒的奖励函数，但存在样本效率低下的问题 [7]。深度逆强化学习方法可进一步分为两类：(1) 基于对抗学习 [35] 的方法，以及 (2) 基于状态匹配 [36, 37] 的方法。GAIL[6]

是一种基于对抗学习的公式化方法，其灵感来源于最大熵逆强化学习 (Maximum Entropy IRL) [38] 和生成对抗网络 (GANs) [35]。在 GAIL 的基础上，已有大量工作提出了替代损失函数 [30, 39, 29]，并通过将其移植到离线策略 (off-policy) 设置中来提高样本效率 [7]。此外，还出现了这些对抗学习方法的视觉扩展 [40, 41, 42]。然而，尽管对抗方法能够产生有效的策略，但由于迭代奖励推断带来的非平稳性，它们效率低下。为了缓解对抗逆强化学习框架中的非平稳奖励问题，最近提出了一系列基于最优传输 (Optimal Transport) 的状态匹配方法 [12, 13, 11]。

最优传输 (Optimal Transport) 最优传输 (Optimal Transport, OT) [36, 37] 是一种在考虑空间几何结构的同时比较概率测度的工具。在模仿学习 (Imitation Learning, IL) 的背景下，OT 利用距离度量 (如 Sinkhorn [33]、Gromov-Wasserstein [43]、GDTW [44]、CO-OT [45] 和 Soft-DTW [46]) 计算一组智能体观测与专家观测之间的对齐。对于这些距离度量中的许多，都存在相应的 IL 算法，例如 SIL [12] 使用 Sinkhorn，PWIL [13] 使用贪心 Wasserstein，GDTW-IL [44] 使用 GDTW，GWIL [47] 使用 Gromov-Wasserstein。Cohen 等人 [11] 的最新工作表明，在所讨论的度量中，Sinkhorn 距离 [12] 能产生最高效的学习。他们进一步证明 SIL 与高维视觉观测和编码表示兼容。受此启发，ROT 采用 Sinkhorn 度量进行 OT 奖励计算，并通过自适应行为正则化对 SIL 进行了改进。

行为正则化控制 (Behavior Regularized Control) 行为正则化是离线强化学习中广泛使用的技术 [48]，通过在策略改进更新中加入显式约束，避免对分布外动作进行自举 [49, 50, 51, 52, 53, 54]。在可获取环境奖励的在线设置中，先前工作 [16, 10] 表明，通过在线交互微调预训练策略，行为正则化可提升样本效率。例如，Jena 等人 [17] 证明了行为正则化在对抗性模仿学习背景下提升样本效率的有效性。ROT 在此基础上扩展至视觉观测、基于最优传输的模仿学习以及自适应正则化，从而带来性能提升 (见附录 H.4)。我们还注意到，自适应正则化的思想此前已在强化学习中探索过 [24]。然而，ROT 采用软性、连续的自适应方案，初步实验表明其学习速度显著快于硬性分配。

6 结论与局限性

本文提出了一种新的模仿学习算法 ROT，在多种仿真和机器人领域相比先前最先进的工作展现出更优的性能。然而，我们认识到本工作存在若干局限性：(a) 由于我们基于最优传输的方法在没有任务特定奖励的情况下将智能体与演示对齐，因此依赖于演示者是“专家”这一假设。将 ROT 扩展到次优、含噪和多模态演示将是一个值得探索的激动人心的问题。(b) 执行行为克隆预训练和基于行为克隆的正则化需要访问专家动作，而在某些现实场景中，尤其是从人类学习时，可能无法获得这些动作。近期利用逆模型从观测数据推断动作的工作可缓解这一挑战 [55]。(c) 在如图 4 所示的“盒中钉 (困难)”和“按压开关”等机器人任务中，我们发现 ROT 的性能相比其他任务大幅下降。这可能是由于缺乏与任务成功相对应的视觉特征。例如，在“钉”任务中，视觉上难以区分钉是在盒内还是盒后。类似地，在“开关”任务中，难以辨别按钮是否被按下。这一局限性可通过在观测空间中集成更多感官模态 (如额外摄像头和触觉传感器) 来解决。

致谢

感谢本·埃文斯 (Ben Evans)、安东尼·陈 (Anthony Chen)、乌利亚娜·皮特巴格 (Ulyana Piterbarg) 和阿比莎·坦卡拉杰 (Abitha Thankaraj) 提出的宝贵反馈与讨论。本研究得到了本田 (Honda)、亚马逊 (Amazon) 的资助, 以及美国海军研究办公室 (ONR) 奖项 N00014-21-1-2404 和 N00014-21-1-2758 的支持。

参考文献

- [1] D. Pomerleau. An autonomous land vehicle in a neural network. *Advances in Neural Information Processing Systems*, 1, 1998.
- [2] O. M. Andrychowicz, B. Baker, M. Chociej, R. Jozefowicz, B. McGrew, J. Pachocki, A. Petron, M. Plappert, G. Powell, A. Ray, et al. Learning dexterous in-hand manipulation. *The International Journal of Robotics Research*, 39(1):3–20, 2020.
- [3] P. N. Kolm and G. Ritter. Modern perspectives on reinforcement learning in finance. *Modern Perspectives on Reinforcement Learning in Finance (September 6, 2019). The Journal of Machine Learning in Finance*, 1(1), 2020.
- [4] A. Y. Ng, S. J. Russell, et al. Algorithms for inverse reinforcement learning. In *Icml*, volume 1, page 2, 2000.
- [5] S. Ross, G. Gordon, and D. Bagnell. A reduction of imitation learning and structured prediction to no-regret online learning. In *Proceedings of the fourteenth international conference on artificial intelligence and statistics*, pages 627–635. JMLR Workshop and Conference Proceedings, 2011.
- [6] J. Ho and S. Ermon. Generative adversarial imitation learning. *Advances in neural information processing systems*, 29, 2016.
- [7] I. Kostrikov, K. K. Agrawal, D. Dwibedi, S. Levine, and J. Tompson. Discriminator-actor-critic: Addressing sample inefficiency and reward bias in adversarial imitation learning. *arXiv preprint arXiv:1809.02925*, 2018.
- [8] D. Yarats, R. Fergus, A. Lazaric, and L. Pinto. Mastering visual continuous control: Improved data-augmented reinforcement learning. *arXiv preprint arXiv:2107.09645*, 2021.
- [9] A. Nair, A. Gupta, M. Dalal, and S. Levine. Awac: Accelerating online reinforcement learning with offline datasets. *arXiv preprint arXiv:2006.09359*, 2020.
- [10] I. Uchendu, T. Xiao, Y. Lu, B. Zhu, M. Yan, J. Simon, M. Bennice, C. Fu, C. Ma, J. Jiao, et al. Jump-start reinforcement learning. *arXiv preprint arXiv:2204.02372*, 2022.
- [11] S. Cohen, B. Amos, M. P. Deisenroth, M. Henaff, E. Vinitsky, and D. Yarats. Imitation learning from pixel observations for continuous control, 2022. URL <https://openreview.net/forum?id=JLbXkHkLcG6>.
- [12] G. Papagiannis and Y. Li. Imitation learning with sinkhorn distances. *arXiv preprint arXiv:2008.09167*, 2020.
- [13] R. Dadashi, L. Hussenot, M. Geist, and O. Pietquin. Primal wasserstein imitation learning. *arXiv preprint arXiv:2006.04678*, 2020.
- [14] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- [15] D. Silver, G. Lever, N. Heess, T. Degris, D. Wierstra, and M. Riedmiller. Deterministic policy gradient algorithms. In *International conference on machine learning*, pages 387–395. PMLR, 2014.
- [16] A. Rajeswaran, V. Kumar, A. Gupta, G. Vezzani, J. Schulman, E. Todorov, and S. Levine. Learning complex dexterous manipulation with deep reinforcement learning and demonstrations. *arXiv preprint arXiv:1709.10087*, 2017.

- [17] R. Jena, C. Liu, and K. Sycara. Augmenting gail with bc for sample efficient imitation learning. *arXiv preprint arXiv:2001.07798*, 2020.
- [18] Y. Tassa, Y. Doron, A. Muldal, T. Erez, Y. Li, D. d. L. Casas, D. Budden, A. Abdolmaleki, J. Merel, A. Lefrancq, et al. Deepmind control suite. *arXiv preprint arXiv:1801.00690*, 2018.
- [19] G. Brockman, V. Cheung, L. Pettersson, J. Schneider, J. Schulman, J. Tang, and W. Zaremba. Openai gym. *arXiv preprint arXiv:1606.01540*, 2016.
- [20] T. Yu, D. Quillen, Z. He, R. Julian, K. Hausman, C. Finn, and S. Levine. Meta-world: A benchmark and evaluation for multi-task and meta reinforcement learning. In *Conference on Robot Learning*, pages 1094–1100. PMLR, 2020.
- [21] F. Torabi, G. Warnell, and P. Stone. Recent advances in imitation learning from observation. *arXiv preprint arXiv:1905.13566*, 2019.
- [22] P. Abbeel and A. Y. Ng. Apprenticeship learning via inverse reinforcement learning. In *Proceedings of the twenty-first international conference on Machine learning*, page 1, 2004.
- [23] T. P. Lillicrap, J. J. Hunt, A. Pritzel, N. Heess, T. Erez, Y. Tassa, D. Silver, and D. Wierstra. Continuous control with deep reinforcement learning. *arXiv preprint arXiv:1509.02971*, 2015.
- [24] A. Nair, B. McGrew, M. Andrychowicz, W. Zaremba, and P. Abbeel. Overcoming exploration in reinforcement learning with demonstrations. In *2018 IEEE international conference on robotics and automation (ICRA)*, pages 6292–6299. IEEE, 2018.
- [25] E. Todorov, T. Erez, and Y. Tassa. Mujoco: A physics engine for model-based control. In *2012 IEEE/RSJ international conference on intelligent robots and systems*, pages 5026–5033. IEEE, 2012.
- [26] M. Plappert, M. Andrychowicz, A. Ray, B. McGrew, B. Baker, G. Powell, J. Schneider, J. Tobin, M. Chociej, P. Welinder, et al. Multi-goal reinforcement learning: Challenging robotics environments and request for research. *arXiv preprint arXiv:1802.09464*, 2018.
- [27] T. Yu, D. Quillen, Z. He, R. Julian, K. Hausman, C. Finn, and S. Levine. Meta-world: A benchmark and evaluation for multi-task and meta reinforcement learning. In *Conference on Robot Learning (CoRL)*, 2019. URL <https://arxiv.org/abs/1910.10897>.
- [28] M. Andrychowicz, F. Wolski, A. Ray, J. Schneider, R. Fong, P. Welinder, B. McGrew, J. Tobin, O. Pieter Abbeel, and W. Zaremba. Hindsight experience replay. *Advances in neural information processing systems*, 30, 2017.
- [29] F. Torabi, G. Warnell, and P. Stone. Generative adversarial imitation from observation. *arXiv preprint arXiv:1807.06158*, 2018.
- [30] J. Fu, K. Luo, and S. Levine. Learning robust rewards with adversarial inverse reinforcement learning. *arXiv preprint arXiv:1710.11248*, 2017.
- [31] S. K. S. Ghasemipour, R. Zemel, and S. Gu. A divergence minimization perspective on imitation learning methods. In *Conference on Robot Learning*, pages 1259–1277. PMLR, 2020.
- [32] R. Sinkhorn and P. Knopp. Concerning nonnegative matrices and doubly stochastic matrices. *Pacific Journal of Mathematics*, 21(2):343–348, 1967.
- [33] M. Cuturi. Sinkhorn distances: Lightspeed computation of optimal transport. *Advances in neural information processing systems*, 26, 2013.
- [34] A. Hussein, M. M. Gaber, E. Elyan, and C. Jayne. Imitation learning: A survey of learning methods. *ACM Computing Surveys (CSUR)*, 50(2):1–35, 2017.
- [35] I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio. Generative adversarial nets. *Advances in neural information processing systems*, 27, 2014.
- [36] C. Villani. *Optimal transport: old and new*, volume 338. Springer, 2009.

- [37] G. Peyré, M. Cuturi, et al. Computational optimal transport: With applications to data science. *Foundations and Trends® in Machine Learning*, 11(5-6):355–607, 2019.
- [38] B. D. Ziebart, A. L. Maas, J. A. Bagnell, A. K. Dey, et al. Maximum entropy inverse reinforcement learning. In *Aaai*, volume 8, pages 1433–1438. Chicago, IL, USA, 2008.
- [39] H. Xiao, M. Herman, J. Wagner, S. Ziesche, J. Etesami, and T. H. Linh. Wasserstein adversarial imitation learning. *arXiv preprint arXiv:1906.08113*, 2019.
- [40] E. Cetin and O. Celiktutan. Domain-robust visual imitation learning with mutual information constraints. *arXiv preprint arXiv:2103.05079*, 2021.
- [41] S. Toyer, R. Shah, A. Critch, and S. Russell. The magical benchmark for robust imitation. *Advances in Neural Information Processing Systems*, 33:18284–18295, 2020.
- [42] R. Rafailov, T. Yu, A. Rajeswaran, and C. Finn. Visual adversarial imitation learning using variational models. *Advances in Neural Information Processing Systems*, 34, 2021.
- [43] G. Peyré, M. Cuturi, and J. Solomon. Gromov-wasserstein averaging of kernel and distance matrices. In *International Conference on Machine Learning*, pages 2664–2672. PMLR, 2016.
- [44] S. Cohen, G. Luise, A. Terenin, B. Amos, and M. Deisenroth. Aligning time series on incomparable spaces. In *International Conference on Artificial Intelligence and Statistics*, pages 1036–1044. PMLR, 2021.
- [45] I. Redko, T. Vayer, R. Flamary, and N. Courty. Co-optimal transport. *arXiv preprint arXiv:2002.03731*, 2020.
- [46] M. Cuturi and M. Blondel. Soft-dtw: a differentiable loss function for time-series. In *International conference on machine learning*, pages 894–903. PMLR, 2017.
- [47] A. Fickinger, S. Cohen, S. Russell, and B. Amos. Cross-domain imitation learning via optimal transport. *arXiv preprint arXiv:2110.03684*, 2021.
- [48] S. Levine, A. Kumar, G. Tucker, and J. Fu. Offline reinforcement learning: Tutorial, review, and perspectives on open problems. *arXiv preprint arXiv:2005.01643*, 2020.
- [49] S. Fujimoto and S. S. Gu. A minimalist approach to offline reinforcement learning. *Advances in Neural Information Processing Systems*, 34, 2021.
- [50] Y. Wu, G. Tucker, and O. Nachum. Behavior regularized offline reinforcement learning. *arXiv preprint arXiv:1911.11361*, 2019.
- [51] A. Ajay, A. Kumar, P. Agrawal, S. Levine, and O. Nachum. {OPAL}: Offline primitive discovery for accelerating offline reinforcement learning. In *International Conference on Learning Representations*, 2021. URL <https://openreview.net/forum?id=V69LGwJ01IN>.
- [52] A. Kumar, J. Fu, M. Soh, G. Tucker, and S. Levine. Stabilizing off-policy q-learning via bootstrapping error reduction. *Advances in Neural Information Processing Systems*, 32, 2019.
- [53] N. Y. Siegel, J. T. Springenberg, F. Berkenkamp, A. Abdolmaleki, M. Neunert, T. Lampe, R. Hafner, N. Heess, and M. Riedmiller. Keep doing what worked: Behavioral modelling priors for offline reinforcement learning. *arXiv preprint arXiv:2002.08396*, 2020.
- [54] S. Fujimoto, D. Meger, and D. Precup. Off-policy deep reinforcement learning without exploration. In *International Conference on Machine Learning*, pages 2052–2062. PMLR, 2019.
- [55] I. Radosavovic, X. Wang, L. Pinto, and J. Malik. State-only imitation learning for dexterous manipulation. In *2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 7865–7871. IEEE, 2020.
- [56] R. Bellman. A markovian decision process. *Journal of mathematics and mechanics*, pages 679–684, 1957.
- [57] R. S. Sutton and A. G. Barto. *Reinforcement learning: An introduction*. MIT press, 2018.

- [58] V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski, et al. Human-level control through deep reinforcement learning. *nature*, 518(7540):529–533, 2015.
- [59] A. Zhan, P. Zhao, L. Pinto, P. Abbeel, and M. Laskin. A framework for efficient robotic manipulation. *arXiv preprint arXiv:2012.07975*, 2020.
- [60] S. Young, D. Gandhi, S. Tulsiani, A. Gupta, P. Abbeel, and L. Pinto. Visual imitation made easy. *arXiv preprint arXiv:2008.04899*, 2020.
- [61] P. A. Knight. The sinkhorn–knopp algorithm: convergence and applications. *SIAM Journal on Matrix Analysis and Applications*, 30(1):261–275, 2008.