

深度广义薛定谔桥

Guan-Horng Liu¹, Tianrong Chen^{1*}, Oswin So^{2*}, Evangelos A. Theodorou¹

¹Georgia Institute of Technology, USA

²Massachusetts Institute of Technology, USA

{ghliu, tianrong.chen, evangelos.theodorou}@gatech.edu

oswinso@mit.edu

摘要

均场博弈 (Mean-Field Game, MFG) 是建模个体智能体与大规模群体随机交互的集体行为的重要数学框架。本文旨在解决一类具有挑战性的均场博弈问题，其中求解器可能无法获得这些交互偏好的可微性，且群体被要求精确收敛到某个期望分布。尽管这些设定在实际应用中具有充分的动机，但其复杂性足以使大多数 (深度) 数值求解器失效。然而，我们证明薛定谔桥 (Schrödinger Bridge) ——作为一种熵正则化的最优传输模型——可以推广以接受均场结构，从而求解这些均场博弈。这一目标通过应用正倒向随机微分方程理论实现，有趣的是，该理论导出了一个与时间差分学习结构相似的框架。因此，它开辟了与深度强化学习的新颖算法联系，我们利用这一联系来促进实用训练。我们证明所提出的目标函数为均场问题提供了充分必要条件。我们的方法名为深度广义薛定谔桥 (DeepGSB)，不仅在求解经典群体导航均场博弈中优于先前方法，而且能够求解 1000 维观点去极化问题，为高维均场博弈设立了新的最先进数值求解器。我们的代码将在 <https://github.com/ghliu/DeepGSB> 公开。

1 引言

在一个炎热的早晨，你穿过人群走向办公室。当你走过人行横道时，你正在思考过去一周公众对一项新政策日益增长的意见，突然被交通开始移动时的鸣笛声打断……

从人群中的导航到观点的传播和交通流动，个体智能体与大规模群体交互的例子在日常生活中随处可见，并且由于其普遍性，成为多学科科学领域的重要研究对象，包括经济学 [1, 2]、观点建模 [3 – 5]、机器人学 [6, 7]，以及最近的机器学习 [8 – 10]。

从数学角度而言，这些场景下的决策过程可由均场博弈 (Mean-Field Game, MFG) [11 – 13] 刻画，该模型描述有限时域上连续统理性智能体之间的非合作微分博弈。设 $u(x, t)$ 为值




图 1: DeepGSB 在薛定谔桥 (SB) 与基于模型的深度强化学习之间开辟了新的算法联系，用于求解高维均场博弈。

* 这些作者贡献相同。工作是在奥斯温 (Oswin) 任职于佐治亚理工学院 (Georgia Tech) 期间完成的。

表 1：与现有方法在均场博弈（Mean-Field Games, MFGs）各项期望特性上的比较。本文提出的 DeepGSB 能够在更高维状态空间中求解更广泛的均场博弈类别。

	continuous state space	stochastic MF dyn. (2)	converges to exact ρ_{target}	discontinuous MF interaction F	highest dimension
Ruthotto et al. [14]	✓	✗	✗	✗	100
Lin et al. [15]	✓	✗	✗	✗	100
Chen [16]	✗	✓	✓	✗ ¹	2
DeepGSB (ours)	✓	✓	✓	✓	1000

函数，亦称最优代价至目标，支配着每个状态 $x \in \mathbb{R}^d$ 和时间 $t \in [0, T]$ 下智能体的策略，并将由此产生的人口密度记为 $\rho(\cdot, t) \in \mathcal{P}(\mathbb{R}^d)$ ，其中 $\mathcal{P}(\mathbb{R}^d)$ 是 $\mathbb{R}^d$ 上的概率测度集合。在纳什均衡处，任何智能体都没有动机改变其决策，平均场博弈（MFG）在最一般的形式下，求解以下偏微分方程（PDEs）：

$$\begin{cases} -\frac{\partial u(x, t)}{\partial t} + H(x, \nabla u, \rho) - \frac{1}{2}\sigma^2 \Delta u = F(x, \rho), & u(x, T) = G(x, \rho(\cdot, T)) \\ \frac{\partial \rho(x, t)}{\partial t} - \nabla \cdot (\rho \nabla_p H(x, \nabla u, \rho) - \frac{1}{2}\sigma^2 \Delta \rho) = 0, & \rho(x, 0) = \rho_0(x) \end{cases}, \quad (1)$$

其中 $\nabla, \nabla \cdot, \Delta$ 分别为梯度、散度和拉普拉斯算子。² 这两个偏微分方程分别称为哈密顿-雅可比-贝尔曼方程和福克-普朗克方程，它们刻画了 $u(x, t)$ 和 $\rho(x, t)$ 的演化。二者通过哈密顿量 $H(x, p, \rho) : \mathbb{R}^d \times \mathbb{R}^d \times \mathcal{P}(\mathbb{R}^d) \rightarrow \mathbb{R}$ 相互耦合，该哈密顿量描述了博弈的动力学；同时通过平均场相互作用 $F(x, \rho) : \mathbb{R}^d \times \mathcal{P}(\mathbb{R}^d) \rightarrow \mathbb{R}$ 耦合，该相互作用量化了智能体与群体交互时的偏好。终端条件 G 通常惩罚与某个期望目标分布 ρ_{target} ，e.g., $G \approx D_{\text{KL}}(\rho(\cdot, T) || \rho_{\text{target}}(\cdot))$ 的偏差。给定方程 (1) 的解 (u, ρ) ，每个智能体据此行动并遵循一个随机微分方程

$$dX_t = -\nabla_p H(X_t, \nabla u(X_t, t), \rho(\cdot, t))dt + \sigma dW_t, \quad X_0 \sim \rho_0, \quad (2)$$

其中 $W_t \in \mathbb{R}^d$ 是维纳过程， $\sigma \in \mathbb{R}$ 是某个扩散标量。在平均场极限下，即当智能体数量趋于无穷时，(2) 的集体行为产生密度 $\rho(\cdot, t)$ 。

在机器学习（Machine Learning）的辅助下，求解方程 (1) 的数值方法取得了快速进展。Ruthotto 等人 [14] 与 Lin 等人 [15] 的开创性工作利用深度神经网络（Deep Neural Networks, DNNs）逼近 (u, ρ) ，并直接惩罚偏微分方程（PDEs）的违反。尽管初步取得了成功，但底层动力学 (2) 要么是退化的（e.g., $\sigma := 0$ ）[14]，要么被完全丢弃，转而通过在整个状态空间上回归网络输出 [15]，随着维度 d 的增长，这种方法的扩展性可能不佳。另一种避免这两种局限性的替代方案是，通过应用非线性费曼-卡茨引理（Feynman-Kac Lemma）[17–19]，将这些偏微分方程重新表述为一组正倒向随机微分方程（Forward-Backward SDEs, FBSDEs），既保留了 (2) 中的完整随机动力学，又具有计算可扩展性。FBSDEs 分析在平均场博弈（Mean Field Games, MFG）的理论研究中广泛出现 [20–23]，然而令人惊讶的是，基于 FBSDEs 的可扩展求解器的开发仍然有限。我们的工作为这一方向做出了贡献。

由于 ρ_{target} 是先验已知的，在许多情况下，人们直接关注于寻找一个最优策略，引导智能体从初始分布 ρ_0 到达精确的 ρ_{target} ，同时尊重 MFG 的结构，特别是平均场相互作用 $F(x, \rho)$ 。然而，将 (1) 提升到这种设置是高度非平凡的。实际上，将 $u(x, T) = D_{\text{KL}}(\rho || \rho_{\text{target}})$ 处的软惩罚替换为 $\rho(x, T) = \rho_{\text{target}}$ 处的硬分布约束，会得到一个 HJB 方程，其边界条件只能通过 FP 隐式定义，而 FP 现在包含两个分布约束，类似于一个最优传输问题。因此，尽管动机充分，大多数先前的方法都难以扩展到这种设置。

在这项工作中，我们证明了薛定谔桥（Schrödinger Bridge, **SB**）作为一个熵正则化的最优传输问题 [24–28]，为求解这类具有分布边界约束（ $\rho_0, \rho_{\text{target}}$ ）的具有挑战性的 MFG 提供了一个优雅的方案。尽管 **SB** 传统上是在 $F := 0$ [29–31] 的设置下建立的，我们证明了 **SB-FBSDE** [27]，一种基于 FBSDE 的求解 **SB** 的方法，可以被推广以接受非平凡的 F ；从而求解 MFG。有趣的是，新的 FBSDEs 系统具有与时序差分（Temporal Difference, TD）学习类似的计算结构，形成了一个缩小差距的框架。¹ 确切地说，Chen [16] 考虑了不连续但非平均场相互作用， $F := F(x)$, on a 离散状态空间。² 除非另有说明，这些算子均关于 x 取值。符号总结见附录 A.1。

在薛定谔桥 (Schrödinger Bridge, SB) 与深度强化学习 (Deep Reinforcement Learning, DeepRL) 之间建立联系; 参见图 1。这一联系使本文方法能够利用深度强化学习技术, 如目标网络、经验回放缓冲区、演员-评论家等, 更重要的是, 能够处理一类广泛的均场交互, 这些交互无需连续或可微。这与大多数现有工作形成对比, 现有工作要求 [14, 15] 或二次 [32] 结构作用于 F , 或对状态空间进行离散化 [16]。本文在多个具有挑战性的均场博弈上验证了所提方法, 称为深度广义薛定谔桥 (Deep Generalized Schrödinger Bridge, DeepGSB), 从人群导航到高维观点去极化 (其中 $d = 1000$), 在数值均场博弈求解器领域树立了最先进的记录。

综上所述, 本文提出以下贡献。

- 本文提出一种新颖的数值方法, 根植于薛定谔桥 (Schrödinger Bridge, SB), 用于求解一类具有挑战性的均场博弈, 其中群体需要精确收敛到目标分布。
- 由此产生的方法 **DeepGSB** 将先前的薛定谔桥结果推广到接受灵活的均场交互 (例如不可微), 并受益于深度强化学习的现代训练技术。
- **DeepGSB** 在引导人群运动和去极化 1000 维观点动态方面取得了有前景的实证结果, 树立了新的最先进数值均场博弈求解器。

2 薛定谔桥 (Schrödinger Bridge, SB) 预备知识

The SB problem was originally introduced in the 1930s for quantum mechanics [29, 33] and later draws broader interests with its connection to optimal transport and control [34–37]. Given a pair of boundary distributions (ρ_0, ρ_T) , SB seeks an optimal pair of stochastic processes of the forms:

$$dX_t = [f(X_t, t) + \sigma^2 \nabla \log \Psi(X_t, t)]dt + \sigma dW_t, \quad X_0 \sim \rho_0, \quad (3a)$$

$$d\bar{X}_s = [-f(\bar{X}_s, s) + \sigma^2 \nabla \log \hat{\Psi}(\bar{X}_s, s)]ds + \sigma dW_s, \quad \bar{X}_0 \sim \rho_T. \quad (3b)$$

虽然 X_t 是一个标准随机过程, 从 $\rho_0, \bar{X}_s$ 开始, 沿着“反转”的时间坐标 $s := T - t$ 从 ρ_T 演化。基础漂移 f 和扩散 σ 通常是先验已知的, 并与哈密顿量 H 相关。假设 $\Psi, \hat{\Psi} \in C^{2,1}(\mathbb{R}^d, [0, T])$ 求解以下耦合偏微分方程, $\frac{\partial}{\partial t} \Psi(x, t)$

$$\begin{aligned} \frac{\partial \Psi}{\partial t} &= -\nabla \Psi^\top f - \frac{1}{2} \sigma^2 \Delta \Psi & \Psi(\cdot, 0) \hat{\Psi}(\cdot, 0) &= \rho_0 \\ \frac{\partial \hat{\Psi}}{\partial t} &= -\nabla \cdot (\hat{\Psi} f) + \frac{1}{2} \sigma^2 \Delta \hat{\Psi} & \Psi(\cdot, T) \hat{\Psi}(\cdot, T) &= \rho_T \end{aligned} \quad \text{s.t.} \quad (4)$$

那么, 薛定谔桥 (Schrödinger Bridge) 理论表明, (3) 中的随机微分方程是熵正则化 (即最小控制) 优化问题的最优解。此外, 由 (3a) 沿 $t \in [0, T]$ 诱导的路径测度几乎必然等于由 (3b) 沿 $s := T - t$ 诱导的路径测度。换言之, (3) 中的两个随机微分方程可以视为彼此的“反向”过程; 因此我们也有 $X_T \sim \rho_T$ 和 $\bar{X}_T \sim \rho_0$ (见图 2)。

由于边界处的耦合约束, 求解 (4) 并不比求解 (1) 容易。幸运的是, 近期进展 [27, 28] 展示了一种计算上可扩展的数值方法, 该方法通过应用非线性费曼-卡茨 (Feynman-Kac) 引理——一种将某些类别的偏微分方程通过某种变换转化为前向-后向随机微分方程组的数学工具。在 SB-FBSDE [27] 中, 这些非线性费曼-卡茨变换由一些深度神经网络参数化, 其中 θ 和 ϕ , i.e.,

$$Z_\theta(\cdot, \cdot) \approx \sigma \nabla \log \Psi(\cdot, \cdot) \quad \text{and} \quad \hat{Z}_\phi(\cdot, \cdot) \approx \sigma \nabla \log \hat{\Psi}(\cdot, \cdot), \quad (5)$$

由 (4) 和 (5) 得到的前向-后向随机微分方程产生以下目标 (见附录 A.2) :

$$\mathcal{L}_{\text{IPF}}(\theta) = \int_0^T \mathbb{E} \left[\frac{1}{2} \|Z_\theta(\bar{X}_s, s)\|_2^2 + Z_\theta(\bar{X}_s, s)^\top \hat{Z}_\phi(\bar{X}_s, s) + \nabla \cdot (\sigma Z_\theta(\bar{X}_s, s) + f) \right] ds, \quad (6a)$$

$$\mathcal{L}_{\text{IPF}}(\phi) = \int_0^T \mathbb{E} \left[\frac{1}{2} \|\hat{Z}_\phi(X_t, t)\|_2^2 + \hat{Z}_\phi(X_t, t)^\top Z_\theta(X_t, t) + \nabla \cdot (\sigma \hat{Z}_\phi(X_t, t) - f) \right] dt. \quad (6b)$$

以下引理作为 Vargas [38] 的直接推论, 表明这些目标可以解释为参数化路径测度之间的 KL 散度。




图 2: 薛定谔桥中正向 (3a) 和反向 (3b) 随机微分方程的仿真, 当 $(\Psi, \hat{\Psi})$ 满足 (4) 中的偏微分方程时, 它们是最小能量解。

引理 1。 设 q^θ 和 q^ϕ 分别为参数化前向和后向随机微分方程的路径密度

$$dX_t^\theta = (f(X_t^\theta, t) + \sigma Z_\theta(X_t^\theta, t)) dt + \sigma dW_t, \quad d\bar{X}_s^\phi = (-f(\bar{X}_s^\phi, t) + \sigma \widehat{Z}_\phi(\bar{X}_s^\phi, t)) ds + \sigma dW_s.$$

那么, 我们有

$$D_{\text{KL}}(q^\theta \| q^\phi) \propto \mathcal{L}_{\text{IPF}}(\phi), \quad \text{及} \quad D_{\text{KL}}(q^\phi \| q^\theta) \propto \mathcal{L}_{\text{IPF}}(\theta).$$

证明。见附录 A.3.2。 □

引理 1 表明, 在 $\mathcal{L}_{\text{IPF}}(\phi)$ 与 $\mathcal{L}_{\text{IPF}}(\theta)$ 之间进行交替最小化等价于执行迭代 KL 投影 [39], 因此等价于应用迭代比例拟合 [40] (IPF) 算法来求解参数化薛定谔桥 [24, 25]。

3 深度广义薛定谔桥 (DeepGSB)

3.1 平均场博弈与薛定谔桥中耦合偏微分方程之间的联系

我们首先以数学形式陈述所关注的问题——具有硬分布约束的平均场博弈 $(\rho_0, \rho_{\text{target}})$ 。与先前工作 [14, 15] 类似, 我们将采用控制-affine Hamiltonian, $\frac{1}{2}\|(\nabla u, \nabla \rho)\|^2 - \nabla u^\top f - \frac{1}{2}\sigma^2\|\nabla \rho\|^2$ 给定某个基础漂移 f 和扩散标量 σ 。将此控制仿射哈密顿量代入 (1) 中的偏微分方程, 得到 $\left(-\frac{\partial u(x,t)}{\partial t} \right.$




图 3: 平均场博弈、薛定谔桥与深度广义薛定谔桥中出现的不同耦合偏微分方程之间的联系。

$$\begin{aligned} & + \frac{1}{2}\|\sigma \nabla u\|^2 - \nabla u^\top f - \frac{1}{2}\sigma^2 \Delta u = F(x, \rho), \\ & \frac{\partial \rho(x,t)}{\partial t} - \nabla \cdot (\rho (\sigma^2 \nabla u - f)) - \frac{1}{2}\sigma^2 \Delta \rho = 0, \quad \rho(x, 0) = \rho_0(x), \quad \rho(x, T) = \rho_{\text{target}}(x), \end{aligned} \quad (7)$$

正如我们在第 1 节中简要讨论的那样, 这些方程与 (1) 的不同之处在于, HJB 方程的边界条件 $u(x, T)$ 现在被吸收到 FP 中, 并通过 $\rho(x, T) = \rho_{\text{target}}(x)$ 隐式定义。由于 (1) 和 (7) 的边界条件之间的解析转换仅存在于高度退化的 3 情形 [41], 这一看似无害的改变足以使大多数先前的方法失效。⁴ 然而, 由于 (7) 现在描述了从 FP 出发的两个分布之间的变换, 同时遵循来自 HJB 的某种最优性, 这暗示了它与最优传输 (Optimal Transport) 以及因此与薛定谔桥 (Schrödinger Bridge, SB) 之间更深层的联系。

为了将这些新的平均场博弈 (Mean Field Game, MFG) 偏微分方程 (7) 与 SB(4) 中出现的偏微分方程联系起来, 我们遵循标准处理方法 [30] 并应用 Hopf-Cole 变换 [42, 43]:

$$\Psi(x, t) := \exp(-u(x, t)), \quad \widehat{\Psi}(x, t) := \rho(x, t) \exp(u(x, t)), \quad (8)$$

经过一些代数运算 (详见附录 A.4.1), 得到以下偏微分方程:

$$\begin{cases} \frac{\partial \Psi(x,t)}{\partial t} = -\nabla \Psi^\top f - \frac{1}{2}\sigma^2 \Delta \Psi + F\Psi \\ \frac{\partial \widehat{\Psi}(x,t)}{\partial t} = -\nabla \cdot (\widehat{\Psi} f) + \frac{1}{2}\sigma^2 \Delta \widehat{\Psi} - F\widehat{\Psi} \end{cases} \quad \text{s.t.} \quad \begin{cases} \Psi(\cdot, 0)\widehat{\Psi}(\cdot, 0) = \rho_0 \\ \Psi(\cdot, T)\widehat{\Psi}(\cdot, T) = \rho_{\text{target}} \end{cases}. \quad (9)$$

可以看出, (9) 通过引入平均场交互项 F 推广了 (4)。设 (Ψ, Ψ) 为 (9) 中这些新的平均场扩展偏微分方程的解, 并回顾 (7) 中采用的哈密顿量, 可以发现

$$-\nabla_p H(X_t, \nabla u, \rho) = f - \sigma^2 \nabla u = f + \sigma^2 \nabla \log \Psi.$$

也就是说, 智能体的动态 (2) 与 SB 中的正向随机微分方程 (3a) 一致。因此, 我们通过 (7) 和 (9) 中的偏微分方程将 MFG(1) 与 SB(4) 框架联系起来; 参见图 3。

³Zhang 和 Chen[41] 建议 $F := 0, f := f(x)$ 和 ρ_0 一个退化的狄拉克 δ 分布。⁴ 为了完整性, 我们注意到当基础漂移与密度无关时, $f := f(x)$, 以及平均场偏好 $\mathcal{F}(\rho): F(x, \rho) = \frac{\partial \mathcal{F}}{\partial \rho}$ 在 ρ 中是凸的, 继承自 (7) 的变分优化保持凸性。在这些情况下, 离散化问题收敛到全局解 [16, 32]。然而, 对于一般的平均场动力学, 例如我们 (18) 中的极化 $f(x, \rho)$, 问题通常是非凸的; 因此只能建立局部收敛 (参见例如 [16] 中的注记 1)。

3.2 具有平均场交互的广义 SB-正倒向随机微分方程

借助 (9)，我们准备展示我们的结果，该结果将先前用于 SB 的正倒向随机微分方程 (FBSDE) 推广到平均场交互情形。

定理 2 (广义 SB-FBSDEs)。假设 $\Psi, \Psi \in C^{2,1}$ ，并令 f, F 满足通常的增长和利普希茨条件 [44, 45]。考虑以下应用于 (9) 的非线性 FK 变换：

$$\begin{aligned} Y_t &\equiv Y(X_t, t) = \log \Psi(X_t, t), & Z_t &\equiv Z(X_t, t) = \sigma \nabla \log \Psi(X_t, t), \\ \hat{Y}_t &\equiv \hat{Y}(X_t, t) = \log \hat{\Psi}(X_t, t), & \hat{Z}_t &\equiv \hat{Z}(X_t, t) = \sigma \nabla \log \hat{\Psi}(X_t, t), \end{aligned} \quad (10)$$

其中 X_t 遵循 (3a)，且 $X_0 \sim \rho_0$ 。则所得 FBSDEs 系统形式为：

$$\begin{aligned} \text{FBSDEs} &: \begin{cases} dX_t = (f_t + \sigma Z_t) dt + \sigma dW_t & (11a) \\ dY_t = \left(\frac{1}{2} \|Z_t\|^2 + F_t \right) dt + Z_t^\top dW_t & (11b) \\ d\hat{Y}_t = \left(\frac{1}{2} \|\hat{Z}_t\|^2 + \nabla \cdot (\sigma \hat{Z}_t - f_t) + \hat{Z}_t^\top Z_t - F_t \right) dt + \hat{Z}_t^\top dW_t & (11c) \end{cases} \\ \text{w.r.t. (3a)} & \end{aligned}$$

现在，考虑 (9) 中类似的变换，但改为关于“反向”SDE $\bar{X}_s \sim (3b)$ 和 $\bar{X}_0 \sim \rho_{\text{target}}$ ，i.e., $Y_s \equiv Y(\bar{X}_s, s) = \log \Psi(\bar{X}_s, s)$ 等。所得 FBSDEs 系统为

$$\begin{aligned} \text{FBSDEs} &: \begin{cases} d\bar{X}_s = (-f_s + \sigma \hat{Z}_s) ds + \sigma dW_s & (12a) \\ dY_s = \left(\frac{1}{2} \|Z_s\|^2 + \nabla \cdot (\sigma Z_s + f_s) + Z_s^\top \hat{Z}_s - F_s \right) ds + Z_s^\top dW_s & (12b) \\ d\hat{Y}_s = \left(\frac{1}{2} \|\hat{Z}_s\|^2 + F_s \right) ds + \hat{Z}_s^\top dW_s & (12c) \end{cases} \\ \text{w.r.t. (3b)} & \end{aligned}$$

由于 $Y_t + \hat{Y}_t = \log \rho(X_t, t)$ 由构造可得，(11) 中的函数 f_t 和 F_t 取参数为 $f_t := f_t(X_t, \exp(Y_t + \hat{Y}_t))$ 和 $F_t := F_t(X_t, \exp(Y_t + \hat{Y}_t))$ 。

类似地，我们有 $f_s := f_s(\bar{X}_s, \exp(Y_s + \hat{Y}_s))$ 及 $F_s := F_s(\bar{X}_s, \exp(Y_s + \hat{Y}_s))$ in (12)。

证明。见附录 A.3.3。 $\square$

正如 (9) 式推广了 (4) 式，本文定理 2 中的结果也通过引入非平凡的均值场交互 F ，推广了普通 SB-FBSDE[27] 中出现的结果（见附录 A.2 中的 (22) 式）。尽管与原始偏微分方程 (9) 相比看似复杂，这些正倒向随机微分方程系统——即 (11) 和 (12)——构成了开发可扩展数值方法的基础，因为它们精确描述了 $Y \equiv \log \Psi$ 和 $\hat{Y} \equiv \log \hat{\Psi}$ 的值应如何沿最优随机微分方程变化（例如，注意 Y_t 和 Z_t 都是 (10) 式中 X_t 的函数）。本质上，非线性费曼-卡茨引理通过使用伊藤公式 [46] 将 (9) 式中的偏微分方程沿 (3) 式中的最优随机微分方程展开，提供了这些偏微分方程的随机表示（以 Y 和 $\hat{Y}$ 的形式）。因此，与先前工作 [15] 中在整个函数空间上求解偏微分方程 (9) 不同，只需在由 (3) 式刻画的高概率区域附近局部求解它们，这便产生了计算上可扩展的方法。

3.3 计算框架的设计

从定理 2 来看，只需用一些参数化函数（本文使用深度神经网络）来近似 $Y_\theta \approx Y$ 和 $Y_\phi \approx \hat{Y}$ ，因为可以如 (10) 所建议的那样推断 $Z_\theta \approx \sigma \nabla Y_\theta$ 和 $Z_\phi \approx \sigma \nabla Y_\phi$ ，然后通过 (11a, 12a) 求解 $(X_t, \bar{X}_s)$ 。下面，本文探讨为 (θ, ϕ) 设计训练目标的各种方案，旨在促使 (Y_θ, Y_ϕ) 满足 (11, 12) 中的正倒向随机微分方程组。

选项 1: $\mathcal{L}_{\text{IPF}}$ 。鉴于定理 2 如何推广了 [27] 中的定理（见附录 A.2 中的 (22)），自然会思考是否采用用于推导 (6)，e.g., $\mathcal{L}_{\text{IPF}}(\phi) := \int \mathbb{E}[dY_t^\theta + d\hat{Y}_t^\phi]$ 的计算方法

⁵ Additionally, we have $\mathcal{L}_{\text{IPF}}(\theta) := \int \mathbb{E}[dY_s^\theta + d\hat{Y}_s^\phi]$; see (24) 见附录 A.2 中的推导。

足以得到正倒向随机微分方程 (FBSDE) (11)。遗憾的是, 情况并非如此, 可以验证

$$\mathcal{L}_{\text{IPF}}^{(11)}(\phi) := \int \mathbb{E} \left[dY_t^\theta + d\hat{Y}_t^\phi \right] = \int \mathbb{E} \left[\frac{1}{2} \|\hat{Z}_t^\phi + Z_t^\theta\|^2 + \nabla \cdot (\sigma \hat{Z}_t^\phi - f) \right] dt = \mathcal{L}_{\text{IPF}}^{(6b)}(\phi).$$

尽管式 (11) 与式 (22) 的区别在于式 (11b) 中额外的项“ $+F_t$ ”和式 (11c) 中额外的项“ $-F_t$ ”, 这两项在 $dY_t^\theta + d\hat{Y}_t^\phi$ 的和中相互抵消, 从而得到不依赖于 F 的相同目标。这意味着从 [27] 天真地优化 $\mathcal{L}_{\text{IPF}}$ 不足以求解具有非平凡 F 的正倒向随机微分方程系统。我们必须寻找额外的目标 (如果存在的话), 以尊重平均场结构。

选项二: $\mathcal{L}_{\text{IPF}}$ + 时序差分目标 $\mathcal{L}_{\text{TD}}$. 让我们重新审视正向-反向随机微分方程 (FBSDEs) (11, 12) 与其对应的偏微分方程 (PDEs) 之间的关系——但这次关注的是 (7) 中的哈密顿-雅可比-贝尔曼方程 (HJB)。以 (X_t, Y_t) 为例: $Y_t = \log \Psi(X_t, t) = -u(X_t, t)$ 这一事实暗示了对 Y_t 的另一种解释, 即将其视为 HJB 的随机表示, 关键在于, 这可以看作是贝尔曼方程 [47] 的连续时间类比。实际上, 以某个固定步长 δt 对 (11b) 进行离散化, 得到

$$Y_{t+\delta t}^\theta = Y_t^\theta + \left(\frac{1}{2} \|Z_t^\theta\|^2 + F_t \right) \delta t + Z_t^{\theta\top} \delta W_t, \quad \delta W_t \sim \mathcal{N}(\mathbf{0}, \delta t \mathbf{I}), \quad (13)$$

这类似于一个 (非折扣的) 时序差分 (TD) [48, 49], 不同之处在于, 除了标准的“奖励” (以控制和状态成本的形式) 之外, 还存在一个随机项。这个随机项在取期望时会在原始贝尔曼方程中消失, 但在刻画值函数 Y_t 的固有随机性方面起着至关重要的作用。基于这种解释, 我们可以为我们的 FBSDEs 系统构造合适的 TD 目标, 如下所示。

命题 3 (针对 (11, 12) 的 TD 目标 $\mathcal{L}_{\text{TD}}$)。单步 TD 目标的形式为:

$$\widehat{\text{TD}}_{t+\delta t}^{\text{single}} := \hat{Y}_t^\phi + \left(\frac{1}{2} \|\hat{Z}_t^\phi\|^2 + \nabla \cdot (\sigma \hat{Z}_t^\phi - f_t) + \hat{Z}_t^{\phi\top} Z_t^\theta - F_t \right) \delta t + \hat{Z}_t^{\phi\top} \delta W_t, \quad (14a)$$

$$\text{TD}_{s+\delta s}^{\text{single}} := Y_s^\theta + \left(\frac{1}{2} \|Z_s^\theta\|^2 + \nabla \cdot (\sigma Z_s^\theta + f_s) + Z_s^{\theta\top} \hat{Z}_s^\phi - F_s \right) \delta s + Z_s^{\theta\top} \delta W_s, \quad (14b)$$

含 $\widehat{\text{TD}}_0 := \log \rho_0 - Y_0^\theta$ 及 $\text{TD}_0 := \log \rho_{\text{target}} - \hat{Y}$, 多步 TD 目标的形式为:

$$\widehat{\text{TD}}_{t+\delta t}^{\text{multi}} := \widehat{\text{TD}}_0 + \sum_{\tau=\delta t}^t \delta \hat{Y}_\tau, \quad \text{TD}_{s+\delta s}^{\text{multi}} := \text{TD}_0 + \sum_{\tau=\delta s}^s \delta Y_\tau, \quad (15)$$

其中 $\delta \hat{Y}_t := \widehat{\text{TD}}_{t+\delta t}^{\text{single}} - \hat{Y}_t$ 及 $\delta Y_s := \text{TD}_{s+\delta s}^{\text{single}} - Y_s$ 。给定这些时序差分目标, 我们可以构建

$$\mathcal{L}_{\text{TD}}(\theta) = \sum_{s=0}^T \mathbb{E} [\|Y_\theta(\bar{X}_s, s) - \text{TD}_s\|] \delta s, \quad \mathcal{L}_{\text{TD}}(\phi) = \sum_{t=0}^T \mathbb{E} [\|\hat{Y}_\phi(X_t, t) - \widehat{\text{TD}}_t\|] \delta t. \quad (16)$$

证明。见附录 A.3.4。 $\square$

可以容易看出, (14) 中的单步时序差分目标与 (13) 具有相似的结构, 只是源自不同的随机微分方程 (11c, 12b)。这样做减少了计算开销, 因为每个参数的相关目标 *e.g.*, $\mathcal{L}_{\text{IPF}}(\theta)$ 和 $\mathcal{L}_{\text{TD}}(\theta)$ 可以从同一个期望中评估。在实践中, 我们发现多步目标通常能带来更好的性能, 这在深度强化学习文献 [50–52] 中也被一致观察到。此外, 常见做法如使用指数移动平均 (即目标值) 和回放缓冲区来计算 TD_t 和 TD_s 也有助于稳定训练。最后, (16) 中的时序差分目标作为回归因变量出现这一事实意味着, 从计算角度看, 平均场交互 F 不需要是连续的或可微的。

必要性与充分性 $\mathcal{L}_{\text{IPF}} + \mathcal{L}_{\text{TD}}$. 目前尚不清楚将 $\mathcal{L}_{\text{TD}}$ 附加到目标函数是否足以使 (Y_θ, Y_ϕ) 满足正倒向随机微分方程 (11, 12)。下面, 我们给出一个肯定的结果。

命题 4. 函数 $(Y_\theta, Z_\theta, Y_\phi, Z_\phi)$ 满足定理 2 中的正向-反向随机微分方程 (FBSDEs) (11, 12), 当且仅当它们是组合损失 $\mathcal{L}(\theta, \phi) := \mathcal{L}_{\text{IPF}}(\phi) + \mathcal{L}_{\text{TD}}(\phi) + \mathcal{L}_{\text{IPF}}(\theta) + \mathcal{L}_{\text{TD}}(\theta)$ 的最小化器。

证明: 见附录 A.3.5。 $\square$

Algorithm 1 Deep Generalized Schrödinger Bridge (DeepGSB)

Input: $(Y_\theta, \hat{Y}_\phi, \sigma \nabla Y_\theta, \sigma \nabla \hat{Y}_\phi)$ for critic or $(Y_\theta, \hat{Y}_\phi, Z_\theta, \hat{Z}_\phi)$ for actor-critic parametrization.

repeat

 Sample $\mathbf{X}^\theta \equiv \{X_t^\theta, Z_t^\theta, \delta W_t\}_{t \in [0, T]}$ from the forward SDE (11a); add $\mathbf{X}^\theta$ to replay buffer $\mathcal{B}$.

for $k = 1$ **to** K **do**

 Sample on-policy $\mathbf{X}_{\text{on}}^\theta$ and off-policy $\mathbf{X}_{\text{off}}^\theta$ samples respectively from $\mathbf{X}^\theta$ and $\mathcal{B}$.

 Compute $\mathcal{L}(\phi) = \mathcal{L}_{\text{IPF}}(\phi; \mathbf{X}_{\text{on}}^\theta) + \mathcal{L}_{\text{TD}}(\phi; \mathbf{X}_{\text{on}}^\theta) + \mathcal{L}_{\text{TD}}(\phi; \mathbf{X}_{\text{off}}^\theta) + \mathcal{L}_{\text{FK}}(\phi; \mathbf{X}_{\text{on}}^\theta)$.

 Update ϕ with the gradient $\nabla_\phi \mathcal{L}(\phi)$.

end for

 Sample $\bar{\mathbf{X}}^\phi \equiv \{\bar{X}_s^\phi, \bar{Z}_s^\phi, \delta W_s\}_{s \in [0, T]}$ from the backward SDE (12a); add $\bar{\mathbf{X}}^\phi$ to replay buffer $\bar{\mathcal{B}}$.

for $k = 1$ **to** K **do**

 Sample on-policy $\bar{\mathbf{X}}_{\text{on}}^\phi$ and off-policy $\bar{\mathbf{X}}_{\text{off}}^\phi$ samples respectively from $\bar{\mathbf{X}}^\phi$ and $\bar{\mathcal{B}}$.

 Compute $\mathcal{L}(\theta) = \mathcal{L}_{\text{IPF}}(\theta; \bar{\mathbf{X}}_{\text{on}}^\phi) + \mathcal{L}_{\text{TD}}(\theta; \bar{\mathbf{X}}_{\text{on}}^\phi) + \mathcal{L}_{\text{TD}}(\theta; \bar{\mathbf{X}}_{\text{off}}^\phi) + \mathcal{L}_{\text{FK}}(\theta; \bar{\mathbf{X}}_{\text{on}}^\phi)$.

 Update θ with the gradient $\nabla_\theta \mathcal{L}(\theta)$.

end for

until converges

命题 4 断言了组合目标 $\mathcal{L}_{\text{IPF}} + \mathcal{L}_{\text{TD}}$ 在求解定理 2 中的广义薛定谔桥-正向-反向随机微分方程 (SB-FBSDEs) 以及由此 (7) 中的平均场博弈 (MFG) 问题时的有效性。其解释如下：如引理 1 所暗示的， $\mathcal{L}_{\text{IPF}}$ 的最小化器总能建立一个有效的“桥”，在边界分布 ρ_0 和 ρ_{target} 之间传输；然而，在没有进一步条件的情况下，这个桥不必遵循“薛定谔”桥。虽然一般的迭代比例拟合 (IPF) 和 Sinkhorn 算法 [16, 32]，在适当的初始化或离散化下，提供了一种确保向“薛定谔”桥收敛的方法，但我们的命题 4 通过引入时序差分 (TD) 目标 $\mathcal{L}_{\text{TD}}$ 提出了一种替代方案。这为我们处理平均场博弈中的广义薛定谔桥提供了灵活性，其中 F 变得非平凡或非凸。此外，它自然地处理了不可微的 F ，这在许多情况下可以提供额外的好处。

$\mathcal{L}_{\text{IPF}} + \mathcal{L}_{\text{TD}}$ $\mathcal{L}_{\text{FK}}$ 选项 3 先前选项 2 先前选项 1 参数化推断 $(Y_\theta, \hat{Y}_\phi)$ then

标 $Z_\theta := \sigma \nabla Y_\theta$ 和 $Z_\phi := \sigma \nabla \hat{Y}_\phi$ 似乎已足够，但在实践中我们发现，用两个额外的深度神经网络 (DNNs) 参数化 (Z_θ, Z_ϕ) ，然后施加以下正向柯尔莫哥洛夫目标，即

$$\mathcal{L}_{\text{FK}}(\theta) = \sum_{s=0}^T \mathbb{E} [\|\sigma \nabla Y_\theta(\bar{X}_s, s) - Z_\theta(\bar{X}_s, s)\|] \delta s, \quad \mathcal{L}_{\text{FK}}(\phi) = \sum_{t=0}^T \mathbb{E} [\|\sigma \nabla \hat{Y}_\phi(X_t, t) - \hat{Z}_\phi(X_t, t)\|] \delta t,$$

通常能提供额外的鲁棒性。这些目标旨在确保非线性正向柯尔莫哥洛夫方程 (10) 成立。

我们的 DeepGSB 算法总结在算法 1 中。此后，我们将选项 2 和选项 3 分别称为 DeepGSB 评论家和 DeepGSB 演员-评论家，因为 Y_θ 和 Z_θ 扮演着类似于评论家和演员网络 [53, 54] 的角色。

关于收敛性的说明。 尽管算法 1 与 IPF [16, 24, 27] 具有相似的交替结构，但组合目标 e.g., $\mathcal{L}(\phi) \propto D_{\text{KL}}(\rho^\theta \parallel \rho^\phi) + \mathbb{E}_{\rho^\theta} [\mathcal{L}_{\text{TD}}(\phi)] \neq D_{\text{KL}}(\rho^\phi \parallel \rho^\theta)$ 并不等价于 IPF 中出现的 (反向) KL 散度。相反，DeepGSB 可能更接近信赖域优化 [55]，因为两者都利用前一阶段的样本迭代更新策略，同时受到某种 KL 惩罚： $\pi^{(i+1)} = \arg \min_\pi D_{\text{KL}}(\pi^{(i)} \parallel \pi) + \mathbb{E}_{\pi^{(i)}} [\mathcal{L}(\pi)]$ 。因此，可以预期 DeepGSB 具有类似的单调改进和局部收敛性质。更多讨论留待附录 A.4.2。

4 实验

平均场博弈的实例化。 我们在两类平均场博弈上验证了 DeepGSB，包括经典人群导航 ($d=2$) 和高维 ($d=1000$) 观点去极化。对于人群导航，我们考虑了先前方法 [14, 15] 中出现的三个平均场博弈，包括 (i) 非对称避障，(ii) V 形瓶颈的熵相互作用，以及 (iii) S 形隧道的拥堵相互作用。我们分别称它们为 GMM、V-neck 和 S-tunnel。障碍物和初始/目标高斯分布 $(\rho_0, \rho_{\text{target}})$ 如图 4 所示。对于观点去极化，我们将 ρ_0 和 ρ_{target} 设置为两个零均值高斯分布，其方差不同，分别表示初始极化和期望的温和观点分布。最后，我们分别对 GMM 和 V-neck/S-tunnel 考虑零和常数基础漂移 f ，并对观点平均场博弈采用极化平均场动力学 [4]；详细讨论见第 4.2 节。




图 4: 人群导航平均场博弈。

表 2: 3 个人群导航平均场博弈和高维观点平均场博弈的平均场相互作用。

GMM ($d=2$)	F_{obstacle}
V-neck ($d=2$)	$F_{\text{obstacle}} + F_{\text{entropy}}$
S-tunnel ($d=2$)	$F_{\text{obstacle}} + F_{\text{congestion}}$
Opinion ($d=1000$)	F_{entropy}

平均场相互作用 F . 本文遵循平均场博弈 (MFG) 理论的标准处理方法 [11], 注意到给定一个泛函 $\mathcal{F}(\rho)$, 它量化了相对于总体 ρ , e.g., $\mathcal{F}_{\text{entropy}} := \mathbb{E}_{\rho}[\log \rho]$ 或 $\mathcal{F}_{\text{congestion}} := \mathbb{E}_{x,y \sim \rho} \left[\frac{1}{\|x-y\|^2+1} \right]$ 的平均场代价, 可以通过取泛函导数 i.e., $\frac{\delta \mathcal{F}(\rho)}{\delta \rho}$ 导出其关联的平均场交互函数 $F(x, \rho)$ 。因此, 熵和拥堵平均场交互以及障碍代价如下 (推导见附录 A.4.3) :

$$F_{\text{entropy}} := \log \rho(x, t) + 1, \quad F_{\text{congestion}} := \mathbb{E}_{y \sim \rho} \left[\frac{2}{\|x-y\|^2+1} \right], \quad F_{\text{obstacle}} := 1500 \cdot \mathbb{1}_{\text{obs}}(x), \quad (17)$$

其中 $\mathbb{1}_{\text{obs}}(\cdot)$ 是问题相关障碍集的 (不连续) 指示函数。我们在表 2 中总结了平均场交互。

架构与超参数. 本文使用全连接深度神经网络 (DNN) 对人群导航中的函数进行参数化, 并使用深度残差网络处理高维观点平均场博弈。所有网络均采用正弦时间嵌入, 并使用 AdamW[56] 进行训练。式 (11, 12) 中的所有随机微分方程 (SDE) 均采用欧拉-丸山方法求解。由于篇幅限制, 本文将主要关注演员-评论家参数化 DeepGSB-ac 的结果, 并将评论家参数化 DeepGSB-c 的讨论以及额外的实验细节留至附录 A.5。

4.1 二维人群导航

图 5 展示了我们的 DeepGSB-ac 在三个群体导航平均场博弈 (MFG) 上的仿真结果。我们还报告了在每个 MFG 上经过最佳调优的现有数值方法 [14–16] (详见附录 A.5.1), 但需注意, 在实践中, 这些方法要么需要软化 F 使其可微 [14, 15] 才能得到合理结果, 要么需要离散化状态空间 [16], 这可能导致难以承受的复杂度。⁶ 我们首先在 GMM 上与 Chen[16] 进行比较 (见图 5a), 因为他们的方法仅适用于非平均场交互 i.e., $F := F(x)$ 。DeepGSB-ac 引导群体平滑避开所有障碍物 (注意障碍物周围 γ 的尖锐轮廓), 而 [16] 由于状态空间 (以及策略) 的离散化, 难以逃脱。为了更好地考察 $F(x, \rho)$ 中 ρ 的影响, 我们接下来在 V 形瓶颈上仿真动力学 (见图 5b), 分别在有和没有平均场交互的情况下进行。显然, 一旦启用熵交互 F_{entropy} , 我们的 DeepGSB-ac 会促使群体分散开来, 但在 [14] 中几乎观察不到类似效果。我们观察到 [14] 在平衡平均场交互 F 和终端惩罚 $D_{\text{KL}}(\rho_T \| \rho_{\text{target}})$ 方面存在困难, 而 DeepGSB 通过构造缓解了这一问题。最后, 我们在 S 形隧道上验证了我们的方法在不同扩散系数 $\sigma = \{0.5, 1, 2\}$ 下的鲁棒性 (见图 5c)。同样, 尽管受到不同程度的随机性影响, 我们的 DeepGSB-ac 仍能保持相同的 ρ_{target} 。这与 [15] 形成对比, 后者由于丢弃了随机微分方程 (SDE) 动力学, 必须在整个状态空间上求解偏微分方程 (PDE), 而这些方程可能对超参数敏感。简而言之, 我们的 DeepGSB 在更好地尊重障碍物和平均场交互方面优于先前方法 [14–16], 同时不失对 ρ_{target} 的收敛性, 并且其性能在不同 MFG 上保持鲁棒。

4.2 高维观点去极化

接下来, 我们展示 DeepGSB 在观点动力学应用 [3–5] 中求解高维平均场博弈的能力, 其中每个智能体在拥有一个 d 维观点 $x \in \mathbb{R}^d$, 该观点通过与群体的交互而演化。鉴于近期关注度日益增加, 我们考虑一类已知会产生强烈极化的观点动力学 [4], 即智能体的观点倾向于分裂成持有截然相反观点的群体。以政党模型 [4] 为例: 给定从某个独立于 ρ 的分布中采样的随机信息 $\xi \in \mathbb{R}^d$, 每个智能体更新

⁶ 如 [16] 所述, 复杂度相对于离散化网格点的数量呈二次方增长。




图 5: 三种人群导航平均场博弈的仿真, 包括 (a) GMM、(b) V 型颈和 (c) S 型隧道, 从 $t = 0$ 到 T 。前五列展示了由我们的 DeepGSB-ac 引导的人群快照, 每种颜色不同, 而第六列 (最右) 叠加了现有方法 [14–16] 生成的相同人群快照。时变轮廓表示 $Y_\theta \approx \log \Psi$, 其梯度通过 $Z = \sigma \nabla Y$ 与策略相关。此图最好以彩色查看。




图 6: (a) 在 2 维和 1000 维观点空间中极化动力学 $\bar{f}_{\text{polarize}}$ 的可视化, 其中方向相似性 [3] 统计了终端分布 ρ_T 。(b) 处成对观点之间余弦角度的直方图。DeepGSB-ac 引导 ρ_T 趋向温和分布, 从而去极化观点动力学。我们使用前两个主成分来可视化 $d=1000$ 。

遵循归一化极化动力学 $\bar{f}_{\text{polarize}} = f_{\text{polarize}} / \|f_{\text{polarize}}\|$ 的观点

2, 其中

$$f_{\text{polarize}}(x, \rho; \xi) := \mathbb{E}_{y \sim \rho} [a(x, y; \xi) \bar{y}], \quad a(x, y; \xi) := \begin{cases} 1 & \text{if } \text{sign}(\langle x, \xi \rangle) = \text{sign}(\langle y, \xi \rangle) \\ -1 & \text{otherwise} \end{cases}, \quad (18)$$

且 $\bar{y} = y / \|y\|$ 。一致性函数 $a(x, y; \xi)$ 表示两个观点 x 和 y 是否在信息 ξ 上达成一致。直观上, (18) 中的动力学表明, 智能体倾向于接受他们同意的观点, 并对他们不同意的观点持敌对态度。如图 6a 所示, 这种行为假设, 也称为偏见同化 [57, 58], 很容易导致极化。

我们可以将我们的平均场博弈框架 (7) 应用于这种极化基础漂移 (18)，其中，从某个弱极化 ρ_0 开始，我们寻求一种策略来补偿极化趋势，并帮助引导观点趋向温和分布 ρ_{target} （为简单起见假设为高斯分布）。我们考虑熵平均场交互 F_{entropy} ，因为它在达成共识之前鼓励观点多样性。如图 6b 所示，在低维 ($d=2$) 和高维 ($d=1000$) 中，我们的 **DeepGSB-ac** 都成功地将观点引导至以 $\mathbf{0} \in \mathbb{R}^d$ 为中心对称的期望分布，从而减轻了极化。DeepGSB-c 的结果仍然相似，尽管对超参数更敏感；见附录 A.5.2。我们强调这些在一类具有挑战性的平均场博弈上的最先进结果，与现有方法 [14, 15] 相比，考虑了更困难的平均场动力学 ($f(x, \rho)$ vs. $f(x)$)，且维度高出一个数量级 ($d=1000$ vs. $d=100$)。

4.3 讨论

DeepGSB-ca 与 DeepGSB-c 对比。表 3 比较了在人群导航平均场博弈中演员-评论家与评论家参数化方法。虽然 DeepGSB-ac 通常能达到更低的 Wasserstein 距离和 TD 误差，但它很少能像 **DeepGSB-c** 那样缩小 $\mathcal{L}_{\text{FK}}(\theta)$ 的一致性差距。实际上，**DeepGSB-c** 的结果在视觉上与 DeepGSB-ac 难以区分，尽管 Y 的轮廓不同；更多讨论见附录 A.5.2。

表 3: DeepGSB-ac 与 DeepGSB-c 在到 ρ_{target} 的 Wasserstein 距离和 FBSDE 违反方面的比较，以 TD 误差和非线性 FK 表示，在 3 次运行中取平均。

MFGs	DeepGSB	$\mathcal{W}_2 \downarrow$	FBSDEs Violation $\downarrow$		
			$\mathcal{L}_{\text{TD}}(\phi)$	$\mathcal{L}_{\text{TD}}(\theta)$	$\mathcal{L}_{\text{FK}}(\theta)$
GMM	-ac	.27 $\pm$.16	9.5 $\pm$ 2.5	7.1 $\pm$ 0.6	5.2 $\pm$ 1.1
	-c	.61 $\pm$.91	7.0 $\pm$ 1.3	10.1 $\pm$ 1.6	0.0 $\pm$ 0.0
V-neck	-ac	.00 $\pm$.00	4.9 $\pm$ 1.5	4.1 $\pm$ 0.5	0.6 $\pm$ 0.2
	-c	.01 $\pm$.00	8.2 $\pm$ 0.8	8.7 $\pm$ 1.6	0.0 $\pm$ 0.0
S-tunnel	-ac	.01 $\pm$.00	25.5 $\pm$ 2.3	28.6 $\pm$ 3.6	2.1 $\pm$ 0.1
	-c	.03 $\pm$.01	30.9 $\pm$ 6.9	26.4 $\pm$ 5.5	0.0 $\pm$ 0.0

DeepGSB 在难以处理的情况下有效 ρ_{target} 。虽然目标密度 ρ_{target} 的可用性是先前工作 [14, 15] 中采用的常见假设，其中 ρ_{target} 参与计算边界损失，但在大多数实际应用中， ρ_{target} 很少可用。这里，我们展示 DeepGSB 在不知道 ρ_{target} （和 ρ_0 ）的情况下也能良好工作，只要我们能从 $X_0 \sim \rho_0$ 和 $\bar{X}_0 \sim \rho_{\text{target}}$ 中采样。这类似于生成建模的设置 [27]。在图 7 中，我们展示了在没有初始和终端密度的情况下训练的 DeepGSB 同样能够良好收敛。关键在于，DeepGSB 依赖于多种其他机制（例如，单步 TD 目标中的自治性和 IPF 目标中的 KL 匹配）来产生同样有效的梯度。这与 [14, 15] 形成对比，后者的训练信号主要通过 $D_{\text{KL}}(\rho||\rho_{\text{target}})$ 的微分获得；因此，在缺少 ρ_{target} 的情况下，他们的方法无法收敛。




图 7: DeepGSB-ac 在无法访问初始和目标分布的情况下训练，即没有 TD0 和 $\perp$ TD0。在这种情况下，我们使用公式 (14) 中的单步公式计算 $\mathcal{L}_{\text{TD}}$ 。

5 结论与局限性

我们提出了 **DeepGSB**，一种用于求解具有分布边界约束的具有挑战性的平均场博弈类问题的新数值方法。通过将先前用于薛定谔桥的正倒向随机微分方程理论推广到接受平均场相互作用，我们展示了可以通过与深度强化学习的有趣算法联系实现实用训练。我们的 **DeepGSB** 在人群导航平均场博弈中优于先前方法，并在 1000 维观点平均场博弈的去极化任务中创造了新的最先进记录。**DeepGSB** 主要针对无约束状态空间中的平均场博弈开发，例如 $\mathbb{R}^d$ 。然而，可能需要采用特定领域的结构，例如约束状态空间。此外，IPF 目标中的发散可能随着维度增长而不利地扩展。这可以通过采用 De Bortoli 等人 [24] 的更简单的回归来缓解。我们将此留作一个有前景的未来方向。

更广泛的影响

均场博弈 (Mean-Field Games, MFGs) 的研究具有其自身的社会影响力。因此, 作为均场博弈求解器, DeepGSB 可能在更实用的设定下为先前无法求解的均场博弈提供解决方案, 从而促进对群体行为的新理解。

致谢与资助披露

作者感谢 Yu-ting Chiang、Augustinos 和 Molei 的有益支持与友好讨论。作者还感谢匿名审稿人 A4H3 在 OpenReview 上最初严厉但富有建设性的评论, 这些评论促使理论结果在反驳阶段得到了实质性改进。

参考文献

- [1] Yves Achdou, Francisco J Buera, Jean-Michel Lasry, Pierre-Louis Lions, and Benjamin Moll. Partial differential equation models in macroeconomics. *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences*, 372(2028):20130397, 2014.
- [2] Yves Achdou, Jiequn Han, Jean-Michel Lasry, Pierre-Louis Lions, and Benjamin Moll. Income and wealth distribution in macroeconomics: A continuous-time approach. *The review of economic studies*, 89(1):45–86, 2022.
- [3] Simon Schweighofer, David Garcia, and Frank Schweitzer. An agent-based model of multi-dimensional opinion dynamics and opinion alignment. *Chaos: An Interdisciplinary Journal of Nonlinear Science*, 30(9):093139, 2020.
- [4] Jason Gaitonde, Jon Kleinberg, and Éva Tardos. Polarization in geometric opinion dynamics. In *Proceedings of the 22nd ACM Conference on Economics and Computation*, pages 499–519, 2021.
- [5] Jan Hązła, Yan Jin, Elchanan Mossel, and Govind Ramnarayan. A geometric model of opinion polarization. *arXiv preprint arXiv:1910.05274*, 2019.
- [6] Zhiyu Liu, Bo Wu, and Hai Lin. A mean field game approach to swarming robots control. In *2018 Annual American Control Conference (ACC)*, pages 4293–4298. IEEE, 2018.
- [7] Karthik Elamvazhuthi and Spring Berman. Mean-field models in swarm robotics: A survey. *Bioinspiration & Biomimetics*, 15(1):015001, 2019.
- [8] Yiping Lu, Chao Ma, Yulong Lu, Jianfeng Lu, and Lexing Ying. A mean-field analysis of deep resnet and beyond: Towards provable optimization via overparameterization from depth. *arXiv preprint arXiv:2003.05508*, 2020.
- [9] Kaitong Hu, Anna Kazeykina, and Zhenjie Ren. Mean-field langevin system, optimal control and deep neural networks. *arXiv preprint arXiv:1909.07278*, 2019.
- [10] E Weinan, Jiequn Han, and Qianxiao Li. A mean-field optimal control formulation of deep learning. *arXiv preprint arXiv:1807.01083*, 2018.
- [11] Jean-Michel Lasry and Pierre-Louis Lions. Mean field games. *Japanese journal of mathematics*, 2(1):229–260, 2007.
- [12] Olivier Guéant, Jean-Michel Lasry, and Pierre-Louis Lions. Mean field games and applications. In *Paris-Princeton lectures on mathematical finance 2010*, pages 205–266. Springer, 2011.
- [13] Alain Bensoussan, Jens Frehse, Phillip Yam, et al. *Mean field games and mean field type control theory*, volume 101. Springer, 2013.
- [14] Lars Ruthotto, Stanley J Osher, Wuchen Li, Levon Nurbekyan, and Samy Wu Fung. A machine learning framework for solving high-dimensional mean field game and mean field control problems. *Proceedings of the National Academy of Sciences*, 117(17):9183–9193, 2020.

- [15] Alex Tong Lin, Samy Wu Fung, Wuchen Li, Levon Nurbekyan, and Stanley J Osher. Alternating the population and control neural networks to solve high-dimensional stochastic mean-field games. *Proceedings of the National Academy of Sciences*, 118(31), 2021.
- [16] Yongxin Chen. Density control of interacting agent systems. *arXiv preprint arXiv:2108.07342*, 2021.
- [17] Jiequn Han, Arnulf Jentzen, and E Weinan. Solving high-dimensional partial differential equations using deep learning. *Proceedings of the National Academy of Sciences*, 115(34): 8505–8510, 2018.
- [18] Ioannis Exarchos and Evangelos A Theodorou. Stochastic optimal control via forward and backward stochastic differential equations and importance sampling. *Automatica*, 87:159–165, 2018.
- [19] Marcus Pereira, Ziyi Wang, Ioannis Exarchos, and Evangelos A Theodorou. Neural network architectures for stochastic control using the nonlinear feynman-kac lemma. *arXiv preprint arXiv:1902.03986*, 2019.
- [20] René Carmona, François Delarue, and Aimé Lachapelle. Control of mckean–vlasov dynamics versus mean field games. *Mathematics and Financial Economics*, 7(2):131–166, 2013.
- [21] René Carmona and François Delarue. Mean field forward-backward stochastic differential equations. *Electronic Communications in Probability*, 18:1–15, 2013.
- [22] René Carmona and Mathieu Laurière. Convergence analysis of machine learning algorithms for the numerical solution of mean field control and games: Ii—the finite horizon case. *arXiv preprint arXiv:1908.01613*, 2019.
- [23] René Carmona and Mathieu Laurière. Convergence analysis of machine learning algorithms for the numerical solution of mean field control and games i: the ergodic case. *SIAM Journal on Numerical Analysis*, 59(3):1455–1485, 2021.
- [24] Valentin De Bortoli, James Thornton, Jeremy Heng, and Arnaud Doucet. Diffusion schrödinger bridge with applications to score-based generative modeling. *arXiv preprint arXiv:2106.01357*, 2021.
- [25] Francisco Vargas, Pierre Thodoroff, Neil D Lawrence, and Austen Lamacraft. Solving schrödinger bridges via maximum likelihood. *arXiv preprint arXiv:2106.02081*, 2021.
- [26] Gefei Wang, Yuling Jiao, Qian Xu, Yang Wang, and Can Yang. Deep generative learning via schrödinger bridge. *arXiv preprint arXiv:2106.10410*, 2021.
- [27] Tianrong Chen, Guan-Horng Liu, and Evangelos A Theodorou. Likelihood training of schrödinger bridge using forward-backward sdes theory. *arXiv preprint arXiv:2110.11291*, 2021.
- [28] Charlotte Bunne, Ya-Ping Hsieh, Marco Cuturi, and Andreas Krause. Recovering stochastic dynamics via gaussian schrödinger bridges. *arXiv preprint arXiv:2202.05722*, 2022.
- [29] Erwin Schrödinger. Sur la théorie relativiste de l’électron et l’interprétation de la mécanique quantique. In *Annales de l’institut Henri Poincaré*, volume 2, pages 269–310, 1932.
- [30] Kenneth Caluya and Abhishek Halder. Wasserstein proximal algorithms for the schrödinger bridge problem: Density control with nonlinear drift. *IEEE Transactions on Automatic Control*, 2021.
- [31] Julio Backhoff, Giovanni Conforti, Ivan Gentil, and Christian Léonard. The mean field schrödinger problem: ergodic behavior, entropy estimates and functional inequalities. *Probability Theory and Related Fields*, 178(1):475–530, 2020.
- [32] Yongxin Chen, Tryphon Georgiou, and Michele Pavon. Optimal steering of inertial particles diffusing anisotropically with losses. In *2015 American Control Conference (ACC)*, pages 1252–1257. IEEE, 2015.

- [33] Erwin Schrödinger. *Über die umkehrung der naturgesetze*. Verlag der Akademie der Wissenschaften in Kommission bei Walter De Gruyter u . . . , 1931.
- [34] Christian Léonard. From the schrödinger problem to the monge–kantrovich problem. *Journal of Functional Analysis*, 262(4):1879–1920, 2012.
- [35] Christian Léonard. A survey of the schrödinger problem and some of its connections with optimal transport. *arXiv preprint arXiv:1308.0215*, 2013.
- [36] Michele Pavon and Anton Wakolbinger. On free energy, stochastic control, and schrödinger processes. In *Modeling, Estimation and Control of Systems with Uncertainty*, pages 334–348. Springer, 1991.
- [37] Paolo Dai Pra. A stochastic control approach to reciprocal diffusion processes. *Applied mathematics and Optimization*, 23(1):313–329, 1991.
- [38] Francisco Vargas. Machine-learning approaches for the empirical schrödinger bridge problem. Technical report, University of Cambridge, Computer Laboratory, 2021.
- [39] Jean-David Benamou, Guillaume Carlier, Marco Cuturi, Luca Nenna, and Gabriel Peyré. Iterative bregman projections for regularized transportation problems. *SIAM Journal on Scientific Computing*, 37(2):A1111–A1138, 2015.
- [40] Solomon Kullback. Probability densities with given marginals. *The Annals of Mathematical Statistics*, 39(4):1236–1243, 1968.
- [41] Qinsheng Zhang and Yongxin Chen. Path integral sampler: a stochastic control approach for sampling. *arXiv preprint arXiv:2111.15141*, 2021.
- [42] Eberhard Hopf. The partial differential equation $u_t + u u_x = \mu x x$. *Communications on Pure and Applied mathematics*, 3(3):201–230, 1950.
- [43] Julian D Cole. On a quasi-linear parabolic equation occurring in aerodynamics. *Quarterly of applied mathematics*, 9(3):225–236, 1951.
- [44] Jiongmin Yong and Xun Yu Zhou. *Stochastic controls: Hamiltonian systems and HJB equations*, volume 43. Springer Science & Business Media, 1999.
- [45] Magdalena Kobylanski. Backward stochastic differential equations and partial differential equations with quadratic growth. *Annals of probability*, pages 558–602, 2000.
- [46] Kiyosi Itô. *On stochastic differential equations*, volume 4. American Mathematical Soc., 1951.
- [47] Richard Bellman. The theory of dynamic programming. Technical report, Rand corp santa monica ca, 1954.
- [48] Emanuel Todorov. Efficient computation of optimal actions. *Proceedings of the national academy of sciences*, 106(28):11478–11483, 2009.
- [49] Michael Lutter, Shie Mannor, Jan Peters, Dieter Fox, and Animesh Garg. Value iteration in continuous actions, states and time. *arXiv preprint arXiv:2105.04682*, 2021.
- [50] Lingheng Meng, Rob Gorbet, and Dana Kulić. The effect of multi-step methods on overestimation in deep reinforcement learning. In *2020 25th International Conference on Pattern Recognition (ICPR)*, pages 347–353. IEEE, 2021.
- [51] Harm van Seijen. Effective multi-step temporal-difference learning for non-linear function approximation. *arXiv preprint arXiv:1608.05151*, 2016.
- [52] Matteo Hessel, Joseph Modayil, Hado Van Hasselt, Tom Schaul, Georg Ostrovski, Will Dabney, Dan Horgan, Bilal Piot, Mohammad Azar, and David Silver. Rainbow: Combining improvements in deep reinforcement learning. In *Thirty-second AAAI conference on artificial intelligence*, 2018.

- [53] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Alex Graves, Ioannis Antonoglou, Daan Wierstra, and Martin Riedmiller. Playing atari with deep reinforcement learning. *arXiv preprint arXiv:1312.5602*, 2013.
- [54] Timothy P Lillicrap, Jonathan J Hunt, Alexander Pritzel, Nicolas Heess, Tom Erez, Yuval Tassa, David Silver, and Daan Wierstra. Continuous control with deep reinforcement learning. *arXiv preprint arXiv:1509.02971*, 2015.
- [55] John Schulman, Sergey Levine, Pieter Abbeel, Michael Jordan, and Philipp Moritz. Trust region policy optimization. In *International conference on machine learning*, pages 1889–1897, 2015.
- [56] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. *arXiv preprint arXiv:1711.05101*, 2017.
- [57] Charles G Lord, Lee Ross, and Mark R Lepper. Biased assimilation and attitude polarization: The effects of prior theories on subsequently considered evidence. *Journal of personality and social psychology*, 37(11):2098, 1979.
- [58] Pranav Dandekar, Ashish Goel, and David T Lee. Biased assimilation, homophily, and the dynamics of polarization. *Proceedings of the National Academy of Sciences*, 110(15):5791–5796, 2013.
- [59] Etienne Pardoux and Shige Peng. Backward stochastic differential equations and quasilinear parabolic partial differential equations. In *Stochastic partial differential equations and their applications*, pages 200–217. Springer, 1992.
- [60] Balint Negyesi, Kristoffer Andersson, and Cornelis W Oosterlee. The one step malliavin scheme: new discretization of bsdes implemented with deep learning regressions. *arXiv preprint arXiv:2110.05421*, 2021.
- [61] Qianxiao Li and Shuji Hao. An optimal control approach to deep learning and applications to discrete-weight neural networks. In *International Conference on Machine Learning*, pages 2985–2994. PMLR, 2018.
- [62] Guan-Horng Liu, Tianrong Chen, and Evangelos A Theodorou. Ddpnpt: Differential dynamic programming neural optimizer. In *International Conference on Learning Representations*, 2021.
- [63] Guan-Horng Liu, Tianrong Chen, and Evangelos A Theodorou. Second-order neural ode optimizer. In *Advances in Neural Information Processing Systems*, 2021.
- [64] Yang Song, Jascha Sohl-Dickstein, Diederik P Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole. Score-based generative modeling through stochastic differential equations. *arXiv preprint arXiv:2011.13456*, 2020.
- [65] Edward Nelson. *Dynamical theories of Brownian motion*, volume 106. Princeton university press, 2020.
- [66] Brian DO Anderson. Reverse-time diffusion equation models. *Stochastic Processes and their Applications*, 12(3):313–326, 1982.
- [67] Grigorios A Pavliotis. *Stochastic processes and applications: diffusion processes, the Fokker-Planck and Langevin equations*, volume 60. Springer, 2014.
- [68] Yang Song, Conor Durkan, Iain Murray, and Stefano Ermon. Maximum likelihood training of score-based diffusion models. *arXiv e-prints*, pages arXiv–2101, 2021.
- [69] Chin-Wei Huang, Jae Hyun Lim, and Aaron Courville. A variational perspective on diffusion-based generative models and score matching. *arXiv preprint arXiv:2106.02808*, 2021.
- [70] Stefan Elfving, Eiji Uchibe, and Kenji Doya. Sigmoid-weighted linear units for neural network function approximation in reinforcement learning. *Neural Networks*, 107:3–11, 2018.
- [71] Adam Paszke, Sam Gross, Soumith Chintala, Gregory Chanan, Edward Yang, Zachary DeVito, Zeming Lin, Alban Desmaison, Luca Antiga, and Adam Lerer. Automatic differentiation in pytorch. 2017.

A 附录

A.1 缩写与符号汇总	15	A.2 非线性 FK 引理与 SB-FBSDE 回顾	15
A.3 正文中的证明	17	A.3.1 预备知识	17
A.3.2 引理 1 的证明	17	A.3.3 定理 2 的证明	18
A.3.4 命题 3 的证明	19	A.3.5 命题 4 的证明	21
A.4 第 3 节和第 4 节的补充推导与备注	23	A.4.1 Hopf-Cole 变换	23
A.4.2 关于收敛性的备注	23	A.4.3 均场势函数的泛函导数	24
A.5 实验细节	24	A.5.1 设置	24
A.5.2 补充实验	26		

A.1 缩写与符号汇总

表 4: 缩写。

MFGs	Mean-Field Games
SB	Schrödinger Bridge
DeepRL	Deep Reinforcement Learning
PDEs	Partial Differential Equations
HJB	Hamilton-Jacobi-Bellman
FP	Fokker-Plank
SDEs	Stochastic Differential Equations
FBSDEs	Forward-Backward SDEs
IPF	Iterative Proportional Fitting
MF interaction	Mean-field interaction
nonlinear FK	nonlinear Feynman-Kac
TD	Temporal Difference

表 5: 符号说明。

t	time coordinate
s	reversed time coordinate
$u(t, x)$	value function
$\rho(t, x)$	marginal distribution
$\rho_0, \rho_{\text{target}}$	initial/target distributions
H	Hamiltonian function
F	MF interaction function
f	MF base drift
σ	diffusion scaler
$(\Psi, \hat{\Psi})$	薛定谔桥偏微分方程组的解
(Y, Z)	nonlinear FK of Ψ
$(\hat{Y}, \hat{Z})$	nonlinear FK of $\hat{\Psi}$
TD_s	TD target for Y_s
$\widehat{\text{TD}}_t$	TD target for $\hat{Y}_t$
θ	Parameter of Y (and Z)
ϕ	Parameter of $\hat{Y}$ (and $\hat{Z}$)

A.2 非线性费曼-卡茨引理与薛定谔桥正倒向随机微分方程回顾

引理 5 （非线性费曼-卡茨引理 [18, 44, 45]）。设 $v \equiv v(x, t)$ 为关于 $x \in \mathbb{R}^d$ 二次连续可微且关于 $t \in [0, T]$, i.e., $v \in C^{2,1}(\mathbb{R}^d, [0, T])$ 一次可微的函数。

考虑如下二阶抛物型偏微分方程:

$$\frac{\partial v}{\partial t} + \frac{1}{2} \text{Tr}(\nabla^2 v G(x, t) G(x, t)^\top) + \nabla v^\top f(x, t) + h(x, v, G(x, t)^\top \nabla v, t) = 0, \quad v(T, x) = \varphi(x), \quad (19)$$

其中 ∇^2 表示关于 x 的黑塞算子, 函数 f, G, h 与 φ 满足适当的正则性条件。具体而言, (i) f, G, h 与 φ 连续, (ii) $f(x, t)$ 与 $G(x, t)$ 关于 x 一致利普希茨连续, (iii) $h(x, y, z, t)$ 关于 z 满足二次增长条件。则方程 (19) 存在唯一解 v , 使得如下随机表示 (称为非线性费曼-卡茨变换) 成立:

$$Y_t = v(X_t, t), \quad Z_t = G(X_t, t)^\top \nabla v(X_t, t), \quad (20)$$

其中 (X_t, Y_t, Z_t) 是下列正倒向随机微分方程组的唯一适应解:

$$\begin{aligned} dX_t &= f(X_t, t)dt + G(X_t, t)dW_t, \quad X_0 = x_0, \\ dY_t &= -h(X_t, Y_t, Z_t, t)dt + Z_t^\top dW_t, \quad Y_T = \varphi(X_T). \end{aligned} \quad (21)$$

原始确定性偏微分方程解 $v(x, t)$ 可通过取条件期望恢复:

$$\mathbb{E}[Y_t | X_t = x] = v(x, t), \quad \mathbb{E}[Z_t | X_t = x] = G(x, t)^\top \nabla v(x, t).$$

引理 5 通过非线性费曼-卡茨变换 (20) 建立了 (19) 中某一类 (非线性) 偏微分方程与正倒向随机微分方程 (21) 之间的有趣联系。本文采用更简单的扩散 $G(x, t) := \sigma$ 作为时不变标量, 但指出该推导可直接推广至更一般的情形。

粘性解 不存在时, 引理 5 可推广至粘性解。此时,

一致收敛, 其中 $v(x, t) = \lim_{\epsilon \rightarrow \infty} v_\epsilon(x, t)$ 在紧集上关于 (x, t) 一致收敛于 (f, G, h, φ) ; 完整讨论见 [18, 59, 60]。

SB-FBSDE [27]. SB-FBSDE 是一类新颖的生成模型, 其灵感来源于近期通过最优控制视角理解深度学习的进展 [61–63], 采用引理 5 对基于分数的扩散模型进行推广。由于偏微分方程 $(\frac{\partial \Psi}{\partial t}, \frac{\partial \hat{\Psi}}{\partial t})$ 的出现, 在原始 SB (4) 中均为抛物型 (19), 可应用引理 5 并推导相应的非线性生成元 h 。如 **SB-FBSDE[27]** 所示, 这导致以下 FBSDE:

$$\begin{cases} dX_t = (f_t + \sigma Z_t) dt + \sigma dW_t & (22a) \\ dY_t = \frac{1}{2} \|Z_t\|^2 dt + Z_t^\top dW_t & (22b) \\ d\hat{Y}_t = \left(\frac{1}{2} \|\hat{Z}_t\|^2 + \nabla \cdot (\sigma \hat{Z}_t - f_t) + \hat{Z}_t^\top Z_t \right) dt + \hat{Z}_t^\top dW_t & (22c) \end{cases}$$

进一步, 非线性费曼-卡茨变换为

$$\begin{aligned} Y_t &= \log \Psi(X_t, t), & Z_t &= \sigma \nabla \log \Psi(X_t, t), \\ \hat{Y}_t &= \log \hat{\Psi}(X_t, t), & \hat{Z}_t &= \sigma \nabla \log \hat{\Psi}(X_t, t), \end{aligned}$$

这立即表明

$$\mathbb{E}[Y_t | X_t = x] = \log \Psi(x, t), \quad \mathbb{E}[\hat{Y}_t | X_t = x] = \log \hat{\Psi}(x, t). \quad (23)$$

显而易见, 当平均场交互 $F(x, \rho)$, (在平均场博弈中 $F(x, \rho) = \mathbb{E}[Y_t + Y_t | X_t = x]$) 是本文定理 2 的一个特例。由于 SB-FBSDE 最初是在生成建模的背景下发展起来的 [64], 其训练依赖于在边界处计算对数似然。这些对数似然可以通过注意到 $\log \rho(x, t) = \mathbb{E}[Y_t + Y_t | X_t = x]$, (由 (23) 和 (8) 式隐含) 来获得。当 $Z_\phi(X_t, t) \approx Z_t$ 且 $Z_\theta(\bar{X}_s, s) \approx Z_s$ 时, SB-FBSDE 的训练目标可以计算为参数化的变分下界:

$$\log \rho_0(\phi; x) \geq \mathcal{L}_{\text{IPF}}(\phi) := \mathbb{E}[Y_t^\theta + \hat{Y}_t^\phi | X_t = x, t = 0] = \int_t \mathbb{E} \left[dY_t^\theta + d\hat{Y}_t^\phi | X_0 = x \right], \quad (24a)$$

$$\log \rho_T(\theta; x) \geq \mathcal{L}_{\text{IPF}}(\theta) := \mathbb{E}[Y_s^\theta + \hat{Y}_s^\phi | \bar{X}_s = x, s = 0] = \int_s \mathbb{E} \left[dY_s^\theta + d\hat{Y}_s^\phi | \bar{X}_0 = x \right]. \quad (24b)$$

利用 (22) 式展开 (24) 式右端, 即可得到 (6) 式中的表达式:

$$\begin{aligned}\mathcal{L}_{\text{IPF}}(\theta) &= \int_0^T \mathbb{E}_{(3b)} \left[\frac{1}{2} \|Z_\theta(\bar{X}_s, s)\|_2^2 + Z_\theta(\bar{X}_s, s)^\top \widehat{Z}_\phi(\bar{X}_s, s) + \nabla \cdot (\sigma Z_\theta(\bar{X}_s, s) + f) \right] ds, \\ \mathcal{L}_{\text{IPF}}(\phi) &= \int_0^T \mathbb{E}_{(3a)} \left[\frac{1}{2} \|\widehat{Z}_\phi(X_t, t)\|_2^2 + \widehat{Z}_\phi(X_t, t)^\top Z_\theta(X_t, t) + \nabla \cdot (\sigma \widehat{Z}_\phi(X_t, t) - f) \right] dt.\end{aligned}$$

由于 (24) 式仅涉及对期望的积分, 即 $\int \mathbb{E}[dY + d\bar{Y}]$, SB-FBSDE 从未显式计算 SDE (22b, 22c) 的解 $(Y_t, \bar{Y}_t)$ 。这与本文的 DeepGSB 形成对比, 后者关键性地需要显式计算 $(Y_t, \bar{Y}_t)$, 并用 TD 目标回归其值, 从而分别尊重 dY 和 $d\bar{Y}$ 的随机动力学。

A.3 正文中的证明

在本节中, 我们将参数化的前向和后向 SDE 分别记为

$$dX_t^\theta = (f_t + \sigma Z_\theta(X_t^\theta, t)) dt + \sigma dW_t, \quad (25a)$$

$$d\bar{X}_s^\phi = \left(-f_s + \sigma \widehat{Z}_\phi(\bar{X}_s^\phi, t) \right) ds + \sigma dW_s, \quad (25b)$$

并将其时间边缘密度分别记为 q^θ 和 q^ϕ 。

A.3.1 预备知识

我们首先重述一些在后续证明中将要用到的有用引理。

引理 6 (伊藤公式 [46])。设 X_t 为伊藤随机微分方程的解:

$$dX_t = f(X_t, t)dt + \sigma(X_t, t)dW_t.$$

则随机过程 $v(X_t, t)$ (其中 $v \in C^{2,1}(\mathbb{R}^d, [0, T])$) 也是伊藤过程, 且满足

$$dv(X_t, t) = \frac{\partial v(X_t, t)}{\partial t} dt + \left[\nabla v(X_t, t)^\top f + \frac{1}{2} \text{Tr} [\sigma^\top \nabla^2 v(X_t, t) \sigma] \right] dt + [\nabla v(X_t, t)^\top \sigma] dW_t. \quad (26)$$

引理 7。在任意满足 $p(x) \neq 0$ 的点 $x \in \mathbb{R}^n$ 处, 以下等式成立。

$$\frac{1}{p(x)} \Delta p(x) = \|\nabla \log p(x)\|^2 + \Delta \log p(x)$$

证明。 $\frac{1}{p(x)} \Delta p(x) = \frac{1}{p(x)} \nabla \cdot \nabla p(x) = \frac{1}{p(x)} \nabla \cdot (p(x) \nabla \log p(x))$ 。对发散项应用链式法则即可得到所需结果。 $\square$

引理 8 (Vargas [38], 命题 1, 第 6.3.1 节)。

$$d \log q_t^\phi = \left[\nabla \cdot (\sigma \widehat{Z}_\phi - f_t) + \sigma (Z_\theta + \widehat{Z}_\phi)^\top \nabla \log q_t^\phi - \frac{1}{2} \|\sigma \nabla \log q_t^\phi\|^2 \right] dt + \sigma \nabla \log q_t^\phi^\top dW_t.$$

证明。对参数化前向随机微分方程 (25a) 应用伊藤引理,

$$d \log q_t^\phi = \left[\frac{\partial \log q_t^\phi}{\partial t} + \nabla \log q_t^\phi^\top (f_t + \sigma Z_\theta) + \frac{\sigma^2}{2} \Delta \log q_t^\phi \right] dt + \sigma \nabla \log q_t^\phi^\top dW_t,$$

where $\frac{\partial \log q_t^\phi}{\partial t}$ obeys (see Eq 13.4 in Nelson [65]):

$$\begin{aligned}-\frac{\partial \log q_t^\phi}{\partial t} &= -\nabla \cdot ((\sigma \widehat{Z}_\phi - f_t) q_t^\phi) + \frac{\sigma^2}{2} \Delta q_t^\phi \\ \Rightarrow \frac{\partial \log q_t^\phi}{\partial t} &= \nabla \cdot (\sigma \widehat{Z}_\phi - f_t) + (\sigma \widehat{Z}_\phi - f_t)^\top \nabla \log q_t^\phi - \frac{\sigma^2 \Delta q_t^\phi}{2 q_t^\phi}.\end{aligned}$$

代入上述关系即可得到所需结果。 $\square$

命题 9 (Vargas [38], 第 6.3.1 节命题 1)。

$$D_{\text{KL}}(q^\theta || q^\phi) = \int_0^T \mathbb{E}_{q_t^\theta} \left[\frac{1}{2} \|\widehat{Z}_\phi + Z_\theta\|^2 + \nabla \cdot (\sigma \widehat{Z}_\phi - f_t) \right] dt + \mathbb{E}_{q_0^\theta} [\log \rho_0] - \mathbb{E}_{q_T^\theta} [\log \rho_{\text{target}}]$$

证明。回顾参数化后向随机微分方程 (25b) 可逆转为 [64, 66]

$$d\bar{X}_t^\phi = \left(f_t - \sigma \widehat{Z}_\phi(\bar{X}_t^\phi, t) + \sigma^2 \nabla \log q^\phi(\bar{X}_t^\phi, t) \right) dt + \sigma dW_t.$$

那么, 我们有

$$\begin{aligned} & D_{\text{KL}}(q^\theta || q^\phi) \\ &= \int_0^T \mathbb{E}_{q_t^\theta} \left[\frac{1}{2} \|\widehat{Z}_\phi + Z_\theta - \sigma \nabla \log q_t^\phi\|^2 \right] dt + D_{\text{KL}}(\rho_0 || q_{t=0}^\phi) \\ &= \int_0^T \mathbb{E}_{q_t^\theta} \left[\frac{1}{2} \|\widehat{Z}_\phi + Z_\theta\|^2 - \sigma (\widehat{Z}_\phi + Z_\theta)^T \nabla \log q_t^\phi + \frac{1}{2} \|\sigma \nabla \log q_t^\phi\|^2 \right] dt + D_{\text{KL}}(\rho_0 || q_{t=0}^\phi) \\ &\stackrel{(*)}{=} \int_0^T \mathbb{E}_{q_t^\theta} \left[\frac{1}{2} \|\widehat{Z}_\phi + Z_\theta\|^2 + \nabla \cdot (\sigma \widehat{Z}_\phi - f_t) \right] dt - \mathbb{E}_{q^\theta} \left[\int_0^T d \log q_t^\phi \right] + D_{\text{KL}}(\rho_0 || q_{t=0}^\phi) \\ &= \int_0^T \mathbb{E}_{q_t^\theta} \left[\frac{1}{2} \|\widehat{Z}_\phi + Z_\theta\|^2 + \nabla \cdot (\sigma \widehat{Z}_\phi - f_t) \right] dt + \mathbb{E}_{q_0^\theta} [\log \rho_0] - \mathbb{E}_{q_T^\theta} [\log \rho_{\text{target}}], \end{aligned}$$

其中 (*) 由引理 8 得出。 $\square$

A.3.2 引理 1 的证明

证明。将 $\mathcal{L}_{\text{IPF}}(\phi)$ 代入命题 9, 并舍弃所有与 ϕ 无关的项, 即可得到。类似的关系可以在 $D_{\text{KL}}(q^\phi || q^\theta)$ 之间推导出来。 $\square$

注记 (另一种更简单的证明)。假设 (Z_θ, q^θ) 和 (Z_ϕ, q^ϕ) 满足适当的正则性条件, 使得当 $x \rightarrow \infty$,

$$\forall t, s \in [0, T], \quad \exists k > 0 : q^\theta(x, t) = \mathcal{O}(\exp^{-\|x\|_k^2}), \quad q^\phi(x, s) = \mathcal{O}(\exp^{-\|x\|_k^2})$$

时, 另一种利用分部积分的证明如下: 回顾参数化的正向随机微分方程 (25a) 可以反向 [64, 66] 为

$$dX_s^\theta = (-f_s - \sigma Z_\theta(X_s^\theta, s) + \sigma^2 \nabla \log q^\theta(X_s^\theta, s)) ds + \sigma dW_s.$$

那么, KL 散度可以计算为

$$\begin{aligned} & D_{\text{KL}}(q^\theta || q^\phi) \\ &\stackrel{(*)}{=} \mathbb{E}_{q^\theta} \left[\int_0^T \frac{1}{2\sigma^2} \|\sigma \widehat{Z}_\phi + \sigma Z_\theta - \sigma^2 \nabla \log q_s^\theta\|^2 ds \right] + D_{\text{KL}}(q_{s=0}^\theta || \rho_{\text{target}}) \tag{27} \\ &= \int_0^T \mathbb{E}_{q_s^\theta} \left[\frac{1}{2} \|\widehat{Z}_\phi + Z_\theta\|^2 - \sigma (\widehat{Z}_\phi + Z_\theta)^T \nabla \log q_s^\theta + \frac{1}{2} \|\sigma \nabla \log q_s^\theta\|^2 \right] ds + D_{\text{KL}}(q_0^\theta || \rho_{\text{target}}) \\ &= \int_0^T \mathbb{E}_{q_s^\theta} \left[\frac{1}{2} \|\widehat{Z}_\phi\|^2 + \widehat{Z}_\phi^T Z_\theta - \sigma \widehat{Z}_\phi^T \nabla \log q_s^\theta \right] ds + \mathcal{O}(1) \\ &\stackrel{(**)}{=} \int_0^T \mathbb{E}_{q_s^\theta} \left[\frac{1}{2} \|\widehat{Z}_\phi\|^2 + \widehat{Z}_\phi^T Z_\theta + \sigma \nabla \cdot \widehat{Z}_\phi \right] ds + \mathcal{O}(1), \\ &\propto \mathcal{L}_{\text{IPF}}(\phi) \end{aligned}$$

其中 (*) 由吉尔萨诺夫定理 [67] 得到, (**) 由分部积分得到。 $\mathcal{O}(1)$ 收集与 ϕ 无关的项。注意, 由于对 q^θ 和 q^ϕ 的额外正则性假设, 边界项消失。类似的变换已被采用, 例如 Song 等人 [68] 的定理 1 或 Huang 等人 [69] 的定理 3。

A.3.3 定理 2 的证明

证明。对 $v := \log \Psi(X_t, t)$ 应用伊藤公式，其中 X_t 遵循 (3a)，

$$d \log \Psi = \frac{\partial \log \Psi}{\partial t} dt + \left[\nabla \log \Psi^\top (f + \sigma^2 \nabla \log \Psi) + \frac{\sigma^2}{2} \Delta \log \Psi \right] dt + \sigma \nabla \log \Psi^\top dW_t,$$

并注意到 $\frac{\partial \log \Psi}{\partial t}$ 的偏微分方程 obeys

$$\frac{\partial \log \Psi}{\partial t} = \frac{1}{\Psi} \left(-\nabla \Psi^\top f - \frac{\sigma^2}{2} \Delta \Psi + F \Psi \right) = -\nabla \log \Psi^\top f - \frac{\sigma^2}{2} \|\nabla \log \Psi\|^2 - \frac{\sigma^2}{2} \Delta \log \Psi + F.$$

由此得到

$$d \log \Psi = \left[\frac{1}{2} \|\sigma \nabla \log \Psi\|^2 + F \right] dt + \sigma \nabla \log \Psi^\top dW_t. \quad (28)$$

现在，通过代入 $v := \log \Psi(X_t, t)$ ，其中 X_t 遵循 (3a)，应用相同的伊藤公式，

$$d \log \hat{\Psi} = \frac{\partial \log \hat{\Psi}}{\partial t} dt + \left[\nabla \log \hat{\Psi}^\top (f + \sigma^2 \nabla \log \Psi) + \frac{\sigma^2}{2} \Delta \log \hat{\Psi} \right] dt + \sigma \nabla \log \hat{\Psi}^\top dW_t,$$

并注意到 $\frac{\partial \log \hat{\Psi}}{\partial t}$ 的偏微分方程 obeys

$$\begin{aligned} \frac{\partial \log \hat{\Psi}}{\partial t} &= \frac{1}{\hat{\Psi}} \left(-\nabla \cdot (\hat{\Psi} f) + \frac{\sigma^2}{2} \Delta \hat{\Psi} - F \hat{\Psi} \right) \\ &= -\nabla \log \hat{\Psi}^\top f - \nabla \cdot f + \frac{\sigma^2}{2} \|\nabla \log \hat{\Psi}\|^2 + \frac{\sigma^2}{2} \Delta \log \hat{\Psi} - F. \end{aligned}$$

由此得到

$$\begin{aligned} d \log \hat{\Psi} &= \left[-\nabla \cdot f + \frac{\sigma^2}{2} \|\nabla \log \hat{\Psi}\|^2 + \sigma^2 \nabla \log \hat{\Psi}^\top \nabla \log \Psi + \sigma^2 \Delta \log \hat{\Psi} - F \right] dt + \sigma \nabla \log \hat{\Psi}^\top dW_t \\ &= \left[\nabla \cdot (\sigma^2 \nabla \log \hat{\Psi} - f) + \frac{\sigma^2}{2} \|\nabla \log \hat{\Psi}\|^2 + \sigma^2 \nabla \log \hat{\Psi}^\top \nabla \log \Psi - F \right] dt + \sigma \nabla \log \hat{\Psi}^\top dW_t. \end{aligned} \quad (29)$$

最后，利用 (10) 中的非线性 FK 变换，即

$$\begin{aligned} Y_t &\equiv Y(X_t, t) = \log \Psi(X_t, t), & Z_t &\equiv Z(X_t, t) = \sigma \nabla \log \Psi(X_t, t), \\ \hat{Y}_t &\equiv \hat{Y}(X_t, t) = \log \hat{\Psi}(X_t, t), & \hat{Z}_t &\equiv \hat{Z}(X_t, t) = \sigma \nabla \log \hat{\Psi}(X_t, t), \end{aligned}$$

我们可以将 (3a, 28, 29) 重写为 (11) 中的 FBSDEs 系统。

$$\begin{aligned} dX_t &= (f_t + \sigma Z_t) dt + \sigma dW_t \\ dY_t &= \left[\frac{1}{2} \|Z_t\|^2 + F_t \right] dt + Z_t^\top dW_t \\ d\hat{Y}_t &= \left[\frac{1}{2} \|\hat{Z}_t\|^2 + \hat{Z}_t^\top Z_t + \nabla \cdot (\sigma \hat{Z}_t - f_t) - F_t \right] dt + \hat{Z}_t^\top dW_t \end{aligned}$$

其中

$$f_t := f(X_t, \exp(Y_t + \hat{Y}_t)), \quad F_t := F(X_t, \exp(Y_t + \hat{Y}_t)).$$

第二个 FBSDEs 系统 (12) 的推导遵循类似的流程。不同之处在于我们需要将偏微分方程 (9) 重新基准到“反向”时间坐标 $s := T - t$ 。这可以通过在 s 坐标下重新表述 (7) 中的 HJB 和 FP 偏微分方程，然后应用以下 Hopf-Cole 变换来实现：

$$\hat{\Psi}(x, s) := \exp(-u(x, s)), \quad \Psi(x, s) := \rho(x, s) \exp(u(x, s)). \quad (31)$$

注意，我们交换了 $\Psi(x, s)$ 与 $\Psi(x, s)$ 的角色，因为前者现在与 (3b) 中出现的策略相关。省略与附录 A.4.1 类似的计算，我们得到以下结果：

$$\begin{cases} \frac{\partial \hat{\Psi}(x, s)}{\partial s} = \nabla \hat{\Psi}^\top f - \frac{1}{2} \sigma^2 \Delta \hat{\Psi} + F \hat{\Psi} \\ \frac{\partial \Psi(x, s)}{\partial s} = \nabla \cdot (\Psi f) + \frac{1}{2} \sigma^2 \Delta \Psi - F \Psi \end{cases} \quad \text{s.t.} \quad \begin{cases} \hat{\Psi}(\cdot, 0) \Psi(\cdot, 0) = \rho_{\text{target}} \\ \hat{\Psi}(\cdot, T) \Psi(\cdot, T) = \rho_0 \end{cases}. \quad (32)$$

对 $v := \log \Psi(\bar{X}_s, s)$ 应用伊藤公式，其中 $\bar{X}_s$ 沿反向随机微分方程 (3b) 演化。

$$d \log \Psi = \frac{\partial \log \Psi}{\partial s} ds + \left[\nabla \log \Psi^\top (-f + \sigma^2 \nabla \log \hat{\Psi}) + \frac{\sigma^2}{2} \Delta \log \Psi \right] ds + \sigma \nabla \log \Psi^\top dW_s,$$

并注意到 $\frac{\partial \log \Psi}{\partial s}$ 的偏微分方程 now obeys

$$\begin{aligned} \frac{\partial \log \Psi}{\partial s} &= \frac{1}{\Psi} \left(\nabla \cdot (\Psi f) + \frac{\sigma^2}{2} \Delta \Psi - F \Psi \right) \\ &= \nabla \log \Psi^\top f + \nabla \cdot f + \frac{\sigma^2}{2} \|\nabla \log \Psi\|^2 + \frac{\sigma^2}{2} \Delta \log \Psi - F. \end{aligned}$$

由此得到

$$\begin{aligned} d \log \Psi &= \left[\nabla \cdot f + \frac{\sigma^2}{2} \|\nabla \log \Psi\|^2 + \sigma^2 \nabla \log \Psi^\top \nabla \log \hat{\Psi} + \sigma^2 \Delta \log \Psi - F \right] ds + \sigma \nabla \log \Psi^\top dW_s \\ &= \left[\nabla \cdot (f + \sigma^2 \nabla \log \Psi) + \frac{\sigma^2}{2} \|\nabla \log \Psi\|^2 + \sigma^2 \nabla \log \Psi^\top \nabla \log \hat{\Psi} - F \right] ds + \sigma \nabla \log \Psi^\top dW_s. \end{aligned} \quad (33)$$

类似地，对 $v := \log \hat{\Psi}(\bar{X}_s, s)$ 应用伊藤公式，其中 $\bar{X}_s$ 遵循相同的反向随机微分方程 (3b)。

$$d \log \hat{\Psi} = \frac{\partial \log \hat{\Psi}}{\partial s} ds + \left[\nabla \log \hat{\Psi}^\top (-f + \sigma^2 \nabla \log \hat{\Psi}) + \frac{\sigma^2}{2} \Delta \log \hat{\Psi} \right] ds + \sigma \nabla \log \hat{\Psi}^\top dW_s,$$

并注意到 $\frac{\partial \log \hat{\Psi}}{\partial s}$ 的偏微分方程 obeys

$$\frac{\partial \log \hat{\Psi}}{\partial s} = \frac{1}{\hat{\Psi}} \left(\nabla \hat{\Psi}^\top f - \frac{\sigma^2}{2} \Delta \hat{\Psi} + F \hat{\Psi} \right) = \nabla \log \hat{\Psi}^\top f - \frac{\sigma^2}{2} \|\nabla \log \hat{\Psi}\|^2 - \frac{\sigma^2}{2} \Delta \log \hat{\Psi} + F.$$

由此得到

$$d \log \hat{\Psi} = \left[\frac{1}{2} \|\sigma \nabla \log \hat{\Psi}\|^2 + F \right] ds + \sigma \nabla \log \hat{\Psi}^\top dW_s. \quad (34)$$

最后，通过类似于 (10) 的非线性费曼-卡茨变换，

$$\begin{aligned} Y_s &\equiv Y(\bar{X}_s, s) = \log \Psi(\bar{X}_s, s), & Z_s &\equiv Z(\bar{X}_s, s) = \sigma \nabla \log \Psi(\bar{X}_s, s), \\ \hat{Y}_s &\equiv \hat{Y}(\bar{X}_s, s) = \log \hat{\Psi}(\bar{X}_s, s), & \hat{Z}_s &\equiv \hat{Z}(\bar{X}_s, s) = \sigma \nabla \log \hat{\Psi}(\bar{X}_s, s), \end{aligned} \quad (35)$$

我们可以将 (3b, 33, 34) 重写为 (12) 中的第二个正倒向随机微分方程组。

$$\begin{cases} d\bar{X}_s = (-f_s + \sigma \hat{Z}_s) ds + \sigma dW_s \\ dY_s = \left(\frac{1}{2} \|Z_s\|^2 + \nabla \cdot (\sigma Z_s + f_s) + Z_s^\top \hat{Z}_s - F_s \right) ds + Z_s^\top dW_s \\ d\hat{Y}_s = \left(\frac{1}{2} \|\hat{Z}_s\|^2 + F_s \right) ds + \hat{Z}_s^\top dW_s \end{cases}$$

其中

$$f_s := f(\bar{X}_s, \exp(Y_s + \hat{Y}_s)), \quad F_s := F(\bar{X}_s, \exp(Y_s + \hat{Y}_s)).$$

证明完毕。 $\square$

A.3.4 命题 3 的证明

证明。我们仅证明时间坐标 t 的时间差分目标 (14a)，因为所有推导可以类似地应用于其反向坐标 $s := T - t$ 。

给定参数化随机微分方程 (11a) 在某个固定步长 δt , *i.e.*, 下的一个实现

$$X_{t+\delta t}^\theta = X_t^\theta + (f_t + \sigma Z_\theta(X_t^\theta, t)) \delta t + \delta W_t, \quad \delta W_t \sim \mathcal{N}(\mathbf{0}, \delta t \mathbf{I}),$$

我们可以将轨迹紧凑地表示为在离散时间网格 $t \in \{0, \delta t, \dots, T - \delta t, T\}$ 上采样得到的元组序列 $\mathbf{X}_t^\theta \equiv (X_t^\theta, Z_t^\theta, \delta W_t)$ 。 Y_t , *i.e.*, (即 (11c) 右端) 的增量变化可由下式计算:

$$\delta \hat{Y}_t(\mathbf{X}_t^\theta) := \left(\frac{1}{2} \|\hat{Z}(X_t^\theta, t)\|^2 + \nabla \cdot (\sigma \hat{Z}(X_t^\theta, t) - f_t) + \hat{Z}(X_t^\theta, t)^\top Z_t^\theta - F_t \right) \delta t + \hat{Z}(X_t^\theta, t)^\top \delta W_t,$$

其中 $Z(\cdot, \cdot)$ 为 (参数化) 后向策略, 为简便起见, 我们记 $Z_t^\theta := Z_\theta(X_t^\theta, t)$ 为简。

回顾反向随机微分方程系统 (11) 满足平衡条件时, 随机微分方程 (11c) 必然成立。这提示以下等式:

$$\hat{Y}(X_{t+\delta t}^\theta, t + \delta t) = \hat{Y}(X_t^\theta, t) + \delta \hat{Y}_t(\mathbf{X}_t^\theta). \quad (37)$$

因此, 我们可以将 (37) 的右端解释为单步时序差分目标 $\hat{Y}_{t+\delta t} - \hat{Y}_t$ (单步时序差分), 从而得到 (14a) 中的表达式。多步时序差分目标可按照标准做法 [51, 52] 相应构造, 任一时序差分目标均可用于构造参数化函数 $Y_\phi \approx Y$ 的时序差分目标, 进而得到 (16)。

A.3.5 命题 4 的证明

证明。首先证明必要性。假设参数化函数 $(Y_\theta, Z_\theta, Y_\phi, Z_\phi)$ 满足 (11, 12) 中的随机微分方程, 显然 TD 目标 $\mathcal{L}_{\text{TD}}(\phi)$ 和 $\mathcal{L}_{\text{TD}}(\theta)$ 都应被最小化, 因为参数化函数满足 (11c, 12b)。接下来, 注意到 (11) 意味着

$$\begin{aligned} Y_T^\theta + \hat{Y}_T^\phi &= \left(Y_0^\theta + \int_0^T dY_t^\theta \right) + \left(\hat{Y}_0^\phi + \int_0^T d\hat{Y}_t^\phi \right) \\ \Rightarrow 0 &= \mathbb{E}_{q^\theta} \left[\left(Y_0^\theta + \hat{Y}_0^\phi \right) + \int_0^T \left(dY_t^\theta + d\hat{Y}_t^\phi \right) - \left(Y_T^\theta + \hat{Y}_T^\phi \right) \right] \\ &\stackrel{(*)}{=} \mathbb{E}_{q_0^\theta} [\log \rho_0] + \int_0^T \mathbb{E}_{q_t^\theta} \left[\frac{1}{2} \|Z_t^\theta + \hat{Z}_t^\phi\|^2 + \nabla \cdot (\sigma \hat{Z}_t^\phi - f_t) \right] dt - \mathbb{E}_{q_T^\theta} [\log \rho_{\text{target}}] \\ &\stackrel{(**)}{=} \mathbb{E}_{q_0^\theta} [\log \rho_0] + D_{\text{KL}}(q^\theta \| q^\phi) - \mathbb{E}_{q^\theta} \left[\log \frac{\rho_0}{\rho_{\text{target}}} \right] - \mathbb{E}_{q_T^\theta} [\log \rho_{\text{target}}] \\ &= D_{\text{KL}}(q^\theta \| q^\phi), \end{aligned}$$

其中 (*) 由 (11b, 11c) 得出, (**) 引用了命题 9。 $\mathcal{L}_{\text{IPF}}(\phi) \propto D_{\text{KL}}(q^\theta \| q^\phi) = 0$ (回顾引理 1) 这一事实表明, 当 (11) 成立时, 目标 $\mathcal{L}_{\text{IPF}}(\phi)$ 被最小化。最后, 由于当 (12) 成立时, 类似的论证可以应用于 $\mathcal{L}_{\text{IPF}}(\theta) \propto D_{\text{KL}}(q^\phi \| q^\theta) = 0$, 我们得出结论: 当参数化函数满足正倒向随机微分方程系统 (11, 12) 时, 所有损失都被最小化。

接下来证明充分性, 这部分更为复杂。首先, 注意到

$$\mathcal{L}_{\text{IPF}}(\phi) \text{ is minimized} \Leftrightarrow D_{\text{KL}}(q^\theta \| q^\phi) = 0 \Leftrightarrow \forall s \in [0, T], Z_s^\theta + \hat{Z}_s^\phi - \sigma \nabla \log q_s^\theta = 0, \quad (38)$$

$$\mathcal{L}_{\text{IPF}}(\theta) \text{ is minimized} \Leftrightarrow D_{\text{KL}}(q^\phi \| q^\theta) = 0 \Leftrightarrow \forall t \in [0, T], Z_t^\theta + \hat{Z}_t^\phi - \sigma \nabla \log q_t^\phi = 0, \quad (39)$$

如 (27) 所暗示的。如果 $\mathcal{L}_{\text{TD}}(\phi)$ 和 $\mathcal{L}_{\text{TD}}(\theta)$ 被最小化, 则以下关系也必须成立

$$d\hat{Y}_t^\phi = \left(\frac{1}{2} \|\hat{Z}_t^\phi\|^2 + \nabla \cdot (\sigma \hat{Z}_t^\phi - f_t) + Z_t^{\theta\top} \hat{Z}_t^\phi - F_t \right) dt + \hat{Z}_t^{\phi\top} dW_t, \quad (40)$$

$$dY_s^\theta = \left(\frac{1}{2} \|Z_s^\theta\|^2 + \nabla \cdot (\sigma Z_s^\theta + f_s) + Z_s^{\theta\top} \hat{Z}_s^\phi - F_s \right) dt + Z_s^{\theta\top} dW_s. \quad (41)$$

现在，注意到参数化正向随机微分方程 (25a) 的福克-普朗克方程满足

$$\frac{\partial q_t^\theta}{\partial t} = -\nabla \cdot (q_t^\theta (f_t + \sigma Z_t^\theta)) + \frac{1}{2} \sigma^2 \Delta q_t^\theta,$$

这意味着 (参见引理 7) ,

$$\frac{\partial \log q_t^\theta}{\partial t} = -\nabla \cdot (f_t + \sigma Z_t^\theta) - \nabla \log q_t^{\theta \top} (f_t + \sigma Z_t^\theta) + \frac{\sigma^2}{2} (\Delta \log q_t^\theta + \|\nabla \log q_t^\theta\|^2). \quad (42)$$

应用伊藤引理得到:

$$\begin{aligned} d \log q_t^\theta &= \frac{\partial \log q_t^\theta}{\partial t} dt + \left[\nabla \log q_t^{\theta \top} (f_t + \sigma Z_t^\theta) + \frac{\sigma^2}{2} \Delta \log q_t^\theta \right] dt + \sigma \nabla \log q_t^{\theta \top} dW_t \\ &\stackrel{(42)}{=} \left[-\nabla \cdot (f_t + \sigma Z_t^\theta) + \sigma^2 \Delta \log q_t^\theta + \frac{\sigma^2}{2} \|\nabla \log q_t^\theta\|^2 \right] dt + \sigma \nabla \log q_t^{\theta \top} dW_t \\ &= \left[-\nabla \cdot (f_t + \sigma Z_t^\theta - \sigma^2 \nabla \log q_t^\theta) + \frac{1}{2} \|\sigma \nabla \log q_t^\theta\|^2 \right] dt + \sigma \nabla \log q_t^{\theta \top} dW_t \\ &\stackrel{(*)}{=} \left[-\nabla \cdot (f_t + \sigma Z_t^\theta - \sigma (Z_t^\theta + \hat{Z}_t^\phi)) + \frac{1}{2} \|Z_t^\theta + \hat{Z}_t^\phi\|^2 \right] dt + (Z_t^\theta + \hat{Z}_t^\phi)^\top dW_t \\ &= \left[\nabla \cdot (\sigma \hat{Z}_t^\phi - f_t) + \frac{1}{2} \|Z_t^\theta + \hat{Z}_t^\phi\|^2 \right] dt + (Z_t^\theta + \hat{Z}_t^\phi)^\top dW_t, \end{aligned} \quad (43)$$

其中 (*) 由 (38) 得出。从 (43) 中减去 (40) 得到

$$d \log q_t^\theta - d \hat{Y}_t^\phi = \left(\frac{1}{2} \|Z_t^\theta\|^2 + F_t \right) dt + Z_t^{\theta \top} dW_t. \quad (44)$$

现在，利用 $Z_\theta := \sigma \nabla Y_\theta$ 和 $Z_\phi := \sigma \nabla Y_\phi$ 的事实，我们知道对于某个函数

$c_t \equiv c(t)$ 有 $Z_t^\theta + \hat{Z}_t^\phi - \sigma \nabla \log q_t^\theta = 0 \Rightarrow Y_t^\theta + \hat{Y}_t^\phi = \log q_t^\theta + c_t$ 。因此，
(44) 式变为

$$dY_t^\theta - dc_t = \left(\frac{1}{2} \|Z_t^\theta\|^2 + F_t \right) dt + Z_t^{\theta \top} dW_t. \quad (45)$$

现在我们用反证法证明 $\forall t \in (0, T), dc_t = 0$ 。首先，注意到 c_t 可以解析地推导为

$$\begin{aligned} c_t &= Y_t^\theta + \hat{Y}_t^\phi - \log q_t^\theta \\ &= \int_0^t (dY_\tau^\theta + d\hat{Y}_\tau^\phi - d \log q_\tau^\theta) \\ &\stackrel{(*)}{=} \int_0^t \left(\left(\frac{\partial Y_\tau^\theta}{\partial \tau} + \nabla Y_\tau^{\theta \top} (f_\tau + \sigma Z_\tau^\theta) + \frac{\sigma^2}{2} \Delta Y_\tau^\theta \right) - \left(\frac{1}{2} \|Z_\tau^\theta\|^2 + F_\tau \right) \right) d\tau \\ &\quad + \int_0^t (\sigma \nabla Y_\tau^{\theta \top} dW_\tau - Z_\tau^{\theta \top} dW_\tau) \\ &\stackrel{(**)}{=} \int_0^t \left(\frac{\partial Y_\tau^\theta}{\partial t} - \left(-\nabla Y_\tau^{\theta \top} f_\tau - \frac{1}{2} \|\sigma \nabla Y_\tau^\theta\|^2 - \frac{\sigma^2}{2} \Delta Y_\tau^\theta + F_\tau \right) \right) d\tau, \end{aligned} \quad (46)$$

where (*) invokes the following Ito lemma and substitutes (44),

$$dY_\tau^\theta = \frac{\partial Y_\tau^\theta}{\partial \tau} d\tau + \left[\nabla Y_\tau^{\theta \top} (f_\tau + \sigma Z_\tau^\theta) + \frac{\sigma^2}{2} \Delta Y_\tau^\theta \right] dt + \sigma \nabla Y_\tau^{\theta \top} dW_\tau,$$

并且 (**) 替换了定义 $Z_\tau^\theta := \sigma \nabla Y_\tau^\theta$ 。方程 (46) 有一个有趣的启示，因为可以验证其被积函数是参数化 HJB $Y_\theta = -u_\theta \approx -u$ 的残差 (回顾 (7) 和 (8))。显而易见，残差在参数化 HJB 被

关于后向参数化 SDE (25b) 通过伊藤引理展开后也应被保留。也就是说，对于函数 $c_s := c(T-t)$ ，以下类似于 (45) 的方程必须成立：

$$dY_s^\theta + dc_s = \left(\frac{1}{2} \|Z_s^\theta\|^2 + \nabla \cdot (f_s + \sigma Z_s^\theta) + Z_s^{\theta^\top} \hat{Z}_s^\phi - F_s \right) dt + Z_s^{\theta^\top} dW_s,$$

这与 (41) 矛盾。因此，我们必须有 $dc_s = dc_t = 0$ ，且 (45) 变为

$$dY_t^\theta = \left(\frac{1}{2} \|Z_t^\theta\|^2 + F_t \right) dt + Z_t^{\theta^\top} dW_t. \quad (47)$$

简而言之，我们已经证明，对于参数化的前向 (25a) 和后向 (25b) SDE，如果 (40, 41) 成立，则 (47) 成立，前提是 $\mathcal{L}_{\text{IPF}}$ 被最小化。完全相同的陈述可以重复用来证明

$$d\hat{Y}_s^\phi = \left(\frac{1}{2} \|\hat{Z}_s^\phi\|^2 + F_s \right) ds + \hat{Z}_s^{\phi^\top} dW_s. \quad (48)$$

因此，如果组合目标被最小化，即 (38, 39, 40, 41) 成立，则参数化函数 $(Y_\theta, Z_\theta, Y_\phi, Z_\phi)$ 满足 (25, 40, 47, 41, 48)，即它们满足定理 2 中的 FBSDE 系统 (11,12)。

□

A.4 第 3 节和第 4 节中的附加推导与备注

A.4.1 霍普夫-科尔变换

回顾霍普夫-科尔变换

$$\Psi(x, t) := \exp(-u(x, t)), \quad \hat{\Psi}(x, t) := \rho(x, t) \exp(u(x, t)).$$

标准普通微积分给出

$$\nabla \Psi = -\exp(-u) \nabla u, \quad \Delta \Psi = \exp(-u) [\|\nabla u\|^2 - \Delta u], \quad (49)$$

$$\nabla \hat{\Psi} = \exp(u) (\rho \nabla u + \nabla \rho), \quad \Delta \hat{\Psi} = \exp(u) [\rho \|\nabla u\|^2 + 2 \nabla \rho^\top \nabla u + \Delta \rho + \rho \Delta u]. \quad (50)$$

因此，我们有

$$\begin{aligned} \frac{\partial \Psi}{\partial t} &= \exp(-u) \left(-\frac{\partial u}{\partial t} \right) \\ &\stackrel{(7)}{=} \exp(-u) \left(-\frac{1}{2} \|\sigma \nabla u\|^2 + \nabla u^\top f + \frac{1}{2} \sigma^2 \Delta u + F \right) \\ &\stackrel{(49)}{=} -\frac{1}{2} \sigma^2 \Delta \Psi - \nabla \Psi^\top f + F \Psi, \end{aligned} \quad (51)$$

$$\begin{aligned} \frac{\partial \hat{\Psi}}{\partial t} &= \exp(u) \left(\frac{\partial \rho}{\partial t} + \rho \frac{\partial u}{\partial t} \right) \\ &\stackrel{(7)}{=} \exp(u) \left(\left(\nabla \cdot (\rho (\sigma^2 \nabla u - f)) + \frac{1}{2} \sigma^2 \Delta \rho \right) + \rho \left(\frac{1}{2} \|\sigma \nabla u\|^2 - \nabla u^\top f - \frac{1}{2} \sigma^2 \Delta u - F \right) \right) \\ &= \exp(u) \left(\sigma^2 \left(\rho \Delta u + \nabla \rho^\top \nabla u + \frac{1}{2} \Delta \rho + \frac{\rho}{2} \|\nabla u\|^2 - \frac{\rho}{2} \Delta u \right) - \nabla \rho^\top f - \rho \nabla \cdot f - \rho \nabla u^\top f - \rho F \right) \\ &\stackrel{(50)}{=} \frac{1}{2} \sigma^2 \Delta \hat{\Psi} - \nabla \hat{\Psi}^\top f - \hat{\Psi} \nabla \cdot f - \hat{\Psi} F, \end{aligned} \quad (52)$$

which yields (9) by noticing that $\nabla \cdot (\hat{\Psi} f) = \nabla \hat{\Psi}^\top f + \hat{\Psi} \nabla \cdot f$.

A.4.2 关于收敛性的说明

算法 (1) 中提出的交替优化方案可以紧凑地表示为 $\min_\phi D_{\text{KL}}(q^\theta || q^\phi) + \mathbb{E}_{q^\phi}[\mathcal{L}_{\text{TD}}(\phi)]$ 和 $\min_\theta D_{\text{KL}}(q^\phi | q^\theta) + \mathbb{E}_{q^\phi}[\mathcal{L}_{\text{TD}}(\theta)]$ 。尽管该过程似乎类似于 IPF，它在 $\min_\phi D_{\text{KL}}(q^\phi | q^\theta)$ 和 $\min_\theta D_{\text{KL}}(q^\theta | q^\phi)$ ，之间进行优化，但我们强调它们彼此不同，因为 KL 散度是以不同方向构造的。

在丢弃 TD 目标的情况下，先前工作 [24] 已证明最小化前向 KL 散度具有与标准 IPF（最小化反向 KL 散度）相似的收敛性。这本质上是开发可扩展方法的关键，因为在前向 KL 散度中被优化的参数（ $D_{\text{KL}}(q^\phi|q^\theta)$ 中的 $e.g., \theta$ ）不同于用于采样期望的参数（ $e.g., \mathbb{E}_{q^\phi}$ ）。因此，可以丢弃 SDE 的计算图，从而产生计算上高效得多的框架。这些优势已在 [24, 27] 以及本工作中被采用，用于解决更高维问题。

然而，当我们需要 TD 目标来强制 MF 结构时，如本工作中所有 MFG 中出现的情况，组合目标并不直接对应于 IPF。尽管算法 (1) 中的交替过程主要受先前 SB 方法 [24, 27] 的启发，但 DeepGSB 的训练过程可能更接近于 TRPO[55]，后者使用前一阶段生成的离策略样本迭代更新策略：

$\pi^{(i+1)} = \arg \min_{\pi} D_{\text{KL}}(\pi^{(i)}||\pi) + \mathbb{E}_{\pi^{(i)}}[\mathcal{L}(\pi)]$ 。TRPO 被证明在迭代过程中享有单调改进（即局部收敛）。

A.4.3 平均场势函数的泛函导数 给定概率测度空间上的泛函 $\mathcal{F} : \mathcal{P}(\mathbb{R}^d) \rightarrow \mathbb{R}$ ，其泛函导数满足以下方程

$$F(x, \rho) := \frac{\delta \mathcal{F}(\rho)}{\delta \rho}(x)$$

$$\lim_{h \rightarrow 0} \frac{\mathcal{F}(\rho + hw) - \mathcal{F}(\rho)}{h} = \int_{\mathbb{R}^d} F(x, \rho) w(x) dx$$

对于任意函数 $w \in L^2(\mathbb{R}^d)$ 。因此，熵平均场泛函 $\mathcal{F}_{\text{entropy}} :=$ 的导数可推导为

$$\begin{aligned} & \lim_{h \rightarrow 0} \frac{1}{h} \left(\mathcal{F}_{\text{entropy}}(\rho + hw) - \mathcal{F}_{\text{entropy}}(\rho) \right) \\ &= \lim_{h \rightarrow 0} \frac{1}{h} \left(\int_{\mathbb{R}^d} \left(hw(x) \log \rho(x) + \rho(x) \frac{hw(x)}{\rho(x)} + \mathcal{O}(h^2) \right) dx \right) \\ &= \int_{\mathbb{R}^d} \left(w(x) \log \rho(x) + w(x) \right) dx = \int_{\mathbb{R}^d} \underbrace{(\log \rho(x) + 1)}_{:= F_{\text{entropy}}(x, \rho)} w(x) dx. \end{aligned} \quad (53)$$

类似地，考虑拥堵平均场泛函 $\mathcal{F}_{\text{congestion}} :=$ derivation can be computed by

$$\int_{\mathbb{R}^d} \int_{\mathbb{R}^d} \frac{1}{\|x-y\|^2+1} \rho(x) \rho(y) dx dy. \text{ Its}$$

$$\begin{aligned} & \lim_{h \rightarrow 0} \frac{1}{h} \left(\mathcal{F}_{\text{congestion}}(\rho + hw) - \mathcal{F}_{\text{congestion}}(\rho) \right) \\ &= \lim_{h \rightarrow 0} \frac{1}{h} \left(\int_{\mathbb{R}^d} \int_{\mathbb{R}^d} \frac{1}{\|x-y\|^2+1} \left(\rho(x)hw(y) + hw(x)\rho(y) + \mathcal{O}(h^2) \right) dx dy \right) \\ &= \int_{\mathbb{R}^d} \int_{\mathbb{R}^d} \frac{1}{\|x-y\|^2+1} \left(\rho(x)w(y) + w(x)\rho(y) \right) dx dy \\ &= \int_{\mathbb{R}^d} \int_{\mathbb{R}^d} \underbrace{\frac{2}{\|x-y\|^2+1}}_{:= F_{\text{congestion}}(x, \rho)} dy w(x) dx. \end{aligned} \quad (54)$$

由此我们得出 (17) 中 F_{entropy} 和 $F_{\text{congestion}}$ 的表达式。

A.5 实验细节

A.5.1 设置

超参数 表 6 总结了每个平均场博弈中的超参数，包括状态空间的维度 d 、扩散标量 σ 、时间范围 T 、离散时间步长 δt （以及 δs ），平均场基础漂移 $f(x, \rho)$ 、平均场交互 $F(x, \rho)$ ，以及边界分布 ρ_0 和 ρ_{target} 的均值/协方差（注意所有平均场博弈均采用高斯分布作为其边界分布）。注意在 1000 维观点平均场博弈中，我们将极化动态 f_{polarize} 乘以 6 以

表 6: 各平均场博弈中的超参数。注意 $\mathbf{0} \in \mathbb{R}^d$ 表示零向量, $\mathbf{I} \in \mathbb{R}^{d \times d}$ 表示单位矩阵, $\text{diag}(\mathbf{v}) \in \mathbb{R}^{d \times d}$ (其中 $\mathbf{v} \in \mathbb{R}^d$) 表示对角矩阵。

	GMM	V-neck	S-tunnel	Opinion	
d	2	2	2	2	1000
σ	1	1	1	0.1	0.5
T	1	2	3	3	3
δt	0.01	0.01	0.01	0.01	0.006
$f(x, \rho)$	$[0, 0]^\top$	$[6, 0]^\top$	$[6, 0]^\top$	$\bar{f}_{\text{polarize}}$	$6 \cdot \bar{f}_{\text{polarize}}$
Diffusion steps	100	200	300	300	500
K^7	250	250	500	100	250
Alternating stages ⁸	40	40	30	40	90
Total training steps	20k	20k	30k	8k	45k
Mean of ρ_0	$\mathbf{0}$	$\begin{bmatrix} -7 \\ 0 \end{bmatrix}$	$\begin{bmatrix} -11 \\ -1 \end{bmatrix}$	$\mathbf{0}$	$\mathbf{0}$
Mean of ρ_{target}	$e^{16 \cdot (\frac{\pi}{4})i},$ $i \in \{0, \dots, 7\}$	$\begin{bmatrix} 7 \\ 0 \end{bmatrix}$	$\begin{bmatrix} 11 \\ 1 \end{bmatrix}$	$\mathbf{0}$	$\mathbf{0}$
Covariance of ρ_0	$\mathbf{I}$	$0.2\mathbf{I}$	$0.5\mathbf{I}$	$\text{diag}(\begin{bmatrix} 0.5 \\ 0.25 \end{bmatrix})$	$\text{diag}(\begin{bmatrix} 4 \\ 0.25 \\ \vdots \\ 0.25 \end{bmatrix})$
Covariance of ρ_{target}	$\mathbf{I}$	$0.2\mathbf{I}$	$0.5\mathbf{I}$	$3\mathbf{I}$	$3\mathbf{I}$

确保高维动力学在时间范围内产生极化。同时, 采用较小的步长 $\delta t = 0.006$, 以减轻相对较大漂移带来的离散化误差。如第 4 节所述, 我们分别对高斯混合模型和 V 形颈/S 形隧道采用零基漂移和常数基漂移 f 。

训练 所有实验均在 3 块 TITAN RTX 和 1 块 TITAN V100 上进行, 其中 V100 位于亚马逊云服务 (AWS) 上。所有实验均采用式 (15) 中的多步时序差分目标, 并采用 Huber 范数计算式 (16) 中的时序差分损失。对于 Fokker-Planck 一致性损失 $\mathcal{L}_{\text{FK}}$, 高斯混合模型和观点平均场博弈采用 ℓ_1 范数, 其余采用 Huber 范数。

网络架构 所有网络 $(Y_\theta, Z_\theta, Y_\phi, Z_\phi)$ 以 (x, t) 为输入, 并遵循输出 = $\text{out_mod}(\text{x_mod}(x) + \text{t_mod}(\text{时间步嵌入}(t)))$,

其中时间步嵌入 $(\cdot)$ 是标准正弦嵌入。

对于人群导航平均场博弈, 这些模块由 2 至 4 个全连接层 (线性层) 后接 Sigmoid 线性单元 (SiLU) 激活函数 [70] 组成, 即

$$\begin{aligned} \text{t_mod} &= \text{线性} \rightarrow \text{SiLU} \rightarrow \text{线性} \quad \text{x_mod} = \text{线性} \rightarrow \text{SiLU} \rightarrow \text{线性} \rightarrow \text{SiLU} \rightarrow \text{线性} \\ &\rightarrow \text{SiLU} \rightarrow \text{线性} \quad \text{out_mod} = \text{线性} \rightarrow \text{SiLU} \rightarrow \text{线性} \rightarrow \text{SiLU} \rightarrow \text{线性} \end{aligned}$$

对于 1000 维观点平均场博弈, 我们保持相同的 t_mod 和 out_mod , 但对 x_mod 采用具有 5 个残差块的残差网络。对于 DeepGSB-ac, 我们分别将策略网络 (Z_θ, Z_ϕ) 和评论家网络 (Y_θ, Y_ϕ) 的线性层隐藏维度设置为 256 和 128, 而对于 DeepGSB-c, 我们将评论家网络 (Y_θ, Y_ϕ) 的线性层隐藏维度设置为 200。

⁷ 我们注意到, 与 SB-FBSDE[27] 不同, 每个阶段的训练迭代次数 (即算法 1 中的 K) 在整个训练过程中保持不变。⁸ 这里, 我们将一个交替阶段称为算法 1 中 $2K$ 训练迭代的完整循环。

先前方法的实现 [14 - 16] 我们所有的实验均使用 PyTorch[71] 实现。因此，我们通过将 Ruthotto 等人 [14] 的 Julia 代码库⁹ 迁移到 PyTorch 来重新实现他们的方法。至于 Lin 等人 [15]，他们的官方 PyTorch 实现是公开可用的。¹⁰ 最后，我们自己实现了 Chen[16] 的方法。由于先前方法 [14 - 16] 是为比我们的 DeepGSB 更小类的平均场博弈开发的（回顾表 1），我们需要放宽平均场博弈的设置，以便它们能在图 5 和图 8 中产生合理的结果。具体来说，我们软化障碍成本，以便 [14, 15] 能够正确区分它们，并保持与 [14, 15] 中采用的相同的 KL 惩罚 $u(x, T) \approx D_{\text{KL}}(\rho(x, T) || \rho_{\text{target}}(x))$ 。我们强调，这些方法 [14, 15] 在 (17) 中的不连续 F_{obstacle} 下均无法良好工作。最后，我们将 GMM 的二维状态空间离散化为具有 50 个时间步长的 40×40 网格，用于 [16]。我们注意到 [16] 的复杂度按 $\mathcal{O}(\tilde{T}D^2)$ 缩放，其中 $\tilde{T}$ 和 D 分别是时间和空间网格的数量，即 $\tilde{T} = 50$ 和 $D = 1600$ 。

评估 我们使用 geomloss 包通过 Sinkhorn 散度来近似 Wasserstein 距离。¹¹ Sinkhorn 散度在 Wasserstein（模糊 = 0）和核（模糊 = ∞ ）距离之间插值，给定超参数模糊。我们在表 3 中设置模糊 = 0.05。

A.5.2 附加实验




图 8：与图 5 相同的设置，除了 DeepGSB-c。此图最好以彩色查看。

图 8 和图 9 报告了 DeepGSB-c 的结果。在人群导航平均场博弈中，由 DeepGSB-c 引导的群体快照在视觉上与 DeepGSB-ac 难以区分（见图 8 与图 5），尽管它们的轮廓存在视觉差异。对于 1000 维观点平均场博弈，DeepGSB-c 和 DeepGSB-ac 都能够没有熵相互作用 F_{entropy} 的情况下将群体观点引导至期望的 ρ_{target} 。图 9 报告了 DeepGSB-c 在这些情况下的结果。然而，我们注意到，当启用 F_{entropy} 时，DeepGSB-ac 通常在收敛到 ρ_{target} 和训练稳定性方面优于 DeepGSB-c。

⁹ <https://github.com/EmoryMLIP/MFGnet.jl>。该代码库采用 MIT 许可证。

¹⁰ <https://github.com/atlin23/apac-net>。该代码库未指定许可证。

¹¹ <https://github.com/jeanfedydy/geomloss>。该代码库采用 MIT 许可证。




图 9: (a) 在 2 维和 1000 维观点空间中极化动力学 $\bar{f}_{\text{polarize}}$ 的可视化, 其中方向相似性 [3] 统计了终端分布 ρ_T . (b) 成对观点之间余弦角的直方图。DeepGSB-c 引导 ρ_T 接近温和分布, 从而使观点动力学去极化。注意, 我们对 DeepGSB-c 采用 $F := 0$ 。我们使用前两个主成分来可视化 $d=1000$ 。