

学习关键要素：基于任务 相关嵌入的跨域模仿学习

Tim Franzmeyer
University of Oxford
frtim@robots.ox.ac.uk

Philip H. S. Torr
University of Oxford
philip.torr@eng.ox.ac.uk

João F. Henriques
University of Oxford
joao@robots.ox.ac.uk

摘要

本文研究自主智能体如何在不同域（如不同环境或不同智能体）中，仅凭示范来学习执行任务。此类跨域模仿学习对于从人类专家示范中训练人工智能体等场景是必需的。本文提出一种可扩展的框架，无需额外示范或进一步领域知识即可实现跨域模仿学习。我们联合训练学习者智能体的策略，并通过对抗训练学习学习者域与专家域之间的映射。具体做法是利用互信息准则寻找专家状态空间的嵌入，该嵌入包含任务相关信息且对域特定因素保持不变。这一步骤显著简化了学习者域与专家域之间映射的估计，从而促进端到端学习。我们展示了在差异显著的域之间成功迁移策略，无需额外监督（如额外示范），且在其他方法失效的情况下仍能有效。

1 引言

强化学习（Reinforcement Learning, RL）在多种任务和不同域中取得了巨大成功 [43, 2]，但其性能依赖于定义精确的奖励函数。在游戏和仿真等简单场景中，奖励易于定义；然而，现实场景更为微妙，尤其是涉及与人类交互时。

克服奖励定义不准确问题的一种可行方法是根据专家行为观察来学习策略，即模仿学习。近期模仿学习算法通过更新学习者智能体的策略，使学习者的状态占用与专家示范者的状态占用相匹配 [4]，这要求学习者与专家处于同一域。在更现实的场景中，这一要求往往难以满足。例如，考虑机器人手臂从人类执行任务的示范中学习将苹果移到盘子上的情形。此处，两个域本质上共享结构（苹果和盘子的外观相似），但存在差异（两个手臂的形态、动力学和外观不同）。

使学习者智能体能够从由不同专家智能体生成的演示中成功执行任务（即使任务相关，我们也将其称为不同领域），将极大地拓宽训练人工智能体的可能性。这种跨领域模仿学习问题被视为迈向价值对齐的重要一步，因为它有助于将行为从人类迁移到人工智能体 [32, 第 7 章]。

该问题直到最近才被研究者在现实环境中考虑。由于其难度，先前关于跨领域模仿学习的工作要么假设专家和学习者的领域几乎相同 [42, 17, 6]，要么需要多个与学习者领域相似的领域中的专家演示 [45, 44]，要么依赖于代理演示的可用性




图 1: 我们考虑一个机器人从人类放置苹果到盘子的演示中学习该任务。这个说明性的跨领域模仿学习问题需要在学习者领域中找到策略 π_L ，其状态 s_L 来自人类专家 ($\mathcal{D}_E$) 在具有状态 s_E 的不同专家领域中生成的演示。我们首先使用互信息准则 ($\mathcal{L}_{MI}$) 来找到一个嵌入函数 f ，该函数将专家状态 s_E 映射到任务相关表示 z ，以丢弃领域特定信息。在给定示例中， f 将主要编码关于苹果和盘子的信息，因为这些与任务最相关。接下来，我们应用对抗损失 $\mathcal{L}_{Disc}$ 来联合训练所有蓝色阴影组件，即学习者的策略 (π_L)、判别器 D 以及将学习者状态映射到专家领域的任务相关表示 z 的映射函数 f 。这里，学习者编码器将苹果的颜色和盘子的类型映射到专家领域的对应物。

两个领域中的任务 [30, 18]。设计这样的代理任务是一个手动过程，需要关于两个领域的先验知识，因为它们必须与目标任务本质上相似，以传达领域之间的相关映射 [18]。Fickinger 等人 [10] 通过直接比较两个领域中的分布，克服了对代理任务的需求，有效地解决了与我们相同的问题设置。虽然非常有前景，但其适用性仅限于短演示和欧几里得空间。

本文提出联合学习学习者策略与学习者、专家状态空间之间的映射，并利用对抗训练。与标准生成对抗模仿学习 [16, 39] 不同，本文为学习者和专家分别使用领域特定编码器。因此，本文设计了一种互信息准则，以寻找能够保留任务相关信息、同时丢弃与任务无关的领域特定信息的专家编码器。需要注意的是，一般而言，跨领域模仿学习是一个欠定义问题，因为学习者的唯一最优策略并未作为问题的一部分被定义：例如，一个模仿猎豹的人形智能体应该爬行（模仿其步态）还是行走（朝同一方向移动）？

本文在不同的跨具身模仿学习场景中评估了所提出的跨领域模仿学习方法，并在相关基准上进行了比较，发现本文方法能够稳健地学习到明显优于基线的策略。本文进行了多项消融研究，特别发现可以控制从专家处传递的领域特定信息量——有效地在尽可能模仿专家行为与寻找使用不同策略最大化专家奖励的新颖策略之间进行插值。

本文的贡献如下：

- 本文提出了一种互信息准则，用于寻找专家状态的嵌入，该嵌入包含任务相关信息，同时丢弃与任务无关的领域特定信息。
- 本文在没有额外代理任务演示的情况下，学习学习者领域与任务相关嵌入之间的映射。
- 本文展示了在多样化环境中训练稳健策略的能力，以及调节学习者与专家领域之间信息流动的能力。

2 相关工作

模仿学习 考虑从专家智能体生成的示范中为学习者智能体寻找最优策略的问题，其中逆强化学习 (IRL) [1, 46] 恢复一个奖励函数，在该奖励函数下观察到的专家行为是最优的。更近期的研究 [16, 11, 39] 将模仿学习定义为一个分布匹配问题，并使用对抗训练 [14] 直接寻找学习者的策略，而无需显式恢复专家的奖励。

跨域模仿学习 将模仿学习推广到学习者和专家处于不同领域的情况。领域之间的小的不匹配，例如视角或重力的变化，或动力学的微小变化，由 [42, 12, 17, 28, 36, 8] 和 Bohez 等人 [6] 处理。为了在存在较大不匹配（例如学习者和专家的不同实施例）的情况下跨域学习策略，先前的工作使用代理任务的示范来学习学习者和专家领域之间的映射，然后使用该映射来寻找学习者的最优策略 [15, 23, 35, 30, 18]，利用环境状态的潜在嵌入 [45, 44]，或假设奖励信号是给定的 [34]。GWIL [10] 不依赖代理任务，而是最小化两个智能体的状态-动作概率分布之间的距离，这些分布位于不同的空间中 [25]。该方法假设欧几里得空间，并且在使用较长的示范时计算上不可行，而较长的示范通常在可用时能提高学习算法的性能。

我们的方法消除了对代理任务的需求，可扩展到复杂行为的详细示范，并能够控制有多少领域特定信息被转移到学习者领域。

在经典强化学习 (RL) [26] 中，行为是从给定的奖励函数中学习的，互信息目标通常用于寻找紧凑的状态表示，通过丢弃不相关信息来提高性能 [29, 3, 37, 24, 22]。我们提出类似地学习专家状态的表示，该表示包含任务相关信息，同时对领域特定信息保持不变。

3 背景

定义。 遵循 Kim 等人 [18] 的方法，本文将域定义为一个元组 $(\mathcal{S}, \mathcal{A}, \mathcal{P}, \zeta)$ ，其中 $\mathcal{S}$ 表示状态空间， $\mathcal{A}$ 为动作空间， $\mathcal{P}$ 为转移函数， ζ 为状态的初始分布。给定动作 $a \in \mathcal{A}$ ，下一状态的分布由转移函数给出，即 $\mathcal{P}(s'|s, a)$ 。无限时域马尔可夫决策过程 (MDP) 通过在域元组上添加奖励函数 $r: \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ （描述特定任务）和折扣因子 $\gamma \in [0, 1]$ 来定义。本文将专家智能体的 MDP 定义为 $\mathcal{M}_E = (\mathcal{S}_E, \mathcal{A}_E, \mathcal{P}_E, r_E, \gamma_E, \zeta_E)$ ，其策略定义为映射 $\pi_E: \mathcal{S}_E \rightarrow \mathcal{B}(\mathcal{A}_E)$ ，其中 $\mathcal{B}$ 为 $\mathcal{A}_E$ 上所有概率测度的集合。类似地定义学习者 MDP $\mathcal{M}_L$ 和学习者策略 π_L ，不同之处在于学习者 MDP 没有奖励函数或折扣因子。专家轨迹是状态序列 $\tau_E = \{s_E^0, s_E^1, \dots, s_E^n\}$ ，其中 n 表示轨迹长度。本文用 $\mathcal{D}_E = \{\tau_i\}$ 表示此类轨迹的集合。

问题定义。 跨域模仿学习的目标是，在给定专家域 $\mathcal{M}_E$ 中的演示 $\mathcal{D}_E$ 的情况下，找到一个策略 π_L ，使其在学习者域 $\mathcal{M}_L$ 中最佳地执行任务。与大多数先前工作不同，本文不假设能够获得代理任务数据集——即两个域中与推理任务相似但不同的简单原始技能。本文不假设能够获得专家演示的动作，这些动作可能难以获取，例如从视频或人类演示中学习时，因此本文认为专家演示仅由状态组成。

基于观察的对抗模仿学习。 本文首先考虑两个 MDP 等价（即 $\mathcal{M}_L = \mathcal{M}_E$ ）的等域情形，并假设专家智能体在 r_E 下的最优策略 π_E 已知。Torabi 等人 [39] 将该问题的解定义为标准模仿学习问题 [16] 的扩展，通过最小化学习者状态转移分布 ρ_{π_L} 与专家状态转移分布 ρ_{π_E} 之间的发散，即

$$\arg \min_{\pi_L} -H(\pi_L) + \mathbb{D}_{\text{JS}}(\rho_{\pi_L}(s, s') - \rho_{\pi_E}(s, s')) = \text{RL} \circ \text{IRL}(\pi_E), \quad (1)$$

其中 $\mathbb{D}_{\text{JS}}$ 为 Jensen-Shannon 发散, $H(\pi_L)$ 为学习者策略熵 [46]。策略 π 的状态转移分布定义为

$$\rho_\pi(s_i, s_j) = \sum_a P(s_j | s_i, a) \pi(a | s_i) \sum_{t=0}^{\infty} \gamma^t P(s_t = s_j | \pi). \quad (2)$$

特别地, 专家状态转移分布 ρ_{π_E} 使用专家演示 $\mathcal{D}_E$ 进行估计。上述目标 (公式 1) 也可推导为逆强化学习 (IRL) 与强化学习 (RL) 问题的复合, 其中 $r_E = \text{IRL}(\pi_E)$ 表示从策略 π_E 求解逆强化学习问题的解, $\pi_L = \text{RL}(r_E)$ 表示在奖励 r_E 下求解强化学习问题的解。

逆强化学习 (IRL) 组件通过寻找一个奖励函数, 该函数为专家策略分配高奖励而与其他策略分配低奖励, 从而恢复出使专家演示唯一最优的奖励函数 $r : \mathcal{S} \times \mathcal{S} \rightarrow \mathbb{R}$, 其形式为 $\text{IRL}(\pi_E) = \arg \min_r (\max_{\pi_L} \mathbb{E}_{\pi_L}[r(s, s')] - \mathbb{E}_{\pi_E}[r(s, s')])$ 。

4 跨域无监督模仿学习

本文首先引入跨域模仿学习问题, 然后推导出一个对抗学习目标, 该目标允许同时训练学习者策略以及学习者与专家马尔可夫决策过程 (MDP) 之间的映射。随后, 本文展示通过寻找专家智能体状态空间中包含任务相关信息而丢弃域特定方面的嵌入, 可以显著简化跨域模仿学习问题。最后, 本文引入时间不变性约束以防止退化的映射解。由于本文方法不依赖来自代理任务的额外演示, 因此将其称为无监督跨域模仿学习目标 (UDIL)。

4.1 跨域对抗模仿学习

本文考虑专家与智能体的马尔可夫决策过程 (MDP) 不同的情况, 即 $\mathcal{M}_L \neq \mathcal{M}_E$, 例如学习者与专家具有不同实施例或处于不同环境中。Kim 等人 [18] 证明, 如果存在一个单射映射 g 将学习者 MDP $\mathcal{M}_L$ 归约到专家 MDP $\mathcal{M}_E$, 那么在 $\mathcal{M}_L$ 中最优的策略 π_L 在 $\mathcal{M}_E$ 中也是最优的。

由于本文不假设来自专家动作的额外监督, 因此将学习者与专家 MDP 之间的映射函数 $g : \mathcal{S}_L \rightarrow \mathcal{S}_E$ 定义为相应状态空间之间的映射。据此, 本文将跨域对抗模仿目标定义为

$$\arg \min_{\pi_L} -H(\pi_L) + \mathbb{D}_{\text{JS}}(\rho_{\pi_L}(g(s_L), g(s'_L)) - \rho_{\pi_E}(s_E, s'_E)). \quad (3)$$

将映射 g 应用于学习者智能体的状态, 使得本文能够比较学习者与专家的分布, 即使它们定义在不同的状态空间上。

4.2 降低专家状态维度

专家领域的完整状态 s_E 通常包含专家所演示任务特有的信息, 该信息由专家的奖励函数 r_E 定义, 同时也包含领域特有但与任务本身无关的信息。我们通过将专家智能体的状态空间缩减为对领域特性不变的任务相关嵌入, 简化了跨域模仿学习问题。

我们假设学习者状态 s 是多维的, 并回顾对抗性模仿问题 (公式 1) 中的逆强化学习 (IRL) 部分, 该部分寻找使专家行为最优的奖励函数。我们定义第二个映射函数 $f : \mathcal{S}_E \rightarrow \mathcal{Z}$, 将专家状态 $s_E \in \mathcal{S}_E$ 映射到低维表示 $z \in \mathcal{Z}$, 其中 $|\mathcal{Z}| \ll |\mathcal{S}_E|$ 。当 f 被选为一种降维操作, 丢弃奖励所不依赖的状态维度时, 我们可以将公式 1 的 IRL 部分仅表示为嵌入表示 z 的函数 (证明见附录 8.1.1),²

¹ 为简化起见, 我们将代价函数替换为奖励函数, 并省略代价函数的正则化项。² 我们假设奖励函数 r 也定义在嵌入空间 $\mathcal{Z}$ 上, 详见附录 8.1.1。

作为

$$\text{IRL}(\pi_E) = \arg \min_r \left(\max_{\pi_L} \mathbb{E}_{\pi_L} [r(z, z')] - \mathbb{E}_{\pi_E} [r(z, z')] \right). \quad (4)$$

简化学习者与专家之间的映射。假设 f 已知，我们可以进一步将学习者与专家状态之间的映射重新定义为 $g: \mathcal{S}_L \rightarrow \mathcal{Z}$ 。也就是说，状态变换 g 不再需要将学习者状态映射到完整的专家状态，而只需映射到专家状态的任务相关嵌入。这不仅显著简化了映射函数 g 的复杂度，还避免了将无关的领域特性从专家域迁移到学习者域。然后，我们可以将跨域对抗性模仿目标重写为

$$\arg \min_{\pi_L, g} -H(\pi_L) + \mathbb{D}_{\text{JS}}(\rho_{\pi_L}(g(s_L), g(s'_L)) - \rho_{\pi_E}(f(s_E), f(s'_E))), \quad (5)$$

该目标最小化学习者状态变换后的分布 s_L 与嵌入专家状态分布 z 之间的距离。

4.3 寻找任务相关嵌入

我们现在详细说明如何从专家演示 $\mathcal{D}_E$ 中找到一个嵌入函数 f 。我们首先组装一个集合，包含演示集 $\mathcal{D}_E$ 的轨迹中观察到的所有专家状态转移 (s_E, s'_E) 。然后，我们通过从 $\mathcal{D}_E$ 中包含的所有单个状态中独立采样两个状态，生成一组伪随机状态转移 $(s_{\text{rand}}, s'_{\text{rand}})$ 。接着，我们将所有状态转移 (s, s') 及其对应的标签 y （指示是随机转移还是专家转移）建模为随机变量 (S, S', Y) 在 $\mathcal{S}_E \times \mathcal{S}_E \times \{0, 1\}$ 上的实现。注意，任何时不变嵌入 $f: \mathcal{S}_E \rightarrow \mathcal{Z}$ 通过 $(Z, Z') = (f(S), f(S'))$ 在 $\mathcal{Z} \times \mathcal{Z} \times \{0, 1\}$ 上诱导出一个随机变量 (Z, Z', Y) 。然后，我们将映射 f 定义为最大化标签 Y 与嵌入状态转移 (Z, Z') 之间互信息 I 的映射，即

$$\arg \max_f I((Z, Z'); Y) = \arg \max_f I((f(S), f(S'))); Y). \quad (6)$$

观察到，最大化 $I(Z; Y)$ 会导致非信息性表示，因为随机轨迹中包含的状态实际上是专家轨迹的状态；只有状态转移 (S, S') 能够区分两者。

4.4 避免退化解

如果 g 是任意复杂度的函数，联合学习映射函数 g 和学习者智能体的策略 π_L 可能导致退化映射。过度表达的 g 可以通过均匀分布的普适性使分布之间的散度任意小，而不管它们的共同结构如何，即任何两个分布都可以通过利用它们的累积密度函数（CDF）和逆 CDF 相互转换。我们通过信息不对称约束来防止这些退化解：确保映射 f 是时不变的，而 JS 散度以时变方式跨时间比较分布。理论分析见附录 8.1.2。

4.5 无监督跨域对抗模仿学习

我们最终将无监督跨域对抗模仿学习（UDIL）目标定义为一个对抗学习问题。我们迭代更新学习者智能体的策略 π_l 、学习者与专家状态空间之间的映射 g 以及判别器 D 。判别器的目标是区分学习者生成的状态转移和专家生成的状态转移，从而得到总体目标

$$\min_{g, \pi_L} \max_{\theta} \mathbb{E}_{\pi_L} [\log(D_{\theta}(g(s_L), g(s'_L)))] + \mathbb{E}_{\pi_E} [\log(1 - D_{\theta}(z, z'))]. \quad (7)$$

5 实验

预备知识。我们在两个不同的基准上测试了我们的方法，这些基准代表了多个领域和不同的智能体，包括基于环境和基于智能体的任务。我们设计实验以回答以下问题。




图 2: 在 XMagical 基准 [40, 45] 中, 具有不同形态的智能体 (如此处展示的夹爪和长杆) 必须将三个品红色方块移动到环境顶部的品红色阴影目标区域。我们评估了两种学习智能体在通过其他智能体的演示进行训练时, 使用我们的算法 UDIL 或 XIRL[45] 基线所获得的奖励。

- 能否仅从专家演示中找到专家状态的任务相关嵌入, 并提升模仿学习的性能?
- 与先前工作相比, 所提出的框架能否稳健地学习有意义的策略?
- 能否控制从专家迁移到学习者的领域特定信息量?

我们与 GWIL 基线 [10] 进行比较, 这是唯一做出与我们相似假设的其他工作, 即无监督跨领域模仿学习, 仅能访问单个专家智能体的演示。在稍后展示的 XMagical 环境中, 我们还与 XIRL[45] 的修改版单演示者智能体版本进行比较, 后者最初依赖于多个不同专家智能体的演示。由于学习领域中没有给出奖励函数, 我们通过将专家智能体奖励函数中可直接迁移到学习领域的组成部分定义为学习智能体的奖励来衡量其性能。为确保可复现性, 我们在随机种子 0 到 6 上运行所有实验, 报告所有实验的均值和标准误 (线条和阴影区域), 并在附录第 8.2 节中详细描述实验。

5.1 XIRL 基线

设置。图 2 展示了 XMagical 环境 [41, 45], 该环境包含四个具有不同形态的智能体, 它们必须在环境中执行等效的修改, 即将所有方块推到阴影区域。相应的基线算法 XIRL[45] 使用其他三个专家智能体的演示来训练每个智能体。由于我们的工作只需要单个专家智能体的演示, 我们专注于两个最不同的智能体, 即图 2 中显示的夹爪和长棍, 并评估每个智能体在另一个智能体的演示上训练时的性能。奖励是任务相关对象与其目标位置之间平均距离的函数。

寻找任务相关嵌入。XMagical 中的环境状态以多维向量形式给出, 该向量描述了环境对象和智能体自身的不同绝对和相对位置。为了找到该状态的任务相关嵌入, 我们首先按照第 4.3 节所述生成专家和伪随机转移集。由于在大型连续域中最大化互信息目标是不可行的 [5, 9], 我们转而通过首先使用 Ross[31] 的方法计算每个单独状态维度的状态转移与标签之间的经验互信息来近似公式 (6) 中的目标。然后, 我们使用肘部法则 [19] 选择具有最高互信息的维度来找到任务相关嵌入。我们发现, 那些直观上与任务相关的状态维度 (例如描述方块位置的维度) 与那些直观上特定于领域且与任务不太相关的状态维度 (例如描述机器人位置的维度) 之间存在明显的差距。

使用专家状态的任务相关嵌入进行模仿学习。我们使用 Zakka 等人 [45] 提供的专家演示数据集, 将我们的方法与 XIRL 基线的性能进行比较。我们遵循 Zakka 等人 [45] 的做法, 同样使用简化的模仿




图 3: 来自三个智能体（跳跃者、半猎豹和步行者）的样本轨迹（第 5.2 节）。我们展示了针对专家状态嵌入空间 d 的不同维度 z 所学到的运动策略（讨论见第 5.3 节）。右侧：对于较大的 d ，跳跃者执行类似游泳的动作（上）。对于较小的 d （下），跳跃者保持直立，仅用脚推动自身前进。左侧：对于较小的 d ，半猎豹以前部着地推动自身前进（上）。对于较大的 d ，步行者执行跌倒与行走混合的动作（下）。

学习框架中，学习者智能体仅接收一个奖励信号，该信号对应于当前环境状态与目标环境状态之间的距离，目标环境状态通过对专家演示集中所有终止状态取平均而预先计算。注意，UDIL 与 XIRL 的主要区别在于专家状态的任务相关嵌入：XIRL 依赖于完整的专家状态。我们使用作者提供的 XIRL 实现，直接应用于状态空间，不改变任何参数。图 2 显示我们始终优于 XIRL，并且在两种情况下都取得了接近最大可能值的分数。我们发现，我们的方法仅从专家演示中获取状态的任务相关嵌入，这显著提升了 XMagical 环境中跨域模仿学习的性能。

5.2 机器人控制的跨域模仿学习

我们现在在复杂的 Mujoco 环境 [7, 38] 中评估 UDIL。我们使用图 3 中展示的实施例：跳跃者、步行者和半猎豹，这些通常用于评估（跨域）模仿学习算法 [20, 16, 12, 30]。我们使用这些环境的固定长度轨迹实现 [13]，以防止隐式地奖励学习者智能体更长的轨迹；这一效应的重要性在 Kostrikov 等人 [20] 中得到了证明。我们首先找到最小的任务相关嵌入，研究其性能，并与 GWIL 进行比较。然后我们进行消融研究，以评估我们框架各个组件的重要性，并研究如何通过改变任务相关专家嵌入的大小来控制从专家域到学习者域的信息传递。我们在附录 8.4 中提供了所产生行为的视频。

寻找任务相关嵌入。与第 5.1 节类似，我们首先生成专家和伪随机转移集合，并计算单个状态维度与转移标签之间的互信息。我们发现，在所有三个智能体中，躯干的 x 位置具有最高的任务相关性，其次是 z 位置（高度）。这在直觉上是合理的，因为专家智能体在训练期间因沿正 x 方向移动而获得相对较大的奖励，其次因处于健康（直立）位置 [7] 而获得较小的奖励。请注意，这些发现仅来自专家演示，不涉及任何奖励知识。此后，描述主要关节相对于躯干的角位置维度具有最高的互信息；描述子组件速度的状态维度具有最低的互信息。我们使用肘部法则将任务相关嵌入识别为描述躯干的位置，随后使用更大的嵌入进行消融研究。联合学习学习者策略和映射函数。我们将学习者编码器参数化，使其学习输入的仿射变换，并将其损失定义为负的




图 4: 不同学习者和专家智能体组合下跨域模仿学习的奖励曲线。平均性能以实线表示, 标准差以阴影区域表示。

判别器的损失, 即学习者编码器被训练以欺骗判别器。学习者的策略由神经网络参数化, 与学习者编码器不同, 该策略无法通过反向传播判别器损失来训练, 因为需要采样步骤来从学习者策略获得状态转移。我们遵循 Ho 和 Ermon [16] 的方法, 使用强化学习训练学习者策略, 学习者智能体因采取导致变换后状态转移 $g(s_L), g(s'_L)$ 的动作而获得更高奖励, 这些状态转移更可能欺骗判别器 D , 即更可能来自专家的任务相关状态转移分布 $\rho_E(z_E, z'_E)$ 。我们使用 DAC [20] 来联合训练 g, π_L 和 D , 如图 1 所示, 并且不改变原始实现中给出的任何超参数以确保可比性。我们将学习者智能体的奖励定义为在目标方向上覆盖的距离, 因为这是三个智能体之间唯一共同的奖励分量, 并将性能与 GWIL [10] 进行比较。

结果。图 4 显示, 学习者智能体在专家和学习者的不同组合下, 对六次随机初始化都能稳健地学习到有意义的策略。我们发现, 与使用真实奖励训练时相比, 跳跃者和行走者覆盖了约 50% 的距离, 而半猎豹达到了专家距离的约 13%。

我们定性检查了智能体学习到的行为, 发现了与专家不同的新颖运动策略。我们在图 3 中展示了这些策略。我们假设这些新行为是由专家状态的任务相关嵌入实现的, 并在第 5.3 节进一步研究如何选择嵌入大小以从专家向学习者传递更多信息。从图 4 可以看出, 我们的框架始终优于 GWIL 基线; 尽管我们尝试了不同的超参数配置, 但我们发现 GWIL 的结果高度随机, 这是由于其使用的 Gromov – Wasserstein 距离 [25] 的特性所致, 正如 GWIL 的作者所指出的 [10, 备注 1]。

5.3 消融研究

我们呈现消融研究, 以阐明框架不同组件的重要性和影响, 重点关注跳跃者和半猎豹智能体。

改变任务相关嵌入的维度。本文研究了任务相关状态嵌入的维度 d 的相关性, 并假设对于更大的嵌入, 从专家域传递到学习域的信息更多。我们评估了 $d \in (3, 6, all)$ 的性能以及由此产生的智能体行为, 其中 all 表示无降维, 即 f 是一个恒等映射




图 5: 当使用我们框架的不同消融版本在另一智能体的演示上进行训练时, 跳跃者和半猎豹所获得的奖励 (行进距离)。详见第 5.3 节。

映射, 在这种情况下, 学习者编码器 g 必须将完整的学习者状态空间映射到完整的专家状态空间。我们可以在图 5 中观察到, 当嵌入大小增加时, 平均性能和鲁棒性通常会下降。我们研究了学习者智能体根据嵌入大小 d 采用的不同运动策略, 并在图 3 中进行了说明。我们发现对于 $d = 3$, 跳跃者和半猎豹都会躺在地板上并推动自己前进。对于更大的嵌入 $d \in \{6, all\}$, 两者都会采用更类似于演示的策略, 将躯干抬离地面的时间更长。跳跃者会跳跃片刻, 然后进行类似游泳的运动, 半猎豹则会表现出类似动物的四足步态。

本文得出结论: 改变专家状态嵌入的规模能够调节专家与学习者领域之间的信息传递。在一个极端情况下, 可能希望学习者以最小的任务相关嵌入来解决任务, 从而允许学习者发展出与专家不同的策略, 例如这有可能使其超越专家。在另一个极端情况下, 可能希望学习者尽可能紧密地复制专家的策略, 这在学习者因信息较少而无法解决任务时可能有用。因此, 选择任务相关嵌入的规模便是在这两种选择之间进行权衡。

省略时间不变性约束。本文通过将判别器输入从 s, s' 缩减为仅当前状态 s , 省略了时间不变性约束。尽管该设置在相同领域模仿学习 [27] 中取得了成功结果, 但本文发现时间不变性约束对于对抗性跨领域模仿学习至关重要 (见图 5)。

从单条轨迹中学习。我们研究了当仅提供单条专家轨迹时方法的性能, 这代表了与 GWIL 最直接的比较, 因为 GWIL 由于其计算复杂度只能利用单条专家轨迹。我们发现, 在仅提供一次演示的情况下, UDIL 同样大幅优于 GWIL, 更多结果见附录 8.3.3。

6 结论

我们提出了一种新颖的跨域模仿学习框架, 使学习智能体能够在状态空间不相似时, 联合学习模仿专家并学习两个状态空间之间的映射。这通过定义一个互信息准则来寻找专家状态的任务相关嵌入得以实现, 该嵌入进一步允许控制专家域与学习域之间的信息传递。我们的方法在不同的随机初始化和领域下表现出稳健的性能, 显著优于先前工作。然而, 由于跨域模仿学习通常是一个欠定问题, 学习到错误策略的风险仍然存在。用于寻找任务相关嵌入的互信息目标在特殊情况下可能产生退化解, 例如当专家策略诱导出状态转移的均匀分布时, 或当环境仅部分可观测时。此外, 在更复杂的领域中, 确定任务相关嵌入的理想大小可能具有挑战性。类似地, 将我们的算法应用于高维观测空间需要进一步的贡献, 并可能构成未来工作的一个有趣方向。

7 致谢

我们感谢 Dylan Campbell 和 Jakob Foerster 提供的有益反馈。我们也感谢匿名审稿人提出的宝贵建议。本工作由皇家工程院 (RF \201819\18\163)。

参考文献

- [1] Abbeel, P. and Ng, A. Y. [2004], Apprenticeship learning via inverse reinforcement learning, in ‘Proceedings, Twenty-First International Conference on Machine Learning, ICML 2004’.
- [2] Akkaya, I., Andrychowicz, M., Chociej, M., Litwin, M., McGrew, B., Petron, A., Paino, A., Plappert, M., Powell, G., Ribas, R. and others [2019], ‘Solving rubik’s cube with a robot hand’, *arXiv preprint arXiv:1910.07113*.
- [3] Anand, A., Racah, E., Ozair, S., Bengio, Y., Côté, M. A. and Devon Hjelm, R. [2019], Unsupervised state representation learning in atari, in ‘Advances in Neural Information Processing Systems’, Vol. 32.
- [4] Arora, S. and Doshi, P. [2021], ‘A survey of inverse reinforcement learning: Challenges, methods and progress’, *Artificial Intelligence* **297**, 103500.
- [5] Belghazi, M. I., Baratin, A., Rajeswar, S., Ozair, S., Bengio, Y., Courville, A. and Hjelm, R. D. [2018], Mutual information neural estimation, in ‘35th International Conference on Machine Learning, ICML 2018’, Vol. 2.
- [6] Bohez, S., Tunyasuvunakool, S., Brakel, P., Sadeghi, F., Hasenclever, L., Tassa, Y., Parisotto, E., Humplik, J., Haarnoja, T., Hafner, R. and others [2022], ‘Imitate and Repurpose: Learning Reusable Robot Movement Skills From Human and Animal Behaviors’, *arXiv preprint arXiv:2203.17138*.
- [7] Brockman, G., Cheung, V., Pettersson, L., Schneider, J., Schulman, J., Tang, J. and Zaremba, W. [2016], ‘Openai gym’, *arXiv preprint arXiv:1606.01540*.
- [8] Cetin, E. and Celiktutan, O. [2021], ‘Domain-robust visual imitation learning with mutual information constraints’, *arXiv preprint arXiv:2103.05079*.
- [9] Cover, T. M. and Thomas, J. A. [2005], *Elements of Information Theory*.
- [10] Fickinger, A., Cohen, S., Russell, S. and Amos, B. [2021], ‘Cross-Domain Imitation Learning via Optimal Transport’, *arXiv preprint arXiv:2110.03684*.
- [11] Fu, J., Luo, K. and Levine, S. [2017], ‘Learning robust rewards with adversarial inverse reinforcement learning’, *arXiv preprint arXiv:1710.11248*.
- [12] Gangwani, T. and Peng, J. [2020], ‘State-only imitation with transition dynamics mismatch’, *arXiv preprint arXiv:2002.11879*.
- [13] Gleave, A., Freire, P., Wang, S. and Toyer, S. [2020], ‘seals: Suite of environments for algorithms that learn specifications’, <https://github.com/HumanCompatibleAI/seals>.
- [14] Goodfellow, I. J., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A. and Bengio, Y. [2014], Generative adversarial nets, in ‘Advances in Neural Information Processing Systems’, Vol. 3.
- [15] Gupta, A., Devin, C., Liu, Y., Abbeel, P. and Levine, S. [2017], ‘Learning invariant feature spaces to transfer skills with reinforcement learning’, *arXiv preprint arXiv:1703.02949*.
- [16] Ho, J. and Ermon, S. [2016], ‘Generative adversarial imitation learning’, *Advances in neural information processing systems* **29**.
- [17] Hudson, E., Warnell, G., Torabi, F. and Stone, P. [2021], ‘Skeletal feature compensation for imitation learning with embodiment mismatch’, *arXiv preprint arXiv:2104.07810*.
- [18] Kim, K., Gu, Y., Son, J., Zha, S. and Ermo, S. [2020], Domain Adaptive Imitation Learning, in ‘37th International Conference on Machine Learning, ICML 2020’, Vol. PartF168147-7.
- [19] Kodinariya, T. M. and Makwana, P. R. [2013], ‘Review on determining number of cluster in k-means clustering’, *International Journal* **1**(6), 90–95.

- [20] Kostrikov, I., Agrawal, K. K., Dwibedi, D., Levine, S. and Tompson, J. [2018a], ‘Discriminator-actor-critic: Addressing sample inefficiency and reward bias in adversarial imitation learning’, *arXiv preprint arXiv:1809.02925*.
- [21] Kostrikov, I., Agrawal, K. K., Dwibedi, D., Levine, S. and Tompson, J. [2018b], ‘Discriminator-actor-critic: Addressing sample inefficiency and reward bias in adversarial imitation learning’, *arXiv preprint arXiv:1809.02925*.
- [22] Lee, A. X., Nagabandi, A., Abbeel, P. and Levine, S. [2020], Stochastic latent actor-critic: Deep reinforcement learning with a latent variable model, in ‘Advances in Neural Information Processing Systems’, Vol. 2020-December.
- [23] Liu, F., Ling, Z., Mu, T. and Su, H. [2019], ‘State alignment-based imitation learning’, *arXiv preprint arXiv:1911.10947*.
- [24] Mazouze, B., des Combes, R. T., Doan, T., Bachman, P. and Hjelm, R. D. [2020], Deep reinforcement and InfoMax learning, in ‘Advances in Neural Information Processing Systems’, Vol. 2020-December.
- [25] Mémoli, F. [2011], ‘Gromov-Wasserstein Distances and the Metric Approach to Object Matching’, *Foundations of Computational Mathematics* **11**(4).
- [26] Montague, P. [1999], ‘Reinforcement Learning: An Introduction, by Sutton, R.S. and Barto, A.G.’, *Trends in Cognitive Sciences* **3**(9).
- [27] Orsini, M., Raichuk, A., Hussenot, L., Vincent, D., Dadashi, R., Girgin, S., Geist, M., Bachem, O., Pietquin, O. and Andrychowicz, M. [2021], ‘What matters for adversarial imitation learning?’, *Advances in Neural Information Processing Systems* **34**.
- [28] Radosavovic, I., Wang, X., Pinto, L. and Malik, J. [2020], State-only imitation learning for dexterous manipulation, in ‘2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)’, pp. 7865–7871.
- [29] Rakelly, K., Gupta, A., Florensa, C. and Levine, S. [2021], ‘Which Mutual-Information Representation Learning Objectives are Sufficient for Control?’, *Advances in Neural Information Processing Systems* **34**.
- [30] Raychaudhuri, D. S., Paul, S., Vanbaas, J. and Roy-Chowdhury, A. K. [2021], Cross-domain imitation from observations, in ‘International Conference on Machine Learning’, pp. 8902–8912.
- [31] Ross, B. C. [2014], ‘Mutual information between discrete and continuous data sets’, *PLoS ONE* **9**(2).
- [32] Russell, S. [2019], *Human compatible: Artificial intelligence and the problem of control*, Penguin.
- [33] Satopaa, V., Albrecht, J., Irwin, D. and Raghavan, B. [2011], Finding a" kneedle" in a haystack: Detecting knee points in system behavior, in ‘2011 31st international conference on distributed computing systems workshops’, IEEE, pp. 166–171.
- [34] Schmeckpeper, K., Rybkin, O., Daniilidis, K., Levine, S. and Finn, C. [2020], ‘Reinforcement learning with videos: Combining offline observations with interaction’, *arXiv preprint arXiv:2011.06507*.
- [35] Sermanet, P., Lynch, C., Chebotar, Y., Hsu, J., Jang, E., Schaal, S., Levine, S. and Brain, G. [2018], Time-contrastive networks: Self-supervised learning from video, in ‘2018 IEEE international conference on robotics and automation (ICRA)’, pp. 1134–1141.
- [36] Stadie, B. C., Abbeel, P. and Sutskever, I. [2017], ‘Third-person imitation learning’, *arXiv preprint arXiv:1703.01703*.
- [37] Stooke, A., Lee, K., Abbeel, P. and Laskin, M. [2021], Decoupling representation learning from reinforcement learning, in ‘International Conference on Machine Learning’, pp. 9870–9879.
- [38] Todorov, E., Erez, T. and Tassa, Y. [2012], MuJoCo: A physics engine for model-based control, in ‘IEEE International Conference on Intelligent Robots and Systems’.
- [39] Torabi, F., Warnell, G. and Stone, P. [2018], ‘Generative adversarial imitation from observation’, *arXiv preprint arXiv:1807.06158*.
- [40] Toyer, S., Shah, R., Critch, A. and Russell, S. [2020a], ‘The magical benchmark for robust imitation’, *Advances in Neural Information Processing Systems* **33**, 18284–18295.
- [41] Toyer, S., Shah, R., Critch, A. and Russell, S. [2020b], ‘The magical benchmark for robust imitation’, *Advances in Neural Information Processing Systems* **33**, 18284–18295.

- [42] Viano, L., Huang, Y.-T., Kamalaruban, P., Innes, C., Ramamoorthy, S. and Weller, A. [2022], ‘Robust learning from observation with model misspecification’, *arXiv preprint arXiv:2202.06003*.
- [43] Vinyals, O., Babuschkin, I., Czarnecki, W. M., Mathieu, M., Dudzik, A., Chung, J., Choi, D. H., Powell, R., Ewalds, T., Georgiev, P., Oh, J., Horgan, D., Kroiss, M., Danihelka, I., Huang, A., Sifre, L., Cai, T., Agapiou, J. P., Jaderberg, M., Vezhnevets, A. S., Leblond, R., Pohlen, T., Dalibard, V., Budden, D., Sulsky, Y., Molloy, J., Paine, T. L., Gulcehre, C., Wang, Z., Pfaff, T., Wu, Y., Ring, R., Yogatama, D., Wünsch, D., McKinney, K., Smith, O., Schaul, T., Lillicrap, T., Kavukcuoglu, K., Hassabis, D., Apps, C. and Silver, D. [2019], ‘Grandmaster level in StarCraft II using multi-agent reinforcement learning’, *Nature* **575**(7782).
- [44] Yin, Z.-H., Sun, L., Ma, H., Tomizuka, M. and Li, W.-J. [2021], ‘Cross Domain Robot Imitation with Invariant Representation’, *arXiv preprint arXiv:2109.05940*.
- [45] Zakka, K., Zeng, A., Florence, P., Tompson, J., Bohg, J. and Dwibedi, D. [2022], Xirl: Cross-embodiment inverse reinforcement learning, in ‘Conference on Robot Learning’, pp. 537–546.
- [46] Ziebart, B. D., Maas, A. L., Bagnell, J. A. and Dey, A. K. [2008], Maximum entropy inverse reinforcement learning., in ‘Aaai’, Vol. 8, Chicago, IL, USA, pp. 1433–1438.

检查清单

1. 关于所有作者……

- (a) 摘要和引言中的主要声明是否准确反映了论文的贡献和范围? [是] (b) 您是否描述了工作的局限性? [是]
] (c) 您是否讨论了工作可能带来的负面社会影响? [N/A] (d) 您是否阅读了伦理审查指南, 并确保论文符合这些指南? [是] 2. 如果您包含理论结果……

- (a) 您是否陈述了所有理论结果的完整假设集? [N/A] (b) 您是否包含了所有理论结果的完整证明?
[N/A] 3. 如果您进行了实验……

- (a) 您是否包含了重现主要实验结果所需的代码、数据和说明 (在补充材料中或作为 URL)? [否] 我们在说明中包含了所有细节, 并将在发表时发布代码。

- (b) 您是否指定了所有训练细节 (例如, 数据划分、超参数、如何选择)? [是]

- (c) 您是否报告了误差线 (例如, 多次运行实验后相对于随机种子的误差)?

[是]

- (d) 是否包含了所使用的计算总量和资源类型 (例如, 图形处理器类型、内部集群或云服务提供商)? [是] 参见附录。

4. 如果使用了现有资产 (例如代码、数据、模型) 或整理/发布新资产……

- (a) 如果工作使用了现有资产, 是否引用了创建者? [是]

- (b) 是否提及了资产的许可证? [是]

- (c) 是否在补充材料中或以统一资源定位符 (URL) 的形式包含了任何新资产? [是]

- (d) 是否讨论了如何以及是否从所使用/整理数据的人员处获得同意?

[是] (c) 是否讨论了所使用/整理的数据是否包含个人信息或冒犯性内容? [N/A] 5. 如果使用了众包或进行了涉及人类受试者的研究……

- (a) 是否包含了提供给参与者的完整说明文本和截图 (如适用)? [N/A] (b) 是否描述了任何潜在的参与者风险, 并附上了机构审查委员会 (IRB) 的批准链接 (如适用)? [N/A] (c) 是否包含了支付给参与者的估计时薪以及用于参与者的总金额

补偿? [N/A]

8 附录

8.1 方法

8.1.1 逆强化学习 (IRL) 简化

本文首先考虑托拉比等人 [39, 方程 7] 中给出的仅状态模仿学习目标:

$$\text{IRL}_\psi(\pi_E) = \arg \max_c \left(\min_{\pi_L} \mathbb{E}_{\pi_L} [c(s, s')] - \mathbb{E}_{\pi_E} [c(s, s')] - \psi(c) \right)$$

本文指出, 策略的期望代价可表示为:

$$\mathbb{E}_\pi [c(s, s')] = \sum_{s, s'} \rho_\pi(s, s') c(s, s')$$

本文假设环境状态 s 由 n 个维度组成, 即 $s = [d_1, d_2, \dots, d_n]$ 。进一步假设专家智能体的代价函数 c_E 在环境维度上是稀疏的。为简化记号, 假设 c_E 仅依赖于前 m 个维度, 即。

$$c(d_1, d'_1, \dots, d_n, d'_n) = c(d_1, d'_1, \dots, d_m, d'_m),$$

其中我们重载 c 以接受两种维度的输入。注意, 同样的推理适用于不同的稀疏模式, 且不失一般性。我们将专家编码器表示为 $f: S_E \rightarrow Z_E$, 它将维度为 n 的专家状态 s_E 映射到维度为 m 的专家状态嵌入 z_E 。我们定义 f 为截断前 m 个维度的操作, 即它包含所有 c_E 非零的维度。因此 $z = [d_1, \dots, d_m]$ 。我们现在可以将 c_E 重新定义为 z 的函数。然后我们可以将期望代价表示为:

$$\begin{aligned} \mathbb{E}_\pi [c(s, s')] &= \sum_{d_1, d'_1, \dots, d_m, d'_m} \rho_\pi(d_1, d'_1, \dots, d_m, d'_m) \cdot c(d_1, d'_1, \dots, d_m, d'_m) \cdot \\ &\quad \cdot \left(\sum_{d_{m+1}, d'_{m+1}, \dots, d_n, d'_n} \rho_\pi(d_{m+1}, d'_{m+1}, \dots, d_n, d'_n) \right) \\ &= \sum_{z, z'} \rho_\pi(z, z') \cdot c(z, z'). \end{aligned}$$

这使得可以将对抗性模仿学习问题改写为:

$$\text{IRL}(\pi_E) = \arg \max_c \left(\min_{\pi_L} \sum_{z, z'} \rho_{\pi_L}^z(z, z') c(z, z') - \sum_{z, z'} \rho_{\pi_E}^z(z, z') c(z, z') - \psi(c) \right) \quad (8)$$

通过将专家代价函数 c_E 替换为专家奖励函数 r_E , 并翻转优化目标, 我们得到方程 4 (为简化起见, 进一步省略了代价正则化项 ψ)。

8.1.2 时间不变性约束

我们考虑一个二维示例问题, 以展示当学习者编码器 g 未施加时间不变性约束时可能出现的平凡解。专家的嵌入状态转移 (z_E^t, z_E^{t+1}) 由从均匀分布中抽取的两个数字组成, 满足 $z_E^{t+1} < z_E^t$ (例如通过拒绝采样)。

$$S_E = \{(z_E^t, z_E^{t+1}) : z_E^{t+1} < z_E^t, (z_E^t, z_E^{t+1}) \in [0, 1]^2\} \quad (9)$$

学习者的状态转移 (s_L^t, s_L^{t+1}) 也由从随机分布中抽取的两个数字组成, 但与之相反 $s_L^{t+1} > s_L^t$, 即它们的顺序是相反的。

$$S_L = \{(s_L^t, s_L^{t+1}) : s_L^{t+1} > s_L^t, (s_L^t, s_L^{t+1}) \in [0, 1]^2\} \quad (10)$$

这些代表了两个最小但不同的待映射分布。我们现在考虑两种备选的映射函数域, 一种强制时间不变性, 另一种不强制。两者都是仿射函数。最一般的、无时间不变性的形式为

$$g^{\text{affine}}(s_L^t, s_L^{t+1}) = (a \cdot s_L^t + b, c \cdot s_L^{t+1} + d),$$

由 a, b, c 和 d 参数化。其时间不变的特化形式为:

$$g^{\text{invariant}}(s_L^t, s_L^{t+1}) = (g'(s_L^t), g'(s_L^{t+1})), \quad g'(s) = a \cdot s + b,$$

这本质上是在两个时间步 t 和 $t+1$ 上应用相同的函数 g' 。




图 7: 状态转移 (z, z') 与标签 $(random, expert)$ 之间随专家嵌入 z 尺寸增加的估计累积互信息。灰色虚线表示肘部。

我们现在分析在两种模型下可以将 S_E 和 S_L 映射的可能解。使用 g^{affine} 时，我们可以简单地设置 $a = c = 0$ （即完全忽略输入）和 $b > d$ ，以满足学习器中的约束（公式 10）。这显然是一个平凡解，因为它满足输出空间的约束但完全忽略输入空间（即输出分布是退化的）。

另一方面，使用 $g^{\text{invariant}}$ 时，我们无法为不同时间步独立设置偏置项 b 。因此，之前的平凡解在该模型中不可表达。相反，我们必须设置 $a < 0$ （即对输入取反）以将其映射到输出空间，同时满足公式 10。

虽然该分析使用了一个简单模型，但请记住，在实践中 g 由深度网络参数化，而深度网络是符合仿射函数集合的超集。因此，当不强制时间不变性时，同样的平凡解也必然出现在高维设置中。

8.2 实验

8.3 寻找专家嵌入

为了找到专家嵌入函数 f ，我们首先从专家演示集中生成伪随机转移，计算各个状态维度与转移标签（随机或专家）之间的互信息，最后使用肘部方法确定任务相关维度，从而得到专家状态的嵌入。

生成随机转移和专家转移集合。我们首先生成两组转移：一组专家转移 $\mathcal{T}_E$ ，以及一组伪随机转移 $\mathcal{T}_{rand}$ 。后者由专家观测集 $\mathcal{D}_E$ 中包含的转移以 15 帧跳跃组装而成。引入此帧跳跃是为了使转移更具区分度，因为它确保转移中两个状态之间的差异显著。随后，我们生成与 $\mathcal{T}_E$ 相同大小的伪随机转移集，方法是从 $\mathcal{D}_E$ 中随机采样两个状态，并将其作为新转移加入伪随机转移集 $\mathcal{T}_{rand}$ ，直至其包含与 $\mathcal{T}_E$ 相同数量的转移。

计算单个维度的互信息。我们首先计算单个状态维度与转移标签（随机或专家）之间的估计互信息，为此先按第 4.3 节所述定义随机变量，并使用罗斯 (Ross) [31] 的方法计算每个状态维度 n 的互信息，得到一个大小为 n 的向量，描述每个状态维度上的转移与标签之间的互信息。

使用肘部法则寻找任务相关维度。我们现在通过累加信息量最大的 k 个维度的互信息，计算所有 $k \in \{0, \dots, n\}$ 的累积互信息。结果绘制在图 7 中。我们使用萨托帕 (Satopaa) 等人 [33] 的实现来寻找




图 8: 我们评估两个学习智能体在其余三种实施例之一的演示上训练时获得的奖励, 使用我们的算法 UDIL 或 XIRL[45] 基线。

曲线中的肘部, 这是一种常用于确定降维聚类数目的方法 [19]。找到的肘部同样显示在图 7 中。然后我们通过定义 f , 使其将专家状态 s_E 缩减至肘部左侧 (含肘部本身) 的维度, 来估计公式 6 中所述的目标, 即 $\arg \max_f I((Z, Z'); Y)$ 。

关于所找到肘部的背景。对于 XIRL (见第 5.1 节), 所发现的任务相关嵌入维度, 即肘部左侧的那些维度, 是描述任务相关对象的 9 个维度。也就是说, 这些维度描述了图 2 (左) 中块的三个 x 位置、三个 y 位置以及对象与目标区域之间的距离。在 Gym 环境 *hopper*、*walker* 和 *halfcheetah* (见第 5.2 节) 中, 所发现的任务相关维度描述了躯干的属性。也就是说, 对于 *hopper*, 它们描述了躯干的 x 和 z 位置; 对于 *halfcheetah*, 它们描述了躯干的 x 坐标和前端的 x 坐标; 对于 *walker*, 它们描述了躯干的 x 坐标和躯干在 x 方向上的速度。

8.3.1 XIRL 实验

设置。我们使用作者实现的 X-Magical 环境 [45, 40]。³ 我们进一步使用作者实现的 XIRL[45] 基线实现。⁴ 我们使用智能体 *gripper* 和 *longstick*, 因为它们具有最大的具身差异。与 XIRL 不同, 我们仅在一个其他智能体的演示上进行训练。我们不使用像素作为观测, 而是直接使用环境状态向量。我们将训练时间增加了一倍, 因为我们发现否则无法达到收敛, 并保持所有其他参数不变。我们针对六个不同的随机种子评估 UDIL 和 XIRL, 并在图 2 中报告均值和标准误。

额外具身的结果。我们进一步在 X-Magical 基准 [41, 45] 的其余具身的演示上评估了 UDIL 和 XIRL。对于具身 *Gripper* 和 *Longstick*, 从四个给定具身中的三个 (*Gripper*, *Longstick*, *Shortstick*, *Mediumstick*) 的演示进行跨域训练, 结果如图 8 所示。我们发现, 在所有测试的具身配对中, UDIL 始终优于 XIRL。

使用对抗训练的 UDIL 结果。我们进一步评估了简化版 UDIL (类似于 XIRL[45], 奖励智能体最小化与预计算目标状态的距离) 以及使用对抗训练的原始 UDIL 实现 (见公式 7) 的性能。从图 9 中可以观察到, UDIL 的对抗实现在两种情况下均优于 XIRL 基线。

³<https://github.com/kevinzakka/x-magical>

⁴<https://x-irl.github.io>




图 9: 我们评估了两个学习智能体在对方演示上训练时获得的奖励, 分别使用简化版 UDIL、未修改的对抗版 UDIL 或 XIRL[45] 基线, 后者按设计采用了简化实现。

表 1: 用于训练学习编码器 g 的超参数。

	Hopper	HalfCheetah	Walker
Learning rate encoder ($\alpha\text{-enc}$)	0.001	0.001	0.0001
Use bias with encoder (enc-use-bias)	False	True	False
Train every $n\text{-enc}$ steps	0.01	0.01	0.1

然而, 相对于简化版 UDIL, 其表现不稳定 (一次更好, 一次更差)。

8.3.2 健身房实验

设置。我们联合训练学习策略 π_L 、学习智能体状态 s_L 与专家智能体任务相关状态嵌入 z_E 之间的映射 g 以及判别器 D (见图 1 中的蓝色组件)。我们重新实现了判别器-演员-评论家算法 [21], 尽可能接近作者给出的原始实现 s 。我们保持所有参数不变, 并参考原始实现以获取更多细节。此外, 我们使用 StableBaselines3 ⁶ 包来实现强化学习智能体, 并使用 Seals 包 ⁷ 来实现具有固定回合长度的健身房环境。我们不更改这些实现中给出的任何参数。

我们引入了一组最小的额外超参数, 这些超参数都与学习编码器 g 相关, 如表 1 所示。我们在判别器-演员-评论家框架中附加了专家编码器 g (在下一节中描述), 该编码器通过反向传播负判别器损失进行训练, 即编码器 g 被训练来欺骗判别器 D 。我们每 $n\text{-encoder}$ 步判别器训练一次学习编码器 g , 即编码器的训练频率低于判别器, 并使用学习率 $\alpha\text{-enc}$ 。我们使用 20 条专家轨迹训练学习智能体, 这些轨迹由在相应环境中使用真实奖励训练的专家智能体生成。我们对每个实验运行六个种子 (零到五), 以确保对不同随机实例的鲁棒性, 并在图 4 中报告均值和标准误。

学习编码器。我们将学习者编码器 g 参数化, 使其学习仿射变换, 即对学习状态 s_L 施加仿射变换。为稳定学习, 我们应用一个 *sigmoid* 来缩放变换权重 (及偏差), 使其不超过最大幅度五。学习者编码器 g 实现为单层神经网络, 为每个输入维度输出一个权重, 可附加偏差 (由 enc-use-bias 表示)。

GWIL 基线。我们使用作者实现运行 GWIL 基线 [10]。⁸ 我们评估了超参数 $gw\text{-entropic}$ 和 $gw\text{-normalize}$ 的不同组合, 发现作者原始实现效果最佳。我们同样对随机种子零到五评估了基线, 并在图 4 中报告均值和标准误。我们发现结果高度随机, 以至于在某些情况下未取得任何正面结果, 正如作者所述 [10, 备注 1]。




图 10: 当仅使用对方的一个演示进行训练时, hopper 和 halfcheetah 所获得的奖励 (行进距离)。详见第 5.3 节。




图 11: 当使用省略学习者编码器 g 的预言机方法训练时, hopper 和 halfcheetah 所获得的奖励 (行进距离)。详见第 8.3.3 节。

8.3.3 消融研究

从单个演示进行模仿。我们评估了当仅给出一个专家演示 (单条轨迹) 时 UDIL 的性能。这构成了与 GWIL 最接近的比较, 因为 GWIL 由于其计算复杂度无法扩展到多于一条轨迹。我们可以在图 11 中观察到, 即使仅给出单条轨迹, UDIL 也优于 GWIL。我们进一步发现, 当模仿 hopper 时, halfcheetah 的性能在一条轨迹 (与通常的 20 条轨迹相比) 下更高。我们进一步调查发现这是一个异常值, 因为对于任何其他智能体组合并非如此。

与理想基线的比较。本文进一步将 UDIL 的性能与理想基线进行比较, 该基线设计如下: 假设使用一个理想机制来选择与任务相关嵌入中专家状态维度相匹配的学习者状态维度, 而状态的顺序仍然未知。然后, 本文直接在任务相关嵌入上运行 UDIL, 即省略学习者编码器 g 。

8.4 视频

本文在补充材料中提供了 XMagical 和 Gym 中最终行为的视频。

⁵<https://github.com/google-research/google-research/tree/master/dac>

⁶<https://github.com/DLR-RM/stable-baselines3>

⁷<https://github.com/HumanCompatibleAI/seals>

⁸<https://github.com/facebookresearch/gwil>