

利用薛定谔桥改进基于生成模型的展开

Sascha Diefenbacher, ^{1,*} Guan-Hong Liu, ^{2,†} Vinicius Mikuni, ^{3,‡} Benjamin Nachman, ^{1,4,§} 和 Weili Nie ^{5,¶} ¹ 劳伦斯伯克利国家实验室物理部, 美国加利福尼亚州伯克利 94720 ² 佐治亚理工学院自主控制与决策系统实验室, 美国佐治亚州亚特兰大 30332 ³ 伯克利实验室国家能源研究科学计算中心, 美国加利福尼亚州伯克利 94720 ⁴ 加州大学伯克利分校伯克利数据科学研究所, 美国加利福尼亚州伯克利 94720 ⁵ 英伟达研究院机器学习研究组 基于机器学习的展开已实现无分箱和高维微分截面测量。该研究领域出现了两种主要方法: 一种基于判别模型, 另一种基于生成模型。判别模型的主要优势在于它们学习对起始仿真的小修正, 而生成模型在数据稀少的相空间区域具有更好的扩展性。我们提出使用薛定谔桥和扩散模型创建 SBUnfold, 这是一种结合判别模型和生成模型优势的展开方法。SBUnfold 的关键特征在于其生成模型将一组事件映射到另一组事件, 而无需像归一化流和标准扩散模型那样经过已知的概率密度。我们证明, 在合成 Z + 喷注数据集上, SBUnfold 相比最新技术方法取得了优异的性能。

I. 引言

校正探测器效应——称为反卷积或展开——是粒子物理、核物理和天体物理中微分截面测量的核心统计任务。经典展开方法基于直方图, 导致在少量维度上进行分箱测量。机器学习有潜力通过实现无分箱和高维测量来革新微分截面测量。已提出多种基于机器学习的展开技术 [1 – 15] (另见参考文献 [16] 的综述), OmniFold 方法 [5, 9] 最近已应用于利用 H1 [17 – 20]、LHCb [21]、CMS [22] 和 STAR [23] 的数据研究强子末态。设 X 表示 ¹ 探测器级事件, Z 表示同一事件的粒子级。展开的目标是利用模拟对 (Z, X) 和数据中的观测 x 推断最可能的密度 $p(z)$ 。在经典方法中, X 和 Z 被离散化, 展开通过正则化矩阵求逆进行, 以近似最大似然解。似然是泊松概率质量函数的乘积, 尽管大多数测量并不直接最大化该似然。例如, 最常见的经典展开算法之一称为 Lucy-Richardson 反卷积 [24, 25] (也称为迭代贝叶斯展开 [26]), 它使用期望最大化

(EM) 算法收敛到最大似然估计量。在无分箱情况下, 似然未知。一种解决方案是使用 EM 算法, 它是两种最大似然机器学习方法的核心。第一种是 OmniFold, 其过程如下 ²:

E step: $\omega_{i+1}(x) = p_{\text{data}}(x)/\tilde{p}_{\text{sim.}}(x)$

$$\tilde{p}_{\text{sim.}}(x) \equiv \int dz p_{\text{sim.}}(x, z) \nu_i(z)$$

M step: $\nu_{i+1}(z) = \tilde{p}_{\text{sim.}}(z)/p_{\text{sim.}}(z)$

$$\tilde{p}_{\text{sim.}}(z) \equiv \int dx p_{\text{sim.}}(x, z) \omega_{i+1}(x)$$

期望 (E) 步和最大化 (M) 步在实践中都通过训练分类器并将所得分数解释为目标似然比来实现, 例如从 p_{data} 和 $\tilde{p}_{\text{sim.}}$ (来自 $p_{\text{sim.}}$ 的样本按 ν 加权) 中抽取样本, 并训练分类器区分它们以完成 E 步。最终结果是在连续极限下按 ν 加权的模拟事件集, 其概率密度为 $p_{\text{sim.}}(z) \nu(z)$ 。另一种称为 IcINN [11] 的方法则基于生成模型:

E step: $p_i(z|x) \propto p_{\text{sim.}}(x|z) \nu_i(z)$

M step: $\nu_{i+1}(z) = \check{p}_{\text{sim.}}(z)/p_{\text{sim.}}(z)$

$$\check{p}_{\text{sim.}}(z) \equiv \int dx p_i(z|x) p_{\text{data}}(x)$$

IcINN 的 E 步骤通过训练一个生成模型 (一个归一化流 [27]) 来模拟 $p_{\text{sim.}}(x|z) \nu_i(z)$ 实现, 而 M 步骤则使用一个分类器, 如同

* sdiefenbacher@lbl.gov † ghliu@gatech.edu ‡ vmikuni@lbl.gov § bpnachman@lbl.gov ¶ wnie@nvidia.com ¹ 大写字母表示随机变量, 小写字母对应这些随机变量的实现。

² 这种积分形式是连续极限表示。在实践中, 积分被替换为对样本的求和。

OmniFold。IcINN 的基础工作已在文献 [7] 中奠定，该文献专注于 E 步骤，其他使用归一化流、扩散模型和生成对抗网络的论文也是如此 [2, 6, 14]。比较 OmniFold 和 IcINN 的 E 步骤和 M 步骤，可以看出它们在形式上是相同的，因此文献 [5] 中的 EM 证明适用于这两种方法。虽然形式上两种算法逐步实现相同的 EM 算法，但在实践中它们具有互补的优势。OmniFold 的一个优势是它从现有的仿真开始，如果该仿真接近自然，那么神经网络只需要学习一个小的修正。相比之下³，IcINN 中的归一化流必须将一个已知的概率密度（例如多维高斯分布）映射到数据，而这些可能差异很大。然而，OmniFold 的 E 步骤直接在数据上训练，因此当事件数量不多时其性能会下降。相比之下，IcINN 的 E 步骤使用仿真进行训练，因此能更好地处理事件较少的情况。我们提出一种称为 SBUnfold 的方法，它融合了 OmniFold 和 IcINN 的优势。我们采用一种称为薛定谔桥（Schrödinger Bridge, SB）的技术，使用扩散模型在 IcINN 工作流中学习生成模型。与归一化流或标准扩散模型不同，薛定谔桥学习将一个数据集映射到另一个数据集，而无需知道其中一个数据集的概率密度。因此，薛定谔桥理想情况下应学习一个小的修正，同时保留使用仿真而非数据进行 E 步骤学习的特性。后一特性意味着当数据中事件较少时，SBUnfold 应优于 OmniFold。由于 OmniFold 和 IcINN 仅在 E 步骤上有所不同，我们专注于所有方法第一次迭代的 E 步骤，并将 IcINN 称为 cINN 以消除歧义。本文结构如下。第二节介绍薛定谔桥，第三节描述如何将其用于反卷积。第四节展示来自 OmniFold 公开 Z+jets 数据集的数值结果。论文最后在第五节给出结论和展望。

二、薛定谔桥与扩散模型的关联

扩散模型（Diffusion Model）因其高度的灵活性、稳定的训练过程以及与其他方法相比通常具有竞争力的结果，已成为生成建模的热门选择。其核心思想是设计

一种随时间变化的扰动过程，该过程缓慢地将数据扰动至可处理的噪声分布。生成模型的目标是逆转这一过程，从噪声样本出发，逐步去噪以生成新的数据观测。基于固定的随机微分方程（SDE）选择

$$d\mathbf{x} = f(\mathbf{x}, t)dt + g(t)d\mathbf{w}, \quad (1)$$

由参数 $f(\mathbf{x}, t) \in \mathbb{R}^d$ 和 $g(t) \in \mathbb{R}$ 描述，数据观测 $\mathbf{x} \in \mathbb{R}^d$ 随时间的演化得以确定。由于额外的随机项（由维纳过程或布朗运动 $\mathbf{w}(t) \in \mathbb{R}^d$ ，标识，通常从与数据同维度的正态分布中采样），相同的初始数据点可能经历不同的路径。逆向过程遵循逆向随机微分方程，其形式如下：

$$d\mathbf{x} = [f(\mathbf{x}, t) - g(t)^2 \nabla \log p(\mathbf{x}, t)]dt + g(t)d\bar{\mathbf{w}}. \quad (2)$$

公式 2 中唯一未知项为分数函数， $\nabla \log p(\mathbf{x}, t)$ ，该函数可通过去噪分数匹配 [29] 并最小化损失函数来近似

$$\mathcal{L}_{SGM} = \frac{1}{2} \mathbb{E}_{\mathbf{x}_t, t} \|\epsilon_\theta(\mathbf{x}_t, t) - \sigma_t \nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t | \mathbf{x})\|_2^2, \quad (3)$$

其中，一个具有可训练参数 θ 的神经网络被优化以近似已被具有时间相关参数 α_t 和 σ_t 的高斯分布扰动的数据的得分函数。对于这种高斯扰动， $q(\mathbf{x}_t | \mathbf{x}) = \mathcal{N}(\mathbf{x}_t, \alpha_t \mathbf{x}, \sigma_t^2 \mathbf{I})$ ，要求 $f(\mathbf{x}, t)$ 关于 $\mathbf{x}$ 是仿射的，并在扩散过程结束时产生高斯噪声。对于任意噪声分布，相应的 $f(\mathbf{x}, t)$ 选择不易确定，这通常限制了扩散过程所允许选择的分布族。一个更通用的框架，允许一般分布之间的映射，对应于薛定谔桥（Schrödinger Bridge）问题的解。

该问题最初由埃尔温·薛定谔提出 [30]，涉及从经历扩散过程的粒子中推断轨迹，其中粒子轨迹的实验观测仅在特定时间值处可用，从而固定了问题的边界条件。通过考虑以下正向和反向随机微分方程，与扩散生成模型的联系变得更加清晰：

$$d\mathbf{x} = [f(\mathbf{x}, t) + g(t)^2 \nabla \log \Psi(\mathbf{x}, t)]dt + g(t)d\mathbf{w}, \quad (4a)$$

$$d\mathbf{x} = [f(\mathbf{x}, t) - g(t)^2 \nabla \log \hat{\Psi}(\mathbf{x}, t)]dt + g(t)d\bar{\mathbf{w}}. \quad (4b)$$

波函数 Ψ 和 $\hat{\Psi}$ 满足

$$\begin{aligned} \frac{\partial \Psi(\mathbf{x}, t)}{\partial t} &= -\nabla \Psi(\mathbf{x}, t)^\top f(\mathbf{x}, t) - \frac{1}{2} g(t)^2 \Delta \Psi(\mathbf{x}, t) \\ \frac{\partial \hat{\Psi}(\mathbf{x}, t)}{\partial t} &= -\nabla \cdot (\hat{\Psi}(\mathbf{x}, t) f(\mathbf{x}, t)) + \frac{1}{2} g(t)^2 \Delta \hat{\Psi}(\mathbf{x}, t) \end{aligned}$$

其中 $\Psi(\mathbf{x}, 0) \hat{\Psi}(\mathbf{x}, 0) = p_A(\mathbf{x})$ 且 $\Psi(\mathbf{x}, 1) \hat{\Psi}(\mathbf{x}, 1) = p_B(\mathbf{x})$ 对于密度 $p_A(\mathbf{x})$ 以及 $p_B(\mathbf{x})$ 。Compared to Eq. 2,

³ 这对于归一化流和传统扩散模型是成立的。生成对抗网络（GANs）[28] 不需要可处理的噪声分布，但稳定性较差。参考文献 [10] 为变分自编码器（VAE）使用了物理潜空间，但 VAE 在生成建模中并非最新技术。

漂移函数中存在额外的非线性项 $g(t)^2 \nabla \log \hat{\Psi} \Psi(\mathbf{x}, t)$, 使得扩散能够在扩散过程结束时不一定由标准正态分布表示的密度之间进行。此外, $\nabla \log \hat{\Psi} \Psi(\mathbf{x}, t)$ 不再表示扰动数据的得分函数, 但与之相关, 因为

$$\Psi(\mathbf{x}, t) \hat{\Psi}(\mathbf{x}, t) = q(\mathbf{x}, t), \quad (5)$$

因此

$$\nabla \log \Psi(\mathbf{x}, t) + \nabla \log \hat{\Psi}(\mathbf{x}, t) = \nabla \log q(\mathbf{x}, t). \quad (6)$$

虽然描述一般薛定谔桥 (Schrödinger Bridge) 问题的方程与扩散生成模型的标准框架有相似之处, 但求解该问题的通用策略并不显而易见。文献 [31] 的作者提出了一种可处理的解, 命名为 I^2SB , 通过考虑数据集中存在成对观测值, 使得 $p(\mathbf{x}_a, \mathbf{x}_b) = p_A(\mathbf{x}_a) p_B(\mathbf{x}_b | \mathbf{x}_a)$ 。这一假设同样适用于展开方法论, 因为在仿真中, 探测器相互作用前后的粒子碰撞对总是可用的。在此近似下, 文献 [31] 的作者证明, 通过设定线性漂移项 $f(\mathbf{x}, t) := 0$, 后验分布 of Eq. 4, $q(\mathbf{x} | \mathbf{x}_a, \mathbf{x}_b)$ 具有解析形式:

$$q(\mathbf{x} | \mathbf{x}_a, \mathbf{x}_b) = \mathcal{N}(\mathbf{x}_t; \mu_t(\mathbf{x}_a, \mathbf{x}_b), \Sigma_t), \quad (7)$$

$$\mu_t = \frac{\bar{\sigma}_t^2}{\bar{\sigma}_t^2 + \sigma_t^2} \mathbf{x}_a + \frac{\sigma_t^2}{\bar{\sigma}_t^2 + \sigma_t^2} \mathbf{x}_b, \quad \Sigma_t = \frac{\sigma_t^2 \bar{\sigma}_t^2}{\bar{\sigma}_t^2 + \sigma_t^2} \cdot I, \quad (8)$$

其中 $\sigma_t^2 := \int_0^t g^2(\tau) d\tau$ 和 $\bar{\sigma}_t^2 := \int_t^1 g^2(\tau) d\tau$ 。根据该表达式, 给定成对数据 $(\mathbf{x}_a, \mathbf{x}_b)$, 我们可以直接确定任意时间步 t 的 $\mathbf{x}_t = \mu_t + \Sigma_t \epsilon$, $\epsilon \sim \mathcal{N}(0, 1)^d$ 。损失函数则与式 3 类似地确定为:

$$\mathcal{L}_{I^2SB} = \frac{1}{2} \mathbb{E}_{\mathbf{x}_t, t} \left\| \epsilon_\theta(\mathbf{x}_t, t) - \frac{\mathbf{x}_t - \mathbf{x}_0}{\sigma_t} \right\|_2^2, \quad (9)$$

其中损失函数右侧项近似了反向漂移 $\nabla \log \hat{\Psi} \Psi(\mathbf{x}, t)$ 的得分函数, 该得分函数可在采样过程中用于将样本从 p_B 传输到 p_A 。在采样过程中, 可以使用标准递归采样器, 如 DDPM[32], 并利用在时间步 $n < N$ 处对去噪数据 $\mathbf{x}_0^\theta = \mathbf{x}_{n+1} - \sigma_{n+1} \epsilon_\theta(\mathbf{x}_{n+1}, n+1)$ 的预测, 其定义为:

$$\mathbf{x}_n \sim q(\mathbf{x}_n | \mathbf{x}_0^\theta, \mathbf{x}_{n+1}), \mathbf{x}_N \sim p_B. \quad (10)$$

随机求解器能够在相同输入下产生不同的观测值, 这些观测值可用于对生成输出的有效性进行不同的覆盖测试。第二种选择是考虑确定性情形, 即后验分布实际上由其均值替代。这一特定情形由以下常微分方程的解描述:

$$d\mathbf{x}_t = \mathbf{v}_t(\mathbf{x}_t | \mathbf{x}_0) dt = \frac{\beta_t}{\sigma_t^2} (\mathbf{x}_t - \mathbf{x}_0) dt, \quad (11)$$

该方程描述了一个最优传输计划 [33]。在我们的研究中, 我们观察到随机与确定性设置下的样本质量相似, 为简单起见, 我们基于确定性情形报告结果。我们设定 $f(\mathbf{x}, t) := 0$ 和 $g(t) = \sqrt{\beta(t)}$, 其中 $\beta(t)$ 为三角函数:

$$\beta(t) = \begin{cases} \beta_0 + 2(\beta_1 - \beta_0)t, & 0 \leq t < \frac{1}{2}, \\ \beta_1 - 2(\beta_1 - \beta_0)(t - \frac{1}{2}), & \frac{1}{2} \leq t \leq 1. \end{cases} \quad (12)$$

含 $\beta_0 = 10^{-5}$ 且 $\beta_1 = 10^{-4}$ 。

III. 展开方法论

我们使用参考文献 [5] 中的公开数据集测试 SBUnfold, 该数据集可在 Zenodo[34] 上获取, 并在下文简要总结。产生 $a Z$ 玻色子的质子-质子碰撞在质心能量为 $\sqrt{s} = 14$ TeV 下生成。对展开的非平凡测试至少需要两个数据集, 一个充当“数据”, 另一个充当“仿真”。对于“数据”, 碰撞使用 Herwig 7.1.5[35–37] 的默认调谐进行仿真。我们仅使用来自 Herwig 的重建事件, 如同真实数据的情况。Herwig 的粒子级事件仅在评估不同方法性能时使用。对于“仿真”, 事件使用 Pythia 8.243[39–41] 的 Tune 26[38] 进行仿真。探测器畸变使用 Delphes 3.4.2[42] 和采用粒子流重建的 CMS 调谐进行仿真。在未来工作中, 我们将研究 SBUnfold 在粒子 (粒子级) 和粒子流对象 (探测器级) 的全相空间上的性能。在本研究中, 我们专注于一组固定的六个观测量, 作为固定维度展开的基准。这些观测量由前导喷注的子结构计算得出。喷注在探测器级使用所有粒子流对象, 在粒子级使用所有稳定的非中微子真实粒子进行聚类。它们由 FastJet 3.3.2[44, 45] 中实现的半径参数为 $R = 0.4$ 的反 k_T 算法 [43] 定义。前四个观测量是喷注质量 m 、组分多重数 M 、 N -子喷注性比值 $\tau_{21} = \tau_2^{(\beta=1)} / \tau_1^{(\beta=1)}$ [46, 47] 以及喷注宽度 w (实现为 $\tau_1^{(\beta=1)}$)。其余两个观测量是 Soft Drop 修饰 [48, 49] (参数为 $z_{\text{cut}} = 0.1$ 和 $\beta = 0$) 后的喷注质量 $\ln \rho = \ln m_{\text{SD}}^2 / p_T^2$ 和动量分数 z_g 。许多观测量使用 FastJet Contrib 1.042[50] 计算。要求 Z 玻色子具有 $p_T > 200$ GeV, 以使接受效应可忽略⁴。每个数据集包含约 160 万个事件。SBUnfold 的噪声预测模型使用包含多个跳跃连接的全连接架构实现。具体而言, 该模型

⁴ See Ref. [9] for how to include acceptance effects.

采用四个残差网络 (ResNet) [51] 模块, 其中每个残差层通过跳跃连接与单层网络的输出相连。所用激活函数为带斜率 $\alpha = 0.01$ 的带泄露修正线性单元 (LeakyRelu) [52], 所有层大小均设为 32。模型实现使用 Pytorch [53] 完成。生成过程从重建级的数据观测出发, 利用薛定谔桥 (SB) 向生成器级事件推进, 共使用 1000 个时间步以提高准确率。条件可逆神经网络 (cINN) 实现采用文献 [7] 中提出的归一化流模型, 而 OmniFold 首次迭代的第一步使用一个全连接模型, 该模型具有三个隐藏层、修正线性单元 (ReLU) 激活函数, 节点大小依次设为 50、150、50, 之后是输出层, 输出层为单节点并使用 Sigmoid 函数激活。cINN 与 OmniFold 均在 TensorFlow [54] 中实现。所有模型的可训练参数量保持相近, 约为 13k。初始学习率设为 10^{-3} , 所有模型训练 30 个训练轮次, 批大小为 128。所有模型训练共使用来自 Pythia 仿真的 100 万个训练事件。用于评估反褶积性能的伪数据取自 Herwig。SBUnfold 与 cINN 在训练期间无法访问数据, 而 OmniFold 共使用 200 万个训练事件 (100 万来自 Pythia, 100 万来自 Herwig)。我们在第四节中研究伪数据训练规模对反褶积结果的影响。所有训练均在 Perlmutter 超级计算机上使用单个 NVIDIA A100 图形处理器完成。

第四节 结果

我们通过首先考察展开分布来评估 SBUnfold 相较于其他展开方法的性能, 其中伪数据和用于训练不同展开方法的样本均源自 Pythia 仿真。展示展开分布的结果如图 1 所示。在附录 A 中, 我们还提供了标准扩散模型所得结果的比较。我们观察到与 Pythia 在生成器层面的预期分布以及用于展开的生成模型的响应具有良好的一致性。我们省略了 OmniFold 的结果, 因为当数据和仿真在统计上完全相同时, 加权函数会变得平凡。我们还研究了每对展开特征之间的成对相关性分布, 以验证 SBUnfold 也能够学习分布之间的正确相关性。结果如图 2 所示。我们再次观察到, 对于两种生成模型, 生成分布与仿真预期分布之间具有良好的一致性, 其中 SBUnfold 在若干分布 (如 z_g vs. $\log \rho$ 和 z_g vs. τ_{21} ...) 上相比 cINN 展现出更优的描述。 z_g 的分布在 $z_g = 0$ 处呈现出尖锐的截断。

表 I. 不同算法之间推土机距离 (EMD) 和三角判别器的比较。EMD 基于未分箱分布计算, 而三角判别器以直方图作为输入。EMD 的不确定性通过从展开数据中进行 100 次有放回自助抽样得出。结果使用从 Pythia 采样的 600,000 个伪数据点进行评估。粗体表示性能最佳的方法。模型 EMD($\times 10$)/三角判别器 ($\times 10^3$)

	cINN	SBUNFOLD
Jet mass	$1.4 \pm 0.2 / \mathbf{0.29}$	$\mathbf{0.70 \pm 0.06} / 0.30$
Jet Width	$0.013 \pm 0.002 / 0.25$	$\mathbf{0.0029 \pm 0.0005} / \mathbf{0.06}$
N	$2.3 \pm 0.8 / \mathbf{0.09}$	$\mathbf{0.57 \pm 0.04} / 0.9$
$\log \rho$	$1.1 \pm 0.3 / \mathbf{0.64}$	$\mathbf{0.27 \pm 0.01} / 0.68$
z_g	$0.095 \pm 0.003 / 10.9$	$\mathbf{0.009 \pm 0.001} / \mathbf{3.1}$
τ_{21}	$0.2 \pm 0.1 / 0.6$	$\mathbf{0.016 \pm 0.001} / \mathbf{0.2}$

这很难用生成模型复现。由于在重建级事件中观察到同样尖锐的分布, SBUnfold 可以在启动扩散过程时利用重建先验, 而 cINN 则始终需要从标准正态分布中采样以进行先验变换。我们还通过计算如图 1 所示直方图上的三角判别器度量 [55 – 57], 以及直接在展开方法生成的边缘化一维特征上使用推土机距离 (Earth Mover’s Distance, EMD), 来量化展开分布与由 Pythia 导出的期望值之间的一致性。结果列于表 I。对于所有分布, 我们观察到 SBUnfold 的 EMD 值显著低于 cINN, 且六项中有四项的三角判别器值也更低。EMD 计算的不确定性来自对展开数据进行 100 次有放回自助抽样所得的标准差。我们观察到 cINN 的 EMD 不确定性通常高于 SBUnfold, 这表明由于更具信息量的先验, SBUnfold 具有更好的稳定性。接下来, 我们保持 SBUnfold 和 cINN 在 Pythia 样本上训练的相同展开方法论, 但改用来自 Herwig 的重建事件作为数据代表。我们在图 3 中比较了不同分布之间的展开结果。我们观察到, 与重建事件的分布相比, 所有展开分布的一致性都有所改善, 而在所有展开方法论中, 喷注质量和 τ_{21} 分布均出现了系统性偏移。这些特征凸显了所有模型对先验的依赖性, 在没有 M 步骤和额外迭代的情况下无法排除这种依赖性。在表 II 中, 我们使用以 Herwig 作为伪数据的展开分布计算了 EMD 和三角判别器。我们再次观察到 SBUnfold 的良好性能, 在六项分布中有四项取得了最低的 EMD 值, 并在六项中有三项取得了最低的三角判别器值。我们还观察到 OmniFold




图 1. 六种不同物理观测量展开算法的比较。所有观测量均在不分箱的情况下同时展开，直方图仅用于评估。结果基于 600,000 个伪数据点进行评估。统计不确定性仅在比值面板中显示。伪数据与仿真由 Pythia 描述。

表 II. 不同算法之间推土机距离 (EMD) 与三角判别器的比较。EMD 在未分箱分布上计算，而三角判别器以直方图作为输入。EMD 的不确定性通过从展开数据中进行 100 次有放回自助抽样得出。结果使用从 Herwig 采样的 600,000 个伪数据点进行评估。粗体表示性能最佳的方法。模型 EMD($\times 10$)/三角判别器($\times 10^3$)

	OmniFold Step 1	cINN	SBUnfold
Jet mass	6.1$\pm$0.1/1.5	10.1 $\pm$ 1.2/2.4	9.0 $\pm$ 0.1/3.1
Jet Width	0.06 $\pm$ 0.001/1.1	0.05 $\pm$ 0.003/0.7	0.02$\pm$0.001/0.2
N	1.7$\pm$0.1/0.2	6.1 $\pm$ 4.0/0.2	3.0 $\pm$ 0.1/0.6
$\log \rho$	1.35 $\pm$ 0.03/1.1	3.1 $\pm$ 2.1/0.8	0.4$\pm$0.1/0.7
z_g	0.086 $\pm$ 0.001/1.2	0.3 $\pm$ 0.1/12.7	0.049$\pm$0.001/3.5
τ_{21}	0.23 $\pm$ 0.02/4.6	0.7 $\pm$ 0.4/3.5	0.12$\pm$0.02/1.4

展开观测量。展示 SBUnfold 学会对重建事件施加小幅修正的结果见附录 B。OmniFold 也是唯一利用数据统计能力来确定展开分布的算法。我们研究了当可用数据条目数从之前使用的 60 万条减少到仅 1000 条时，展开结果如何变化。对于 SBUnfold 和 cINN，这一变化仅改变了训练模型生成的样本数量，而 OmniFold 在训练期间只能访问 1000 个数据示例，同时 Pythia 样本数量保持不变，仍为 100 万。展开结果如图 4 所示。由于数据条目较少，我们观察到展开结果的统计波动更大，但与预期量相比仍显示出良好的一致性。我们通过计算 EMD 和三角判别器进一步评估展开结果，结果列于表 III。SBUnfold 和 cINN 的报告结果受数据量减少的影响较小，尽管由于伪数据示例有限，EMD 的不确定性大幅增加。另一方面，OmniFold 与之前相比表现出更严重的退化

在所有观测量上均达到相近性能，特别是 OmniFold 在粒子多重数上表现出改进的性能，粒子多重数并非连续分布，因此生成模型更难精确确定。本文还研究了 SBUnfold 如何通过计算重建事件与生成器级事件之间的迁移矩阵，将物理观测量校正回生成器级事件。




图 2. 使用 cINN (左) 或 SBUnfold (右) 算法时所有展开变量之间的成对相关性图。

表 III. 不同算法之间推土机距离 (EMD) 和三角判别器的比较。EMD 在未分箱分布上计算, 而三角判别器使用直方图作为输入。EMD 的不确定性通过从展开数据中进行 100 次有放回自助抽样得出。结果使用从 Herwig 采样的 1000 个伪数据点进行评估。粗体表示性能最佳的方法。模型 EMD ($\times 10$) / 三角判别器 ($\times 10^3$)

OmniFold Step 1 cINN SBUnfold 喷注质量 $8.7 \pm 1.8 / 13.6$
 $9.2 \pm 3.0 / 8.4$ **$7.7 \pm 2.5 / 6.9$** 喷注宽度 $0.14 \pm 0.02 / 18$
 $0.07 \pm 0.02 / 5.7$ **$0.05 \pm 0.02 / 4.6$** N $12 \pm 3 / 10.9$ **$5.4 \pm 1.3 / 3.8$**
 $5.8 \pm 1.6 / 3.7$ $\log \rho$ $4.0 \pm 0.8 / 11$ $1.6 \pm 0.5 / 6.2$ **$1.2 \pm 0.3 / 4.4$**
 z_g $0.08 \pm 0.02 / 1.5$ $0.08 \pm 0.03 / 7.2$ **$0.06 \pm 0.01 / 7.1$** τ_{21}
 $0.4 \pm 0.07 / 16$ $0.2 \pm 0.05 / 12$ **$0.1 \pm 0.04 / 8$**

Jet mass	$8.7 \pm 1.8 / 13.6$	$9.2 \pm 3.0 / 8.4$	$7.7 \pm 2.5 / 6.9$
Jet Width	$0.14 \pm 0.02 / 18$	$0.07 \pm 0.02 / 5.7$	$0.05 \pm 0.02 / 4.6$
N	$12 \pm 3 / 10.9$	$5.4 \pm 1.3 / 3.8$	$5.8 \pm 1.6 / 3.7$
$\log \rho$	$4.0 \pm 0.8 / 11$	$1.6 \pm 0.5 / 6.2$	$1.2 \pm 0.3 / 4.4$
z_g	$0.08 \pm 0.02 / 1.5$	$0.08 \pm 0.03 / 7.2$	$0.06 \pm 0.01 / 7.1$
τ_{21}	$0.4 \pm 0.07 / 16$	$0.2 \pm 0.05 / 12$	$0.1 \pm 0.04 / 8$

结果, EMD 值经常偏离超过两个标准差。

五、结论与展望

本文提出了 SBUnfold, 一种利用薛定谔桥 (SB) 设计分布间随机映射的展开算法。由于 SB 允许任意分布之间的传输⁵, SBUnfold 不需要类似的可处理先验

其他生成模型, 而是利用扩散过程直接从探测器效应中去除物理观测量的噪声。我们使用合成 Z + 喷注样本展示了 SBUnfold 的性能, 并与使用生成模型 (cINN) 和重加权 (OmniFold) 的最先进方法进行了比较。通过不同度量, 我们观察到 SBUnfold 具有出色的性能。与 cINN 相比, SBUnfold 在具有尖锐特征的分布上表现出更高的保真度, 且总体不确定性更小, 这可能是由于重建级事件提供了更具信息量的先验。与 OmniFold 相比, SBUnfold 在可用数据观测数量变化时表现出更稳健的性能, 在可用数据量减少的情况下显示出有前景的结果。我们仅研究了不同展开算法的期望步骤, 将最大化步骤留待未来研究。我们注意到 IcINN 使用的基于分类器的最大化步骤也适用于 SBUnfold, 比较两种算法在后续迭代中展开结果的改进将是有趣的。最后, 与 OmniFold 类似, SBUnfold 可以轻松适应不同的数据结构, 如图像类数据集。另一方面, 扩散过程目前依赖于展开过程中使用的特征的特定顺序 (见公式 8), 这使得 SBUnfold 在低层级特征 (如

⁵ 我们的薛定谔桥并非通用函数逼近器; 它可将分布相互映射, 但可能无法保持条件概率密度 [31]。我们的数值结果表明这并非问题, 我们期望单调

探测器畸变属于薛定谔桥能够适应的函数类别, 但我们将进一步的研究留待未来工作。我们感谢 Jesse Thaler 就此观点进行的有益讨论。




图 3. 不同展开算法在六个不同物理观测量上的比较。所有观测量同时展开，无需分箱，直方图仅用于评估。结果基于 600,000 个伪数据点进行评估。统计不确定性仅在比值面板中显示。伪数据取自 Herwig，而 Pythia 作为主模拟器。

如粒子，并非易事。后续研究将探讨如何在 SBUnfold 中适应置换不变性。

代码可用性

本文代码可在
<https://github.com/ViniciusMikuni/SBUnfold>
 获取。

致谢

感谢 Daniel Whiteson、Tilman Plehn 和 Jesse Thaler 对手稿提出的深刻讨论与反馈。VM、SD 和 BN 受

美国能源部 (DOE) 科学办公室

合同 DE-AC02-05CH11231 资助。GHL 感谢 Evangelos Theodorou 的有益讨论。本研究使用了国家能源研究科学计算中心的资源，该中心是美国能源部科学办公室用户设施，由美国能源部科学办公室根据合同 DE-AC02-05CH11231 支持，使用 NERSC 奖项 HEP-ERCAP0021099。

附录 A：与标准扩散模型的比较

本文研究了使用 SBUnfold 相对于标准扩散模型的优势。扩散模型实现遵循 [58] 中提出的用于喷注运动学生成的 FPCD 模型。骨干神经网络架构与 SBUnfold 中使用的相同。同样，学习率、训练轮次和训练样本在两个模型之间保持一致。实现之间的主要概念差异在于 SBUnfold 从重建级事件开始，而不是 FPCD 中使用的高斯先验。与 cINN 实现类似，FPCD 模型仅以重建级事件为条件来确定展开响应。使用 Pythia 同时作为伪数据和仿真得到的展开分布结果如图 5 所示。对于所有分布，我们观察到展开结果与伪数据之间具有良好的一致性。在表 IV 中，我们使用不同方法获得的展开分布计算了 EMD 和三角判别器。从结果中我们观察到 FPCD 通常优于




图 4. 不同展开算法在六个不同物理观测量上的比较。所有观测量同时展开，无需分箱，直方图仅用于评估。结果在 1000 个伪数据点上评估，OmniFold 使用相同数量的数据点进行训练，而其他算法仅依赖仿真。统计不确定性仅在比值面板中显示。伪数据取自 Herwig，而 Pythia 作为主仿真器。

表四：不同展开方法之间推土机距离（EMD）与三角判别器的比较。EMD 在未分箱分布上计算，而三角判别器以直方图作为输入。EMD 的不确定性通过从展开数据中进行 100 次有放回自助抽样得出。结果使用从 Pythia 采样的 600,000 个伪数据点进行评估。粗体表示性能最佳的方法。模型 EMD ($\times 10$)/三角判别器 ($\times 10^3$)

	FPCD	cINN	SBUNFOLD
Jet mass	$0.74 \pm 0.08 / \mathbf{0.19}$	$1.4 \pm 0.2 / 0.29$	$\mathbf{0.70 \pm 0.06 / 0.30}$
Jet Width	$0.0087 \pm 0.0006 / 0.9$	$0.013 \pm 0.002 / 0.25$	$\mathbf{0.0029 \pm 0.0005 / 0.04}$
N	$0.81 \pm 0.06 / 0.1$	$2.3 \pm 0.8 / \mathbf{0.09}$	$\mathbf{0.57 \pm 0.04 / 0.9}$
$\log \rho$	$0.34 \pm 0.01 / 0.77$	$1.1 \pm 0.3 / \mathbf{0.64}$	$\mathbf{0.27 \pm 0.01 / 0.68}$
z_g	$0.035 \pm 0.007 / 12.4$	$0.095 \pm 0.003 / 10.9$	$\mathbf{0.009 \pm 0.001 / 3.1}$
τ_{21}	$0.024 \pm 0.002 / 0.3$	$0.2 \pm 0.1 / 0.6$	$\mathbf{0.016 \pm 0.001 / 0.2}$

在 EMD 度量上形成了 cINN，但仍未达到与 SBUnfold 相同的性能水平。这些结果表明，标准扩散模型可能比原始 cINN 中实现的归一化流模型更具表达力，但仍不如 SBUnfold 精确，后者利用了来自重建级对象的更具信息量的先验分布，而非 cINN 和 FPCD 所需的高斯先验。

附录 B：展开事件的迁移矩阵

在本附录中，我们通过使用 Herwig 作为伪数据、探测器响应由 Pythia 仿真推导，计算相应的迁移矩阵，研究 SBUnfold 如何将重建级分布映射回生成器级样本。分布如图 6 所示。

所有观测量的迁移矩阵在对角线附近具有高比例的事件，这与 SBUnfold 学习仅应用小修正一致




图 5: 不同展开算法在六个不同物理观测量上的比较。结果在 600,000 个伪数据点上评估。统计不确定性仅在比率面板中显示。伪数据和仿真由 Pythia 描述。

对输入。

- [1] A. Glazov, (2017), [arXiv:1712.01814 \[physics.data-an\]](#).
 [2] K. Datta, D. Kar, and D. Roy, (2018), [arXiv:1806.00433 \[physics.data-an\]](#).
 [3] M. Bunse, N. Piatkowski, T. Ruhe, W. Rhode, and K. Morik, in *5th International Conference on Data Science and Advanced Analytics (DSAA)* (IEEE, 2018) pp. 21–30.
 [4] T. Ruhe, T. Voigt, M. Wornowizki, M. Börner, W. Rhode, and K. Morik (2019).
 [5] A. Andreassen, P. T. Komiske, E. M. Metodiev, B. Nachman, and J. Thaler, *Phys. Rev. Lett.* **124**, 182001 (2020), [arXiv:1911.09107 \[hep-ph\]](#).
 [6] M. Bellagente, A. Butter, G. Kasieczka, T. Plehn, and [arXiv:1912.00477 \[hep-ph\]](#).
 [7] M. Bellagente, A. Butter, G. Kasieczka, T. Plehn, A. Rousselot, and R. Winterhalder, (2020), [10.21468/SciPostPhys.9.5.074](#), [arXiv:2006.06685 \[hep-ph\]](#).
 [8] M. Vandegar, M. Kagan, A. Wehenkel, and G. Louppe, (2020), [arXiv:2011.05836 \[stat.ML\]](#).
 [9] A. Andreassen, P. T. Komiske, E. M. Metodiev, B. Nachman, A. Suresh, and J. Thaler, (2021), [arXiv:2105.04448 \[统计机器学习 \(stat.ML\)\]](#). [10] J. N. Howard, S. Mandt, D. Whiteson 和 Y. Yang, 《科学报告》 **12**, 7567 (2022), [arXiv:2101.08944 \[高能物理-现象学 \(hep-ph\)\]](#). [11] M. Backes, A. Butter, M. Dunford 和 B. Malaescu, (2022), [arXiv:2212.08674 \[高能物理-现象学 \(hep-ph\)\]](#). [12] M. Arratia, D. Britzger, O. Long 和 B. Nachman, 《仪器学报》 **17**, P07009 (2022), [arXiv:2203.16722 \[高能物理-实验 \(hep-ex\)\]](#). [13] J. Chan 和 B. Nachman, 《物理评论 D》 **108**, 016002 (2023), [arXiv:2302.05390 \[高能物理-现象学 \(hep-ph\)\]](#). [14] A. Shmakov, K. Greif, M. Fenton, A. Ghosh, P. Baldi 和 D. Whiteson, (2023), [arXiv:2305.10399 \[高能物理-实验 \(hep-ex\)\]](#). [15] T. Alghamdi 等人, (2023), [arXiv:2307.04450 \[高能物理-现象学 \(hep-ph\)\]](#). [16] M. Arratia 等人, (2021), [arXiv:2109.13243 \[高能物理-现象学 \(hep-ph\)\]](#). [17] V. Andreev 等人 (H1), 《物理评论快报》 **128**, 132002 (2022), [arXiv:2108.12376 \[高能物理-实验 \(hep-ex\)\]](#). [18] H1 合作组, [arXiv:2203.13620 \[高能物理实验 \(hepex\)\]](#). [19] V. Andreev 等人 (H1), (2023), [arXiv:2303.13620 \[高能物理实验 \(hepex\)\]](#). [20] H1 合作组, H1prelim-23-031 (2023). [21] (2022), [arXiv:2208.11691 \[高能物理-实验 \(hep-ex\)\]](#). [22] P. T. Komiske, S. Kryhin 和 J. Thaler, 《物理评论 D》 **106**, 094021 (2022), [arXiv:2205.04459 \[高能物理-现象学 \(hep-ph\)\]](#). [23] Y. Song (STAR), (2023), [arXiv:2307.07718 \[核物理-实验 \(nucl-ex\)\]](#).




图 6. 使用 SBUnfold 展开后重建级事件与生成器级分布之间的迁移分布。结果基于 600,000 个伪数据点评估。伪数据取自 Herwig, 而 Pythia 作为主模拟器。

- [24] L. B. Lucy, *Astronomical Journal* **79**, 745 (1974).
 [25] W. H. Richardson, *J. Opt. Soc. Am.* **62**, 55 (1972).
 [26] G. D'Agostini, *Nucl. Instrum. Meth.* **A362**, 487 (1995).
 [27] D. J. Rezende and S. Mohamed, *Proceedings of Machine Learning Research*, **37**, 1530 (2016), [arXiv:1505.05770 \[stat.ML\]](#).
 [28] I. J. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville 和 Y. Bengio, (2014), [arXiv:1406.2661 \[统计机器学习 \(stat.ML\)\]](#). [29] Y. Song, J. Sohl-Dickstein, D. P. Kingma, A. Kumar, S. Ermon 和 B. Poole, *ArXiv abs/2011.13456* (2021). [30] E. Schrödinger, 《普鲁士科学院会议报告. 物理数学类》特刊 **9**, 144 (1931).
 [31] G.-H. Liu, A. Vahdat, D.-A. Huang, E. A. Theodorou, W. Nie 和 A. Anandkumar, *arXiv 预印本 arXiv:2302.05872* (2023). [32] J. Ho, A. Jain 和 P. Abbeel, 载于《神经信息处理系统进展》, 第 33 卷, 由
 H. Larochelle, M. Ranzato, R. Hadsell, M. Balcan 和 H. Lin (Curran Associates, Inc., 2020) pp. 6840–6851.
 [33] G. Peyré, M. Cuturi, *et al.*, *Foundations and Trends® in Machine Learning* **11**, 355 (2019).
 [34] A. Andreassen, P. Komiske, E. Metodiev, B. Nachman, and J. Thaler, “Pythia/Herwig + Delphes Jet Datasets for OmniFold Unfolding,” (2019).
 [35] M. Bahr *et al.*, *Eur. Phys. J.* **C58**, 639 (2008), [arXiv:0803.0883 \[hep-ph\]](#).
 [36] J. Bellm *et al.*, *Eur. Phys. J.* **C76**, 196 (2016), [arXiv:1512.01178 \[hep-ph\]](#).
 [37] J. Bellm *et al.*, (2017), [arXiv:1705.06919 \[hep-ph\]](#).
 [38] *ATLAS Run 1 Pythia8 tunes*, Tech. Rep. ATL-PHYS-PUB-2014-021 (CERN, Geneva, 2014).
 [39] T. Sjöstrand, S. Mrenna, and P. Z. Skands, *Comput. Phys. Commun.* **178**, 852 (2008), [arXiv:0710.3820 \[hep-ph\]](#).
 [40] T. Sjöstrand, S. Mrenna, and P. Z. Skands, *JHEP* **05**, 026 (2006), [arXiv:hep-ph/0603175 \[hep-ph\]](#).
 [41] T. Sjöstrand, S. Ask, J. R. Christiansen, R. Corke, N. Desai, P. Ilten, S. Mrenna, S. Prestel, C. O. Rasmussen, and P. Z. Skands, 《计算机物理通讯》**191**, 159 (2015), [arXiv:1410.3012 \[hep-ph\]](#).
 [42] J. de Favereau, C. Delaere, P. Demin, A. Giammanco, V. Lemaitre, A. Mertens 和 M. Selvaggi (DELPHES 3), 《高能物理杂志》**02**, 057 (2014), [arXiv:1307.6346 \[高能物理实验\]](#). [43] M. Cacciari, G. P. Salam 和 G. Soyez, 《高能物理杂志》**04**, 063 (2008), [arXiv:0802.1189 \[高能物理唯象学\]](#). [44] M. Cacciari, G. P. Salam 和 G. Soyez, 《欧洲物理杂志 C》**72**, 1896 (2012), [arXiv:1111.6097 \[高能物理唯象学\]](#). [45] M. Cacciari 和 G. P. Salam, 《物理快报 B》**641**, 57 (2006), [arXiv:高能物理唯象学/0512210 \[高能物理唯象学\]](#). [46] J. Thaler 和 K. Van Tilburg, 《高能物理杂志》**03**, 015 (2011), [arXiv:1011.2268 \[高能物理唯象学\]](#). [47] J. Thaler 和 K. Van Tilburg, 《高能物理杂志》**02**, 093 (2012), [arXiv:1108.2701 \[高能物理唯象学\]](#). [48] A. J. Larkoski, S. Marzani, G. Soyez 和 J. Thaler,

《高能物理杂志》**05**, 146 (2014), [arXiv:1402.2657](#) [高能物理-现象学]。[49] M. Dasgupta, A. Fregoso, S. Marzani 和 G. P. Salam, 《高能物理杂志》**09**, 029 (2013), [arXiv:1307.0007](#) [高能物理-现象学]。[50] “Fastjet 贡献”, <https://fastjet.hepforge.org/contrib/>。[51] K. He, X. Zhang, S. Ren 和 J. Sun, 载于《IEEE 计算机视觉与模式识别会议论文集》(2016) 第 770 – 778 页。[52] B. Xu, N. Wang, T. Chen 和 M. Li, CoRR [abs/1505.00853](#) (2015), **1505.00853**。[53] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury,

G. Chanan, T. Killeen, Z. Lin, N. Gimelshein, L. Antiga, 等人, 神经信息处理系统进展 **32** (2019)。[54] M. Abadi, P. Barham, J. Chen, Z. Chen, A. Davis,

J. Dean, M. Devin, S. Ghemawat, G. Irving, M. Isard, 等人, 载于《OSDI》, 第 16 卷 (2016) 第 265 – 283 页。[55] F. Topsøe, 《IEEE 信息论汇刊》**46**, 1602 (2000)。[56] P. Gras, S. Höche, D. Kar, A. Larkoski, L. Lönnblad, S. Plätzer, A. Siódmok, P. Skands, G. Soyez 和 J. Thaler, 《高能物理杂志》**07**, 091 (2017), [arXiv:1704.03878](#) [高能物理-唯象学]。[57] S. Bright-Thonney 和 B. Nachman, 《高能物理杂志》**03**, 098 (2019), [arXiv:1810.05653](#) [高能物理-唯象学]。[58] V. Mikuni, B. Nachman 和 M. Pettee, 《物理评论 D》**108**, 036025 (2023)。