

广义薛定谔桥匹配

Guan-Hong Liu^{1*}, Yaron Lipman^{2,3}, Maximilian Nickel³, Brian Karrer³,
Evangelos A. Theodorou¹, Ricky T. Q. Chen³

¹Georgia Institute of Technology ²Weizmann Institute of Science ³FAIR, Meta
{ghliu, evangelos.theodorou}@gatech.edu
{ylipman, maxn, briankarrer, rtqichen}@meta.com

摘要

现代用于训练扩散模型或流模型的分布匹配算法直接规定了两个边界分布之间边际分布的时间演化。本文考虑一种广义分布匹配设置，其中这些边际分布仅作为某个任务特定目标函数的解被隐式描述。该问题设置被称为广义薛定谔桥（GSB），在机器学习内外的许多科学领域中普遍存在。我们提出广义薛定谔桥匹配（GSBM），这是一种受近期进展启发的新匹配算法，将其推广到超越动能最小化并考虑任务特定的状态代价。我们证明这种推广可以转化为求解条件随机最优控制，对此可以使用高效的变分近似，并进一步借助路径积分理论进行去偏。与先前求解 GSB 问题的方法相比，我们的 GSBM 算法在训练过程中更好地保持了边界分布之间的可行传输映射，从而实现稳定收敛并显著提高可扩展性。我们在大量实验设置上实证验证了我们的主张，包括人群导航、观点去极化、激光雷达流形和图像域迁移。我们的工作为训练具有任务特定最优性结构的扩散模型带来了新的算法机会。代码可在 <https://github.com/facebookresearch/generalized-schrodinger-bridge-matching> 获取

1 引言

分布匹配问题——学习匹配特定分布的传输映射——是机器学习许多领域中普遍存在的问题设置，在最优传输（Peyré & Cuturi, 2017）、领域自适应（Wang & Deng, 2018）和生成建模（Sohl-Dickstein et al., 2015; Chen et al., 2018）中有广泛应用。这些任务通常被表述为学习映射 $X_0 \mapsto X_1$ ，使得 $X_0 \sim \mu, X_1 \sim \nu$ 遵循两个分布 μ, ν 的（未知）规律。例如，扩散模型¹将映射构造为随机微分方程（SDE）的解，其漂移项 $u_t^\theta(X_t) : \mathbb{R}^d \times [0, 1] \rightarrow \mathbb{R}^d$ 由 θ 参数化：

$$dX_t = u_t^\theta(X_t)dt + \sigma dW_t, \quad X_0 \sim \mu, X_1 \sim \nu. \quad (1)$$

由 (1) 式诱导的边际密度 p_t 按照福克-普朗克方程（FPE; Risken (1996)）演化：

$$\frac{\partial}{\partial t} p_t(X_t) = -\nabla \cdot (u_t^\theta(X_t) p_t(X_t)) + \frac{\sigma^2}{2} \Delta p_t(X_t), \quad p_0 = \mu, p_1 = \nu, \quad (2)$$

并且规定 p_t 与固定的 σ 唯一地确定了 (1) 中的一族参数化随机微分方程。事实上，扩散模型在合成高保真数据方面的现代成功（Song 等人, 2021; Dhariwal 和 Nichol, 2021）部分归因于将 p_t 构造为可处理的条件概率路径的混合（Liu 等人, 2023b; Albergo 等人, 2023; Tong 等人, 2023）。这些可处理性使得可扩展的算法能够“在给定 p_t 的情况下匹配 u^θ 和 σ ”，以下称为匹配算法^{*}。部分工作是在 Meta 的 FAIR 担任研究实习生期间完成的。¹我们在全文中采用常数 $\sigma \in \mathbb{R}$ ，但指出所有分析均可推广到时间依赖的 σ_t 。

或者，也可以将 p_t 隐式地指定为某个目标函数的最优解，例如最优传输（OT；Villani 等人（2009）），或薛定谔桥问题（SB；薛定谔（1931）；Fortet（1940）；De Bortoli 等人（2021））。SB 将标准扩散模型推广到任意 μ 和 ν ，并具有完全非线性的随机过程，并且在所有匹配 μ 和 ν 之间可能的随机微分方程中，寻求使动能最小化的唯一 u_t 。

虽然寻找动能最小的传输可以从统计物理或熵正则化最优传输（Peyré 和 Cuturi, 2019；Vargas 等人, 2021）中得到动机，并且动能通常与生成建模中的采样效率相关（Chen 等人, 2022；Shaul 等人, 2023），但它仍然限制了“最优性”设计的灵活性。事实上，动能对应于最优传输中的平方欧几里得代价，尽管它很流行，但仅仅是众多可供部署的替代方案之一（Di Marino 等人, 2017）。一方面，在原始数据空间（例如图像的像素空间）中定义的 ℓ_2 距离，与其他度量相比，是否最适合量化传输映射的最优性，仍然存在争议。另一方面，在一般科学领域中的分布匹配，例如群体建模（Ruthotto 等人, 2020）、机器人导航（Liu 等人, 2018）或分子模拟（Noé 等人, 2020），通常涉及更复杂的最优性条件，需要更通用的算法来处理。

为此，我们提倡一种广义的分布匹配设置，先前作为广义薛定谔桥问题（GSB；Chen 等人（2015）；Chen（2023）；Liu 等人（2022））引入：

$$\min_{\theta} \int_0^1 \mathbb{E}_{p_t} \left[\frac{1}{2} \|u_t^\theta(X_t)\|^2 + V_t(X_t) \right] dt \quad \text{subject to (1) or, equivalently, (2).} \quad (3)$$

GSB 是一个分布匹配问题——它仍然寻求一个扩散模型（1），该模型将 μ 传输到 ν 。然而，与标准 SB 相比，GSB 的目标涉及额外的状态成本 V_t ，该成本通过量化惩罚（或等价地，奖励）来影响解，类似于一般决策问题。该状态成本还可以包含随机变量 X_t 的分布性质。 V_t 的例子包括，例如，观点传播中的平均场交互（Gaitonde et al., 2021）、量子势（Philippidis et al., 1979）或几何先验。

求解 GSB 问题涉及处理两个不同的方面：最优性（3）和可行性（2）。在满足（2）的可行解集合中，GSB 将（3）中目标值最低的解视为最优解。因此，开发在可行集内搜索最优解的算法至关重要。不幸的是，现有的近似求解（3）的方法要么需要放宽可行性（Koshizuka & Sato, 2023），要么遵循 Sinkhorn 算法的设计（Cuturi, 2013），优先考虑最优性而非可行性。虽然针对 SB（即当 $V_t := 0$ 时）已经开发了一系列令人兴奋的新匹配算法（Peluchetti, 2023; Shi et al., 2023），以确保解在训练过程中接近可行集，但这些“SB 匹配”（SBM）算法是否能够以及如何扩展到处理非平凡的 V_t ，仍然不清楚。

我们提出广义薛定谔桥匹配（GSBM），这是一种新的匹配算法，将 SBM 推广到非平凡的 V_t 。我们讨论这种推广如何与条件随机最优控制（CondSOC）问题相关联，现有的 SBM 算法可以作为其特例推导出来。我们利用高斯路径近似开发了可扩展的 CondSOC 求解器，并进一步通过路径积分理论（Kappen, 2005）进行去偏。GSBM 继承了其前身（Liu et al., 2023b; Shi et al., 2023）类似的算法特征，即在优化过程中，由后续 u_t^θ 的解所诱导的学习到的 $p^{\theta 0}$ 和 $p^{\theta 1}$ 保持接近边界边缘分布 (μ, ν) ，并在更严格的理论条件下精确保持它们；详见第 3.1 节。这使得 GSBM 区别于先前的方法（例如 Liu et al. (2022)），后者学习同一问题（3）的近似解，但其后续解仅在最终收敛后才接近 (μ, ν) 。这进一步形成了一个仅依赖于 μ, ν 的样本——无需知道其密度——并享有稳定收敛的框架，使其适用于高维应用。关于与随机最优控制及相关工作（Liu et al., 2022）联系的说明见附录 A。总结而言，我们提出以下贡献：

- 我们提出 GSBM，这是一种新的匹配算法，用于学习两个分布之间的扩散模型，同时通过指定 V_t 来尊重（3）中某些任务特定的最优性结构。
- GSBM 将最近的匹配方法转化为条件随机最优控制问题，从中可以纳入非平凡的 V_t ，并通过高斯路径近似在大规模上求解。

Algorithm 1 <code>match</code> (implicit)	Algorithm 2 <code>match</code> (explicit)
Require: p_t s.t. $p_0 = \mu, p_1 = \nu$ repeat Sample $X_0 \sim p_0, X_t \sim p_t, X_1 \sim p_1$ Take gradient step w.r.t. $\mathcal{L}_{\text{implicit}}(\theta)$ until converges return $\nabla s_t^{\theta^*}$	Require: $p_t := \mathbb{E}_{p_{0,1}}[p_{t 0,1}]$ s.t. $p_0 = \mu, p_1 = \nu, u_{t 0,1}$ repeat Sample $X_0, X_1 \sim p_{0,1}, X_t \sim p_{t 0,1}$ Compute $u_{t 0,1}$ given (X_0, X_t, X_1) Take gradient step w.r.t. $\mathcal{L}_{\text{explicit}}(\theta)$ until converges return $u_t^{\theta^*}$

- 与先前的方法（例如 Liu et al. (2022)）相比，后者也提供 (3) 的近似解，GSBM 享有稳定的收敛性、改进的可扩展性，并且关键的是，在整个训练过程中保持一个更接近分布边界的传输映射。
- 通过大量实验，我们展示了 GSBM 在各种分布匹配问题上的卓越能力，从标准的群体导航和激光雷达流形上的 3D 导航，到高维观点建模和非配对图像翻译。

2 预备知识：给定概率路径的匹配扩散模型

如第 1 节所述，匹配算法的目标是学习一个由 u_t^θ 参数化的随机微分方程，使其福克-普朗克方程 (2) 对所有 $t \in [0, 1]$ 匹配某个给定的边缘分布 p_t 。本节回顾两类匹配算法，它们将在本文提出的广义薛定谔桥匹配方法的发展中发挥关键作用。

熵作用匹配（隐式）。这是一种近期提出的匹配方法（Neklyudov 等, 2023），它学习由 p_t 规定的福克-普朗克方程所支配的唯一梯度场。具体而言，设 $s_t^\theta(X_t) : \mathbb{R}^d \times [0, 1] \rightarrow \mathbb{R}$ 为一个参数化函数，则唯一梯度场 $\nabla s_t^\theta(X_t)$ ——通过该梯度场，从 μ 在时间 0 到 t 的前推概率密度与 p_t 匹配——最小化

$$\mathcal{L}_{\text{implicit}}(\theta) := \mathbb{E}_\mu [s_0^\theta(X_0)] - \mathbb{E}_\nu [s_1^\theta(X_1)] + \int_0^1 \mathbb{E}_{p_t} \left[\frac{\partial s_t^\theta}{\partial t} + \frac{1}{2} \|\nabla s_t^\theta\|^2 + \frac{\sigma^2}{2} \Delta s_t^\theta \right] dt. \quad (4)$$

Neklyudov et al. (2023) showed that $\mathcal{L}_{\text{implicit}}(\theta)$ *implicitly matches* a unique gradient field ∇s_t^* with least kinetic energy, i.e., it is equivalent to minimizing $\int_0^1 \mathbb{E}_{p_t} [\frac{1}{2} \|\nabla s_t^\theta - \nabla s_t^*\|^2] dt$, where

$$\nabla s_t^* = \arg \min_{u_t} \int_0^1 \mathbb{E}_{p_t} \left[\frac{1}{2} \|u_t(X_t)\|^2 \right] dt \text{ subject to (2)}.$$

桥接与流匹配（显式）。如果 p_t 可以分解为 $p_t := \mathbb{E}_{p_{0,1}}[p_t(X_t|x_0, x_1)]$ ，其中条件密度 $p_t(X_t|x_0, x_1)$ ——简写为 $p_{t|0,1}$ ——与一个随机微分方程 (SDE) $dX_t = u_t(X_t|x_0, x_1)dt + \sigma dW_t$ 相关联，那么可以证明（Lipman 等人, 2023；Albergo 和 Vanden-Eijnden, 2023；Liu 等人, 2023a），其最小化器为（推导见附录 C.1）

$$\mathcal{L}_{\text{explicit}}(\theta) := \int_0^1 \mathbb{E}_{p_{0,1}} \mathbb{E}_{p_{t|0,1}} \left[\frac{1}{2} \|u_t^\theta(X_t) - u_t(X_t|x_0, x_1)\|^2 \right] dt, \quad (5)$$

与 $\nabla s_t^{\theta^*}$ 类似，也满足 p_t 所规定的 FPE。换言之， $u_t^{\theta^*}$ 对所有 t 保持 p_t 。

隐式与显式匹配损失相比。虽然熵作用匹配（Entropic Action Matching）提出了一种假设最少的一般匹配方法，但其隐式匹配损失 $\mathcal{L}_{\text{implicit}}$ (4) 在高维应用中扩展性不佳，因为需要近似拉普拉斯算子（例如使用 Hutchinson (1989)），并且在受限函数族（如深度神经网络）上优化时会引入无法量化的偏差。显式匹配损失 $\mathcal{L}_{\text{explicit}}$ (5) 提供了一种计算高效的替代方案，但需要额外信息，即 $u_t(X_t|x_0, x_1) \equiv u_{t|0,1}$ 。值得注意的是，在两种情况下，最小化器都保持了规定的边缘分布 p_t 。因此，如果 $p_0 = \mu$ 且 $p_1 = \nu$ ，这些匹配算法将始终返回一个可行的解——一个在 μ 和 ν 之间匹配的扩散模型。我们在算法 1 和算法 2 中总结了上述两种方法。

3 广义薛定谔桥匹配 (GSBM)

本文提出广义薛定谔桥匹配 (GSBM)，这是一种新颖的匹配算法，与第 2 节中假设给定 p_t 的算法不同，它同时优化 p_t 以最小化 (3)，并满足可行性约束 (2)。所有证明见附录 B。

3.1 交替优化方案

让我们重新审视 GSB 问题 (3)，特别是 (2) 中的 FPE 约束。动态最优传输 (Liu 等, 2023b) 和 SB (Peluchetti, 2023) 的最新进展提出将该动力学约束分解为两个部分：边缘 $p_t, t \in (0, 1)$ ，以及边界 $p_{0,1}$ 之间的联合耦合，并在 u_t^θ 和 p_t 之间采用交替优化。具体来说，这些优化方法在很大程度上启发了最近的 SB 匹配变体 (Shi 等, 2023) 和我们的 GSBM，通常遵循以下方案，在两个阶段之间交替：

Stage 1: Optimize the objective, in our case, (3) w.r.t. the drift u_t^θ given fixed $p_{t \in [0,1]}$.

Stage 2: Optimize (3) w.r.t. the marginals $p_{t \in (0,1)}$ given the coupling $p_{0,1}^\theta$ defined by u_t^θ .

特别注意，阶段 1 中提出的优化类似于第 2 节中的匹配算法。我们在以下命题中具体化这一联系：

命题 1 (阶段 1)。阶段 1 的唯一极小值与 $\nabla s_t^*(X_t)$ 一致。

乍一看这可能违反直觉，因为动能和 V_t 都出现在 (3) 中。这是因为一旦 p_t 固定， u_t^θ 不再影响 $\mathbb{E}_{p_t}[V_t(X_t)]$ 的值，而在所有概率密度匹配 p_t 的 u_t^θ 中，梯度场是动能的唯一极小值。² 我们强调，阶段 1 的作用是在给定 p_t 的情况下学习 u_t^θ ，并提供更好的耦合 $p_{0,1}^\theta$ ，然后在阶段 2 中用于细化 p_t 。因此，显式匹配损失 (5) 提供了相同的算法目的。虽然它只是阶段 1 目标的上界，但其解从测度论角度看通常稳定收敛（更多解释见附录 C.1）。在实践中，我们发现 $\mathcal{L}_{\text{explicit}}$ 与 $\mathcal{L}_{\text{implicit}}$ 同样有效，同时显著提高了可扩展性，因此更适合高维应用。

我们现在给出主要结果，表明 GSBM 的阶段 2 可以转化为一个变分问题，其中 V_t 通过优化条件受控过程出现。

命题 2 (第二阶段；条件随机最优控制；CondSOC)。设第二阶段的最小化器可分解为 $p_t(X_t) = \int p_t(X_t|x_0, x_1) p_{0,1}^\theta(x_0, x_1) dx_0 dx_1$ 中 $p_{0,1}^\theta$ 是由求解 (1) 式并给定 u_t^θ 所诱导的边界耦合。则 $p_t(X_t|x_0, x_1) \equiv p_{t|0,1}$ 求解：

$$\min_{u_t|_{0,1}} \mathcal{J} := \int_0^1 \mathbb{E}_{p_t(X_t|x_0, x_1)} \left[\frac{1}{2} \|u_t(X_t|x_0, x_1)\|^2 + V_t(X_t) \right] dt \quad (6a)$$

$$\text{s.t. } dX_t = u_t(X_t|x_0, x_1)dt + \sigma dW_t, \quad X_0 = x_0, \quad X_1 = x_1 \quad (6b)$$

注意，(6) 式与 (3) 式的区别仅在于边界条件，其中原始分布 μ, ν 被由 u_t^θ 诱导的耦合 p_t 所抽取的两个端点 (x_0, x_1) 替代。一般而言，(6) 式的解没有闭式形式，除非在特殊情况下。在引理 3 中，我们展示了当 $V(x)$ 为二次型且 $\sigma > 0$ 时的一种情况。注意，当 $V(x)$ 消失时，引理 3 中的 $p_{t|0,1}$ 退化为布朗桥，GSBM 恢复先前工作中出现的匹配算法 (Liu, 2022; Shi et al., 2023)，这些算法近似 OT/SB，如表 1 所总结。这表明本文的命题 2 直接将它们推广到非平凡的 V_t 。

表 1: 针对不同 V_t 的 (6) 式解，以及它们与不同方法的联系，包括修正流 (Liu et al., 2023b)、DSBM (Shi et al., 2023) 和本文的 GSBM。

Method	$V_t(x)$	$p_t(X_t x_0, x_1)$
RecFlow ($\sigma=0$)	0	straight line (Lemma 3 with $\alpha, \sigma \rightarrow 0$)
DSBM ($\sigma>0$)	0	Brownian bridge (Lemma 3 with $\alpha \rightarrow 0$)
GSBM ($\sigma \geq 0$)	quadratic arbitrary	Lemma 3 Sec. 3.2

² 值得注意的是，优化中缺少 V_t 此前被视为旨在求解 (3) 式的 Sinkhorn 方法的一个问题 (Liu et al., 2022)。然而，在 GSBM 中，它自然地源于优化的分解方式。




图 1: 针对 $\mu_t \in \mathbb{R}^2, \gamma_t \in \mathbb{R}$ 的样条优化 (算法 3) 示例, 以及所得的 CondSOC (6) 式解。

Algorithm 3 SplineOpt

Require: $x_0, x_1, \{X_{t_k}\}$ where $0 < t_1 < \dots < t_K < 1$
Initialize μ_t, γ_t with (9)
for $m = 0$ **to** M **do**
 Sample $X_t^i \sim \mathcal{N}(\mu_t, \gamma_t^2 \mathbf{I}_d)$ with (7)
 Compute $V_t(X_t^i)$ and $u_t(X_t^i|x_0, x_1)$ with (8)
 Estimate the objective $\mathcal{J}$ in (6a)
 Take gradient step w.r.t control pts. $\{X_{t_k}, \gamma_{t_k}\}$
end for
return $p_{t|0,1}$ parametrized by optimized μ_t, γ_t

引理 3 (二次 V 和 $\sigma > 0$). 下 (6) 式的解析解 设 $V(x) := \alpha \|\sigma x\|^2, \alpha, \sigma > 0$, 则 (6) 式的最优解遵循高斯路径 $X_t^* \sim \mathcal{N}(c_t x_0 + e_t x_1, \gamma_t^2 \mathbf{I}_d)$, 其中

$$c_t = \frac{\sinh(\eta(1-t))}{\sinh \eta}, \quad e_t = \cosh(\eta(1-t)) - c_t \cosh \eta, \quad \gamma_t = \sigma \sqrt{\frac{\sinh(\eta(1-t))}{\eta}} e_t, \quad \eta = \sigma \sqrt{2\alpha}.$$

这些系数在 $\alpha \rightarrow 0$ 时恢复布朗桥, 若进一步 $\sigma \rightarrow 0$, 则恢复直线。

3.2 一般非线性状态代价下 CONDSOC 的近似解

当 V_t 既非二次型也非退化时, 我们开发了搜索 (6) 中 CondSOC 近似解的方法。由于我们需要搜索从 $p_{0,1}^\theta$ 中抽取的每一对 (x_0, x_1) , 我们寻求可并行化且无需仿真的高效方法——除了从 $p_{0,1}^\theta$ 中采样之外。

高斯路径近似。 受引理 3 的启发, 并且由于 (6) 的边界条件只是两个固定点, 我们提出将 (6) 的解近似为固定在 x_0, x_1 处的高斯概率路径:

$$p_t(X_t|x_0, x_1) \approx \mathcal{N}(\mu_t, \gamma_t^2 \mathbf{I}_d), \quad \text{s.t.} \quad \mu_0 = x_0, \mu_1 = x_1, \gamma_0 = \gamma_1 = 0, \quad (7)$$

其中 $\mu_t \in \mathbb{R}^d$ 和 $\gamma_t \in \mathbb{R}$ 分别是随时间变化的均值和标准差。由 (7) 直接得到的一个结果是闭式条件漂移 (Särkkä & Solin, 2019) (推导见附录 C.2):

$$u_t(X_t|x_0, x_1) = \partial_t \mu_t + a_t(X_t - \mu_t), \quad \text{其中} \quad a_t := \frac{1}{\gamma_t} \left(\partial_t \gamma_t - \frac{\sigma^2}{2\gamma_t} \right). \quad (8)$$

注意 $a_t \in \mathbb{R}$ 是一个随时间变化的标量。因此, 无论 μ_t, σ_t 多么复杂, 底层随机微分方程 (具有 (8) 中的条件漂移 $u_t(X_t|x_0, x_1)$) 仍然是线性的。还要注意, 这个漂移由于是一个梯度场, 是所有生成 $p_t(X_t|x_0, x_1)$ 的漂移中动力学最优的选择。

样条优化。 为了便于高效优化, 我们将 μ_t, σ_t 分别参数化为 d 和一维样条, 其中控制点 $X_{t_k} \in \mathbb{R}^d$ 和 $\gamma_{t_k} \in \mathbb{R}$ 沿时间步 $0 < t_1 < \dots < t_K < 1$ 稀疏且均匀地采样:

$$\mu_t := \text{Spline}(t; x_0, \{X_{t_k}\}, x_1) \quad \gamma_t := \text{Spline}(t; \gamma_0=0, \{\gamma_{t_k}\}, \gamma_1=0). \quad (9)$$

注意, (9) 中的参数化满足 (7) 中的边界条件, 因此无论 $\{X_{t_k}, \gamma_{t_k}\}$ 如何变化, 它仍然是 (6b) 的一个可行解。控制点的数量 K 远小于离散化步数 (所有实验中 $K \leq 30$)。与之前需要缓存整个离散化随机微分方程的工作 (Liu 等人, 2022) 相比, 这显著降低了内存复杂度。

算法 3 总结了样条优化过程, 关键的是, 该过程不涉及对随机微分方程 (6b) 的仿真。这是因为我们仅使用来自 $p_{t|0,1}$ 的独立样本进行优化, 而这些样本具有已知的闭式形式。由于条件随机最优控制问题将分布边界约束放宽为仅两个端点, 我们计算高效的变分近似在实践中表现非常好。此外, 由于我们只需要优化极少的样条参数, 我们发现没有必要考虑摊销变分推断 (Kingma & Welling, 2014)。最后, 注意由于我们针对每一对 $(x_0, x_1) \sim p_{0,1}^\theta$ 求解条件随机最优控制问题, 并在之后进行边缘化以构造 p_t , 我们无需

Algorithm 5 Generalized Schrödinger Bridge Matching (GSBM)

```

1: Initialize  $u_t^\theta$  and set  $p_t$  as the solution to (6) with independent coupling  $p_{0,1} := \mu \otimes \nu$ 
2: repeat
3:    $u_t^\theta \leftarrow \text{match}(p_t) \text{ or } \text{match}(p_t, u_{t|0,1})$  ▷ Alg. 1 or 2
4:   Sample  $X_0, X_1, X_{t_k}$  from  $u_t^\theta$  on timesteps  $0 < t_1 < \dots < t_K < 1$ 
5:   Optimize  $p_{t|0,1}, \mu_t, \gamma_t \leftarrow \text{SplineOpt}(X_0, X_1, \{X_{t_k}\})$  ▷ Alg. 3
6:   Determine  $u_{t|0,1}$  from  $\mu_t, \gamma_t$  using (8)
7:   if apply path integral resampling then ▷ optional step
8:      $p_{t|0,1} \leftarrow \text{ImptSample}(p_{t|0,1})$  ▷ Alg. 4
9:   end if
10: until converges

```

显式地考虑 $p_{t|0,1}$ 的混合解，只要我们采样足够多的 (x_0, x_1) 对即可。在实践中，我们从 u_t^θ ,³ 初始化 $\{X_{t_k}\}$ ，并从布朗桥的标准差初始化 $\gamma_{t_k} := \sigma \sqrt{t_k(1-t_k)}$ 。图 1 展示了一个二维示例。

使用路径积分理论进行重采样。在高斯概率路径族不足以建模 (6) 的解的情况下，一种更严格的方法涉及路径积分理论 (Kappen, 2005)，该理论为给定任何具有足够支撑的采样分布时 (6) 的最优密度提供了解析表达式。我们在以下命题中讨论这一点。

命题 4 ((6) 的路径积分分解)。设 $r(\bar{X}|x_0, x_1)$ 为关于布朗运动绝对连续的分布，记为 $q(\bar{X}|x_0)$ ，其中我们简写 $\bar{X} \equiv X_{t \in [0, 1]}$ 。假设 r 与随机微分方程 $dX_t = v_t(X_t)dt + \sigma dW_t$, $X_0=x_0, X_1=x_1, \sigma>0$ 相关联。那么，(6) 的最优路径积分分解可以通过以下方式获得

$$p^*(\bar{X}|x_0, x_1) = \frac{1}{Z} \omega(\bar{X}|x_0, x_1) r(\bar{X}|x_0, x_1), \quad (10)$$

其中 Z 是归一化常数， ω 是重要性权重：

$$\omega(\bar{X}|x_0, x_1) := \exp \left(- \int_0^1 \frac{1}{\sigma^2} \left(V_t(X_t) + \frac{1}{2} \|v_t(X_t)\|^2 \right) dt - \int_0^1 \frac{1}{\sigma} v_t(X_t)^\top dW_t \right). \quad (11)$$

在实际应用中， $r(\bar{X}|x_0, x_1)$ 可以是任意分布，但越接近最优的 p^* ，重要性权重 ω (的方差就越低 (Kappen & Ruiz, 2016))。因此，自然考虑将前述高斯概率路径作为 $r(\bar{X}|x_0, x_1)$ ，利用算法 3 进行适当优化，然后按照 (10) 式比例进行重采样——这在期望上等价于执行自归一化重要性采样，但在算法上更简单，且有助于在大量样本权重值较低时降低方差。虽然路径积分重采样可能因条件漂移的变化（由 (8) 式控制 $p^*(\bar{X}|x_0, x_1)$ ）而使 $\mathcal{L}_{\text{explicit}}$ 不太适用，但我们仍观察到经验上的改进，有时甚至显著（见第 4.4 节）。总体而言，我们提出将路径积分重采样作为 GSBM 算法中的一个可选步骤，因为它需要顺序仿真。⁴ 在实践中，我们还经验性地发现，仅使用高斯概率路径就已足够有效，并且在大规模场景下易于使用。

Algorithm 4 ImptSample

```

Require:  $p_{t|0,1}, \mu_t, \gamma_t, \sigma > 0$ 
Sample  $X_{t \in [0,1]}^i$  from (6b) given (8)
Compute  $\omega^i$  with (11) and  $Z = \sum_i \omega^i$ 
return Resample  $p_{t|0,1}$  with (10).

```

3.3 算法概述与收敛性分析

我们在算法 5 中总结了 GSBM，如第 3.1 节所述，它在阶段 1（第 3 行）和阶段 2（第 4-9 行）之间交替进行。与 DSBM (Shi et al., 2023) 在 $V_t = 0$ 时构造解析的 $p_{t|0,1}$ 和 $u_{t|0,1}$ 不同，我们的 GSBM 求解具有非平凡 V_t 的底层 CondSOC (6)。我们强调这些计算易于并行化，并且由于我们高效的参数化而收敛迅速，因此引入的计算开销很小（见第 4.4 节）。

³ 这不会引入计算开销，因为 $\{X_{t_k}\}$ 是仿真 $x_0, x_1 \sim p_{0,1}^\theta$ 时的中间步骤。⁴ 我们注意到，从 (6a,8) 仿真轨迹 $\bar{X} \equiv X_{t \in [0, 1]}$ 可以通过计算协方差函数高效完成，这仅需求解一个一维常微分方程；详细说明见附录 C.2。




图 2: 在三个具有平均场代价的人群导航任务上的可行性与最优性。




图 3: 长时间训练后使用 u_t^θ 仿真随机微分方程。注意 DeepGSB 与我们的 GSBM 差异显著, 后者在所有时间都满足可行性。




图 4: 激光雷达表面上的群体导航。高度由灰度颜色表示。

我们注意到, 即使当 $\sigma=0$ 时, GSBM (算法 5) 仍然有效, 尽管 GSB 问题 (3) 最初是在 $\sigma>0$ (Chen 等人, 2015) 中提出的。在这种情况下, 隐式匹配和显式匹配仍然保持 p_t , 并分别对应于作用 (Neklyudov 等人, 2023) 和流匹配 (Lipman 等人, 2023), 而 CondSOC 对应于考虑 V_t 的广义测地路径。

最后, 我们在以下定理中提供收敛性分析。

定理 5 (局部收敛)。设阶段 1 和阶段 2 的中间结果, 在重复 n 次后, 为 θ^n 。那么, 其在 (3), $\mathcal{L}(\theta^n)$ 中的目标值随着 n 的增长而单调非增:

$$\mathcal{L}(\theta^n) \geq \mathcal{L}(\theta^{n+1}).$$

定理 6。GSB 问题 (3) 的最优解是 GSBM (算法 5) 的不动点。

4 实验

我们在各种分布匹配任务上测试 GSBM, 每个任务都有其自身的状态代价 $V_t(x)$ 。默认情况下, 我们使用显式匹配损失 (5) 而不进行路径积分重采样, 主要是由于其可扩展性, 但在第 4.4 节中消融了它们的相对性能。我们的 GSBM 主要与 DeepGSB (Liu 等人, 2022) 进行比较, 后者是一种受 Sinkhorn 启发的机器学习方法, 优于现有的深度方法 (Ruthotto 等人, 2020; Lin 等人, 2021)。其他细节见附录 D。

4.1 具有均场和几何状态代价的人群导航

本文首先验证所提出的广义薛定谔桥模型 (GSBM) 在解决人群导航问题上的有效性, 该问题是广义薛定谔桥问题 (3) 的一个典型实例。具体而言, 本文考虑以下两类任务 (详见附录 D.1):

均场交互。这些是 DeepGSB 中引入的合成数据集 $\mathbb{R}^2$, 其中状态代价 V_t 由两部分组成: 障碍物代价用于评估物理约束, 以及个体智能体与群体密度之间的“均场”交互代价 p_t :

$$V_t(x) = L_{\text{obstacle}}(x) + L_{\text{interact}}(x; p_t), \quad L_{\text{interact}}(x; p_t) = \begin{cases} \log p_t(x) & (\text{entropy}) \\ \mathbb{E}_{y \sim p_t} \left[\frac{2}{\|x-y\|^2 + 1} \right] & (\text{congestion}) \end{cases} \cdot (12)$$

熵代价和拥塞代价都是均场博弈的基本要素。它们衡量个体停留在人口密度高的拥挤区域所产生的代价。

由激光雷达定义的几何曲面。一个更现实的场景涉及在复杂几何曲面上的导航。特别地, 本文考虑通过激光雷达扫描观测到的曲面




图 5: DSBM (Shi 等人, 2023 年) 与本文 GSBM 的比较: (最左 5 列) 生成过程及 (最右 3 列) 训练过程中的耦合 $p^\theta(X_1|X_0)$ 。通过潜空间构造 V_t , GSBM 表现出更快的收敛速度并产生更好的耦合。



图 6: $p_t(X_t|x_0, x_1)$ 的均值。与 DSBM 中使用线性插值不同, GSBM 优化 $p_{t|0,1}$ w.r.t. (6), 其中 V_t 通过潜空间定义, 从而展现出更具语义意义的插值。

表 2: DSBM 与我们的 GSBM 在狗 $\rightarrow$ 猫上的 FID 值。

DSBM	GSBM
14.16	12.39

雷尼尔山 (Legg & Anderson, 2013), 经细化至 34,183 个点 (见图 4)。我们采用状态代价

$$V(x) = L_{\text{manifold}}(x) + L_{\text{height}}(x), \quad L_{\text{manifold}}(x) = \|\pi(x) - x\|^2, \quad L_{\text{height}}(x) = \exp(\pi^{(z)}(x)), \quad (13)$$

其中 $\pi(x)$ 将 x 投影到由 k 最近邻拟合的近似切平面 (见图 4 和附录 D.3), $\pi^{(z)}(x)$ 指 $\pi(x)$, i.e., 的 z 坐标, 即其高度。

图 2 追踪了三个平均场任务 (Stunnel、Vneck、GMM) 的可行性与最优性, 分别由 $\mathcal{W}_2(p_1^\theta, \nu)$ 和 (3) 度量。在所有任务上, 我们的 GSBM 在训练过程中始终保持可行解, 同时逐步提升最优性。相比之下, 由于缺乏收敛性分析, 训练 DeepGSB 表现出相对不稳定和偶发散 (见图 3)。至于几何状态代价, 图 4 展示了我们的 GSBM 如何忠实恢复期望的多模态分布: 它成功识别出两条具有低状态代价的可行路径, 其中一条绕过了鞍点。相比之下, DeepGSB 仅生成单模态分布, 样本散布在高状态代价的高山区域, 导致更高的目标值 (3)。

4.2 图像域插值与非配对翻译

接下来, 我们考虑 AFHQ (Choi et al., 2020) 中狗与猫之间的非配对翻译。我们旨在探索如何通过适当选择状态代价 V_t 来促进更自然的插值和更具语义意义的耦合。虽然 V_t 的设计本身是一个有趣的开放问题, 但在此我们利用学习到的潜空间的几何结构。为此, 我们使用预训练的变分自编码器 (Kingma & Welling, 2014), 然后基于两个端点的插值定义 V_t (注意 x 和 z 分别属于图像空间和潜空间):

$$V_t(x|x_0, x_1) = \|x - \text{Decoder}(z_t)\|^2, \quad z_t := I(t, \text{Encoder}(x_0), \text{Encoder}(x_1)). \quad (14)$$

尽管 $I(t, z_0, z_1)$ 可以是任意合适的插值方式, 我们发现球面线性插值 (Shoemake, 1985) 尤为有效, 这得益于潜空间中的高斯几何结构。由于高维度极大地阻碍了 DeepGSB, 我们主要与 DSBM (Shi et al., 2023) 进行比较, 后者是当 V_t 退化时我们 GSBM 的特例。与 DSBM 相同, 我们将图像调整为 64×64 。

图 5 报告了 DSBM 与我们 GSBM 生成过程的定性比较, 以及它们在训练期间的耦合情况。显然, 借助语义上有意义的 V_t , GSBM 通常在训练早期就收敛到接近最优的耦合, 并且如预期那样, 产生更可解释的生成过程。有趣的是, 尽管受到




图 8: 我们的 GSBM 揭示了当穿越被障碍物（灰色显示）包围的狭窄通道时，最优解如何随噪声水平（ σ ）发生剧烈变化。

表 3: 在求解 Stunnel 问题上，匹配损失组合与 PI 重采样相对于 $\mathcal{L}_{\text{explicit}}$ 的相对运行时间。

	$\mathcal{L}_{\text{explicit}}$	$\mathcal{L}_{\text{implicit}}$
without PI	100%	276%
with PI	108%	284%

相同的噪声水平（本例中为 $\sigma=0.5$ ），GSBM 的生成过程通常比 DSBM 噪声更少。这归因于我们针对 CondSOC 问题（6）的优化以及我们对 V_t 的特定选择。如图 6 所示，GSBM 中使用的条件密度 $p_t(X_t|x_0, x_1)$ 消除了布朗桥中观察到的不自然伪影，后者依赖于像素空间中的简单线性插值。定量上，作为可行性度量，我们的 GSBM 也取得了更低的 FID 值，如表 2 所示。最后，我们注意到，与 DSBM 相比，包含 V_t 和求解 CondSOC 仅增加了 0.5% 的实际运行时间（见表 5）。

4.3 高维观点去极化

最后，我们考虑高维观点去极化，该问题最初在 DeepGSB 中引入，其中观点 $X_t \in \mathbb{R}^{1000}$ 在与群体交互演化时受到极化效应（Schweighofer et al., 2020）的影响（见附录 D.2）：

$$dX_t = f_{\text{polarize}}(X_t; p_t)dt + \sigma dW_t \quad (15)$$

在没有任何干预的情况下，(15) 中的观点动力学倾向于分裂成观点截然相反的群体（图 7 第一列），而非期望的单峰分布 p_1 （图 7 第二列）。为使我们的 GSBM 适应该任务，我们将 (15) 视为基础漂移，具体定义 $u_t^\theta(X_t) := f_{\text{polarize}}(X_t; p_t) + v_t^\theta(X_t)$ ，然后通过将动能替换为 $\int \|v_t^\theta\|^2 dt$ 来求解 CondSOC（6）。与 DeepGSB 类似，我们考虑 (12) 中定义的相同拥堵成本 V_t 。如图 7 所示，DeepGSB 和我们的 GSBM 均展现出缓解观点隔离的能力。然而，我们的 GSBM 更接近目标 p_1 ，表明可行性更强，并且相对于 DeepGSB 实现了几乎一半的目标值 (3)。




图 7: 终端观点 $X_1 \in \mathbb{R}^{1000}$ 的分布及其方向相似性 (DS; 见附录 D.2)。

4.4 讨论

噪声的影响 (σ)。在随机控制设置中（Theodorou 等人，2010），任务特定的 σ 值在表示环境不确定性或控制执行误差方面起着关键作用。因此，最优控制会根据 σ 发生剧烈变化。图 8 展示了我们的 GSBM 如何正确解决这一现象，以 Kappen (2005) 中讨论的著名“醉蜘蛛”问题为例。在没有噪声的情况下（ $\sigma=0$ ），很容易穿过狭窄通道。当存在大量噪声时（ $\sigma=1.0$ ），与障碍物碰撞的概率很高，因此最优解是完全绕过障碍物。

路径积分 (PI) 重采样的消融实验。在表 4 中，我们消融了在不同匹配损失和噪声 σ 下启用 PI 重采样时目标值的变化，并报告了它们在 Stunnel 任务上的性能（5 次独立试验的平均值）。我们观察到，PI 重采样倾向于提升整体性能，尤其是在低噪声条件下，代价是运行时间略微增加 8%。同时，如表 3 所示，隐式匹配 (4) 通常需要更长的总时间（ $\times 2.7$ ，即使在二维情况下），与其显式对应方法相比。

GSBM 性能分析。我们的 GSBM 与之前的 SB 匹配方法（Shi 等人，2023；Peluchetti，2023）之间的主要算法区别在于 $p_{t|0,1}$ 和 $u_{t|0,1}$ 的计算方式（见引理 3），其中 GSBM 涉及求解一个额外的 CondSOC 问题，即算法 5 中的第 5-6 行。表 5 表明，这些仅属于 GSBM 的计算与算法 5 中的其他组件相比，引入的计算开销很小。这种计算效率归功于我们高效的变分近似，它允许无仿真、可并行的优化。

表 4: 在 Stunnel 中启用 PI 重采样对每个匹配损失和 σ 时, 目标值 (3) 如何变化。通过降低 (-) 目标值, 性能得到改善。

	$\sigma = 0.5$	1.0	2.0
$\mathcal{L}_{\text{explicit}}$	-44.6 ± 5.9	-5.2 ± 2.6	1.5 ± 3.5
$\mathcal{L}_{\text{implicit}}$	-112.4 ± 53.7	-2.0 ± 8.0	-0.7 ± 6.0

表 5: 在 AFHQ 任务上测量的算法 5 不同阶段所花费的时间百分比。

match (line 3)	Simulate u_t^θ (line 4)	Solve (6) (lines 5-6)
64.3%	35.2%	0.5%

5 结论与局限性

我们开发了 GSBM, 一种新的匹配算法, 为广义薛定谔桥 (GSB) 问题提供近似解。我们展示了 GSBM 在解决人群导航、观点建模和可解释域迁移方面优于先前方法的强大能力。需要注意的是, GSBM 要求 V_t 可微, 并依赖二次控制代价来建立其收敛性分析, 尽管这比先前方法有显著改进, 但仍作为必要条件。我们承认这些局限性, 并将其留待未来工作。

致谢

我们感谢 Python 社区 (Van Rossum & Drake Jr, 1995; Oliphant, 2007) 以及支持这项工作的核心工具集, 包括 PyTorch (Paszke 等人, 2019)、functorch (Horace He, 2021)、torchdiffeq (Chen, 2018)、JAX (Bradbury 等人, 2018)、Flax (Heek 等人, 2020)、Hydra (Yadan, 2019)、Jupyter (Kluyver 等人, 2016)、Matplotlib (Hunter, 2007)、numpy (Oliphant, 2006; Van Der Walt 等人, 2011) 和 SciPy (Jones 等人, 2014)。

参考文献

- Michael S Albergo and Eric Vanden-Eijnden. Building normalizing flows with stochastic interpolants. In *International Conference on Learning Representations (ICLR)*, 2023.
- Michael S Albergo, Nicholas M Boffi, and Eric Vanden-Eijnden. Stochastic interpolants: A unifying framework for flows and diffusions. *arXiv preprint arXiv:2303.08797*, 2023.
- Luigi Ambrosio, Nicola Gigli, and Giuseppe Savaré. *Gradient flows: In metric spaces and in the space of probability measures*. Springer Science & Business Media, 2008.
- Brian DO Anderson. Reverse-time diffusion equation models. *Stochastic Processes and their Applications*, 12(3):313–326, 1982.
- James Bradbury, Roy Frostig, Peter Hawkins, Matthew James Johnson, Chris Leary, Dougal Maclaurin, George Necula, Adam Paszke, Jake VanderPlas, Skye Wanderman-Milne, and Qiao Zhang. JAX: composable transformations of Python+NumPy programs, 2018. URL <http://github.com/google/jax>.
- Ricky T. Q. Chen. torchdiffeq, 2018. URL <https://github.com/rtqichen/torchdiffeq>.
- Ricky T. Q. Chen and Yaron Lipman. Riemannian flow matching on general geometries. *arXiv preprint arXiv:2302.03660*, 2023.
- Ricky T. Q. Chen, Yulia Rubanova, Jesse Bettencourt, and David K Duvenaud. Neural ordinary differential equations. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2018.
- Tianrong Chen, Guan-Horng Liu, and Evangelos A Theodorou. Likelihood training of Schrödinger bridge using forward-backward SDEs theory. In *International Conference on Learning Representations (ICLR)*, 2022.
- Yongxin Chen. Density control of interacting agent systems. *IEEE Transactions on Automatic Control*, 2023.
- Yongxin Chen and Tryphon Georgiou. Stochastic bridges of linear systems. *IEEE Transactions on Automatic Control*, 61(2):526–531, 2015.

- Yongxin Chen, Tryphon Georgiou, and Michele Pavon. Optimal steering of inertial particles diffusing anisotropically with losses. In *American Control Conference (ACC)*. IEEE, 2015.
- Yunjey Choi, Youngjung Uh, Jaejun Yoo, and Jung-Woo Ha. Stargan v2: Diverse image synthesis for multiple domains. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2020.
- Marco Cuturi. Sinkhorn distances: Lightspeed computation of optimal transport. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2013.
- Valentin De Bortoli, James Thornton, Jeremy Heng, and Arnaud Doucet. Diffusion Schrödinger bridge with applications to score-based generative modeling. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.
- Prafulla Dhariwal and Alex Nichol. Diffusion models beat GANs on image synthesis. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.
- Simone Di Marino, Augusto Gerolin, and Luca Nenna. Optimal transportation theory with repulsive costs. *Topological optimization and optimal transport*, 17:204–256, 2017.
- Robert Fortet. Résolution d’un système d’équations de M. Schrödinger. *Journal de Mathématiques Pures et Appliquées*, 19(1-4):83–105, 1940.
- Jason Gaitonde, Jon Kleinberg, and Éva Tardos. Polarization in geometric opinion dynamics. In *ACM Conference on Economics and Computation*, pp. 499–519, 2021.
- Jonathan Heek, Anselm Levskaya, Avital Oliver, Marvin Ritter, Bertrand Rondepierre, Andreas Steiner, and Marc van Zee. Flax: A neural network library and ecosystem for JAX, 2020. URL <http://github.com/google/flax>.
- Irina Higgins, Loic Matthey, Arka Pal, Christopher Burgess, Xavier Glorot, Matthew Botvinick, Shakir Mohamed, and Alexander Lerchner. β -vae: Learning basic visual concepts with a constrained variational framework. In *International Conference on Learning Representations (ICLR)*, 2016.
- Richard Zou Horace He. functorch: Jax-like composable function transforms for pytorch. <https://github.com/pytorch/functorch>, 2021.
- John D Hunter. Matplotlib: A 2d graphics environment. *Computing in science & engineering*, 9(3): 90, 2007.
- Michael F Hutchinson. A stochastic estimator of the trace of the influence matrix for Laplacian smoothing splines. *Communications in Statistics-Simulation and Computation*, 18(3):1059–1076, 1989.
- Kiyosi Itô. *On stochastic differential equations*, volume 4. American Mathematical Soc., 1951.
- Eric Jones, Travis Oliphant, and Pearu Peterson. {SciPy}: Open source scientific tools for {Python}. 2014.
- Hilbert J Kappen. Path integrals and symmetry breaking for optimal control theory. *Journal of Statistical Mechanics: Theory and Experiment*, 2005(11):P11011, 2005.
- Hilbert Johan Kappen and Hans Christian Ruiz. Adaptive importance sampling for control and inference. *Journal of Statistical Physics*, 162(5):1244–1266, 2016.
- Diederik P Kingma and Max Welling. Auto-Encoding variational bayes. In *International Conference on Learning Representations (ICLR)*, 2014.
- Thomas Kluyver, Benjamin Ragan-Kelley, Fernando Pérez, Brian E Granger, Matthias Bussonnier, Jonathan Frederic, Kyle Kelley, Jessica B Hamrick, Jason Grout, Sylvain Corlay, et al. Jupyter notebooks-a publishing format for reproducible computational workflows. In *ELPUB*, pp. 87–90, 2016.

- Takeshi Koshizuka and Issei Sato. Neural Lagrangian Schrödinger bridge: Diffusion modeling for population dynamics. In *International Conference on Learning Representations (ICLR)*, 2023.
- Nicholas Legg and Scott Anderson. Southwest Flank of Mt. Rainier, WA, 2013. URL <https://opentopography.org/meta/OT.052013.26910.1>. Accessed on 2023-09-12.
- Christian Léonard. A survey of the Schrödinger problem and some of its connections with optimal transport. *Discrete and Continuous Dynamical Systems*, 2013.
- Christian Léonard, Sylvie Rœlly, and Jean-Claude Zambrini. Reciprocal processes. A measure-theoretical point of view. *Probability Surveys*, 2014.
- David Levin. The approximation power of moving least-squares. *Mathematics of Computation*, 67(224):1517–1531, 1998.
- Sergey Levine. Reinforcement learning and control as probabilistic inference: Tutorial and review. *arXiv preprint arXiv:1805.00909*, 2018.
- Xuechen Li, Ting-Kam Leonard Wong, Ricky T. Q. Chen, and David Duvenaud. Scalable gradients for stochastic differential equations. In *International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2020.
- Alex Tong Lin, Samy Wu Fung, Wuchen Li, Levon Nurbekyan, and Stanley J Osher. Alternating the population and control neural networks to solve high-dimensional stochastic mean-field games. *Proceedings of the National Academy of Sciences*, 118(31), 2021.
- Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow matching for generative modeling. In *International Conference on Learning Representations (ICLR)*, 2023.
- Guan-Horng Liu, Tianrong Chen, Oswin So, and Evangelos A Theodorou. Deep generalized Schrödinger bridge. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.
- Guan-Horng Liu, Arash Vahdat, De-An Huang, Evangelos A Theodorou, Weili Nie, and Anima Anandkumar. I²SB: Image-to-Image Schrödinger bridge. In *International Conference on Machine Learning (ICML)*, 2023a.
- Qiang Liu. Rectified flow: A marginal preserving approach to optimal transport. *arXiv preprint arXiv:2209.14577*, 2022.
- Xingchao Liu, Chengyue Gong, and Qiang Liu. Flow straight and fast: Learning to generate and transfer data with rectified flow. In *International Conference on Learning Representations (ICLR)*, 2023b.
- Zhiyu Liu, Bo Wu, and Hai Lin. A mean field game approach to swarming robots control. In *American Control Conference (ACC)*. IEEE, 2018.
- Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations (ICLR)*, 2019.
- Alain Mazzolo and Cécile Monthus. Conditioning diffusion processes with killing rates. *Journal of Statistical Mechanics: Theory and Experiment*, 2022(8):083207, 2022.
- Kirill Neklyudov, Daniel Severo, and Alireza Makhzani. Action matching: A variational method for learning stochastic dynamics from samples. In *International Conference on Machine Learning (ICML)*, 2023.
- Frank Noé, Alexandre Tkatchenko, Klaus-Robert Müller, and Cecilia Clementi. Machine learning for molecular simulation. *Annual Review of Physical Chemistry*, 71:361–390, 2020.
- Masashi Okada and Tadahiro Taniguchi. Variational inference mpc for bayesian model-based reinforcement learning. In *Conference on Robot Learning (CoRL)*, 2020.
- Travis E Oliphant. *A guide to NumPy*, volume 1. Trelgol Publishing USA, 2006.

- Travis E Oliphant. Python for scientific computing. *Computing in Science & Engineering*, 9(3): 10–20, 2007.
- Etienne Pardoux and Shige Peng. Backward stochastic differential equations and quasilinear parabolic partial differential equations. In *Stochastic Partial Differential Equations and Their Applications*. Springer, 2005.
- Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, et al. Pytorch: An imperative style, high-performance deep learning library. In *Advances in neural information processing systems*, pp. 8026–8037, 2019.
- Stefano Peluchetti. Non-Denoising forward-time diffusions, 2022. URL <https://openreview.net/forum?id=oVfIKuhqfC>.
- Stefano Peluchetti. Diffusion bridge mixture transports, Schrödinger bridge problems and generative modeling. *arXiv preprint arXiv:2304.00917*, 2023.
- Gabriel Peyré and Marco Cuturi. Computational optimal transport. *Center for Research in Economics and Statistics Working Papers*, 2017.
- Gabriel Peyré and Marco Cuturi. Computational optimal transport: With applications to data science. *Foundations and Trends® in Machine Learning*, 11(5-6):355–607, 2019.
- Chris Philippidis, Chris Dewdney, and Basil J Hiley. Quantum interference and the quantum potential. *Nuovo Cimento B*, 52(1):15–28, 1979.
- Konrad Rawlik, Marc Toussaint, and Sethu Vijayakumar. On stochastic optimal control and reinforcement learning by approximate inference. In *International Joint Conference on Artificial Intelligence (IJCAI)*, 2013.
- Hannes Risken. Fokker-Planck equation. In *The Fokker-Planck Equation*, pp. 63–95. Springer, 1996.
- Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-Net: Convolutional networks for biomedical image segmentation. In *International Conference on Medical Image Computing and Computer-assisted Intervention*. Springer, 2015.
- Lars Ruthotto, Stanley J Osher, Wuchen Li, Levon Nurbekyan, and Samy Wu Fung. A machine learning framework for solving high-dimensional mean field game and mean field control problems. *Proceedings of the National Academy of Sciences*, 117(17):9183–9193, 2020.
- Simo Särkkä and Arno Solin. *Applied stochastic differential equations*, volume 10. Cambridge University Press, 2019.
- Erwin Schrödinger. *Über die Umkehrung der Naturgesetze*, volume IX. Sitzungsberichte der Preuss Akad. Wissen. Phys. Math. Klasse, Sonderausgabe, 1931.
- Simon Schweighofer, David Garcia, and Frank Schweitzer. An agent-based model of multi-dimensional opinion dynamics and opinion alignment. *Chaos: An Interdisciplinary Journal of Nonlinear Science*, 30(9):093139, 2020.
- Neta Shaul, Ricky T. Q. Chen, Maximilian Nickel, Matthew Le, and Yaron Lipman. On kinetic optimal probability paths for generative models. In *International Conference on Machine Learning (ICML)*, 2023.
- Yuyang Shi, Valentin De Bortoli, Andrew Campbell, and Arnaud Doucet. Diffusion Schrödinger bridge matching. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.
- Ken Shoemake. Animating rotation with quaternion curves. In *Conference on Computer Graphics and Interactive Techniques*, 1985.
- Jascha Sohl-Dickstein, Eric Weiss, Niru Maheswaranathan, and Surya Ganguli. Deep unsupervised learning using nonequilibrium thermodynamics. In *International Conference on Machine Learning (ICML)*, 2015.

- Yang Song, Jascha Sohl-Dickstein, Diederik P Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole. Score-based generative modeling through stochastic differential equations. In *International Conference on Learning Representations (ICLR)*, 2021.
- Evangelos Theodorou. Nonlinear stochastic control and information theoretic dualities: Connections, interdependencies and thermodynamic interpretations. *Entropy*, 17(5):3352–3375, 2015.
- Evangelos Theodorou, Jonas Buchli, and Stefan Schaal. A generalized path integral control approach to reinforcement learning. *Journal of Machine Learning Research (JMLR)*, 11(Nov): 3137–3181, 2010.
- Emanuel Todorov. Linearly-solvable Markov decision problems. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2007.
- Alexander Tong, Nikolay Malkin, Guillaume Huguette, Yanlei Zhang, Jarrid Rector-Brooks, Kilian Fatras, Guy Wolf, and Yoshua Bengio. Improving and generalizing flow-based generative models with minibatch optimal transport. In *International Conference on Machine Learning (ICML), Workshop Track*, 2023.
- Stefan Van Der Walt, S Chris Colbert, and Gael Varoquaux. The numpy array: a structure for efficient numerical computation. *Computing in Science & Engineering*, 13(2):22, 2011.
- Guido Van Rossum and Fred L Drake Jr. *Python reference manual*. Centrum voor Wiskunde en Informatica Amsterdam, 1995.
- Francisco Vargas, Pierre Thodoroff, Neil D Lawrence, and Austen Lamacraft. Solving Schrödinger bridges via maximum likelihood. *Entropy*, 2021.
- Cédric Villani et al. *Optimal transport: Old and new*, volume 338. Springer, 2009.
- Mei Wang and Weihong Deng. Deep visual domain adaptation: A survey. *Neurocomputing*, 312: 135–153, 2018.
- Holger Wendland. *Scattered data approximation*, volume 17. Cambridge university press, 2004.
- Omry Yadan. Hydra - a framework for elegantly configuring complex applications. Github, 2019. URL <https://github.com/facebookresearch/hydra>.
- Jiongmin Yong and Xun Yu Zhou. *Stochastic controls: Hamiltonian systems and HJB equations*, volume 43. Springer Science & Business Media, 1999.
- Jun-Yan Zhu, Taesung Park, Phillip Isola, and Alexei A Efros. Unpaired image-to-image translation using cycle-consistent adversarial networks. In *Proceedings of the IEEE international conference on computer vision*, pp. 2223–2232, 2017.

随机最优控制及相关工作综述

通过重构为随机最优控制求解广义薛定谔桥 广义薛定谔桥 (GSB) 问题 (3) 的解也可以表示为随机最优控制 (SOC) 问题的解，通常结构为

$$\min_{u_t(\cdot)} \int_0^1 \mathbb{E}_{p_t} \left[\frac{1}{2} \|u_t(X_t)\|^2 + V_t(X_t) \right] dt + \mathbb{E}_{p_1} [\phi(X_1)], \quad (16a)$$

(16b) 其中我们看到, s.t. $dX_t = u_t(X_t)dt + \sigma dW_t$, $X_0 \sim \mu$, GSB (3) 中的终端分布“硬约束”被放宽为软性的“终端代价” $\phi(\cdot) : \mathbb{R}^d \rightarrow \mathbb{R}$ 。具有 (16) 或 (3) 形式的问题已知与线性可解马尔可夫决策过程 (Todorov, 2007; Rawlik et al., 2013) 相关, 对应一类可处理的 SOC 问题, 其最优性条件——哈密顿-雅可比-贝尔曼方程——允许高效近似。这归因于 ℓ_2 -范数控制代价的存在, 它可以解释为受控过程与非受控过程之间的 KL 散度。这种解释将 SOC 问题与概率推断联系起来 (Levine, 2018; Okada & Taniguchi, 2020), 由此可以开发机器学习算法, 例如我们的 GSBM。

然而, 天真地将 GSB 问题 (3) 转化为 SOC 问题可能引入许多潜在问题。终端代价的设计极其重要, 在许多情况下, 它是一个难以处理的代价函数, 因为我们无法获得密度 μ 和 ν 。先前的工作主要局限于简单的终端代价 (Ruthotto et al., 2020), 使用基于批量估计的有偏近似 (Koshizuka & Sato, 2023), 或使用对抗方法来学习代价函数 (Zhu et al., 2017; Lin et al., 2021)。此外, 这种方法需要对 SDE 仿真进行微分, 需要高内存使用。尽管已经开发了内存高效的伴随方法 (Chen et al., 2018; Li et al., 2020), 但它们在大规模使用时仍然计算昂贵。

相比之下, 我们的 GSBM 方法只需要来自 μ 和 ν 的样本。通过将边界分布作为硬约束而非软约束来强制执行, 我们的算法在实践中找到的解能更好地满足可行性。这进一步使我们能够考虑更高维的问题, 而无需引入额外的超参数来调整终端代价。最后, 我们的算法大幅减少了所需的 SDE 仿真次数, 因为 GSBM 的匹配算法 (阶段 1) 和 CondSOC 变分公式 (阶段 2) 都可以无仿真地完成。

与相关工作的比较 表 6 将先前同样为 (3) 提供近似解的学习类方法与本文的 GSBM 进行了比较。同时, 图 9 总结了不同类别的匹配算法。

表 6: 本文的 GSBM 具有更好的可行性, 仅需来自 μ, ν 的样本, 具备局部收敛性分析, 并展现出显著更优的可扩展性。

	Feasibility (2)	Requirement from distributions μ, ν	Convergence analysis	Dimension d
NLSB (Koshizuka & Sato, 2023)	$\times$ (relaxed)	samples & densities	$\checkmark$ (local)	5
DeepGSB (Liu et al., 2022)	$\approx \mathbf{F}$ only in limit	samples & densities	$\times$	1000
GSBM (this work)	$\approx \mathbf{F}$	only samples	$\checkmark$ (local)	$\gtrsim 12K$




图 9: 不同匹配算法的总结。注意 OT 和 SB 均基于 ℓ_2 代价。

B 证明

命题 1 (阶段 1)。 阶段 1 的唯一极小值与 $\nabla s_t^*(X_t)$ 一致。

证明：在 (3) 中固定 p_t 后， $\mathbb{E}_{p_t}[V_t(X_t)]$ 的值不再依赖于 u_t^θ ，使得 (3) 与隐式匹配中的优化问题相同；参见 (4) 及第 2 节。由于隐式匹配 (4) 存在唯一极小值点 ∇s_t^* ，证明完成。 $\square$

命题 2 (第二阶段；条件随机最优控制；CondSOC)。 设第二阶段的最小化器可分解为 $p_t(X_t) = \int p_t(X_t|x_0, x_1)p_{0,1}^\theta(x_0, x_1)dx_0dx_1$ 中 $p_{0,1}^\theta$ 是由求解 (1) 式并给定 u_t^θ 所诱导的边界耦合。则 $p_t(X_t|x_0, x_1) \equiv p_{t|0,1}$ 求解：

$$\min_{u_{t|0,1}} \mathcal{J} := \int_0^1 \mathbb{E}_{p_t(X_t|x_0, x_1)} \left[\frac{1}{2} \|u_t(X_t|x_0, x_1)\|^2 + V_t(X_t) \right] dt \quad (6a)$$

$$s.t. \, dX_t = u_t(X_t|x_0, x_1)dt + \sigma dW_t, \quad X_0 = x_0, \quad X_1 = x_1 \quad (6b)$$

证明：回顾以 FPE 约束 (2) 形式表示的 GSB 问题 (3)：

$$\min_{u_t} \int_0^1 \mathbb{E}_{p_t} \left[\frac{1}{2} \|u_t(X_t)\|^2 + V_t(X_t) \right] dt \quad (17a)$$

$$s.t. \, \frac{\partial}{\partial t} p_t(X_t) = -\nabla \cdot (u_t(X_t) p_t(X_t)) + \frac{\sigma^2}{2} \Delta p_t(X_t), \quad p_0 = \mu, p_1 = \nu. \quad (17b)$$

在温和的正则性假设下 (Anderson, 1982; Yong & Zhou, 1999)，莱布尼茨法则和富比尼定理适用，我们可以将 $p_{0,1}$ 从边缘分布 p_t 中分离出来——因为假设其固定。具体地，目标值 (17a) 可分解为

$$\begin{aligned} \int_0^1 \mathbb{E}_{p_t} \left[\frac{1}{2} \|u_t\|^2 + V_t \right] dt &= \int_0^1 \mathbb{E}_{p_{0,1}} \left[\mathbb{E}_{p_{t|0,1}} \left[\frac{1}{2} \|u_t\|^2 + V_t \right] \right] dt, \quad \text{by law of total expectation} \\ &= \mathbb{E}_{p_{0,1}} \left[\int_0^1 \mathbb{E}_{p_{t|0,1}} \left(\frac{1}{2} \|u_t\|^2 + V_t \right) dt \right], \quad \text{by Fubini's Theorem} \end{aligned}$$

这恢复了 (6a)。类似地，FPE(17b) 中的每一项可分解为

$$\begin{aligned} \frac{\partial}{\partial t} p_t(X_t) &= \frac{\partial}{\partial t} \int p_t(X_t|x_0, x_1)p_{0,1}(x_0, x_1)dx_{0,1} = \mathbb{E}_{p_{0,1}} \left[\frac{\partial}{\partial t} p_{t|0,1} \right], \\ \nabla \cdot (u_t(X_t) p_t(X_t)) &= \nabla \cdot \left(u_t(X_t) \int p_t(X_t|x_0, x_1)p_{0,1}(x_0, x_1)dx_{0,1} \right) \\ &= \nabla \cdot \left(\int u_t(X_t)p_t(X_t|x_0, x_1)p_{0,1}(x_0, x_1)dx_{0,1} \right) \\ &= \mathbb{E}_{p_{0,1}} [\nabla \cdot (u_t p_{t|0,1})], \\ \Delta p_t(X_t) &= \nabla \cdot (\nabla p_t(X_t)) \\ &= \nabla \cdot \left(\nabla \int p_t(X_t|x_0, x_1)p_{0,1}(x_0, x_1)dx_{0,1} \right) \\ &= \mathbb{E}_{p_{0,1}} [\nabla \cdot \nabla p_{t|0,1}] \\ &= \mathbb{E}_{p_{0,1}} [\Delta p_{t|0,1}], \end{aligned}$$

and, finally, $p_0(x_0) = \mathbb{E}_{p_{0,1}}[\delta_{x_0}(x)]$ and $p_1(x_1) = \mathbb{E}_{p_{0,1}}[\delta_{x_1}(x)]$. Collecting all related terms yields:

$$\frac{\partial}{\partial t} p_{t|0,1} = -\nabla \cdot (u_t p_{t|0,1}) + \Delta p_{t|0,1}, \quad p_0 = \delta_{x_0}, p_1 = \delta_{x_1},$$

这等价于 (6b) 中的条件随机微分方程。注意，我们将 u_t 记为 $u_t(X_t|x_0, x_1)$ ，以强调当 $p_{t|0,1}(X_t|x_0, x_1)$ 从 $p_t(X_t)$ 中分解出来时，GSB 问题 (3) 可以分解为多个 SOC 问题的混合，每个问题都有一个端点约束 (x_0, x_1) 。 $\square$

注 (命题 2 与 (6) 的偏微分方程解释)。 (6) 的最优控制由 $u_t^*(X_t|x_0, x_1) = \sigma^2 \nabla \log \Psi_t(X_t|x_1)$ 给出, 其中时变势 $\Psi_t(X_t|x_1)$ 满足一个称为哈密顿-雅可比-贝尔曼 (Hamilton-Jacobi-Bellman, HJB) 偏微分方程: $\frac{\partial}{\partial t} \Psi_t(x|x_1) = -$

$$\sigma^2 \Delta \Psi_t(x|x_1) + V_t(x) \Psi_t(x|x_1), \quad \Psi_1(x|x_1) = \delta_{x_1}(x). \quad (18)$$

一般来说, (18) 缺乏闭式解, 除非在特定情况下。例如, 当 V 为二次型时, 其解由 (19) 给出。此外, 当 V 退化时, (18) 简化为热核, 其解对应于 DSBM (Shi et al., 2023) 中使用的布朗桥的漂移。否则, 可以借助路径积分理论来近似其解, 如命题 4 所示。

引理 3 (二次 V 和 $\sigma > 0$). 下 (6) 的解析解) 设 $V(x) := \alpha \|\sigma x\|^2$, $\alpha, \sigma > 0$, , $\mathbf{I}_d$ 则 (6) 的最优解遵循高斯路径 $X_t^* \sim \mathcal{N}(c_t x_0 + e_t x_1, \gamma_t^2)$, 其中 $c_t = \frac{\sinh(\eta(1-t))}{\sinh \eta}$, $e_t = \cosh(\eta(1-t)) - c_t \cosh \eta$, $\gamma_t = \sigma \sqrt{\frac{\sinh(\eta(1-t))}{\eta}} e_t$, $\eta = \sigma \sqrt{2\alpha}$.

这些系数在 $\alpha \rightarrow 0$ 时恢复布朗桥, 若进一步 $\sigma \rightarrow 0$, 则恢复直线。

证明。这是具有二次杀伤率的条件扩散过程的直接结果 (Mazzolo & Monthus, 2022)。具体而言, Mazzolo & Monthus (2022, Eq. (84)) 给出了当 $V_t := \alpha \|\sigma x\|^2$ 时 (6) 的最优控制的解析表达式:

$$u_t(X_t|x_0, x_1) = \frac{\eta}{\sinh(\eta(1-t))} x_1 - \frac{\eta}{\tanh(\eta(1-t))} X_t, \quad \eta := \sigma \sqrt{2\alpha}. \quad (19)$$

由于公式 (19) 表明这是一个线性随机微分方程, 其均值 $\mu_t \in \mathbb{R}^d$ 满足一个常微分方程 (Sarkkari & Solin, 2019):

$$\frac{d\mu_t}{dt} = \frac{\eta}{\sinh(\eta(1-t))} x_1 - \frac{\eta}{\tanh(\eta(1-t))} \mu_t$$

其解析解为

$$\mu_t = \frac{x_1 \int_0^t \left(\frac{\eta g_\tau}{\sinh(\eta(1-\tau))} \right) d\tau + K}{g_t}, \quad (20)$$

其中 K 依赖于初始条件, 并且

$$g_t := \exp \left(\int_0^t \frac{\eta}{\tanh(\eta(1-\tau))} d\tau \right) \stackrel{(*)}{=} \exp \left([\ln v_\tau]_{\sinh(\eta(1-t))}^{\sinh \eta} \right) = \frac{\sinh \eta}{\sinh(\eta(1-t))}.$$

注意 (*) 是由于变量替换 $v_\tau := \sinh(\eta(1-\tau))$ 。将 g_t 代回公式

$$x_0 = \mu_0 = \frac{x_1 \cdot 0 + K}{1} \stackrel{(20)}{=} K, \text{ 并注意到 } K = \frac{\sinh(\eta(1-t))}{\sinh \eta} x_1, \text{ 即可得到所需的系数:}$$

$$\mu_t = c_t x_0 + e_t x_1, \quad c_t = \frac{\sinh(\eta(1-t))}{\sinh \eta}, \quad e_t = \cosh(\eta(1-t)) - c_t \cosh \eta. \quad (21)$$

类似地, 公式 (19) 中随机微分方程的方差 $\Sigma_t \in \mathbb{R}^{d \times d}$ 满足常微分方程

$$d\Sigma_t = -\frac{2\eta}{\tanh(\eta(1-t))} \Sigma_t + \sigma^2 \mathbf{I}_d.$$

重复与求解 μ_t 类似的推导, 得到

$$\Sigma_t = \frac{\sigma^2}{\eta} \sinh^2(\eta(1-t)) (\coth(\eta(1-t)) - \coth \eta) \mathbf{I}_d = \frac{\sigma^2}{\eta} \sinh(\eta(1-t)) e_t \mathbf{I}_d. \quad (22)$$

由于 $\Sigma_t = \gamma_t^2 \mathbf{I}_d$, 这给出了所需的 γ_t 。

我们现在展示这些系数 (21) 和 (22) 如何在 α 或等价地 $\eta := \sigma \sqrt{2\alpha}$ 趋近于零极限时恢复布朗桥。

$$\lim_{\eta \rightarrow 0} c_t = \lim_{\eta \rightarrow 0} \frac{e^{\eta(1-t)} - e^{-\eta(1-t)}}{e^\eta - e^{-\eta}} \stackrel{(*)}{=} \frac{1 + \eta(1-t) - (1 - \eta(1-t))}{1 + \eta - (1 - \eta)} = 1 - t,$$

极限 $e_t = \lim_{\eta \rightarrow 0} (\cosh(\eta(1-t)) - c_t \cosh \eta) = 1 - (1-t) \cdot 1 = t$,

$$\lim_{\eta \rightarrow 0} \gamma_t = \lim_{\eta \rightarrow 0} \sigma \sqrt{\frac{\sinh(\eta(1-t))}{\eta}} e_t \stackrel{(**)}{=} \sigma \sqrt{(1-t)t},$$

其中 $(*)$ 和 $(**)$ 分别由 $\exp(x) \approx 1 + x$ 和

$$\lim_{\eta \rightarrow 0} \frac{\sinh(\eta(1-t))}{\eta} = \lim_{\eta \rightarrow 0} \frac{e^{\eta(1-t)} - e^{-\eta(1-t)}}{2\eta} \stackrel{(*)}{=} \frac{1 + \eta(1-t) - (1 - \eta(1-t))}{2\eta} = 1 - t.$$

因此，我们恢复了布朗桥的解析解。可以很容易地看出，如果进一步 $\sigma \rightarrow 0$ ，该解退化为 x_0 和 x_1 之间的线性插值。□

注 (引理 3 满足 (6b) 中的边界条件)。可以验证 $c_0 = 1, e_0 = 0$, 和 $\gamma_0 = 0$ 。此外，我们有 $c_1 = 0, e_1 = 1$ 和 $\gamma_1 = 0$ 。因此，正如预期的那样，引理 3 满足 (6b) 中的边界条件。

命题 4 ((6) 的路径积分分解)。设 $r(\bar{X}|x_0, x_1)$ 为关于布朗运动绝对连续的分布，记为 $q(\bar{X}|x_0)$ ，其中我们简写 $\bar{X} \equiv X_{t \in [0, 1]}$ 。假设 r 与随机微分方程 $dX_t = v_t(X_t)dt + \sigma dW_t$, $X_0=x_0, X_1=x_1, \sigma>0$ 相关联。那么，(6) 的最优路径积分分解可以通过以下方式获得

$$p^*(\bar{X}|x_0, x_1) = \frac{1}{Z} \omega(\bar{X}|x_0, x_1) r(\bar{X}|x_0, x_1), \quad (10)$$

其中 Z 是归一化常数， ω 是重要性权重：

$$\omega(\bar{X}|x_0, x_1) := \exp \left(- \int_0^1 \frac{1}{\sigma^2} \left(V_t(X_t) + \frac{1}{2} \|v_t(X_t)\|^2 \right) dt - \int_0^1 \frac{1}{\sigma} v_t(X_t)^\top dW_t \right). \quad (11)$$

证明。由于 (6b) 的终端边界条件固定在 x_1 ，我们可以将 (6) 转化为：

$$\min_{u_{t|0,1}} \int_0^1 \mathbb{E}_{p_t(X_t|x_0, x_1)} \left[\frac{1}{2\sigma^2} \|u_t(X_t|x_0, x_1)\|^2 + \frac{1}{\sigma^2} V_t(X_t) \right] dt - \log \mathbb{1}_{x_1}(X_1), \quad (23a)$$

$$\text{s.t. } dX_t = u_t(X_t|x_0, x_1)dt + \sigma dW_t, \quad X_0 = x_0 \quad (23b)$$

其中 $\mathbb{1}_{\mathcal{A}}(\cdot)$ 是集合 $\mathcal{A}$ 的指示函数。因此，终端代价“ $-\log \mathbb{1}_{x_1}(x)$ ”在 $x = x_1$ 处消失，但在其他情况下爆炸。方程 (23) 是一个有效的随机最优控制 (SOC) 问题，其最优解可以以路径积分的形式获得 (Kappen, 2005)：

$$p^*(\bar{X}|x_0, x_1) = \frac{1}{Z'} \exp \left(- \int_0^1 \frac{1}{\sigma^2} V_t(X_t) dt \right) \mathbb{1}_{x_1}(X_1) q(\bar{X}|x_0), \quad (24)$$

其中 $q(\cdot|x_0)$ 是以 $X_0 = x_0$ 为条件的布朗运动的密度，归一化常数 Z' 使得 (24) 保持为适当的分布，并且我们简写 $\bar{X} \equiv X_{t \in [0, 1]}$ 。我们强调，方程 (23) 和 (24) 是重要的变换，使我们能够在 $V_t := 0$ 时恢复先前工作中使用的条件分布 (Shi 等人, 2023) (见下面的注释)。直接使用 (24) 从 q 重新加权样本可能具有较差的复杂度，因为大多数样本由于 $\mathbb{1}_{x_1}(\cdot)$ 而被赋予零权重。一种更有效的替代方法是将 (24) 中的采样分布从 q 重新基于重要性采样 $r(\bar{X}|x_0, x_1)$ ，使得 $X_0 = x_0, X_1 = x_1$ ，并且关于 q 绝对连续。然后，来自信息论随机最优控制 (Theodorou 等人, 2010; Theodorou, 2015) 的显著结果表明

$$p^*(\bar{X}|x_0, x_1) = \frac{1}{Z} \exp \left(- \int_0^1 \frac{1}{\sigma^2} V_t(X_t) dt \right) \frac{q(\bar{X}|x_0)}{r(\bar{X}|x_0, x_1)} r(\bar{X}|x_0, x_1), \quad (25)$$

其中拉东-尼科迪姆导数 (Radon-Nikodym derivative) $\frac{q}{r}$ 可通过吉尔萨诺夫定理 (Girsanov's theorem) 计算 (Särkkä & Solin, 2019)：

$$\frac{q(\bar{X}|x_0)}{r(\bar{X}|x_0, x_1)} = \exp \left(- \int_0^1 \frac{1}{2\sigma^2} \|v_t(X_t)\|^2 dt - \int_0^1 \frac{1}{\sigma} v_t(X_t)^\top dW_t \right). \quad (26)$$

将 (26) 代入 (25) 即完成证明。□

注 (当 $V_t := 0$)。时，方程 (24) 恢复为布朗桥。可以验证，当 $V_t := 0$ 时，最优解 $p^*(\bar{X}|x_0, x_1) \propto q(\bar{X}|x_0) \mathbb{1}_{x_1}(X_1) = q(\bar{X}|x_0, x_1)$ 正是以终点为 x_1 的条件布朗运动，这恰好是布朗桥。

定理 5（局部收敛）。设阶段 1 和阶段 2 的中间结果，在重复 n 次后，为 θ^n 。那么，其在 (3), $\mathcal{L}(\theta^n)$ 中的目标值随着 n 的增长而单调非增：

$$\mathcal{L}(\theta^n) \geq \mathcal{L}(\theta^{n+1}).$$

证明。设 $p_t^{\theta^n}$ 和 $u_t^{\theta^n}$ 分别为按照算法 5, i.e., p^{θ^n} 进行 n 步交替优化后的边缘分布和向量场。 p_t 和 $u_t^{\theta^n}$ 满足福克-普朗克方程 (FPE)。此外，设 $p_{0,1}^{\theta^n}$ 和 $p_{t|0,1}^{\theta^n}$ 分别为由 $u_t^{\theta^n}$ 定义的耦合和条件分布，并设 $p_{t|0,1}^*$ 为条件薛定谔桥问题 (CondSOC) (6) 的解。这意味着第 $n+1$ 步的边缘分布由下式给出

$$p_t^{\theta^{n+1}} := \int p_{0,1}^{\theta^n} p_{t|0,1}^* dx_{0,1}. \quad (27)$$

现在，在温和假设下 (Anderson, 1982; Yong & Zhou, 1999)，例如所有分布在 $\|x\| \rightarrow \infty$ 处以足够快的速度趋于零，且所有被积函数有界，我们有（注意为简化记号，所有函数的输入均已省略）：

$$\begin{aligned} \mathcal{L}(\theta^n) &= \int \int p_t^{\theta^n} \left(\frac{1}{2} \|u_t^{\theta^n}\|^2 + V_t \right) dx_t dt \\ &= \int p_{0,1}^{\theta^n} \left[\int \int p_{t|0,1}^{\theta^n} \left(\frac{1}{2} \|u_t^{\theta^n}\|^2 + V_t \right) dx_{t|0,1} dt \right] dx_{0,1} \quad \text{by Fubini's Theorem} \\ &\geq \int p_{0,1}^{\theta^n} \left[\int \int p_{t|0,1}^* \left(\frac{1}{2} \|u_t^{\theta^n}\|^2 + V_t \right) dx_{t|0,1} dt \right] dx_{0,1} \quad \text{by optimizing (6)} \\ &= \int \int p_t^{\theta^{n+1}} \left(\frac{1}{2} \|u_t^{\theta^n}\|^2 + V_t \right) dx_t dt \quad \text{by Fubini's Theorem and (27)} \\ &\geq \int \int p_t^{\theta^{n+1}} \left(\frac{1}{2} \|u_t^{\theta^{n+1}}\|^2 + V_t \right) dx_t dt \quad (28) \\ &= \mathcal{L}(\theta^{n+1}), \end{aligned}$$

其中我们将阶段 1 的解分解为 $p_t^{\theta^n} := \int p_{0,1}^{\theta^n} p_{t|0,1}^{\theta^n} dx_{0,1}$ 等式源于 $u_t^{\theta^{n+1}}$ ，作为前一阶段 1 的解，找到了唯一极小化子，其边缘分布与 $p_t^{\theta^{n+1}}$ 相同，同时最小化动能，即

$$\int p_t^{\theta^{n+1}} \|u_t^{\theta^n}\|^2 dx_t \geq \int p_t^{\theta^{n+1}} \|u_t^{\theta^{n+1}}\|^2 dx_t.$$

□

定理 6。 GSB 问题 (3) 的最优解是 GSBM (算法 5) 的不动点。

证明。设 p_t^* 和 u_t^* 为 (3) 中 GSB 问题的最优解，并假设 $p_t^* := \int p_{t|0,1}^* p_{0,1}^* dx_0 dx_1$ 。只需证明

1. Given $x_0, x_1 \sim p_{0,1}^*$ ，条件分布 $p_{t|0,1}^*$ 是 (6) 的最优解，两种匹配算法
2. Given (算法 1 和 2) 均返回 u_t^* 。

第一个陈述直接由 (3) 的正向-反向随机微分方程 (FBSDE) 表示得出，该表示最初由 Liu 等人 (2022, 定理 2) 推导。FBSDE 理论表明，桥接任意 $x_0, x_1 \sim p_{0,1}^*$ 的 (条件) 最优控制满足一个与 (6) 的 HJB 偏微分方程 (即 (18)) 唯一关联的倒向随机微分方程 (BSDE) (Pardoux & Peng, 2005)。这直接意味着 $p_{t|0,1}^*$ 是 (6) 的解

由于已知 u_t^* 是一个梯度场 (Liu 等人, 2022, 式 (3))，它必然与隐式匹配算法 (算法 1) 返回的解一致，因为 $\mathcal{L}_{\text{implicit}}$ 返回匹配 p_t^* 的唯一梯度场。另一方面，由于显式匹配损失 (5) 可以解释为马尔可夫投影 (Shi 等人, 2023)，即它返回与由 (6) 的解定义的互反路径测度 (Léonard, 2013; Léonard 等人, 2014) 在 KL 意义下最接近的马尔可夫过程。由于

(6) 的解，如第一个陈述所证明的，就是 $p_{t|0,1}^*$ ，因此最接近的马尔可夫过程按构造就是 u_t^* 。因此，第二个陈述也成立，证明完毕。需要注意的是，虽然 $\mathcal{L}_{\text{explicit}}$ 和 $\mathcal{L}_{\text{implicit}}$ 在一般情况下不具有相同的最小化点，但在平衡点 p_t^* 处它们确实相同。 $\square$

C 附加推导与讨论

C.1 显式匹配损失

(5) 如何保持规定的 p_t 。 (5) 的严格推导可参见例如 Shi 等人 (2023, 命题 2)，称为马尔可夫投影。这里我们提供另一种推导，更接近流匹配 (Lipman 等人, 2023) 中的推导。

引理 7. 设边缘分布 p_t 由条件概率路径的混合构造而成，其中 i.e., $p_t(x) := \mathbb{E}_{p_{0,1}}[p_t(x|x_0, x_1)]$ $p_t(x|x_0, x_1) \equiv p_{t|0,1}$ 是随机微分方程的时间边缘分布， $dX_t = u_t(X_t|x_0, x_1)dt + \sigma dW_t$, $X_0 = x_0$, $X_1 = x_1$ ，则满足由 p_t 规定的福克-普朗克方程的随机微分方程漂移项为

$$u_t^*(x) = \frac{\mathbb{E}_{p_{0,1}}[u_t(x|x_0, x_1)p_{t|0,1}(x|x_0, x_1)]}{p_t(x)}. \quad (29)$$

证明。只需验证 $u_t^*(x)$ 满足由 p_t 规定的福克-普朗克方程：

$$\begin{aligned} \frac{\partial}{\partial t} p_t(x) &= \int \left(\frac{\partial}{\partial t} p_{t|0,1} \right) p_{0,1} dx_{0,1} \\ &= \int (-\nabla \cdot (u_{t|0,1} p_{t|0,1})) p_{0,1} dx_{0,1} + \int \left(\frac{1}{2} \sigma^2 \Delta p_{t|0,1} \right) p_{0,1} dx_{0,1} \\ &\stackrel{(29)}{=} -\nabla \cdot (u_t^* p_t) + \frac{1}{2} \sigma^2 \Delta p_t. \end{aligned}$$

$\square$

引理 7 的一个直接推论是

$$\mathcal{L}_{\text{explicit}}(\theta) = \mathbb{E}_{p_t} \left[\frac{1}{2} \|u_t^\theta(X_t) - u_t^*(X_t)\|^2 \right] + \mathcal{O}(1), \quad (30)$$

其中 $\mathcal{O}(1)$ 与 θ 独立。因此， u_t^* 保持规定的 p_t 。

与隐式匹配的关系 (4)。 显式和隐式匹配损失都与某些回归目标相关，只是目标不同，i.e., u_t^* 在 (30) vs. ∇s_t^* 在第 2 节。正如 Neklyudov 等人 (2023) 所指出的，这两个目标通过亥姆霍兹分解相互关联 (Ambrosio 等人, 2008, 引理 8.4.2)，这表明 $u_t^* = \nabla s_t^* + w_t$ 其中 w_t 是无散度向量场，i.e., $\nabla \cdot (w_t p_t) = 0$ 。尽管这意味着 $\mathcal{L}_{\text{explicit}}$ 仅上界动能，但其顺序解，通过在第 2 阶段交替求解 (6)，从测度角度看仍然是良定义的 (Peluchetti, 2022; 2023; Shi 等人, 2023)。具体而言，顺序过程在由 (6) 的解定义的互易路径测度 (形式为 $p_t := \mathbb{E}_{p_{0,1}}[p_{t|0,1}]$) 与马尔可夫路径测度之间进行交替投影，并收敛到标准薛定谔桥问题的最优解。

C.2 高斯概率路径

解析条件漂移的推导 (8). 回顾 (7) 中的高斯路径近似：

$$X_t = \mu_t + \gamma_t Z, \quad Z \sim \mathcal{N}(0, \mathbf{I}_d),$$

这直接意味着速度矢量场与得分函数 (Särkkä & Solin, 2019; Albergo et al., 2023)：

$$\partial_t X_t = \partial_t \mu_t + \frac{\partial_t \gamma_t}{\gamma_t} (X_t - \mu_t), \quad \nabla \log p_t(X_t) = -\frac{1}{\gamma_t^2} (X_t - \mu_t).$$




图 10: 算法 6 如何忠实恢复协方差矩阵, 本例中为布朗桥。

Algorithm 6 CovSample (line 1 in Alg. 4)

Require: SDE (6b) with μ_t, γ_t
 Discretize $\bar{t} := [t_1, \dots, t_K]$, $0 < t_1 < \dots < t_K < 1$
 Solve $g_{\bar{t}}$ according the 1D ODE in (32)
 Compute covariance matrix $C_{\bar{t}} \in \mathbb{R}^{K \times K}$ by (33)
 Perform Cholesky decomposition $C_{\bar{t}} = L_{\bar{t}} L_{\bar{t}}^T$
 Sample $X_{\bar{t}} = \mu_{\bar{t}} + L_{\bar{t}} Z_{\bar{t}}$, $Z_{\bar{t}} \in \mathbb{R}^{K \times d}$, $[Z_{\bar{t}}]_{ij} \sim \mathcal{N}(0, 1)$
return $X_{\bar{t}}$

随后可构建条件漂移:

$$u_t(X_t|x_0, x_1) = \partial_t X_t + \frac{\sigma^2}{2} \nabla \log p_t(X_t) = \partial_t \mu_t + \frac{1}{\gamma_t} \left(\partial_t \gamma_t - \frac{\sigma^2}{2\gamma_t} \right) (X_t - \mu_t). \quad (31)$$

注意, (31) 式由于对 X_t 的线性性而具有梯度场的形式。可以验证, 将布朗桥 $\mu_t := (1-t)x_0 + tx_1$ 和 $\gamma_t := \sigma\sqrt{t(1-t)}$ 代入 (31) 式, 确实得到所需的漂移项 $\frac{x_1 - X_t}{1-t}$ 。

利用解析协方差函数的高效仿真 (脚注 4). 命题 4 需要来自路径空间中“联合”分布的样本。这需要顺序仿真, 在高维应用中可能扩展性较差。幸运的是, 对于具有由 (8) 给出的 (线性) 条件漂移 $u_{t|0,1}$ 的 (6b), 存在高效的计算方法, 因为 (6b) 的解析解为

$$X_t = e^{g_t} \left(x_0 + \int_0^t e^{-g_\tau} b_\tau d\tau + \int_0^t e^{-g_\tau} \sigma dW_s \right), \quad g_t := \int_0^t a_\tau d\tau, \quad (32)$$

$a_t := \frac{1}{\gamma_t} \left(\partial_t \gamma_t - \frac{\sigma^2}{2\gamma_t} \right)$ 其中 $\gamma_t \in \mathbb{R}$ 的定义如 (8), $b_t := \partial_t \mu_t - a_t \mu_t$ 所示, 且 $\int dW_s$ 为伊藤随机积分 (Itô, 1951)。两个时间步 s, t 之间的协方差函数, 使得 $0 \leq s < t \leq 1$, 可通过以下方式计算:

$$\begin{aligned} \text{Cov}(s, t) &= e^{g_s + g_t} \left\langle \int_0^s e^{-g_\tau} \sigma dW_\tau, \int_0^t e^{-g_\tau} \sigma dW_\tau \right\rangle \\ &\stackrel{(i)}{=} e^{g_s + g_t} \left\langle \int_0^s e^{-g_\tau} \sigma dW_\tau, \int_0^s e^{-g_\tau} \sigma dW_\tau \right\rangle \\ &\stackrel{(ii)}{=} e^{g_s + g_t} \int_0^s e^{-2g_\tau} \sigma^2 d\tau \\ &\stackrel{(iii)}{=} e^{g_t - g_s} \gamma_s^2, \end{aligned}$$

其中 (i) 源于伊藤积分在 $[0, s]$ 与 $[s, t]$ 之间的独立性, (iii) 源于伊藤等距性, 最后, $\gamma_s^2 = \text{Var}(s) := e^{2g_s} \int_0^s e^{-2g_\tau} \sigma^2 d\tau$ 的代入。

对 t, s 重复相同推导, 使得 $0 \leq t < s \leq 1$, 则 (6b) 在任意两个时间步 $s, t \in [0, 1]$ 之间的协方差函数可简洁地写为

$$\text{Cov}(s, t) = \gamma_{\min(s, t)}^2 e^{g_{\max(s, t)} - g_{\min(s, t)}}, \quad (33)$$

关键在于, 这仅需求解一个“一维”常微分方程 $d g_t = a_t dt, g_0 = 0$ 。我们在算法 6 中总结了该算法, 并在图 10 中给出了布朗桥的示例。再次强调, 所有计算均可按批次并行化。

C.3 二次 V AND $\sigma = 0$ 下 (6) 的解析解

回顾有限时域连续时间线性二次调节器, 其定义为:

$$\min_{u_t} x_1^\top F x_1 + \int_0^1 [x_t^\top Q x_t + u_t^\top R u_t] dt \quad \text{s.t. } \dot{x}_t = A x_t + B u_t, \quad (34)$$

其最优控制 $u_t^* = -R^{-1}BP_t x_t$ 可通过求解如下黎卡提微分方程获得：

$$-\dot{P}_t = A^\top P_t + P_t A - P_t B R^{-1} B^\top P_t + Q, \quad P_1 = F,$$

或等价地，求解如下李雅普诺夫微分方程（可验证对于所有 t ）：，有 $H_t = P_t^{-1}$ ）

$$\dot{H}_t = A H_t + H_t A^\top - B R^{-1} B^\top + H_t Q H_t, \quad H_1 = F^{-1}. \quad (35)$$

端点约束可通过设定 $F \rightarrow \infty$ 来考虑，如 Chen & Georgiou (2015) 所建议，从而得到 $H_1 = 0$ 。据此，对于二次的 $V(x) := \alpha \|x\|^2$ 和 $\sigma := 0$ ，方程 (6) 的解可通过求解 (35) 中的矩阵常微分方程获得，其中 $A = 0, B = I_d, R = \frac{1}{2} I_d$ ，以及 $Q = \alpha I_d$ ，该解具有类似 (19) 的双曲正切函数形式的解析解。

D 实验细节

D.1 实验设置

表 7: 各任务下 SplineOpt (算法 3) 的超参数。

	Stunnel	Vneck	GMM	Lidar	AFHQ	Opinion
Number of control pts. K	30	30	30	30	8	30
Number of gradient steps M	1000	3000	2000	200	100	700
Number of samples $ i $	4	4	4	4	4	4
Optimizer	SGD	SGD	SGD	mSGD	Adam	SGD

基线。所有 DeepGSB 实验均使用其官方实现⁵及默认超参数运行。我们采用“演员-评论家”参数化方式，因为它通常能带来更好的性能，尽管需要额外的价值网络。另一方面，我们自行实现了 DSBM，因为通过禁用 (6) 中 CondSOC 问题的优化并返回布朗桥的解析解，我们的 GSBM 可以等价于 DSBM。这使我们能够更有效地消融算法差异，确保任何性能差距都归因于 V_t 的存在。所有方法，包括我们的 GSBM，均在 PyTorch (Paszke 等人, 2019) 中实现。

网络架构。对于人群导航 (第 4.1 节) 和观点去极化 (第 4.3 节)，我们采用与 DeepGSB 相同的架构，该架构由 4 到 5 个残差块组成，并带有正弦时间嵌入。对于 AFHQ 任务，我们考虑 Dhariwal & Nichol (2021)⁶ 实现的 U-Net (Ronneberger 等人, 2015) 架构。所有网络均从头开始训练，不使用任何预训练检查点，并使用 AdamW (Loshchilov & Hutter, 2019) 进行优化。

任务特定噪声水平 (σ)。对于具有平均场成本的群体导航任务，我们采用 $\sigma = \{1.0, 2.0\}$ ，而观点去极化任务使用 $\sigma = 0.5$ 。这些值继承自 DeepGSB。另一方面，我们分别对 LiDAR 和 AFHQ 任务使用 $\sigma = 1$ 和 0.5 。

GSBM 超参数。表 7 总结了样条优化中使用的超参数。默认情况下，生成过程离散为 1000 步，但观点去极化任务除外，我们遵循 DeepGSB 的设置并离散为 300 步。

GSBM 实现 (前向与后向方案)。在实践中，我们采用 DSBM (Shi 等人, 2023) 中提出的相同“前向与后向”方案，参数化两个漂移项，一个用于前向随机微分方程，另一个用于后向。在奇数训练轮次中，我们从前向漂移模拟耦合 (算法 5 第 4 行)，求解相应的条件随机最优控制问题 (6)，然后将得到的 p_t 与后向漂移匹配。相反，在偶数训练轮次中，我们遵循反向过程，将前向漂移与从后向漂移获得的 p_t 匹配。前向-后向交替方案通常能提升性能，因为前向漂移始终匹配真实终端分布 $p_1 = \nu$ (后向漂移反之亦然)。⁵ <https://github.com/ghliu/DeepGSB>，遵循 Apache 许可证。⁶ <https://github.com/openai/guided-diffusion>，遵循 MIT 许可证。

人群导航设置。所有三个平均场任务——Stunnel、Vneck 和 GMM——均采用自 DeepGSB，如图 11 所示。我们略微修改了 GMM 的初始分布，以验证完全多模态分布。对于平均场交互代价 (12)，Vneck 任务考虑熵代价，Stunnel 和 GMM 任务考虑拥堵代价。我们调整 L_{obstacle} 与 L_{interact} 之间的乘法因子，以确保启用平均场交互时发生明显变化；见表 8。这些因子远大于 DeepGSB 中考虑的因子 ($\lambda_2 < 3$)。在实践中，我们软化障碍代价以保证可微性，类似于先前工作 (Ruthotto et al., 2020; Lin et al., 2021)，并将 $p_t(x) \approx \sum_{(x_0, x_1)} p_t(x|x_0, x_1)$ 近似为高斯混合。




图 11: 每个具有平均场状态成本的群体导航任务的初始和终端分布。障碍物标记为灰色。

表 8: 每个群体导航任务的状态成本乘法因子: $V_t(x) = \lambda_{\text{obs}} L_{\text{obstacle}}(x) + \lambda_{\text{int}} L_{\text{interact}}(x; p_t)$ 。

	Stunnel	Vneck	GMM
λ_{obs}	1500	3000	1500
λ_{int}	50	8	5

AFHQ 设置。由于我们的状态代价 V_t 通过潜空间定义，我们预训练一个 β -VAE (Higgins et al., 2016)，其中 $\beta = 0.1$ 。另一方面，球面线性插值 (Slerp; Shoemake (1985)) 指的是沿大圆弧的恒速旋转运动：

$$I_{\text{Slerp}}(t, z_0, z_1) := \frac{\sin((1-t)\Omega)}{\sin\Omega} z_0 + \frac{\sin(t\Omega)}{\sin\Omega} z_1, \quad \Omega = \arccos(\langle z_0, z_1 \rangle). \quad (36)$$

D.2 观点去极化




图 12: $\mathbb{R}^{1000}$ 中极化漂移 (37) 的仿真。

极化漂移 (15)。我们使用与 DeepGSB 相同的极化漂移，基于政党模型 (Gaitonde et al., 2021)。在每个时间步 t ，所有智能体接收相同的随机信息 $\xi_t \in \mathbb{R}^d$ ，该信息独立于 p_t 采样，然后根据以下方式对该信息做出反应

$$f_{\text{polarize}}(x; p_t, \xi_t) := \mathbb{E}_{y \sim p_t} [a(x, y, \xi_t) \bar{y}], \quad a(x, y, \xi_t) := \begin{cases} 1 & \text{if } \text{sign}(\langle x, \xi_t \rangle) = \text{sign}(\langle y, \xi_t \rangle) \\ -1 & \text{otherwise} \end{cases}, \quad (37)$$

其中 $\bar{y} := y/\|y\|_2$ 和 $a(x, y, \xi_t)$ ——一致性函数——指示两个观点 x 和 y 是否在信息 ξ_t 上达成一致。因此，(37) 表明智能体倾向于接受他们同意的观点，同时对他们不同意的观点表现出敌意。已知这会产生极化，如图 12 所示。

方向相似性图示 图 7 和图 12。方向相似度是观点建模的标准可视化方法 (Schweighofer 等人, 2020)，它统计成对观点之间余弦角的直方图。因此，更平坦的方向相似度表明观点分布极化程度较低。

D.3 利用激光雷达数据逼近几何流形

由于激光雷达数据是 $[-5, 5]^3 \subset \mathbb{R}^3$ 中的点云集合，我们采用标准方法将其更多地视为黎曼流形。对于环境空间中的每个点，我们首先取 k 个最近邻并拟合二维切平面来定义投影算子。设 $\mathcal{N}_k(x) = \{x_1, \dots, x_k\}$ 为环境空间中查询点 $x \in \mathbb{R}^3$ 的 k 个最近邻集合。我们

然后通过移动最小二乘法拟合一个二维平面 (Levin, 1998; Wendland, 2004) ,

$$\arg \min_{a,b,c} \frac{1}{k} \sum_{i=1}^k w(x, x_i) (ax_i^{(x)} + bx_i^{(y)} + c - x_i^{(z)})^2 \quad (38)$$

其中上标表示 x, y, z 坐标, 我们使用加权 $w(x, x_i) = \exp\{-\|x - x_i\|/\tau\}$, 其中 $\tau = 0.001$ 。我们通过伪逆求解此问题, 得到近似切平面 $ax + by + c = z$ 。当 $k \rightarrow \infty$ 时, 该切平面是光滑的; 然而, 我们发现使用 $k = 20$ 在我们的实验中效果足够好, 且我们的 GSBM 算法对 k 的值具有鲁棒性。然后利用该平面定义投影算子 $\pi(x)$ 。

$$\pi(x) = x - \left(\frac{x^\top n + c}{\|n\|^2} \right) n, \quad \text{where } n = [a \ b \ -1]^\top. \quad (39)$$

该投影算子足以将激光雷达数据集视为流形。对 π 进行微分将自动把梯度投影到切平面上。这将确保通过状态代价 V_t 进行的优化被恰当地投影到切平面上, 从而允许我们优化诸如轨迹在流形上的高度等量。

本文所使用的精确状态代价包含一项额外的边界约束:

$$V(x) = \lambda \left[\underbrace{\|\pi(x) - x\|^2}_{L_{\text{manifold}}} + \underbrace{\exp(\pi(x)^{(z)})}_{L_{\text{height}}} + \underbrace{\sum_{p \in \{x^{(x)}, x^{(y)}\}} \text{sigm}(p^{-5/0.1}) + (1 - \text{sigm}(p^{+5/0.1}))}_{L_{\text{boundary}}} \right], \quad (40)$$

其中“sigm”是 Sigmoid 函数, 用于松弛边界约束。损失 L_{boundary} 仅确保我们不会离开激光雷达数据存在的区域。我们设定 $\lambda = 5000$ 。 $L_{\text{manifold}}(x)$ 的梯度将 x 沿与切平面正交的方向移动, 而 $L_{\text{height}}(x)$ 的梯度将 x 沿切平面上的方向移动。如果我们仅有 L_{manifold} , 则 CondSOC 本质上求解测地线路径, 并且当 $\sigma \rightarrow 0$ 时, 我们恢复了黎曼流匹配 (Riemannian Flow Matching) (Chen & Lipman, 2023) 的近似 (在环境空间中参数化)。状态代价 L_{height} 依赖于 $\pi(x)$, 因为这确保我们在优化高度时沿山坡下行。当然, 也可以考虑其他状态代价来代替 L_{height} 。

D.4 附加实验结果




图 13: 展示不同耦合 $X_1|x_0$ 如何在非平凡状态代价 $V(x)$ 下出现的示意图。

非平凡 $V(x)$ 诱导出不同的耦合。图 13 展示了不同耦合 $X_1|x_0$ 如何在非平凡状态代价 $V(x)$ 下出现。具体而言, 我们用不同颜色标记初始分布 (最左列) 的不同区域, 并跟踪它们的推前映射。我们考虑相同的 $V(x)$, i.e., 障碍物和拥堵代价, 用于 Stunnel (顶行), 并对 Spiral $\rightarrow$ Moon (底行) 采用二次代价。在这两种特定情况下, 非平凡的 $V(x)$ 促进了更强的混合, 从而产生了与没有 $V(x)$ 时 (中间列) 所诱导的耦合不同的耦合 (最右列)。



图 14: 通过随机采样的 (x_0, x_1) 的 $p_t(X_t|x_0, x_1)$ 均值, 对 DSBM (Shi et al., 2023) 与我们的 GSBM 进行额外比较。DSBM 仅在 x_0 和 x_1 之间进行线性插值, 而我们的 GSBM 针对 (6) 进行优化, 其中 V_t 通过潜空间定义, 从而展现出更具语义意义的插值。

表 9: NLSB (Koshizuka & Sato, 2023) 与我们的 GSBM 之间的定量比较。注意, 我们的 GSBM 始终确保可行性。相比之下, NLSB 通过将 GSB 问题转化为具有软终端代价的随机最优控制 (SOC) 问题 (见附录 A) 来处理该问题, 可能过度强调最优性而牺牲可行性。

	Feasibility $\mathcal{W}(p_1^\theta, \nu)$			Optimality (3)		
	Stunnel	Vneck	GMM	Stunnel	Vneck	GMM
NLSB (Koshizuka & Sato, 2023)	30.54	0.02	67.76	207.06	147.85	4202.71
GSBM (ours)	0.03	0.01	4.13	460.88	155.53	229.12




图 15: NLSB (Koshizuka & Sato, 2023) 在相同人群导航任务上的性能。注意, NLSB 在 Stunnel 上陷入了某些局部极小值, 并在 GMM 上完全失败。

AFHQ 上的额外插值结果。图 14 提供了 DSBM (Shi 等人, 2023) 与本文 GSBM 在 $p_t(X_t|x_0, x_1)$ 上随机采样 (x_0, x_1) 时的比较结果。

具有平均场成本的群体导航的额外比较。

表 9 和图 15 报告了 NLSB⁷ (Koshizuka 与 Sato, 2023) 的性能——这是一种基于伴随的方法, 用于近似⁷ <https://github.com/take-koshizuka/nlsb>, 采用 MIT 许可证。

求解同一 GSB 问题 (3) 的解。图 16 提供了 DeepGSB (Liu 等人, 2022) 与本文 GSBM 之间的额外比较。显然, 本文 GSBM 优于这两种方法。




图 16: DeepGSB (Liu 等人, 2022) 与本文 GSBM 在 (从上到下) Stunnel 上 $\sigma = 2.0$ 和 Vneck 上 $\sigma = \{1.0, 2.0\}$ 的额外比较。再次注意 DeepGSB 的训练如何表现出相对不稳定性和偶发散。