

通过原始 Wasserstein 状态占用匹配的离线观察模仿

严凯¹ Alexander G. Schwing¹ Yu-Xiong Wang¹

摘要

在现实场景中，与环境的任意交互往往代价高昂，且专家示范的动作并非总能获得。为减少对两者的依赖，离线观察学习（Learning from Observations, LfO）被广泛研究：智能体仅凭专家状态和任务无关的非专家状态-动作对来学习解决任务。最先进的分布校正估计（Distribution Correction Estimation, DICE）方法，如 SMODICE，最小化学习者策略与经验专家策略之间的状态占用散度。然而，此类方法仅限于 f -散度（KL 散度和 χ^2 ）或采用鲁宾斯坦对偶的瓦瑟斯坦距离，后者限制了底层距离度量，而该度量对基于瓦瑟斯坦的解决方案的性能至关重要。为支持更灵活的距离度量，我们提出原始瓦瑟斯坦 DICE（Primal Wasserstein DICE, PW-DICE）。它最小化学习者与专家状态占用之间的原始瓦瑟斯坦距离，并利用对比学习得到的距离度量。理论上，我们的框架是 SMODICE 的推广，也是首个统一 f -散度与瓦瑟斯坦最小化的工作。实验上，我们发现 PW-DICE 优于多种最先进的方法。代码可在 <https://github.com/KaiYan289/PW-DICE> 获取。

1. 引言

近年来，离线强化学习（Reinforcement Learning, RL）取得了显著进展（Chen 等, 2021b; Kostrikov 等, 2022a; b）：序贯决策问题通过独立收集的交互数据得以解决。¹ 伊利诺伊大学厄巴纳-香槟分校格兰杰工程学院，美国伊利诺伊州厄巴纳。通讯作者：严凯 <kaiyan3@illinois.edu>。

Proceedings of the 41st International Conference on Machine Learning, Vienna, Austria. PMLR 235, 2024. Copyright 2024 by the author(s).

数据而非在线交互，后者通常成本高昂（例如自动驾驶（Kiran 等, 2021））。即使没有在线交互，这些方法也能达到高样本效率。然而，此类方法需要奖励标签，而在自然环境中收集数据时，这些标签往往缺失（Chang 等, 2020）。此外，对于许多任务（如机器人操作），获取有信息量的奖励代价高昂，因为它需要精心手工设计（Yu 等, 2019）。为了绕过对奖励标签的需求，离线模仿学习（Imitation Learning, IL）已广泛流行（Hakhamaneshi 等, 2022; Ho 和 Ermon, 2016; Kim 等, 2022a）。它使智能体能够从现有演示中学习，而无需奖励标签。然而，与奖励标签一样，专家演示同样昂贵且往往稀缺，因为需要为每个目标任务反复收集。在各类专家数据短缺中，有一种被广泛研究的类型：离线观察学习（Learning from Observations, LfO）。在 LfO 中，仅记录专家状态，而非同时记录状态和动作。当从具有不同具身形态的专家（Ma 等, 2022）或视频演示（Chen 等, 2021a）中学习时，该设置十分有用，因为专家动作要么不适用，要么不可用。

因此，在离线观察模仿（LfO）中提出了许多方法，包括逆强化学习（Zolna 等, 2020; Torabi 等, 2019; Kostrikov 等, 2019）、基于相似度的奖励标记（Sermanet 等, 2017; Chen 等, 2021a）以及动作伪标记（Torabi 等, 2018; Kumar 等, 2019）。观察模仿的最先进解决方案是分布校正估计（DICE）方法族，即 LobsDICE（Kim 等, 2022b）和 SMODICE（Ma 等, 2022）：这两种方法都在对偶空间中执行凸优化，以最小化学习者和从数据集中近似的经验专家策略之间状态占用（访问频率）的 f -散度。值得注意的是，DICE 方法主要关注 f -散度（Kim 等, 2022b; Ma 等, 2022; Kostrikov 等, 2020; Kim 等, 2022a）（主要是 KL 散度和 χ^2 -散度；定义见附录 B），这些度量忽略了分布的一些潜在几何特性（Stanczuk 等, 2021）。虽然存在一种 DICE 变体 SoftDICE（Sun 等, 2021），它将 Wasserstein 距离引入 DICE 方法，但它采用了康托罗维奇-鲁宾斯坦对偶性（Kantorovich & Rubinstein, 1958; Peyré & Cuturi,

2019)，这限制了底层距离度量的选择：对偶性要求底层度量是欧几里得的（Stanczuk 等，2021）。距离度量的这种限制不仅在理论上不利，而且影响实际性能。具体而言，我们发现基于 Wasserstein 的方法中的距离度量对性能至关重要（第 3.1 节）。

为实现更灵活的距离度量，本文提出原始瓦瑟斯坦 DICE（PW-DICE），一种优化瓦瑟斯坦距离原始形式的 DICE 方法。PW-DICE 如图 1 所示。借助适当的离线悲观正则化器（Jin 等，2021），瓦瑟斯坦匹配变量与学习者策略的联合最小化可表述为拉格朗日空间上的凸优化。随后通过加权行为克隆检索策略，权重由拉格朗日函数确定。与 SMODICE 和 LobsDICE 不同，本文的底层距离度量可任意选择；与所有先前工作不同，本文探索了从数据中对学习度量的可能性。与现有基于瓦瑟斯坦的工作相比——这些工作要么使用 Rubinstein 对偶，要么选择简单固定的度量（例如 PWIL（Dadashi 等，2021）使用欧氏距离，OTR（Luo 等，2023）使用余弦距离）——本文的努力赋予 PW-DICE 更大的灵活性。同时，通过特定选择的超参数，SMODICE 可作为 PW-DICE 的特例获得，这在理论上保证了本文的性能。

本文将贡献总结如下：1) 据本文所知，这是首项揭示 LfO 中底层距离度量实际重要性的工作；2) 本文提出一种新颖的离线 LfO 方法 PW-DICE，该方法使用原始瓦瑟斯坦距离进行 LfO，在距离度量方面比先前工作获得更大灵活性，同时消除了数据覆盖假设；3) 本文从理论上证明 PW-DICE 是 SMODICE 的推广，从而为基于瓦瑟斯坦和 f 散度的 DICE 方法提供了首个统一框架；4) 本文通过实验表明，在多个离线 LfO 测试平台上，本文方法取得了优于最新技术的结果。

2. 预备知识

马尔可夫决策过程。马尔可夫决策过程（MDP）是序贯决策问题中被广泛采用的表述。一个 MDP 包含五个组成部分：状态空间 S 、动作空间 A 、转移函数 T 、奖励 r 和折扣因子 γ 。MDP 以离散步骤演化：在第 $t \in \{0, 1, 2, \dots\}$ 步，给定状态 $s_t \in S$ ，智能体遵循其策略 $\pi(a_t|s_t) \in \Delta(A)$ （其中 $\Delta(A)$ 是 A 上的概率单纯形）选择动作 $a_t \in A$ 。在收到 a_t 后，MDP 根据转移概率转移到新状态 $s_{t+1} \in S$

函数 $T(s_{t+1}|s_t, a_t)$ ，并产生奖励 $r(s_t, a_t) \in \mathbb{R}$ 作为反馈。智能体需要最大化折扣总奖励 $\sum_t \gamma^t r(s_t, a_t)$ ，其中折扣因子为 $\gamma \in [0, 1]$ 。马尔可夫决策过程的一次完整运行定义为一个回合，沿轨迹收集的状态（-动作）对为 τ 。状态占用，即在给定策略 π 下状态的访问频率，为 $d_s^\pi(s) = (1 - \gamma) \sum_t \gamma^t \Pr(s_t = s)$ 。关于状态占用及其他占用的更严格定义见附录 B。

离线观察模仿学习（LfO）。在离线观察模仿学习中，智能体需要从两类数据中学习：1) 专家数据集 E ，包含解决确切目标任务的仅状态轨迹 $\tau_E = \{s_1, s_2, \dots, s_{n_1}\}$ ；2) 与任务无关的非专家数据集 I ，由相关性较低的状态-动作轨迹 $\tau_I = \{(s_1, a_1), (s_2, a_2), \dots, (s_{n_2}, a_{n_2})\}$ 组成。理想情况下，智能体从 I 中学习环境动态，并利用从 I 推断出的马尔可夫决策过程信息，尝试跟随 E 中的专家状态。离线观察模仿学习中最先进的方法是 SMODICE（Ma 等，2022）和 LobsDICE（Kim 等，2022b）。这两种方法在本质上相似，前者最小化状态占用散度，后者优化相邻状态对占用散度。

Wasserstein 距离。Wasserstein 距离，也称为推土机距离（EMD）（Kantorovich，1960），被广泛用作两个概率分布之间的距离。它更好地捕捉了底层空间的几何结构，并且不要求支撑集之间存在交集。对于状态空间 S 上的两个分布 $p \in \Delta(S), q \in \Delta(S)$ ，具有底层度量 $c(x, y) : S \times S \rightarrow \mathbb{R}$ 的 Wasserstein 距离 $\mathcal{W}$ 可以写为 $\mathcal{W}(p, q) = \inf_{\Pi \in \Pi(p, q)} \sum_{x \in S} \sum_{y \in S} \Pi(x, y) c(x, y)$ ，这是 Wasserstein 距离的原始形式； Π 是 p 和 q 之间的匹配变量。Wasserstein 距离还具有等价的 Kantorovich-Rubinstein 对偶形式（Kantorovich & Rubinstein，1958），即 $\mathcal{W}(p, q) = \max_{\|f\|_L \leq 1} \mathbb{E}_{x \sim p} f(x) - \mathbb{E}_{y \sim q} f(y)$ ，其中 $\|f\|_L \leq 1$ 表示函数 f 是 1-Lipschitz 的。虽然这种形式常被机器学习社区采用，但 Lipschitz 约束在实践中通常通过梯度正则化器来实现。由于梯度是使用欧氏距离定义的，因此 Rubinstein 对偶性的底层距离度量也被限制为欧氏距离（Stanczuk 等，2021），这通常是次优的。

3. 方法

本节组织如下：在第 3.1 节中，我们首先验证我们的动机，即通过比较度量来选择适当距离度量的重要性

除非另有说明，本文仅考虑 1-瓦瑟斯坦距离。




图 1. 本文方法 PW-DICE 的示意图。a) 问题设定：不同轨迹用不同样式的箭头表示。b) PW-DICE 最小化学习者状态占用 $d_s^\pi(s)$ 与专家状态占用 $d_s^E(s)$ 之间的正则化 1-沃瑟斯坦距离。底层距离函数通过对比学习来表示状态之间的可达性。c) 根据匹配结果，为下游加权行为克隆 (Behavior Cloning, BC) 计算权重以恢复策略。透明度高表示该状态及其对应动作的权重小。




图 2. 使用 OTR (Luo 等, 2023) (第一列) 和 SMODICE (Ma 等, 2022) (第二、三列) 时，默认 (归一化余弦) 距离度量与欧氏距离度量的性能比较。结果表明，底层距离度量对基于沃瑟斯坦的方法的性能至关重要。

现有的基于沃瑟斯坦的解决方案；然后，我们在第 3.2 节详细阐述所提出的优化目标；最后，在第 3.3 节讨论距离度量的选择。符号参考见附录 F 中的表 2，详细推导见附录 C。

3.1. 动机验证

如第 1 节所述，我们的目标是改进从专家数据集估计的学习者策略与专家策略之间的发散最小化思想。为此，我们建议使用原始沃瑟斯坦距离，它允许灵活地使用任意底层距离度量。为了展示距离度量的重要性以及能够选择它们的优势，我们研究了最优传输奖励 (Optimal Transport Reward, OTR) (Luo 等, 2023)，这是一种当前基于沃瑟斯坦的模仿学习方法，可应用于我们的仅从观察学习 (Learning from Observation, LfO) 设定。OTR 优化任务无关数据集中每条轨迹与专家轨迹之间的原始沃瑟斯坦距离。

轨迹，并利用结果对任务无关数据集中的每个状态分配奖励。随后，应用离线强化学习以检索最优策略。图 2 展示了 OTR 在 D4RL MuJoCo 数据集上的结果 (详见第 4.2 节)，测试环境同时出现在 SMODICE (Ma 等, 2022) 和 OTR 中。我们测试了 Luo 等 (2023) 中使用的基于余弦相似度的占用度量以及欧氏距离作为底层距离度量。结果表明，距离度量对结果有显著影响。因此，选择合适的度量对于基于 Wasserstein 的解法的性能至关重要。

该实验促使我们开发一种方法，允许在基于 Wasserstein 的公式中使用任意距离度量。此外，观察到的性能差异启发我们自动选择度量，超越余弦和欧氏等经典度量。接下来讨论所提方法的公式化。

3.2. 优化目标

我们的目标是优化由策略 π 诱导的模型估计状态占用 $d_s^\pi(s)$ 与从专家数据估计的经验状态占用 $d_s^E(s)$ 之间的原始 Wasserstein 距离。这可以通过以下规划形式化：

$$\min_{\Pi, \pi} \sum_{s_i \in S} \sum_{s_j \in S} \Pi(s_i, s_j) c(s_i, s_j), \text{ s.t. } d_{sa}^\pi \geq 0, \Pi \geq 0; \quad (1)$$

$$\forall s \in S, d_s^\pi(s) = (1 - \gamma)p_0(s) + \gamma \sum_{\bar{s}, \bar{a}} d_{sa}^\pi(\bar{s}, \bar{a}) p(s|\bar{s}, \bar{a});$$

$$\forall s_i, s_j \in S, \sum_k \Pi(s_k, s_j) = d_s^E(s_j), \sum_k \Pi(s_i, s_k) = d_s^\pi(s_i).$$

在式 (1) 中，我们使用 $\Pi(s_i, s_j)$ 作为两个状态占用分布 $d_s^\pi(s)$ 和 $d_s^E(s)$ 之间的匹配变量， $c(s_i, s_j)$ 是状态 s_i 与

s_j 之间的距离。此外, d_{sa}^π 是学习策略 π 的状态-动作占用, $p_0 \in \Delta(S)$ 是 MDP 初始状态的分布。注意式 (1) 中有两类约束: 第一行与 $d_{sa}^\pi \geq 0$ 一起是匹配变量 Π 的边际约束。第二行和 $\Pi \geq 0$ 是 Bellman 流约束 (Ma 等, 2022), 确保 d_s^π 与可行策略 π 之间的对应关系。

对于表格型 MDP, 式 (1) 可以通过任何线性规划 (LP) 求解器求解, 因为目标和约束都是线性的。然而, 对于任何具有连续状态或动作空间的 MDP, 使用 LP 求解器是不切实际的。在这些情况下, 需要将问题转化为易于优化的形式。消除约束的常用方法是考虑拉格朗日对偶问题。然而, 带约束的 LP 的拉格朗日对偶问题也是带约束的 LP。为了减少对偶规划中的约束, 我们通过以下方式平滑目标:

$$\Pi(s_i, s_j)c(s_i, s_j) + \epsilon_1 D_f(\Pi \| U) + \epsilon_2 D_f(d_{sa}^\pi \| d_{sa}^I). \quad (2)$$

在公式 (2), d_s^I 中, d_s 和 d_{sa}^I 分别是任务无关数据集 I 的经验状态占用和经验状态-动作占用。此外, 我们令 $U(s, s') = d_s^E(s)d_{s'}^I(s')$, i.e., U 为两个独立分布 d_s^E 与 $d_{s'}^I$ 的乘积。而且, $\epsilon_1 > 0, \epsilon_2 > 0$ 是超参数, D_f 可以是任意 f -发散 (本文重点关注 KL 散度)。注意, 尽管使用了 f 发散, 但与 SMODICE (Ma 等人, 2022) 或 LobsDICE (Kim 等人, 2022b) 不同, 该公式不要求任务无关数据对专家数据具有数据覆盖。这两个正则化项是“悲观的”: 它们鼓励智能体保持在数据集的支持集内, 这在离线模仿学习/强化学习中很常见 (Jin 等人, 2021)。

鉴于目标函数光滑, 我们应用芬切尔对偶性在对偶空间中推导出鲁棒的单层优化。详细推导见附录 C.2。

当令 D_f 为 KL 散度时 (关于 χ^2 -散度的讨论见附录 E.2), 对偶规划如下:

$$\begin{aligned} \min_{\lambda} \quad & \epsilon_1 \log \mathbb{E}_{s_i \sim I, s_j \sim E} \exp \left(\frac{\lambda_{i+|S|} + \lambda_{j+2|S|} - c(s_i, s_j)}{\epsilon_1} \right) \\ & + \epsilon_2 \log \mathbb{E}_{(s_i, a_j) \sim I} \exp \left(\frac{-\gamma \mathbb{E}_{s_k \sim p(\cdot | s_i, a_j)} \lambda_k + \lambda_i - \lambda_{i+|S|}}{\epsilon_2} \right) \\ & - [(1 - \gamma) \mathbb{E}_{s \sim p_0} \lambda_{:|S|} + \mathbb{E}_{s \sim E} \lambda_{2|S|:3|S|}]. \end{aligned} \quad (3)$$

直观上, 目标中的对偶变量 $\lambda \in \mathbb{R}^{3|S|}$ 分为三部分, 每部分大小为 $|S|$: $\lambda_i, i \in \{1, 2, \dots, |S|\}$ 可视为值函数的方差, 其中 $-\gamma \mathbb{E}_{s_k \sim p(\cdot | s_i, a_j)} \lambda_k + \lambda_i - \lambda_{i+|S|}$ 是其贝尔曼残差, 或负 TD(0) 优势。 $\lambda_{i+|S|}$ 和 $\lambda_{i+2|S|}$ 是附加到特定状态上的代价: 如果我们比较

将 Wasserstein 匹配比作运输概率质量, $\lambda_{i+|S|}$ 是从 π 的状态出发的装载成本, $\lambda_{i+2|S|}$ 是到达 E 的状态的卸载成本。注意, 根据定理 C.1 (详细推导见附录 C.2), 我们

$$\text{have } d_{sa}^\pi = d_{sa}^I \cdot \text{softmax} \left(\frac{-\gamma \mathbb{E}_{s_k \sim p(\cdot | s_i, a_j)} \lambda_k + \lambda_i - \lambda_{i+|S|}}{\epsilon_2} \right)$$

在最优时, softmax 的分母对所有状态-动作对求和。

在 λ 优化后, 我们通过加权行为克隆恢复期望策略 π , 最大化以下目标:

$$\begin{aligned} \mathbb{E}_{(s_i, a_j) \sim d_{sa}^\pi} \log \pi(a_j | s_i) &= \mathbb{E}_{(s_i, a_j) \sim I} \frac{d_{sa}^\pi(s_i, a_j)}{d_{sa}^I(s_i, a_j)} \log \pi(a_j | s_i) \\ &\propto \mathbb{E}_{(s_i, a_j) \sim I} \exp \left(\frac{-\gamma \mathbb{E}_{s_k} \lambda_k + \lambda_i - \lambda_{i+|S|}}{\epsilon_2} \right) \log \pi(a_j | s_i). \end{aligned} \quad (4)$$

在实践中, 我们对 $p(\cdot | s_i, a_j)$, a 方法使用 1 样本估计, 该方法在先前工作中被证明简单有效 (Ma 等, 2022; Kim 等, 2022b)。也就是说, 我们从数据集中采样 $(s_i, a_j, s_k) \sim I$ 而不是 (s_i, a_j) , 并使用对应于 s_k 的 λ_k 作为 $\mathbb{E}_{s_k \sim p(\cdot | s_i, a_j)} \lambda_k$ 的估计。由于实际中状态数量可能无限, 我们使用一个三头神经网络 $\lambda_s, \lambda_{s+|S|}, \lambda_{s+2|S|}$ 来估计给定状态 s 。算法伪代码见附录 A, 其中我们通过式 (3) 迭代优化对偶, 并通过式 (4) 获得策略 π 。

重要的是, 注意我们的公式可以视为 SMODICE (Ma 等人, 2022) 的泛化。不难看出原因, 我们接下来指出这一点。SMODICE 使用 KL 散度的目标如下:

$$\begin{aligned} \min_V \quad & \log \mathbb{E}_{(s, a) \sim I} [\exp(R(s) + \gamma \mathbb{E}_{s' \sim (s, a)} V(s')) - V(s)] + \\ & (1 - \gamma) \mathbb{E}_{s \sim p_0} [V(s)], \end{aligned} \quad (5)$$

其中 $V(s)$ 是价值函数, $R(s)$ 是为状态分配的奖励。容易看出 λ_i 对应于 SMODICE 中的 $V(s)$, 并且 SMODICE 是 PW-DICE 在 $\epsilon_1 \rightarrow 0, \epsilon_2 = 1$ 和 $c(s, s') = -R(s)$ 时的特例。我们强调, 在 SMODICE 设置中, 距离 $c(s, s')$ 仅依赖于第一个状态 s 。因此, 对于给定 π , i.e., d_s^π 的特定状态占用, 任何匹配计划的总匹配成本是固定的。同时, 具有大系数 ϵ_2 的悲观正则化项占主导地位。这种泛化性质也适用于其他散度, 例如 χ^2 。更严格的推导见附录 C。

3.3. 底层距离度量

给定式 (3) 和式 (4), 仍需选择距离度量 $c(s_i, s_j)$ 。对于表格情况, 可以使用最简单的距离, 即当 $s_i \neq s_j$ 时 $c(s_i, s_j) = 1$, 否则为 0。然而, 这种距离在连续情况下仅提供“稀疏”信息。该距离大多

为 0，并且如果专家数据集 E 和任务无关数据集中没有共同状态，则会退化为全零。为了解决这个问题，先前的 I 工作探索了许多启发式选择，例如余弦相似度（Luo 等人，2023）或欧氏距离（Sun 等人，2021）。然而，如第 3.1 节验证我们的动机时所示，这些选择对于特定环境往往不是最优的。

在这项工作中，受 CURL（Laskin 等人，2020）和 SMODICE（Ma 等人，2022）的启发，我们提出了一种加权，由 $R(s) = \log \frac{d_s^E(s)}{\overline{d_s^I(s)} + \alpha \overline{d_s^E(s)}}$ 以及通过 InfoNCE（Wan 等人，2021）损失学习的嵌入之间的欧氏距离组成。更具体地说，我们令距离度量 c 为

$$c(s_i, s_j) = R(s_i) + \beta \|g(s_i) - g(s_j)\|_2^2, \quad (6)$$

其中 $g(s_i), g(s_j)$ 分别是状态 s_i, s_j 的学习嵌入， α 是接近 0 的正常数， $\beta \geq 0$ 是超参数。

距离函数由两部分组成。第一部分 $R(s_i)$ 是 SMODICE 奖励函数 $\log \frac{d_s^E(s)}{\overline{d_s^I(s)}}$ 的修改版本。直观上，较高的 $\log \frac{d_s^E(s)}{\overline{d_s^I(s)}}$ 表明状态 s 被专家访问的频率高于生成任务无关数据的智能体，这可能是可取的。这种奖励可以通过训练一个判别器 $h(s)$ 来获得，该判别器将来自 E 的专家状态标记为 1，非专家状态标记为 0。如果 h 是最优的，即 $h(s) = h^*(s) = \frac{d_s^E(s)}{\overline{d_s^E(s)} + \overline{d_s^I(s)}}$ ，则我们有。基于此，我们改变分母

$\frac{d_s^E(s)}{\overline{d_s^I(s)}} = \log \frac{h^*(s)}{1-h^*(s)}$
 nator $d_s^E(s)$ 到 $(1-\alpha)\overline{d_s^I(s)} + \alpha d_s^E(s)$ 以解除任务无关数据集 I 覆盖专家数据集 E , i.e., d_s^I 的理论假设 $s(s) > 0$ 无论 $d_s^E(s) > 0$ 。

第二部分使用通过 InfoNCE（Wan 等人，2021）学到的嵌入 $g(s)$ ，该嵌入也被 CURL（Laskin 等人，2020）和 FIST（Hakhamaneshi 等人，2022）采用。与 CURL 不同，在 CURL 中对比学习是作为强化学习之外的辅助损失以更好地提取特征；与 FIST 不同，FIST 试图寻找当前状态与数据集中某个状态之间的相似性，我们希望 $g(s)$ 和 $g(s')$ 相似当且仅当它们在任务无关数据集中沿轨迹可达。为此，我们采样一批连续状态对 $(s_i, s'_i), i \in \{1, 2, \dots\}$ ，并使用以下损失函数：

$$\log \frac{\exp(g(s_i)^T W g(s'_i))}{\exp(g(s_i)^T W g(s'_i)) + \sum_{j \neq i} \exp(g(s_i)^T W g(s'_j))}. \quad (7)$$

这里， $g(s_i)$ 可以看作对比学习中的锚点， W 是学习到的矩阵， $g(s'_i)$ 是其正键， $g(s'_j), j \neq i$ 是其负键。直观上，其思想是学习一个好的嵌入空间，在该空间中状态的邻域可以通过嵌入向量之间的欧氏距离来评估。我们将邻域定义为“可达性”

状态之间：如果一个状态可以通过任务无关数据中的轨迹到达另一个状态，那么状态应该接近，否则它们彼此远离。这个定义将导致成功的状态在嵌入空间中分组（可视化见图 6），同时对状态的实际数值具有鲁棒性（经验评估见第 4.2 节）。

4. 实验

我们在多个环境中评估 PW-DICE。我们努力回答两个主要问题：1) Wasserstein 目标是否确实能使学习者策略与专家策略更接近（第 4.1 节）？2) PW-DICE 能否在更复杂的环境上改进基于 f -散度的方法，以及灵活的底层距离度量是否确实有帮助（第 4.2 节）？

4.1. 原始 Wasserstein 与 f -散度

基线。 我们将所提方法与两大最先进的基线方法进行比较：SMODICE（Ma 等人，2022 年）和 LobsDICE（Kim 等人，2022b 年）。我们测试了所提方法的两种变体：1) 线性规划（LP），直接求解式（1）；2) 正则化（Reg），求解式（2）。由于环境是表格型的，所有方法均使用 CVXPY（Agrawal 等人，2019）² 实现，以获得最优数值解。均值和标准差由 10 次不同随机种子的独立运行得到。我们使用遗憾值（即学习者策略与专家策略所获奖励之间的差距，越低越好）评估所有方法。为与 LobsDICE 保持一致，在附录 E.1 中，我们还比较了状态占用和状态对占用的总变差（TV）距离，即 $\text{TV}(d_s^E \| d_s^E)$ 和 $\text{TV}(d_{ss}^E \| d_{ss}^E)$ 。

环境设置。 遵循 LobsDICE（Kim 等人，2022b 年）中的随机 MDP 实验，我们随机生成一个具有 $|S| = 20$ 个状态、 $|A| = 4$ 个动作和 $\gamma = 0.95$ 的 MDP。MDP 的随机性由控制，其中 $\eta = 0$ 表示确定性， $\eta = 1$ 表示高度随机。智能体始终从某个特定状态出发，目标是到达另一个具有奖励 +1 的特定状态，该奖励是唯一的奖励来源。我们报告不同 η 、专家数据集大小和任务无关数据集大小下的遗憾值。与 LobsDICE 的唯一区别在于：专家策略是确定性的，而非 Softmax 函数，因为我们发现 MDP 状态的高连通性导致值函数接近均匀。因此，Softmax 专家策略高度次优且接近均匀。解释见附录 D，结果见附录 E.1。

实验设置。 由于环境是表格型的，如

² 在我们的实验中，CVXPY 通常在优化过程中调用 Gurobi（Gurobi Optimization, LLC, 2023）进行线性规划，调用 MOSEK（ApS, 2019）处理其他目标。




图 3. 各方法在表格环境上的遗憾值（学习者与专家之间的奖励差距）。我们观察到所提方法表现最佳，无论是否存在正则化项；正则化项在连续 MDP 中更为重要。

如上所述，我们使用 CVXPY (Agrawal 等人, 2019) 通过原始形式求解每种方法的最优策略。例如，我们直接求解方程 (1) 以获得学习者的策略 π 。遵循 SMODICE，为了估计转移函数和任务无关的平均策略 π^I ，我们简单地从任务无关数据集中统计状态-动作对和转移 I ，即转移概率 $p(s'|s, a) = \frac{\#[(s, a, s') \in I]}{\#[(s, a) \in I]}$ ，以及 $\pi^I(a|s) = \frac{\#[(s, a) \in I]}{\#[(s) \in I]}$ （#表示“数量”）。类似地，专家状态占用 d_s^E 通过 $d_s^E(s) = \frac{\#[(s) \in E]}{|E|}$ 估计，其中 $|E|$ 是专家数据集的大小 E 。值得注意的是，如果分母为 0，则分布将被估计为均匀分布。由于环境是表格型的，我们使用最简单的距离度量，如第 3.3, i.e., $c(s_i, s_j) = 1$ 节开头所述，如果 $s_i \neq s_j$ ，否则为 0。

主要结果。 图 3 展示了每种方法的遗憾值。我们观察到，无论是否使用正则化器，我们的方法表现相似，并且在专家数据集大小 $\{10, 100, 1000, 10000\}$ 、任务无关（非专家）数据集大小 $\{10, 100, 1000, 10000\}$ 和噪声水平 $\eta \in \{0.01, 0.1, 1\}$ 方面均实现了最低的遗憾值。差距随着任务无关数据集大小的增加而增大，这表明当马尔可夫决策过程动态被更准确地估计时，我们的方法效果更好。LobsDICE 在此场景中表现不佳，尽管它在最小化与 Softmax 专家的发散方面表现最佳，但该专家更具随机性和次优性（详见附录 E.1）。

4.2. 更复杂的环境

基线。 我们在研究中采用了七个基线：最先进的 DICE 方法 SMODICE (Ma 等人, 2022)、Lobs-DICE (Kim 等人, 2022b) 和 ReCOIL (Sikchi 等人, 2024)，非 DICE 方法 ORIL (Zolna 等人, 2020)，基于 Wasserstein 的方法 OTR (Luo 等人, 2023)，具有额外专家动作访问权限的 DWBC (Xu 等人, 2022)，以及普通的行为克隆 (BC)。由于我们无法访问 ReCOIL 代码，我们直接报告他们论文中的最终数字。均值和标准差通过 3 次独立运行（使用不同种子）获得。我们使用平均奖励来衡量性能（越高越好）。

环境与实验设置。 遵循 SMODICE (Ma 等人, 2022)，我们在四个标准的 OpenAI gym MuJoCo 环境上测试 PW-DICE: hopper、halfcheetah、ant 和 walker2d，以及两个更具挑战性的 MuJoCo 测试平台：antmaze 和 Franka kitchen。我们使用的数据集与 SMODICE 中的相同（详见附录 D）。我们使用的度量是归一化平均奖励，奖励越高表示性能越好³。如果最终奖励相近，则梯度步更新次数更少的算法更优。我们绘制奖励曲线，展示奖励的均值和标准差随梯度步数的变化。超参数详见附录 D。

³ 我们采用与 D4RL (Fu 等人, 2020b) 和 SMODICE (Ma 等人, 2022) 相同的归一化标准。




图 4. MuJoCo 测试平台上的性能比较。SMODICE-KL 和 SMODICE-CHI 代表使用不同 f -散度 (KL 或 χ^2) 的 SMODICE 变体。我们的方法在所有基线中通常表现最佳 (即归一化奖励最高)。

主要结果。图 4 展示了 MuJoCo 测试平台上的结果，我们的方法在所有四个测试平台上达到了与基线相当或更好的性能。使用 KL 散度的 SMODICE 和 LobsDICE 表现良好，而其他方法则表现挣扎。

注意，OTR (Luo 等人, 2023) 尽管使用了原始 Wasserstein 距离，但在大多数环境中表现挣扎，这可能是由于由 Wasserstein 距离计算的分配奖励并不总是合理的。示例见图 5。

我们的距离度量设计是否有效? 我们通过定性和定量研究来说明距离度量设计的重要性和有效性。对于定性评估，我们从 MuJoCo hopper 环境的 D4RL 数据集中抽取 4 条不同的轨迹，并比较 t-SNE (Van der Maaten & Hinton, 2008) 可视化结果 (为了更好的可读性，我们只绘制轨迹的 150 步)。图 6 中的结果表明，我们的嵌入成功学习了状态之间的可达性拓扑，将不同的轨迹分开，并连接同一轨迹中的状态，无论它们之间的距离如何。

对于定量评估，我们对 PW-DICE 中使用的距离度量进行了消融实验。具体来说，我们测试了 PW-DICE 使用 $c(s, s') = R(s)$ 的结果，




图 5. OTR (Luo 等, 2023) 中成功 (与 OTR 论文一致) 与失败的奖励分配示意图。OTR 在任务无关数据集与专家数据集中各轨迹状态上的均匀分布之间进行 Wasserstein 匹配，而非在策略分布之间匹配。奖励由匹配结果计算得出。该方案可能因给出相似奖励而无法区分好轨迹与坏轨迹，如失败案例 b) 所示。

$c(s, s') = \|s - s'\|_2^2$ (欧氏距离)、 $c(s, s') = 1 - \frac{s^T s'}{\|s\| \|s'\|}$ (余弦相似度)、 $c(s, s')$ 来自对比学习及其组合。结果如图 7 所示。结果表明，本文设计的距离以及余弦相似度与 $R(s)$ 的组合均表现良好，而单一分量的距离度量则失效 (包括




图 6. a) 状态及其对应的对比嵌入的 t-分布随机邻域嵌入可视化。不同颜色代表不同轨迹。注意，尽管轨迹在原始状态空间中接近，但在嵌入空间中它们是分离的；尽管同一轨迹上的状态在原始状态空间中分离，但在嵌入空间中它们是相连的。

鲁宾斯坦对偶性所蕴含的欧氏距离)。

消融实验 ϵ_1 与 ϵ_2 。为了展示 PW-DICE 对 ϵ_1 和 ϵ_2 选择的鲁棒性，我们在 MuJoCo 环境上进行了消融实验。具体而言，我们测试了 $\epsilon_1 \in \{0.1, 0.5, 1\} \times \epsilon_2 \in \{0.1, 0.5, 1\}$ 。结果如图 8 所示。虽然某些超参数的选择会导致失败，但 PW-DICE 总体上对超参数的选择具有鲁棒性。 ϵ_1 与 ϵ_2 。通常， ϵ_1 应较小以保持良好的性能。更多消融实验见附录 E。

对失真状态表示的鲁棒性。使用学习得到的距离度量的一个重要动机是，固定距离度量可能受限于状态表示。例如，当为质点学习导航时，若状态以坐标形式给出，欧氏距离可能表现良好。然而，当某些维度发生缩放时（例如，由于度量单位从英寸变为米），欧氏距离将不再准确。虽然通过状态归一化可以缓解各维度独立缩放的问题，但在本实验中，我们考虑对状态表示进行更复杂的扭曲。

更具体地说，对于状态 $s \in \mathbb{R}^{1 \times n}$ ，我们随机生成一个扭曲矩阵 $D = 0.1I + D' \in \mathbb{R}^{n \times n}$ ，其中 D' 的每个元素独立且随机地从 $\mathcal{N}(0, 4^2)$ 中采样。暴露给智能体的新状态（在数据集和评估中均如此）计算为 $s' = D's$ 。我们在多个 MuJoCo 环境中将我们的方法与 SMODICE 进行比较。结果如图 9 所示。我们观察到，我们的方法通常比 SMODICE 对不良状态表示更具鲁棒性。




图 7. 距离度量选择的消融实验。我们选择的 $c(s, s')$ 结合了对比学习得到的距离和基于判别器的分量 R ，表现最佳。欧氏距离在我们的场景中失效，这进一步证明了使用原始形式而非 Rubinstein 对偶形式的重要性。

5. 相关工作

用于模仿学习的 Wasserstein 距离。作为一种能够利用分布几何特性并为具有不同支撑集的分布提供梯度的度量，沃瑟斯坦距离 (Wasserstein Distance，又称最优传输) (康托罗维奇，1960) 是研究分布散度最小化时的常用选择。它在模仿学习/强化学习中被广泛使用 (阿加瓦尔等，2021；菲金格等，2022；肖等，2019；达达希等，2021；加格等，2021)。其中，软骰子 (SoftDICE) (孙等，2021) 与我们的原始沃瑟斯坦距离模仿学习 (PW-DICE) 最为相似，同样在骰子框架下优化沃瑟斯坦距离。然而，软骰子及大多数基于沃瑟斯坦距离的模仿学习算法 (孙等，2021；肖等，2019；张等，2020；刘等，2020) 使用鲁宾斯坦-康托罗维奇对偶性 (康托罗维奇与鲁宾斯坦，1958；佩雷与库图里，2019)，这限制了底层距离度量必须为欧几里得度量。有少数方法优化原始沃瑟斯坦距离。例如，最优传输奖励 (OTR) (罗等，2023) 计算两条轨迹之间的原始沃瑟斯坦距离，并据此为离线强化学习分配奖励。原始沃瑟斯坦模仿学习 (PWIL) (达达希等，2021) 使用贪心耦合简化沃瑟斯坦距离的计算。然而，前者在我们的实验设置中表现不佳，后者仅优化沃瑟斯坦距离的上界。此外，这两种方法都只使用固定的启发式距离度量，如欧几里得度量 (达达希等，2021) 和余弦度量 (罗等，2023)。我们的原始沃瑟斯坦距离模仿学习解决了这些问题。

从观察中进行离线模仿学习。从观察中进行离线学习 (Offline Learning from Observation, LfO) 旨在从无标注动作的专家观察中学习，这在机器人学中非常有用，因为专家动作要么不可用 (例如，




图 8. 在 MuJoCo 测试平台上对 ϵ_1 和 ϵ_2 的消融实验： $\epsilon_1 = 0.1$ 标记为绿色， $\epsilon_1 = 0.5$ 标记为红色， $\epsilon_1 = 1.0$ 标记为蓝色。颜色越深， ϵ_2 越大。我们的方法通常对超参数变化具有鲁棒性，尽管某些选择会导致失败。通常，较大的 ϵ_1 会导致性能下降。




图 9. 在状态表示失真情况下，我们提出的方法 PW-DICE 与 SMODICE 的性能比较。我们的方法通常优于 SMODICE。

在视频中 (Pari 等人, 2022 年) 或不适用 (例如, 来自不同实施例 (Sermanet 等人, 2017 年))。该领域存在三个主要方向: 1) 离线规划或强化学习, 使用基于相似度的指定奖励 (Torabi 等人, 2018 年; Kumar 等人, 2019 年); 2) 占用发散最小化, 包括迭代逆强化学习方法 (Zolna 等人, 2020 年; Xu 和 Denil, 2019 年; Torabi 等人, 2019 年) 和 DICE (Ma 等人, 2022 年; Kim 等人, 2022a; b; Lee 等人, 2021 年; Zhu 等人, 2020 年); 3) 动作伪标签, 其中缺失的动作通过逆动态模型预测 (Sermanet 等人, 2017 年; Chen 等人, 2019 年; Wu 等人, 2019 年)。我们的 PW-DICE 属于第二类, 但推广了 SMODICE, 统一了 f -发散和 Wasserstein, 并在经验上改进了现有方法。

状态表示的对比学习。对比学习方法, 如 InfoNCE (Wan 等人, 2021 年) 和 SIMCLR (Chen 等人, 2020 年), 旨在找到满足特定数据点对之间相似性和不相似性约束的良好表示。对比学习在强化学习中被广泛使用, 尤其是

在视觉输入 (Laskin 等人, 2020 年; Pari 等人, 2022 年; Sermanet 等人, 2017 年) 和元强化学习 (Fu 等人, 2020a) 中, 以提高智能体的泛化能力并缓解维度灾难。在这些方法中, 相似性约束可以来自同一状态的不同增强 (Laskin 等人, 2020 年; Pari 等人, 2022 年)、多视图对齐 (Sermanet 等人, 2017 年)、重建后的一致性 (Zhu 等人, 2023 年) 或任务上下文 (Fu 等人, 2020a)。与先前工作不同, PW-DICE 使用对比学习来识别考虑状态可达性的良好距离度量, 同时仍采用 DICE 工作中的奖励。

6. 结论

在本文中, 我们提出了 PW-DICE, 这是一种使用 Wasserstein 距离的原始形式和对比例学习的距离度量的 DICE 方法。通过添加适当的悲观正则化器, 我们制定了一个无约束凸优化, 并使用加权行为克隆检索策略。我们的方法是 SMODICE 的推广, 统一了模仿学习中的 f -发散和 Wasserstein 最小化。这种推广使得性能优于多个基线, 如 SMODICE (Ma 等人, 2022 年) 和 LobsDICE (Kim 等人, 2022b)。

局限性与未来方向。为了获得无约束优化形式, 本文在目标函数中加入 KL 项。这使得最终目标中引入了对数求和指数 (logsumexp)。一些研究认为, 由于使用小批量数据, 对数求和指数会给优化带来不稳定性: 小批量梯度估计对于期望的对数和指数是有偏的 (Sun 等, 2021)。尽管本文未观察到这一现象, 且先前工作 (Ma 等, 2022) 认为其可容忍, 但在更具挑战性的环境中, 这可能是 PW-DICE 的一个潜在缺陷。因此, 下一步是在保持 PW-DICE 有益特性的同时, 寻找更稳健的形式。

致谢

本工作部分由国家自然科学基金 (NSF) 资助, 项目编号 2008387、2045586、2106825、MRI 1725729, 美国国家食品与农业研究所 (NIFA) 奖项 2020-67021-32799, 伊利诺伊大学医疗工程系统中心与 OSF 基金会的 Jump ARCHES 捐赠基金, 以及 IBM-伊利诺伊发现加速器研究所支持。

影响声明

本文通过利用专家观测和过往经验数据, 自动化决策过程。虽然我们的努力提高了自动化任务解决的效率, 但也可能在多个方面带来负面社会影响。例如, 由于本文工作主要在

运动任务上测试，所提出的决策技术存在被用于有害应用（如军事）的潜在风险。此外，自动化决策的改进可能潜在地导致就业机会减少。

参考文献

- Agarwal, R., Machado, M. C., Castro, P. S., and Bellemare, M. G. Contrastive behavioral similarity embeddings for generalization in reinforcement learning. In *ICLR*, 2021.
- Agrawal, A., Amos, B., Barratt, S., Boyd, S., Diamond, S., and Kolter, J. Z. Differentiable convex optimization layers. In *NeurIPS*, 2019.
- ApS, M. *The MOSEK optimization toolbox for CVXPY manual.*, 2019. URL <https://docs.mosek.com/9.0/faq/index.html>.
- Boyd, S. and Vandenberghe, L. *Convex optimization*. Cambridge University Press, 2004.
- Brockman, G., Cheung, V., Pettersson, L., Schneider, J., Schulman, J., Tang, J., and Zaremba, W. OpenAI gym, 2016.
- Chang, M., Gupta, A., and Gupta, S. Semantic visual navigation by watching YouTube videos. In *NeurIPS*, 2020.
- Chen, A. S., Nair, S., and Finn, C. Learning generalizable robotic reward functions from “in-the-wild” human videos. In *RSS*, 2021a.
- Chen, L., Lu, K., Rajeswaran, A., Lee, K., Grover, A., Laskin, M., Abbeel, P., Srinivas, A., and Mordatch, I. Decision transformer: Reinforcement learning via sequence modeling. In *NeurIPS*, 2021b.
- Chen, T., Kornblith, S., Norouzi, M., and Hinton, G. A simple framework for contrastive learning of visual representations. In *NeurIPS*, 2020.
- Chen, X., Li, S., Li, H., Jiang, S., Qi, Y., and Song, L. Generative adversarial user model for reinforcement learning based recommendation system. In *ICML*, 2019.
- Dadashi, R., Hussenot, L., Geist, M., and Pietquin, O. Primal wasserstein imitation learning. In *ICLR*, 2021.
- Dai, B., He, N., Pan, Y., Boots, B., and Song, L. Learning from conditional distributions via dual embeddings. In *AISTATS*, 2017.
- Fickinger, A., Cohen, S., Russell, S., and Amos, B. Cross-domain imitation learning via optimal transport. In *ICLR*, 2022.
- Fu, H., Tang, H., Hao, J., Chen, C., Feng, X., Li, D., and Liu, W. Towards effective context for meta-reinforcement learning: An approach based on contrastive learning. In *AAAI*, 2020a.
- Fu, J., Kumar, A., Nachum, O., Tucker, G., and Levine, S. D4RL: Datasets for deep data-driven reinforcement learning. *ArXiv:2004.07219*, 2020b.
- Garg, D., Chakraborty, S., Cundy, C., Song, J., and Ermon, S. IQ-Learn: Inverse soft-Q learning for imitation. In *NeurIPS*, 2021.
- Ghasemipour, S., Zemel, R., and Gu, S. A divergence minimization perspective on imitation learning methods. In *CoRL*, 2019.
- Gurobi Optimization, LLC. Gurobi optimizer reference manual, 2023. URL <https://www.gurobi.com>.
- Hakhamaneshi, K., Zhao, R., Zhan, A., Abbeel, P., and Laskin, M. Hierarchical few-shot imitation with skill transition models. In *ICLR*, 2022.
- Ho, J. and Ermon, S. Generative adversarial imitation learning. In *NIPS*, 2016.
- Jin, Y., Yang, Z., and Wang, Z. Is pessimism provably efficient for offline RL? In *ICML*, 2021.
- Kantorovich, L. and Rubinstein, G. S. On a space of totally additive functions. *Vestnik Leningradskogo Universiteta*, 1958.
- Kantorovich, L. V. Mathematical methods of organizing and planning production. *Management science*, 1960.
- Kim, G., Seo, S., Lee, J., Jeon, W., Hwang, H., Yang, H., and Kim, K. DemoDICE: Offline imitation learning with supplementary imperfect demonstrations. In *ICLR*, 2022a.
- Kim, G.-H., Lee, J., Jang, Y., Yang, H., and Kim, K. LobSDICE: Offline learning from observation via stationary distribution correction estimation. In *NeurIPS*, 2022b.
- Kiran, B., Sobh, I., Talpaert, V., Mannion, P., Sallab, A., Yogamani, S., and Perez, P. Deep reinforcement learning for autonomous driving: A survey. *IEEE Transactions on Intelligent Transportation Systems*, 2021.
- Kostrikov, I., Agrawal, K. K., Dwibedi, D., Levine, S., and Tompson, J. Discriminator-actor-critic: Addressing sample inefficiency and reward bias in adversarial imitation learning. In *ICLR*, 2019.
- Kostrikov, I., Nachum, O., and Tompson, J. Imitation learning via off-policy distribution matching. In *ICLR*, 2020.

- Kostrikov, I., Nair, A., and Levine, S. Conservative Q-learning for offline reinforcement learning. In *ICLR*, 2022a.
- Kostrikov, I., Nair, A., and Levine, S. Offline reinforcement learning with implicit Q-learning. In *ICLR*, 2022b.
- Kumar, A., Gupta, S., and Malik, J. Learning navigation subroutines from egocentric videos. In *CoRL*, 2019.
- Laskin, M., Srinivas, A., and Abbeel, P. CURL: Contrastive unsupervised representations for reinforcement learning. In *ICML*, 2020.
- Lee, J., Jeon, W., Lee, B.-J., Pineau, J., and Kim, K.-E. OptiDICE: Offline policy optimization via stationary distribution correction estimation. In *ICML*, 2021.
- Liu, F., Ling, Z., Mu, T., and Su, H. State alignment-based imitation learning. In *ICLR*, 2020.
- Luo, Y., Jiang, Z., Cohen, S., Grefenstette, E., and Deisenroth, M. P. Optimal transport for offline imitation learning. In *ICLR*, 2023.
- Ma, Y. J., Shen, A., Jayaraman, D., and Bastani, O. Smodice: Versatile offline imitation learning via state occupancy matching. In *ICML*, 2022.
- Nachum, O., Chow, Y., Dai, B., and Li, L. DualDICE: Behavior-agnostic estimation of discounted stationary distribution corrections. In *NeurIPS*, 2019.
- Pari, J., Shafiuallah, N. M. M., Arunachalam, S. P., and Pinto, L. The surprising effectiveness of representation learning for visual imitation. In *RSS*, 2022.
- Peyré, G. and Cuturi, M. Computational optimal transport. *Foundations and Trends in Machine Learning*, 2019.
- Polyanskiy, Y. f -divergences, 2020. URL https://people.lids.mit.edu/yp/homepage/data/LN_fdiv.pdf.
- Sermanet, P., Lynch, C., Hsu, J., and Levine, S. Time-contrastive networks: Self-supervised learning from multi-view observation. In *CVPRW*, 2017.
- Sikchi, H. S., Zhang, A., and Niekum, S. Imitation from arbitrary experience: A dual unification of reinforcement and imitation learning methods. In *ICLR*, 2024.
- Stanczuk, J., Etman, C., Kreusser, L., and Schonlieb, C.-B. Wasserstein GANs work because they fail (to approximate the wasserstein distance). *ArXiv:2103.01678*, 2021.
- Sun, M., Mahajan, A., Hofmann, K., and Whiteson, S. Soft-DICE for imitation learning: Rethinking off-policy distribution matching. *ArXiv:2106.03155*, 2021.
- Torabi, F., Warnell, G., and Stone, P. Behavioral cloning from observation. In *IJCAI*, 2018.
- Torabi, F., Warnell, G., and Stone, P. Generative adversarial imitation from observation. In *ICML Workshop on Imitation, Intent, and Interaction*, 2019.
- Van der Maaten, L. and Hinton, G. Visualizing data using t-SNE. *JMLR*, 2008.
- Wan, C., Zhang, T., Xiong, Z., and Ye, H. Representation learning for fault diagnosis with contrastive predictive coding. In *CAA Symposium on Fault Detection, Supervision, and Safety for Technical Processes (SAFEPROCESS)*, 2021.
- Wu, A., Piergiovanni, A., and Ryoo, M. S. Model-based behavioral cloning with future image similarity learning. In *CoRL*, 2019.
- Xiao, H., Herman, M., Wagner, J., Ziesche, S., Etesami, J., and Linh, T. H. Wasserstein adversarial imitation learning. *arXiv preprint arXiv:1906.08113*, 2019.
- Xu, D. and Denil, M. Positive-unlabeled reward learning. In *CoRL*, 2019.
- Xu, H., Zhan, X., Yin, H., and Qin, H. Discriminator-weighted offline imitation learning from suboptimal demonstrations. In *NeurIPS*, 2022.
- Yu, T., Quillen, D., He, Z., Julian, R., Hausman, K., Finn, C., and Levine, S. Meta-World: A benchmark and evaluation for multi-task and meta reinforcement learning. In *CoRL*, 2019.
- Zhang, M., Wang, Y., Ma, X., Xia, L., Yang, J., Li, Z., and Li, X. Wasserstein distance guided adversarial imitation learning with reward shape exploration. In *Data Driven Control and Learning Systems (DDCLS)*, 2020.
- Zhu, J., Xia, Y., Wu, L., Deng, J., Zhou, W., Qin, T., Liu, T.-Y., and Li, H. Masked contrastive representation learning for reinforcement learning. *IEEE TPAMI*, 2023.
- Zhu, Z., Lin, K., Dai, B., and Zhou, J. Off-policy imitation learning from observations. In *NeurIPS*, 2020.
- Zolna, K., Novikov, A., Konyushkova, K., Gulcehre, C., Wang, Z., Aytar, Y., Denil, M., de Freitas, N., and Reed, S. E. Offline learning from demonstrations and unlabeled experience. In *NeurIPS Workshop on Offline Reinforcement Learning*, 2020.

Algorithm 1 PW-DICE

Input: Expert state-only dataset E , task-agnostic state-action dataset I , distance metric $c : |S| \times |S| \rightarrow \mathbb{R}$
Input: Triple head network for dual variable $\lambda_{\theta_1}(s, h) : |S| \times \{0, 1, 2\} \rightarrow \mathbb{R}$ parameterized by θ_1 , actor $\pi_{\theta_2}(a|s)$ parameterized by θ_2 , the number of epoches N , batch size B , learning rate η .
Initialize initial state dataset $I_{\text{ini}} = \{\}$.
for $\tau \in I$ **do**
 Add first state of τ to I_{ini}
end for
for epoch = 1 **to** N **do**
 for $(s, a, s') \in I$ **do**
 Sample state s^I from I , state s^E from E
 $l_1 \leftarrow \frac{1}{\epsilon_1}(\lambda_{\theta_1}(s^I, 1) + \lambda_{\theta_1}(s^E, 2) - c(s^I, s^E)) - \log B$
 $l_2 \leftarrow \frac{1}{\epsilon_2}(-\gamma\lambda_{\theta_1}(s', 0) + \lambda_{\theta_1}(s, 0) - \lambda_{\theta_1}(s, 1)) - \log B$
 Sample initial states s_{ini} from I_{ini}
 $l_3 \leftarrow -\frac{1}{B}[(1 - \gamma)\lambda_{\theta_1}(s_{\text{ini}}, 0) + \lambda_{\theta_1}(s^E, 2)]$
 $l \leftarrow \text{logsumexp}(l_1) + \text{logsumexp}(l_2) + l_3$
 $\theta_1 \leftarrow \theta_1 - \eta \frac{\partial l}{\partial \theta_1}$
 end for
 for $(s, a, s') \in I$ **do**
 $v \leftarrow \frac{1}{\epsilon_2}(-\gamma\lambda_{\theta_1}(s', 0) + \lambda_{\theta_1}(s, 0) - \lambda_{\theta_1}(s, 1))$
 $l \leftarrow \exp(v) \log \pi_{\theta_2}(a|s)$
 $\theta_2 \leftarrow \theta_2 - \eta \frac{\partial l}{\partial \theta_2}$
 end for
end for

附录：通过原始 Wasserstein 状态占用匹配的离线观察模仿。附录组织如下：首先在 A 节中给出 PW-DICE 的伪代码。随后在 B 节中严格介绍本文最重要的数学概念，包括状态、状态-动作和状态对占用，以及 f -散度和 Fenchel 共轭。之后在 C 节中给出主文中省略的详细推导及相应证明。在 D 节中详细描述实验设置。在 E 节中给出额外实验结果，包括辅助度量、在表格实验中使用与 LobsDICE (Kim 等, 2022b) 相同的 Softmax 专家 (实际上次优, 见 E.1.2 节) 的实验结果，以及 MuJoCo 环境中的消融实验。在 F 节中总结符号。最后在 G 节中列出训练过程中使用的计算资源。

A. 伪代码

算法 1 详细描述了本文主要算法的训练过程。实现时，我们在整个任务无关数据集 I 上对系数 v 进行归一化，以获得更好的稳定性。距离度量的对比学习实现细节见 D.2 节。

B. 数学概念

本节介绍论文中使用的三个重要概念：状态/状态-动作/状态对占用、 f -散度和 Fenchel 共轭。第一个是贯穿全文的关键概念，第二个用于动机阐述，最后一个用于 C.2 节。

B.1. 状态、状态-动作和状态对占用

考虑一个具有初始状态分布 p_0 和无限时域的 MDP (S, A, T, r, γ) ；在第 t 个时间步，将当前状态记为 s_t ，动作记为 a_t 。那么，在固定策略 π 下， $\Pr(s_t = s)$ 和 $\Pr(a_t = a)$ 的概率

对于任意 s, a 是确定的。基于此，状态占用，即策略 π 下的状态访问频率，定义为 $d_s^\pi(s) = (1 - \gamma) \sum_{t=0}^{\infty} \gamma^t \Pr(s_t = s)$ 。类似地，将状态-动作占用定义为 $d_{sa}^\pi(s, a) =$

$(1 - \gamma) \sum_{t=0}^{\infty} \gamma^t \Pr(s_t = s, a_t = a)$ 。一些工作如 LobsDICE 也使用状态对占用，其定义为

$d_{ss}^\pi(s, s') = (1 - \gamma) \sum_{t=0}^{\infty} \gamma^t \Pr(s_t = s, s_{t+1} = s')$ 。在本文中，将生成任务无关数据集 I 的平均策略记为 π^I ，其状态占用为 d_s^I ，状态-动作占用为 d_{sa}^I ；将生成专家数据集 E 的专家策略记为 π^E ，其状态占用为 d_s^E 。

B.2. f -divergence

f -散度是衡量概率分布之间距离的一种测度 p, q ，在机器学习领域被广泛使用 (Ghasemipour 等人, 2019)。对于定义域 $\mathcal{X}$ 上的两个概率分布 p, q ，基于任意连续凸函数 f ， p 与 q 之间的 f -散度定义为

$$D_f(p||q) = \mathbb{E}_{x \sim q} \left[f \left(\frac{p(x)}{q(x)} \right) \right]. \quad (8)$$

例如，当 $f(x) = x \log x$ 时，有 $D_f(p||q) = \mathbb{E}_{x \sim q} \frac{p(x)}{q(x)} \log \frac{p(x)}{q(x)} = \mathbb{E}_{x \sim p} \log \frac{p(x)}{q(x)}$ ，这导出了 KL-散度。当 $f(x) = (x - 1)^2$ 时，有 $D_f(p||q) = \mathbb{E}_{x \sim q} ((\frac{p(x)-q(x)}{q(x)})^2)$, which induces the χ^2 -divergence.

B.3. 芬切尔共轭

芬切尔共轭在 DICE 方法中被广泛使用，既可用于去偏估计 (Nachum 等人, 2019)，也可用于求解具有更强约束的公式，以获得数值上更稳定的目标 (Ma 等人, 2022)。PW-DICE 将芬切尔共轭用于后者。对于向量空间 Ω 和凸可微函数 $f: \Omega \rightarrow \mathbb{R}$ ， $f(x)$ 的芬切尔共轭定义为

$$f_*(y) = \max_{x \in \Omega} \langle x, y \rangle - f(x), \quad (9)$$

其中 $\langle \cdot, \cdot \rangle$ 是 Ω 上的内积。

C. 数学推导

在本节中，我们提供因篇幅限制而在正文中省略的详细推导。在 C.1 节中，我们简要介绍 SMODICE，以阐明使用 Wasserstein 距离的动机以及 SMODICE 与我们提出的 PW-DICE 的关系。在 C.2 节中，我们提供在 3.2 节中省略的目标函数的详细推导。C.3 节和 C.4 节是对 C.2 节的补充：在 C.3 节中，我们提供约束的压缩表示元素 A 和 b 的详细推导，在 C.4 节中，我们解释为什么在推导过程的一步中应用了额外的约束而最优解保持不变。最后，在 C.5 节中，我们为我们的方法是 3.2 节中 SMODICE 的泛化这一主张提供详细证明。

C.1. SMODICE

SMODICE (Ma 等人, 2022) 是一种最先进的离线从观察学习 (LfO) 方法。它最小化学习者策略 π 的状态占用与专家策略 π^E 的状态占用之间的 f -发散，即目标为

$$\min_{\pi} D_f(d_s^\pi(s) || d_s^E(s)), \text{ s.t. } \pi \text{ 是可行的}. \quad (10)$$

此处， π 的可行性与主论文中公式 (1) 第二行约束的贝尔曼流约束 (Bellman flow constraint) 相同。为纳入环境动态的唯一信息来源，即任务无关数据集 I ，目标被松弛为

$$\max_{\pi} \mathbb{E}_{s \sim d^\pi} \log \frac{d_s^E(s)}{d_s^I(s)} - D_f(d_{sa}^\pi(s, a) || d_{sa}^I(s, a)), \text{ s.t. } \pi \text{ 是一项可行的策略}. \quad (11)$$

此处， D_f 可以是任何不小于 KL 散度的发散度量（SMODICE 主要研究 χ^2 -发散）。第一项 $\log \frac{d_s^E(s)}{\overline{d_s^I(s)}}$ 表示状态的相对重要性。专家访问某一特定状态 s 的频率高于非专家策略，则该状态 s 越可能是理想状态。依赖这一比值会引入理论上的局限性：必须假设在 $d_s^E(s) > 0$ 处有 $d_s^I(s) > 0$ ，而这在高维空间中不一定成立。因此，我们在奖励设计中引入超参数 α 来混合分母中的分布。

通过将约束问题转化为拉格朗日对偶空间中的无约束问题，SMODICE 优化以下目标（假设使用 KL 散度）：

$$\min_V (1 - \gamma) \mathbb{E}_{s \sim p_0} [V(s)] + \log \mathbb{E}_{(s, a, s') \sim I} \exp \left[\log \frac{d_s^E(s)}{d_s^I(s)} + \gamma V(s') - V(s) \right], \quad (12)$$

其中 p_0 是初始状态分布， γ 是折扣因子。如第 3.2 节所述，该目标是 PW-DICE 在 $c(s, s') = \log \frac{d_s^E(s)}{d_s^I(s)}$, $\epsilon_2 = 1, \epsilon_1 \rightarrow 0$ 条件下的特例。LobsDICE (Kim 等人, 2022b) 在思想上类似；然而，它最小化的是状态对散度 $\text{KL}(d_{ss}^\pi \| d_{ss}^E)$ 。

C.2. 本文目标的详细推导

如第 3.2 节公式 (1) 所述，本文的原始目标为

$$\begin{aligned} & \min_{\Pi, \pi} \sum_{s_i \in S} \sum_{s_j \in S} \Pi(s_i, s_j) c(s_i, s_j), \text{ s.t. } d_{sa}^\pi \geq 0, \Pi \geq 0; \\ & \forall s \in S, d_s^\pi(s) = (1 - \gamma) p_0(s) + \gamma \sum_{\bar{s}, \bar{a}} d_{sa}^\pi(\bar{s}, \bar{a}) p(s | \bar{s}, \bar{a}); \\ & \forall s_i, s_j \in S, \sum_k \Pi(s_k, s_j) = d_s^E(s_j), \sum_k \Pi(s_i, s_k) = d_s^\pi(s_i). \end{aligned} \quad (13)$$

在平滑目标之前，为了可读性，我们将公式 (13) 中的主要目标重写为关于单一向量 x 的线性规划问题，其中 $\Pi \in \mathbb{R}^{|S| \times |S|}$ 和 $d_{sa}^\pi \in \mathbb{R}^{|S| \times |A|}$ 按行优先方式展平。

相应地，我们将状态间的距离 c 扩展为 $c' : (|S|(|S| + |A|)) \times (|S|(|S| + |A|)) \rightarrow \mathbb{R}$ ，使得在 c 的原始域上为 $c' = c$ ，否则为 $c' = 0$ 。进一步，我们将所有线性等式约束总结在 $Ax = b$. Eq. (1) 中，则等价于

$$\min_{x \geq 0} (c')^T x \quad \text{s.t.} \quad Ax = b, x \geq 0. \quad (14)$$

容易看出，公式 (14) 的拉格朗日对偶形式也是一个约束优化。为了将优化转化为无约束优化，本文修改目标如下（与正文公式 (2) 相同）：

$$\begin{aligned} & \min_x (c')^T x + \epsilon_1 D_f(\Pi \| U) + \epsilon_2 D_f(d_{sa}^\pi \| d_{sa}^I), \\ & \text{s.t. } Ax = b, x \geq 0, \end{aligned} \quad (15)$$

其中 $U(s, s') = d_s^E(s) d_{s'}^I(s')$, i.e., U 是两个独立分布 d_s^E 和 $d_{s'}^I$. $\epsilon_1 > 0, \epsilon_2 > 0$ 的乘积，是超参数， D_f 可以是任意 f -散度。注意，尽管使用了 f -散度，但与 SMODICE (Ma 等人, 2022) 或 LobsDICE (Kim 等人, 2022b) 不同，该公式不要求任务无关数据对专家数据具有数据覆盖。两个正则化项是“悲观的”，鼓励智能体保持在数据集的支持集内。这已在离线模仿学习/强化学习中使用 (Jin 等人, 2021)。

在式 (2) 的正则化目标下，本文考虑其拉格朗日对偶问题：

$$\max_{\lambda} \min_{x \geq 0} L(\lambda, x), \text{ where } L(\lambda, x) = (c')^T x + \epsilon_1 D_f(\Pi \| U) + \epsilon_2 D_f(d_{sa}^\pi \| d_{sa}^I) - \lambda^T (Ax - b). \quad (16)$$

虽然式 (16) 仅具有非负性约束，但其定义域为非负数集。因此，该目标可视为无约束优化。为获得实用且稳定的解，单层优化更为可取。为此，

可以考虑利用卡罗需-库恩-塔克条件 (Boyd & Vandenberghe, 2004)，并将内层优化的导数设为零。然而，这种方法会在目标函数中引入指数函数 (Polyanskiy, 2020; Kim et al., 2022b)，导致数值不稳定 (Kim et al., 2022b)。为避免此问题，本文首先将式 (16) 改写为取负形式 $L(\lambda, x)$ ，以分离 Π 和 d_{sa}^π 在 x 中：

$$\min_{\lambda} \max_{x \geq 0} -L(\lambda, x) = \min_{\lambda} \left\{ \epsilon_1 \max_{\Pi \in \Delta(S^2)} \left[\frac{(A_1^T \lambda - c)^T}{\epsilon_1} \Pi - D_f(\pi \| U) \right] + \epsilon_2 \max_{d_{sa}^\pi \in \Delta(S \cdot A)} \left[\frac{(A_2^T \lambda)^T}{\epsilon_2} d_{sa}^\pi - D_f(d_{sa}^\pi \| d_{sa}^I) \right] - b^T \lambda \right\}. \quad (17)$$

In Eq. (17), we have $A = \begin{bmatrix} A_1 \\ A_2 \end{bmatrix}$ ，其中 $A_1 \in \mathbb{R}^{|S| \times |S| \times M}$, $A_2 \in \mathbb{R}^{|S| \times |A| \times M}$ ，且 $M = 3|S|$ 为原始形式中等式约束的个数。关于 A, A_1, A_2 和 b 中的元素，参见第 C.3 节。式 (17) 中有两点值得注意。

首先，本文附加了两个额外约束，即 $\Pi \in \Delta, d_{sa}^\pi \in \Delta$ 。这些约束不会影响最终结果，原因如下：

引理 1. 对于任意马尔可夫决策过程及可行的专家策略 π^E ，式 (1) 中带有 $\Pi \geq 0, d_{sa}^\pi \geq 0$ 的 $\Pi \in \Delta, d_{sa}^\pi \in \Delta$ 不等式约束与不带该约束是等价的。

引理 1 的详细证明见附录 C.4。简言之，式 (16) 的最优解，只要满足原始形式中的所有约束，必有 $\Pi \in \Delta, d_{sa}^\pi \in \Delta$ 。

其次，由于关联 Π 与 d_{sa}^π 的等式约束在对偶中均被松弛，我们将最大值算子分解为两个独立的最大化问题。利用式 (17)，现应用 SMODICE (Ma et al., 2022):) 中的如下定理：

定理 C.1. 在温和假设下 (Dai 等人, 2017)，对于任意 f -散度 D_f 、定义域 $\mathcal{X}$ 上的概率分布 p, q 以及函数 $y: \mathcal{X} \rightarrow \mathbb{R}$ ，有

$$\max_{p \in \Delta(\mathcal{X})} \mathbb{E}_{x \sim p}[y(x)] - D_f(p \| q) = \mathbb{E}_{x \sim q}[f_*(y(x))]. \quad (18)$$

对于最大化子 $p^*(x) = \arg \max_{p \in \Delta(\mathcal{X})} \mathbb{E}_{x \sim p}[f_*(y(x))]$ ，有 $p^*(x) = q(x)f'_*(y(x))$ ，其中 $f_*(\cdot)$ 是 f 的芬切尔共轭， f'_* 是其导数。

完整证明可参见 Polyanskiy (2020) 中的定理 7.14*。 f -散度与芬切尔共轭的严格定义见附录 B。本文主要考虑 KL 散度作为 D_f ，对应 $f(x) = x \log x$ ，与 $f_*(x) =$ 对数求和指数 (x 为芬切尔对偶函数，且 $x \in \Delta$ (Boyd & Vandenberghe, 2004)⁴)。根据定理 C.1，对第一个最大值算子设 $p = \Pi, x = \lambda, y(x) = \frac{A_1^T \lambda - c}{\epsilon_1}$ ，对第二个最大值算子设 $p = d_{sa}^\pi, x = \lambda, y(x) = \frac{A_2^T \lambda}{\epsilon_2}$ 。由此得到如下单层凸目标：

$$\min_{\lambda} \epsilon_1 \log \mathbb{E}_{s_i \sim I, s_j \sim E} \exp \left(\frac{(A_1^T \lambda - c)^T}{\epsilon_1} \right) + \epsilon_2 \log \mathbb{E}_{(s_i, a_j) \sim I} \exp \left(\frac{A_2^T \lambda}{\epsilon_2} \right) - b^T \lambda, \quad (19)$$

据此，通过考虑附录 C.3 中 A_1, A_2 与 b 的分量，得到式 (3) 所述的最终目标及第 3.2 节所述的最大化子。

C.3. 分量 A, b 在式 (14)

在本小节中，我们详细讨论式 (14) 中 A, b 的各项。在式 (14) 中，我们总结了中的所有等式约束，其中 Π, d_{sa}^π 按行优先方式展平。因此，我们有 $x_{:i|S|+j} = \Pi(s_i, s_j)$ ，并且 $x_{|S|^2+i|A|+j} = d_{sa}^\pi(s_i, a_j)$ 。

⁴ χ^2 -散度在 MuJoCo 环境中的效果不如 KL 散度。详见附录 E.2。

我们进一步假设在 A 和 b 中, 前 $|S|$ 行是贝尔曼流约束

$$\forall s, \sum_a d_{sa}^\pi(s, a) - \gamma \sum_{\bar{s}, \bar{a}} p(s|\bar{s}, \bar{a}) d_{sa}^\pi(\bar{s}, \bar{a}) = (1 - \gamma) p_0(s). \quad (20)$$

第二 $|S|$ 行是 $\sum_j \Pi(s_i, s_j) = d_s^\pi(s_i)$

$$\forall s, \sum_{s'} \Pi(s, s') = \sum_a d_{sa}^\pi(s, a). \quad (21)$$

第三 $|S|$ 行是 $\sum_i \Pi(s_i, s_j) = d_s^E(s_j)$ constraints

$$\forall s, \sum_{s'} \Pi(s', s) = \sum_a d_{sa}^E(s, a). \quad (22)$$

因此, 我们有 $A_{i, |S|^2+j|A|+k} = -\gamma p(s_i|s_j, a_k)$ 对于 $i \in \{1, 2, \dots, |S|\}$, $A_{i, |S|^2+i|A|:|S|^2+(i+1)|A|} = 1$ 对于 $i \in \{1, 2, \dots, |S|\}$ (Eq. (20)), $A_{i+|S|, i|S|+j} = 1$ 对于 $i \in \{1, 2, \dots, |S|\}$, $A_{i+|S|, |S|^2+i|A|+j} = -1$ (Eq. (21)), 并且 $A_{i+2|S|, j|S|+i} = 1$ (Eq. (22)). A 的其他项 0. A_1 在式 (17) 中为第一 $|S| \times |S|$ 的行 A , 以及 A_2 是最后的 $|S| \times |A|$ 行 A .

For vector b , we have

$$b = \begin{bmatrix} (1 - \gamma)p_0 \\ 0 \\ d_s^E \end{bmatrix}. \quad (23)$$

C.4. 引理 1

在本节中, 我们给出附录 C.2 中使用的引理 1 的证明。该引理内容如下:

引理 1. 对于任意马尔可夫决策过程及可行的专家策略 π^E , 式 (1) 中带有 $\Pi \geq 0, d_{sa}^\pi \geq 0$ 的 $\Pi \in \Delta, d_{sa}^\pi \in \Delta$ 不等式约束与不带该约束是等价的。

证明。根据等式约束, $\sum_s d_s^\pi(s')$ 对任意 s' $\sum_s \Pi(s, s') =$ 成立。因此, 由状态占用的定义可 $\sum_{s'} \sum_s \Pi(s, s') =$ 得 $\sum_{s'} d_s^E(s') = 1$ 。因此 $\Pi \geq 0$ 等价于 $\Pi \geq \Delta$ 。类似地, 对贝尔曼流

等式约束两边求和, 可得

$$\begin{aligned} \sum_s d_s^\pi(s) &= \sum_s (1 - \gamma) p_0(s) + \sum_s \gamma \sum_{\bar{s}, \bar{a}} d_{sa}^\pi(\bar{s}, \bar{a}) p(s|\bar{s}, \bar{a}) \\ \sum_{s,a} d_{sa}^\pi(s, a) &= (1 - \gamma) + \gamma \sum_s \sum_{\bar{s}, \bar{a}} d_{sa}^\pi(\bar{s}, \bar{a}) p(s|\bar{s}, \bar{a}) \\ \sum_{s,a} d_{sa}^\pi(s, a) &= (1 - \gamma) + \gamma \sum_{s'} \sum_{s,a} d_{sa}^\pi(s, a) p(s'|s, a) \\ \sum_{s,a} d_{sa}^\pi(s, a) (1 - \gamma \sum_{s'} p(s'|s, a)) &= 1 - \gamma \\ \sum_{s,a} d_{sa}^\pi(s, a) &= 1 \end{aligned} \quad (24)$$

给定 p_0 和合法的转移函数。因此, $d_{sa}^\pi \geq 0$ 等价于 $d_{sa}^\pi \in \Delta$ 。

□

直观上, 通过添加额外约束, 我们可以假设式 (1) 中存在冗余的等式约束, 并且它们在拉格朗日对偶中未被松弛。通过对偶形式施加更严格的约束, 芬切尔共轭得到了数值上更稳定的公式。

C.5. 对 SMODICE 泛化的证明

在第 3.2 节中，我们声称所提出的方法 PW-DICE 是 SMODICE 的泛化。更具体地说，我们有以下声明和推论：

声明 1. 如果 $c(s_i, s_j) = -\log \frac{d_s^E(s_i)}{d_s^I(s_i)}$, $\epsilon_2 = 1$ ，则当 $\epsilon_1 \rightarrow 0$, Eq. (3) 时，等价于使用 KL 散度的 SMODICE 目标。

推论 C.2. 若 $c(s_i, s_j) = -\log \frac{d_s^E(s_i)}{d_s^I(s_i)}$, $\epsilon_2 = 1$ ，则当 $\epsilon_1 \rightarrow 0$, Eq. (17) 等价于任意 f -散度下的 SMODICE。

本文首先从原始视角给出一个简单证明：

证明。（原始视角）根据式 (11) 和式 (1)，SMODICE 与 PW-DICE 的原始目标如下：

$$\begin{aligned} \min_x (c')^T x + \epsilon_1 D_f(\Pi \| U) + \epsilon_2 D_f(d_{sa}^\pi \| d_{sa}^I), \text{ s.t. } Ax = b, x \geq 0; \text{ (PW-DICE)} \\ \max_\pi \mathbb{E}_{s \sim d^\pi} \log \frac{d_s^E(s)}{d_s^I(s)} - D_f(d_{sa}^\pi(s, a) \| d_{sa}^I(s, a)), \text{ s.t. } \pi \text{ 是一个可行策略。 (SMODICE)} \end{aligned} \quad (25)$$

Here, $x = \begin{bmatrix} d_s^\pi \\ \Pi \end{bmatrix}$ 。注：1) $Ax = b, x \geq 0$ 包含三个等式约束：贝尔曼流方程（与“ π 是一个可行策略”相同）、 $\sum_{s'} \Pi(s, s') = d^E(s)$ ；2) $(c')^T x = \sum_{s, s'} c(s, s') \Pi(s, s')$ 。

$$\sum_s \sum_{s'} c(s, s') \Pi(s, s') = \sum_s \log \frac{d_s^E(s)}{d_s^I(s)} \sum_{s'} \Pi(s, s') = -\mathbb{E}_{s \sim d_s^\pi} \log \frac{d_s^E(s)}{d_s^I(s)}. \quad (26)$$

因此，当 $\epsilon_1 = 0, \epsilon_2 = 1, c'(s, s') = c(s, s') = -\log \frac{d_s^E(s)}{d_s^I(s)}$ 时，PW-DICE 与 SMODICE 的目标函数互为相反数（一个最大化，另一个最小化），且对 d_{sa}^π 的约束完全相同。由于 Π 也可解（一个显然的解是 $\Pi = d_s^\pi \otimes d_s^E$ ），两个目标函数相同，因此式 (25) 中的目标函数等价。由于我们未指定 D_f ，该断言与推论均得证。 $\square$

然而，该断言在其对偶形式下并不直观：由于在对偶形式中我们总有 $\epsilon_1 > 0, \epsilon_2 > 0$ ，式 (3) 中的行为并非平凡。因此，这里我们直接从对偶视角对连续空间中的 KL 散度 D_f 给出断言 1 的另一个证明：

证明。（对偶视角，KL 散度，连续空间）首先，我们用反证法证明

$$\lim_{\epsilon_1 \rightarrow 0} \epsilon_1 \log \mathbb{E}_{s \sim I, s' \sim E} \exp \left(\frac{\lambda_{s+|S|} + \lambda_{s'+2|S|} - c(s, s')}{\epsilon_1} \right) \quad (27)$$

不是最大算子，因为在最优解处，对于每个 $d_s^I(s) > 0, d_s^E(s') > 0$ ， $\lambda_{s+|S|} + \lambda_{s'+2|S|} - c(s, s')$ 都相等。否则，假设状态对 (s, s') 具有最大的 $\lambda_{s+|S|} + \lambda_{s'+2|S|} - c(s, s')$ ；由于 ϵ_1 可以任意接近 0，存在足够小的 ϵ_1 ，使得存在 $s \neq s_0$ 或 $s' \neq s'_0$ ，使 λ_s 或 $\lambda_{s'}$ 的无穷小增量值得进行（即关于 λ_s 或 $\lambda_{s'}$ 的偏导数大于 0）。

然后，我们有

$$\begin{aligned} & \lim_1 \epsilon_1 \log \mathbb{E}_{s \sim I, s' \sim E} \exp \left(\frac{\lambda_{s+|S|} + \lambda_{s'+2|S|} - c(s, s')}{\epsilon_1} \right) \\ &= \mathbb{E}_{s \sim I, s' \sim E} (\lambda_{s+|S|} + \lambda_{s'+2|S|} - c(s, s')) \\ &= \mathbb{E}_{s \sim I} \left[\lambda_{s+|S|} + \log \frac{d_s^E(s)}{d_s^I(s)} \right] + \mathbb{E}_{s' \sim E} \lambda_{s'+2|S|}. \end{aligned} \quad (28)$$

注意，式 (28) 中的 $\lambda_{s'+2|S|}$ 随后与目标函数中的线性项 $-\mathbb{E}_{s' \sim E} \lambda_{s'+2|S|}$ （见式 (3)）相消，因此 $\lambda_{s'+2|S|}$ 的值不再重要。这意味着，对于任意 $\lambda_{s'+2|S|}$ ，都存在最优解。因此，不失一般性，我们令 $\lambda_{s'+2|S|} = 0$ 。目标函数则变为

$$\begin{aligned} & \epsilon_1 \log \mathbb{E}_{s \sim I} \exp \left(\frac{\lambda_{s+|S|} + \log \frac{d_s^E(s)}{d_s^I(s)}}{\epsilon_1} \right) + \\ & \epsilon_2 \log \mathbb{E}_{(s,a,s') \sim I} \exp \left(\frac{-\gamma \lambda_{s'} + \lambda_s - \lambda_{s+|S|}}{\epsilon_2} \right) - (1 - \gamma) \mathbb{E}_{s \sim p_0} \lambda_s. \end{aligned} \quad (29)$$

然后，我们可以对 $\epsilon_1 \rightarrow 0$ 使用相同的技巧，并推断出

$\lambda_{s+|S|} = -\log \frac{d_s^E(s)}{d_s^I(s)} + Q$ ，其中 Q 是某个常数。然后，我们得到优化目标为

$$L(\lambda) = Q + \epsilon_2 \log \mathbb{E}_{(s,a,s') \sim I} \exp \left(\frac{-\gamma \lambda_{s'} + \lambda_s + \log \frac{d_s^E(s)}{d_s^I(s)} - Q}{\epsilon_2} \right) - (1 - \gamma) \mathbb{E}_{s \sim p_0} \lambda_s. \quad (30)$$

注意 Q 再次被抵消，这意味着 Q 的值无关紧要。不失一般性，我们设 $Q = 0$ ，然后得到具有 KL 散度的 SMODICE 目标。 $\square$

D. 实验细节

D.1. 表格型马尔可夫决策过程

实验设置。我们采用 LobsDICE (Kim 等人, 2022b) 中的表格型马尔可夫决策过程实验。在该表格实验中，马尔可夫决策过程有 20 个状态，每个状态有 4 个动作 s ；每个动作 a 导致四个均匀选择的状态四个后续状态上的概率分布向量由以下公式确定

$$\begin{aligned} & s'_1, s'_2, s'_3, s'_4. \\ \text{公式} \quad & (p(s'_1|s, a), p(s'_2|s, a), p(s'_3|s, a), p(s'_4|s, a)) = (1 - \eta)X + \eta Y, \text{ 其中 } X \sim \text{分类} \left(\frac{1}{4}, \frac{1}{4}, \frac{1}{4}, \frac{1}{4} \right) \end{aligned}$$

，且 $Y \sim$ 狄利克雷分布 $(1, 1, 1, 1)$ 。 $\eta \in [0, 1]$ 控制转移的随机性： $\eta = 0$ 表示确定性， $\eta = 1$ 表示高度随机。智能体始终从状态 s_0 开始，只能通过到达特定状态 s_x 获得 +1 的奖励，该状态的选择使得最优价值函数 $V^*(s_0)$ 最小化。折扣因子 γ 设为 0.95。

数据集设置。对于每个马尔可夫决策过程，专家数据集使用无限时域的确定性最优策略生成，任务无关数据集以类似方式生成，但使用均匀策略。注意，我们使用了与 LobsDICE 的 Softmax 策略不同的专家策略，因为我们发现由于马尔可夫决策过程的高连通性，每个状态的价值函数非常接近。因此，“专家”Softmax 策略实际上接近均匀且严重次优。

超参数选择。SMODICE 没有超参数选择。对于 LobsDICE，我们遵循其论文中的设置，即 $\alpha = 0.1$ 。对于我们的方法，带正则化项的版本使用 $\epsilon_1 = \epsilon_2 = 0.01$ ，线性规划版本使用 $\epsilon_1 = \epsilon_2 = 0$ 。

D.2. MuJoCo 环境

实验设置。遵循 SMODICE (Ma 等人, 2022)，我们测试了四个广泛采用的 MuJoCo 运动环境：跳跃者、半猎豹、蚂蚁和步行者 2D，以及两个更具挑战性的运动环境：蚂蚁迷宫和厨房。以下是每个环境的详细描述。参见图 10 的图示。

1. 跳跃者。跳跃者是一个二维环境，智能体控制单腿机器人向前跳跃。状态为 11 维，包括机器人每个关节的角度和速度；动作为 3 维，每个动作控制施加在特定关节上的扭矩。

2. 半猎豹。在半猎豹中，智能体控制一个类似猎豹的机器人向前奔跑。与跳跃者类似，该环境也是二维的，具有 17 维状态空间描述坐标和速度，以及 6 维动作空间控制其关节上的扭矩。




图 10. 第 4.2 节中基于 OpenAI Gym (Brockman 等人, 2016) 和 D4RL (Fu 等人, 2020b) 测试的环境图示。

3. 蚂蚁。蚂蚁是一个三维环境，智能体控制四足机器蚂蚁向前移动。111 维状态空间包括每个关节的坐标和速度。动作空间为 8 维。
4. 步行者 2D。步行者 2D，顾名思义，是一个二维环境，智能体控制双足机器人向前行走。状态空间为 27 维，动作空间为 8 维。
5. 蚂蚁迷宫。在本工作中，我们考虑 U 形迷宫任务，智能体需要操控一个具有 29 维状态的 8 自由度机器蚂蚁，从迷宫的一端爬到另一端，如图 10 所示。
6. 厨房。D4RL 中的 Franka **Kitchen** 是一个具有挑战性的环境，智能体操控一个 9 自由度机械臂，并尝试完成 4 个顺序子任务。子任务候选包括移动水壶、打开微波炉、打开底部或顶部炉灶、打开左侧或右侧橱柜以及打开灯。状态空间描述机器人的状态以及目标物品的目标位置和当前位置。状态为 60 维。

数据集设置。 我们采用与 SMODICE (Ma 等, 2022) 相同的设置。SMODICE 使用 D4RL (Fu 等, 2020b) 中“expert-v2”数据集的一条轨迹 (1000 个状态) 作为专家数据集 E 。对于任务无关数据集 I ，SMODICE 使用“expert-v2”中 200 条轨迹 (200K 个状态-动作对) 与整个“random-v2”数据集 (1M 个状态-动作对) 的拼接。

超参数选择。 表 1 总结了我们的超参数，这些超参数在适用时也是普通行为克隆的超参数。对于基线 (SMODICE、LobsDICE、ORIL、OTR 和 DWBC)，我们使用其论文中报告的超参数 (除非论文与代码中的超参数值不同，此时我们报告代码中的值)。

Type	Hyperparameter	Value	Note
Disc.	Network Size	[256, 256]	
	Activation Function	Tanh	
	Learning Rate	0.0003	
	Training Length	40K steps	
	Batch Size	512	
	Optimizer	Adam	
Actor	Network Size	[256, 256]	
	Activation Function	ReLU	
	Learning Rate	0.001	
	Weight Decay	10^{-5}	
	Training length	1M steps	
	Batch Size	1024	
Critic	Optimizer	Adam	
	Tanh-Squashed	Yes	
	Network Size	[256, 256]	
	Activation Function	ReLU	
	Learning Rate	0.0003	
	Training Length	1M steps	
	Batch Size	1024	
	Optimizer	Adam	
	ϵ_1	kitchen 0.01, others 0.5	coefficient for the KL regularizer
	ϵ_2	kitchen 2, others 0.5	coefficient for the KL regularizer
	α	0.01	mixing coefficient to the denominator of $R(s)$
	β	5	coefficient for combination of distance metric
	γ	0.998	discount factor in our formulation

表 1. 我们选择的超参数。我们使用与 SMODICE (Ma 等, 2022) 相同的网络架构和优化器。

对比学习距离的实现。我们在 FIST (Hakhamaneshi 等, 2022) 的实现基础上构建对比学习模块。对比学习嵌入框架在任务无关数据集上训练 200 个训练轮次。每个训练轮次中, 我们使用 4096 的批大小, 每个数据点由一个连续状态对 $(s_i, s'_i), i \in \{1, 2, \dots, 4096\}$ 组成, 状态为 n 维。首先对每个 s_i 和 s'_i 应用一个具有 $M = 32$ 个嵌入维度的编码层 $g(s) : \mathbb{R}^n \rightarrow \mathbb{R}^{M \times 1}$ 。然后计算得分矩阵 $L \in \mathbb{R}^{4096 \times 4096}$, 使得 $L_{i,j} = g(s_i)^T W g(s'_j)$, $W \in \mathbb{R}^{M \times M} = \text{softplus}(W_0)$ (W_0 是一个可学习矩阵, 其结构设计旨在提高稳定性。最后, L 的每一行被视为 4096 路分类的得分。标签是单位矩阵。这种训练范式给出了式 (7) 中同样提供的损失:

$$L_c = \log \frac{\exp(q^T W k_+)}{\exp(q^T W k_+) + \sum_{k_-} \exp(q^T W k_-)}. \quad (31)$$

这里, $q = g(s_i)$ 是查询 (锚点), W 是权重矩阵, $k_+ = g(s'_i)$ 是正键, $k_- \in \{g(s'_j) | j \neq i\}$ 是负键。该目标本质上相当于一个 4096 路分类任务, 其中第 i 个样本的正确标签是 i 。

E. 附加实验结果

E.1. 表格环境的补充结果

E.1.1. 状态与状态对全变差距离

本节展示学习者与专家策略之间的状态占用全变差 (Total Variation, TV) 发散, 以及学习者与专家之间的状态对占用全变差发散, 即 $\text{TV}(d_s^\pi \| d_s^E)$ 和 $\text{TV}(d_{ss}^\pi \| d_{ss}^E)$ 。图 11 展示了学习者策略与专家策略之间状态占用距离的结果。图 12 展示了状态对占用之间的距离。我们观察到, 我们的方法优于 SMODICE 和 LobsDICE。

E.1.2. 使用 Softmax 专家的表格实验

与 LobsDICE (Kim 等人, 2022b) 保持一致, 我们还报告了使用与 LobsDICE 完全相同的设置 (即使用高度次优的专家) 的实验结果。图 13、图 14 和图 15 分别展示了该设置下各方法的遗憾值、状态占用发散 $\text{TV}(d_s^\pi \| d_s^E)$ 和状态对占用发散 $\text{TV}(d_{ss}^\pi \| d_{ss}^E)$ 。结果表明, 我们的方法在最小化占用发散方面表现不佳, 因为我们的 PW-DICE 中 f -发散正则化项的系数远小于 0 或等于 0, 这意味着我们获得的策略更具确定性, 因此与高度随机的“专家”策略不同。值得注意的是, 我们的方法在准确估计 MDP 的情况下




图 11. 各方法在表格环境上的全变差距离 $TV(d_s^\pi \| d_s^E)$ 。对于小型任务无关数据集，我们的方法（无论是否使用正则化项）与基线方法表现相当；而在更大的任务无关数据集（更准确的估计动态）上，我们的方法表现更优。




图 12. 学习者与专家之间的状态对占用全变差距离 ($TV(d_{ss}^\pi \| d_{ss}^E)$) 在表格环境上的结果。与状态占用全变差距离和遗憾值类似，我们的方法表现最佳，尤其是在更大的任务无关数据集上。




图 13. 使用 Softmax 专家的表格实验中各方法的遗憾值。使用正则化项的我们的方法通常获得更低的遗憾值。此外，我们的方法是唯一实现负遗憾值（即优于高度次优的“专家”）的方法。

动态特性（即任务无关/非专家数据集的大规模）是唯一实现负遗憾的方法，即本文方法甚至优于“专家”策略。此外，带有正则化项的本文方法通常能达到更低的遗憾。

E.2. MuJoCo 环境下使用 χ^2 散度的 PW-DICE

在主论文中，我们主要考虑了使用 KL 散度的 PW-DICE。然而，如推论 C.2 所示，PW-DICE 中的 D_f 正则化项也可以是 χ^2 散度。假设我们像 SMODICE (Ma 等人, 2022 年) 那样使用半 χ^2 散度，即 $f(x) = \frac{1}{2}(x-1)^2$, $f_*(x) = \frac{1}{2}(x+1)^2$ ，且 $f'(x) = x+1$ 。采用这种散度后，PW-DICE 的最终优化目标如下：

$$\begin{aligned} & \min_{\lambda} \frac{\epsilon_1}{2} \mathbb{E}_{s_i \sim I, s_j \sim E} \left(\frac{\lambda_{i+|S|} + \lambda_{j+2|S|} - c(s_i, s_j)}{\epsilon_1} + 1 \right)^2 \\ & + \frac{\epsilon_2}{2} \mathbb{E}_{(s_i, a_j, s_k) \sim I} \left(\frac{-\gamma \lambda_k + \lambda_i - \lambda_{i+|S|}}{\epsilon_2} + 1 \right)^2 - [(1-\gamma) \mathbb{E}_{s \sim p_0} \lambda_{:|S|} + \mathbb{E}_{s \sim E} \lambda_{2|S|:3|S|}], \end{aligned} \quad (32)$$

策略损失为

$$E_{(s,a) \sim I} \max \left(0, \frac{-\gamma \mathbb{E}_{s_k \sim p(\cdot|s_i, a_j)} \lambda_k + \lambda_i - \lambda_{i+|S|}}{\epsilon_2} \right). \quad (33)$$

然而，与 SMODICE 类似，我们发现 χ^2 散度正则化项在 MuJoCo 环境下效果不佳，因为任务无关数据集中好动作与坏动作之间的权重比仅与 $-\gamma \lambda_k + \lambda_i - \lambda_{i+|S|}$ 成比例（而非指数关系），因此区分度不足。结果，检索到的策略高度随机。图 16 展示了 χ^2 散度的结果，远差于 KL 散度的结果。




图 14. 各方法在 softmax 专家表格实验中的状态占用 TV 距离 $\text{TV}(d_s^\pi \| d_s^E)$ 。本文方法效果不佳，因为专家策略高度随机。

E.3. 从动力学不匹配的专家中学习

为了证明本文方法对不同动力学具有鲁棒性，我们采用了 SMODICE (Ma 等人, 2022 年) 中的动力学不匹配设置，其中智能体需要从与第 4.2 节主要结果相同的任务无关数据集中学习，但专家数据集由动力学差异很大的专家生成：例如，在蚂蚁环境中专家的一条腿被截肢，在半猎豹环境中专家的躯干短得多。我们使用与 SMODICE 完全相同的设置；图 17 展示了结果，表明本文方法通常比 SMODICE、LobsDICE 和 ORIL 对形态差异更具鲁棒性。

F. 符号表

表 2 列出了论文中出现的符号。

G. 计算资源

所有实验均在 Ubuntu 18.04 服务器上使用单块 NVIDIA RTX 2080Ti GPU 进行，该服务器配备 72 颗 Intel Xeon Gold 6254 CPU @ 3.10GHz。在给定这些资源的情况下，我们的方法在 MuJoCo 环境中完成训练大约需要 5 – 5.5 小时（其中距离度量的训练，包括 $R(s)$ 和对比学习，耗时 20 – 40 分钟），而 ORIL、SMODICE 和 LobsDICE 大约需要 2.5 – 3 小时。由于所有方法的 actor 网络相同，推理速度相似，不构成瓶颈。




图 15. 各方法在 softmax 专家表格实验中的状态对占用总变差距离 $TV(d_{ss}^{\pi} || d_{ss}^E)$ 。由于专家策略高度随机，我们的方法效果不佳。




图 16. PW-DICE 中 χ^2 -散度（蓝色）与 KL 散度（红色）的性能比较。 χ^2 -散度的效果不如 KL 散度。




图 17. 专家动力学不匹配情况下的性能比较；结果表明，在这两个环境中，我们的方法通常比 SMODICE、LobsDICE 和 ORIL 更鲁棒。

Name	Meaning	Note
S	State space	$ S $ is the size of state space
A	Action space	$ A $ is the size of state space
γ	Discount factor	$\gamma \in (0, 1)$
r	Reward function	$r(s, a)$ for single state-action pair
T	Transition function	
p	Transition (single entry)	$p(s' s, a) \in \Delta(S)$
p_0	Initial distribution	$p_0 \in \Delta(S)$
s	State	$s \in S$
a	Action	$a \in A$
$\bar{s}$	Past state	
$\bar{a}$	Past action	
τ	Trajectories	State-only or state-action; depend on context
E	Expert dataset	state-only expert trajectories
I	Task-agnostic dataset	state-action trajectories of unknown optimality
π	Learner policy	
π^E	Expert policy abstracted from E	
π^I	Task-agnostic policy abstracted from I	
d_{sa}^π	State-action occupancy of π	1) $\forall s \in S, \sum_a d_{sa}^\pi(s, a) = d_s^\pi(s)$. This equation also applies similarly between d_{sa}^E and d_s^E , as well as d_{sa}^I and d_s^I . 2) $d_s^\pi(s) = (1 - \gamma) \sum_{i=0}^{\infty} \gamma^i \Pr(s_i = s)$, where s_i is the i -th state in a trajectory. This holds similarly for $d^I(s)$ and $d^E(s)$. 3) $d_{sa}^\pi(s, a) = d_s^\pi(s) \pi(a s)$. This holds similarly for d_{sa}^E, π^E and d_{sa}^I, π^I .
d_s^π	State occupancy of π	
d_{ss}^π	State-pair occupancy of π	
d_s^E	State occupancy of π^E	
d_{ss}^E	State-pair occupancy of π^E	
d_{sa}^I	State-action occupancy of π^I	
d_s^I	State occupancy of π^I	
λ	Dual variable	
D_f	f -divergence	
$f_*(\cdot)$	Fenchel conjugate of f	
c	Matching cost for Wasserstein distance	With extended domain
c'	Matching cost for Wasserstein distance	
Π	Wasserstein matching variable	$\sum_{s \in S} \Pi(s, s') = d_s^E(s'), \sum_{s' \in S} \Pi(s, s') = d_s^\pi(s)$
A	Equality constraint matrix	
x	unified self-variable	concatenation of flattened Π and d_{sa}^π (row first)
b	Equality constraint vector	$Ax = b$
U	Distribution as regularizer	product of d_s^I and d_s^E
$\mathcal{W}$	Wasserstein distance	
$h(\cdot)$	state discriminator	
W	Weight matrix of contrastive learning	$W \in \mathbb{R}^{32 \times 32}$
$g(\cdot)$	embedding to be learned	
L	score matrix	$L \in \mathbb{R}^{4096 \times 4096}$
n	number of dimensions for state	
M	number of dimensions for embedding	$M = 32$
β	coefficient for learned embedding in distance metric	

表 2. 论文中使用的完整符号列表。第一部分用于离线 LfO 设置，第二部分列出 PW-DICE 特有的符号，第三部分用于对比学习（附录 D.2）中使用的符号。