

不匹配执行下的单样本模仿

库沙尔·凯迪亚^{*,1}、普里特维什·丹^{*,1}、安吉拉·赵¹、马克西姆斯·A·佩斯¹、桑吉班·乔杜里¹




图 1: RHyme 概览。本文提出 RHyme, 一种分层框架, 用于训练机器人策略以模仿来自执行不匹配任务演示者的长时程视频。训练目标 (左): 给定未配对的人机数据集, RHyme 利用序列级相似度函数“想象”创建配对数据集, 用于训练单样本模仿机器人策略。推理目标 (右): 本文的机器人策略将人类视频转换为机器人动作, 以执行指定的长时程任务。

摘要——人类演示作为提示, 是编程机器人执行长时程操作任务的有效方式。然而, 由于运动风格和物理能力上的执行不匹配, 将这些演示转换为机器人可执行动作面临重大挑战。现有的人机转换方法要么依赖难以扩展的配对数据, 要么严重依赖帧级视觉相似性, 而后者在实践中常常失效。为应对这些挑战, 本文提出 RHyme, 一种新颖的框架, 利用序列级最优传输代价函数自动配对人迹与机器人轨迹。给定长时程机器人演示, RHyme 通过检索和组合短程人类片段来合成语义等价的人类视频。该方法无需配对数据即可实现有效的策略训练。RHyme 成功模仿了一系列跨具身演示者, 包括仿真环境和真实人手, 任务成功率相比以往方法提升超过 50%。本文在以下网站公开代码和数据集。

一、引言

人类演示为编程机器人执行长时程操作任务提供了一种有效方法 [1–4]。与语言指令不同, 演示扎根于任务环境, 为遵循哪些步骤、与哪些物体交互以及如何交互提供了丰富线索 [5, 6]。

我们将此视为一个翻译问题, 其中人类视频必须被翻译成一系列机器人动作 [7–10]。然而, 训练此类策略通常需要成对的人机演示, 这对于长程任务而言难以大规模收集。尽管存在大规模人类视频 (如 YouTube) 和机器人数据集 [11, 12], 但它们并非成对, 因此不适合直接学习这种翻译。先前工作利用非成对的人机演示来学习视觉表征, 将人类和机器人图像映射到共享嵌入空间 [4, 6, 13–15]。随后训练策略以机器人视频嵌入为条件生成动作, 并在测试时直接迁移到以人类提示视频嵌入为条件的工作中。然而, 这些工作依赖的一个关键假设是人类和机器人以匹配的执行方式完成任务, 即人类执行任务的方式在视觉上与机器人相似 (例如缓慢移动单臂并进行简单抓取)。现实中, 人类往往动作更快、使用双手操作, 甚至同时执行多个任务, 造成执行风格的错配。这种错配导致人类和机器人嵌入之间的不对齐, 阻碍了策略的直接迁移。我们解决这种错配执行下的模仿问题。我们的核心洞见是, 尽管人类和机器人可能在视觉和物理上以不同方式执行同一任务

¹ 康奈尔大学 * 同等贡献

通过不同方式，我们可以对整个图像嵌入序列进行推理，从而建立高层次等价关系

它们生成。本文表明，尽管人类与机器人的单个图像嵌入可能呈现差异，但可以构建序列级相似性函数，使二者更为接近。值得注意的是，无需在配对数据上微调表示即可实现这一点。本文提出 RHyme（不匹配执行下的混合模仿检索框架），该框架训练机器人策略以跟随来自不匹配专家的长时程演示，且无需访问配对的人机视频（图 1）。首先，RHyme 定义人类与机器人嵌入之间的序列级相似性度量，利用最优传输衡量对齐程度。给定机器人轨迹和人类操作数据数据库，RHyme 通过检索并组合与机器人视频相似的人类演示短时程片段，想象出长时程视频。该检索过程由人类与机器人序列之间的最优传输相似性度量引导。该框架采用混合方法训练策略，同时纳入真实机器人演示和想象的人类序列。本文贡献如下：

- 1) 本文引入 RHyme，一种基于检索的算法，用于创建人类与机器人轨迹的配对数据集，从而在不匹配执行下实现一次性模仿。
- 2) 本文提出三个新颖的数据集，用于 Franka Kitchen 仿真器中的跨具身学习，其执行不匹配程度相对于机器人逐步增加。
- 3) 在仿真和真实世界中，本文证明 RHyme 优于基线方法，在模仿未见人类视频时将任务完成率提高 2 倍。此外，本文表明序列级相似性函数相比帧级相似性函数显著提升检索性能。

II. 相关工作

人类演示已被以多种不同方式用于引导机器人操作策略。本文将工作置于各相关研究集群之中。

跟踪参考运动。当机器人接收到演示者的运动作为输入时，模仿挑战被简化为运动跟踪。具有类人关节配置的机器人可以直接模仿人类轨迹，这种方法已应用于具有相似形态的人形机器人 [16 – 21] 和机器人手 [22 – 29]。当执行能力不匹配时，要么简化人类模型 [16, 18, 20]，要么优化机器人轨迹 [17, 19, 30, 31] 以近似匹配参考轨迹。[21] 展示了一种从视频中提取人体姿态并将其用作训练强化学习智能体的参考的方法。类似地，人类演示已被用于指导机器人手的强化学习 [22 – 25]。最近，互联网上大规模的人类视频数据集已被用于提取手部位置并适应机器人操作 [26 – 29, 32]，或依赖于其他常见抽象，如光流作为共同

跨具身轨迹表征 [33]，仍需匹配执行过程。与这些工作不同，本文专注于直接从人类 RGB 视频中学习机器人操作任务，无需显式运动输入。从演示者视频学习奖励函数。这些方法解决当演示者运动无法简单模仿时的行为匹配问题。其视频仍包含有用的任务信息，可用于为机器人强化学习学习奖励函数。该研究方向中的通用方法 [2, 34 – 36] 是提取奖励函数，鼓励机器人以与视频相同的方式操作物体。例如，[34] 通过让机器人学习匹配演示者扰动绳子的示范来实现自监督。GraphIRL[2] 从演示者提取物体姿态运动序列，并强制与机器人执行保持时间循环一致性。其他方法将问题框架化为任务匹配 [37, 38]，当机器人被认为执行与演示者相同的技能时给予奖励。虽然这些论文直接解决执行不匹配问题，但它们需要强化学习来训练机器人策略，这对复杂任务具有挑战性。学习对齐的人机表征。应对这一挑战的另一策略是训练机器人和人类在执行相同任务时不可区分的表征。该方法通常将任务框架化为视频翻译挑战，将演示者视频转换为机器人视角以简化任务模仿 [9, 10, 39]。此外，WHIRL[3] 等方法通过有效掩蔽机器人和人类来对齐视频，创建中性视觉场。嵌入可以利用直接配对人与机器人动作的数据集，或利用人类偏好数据集对图像帧进行排序来对齐，如 X-IRL[1] 和 RAPL[40] 所示。与这些方法不同，本文方法不依赖标注的人机对应关系。演示视频的一次性视觉模仿。本文解决该问题设置，机器人从人类演示视频中一次性模仿动作，即机器人使用提示视频作为引导，在观看一次后尝试复制所示动作 [4, 6 – 8, 32, 41 – 43]。若存在执行相同任务的人机视频配对数据集，机器人可直接学习将提示视频转换为动作 [7, 8]。与本文最接近的是无人机技能配对数据的设置。然而，这些工作 [4, 6] 训练以机器人视频为条件的策略，并依赖测试时对提示演示的零样本迁移。例如，XSkill[4] 使用基于视觉相似性的自监督聚类算法来对齐人与机器人视频的表征。然而，当执行存在显著不匹配时，此类方法可能失效。本文通过将视觉模仿问题构建为训练时检索问题来解决该问题。在训练期间，将机器人视频与未配对游戏数据集中最接近的人类片段进行匹配，以想象合成演示视频。训练

基于这些合成视频的条件化机器人策略使机器人能够将演示视频转化为机器人动作。

III. 问题表述

推理时间：转化人类演示

视频到机器人动作 机器人的目标是通过策略 $\pi(a_R|s_R, \mathbf{v}_H)$ 将视频转换为机器人动作 a_R ，在状态 s_R 下复现视频中演示的一系列任务。人类演示视频是图像序列 $\mathbf{v}_H = \{v_H^0, v_H^1, \dots, v_H^T\}$ ，其中 T 为视频长度。训练阶段：从非配对的人类与机器人数据中学习

机器人数据。虽然利用成对的人机数据训练策略是可行的，但大规模收集此类数据并不现实。因此，本文将问题构建为从非配对数据中学习对齐的嵌入，从而能够将基于机器人嵌入训练的策略迁移到人类嵌入上。本文假设可访问两个数据集：一个包含长时程操作任务的机器人数据集 (D_{robot} ，以及一个包含展示与物体和环境交互的短时程人类视频片段的演示数据集 (D_{play} 。机器人数据集 $D_{\text{robot}} = \{(\xi_R, \mathbf{v}_R)\}$ 由状态-动作轨迹与机器人视频的配对组成。每条机器人轨迹，

$\xi_R = \{(s_R^0, a_R^0), (s_R^1, a_R^1), \dots, (s_R^T, a_R^T)\}$ ，表示一个回合中机器人状态和动作的序列。

相应地，机器人执行任务的 $\mathbf{v}_R = \{v_R^0, v_R^1, \dots, v_R^T\}$ is a 图像视频序列。演示数据集 $D_{\text{play}} = \{\mathbf{v}_H\}$ 由与机器人数据集没有直接对应关系的人类视频组成。在测试时，演示者的视频包含一组任务，其组合在训练期间机器人未曾见过。然而，与先前工作 [4] 一致，我们假设组成任务在 D_{play} 和 D_{robot} 中分别被覆盖。我们的目标是训练两个模块：视觉编码器和机器人策略。视觉编码器将人类和机器人视频映射到共享嵌入空间以实现转换。我们采用视频编码器 $\phi(\mathbf{v})$ 从所有视频中为每一帧提取嵌入序列 $\mathbf{z} = \{z_0, z_1, \dots, z_T\}$ 。然后，给定人类演示视频 $\mathbf{v}_H$ ，我们生成潜在嵌入序列 $\mathbf{z}_H$ 。我们的目标是训练一个策略，该策略以嵌入序列为条件来预测机器人动作 $\pi(a_R|s_R, \mathbf{z}_H)$ ，而无需访问配对的人类和机器人数据。我们在第四节讨论如何训练编码器和策略。

四、方法

我们提出 RHyme，一种一次性模仿学习算法，无需配对数据即可将人类视频转换为机器人动作。在策略训练之前，我们首先使用未配对的人类和机器人视频数据集训练视频编码器（第 IV-A 节）。然后，该训练好的视频编码器被冻结，并在策略训练期间用于检索（第 IV-B 节）。在训练时，仅给定机器人轨迹，RHyme 通过检索和组合短时人类片段来想象相应的演示。然后，它训练一个策略，以想象的演示为条件来预测机器人动作。

我们编码一个由 8 个相邻图像组成的 1 时间步滑动窗口，以生成每个图像嵌入。

演示。我们在下面讨论检索、训练过程和视频嵌入的细节。

A. 训练视觉编码器

我们以三种方式对齐人类和机器人视频嵌入：视觉上、时间上和任务层面，所有这些都不需要轨迹级别的对应关系。我们采用无监督损失 $\mathcal{L}_{\text{vis}}(\phi)$ 和 $\mathcal{L}_{\text{temp}}(\phi)$ 进行视觉和时间对齐，遵循先前工作 [44, 45]，并引入可选的任务对齐损失 $\mathcal{L}_{\text{task}}(\phi)$ 。

视觉对齐。为了对齐人类与机器人的嵌入 ($\mathbf{z}_R, \mathbf{z}_H$ ，本文采用自监督方法斯瓦夫 (SwAV) [44]，该方法基于共享视觉特征对图像进行聚类。斯瓦夫学习一组 K 个原型向量，并将每张图像分配给这些原型。斯瓦夫损失 $\mathcal{L}_{\text{vis}}(\phi)$ 同时更新编码器和原型，通过聚类相似的视觉特征来对齐人类与机器人视频。

对齐时间 为了对齐人类和机器人视频中时间上相邻的帧，我们使用时间对比损失 [45]。该损失鼓励时间上接近的帧的嵌入彼此相似。对于每一帧 z^t ，我们定义一个正样本集 $\mathbf{z}^+$ ，包含时间窗口 w 内的帧，以及一个负样本集 $\mathbf{z}^-$ ，包含该窗口外的帧。利用对比损失 $\mathcal{L}_{\text{temp}}(\phi)$ ，我们将正样本集的嵌入拉近，并将负样本集的嵌入推远，从而捕捉跨视频的时间连续性。

任务对齐。任务级对齐 $\mathcal{L}_{\text{task}}(\phi)$ 适用于存在少量成对人类与机器人片段的情况。与帧级方法不同，该方法对齐机器人 $\mathbf{z}_R$ 与演示者 $\mathbf{z}_H$ 的视频嵌入。本文计算最优传输距离 $d(\mathbf{z}_R, \mathbf{z}_H)$ 以衡量两段视频嵌入序列之间的相似性。随后采用对比学习目标 (INFO-NCE [46]) 拉近匹配嵌入，推远不同任务的嵌入。最终的任务对齐损失为：

$$\mathcal{L}_{\text{task}}(\phi) = - \sum_i \frac{\exp(-d(\mathbf{z}_R^i, \mathbf{z}_H^i))}{\exp(-d(\mathbf{z}_R^i, \mathbf{z}_H^i)) + \sum_{j \neq i} \exp(-d(\mathbf{z}_R^i, \mathbf{z}_H^j))}$$

用于训练视觉编码器 ϕ 的最终损失函数为：

$$\mathcal{L}(\phi) = \lambda_{\text{vis}} \mathcal{L}_{\text{vis}}(\phi) + \lambda_{\text{temp}} \mathcal{L}_{\text{temp}}(\phi) + \lambda_{\text{task}} \mathcal{L}_{\text{task}}(\phi) \quad (1)$$

其中 $\lambda_{\text{task}} = 0$ 默认为零，仅在获得短视界配对数据时非零。

B. 训练机器人策略

训练概览。算法 1 详细阐述了利用机器人轨迹和想象的人类演示视频训练机器人策略 π_θ 的方法。训练过程分为两个阶段。阶段 1：构建配对数据集。对于 D_{robot} 中的每条机器人轨迹 ξ_R 和视频 $\mathbf{v}_R$ ，我们使用学习到的视频编码器 ϕ 将机器人视频编码为嵌入 $\mathbf{z}_R = \phi(\mathbf{v}_R)$ 。随后，通过函数 Imagine-Demo 将 $\mathbf{z}_R$ 与游戏数据集 D_{play} 中的演示片段对齐，检索出想象的人类嵌入 $\hat{\mathbf{z}}_H$ 。由此生成包含 $(\hat{\mathbf{z}}_H, \mathbf{z}_R, \xi_R)$ 的配对数据集 D_{paired} 。阶段 2：在配对数据集上训练策略。策略 π_θ 以混合方式在配对数据集 D_{paired} 上进行训练。对于 D_{paired} 中的每个元素，我们以两种模式更新策略。

模式——模式 1：策略以机器人视频嵌入 $\mathbf{z}_R$ 为条件来预测动作 $\pi_\theta(a_t|s_t, \mathbf{z}_R)$ 。模式 2：策略以想象的人类演示嵌入 $\hat{\mathbf{z}}_H$ 为条件来预测动作 $\pi_\theta(a_t|s_t, \hat{\mathbf{z}}_H)$ 。通过在这两种模式之间交替，策略学会从机器人视频和想象的人类视频中泛化，从而能够处理执行不匹配问题。

Algorithm 1 RHyME: Retrieval for Hybrid imitation under Mismatched Execution

Input: Robot Dataset D_{robot} , Human Play Dataset D_{play} , Video Encoder $\phi(\mathbf{z}|\mathbf{v})$
Output: Trained Robot Policy $\pi_\theta(a|s, \mathbf{z})$
Initialize Robot Policy π_θ
while not converged **do**
 Get robot video and actions $\xi_R, \mathbf{v}_R \sim D_{\text{robot}}$
 Generate robot embeddings $\mathbf{z}_R = \phi(\mathbf{v}_R)$
 // Retrieve human embeddings
 $\hat{\mathbf{z}}_H \leftarrow \text{Imagine-Demo}(\mathbf{z}_R, D_{\text{play}})$
 // Hybrid Training
 for (s_t, a_t) in ξ_R **do**
 // Condition on imagined demo
 Update-Policy($a_t, \pi_\theta(s_t, \hat{\mathbf{z}}_H)$)
 // Condition on robot video
 Update-Policy($a_t, \pi_\theta(s_t, \mathbf{z}_R)$)
Return Trained Robot Policy π

Algorithm 2 Imagine-Demo: Retrieving Matched Human Embeddings

Input: Robot Embeddings $\mathbf{z}_R$, Human Play Dataset D_{play} , Video Encoder $\phi(\mathbf{z}|\mathbf{v})$, Segment Length K , Distance Function d
Output: Imagined Demo $\hat{\mathbf{z}}_H$
Initialize empty demo $\hat{\mathbf{z}}_H \leftarrow \{\}$
// Divide long-horizon robot sequence into short-horizon clips
 $Z_R = \{z_R^{1:K}, z_R^{K+1:2K}, \dots, z_R^{T-K+1:T}\}$
for robot segment $z_R^{i:i+K}$ in Z_R **do**
 // Find closest short-horizon clip embedding in play dataset
 $\hat{\mathbf{z}}_H \leftarrow \arg \min_{\mathbf{z}_H \in D_{\text{play}}} d(\mathbf{z}_H, z_R^{i:i+K})$
 // Extend imagined embedding sequence with retrieved demo
 $\hat{\mathbf{z}}_H.\text{extend}(\hat{\mathbf{z}}_{\text{play}})$
Return Imagined Demo $\hat{\mathbf{z}}_H$

想象人类演示视频。算法 2 详细阐述了用于想象人类嵌入序列的检索过程。我们将机器人视频划分为短视界窗口，并将其嵌入与游戏数据集中的嵌入进行比较，检索出序列级距离最小的片段。这些检索到的片段被拼接起来，形成想象的长视界人类演示视频。关键挑战在于定义距离度量。

函数 $d(\mathbf{z}_R, \mathbf{z}_H)$ ，能够处理长度可变的视频序列。本文提出两种计算该距离的方法：最优传输距离与时间循环一致性（Temporal Cyclic Consistency, TCC）距离。方法一：最优传输距离。本文计算人类与机器人视频嵌入之间的 Wasserstein 距离（最优传输）[47]，即将一个视频嵌入序列转换为另一个序列的最优传输计划的代价。机器人的嵌入分布定义为 $\rho_R = \{1/T, 1/T, \dots, 1/T\}$ ，人类的嵌入分布定义为 $\rho_H = \{1/T', 1/T', \dots, 1/T'\}$ ，其中 T 与 T' 分别为视频序列的长度。传输的代价函数为 C ，其中 C^{ij} 为机器人嵌入 z_R^i 与人类嵌入 z_H^j 之间的余弦距离。本文的目标是找到最优分配 $M^* \in \mathbb{R}^{T \times T'}$ ，将分布从 ρ_R 传输至 ρ_H ，同时最小化计算 $\in \mathbb{R}^{T \times T'}$ 划代价。形式上，需要找到 $M^* = \arg \min_M$

。求解最优传输分配后，距离 $\sum_i \sum_j C^{ij} M^{ij}$ 离函数即为计划代价，即 $d(\mathbf{z}_R, \mathbf{z}_H) = \sum_i \sum_j C^{ij} M^{ij}$ 。实践中，本文优化该问题的熵正则化版本，利用 Sinkhorn-Knopp 算法 [47] 高效地求得近似解。方法二：时间循环一致性（TCC）距离。本文遵循 [48] 计算人类与机器人视频之间的 TCC 损失，该损失计算机器人视频嵌入 $\mathbf{z}_R = \{z_R^1, z_R^2, \dots, z_R^T\}$ 与人类视频嵌入 $\mathbf{z}_H = \{z_H^1, z_H^2, \dots, z_H^{T'}\}$ 之间的循环一致性。对于每个机器人帧 z_R^t ，首先计算相似度分布 α 相对于人类嵌入，以找到软最近邻 $\tilde{z}_H = \sum_{t'=1}^{T'} \alpha_t z_H^{t'}$ of z_R^t 的相似度分布 β ，循环回机器人视频，得到其软最近邻 $\tilde{z}_R^t = \sum_{t=1}^T \beta^t z_R^t$ 。TCC 机器人帧 z_R^t 的距离为其与循环回帧 $\tilde{z}_R^t$ 的均方误差，即 $\ell_{\text{tcc}} = \|z_R^t - \tilde{z}_R^t\|_2$ 。本文通过累加帧级损失定义视频级 TCC 距离函数 $d(\mathbf{z}_R, \mathbf{z}_H) = \sum_{t=1}^T \ell_{\text{tcc}}(z_R^t)$ 。本文假设，在两种情况下，使用 TCC 距离进行视频检索可能不准确：（1）当人类与机器人嵌入因执行速度或风格差异而不同，导致帧对齐不佳时。（2）当多个机器人嵌入对应单个人类帧时，例如单手机人任务与双手人类动作。

五、实验

设置。仿真：本文使用 Franka Kitchen 仿真器 [49] 评估所提方法，其中一台 7 自由度 Franka 机械臂执行 7 项不同任务。本文生成 3 个跨具身视频数据集，每个数据集逐步增加具身与执行的不匹配程度，包含 580 条完成 4 项任务序列的长时程机器人轨迹，以及用于训练模型的跨具身演示者操作数据（> 3 小时）。首先，在

S PHERE-EASY 中，本文将机器人的视觉渲染替换为




图 2：不匹配执行数据集上的性能。本文在三个数据集上展示结果（左）。随着演示者执行与机器人执行的偏差增大，使用本文框架 RHyME 训练的策略在任务召回率和误差率上始终优于 XSkill。




图 3：真实世界结果。（左）任务嵌入：本文使用 t -分布随机邻域嵌入可视化人类和机器人完成三项任务的跨具身潜在嵌入。（右）任务完成：本文比较 RHyME 与 XSkill 在由人类提示视频指定的已见和未见长时程任务上的性能。不透明段表示任务完成率，增强的透明条表示任务尝试率。

一个跟随夹爪位置的球体，从而在机器人与演示者之间产生视觉差距。其次，在 **SPHERE-MEDIUM** 中，本文引入操作风格不匹配，例如机器人拖动物体而演示者提起并搬运物体。最后，在 **SPHERE-HARD** 中，本文制造进一步发散，演示者同时执行两项任务，类似于人类使用双手的方式。图 2（左）展示了跨具身数据集。真实世界：本文使用一台 7 自由度 Franka 机械臂执行 4 项不同任务。本文在 40 条完成 3 项任务序列的长时程机器人轨迹和 ~ 15 分钟人类操作数据上训练模型，并保留 3 项测试任务的未见组合。

基线。 XSkill [4] 仅在训练期间以机器人视频为条件，并利用其共享表示空间在测试时对输入的人类视频实现零样本泛化。OraclePairing [7, 8] 是黄金标准方法，假设存在一个预言机将人类演示与机器人轨迹配对，从而在训练时能够以人类为条件。我们的方法 RHyME 找到了一个折中方案。在没有配对的情况下，它通过利用序列级对应关系，想象出执行与机器人轨迹相同任务的人类视频（第 IV-B 节）。我们比较了算法的两种变体，RHyME-TCC 和 RHyME-OT，它们在检索所用的距离函数上有所不同。在真实世界中，我们使用 XSkill [4] 作为 RHyME-OT 的基线。我们还展示了如何利用短时程的机器人-演示者任务对来改进视觉表示。

评估与成功度量。 在测试阶段，我们向机器人策略提供长时程人类视频作为提示。仿真：我们评估了 20 个不同演示者视频的一次性模仿性能，滚动

从最后 5 个模型检查点中提取机器人策略，每个数据集共产生 100 次试验。我们测量任务召回率，通过统计演示者视频中成功完成的任务数量来评估召回率；以及任务不精确度，用于衡量不精确性并报告机器人错误尝试的任务百分比——即演示者视频中未指定的任务。真实世界：我们在 30 个不同的人类视频（20 个已见，10 个未见）上评估性能。我们将任务召回率细分为两个度量：任务尝试次数和任务完成次数，它们衡量

(a) 机器人尝试执行人类视频所指定任务的能力，以及 (b) 低层控制策略完全完成任务的能力。

问题 1. 性能如何随执行不匹配程度的不同而变化？随着跨具身演示者的执行与机器人执行之间的偏差进一步增大，采用本文框架 RHyME 训练的策略始终优于 XSkill（图 2），其中在双手演示者设置 **SPHERE-HARD** 中差距最大（53% 对 1%）。OraclePairing 基线作为性能的上界。

图 4（左） 通过探测视频编码器 ϕ 的视觉表征来研究这一趋势，该编码器在不同策略间是共享的。我们使用 t -分布随机邻域嵌入图绘制了机器人和演示者在三个不同任务中的图像嵌入。随着执行不匹配程度的增加，机器人和演示者的嵌入按任务聚类的程度降低，这支持了 XSkill 在 **SPHERE-HARD** 测试时无法零样本迁移到演示者嵌入的观点。RHyME 算法通过在训练时推理来克服这一问题，并成功检索到正确的演示视频。




图 4: 跨具身视觉嵌入。(左) 任务嵌入可视化。我们使用 t -分布随机邻域嵌入来可视化机器人和演示者在所有三个数据集上执行不同任务时生成的跨具身潜在嵌入。(右) TCC 失败示例: 机器人和视频片段是等价的, 但特定帧具有较高的 TCC 损失。例如, 显示机器人执行“水壶”动作的帧由于其在视频中的最近邻同时执行“水壶”和“灯”动作而具有高损失。该帧循环回到机器人执行“灯”动作, 这是不匹配的。




图 5: 最优传输距离。我们通过计算最优传输 (Optimal Transport) 计划的代价来衡量 SPHERE-HARD 数据集上机器人和演示者视频之间的相似性。整个传输代价矩阵的代价之和即为视频之间的距离。当视频之间的任务相同时, 最优传输代价最低 (用勾号突出显示)。

嵌入序列。然而, RHyME-OT 在三个数据集上的两项指标均优于 RHyME-TCC, 这表明使用 TCC 进行训练时检索不准确。问题 2: 当以人类视频作为提示时, RHyME 在真实厨房任务中的表现如何? 在人类与机器人视频之间存在自然的视觉和执行差异的情况下, 当使用已见和未见的人类提示视频时, RHyME 始终优于 XSkill (图 3 右)。在面对已见任务的组合时, 我们观察到任务尝试和任务完成方面的边际收益, 但在未见设置中, 两项指标均有显著提升 (分别为 83% 对 50% 和 67% 对 33%), 而我们的框架正是旨在泛化到该设置。问题 3: 使用最优传输和 TCC 的视频检索在测试时如何影响策略? 由于执行差异导致任务嵌入簇偏离, 我们观察到 TCC 检索的不准确性: 在 SPHERE-HARD 中 (图 4 右), 当两个片段完成相同的两个任务时, 一个双臂任务嵌入位于两个机器人任务簇之间, 导致循环回到错误的机器人帧, 从而造成较高的任务不精确性。RHyME-OT 在所有数据集上均表现严格更优 (图 2)。这种性能差异的关键原因在于最优传输




图 6: 在 SPHERE-HARD 上配对技能可提升性能。对于非检索和基于检索的方法, 当视觉编码器使用对比最优传输损失对短时程机器人演示片段对进行微调时, 性能均有所提升。

通过在一系列嵌入中匹配视频来计算距离。图 5 可视化了在困难的 SPHERE-HARD 数据集中, 提示机器人片段与演示视频之间的最优传输方案成本。当比较执行两个任务 (例如水壶和灯) 的机器人片段时, 仅在与执行相同两个任务的演示者比较时, 跨任务分配的传输成本才最小。另一方面, TCC 试图在机器人和演示帧之间建立一一对应关系, 而该数据集中缺乏这种对应关系。问题 4: RHyME 在哪些方面成功, 其他方法的常见失败模式是什么? 我们使用 t -分布随机邻域嵌入 (t -SNE) 可视化视觉嵌入 (图 3 左)。我们发现, 现实世界中的图像嵌入通常按任务聚类, 但在灯开关任务期间趋于偏离。因此, 我们观察到 XSkill 在提示人类嵌入时从不尝试该任务。另一方面, 在未见过的设置中, RHyME 总是尝试灯开关任务, 并在 10 次中完成了 9 次。用于想象配对数据集的最优传输检索 (第 IV 节) 能够通过推理嵌入分布而不是依赖完美的嵌入对齐来正确匹配完成相同任务的人类和机器人片段, 因此 RHyME 能够在训练时准确地将动作标签与想象的人类视频配对, 并获得更好的性能 (图 3 右)。问题 5: 使用任务等价对微调视觉表示是否改善一次性模仿? 按照第 IV-A 节, 我们假设可以访问跨实施例的短视界任务配对, 并在 SPHERE-HARD 设置中对视觉表示应用 $L_{task}(\phi)$ 。

我们发现，鼓励嵌入上的诱导分布相似可以提升 **XSkill** 和 RHyME-OT 的性能（图 6），并且随着更多配对片段的增加而扩展。最终，在存在执行不匹配的情况下，使用最优传输比较嵌入上的诱导分布是在任务级别匹配片段的有益设计选择，因为 RHyME-OT（0% 微调）仍然显著优于 **XSkill**（微调）。

六、讨论与局限性

本文针对演示者执行不匹配情况下的单次模仿挑战展开研究。提出新颖框架 RHyME，利用任务级对应关系弥合机器人与演示者之间的帧级视觉差异，从而在无配对数据条件下学习视频条件策略。

局限性。 尽管测试阶段的任务组合在训练期间不可见，但本文方法依赖机器人数据集中任务对之间的转换来学习转换动作。这限制了学习全新任务序列的能力。需要指出的是，当此类转换存在时，本文方法仍能良好泛化至新组合。

七、致谢

Sanjiban Choudhury 部分受谷歌教员研究奖、OpenAI 超级对齐资助、ONR 青年研究员奖、NSF RI #2312956 及 NSF FRR #2327973 支持。

参考文献

- [1] K. Zakka, A. Zeng, P. R. Florence, J. Tompson, J. Bohg, and D. Dwibedi, “Xirl: Cross-embodiment inverse reinforcement learning,” in *Conference on Robot Learning*, 2021.
- [2] S. Kumar, J. Zamora, N. Hansen, R. Jangir, and X. Wang, “Graph inverse reinforcement learning from diverse videos,” 2022.
- [3] S. Bahl, A. Gupta, and D. Pathak, “Human-to-robot imitation in the wild,” 2022.
- [4] M. Xu, Z. Xu, C. Chi, M. Veloso, and S. Song, “XSkill: Cross embodiment skill discovery,” in *7th Annual Conference on Robot Learning*, 2023. [Online]. Available: <https://openreview.net/forum?id=8L6pHd9aS6w>
- [5] S. Bahl, R. Mendonca, L. Chen, U. Jain, and D. Pathak, “Affordances from human videos as a versatile representation for robotics,” 2023.
- [6] C. Wang, L. Fan, J. Sun, R. Zhang, L. Fei-Fei, D. Xu, Y. Zhu, and A. Anandkumar, “Mimicplay: Long-horizon imitation learning by watching human play,” 2023.
- [7] E. Jang, A. Irpan, M. Khansari, D. Kappler, F. Ebert, C. Lynch, S. Levine, and C. Finn, “Bc-z: Zero-shot task generalization with robotic imitation learning,” vol. abs/2202.02005, 2022.
- [8] V. Jain, M. Attarian, N. Joshi, A. Wahid, D. Driess, Q. Vuong, P. R. Sanketi, P. Sermanet, S. Welker, C. Chan, I. Gilitschenski, Y. Bisk, and D. Dwibedi, “Vid2robot: End-to-end video-conditioned policy learning with cross-attention transformers,” vol. abs/2403.12943, 2024.
- [9] L. M. Smith, N. Dhawan, M. Zhang, P. Abbeel, and S. Levine, “AVID: learning multi-stage tasks via pixel-level translation of human videos,” in *Robotics: Science and Systems XVI, Virtual Event / Corvallis, Oregon, USA, July 12-16, 2020*, M. Toussaint, A. Bicchi, and T. Hermans, Eds., 2020. [Online]. Available: <https://doi.org/10.15607/RSS.2020.XVI.024>
- [10] E. Chane-Sane, C. Schmid, and I. Laptev, “Learning video-conditioned policies for unseen manipulation tasks,” *2023 IEEE International Conference on Robotics and Automation (ICRA)*, pp. 909–916, 2023.
- [11] A. Khazatsky, K. Pertsch, S. Nair, A. Balakrishna, S. Dasari, S. Karamcheti, S. Nasiriany, M. K. Srirama, L. Y. Chen, K. Ellis *et al.*, “Droid: A large-scale in-the-wild robot manipulation dataset,” *arXiv preprint arXiv:2403.12945*, 2024.
- [12] A. Padalkar, A. Pooley, A. Jain, A. Bewley, A. Herzog, A. Irpan, A. Khazatsky, A. Rai, A. Singh, A. Brohan *et al.*, “Open x-embodiment: Robotic learning datasets and rt-x models,” *arXiv preprint arXiv:2310.08864*, 2023.
- [13] S. Nair, A. Rajeswaran, V. Kumar, C. Finn, and A. Gupta, “R3m: A universal visual representation for robot manipulation,” in *Conference on Robot Learning*, 2022.
- [14] Y. J. Ma, S. Sodhani, D. Jayaraman, O. Bastani, V. Kumar, and A. Zhang, “Vip: Towards universal visual reward and representation via value-implicit pre-training,” *arXiv preprint arXiv:2210.00030*, 2022.
- [15] T. Xiao, I. Radosavovic, T. Darrell, and J. Malik, “Masked visual pre-training for motor control,” *arXiv preprint arXiv:2203.06173*, 2022.
- [16] N. S. Pollard, J. K. Hodgins, M. Riley, and C. G. Atkeson, “Adapting human motion for the control of a humanoid robot,” vol. 2, 2002, pp. 1390–1397 vol.2.
- [17] S. Nakaoka, A. Nakazawa, K. Yokoi, H. Hirukawa, and K. Ikeuchi, “Generating whole body motions for a biped humanoid robot from captured human dances,” vol. 3, 2003, pp. 3905–3910 vol.3.
- [18] S. Kim, C. Kim, B.-J. You, and S.-R. Oh, “Stable whole-body motion generation for humanoid robots to imitate human motions,” 2009, pp. 2518–2524.
- [19] W. Suleiman, E. Yoshida, F. Kanehiro, J.-P. Laumond, and A. Monin, “On human motion imitation by humanoid robot,” 2008, pp. 2697–2704.
- [20] J. Koenemann, F. Burget, and M. Bennewitz, “Real-time imitation of human whole-body motions by humanoids,” 2014, pp. 2806–2812.
- [21] X. B. Peng, A. Kanazawa, J. Malik, P. Abbeel, and S. Levine, “Sfv: Reinforcement learning of physical skills from videos,” vol. 37, 2018, p. 178.

- [22] A. Handa, K. V. Wyk, W. Yang, J. Liang, Y.-W. Chao, Q. Wan, S. Birchfield, N. D. Ratliff, and D. Fox, “Dex-pilot: Vision-based teleoperation of dexterous robotic hand-arm system,” 2019, pp. 9164–9170.
- [23] G. Garcia-Hernando, E. Johns, and T.-K. Kim, “Physics-based dexterous manipulations with estimated hand poses and residual reinforcement learning,” 2020, pp. 9561–9568.
- [24] Y. Qin, Y.-H. Wu, S. Liu, H. Jiang, R. Yang, Y. Fu, and X. Wang, “Dexmv: Imitation learning for dexterous manipulation from human videos,” in *European Conference on Computer Vision*, 2021.
- [25] P. Mandikal and K. Grauman, “DexVIP: Learning dexterous grasping with human hand pose priors from video,” in *5th Annual Conference on Robot Learning*, 2021. [Online]. Available: <https://openreview.net/forum?id=kSnfpHJBjOt>
- [26] J. Ye, J. Wang, B. Huang, Y. Qin, and X. Wang, “Learning continuous grasping function with a dexterous hand from human demonstrations,” vol. 8, 2022, pp. 2882–2889.
- [27] K. Shaw, S. Bahl, and D. Pathak, “Videodex: Learning dexterity from internet videos,” in *Conference on Robot Learning*, 2022.
- [28] A. Sivakumar, K. Shaw, and D. Pathak, “Robotic telekinesis: Learning a robotic hand imitator by watching humans on youtube,” 2022.
- [29] S. P. Arunachalam, S. Silwal, B. Evans, and L. Pinto, “Dexterous imitation made easy: A learning-based framework for efficient dexterous manipulation,” 2022.
- [30] Y. Kuang, J. Ye, H. Geng, J. Mao, C. Deng, L. Guibas, H. Wang, and Y. Wang, “Ram: Retrieval-based affordance transfer for generalizable zero-shot robotic manipulation,” *arXiv preprint arXiv:2407.04689*, 2024.
- [31] H. Bharadhwaj, R. Mottaghi, A. Gupta, and S. Tulsiani, “Track2act: Predicting point tracks from internet videos enables diverse zero-shot robot manipulation,” *arXiv preprint arXiv:2405.01527*, 2024.
- [32] Y. Zhu, A. Lim, P. Stone, and Y. Zhu, “Vision-based manipulation from single human video with open-world object graphs,” *arXiv preprint arXiv:2405.20321*, 2024.
- [33] M. Xu, Z. Xu, Y. Xu, C. Chi, G. Wetzstein, M. Veloso, and S. Song, “Flow as the cross-domain manipulation interface,” *arXiv preprint arXiv:2407.15208*, 2024.
- [34] A. Nair, D. Chen, P. Agrawal, P. Isola, P. Abbeel, J. Malik, and S. Levine, “Combining self-supervised learning and imitation for vision-based rope manipulation,” 2017, pp. 2146–2153.
- [35] M. Sieb, X. Zhou, A. Huang, O. Kroemer, and K. Fragkiadaki, “Graph-structured visual imitation,” in *Conference on Robot Learning*, 2019.
- [36] K. Schmeckpeper, A. Xie, O. Rybkin, S. Tian, K. Daniilidis, S. Levine, and C. Finn, “Learning predictive models from observation and interaction,” in *Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XX*. Springer, 2020, pp. 708–725.
- [37] L. Shao, T. Migimatsu, Q. Zhang, K. Yang, and J. Bohg, “Concept2robot: Learning manipulation concepts from instructions and human demonstrations,” vol. 40, 2020, pp. 1419 – 1434.
- [38] A. S. Chen, S. Nair, and C. Finn, “Learning generalizable robotic reward functions from ”in-the-wild” human videos,” vol. abs/2103.16817, 2021.
- [39] H. Xiong, Q. Li, Y.-C. Chen, H. Bharadhwaj, S. Sinha, and A. Garg, “Learning by watching: Physical imitation of manipulation skills from human videos,” 2021, pp. 7827–7834.
- [40] R. Tian, C. Xu, M. Tomizuka, J. Malik, and A. V. Bajcsy, “What matters to you? towards visual representation alignment for robot learning,” vol. abs/2310.07932, 2023.
- [41] Y. Duan, M. Andrychowicz, B. C. Stadie, J. Ho, J. Schneider, I. Sutskever, P. Abbeel, and W. Zaremba, “One-shot imitation learning,” in *Neural Information Processing Systems*, 2017.
- [42] S. Dasari and A. K. Gupta, “Transformers for one-shot visual imitation,” *ArXiv*, vol. abs/2011.05970, 2020.
- [43] Z. Mandi, F. Liu, K. Lee, and P. Abbeel, “Towards more generalizable one-shot visual imitation learning,” *2022 International Conference on Robotics and Automation (ICRA)*, pp. 2434–2444, 2021.
- [44] M. Caron, I. Misra, J. Mairal, P. Goyal, P. Bojanowski, and A. Joulin, “Unsupervised learning of visual features by contrasting cluster assignments,” *Advances in neural information processing systems*, vol. 33, pp. 9912–9924, 2020.
- [45] P. Sermanet, C. Lynch, Y. Chebotar, J. Hsu, E. Jang, S. Schaal, and S. Levine, “Time-contrastive networks: Self-supervised learning from video,” 2017, pp. 1134–1141.
- [46] A. van den Oord, Y. Li, and O. Vinyals, “Representation learning with contrastive predictive coding,” *ArXiv*, vol. abs/1807.03748, 2018.
- [47] G. Peyré and M. Cuturi, “Computational optimal transport,” *Found. Trends Mach. Learn.*, vol. 11, pp. 355–607, 2018.
- [48] D. Dwibedi, Y. Aytar, J. Tompson, P. Sermanet, and A. Zisserman, “Temporal cycle-consistency learning,” *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 1801–1810, 2019.
- [49] A. Gupta, V. Kumar, C. Lynch, S. Levine, and K. Hausman, “Relay policy learning: Solving long-horizon tasks via imitation and reinforcement learning,” *ArXiv*, vol. abs/1910.11956, 2019.