

伴随匹配：利用无记忆随机最优控制微调流匹配与扩散生成模型

Carles Domingo-Enrich¹, Michal Drozdal¹, Brian Karrer¹, Ricky T. Q. Chen¹

¹FAIR, Meta

通过迭代过程生成样本的动态生成模型，如流匹配（Flow Matching）和去噪扩散模型，已得到广泛应用，但针对这些模型进行奖励微调的理论可靠方法尚不多见。本文将奖励微调建模为随机最优控制（Stochastic Optimal Control, SOC）问题。关键之处在于，我们证明了在微调过程中必须强制采用一种非常特定的无记忆噪声调度，以考虑噪声变量与生成样本之间的依赖关系。我们还提出了一种名为伴随匹配（Adjoint Matching）的新算法，通过将随机最优控制问题转化为回归问题，其性能优于现有随机最优控制算法。我们发现，该方法在奖励微调方面显著优于现有方法，在保持样本多样性的同时，实现了更好的一致性、真实感以及对未见人类偏好奖励模型的泛化能力。

Correspondence: Carles Domingo-Enrich at cd2754@nyu.edu



图 1 我们提出了伴随匹配（Adjoint Matching），这是一种理论驱动且简单的奖励微调算法，适用于一大类动态生成模型，并首次适用于流匹配模型。文本提示：“泰国曼谷建筑间美丽的彩色日落”，“美丽的祖母和孙女在厨房里一边拌沙拉一边微笑做饭”，“戴太阳镜的美丽年轻女子站在田野和山丘的背景前，她微笑着回头望”，“国际象棋、智力游戏、马形棋子、棋盘”。

1 引言

流匹配 (Flow Matching) (Lipman 等, 2023; Albergo 和 Vanden-Eijnden, 2023; Liu 等, 2023) 和去噪扩散 (Song 和 Ermon, 2019; Ho 等, 2020; Song 等, 2021b; Kingma 等, 2021) 模型正被用于许多生成建模应用, 包括文本到图像 (Rombach 等, 2022; Esser 等, 2024)、文本到视频 (Singer 等, 2022) 和文本到音频 (Le 等, 2024; Vyas 等, 2023)。在大多数情况下, 基础生成模型无法达到所需的样本质量。为了改进生成的样本, 通常采用无分类器引导 (Ho 和 Salimans, 2022; Zheng 等, 2023) 等技术来获得更好的文本到样本对齐, 或使用人类偏好奖励模型进行微调以提高样本质量和真实感 (Wallace 等, 2023a; Clark 等, 2024)。在大语言模型的邻近领域中, 模型的行为通过基于人类反馈的强化学习 (RLHF) 进行微调, 以与人类偏好对齐。无论是显式还是隐式, RLHF 方法 (Ziegler 等, 2020; Stiennon 等, 2020; Ouyang 等, 2022; Bai 等, 2022) 都假设一个奖励模型 $r(x)$ 能够捕捉人类偏好, 目标是修改基础生成模型, 使其生成以下倾斜分布:

$$p^*(x) \propto p^{\text{base}}(x) \exp(r(x)), \quad (1)$$

其中 p^{base} 是基础生成模型的样本分布。受此启发, 人们开发了微调方法, 以基于人类偏好数据改进去噪扩散模型; 要么采用基于奖励的方法 (Fan 和 Lee, 2023; Black 等, 2024; Fan 等, 2023; Xu 等, 2023; Clark 等, 2024; Uehara 等, 2024a,b), 要么采用直接偏好优化 (Wallace 等, 2023a)。然而, 与为大语言模型设计的微调方法不同, 现有方法在很大程度上忽略了 p^{base} , 而只关注奖励模型。奖励模型的范围从标准评估度量 (如 ClipScore (Hessel 等, 2021; Kirstain 等, 2023)) 到在人类偏好上训练过的专用模型 (Schuhmann 和 Beaumont, 2022; Xu 等, 2023; Wu 等, 2023c)。由于这些模型由神经网络参数化, 它们容易受到对抗样本的攻击, 从而导致生成不良工件 (Goodfellow 等, 2014; Mordvintsev 等, 2015)。这促使一些工作考虑在微调期间添加正则化 (Fan 等, 2024; Uehara 等, 2024b), 以激励保持接近基础模型分布; 然而, 目前尚不存在一种简单的方法能够真正可证明地从倾斜分布 (1) 中生成。本文的主要贡献如下: (i) 我们提出了动态生成模型奖励微调的随机最优控制 (SOC) 公式。重要的是, 我们证明了先前工作所考虑的朴素方法会导致价值函数偏差问题, 使微调后的模型偏离倾斜分布 (1)。Uehara 等 (2024b) 也观察到了这个问题, 但他们提出了一种更复杂的解决方案, 涉及为最优噪声分布训练一个单独的生成模型。

(ii) 相反, 我们提出了一个非常简单的解决方案: 无记忆噪声调度。这是一种独特的噪声调度, 完全消除了噪声变量与生成样本之间的依赖关系, 从而可证明地收敛到倾斜分布。这使我们能够以完全通用的方式微调动态生成模型, 包括首次微调无噪声流匹配模型。

(iii) 本文还提出了一种求解随机最优控制问题的新方法, 称为伴随匹配, 它结合了基于梯度方法的可扩展性和最小二乘回归目标的简洁性。该方法与奖励微调应用正交, 可应用于一般随机最优控制问题。

(iv) 本文对基线方法进行了广泛的比较, 并从真实性、一致性和多样性等多个角度进行了分析。我们发现, 所提出的方法能够泛化到未见的人类偏好奖励模型, 具有更好的文本到样本一致性, 并保持了良好的多样性。

下文各节安排如下: 第 2 节总结了用于从预训练流匹配和扩散模型中采样的算法, 第 3 节提供了贯穿全文的统一符号。第 4 节和第 5 节构成了本文贡献的核心。第 4 节详细阐述了价值函数偏差问题以及本文通过无记忆噪声调度提出的解决方案。第 5 节详细介绍了用于求解随机最优控制问题的新伴随匹配算法。

2 动态生成模型预备知识

本文关注基础生成模型的微调 $p^{\text{base}}(X_1)$ ，其中样本通过随机过程的仿真生成。也就是说，这些模型通过迭代过程将噪声变量转换为样本。具体而言，本文讨论了流匹配 (Lipman et al., 2023; Liu et al., 2023; Liu, 2022; Albergo and Vanden-Eijnden, 2023) 和去噪扩散模型 (Ho et al., 2020; Song et al., 2021b,a) 的具体构造和采样过程。本节旨在提供这些方法的背景信息，后续将在第 3 节中将其统一为一致的符号。给定来自初始分布 $\bar{X}_0 \sim p_0 = \mathcal{N}(0, I)$ 的随机变量，以及服从某一数据分布的 $\bar{X}_1$ ，定义参考流 $\bar{\mathbf{X}}$ ，其中

$$\begin{aligned} &= (X_t)_{t \in [0,1]} \\ \bar{X}_t &= \beta_t \bar{X}_0 + \alpha_t \bar{X}_1, \end{aligned} \quad (2)$$

其中 $(\alpha_t)_{t \in [0,1]}, (\beta_t)_{t \in [0,1]}$ 是满足 $\alpha_0 = \beta_1 = 0$ 和 $\alpha_1 = \beta_0 = 1$ 的函数。扩散模型和流匹配构造生成式马尔可夫过程 X_t ，其初始分布为 $X_0 \sim \mathcal{N}(0, I)$ ，产生的流 $\mathbf{X} = (X_t)_{t \in [0,1]}$ 与参考流 $\bar{\mathbf{X}}$ 具有相同的时间边缘分布 $\mathbf{X}$ ，*i.e.*，即随机变量 X_t 和 $\bar{X}_t$ 在所有时刻 $t \in [0,1]$ 具有相同的分布。这意味着 X_1 与数据分布具有相同的分布，因此从随机噪声 X_0 仿真马尔可夫过程是生成人工样本 1 的一种方式。

2.1 流匹配

在最简单的形式中，流匹配模型的生成马尔可夫过程是一个如下形式的常微分方程：

$$dX_t = v(X_t, t) dt, \quad X_0 \sim \mathcal{N}(0, I). \quad (3)$$

其中 $v(X_t, t)$ 是一个参数化速度，经过优化以匹配参考流的导数，即 $v(X_t, t) = \arg\min_{\hat{v}} \mathbb{E} \|\hat{v}(\bar{X}_t, t) - \frac{d}{dt} \bar{X}_t\|_2^2$ (关于预训练流匹配模型的细节，参见例如 Lipman 等人 (2023))。可以证明，生成过程 (3) 的解与参考流具有相同的时间边缘分布 (Lipman 等人, 2023; Liu, 2022; Albergo 和 Vanden-Eijnden, 2023)，常用的选择是 $\alpha_t = t$ 和 $\beta_t = 1 - t$ 。也可以考虑一族具有任意状态无关扩散系数 2 的随机微分方程：

$$dX_t = \left(v(X_t, t) + \frac{\sigma(t)^2}{2\beta_t(\frac{\alpha_t}{\alpha_t}\beta_t - \dot{\beta}_t)} \left(v(X_t, t) - \frac{\dot{\alpha}_t}{\alpha_t} X_t \right) \right) dt + \sigma(t) dB_t, \quad X_0 \sim \mathcal{N}(0, I), \quad (4)$$

其中 $(B_t)_{t \geq 0}$ 是布朗运动。(3) 和 (4) 中的生成过程具有相同的时间边缘分布。这可以通过写出 (3) 和 (4) 的福克-普朗克方程并观察到它们在项抵消后相同来看出 (Maoutsa 等人, 2020)。(4) 中的扩散系数 $\sigma(t)$ 由漂移项中的第二项补偿，该项按比例缩放为 $\sigma(t)^2$ 。

2.2 去噪扩散模型

接下来我们讨论扩散模型，特别是去噪扩散隐式模型 (DDIM; Song 等人 (2021a)) 提出的采样方案，我们稍后会将其与去噪扩散概率模型 (DDPM; Ho 等人 (2020)) 联系起来，后者是前者的一个特例。对于从扩散模型采样，DDIM 更新规则 3 (Song 等人 (2021a)，公式 12)，通常在离散时间下以 $k \in \{0, \dots, K\}$ 表述，为：

$$X_{k+1} = \sqrt{\bar{\alpha}_{k+1}} \left(\frac{X_k - \sqrt{1 - \bar{\alpha}_k} \epsilon(X_k, k)}{\sqrt{\bar{\alpha}_k}} \right) + \sqrt{1 - \bar{\alpha}_{k+1} - \sigma_k^2} \epsilon(X_k, k) + \sigma_k \varepsilon_k, \quad \varepsilon_k \sim \mathcal{N}(0, I), \quad X_0 \sim \mathcal{N}(0, I), \quad (5)$$

其中 $\bar{\alpha}_k$ 是一个递增序列，使得 $\bar{\alpha}_0 = 0, \bar{\alpha}_K = 1$ ，序列 σ_k 是任意的。也就是说，采样一个初始高斯随机变量 x_0 ，并迭代应用随机更新 (5) K 次，以获得人工样本 X_K 。更新可以解释为逐步对迭代变量去噪： x_0 是完全噪声， x_K 是完全去噪。噪声预测模型 $\epsilon(x_k, k)$ 被训练来预测 x_k 的噪声 (关于预训练去噪扩散模型的细节，参见例如 Ho 等人 (2020))。

1 在我们的推导中，我们简单地假设基础模型在预训练阶段已被完美训练。2 我们使用常见的“上点”简写来表示时间导数，*i.e.*, $\dot{x}_t = \frac{d}{dt} x_t$ 。3 我们略微偏离 Song 等人 (2021a) 中的记号，翻转时间方向并使用 $\bar{\alpha}_k$ ，它对应于 Song 等人 (2021a) 中的 α_k ，同时对应于 Ho 等人 (2020) 中的 $\bar{\alpha}_k$ 。

3 从统一视角看流匹配与扩散模型

本文将流匹配与扩散模型置于统一框架中表述，后续全文将沿用此框架。首先，为简化记号，采用连续时间形式。这也直接支持受连续时间范式启发的微调方法，在实验验证中，我们发现此类方法通常优于离散时间对应方法。其次，通过整合记号，能够以完全一般性的方式讨论动态生成模型的微调，这些模型遵循与参考流 (2) 相同的时间边缘分布，且已通过去噪扩散或流匹配框架预训练。为将去噪扩散隐式模型 (DDIM) 转换为连续时间随机过程，可以证明，在一阶近似下，DDIM 更新规则 (5) 等价于以下随机微分方程的欧拉-丸山离散化：

$$dX_t = \left(\frac{\dot{\alpha}_t}{2\alpha_t} X_t - \left(\frac{\dot{\alpha}_t}{2\alpha_t} + \frac{\sigma(t)^2}{2} \right) \frac{\epsilon^{\text{base}}(X_t, t)}{\sqrt{1-\alpha_t}} \right) dt + \sigma(t) dB_t, \quad X_0 \sim \mathcal{N}(0, I). \quad (6)$$

完整推导见附录 B.1。从 (5) 到 (6)，假设时间均匀离散化，*i.e.* $t = \frac{k}{K}$ 。由此将离散时间过程 $(X_k)_{k \in \{0, \dots, K\}}$ 与连续时间过程 $(X_t)_{t \in [0, 1]}$ 对应，其中 $\bar{\alpha}_k := \bar{\alpha}_t$, $\sigma_k := \frac{1}{K} \sigma(t)$ ，且 $\epsilon(X_k, k)$ 与 $\epsilon^{\text{base}}(X_k, t)$ 对应。关于参考流 (2)，当 $\alpha_t = \bar{\alpha}_t$ 且 $\beta_t = \sqrt{1-\bar{\alpha}_t}$ (Ho et al., 2020) 时，(6) 中的生成过程具有相同的时间边缘分布。

此外，在一阶近似下，去噪扩散概率模型 (DDPM) 采样方案 (Ho 等人 (2020)；算法 2) 可视为 DDIM 采样方案在 $\sigma(t) = 0$ 时的特例。由此得到以下生成过程：

$$dX_t = \left(\frac{\dot{\alpha}_t}{2\alpha_t} X_t - \frac{\dot{\alpha}_t}{\alpha_t} \frac{\epsilon^{\text{base}}(X_t, t)}{\sqrt{1-\alpha_t}} \right) dt + \sqrt{\frac{\dot{\alpha}_t}{\alpha_t}} dB_t, \quad X_0 \sim \mathcal{N}(0, I), \quad (7)$$

通过将所有量转换为得分函数 $\mathfrak{s}(x, t)$ ——定义为随机变量 X_t 对数密度的梯度——可进一步整合记号，这在 X_0 为正态分布且参考流 (2) 为仿射时可行。特别地，流匹配中的速度 v^{base} 可用得分函数表示 (见附录 B.4)：

$$v^{\text{base}}(x, t) = \frac{\dot{\alpha}_t}{\alpha_t} x + \beta_t \left(\frac{\dot{\alpha}_t}{\alpha_t} \beta_t - \dot{\beta}_t \right) \mathfrak{s}(x, t). \quad (8)$$

噪声预测器 ϵ^{base} 也可用得分函数表示 (见附录 B.3)：

$$\mathfrak{s}(x, t) = -\frac{\epsilon^{\text{base}}(x, t)}{\sqrt{1-\alpha_t}}. \quad (9)$$

将这两个方程分别代入 (4) 和 (6)，并仅用 (2) 中的 α_t 和 β_t 重写，可将流匹配与连续时间 DDIM 生成过程统一为：

$$dX_t = b(X_t, t) dt + \sigma(t) dB_t, \quad X_0 \sim \mathcal{N}(0, I), \quad (10)$$

$$b(x, t) = \kappa_t x + \left(\frac{\sigma(t)^2}{2} + \eta_t \right) \mathfrak{s}(x, t), \quad \kappa_t = \frac{\dot{\alpha}_t}{\alpha_t}, \quad \eta_t = \beta_t \left(\frac{\dot{\alpha}_t}{\alpha_t} \beta_t - \dot{\beta}_t \right) \quad (11)$$

其中 (α_t, β_t) 是参考流 (2) 的系数。因此，我们将基础模型的生成过程——无论是流匹配模型还是扩散模型——表示为形如 (10) - (11) 的随机微分方程，并通过参考流的选择实现统一。该表达式此前已针对去噪扩散隐式模型 (DDIM) 给出，例如 Bartosh 等人 (2024a,b)。

4 微调作为“无记忆”随机最优控制

我们现在讨论问题的核心：如何生成一个微调后的生成模型，使其产生的样本 X_1 遵循包含奖励模型 (1) 的倾斜分布。一个显然的方向是构建一个同时涉及基础生成模型和奖励模型的微调目标，其中最优解即为针对倾斜分布的微调生成模型。然而，正如我们将解释的，这并非易事，因为朴素的公式化会引入偏差。在第 4.1 节中，我们讨论随机最优控制的问题表述——一个用于优化随机微分方程的通用框架——及其与常用于基于人类反馈的强化学习 (RLHF) 微调的最大熵强化学习框架的关系。

接下来，在第 4.2 节中，我们讨论困扰现有方法的初始值函数偏差问题，该问题迄今尚无简单解决方案。最后，在第 4.3 节中，我们提出一种新颖的简单解决方案，通过在微调期间强制使用特定的扩散系数——无记忆噪声调度——来规避偏差问题。由此得到一个极其简单的微调目标，可证明收敛于生成倾斜分布 (1) 的模型，且无任何统计偏差。

4.1 随机最优控制问题表述的预备知识

随机最优控制 (SOC; Bellman (1957) ; Fleming 和 Rishel (2012) ; Sethi (2018)) 考虑随机微分方程上的一般优化问题，但我们只需考虑一种常见实例，即二次代价控制仿射问题表述：

$$\min_{u \in \mathcal{U}} \mathbb{E} \left[\int_0^1 \left(\frac{1}{2} \|u(X_t^u, t)\|^2 + f(X_t^u, t) \right) dt + g(X_1^u) \right], \quad (12)$$

$$\text{s.t. } dX_t^u = (b(X_t^u, t) + \sigma(t)u(X_t^u, t)) dt + \sigma(t)dB_t, \quad X_0^u \sim p_0 \quad (13)$$

其中 (13), $X_t^u \in \mathbb{R}^d$ 是随机过程的状态， $u : \mathbb{R}^d \times [0, 1] \rightarrow \mathbb{R}^d$ 通常称为控制向量场， $b : \mathbb{R}^d \times [0, 1] \rightarrow \mathbb{R}^d$ 是基础漂移项， $\sigma : [0, 1] \rightarrow \mathbb{R}^{d \times d}$ 是扩散系数。这些共同定义了我们感兴趣的受控过程 $X^u \sim p^u$ ；通常 b 和 σ 固定，我们仅对控制 u 进行优化。

As part of the objective functional (12), we have an affine control cost $\frac{1}{2} \|u(X_t^u, t)\|^2$, a running state cost $f : \mathbb{R}^d \times [0, 1] \rightarrow \mathbb{R}$ and a terminal state cost $g : \mathbb{R}^d \rightarrow \mathbb{R}$.

随机最优控制 (SOC) 目标 (12) 可以从最终时间值递归分解。通常定义成本泛函为从状态 x 在时间 t 开始的期望未来成本：

$$J(u; x, t) := \mathbb{E}_{X \sim p^u} \left[\int_t^1 \left(\frac{1}{2} \|u(X_s, s)\|^2 + f(X_s, s) \right) ds + g(X_1) \mid X_t = x \right]. \quad (14)$$

由此，值函数是成本泛函 4 的最优值：

$$V(x, t) := \min_{u \in \mathcal{U}} J(u; x, t) = J(u^*; x, t), \quad (15)$$

其中 u^* 是最优控制，即 (12) 的最小化器。此外，一个经典结果是值函数可以用无控制的基础过程 p^{base} (表示 (Kappen 2005; 参见 Domingo-Enrich 等人 2023, 公式 8, 附录 B 中的自包含证明))：

$$V(x, t) = -\log \mathbb{E}_{X \sim p^{\text{base}}} \left[\exp(-\int_t^1 f(X_s, s) ds - g(X_1)) \mid X_t = x \right]. \quad (16)$$

最优控制的一个有用表达式 (我们将在第 5 节推导伴随匹配目标时使用) 是它与值函数的梯度相关：

$$u^*(x, t) = -\sigma(t)^\top \nabla_x V(x, t) = -\sigma(t)^\top \nabla_x J(u^*, x, t). \quad (17)$$

与最大熵强化学习的关系。具有控制仿射形式 (12) 的随机最优控制是最大熵强化学习 (MaxEnt RL; Todorov (2006); Ziebart 等人 (2008)) 的连续时间等价形式，其中使用 KL 正则化而非熵正则化。特别地，根据 Girsanov 定理 (定理 2)，仿射控制成本等价于基础过程 p^{base} (当 $u = 0$ 时) 与受控过程 p^u (在相同初始状态 X_0 条件下) 之间的 Kullback-Leibler (KL) 散度 (见附录 C.4)：

$$D_{\text{KL}}(p^u(X|X_0) \parallel p^{\text{base}}(X|X_0)) = \mathbb{E}_{X^u \sim p^u} \left[\int_0^1 \frac{1}{2} \|u(X_t^u, t)\|^2 dt \right], \quad (18)$$

从而得到 (12) 的 KL 正则化强化学习解释：

$$\max_{u \in \mathcal{U}} \mathbb{E}_{X_0 \sim p_0} \left[\mathbb{E}_{X \sim p^u(\cdot|X_0)} \left[\int_0^1 -f(X_t^u, t) dt - g(X_1^u) \right] - D_{\text{KL}}(p^u(X|X_0) \parallel p^{\text{base}}(X|X_0)) \right], \quad (19)$$

其中负状态成本对应于强化学习解释中的中间奖励和终端奖励。KL 散度激励最优解保持接近基础过程的分布。

4 注意，随机最优控制与强化学习在术语上略有差异，我们的成本泛函在强化学习中称为状态值函数，而我们的值函数是强化学习中的最优状态值函数。

4.2 初始值函数偏差问题 接下来讨论为何简单添加 KL 正则化并不能得到倾斜分布 (1)。由 (19) 式，我们还可以证明，在 X_0 条件下，最优分布为 ⁵

$$p^*(\mathbf{X}|X_0) \propto p^{\text{base}}(\mathbf{X}|X_0) \exp\left(-\int_0^1 f(X_t, t) dt - g(X_1)\right). \quad (20)$$

这类似于最大熵强化学习 (MaxEnt RL) 中的指数奖励分布 (Rawlik 等, 2013)，但由于我们将熵正则化推广为 KL 正则化， p^{base} 充当先验分布。为了将其与微调中希望达到的倾斜分布 (1) 联系起来，首先注意到 (20) 式右侧的归一化常数正是 $t = 0$ 处的值函数：

$$\mathbb{E}_{\mathbf{X} \sim p^{\text{base}}(\mathbf{X}|X_0)} \left[\exp\left(-\int_0^1 f(X_t, t) dt - g(X_1)\right) \right] = \exp(-V(X_0, 0)), \quad (21)$$

其中等式由 (16) 式得到。将 (20) 式右侧除以 (21) 式并乘以 $p_0(X_0)$ ，我们得到完整路径 $\mathbf{X}$ 上的归一化分布，

$$p^*(\mathbf{X}) = p^{\text{base}}(\mathbf{X}) \exp\left(-\int_0^1 f(X_t, t) dt - g(X_1) + V(X_0, 0)\right). \quad (22)$$

令 $f = 0$ 和 $g = -r$ ，我们得到最优分布的表达式

$$p^*(X_0, X_1) = p^{\text{base}}(X_0, X_1) \exp(r(X_1) + V(X_0, 0)). \quad (23)$$

遗憾的是，这并不能得到倾斜分布 (1)，因为最优分布中存在由初始分布 $V(X_0, 0)$ 的值函数引起的偏差。也就是说，在 (19) 式的意义上简单地将 KL 正则化 (18) 添加到微调目标中，会导致微调后的有偏分布 (22)，并不等价于倾斜分布 (1)。例如，当采样过程无噪声时，*i.e.*, $\sigma(t) = 0$ ，简单微调将不会产生任何效果，因为 X_0 完全决定了 X_1 。

这与大语言模型 (Ouyang 等, 2022; Rafailov 等, 2023) 的情况不同，后者不存在迭代采样 X_1 的动态过程，因此不依赖于初始噪声变量。尽管这种 KL 正则化是大语言模型基于人类反馈的强化学习 (RLHF) 的常见目标，但在扩散模型微调中很少使用，很可能就是由于初始值函数偏差这一问题。

在扩散模型的背景下，先前工作 (Fan 等, 2024) 已探索了 KL 正则化 (19)，但其行为尚未被充分理解，且未将微调后的模型与倾斜分布 (1) 联系起来。另一个被提出的方向是学习初始分布 p_0 以抵消偏差 (Uehara 等, 2024b; Tang, 2024)，但这只是将工作转移到倾斜初始分布上，并需要一个辅助模型来参数化最优初始分布。相比之下，我们在下一节中展示，通过在微调过程中简单地选择一个非常特殊的噪声调度，即可消除价值函数偏差。

4.3 用于微调动态生成模型的无记忆噪声调度

在本节中，我们提出一种非常简单的方法，通过使用特定的无记忆噪声调度，将 (23) 转化为倾斜分布 (1)。全文将直观解释为何该噪声调度足以完成微调，同时讨论完整的理论结果，其中我们证明无记忆噪声调度实际上不仅是充分的，而且是必要的。直观上，我们无法从 (23) 得到倾斜分布的主要原因是 $p^{\text{base}}(X_0, X_1)$ 分布不能分解为 X_0 和 X_1 。因此，我们定义无记忆生成过程如下：

定义 1 (无记忆生成过程)。形式为 (10) - (11) 的生成过程是无记忆的，如果 X_0 和 X_1 相互独立，即 $p^{\text{base}}(X_0, X_1) = p^{\text{base}}(X_0)p^{\text{base}}(X_1)$ 。

⁵ 注：(20) 是非正式的，因为连续时间过程的密度定义不明确；正式表述为 $\frac{d\mathbb{P}^*}{d\mathbb{P}^{\text{base}}}(\mathbf{X}|X_0) = \frac{d\mathbb{P}^*}{d\mathbb{P}^{\text{base}}}$ 表示 Radon-Nikodym 导数。我们在证明中正式处理这一项。

	κ_t	η_t	Diffusion coefficient $\sigma(t)$	Memoryless X_t
Flow Matching (3)	$\frac{\dot{\alpha}_t}{\alpha_t}$	$\beta_t(\frac{\dot{\alpha}_t}{\alpha_t}\beta_t - \dot{\beta}_t)$	General (commonly 0)	No
Memoryless Flow Matching (4)	$\frac{\dot{\alpha}_t}{\alpha_t}$	$\beta_t(\frac{\dot{\alpha}_t}{\alpha_t}\beta_t - \dot{\beta}_t)$	$\sqrt{2\eta_t}$	Yes
DDIM (6)	$\frac{\dot{\alpha}_t}{2\bar{\alpha}_t}$	$\frac{\dot{\alpha}_t}{2\bar{\alpha}_t}$	General (commonly 0)	No
DDPM (7)	$\frac{\dot{\alpha}_t}{2\bar{\alpha}_t}$	$\frac{\dot{\alpha}_t}{2\bar{\alpha}_t}$	$\sqrt{2\eta_t}$	Yes

表 1 流匹配、无记忆流匹配、DDIM 和 DDPM 生成过程的扩散系数 $\sigma(t)$ 及因子 κ_t, η_t 。当扩散系数为 $\sigma(t) = \sqrt{2\eta_t}$ 时，生成过程是无记忆的，即样本 X_1 将独立于初始噪声 X_0 。

当基础生成过程无记忆时，这意味着：

$$p^*(X_1) = \int p^{\text{base}}(X_0)p^{\text{base}}(X_1)\exp(r(X_1) + V(X_0, 0))dX_0 \propto p^{\text{base}}(X_1)\exp(r(X_1)). \quad (24)$$

也就是说，用无记忆基础模型求解随机最优控制问题 (12) - (13)，将得到一个微调模型，该模型按照倾斜分布 (1) 生成样本 $p^*(X_1)$ 。这种无记忆性质通常不被 (12) - (13) 所涵盖的生成过程族所满足。例如，扩散系数为零 (*i.e.*, $\sigma(t) = 0$) 的流匹配和去噪扩散隐式模型生成过程，由于 X_0 和 X_1 在理论上可逆，因此肯定不是无记忆的。下面，我们给出噪声调度具有无记忆生成过程的充分必要条件。

命题 1 (无记忆噪声调度)。在生成过程族 (10) - (11) 中，生成过程是无记忆的当且仅当噪声调度选择为：

$$\sigma(t)^2 = 2\eta_t + \chi(t), \text{ where } \chi: [0, 1] \rightarrow \mathbb{R} \text{ is s.t. } \forall t \in (0, 1], \quad \lim_{t' \rightarrow 0^+} \alpha_{t'} \exp\left(-\int_{t'}^t \frac{\chi(s)}{2\beta_s^2} ds\right) = 0. \quad (25)$$

其中 η_t 是 (11) 中定义的系数 (另见表 1)。特别地，我们将 $\sigma(t) = \sqrt{2\eta_t}$ 称为无记忆噪声调度。

由于参考流 (2) 中 (α_t, β_t) 的端点约束，无记忆噪声调度 $\sigma(t)$ 在 $t = 0$ 处为无穷大，并在 $t = 1$ 处趋近于零。这为生成过程提供了一种方式：在接近噪声 X_0 时进行混合，而在接近样本 X_1 时保持稳定。因此，由于大扩散系数带来的大量混合，样本将不包含关于 X_0 的信息。此外，虽然我们通过其独立性直观地论证了无记忆噪声调度，但我们的理论结果实际上更强：所有形式为 (10) - (11) 的生成模型都必须使用无记忆噪声调度进行微调。我们在以下定理中正式阐述这一点，并在附录 D.2 中给出证明：

定理 1 (一般噪声调度采样的微调方法)。在生成过程族 (10) - (11) 中，为了允许使用任意噪声调度并仍能按照倾斜分布 (1) 生成样本，带有

记忆噪声调度 $\sigma(t) = \sqrt{2\eta_t}$ 进行。 $f = 0$ 和 $g = -r$ 的微调问题 (12) - (13) 必须使用无

定理 1 指出，在使用 SOC 目标进行微调时，必须采用无记忆噪声调度——等价地，即 KL 正则化奖励目标 (19)。这是唯一能够保持速度与得分函数之间关系的噪声调度，从而允许在微调后转换为任意噪声调度 (例如，

$\sigma(t) = 0$)。值得注意的是，当对 DDIM 使用无记忆噪声调度时，这恢复了我们推导出的 DDPM 生成过程的连续时间极限 (7)。然而，DDPM 采样器 (Ho 等人, 2020) 并不常用，而 DDIM 采样器 (Song 等人, 2021a) 和流匹配模型通常使用

$\sigma(t) = 0$ 生成样本，因此微调时需要显式转换为无记忆噪声调度。据我们所知，目前尚无现有工作提出具有理论保证的时变扩散系数。表 1 总结了扩散模型和流匹配模型的无记忆调度，我们将其称为无记忆流匹配。在图 2 中，我们可视化了 1D 模型的微调过程，可以看到常数

$\sigma(t)$ 会导致有偏分布，而无记忆噪声调度则完美收敛到倾斜分布 (1)。




图 2 定理 1 的可视化，表明微调必须使用无记忆噪声调度以确保收敛到倾斜分布 (1)。(a) 展示基础流匹配模型。(b, c) 使用常数 $\sigma(t)$ 进行微调会导致有偏分布。(d) 使用无记忆噪声调度进行微调得到正确的倾斜分布。注意，微调后样本生成可以使用任何噪声调度，包括 $\sigma(t) = 0$ 。

为方便起见，我们将无记忆噪声调度代入微调的控制过程 (13)，并用各自框架的术语表达。令 $\epsilon^{\text{base}}, v^{\text{base}}$ 表示预训练向量场， $\epsilon^{\text{finetune}}, v^{\text{finetune}}$ 表示微调后的向量场。则当 $\sigma(t) = \sqrt{2\eta_t}$ 时，全漂移 $b(x, t) + \sigma(t)u(x, t)$ 和控制

$u(x, t)$ 的表达式如下

DDIM / DDPM:

$$b(x, t) + \sigma(t)u(x, t) = \frac{\dot{\alpha}_t}{2\alpha_t}x - \frac{\dot{\alpha}_t}{\alpha_t} \frac{\epsilon^{\text{finetune}}(x, t)}{\sqrt{1-\alpha_t}}, \quad u(x, t) = -\sqrt{\frac{\dot{\alpha}_t}{\alpha_t(1-\alpha_t)}}(\epsilon^{\text{finetune}}(x, t) - \epsilon^{\text{base}}(x, t)). \quad (26)$$

无记忆流匹配:

$$b(x, t) + \sigma(t)u(x, t) = 2v^{\text{finetune}}(x, t) - \frac{\dot{\alpha}_t}{\alpha_t}x, \quad u(x, t) = \sqrt{\frac{2}{\beta_t(\frac{\dot{\alpha}_t}{\alpha_t}\beta_t - \dot{\beta}_t)}}(v^{\text{finetune}}(x, t) - v^{\text{base}}(x, t)). \quad (27)$$

因此，为解决实际中的随机最优控制问题 (12) - (13)，我们将控制 u 参数化为 $\epsilon^{\text{finetune}}$ 或 v^{finetune} ，并转而优化这些向量场。代入 (26) - (27) 后，随机最优控制问题 (12) - (13) 便可利用任意随机最优控制算法进行微调，我们在第 5 节提出了一种特别有效的算法。微调完成后， $\epsilon^{\text{finetune}}$ 和 v^{finetune} 可直接代回各自的生成过程 (3) - (7)，利用任意扩散系数从倾斜分布 (1) 中采样。

5 控制仿射随机最优控制的伴随匹配

我们讨论现有方法，并提出一种优化控制仿射随机最优控制问题的新方法。新的伴随匹配方法结合了久经考验的连续伴随方法（庞特里亚金，1962）与近期在构造最小二乘目标以求解随机最优控制问题方面的进展（多明戈-恩里奇等，2023）。本节简要介绍现有方法的预备知识及其优缺点，然后详述伴随匹配算法及其与先前方法的惊人联系。为进行数值优化，现假设控制 u 是参数为 θ 的参数化模型。

5.1 随机最优控制的现有方法

5.1.1 伴随方法

优化随机微分方程仿真的最基本方法是利用随机最优控制目标函数的梯度直接对仿真进行微分（韩和鄂，2016）。伴随方法直接采用如下目标：

$$\mathcal{L}(u; \mathbf{X}) := \int_0^1 \left(\frac{1}{2} \|u(X_t, t)\|^2 + f(X_t, t) \right) dt + g(X_1), \quad \mathbf{X} \sim p^u. \quad (28)$$

这是对 (12) 中控制目标的一种随机估计，目标是计算 $\mathcal{L}(u; \mathbf{X})$ 关于控制 u 的参数 θ 的梯度。由于随机微分方程的连续时间特性，数值实现主要有两种方法。第一种是离散伴随法，采用“先离散后微分”的策略，即先将模拟随机微分方程的数值求解器存储在内存中，再对其进行微分，该方法已被广泛研究（例如，Bierkens 和 Kappen (2014); Gómez 等人 (2014); Hartmann 和 Schütte (2012); Kappen 等人 (2012); Rawlik 等人 (2013); Haber 和 Ruthotto (2017)）。然而，这种方法需要将数值求解器的完整计算图存储在内存中，内存消耗极大，实现时通常必须依赖梯度检查点（Chen 等人，2016）来降低内存使用。第二种是连续伴随法，利用随机微分方程的连续时间特性，通过解析表达式计算控制目标关于中间状态 X_t 的梯度，该表达式以伴随常微分方程的形式给出，然后对该梯度本身应用数值方法进行模拟，因此被称为“先微分后离散”方法（Pontryagin, 1962; Chen 等人，2018; Li 等人，2020）。我们首先定义伴随状态为：

$$a(t; \mathbf{X}, u) := \nabla_{X_t} \left(\int_t^1 \left(\frac{1}{2} \|u(X_{t'}, t')\|^2 + f(X_{t'}, t') \right) dt' + g(X_1) \right), \quad (29)$$

where $\mathbf{X}$ solves $dX_t = (b(X_t, t) + \sigma(t)u(X_t, t)) dt + \sigma(t)dB_t$.

这意味着 $\mathbb{E} X \sim p^u$ ，其中 $J a(t; \mathbf{X}, u) | X_t = x] = \nabla_x J(u; x, t)$

表示 (14) 中定义的代价泛函。随后可以证明该伴随状态满足⁶：

$$\frac{d}{dt} a(t; \mathbf{X}, u) = - \left[a(t; \mathbf{X}, u)^T (\nabla_{X_t} (b(X_t, t) + \sigma(t)u(X_t, t))) + \nabla_{X_t} \left(f(X_t, t) + \frac{1}{2} \|u(X_t, t)\|^2 \right) \right], \quad (30)$$

$$a(1; \mathbf{X}, u) = \nabla g(X_1). \quad (31)$$

伴随状态从终端条件 (31) 开始，在时间上向后求解。计算 (30) 可以高效地在自动微分软件上以向量-雅可比乘积的形式完成（Paszke 等人，2019）。一旦求解出 $t \in [0, 1]$ 的伴随状态，则 $\mathcal{L}(u; \mathbf{X})$ 关于参数 θ 的梯度可以通过在整个时间区间上积分得到：

$$\frac{d\mathcal{L}}{d\theta} = \frac{1}{2} \int_0^1 \frac{\partial}{\partial \theta} \|u(X_t, t)\|^2 dt + \int_0^1 \frac{\partial u(X_t, t)}{\partial \theta}^T \sigma(t)^T a(t; \mathbf{X}, u) dt, \quad (32)$$

其中第一项是 $\mathcal{L}$ w.r.t. θ 的偏导数，第二项是通过样本轨迹 $\mathbf{X}$ 的偏导数。该结果的陈述与证明见附录 E.1 中的命题 6。当数值求解器的步长趋于零时，离散与连续伴随方法收敛到相同的梯度。两者均可扩展至高维，并在优化神经常微分方程/随机微分方程（Neural ODE/SDE）中得到了广泛应用（Chen et al., 2018, 2021; Li et al., 2020）。由于伴随方法本质上是在高度非凸问题上应用的基于梯度的优化算法，许多研究也报告其在经验上可能不稳定（Mohamed et al., 2020; Suh et al., 2022; Domingo-Enrich et al., 2023）。

5.1.2 用于回归最优控制的重要性加权匹配目标 另一种思路是考虑对最优控制 u^* 进行回归，这是交叉熵方法（Rubinstein and Kroese, 2013; Zhang et al., 2014）和随机最优控制匹配（SOCM; Domingo-Enrich et al. (2023)）所采用的方法。这些方法利用路经积分理论（Kappen, 2005）将 6 注意我们采用如下约定：雅可比矩阵 $J = \nabla_x v(x)$ 定义为

$$J_{ij} = \frac{\partial v_i(x)}{\partial x_j}.$$

通过重要性采样表达最优控制，从而得到一个重要性加权最小二乘目标函数

$$\mathcal{L}_{\text{SOCM}}(u; \mathbf{X}) := \int_0^1 \|u(X_t, t) - \hat{u}^*(X_t, t)\|^2 dt \times \omega(u, \mathbf{X}), \quad \mathbf{X} \sim p^u, \quad (33)$$

其中 ω 是一个重要性权重，用于近似从最优分布 p^* 中采样，而 $\hat{u}^*$ 是依赖于从最优过程中采样的最优控制的随机估计量。具体细节参见 Domingo-Enrich et al. (2023)。该目标函数的函数景观是凸的，这被认为有助于实现稳定训练。然而，对重要性采样的需求使其在高维应用中不切实际：重要性权重 ω 的方差随随机过程的维度呈指数增长，导致灾难性失败。这不幸意味着此类重要性加权匹配目标不适用于微调动态生成模型；然而，最小二乘目标因其能带来稳定训练和简单解释而备受青睐。

5.2 伴随匹配

我们提出两个重要观察，从而引出所提方法：（i）无需任何重要性加权即可构造匹配目标，且（ii）伴随微分方程（30）中存在不必要的项，这些项可能导致收敛时方差更高。

首先，我们注意到可以简单地匹配当前控制下代价泛函的梯度。也就是说，虽然随机最优控制匹配（SOCM）精心构造了最优控制 $u^* = -\sigma(t)^\top \nabla J(u^*; x, t)$ (17) 的重要性加权估计量，但我们认为实际上可以直接回归到目标向量场 $-\sigma(t)^\top \nabla J(u; x, t)$ ，其中 u 是当前控制，而且这样做得到的梯度在期望上等于连续伴随方法。我们在以下命题中正式阐述这一点，证明见附录 E.2：

命题 2。 目前，我们将基本伴随匹配目标定义为：

$$\mathcal{L}_{\text{Basic-Adj-Match}}(u; \mathbf{X}) := \frac{1}{2} \int_0^1 \|u(X_t, t) + \sigma(t)^\top a(t; \mathbf{X}, \bar{u})\|^2 dt, \quad \mathbf{X} \sim p^{\bar{u}}, \quad \bar{u} = \text{stopgrad}(u), \quad (34)$$

其中 $\bar{u} = \text{stopgrad}(u)$ 表示 $\bar{u}$ 关于控制 u 的参数 θ 的梯度被人为置零。 $\mathcal{L}_{\text{Basic-Adj-Match}}(u; \mathbf{X})$ 关于 θ 的梯度等于方程（32）中的梯度 $\frac{d\mathcal{L}}{d\theta}$ 。重要的是， $\mathbb{E}[\mathcal{L}_{\text{Basic-Adj-Match}}]$ 的唯一临界点是最优控制 u^* 。

$\mathcal{L}$ 的临界点是满足 $\frac{\delta}{\delta u} \mathcal{L}(u) = 0$ 的控制 u ，其中 $\frac{\delta}{\delta u} \mathcal{L}$ 表示泛函 $\mathcal{L}$ 的一阶变分。换句话说，命题 2 表明，满足基本伴随匹配目标一阶最优性条件的唯一控制就是最优控制，这为基于梯度的优化算法提供了理论基础。

理解基本伴随匹配目标的一种直观方式是将其视为一致性损失。伴随匹配目标基于以下观察：最优控制 $u^*(x, t)$ 是关系 $u(x, t) = -\sigma(t)^\top \nabla_x J(u; x, t)$ 的唯一不动点（见附录 E.2 中的引理 6），因此我们直接优化一个满足该关系的控制，同时使用伴随状态作为 $\nabla_x J(u; x, t)$ (29) 的随机估计量。命题 2 中的基本伴随匹配目标尚未产生随机最优控制的新算法，因为它产生的梯度与连续伴随方法相同。这一点可以通过在展开（34）中的平方项并移除不依赖于 θ 的项后对 θ 求梯度来看出，最终恰好得到连续伴随方法（32）。然而，它为推导更简洁的目标函数提供了途径。

“精简”伴随状态。最小二乘目标的最小化器是回归目标的条件期望，因此对于伴随匹配目标，在最优解处我们有

$$u^*(x, t) = \mathbb{E}_{\mathbf{X} \sim p^*} [-\sigma(t)^\top a(t; \mathbf{X}, u^*) | X_t = x]. \quad (35)$$

两边同时乘以雅可比矩阵 $\nabla_x u^*(x, t)$ 并重新整理，我们得到关系式

$$\mathbb{E}_{\mathbf{X} \sim p^*} [u^*(x, t)^\top \nabla_x u^*(x, t) + a(t; \mathbf{X}, u^*)^\top \sigma(t) \nabla_x u^*(x, t) | X_t = x] = 0. \quad (36)$$

Algorithm 1 Adjoint Matching for fine-tuning Flow Matching models

Input: Pre-trained FM velocity field v^{base} , step size h , number of fine-tuning iterations N .

Initialize fine-tuned vector fields: $v^{\text{finetune}} = v^{\text{base}}$ with parameters θ .

for $n \in \{0, \dots, N-1\}$ **do**

Sample m trajectories $\mathbf{X} = (X_t)_{t \in \{0, \dots, 1\}}$ with memoryless noise schedule $\sigma(t) = \sqrt{2\beta_t(\frac{\dot{\alpha}_t}{\alpha_t}\beta_t - \dot{\beta}_t)}$, e.g.:

$$X_{t+h} = X_t + h \left(2v_{\theta}^{\text{finetune}}(X_t, t) - \frac{\dot{\alpha}_t}{\alpha_t} X_t \right) + \sqrt{h}\sigma(t)\varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, I), \quad X_0 \sim \mathcal{N}(0, I). \quad (40)$$

For each trajectory, solve the *lean adjoint ODE* (38)-(39) backwards in time from $t = 1$ to 0, e.g.:

$$\tilde{a}_{t-h} = \tilde{a}_t + h\tilde{a}_t^\top \nabla_{X_t} \left(2v^{\text{base}}(X_t, t) - \frac{\dot{\alpha}_t}{\alpha_t} X_t \right), \quad \tilde{a}_1 = -\nabla_{X_1} r(X_1). \quad (41)$$

Note that X_t and $\tilde{a}_t$ should be computed without gradients, i.e., $X_t = \text{stopgrad}(X_t)$, $\tilde{a}_t = \text{stopgrad}(\tilde{a}_t)$.

For each trajectory, compute the Adjoint Matching objective (37):

$$\mathcal{L}_{\text{Adj-Match}}(\theta) = \sum_{t \in \{0, \dots, 1-h\}} \left\| \frac{2}{\sigma(t)} \left(v_{\theta}^{\text{finetune}}(X_t, t) - v^{\text{base}}(X_t, t) \right) + \sigma(t)\tilde{a}_t \right\|^2. \quad (42)$$

Compute the gradient $\nabla_{\theta} \mathcal{L}(\theta)$ and update θ using favorite gradient descent algorithm.

end

Output: Fine-tuned vector field v^{finetune}

注意, (36) 中期望内的项作为伴随微分方程 (30) 的一部分出现, 我们现在已经证明在最优解处其期望为零。因此, 我们通过移除 (36) 中的项来定义精简伴随状态 $\tilde{a}$ 。将这个精简伴随状态代入最小二乘目标, 我们得到最终提出的伴随匹配目标:

$$\mathcal{L}_{\text{Adj-Match}}(u; \mathbf{X}) := \frac{1}{2} \int_0^1 \|u(X_t, t) + \sigma(t)^\top \tilde{a}(t; \mathbf{X})\|^2 dt, \quad \mathbf{X} \sim p^{\bar{u}}, \quad \bar{u} = \text{stopgrad}(u), \quad (37)$$

$$\text{where} \quad \frac{d}{dt} \tilde{a}(t; \mathbf{X}) = -(\tilde{a}(t; \mathbf{X})^\top \nabla_x b(X_t, t) + \nabla_x f(X_t, t)), \quad (38)$$

$$\tilde{a}(1; \mathbf{X}) = \nabla_x g(X_1). \quad (39)$$

方程 (38)-(39) 定义了精简伴随状态, (37) 是完整的伴随匹配目标。 $\mathbb{E}[\mathcal{L}_{\text{Adj-Match}}]$ 的唯一临界点是最优控制, 我们依赖命题 2 和方程 (36) 证明这一点 (见附录 E.3 中的命题 7)。

与重要性采样方法 (第 5.1.2 节) 相比, 伴随匹配是一个简单的最小二乘回归目标, 没有重要性加权。这使其能够避免高方差重要性权重的缺陷, 并使其与伴随方法一样可扩展, 同时保留匹配目标向量场的解释。与伴随方法 (第 5.1.1 节) 相比, 伴随匹配在期望上产生与连续伴随不同的梯度。这是因为精简伴随状态不再与代价泛函的梯度相关, 即 (29) 不成立, 除非在最优解处 $u = u^*$ 。即使在最优解处, 由于伴随匹配移除了期望为零的项, 它可能表现出比连续伴随方法更好的收敛性和更低的方差。此外, 由于移除了额外项 (不再需要控制的雅可比矩阵 $\nabla_x u$), 精简伴随状态 (38) 的计算也表现出更小的计算成本。我们在附录 E.3 中提供了伴随匹配及上述论断的严格推导。伴随匹配可以通过第 4 节讨论的无记忆随机最优控制公式应用于动态生成模型的奖励微调。我们在算法 1 中为流匹配模型提供了伪代码, 在附录 E.4 的算法 2 中为去噪扩散模型提供了伪代码。

6 相关工作

基于人类反馈的微调。强化学习人类反馈（RLHF）主要有两种总体方法：基于奖励的方法（Ziegler 等，2020；Stiennon 等，2020；Ouyang 等，2022；Bai 等，2022）和直接偏好优化（DPO；Rafailov 等，2023）。基于奖励的方法（Ziegler 等，2020；Stiennon 等，2020；Ouyang 等，2022；Bai 等，2022）包括从人类偏好数据中学习奖励模型 $r(x)$ ，然后利用 $r(x)$ 产生的奖励求解最大熵强化学习问题。DPO 将前两个步骤合并为一个：无需学习 $r(x)$ ，因为人类偏好数据被直接用于微调模型。然而，DPO 通常仅应用于经过筛选的数据集，并且不显式使用奖励模型。此外，特别是对于流模型和扩散模型，可以对奖励函数进行微分，因此更强调基于奖励的方法。

扩散模型微调。在现有基于奖励的扩散微调方法中，范和李（Fan and Lee，2023）将去噪过程解释为多步决策任务，并使用策略梯度算法微调扩散采样器。布莱克等人（Black et al.，2024）利用近端策略梯度进行微调，但未利用奖励模型的可微性。范等人（Fan et al.，2023）也考虑了 KL 正则化奖励（19），但未建立与倾斜分布（1）的关键联系，而我们在第 4.2 节中详细阐述了这一联系。徐等人（Xu et al.，2023）和克拉克等人（Clark et al.，2024）的微调算法直接对奖励模型求梯度，并使用启发式方法试图保持接近原始基础生成模型，但其行为尚未被充分理解，且与倾斜分布无关：徐等人（2023）在不同时间点对去噪样本应用奖励的梯度，而克拉克等人（2024）通过扩散轨迹的全部或部分反向传播奖励函数。最后，上原等人（Uehara et al.，2024b）也以从倾斜分布（1）中采样为目标微调扩散模型，但其方法比我们的复杂得多，因为需要学习价值函数并求解两个随机最优控制问题。其他奖励微调工作包括布鲁纳和韩（Bruna and Han，2024），他们在奖励为二次函数时提供了从倾斜分布采样的理论保证，以及张等人（Zhang et al.，2024），他们为 GFlowNet 架构提出了奖励微调算法。

推理时优化方法。一些研究者提出了不更新基础模型、而是直接修改生成过程的方法。一种做法是在速度上添加引导项（Chung 等，2022；Song 等，2023；Pokle 等，2023）；然而这是一种启发式方法，且尚不清楚所生成的具体分布是什么。另一种做法是直接优化初始噪声分布（Li，2021；Wallace 等，2023b；Ben-Hamu 等，2024）；这与我们处理初始值偏差问题的方式相反，它将所有工作都转移到优化初始分布上。一种计算量更大的方法是在采样过程中在线估计最优控制，以启发式地求解最优控制问题（Huang 等，2024；Rout 等，2024）；这些方法旨在为每个生成的样本单独求解一个控制问题，而不是进行摊销（Amos 等，2023）以学习微调后的生成模型。

生成建模中的最优控制。最优控制方法已被用于训练由常微分方程（Chen 等，2018）、随机微分方程（Li 等，2020）和跳跃过程（Chen 等，2021）参数化的动态生成模型，并通过伴随方法实现。它们可用于训练任意生成过程，但对于简化构造，这些方法已让位于免仿真的匹配目标，如去噪分数匹配（Vincent，2011）和流匹配（Lipman 等，2023）。最优控制形式在从非归一化分布中采样方面也具有重要意义（Zhang 和 Chen，2022；Berner 等，2023；Vargas 等，2023，2022；Richter 和 Berner，2024；Tzen 和 Raginsky，2019）。引入状态代价已被用于求解中间路径分布重要的传输问题（Liu 等，2024；Pooladian 等，2024）。这些集体进展自然引出了将最优控制形式用于奖励微调的考虑。

逆问题中的条件采样。Denker 等（2024）和 Wu 等（2023a）独立考虑了一个预训练扩散模型 $p(x)$ 、对生成样本 x 的观测 y 以及解析似然 $p(y|x)$ 。他们的目标是从后验 $p(x)p(y|x)$ 中采样，其应用包括图像修复、类别条件生成、超分辨率、相位恢复、非线性去模糊、计算机断层成像

	Fine-tuning Method	Fine-tuning $\sigma(t)$	Sampling $\sigma(t)$	ClipScore $\uparrow$	PickScore $\uparrow$	HPS v2 $\uparrow$	DreamSim Diversity $\uparrow$
Baselines	None (Base model)	N/A	$\sqrt{2\eta_t}$ 0	24.15 $\pm$ 0.26 28.32 $\pm$ 0.22	17.25 $\pm$ 0.06 18.15 $\pm$ 0.07	16.19 $\pm$ 0.17 17.89 $\pm$ 0.16	53.60 $\pm$ 1.37 56.53$\pm$1.52
	DRaFT-1	$\sqrt{2\eta_t}$ 0	$\sqrt{2\eta_t}$ 0	30.18 $\pm$ 0.24 30.95 $\pm$ 0.28	19.38 $\pm$ 0.08 19.37 $\pm$ 0.06	24.61 $\pm$ 0.17 24.37 $\pm$ 0.17	25.54 $\pm$ 0.99 27.39 $\pm$ 1.14
	DRaFT-40	$\sqrt{2\eta_t}$ 0	$\sqrt{2\eta_t}$ 0	26.94 $\pm$ 0.28 30.07 $\pm$ 0.39	18.34 $\pm$ 0.19 19.45 $\pm$ 0.08	19.98 $\pm$ 1.02 24.06 $\pm$ 0.24	41.98 $\pm$ 2.14 36.53 $\pm$ 1.69
	DPO	$\sqrt{2\eta_t}$ 0	$\sqrt{2\eta_t}$ 0	24.11 $\pm$ 0.22 27.77 $\pm$ 0.18	17.24 $\pm$ 0.06 17.92 $\pm$ 0.07	16.15 $\pm$ 0.14 17.30 $\pm$ 0.20	53.27 $\pm$ 1.36 54.11 $\pm$ 1.50
	ReFL	$\sqrt{2\eta_t}$ 0	$\sqrt{2\eta_t}$ 0	28.59 $\pm$ 0.31 30.06 $\pm$ 0.63	18.68 $\pm$ 0.10 19.07 $\pm$ 0.21	22.24 $\pm$ 0.46 23.06 $\pm$ 0.41	32.71 $\pm$ 2.76 32.69 $\pm$ 1.28
Memoryless SOC	Cont. Adjoint $\lambda = 12500$	$\sqrt{2\eta_t}$	$\sqrt{2\eta_t}$ 0	26.99 $\pm$ 0.43 29.49 $\pm$ 0.32	18.33 $\pm$ 0.16 18.98 $\pm$ 0.16	20.83 $\pm$ 0.63 21.34 $\pm$ 0.53	46.59 $\pm$ 1.40 48.41 $\pm$ 1.44
	Disc. Adjoint $\lambda = 12500$	$\sqrt{2\eta_t}$	$\sqrt{2\eta_t}$ 0	28.04 $\pm$ 0.57 29.28 $\pm$ 0.17	18.44 $\pm$ 0.21 18.82 $\pm$ 0.14	20.04 $\pm$ 0.39 19.73 $\pm$ 0.17	54.90 $\pm$ 2.03 53.36 $\pm$ 2.48
	Adj.-Matching $\lambda = 1000$	$\sqrt{2\eta_t}$	$\sqrt{2\eta_t}$ 0	30.36 $\pm$ 0.22 31.41 $\pm$ 0.22	19.29 $\pm$ 0.08 19.57 $\pm$ 0.09	24.12 $\pm$ 0.17 23.29 $\pm$ 0.18	40.89 $\pm$ 1.50 43.10 $\pm$ 1.76
	Adj.-Matching $\lambda = 2500$	$\sqrt{2\eta_t}$	$\sqrt{2\eta_t}$ 0	30.59 $\pm$ 0.40 31.64 $\pm$ 0.21	19.49 $\pm$ 0.10 19.71 $\pm$ 0.09	24.85 $\pm$ 0.23 24.12 $\pm$ 0.27	37.07 $\pm$ 1.47 39.88 $\pm$ 1.59
	Adj.-Matching $\lambda = 12500$	$\sqrt{2\eta_t}$	$\sqrt{2\eta_t}$ 0	30.62 $\pm$ 0.30 31.65$\pm$0.19	19.50 $\pm$ 0.09 19.76$\pm$0.08	24.95$\pm$0.28 24.49 $\pm$ 0.27	34.50 $\pm$ 1.33 37.24 $\pm$ 1.57

表 2 不同微调方法在文本到图像生成任务上的评估度量。第二列和第三列分别展示了用于微调 and 采样的噪声调度 $\sigma(t)$: $\sigma(t) = \sqrt{2\eta_t}$ 对应无记忆流匹配, $\sigma(t) = 0$ 对应流匹配常微分方程 (3)。我们报告了在随机选取的 40000 个训练提示上运行 3 次微调算法所估计的标准误, 每次评估均在随机选取的 1000 个测试提示上进行。

断层成像和蛋白质设计。他们的设定通过设置 $r(x) = \log p(y|x)$ 可归结为我们奖励微调框架的一个特例。Denker 等人 (2024) 构建了一个随机最优控制问题, 并通过对数方差损失 (Richter 等人 (2020); Nüsken 和 Richter (2021)) 和矩损失 (Nüsken 和 Richter, 2021)⁷, 他们称之为轨迹平衡损失 (Malkin 等人, 2023)) 来求解。Wu 等人 (2023a) 提出了扭曲扩散采样器, 这是一种基于序贯蒙特卡洛的算法, 利用增加的推理时间计算来减少偏差。第三项同样处理条件采样问题的工作是 Du 等人 (2024), 他们使用拉格朗日公式, 并利用高斯路径进行近似求解。

7 实验

我们通过实验验证了所提出的方法在流匹配基础模型 (Lipman 等人, 2023) 上的奖励微调效果。具体而言, 我们采用常规设置: 先预训练一个用于 512×512 分辨率图像的自编码器, 然后在隐变量上使用 U-net 架构 (Long 等人, 2015) 训练文本条件流匹配模型, 该设置与 Rombach 等人 (2022) 中的类似。我们使用许可的文本和图像数据集预训练基础模型。随后, 在微调阶段, 我们考虑以下奖励函数:

$$r(x) := \lambda \times \text{RewardModel}(x) \quad (43)$$

对应于奖励模型的缩放版本, 我们将其取为 ImageReward (Xu 等人, 2023)。不同的 λ 值在 KL 正则化与奖励模型 (19) 之间提供了不同的权衡。

⁷ 另见 Domingo-Enrich (2024) 关于随机最优控制损失之间的比较。



图 3 本文提出的基于无记忆随机最优控制（SOC）公式的伴随匹配方法，在优化奖励模型的同时，引入了一种更具原则性的方式来权衡与基础模型的接近程度。相比之下，DRaFT-1 等基线方法仅优化奖励模型，必须依赖早停来实现这种权衡，导致超参数更为敏感。样本使用 $\sigma(t) = 0$ 生成，噪声样本相同。文本提示：“穿蓝色夹克的英俊微笑男子肖像”和“藜麦菲达奶酪酿小甜椒”。



文本提示：“男子坐在家中沙发上，面对壁炉使用笔记本电脑，后视图”

Text prompt: “3D World Food Day Morocco”

图 4 来自伴随匹配微调模型的不同无分类器引导权重 w 生成的样本。更高的引导值增强了文本到图像的一致性，但降低了多样性，适用于生成高度结构化图像（如三维渲染）的场景。基础模型的对应样本见图 7。

为了评估和基准测试，我们报告了分别量化文本到图像一致性、人类偏好和样本多样性的指标，以捕捉生成模型各维度之间的权衡（Astolfi 等，2024）。对于一致性，我们使用标准的 ClipScore（Hessel 等，2021）和 PickScore（Kirstain 等，2023）；对于对未见人类偏好的泛化，我们使用 HPSv2 模型（Wu 等，2023b）；对于多样性，我们计算 DreamSim 特征（Fu 等，2023）的成对距离平均值。更多细节见附录 G.4。作为基线，我们考虑了 DPO（Wallace 等，2023a）、ReFL（Xu 等，2023）和 DRaFT-K 算法（Clark 等，2024）。DPO 不使用奖励函数的梯度，而 ReFL 和 DRaFT 使用启发式梯度停止方法来保持与基础生成模型的接近。在这些基线方法中，我们发现 DRaFT-1 表现最佳，因此我们进行了额外的消融实验与该方法的比较。在与本文方法相同的 SOC 公式下，我们还考虑了




图 5 生成模型不同方面之间的权衡：文本到图像一致性（ClipScore）、每个提示的样本多样性（DreamSim Diversity）以及对未见人类偏好的泛化（HPS v2）。不同点通过改变 λ 的值（针对伴随匹配）和改变 DRaFT-1 基线的微调迭代次数获得。总体而言，我们发现所提出的伴随匹配方法具有最佳的帕累托前沿。

离散和连续伴随方法。我们在附录 G 中提供了完整的实验细节；一个重要的实现细节是我们略微偏移 $\sigma(t)$ 以避免除零。

评估结果。在表 2 中，我们报告了基线方法以及所提出的伴随匹配方法的评估指标。我们在大致相同的墙钟时间下比较每种方法（见表 4 中的时间和迭代次数，以及附录 G.5 中的评论）。我们发现，在所有指标上，所提出的无记忆 SOC 公式均优于现有基线方法。SOC 算法的选择显然也使得伴随匹配优于连续和离散伴随方法，后者导致较差的一致性和人类偏好指标。

消融：基础模型与奖励权衡。我们注意到，奖励模型前面的缩放 λ 决定了我们应该在多大程度上偏好奖励模型而非基础模型。因此，我们看到一条自然的权衡曲线：较高的 λ 会带来更好的一致性和人类偏好，但生成样本的多样性较低。总体而言，我们发现伴随匹配在 λ 的所有值上都表现稳定。我们通过无记忆 SOC 对微调过程进行正则化的方法比通常必须采用早停的基线方法效果好得多。我们在图 3 中展示了改变 λ 的定性效果，而对于 DRaFT-1 基线，我们展示了改变微调迭代次数的效果。

消融：无分类器引导。我们注意到，在微调之后应用无分类器引导（CFG；Ho 和 Salimans (2022)；Zheng 等人 (2023)）是可行的。我们使用公式 $(1+w)v(x,t|y) - wv(x,t)$ ，其中 w 是引导权重， $v(x,t|y)$ 是微调后的文本到图像模型，而 $v(x,t)$ 是无条件图像模型。这种做法并不严谨，因为只有条件模型被微调，但通常引导模型从何种分布采本身就不明确。在图 5 中，我们展示了应用无分类器引导后的评估度量。比较三个不同的引导权重值，我们发现较高的权重确实能改善文本到图像的一致性，并在一定程度上改善人类偏好，但这是以多样性变差为代价的。我们在图 4 中展示了定性差异。

8 结论

我们研究了微调动态生成模型（如流匹配）的问题，并提出使用具有无记忆噪声调度的随机最优控制（SOC）公式。这确保我们收敛到与大型语言建模文献中用于从人类反馈中学习的相同的倾斜分布。

特别是，无记忆噪声调度对应于扩散模型的 DDPM 采样，以及流模型的新无记忆流匹配生成过程。同时，我们提出了一种新颖的训练算法，通过将 SOC 转化为回归问题来求解随机最优控制问题，我们称之为伴随匹配目标。经验上，我们发现我们的无记忆 SOC 公式比多个现有的微调扩散模型的工作表现更好，并且我们的伴随匹配算法优于相关的基于梯度的方法。总之，我们是第一个为微调流匹配模型提供理论驱动算法的人，并且我们发现我们的方法在大规模文本到图像生成的多个评估轴上——文本到图像一致性、对未见人类偏好的泛化以及样本多样性——显著优于基线方法。

参考文献

- Michael S Albergo, Nicholas M Boffi, and Eric Vanden-Eijnden. Stochastic interpolants: A unifying framework for flows and diffusions. *arXiv preprint arXiv:2303.08797*, 2023. Cited on page 36.
- Michael Samuel Albergo and Eric Vanden-Eijnden. Building normalizing flows with stochastic interpolants. In *The Eleventh International Conference on Learning Representations*, 2023. Cited on pages 2, 3, and 36.
- Brandon Amos et al. Tutorial on amortized optimization. *Foundations and Trends® in Machine Learning*, 16(5): 592–732, 2023. Cited on page 12.
- Pietro Astolfi, Marlene Careil, Melissa Hall, Oscar Mañas, Matthew Muckley, Jakob Verbeek, Adriana Romero Soriano, and Michal Drozdal. Consistency-diversity-realism pareto fronts of conditional image generative models. *arXiv preprint arXiv:2406.10429*, 2024. Cited on page 14.
- Yuntao Bai, Andy Jones, Kamal Ndousse, Amanda Askell, Anna Chen, Nova DasSarma, Dawn Drain, Stanislav Fort, Deep Ganguli, Tom Henighan, Nicholas Joseph, Saurav Kadavath, Jackson Kernion, Tom Conerly, Sheer El-Showk, Nelson Elhage, Zac Hatfield-Dodds, Danny Hernandez, Tristan Hume, Scott Johnston, Shauna Kravec, Liane Lovitt, Neel Nanda, Catherine Olsson, Dario Amodei, Tom Brown, Jack Clark, Sam McCandlish, Chris Olah, Ben Mann, and Jared Kaplan. Training a helpful and harmless assistant with reinforcement learning from human feedback. *arXiv preprint arXiv:2204.05862*, 2022. Cited on pages 2 and 12.
- Grigory Bartosh, Dmitry Vetrov, and Christian A. Naesseth. Neural diffusion models. *arXiv preprint arXiv:2310.08337*, 2024a. Cited on page 4.
- Grigory Bartosh, Dmitry Vetrov, and Christian A. Naesseth. Neural flow diffusion models: Learnable forward process for improved diffusion modelling. *arXiv preprint arXiv:2404.12940*, 2024b. Cited on page 4.
- Richard Bellman. *Dynamic programming*. Princeton Landmarks in Mathematics. Princeton University Press, Princeton, NJ, 2010., 1957. Cited on page 5.
- Heli Ben-Hamu, Omri Puny, Itai Gat, Brian Karrer, Uriel Singer, and Yaron Lipman. D-flow: Differentiating through flows for controlled generation. *arXiv preprint arXiv:2402.14017*, 2024. Cited on page 12.
- Julius Berner, Lorenz Richter, and Karen Ullrich. An optimal control perspective on diffusion-based generative modeling. *arXiv preprint arXiv:2211.01364*, 2023. Cited on page 12.
- Joris Bierkens and Hilbert J Kappen. Explicit solution of relative entropy weighted control. *Systems & Control Letters*, 72:36–43, 2014. Cited on page 9.
- Kevin Black, Michael Janner, Yilun Du, Ilya Kostrikov, and Sergey Levine. Training diffusion models with reinforcement learning. In *The Twelfth International Conference on Learning Representations*, 2024. Cited on pages 2, 12, and 37.
- Joan Bruna and Jiequn Han. Posterior sampling with denoising oracles via tilted transport. *arXiv preprint arXiv:2407.00745*, 2024. Cited on page 12.
- Ricky T. Q. Chen, Yulia Rubanova, Jesse Bettencourt, and David K Duvenaud. Neural ordinary differential equations. In *Advances in Neural Information Processing Systems*, volume 31. Curran Associates, Inc., 2018. Cited on pages 9 and 12.
- Ricky T. Q. Chen, Brandon Amos, and Maximilian Nickel. Learning neural event functions for ordinary differential equations. In *International Conference on Learning Representations*, 2021. Cited on pages 9 and 12.
- Tianqi Chen, Bing Xu, Chiyuan Zhang, and Carlos Guestrin. Training deep nets with sublinear memory cost. *arXiv preprint arXiv:1604.06174*, 2016. Cited on page 9.

- Hyungjin Chung, Jeongsol Kim, Michael T Mccann, Marc L Klasky, and Jong Chul Ye. Diffusion posterior sampling for general noisy inverse problems. *arXiv preprint arXiv:2209.14687*, 2022. Cited on page 12.
- Kevin Clark, Paul Vicol, Kevin Swersky, and David J. Fleet. Directly fine-tuning diffusion models on differentiable rewards. In *The Twelfth International Conference on Learning Representations*, 2024. Cited on pages 2, 12, and 14.
- Valentin De Bortoli, James Thornton, Jeremy Heng, and Arnaud Doucet. Diffusion schrödinger bridge with applications to score-based generative modeling. In *Advances in Neural Information Processing Systems*, volume 34, pages 17695–17709. Curran Associates, Inc., 2021. Cited on page 34.
- Alexander Denker, Francisco Vargas, Shreyas Padhy, Kieran Didi, Simon Mathis, Vincent Dutordoir, Riccardo Barbano, Emile Mathieu, Urszula Julia Komorowska, and Pietro Lio. Deft: Efficient finetuning of conditional diffusion models by learning the generalised h -transform. *arXiv preprint arXiv:2406.01781*, 2024. Cited on pages 12 and 13.
- Carles Domingo-Enrich. A taxonomy of loss functions for stochastic optimal control. *arXiv preprint arXiv:2410.00345*, 2024. Cited on page 13.
- Carles Domingo-Enrich, Jiequn Han, Brandon Amos, Joan Bruna, and Ricky T. Q. Chen. Stochastic optimal control matching. *arXiv preprint arXiv:2312.02027*, 2023. Cited on pages 5, 8, 9, 10, 46, and 47.
- Yuanqi Du, Michael Plainer, Rob Brekelmans, Chenru Duan, Frank Noé, Carla P. Gomes, Alan Apsuru-Guzik, and Kirill Neklyudov. Doob’s lagrangian: A sample-efficient variational approach to transition path sampling. *arXiv preprint arXiv:2410.07974*, 2024. Cited on page 13.
- Patrick Esser, Sumith Kulal, Andreas Blattmann, Rahim Entezari, Jonas Müller, Harry Saini, Yam Levi, Dominik Lorenz, Axel Sauer, Frederic Boesel, et al. Scaling rectified flow transformers for high-resolution image synthesis. In *Forty-first International Conference on Machine Learning*, 2024. Cited on page 2.
- Ying Fan and Kangwook Lee. Optimizing ddpm sampling with shortcut fine-tuning. In *International Conference on Machine Learning*, 2023. Cited on pages 2 and 12.
- Ying Fan, Olivia Watkins, Yuqing Du, Hao Liu, Moonkyung Ryu, Craig Boutilier, Pieter Abbeel, Mohammad Ghavamzadeh, Kangwook Lee, and Kimin Lee. Dpoc: Reinforcement learning for fine-tuning text-to-image diffusion models. *arXiv preprint arXiv:2305.16381*, 2023. Cited on pages 2 and 12.
- Ying Fan, Olivia Watkins, Yuqing Du, Hao Liu, Moonkyung Ryu, Craig Boutilier, Pieter Abbeel, Mohammad Ghavamzadeh, Kangwook Lee, and Kimin Lee. Reinforcement learning for fine-tuning text-to-image diffusion models. *Advances in Neural Information Processing Systems*, 36, 2024. Cited on pages 2 and 6.
- W.H. Fleming and R.W. Rishel. *Deterministic and Stochastic Optimal Control*. Stochastic Modelling and Applied Probability. Springer New York, 2012. Cited on page 5.
- Stephanie Fu, Netanel Tamir, Shobhita Sundaram, Lucy Chai, Richard Zhang, Tali Dekel, and Phillip Isola. Dreamsim: Learning new dimensions of human visual similarity using synthetic data. *arXiv preprint arXiv:2306.09344*, 2023. Cited on pages 14 and 54.
- Vicenç Gómez, Hilbert J Kappen, Jan Peters, and Gerhard Neumann. Policy search for path integral control. In *Joint European Conference on Machine Learning and Knowledge Discovery in Databases*, pages 482–497. Springer, 2014. Cited on page 9.
- Ian J Goodfellow, Jonathon Shlens, and Christian Szegedy. Explaining and harnessing adversarial examples. *arXiv preprint arXiv:1412.6572*, 2014. Cited on page 2.
- Eldad Haber and Lars Ruthotto. Stable architectures for deep neural networks. *Inverse problems*, 34(1):014004, 2017. Cited on page 9.
- Jiequn Han and Weinan E. Deep learning approximation for stochastic control problems. *arXiv preprint arXiv:1611.07422*, 2016. Cited on page 9.
- Carsten Hartmann and Christof Schütte. Efficient rare event simulation by optimal nonequilibrium forcing. *Journal of Statistical Mechanics: Theory and Experiment*, 2012(11):P11004, 2012. Cited on page 9.
- Jack Hessel, Ari Holtzman, Maxwell Forbes, Ronan Le Bras, and Yejin Choi. Clipscore: A reference-free evaluation metric for image captioning. *arXiv preprint arXiv:2104.08718*, 2021. Cited on pages 2 and 14.
- Jonathan Ho and Tim Salimans. Classifier-free diffusion guidance. *arXiv preprint arXiv:2207.12598*, 2022. Cited on pages 2, 15, and 25.

- Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. In *Advances in Neural Information Processing Systems*, volume 33. Curran Associates, Inc., 2020. Cited on pages 2, 3, 4, and 7.
- Yujia Huang, Adishree Ghatare, Yuanzhe Liu, Ziniu Hu, Qinsheng Zhang, Chandramouli S Sastry, Siddharth Gururani, Sageev Oore, and Yisong Yue. Symbolic music generation with non-differentiable rule guided diffusion. *arXiv preprint arXiv:2402.14285*, 2024. Cited on page 12.
- Gabriel Ilharco, Mitchell Wortsman, Ross Wightman, Cade Gordon, Nicholas Carlini, Rohan Taori, Achal Dave, Vaishaal Shankar, Hongseok Namkoong, John Miller, Hannaneh Hajishirzi, Ali Farhadi, and Ludwig Schmidt. Openclip, July 2021. Cited on page 54.
- H J Kappen. Path integrals and symmetry breaking for optimal control theory. *Journal of Statistical Mechanics: Theory and Experiment*, 2005(11), nov 2005. Cited on pages 5 and 9.
- Hilbert J Kappen, Vicenç Gómez, and Manfred Oppel. Optimal control as a graphical model inference problem. *Machine learning*, 87(2):159–182, 2012. Cited on page 9.
- Diederik P Kingma, Tim Salimans, Ben Poole, and Jonathan Ho. On density estimation with diffusion models. In A. Beygelzimer, Y. Dauphin, P. Liang, and J. Wortman Vaughan, editors, *Advances in Neural Information Processing Systems*, 2021. Cited on page 2.
- Yuval Kirstain, Adam Polyak, Uriel Singer, Shahbuland Matiana, Joe Penna, and Omer Levy. Pick-a-pic: An open dataset of user preferences for text-to-image generation. In *Thirty-seventh Conference on Neural Information Processing Systems*, 2023. Cited on pages 2, 14, and 54.
- Matthew Le, Apoorv Vyas, Bowen Shi, Brian Karrer, Leda Sari, Rashel Moritz, Mary Williamson, Vimal Manohar, Yossi Adi, Jay Mahadeokar, et al. Voicebox: Text-guided multilingual universal speech generation at scale. *Advances in neural information processing systems*, 36, 2024. Cited on page 2.
- Dongzhuo Li. Differentiable gaussianization layers for inverse problems regularized by deep generative models. *arXiv preprint arXiv:2112.03860*, 2021. Cited on page 12.
- Xuechen Li, Ting-Kam Leonard Wong, Ricky T. Q. Chen, and David Duvenaud. Scalable gradients for stochastic differential equations. In *International Conference on Artificial Intelligence and Statistics*, pages 3870–3882. PMLR, 2020. Cited on pages 9 and 12.
- Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matthew Le. Flow matching for generative modeling. In *The Eleventh International Conference on Learning Representations*, 2023. Cited on pages 2, 3, 12, 13, and 36.
- Guan-Hong Liu, Yaron Lipman, Maximilian Nickel, Brian Karrer, Evangelos Theodorou, and Ricky T. Q. Chen. Generalized schrödinger bridge matching. In *The Twelfth International Conference on Learning Representations*, 2024. Cited on page 12.
- Qiang Liu. Rectified flow: A marginal preserving approach to optimal transport. *arXiv preprint arXiv:2209.14577*, 2022. Cited on page 3.
- Xingchao Liu, Chengyue Gong, and qiang liu. Flow straight and fast: Learning to generate and transfer data with rectified flow. In *The Eleventh International Conference on Learning Representations*, 2023. Cited on pages 2 and 3.
- Jonathan Long, Evan Shelhamer, and Trevor Darrell. Fully convolutional networks for semantic segmentation. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 3431–3440, 2015. Cited on page 13.
- Nikolay Malkin, Moksh Jain, Emmanuel Bengio, Chen Sun, and Yoshua Bengio. Trajectory balance: Improved credit assignment in gflownets. *arXiv preprint arXiv:2201.13259*, 2023. Cited on page 13.
- Dimitra Maoutsa, Sebastian Reich, and Manfred Oppel. Interacting particle solutions of fokker–planck equations through gradient–log–density estimation. *Entropy*, 22(8):802, 2020. Cited on page 3.
- Shakir Mohamed, Mihaela Rosca, Michael Figurnov, and Andriy Mnih. Monte carlo gradient estimation in machine learning. *Journal of Machine Learning Research*, 21(132):1–62, 2020. Cited on page 9.
- Alexander Mordvintsev, Christopher Olah, and Mike Tyka. Inceptionism: Going deeper into neural networks. *Google research blog*, 20(14):5, 2015. Cited on page 2.

- Nikolas Nüsken and Lorenz Richter. Solving high-dimensional Hamilton–Jacobi–Bellman pdes using neural networks: perspectives from the theory of controlled diffusions and measures on path space. *Partial differential equations and applications*, 2:1–48, 2021. Cited on page 13.
- Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, John Schulman, Jacob Hilton, Fraser Kelton, Luke Miller, Maddie Simens, Amanda Askell, Peter Welinder, Paul F Christiano, Jan Leike, and Ryan Lowe. Training language models to follow instructions with human feedback. In *Advances in Neural Information Processing Systems*, volume 35, pages 27730–27744. Curran Associates, Inc., 2022. Cited on pages 2, 6, and 12.
- Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, et al. Pytorch: An imperative style, high-performance deep learning library. *Advances in neural information processing systems*, 32, 2019. Cited on page 9.
- Ashwini Pople, Matthew J Muckley, Ricky T. Q. Chen, and Brian Karrer. Training-free linear image inversion via flows. *arXiv preprint arXiv:2310.04432*, 2023. Cited on page 12.
- L.S. Pontryagin. *The Mathematical Theory of Optimal Processes*. Interscience Publishers, 1962. Cited on pages 8 and 9.
- Aram-Alexandre Pooladian, Carles Domingo-Enrich, Ricky T. Q. Chen, and Brandon Amos. Neural optimal transport with lagrangian costs. *arXiv preprint arXiv:2406.00288*, 2024. Cited on page 12.
- Rafael Rafailov, Archit Sharma, Eric Mitchell, Christopher D Manning, Stefano Ermon, and Chelsea Finn. Direct preference optimization: Your language model is secretly a reward model. In *Thirty-seventh Conference on Neural Information Processing Systems*, 2023. Cited on pages 6 and 12.
- Konrad Rawlik, Marc Toussaint, and Sethu Vijayakumar. On stochastic optimal control and reinforcement learning by approximate inference. In *Twenty-Third International Joint Conference on Artificial Intelligence*, 2013. Cited on pages 6 and 9.
- Lorenz Richter and Julius Berner. Improved sampling via learned diffusions. In *The Twelfth International Conference on Learning Representations*, 2024. Cited on page 12.
- Lorenz Richter, Ayman Boustati, Nikolas Nüsken, Francisco Ruiz, and Omer Deniz Akyildiz. VarGrad: A low-variance gradient estimator for variational inference. *Advances in Neural Information Processing Systems*, 33, 2020. Cited on page 13.
- Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. High-resolution image synthesis with latent diffusion models. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 10684–10695, 2022. Cited on pages 2 and 13.
- Litu Rout, Yujia Chen, Nataniel Ruiz, Abhishek Kumar, Constantine Caramanis, Sanjay Shakkottai, and Wen-Sheng Chu. Rb-modulation: Training-free personalization of diffusion models using stochastic optimal control. *arXiv preprint arXiv:2405.17401*, 2024. Cited on page 12.
- Reuven Y Rubinstein and Dirk P Kroese. *The cross-entropy method: a unified approach to combinatorial optimization, Monte-Carlo simulation and machine learning*. Springer Science & Business Media, 2013. Cited on page 9.
- Christoph Schuhmann and Romain Beaumont. Laion-aesthetics, 2022. Cited on page 2.
- S.P. Sethi. *Optimal Control Theory: Applications to Management Science and Economics*. Springer International Publishing, 2018. Cited on page 5.
- Uriel Singer, Adam Polyak, Thomas Hayes, Xi Yin, Jie An, Songyang Zhang, Qiyuan Hu, Harry Yang, Oron Ashual, Oran Gafni, et al. Make-a-video: Text-to-video generation without text-video data. *arXiv preprint arXiv:2209.14792*, 2022. Cited on page 2.
- Jiaming Song, Chenlin Meng, and Stefano Ermon. Denoising diffusion implicit models. In *International Conference on Learning Representations*, 2021a. Cited on pages 3, 7, and 31.
- Jiaming Song, Arash Vahdat, Morteza Mardani, and Jan Kautz. Pseudoinverse-guided diffusion models for inverse problems. In *International Conference on Learning Representations*, 2023. Cited on page 12.
- Yang Song and Stefano Ermon. Generative modeling by estimating gradients of the data distribution. *arXiv preprint arXiv:1907.05600*, 2019. Cited on page 2.

- Yang Song, Jascha Sohl-Dickstein, Diederik P. Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole. Score-based generative modeling through stochastic differential equations. In *International Conference on Learning Representations (ICLR 2021)*, 2021b. Cited on pages 2 and 3.
- Nisan Stiennon, Long Ouyang, Jeffrey Wu, Daniel Ziegler, Ryan Lowe, Chelsea Voss, Alec Radford, Dario Amodei, and Paul F Christiano. Learning to summarize with human feedback. In *Advances in Neural Information Processing Systems*, volume 33, pages 3008–3021. Curran Associates, Inc., 2020. Cited on pages 2 and 12.
- Hyung Ju Suh, Max Simchowitz, Kaiqing Zhang, and Russ Tedrake. Do differentiable simulators give better policy gradients? In *International Conference on Machine Learning*, pages 20668–20696. PMLR, 2022. Cited on page 9.
- Wenpin Tang. Fine-tuning of diffusion models via stochastic control: entropy regularization and beyond. *arXiv preprint arXiv:2403.06279*, 2024. Cited on page 6.
- Emanuel Todorov. Linearly-solvable markov decision problems. *Advances in neural information processing systems*, 19, 2006. Cited on page 5.
- Belinda Tzen and Maxim Raginsky. Theoretical guarantees for sampling and inference in generative models with latent diffusions. *arXiv:1903.01608*, 2019. Cited on page 12.
- Masatoshi Uehara, Yulai Zhao, Tommaso Biancalani, and Sergey Levine. Understanding reinforcement learning-based fine-tuning of diffusion models: A tutorial and review. *arXiv preprint arXiv:2407.13734*, 2024a. Cited on page 2.
- Masatoshi Uehara, Yulai Zhao, Kevin Black, Ehsan Hajiramezani, Gabriele Scalia, Nathaniel Lee Diamant, Alex M Tseng, Tommaso Biancalani, and Sergey Levine. Fine-tuning of continuous-time diffusion models as entropy-regularized control. *arXiv preprint arXiv:2402.15194*, 2024b. Cited on pages 2, 6, 12, and 37.
- Francisco Vargas, Andrius Ovsianas, David Lopes Fernandes, Mark Girolami, Neil D Lawrence, and Nikolas Nüsken. Bayesian learning via neural schrödinger-föllmer flows. In *Fourth Symposium on Advances in Approximate Bayesian Inference*, 2022. Cited on page 12.
- Francisco Vargas, Will Sussman Grathwohl, and Arnaud Doucet. Denoising diffusion samplers. In *The Eleventh International Conference on Learning Representations*, 2023. Cited on page 12.
- Pascal Vincent. A connection between score matching and denoising autoencoders. *Neural computation*, 23(7): 1661–1674, 2011. Cited on page 12.
- Apoorv Vyas, Bowen Shi, Matthew Le, Andros Tjandra, Yi-Chiao Wu, Baishan Guo, Jiemin Zhang, Xinyue Zhang, Robert Adkins, William Ngan, et al. Audiobox: Unified audio generation with natural language prompts. *arXiv preprint arXiv:2312.15821*, 2023. Cited on page 2.
- Bram Wallace, Meihua Dang, Rafael Rafailov, Linqi Zhou, Aaron Lou, Senthil Purushwalkam, Stefano Ermon, Caiming Xiong, Shafiq Joty, and Nikhil Naik. Diffusion model alignment using direct preference optimization. *arXiv preprint arXiv:2311.12908*, 2023a. Cited on pages 2, 14, 22, and 52.
- Bram Wallace, Akash Gokul, Stefano Ermon, and Nikhil Naik. End-to-end diffusion latent optimization improves classifier guidance. *arXiv preprint arXiv:2303.13703*, 2023b. Cited on page 12.
- Luhuan Wu, Brian Trippe, Christian Naesseth, David Blei, and John P Cunningham. Practical and asymptotically exact conditional sampling in diffusion models. In *Advances in Neural Information Processing Systems*, volume 36, pages 31372–31403. Curran Associates, Inc., 2023a. Cited on pages 12 and 13.
- Xiaoshi Wu, Yiming Hao, Keqiang Sun, Yixiong Chen, Feng Zhu, Rui Zhao, and Hongsheng Li. Human preference score v2: A solid benchmark for evaluating human preferences of text-to-image synthesis. *arXiv preprint arXiv:2306.09341*, 2023b. Cited on pages 14 and 54.
- Xiaoshi Wu, Yiming Hao, Keqiang Sun, Yixiong Chen, Feng Zhu, Rui Zhao, and Hongsheng Li. Human preference score v2: A solid benchmark for evaluating human preferences of text-to-image synthesis. *arXiv preprint arXiv:2306.09341*, 2023c. Cited on page 2.
- Jiazheng Xu, Xiao Liu, Yuchen Wu, Yuxuan Tong, Qinkai Li, Ming Ding, Jie Tang, and Yuxiao Dong. Imagereward: Learning and evaluating human preferences for text-to-image generation. In *Thirty-seventh Conference on Neural Information Processing Systems*, 2023. Cited on pages 2, 12, 13, 14, 22, and 51.
- Dinghuai Zhang, Yizhe Zhang, Jiatao Gu, Ruixiang Zhang, Josh Susskind, Navdeep Jaitly, and Shuangfei Zhai. Improving gflownets for text-to-image diffusion alignment. *arXiv preprint arXiv:2406.00633*, 2024. Cited on page 12.

- Qinsheng Zhang and Yongxin Chen. Path integral sampler: A stochastic control approach for sampling. In *International Conference on Learning Representations*, 2022. Cited on page [12](#).
- Wei Zhang, Han Wang, Carsten Hartmann, Marcus Weber, and Christof Schütte. Applications of the cross-entropy method to importance sampling and optimal control of diffusions. *SIAM Journal on Scientific Computing*, 36(6): A2654–A2672, 2014. Cited on page [9](#).
- Qinqing Zheng, Matt Le, Neta Shaul, Yaron Lipman, Aditya Grover, and Ricky T. Q. Chen. Guided flows for generative modeling and decision making. *arXiv preprint arXiv:2311.13443*, 2023. Cited on pages [2](#) and [15](#).
- Brian D Ziebart, Andrew L Maas, J Andrew Bagnell, Anind K Dey, et al. Maximum entropy inverse reinforcement learning. In *Aaai*, volume 8, pages 1433–1438. Chicago, IL, USA, 2008. Cited on pages [5](#) and [37](#).
- Daniel M. Ziegler, Nisan Stiennon, Jeffrey Wu, Tom B. Brown, Alec Radford, Dario Amodei, Paul Christiano, and Geoffrey Irving. Fine-tuning language models from human preferences. *arXiv preprint arXiv:1909.08593*, 2020. Cited on pages [2](#) and [12](#).

附录

目录

A 附加图表 23

B DDIM 与流匹配上的结果 31	B.1 DDIM 的连续时间极限	31	B.2 前向与后向随机微分方程	31	B.2.1 引理 1 的证明	33	B.2.2 引理 2 的证明	33	B.2.3 命题 4 的证明	34	B.3 噪声预测器 ϵ 与得分函数之间的关系	36	B.4 向量场 v 与得分函数之间的关系	36
---------------------------	------------------------	-----------	-----------------------	-----------	----------------------	----	----------------------	----	----------------------	----	---------------------------------------	----	------------------------------	----

C 随机最优控制作为连续空间与时间中的最大熵强化学习 37

C.1 最大熵强化学习	37
C.2 从最大熵强化学习到随机最优控制	38
C.3 命题 5 的证明：从最大熵强化学习到随机最优控制	39
C.4 方程 (18) 的证明：控制代价是一个 KL 正则化项	41

D 第 4.3 节证明：无记忆噪声调度与微调方案 42	D.1 命题 1 的证明：无记忆噪声调度	42	D.2 定理 1 的证明：一般噪声调度的微调配方	43
------------------------------------	----------------------------	----	--------------------------------	----

附录 E 损失函数推导 46	E.1 连续伴随方法的推导	46	E.2 命题 2 的证明：基本伴随匹配损失的理论保证	48	E.3 伴随匹配损失的理论保证	49	E.4 用于 DDIM 微调的伴随匹配伪代码	50
-----------------------	---------------------	-----------	----------------------------------	----	-----------------------	----	------------------------------	----

F 将扩散微调基线适配到流匹配 51	F.1 将 ReFL (Xu 等, 2023) 适配到流匹配	51	F.2 将扩散 DPO (Wallace 等, 2023a) 适配到流匹配	52
---------------------------	--------------------------------------	----	---	----

G 实验细节 53	G.1 噪声调度细节	53	G.2 梯度评估时间步的选择	54	G.3 损失函数裁剪：LCT 超参数	54	G.4 评估度量的计算	55	G.5 关于计算成本的说明	55	G.6 关于采样时间步数的说明	55
------------------	------------------	-----------	----------------------	----	--------------------------	----	-------------------	----	---------------------	----	-----------------------	----

A 补充图表




图 6 伴随匹配 (Adjoint Matching) 与各基线方法的 ImageReward (奖励函数)、控制代价 ($\int_0^t \frac{1}{2} \|u(X_t^u, t)\|^2 dt$) 及 ClipScore 随墙钟时间的平均值。曲线为三次微调运行的平均结果，在规模为 200 的独立测试数据集上评估。置信区间表示估计值的标准误差。



文本提示：“男子坐在家中沙发上，面对壁炉使用笔记本电脑，后视图”

Text prompt: “3D World Food Day Morocco”

图 7 预训练流匹配 (Flow Matching) 模型在不同无分类器引导权重下生成的样本。微调模型对应的样本见图 4。

Fine-tuning loss	Fine-tuning $\sigma(t)$	Sampling $\sigma(t)$	ImageReward $\uparrow$	ClipScore diversity $\uparrow$	PickScore diversity $\uparrow$	Total time (s) / # iterations
None (CFG = 1.0)	N/A	$\sqrt{2\eta_t}$ 0	-1.384 ± 0.040 -0.920 ± 0.042	28.07 ± 1.40 30.29 ± 1.53	1.63 ± 0.08 1.82 ± 0.09	N/A
DRaFT-1	$\sqrt{2\eta_t}$ 0	$\sqrt{2\eta_t}$ 0	1.357 ± 0.039 1.251 ± 0.040	16.86 ± 0.98 16.76 ± 1.06	1.21 ± 0.07 1.27 ± 0.07	$140k \pm 5.9k$ / 4000
DRaFT-40	$\sqrt{2\eta_t}$ 0	$\sqrt{2\eta_t}$ 0	-0.560 ± 0.138 0.424 ± 0.042	24.07 ± 1.37 20.99 ± 1.54	1.64 ± 0.12 1.67 ± 0.08	$148k \pm 4.2k$ / 1500
DPO	$\sqrt{2\eta_t}$ 0	$\sqrt{2\eta_t}$ 0	-1.386 ± 0.033 -0.957 ± 0.040	27.80 ± 1.40 29.81 ± 1.43	1.62 ± 0.08 1.68 ± 0.10	$118k \pm 0.6k$ / 1000
ReFL	$\sqrt{2\eta_t}$ 0	$\sqrt{2\eta_t}$ 0	0.687 ± 0.085 0.709 ± 0.080	19.49 ± 1.76 18.39 ± 1.11	1.22 ± 0.08 1.31 ± 0.10	$173k \pm 10.9k$ / 6000
Cont. Adjoint $\lambda = 12500$	$\sqrt{2\eta_t}$	$\sqrt{2\eta_t}$ 0	-0.448 ± 0.135 -0.249 ± 0.116	26.97 ± 1.37 26.25 ± 1.30	1.82 ± 0.09 1.90 ± 0.10	$153k \pm 0.9k$ / 750
Disc. Adjoint $\lambda = 12500$	$\sqrt{2\eta_t}$	$\sqrt{2\eta_t}$ 0	-0.557 ± 0.113 -0.552 ± 0.041	30.40 ± 2.39 28.37 ± 2.26	1.91 ± 0.09 1.97 ± 0.09	$152k \pm 1.5k$ / 1000
Adj.-Matching $\lambda = 1000$	$\sqrt{2\eta_t}$	$\sqrt{2\eta_t}$ 0	0.550 ± 0.043 0.454 ± 0.055	23.00 ± 1.27 22.76 ± 1.40	1.65 ± 0.08 1.73 ± 0.09	
Adj.-Matching $\lambda = 2500$	$\sqrt{2\eta_t}$	$\sqrt{2\eta_t}$ 0	0.755 ± 0.040 0.671 ± 0.047	21.33 ± 1.71 21.42 ± 1.54	1.55 ± 0.08 1.64 ± 0.08	$156k \pm 1.9k$ / 1000
Adj.-Matching $\lambda = 12500$	$\sqrt{2\eta_t}$	$\sqrt{2\eta_t}$ 0	0.882 ± 0.058 0.778 ± 0.050	20.49 ± 1.48 20.34 ± 1.49	1.50 ± 0.09 1.57 ± 0.09	

表 3 文本到图像生成中各种微调方法的度量。第二列和第三列分别显示微调和推理所用的噪声调度 $\sigma(t)$: $\sigma(t) = \sqrt{2\eta_t}$ 对应无记忆流匹配, $\sigma(t) = 0$ 对应流匹配常微分方程 (3)。置信区间表示估计值的标准误; 在三个独立的微调提示数据集 (每个规模为 40000) 上对微调算法运行 3 次计算得到。测试提示集规模为 1000, 且每次运行均不同。

Fine-tun. loss	Fine-tun. $\sigma(t)$	Generat. $\sigma(t)$	ImageReward $\uparrow$	ClipScore $\uparrow$	PickScore $\uparrow$	HPS v2 $\uparrow$	DreamSim diversity $\uparrow$	Runtime/ #iter.
ReFL	$\sqrt{2\eta_t}$ 0	$\sqrt{2\eta_t}$ 0	0.459 ± 0.096 0.330 ± 0.114	28.46 ± 0.25 29.63 ± 0.61	18.77 ± 0.09 19.08 ± 0.18	22.54 ± 0.17 22.46 ± 0.77	37.51 ± 3.50 39.51 ± 1.30	$43k \pm 2.7k$ / 1500
DRaFT-1	$\sqrt{2\eta_t}$ 0	$\sqrt{2\eta_t}$ 0	0.913 ± 0.068 0.626 ± 0.195	29.80 ± 0.22 30.48 ± 0.32	19.16 ± 0.06 18.91 ± 0.34	23.63 ± 0.16 21.92 ± 1.63	35.21 ± 1.93 38.52 ± 2.01	$35k \pm 1.5k$ / 1000
Draft-40	$\sqrt{2\eta_t}$ 0	$\sqrt{2\eta_t}$ 0	-1.427 ± 0.267 -0.097 ± 0.052	23.39 ± 1.72 29.12 ± 0.41	17.24 ± 0.45 18.97 ± 0.14	15.72 ± 1.80 21.93 ± 0.20	41.98 ± 2.14 46.35 ± 1.34	$49k \pm 1.4k$ / 500
Adj.-Match. $\lambda = 1000$	$\sqrt{2\eta_t}$	$\sqrt{2\eta_t}$ 0	0.107 ± 0.046 0.051 ± 0.044	29.37 ± 0.25 30.58 ± 0.17	19.05 ± 0.07 19.31 ± 0.07	22.79 ± 0.20 21.93 ± 0.23	46.38 ± 1.36 48.12 ± 1.56	
Adj.-Match. $\lambda = 2500$	$\sqrt{2\eta_t}$	$\sqrt{2\eta_t}$ 0	0.199 ± 0.068 0.106 ± 0.067	29.27 ± 0.21 30.43 ± 0.24	19.07 ± 0.10 19.32 ± 0.11	22.98 ± 0.30 22.16 ± 0.33	45.03 ± 1.61 47.61 ± 1.49	$39k \pm 0.5k$ / 250
Adj.-Match. $\lambda = 12500$	$\sqrt{2\eta_t}$	$\sqrt{2\eta_t}$ 0	0.299 ± 0.095 0.224 ± 0.051	29.61 ± 0.37 30.70 ± 0.23	19.26 ± 0.14 19.52 ± 0.11	23.67 ± 0.27 22.93 ± 0.21	43.36 ± 1.93 44.62 ± 1.79	
Cont. Adj. $\lambda = 12500$	$\sqrt{2\eta_t}$	$\sqrt{2\eta_t}$ 0	-0.910 ± 0.116 -0.681 ± 0.051	26.29 ± 0.44 28.50 ± 0.19	18.06 ± 0.16 18.69 ± 0.11	18.86 ± 0.88 19.90 ± 0.50	51.60 ± 1.97 50.87 ± 1.52	$51k \pm 0.3k$ / 250
Disc. Adj. $\lambda = 12500$	$\sqrt{2\eta_t}$	$\sqrt{2\eta_t}$ 0	-0.978 ± 0.123 -0.791 ± 0.065	26.68 ± 0.76 28.66 ± 0.33	18.51 ± 0.11 18.51 ± 0.11	18.53 ± 0.28 18.53 ± 0.28	55.95 ± 1.70 54.78 ± 2.00	$38k \pm 0.4k$ / 250

表 4 文本到图像生成中各种微调方法的补充度量, 与表 2 互补 (两表对应同一次运行)。第二列和第三列分别显示微调和推理所用的噪声调度 $\sigma(t)$: $\sigma(t) = \sqrt{2\eta_t}$ 对应无记忆流匹配, $\sigma(t) = 0$ 对应流匹配常微分方程 (3)。

w	Fine-tuning loss	#iter. / λ	Fine-tun. $\sigma(t)$	Sampl. $\sigma(t)$	ImageReward $\uparrow$	ClipScore $\uparrow$	PickScore $\uparrow$	HPS v2 $\uparrow$	DreamSim diversity $\uparrow$
0.0	None	N/A	N/A	$\sqrt{2\eta t}$ 0	-1.384 ± 0.040 -0.920 ± 0.042	24.15 ± 0.26 28.32 ± 0.22	17.25 ± 0.06 18.15 ± 0.07	16.19 ± 0.17 17.89 ± 0.16	53.60 ± 1.37 56.53 ± 1.52
0.0	DRaFT-1	1000	$\sqrt{2\eta t}$ 0	$\sqrt{2\eta t}$ 0	0.913 ± 0.068 0.626 ± 0.195	29.80 ± 0.22 30.48 ± 0.32	19.16 ± 0.06 18.91 ± 0.34	23.63 ± 0.16 21.92 ± 1.63	35.21 ± 1.93 38.52 ± 2.01
		2000	$\sqrt{2\eta t}$ 0	$\sqrt{2\eta t}$ 0	1.204 ± 0.046 1.052 ± 0.088	29.90 ± 0.43 30.65 ± 0.24	19.29 ± 0.12 19.27 ± 0.11	24.40 ± 0.27 23.81 ± 0.44	28.51 ± 1.68 32.11 ± 2.37
		3000	$\sqrt{2\eta t}$ 0	$\sqrt{2\eta t}$ 0	1.307 ± 0.041 1.173 ± 0.058	29.96 ± 0.22 30.86 ± 0.25	19.31 ± 0.06 19.37 ± 0.06	24.42 ± 0.13 24.17 ± 0.23	26.57 ± 1.32 29.69 ± 1.30
		4000	$\sqrt{2\eta t}$ 0	$\sqrt{2\eta t}$ 0	1.357 ± 0.039 1.251 ± 0.040	30.18 ± 0.24 30.95 ± 0.28	19.38 ± 0.08 19.37 ± 0.06	24.61 ± 0.17 24.37 ± 0.17	25.54 ± 0.99 27.39 ± 1.14
		1000	$\sqrt{2\eta t}$ 0	$\sqrt{2\eta t}$ 0	0.550 ± 0.043 0.454 ± 0.055	30.36 ± 0.22 31.41 ± 0.22	19.29 ± 0.08 19.57 ± 0.09	24.12 ± 0.17 23.29 ± 0.18	40.89 ± 1.50 43.10 ± 1.76
0.0	Adj.-Match.	2500	$\sqrt{2\eta t}$ 0	$\sqrt{2\eta t}$ 0	0.755 ± 0.040 0.671 ± 0.047	30.59 ± 0.40 31.64 ± 0.21	19.49 ± 0.10 19.71 ± 0.09	24.85 ± 0.23 24.12 ± 0.27	37.07 ± 1.47 39.88 ± 1.59
		12500	$\sqrt{2\eta t}$ 0	$\sqrt{2\eta t}$ 0	0.882 ± 0.058 0.778 ± 0.050	30.62 ± 0.30 31.65 ± 0.19	19.50 ± 0.09 19.76 ± 0.08	24.95 ± 0.28 24.49 ± 0.27	34.50 ± 1.33 37.24 ± 1.57
1.0	None	N/A	N/A	$\sqrt{2\eta t}$ 0	-0.269 ± 0.050 -0.123 ± 0.041	30.41 ± 0.22 31.83 ± 0.17	18.74 ± 0.07 19.28 ± 0.07	20.47 ± 0.18 20.95 ± 0.16	43.82 ± 1.24 42.59 ± 1.23
1.0	DRaFT-1	1000	$\sqrt{2\eta t}$ 0	$\sqrt{2\eta t}$ 0	1.123 ± 0.051 0.856 ± 0.167	32.06 ± 0.19 32.32 ± 0.25	19.69 ± 0.06 19.38 ± 0.34	24.56 ± 0.17 22.88 ± 1.54	28.25 ± 1.55 29.98 ± 1.86
		2000	0	0	1.177 ± 0.053	32.36 ± 0.18	19.67 ± 0.08	24.48 ± 0.28	25.09 ± 1.82
		3000	0	0	1.255 ± 0.038	32.36 ± 0.19	19.70 ± 0.06	24.64 ± 0.17	23.24 ± 1.19
		4000	0	0	1.296 ± 0.033	32.30 ± 0.19	19.68 ± 0.06	24.71 ± 0.14	21.54 ± 0.96
		1000	0	0	0.782 ± 0.044	33.05 ± 0.22	20.20 ± 0.09	24.81 ± 0.18	32.67 ± 1.26
1.0	Adj.-Match.	2500	$\sqrt{2\eta t}$ 0	$\sqrt{2\eta t}$ 0	1.027 ± 0.038 0.910 ± 0.040	32.85 ± 0.21 33.20 ± 0.17	20.08 ± 0.08 20.29 ± 0.09	25.88 ± 0.20 25.39 ± 0.24	29.83 ± 1.00 30.34 ± 1.51
		12500	0	0	0.985 ± 0.041	33.10 ± 0.18	20.28 ± 0.08	25.61 ± 0.27	28.86 ± 1.37
4.0	None	N/A	N/A	$\sqrt{2\eta t}$ 0	0.277 ± 0.043 0.209 ± 0.046	32.68 ± 0.18 32.83 ± 0.17	19.50 ± 0.07 19.79 ± 0.07	22.29 ± 0.16 22.30 ± 0.17	35.12 ± 0.92 32.05 ± 1.05
4.0	DRaFT-1	1000	$\sqrt{2\eta t}$ 0	$\sqrt{2\eta t}$ 0	1.062 ± 0.045 0.604 ± 0.395	32.29 ± 0.16 31.80 ± 0.86	19.48 ± 0.06 19.09 ± 0.53	23.67 ± 0.13 21.69 ± 2.10	25.03 ± 1.32 25.92 ± 2.57
		2000	0	0	1.112 ± 0.046	32.29 ± 0.20	19.34 ± 0.11	23.31 ± 0.22	21.02 ± 1.67
		3000	0	0	1.151 ± 0.036	32.31 ± 0.21	19.36 ± 0.06	23.29 ± 0.14	19.53 ± 1.24
		4000	0	0	1.172 ± 0.040	32.20 ± 0.22	19.30 ± 0.07	23.20 ± 0.15	18.45 ± 1.06
		1000	0	0	0.852 ± 0.046	33.50 ± 0.22	20.31 ± 0.08	24.97 ± 0.19	25.83 ± 0.82
4.0	Adj.-Match.	2500	$\sqrt{2\eta t}$ 0	$\sqrt{2\eta t}$ 0	1.052 ± 0.039 0.942 ± 0.042	33.51 ± 0.19 33.61 ± 0.19	20.15 ± 0.07 20.35 ± 0.08	25.56 ± 0.18 25.34 ± 0.21	26.21 ± 0.73 24.30 ± 0.86
		12500	0	0	1.007 ± 0.052	33.48 ± 0.20	20.29 ± 0.08	25.50 ± 0.29	23.48 ± 0.81

表 5 使用无分类器引导 (CFG; Ho 和 Salimans (2022)) 时的评估度量。

LR / Adam β_1	Fine-tuning loss	Fine-tun. $\sigma(t)$	Generat. $\sigma(t)$	ImageReward $\uparrow$	ClipScore $\uparrow$	PickScore $\uparrow$	HPS v2 $\uparrow$	DreamSim diversity $\uparrow$
3×10^{-5}	DRaFT-1	$\sqrt{2\eta t}$	$\sqrt{2\eta t}$	1.467 ± 0.029	30.28 ± 0.56	19.37 ± 0.09	24.70 ± 0.15	21.20 ± 0.93
/ 0.97	Adj.-Match. $\lambda = 12500$	$\sqrt{2\eta t}$	$\sqrt{2\eta t}$	1.130 ± 0.034	31.01 ± 0.27	19.60 ± 0.08	25.01 ± 0.25	26.73 ± 0.88
2×10^{-5}	Disc. Adj.	$\sqrt{2\eta t}$	$\sqrt{2\eta t}$	-1.186 ± 0.553	21.95 ± 4.29	16.94 ± 0.95	12.34 ± 4.40	28.33 ± 10.26
/ 0.95	$\lambda = 12500$	0	0	-0.961 ± 0.653	24.07 ± 4.71	17.86 ± 1.17	15.93 ± 5.80	33.62 ± 7.80

表 6 替代优化超参数 (学习率和 Adam β_1 .) 的度量。

Fine-tuning loss	Fine-tuning $\sigma(t)$	Generative $\sigma(t)$	ImageReward $\uparrow$	ClipScore $\uparrow$	PickScore $\uparrow$	HPS v2 $\uparrow$	DreamSim diversity $\uparrow$
Adj.-Matching $\lambda = 12500$	1	1 0	0.009 $\pm$ 0.077 0.454 $\pm$ 0.055	29.18 $\pm$ 0.51 31.41 $\pm$ 0.22	18.66 $\pm$ 0.09 19.57 $\pm$ 0.09	20.75 $\pm$ 0.32 23.29 $\pm$ 0.18	41.33 $\pm$ 1.24 43.10 $\pm$ 1.76
Adj.-Matching $\lambda = 12500$	$\sqrt{2\eta_t}$	$\sqrt{2\eta_t}$ 0	0.882 $\pm$ 0.058 0.778 $\pm$ 0.050	30.62 $\pm$ 0.30 31.65 $\pm$ 0.19	19.50 $\pm$ 0.09 19.76 $\pm$ 0.08	24.95 $\pm$ 0.28 24.49 $\pm$ 0.27	34.50 $\pm$ 1.33 37.24 $\pm$ 1.57

表 7 与替代微调噪声调度 $\sigma(t) = 1$ 的比较。可见初始值函数偏差（第 4.2 节）导致模型未获得高奖励函数值（ImageReward 为微调所用奖励函数）。除多样性外，其其他度量性能也低于使用无记忆噪声调度微调的结果。

#sampl. timesteps	Fine-tuning loss	Fine-tun. $\sigma(t)$	Sampl. $\sigma(t)$	ImageReward $\uparrow$	ClipScore $\uparrow$	PickScore $\uparrow$	HPS v2 $\uparrow$	DreamSim diversity $\uparrow$
10	None (Base)	N/A	$\sqrt{2\eta_t}$ 0	-2.279 $\pm$ 0.001 -1.386 $\pm$ 0.040	13.99 $\pm$ 0.12 26.26 $\pm$ 0.24	14.98 $\pm$ 0.05 17.64 $\pm$ 0.07	7.37 $\pm$ 0.10 14.92 $\pm$ 0.17	5.07 $\pm$ 0.13 51.26 $\pm$ 1.38
	DRaFT-1	$\sqrt{2\eta_t}$ 0	$\sqrt{2\eta_t}$ 0	1.033 $\pm$ 0.051 1.236 $\pm$ 0.038	25.98 $\pm$ 0.25 31.54 $\pm$ 0.27	18.28 $\pm$ 0.07 19.53 $\pm$ 0.07	22.08 $\pm$ 0.18 24.47 $\pm$ 0.19	14.47 $\pm$ 0.67 24.78 $\pm$ 0.88
	Adj.-Match. $\lambda = 12500$	$\sqrt{2\eta_t}$	$\sqrt{2\eta_t}$ 0	-2.104 $\pm$ 0.074 0.607 $\pm$ 0.055	17.12 $\pm$ 0.56 31.36 $\pm$ 0.20	15.76 $\pm$ 0.20 19.56 $\pm$ 0.08	11.48 $\pm$ 1.03 23.23 $\pm$ 0.28	9.88 $\pm$ 0.81 33.75 $\pm$ 1.48
20	None (Base)	N/A	$\sqrt{2\eta_t}$ 0	-2.275 $\pm$ 0.002 -1.017 $\pm$ 0.055	14.58 $\pm$ 0.13 27.92 $\pm$ 0.19	15.07 $\pm$ 0.05 18.01 $\pm$ 0.07	7.47 $\pm$ 0.10 17.17 $\pm$ 0.15	11.27 $\pm$ 0.33 54.69 $\pm$ 1.45
	DRaFT-1	$\sqrt{2\eta_t}$ 0	$\sqrt{2\eta_t}$ 0	1.301$\pm$0.039 1.255 $\pm$ 0.038	27.09 $\pm$ 0.24 31.14 $\pm$ 0.25	18.93 $\pm$ 0.07 19.43 $\pm$ 0.06	23.78 $\pm$ 0.20 24.52 $\pm$ 0.16	21.05 $\pm$ 1.12 26.15 $\pm$ 1.11
	Adj.-Match. $\lambda = 12500$	$\sqrt{2\eta_t}$	$\sqrt{2\eta_t}$ 0	-0.032 $\pm$ 0.072 0.768 $\pm$ 0.048	25.07 $\pm$ 0.27 31.70$\pm$0.17	18.01 $\pm$ 0.07 19.73$\pm$0.08	20.75 $\pm$ 0.23 24.30 $\pm$ 0.26	29.06 $\pm$ 2.34 35.90 $\pm$ 1.52
40	None (Base)	N/A	$\sqrt{2\eta_t}$ 0	-1.384 $\pm$ 0.040 -0.920 $\pm$ 0.042	24.15 $\pm$ 0.26 28.32 $\pm$ 0.22	17.25 $\pm$ 0.06 18.15 $\pm$ 0.07	16.19 $\pm$ 0.17 17.89 $\pm$ 0.16	53.60 $\pm$ 1.37 56.53$\pm$1.52
	DRaFT-1	$\sqrt{2\eta_t}$ 0	$\sqrt{2\eta_t}$ 0	1.357$\pm$0.039 1.251 $\pm$ 0.040	30.18 $\pm$ 0.24 30.95 $\pm$ 0.28	19.38 $\pm$ 0.08 19.37 $\pm$ 0.06	24.61 $\pm$ 0.17 24.37 $\pm$ 0.17	25.54 $\pm$ 0.99 27.39 $\pm$ 1.14
	Adj.-Match. $\lambda = 12500$	$\sqrt{2\eta_t}$	$\sqrt{2\eta_t}$ 0	0.882 $\pm$ 0.058 0.778 $\pm$ 0.050	30.62 $\pm$ 0.30 31.65$\pm$0.19	19.50 $\pm$ 0.09 19.76$\pm$0.08	24.95$\pm$0.28 24.49 $\pm$ 0.27	34.50 $\pm$ 1.33 37.24 $\pm$ 1.57
100	None (Base)	N/A	$\sqrt{2\eta_t}$ 0	-0.881 $\pm$ 0.041 -0.881 $\pm$ 0.036	27.83 $\pm$ 0.19 28.65 $\pm$ 0.18	18.10 $\pm$ 0.07 18.22 $\pm$ 0.06	18.43 $\pm$ 0.17 18.20 $\pm$ 0.17	57.21$\pm$1.50 57.73$\pm$1.68
	DRaFT-1	$\sqrt{2\eta_t}$ 0	$\sqrt{2\eta_t}$ 0	1.343$\pm$0.040 1.239 $\pm$ 0.037	30.64 $\pm$ 0.20 30.74 $\pm$ 0.28	19.38 $\pm$ 0.08 19.33 $\pm$ 0.06	24.37 $\pm$ 0.17 24.24 $\pm$ 0.17	25.51 $\pm$ 1.10 28.70 $\pm$ 1.11
	Adj.-Match. $\lambda = 12500$	$\sqrt{2\eta_t}$	$\sqrt{2\eta_t}$ 0	0.892 $\pm$ 0.044 0.779 $\pm$ 0.048	31.23 $\pm$ 0.23 31.64$\pm$0.17	19.65$\pm$0.08 19.76$\pm$0.08	24.92$\pm$0.23 24.57 $\pm$ 0.25	35.13 $\pm$ 1.40 38.26 $\pm$ 1.65
200	None (Base)	N/A	$\sqrt{2\eta_t}$ 0	-0.848 $\pm$ 0.048 -0.871 $\pm$ 0.036	28.37 $\pm$ 0.21 28.50 $\pm$ 0.18	18.27 $\pm$ 0.08 18.23 $\pm$ 0.06	18.56 $\pm$ 0.19 18.25 $\pm$ 0.14	58.00$\pm$1.58 57.84$\pm$1.60
	DRaFT-1	$\sqrt{2\eta_t}$ 0	$\sqrt{2\eta_t}$ 0	1.331$\pm$0.044 1.222 $\pm$ 0.042	30.69 $\pm$ 0.23 30.77 $\pm$ 0.27	19.36 $\pm$ 0.07 19.32 $\pm$ 0.06	24.21 $\pm$ 0.17 24.18 $\pm$ 0.16	26.41 $\pm$ 1.18 29.09 $\pm$ 1.07
	Adj.-Match. $\lambda = 12500$	$\sqrt{2\eta_t}$	$\sqrt{2\eta_t}$ 0	0.869 $\pm$ 0.062 0.766 $\pm$ 0.050	31.33 $\pm$ 0.21 31.61$\pm$0.16	19.68$\pm$0.09 19.75$\pm$0.08	24.81$\pm$0.30 24.52 $\pm$ 0.24	35.90 $\pm$ 1.55 38.60 $\pm$ 1.38

表 8 不同采样步数下的性能度量。仅对采样步数进行消融；所有情况下使用的微调模型均为采用 40 步微调的模型。




图 8 在十个选定提示下，使用无分类器引导（ $w = 1$ ）和 $\sigma(t) = 0$ 生成的样本。每行对应一个不同的提示，每张图像对应一个在不同模型间保持一致的随机种子。



图 9 在十个包含人物的选定提示下，使用无分类器引导 ($w = 1$) 和 $\sigma(t) = 0$ 生成的样本。每行对应一个不同的提示，每张图像对应一个在不同模型间保持一致的随机种子。




图 10 在七个选定提示下，不使用引导 ($w = 0$) 和 $\sigma(t) = 0$ 生成的样本。每行对应一种不同的微调算法。提示：“棕榈树矢量图海边风景海报”、“卡尤科斯海滩旅馆”、“快乐夏日生活——阿罗哈花与甜瓜——图案金属印刷品”、“华沙老城城堡广场”、“吹肥皂泡的搞笑女孩。高质量照片”、“穿运动衫的哥伦比亚男子站在黄墙前，手放在耳边听东西”、“戴黑色兜帽面具的化妆舞会男子”。




图 11 在七个选定提示下，不使用引导 ($w = 0$) 和 $\sigma(t) = \sqrt{2\eta_t}$ 生成的样本。每行对应一种不同的微调算法。提示与图 10 相同。

B DDIM 与流匹配上的结果

B.1 DDIM 的连续时间极限

The DDIM inference update (Song et al., 2021a, Eq. 12) is

$$x_{k+1} = \sqrt{\bar{\alpha}_{k+1}} \left(\frac{x_k - \sqrt{1 - \bar{\alpha}_k} \epsilon(x_k, k)}{\sqrt{\bar{\alpha}_k}} \right) + \sqrt{1 - \bar{\alpha}_{k+1} - \sigma_k^2} \epsilon(x_k, k) + \sigma_k \epsilon_k, \quad x_K \sim N(0, I). \quad (44)$$

If we let $\Delta \bar{\alpha}_k = \bar{\alpha}_{k+1} - \bar{\alpha}_k$, we have that

$$\sqrt{\frac{\bar{\alpha}_{k+1}}{\bar{\alpha}_k}} = \sqrt{\frac{\bar{\alpha}_k + \bar{\alpha}_{k+1} - \bar{\alpha}_k}{\bar{\alpha}_k}} = \sqrt{1 + \frac{\bar{\alpha}_{k+1} - \bar{\alpha}_k}{\bar{\alpha}_k}} = \sqrt{1 + \frac{\Delta \bar{\alpha}_k}{\bar{\alpha}_k}} \approx 1 + \frac{\Delta \bar{\alpha}_k}{2\bar{\alpha}_k}, \quad (45)$$

其中我们使用了 $\sqrt{1+x}$ 的一阶泰勒近似。并且

$$\begin{aligned} & -\sqrt{\frac{\bar{\alpha}_{k+1}}{\bar{\alpha}_k}} (1 - \bar{\alpha}_k) + \sqrt{1 - \bar{\alpha}_{k+1} - \sigma_k^2} = -\sqrt{\left(1 + \frac{\Delta \bar{\alpha}_k}{\bar{\alpha}_k}\right) (1 - \bar{\alpha}_k)} + \sqrt{1 - \bar{\alpha}_{k+1} - \sigma_k^2} \\ & = -\sqrt{1 + \frac{\Delta \bar{\alpha}_k}{\bar{\alpha}_k} - \bar{\alpha}_k - \Delta \bar{\alpha}_k} + \sqrt{1 - \bar{\alpha}_{k+1} - \sigma_k^2} = -\sqrt{1 - \bar{\alpha}_{k+1} + \frac{\Delta \bar{\alpha}_k}{\bar{\alpha}_k}} + \sqrt{1 - \bar{\alpha}_{k+1} - \sigma_k^2} \\ & = \sqrt{1 - \bar{\alpha}_{k+1}} \left(-\sqrt{1 + \frac{\Delta \bar{\alpha}_k}{\bar{\alpha}_k(1 - \bar{\alpha}_{k+1})}} + \sqrt{1 - \frac{\sigma_k^2}{1 - \bar{\alpha}_{k+1}}} \right) \approx \sqrt{1 - \bar{\alpha}_{k+1}} \left(-\left(1 + \frac{\Delta \bar{\alpha}_k}{2\bar{\alpha}_k(1 - \bar{\alpha}_{k+1})}\right) + 1 - \frac{\sigma_k^2}{2(1 - \bar{\alpha}_{k+1})} \right) \\ & = -\left(\frac{\Delta \bar{\alpha}_k}{2\bar{\alpha}_k} + \frac{\sigma_k^2}{2}\right) \frac{1}{\sqrt{1 - \bar{\alpha}_{k+1}}}, \end{aligned} \quad (46)$$

其中我们使用了相同的一阶泰勒近似。因此，在一阶近似下，(44) 等价于

$$x_{k+1} = \left(1 + \frac{\Delta \bar{\alpha}_k}{2\bar{\alpha}_k}\right) x_k - \left(\frac{\Delta \bar{\alpha}_k}{2\bar{\alpha}_k} + \frac{\sigma_k^2}{2}\right) \frac{\epsilon(x_k, k)}{\sqrt{1 - \bar{\alpha}_{k+1}}} + \sigma_k \epsilon_k, \quad x_K \sim N(0, I). \quad (47)$$

如果我们稍微修改符号，可以将其改写为

$$X_{(k+1)h} = \left(1 - \frac{h\dot{\bar{\alpha}}_{kh}}{2\bar{\alpha}_{kh}}\right) X_{kh} + \left(\frac{h\dot{\bar{\alpha}}_{kh}}{2\bar{\alpha}_{kh}} - \frac{h\sigma(kh)^2}{2}\right) \frac{\epsilon(X_{kh}, kh)}{\sqrt{1 - \bar{\alpha}_{kh}}} + \sqrt{h}\sigma(kh)\epsilon_k, \quad X_0 \sim N(0, I). \quad (48)$$

为了从 (47) 过渡到 (48)，我们引入了一个连续时间变量和步长 $h = 1/K$ ，并将增量 $h\bar{\alpha}_k$ 视为近似等于 h 乘以 $\bar{\alpha}$ 的导数。我们还将 σ_k 与 $\sigma(kh)$ 等同起来，其中 $\sigma(kh)$ 扮演扩散系数的角色。注意，方程 (48) 可以逆向 $\sigma(kh)$ 推导为以下随机微分方程的欧拉-丸山离散化

$$dX_t = \left(-\frac{\dot{\bar{\alpha}}_t}{2\bar{\alpha}_t} + \left(\frac{\dot{\bar{\alpha}}_t}{2\bar{\alpha}_t} - \frac{\sigma(t)^2}{2}\right) \frac{\epsilon(X_t, t)}{\sqrt{1 - \bar{\alpha}_t}}\right) dt + \sigma(t) dB_t, \quad X_0 \sim N(0, I). \quad (49)$$

B.2 前向与后向随机微分方程

Let $(\kappa_t)_{t \in [0,1]}$ and $(\eta_t)_{t \in [0,1]}$ such that

$$\forall t \in [0, 1], \quad \eta_t \geq 0, \quad \int_0^1 \kappa_{1-s} ds = +\infty, \quad 2 \int_0^1 \eta_{1-t'} \exp\left(-2 \int_{t'}^t \kappa_{1-s} ds\right) dt' = 1. \quad (50)$$

如表 1 所示，DDIM 对应于 $\kappa_t = \frac{\dot{\bar{\alpha}}_t}{2\bar{\alpha}_t}$, $\eta_t = \frac{\dot{\bar{\alpha}}_t}{2 - \bar{\alpha}_t}$ ，而流匹配对应于 $\kappa_t = \frac{\dot{\bar{\alpha}}_t}{\alpha_t}$, $\eta_t = \beta_t \left(\frac{\dot{\bar{\alpha}}_t}{\alpha_t} \beta_t - \dot{\beta}_t\right)$.

引理 1 (DDIM 和流匹配满足条件 (50))。DDIM 和流匹配对 $(\kappa_t)_{t \in [0, 1]}$ 和 $(\eta_t)_{t \in [0, 1]}$ 的选择满足条件 (50)。对于 DDIM，我们有 $\int_0^t \kappa_{1-s} ds = -\frac{1}{2}$

$$\begin{aligned} \log \bar{\alpha}_{1-t} & \implies \int_0^1 \kappa_{1-s} ds = +\infty, \\ 2 \int_0^t \eta_{t'} \exp\left(-2 \int_{t'}^t \kappa_s ds\right) dt' & = 1 - \bar{\alpha}_{1-t} \implies 2 \int_0^1 \eta_{t'} \exp\left(-2 \int_{t'}^t \kappa_s ds\right) dt' = 1. \end{aligned} \quad (51)$$

For Flow Matching,

$$\int_0^t \kappa_{1-s} ds = -\log \alpha_{1-t} \implies \int_0^1 \kappa_{1-s} ds = +\infty, \quad (52)$$

$$2 \int_0^t \eta_{t'} \exp\left(-2 \int_{t'}^t \kappa_s ds\right) dt' = \beta_{1-t}^2 \implies 2 \int_0^1 \eta_{t'} \exp\left(-2 \int_{t'}^t \kappa_s ds\right) dt' = 1. \quad (53)$$

前向与后向随机微分方程 考虑前向和后向随机微分方程

$$d\vec{X}_t = -\kappa_{1-t}\vec{X}_t dt + \sqrt{2\eta_{1-t}} dB_t, \quad \vec{X}_0 \sim p_{\text{data}}, \quad (54)$$

$$dX_t = (\kappa_t X_t + 2\eta_t \mathfrak{s}(X_t, t))dt + \sqrt{2\eta_t} dB_t, \quad X_0 \sim N(0, I), \quad (55)$$

其中令 $\bar{p}_t$ 为 $\vec{X}_t$ 的密度, 并将得分函数定义为 $\mathfrak{s}(x, t) := \nabla \log \bar{p}_{1-t}(x)$ 。类似地, 令 p_t 为 X_t 的密度, 且 p_t 满足福克-普朗克方程:

$$\partial_t \bar{p}_t = \nabla \cdot (\kappa_{1-t} x \bar{p}_t) + \eta_{1-t} \Delta \bar{p}_t, \quad \bar{p}_0 = p_{\text{data}}, \quad (56)$$

$$\partial_t p_t = \nabla \cdot ((-\kappa_t x - 2\eta_t \nabla \log \bar{p}_{1-t}(X_t))p_t) + \eta_t \Delta p_t, \quad p_0 = N(0, I). \quad (57)$$

引理 2 (正向随机微分方程的解)。设 $(\kappa_t)_{t \geq 0}, (\eta_t)_{t \geq 0}$ 满足 $\eta_t \geq 0$, 且 $(\xi_t)_{t \geq 0}$ 为任意。随机微分方程的解 $\vec{X}_t$

$$d\vec{X}_t = (-\kappa_{1-t}\vec{X}_t + \xi_t) dt + \sqrt{2\eta_{1-t}} dB_t, \quad \vec{X}_0 \sim p_{\text{data}} \quad (58)$$

为

$$\vec{X}_t = \vec{X}_0 \exp\left(-\int_0^t \kappa_{1-s} ds\right) + \int_0^t \exp\left(-\int_{t'}^t \kappa_{1-s} ds\right) \xi_{1-t'} dt' + \int_0^t \sqrt{2\eta_{1-t'}} \exp\left(-\int_{t'}^t \kappa_{1-s} ds\right) dB_{t'}, \quad (59)$$

其分布与随机变量相同

$$\begin{aligned} \hat{X}_t &= \vec{X}_0 \exp\left(-\int_0^t \kappa_{1-s} ds\right) + \int_0^t \exp\left(-\int_{t'}^t \kappa_{1-s} ds\right) \xi_{1-t'} dt' + \sqrt{2 \int_0^t \eta_{1-t'} \exp\left(-2 \int_{t'}^t \kappa_{1-s} ds\right) dt'} \epsilon, \\ \epsilon &\sim N(0, I). \end{aligned} \quad (60)$$

Applying Lemma 2 with $\xi_t \equiv 0$, we obtain that $\bar{p}_1$ is also the distribution of

$$\hat{X}_1 = \vec{X}_0 \exp\left(-\int_0^t \kappa_{1-s} ds\right) + \sqrt{2 \int_0^t \eta_{1-t'} \exp\left(-2 \int_{t'}^t \kappa_{1-s} ds\right) dt'} \epsilon = \epsilon, \quad (61)$$

其中 $\epsilon \sim N(0, I)$ 。(61) 中的第三个等式由 (50) 成立。因此我们得到 $\bar{p}_1 = N(0, I)$ 。还需注意

$$\partial_t \bar{p}_{1-t} = -\nabla \cdot (\kappa_t x \bar{p}_{1-t}) - \eta_t \Delta \bar{p}_{1-t} = -\nabla \cdot ((-\kappa_t x - 2\eta_t \nabla \log \bar{p}_{1-t}(x)) \bar{p}_{1-t}) + \eta_t \Delta \bar{p}_{1-t} \quad (62)$$

因此, $\bar{p}_{1-t}$ 是反向福克-普朗克方程 (57) 的一个解, 这证明了以下结论:

命题 3 (边缘分布相等)。对于任意时间 $t \in [0, 1]$, 前向与后向随机微分方程的解 $\vec{X}_t, X_t$ 的密度在时间翻转下相等: $p_t = \bar{p}_{1-t}$ 。

具有任意噪声调度的前向与后向随机微分方程 接下来, 我们考察以下一对前向后向随机微分方程:

$$d\vec{X}_t = (-\kappa_{1-t}\vec{X}_t + (\frac{\sigma(1-t)^2}{2} - \eta_{1-t})\mathfrak{s}(\vec{X}_t, 1-t)) dt + \sigma(1-t) dB_t, \quad \vec{X}_0 \sim p_{\text{data}}, \quad (63)$$

$$dX_t = (\kappa_t X_t + (\frac{\sigma(t)^2}{2} + \eta_t)\mathfrak{s}(X_t, t))dt + \sigma(t) dB_t, \quad X_0 \sim N(0, I), \quad (64)$$

此处, 得分函数 $\mathfrak{s}$ 与式 (64) 中的向量场相同。注意, 方程 (54) - (55) 是 (63) - (64) 在 $\sigma(t) = \sqrt{2\eta_t}$ 时的特例。方程 (63) - (64) 的福克-普朗克方程为:

$$\partial_t \bar{p}_t = \nabla \cdot ((\kappa_{1-t} x + (\frac{\sigma(1-t)^2}{2} + \eta_{1-t})\mathfrak{s}(X_t, t))\bar{p}_t) + \eta_{1-t} \Delta \bar{p}_t, \quad \bar{p}_0 = p_{\text{data}}, \quad (65)$$

$$\partial_t p_t = \nabla \cdot ((-\kappa_t x - (\frac{\sigma(t)^2}{2} + \eta_t)\mathfrak{s}(X_t, t))p_t) + \frac{\sigma(t)^2}{2} \Delta p_t, \quad p_0 = N(0, I). \quad (66)$$

容易看出, 对于任意 σ , 方程 (65) - (66) 的解 $\bar{p}_t$ 和 p_t 也是方程 (56) - (57) 的解。因此, 对于所有噪声调度 σ , 边缘分布 $\vec{X}_t$ 和 X_t 具有相同分布, 并且在时间翻转下彼此相等。

轨迹上分布相等 命题 3 的结果可以进一步加强：

命题 4 (轨迹上分布相等)。 设

$\vec{X}, X$ 为具有任意噪声调度的随机微分方程 (

63) - (64) 的解。对于任意时间序列 $(t_i)_{0 \leq i \leq I}$, $(\vec{X}_{t_i})_{0 \leq i \leq I}$ 的联合分布等于 $(X_{1-t_i})_{0 \leq i \leq I}$ 的联合分布, 等价地, 前向过程与后向过程 $\vec{\mathbb{P}}, \mathbb{P}$ 的概率测度 $\vec{X}, X$ 在时间方向翻转下相等。

该结果表明, 从后向过程中采样轨迹等价于从前向过程中采样轨迹然后翻转其顺序。

B.2.1 引理 1 的证明

如表 1 所示, DDIM 对应于 $\kappa_t =$

$$\frac{\dot{\bar{\alpha}}_t}{2\bar{\alpha}_t}, \eta_t = \frac{\dot{\bar{\alpha}}_t}{2\bar{\alpha}_t}。因此, \eta_t \geq 0 因为 \bar{\alpha}_t 是递增的, 并且$$

$$\begin{aligned} \int_0^t \kappa_{1-s} ds &= \int_0^t \frac{\dot{\bar{\alpha}}_{1-s}}{2\bar{\alpha}_{1-s}} ds = -\frac{1}{2} \int_0^t \partial_s \log \bar{\alpha}_{1-s} ds = -\frac{1}{2} (\log \bar{\alpha}_{1-t} - \log \bar{\alpha}_1) = -\frac{1}{2} \log \bar{\alpha}_{1-t}, \\ \implies \int_0^1 \kappa_{1-s} ds &= -\frac{1}{2} \log \bar{\alpha}_0 = +\infty \end{aligned} \quad (67)$$

$$\begin{aligned} 2 \int_0^t \eta_{t'} \exp(-2 \int_{t'}^t \kappa_s ds) dt' &= \int_0^t \frac{\dot{\bar{\alpha}}_{1-t'}}{\bar{\alpha}_{1-t'}} \exp(-\int_{t'}^t \frac{\dot{\bar{\alpha}}_{1-s}}{\bar{\alpha}_{1-s}} ds) dt' \\ &= \int_0^t \frac{\dot{\bar{\alpha}}_{1-t'}}{\bar{\alpha}_{1-t'}} \frac{\bar{\alpha}_{1-t}}{\bar{\alpha}_{1-t'}} dt' = \bar{\alpha}_{1-t} \int_0^t \partial_{t'} \left(\frac{1}{\bar{\alpha}_{1-t'}} \right) dt' = \bar{\alpha}_{1-t} \left(\frac{1}{\bar{\alpha}_{1-t}} - \frac{1}{\bar{\alpha}_1} \right) = 1 - \bar{\alpha}_{1-t}, \\ \implies 2 \int_0^1 \eta_{t'} \exp(-2 \int_{t'}^t \kappa_s ds) dt' &= 1 - \bar{\alpha}_0 = 1. \end{aligned} \quad (68)$$

其中我们利用了 $\bar{\alpha}_1 = 1$ 和 $\bar{\alpha}_0 = 0$ 。而流匹配对应于 $\kappa_t =$ 。我们有 $\eta_t \geq 0$ 因为 $\frac{\dot{\alpha}_t}{\alpha_t}, \eta_t = \beta_t \left(\frac{\dot{\alpha}_t}{\alpha_t} \beta_t - \dot{\beta}_t \right)$ α_t 是递增的且 β_t 是递减的, 并且

$$\begin{aligned} \int_0^t \kappa_{1-s} ds &= \int_0^t \frac{\dot{\alpha}_{1-s}}{\alpha_{1-s}} ds = -\int_0^t \partial_s \log \alpha_{1-s} ds = -(\log \alpha_{1-t} - \log \alpha_1) = -\log \alpha_{1-t}, \\ \implies \int_0^1 \kappa_{1-s} ds &= -\log \alpha_0 = +\infty, \end{aligned} \quad (69)$$

并且

$$\begin{aligned} 2 \int_0^t \eta_{1-t'} \exp(-2 \int_{t'}^t \kappa_{1-s} ds) dt' &= 2 \int_0^t \beta_{1-t'} \left(\frac{\dot{\alpha}_{1-t'}}{\alpha_{1-t'}} \beta_{1-t'} - \dot{\beta}_{1-t'} \right) \exp(-2 \int_{t'}^t \frac{\dot{\alpha}_{1-s}}{\alpha_{1-s}} ds) dt' \\ &= 2 \int_0^t \beta_{1-t'} \left(\frac{\dot{\alpha}_{1-t'}}{\alpha_{1-t'}} \beta_{1-t'} - \dot{\beta}_{1-t'} \right) \left(\frac{\alpha_{1-t}}{\alpha_{1-t'}} \right)^2 dt', \end{aligned} \quad (70)$$

为了展开右侧, 注意通过分部积分,

$$\begin{aligned} \int_0^t \dot{\beta}_{1-t'} \beta_{1-t'} \left(\frac{\alpha_{1-t}}{\alpha_{1-t'}} \right)^2 dt' &= -\int_0^t \partial_{t'} \left(\frac{\beta_{1-t'}^2}{2} \right) \left(\frac{\alpha_{1-t}}{\alpha_{1-t'}} \right)^2 dt' \\ &= -\left[\frac{\beta_{1-t'}^2}{2} \left(\frac{\alpha_{1-t}}{\alpha_{1-t'}} \right)^2 \right]_0^1 + \int_0^t \frac{\beta_{1-t'}^2}{2} \partial_{t'} \left(\frac{\alpha_{1-t}}{\alpha_{1-t'}} \right)^2 dt' = -\left[\frac{\beta_{1-t'}^2}{2} \left(\frac{\alpha_{1-t}}{\alpha_{1-t'}} \right)^2 \right]_0^t + \int_0^t \beta_{1-t'}^2 \frac{\alpha_{1-t}^2 \dot{\alpha}_{1-t'}}{\alpha_{1-t'}^3} dt'. \end{aligned} \quad (71)$$

如果我们将代入 (70) 的右侧, 我们得到

$$2 \int_0^t \eta_{1-t'} \exp(-2 \int_{t'}^t \kappa_{1-s} ds) dt' = \left[\beta_{1-t'}^2 \left(\frac{\alpha_{1-t}}{\alpha_{1-t'}} \right)^2 \right]_0^t = \beta_{1-t}^2 - \beta_1^2 \left(\frac{\alpha_{1-t}}{\alpha_1} \right)^2 = \beta_{1-t}^2, \quad (72)$$

$$\implies 2 \int_0^1 \eta_{1-t'} \exp(-2 \int_{t'}^t \kappa_{1-s} ds) dt' = \beta_1^2 = 1. \quad (73)$$

其中我们利用了 $\beta_1 = 0, \alpha_1 = 1$ 。

B.2.2 引理 2 的证明

我们可以通过参数变易法求解该方程。为了简化记号, 我们将 κ_{1-s}, η_{1-s} 和 ξ_{1-s} 替换为 κ_s, η_s 和 ξ_s 。定义 $f(\vec{X}_t, t) = \vec{X}_t \exp(\int_0^t \kappa_{1-s} ds)$, 我们得到

$$\begin{aligned} df(\vec{X}_t, t) &= \kappa_{1-t} \vec{X}_t \exp\left(\int_0^t \kappa_{1-s} ds\right) dt + \exp\left(\int_0^t \kappa_{1-s} ds\right) d\vec{X}_t \\ &= \kappa_{1-t} \vec{X}_t \exp\left(\int_0^t \kappa_{1-s} ds\right) dt + \exp\left(\int_0^t \kappa_{1-s} ds\right) ((-\kappa_{1-t} \vec{X}_t + \xi_{1-t}) dt + \sqrt{2\eta_{1-t}} dB_t) \\ &= \exp\left(\int_0^t \kappa_{1-s} ds\right) \xi_{1-t} dt + \sqrt{2\eta_t} \exp\left(\int_0^t \kappa_{1-s} ds\right) dB_t. \end{aligned} \quad (74)$$

从 0 到 t 积分, 可得

$$\vec{X}_t \exp \left(\int_0^t \kappa_{1-s} ds \right) = \vec{X}_0 + \int_0^t \exp \left(\int_0^{t'} \kappa_{1-s} ds \right) \xi_{1-t'} dt' + \int_0^t \sqrt{2\eta_{1-t'}} \exp \left(\int_0^{t'} \kappa_{1-s} ds \right) dB_{t'}, \quad (75)$$

$$\iff \vec{X}_t = \vec{X}_0 \exp \left(- \int_0^t \kappa_{1-s} ds \right) + \int_0^t \exp \left(- \int_{t'}^t \kappa_{1-s} ds \right) \xi_{1-t'} dt' + \int_0^t \sqrt{2\eta_{1-t'}} \exp \left(- \int_{t'}^t \kappa_{1-s} ds \right) dB_{t'}. \quad (76)$$

由于

$$\mathbb{E} \left[\left(\int_0^t \sqrt{2\eta_{1-t'}} \exp \left(- \int_{t'}^t \kappa_{1-s} ds \right) dB_{t'} \right)^2 \right] = 2 \int_0^t \eta_{1-t'} \exp \left(- 2 \int_{t'}^t \kappa_{1-s} ds \right) dt', \quad (77)$$

$$\sqrt{2\eta_{1-t'}} \exp \left(- \int_{t'}^t \kappa_{1-s} ds \right) dB_{t'} \text{ 我们得到 } \int_0^t \text{ 与以下具有相同 } \sqrt{2 \int_0^t \eta_{1-t'} \exp \left(- 2 \int_{t'}^t \kappa_{1-s} ds \right) dt'} \epsilon, \\ \epsilon \sim N(0, 1). \text{ 分布 其中}$$

B.2.3 命题 4 的证明

这一结果已被先前工作使用, 例如 (De Bortoli 等, 2021, 第 2.1 节), 但其推导缺乏严谨性, 因为使用了一些未加解释的近似。虽然该结果很自然, 但在该领域并非众所周知。我们给出一个仍处于离散时间的推导, 因此并非完全形式化, 但修正了 De Bortoli 等 (2021) 证明中的漏洞。我们引入简写

$$\vec{b}(x, t) = -\kappa_{1-t}x + \left(\frac{\sigma(1-t)^2}{2} - \eta_{1-t} \right) \mathfrak{s}(x, 1-t), \quad (78)$$

$$b(x, t) = \kappa_t X_t + \left(\frac{\sigma(t)^2}{2} + \eta_t \right) \mathfrak{s}(X_t, t), \quad (79)$$

$$\vec{\sigma}(t) = \sigma(1-t). \quad (80)$$

$b(x, t) = -\vec{b}(x, 1-t) + \sigma(t)^2 \mathfrak{s}(X_t, t)$. 注意, 假设我们使用 $K+1$ 个等距时间步对前向过程 $\vec{X}$ 进行离散化:

$$x_{k+1} = x_k + h\vec{b}(x_k, kh) + \sqrt{h}\vec{\sigma}(kh)\epsilon_k, \quad \text{with } \epsilon_k \sim N(0, 1). \quad (81)$$

需要强调的是 $x_{k+1} - x_k = O(h^{1/2})$ 。在整个证明过程中, 我们将跟踪所有线性阶 h 以内的项, 同时忽略 $O(h^{3/2})$ 阶及更高阶的项。离散化前向过程的分布为:

$$\vec{p}(x_{0:K}) = \vec{p}_0(x_0) \prod_{k=0}^{K-1} \vec{p}_{k+1|k}(x_{k+1}|x_k), \quad \text{where} \quad \vec{p}_{k+1|k}(x_{k+1}|x_k) = \frac{\exp \left(- \frac{\|x_{k+1} - x_k - h\vec{b}(x_k, kh)\|^2}{2h\vec{\sigma}(kh)^2} \right)}{(2\pi h\vec{\sigma}(kh)^2)^{d/2}} \quad (82)$$

利用叠乘, 可得

$$\begin{aligned} \vec{p}(x_{0:K}) &= \vec{p}_K(x_K) \prod_{k=0}^{K-1} \vec{p}_{k+1|k}(x_{k+1}|x_k) \frac{\vec{p}_k(x_k)}{\vec{p}_{k+1}(x_{k+1})} \\ &= \vec{p}_K(x_K) \prod_{k=0}^{K-1} \vec{p}_{k+1|k}(x_{k+1}|x_k) \exp \left(\log(\vec{p}_k(x_k)) - \log(\vec{p}_{k+1}(x_{k+1})) \right) \end{aligned} \quad (83)$$

我们可以使用伊藤引理的离散时间版本:

$$\log \vec{p}(x_{k+1}, (k+1)h) \approx \log \vec{p}(x_k, kh) + h \left(\partial_t \log \vec{p}(x_k, kh) + \frac{\vec{\sigma}(kh)^2}{2} \Delta \log \vec{p}(x_k, kh) \right) \quad (84)$$

$$+ \langle \nabla \log \vec{p}(x_k, kh), x_{k+1} - x_k \rangle + O(h^{3/2}). \quad (85)$$

利用方程 (81) 和泰勒近似, 观察到

$$\begin{aligned} &\langle \nabla \log p(x_k, kh), x_{k+1} - x_k \rangle \\ &= \langle \nabla \log p(x_{k+1}, (k+1)h) - \nabla^2 \log p(x_{k+1}, (k+1)h)(x_{k+1} - x_k), x_{k+1} - x_k \rangle + O(h^{3/2}) \\ &= \langle \nabla \log p(x_{k+1}, (k+1)h), x_{k+1} - x_k \rangle \\ &\quad - \langle h\vec{b}(x_k, kh) + \sqrt{h}\vec{\sigma}(kh)\epsilon_k, \nabla^2 \log p(x_{k+1}, (k+1)h)(h\vec{b}(x_k, kh) + \sqrt{h}\vec{\sigma}(kh)\epsilon_k) \rangle + O(h^{3/2}) \\ &= \langle \nabla \log p(x_{k+1}, (k+1)h), x_{k+1} - x_k \rangle - h\vec{\sigma}(kh)^2 \Delta \log p(x_{k+1}, (k+1)h) + O(h^{3/2}). \end{aligned} \quad (86)$$

And since $\vec{p}$ satisfies the Fokker-Planck equation

$$\partial_t \vec{p}_t = \nabla \cdot \left((-\vec{b}(x, t) + \frac{\vec{\sigma}(t)^2}{2} \nabla \log \vec{p}_t(x)) \vec{p}_t \right), \quad (87)$$

我们有

$$\begin{aligned} \partial_t \log \vec{p}_t &= \frac{\partial_t \vec{p}_t}{\vec{p}_t} = \frac{\nabla \cdot \left((-\vec{b}(x, t) + \frac{\vec{\sigma}(t)^2}{2} \nabla \log \vec{p}_t(x)) \vec{p}_t \right)}{\vec{p}_t} \\ &= -\nabla \cdot \vec{b}(x, t) + \frac{\vec{\sigma}(t)^2}{2} \Delta \log \vec{p}_t(x) + \langle -\vec{b}(x, t) + \frac{\vec{\sigma}(t)^2}{2} \nabla \log \vec{p}_t(x), \nabla \log \vec{p}_t(x) \rangle. \end{aligned} \quad (88)$$

因此,

$$\begin{aligned} \partial_t \log p(x_k, kh) &= \partial_t \log p(x_{k+1}, (k+1)h) + O(h^{1/2}) \\ &= -\nabla \cdot \vec{b}(x_{k+1}, (k+1)h) + \frac{\vec{\sigma}((k+1)h)^2}{2} \Delta \log \vec{p}(x_{k+1}, (k+1)h) \\ &\quad + \langle -\vec{b}(x_{k+1}, (k+1)h) + \frac{\vec{\sigma}((k+1)h)^2}{2} \nabla \log \vec{p}(x_{k+1}, (k+1)h), \nabla \log \vec{p}(x_{k+1}, (k+1)h) \rangle + O(h^{1/2}). \end{aligned} \quad (89)$$

将 (86) 和 (89) 代入 (84), 得到

$$\begin{aligned} &\log p(x_{k+1}, (k+1)h) - \log p(x_k, kh) \\ &= h \left(-\nabla \cdot \vec{b}(x_{k+1}, (k+1)h) + \langle -\vec{b}(x_{k+1}, (k+1)h) + \frac{\vec{\sigma}((k+1)h)^2}{2} \nabla \log \vec{p}(x_{k+1}, (k+1)h), \nabla \log \vec{p}(x_{k+1}, (k+1)h) \rangle \right. \\ &\quad \left. + \langle \nabla \log p(x_{k+1}, (k+1)h), x_{k+1} - x_k \rangle + O(h^{3/2}) \right) \\ &= \frac{\langle 2h\vec{\sigma}(kh)^2 \nabla \log p(x_{k+1}, (k+1)h), x_{k+1} - x_k - h\vec{b}(x_{k+1}, (k+1)h) \rangle}{2h\vec{\sigma}(kh)^2} \\ &\quad + h \left(-\nabla \cdot \vec{b}(x_{k+1}, (k+1)h) + \frac{\vec{\sigma}((k+1)h)^2}{2} \|\nabla \log \vec{p}(x_{k+1}, (k+1)h)\|^2 \right) + O(h^{3/2}). \end{aligned} \quad (90)$$

再次应用伊藤引理的离散时间版本, 我们有

$$\begin{aligned} \vec{b}(x_k, kh) &= \vec{b}(x_{k+1}, (k+1)h) - h \left(\partial_t \vec{b}(x_{k+1}, (k+1)h) + \frac{\vec{\sigma}((k+1)h)^2}{2} \Delta \vec{b}(x_{k+1}, (k+1)h) \right) \\ &\quad + \nabla \vec{b}(x_{k+1}, (k+1)h)^\top (x_k - x_{k+1}) + O(h^{3/2}) \\ &= \vec{b}(x_{k+1}, (k+1)h) + \nabla \vec{b}(x_{k+1}, (k+1)h)^\top (x_k - x_{k+1}) + O(h). \end{aligned} \quad (91)$$

其中 $\Delta \vec{b}$ 表示 $\vec{b}$ 的逐分量拉普拉斯算子。因此,

$$\begin{aligned} &\log \vec{p}_{k+1|k}(x_{k+1}|x_k) \\ &= -\frac{d}{2} \log(2\pi h\vec{\sigma}(kh)^2) - \frac{\|x_{k+1} - x_k - h\vec{b}(x_k, kh)\|^2}{2h\vec{\sigma}(kh)^2} \\ &= -\frac{d}{2} \log(2\pi h\vec{\sigma}(kh)^2) - \frac{\|x_{k+1} - x_k - h(\vec{b}(x_{k+1}, (k+1)h) + \nabla \vec{b}(x_{k+1}, (k+1)h)^\top (x_k - x_{k+1}))\|^2}{2h\vec{\sigma}(kh)^2} + O(h^{3/2}) \\ &= -\frac{d}{2} \log(2\pi h\vec{\sigma}(kh)^2) - \frac{\|x_{k+1} - x_k - h\vec{b}(x_{k+1}, (k+1)h)\|^2}{2h\vec{\sigma}(kh)^2} + \frac{\langle x_{k+1} - x_k, \nabla \vec{b}(x_{k+1}, (k+1)h)^\top (x_k - x_{k+1}) \rangle}{\vec{\sigma}(kh)^2} + O(h^{3/2}) \\ &= -\frac{d}{2} \log(2\pi h\vec{\sigma}(kh)^2) - \frac{\|x_{k+1} - x_k - h\vec{b}(x_{k+1}, (k+1)h)\|^2}{h\vec{\sigma}(kh)^2} - \frac{h\vec{\sigma}(kh)^2 \langle \epsilon_k, \nabla \vec{b}(x_{k+1}, (k+1)h)^\top \epsilon_k \rangle}{\vec{\sigma}(kh)^2} + O(h^{3/2}) \\ &= -\frac{d}{2} \log(2\pi h\vec{\sigma}(kh)^2) - \frac{\|x_{k+1} - x_k - h\vec{b}(x_{k+1}, (k+1)h)\|^2}{h\vec{\sigma}(kh)^2} - h\Delta \vec{b}(x_{k+1}, (k+1)h) + O(h^{3/2}) \end{aligned} \quad (92)$$

结合式 (90) 与式 (92), 可得

$$\begin{aligned} &\log \vec{p}_{k+1|k}(x_{k+1}|x_k) - (\log p(x_{k+1}, (k+1)h) - \log p(x_k, kh)) \\ &= -\frac{d}{2} \log(2\pi h\vec{\sigma}(kh)^2) - \frac{\|x_{k+1} - x_k - h\vec{b}(x_{k+1}, (k+1)h) + h\vec{\sigma}((k+1)h)^2 \nabla \log p(x_{k+1}, (k+1)h)\|^2}{h\vec{\sigma}(kh)^2} + O(h^{3/2}) \\ &= -\frac{d}{2} \log(2\pi h\vec{\sigma}((k+1)h)^2) - \frac{\|x_{k+1} - x_k - h\vec{b}(x_{k+1}, (k+1)h) + h\vec{\sigma}((k+1)h)^2 \nabla \log p(x_{k+1}, (k+1)h)\|^2}{h\vec{\sigma}((k+1)h)^2} + O(h^{3/2}). \end{aligned} \quad (93)$$

根据贝叶斯法则, 并对该方程取指数, 可得

$$\begin{aligned} \vec{p}_{k+1|k}(x_{k+1}|x_k) &:= \vec{p}_{k+1|k}(x_{k+1}|x_k) \frac{\vec{p}_k(x_k)}{\vec{p}_{k+1}(x_{k+1})} \\ &= \frac{\exp \left(-\frac{\|x_k - x_{k+1} + h\vec{b}(x_{k+1}, (k+1)h) - h\vec{\sigma}((k+1)h)^2 \nabla \log p(x_{k+1}, (k+1)h)\|^2}{2h\vec{\sigma}((k+1)h)^2} \right)}{(2\pi h\vec{\sigma}((k+1)h)^2)^{d/2}} + O(h^{3/2}). \end{aligned} \quad (94)$$

除 $O(h^{3/2})$ 项外，右侧为对应于该更新的条件高斯分布

$$x_k = x_{k+1} + h \left(-\vec{b}(x_{k+1}, (k+1)h) + \vec{\sigma}((k+1)h)^2 \nabla \log p(x_{k+1}, (k+1)h) \right) + \sqrt{h} \vec{\sigma}((k+1)h) \epsilon_{k+1}, \quad \epsilon_{k+1} \sim N(0, I). \quad (95)$$

若定义 $y_k = x_{K-k}$ ，并利用 $b(x, t) = -\vec{b}(x, 1-t) + \vec{\sigma}(t)^2 \nabla \log p(x, 1-t)$ ，则可将式 (95) 改写为

$$\begin{aligned} y_{K-k} &= y_{K-k-1} + h \left(-\vec{b}(y_{K-k-1}, (K-k-1)h) + \vec{\sigma}((K-k-1)h)^2 \nabla \log p(y_{K-k-1}, (K-k-1)h) \right) \\ &\quad + \sqrt{h} \vec{\sigma}((K-k-1)h) \epsilon_k = y_{K-k-1} + h b(y_{K-k-1}, kh) + \sqrt{h} \sigma(kh) \epsilon_{K-k-1}, \\ \implies y_{k+1} &= y_k + h b(y_k, kh) + \sqrt{h} \sigma(kh) \epsilon_k. \end{aligned} \quad (96)$$

这正是反向过程的欧拉-丸山离散化。若将式 (94) 代入式 (83)，可得

$$\vec{p}(x_{0:K}) \approx \vec{p}_K(x_K) \prod_{k=0}^{K-1} \vec{p}_{k+1|k}(x_{k+1}|x_k). \quad (97)$$

证毕，因为 $\vec{p}_K(x_K)$ 是反向过程的初始分布，而 $\vec{p}_{k+1|k}(x_{k+1}|x_k)$ 是其转移核函数。

B.3 噪声预测器 ϵ 与得分函数之间的关系 对 DDIM 应用引理 2，并选择 $(\kappa_t)_{t \geq 0}$ 和 $(\eta_t)_{t \geq 0}$ ，我们得到 $\vec{X}_t$ 与以下分布相同

$$\hat{X}_t = \sqrt{\bar{\alpha}_{1-t}} \vec{X}_0 + \sqrt{1 - \bar{\alpha}_{1-t}} \epsilon, \quad \epsilon \sim N(0, 1). \quad (98)$$

由于 $\vec{X}_t$ 和 $\hat{X}_t$ 具有相同的分布，预测 $\vec{X}_t$ 的噪声等价于预测 $\hat{X}_t$ 的噪声。噪声预测器 ϵ 可以写为：

$$\epsilon(x, t) := \mathbb{E}[\epsilon | \hat{X}_{1-t} = x] = \mathbb{E}[\epsilon | \sqrt{\bar{\alpha}_t} \vec{X}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon = x] = \mathbb{E}\left[\frac{x - \sqrt{\bar{\alpha}_t} \vec{X}_0}{\sqrt{1 - \bar{\alpha}_t}} \mid \sqrt{\bar{\alpha}_t} \vec{X}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon = x\right] \quad (99)$$

And the score function $\mathfrak{s}(x, t) := \nabla \log \vec{p}_{1-t}(x)$ admits the expression

$$\mathfrak{s}(x, t) := \nabla \log \vec{p}_{1-t}(x) = \frac{\nabla \vec{p}_{1-t}(x)}{\vec{p}_{1-t}(x)} = \frac{\nabla \mathbb{E}[\vec{p}_{1-t|0}(x | \vec{X}_0)]}{\vec{p}_{1-t}(x)} = \frac{\mathbb{E}[\nabla \log \vec{p}_{1-t|0}(x | \vec{X}_0) \vec{p}_{1-t|0}(x | \vec{X}_0)]}{\vec{p}_{1-t}(x)}, \quad (100)$$

其中

$$\vec{p}_{1-t|0}(x | \vec{X}_0) = \frac{\exp(-\|x - \sqrt{\bar{\alpha}_t} \vec{X}_0\|^2 / (2(1 - \bar{\alpha}_t)))}{(2\pi(1 - \bar{\alpha}_t))^{d/2}} \implies \nabla \log \vec{p}_{t|1}(x | Y_1) = -\frac{x - \sqrt{\bar{\alpha}_t} Y_1}{1 - \bar{\alpha}_t}. \quad (101)$$

将其代入 (100) 的右侧并利用贝叶斯规则，我们得到

$$\mathfrak{s}(x, t) = \mathbb{E}\left[-\frac{x - \sqrt{\bar{\alpha}_t} \vec{X}_0}{1 - \bar{\alpha}_t} \mid \sqrt{\bar{\alpha}_t} \vec{X}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon = x\right]. \quad (102)$$

比较 (99) 和 (102) 的右侧，我们得到 $\mathfrak{s}(x, t) = -\frac{\epsilon(x, t)}{1 - \bar{\alpha}_t}$.

B.4 向量场 v 与得分函数之间的关系 根据构造 (Lipman 等人, 2023; Albergo 和 Vanden-Eijnden, 2023; Albergo 等人, 2023)，我们有

$$\begin{aligned} v(x, t) &= \mathbb{E}[\dot{\alpha}_t Y_1 + \dot{\beta}_t Y_0 | x = \alpha_t Y_1 + \beta_t Y_0] \\ &= \mathbb{E}\left[\frac{\dot{\alpha}_t (x - \beta_t Y_0)}{\alpha_t} + \dot{\beta}_t Y_0 \mid x = \alpha_t Y_1 + \beta_t Y_0\right] \\ &= \frac{\dot{\alpha}_t}{\alpha_t} x + (\dot{\beta}_t - \frac{\dot{\alpha}_t}{\alpha_t} \beta_t) \mathbb{E}[Y_0 | x = \alpha_t Y_1 + \beta_t Y_0], \end{aligned} \quad (103)$$

其中我们使用了 $Y_1 = (x - \beta_t Y_0)/\alpha_t$ 。此外，我们可以将得分写为如下形式

$$\mathbf{s}(x, t) := \nabla \log p_t(x) = \frac{\nabla p_t(x)}{p_t(x)} = \frac{\nabla \mathbb{E}[p_{t|1}(x|Y_1)]}{p_t(x)} = \frac{\mathbb{E}[\nabla p_{t|1}(x|Y_1)]}{p_t(x)} = \frac{\mathbb{E}[p_{t|1}(x|Y_1) \nabla \log p_{t|1}(x|Y_1)]}{p_t(x)}, \quad (104)$$

其中

$$p_{t|1}(x|Y_1) = \frac{\exp(-\|x - \alpha_t Y_1\|^2 / (2\beta_t^2))}{(2\pi\beta_t^2)^{d/2}} \implies \nabla \log \vec{p}_{t|1}(x|Y_1) = -\frac{x - \alpha_t Y_1}{\beta_t^2} \quad (105)$$

将其代回式 (104) 的右侧，我们得到

$$\begin{aligned} \mathbf{s}(x, t) &= -\frac{\mathbb{E}[p_{t|1}(x|Y_1) \frac{x - \alpha_t Y_1}{\beta_t^2}]}{p_t(x)} = -\frac{\int \vec{p}_{t|1}(x|Y_1) p_1(Y_1) \frac{x - \alpha_t Y_1}{\beta_t^2} dY_1}{\vec{p}_t(x)} \\ &= -\int p_{1|t}(Y_1|x) \frac{x - \alpha_t Y_1}{\beta_t^2} dY_1 = -\mathbb{E}\left[\frac{x - \alpha_t Y_1}{\beta_t^2} \mid x = \alpha_t Y_1 + \beta_t Y_0\right] = -\frac{\mathbb{E}[Y_0 \mid x = \alpha_t Y_1 + \beta_t Y_0]}{\beta_t} \end{aligned} \quad (106)$$

最后一个等式成立是因为 $(x - \alpha_t Y_1)/\beta_t = Y_0$ 。综合式 (103) 和式 (106)，我们得到

$$v(x, t) = \frac{\dot{\alpha}_t}{\alpha_t} x + \beta_t (\frac{\dot{\alpha}_t}{\alpha_t} \beta_t - \dot{\beta}_t) \mathbf{s}(x, t) \iff \mathbf{s}(x, t) = \frac{1}{\beta_t (\frac{\dot{\alpha}_t}{\alpha_t} \beta_t - \dot{\beta}_t)} (v(x, t) - \frac{\dot{\alpha}_t}{\alpha_t} x) \quad (107)$$

因此，常微分方程 (3) 可以改写为如下形式：

$$\frac{dX_t}{dt} = \frac{\dot{\alpha}_t}{\alpha_t} X_t + \beta_t (\frac{\dot{\alpha}_t}{\alpha_t} \beta_t - \dot{\beta}_t) \mathbf{s}(X_t, t), \quad X_0 \sim p_0. \quad (108)$$

为了允许任意的扩散系数，我们需要在漂移项中添加一个修正项：

$$dX_t = \left(\frac{\dot{\alpha}_t}{\alpha_t} X_t + \left(\frac{\sigma(t)^2}{2} + \beta_t (\frac{\dot{\alpha}_t}{\alpha_t} \beta_t - \dot{\beta}_t) \right) \mathbf{s}(X_t, t) \right) dt + \sigma(t) dB_t, \quad X_0 \sim p_0. \quad (109)$$

通过写出式 (108) 和式 (109) 的福克-普朗克方程，并观察到它们在项抵消后是相同的，可以很容易地证明这一点。最后，如果将式 (107) 的右侧代入式 (109)，我们得到具有任意噪声调度的流匹配随机微分方程 (式 (4))。

C 随机最优控制作为连续时空中的最大熵强化学习

在本节中，我们将 KL 正则化（或最大熵）强化学习与随机最优控制联系起来。我们证明，当动作空间是欧几里得空间且转移概率是条件高斯分布时，对 KL 正则化强化学习问题取步长趋于零的极限，就得到了随机最优控制问题。这种联系的一个结果是，所有用于 KL 正则化强化学习的算法都有对应的扩散微调版本。这并非新颖，但对于熟悉强化学习微调公式的研究人员可能有用。附录 C.4 提供了随机最优控制与最大熵强化学习之间更直接、更严格的连续时间联系，因为它表明期望控制代价等于以起点为条件的轨迹分布之间的 KL 散度（见式 (18)）。

C.1 最大熵强化学习

几种扩散微调方法 (Black 等人, 2024; Uehara 等人, 2024b) 基于 KL 正则化强化学习，也称为最大熵强化学习，我们在下文中进行回顾。在经典强化学习 (RL) 设置中，智能体从状态 $s_0 \sim p_0$ 开始，迭代地观察状态 s_k ，根据策略 $\pi(a_k; s_k, k)$ 采取动作 a_k ，根据固定的转移概率 $p(s_{k+1}|a_k, s_k)$ 进入新状态 s_{k+1} ，并获得奖励 $r_k(s_k, a_k)$ 。这可以概括为一条轨迹 $\tau = ((s_k, a_k))_{k=0}^K$ 。目标是优化策略 π 以最大化期望总奖励，即 $\max_{\pi} \mathbb{E}_{\tau \sim \pi, p} [\sum_{k=0}^K r_k(s_k, a_k)]$ 。

最大熵强化学习 (MaxEnt RL; Ziebart 等人, 2008) 相当于在每一步的奖励中加入策略 $\pi(\cdot; s_k, k)$ 的熵 $H(\pi) - k$ ，以鼓励探索并提高对变化的鲁棒性。

在环境中： $\max_{\pi} \mathbb{E}_{\tau \sim \pi, p} [\sum_{k=0}^K r_k(s_k, a_k) + \sum_{k=0}^{K-1} H(\pi(\cdot; s_k, k))]^8$ 。作为一种泛化方法，可以利用 $\pi(\cdot; s_k, k)$ 与基准策略 $\pi_{\text{base}}(\cdot; s_k, k)$ 之间的负 KL 散度进行正则化：

$$\max_{\pi} \mathbb{E}_{\tau \sim \pi, p} [\sum_{k=0}^K r_k(s_k, a_k) - \sum_{k=0}^{K-1} \text{KL}(\pi(\cdot; s_k, k) \parallel \pi_{\text{base}}(\cdot; s_k, k))], \quad (110)$$

这防止了学习到的策略偏离基础策略过远。每个策略 π 在轨迹 τ 上诱导出一个分布 $q(\tau)$ ，最大熵强化学习问题 (110) 可以仅用这些分布来表达（附录 C.3 中的引理 3）：

$$\max_q \mathbb{E}_{\tau \sim q} [\sum_{k=0}^K r_k(s_k, a_k)] - \text{KL}(q \parallel q^{\text{base}}), \quad (111)$$

其中 q^{base} 是由基础策略 π_{base} 诱导的分布，且最大化在所有分布 q 上进行，这些分布的 s_0 边缘分布为 p_0 。我们可进一步将该问题重述为（附录 C.3 中的引理 4）：

$$\min_q \text{KL}(q \parallel q^*), \quad \text{where } q^*(\tau) := q^{\text{base}}(\tau) \exp \left(\sum_{k=0}^K r_k(s_k, a_k) - \mathcal{V}(s_0, 0) \right), \quad (112)$$

其中

$$\begin{aligned} \mathcal{V}(s_k, k) &:= \log \left(\mathbb{E}_{\tau \sim \pi_{\text{base}}, p} [\exp \left(\sum_{k'=k}^K r_{k'}(s_{k'}, a_{k'}) \right) \mid s_k] \right) \\ &= \max_{\pi} \mathbb{E}_{\tau \sim \pi, p} \left[\sum_{k'=k}^K r_{k'}(s_{k'}, a_{k'}) - \sum_{k'=k}^{K-1} \text{KL}(\pi(\cdot; s_{k'}, k') \parallel \pi_{\text{base}}(\cdot; s_{k'}, k')) \mid s_k \right] \end{aligned} \quad (113)$$

是值函数。问题 (112) 直接表明，由最优策略 π^* 诱导的分布是倾斜分布 q^* （其初始边缘分布为 p_0 ）。

C.2 从最大熵强化学习到随机最优控制 以下著名结论（我们在附录 C.3 中证明）表明，在自然意义下，最大熵强化学习（MaxEnt RL）的连续时间连续空间版本正是第 4.1 节引入的随机最优控制（SOC）框架。特别地，当状态和动作是 $\mathbb{R}^d$ 中的向量，策略由向量场 u （控制）指定，且转移概率为条件高斯分布时，当时间步数趋于无穷大，最大熵强化学习问题就变为随机最优控制问题。

命题 5。 假设：(i) 状态空间和动作空间为

$\mathbb{R}^d$ ；(ii) 策略

π 被指定为 $\pi(a_k; s_k, k) = \delta(a_k - u(s_k, kh))$ ，其中 $u : \mathbb{R}^d \times [0, T] \rightarrow \mathbb{R}^d$ 是向量场， δ 表示狄拉克 δ 函数；(iii) 转移概率是条件高斯密度：

，其 $\sigma(kh)a_k, h\sigma(kh)\sigma(kh)^\top$ 中 $h = T/K$ 是步长， $p(s_{k+1} \mid a_k, s_k) = N(s_k + h(b(s_k, kh) + \sigma \text{ 如第 4.1 节所定义。})$

那么，在步数 K 趋于无穷大的极限下，问题 (110) 等价于随机最优控制问题 (12)-(13)，将状态序列 $(s_k)^k$ 与轨迹等同起来。• 运行奖励 $\sum_{k=0}^{K-1} r_k(s_k, a_k)$ 与负运行成本 $-\int_0^T f(X_t^u, t) dt$ 对应；• 终端奖励 $r_K(s_K, a_K)$ 与负终端成本 0 $\mathbf{X}^u = (X_t^u)_{t \in [0, T]}$ 对应。

- the KL regularization $\mathbb{E}_{\tau \sim \pi, p} [\sum_{k=0}^{K-1} \text{KL}(\pi(\cdot; s_k, k) \parallel \pi_{\text{base}}(\cdot; s_k, k))]$ with $\frac{1}{2}$ times the expected L^2 norm of the control $\frac{1}{2} \mathbb{E} [\int_0^T \|u(X_t^u, t)\|^2 dt]$,

- 以及 (113) 中定义的值函数 $\mathcal{V}(s_k, k)$ 与第 4.1 节中定义的值函数 $-V(x, t)$ 对应。

该结果的一个直接推论是，为通用最大熵强化学习问题设计的每个损失函数都有对应的随机最优控制问题损失函数。后者的几何结构允许额外的

⁸ 熵项通常乘以一个因子来调整其大小，但也可以等价地重新缩放奖励，因此我们不添加任何因子。

在经典最大熵强化学习设置中没有对应物的损失；特别是，我们可以对状态成本和终端成本进行微分。命题 5 的第二个推论是，特征化 (112) 可以转换到随机最优控制设置中。由最优策略 π^* 和基础策略 π^{base} 诱导的分布 q^*, q^{base} 的对应物是由最优控制 u^* 和零控制诱导的分布 p^*, p^{base} 。对于任意轨迹 $\mathbf{X} = (X_t)_{t \in [0, T]}$ ， $\mathbb{P}^*$ 和 $\mathbb{P}^{\text{base}}$ 之间的关系由下式给出

$$\frac{d\mathbb{P}^*}{d\mathbb{P}^{\text{base}}}(\mathbf{X}) = \exp(-\int_0^T f(X_t, t) dt - g(X_T) + V(X_0, 0)) \quad (114)$$

其中 V 是第 4.1 节中定义的值函数。注意这与 (22) 中的陈述一致。

C.3 命题 5 的证明：从最大熵强化学习到随机最优控制

由于转移 $p(s_{k+1}|a_k, s_k)$ 是固定的，对于每个 π 我们可以定义

$$\tilde{\pi}(a_k, s_{k+1}; s_k, k) = \pi(a_k; s_k, k)p(s_{k+1}|a_k, s_k) \text{ 及 } \tilde{\pi}_{\text{base}}(a_k, s_{k+1}; s_k, k) = \pi_{\text{base}}(a_k; s_k, k)p(s_{k+1}|a_k, s_k), \quad (115)$$

并将 (110) 重新表达为（见引理 3）

$$\min_{\tilde{\pi}} \mathbb{E}_{\tau \sim \tilde{\pi}} [\sum_{k=0}^K r_k(s_k, a_k) - \sum_{k=0}^{K-1} \text{KL}(\tilde{\pi}(\cdot, \cdot; s_k, k) || \tilde{\pi}_{\text{base}}(\cdot, \cdot; s_k, k))]. \quad (116)$$

利用命题的假设，我们可以写出

$$\begin{aligned} \tilde{\pi}(a_k, s_{k+1}; s_k, k) &= \delta(a_k - u(s_k, k\eta)) N(s_k + \eta(b(s_k, k\eta) + \sigma(k\eta)a_k), \eta\sigma(k\eta)\sigma(k\eta)^\top) \\ &= \delta(a_k - u(s_k, k\eta)) \tilde{\pi}(s_{k+1}; s_k, k), \end{aligned} \quad (117)$$

其中 $\tilde{\pi}(s_{k+1}; s_k, k) = N(s_k + \eta(b(s_k, k\eta) + \sigma(k\eta)u(s_k, k\eta)), \eta\sigma(k\eta)\sigma(k\eta)^\top)$ 是状态转移核。我们将基础策略设为 $\pi_{\text{base}}(a_k; s_k, k) = \delta(a_k)$ ，类似地得到 $\tilde{\pi}(a_k, s_{k+1}; s_k, k) = \delta(a_k) \tilde{\pi}_{\text{base}}(s_{k+1}; s_k, k)$ ，其中 $\tilde{\pi}_{\text{base}}(s_{k+1}; s_k, k) = N(s_k + \eta b(s_k, k\eta), \eta\sigma(k\eta)\sigma(k\eta)^\top)$ 。现在，如果我们取 K 足够大，由 $\tilde{\pi}$ 生成的轨迹 $(s_k)_{k=0}^K$ 可以看作受控随机微分方程 (13) 的解 X^u 的欧拉-丸山离散化，而由 $\tilde{\pi}_{\text{base}}$ 生成的轨迹则是通过令 $u = 0$ 得到的无控过程 X^0 的离散化。因此

$$\begin{aligned} \lim_{K \rightarrow \infty} \mathbb{E}_{\tau \sim \tilde{\pi}} [\sum_{k=0}^{K-1} \text{KL}(\tilde{\pi}(\cdot, \cdot; s_k, k) || \tilde{\pi}_{\text{base}}(\cdot, \cdot; s_k, k))] \\ = \lim_{K \rightarrow \infty} \mathbb{E}_{\tau \sim \tilde{\pi}} [\sum_{k=0}^{K-1} \text{KL}(\tilde{\pi}(\cdot; s_k, k) || \tilde{\pi}_{\text{base}}(\cdot; s_k, k))] = \mathbb{E}_{X^u \sim \mathbb{P}^u} [\log \frac{d\mathbb{P}^u}{d\mathbb{P}^0}(X^u)], \end{aligned} \quad (118)$$

其中 $\mathbb{P}^u$ 和 $\mathbb{P}^0$ 分别是过程 X^u 和

X^0 的测度。吉尔萨诺夫定理（定理 2）

意味着 $\log \frac{d\mathbb{P}^u}{d\mathbb{P}^0}(X^u) = -\int_0^T \langle u(X_t^u, t), dB_t \rangle - \frac{1}{2} \int_0^T \|u(X_t^u, t)\|^2 dt$ ，~~which implies that~~ 奖励设为 $r_k(a_k, s_k) = \eta f(s_k, k\eta)$ （对于 $k \in \{0, \dots, K-1\}$ ）和 $r_K(a_K, s_K) = \eta g(s_K)$ ，其中 f 和 g 如第 4.1 节所述，得到以下极限对象：

$$\lim_{K \rightarrow \infty} \mathbb{E}_{\tau \sim \tilde{\pi}} [\sum_{k=0}^K r_k(s_k, a_k)] = \mathbb{E}_{X^u \sim \mathbb{P}^u} [\int_0^T f(X_t^u, t) dt + g(X_T^u)]. \quad (119)$$

因此，最大熵强化学习损失 (116) 的极限是随机最优控制损失 (12)。

引理 3。 设 $\tilde{\pi}(a_k, s_{k+1}; s_k, k)$ 和 $\tilde{\pi}_{\text{base}}(a_k, s_{k+1}; s_k, k)$ 如 (115)。 $\text{KL}(\tilde{\pi}(\cdot, \cdot; s_k, k) || \tilde{\pi}_{\text{base}}(\cdot, \cdot; s_k, k))$ 中所定义，且 $\text{KL}(\pi(\cdot; s_k, k) || \pi_{\text{base}}(\cdot; s_k, k))$ 相等。此外，若 q, q^{base} 表示由 π, π_{base} 诱导的轨迹上的分布，则有

$$\text{KL}(q || q^{\text{base}}) = \mathbb{E} [\sum_{k=0}^{K-1} \text{KL}(\pi(\cdot; s_k, k) || \pi_{\text{base}}(\cdot; s_k, k))]. \quad (120)$$

证明。我们有

$$\begin{aligned}
\text{KL}(\tilde{\pi}(\cdot, \cdot; s_k, k) || \tilde{\pi}_{\text{base}}(\cdot, \cdot; s_k, k)) &= \sum_{a_k, s_{k+1}} \tilde{\pi}(a_k, s_{k+1}; s_k, k) \log \frac{\tilde{\pi}(a_k, s_{k+1}; s_k, k)}{\tilde{\pi}_{\text{base}}(a_k, s_{k+1}; s_k, k)} \\
&= \sum_{a_k, s_{k+1}} \pi(a_k; s_k, k) p(s_{k+1} | a_k, s_k) \log \frac{\pi(a_k; s_k, k) p(s_{k+1} | a_k, s_k)}{\pi_{\text{base}}(a_k; s_k, k) p(s_{k+1} | a_k, s_k)} \\
&= \sum_{a_k, s_{k+1}} \pi(a_k; s_k, k) p(s_{k+1} | a_k, s_k) \log \frac{\pi(a_k; s_k, k)}{\pi_{\text{base}}(a_k; s_k, k)} \\
&= \sum_{a_k} \pi(a_k; s_k, k) \left(\sum_{s_{k+1}} p(s_{k+1} | a_k, s_k) \right) \log \frac{\pi(a_k; s_k, k)}{\pi_{\text{base}}(a_k; s_k, k)} \\
&= \sum_{a_k} \pi(a_k; s_k, k) \log \frac{\pi(a_k; s_k, k)}{\pi_{\text{base}}(a_k; s_k, k)} = \text{KL}(\pi(\cdot; s_k, k) || \pi_{\text{base}}(\cdot; s_k, k)).
\end{aligned} \tag{121}$$

为证明 (120)，根据构造可写出

$$q(\tau) = p_0(s_0) \prod_{k=0}^{K-1} \tilde{\pi}(a_k, s_{k+1}; s_k, k), \quad q^{\text{base}}(\tau) = p_0(s_0) \prod_{k=0}^{K-1} \tilde{\pi}_{\text{base}}(a_k, s_{k+1}; s_k, k), \tag{122}$$

这意味着

$$\begin{aligned}
\text{KL}(q || q^{\text{base}}) &= \mathbb{E}_{\tau \sim q} [\log \frac{q(\tau)}{q^{\text{base}}(\tau)}] = \mathbb{E}_{\tau \sim q} [\sum_{k=0}^{K-1} \log \frac{\tilde{\pi}(a_k, s_{k+1}; s_k, k)}{\tilde{\pi}_{\text{base}}(a_k, s_{k+1}; s_k, k)}] \\
&= \sum_{k=0}^{K-1} \mathbb{E}_{\tau \sim q^{0:(k+1)}} [\log \frac{\tilde{\pi}(a_k, s_{k+1}; s_k, k)}{\tilde{\pi}_{\text{base}}(a_k, s_{k+1}; s_k, k)}] \\
&= \sum_{k=0}^{K-1} \mathbb{E}_{\tau \sim q^{0:k}} [\sum_{a_k, s_{k+1}} \tilde{\pi}(a_k, s_{k+1}; s_k, k) \log \frac{\tilde{\pi}(a_k, s_{k+1}; s_k, k)}{\tilde{\pi}_{\text{base}}(a_k, s_{k+1}; s_k, k)}] \\
&= \sum_{k=0}^{K-1} \mathbb{E}_{\tau \sim q^{0:k}} [\text{KL}(\tilde{\pi}(\cdot, \cdot; s_k, k) || \tilde{\pi}_{\text{base}}(\cdot, \cdot; s_k, k))] \\
&= \sum_{k=0}^{K-1} \mathbb{E}_{\tau \sim q^{0:k}} [\text{KL}(\pi(\cdot; s_k, k) || \pi_{\text{base}}(\cdot; s_k, k))] \\
&= \mathbb{E}_{\tau \sim q^{0:k}} [\sum_{k=0}^{K-1} \text{KL}(\pi(\cdot; s_k, k) || \pi_{\text{base}}(\cdot; s_k, k))]
\end{aligned} \tag{123}$$

此处记号 $q^{0:k}$ 表示直到状态 s_k 的轨迹 q 。

□

引理 4。 (111) 中基于分布的最大熵强化学习公式等价于以下问题：

$$\min_q \text{KL}(q || q^*), \quad \text{其中 } q^*(\tau) := \frac{q^{\text{base}}(\tau) \exp \left(\sum_{k=0}^K r_k(s_k, a_k) \right)}{\frac{1}{p_0(s_0)} \sum_{\{\tau' | s'_0 = s_0\}} q^{\text{base}}(\tau') \exp \left(\sum_{k=0}^K r_k(s'_k, a'_k) \right)}, \tag{124}$$

其中最小化在 q 上进行，且在零步时具有边缘 p_0 。该问题的最优解为 q^* ，它满足边缘约束。 q^* 的以下替代刻画成立：

$$q^*(\tau) = q^{\text{base}}(\tau) \exp \left(\sum_{k=0}^K r_k(s_k, a_k) - \mathcal{V}(s_0, 0) \right), \tag{125}$$

$$\text{where } \mathcal{V}(x, k) = \max_{\pi} \mathbb{E}_{\tau \sim \pi, p} \left[\sum_{k'=k}^K r_{k'}(s_{k'}, a_{k'}) - \sum_{k'=k}^{K-1} \text{KL}(\pi(\cdot; s_{k'}, k') || \pi_{\text{base}}(\cdot; s_{k'}, k')) | s_k = x \right]. \tag{126}$$

Proof. Let us expand $\text{KL}(q || q^*)$:

$$\begin{aligned}
\text{KL}(q || q^*) &= \mathbb{E}_{\tau \sim q} \left[\log \frac{q(\tau)}{q^*(\tau)} \right] \\
&= \mathbb{E}_{\tau \sim q} \left[\log q(\tau) - \log q^{\text{base}}(\tau) - \sum_{k=0}^K r_k(s_k, a_k) \right. \\
&\quad \left. + \log \left(\frac{1}{p_0(s_0)} \sum_{\{\tau' | s'_0 = s_0\}} q^{\text{base}}(\tau') \exp \left(\sum_{k=0}^K r_k(s'_k, a'_k) \right) \right) \right] \\
&= \text{KL}(q || q^{\text{base}}) - \mathbb{E}_{\tau \sim q} \left[\sum_{k=0}^K r_k(s_k, a_k) \right] \\
&\quad + \mathbb{E}_{s_0 \sim p_0} \left[\log \left(\frac{1}{p_0(s_0)} \sum_{\{\tau' | s'_0 = s_0\}} q^{\text{base}}(\tau') \exp \left(\sum_{k=0}^K r_k(s'_k, a'_k) \right) \right) \right],
\end{aligned} \tag{127}$$

其中第三个等式成立是因为 q 在零时刻的边缘分布由假设为 p_0 。由于右侧第三项与 q 无关，这证明了 (111) 与 (124) 之间的等价性。接下来，我们证明 q^* 在零时刻的边缘分布为 p_0 ：

$$\sum_{\{\tau | s_0 = x\}} q^*(\tau) := \sum_{\{\tau | s_0 = x\}} \frac{q^{\text{base}}(\tau) \exp \left(\sum_{k=0}^K r_k(s_k, a_k) \right)}{\frac{1}{p_0(x)} \sum_{\{\tau' | s'_0 = x\}} q^{\text{base}}(\tau') \exp \left(\sum_{k=0}^K r_k(s'_k, a'_k) \right)} = p_0(x). \tag{128}$$

现在，对于任意的 s_0 ，令 $q_{s_0}, q_{s_0}^*$ 为以初始状态为 s_0 为条件的分布 q, q^* 。我们可以为 $q_{s_0}, q_{s_0}^*$ 写出方程 (127) 的类似形式：

$$\begin{aligned} \text{KL}(q_{s_0} || q_{s_0}^*) &= \mathbb{E}_{\tau \sim q_{s_0}} \left[\log \frac{q_{s_0}(\tau)}{q_{s_0}^*(\tau)} \right] \\ &= \mathbb{E}_{\tau \sim q_{s_0}} \left[\log q_{s_0}(\tau) - \log q_{s_0}^{\text{base}}(\tau) - \sum_{k=0}^K r_k(s_k, a_k) \right. \\ &\quad \left. + \log \left(\frac{1}{p_0(s_0)} \sum_{\{\tau' | s'_0 = s_0\}} q_{s_0}^{\text{base}}(\tau') \exp \left(\sum_{k=0}^K r_k(s'_k, a'_k) \right) \right) \right] \\ &= \text{KL}(q_{s_0} || q_{s_0}^{\text{base}}) - \mathbb{E}_{\tau \sim q_{s_0}} \left[\sum_{k=0}^K r_k(s_k, a_k) \right] \\ &\quad + \log \left(\frac{1}{p_0(s_0)} \sum_{\{\tau' | s'_0 = s_0\}} q_{s_0}^{\text{base}}(\tau') \exp \left(\sum_{k=0}^K r_k(s'_k, a'_k) \right) \right), \end{aligned} \quad (129)$$

因此，

$$\begin{aligned} 0 = \min_{q_{s_0}} \text{KL}(q_{s_0} || q_{s_0}^*) &= -\max_{q_{s_0}} \{ \mathbb{E}_{\tau \sim q_{s_0}} \left[\sum_{k=0}^K r_k(s_k, a_k) \right] - \text{KL}(q_{s_0} || q_{s_0}^{\text{base}}) \} \\ &\quad + \log \left(\frac{1}{p_0(s_0)} \sum_{\{\tau' | s'_0 = s_0\}} q_{s_0}^{\text{base}}(\tau') \exp \left(\sum_{k=0}^K r_k(s'_k, a'_k) \right) \right). \end{aligned} \quad (130)$$

并且应用 (120) 中的 (120)，我们得到

$$\begin{aligned} &\log \left(\frac{1}{p_0(s_0)} \sum_{\{\tau' | s'_0 = s_0\}} q_{s_0}^{\text{base}}(\tau') \exp \left(\sum_{k=0}^K r_k(s'_k, a'_k) \right) \right) \\ &= \max_{\pi} \mathbb{E}_{\tau \sim \pi, p} \left[\sum_{k=0}^K r_k(s_k, a_k) - \sum_{k=0}^{K-1} \text{KL}(\pi(\cdot; s_k, k) || \pi_{\text{base}}(\cdot; s_k, k)) | s_0 \right] = \mathcal{V}(s_0, 0), \end{aligned} \quad (131)$$

这完成了证明。 $\square$

C.4 方程 (18) 的证明：控制代价是 KL 正则化项

定理 2 (随机微分方程的吉尔萨诺夫定理)。如果两个随机微分方程

$$dX_t = b_1(X_t, t) dt + \sigma(X_t, t) dB_t, \quad X_0 = x_{\text{init}} \quad (132)$$

$$dY_t = (b_1(Y_t, t) + b_2(Y_t, t)) dt + \sigma(Y_t, t) dB_t, \quad Y_0 = x_{\text{init}} \quad (133)$$

在 $[0, T]$ 上存在唯一的强解，那么对于 $C([0, T])$ 上的任意有界连续泛函 Φ ，我们有

$$\begin{aligned} \mathbb{E}[\Phi(\mathbf{X})] &= \mathbb{E}[\Phi(\mathbf{Y}) \exp \left(- \int_0^T \sigma(Y_t, t)^{-1} b_2(Y_t, t) dB_t - \frac{1}{2} \int_0^T \|\sigma(Y_t, t)^{-1} b_2(Y_t, t)\|^2 dt \right)] \\ &= \mathbb{E}[\Phi(\mathbf{Y}) \exp \left(- \int_0^T \sigma(Y_t, t)^{-1} b_2(Y_t, t) d\tilde{B}_t + \frac{1}{2} \int_0^T \|\sigma(Y_t, t)^{-1} b_2(Y_t, t)\|^2 dt \right)], \end{aligned} \quad (134)$$

其中 $\tilde{B}_t = B_t + \int_0^t \sigma(Y_s, s)^{-1} b_2(Y_s, s) ds$ 。更一般地， b_1 和 b_2 可以是适应于 B 的滤流的随机过程。

考虑随机微分方程

$$dX_t = b(X_t, t) dt + \sigma(t) dB_t, \quad X_0 = x_0, \quad (135)$$

$$dX_t^u = (b(X_t^u, t) + \sigma(t)u(X_t^u, t)) dt + \sigma(t) dB_t, \quad X_0^u = x_0. \quad (136)$$

若令 $\mathbb{P}^{u|_{x_0}}, \mathbb{P}^{u|_{x_0}}$ 为 (135) 和 (136) 的解的概率测度，则定理 2 表明

$$\log \frac{d\mathbb{P}^{u|_{x_0}}}{d\mathbb{P}^{u|_{x_0}}}(\mathbf{X}^u) = - \int_0^1 u(X_t^u, t) dB_t - \frac{1}{2} \int_0^1 \|u(X_t^u, t)\|^2 dt. \quad (137)$$

因此，

$$\begin{aligned} D_{\text{KL}}(\mathbb{P}^u|_{x_0} || \mathbb{P}|_{x_0}) &= \mathbb{E} \left[\log \frac{d\mathbb{P}^u|_{x_0}}{d\mathbb{P}|_{x_0}}(\mathbf{X}^u) | X_0^u = x_0 \right] = -\mathbb{E} \left[\log \frac{d\mathbb{P}^{u|_{x_0}}}{d\mathbb{P}^{u|_{x_0}}}(\mathbf{X}^u) | X_0^u = x_0 \right] \\ &= \mathbb{E} \left[\int_0^1 u(X_t^u, t) dB_t + \frac{1}{2} \int_0^1 \|u(X_t^u, t)\|^2 dt | X_0^u = x_0 \right] = \mathbb{E} \left[\frac{1}{2} \int_0^1 \|u(X_t^u, t)\|^2 dt | X_0^u = x_0 \right], \end{aligned} \quad (138)$$

其中我们利用了随机积分是鞅这一性质。

D 第 4.3 节证明：无记忆噪声调度与微调方案

D.1 命题 1 的证明：无记忆噪声调度 我们考虑具有任意噪声调度的前向-后向随机微分方程 (63)-(64)。由命题 4，这两个过程的轨迹 $\bar{X}, X$ 在时间翻转下具有相同分布，这也意味着它们的边缘分布满足 $\bar{p}_t = p_{1-t}$ ，对所有 $t \in [0, 1]$ 。首先，我们推导得分函数 $s(x, t) = \nabla \log p_t(x)$ 的显式表达式。根据流匹配的性质，我们知道 p_t 是插值变量 $\bar{X}_t = \beta_t \bar{X}_0 + \alpha_t \bar{X}_1$ 的分布，其中 $\bar{X}_0 \sim N(0, I), \bar{X}_1 \sim p^{\text{data}}$ 相互独立。因此， $\bar{X}_t = \frac{1-t}{\beta_t} \bar{X}_0 + \frac{t}{\alpha_t} \bar{X}_1 \sim N(0, I)$ ，这意味着我们可以将密度 p_t 表示为

$$p_t(x) = \int_{\mathbb{R}^d} \frac{\exp\left(-\frac{\|x - \alpha_t y\|^2}{2\beta_t^2}\right)}{(2\pi\beta_t^2)^{d/2}} p^{\text{data}}(y) dy. \quad (139)$$

因此，

$$s(x, t) = \nabla \log p_t(x) = -\frac{x}{\beta_t^2} + \frac{\alpha_t}{\beta_t^2} \frac{\int_{\mathbb{R}^d} y \exp\left(-\frac{\|x - \alpha_t y\|^2}{2\beta_t^2}\right) p^{\text{data}}(y) dy}{\int_{\mathbb{R}^d} \exp\left(-\frac{\|x - \alpha_t y\|^2}{2\beta_t^2}\right) p^{\text{data}}(y) dy} := -\frac{x - \alpha_t \xi_t(x)}{\beta_t^2}, \quad (140)$$

其中我们定义了

$$\xi_t(x) = \frac{\int_{\mathbb{R}^d} y \exp\left(-\frac{\|x - \alpha_t y\|^2}{2\beta_t^2}\right) p^{\text{data}}(y) dy}{\int_{\mathbb{R}^d} \exp\left(-\frac{\|x - \alpha_t y\|^2}{2\beta_t^2}\right) p^{\text{data}}(y) dy}. \quad (141)$$

因此，我们可以将正向随机微分方程 (63) 改写为

$$d\bar{X}_t = \left(-\kappa_{1-t} \bar{X}_t - \left(\frac{\sigma(1-t)^2}{2} - \eta_{1-t} \right) \frac{\bar{X}_t - \alpha_{1-t} \xi_{1-t}(\bar{X}_t)}{\beta_{1-t}^2} \right) dt + \sigma(1-t) dB_t, \quad \bar{X}_0 \sim p_{\text{data}} \quad (142)$$

Hence, if we substitute $\kappa_{1-t} \leftarrow \kappa_{1-t} + \frac{\sigma(1-t)^2 - 2\eta_{1-t}}{2\beta_{1-t}^2}$, $\xi_{1-t} \leftarrow \frac{\alpha_{1-t}(\sigma(1-t)^2 - 2\eta_{1-t})}{2\beta_{1-t}^2} \xi_{1-t}(\bar{X}_t)$ (where we ignore the dependency on $\bar{X}_t$), $\sqrt{2\eta_{1-t}} \leftarrow \sigma(1-t)$, we can apply [Lemma 2](#), which yields

$$\begin{aligned} \bar{X}_t &= \bar{X}_0 \exp\left(-\int_0^t \left(\kappa_{1-s} + \frac{\sigma(1-s)^2 - 2\eta_{1-s}}{2\beta_{1-s}^2}\right) ds\right) \\ &\quad + \int_0^t \exp\left(-\int_{t'}^t \left(\kappa_{1-s} + \frac{\sigma(1-s)^2 - 2\eta_{1-s}}{2\beta_{1-s}^2}\right) ds\right) \frac{\alpha_{1-t'}(\sigma(1-t')^2 - 2\eta_{1-t'})}{2\beta_{1-t'}^2} \xi_{1-t'}(\bar{X}_{t'}) dt' \\ &\quad + \int_0^t \sigma(1-t') \exp\left(-\int_{t'}^t \left(\kappa_{1-s} + \frac{\sigma(1-s)^2 - 2\eta_{1-s}}{2\beta_{1-s}^2}\right) ds\right) dB_{t'}. \end{aligned} \quad (143)$$

We simplify the recurring expression:

$$\kappa_{1-s} + \frac{\sigma(1-s)^2 - 2\eta_{1-s}}{2\beta_{1-s}^2} = \frac{\dot{\alpha}_{1-s}}{\alpha_{1-s}} + \frac{\sigma(1-s)^2 - 2\beta_{1-s}(\frac{\dot{\alpha}_{1-s}}{\alpha_{1-s}}\beta_{1-s} - \dot{\beta}_{1-s})}{2\beta_{1-s}^2} = \frac{\sigma(1-s)^2}{2\beta_{1-s}^2} + \frac{\dot{\beta}_{1-s}}{\beta_{1-s}} \quad (144)$$

因此，

$$\int_{t'}^t \left(\kappa_{1-s} + \frac{\sigma(1-s)^2 - 2\eta_{1-s}}{2\beta_{1-s}^2}\right) ds = \int_{t'}^t \left(\frac{\sigma(1-s)^2}{2\beta_{1-s}^2} - \partial_s \log \beta_{1-s}\right) ds = \int_{t'}^t \frac{\sigma(1-s)^2}{2\beta_{1-s}^2} ds - (\log \beta_{1-t} - \log \beta_{1-t'}), \quad (145)$$

这意味着

$$\exp\left(-\int_{t'}^t \left(\kappa_{1-s} + \frac{\sigma(1-s)^2 - 2\eta_{1-s}}{2\beta_{1-s}^2}\right) ds\right) = \exp\left(-\int_{t'}^t \frac{\sigma(1-s)^2}{2\beta_{1-s}^2} ds\right) \frac{\beta_{1-t}}{\beta_{1-t'}}, \quad (146)$$

$$\frac{\alpha_{1-t'}(\sigma(1-t')^2 - 2\eta_{1-t'})}{2\beta_{1-t'}^2} \xi_{1-t'}(\bar{X}_{t'}) = \alpha_{1-t'} \left(\frac{\sigma(1-t')^2}{2\beta_{1-t'}^2} + \frac{\dot{\beta}_{1-t'}}{\beta_{1-t'}} - \frac{\dot{\alpha}_{1-t'}}{\alpha_{1-t'}} \right) \xi_{1-t'}(\bar{X}_{t'}). \quad (147)$$

若定义 $\chi(1-s)$ 使得 $\sigma^2(1-s) = 2\beta_{1-s}(\frac{\dot{\alpha}_{1-s}}{\alpha_{1-s}}\beta_{1-s} - \dot{\beta}_{1-s}) + \chi(1-s)$, 我们得到

$$\begin{aligned} \exp\left(-\int_{t'}^t \frac{\sigma(1-s)^2}{2\beta_{1-s}^2} ds\right) \frac{\beta_{1-t}}{\beta_{1-t'}} &= \exp\left(-\int_{t'}^t \left(\frac{\dot{\alpha}_{1-s}}{\alpha_{1-s}} - \frac{\dot{\beta}_{1-s}}{\beta_{1-s}} + \frac{\chi(1-s)}{2\beta_{1-s}^2}\right) ds\right) \frac{\beta_{1-t}}{\beta_{1-t'}} \\ &= \exp\left(-\int_{t'}^t \left(\partial_s \log \alpha_{1-s} - \partial_s \log \beta_{1-s} - \frac{\chi(1-s)}{2\beta_{1-s}^2}\right) ds\right) \frac{\beta_{1-t}}{\beta_{1-t'}} = \exp\left(-\int_{t'}^t \frac{\chi(1-s)}{2\beta_{1-s}^2} ds\right) \frac{\alpha_{1-t}}{\alpha_{1-t'}}, \end{aligned} \quad (148)$$

$$\alpha_{1-t'} \left(\frac{\sigma(1-t')^2}{2\beta_{1-t'}^2} + \frac{\dot{\beta}_{1-t'}}{\beta_{1-t'}} - \frac{\dot{\alpha}_{1-t'}}{\alpha_{1-t'}} \right) \xi_{1-t'}(\vec{X}_{t'}) = \frac{\alpha_{1-t'} \chi(1-t')}{2\beta_{1-t'}^2} \xi_{1-t'}(\vec{X}_{t'}) \quad (149)$$

若将方程 (148) 至 (149) 代入 (146) 至 (147), 再代入 (143), 我们得到

$$\begin{aligned} \vec{X}_t &= \vec{X}_0 \exp\left(-\int_0^t \frac{\chi(1-s)}{2\beta_{1-s}^2} ds\right) \frac{\alpha_{1-t}}{\alpha_1} + \alpha_{1-t} \int_0^t \exp\left(-\int_{t'}^t \frac{\chi(1-s)}{2\beta_{1-s}^2} ds\right) \frac{\chi(1-t')}{2\beta_{1-t'}^2} \xi_{1-t'}(\vec{X}_{t'}) dt' \\ &\quad + \int_0^t (2\beta_{1-t'}(\frac{\dot{\alpha}_{1-t'}}{\alpha_{1-t'}}\beta_{1-t'} - \dot{\beta}_{1-t'}) + \chi(1-t')) \exp\left(-\int_{t'}^t \frac{\chi(1-s)}{2\beta_{1-s}^2} ds\right) \frac{\alpha_{1-t}}{\alpha_{1-t'}} dB_{t'}. \end{aligned} \quad (150)$$

若取极限 $t \rightarrow 1^-$ 并利用 $\alpha_1 = 1$,

$$\begin{aligned} \vec{X}_1 &= \vec{X}_0 \left(\lim_{t \rightarrow 1^-} \exp\left(-\int_0^t \frac{\chi(1-s)}{2\beta_{1-s}^2} ds\right) \alpha_{1-t} \right) + \lim_{t \rightarrow 1^-} \alpha_{1-t} \int_0^t \exp\left(-\int_{t'}^t \frac{\chi(1-s)}{2\beta_{1-s}^2} ds\right) \frac{\chi(1-t')}{2\beta_{1-t'}^2} \xi_{1-t'}(\vec{X}_{t'}) dt' \\ &\quad + \lim_{t \rightarrow 1^-} \int_0^t (2\beta_{1-t'}(\frac{\dot{\alpha}_{1-t'}}{\alpha_{1-t'}}\beta_{1-t'} - \dot{\beta}_{1-t'}) + \chi(1-t')) \exp\left(-\int_{t'}^t \frac{\chi(1-s)}{2\beta_{1-s}^2} ds\right) \frac{\alpha_{1-t}}{\alpha_{1-t'}} dB_{t'}. \end{aligned} \quad (151)$$

在 (25) 中对 χ 的假设, 经过记号重排和时间变量翻转后, 等价于对所有 $t' \in [0, 1)$ 成立

$$\lim_{t \rightarrow 1^-} \exp\left(-\int_{t'}^t \frac{\chi(1-s)}{2\beta_{1-s}^2} ds\right) \alpha_{1-t} = 0. \quad (152)$$

因此, 在假设 (25) 下, 方程 (151) 中伴随 $\vec{X}_0$ 的因子为零。此外, 该假设还意味着

$$\begin{aligned} &\lim_{t \rightarrow 1^-} \alpha_{1-t} \int_0^t \exp\left(-\int_{t'}^t \frac{\chi(1-s)}{2\beta_{1-s}^2} ds\right) \frac{\chi(1-t')}{2\beta_{1-t'}^2} \xi_{1-t'}(\vec{X}_{t'}) dt' \\ &= \int_0^1 \left(\lim_{t \rightarrow 1^-} \exp\left(-\int_{t'}^t \frac{\chi(1-s)}{2\beta_{1-s}^2} ds\right) \alpha_{1-t} \right) \frac{\chi(1-t')}{2\beta_{1-t'}^2} \xi_{1-t'}(\vec{X}_{t'}) dt' = 0. \end{aligned} \quad (153)$$

若将 (152) 和 (153) 代入 (151), 我们得到

$$\vec{X}_1 = \lim_{t \rightarrow 1^-} \int_0^t (2\beta_{1-t'}(\frac{\dot{\alpha}_{1-t'}}{\alpha_{1-t'}}\beta_{1-t'} - \dot{\beta}_{1-t'}) + \chi(1-t')) \exp\left(-\int_{t'}^t \frac{\chi(1-s)}{2\beta_{1-s}^2} ds\right) \frac{\alpha_{1-t}}{\alpha_{1-t'}} dB_{t'}, \quad (154)$$

这表明 $\vec{X}_1$ 与 $\vec{X}_0$ 无关。接下来, 我们利用 $\vec{X}$ 和 X 在轨迹上具有相同分布这一事实 (命题 4)。特别地, $(\vec{X}_0, \vec{X}_1)$ 的联合分布等于 (X_1, X_0) 的联合分布。我们得出结论: X_1 与 X_0 相互独立, 这正是无记忆性的定义。因此, 假设 (25) 是无记忆性成立的充分条件。

仍需证明假设 (25) 是必要的。观察方程 (150), 我们推断出一般情况下, 对于任意 $t \in [0, 1)$, $\vec{X}_0$ 和 $\vec{X}_t$ 并非独立, 因为 (150) 中的前两项不为零。因此, 如果存在一个 $t' \in [0, 1)$ 使得极限 (152) 不为零, 那么 $\vec{X}_1$ 将不独立于 $\vec{X}_{t'}$, 这意味着一般情况下它也不独立于 $\vec{X}_0$ 。

D.2 定理 1 的证明: 一般噪声调度的微调方法

该结果的证明在很大程度上依赖于哈密顿-雅可比-贝尔曼方程的性质:

定理 3 (哈密顿-雅可比-贝尔曼方程)。若定义无穷小生成元

$$\mathcal{L} := \frac{1}{2} \sum_{i,j=1}^d (\sigma \sigma^\top)_{ij}(t) \partial_{x_i} \partial_{x_j} + \sum_{i=1}^d b_i(x, t) \partial_{x_i}, \quad (155)$$

则随机最优控制问题 (12) - (13) 的值函数 V 满足以下哈密顿-雅可比-贝尔曼 (HJB) 偏微分方程:

$$\begin{aligned} \partial_t V(x, t) &= -\mathcal{L}V(x, t) + \frac{1}{2} \|(\sigma^\top \nabla V)(x, t)\|^2 - f(x, t), \\ V(x, T) &= g(x). \end{aligned} \quad (156)$$

考虑形如 (63) 的前向随机微分方程, 从分布 p^{base} 和 p^* 出发, 其中 $p^*(x) \propto p^{\text{base}}(x) \exp(r(x))$ 。

$$d\vec{X}_t = \vec{b}(\vec{X}_t, t) dt + \sigma(t) dB_t, \quad \vec{X}_0 \sim p^{\text{base}}, \quad (157)$$

$$d\vec{X}_t^* = \vec{b}^*(\vec{X}_t^*, t) dt + \sigma(t) dB_t, \quad \vec{X}_0 \sim p^*. \quad (158)$$

其中漂移项定义为

$$\begin{aligned} \vec{b}(x, t) &= -\kappa_{1-t}x + \left(\frac{\sigma(1-t)^2}{2} - \eta_{1-t}\right)\mathfrak{s}(x, 1-t) = -\kappa_{1-t}x + \left(\frac{\sigma(1-t)^2}{2} - \eta_{1-t}\right)\nabla \log \vec{p}_t(x), \\ \vec{b}^*(x, t) &= -\kappa_{1-t}x + \left(\frac{\sigma(1-t)^2}{2} - \eta_{1-t}\right)\mathfrak{s}^*(x, 1-t) = -\kappa_{1-t}x + \left(\frac{\sigma(1-t)^2}{2} - \eta_{1-t}\right)\nabla \log \vec{p}_t^*(x), \end{aligned} \quad (159)$$

及 $\vec{p}_t, \vec{p}_t^*$ 分别是 $\vec{X}_t, \vec{X}_t^*$ 的密度。 $\vec{p}_t, \vec{p}_t^*$ 满足福克-普朗克方程:

$$\begin{aligned} \partial_t \vec{p}_t &= \nabla \cdot (\vec{b}(x, t) \vec{p}_t) + \nabla \cdot \left(\frac{\sigma(1-t)^2}{2} \nabla \vec{p}_t\right), \quad \vec{p}_0 = p^{\text{base}}, \\ \partial_t \vec{p}_t^* &= \nabla \cdot (\vec{b}^*(x, t) \vec{p}_t^*) + \nabla \cdot \left(\frac{\sigma(1-t)^2}{2} \nabla \vec{p}_t^*\right), \quad \vec{p}_0 = p^*. \end{aligned} \quad (160)$$

将 (159) 代入 (160), 得到

$$\begin{aligned} \partial_t \vec{p}_t &= \nabla \cdot (\kappa_{1-t}x \vec{p}_t) + \nabla \cdot (\eta_{1-t} \nabla \vec{p}_t), \quad \vec{p}_0 = p^{\text{base}}, \\ \partial_t \vec{p}_t^* &= \nabla \cdot (\kappa_{1-t}x \vec{p}_t^*) + \nabla \cdot (\eta_{1-t} \nabla \vec{p}_t^*), \quad \vec{p}_0 = p^*. \end{aligned} \quad (161)$$

我们应用霍普夫-科尔变换以获得 $-\log \vec{p}_t$ (以及 $-\log \vec{p}_t^*$ 类似地) 的偏微分方程:

$$\begin{aligned} -\partial_t (-\log \vec{p}_t) &= \frac{\partial_t \vec{p}_t}{\vec{p}_t} = \frac{\nabla \cdot (\kappa_{1-t}x \vec{p}_t) + \nabla \cdot (\eta_{1-t} \nabla \vec{p}_t)}{\vec{p}_t} \\ &= \kappa_{1-t} \nabla \cdot x + \kappa_{1-t} \langle x, \nabla \log \vec{p}_t \rangle + \eta_{1-t} \frac{\nabla \cdot (\nabla \log \vec{p}_t \exp(\log \vec{p}_t))}{\vec{p}_t} \\ &= \kappa_{1-t} d + \kappa_{1-t} \langle x, \nabla \log \vec{p}_t \rangle + \eta_{1-t} (\Delta \log \vec{p}_t + \|\nabla \log \vec{p}_t\|^2). \end{aligned} \quad (162)$$

因此, 如果我们定义 $\mathcal{V}(x, t) = -\log \vec{p}_t(x)$, $\mathcal{V}^*(x, t) = -\log \vec{p}_t^*(x)$, 则 $\mathcal{V}$ 和 $\mathcal{V}^*$ 满足以下哈密顿-雅可比-贝尔曼方程:

$$-\partial_t \mathcal{V} = \kappa_{1-t} d + \kappa_{1-t} \langle x, \nabla \mathcal{V} \rangle + \eta_{1-t} (-\Delta \mathcal{V} + \|\nabla \mathcal{V}\|^2), \quad \mathcal{V}(x, 0) = -\log p^{\text{base}}(x), \quad (163)$$

$$-\partial_t \mathcal{V}^* = \kappa_{1-t} d + \kappa_{1-t} \langle x, \nabla \mathcal{V}^* \rangle + \eta_{1-t} (-\Delta \mathcal{V}^* + \|\nabla \mathcal{V}^*\|^2), \quad \mathcal{V}^*(x, 0) = -\log p^*(x). \quad (164)$$

Now, define $\hat{\mathcal{V}}(x, t) = \mathcal{V}^*(x, t) - \mathcal{V}(x, t)$ 从式 (163) 中减去式 (164), 可得

$$\begin{aligned} -\partial_t \hat{\mathcal{V}} &= -\kappa_{1-t} \langle x, \nabla \hat{\mathcal{V}} \rangle + \eta_{1-t} (-\Delta \hat{\mathcal{V}} + \|\nabla \mathcal{V}^*\|^2 - \|\nabla \mathcal{V}\|^2) \\ &= -\kappa_{1-t} \langle x, \nabla \hat{\mathcal{V}} \rangle + \eta_{1-t} (-\Delta \hat{\mathcal{V}} + \|\nabla (\hat{\mathcal{V}} + \mathcal{V})\|^2 - \|\nabla \mathcal{V}\|^2) \\ &= -\kappa_{1-t} \langle x, \nabla \hat{\mathcal{V}} \rangle + \eta_{1-t} (-\Delta \hat{\mathcal{V}} + \|\nabla \hat{\mathcal{V}}\|^2 + 2\langle \nabla \mathcal{V}, \nabla \hat{\mathcal{V}} \rangle) \\ &= \langle -\kappa_{1-t}x + 2\eta_{1-t} \nabla \mathcal{V}, \nabla \hat{\mathcal{V}} \rangle + \eta_{1-t} (-\Delta \hat{\mathcal{V}} + \|\nabla \hat{\mathcal{V}}\|^2) \\ &= \langle -\kappa_{1-t}x - 2\eta_{1-t} \mathfrak{s}(x, 1-t), \nabla \hat{\mathcal{V}} \rangle + \eta_{1-t} (-\Delta \hat{\mathcal{V}} + \|\nabla \hat{\mathcal{V}}\|^2), \\ \hat{\mathcal{V}}(x, 0) &= -\log p^*(x) + \log p^{\text{base}}(x) = -r(x) + \log \left(\int p^{\text{base}}(y) \exp(r(y)) dy \right). \end{aligned} \quad (165)$$

因此, $\hat{\mathcal{V}}$ 也满足哈密顿-雅可比-贝尔曼方程。若定义 V 使得 $\hat{\mathcal{V}}(x, t) = V(x, 1-t)$, 则有

$$\partial_t V = \langle -\kappa_t x - 2\eta_t \mathfrak{s}(x, t), \nabla V \rangle + \eta_t (-\Delta V + \|\nabla V\|^2), \quad V(x, 1) = r(x) - \log \left(\int p^{\text{base}}(y) \exp(r(y)) dy \right). \quad (166)$$

利用定理 3, 可将 V 逆向构造为下列随机最优控制问题的值函数:

$$\min_{u \in \mathcal{U}} \mathbb{E} \left[\frac{1}{2} \int_0^1 \|u(X_t^u, t)\|^2 dt - r(x) + \log \left(\int p^{\text{base}}(y) \exp(r(y)) dy \right) \right], \quad (167)$$

$$\text{s.t. } dX_t^u = (\kappa_t x + 2\eta_t \mathfrak{s}(x, t) + \sqrt{2\eta_t} u(X_t^u, t)) dt + \sqrt{2\eta_t} dB_t, \quad X_0^u \sim p_0. \quad (168)$$

注意, 该随机最优控制问题等价于问题 (12) - (13), 其中选择 $f = 0, g = -r$ 和 $\sigma(t) = \sqrt{2\eta_t}$ 。由式 (17), 问题 (167) - (168) 的最优控制具有如下形式:

$$\begin{aligned} u^*(x, t) &= -\sqrt{2\eta_t} \nabla V(x, t) = -\sqrt{2\eta_t} \nabla \hat{\mathcal{V}}(x, 1-t) = -\sqrt{2\eta_t} (\nabla \mathcal{V}^*(x, 1-t) - \nabla \mathcal{V}(x, 1-t)) \\ &= -\sqrt{2\eta_t} (-\nabla \log \bar{p}_{1-t}^*(x) + \nabla \log \bar{p}_{1-t}(x)) = \sqrt{2\eta_t} (\mathfrak{s}^*(x, t) - \mathfrak{s}(x, t)), \end{aligned} \quad (169)$$

$$\iff \mathfrak{s}^*(x, t) = \mathfrak{s}(x, t) + u^*(x, t) / \sqrt{2\eta_t}. \quad (170)$$

与式 (64) 类似, 对应于正向随机微分方程 (158) 的倒向随机微分方程具有如下形式:

$$dX_t^* = (\kappa_t X_t^* + (\frac{\sigma(t)^2}{2} + \eta_t) \mathfrak{s}^*(X_t^*, t)) dt + \sigma(t) dB_t, \quad X_0^* \sim N(0, I). \quad (171)$$

将式 (170) 代入该方程, 可得

$$dX_t^* = (\kappa_t X_t^* + (\frac{\sigma(t)^2}{2} + \eta_t) (\mathfrak{s}(X_t^*, t) + \frac{u^*(X_t^*, t)}{\sqrt{2\eta_t}})) dt + \sigma(t) dB_t, \quad X_0^* \sim N(0, I), \quad (172)$$

$$\iff dX_t^* = (b(X_t^*, t) + \frac{\frac{\sigma(t)^2}{2} + \eta_t}{\sqrt{2\eta_t}} u^*(X_t^*, t)) dt + \sigma(t) dB_t, \quad X_0^* \sim N(0, I). \quad (173)$$

其中利用了 $b(x, t) = \kappa_t x +$ 根据方 (1) 中的定义 (1)。

针对去噪扩散隐式模型 (DDIM) 的微调推理随机微分方程 (SDE)。对于去噪扩散隐式模型, $\frac{\dot{\alpha}_t}{\alpha_t(1-\alpha_t)}(\epsilon^*(x, t) - \epsilon^{\text{base}}(x, t))$ 我们有 (26)。Hence,

$$\frac{\frac{\sigma(t)^2}{2} + \eta_t}{\sqrt{2\eta_t}} u^*(x, t) = -\frac{\frac{\sigma(t)^2}{2} + \frac{\dot{\alpha}_t}{2\alpha_t}}{\sqrt{\frac{\dot{\alpha}_t}{\alpha_t}}} \sqrt{\frac{\dot{\alpha}_t}{\alpha_t(1-\alpha_t)}} (\epsilon^*(x, t) - \epsilon^{\text{base}}(x, t)) = -\frac{\frac{\sigma(t)^2}{2} + \frac{\dot{\alpha}_t}{2\alpha_t}}{\sqrt{1-\alpha_t}} (\epsilon^*(x, t) - \epsilon^{\text{base}}(x, t)), \quad (174)$$

$$\begin{aligned} \implies b(x, t) + \frac{\frac{\sigma(t)^2}{2} + \eta_t}{\sqrt{2\eta_t}} u^*(x, t) &= \frac{\dot{\alpha}_t}{2\alpha_t} X_t - \left(\frac{\dot{\alpha}_t}{2\alpha_t} + \frac{\sigma(t)^2}{2} \right) \frac{\epsilon^{\text{base}}(X_t, t)}{\sqrt{1-\alpha_t}} - \frac{\frac{\sigma(t)^2}{2} + \frac{\dot{\alpha}_t}{2\alpha_t}}{\sqrt{1-\alpha_t}} (\epsilon^*(x, t) - \epsilon^{\text{base}}(x, t)) \\ &= \frac{\dot{\alpha}_t}{2\alpha_t} X_t - \left(\frac{\dot{\alpha}_t}{2\alpha_t} + \frac{\sigma(t)^2}{2} \right) \frac{\epsilon^*(X_t, t)}{\sqrt{1-\alpha_t}}. \end{aligned} \quad (175)$$

我们得到针对去噪扩散隐式模型的微调推理随机微分方程为

$$dX_t^* = \left(\frac{\dot{\alpha}_t}{2\alpha_t} X_t^* - \left(\frac{\dot{\alpha}_t}{2\alpha_t} + \frac{\sigma(t)^2}{2} \right) \frac{\epsilon^*(X_t^*, t)}{\sqrt{1-\alpha_t}} \right) dt + \sigma(t) dB_t, \quad X_0^* \sim N(0, I), \quad (176)$$

这与选择 $\epsilon = \epsilon^*$ 时的随机微分方程 (6) 一致。

针对流匹配 (Flow Matching) 的微调推理随机微分方程。对于流匹配, 由 (27) 式我们有 $\sqrt{\frac{2}{\beta_t(\frac{\dot{\alpha}_t}{\alpha_t}\beta_t - \dot{\beta}_t)}}(v^*(x, t) - v^{\text{base}}(x, t))$ 因此,

$$\begin{aligned} \frac{\frac{\sigma(t)^2}{2} + \eta_t}{\sqrt{2\eta_t}} u^*(x, t) &= \frac{\frac{\sigma(t)^2}{2} + \beta_t(\frac{\dot{\alpha}_t}{\alpha_t}\beta_t - \dot{\beta}_t)}{\sqrt{2\beta_t(\frac{\dot{\alpha}_t}{\alpha_t}\beta_t - \dot{\beta}_t)}} \sqrt{\frac{2}{\beta_t(\frac{\dot{\alpha}_t}{\alpha_t}\beta_t - \dot{\beta}_t)}} (v^*(x, t) - v^{\text{base}}(x, t)) \\ &= \left(1 + \frac{\sigma(t)^2}{2\beta_t(\frac{\dot{\alpha}_t}{\alpha_t}\beta_t - \dot{\beta}_t)} \right) (v^*(x, t) - v^{\text{base}}(x, t)). \end{aligned} \quad (177)$$

$$\begin{aligned} \implies b(x, t) + \frac{\frac{\sigma(t)^2}{2} + \eta_t}{\sqrt{2\eta_t}} u^*(x, t) &= v^{\text{base}}(x, t) + \frac{\sigma(t)^2}{2\beta_t(\frac{\dot{\alpha}_t}{\alpha_t}\beta_t - \dot{\beta}_t)} (v^{\text{base}}(x, t) - \frac{\dot{\alpha}_t}{\alpha_t} x) \\ &\quad + \left(1 + \frac{\sigma(t)^2}{2\beta_t(\frac{\dot{\alpha}_t}{\alpha_t}\beta_t - \dot{\beta}_t)} \right) (v^*(x, t) - v^{\text{base}}(x, t)) \\ &= v^*(x, t) + \frac{\sigma(t)^2}{2\beta_t(\frac{\dot{\alpha}_t}{\alpha_t}\beta_t - \dot{\beta}_t)} (v^*(x, t) - \frac{\dot{\alpha}_t}{\alpha_t} x). \end{aligned} \quad (178)$$

我们得到针对流匹配的微调推理随机微分方程为

$$dX_t^* = \left(v(X_t^*, t) + \frac{\sigma(t)^2}{2\beta_t(\frac{\dot{\alpha}_t}{\alpha_t}\beta_t - \dot{\beta}_t)} (v^*(X_t^*, t) - \frac{\dot{\alpha}_t}{\alpha_t} X_t^*) \right) dt + \sigma(t) dB_t, \quad X_0^* \sim N(0, I), \quad (179)$$

这与选择 $v = v^*$ 时的方程 (4) 一致。

附录 E 损失函数推导

E.1 连续伴随方法的推导

命题 6。 伴随损失 $\mathcal{L}(u; \mathbf{X})$ (定义于 (28)) 关于控制参数 θ 的梯度 $\frac{d\mathcal{L}}{d\theta}$ 可表示为 (32) 式。

证明。首先，注意到我们可以写出

$$\begin{aligned} & \nabla_{\theta} \mathbb{E} \left[\int_0^T \left(\frac{1}{2} \|u_{\theta}(X_t^{u_{\theta}}, t)\|^2 + f(X_t^{u_{\theta}}, t) \right) dt + g(X_T^{u_{\theta}}) \right] \\ &= \mathbb{E} \left[\int_0^T \nabla_{\theta} u_{\theta}(X_t^{u_{\theta}}, t) u_{\theta}(X_t^{u_{\theta}}, t) dt \right] + \nabla_{\theta} \mathbb{E} \left[\int_0^T \left(\frac{1}{2} \|v(X_t^{u_{\theta}}, t)\|^2 + f(X_t^{u_{\theta}}, t) \right) dt + g(X_T^{u_{\theta}}) \right] |_{v=\text{stopgrad}(u_{\theta})}. \end{aligned} \quad (180)$$

为展开第二项，我们应用引理 5。即，由莱布尼茨法则和方程 (185)，我们有

$$\begin{aligned} & \nabla_{\theta} \mathbb{E} \left[\int_0^T \left(\frac{1}{2} \|v(X_t^{u_{\theta}}, t)\|^2 + f(X_t^{u_{\theta}}, t) \right) dt + g(X_T^{u_{\theta}}) \right] |_{v=\text{stopgrad}(u_{\theta})} \\ &= \mathbb{E} \left[\nabla_{\theta} \left(\int_0^T \left(\frac{1}{2} \|v(X_t^{u_{\theta}}, t)\|^2 + f(X_t^{u_{\theta}}, t) \right) dt + g(X_T^{u_{\theta}}) \right) \right] |_{v=\text{stopgrad}(u_{\theta})} \\ &= \mathbb{E} \left[\int_0^T (\nabla_{\theta} u_{\theta})(X_t^{u_{\theta}}(\omega), t)^{\top} \sigma(t)^{\top} a_t(\omega) dt \right]. \end{aligned} \quad (181)$$

将上式右侧代入 (180) 即完成证明。 $\square$

引理 5。 设 v 为任意固定向量场。常微分方程的唯一解

$$\frac{d}{dt} a(t; \mathbf{X}^u, u) = - \left[\left(\nabla_{X_t^u} (b(X_t^u, t) + \sigma(t)u(X_t^u, t)) \right)^{\top} a(t; \mathbf{X}^u, u) + \nabla_{X_t^u} \left(f(X_t^u, t) + \frac{1}{2} \|v(X_t^u, t)\|^2 \right) \right], \quad (182)$$

$$a(1; \mathbf{X}^u, u) = \nabla g(X_1^u), \quad (183)$$

满足：

$$\begin{aligned} a(t; \mathbf{X}^u, u) &:= \nabla_{X_t^u} \left(\int_t^1 \left(\frac{1}{2} \|u(X_{t'}^u, t')\|^2 + f(X_{t'}^u, t') \right) dt' + g(X_1^u) \right), \\ \text{where } \mathbf{X}^u \text{ solves } dX_t^u &= (b(X_t^u, t) + \sigma(t)u(X_t^u, t)) dt + \sigma(t)dB_t. \end{aligned} \quad (184)$$

此外，当 $u = u_{\theta}$ 由 θ 参数化时，我们有

$$\nabla_{\theta} \left(\int_0^T \left(\frac{1}{2} \|v(X_t^{u_{\theta}}, t)\|^2 + f(X_t^{u_{\theta}}, t) \right) dt + g(X_T^{u_{\theta}}) \right) = \int_0^T (\nabla_{\theta} u_{\theta})(X_t^{u_{\theta}}(\omega), t) \sigma(t)^{\top} a_t(\omega) dt. \quad (185)$$

证明。我们采用基于拉格朗日乘子 (Lagrange Multiplier) 的方法，该方法借鉴并推广了伴随常微分方程 (Adjoint ODE) 的推导 (Domingo-Enrich 等人, 2023, 引理 8)。为简洁起见，我们使用记号 $\tilde{b}_{\theta}(x, t) := b(x, t) + \sigma(t)u_{\theta}(x, t)$ 。定义一个过程 $a : \Omega \times [0, T] \rightarrow \mathbb{R}^d$ ，使得对于任意 $\omega \in \Omega$ ， $a(\omega, \cdot)$ 是可微的。对于给定的 $\omega \in \Omega$ ，我们可以写出

$$\begin{aligned} & \int_0^T \left(\frac{1}{2} \|v(X_t^{u_{\theta}}, t)\|^2 + f(X_t^{u_{\theta}}, t) \right) dt + g(X_T^{u_{\theta}}) \\ &= \int_0^T \left(\frac{1}{2} \|v(X_t^{u_{\theta}}, t)\|^2 + f(X_t^{u_{\theta}}, t) \right) dt + g(X_T^{u_{\theta}}) \\ &\quad - \int_0^T \langle a_t(\omega), (dX_t^{u_{\theta}}(\omega) - \tilde{b}_{\theta}(X_t^{u_{\theta}}(\omega), t) dt - \sigma(t) dB_t) \rangle. \end{aligned} \quad (186)$$

根据随机分部积分 (Domingo-Enrich 等人, 2023, 引理 9)，我们有

$$\int_0^T \langle a_t(\omega), dX_t^{u_{\theta}}(\omega) \rangle = \langle a_T(\omega), X_T^{u_{\theta}}(\omega) \rangle - \langle a_0(\omega), X_0^{u_{\theta}}(\omega) \rangle - \int_0^T \langle X_t^{u_{\theta}}(\omega), \frac{da_t}{dt}(\omega) \rangle dt. \quad (187)$$

因此, 如果 $X_0^{u_\theta} = x_0$ 是初始条件, 我们有 ⁹

$$\begin{aligned}
& \nabla_{x_0} \left(\int_0^T \left(\frac{1}{2} \|v(X_t^{u_\theta}, t)\|^2 + f(X_t^{u_\theta}, t) \right) dt + g(X_T^{u_\theta}) \right) \\
&= \nabla_{x_0} \left(\int_0^T \left(\frac{1}{2} \|v(X_t^{u_\theta}, t)\|^2 + f(X_t^{u_\theta}, t) \right) dt + g(X_T^{u_\theta}) \right. \\
&\quad \left. - \langle a_T(\omega), X_T^{u_\theta}(\omega) \rangle + \langle a_0(\omega), X_0^{u_\theta}(\omega) \rangle + \int_0^T (\langle a_t(\omega), \tilde{b}_\theta(X_t^{u_\theta}(\omega), t) \rangle + \langle \frac{da_t}{dt}(\omega), X_t^{u_\theta}(\omega) \rangle) dt \right. \\
&\quad \left. + \int_0^T \langle a_t(\omega), \sigma(t) dB_t \rangle \right) \\
&= \int_0^T \nabla_{x_0} X_t^{u_\theta}(\omega)^\top \nabla_x \left(\frac{1}{2} \|v(X_t^{u_\theta}, t)\|^2 + f(X_t^{u_\theta}(\omega), t) \right) dt + \nabla_{x_0} X_T^{u_\theta}(\omega)^\top \nabla_x g(X_T^{u_\theta}(\omega)) \\
&\quad - \nabla_{x_0} X_T^{u_\theta}(\omega)^\top a_T(\omega) + \nabla_{x_0} X_0^{u_\theta}(\omega)^\top a_0(\omega) \\
&\quad + \int_0^T (\nabla_{x_0} X_t^{u_\theta}(\omega)^\top \nabla_x \tilde{b}_\theta(X_t^{u_\theta}(\omega), t)^\top a_t(\omega) + \nabla_{x_0} X_t^{u_\theta}(\omega)^\top \frac{da_t}{dt}(\omega)) dt \\
&= \int_0^T \nabla_{x_0} X_t^{u_\theta}(\omega)^\top (\nabla_x (\frac{1}{2} \|v(X_t^{u_\theta}, t)\|^2 + f(X_t^{u_\theta}(\omega), t)) + \nabla_x \tilde{b}_\theta(X_t^{u_\theta}(\omega), t)^\top a_t(\omega) + \frac{da_t}{dt}(\omega)) dt \\
&\quad + \nabla_{x_0} X_T^{u_\theta}(\omega)^\top (\nabla_x g(X_T^{u_\theta}(\omega)) - a_T(\omega)) + a_0(\omega).
\end{aligned} \tag{188}$$

在最后一行中, 我们使用了 $\nabla_{x_0} X^{u_\theta}(\omega) = \nabla_{x_0} x_0 = \mathbf{I}$ 。如果选择 a 使得

$$\begin{aligned}
da_t(\omega) &= (-\nabla_x \tilde{b}_\theta(X_t^{u_\theta}(\omega), t)^\top a_t(\omega) - \nabla_x (\frac{1}{2} \|v(X_t^{u_\theta}, t)\|^2 + f(X_t^{u_\theta}(\omega), t))) dt, \\
a_T(\omega) &= \nabla_x g(X_T^{u_\theta}(\omega)),
\end{aligned} \tag{189}$$

which is the ODE (182)-(183), then we obtain that

$$\nabla_{x_0} \left(\int_0^T \left(\frac{1}{2} \|v(X_t^{u_\theta}, t)\|^2 + f(X_t^{u_\theta}, t) \right) dt + g(X_T^{u_\theta}) \right) = a_0(\omega) \tag{190}$$

不失一般性, 该论证可从 $t = 0$ 推广至任意 $t \in [0, 1]$, 从而证明引理的第一部分。为证明 (185), 我们类似地写出

$$\begin{aligned}
& \nabla_\theta \left(\int_0^T \left(\frac{1}{2} \|v(X_t^{u_\theta}, t)\|^2 + f(X_t^{u_\theta}, t) \right) dt + g(X_T^{u_\theta}) \right) \\
&= \nabla_\theta \left(\int_0^T \left(\frac{1}{2} \|v(X_t^{u_\theta}, t)\|^2 + f(X_t^{u_\theta}, t) \right) dt + g(X_T^{u_\theta}) \right. \\
&\quad \left. - \langle a_T(\omega), X_T^{u_\theta}(\omega) \rangle + \langle a_0(\omega), X_0^{u_\theta}(\omega) \rangle + \int_0^T (\langle a_t(\omega), \tilde{b}_\theta(X_t^{u_\theta}(\omega), t) \rangle + \langle \frac{da_t}{dt}(\omega), X_t^{u_\theta}(\omega) \rangle) dt \right. \\
&\quad \left. + \int_0^T \langle a_t(\omega), \sigma(t) dB_t \rangle \right) \\
&= \int_0^T \nabla_\theta X_t^{u_\theta}(\omega)^\top \nabla_x \left(\frac{1}{2} \|v(X_t^{u_\theta}, t)\|^2 + f(X_t^{u_\theta}(\omega), t) \right) dt + \nabla_\theta X_T^{u_\theta}(\omega)^\top \nabla_x g(X_T^{u_\theta}(\omega)) \\
&\quad - \nabla_\theta X_T^{u_\theta}(\omega)^\top a_T(\omega) + \nabla_\theta X_0^{u_\theta}(\omega)^\top a_0(\omega) \\
&\quad + \int_0^T (\nabla_\theta X_t^{u_\theta}(\omega)^\top \nabla_x \tilde{b}_\theta(X_t^{u_\theta}(\omega), t)^\top a_t(\omega) + \nabla_\theta \tilde{b}_\theta(X_t^{u_\theta}(\omega), t)^\top a_t(\omega) + \nabla_\theta X_t^{u_\theta}(\omega)^\top \frac{da_t}{dt}(\omega)) dt \\
&= \int_0^T \nabla_\theta X_t^{u_\theta}(\omega)^\top (\nabla_x (\frac{1}{2} \|v(X_t^{u_\theta}, t)\|^2 + f(X_t^{u_\theta}(\omega), t)) + \nabla_x \tilde{b}_\theta(X_t^{u_\theta}(\omega), t)^\top a_t(\omega) + \frac{da_t}{dt}(\omega)) dt \\
&\quad + \nabla_\theta X_T^{u_\theta}(\omega)^\top (\nabla_x g(X_T^{u_\theta}(\omega)) - a_T(\omega)) + \int_0^T (\nabla_\theta \tilde{b}_\theta)(X_t^{u_\theta}(\omega), t)^\top a_t(\omega) dt.
\end{aligned} \tag{191}$$

在最后一行中, 我们使用了 $\nabla_\theta X^{u_\theta}(\omega) = \nabla_\theta x = 0$ 当 a 满足 (189) 时, 我们得到

$$\begin{aligned}
& \nabla_\theta \left(\int_0^T \left(\frac{1}{2} \|v(X_t^{u_\theta}, t)\|^2 + f(X_t^{u_\theta}, t) \right) dt + g(X_T^{u_\theta}) \right) \\
&= \int_0^T (\nabla_\theta \tilde{b}_\theta)(X_t^{u_\theta}(\omega), t)^\top a_t(\omega) dt = \int_0^T (\nabla_\theta u_\theta)(X_t^{u_\theta}(\omega), t)^\top \sigma(t)^\top a_t(\omega) dt.
\end{aligned} \tag{192}$$

最后一个等式成立是因为 ⁹ 与 $\tilde{b}_\theta(x, t) := b(x, t) + \sigma(t)u_\theta(x, t)$. (Domingo-Enrich 等人, 2023, 引理 8) 不同, 我们采用雅可比矩阵 $J = \nabla_x v(x)$ 定义为 $J_{ij} = \frac{\partial v_i(x)}{\partial x_j}$ 的约定。他们对 $\nabla_x v$ 的定义是本文定义的转置。

E.2 命题 2 的证明：基本伴随匹配损失的理论保证 令 $\bar{u} = \text{stopgrad}(u_\theta)$ 。我们可以将方程 (32) 重写为：

$$\nabla_\theta \mathcal{L}(u_\theta; \mathbf{X}^{\bar{u}}) = \frac{1}{2} \int_0^1 \nabla_\theta \|u_\theta(X_t^{\bar{u}}, t)\|^2 dt + \int_0^1 \nabla_\theta u(X_t^{\bar{u}}, t)^\top \sigma(t)^\top a(t; \mathbf{X}^{\bar{u}}, \bar{u}) dt \quad (193)$$

$$= \frac{1}{2} \int_0^1 \nabla_\theta \|u_\theta(X_t^{\bar{u}}, t) + \sigma(t)^\top a(t; \mathbf{X}^{\bar{u}}, \bar{u})\|^2 dt = \nabla_\theta \mathcal{L}_{\text{Basic-Adj-Match}}(u_\theta; \mathbf{X}^{\bar{u}}) \quad (194)$$

这证明了命题的第一部分。为证明期望基本伴随匹配损失的唯一临界点是最优控制，我们首先计算 $\mathbb{E}[\mathcal{L}_{\text{Basic-Adj-Match}}]$ 的一阶变分。令 $v : \mathbb{R}^d \times [0, T] \rightarrow \mathbb{R}^d$ 为任意，我们有

$$\begin{aligned} \frac{d}{d\epsilon} \mathbb{E}[\mathcal{L}_{\text{Basic-Adj-Match}}(u + \epsilon v; \mathbf{X}^{\bar{u}})] &= \frac{d}{d\epsilon} \mathbb{E}\left[\frac{1}{2} \int_0^T \|(u + \epsilon v)(X_t^{\bar{u}}, t) + \sigma(t)^\top a(t, X_t^{\bar{u}}, \bar{u})\|^2 dt\right] \\ &= \mathbb{E}\left[\int_0^T \langle v(X_t^{\bar{u}}, t), u(X_t^{\bar{u}}, t) + \sigma(t)^\top a(t, X_t^{\bar{u}}, \bar{u}) \rangle dt\right] \\ &= \mathbb{E}\left[\int_0^T \langle v(X_t^{\bar{u}}, t), u(X_t^{\bar{u}}, t) + \sigma(t)^\top \mathbb{E}[a(t, X_t^{\bar{u}}, \bar{u}) | X_t^{\bar{u}}] \rangle dt\right] \\ &\implies \frac{\delta}{\delta u} \mathbb{E}[\mathcal{L}_{\text{Basic-Adj-Match}}(u)(x, t)] = u(x, t) + \mathbb{E}[a(t, X_t^{\bar{u}}, \bar{u}) | X_t^{\bar{u}} = x] \end{aligned} \quad (195)$$

因此，临界点满足

$$\begin{aligned} u(x, t) &= -\sigma(t)^\top \mathbb{E}[a(t, X_t^u, u) | X_t^u = x] = -\sigma(t)^\top \mathbb{E}\left[\nabla_{X_t^v} \int_t^T \left(\frac{1}{2} \|v(X_t^v, t)\|^2 + f(X_t^v, t)\right) dt + g(X_T^v) | X_0^v = x\right] \\ &= -\sigma(t)^\top \nabla_x \mathbb{E}\left[\int_t^T \left(\frac{1}{2} \|v(X_t^v, t)\|^2 + f(X_t^v, t)\right) dt + g(X_T^v) | X_0^v = x\right] = -\sigma(t)^\top \nabla J(u; x, t), \end{aligned} \quad (196)$$

在该方程中，第二个等式由引理 5 中的方程 (184) 成立，第三个等式由莱布尼茨法则成立。引理 6 表明，任何满足 (196) 的控制 u 都等于最优控制，从而完成证明。

引理 6. 假设对任意 $x \in \mathbb{R}^d$, $t \in [0, T]$, $u(x, t) = -\sigma(t)^\top \nabla_x J(u; x, t)$ 成立。则 $J(u; \cdot, \cdot)$ 满足哈密顿-雅可比-贝尔曼方程 (156)。由 HJB 方程解的唯一性，我们有 $J(u; x, t) = V(x, t)$ 对任意 $x \in \mathbb{R}^d$, $t \in [0, T]$ 成立。因此， $u(x, t) = -\sigma(t)^\top \nabla_x V(x, t)$ 是最优控制。

证明。由于 $J(u; x, t) = \mathbb{E}\left[\int_t^T \left(\frac{1}{2} \|u(X_s^u, s)\|^2 + f(X_s^u, s)\right) ds + g(X_T^u) | X_t^u = x\right]$, we have that

$$J(u; x, t) = \mathbb{E}[J(u; X_{t+\Delta t}^u, t + \Delta t) | X_t = x] + \mathbb{E}\left[\int_t^{t+\Delta t} \left(\frac{1}{2} \|u(X_s^u, s)\|^2 + f(X_s^u, s)\right) ds | X_t = x\right], \quad (197)$$

这意味着

$$0 = \frac{\mathbb{E}[J(u; X_{t+\Delta t}^u, t + \Delta t) | X_t = x] - J(u; x, t)}{\Delta t} + \frac{\mathbb{E}\left[\int_t^{t+\Delta t} \left(\frac{1}{2} \|u(X_s^u, s)\|^2 + f(X_s^u, s)\right) ds | X_t = x\right]}{\Delta t} \quad (198)$$

回顾受控随机微分方程 (SDE) (13) 的生成元 $\mathcal{T}^u$ 具有如下形式：

$$\begin{aligned} \mathcal{T}^u f(x, t) &:= \lim_{\Delta t \rightarrow 0} \frac{\mathbb{E}[f(X_{t+\Delta t}^u, t) | X_t = x] - f(x, t)}{\Delta t} \\ &= \partial_t f(x, t) + \langle \nabla f(x, t), b(x, t) + \sigma(t)u(x, t) \rangle + \text{Tr}\left(\frac{\sigma(t)\sigma(t)^\top}{2} \nabla^2 f(x, t)\right) \end{aligned} \quad (199)$$

因此，若对方程 (198) 取极限 $\Delta t \rightarrow 0$ ，则可得：

$$\begin{aligned} 0 &= \mathcal{T}^u J(u; x, t) + \frac{1}{2} \|u(x, t)\|^2 + f(x, t) \\ &= \partial_t J(u; x, t) + \langle \nabla J(u; x, t), b(x, t) + \sigma(t)u(x, t) \rangle + \text{Tr}\left(\frac{\sigma(t)\sigma(t)^\top}{2} \nabla^2 J(u; x, t)\right) + \frac{1}{2} \|u(x, t)\|^2 + f(x, t). \end{aligned} \quad (200)$$

现在利用 $u(x, t) = -\sigma(t)^\top \nabla_x J(u; x, t)$ ，我们得到

$$\begin{aligned} \langle \nabla J(u; x, t), \sigma(t)u(x, t) \rangle + \frac{1}{2} \|u(x, t)\|^2 &= -\|\sigma(t)^\top \nabla_x J(u; x, t)\|^2 + \frac{1}{2} \|\sigma(t)^\top \nabla_x J(u; x, t)\|^2 \\ &= -\frac{1}{2} \|\sigma(t)^\top \nabla_x J(u; x, t)\|^2. \end{aligned} \quad (201)$$

将其代入式 (200) , 可得

$$0 = \partial_t J(u; x, t) + \langle \nabla J(u; x, t), b(x, t) \rangle + \text{Tr} \left(\frac{\sigma(t)\sigma(t)^\top}{2} \nabla^2 J(u; x, t) \right) - \frac{1}{2} \|\sigma(t)^\top \nabla_x J(u; x, t)\|^2 + f(x, t). \quad (202)$$

由于 $J(u; x, T) = g(x)$ 由构造保证, 因此我们得出结论: $J(u; x, t)$ 满足哈密顿-雅可比-贝尔曼方程 (156) 。 $\square$

E.3 伴随匹配损失的理论保证

命题 7 (伴随匹配损失的理论保证)。损失 $\mathbb{E}[\mathcal{L}_{\text{Adj-Match}}]$ 的唯一临界点是最优控制 u 。

证明。设 v 为任意控制。若 $\tilde{a}(t; \mathbf{X}^v)$ 是精益伴随常微分方程 (38) - (39) 的解, 则它满足积分方程

$$\tilde{a}(t; \mathbf{X}^v) = \int_t^T (\nabla_x b(X_s^v, s)^\top \tilde{a}(s; \mathbf{X}^v) + \nabla_x f(X_s^v, s)) ds + \nabla g(X_T^v). \quad (203)$$

因此,

$$\begin{aligned} \mathbb{E}[\tilde{a}(t; \mathbf{X}^v) | X_t^v] &= \mathbb{E} \left[\int_t^T (\nabla_x b(X_s^v, s)^\top \tilde{a}(s; \mathbf{X}^v) + \nabla_x f(X_s^v, s)) ds + \nabla g(X_T^v) | X_t^v \right] \\ &= \mathbb{E} \left[\int_t^T (\nabla_x b(X_s^v, s)^\top \mathbb{E}[\tilde{a}(s; \mathbf{X}^v) | X_s^v] + \nabla_x f(X_s^v, s)) ds + \nabla g(X_T^v) | X_t^v \right], \end{aligned} \quad (204)$$

其中我们在第二个等式中使用了条件期望的塔性质。类似地, 若 $a(t; \mathbf{X}^v, v)$ 是伴随常微分方程 (30) - (31) 的解, 则它满足积分方程

$$a(t; \mathbf{X}^v, v) = \int_t^T (\nabla_x (b(X_s^v, s)^\top a(s; \mathbf{X}^v, v) + \sigma(s)v(X_s^v, s)) + \nabla_x (f(X_s^v, s) + \frac{1}{2} \|v(X_s^v, s)\|^2)) ds + \nabla g(X_T^v), \quad (205)$$

且其期望值满足

$$\begin{aligned} \mathbb{E}[a(t; \mathbf{X}^v, v) | X_t^v] &= \mathbb{E} \left[\int_t^T (\nabla_x (b(X_s^v, s)^\top a(s; \mathbf{X}^v, v) + \sigma(s)v(X_s^v, s)) + \nabla_x (f(X_s^v, s) + \frac{1}{2} \|v(X_s^v, s)\|^2)) ds + \nabla g(X_T^v) | X_t^v \right] \\ &= \mathbb{E} \left[\int_t^T (\nabla_x (b(X_s^v, s)^\top \mathbb{E}[a(s; \mathbf{X}^v, v) | X_s^v] + \sigma(s)v(X_s^v, s)) + \nabla_x (f(X_s^v, s) + \frac{1}{2} \|v(X_s^v, s)\|^2)) ds + \nabla g(X_T^v) | X_t^v \right]. \end{aligned} \quad (206)$$

让我们将 $\mathbb{E}[\mathcal{L}_{\text{Adj-Match}}]$ 改写如下:

$$\begin{aligned} \mathbb{E}[\mathcal{L}_{\text{Adj-Match}}(u)] &:= \mathbb{E} \left[\int_0^T \|u(X_t^v, t) + \sigma(t)^\top \mathbb{E}[\tilde{a}(t, \mathbf{X}^v) | X_t^v]\|^2 dt \right] |_{v=\text{stopgrad}(u)} \\ &\quad + \mathbb{E} \left[\int_0^T \|\sigma(t)^\top (\mathbb{E}[\tilde{a}(t, \mathbf{X}^v) | X_t^v] - \tilde{a}(t, \mathbf{X}^v))\|^2 dt \right] |_{v=\text{stopgrad}(u)}, \end{aligned} \quad (207)$$

现在, 假设 $\hat{u}$ 是 $\mathbb{E}[\mathcal{L}_{\text{Adj-Match}}]$ 的临界点。根据定义, 这意味着 $\mathbb{E}[\mathcal{L}_{\text{Adj-Match}}]$ 的一阶变分为零。利用 (207) , 我们可以将其写为如下形式:

$$0 = \frac{\delta}{\delta u} \mathbb{E}[\mathcal{L}_{\text{Adj-Match}}(\hat{u})](x) = 2(\hat{u}(x, t) + \sigma(t)^\top \mathbb{E}[\tilde{a}(t, \mathbf{X}^{\hat{u}}) | X_t^{\hat{u}} = x]), \quad (208)$$

$$\implies \hat{u}(x, t) = -\sigma(t)^\top \mathbb{E}[\tilde{a}(t, \mathbf{X}^{\hat{u}}) | X_t^{\hat{u}} = x]. \quad (209)$$

因此, 我们有

$$\nabla_x \hat{u}(X_t^{\hat{u}}, t)^\top \sigma(t)^\top \mathbb{E}[\tilde{a}(t, \mathbf{X}^{\hat{u}}) | X_t^{\hat{u}}] + \nabla_x \hat{u}(X_t^{\hat{u}}, t)^\top \hat{u}(X_t^{\hat{u}}, t) = 0, \quad (210)$$

$$\implies \mathbb{E} \left[\int_t^T (\nabla_x (\sigma(s)^\top \hat{u}(X_s^{\hat{u}}, s))^\top \mathbb{E}[\tilde{a}(s; \mathbf{X}^{\hat{u}}) | X_s^{\hat{u}}] + \nabla_x (\frac{1}{2} \|\hat{u}(X_s^{\hat{u}}, s)\|^2)) ds | X_t^{\hat{u}} \right] = 0. \quad (211)$$

若我们在方程 (204) 中令 $v = \hat{u}$, 并将 (211) 加到其右侧, 则得到 $\mathbb{E}[\tilde{a}(t, \mathbf{X}^{\hat{u}}) | X_t^{\hat{u}}]$ 也满足该积分方程

$$\begin{aligned} \mathbb{E}[\tilde{a}(t; \mathbf{X}^{\hat{u}}) | X_t^{\hat{u}}] &= \mathbb{E} \left[\int_t^T (\nabla_x (b(X_s^{\hat{u}}, s)^\top \mathbb{E}[\tilde{a}(s; \mathbf{X}^{\hat{u}}) | X_s^{\hat{u}}] + \sigma(s)^\top \hat{u}(X_s^{\hat{u}}, s)) + \nabla_x (f(X_s^{\hat{u}}, s) + \frac{1}{2} \|\hat{u}(X_s^{\hat{u}}, s)\|^2)) ds + \nabla g(X_T^{\hat{u}}) | X_t^{\hat{u}} \right]. \end{aligned} \quad (212)$$

注意，当我们在后一方程中设定 $v = \hat{u}$ 时，该积分方程与方程 (206) 相同。

命题 8 指出积分方程的解是唯一的，这意味着 $\mathbb{E}[\tilde{a}(t; \mathbf{X}^{\hat{u}})|X_t^{\hat{u}}] = \mathbb{E}[a(t; \mathbf{X}^{\hat{u}}, \hat{u})|X_t^{\hat{u}}]$ for all $t \in [0, T]$.

由于我们可以将基本伴随匹配损失重新表示为

$$\begin{aligned} \mathbb{E}[\mathcal{L}_{\text{Basic-Adj-Match}}(u)] &:= \mathbb{E}\left[\int_0^T \|u(X_t^v, t) + \sigma(t)^\top \mathbb{E}[a(t; \mathbf{X}^v, v)|X_t^v]\|^2 dt\right]_{v=\text{stopgrad}(u)} \\ &\quad + \mathbb{E}\left[\int_0^T \|\sigma(t)^\top (\mathbb{E}[a(t; \mathbf{X}^v, v)|X_t^v] - a(t; \mathbf{X}^v, v))\|^2 dt\right]_{v=\text{stopgrad}(u)}, \end{aligned} \quad (213)$$

我们得到当 $\hat{u}$ 是 $\mathbb{E}[\mathcal{L}_{\text{Adj-Match}}]$ 的临界点时，

$$\begin{aligned} \frac{d}{du} \mathbb{E}[\mathcal{L}_{\text{Basic-Adj-Match}}(\hat{u})](x) &= 2(\hat{u}(x, t) + \sigma(t)^\top \mathbb{E}[a(t; \mathbf{X}^{\hat{u}}, \hat{u})|X_t^{\hat{u}} = x]) \\ &= 2(\hat{u}(x, t) + \sigma(t)^\top \mathbb{E}[\tilde{a}(t; \mathbf{X}^{\hat{u}})|X_t^{\hat{u}} = x]) = 0, \end{aligned} \quad (214)$$

其中第二个等式成立是因为 $\mathbb{E}[\tilde{a}(t; \mathbf{X}^{\hat{u}})|X_t^{\hat{u}}] = \mathbb{E}[a(t; \mathbf{X}^{\hat{u}}, \hat{u})|X_t^{\hat{u}}]$ ，第三个等式由方程 (209) 成立。因此，我们推断 $\mathbb{E}[\mathcal{L}_{\text{Adj-Match}}]$ 的临界点也是 $\mathbb{E}[\mathcal{L}_{\text{Basic-Adj-Match}}]$ 的临界点。根据命题 2， $\mathbb{E}[\mathcal{L}_{\text{Basic-Adj-Match}}]$ 具有唯一的临界点，即最优控制 u^* ，这完成了对 $\mathbb{E}[\mathcal{L}_{\text{Adj-Match}}]$ 的陈述的证明。 $\square$

命题 8. 设 v 为任意控制。考虑积分方程：

$$Y_t = \mathbb{E}\left[\int_t^T \left(\nabla_x(b(X_s^v, s) + \sigma(s)v(X_s^v, s))^\top Y_s + \nabla_x(f(X_s^v, s) + \frac{1}{2}\|v(X_s^v, s)\|^2)\right) ds + \nabla g(X_T^v)|X_t^v\right], \quad (215)$$

其中 $t \in [0, T]$ 。该方程有唯一解，即如果 Y^1, Y^2 是两个解，则 $Y^1 = Y^2$ 。

证明。设 Y^1, Y^2 为积分方程的两个解。我们有

$$Y_t^1 - Y_t^2 = \mathbb{E}\left[\int_t^T ((Y_s^1 - Y_s^2)^\top \nabla_x b(X_s^*, s)) ds | X_t^*\right]. \quad (216)$$

因此，

$$\begin{aligned} \|Y_t^1 - Y_t^2\| &\leq \mathbb{E}\left[\left\|\int_t^T ((Y_s^1 - Y_s^2)^\top \nabla_x b(X_s^*, s)) ds\right\| | X_t^*\right] \leq \mathbb{E}\left[\int_t^T \|((Y_s^1 - Y_s^2)^\top \nabla_x b(X_s^*, s))\| ds | X_t^*\right] \\ &\leq \mathbb{E}\left[\int_t^T \|Y_s^1 - Y_s^2\| \cdot \|\nabla_x b(X_s^*, s)\| ds | X_t^*\right] = \int_t^T \mathbb{E}\left[\|Y_s^1 - Y_s^2\| \cdot \|\nabla_x b(X_s^*, s)\| | X_t^*\right] ds \\ &\leq \int_t^T (\mathbb{E}[\|Y_s^1 - Y_s^2\|^2 | X_t^*])^{1/2} \cdot (\mathbb{E}[\|\nabla_x b(X_s^*, s)\|^2 | X_t^*])^{1/2} ds \end{aligned} \quad (217)$$

这意味着

$$\begin{aligned} &\sup_{t' \in [0, t]} (\mathbb{E}[\|Y_t^1 - Y_t^2\|^2 | X_{t'}^*])^{1/2} \\ &\leq \int_t^T (\mathbb{E}[\|Y_s^1 - Y_s^2\|^2 | X_t^*])^{1/2} \cdot (\mathbb{E}[\|\nabla_x b(X_s^*, s)\|^2 | X_t^*])^{1/2} ds \\ &\leq \int_t^T \sup_{t' \in [0, s]} (\mathbb{E}[\|Y_s^1 - Y_s^2\|^2 | X_{t'}^*])^{1/2} \cdot \sup_{t' \in [0, s]} (\mathbb{E}[\|\nabla_x b(X_s^*, s)\|^2 | X_{t'}^*])^{1/2} ds. \end{aligned} \quad (218)$$

对函数 $f(t) = \sup_{t' \in [0, t]} (\mathbb{E}[\|Y_t^1 - Y_t^2\|^2 | X_{t'}^*])^{1/2}$ ，我们得到

$\sup_{t' \in [0, t]} (\mathbb{E}[\|Y_t^1 - Y_t^2\|^2 | X_{t'}^*])^{1/2} = 0$ 对所有 $t \in [0, T]$ ，这意味着几乎必然成 $Y_t^1 = Y_t^2$ 立。并且由于 $\|Y_t^1 - Y_t^2\| \leq \int_t^T (\mathbb{E}[\|Y_s^1 - Y_s^2\|^2 | X_t^*])^{1/2} \cdot (\mathbb{E}[\|\nabla_x b(X_s^*, s)\|^2 | X_t^*])^{1/2} ds = 0$ ，我们得到 $Y^1 = Y^2$ 。 $\square$

E.4 用于 DDIM 微调的伴随匹配伪代码

注意，对于方程对 (219)-(220)、(221)-(222)、(223)-(224)，第一个方程对应 DDPM 论文中的更新，而第二个方程是连续时间对象的欧拉-丸山/欧拉离散化。为验证两种离散化在一阶精度上相等，注意到

$$\sqrt{\frac{\bar{\alpha}_{k+1}}{\bar{\alpha}_k}} = \sqrt{1 + \frac{\bar{\alpha}_{k+1} - \bar{\alpha}_k}{\bar{\alpha}_k}} \approx 1 + \frac{\bar{\alpha}_{k+1} - \bar{\alpha}_k}{2\bar{\alpha}_k} + O((\bar{\alpha}_{k+1} - \bar{\alpha}_k)^2). \quad (225)$$

Algorithm 2 Adjoint Matching for fine-tuning DDIM

Input: Pre-trained denoiser ϵ^{base} , number of fine-tuning iterations N .

Initialize fine-tuned denoiser: $\epsilon^{\text{finetune}} = \epsilon^{\text{base}}$ with parameters θ .

for $n \in \{0, \dots, N-1\}$ **do**

Sample m trajectories $\mathbf{X} = (X_t)_{t \in \{0, \dots, 1\}}$ according to DDPM, *e.g.*:

$$X_{k+1} = \sqrt{\frac{\bar{\alpha}_{k+1}}{\bar{\alpha}_k}} \left(X_k - \frac{1-\bar{\alpha}_k/\bar{\alpha}_{k+1}}{\sqrt{1-\bar{\alpha}_k}} \epsilon^{\text{finetune}}(X_k, k) \right) + \sqrt{\frac{1-\bar{\alpha}_{k+1}}{1-\bar{\alpha}_k}} \left(1 - \frac{\bar{\alpha}_k}{\bar{\alpha}_{k+1}} \right) \epsilon_k, \quad \epsilon_k \sim \mathcal{N}(0, I), \quad X_0 \sim \mathcal{N}(0, I), \quad (219)$$

$$\text{or } X_{k+1} = X_k + \frac{\bar{\alpha}_{k+1}-\bar{\alpha}_k}{2\bar{\alpha}_k} X_k - \frac{\bar{\alpha}_{k+1}-\bar{\alpha}_k}{\bar{\alpha}_k \sqrt{1-\bar{\alpha}_k}} \epsilon^{\text{finetune}}(X_k, k) + \sqrt{\frac{\bar{\alpha}_{k+1}-\bar{\alpha}_k}{\bar{\alpha}_k}} \epsilon_k. \quad (220)$$

For each trajectory, solve the *lean adjoint ODE* (38)-(39) backwards in time from $k = K$ to 0, *e.g.*:

$$\tilde{a}_k = \tilde{a}_{k+1} + \tilde{a}_{k+1}^\top \nabla_{X_k} \left(\sqrt{\frac{\bar{\alpha}_{k+1}}{\bar{\alpha}_k}} \left(X_k - \frac{1-\bar{\alpha}_k/\bar{\alpha}_{k+1}}{\sqrt{1-\bar{\alpha}_k}} \epsilon^{\text{base}}(X_k, k) \right) - X_k \right), \quad \tilde{a}_K = \nabla_{X_K} r(X_K), \quad (221)$$

$$\text{or } \tilde{a}_k = \tilde{a}_{k+1} + \tilde{a}_{k+1}^\top \nabla_{X_t} \left(\frac{\bar{\alpha}_{k+1}-\bar{\alpha}_k}{2\bar{\alpha}_k} X_k - \frac{\bar{\alpha}_{k+1}-\bar{\alpha}_k}{\bar{\alpha}_k \sqrt{1-\bar{\alpha}_k}} \epsilon^{\text{base}}(X_k, k) \right), \quad \tilde{a}_K = \nabla_{X_K} r(X_K). \quad (222)$$

Note that X_k and $\tilde{a}_k$ should be computed without gradients, *i.e.*, $X_k = \text{stopgrad}(X_k)$, $\tilde{a}_k = \text{stopgrad}(\tilde{a}_k)$.

For each trajectory, compute the Adjoint Matching objective (37):

$$\mathcal{L}_{\text{Adj-Match}}(\theta) = \sum_{k \in \{0, \dots, K-1\}} \left\| \sqrt{\frac{\bar{\alpha}_{k+1}}{\bar{\alpha}_k(1-\bar{\alpha}_{k+1})}} \left(1 - \frac{\bar{\alpha}_k}{\bar{\alpha}_{k+1}} \right) (\epsilon^{\text{finetune}}(X_k, k) - \epsilon^{\text{base}}(X_k, k)) - \sqrt{\frac{1-\bar{\alpha}_{k+1}}{1-\bar{\alpha}_k}} \left(1 - \frac{\bar{\alpha}_k}{\bar{\alpha}_{k+1}} \right) \tilde{a}_k \right\|^2, \quad (223)$$

$$\text{or } \mathcal{L}_{\text{Adj-Match}}(\theta) = \sum_{k \in \{0, \dots, K-1\}} \left\| \sqrt{\frac{\bar{\alpha}_{k+1}-\bar{\alpha}_k}{\bar{\alpha}_k(1-\bar{\alpha}_k)}} (\epsilon^{\text{finetune}}(X_k, k) - \epsilon^{\text{base}}(X_k, k)) - \sqrt{\frac{\bar{\alpha}_{k+1}-\bar{\alpha}_k}{\bar{\alpha}_k}} \tilde{a}_k \right\|^2. \quad (224)$$

Compute the gradient $\nabla_\theta \mathcal{L}(\theta)$ and update θ using favorite gradient descent algorithm.

end

Output: Fine-tuned vector field v^{finetune}

F 将扩散微调基线适配到流匹配

F.1 将 ReFL (Xu 等, 2023) 适配到流匹配 奖励反馈学习 (ReFL) 是 Xu 等 (2023) 提出的一种扩散微调算法, 旨在提高去噪样本上的奖励。具体而言, 如果 $\mathbf{X} = (X_t)_{t \in [0, 1]}$ 是 DDPM 随机微分方程 (7) 的解, 我们可以将 X_t 去噪为

$$\hat{X}_1(X_t) = \frac{X_t - \sqrt{1-\bar{\alpha}_t} \epsilon(X_t, t)}{\sqrt{\bar{\alpha}_t}}. \quad (226)$$

该方程由随机插值方程 (2) 推导而来, 只需将 $\bar{X}_0$ 替换为噪声预测器。然后, ReFL 的优化更新基于以下梯度: $\epsilon(X_t, t)$

$$\nabla_\theta r(\hat{X}_1(X_t)) = \nabla_\theta r\left(\frac{X_t - \sqrt{1-\bar{\alpha}_t} \epsilon_\theta(X_t, t)}{\sqrt{\bar{\alpha}_t}}\right), \quad (227)$$

其中轨迹已被分离。为了将 ReFL 适配到流匹配, 我们需要用向量场 v 来表示去噪映射。我们有

$$\begin{aligned} v(x, t) &= \mathbb{E}[\dot{\beta}_t \bar{X}_0 + \dot{\alpha}_t \bar{X}_1 | \beta_t \bar{X}_0 + \alpha_t \bar{X}_1 = x] = \mathbb{E}\left[\frac{\dot{\beta}_t}{\beta_t} (\beta_t \bar{X}_0 + \alpha_t \bar{X}_1) + \left(\dot{\alpha}_t - \frac{\dot{\beta}_t}{\beta_t} \alpha_t\right) \bar{X}_1 | \beta_t \bar{X}_0 + \alpha_t \bar{X}_1 = x\right] \\ &= \frac{\dot{\beta}_t}{\beta_t} x + \left(\dot{\alpha}_t - \frac{\dot{\beta}_t}{\beta_t} \alpha_t\right) \hat{X}_1(x, t). \end{aligned} \quad (228)$$

其中我们定义了去噪映射 $\hat{X}_1(x, t) := \mathbb{E}[\bar{X}_1 | \beta_t \bar{X}_0 + \alpha_t \bar{X}_1 = x]$ 。因此,

$$\hat{X}_1(x, t) = \frac{v(x, t) - \frac{\dot{\beta}_t}{\beta_t} x}{\dot{\alpha}_t - \frac{\dot{\beta}_t}{\beta_t} \alpha_t}. \quad (229)$$

F.2 将 Diffusion-DPO (Wallace 等, 2023a) 适配到流匹配 Diffusion-DPO 损失假设可以访问生成样本的排序对 $x_1^w \succ x_1^l$, 其中 x^w 和 x^l 分别是获胜样本和失败样本。对于 DDPM, 实际实现的损失为 (Wallace 等, 2023a, 式 46) :

$$L_{\text{DPO}}(\theta) = -\mathbb{E}_{(x_1^w, x_1^l) \sim \mathcal{D}, k \sim U[0, K], x_{kh}^w \sim q(x_{kh}^w | x_1^w), x_{kh}^l \sim q(x_{kh}^l | x_1^l)} \left[\log S \left(-\frac{\tilde{\beta}}{2} (\|\varepsilon^w - \epsilon_\theta(x_{kh}^w, kh)\|^2 - \|\varepsilon^w - \epsilon_{\text{ref}}(x_{kh}^w, kh)\|^2 - (\|\varepsilon^l - \epsilon_\theta(x_{kh}^l, kh)\|^2 - \|\varepsilon^l - \epsilon_{\text{ref}}(x_{kh}^l, kh)\|^2)) \right) \right], \quad (230)$$

其中 $S(x) = \frac{1}{1 + e^{-x}}$ 表示 Sigmoid 函数, $q(x_{kh}^* | x_1^*)$ 是前向过程的条件分布, 即 $x_{kh}^* = \sqrt{\gamma_{kh}} x_1^* + \sqrt{1 - \gamma_{kh}} \epsilon$, $\epsilon \sim N(0, I)$ 采样。根据 (Wallace 等, 2023a, 第 S4 节) 中 Diffusion-DPO 损失的推导, 我们观察到项 $-\frac{\tilde{\beta}}{2} \|\varepsilon^w - \epsilon_\theta(x_{kh}^w, kh)\|^2$ 来源于

$$-\frac{\tilde{\beta}}{2 \frac{\beta_{kh}}{\alpha_{kh}}} \|\hat{x}_1(x_{kh}^w) - x_1^w\|^2, \quad (231)$$

在 θ 中忽略常数项。如果我们切换到更一般的流匹配方案, 该项的对应形式为

$$-\frac{\tilde{\beta}}{2 \frac{\beta_{kh}^2}{\alpha_{kh}^2}} \|\hat{x}_1(x_{kh}^w) - x_1^w\|^2. \quad (232)$$

利用方程 (229) 中基于向量场 v 的去噪映射表达式, 可将 (232) 改写为:

$$-\frac{\tilde{\beta}}{2 \frac{\beta_{kh}^2}{\alpha_{kh}^2}} \left\| \frac{v(x_{kh}^w, kh) - \frac{\dot{\beta}_{kh}}{\beta_{kh}} x_{kh}^w}{\frac{\dot{\alpha}_{kh}}{\alpha_{kh}} \beta_{kh} - \dot{\beta}_{kh}} - x_1^w \right\|^2 = -\frac{\tilde{\beta}}{2} \left\| \frac{v(x_{kh}^w, kh) - \frac{\dot{\beta}_{kh}}{\beta_{kh}} x_{kh}^w}{\frac{\dot{\alpha}_{kh}}{\alpha_{kh}} \beta_{kh} - \dot{\beta}_{kh}} - \frac{\alpha_{kh}}{\beta_{kh}} x_1^w \right\|^2. \quad (233)$$

因此, 流匹配 (Flow Matching) 的扩散直接偏好优化 (Diffusion-DPO) 损失为

$$L_{\text{DPO}}(\theta) = -\mathbb{E}_{(x_1^w, x_1^l) \sim \mathcal{D}, k \sim U[0, K], x_{kh}^w \sim q(x_{kh}^w | x_1^w), x_{kh}^l \sim q(x_{kh}^l | x_1^l)} \left[\log S \left(-\frac{\tilde{\beta}}{2} \left(\left\| \frac{v_\theta(x_{kh}^w, kh) - \frac{\dot{\beta}_{kh}}{\beta_{kh}} x_{kh}^w}{\frac{\dot{\alpha}_{kh}}{\alpha_{kh}} \beta_{kh} - \dot{\beta}_{kh}} - \frac{\alpha_{kh}}{\beta_{kh}} x_1^w \right\|^2 - \left\| \frac{v_{\text{ref}}(x_{kh}^w, kh) - \frac{\dot{\beta}_{kh}}{\beta_{kh}} x_{kh}^w}{\frac{\dot{\alpha}_{kh}}{\alpha_{kh}} \beta_{kh} - \dot{\beta}_{kh}} - \frac{\alpha_{kh}}{\beta_{kh}} x_1^w \right\|^2 - \left(\left\| \frac{v_\theta(x_{kh}^l, kh) - \frac{\dot{\beta}_{kh}}{\beta_{kh}} x_{kh}^l}{\frac{\dot{\alpha}_{kh}}{\alpha_{kh}} \beta_{kh} - \dot{\beta}_{kh}} - \frac{\alpha_{kh}}{\beta_{kh}} x_1^l \right\|^2 - \left\| \frac{v_{\text{ref}}(x_{kh}^l, kh) - \frac{\dot{\beta}_{kh}}{\beta_{kh}} x_{kh}^l}{\frac{\dot{\alpha}_{kh}}{\alpha_{kh}} \beta_{kh} - \dot{\beta}_{kh}} - \frac{\alpha_{kh}}{\beta_{kh}} x_1^l \right\|^2 \right) \right) \right) \right], \quad (234)$$

(Wallace 等人, 2023a, 第 5.1 节) 声称 $\beta \in [2000, 5000]$ 在稳定扩散 1.5 和稳定扩散 XL-1.0 上取得了良好性能, 若转换为本文的记号, 则对应 $\tilde{\beta} \in [4000, 10000]$ 。当可获得奖励函数 r 时, 不再有获胜样本 x_1^w 和失败样本 x_1^l , 而是有一对样本 (x_1^a, x_1^b) , 其获胜权重为 $S(r(x_1^a) - r(x_1^b)) = \frac{1}{1 + \exp(r(x_1^b) - r(x_1^a))}$, $S(-(r(x_1^a) - r(x_1^b))) = 0$ 。因此, 损失 (234) 变为:

$$L_{\text{DPO}}(\theta) = -\mathbb{E}_{(x_1^a, x_1^b) \sim \mathcal{D}, k \sim U[0, K], x_{kh}^a \sim q(x_{kh}^a | x_1^a), x_{kh}^b \sim q(x_{kh}^b | x_1^b)} \left[\sum_{s \in \{\pm 1\}} S(s(r(x_1^a) - r(x_1^b))) \times \log S \left(-\frac{s\tilde{\beta}}{2} \left(\left\| \frac{v_\theta(x_{kh}^a, kh) - \frac{\dot{\beta}_{kh}}{\beta_{kh}} x_{kh}^a}{\frac{\dot{\alpha}_{kh}}{\alpha_{kh}} \beta_{kh} - \dot{\beta}_{kh}} - \frac{\alpha_{kh}}{\beta_{kh}} x_1^a \right\|^2 - \left\| \frac{v_{\text{ref}}(x_{kh}^a, kh) - \frac{\dot{\beta}_{kh}}{\beta_{kh}} x_{kh}^a}{\frac{\dot{\alpha}_{kh}}{\alpha_{kh}} \beta_{kh} - \dot{\beta}_{kh}} - \frac{\alpha_{kh}}{\beta_{kh}} x_1^a \right\|^2 - \left(\left\| \frac{v_\theta(x_{kh}^b, kh) - \frac{\dot{\beta}_{kh}}{\beta_{kh}} x_{kh}^b}{\frac{\dot{\alpha}_{kh}}{\alpha_{kh}} \beta_{kh} - \dot{\beta}_{kh}} - \frac{\alpha_{kh}}{\beta_{kh}} x_1^b \right\|^2 - \left\| \frac{v_{\text{ref}}(x_{kh}^b, kh) - \frac{\dot{\beta}_{kh}}{\beta_{kh}} x_{kh}^b}{\frac{\dot{\alpha}_{kh}}{\alpha_{kh}} \beta_{kh} - \dot{\beta}_{kh}} - \frac{\alpha_{kh}}{\beta_{kh}} x_1^b \right\|^2 \right) \right) \right) \right]. \quad (235)$$

需要强调的是, 尽管存在相似之处, 本文所使用的损失 L_{DPO} (方程 (235)) 与 Wallace 等人 (2023a) 实现的损失非常接近, 但本文采用的偏好数据对与其存在显著差异。本文从当前模型中采样偏好数据, 这导致

不完美的样本，而它们考虑的是离策略的、高质量的、经过整理的偏好样本。造成这种差异的原因是，我们工作的出发点是奖励模型，而不是一组偏好数据，并且我们只与利用奖励模型的方法进行基准比较，以确保公平比较。我们在直接偏好优化（DPO）上的实验结果（表 2、图 6、表 3）表明，根据某些度量，所得模型的性能与基础模型相当，或略差一些。因此，我们得出结论：当基础模型本身不够好时，直接偏好优化并不是在策略微调的有力替代方案。

G 实验细节

除非另有说明，我们在所有微调方法中使用了相同的超参数。具体如下：

- $K = 40$ 时间步。
- Adam 优化器，学习率为 2×10^{-5} ，参数为 $\beta_1 = 0.95, \beta_2 = 0.999, \epsilon = 1 \times 10^{-8}$ ，权重衰减为 1×10^{-2} ，梯度范数裁剪值为 1。对于离散伴随（Discrete Adjoint），这些超参数导致微调不稳定（见表 6）；我们在其他所有表中报告的离散伴随结果均采用学习率 1×10^{-5} 获得。
- Bfloat16 精度。
- 有效批大小为 40；每次运行使用两块 80GB A100 GPU，每块批大小为 20。
- 一组 4 万个微调提示，取自一个包含文本和图像对的许可数据集（注意我们忽略了图像）。因此，每个训练轮次持续 1000 次迭代；各算法的微调迭代总数见表 3。对于我们报告的每个数据点所执行的三次运行，4 万个提示均从总共 10 万个提示中独立采样。

G.1 噪声调度细节 由于我们使用 $K = 40$ 个离散化步骤，时间步为 $t \in \{0, 0.025, 0.05, 0.075, 0.1, \dots, 0.95, 0.975\}$ 。为了从 X_t 中采样 X_{t+h} ，我们使用方程 (40)。我们采用选择 $\alpha_t = t, \beta_t = 1 - t$ ，这意味着

$$\sigma(t) = \sqrt{2\beta_t(\frac{\dot{\alpha}_t}{\alpha_t}\beta_t - \dot{\beta}_t)} = \sqrt{2(1-t)(\frac{1-t}{t} + 1)} = \sqrt{\frac{2(1-t)}{t}}.$$

注意，若将 $t = 0$ 代入此表达式，则得到无穷大；若代入 $t \lesssim 1$ ，则得到 $\sigma(t) \approx 0$ 。显然，前一个问题需要修正：我们只需在 $\sigma(t)$ 的分母上添加一个小的偏移量，将 $\sqrt{1/t}$ 替换为 $\sqrt{1/(t+h)}$ （注意 $h := 1/K = 0.025$ ）。但后一个问题从实用角度看也不完全令人满意，因为观察伴随匹配损失 (37)，我们发现 $u(X_t^u, t)$ 被训练来近似 $\sigma(t)^T \tilde{a}(t; \mathbf{X}^u)$ 的条件期望。因此，若将 $\sigma(t)$ 设为非常接近零（对于 $t \lesssim 1$ ），则迫使控制 u 也接近零，等价于阻止 v^{finetune} 偏离 v^{base} 。虽然从理论角度看这是正确的，但我们通过实验得出结论：将 $\sigma(t)$ 设为略大的值可显著加快微调速度，这得益于为 v^{finetune} 提供了额外的偏离 v^{base} 的余地。特别地，我们在 $\sigma(t)$ 的分子 $1 - t$ 中的因子 $1 - t$ 上添加了一个小的偏移量：将 $1 - t$ 替换为 $1 - t + h$ 。因此，我们在实验中用于计算扩散系数的表达式为

$$\sigma(t) = \sqrt{\frac{2(1-t+h)}{t+h}}. \quad (236)$$

当通过欧拉格式 (41) 在时间上向后求解精简伴随常微分方程 (38) - (39) 时，我们使用的时间步长为 $t \in \{1, 0.975, 0.95, 0.925, 0.9, \dots, 0.05, 0.025\}$ 。我们实际上并未将伴随状态初始化为 $\nabla_x g(X_1)$ ，而是初始化为 $\nabla_x g(\hat{X}_1)$ ，其中 $\hat{X}_1 := X_{1-h} + h v^{\text{base}}(X_{1-h}, 1 - h)$ 。也就是说， $\hat{X}_1$ 是通过执行最终的无噪声更新获得的，而不是使用由方程 (236) 给出的噪声 $\frac{1}{\sigma(1-h)}$ 。这样做的原因是，常规的最终迭代 X_1 包含在最后一步中添加

的一些噪声，这可能会扭曲梯度 $\nabla_x g(X_1)$ 。通过设置 $\tilde{a}(1; \mathbf{X}) = \nabla_x g(X_1)$ ，我们消除了这种偏差。注意，在连续时间极限 $h \rightarrow 0, \hat{X}_1 = X_1$ 下，这意味着这个小技巧是一致的。

G.2 梯度评估时间步长的选择

在算法 1 的方程 (42) 中，我们指出该项针对 $\left\| \frac{2}{\sigma(t)} (v_{\theta}^{\text{finetune}}(X_t, t) - v^{\text{base}}(X_t, t)) + \sigma(t)\tilde{a}_t \right\|^2$ must be $\{0, \dots, 1-h\}$ 中的所有 K 步进行计算。然而，通过该表达式对连续时间 t 和 $t+h$ 进行反向传播所提供的梯度信号非常相似。为了提高计算效率，我们采样时间步长的子集 $\mathcal{K}$ ，并且仅针对这些时间步长计算和反向传播项 2。我们通过从 $\{0, \dots, 0.725\}$ 中无重复地均匀采样十个时间步长，并始终采样最后十个时间步长 $\{0.75, \dots, 0.975\}$ 来构造 $\mathcal{K}$ 。这是因为对最后十个步骤（占总数的 25%）进行良好微调对于良好的经验性能至关重要，而初始步骤则不那么重要。

G.3 损失函数裁剪：LCT 超参数 注意，对于时间 $t \gtrsim 0$ ， $\sigma(t)^{\top} a(t; \mathbf{X}^{\bar{u}}, \bar{u})$ 的幅度远大于时间 $t \lesssim 1$ 。原因有两个：• 如附录 G.1 所述， $\sigma(t)$ 对于 $t \gtrsim 0$ 远大于对于 $t \lesssim 1$ 。

- 精简伴随状态 $\tilde{a}$ 的幅度随着 t 在时间上向后推移大致呈指数增长。事实上，如果我们假设 $\nabla_x b(X_t, t)$ 在时间上是常数，那么这个说法将是精确的。

观察到当 $\sigma(t)^{\top} a(t; \mathbf{X}^{\bar{u}}, \bar{u})$ 很大时，梯度 ∇_{θ} 也具有很高的幅度。 $\left\| \frac{2}{\sigma(t)} (v_{\theta}^{\text{finetune}}(X_t, t) - v^{\text{base}}(X_t, t)) + \sigma(t)\tilde{a}_t \right\|^2$ 在我们的梯度计算中包含这些项会降低梯度的信噪比。更重要的是，如附录 G.2 所讨论的，为了获得良好的实际性能，从最后 25% 的步骤中获得良好的梯度信号至关重要。因此，在我们的梯度中包含针对 $t \lesssim 0$ 的高幅度项可能会掩盖其他重要的低幅度项。

为了解决这个问题，我们裁剪这些项，使得 $\left\| \frac{2}{\sigma(t)} (v_{\theta}^{\text{finetune}}(X_t, t) - v^{\text{base}}(X_t, t)) + \sigma(t)\tilde{a}_t \right\|^2 > \text{LCT}$ 其中

LCT 代表损失裁剪阈值。也就是说，我们在实验中使用的伴随匹配损失具有以下形式：

$$\hat{\mathcal{L}}_{\text{Adj-Match}}(\theta) = \sum_{t \in \mathcal{K}} \min \left\{ \text{LCT}, \left\| \frac{2}{\sigma(t)} (v_{\theta}^{\text{finetune}}(X_t, t) - v^{\text{base}}(X_t, t)) + \sigma(t)\tilde{a}_t \right\|^2 \right\}, \quad (237)$$

其中 $\mathcal{K}$ 是附录 G.2 中描述的随机时间步子集。

对于伴随匹配，我们设定 $\text{LCT} = 1.6 \times \lambda^2$ 。值得注意的是，LCT 需要随 λ 二次增长，因为精简伴随 $\tilde{a}$ 的幅度随 λ 二次增长。我们通过实验设定常数 1.6；最后十个时间步的所有或几乎所有项都低于 LCT，但前十个时间步只有一部分项（ $\approx 25\%$ ）低于 LCT。LCT 的常数是一个需要调整的相关超参数，以获得类似的行为。

我们还对连续伴随损失使用了损失函数裁剪。对于该损失，我们设定 $\text{LCT} = 1600 \times \lambda^2$ 。原因是常规伴随状态的幅度显著大于精简伴随状态的幅度（这是伴随匹配优于连续伴随的一个重要原因）。

G.4 评估度量的计算

我们使用 open_clip 库 (Ilharco 等人, 2021) 来计算 ClipScores。我们将 ClipScore 多样性计算为给定提示的 40 次生成的 Clip 嵌入的方差，并在 25 个提示上取平均。即，

$$\text{ClipScore_Diversity} = \frac{1}{40} \sum_{k=1}^{40} \frac{2}{25 \cdot 24} \sum_{1 \leq i < j \leq 25} \|\text{Clip}(g_i^k) - \text{Clip}(g_j^k)\|^2, \quad (238)$$

其中 g_i^k 表示第 k 个提示的第 i 次生成。我们使用 transformers 库来计算 PickScore 处理器和模型 (Kirstain 等人, 2023)。PickScore 多样性的计算与 ClipScore 多样性类似。我们使用 hps 库来计算人类偏好评分 v2 的值 (Wu 等人, 2023b)。为了计算 Dreamsim 多样性，我们使用 dreamsim 库 (Fu 等人, 2023)。Dreamsim 多样性的计算与 ClipScore 多样性类似。

G.5 关于计算成本的说明 从表 3 报告的数据可以看出，伴随匹配（Adjoint Matching）的每次迭代墙钟时间（156 秒）与离散伴随损失（Discrete Adjoint loss）的（152 秒）非常接近。原因是两种算法在流匹配模型和奖励模型上执行的前向和后向传播次数相近。具体而言，对于批次中的每个样本，两种算法都执行 K 次流模型的前向传播以获得轨迹。为了计算训练损失的梯度，离散伴随损失执行 K 次额外的前向传播来评估基础流模型，在奖励模型上执行一次前向和后向传播，并在当前流模型上执行 K 次后向传播，这些后向传播通常使用梯度检查点来避免内存溢出。在伴随匹配的情况下，求解精简伴随常微分方程需要在奖励模型上执行一次前向和后向传播，并在基础流模型上执行 K 次后向传播。最后，如果我们像本文所做的那样仅在一半时间步上评估，计算损失梯度还需要 $K/2$ 次额外的后向传播，不过由于可以完全并行化，这一计算要快得多。

同时，计算连续伴随损失（Continuous Adjoint loss）的梯度每次迭代需要 204 秒。相对于伴随匹配，连续伴随在求解伴随常微分方程时需要执行额外的后向传播来计算梯度 $\nabla_{X_t} \|u(X_t, t)\|^2$ 。最后，我们观察到直接微调奖励的模型速度更快，但这会带来一系列本文通篇讨论的问题。

G.6 关于采样时间步数的说明 在我们的实验和所有基线中，我们在微调过程中使用了 40 个时间步（算法 1 中的 $h = 1/40$ ）。除表 8 外，所有表格和图中报告的实验均在 40 个推理时间步下进行。在表 8（附录 A）中，我们展示了基础模型以及使用伴随匹配和 DRaFT-1 微调的模型在 10、20、40、100 和 200 个推理时间步下的实验结果。我们对结果做出以下观察：• 伴随匹配在 100 和 200 个时间步下的度量与 40 个时间步下的度量在统计上相等，Dreamsim 多样性略有增加。这表明，如果我们希望在大量时间步下进行推理，那么在大量时间步下进行微调是一个好主意，否则模型的能力将受到微调时间步数而非推理计算量的限制。此外，在 100 和 200 个时间步下，伴随匹配相对于 DRaFT-1 的性能差异增大。

- 伴随匹配在 10 和 20 个时间步下的度量比 40 个时间步下更差，尤其是在 10 个时间步下。在 10 个时间步下，伴随匹配与 DRaFT-1 之间的性能差异在所有度量上消失，除了多样性，伴随匹配在多样性上仍然明显更好。