

基于最优传输的零样本离线模仿学习

Thomas Rupf^{1 2} Marco Bagatella^{2 3} 尼科·古尔特勒^{1 2} Jonas Frey^{2 3} Georg Martius^{1 2}

摘要

零样本模仿学习算法有望在测试时仅凭一次演示即可复现未见过的行为。现有实用方法将专家演示视为一系列目标，通过高层目标选择器和低层目标条件策略实现模仿。然而，该框架可能存在短视行为：智能体为实现单个目标而采取的即时行动可能损害长期目标。我们提出一种新方法，通过直接优化模仿学习固有的占用匹配目标来缓解此问题。我们提出将目标条件价值函数提升为占用之间的距离，并通过学习到的世界模型近似这些占用。由此产生的方法能够从离线、次优数据中学习，并具备非短视的零样本模仿能力，我们在复杂的连续基准中对此进行了验证。代码可在 <https://github.com/martius-lab/zilot> 获取。

然而，这些方法依赖大量专家数据，通常涉及昂贵的人工参与，例如遥操作。强化学习方法为这一问题提供了潜在的解决方案，它能够从次优数据源中学习（Sutton & Barto, 2018）。该框架下的现有方法通过将任务类别限制为加性奖励（Laskin 等, 2021; Sancaktar 等, 2022; Frans 等, 2024）或单一目标（Bagatella & Martius, 2023），减轻了学习通用策略的负担。

本文解除了以往方法的限制，提出了一种能够从离线、次优数据源中复现丰富行为的方法。我们允许在推理时通过一个不含动作的单一演示来指定任意任务，符合零样本模仿学习（Imitation Learning, IL）的设置（Pathak et al., 2018; Pirotta et al., 2024）。此外，我们考虑了对该设置的放宽（Pathak et al., 2018），其中专家演示可以是粗略的，由没有精确时间步信息的有序状态序列组成，并且是部分的，意味着每个状态只包含完整状态的部分信息。从实用的角度看，这两种放宽是可取的，因为它们允许用户避免指定对任务无关紧要或获取成本高昂的信息（例如只能通过遥操作获得）。例如，当要求机械臂沿路径移动物体时，只需提供物体在几个“检查点”的位置，而无需指定精确的机械臂姿态。

1. 引言

语言建模中零样本/少样本能力的出现（Brown 等, 2020; Wei 等, 2022; Kojima 等, 2022）重新激发了机器学习各领域对通用智能体的兴趣。通常，此类智能体在极少人工监督下进行预训练。在推理时，它们能够跨多种任务泛化，无需进一步训练，即零样本。这种能力也一直是基于学习的控制领域的长期目标（Duan 等, 2017）。通过利用监督学习的扩展性和泛化特性，已取得有前景的成果（Jang 等, 2022; Reed 等, 2022; O'Neill 等, 2023; Ghosh 等, 2024; Kim 等, 2024），1 图宾根大学，德国图宾根 2 马克斯·普朗克智能系统研究所，德国图宾根 3 苏黎世联邦理工学院，瑞士苏黎世。通讯作者：Thomas Rupf < thrupf@ethz.ch >。

原则上，指定的目标序列可以分解为多个单目标任务，这些任务可以由目标条件策略完成，正如最近的零样本模仿学习方法所提出的（Pathak et al., 2018; Hao et al., 2023）。然而，我们表明，当专家演示是部分的时候，这种分解容易导致短视行为。继续上面的机器人操作示例，考虑一个由两个顺序目标描述的任务，每个目标指定物体应到达的某个位置。在这种情况下，最优的目标条件策略会试图尽快到达第一个目标，可能通过将物体扔向它。然后智能体将放弃对物体的控制，使其处于次优甚至不可恢复的状态。在这种情况下，智能体将无法将物体移向第二个目标。这种短视行为是由目标抽象引起的一个根本问题，正如我们在第节中正式论证的那样。




图 1. ZILOT 概述。在从离线数据中学习世界模型 $\hat{P}$ 和目标条件价值函数 V 之后（左），零阶优化器直接将学习到的世界模型中轨迹的占用 $\hat{\rho}^\pi$ 与单个专家演示的占用 $\hat{\rho}^E$ 进行匹配（中）。这是通过使用最优传输将目标条件价值函数提升为占用之间的距离来实现的。由此产生的策略表现出非短视行为（右）。

3，并在难以控制的环境中导致灾难性失败，正如我们在第 5 节中通过实验所证明的。

本文通过采用占用匹配（Occupancy Matching）公式，为零样本离线模仿学习提供整体解决方案。我们将方法命名为 **ZILOT**（基于最优传输的零样本离线模仿学习）。利用最优传输（Optimal Transport, OT）将目标条件强化学习（GC-RL）固有的状态-目标距离提升为专家占用与策略占用之间的距离，其中后者通过查询学习到的世界模型来近似。此外，我们在标准固定时域模型预测控制（MPC）设置中将该距离作为目标函数。最小化该距离可在零样本模仿中产生非短视行为。通过在多个机器人仿真环境、下游任务和离线数据集上将我们的规划器与先前的零样本模仿学习方法进行比较，实验验证了上述主张。

2. 预备知识

2.1. 模仿学习

我们将环境建模为可控马尔可夫链¹

$\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, \mu_0)$ ，其中 $\mathcal{S}$ 和 $\mathcal{A}$ 分别为状态空间和动作空间， $P: \mathcal{S} \times \mathcal{A} \rightarrow \Omega(\mathcal{S})^2$ 为转移函数， $\mu_0 \in \Omega(\mathcal{S})$ 为初始状态分布。为允许部分演示，我们额外定义目标空间 $\mathcal{G}$ 及满射函数 $\phi: \mathcal{S} \rightarrow \mathcal{G}$ ，将每个状态映射到其抽象表示。为定义“目标达成”，假设目标空间 $\mathcal{G}$ 上存在目标度量 h ，该度量无需已知。若对某个固定 $\epsilon > 0$ 有 $h(\phi(s), g) < \epsilon$ ，则认为状态 $s \in \mathcal{S}$ 已达成目标 $g \in \mathcal{G}$ 。对每个策略 $\pi: \mathcal{S} \rightarrow \Omega(\mathcal{A})$ ，可分别度量（无折扣的） N 步状态占用和目标占用为

$$\varrho_N^\pi(s) = \frac{1}{N+1} \sum_{t=0}^N \Pr[s = s_t] \quad (1)$$

¹ 或无奖励马尔可夫决策过程。2 其中 $\Omega(\mathcal{S})$ 表示 $\mathcal{S}$ 上的分布集合。

和

$$\rho_N^\pi(g) = \frac{1}{N+1} \sum_{t=0}^N \Pr[g = \phi(s_t)], \quad (2)$$

其中 $s_0 \sim \mu_0$, $s_{t+1} \sim P(s_t, a_t)$ 和 $a_t \sim \pi(s_t)$ 。这些量在模仿学习中尤为重要。读者可参阅（Liu 等，2023）了解模仿学习设置的完整概述，本文仅讨论具有粗略和部分专家轨迹的离线模仿学习。假设可访问两个数据集： $\mathcal{D}_\beta = (s_0^i, a_0^i, s_1^i, a_1^i, \dots)_{i=1}^{|\mathcal{D}_\beta|}$ ，包含来自 $\mathcal{M}$ 的完整状态-动作轨迹，以及 $\mathcal{D}_E = (g_0^i, g_1^i, \dots)_{i=1}^{|\mathcal{D}_E|}$ ，包含以目标序列形式呈现的专家演示，不一定遵循 $\mathcal{M}$ 的动态。注意两个数据集均无奖励标签。目标是训练策略 π 以模仿专家，通常表述为匹配目标占用

$$\rho_N^\pi \stackrel{D}{=} \rho_N^{\pi^E}. \quad (3)$$

本文考虑的场景是零样本离线模仿学习（zero-shot offline IL），它对离线模仿学习施加了两个额外约束。首先， $\mathcal{D}_E$ 仅在推理时可用，这意味着预训练必须与任务无关。我们进一步假设 $\mathcal{D}_E$ 由单条轨迹 $(g_0, \dots, g_m) = g_{0:m}$ 组成。其次，在推理时，智能体应以“适度的计算开销”来模仿 π_E （Pathak 等人，2018；Touati 和 Ollivier，2021；Pirota 等人，2024）。实际上，对未见轨迹的模仿应比从头开始的模仿学习便宜几个数量级，并尽量避免代价高昂的操作（例如网络更新）。

2.2. 最优传输 (Optimal Transport)

在机器学习领域，匹配分布通常是一个重要问题，即寻找某个概率测度 μ 使其近似于另一个概率测度 ν 。近年来，最优传输（Optimal Transportation, OT）受到越来越多的关注（Amos 等，2023；Haldar 等，2022；




图 2. 两个高斯分布离散近似 $\hat{\mu}, \hat{\nu}$ 与 μ, ν 之间的最优传输示例。成本矩阵 C 由逐点成本构成，此处成本为欧氏距离。耦合矩阵 $T \in \mathcal{U}(\hat{\mu}, \hat{\nu})$ (中图) 通过表示匹配关系的连线进行可视化 (右图)。

Bunne 等, 2023; Pooladian 等, 2024)。如图 2 所示，最优传输不仅像 f -散度（如库尔贝克-莱布勒散度 (D_{KL})）那样逐点比较概率测度，还融入了底层空间的几何结构。这也使得最优传输对概率测度的经验近似（采样）具有鲁棒性（(Peyré 和 Cuturi, 2019)，第 129 页）。形式上，最优传输描述了两个测度 $\mu \in \mathcal{P}(\mathcal{X}), \nu \in \mathcal{P}(\mathcal{Y})$ 的耦合 $\gamma \in \mathcal{P}(\mathcal{X} \times \mathcal{Y})$ ，其相对于某个代价函数 $c: \mathcal{X} \times \mathcal{Y} \rightarrow \mathbb{R}$ 的传输代价最小。原始康托罗维奇 (Kantorovich) 形式由以下优化问题给出

$$\text{OT}_c(\mu, \nu) = \inf_{\gamma \in \mathcal{U}(\mu, \nu)} \int_{\mathcal{X} \times \mathcal{Y}} c(x_1, x_2) d\gamma(x_1, x_2) \quad (4)$$

其中优化在所有 μ 和 ν 的联合分布上进行，记为 $\gamma \in \mathcal{U}(\mu, \nu)$ (耦合)。如果 $\mathcal{X} = \mathcal{Y}$ 和 $(\mathcal{X}, c)$ 是度量空间，则对于 $p \in \mathbb{N}$, $W_p^p = \text{OT}_{c^p}$ 被称为 Wasserstein- p 距离，它被证明是 $\mathcal{X}$ 上具有有限 p 阶矩的测度子集上的度量 (Clement 和 Desch, 2008)。

给定样本 $x_1, \dots, x_n \sim \mu$ 和 $y_1, \dots, y_m \sim \nu$ ，离散概率测度 $\hat{\mu} = \sum_{i=1}^n a_i \delta_{x_i}$ 与 $\hat{\nu} = \sum_{j=1}^m b_j \delta_{y_j}$ 之间的离散最优传输问题可以写成方程 4 的离散版本，即

$$\text{OT}_c(\hat{\mu}, \hat{\nu}) = \min_{T \in \mathcal{U}(\mathbf{a}, \mathbf{b})} \sum_{i=1}^n \sum_{j=1}^m c(x_i, y_j) T_{ij} \quad (5)$$

$$= \min_{T \in \mathcal{U}(\mathbf{a}, \mathbf{b})} \langle \mathbf{C}, \mathbf{T} \rangle \quad (6)$$

其成本矩阵为 $C_{ij} = c(x_i, y_j)$ 。边际约束现在可以写为 $\mathcal{U}(\mathbf{a}, \mathbf{b}) = \{\mathbf{T} \in \mathbb{R}^{n \times m} : \mathbf{T} \cdot \mathbf{1}_m = \mathbf{b} \text{ 和 } \mathbf{T}^\top \cdot \mathbf{1}_n = \mathbf{a}\}$ 。该优化问题可以通过线性规划求解。此外，Cuturi (2013) 表明，熵正则化版本通常表示为 $\eta D_{\text{KL}}(\mathbf{T}, \mathbf{a}\mathbf{b}^\top)$ ， $\text{OT}_{c, \eta}(\hat{\mu}, \hat{\nu}) = \min_{T \in \mathcal{U}(\mathbf{a}, \mathbf{b})} \langle \mathbf{C}, \mathbf{T} \rangle -$ 可以通过 Sinkhorn 算法 (Sinkhorn & Knopp, 1967) 在对偶形式下高效求解。

2.3. 目标条件强化学习

由于文献中的技术将在本工作中反复出现，我们简要介绍目标条件强化学习 (GC-RL) 的基本思想。

在 GC-RL 中。我们可以通过丰富可控马尔可夫链 $\mathcal{M}$ 来引入该框架。我们将其条件化于目标 $g \in \mathcal{G}$ ，并将其建模为一个（无折扣的）马尔可夫决策过程。与上述无奖励设置 Process $\mathcal{M}_g = (\mathcal{S} \cup \{\perp\}, \mathcal{A}, P_g, \mu_0, R_g, T_{\max})$ 相比，动态现在包括一个吸收状态 $\perp$ ，在达到目标时进入，并且在此之前奖励为 -1 ：

$$P_g(s, a) = \begin{cases} P(s, a) & \text{if } h(\phi(s), g) \geq \epsilon \\ \delta_\perp & \text{otherwise} \end{cases} \quad (7)$$

$$R_g(s, a) = \begin{cases} -1 & \text{if } h(\phi(s), g) \geq \epsilon \\ 0 & \text{otherwise} \end{cases} \quad (8)$$

其中 δ_x 表示将所有概率质量分配给 x 的概率分布。

我们现在可以将目标条件价值函数定义为


$$V^\pi(s_0, g) = \mathbb{E}_{\mu_0, P_g, \pi} \left[\sum_{t=0}^{T_{\max}} R_g(s_t, a_t) \right] \quad (9)$$

其中 $s_0 \sim \mu_0, s_{t+1} \sim P_g(s_t, a_t), a_t \sim \pi(s_t, g)$ 。最优目标条件策略为 $\pi^* = \arg \max_{\pi} \mathbb{E}_{g \sim \mu_{\mathcal{G}}, s \sim \mu_0} V^\pi(s_0, g)$ 对于某个目标分布 $\mu_{\mathcal{G}} \in \Omega(\mathcal{G})$ 。直观上，价值函数 $V^\pi(s, g)$ 对应于 π 从状态 s 移动到目标 g 所需的期望步数的负值。因此，距离 $d = -V^*$ 对应于期望首次命中时间。如果没有目标抽象，即 $\phi = \text{id}_{\mathcal{S}}$ ，则 $(\mathcal{S}, d)$ is a 拟度量空间 (Wang 等人, 2023), i.e. d 是非负的且满足三角不等式。但请注意， d 不一定是对称的。

3. 目标抽象与近视规划

模仿学习问题核心的分布匹配目标通常难以优化。因此，传统的零样本模仿学习方法利用层次分解，将其转化为一组目标条件强化学习问题 (Pathak 等人, 2018; Hao 等人, 2023)。本文首先描述该方法，然后展示其可能引入的短视行为与次优性。

在预训练阶段，Pathak 等人 (2018) 提出训练一个目标条件策略 $\pi_g: \mathcal{S} \times \mathcal{G} \rightarrow \mathcal{A}$ 用于到达单一目标，以及一个目标识别器 $C: \mathcal{S} \times \mathcal{G} \rightarrow \{0, 1\}$ 用于检测给定状态是否实现给定目标。给定专家演示 $g_{1:M}$ 和初始状态 s_0 ，模仿专家可被顺序分解为 M 个目标到达问题，并由包含两个策略的层次化智能体求解。在低层， π_g 选择动作以到达当前目标；在高层， C 判断当前目标是否已实现，并决定 π_g 是否应瞄准序列中的下一个目标。


 图 3. 具有 $\phi: (x, y) \mapsto x$ 的可控马尔可夫链。

本文将原像 $\phi^{-1}(g) = \{s \in \mathcal{S} : \phi(s) = g\}$ 定义为映射到某个目标的所有状态集合，并在目标抽象下将上述方法的次优性形式化如下。

命题 3.1. 定义最优分类器 $C(s, g) = \mathbf{1}_{h(\phi(s), g) < \epsilon}$ 。给定已访问状态集 $\mathcal{P} \subseteq \mathcal{S}$ 、当前状态 $s \in \mathcal{P}$ 和目标序列 $g_{1:M} \in \mathcal{G}^M$ ，令最优层次化策略为 $\pi_h^*(s) = \pi^*(s, g_{i+1})$ ，其中 i 是使得存在状态 $s_p \in \mathcal{P}$ 满足 $h(\phi(s_p), g_i) < \epsilon$ 的最小整数，否则为 $i = 0$ 。存在一个可控马尔可夫链 $\mathcal{M}$ 和一个可实现的目标序列 $g_{0:M}$ ，使得在适当的目标抽象 $\phi(\cdot)$, π^* 下， h 无法到达序列中的所有目标，i.e. $\rho_N^{\pi^*}(g_i) = 0$ 对某个 $i \in [0, \dots, M]$ 和所有 $N \in \mathbb{N}$ 成立。

证明. 考虑图 3 中描述的可控马尔可夫链 $\mathcal{M}$ ，其目标抽象为 $\phi: (x, y) \mapsto x$ 和 $p > 0$ 。现在考虑目标序列 $(g_0, g_1, g_2) = (0, 1, 2)$ ，该序列只能通过初始状态 $s_0 = (0, 0)$ 采取动作 a_1 的策略来实现。考虑 π_h^* 在 s_0 中，其中 $\mathcal{P} = \{s_0\}$ 。使得 $h(\phi(s_0), g_i) < \epsilon$ 成立的最小整数 i 为 $i = 0$ ，因此 $\pi_h^*(s_0) = \pi^*(s_0, g_1)$ 。然后可以比较 s_0 中的状态-动作值 Q ：

$$Q^{\pi^*(\cdot, g_1)}(s_0, a_1, g_1) = \sum_{t=0}^{T_{\max}} -p^t = -1 \cdot \frac{1 - p^{(T_{\max}+1)}}{1 - p} < -1 = Q^{\pi^*(\cdot, g_1)}(s_0, a_0, g_1). \quad (10)$$

这意味着 $\pi_h^*(s_0) = \pi^*(s_0, 1) = a_0$ 。 π_h^* 访问的下一个状态将始终是 $(1, 0)$ ，从该状态无法到达 $(2, 1)$ ，且 g_2 不可实现。因此对所有 $N \in \mathbb{N}$ 有 $\rho_N^{\pi_h^*}(g_2) = 0$ 。 $\square$

我们指出，这一问题出现在目标抽象 (Goal Abstraction) 的背景下，而目标抽象在我们所考虑的局部示范设置中起着至关重要的作用。如果没有目标抽象，即每个目标都被完全指定，那么策略在实现目标时就没有任何余地 (假设 $\epsilon \rightarrow 0$ 也成立)。然而，目标抽象在实践中无处不在 (Schaul 等人, 2015)，并且对于在复杂环境中实现学习是必要的 (Andrychowicz 等人, 2017)。

4. 用于零样本模仿学习的最优传输

借助价值估计、基于模型的强化学习和轨迹优化领域的最新工具，我们提出了一种零样本离线模仿学习方法，该方法直接优化占用匹配目标，仅引入最小的近似。因此，近视程度大大降低，正如我们在第 5 节中通过实验所展示的那样。

具体而言，我们提出通过最小化目标空间上关于目标度量 h 的 Wasserstein-1 度量 W_1 来求解方程 3 中的占用匹配问题。 $\mathcal{G}$, i.e.

$$W_1(\rho_N^\pi, \rho_N^E) = \text{OT}_h(\rho_N^\pi, \rho_N^E). \quad (11)$$

该目标涉及两个不可获取的量：目标占用 ρ_N^π, ρ_N^E ，以及目标度量 h 。我们的关键贡献在于如何实际估计这些量，从而能够利用可扩展的深度强化学习技术来优化该目标。

占用估计 由于专家和策略的占用都是不可获取的，我们选择离散的、基于样本的近似。对于专家占用 ρ_N^E ，在推理时提供的单条轨迹 $(g_0, \dots, g_M)$ 代表了来自该占用的一个有效样本，我们直接使用它。对于任意智能体策略 π ，我们在 $\mathcal{D}_\beta$ 上训练动力学模型 $\hat{P} \approx F$ 之后使用离散近似，这可以通过标准的监督学习离线完成。然后，我们可以通过联合展开学习到的动力学模型和策略 π 来近似 ρ_N^π 。由此我们得到离散近似

$$\rho_N^E \approx \hat{\rho}_M^E = \frac{1}{M+1} \sum_{j=0}^M \delta_{g_j} \quad \text{and} \quad (12)$$

$$\rho_N^\pi \approx \hat{\rho}_N^\pi = \frac{1}{N+1} \sum_{t=0}^N \delta_{\phi(s_t)} \quad (13)$$

其中对于后者我们进行采样

$$s_0 \sim \mu_0, s_{t+1} \sim \hat{P}(s_t, a_t), a_t \sim \pi(s_t). \quad (14)$$

类似地，我们也可以获得 π 的状态占用估计为 $\varrho_N^\pi \approx \hat{\varrho}_N^\pi = \frac{1}{N+1} \sum_{t=0}^N \delta_{s_t}$ 。

度量近似 由于 h 在实际环境中可能不可用或难以指定，我们提出从离线数据 $\mathcal{D}_\beta$ 训练一个目标条件价值函数 V^* ，并使用距离 $d(s, g) = -V^*(s, g)$ (即学习到的首次命中时间) 作为代理。对于给定的状态-目标对 (s, g) ，这对应于近似 $d(s, g) \approx h(\phi(s), g)$ 。容易证明， $h(\phi(\cdot), g)$ 的最小化器也最小化。使用 d 还具有将马尔可夫决策过程 $d(\cdot, g)$ 的动态纳入最优传输问题代价的好处。

这种距离的使用在过去曾被用作状态占用之间瓦瑟斯坦度量的代价函数 (Durugkar 等人, 2021 年)。正如我们在第 5.3, d 节中所示, 它能够捕捉马尔可夫决策过程中潜在的不对称性, 同时保持对 h 的信息性。我们注意到, 虽然 $h: \mathcal{G} \times \mathcal{G} \rightarrow \mathbb{R}$ 是目标空间中的距离, 但 $d: \mathcal{S} \times \mathcal{G} \rightarrow \mathbb{R}$ 是状态与目标之间的距离。尽管如此, d 仍然适用, 因为策略的占用也可以在状态空间中估计为 $\hat{\varrho}_N^\pi$ 。鉴于上述考虑, 我们可以将目标重写为离散最优传输问题

$$\pi^* = \arg \min_{\pi} \text{OT}_d(\hat{\varrho}_N^\pi, \hat{\rho}_M^E). \quad (15)$$

优化 在解决了密度和度量近似之后, 我们现在专注于优化方程 15 中的目标。幸运的是, 作为一个离散最优传输问题, 当引入熵正则化因子 η (时, 可以使用辛霍恩算法高效地评估该目标 (Cuturi, 2013 年; Peyré 和 Cuturi, 2019 年)。在状态 $s_k \in \mathcal{S}$ 处优化目标的非马尔可夫确定性策略可以写为

$$\begin{aligned} \pi(s_{0:k}, g_{0:m}) \\ \approx \arg \min_{a_k} \min_{a_{k+1:N-1}} \text{OT}_{d,\eta} \left(\frac{1}{N+1} \sum_{i=0}^N \delta_{s_i}, \frac{1}{M+1} \sum_{j=0}^M \delta_{g_j} \right) \end{aligned} \quad (16)$$

其中 $s_{0:k}$ 是迄今为止访问过的状态, $s_{k+1:N}$ 是使用学习到的动力学模型 F 和动作 $a_{k:N-1}$ 展开的。注意, 虽然 $s_{0:k}$ 是目标的一部分, 但它们是常数, 不会被主动优化。

直观上, 该优化问题对应于从序列 $(a_{k:N-1})$ 中寻找第一个动作, 该动作最小化经验专家目标占用与诱导的经验策略状态占用之间的最优传输代价。此类优化问题自然适用于基于零阶优化器和学习世界模型的规划框架 (Chua 等, 2018; Ha 与 Schmidhuber, 2018); 虽然这些算法传统上用于加性代价, 但零阶优化器的灵活性 (Rubinstein 与 Kroese, 2004; Williams 等, 2015; Pinneri 等, 2020) 允许直接应用于我们的问题。因此, 方程 17 中的目标可以直接通过 CEM 变体 (Pinneri 等, 2020) 或 MPPI (Williams 等, 2015) 以模型预测控制 (MPC) 方式进行优化。

与其他模型预测控制方法类似, 由于学习到的动力学模型存在不完善之处或计算约束, 我们不得不为有限时域 H 进行规划, 该时域可能小于 N 。这被称为滚动时域控制 (Datko, 1969)。当用于计算 $\hat{\varrho}_N^\pi$ 的策略展开被截断时, 也需要截断目标序列, 以排除任何无法实现的目标。

在 H 步内到达。为此, 我们训练一个额外的价值函数 W , 通过最小化回归到 V , i.e. 来估计从一个目标到下一个目标所需的

$$s, s' \sim \mathcal{D}_\beta [(W(\phi(s); \phi(s')) - V(s; \phi(s')))^2].$$

步数。对于 $i \in [0, \dots, M]$, 我们可以估计 g_i 应到达的时间为

$$t_i \approx -V(s_0; g_0) - \sum_{j=1}^i W(g_{j-1}; g_j). \quad (17)$$

然后, 我们简单地截断在线问题, 仅考虑与 $K = \min\{j : t_j \geq k+H\}$ 相关的目标, 其中 $s_1, \dots, s_{k+H}$, i.e. $g_0, \dots, g_K$ 。我们注意到, 如果 $K < M$, 这种对无限时域目标的近似可能导致短视行为; 然而, 随着有效规划时域的增加, 最优行为得以恢复。算法 1 展示了实用最优传输目标的计算方式。

Algorithm 1 OT cost computation for ZILOT

Require: Pretrained GC value functions V, W and dynamics model $\hat{P}$; horizon H , solver iterations r and regularization factor η .

Initialization: State s_0 and expert trajectory $g_{1:M}$, precomputed $t_{0:M}$

input State history $s_{0:k}$, future actions $a_{k:k+H-1}$
 {Rollout learned dynamics}
 $s_{k+1:k+H} \leftarrow \text{rollout}(\hat{P}, s_k, a_{k:k+H-1})$
 {Compute which goals are reachable}
 $K \leftarrow \min\{j : t_j \geq k+H\}$
 {Compute cost matrix}
 $C_{ij} \leftarrow -V(s_i; g_j), i \in \{0, \dots, k+H\}, j \in \{0, \dots, K\}$
 {Compute uniform marginals}
 $\mathbf{a} \leftarrow \frac{1}{k+H+1} \mathbf{1}_{k+H+1}, \mathbf{b} \leftarrow \frac{1}{K+1} \mathbf{1}_{K+1}$
 {Run Sinkhorn Algorithm}
 $\mathbf{T} \leftarrow \text{sinkhorn}(\mathbf{a}, \mathbf{b}, \mathbf{C}, r, \eta)$
output $\sum_{ij} T_{ij} C_{ij}$ {Return OT cost}

实现 所提出的方法仅依赖于三个学习得到的组件: 一个动力学模型 $\hat{P}$, 以及状态-目标与目标-目标的目标条件价值函数 V 和 W 。所有这些组件都可以从数据集 $\mathcal{D}_\beta$ 中离线学习。在实践中, 我们发现若干现有的深度强化学习框架可以很容易地适配来学习这些函数。我们采用 TD-MPC2 (Hansen 等人, 2024 年), 这是一种最新的基于模型的算法, 在单任务和多任务的在线与离线强化学习中已展现出有前景的结果。我们注意到, 规划是在 TD-MPC2 编码器构建的潜空间中进行的。我们对该方法进行了调整, 以允许估计目标条件价值函数, 具体描述见附录 C。我们遵循先前的工作 (Andrychowicz 等人, 2017 年; Bagatella 与 Martius, 2023 年; Tian 等人, 2021 年), 从 $\mathcal{D}_\beta$ 中轨迹的未来部分采样目标, 以便在无监督的情况下合成奖励。我们注意到

这种目标采样方法同样不需要任何关于 h 。

5. 实验

本节对 ZILOT 在零样本模仿学习中的表现进行了广泛的实证评估。我们首先描述实验设置，然后展示定性和定量结果，以及消融实验。我们考虑了在 5 个环境中定义的 30 个任务，如下文总结，并在附录 A 和 C 中详细描述。

fetch (Plappert 等人, 2018 年) 是一个操作套件，其中机械臂将立方体推向目标 (Push) 或举起 (Pick&Place)。为了说明短视规划的失败案例，我们还评估了 Push 的一个变体 (即 Slide)，其中桌面尺寸超过了机械臂的活动范围，桌面摩擦力降低，并且机械臂被限制为必须接触桌面。因此，智能体无法完全约束立方体，例如通过将其拿起或按压它，并且环境会严厉惩罚粗心的操作。在所有三个环境中，任务包括沿着形状像字母“S”、“L”和“U”的轨迹移动立方体。

halfcheetah (Wawrzyński, 2009 年) 是一个经典的 Mujoco 环境，其中智能体在二维水平面上控制一个类似猫的智能体。由于该环境默认不是目标条件的，我们选择猎豹的 x 坐标和朝向作为有意义的目标抽象。这允许定义涉及站立、用前腿或后腿跳跃以及做空翻的任务。

pointmaze (Fu 等, 2021) 涉及通过力控制操纵点质量穿过迷宫。下游任务包括在迷宫中跟随一系列航路点。

规划器 最自然的比较是 Pathak 等 (2018) 提出的框架，该框架通过层次分解来处理模仿，如第 3 节所述。两个层次组件均在 TD-MPC2 中学习：低层目标条件策略默认是 TD-MPC2 的一部分，而目标分类器 (Cls) 可以通过对学习到的价值函数 V 进行阈值化获得。我们优先考虑该基线 (**Policy+Cls**)，通过在每个环境中从值 $\{1, 2, 3, 4, 5\}$ 中选择最小化 $W_{\min}$ 的阈值。此外，我们还比较了该基线的一个版本，将低层策略替换为目标条件价值函数的零阶优化 (**MPC+Cls**)，从而消融任何由基于模型的组件带来的好处。我们指出，所有 MPC 方法都使用相同的零阶优化器 iCEM (Pinneri 等, 2020)。我们进一步将 ZILOT 与 **ERFB** 和 **RERFB** 进行比较，这两种方法使用前向-后向 (**FB**) 框架结合零样本强化学习和基于奖励的模仿学习 (Pirotta 等, 2024)。我们请读者参阅




图 4. fetch slide large 2D 中的示例任务。左侧两列显示了近视方法 MPC+Cls 和 ZILOT (我们的方法) 在五个种子上的五条轨迹。轨迹绘制在目标空间的 $x-y$ 平面上，仅显示立方体的移动。ZILOT 的行为更接近地模仿给定的目标轨迹。右侧，我们在回合时间约四分之三处可视化 OT 目标。它包括过去和计划的未来状态，以及它们与目标的耦合。注意，规划发生在 TD-MPC2 的潜在状态中，并且使用单独训练的解码器进行此可视化。

附录 B 讨论了在我们的粗略和部分设置中所有 FB-IL 方法。

度量 我们报告两个度量来评估规划器性能。第一个是智能体轨迹与给定目标序列在目标度量 h 下的最小经验 Wasserstein-1 距离。形式上，给定轨迹 $(s_0, \dots, s_N)$ 和目标序列，我们定义为

$$(g_0, \dots, g_M) \quad W_{\min}(s_{0:N}, g_{1:M})$$

$$\min_{k \in \{0, \dots, N\}} W_1 \left(\frac{1}{k+1} \sum_{i=0}^k \delta_{\phi(s_i)}, \frac{1}{M+1} \sum_{j=0}^M \delta_{g_j} \right). \quad (18)$$

我们引入了一个次级度量“目标达成率” (GoalFraction)，它表示按给定顺序达成的目标所占的比例。形式上，这对应于与期望顺序相匹配的已达成目标的最长子序列的长度。

5.1. ZILOT 能否有效模仿未见过的轨迹？

我们首先着手定性评估该方法在复杂环境中是否具备模仿能力，尽管存在实用近似。图 4 展示了 MPC+Cls 和 ZILOT 如何模仿专家在 fetch slide large 2D 环境的大桌子上滑动立方体。短视的基线在将立方体移向第二个目标后难以重新控制立方体，导致轨迹超出操作范围。相比之下，ZILOT




图 5. ZILOT 与其他方法在各环境上的性能比较汇总。表 1 报告了更详细的结果。

会规划超出第二个目标之后的动作。如图 4 中间部分所示，最优传输 (OT) 问题的耦合近似地将规划轨迹中的每个状态与适当的目标配对，从而更接近地模仿专家。

5.2. ZILOT 与先前方法相比表现如何？

我们在表 5 中提供了 ZILOT 相对于其他规划器的定量评估。更多细节请参见附录 A。由于 ZILOT 直接优化分布匹配目标，它通常能更紧密地复现专家轨迹，从而获得更低的 Wasserstein 距离。这在那些对短视规划惩罚严重的环境中尤为明显，例如图 4 所示的 Fetch Slide 环境。在大多数环境中，我们的方法在达到目标的比例上也优于基线。在惩罚较轻的环境中，ZILOT 可能会牺牲精确到达下一个目标的精度，以换取整体上更接近专家轨迹的匹配，这在 pointmaze 环境中最为明显。我们注意到，两个短视基线 Pi+Cls 和 MPC+Cls 的性能非常相似，这表明与 ZILOT 的性能差距源于目标函数的变化，而非实现或基于模型的组件。我们推测 ERFB 和 RERFB 表现欠佳的原因有两个方面。首先，FB 框架 (Touati & Ollivier, 2021; Pirota et al., 2024) 在低数据情况下表现不佳 (Jeen et al., 2024)。其次，ERFB 和 RERFB 使用正则化的 f 散度目标，这转化为具有加性奖励的强化学习问题。正如 (Pirota et al., 2024) 所述，这种正则化是有代价的，特别是在状态不包含动力学信息或遍历马尔可夫决策过程中。在这种情况下，策略可以通过停留在最可能的专家状态来优化奖励，从而产生退化解。相反，ZILOT 会丢弃这样的解，因为它使用未正则化的目标。

5.3. 什么对 ZILOT 重要？

为了验证我们的一些设计选择，我们最终评估了以下方法版本。

- 最优传输+非平衡，我们的方法采用非平衡最优传输 (Liero 等人, 2018; S  journ   等人, 2019)，将硬边界约束 $\mathcal{U}$ (见第 2.2 节) 转化为软约束。我们使用该方法来解决粗略专家轨迹未必能产生可行的专家占用近似这一问题。
- 最优传输+分类器，我们方法的一个版本，使用分类器 (具有相同的超参数搜索) 来丢弃所有被识别为已达成的目标。这使得该方法在最优传输目标中仅考虑未来的目标和状态。
- **OT+ h** ，我们的方法在最优传输问题中以 $\mathcal{G}$ 上的目标度量 h 作为代价函数，替换 d 。

我们的结果总结于图 6。首先，我们发现使用非平衡最优传输并未带来显著改进。其次，使用目标分类器可能对匹配性能产生不利影响。我们推测这是因为跟踪状态历史能够更好、更具信息量地估计专家占用的哪一部分已经完成。最后，我们观察到目标度量 h 可能并不优于 d ，即使它可用。我们主要将此归因于在所考虑的环境中，任何动作都会直接改变状态占用，但目标占用并非如此。由于 h 仅允许比较目标占用，在大多数动作不会改变目标抽象下未来状态轨迹的情况下 (例如抓取任务开始时，如附录 E 中其达成轨迹所示)，优化景观可能非常平坦。此外，虽然 h 在局部是准确的，但它忽略了马尔可夫决策过程的全局几何结构，这从其在不完全对称环境 (即半猎豹) 中的较差性能可见。




图 6. ZILOT 中设计选择的消融，包括耦合约束（最优传输+非平衡）、部分轨迹匹配（最优传输+分类器）以及用 $d(OT+h)$ 近似 h 。更详细的结果请参见表 2。

6. 相关工作

零样本模仿学习 当推理时允许大量计算时，若干现有方法利用预训练模型推断动作，并通过行为克隆（Behavior Cloning）检索模仿策略（Pan et al., 2020; Zhang et al., 2023; Torabi et al., 2018）。如第 3 节所述，大多数（真正的）零样本方法将模仿专家演示的问题转化为跟随其观测序列（Pathak et al., 2018; Hao et al., 2023）。然后通过目标条件策略从一个目标过渡到下一个目标来模仿专家演示。相比之下，本文提出一种整体性的模仿方法，考虑规划时域内的所有目标。

零样本强化学习 大量工作致力于在无监督条件下学习通用智能体，涵盖理论（Touati & Ollivier, 2021; Touati et al., 2023）和实用（Laskin et al., 2021; Mendonca et al., 2021）方面。其中，（Sancaktar et al., 2022; P. et al., 2021; Bagatella & Martius, 2023）通过好奇探索学习动力学模型，并展示如何利用该模型优化加性目标。最近，Frans et al. (2024) 使用函数奖励编码将任意加性奖励函数编码到潜变量中，用于条件化策略。虽然这些方法在标准强化学习设置中有效，但不适合解决全局强化学习问题（Santi et al., 2024）（即分布匹配）。一个值得注意的例外是前向-后向框架（Touati & Ollivier, 2021; Pirota et al., 2024），我们在附录 B 中详细讨论。

模仿学习 近期一系列工作专注于通过匹配状态、状态-动作或状态-下一状态占用度量来训练模仿专家的智能体，具体取决于可用信息。这些方法要么直接优化各种分布匹配目标（Liu et al., 2023; Ma et al., 2022），要么使用生成对抗网络（GAN）恢复奖励

（Ho & Ermon, 2016; Li et al., 2023），或在一种情况下使用最优传输（OT）（Luo et al., 2023）。另一类工作通过直接匹配动作分布展示了令人印象深刻的真实世界结果（Shafiuallah et al., 2022; Florence et al., 2021; Chi et al., 2023）。所有这些方法都不是以零样本方式运作，或者需要临时数据收集。

强化学习中的最优传输 以往的工作常将最优传输（Optimal Transport, OT）作为强化学习中的奖励信号。一个应用是在线微调，其中策略的展开轨迹根据其专家轨迹的匹配程度按比例获得奖励（Dadashi 等, 2021; Haldar 等, 2022）。Luo 等（2023）则采用类似的轨迹匹配策略，为未标记的混合质量离线数据集恢复奖励标签。上述大多数工作依赖简单的余弦相似度和欧氏距离作为其最优传输问题的代价函数。

7. 讨论

本文指出当前零样本模仿学习（Zero-shot Imitation Learning）方法的一个失效模式：这些方法将模仿专家演示视为在短视目标条件强化学习（GC-RL）策略下依次达成一系列目标。为解决该问题，本文将任务重新表述为占用匹配（Occupancy Matching）。通过引入离散化与最小近似，本文推导出一个最优传输（Optimal Transportation）问题，该问题可在推理阶段利用学习到的动力学模型、目标条件价值函数以及零阶优化器直接优化。在多种环境与任务上的实验结果表明，本文方法优于最先进的零样本模仿学习方法，尤其在需要非短视规划的场景中表现突出。此外，本文通过一系列消融实验验证了设计选择的合理性。

从实用的角度来看，本文方法的主要局限在于其对世界模型的依赖。由于学习到的动力学模型的不准确性和计算成本随预测时长的增加而上升，我们不得不优化一个固定时长的目标。这可能会重新引入一定程度的

可能导致超出规划时域后产生次优行为的短视。然而，在我们的实证验证中，这并非一个实用问题，并且我们期望随着所学世界模型准确率的提升，我们的框架能进一步受益。从理论角度看，即使专家轨迹由马尔可夫策略收集，且马尔可夫策略足以用于模仿，ZILOT 也会诱导出非马尔可夫策略。尽管非马尔可夫策略的空间更大，我们发现 ZILOT 能够高效地找到近最优策略。这与若干实用的零样本模仿学习算法基于对非马尔可夫策略的高效搜索这一事实相符（例如基于目标达成策略和分类器的算法（Pathak 等人，2019；Pirotta 等人，2024））。

影响声明

模仿学习（Imitation Learning）的进步可能催生跨多种应用领域能力更强的机器人系统。尽管此类系统可能因其使用场景而产生社会影响，但本文的贡献在于算法层面而非特定领域。

致谢

感谢安塞尔姆·保卢斯（Anselm Paulus）、米克尔·卓布罗（Mikel Zhobro）和努里亚·阿门戈尔·乌尔皮（Núria Armengol Urpí）在整个项目中的帮助。马尔科·巴加泰拉（Marco Bagatella）和乔纳斯·弗雷（Jonas Frey）受马克斯·普朗克学习系统中心（Max Planck ETH Center for Learning Systems）资助。格奥尔格·马蒂乌斯（Georg Martius）是机器学习卓越集群（Machine Learning Cluster of Excellence）成员，卓越集群编号 2064/1 - 项目编号 390727645。感谢德国联邦教育与研究部（BMBF）通过蒂宾根人工智能中心（Tübingen AI Center，项目编号：01IS18039A）提供的支持。最后，本工作受欧洲研究理事会（ERC）项目 101045454 REAL-RL 资助。

参考文献

- Amos, B., Luise, G., Cohen, S., and Redko, I. [Meta optimal transport](#). In Krause, A., Brunskill, E., Cho, K., Engelhardt, B., Sabato, S., and Scarlett, J. (eds.), *International Conference on Machine Learning, ICML 2023, 23-29 July 2023, Honolulu, Hawaii, USA*, volume 202 of *Proceedings of Machine Learning Research*, pp. 791–813. PMLR, 2023.
- Andrychowicz, M., Crow, D., Ray, A., Schneider, J., Fong, R., Welinder, P., McGrew, B., Tobin, J., Abbeel, P., and Zaremba, W. [Hindsight experience replay](#). In Guyon, I., von Luxburg, U., Bengio, S., Wallach, H. M., Fergus, R., Vishwanathan, S. V. N., and Garnett, R. (eds.), *Advances in Neural Information Processing Systems 30: Annual Conference on Neural Information Processing Systems 2017, December 4-9, 2017, Long Beach, CA, USA*, pp. 5048–5058, 2017.
- Bagatella, M. and Martius, G. [Goal-conditioned offline planning from curious exploration](#). In Oh, A., Naumann, T., Globerson, A., Saenko, K., Hardt, M., and Levine, S. (eds.), *Advances in Neural Information Processing Systems 36: Annual Conference on Neural Information Processing Systems 2023, NeurIPS 2023, New Orleans, LA, USA, December 10 - 16, 2023*, 2023.
- Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J. D., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D., Wu, J., Winter, C., Hesse, C., Chen, M., Sigler, E., Litwin, M., Gray, S., Chess, B., Clark, J., Berner, C., McCandlish, S., Radford, A., Sutskever, I., and Amodei, D. [Language models are few-shot learners](#). In Larochelle, H., Ranzato, M., Hadsell, R., Balcan, M., and Lin, H. (eds.), *Advances in Neural Information Processing Systems*, volume 33, pp. 1877–1901. Curran Associates, Inc., 2020.
- Bunne, C., Stark, S. G., Gut, G., del Castillo, J. S., Levesque, M., Lehmann, K.-V., Pelkmans, L., Krause, A., and Rätsch, G. [Learning single-cell perturbation responses using neural optimal transport](#). *Nature Methods*, 20(11):1759–1768, Nov 2023. ISSN 1548-7105. doi: 10.1038/s41592-023-01969-x.
- Chi, C., Feng, S., Du, Y., Xu, Z., Cousineau, E., Burchfiel, B., and Song, S. Diffusion policy: Visuomotor policy learning via action diffusion. In *Proceedings of Robotics: Science and Systems (RSS)*, 2023.
- Chua, K., Calandra, R., McAllister, R., and Levine, S. [Deep reinforcement learning in a handful of trials using probabilistic dynamics models](#). In Bengio, S., Wallach, H. M., Larochelle, H., Grauman, K., Cesa-Bianchi, N., and Garnett, R. (eds.), *Advances in Neural Information Processing Systems 31: Annual Conference on Neural Information Processing Systems 2018, NeurIPS 2018, December 3-8, 2018, Montréal, Canada*, pp. 4759–4770, 2018.
- Clement, P. and Desch, W. An elementary proof of the triangle inequality for the wasserstein metric. *Proceedings of The American Mathematical Society - PROC AMER MATH SOC*, 136:333–340, 01 2008. doi: 10.1090/S0002-9939-07-09020-X.
- Cuturi, M. [Sinkhorn distances: Lightspeed computation of optimal transport](#). In Burges, C., Bottou, L., Welling, M., Ghahramani, Z., and Weinberger, K. (eds.), *Advances in Neural Information Processing Systems*, volume 26. Curran Associates, Inc., 2013.
- Cuturi, M., Meng-Papaxanthos, L., Tian, Y., Bunne, C., Davis, G., and Teboul, O. [Optimal transport tools \(ott\)](#):

- A jax toolbox for all things wasserstein. *arXiv preprint arXiv:2201.12324*, 2022.
- Dadashi, R., Hussenot, L., Geist, M., and Pietquin, O. **Primal wasserstein imitation learning**. In *9th International Conference on Learning Representations, ICLR 2021, Virtual Event, Austria, May 3-7, 2021*. OpenReview.net, 2021.
- Datko, R. **Foundations of optimal control theory (e. bruce lee and lawrence markus)**. *SIAM Rev.*, 11(1):93–95, January 1969. ISSN 0036-1445. doi: 10.1137/1011020.
- Duan, Y., Andrychowicz, M., Stadie, B. C., Ho, J., Schneider, J., Sutskever, I., Abbeel, P., and Zaremba, W. **One-shot imitation learning**. In Guyon, I., von Luxburg, U., Bengio, S., Wallach, H. M., Fergus, R., Vishwanathan, S. V. N., and Garnett, R. (eds.), *Advances in Neural Information Processing Systems 30: Annual Conference on Neural Information Processing Systems 2017, December 4-9, 2017, Long Beach, CA, USA*, pp. 1087–1098, 2017.
- Durugkar, I., Tec, M., Niekum, S., and Stone, P. **Adversarial intrinsic motivation for reinforcement learning**. In Ranzato, M., Beygelzimer, A., Dauphin, Y. N., Liang, P., and Vaughan, J. W. (eds.), *Advances in Neural Information Processing Systems 34: Annual Conference on Neural Information Processing Systems 2021, NeurIPS 2021, December 6-14, 2021, virtual*, pp. 8622–8636, 2021.
- Eysenbach, B., Zhang, T., Levine, S., and Salakhutdinov, R. **Contrastive learning as goal-conditioned reinforcement learning**. In Koyejo, S., Mohamed, S., Agarwal, A., Belgrave, D., Cho, K., and Oh, A. (eds.), *Advances in Neural Information Processing Systems 35: Annual Conference on Neural Information Processing Systems 2022, NeurIPS 2022, New Orleans, LA, USA, November 28 - December 9, 2022*, 2022.
- Flamary, R., Courty, N., Gramfort, A., Alaya, M. Z., Boissunon, A., Chambon, S., Chapel, L., Corenflos, A., Fatras, K., Fournier, N., Gautheron, L., Gayraud, N. T., Janati, H., Rakotomamonjy, A., Redko, I., Rolet, A., Schutz, A., Seguy, V., Sutherland, D. J., Tavenard, R., Tong, A., and Vayer, T. **Pot: Python optimal transport**. *Journal of Machine Learning Research*, 22(78):1–8, 2021.
- Florence, P., Lynch, C., Zeng, A., Ramirez, O. A., Wahid, A., Downs, L., Wong, A., Lee, J., Mordatch, I., and Tompson, J. **Implicit behavioral cloning**. In Faust, A., Hsu, D., and Neumann, G. (eds.), *Conference on Robot Learning, 8-11 November 2021, London, UK*, volume 164 of *Proceedings of Machine Learning Research*, pp. 158–168. PMLR, 2021.
- Frans, K., Park, S., Abbeel, P., and Levine, S. **Unsupervised zero-shot reinforcement learning via functional reward encodings**. In *Forty-first International Conference on Machine Learning, ICML 2024, Vienna, Austria, July 21-27, 2024*. OpenReview.net, 2024.
- Fu, J., Kumar, A., Nachum, O., Tucker, G., and Levine, S. **D4RL: Datasets for Deep Data-Driven Reinforcement Learning**, 2021.
- Ghosh, D., Walke, H., Pertsch, K., Black, K., Mees, O., Dasari, S., Hejna, J., Kreiman, T., Xu, C., Luo, J., Tan, Y. L., Chen, L. Y., Sanketi, P., Vuong, Q., Xiao, T., Sadigh, D., Finn, C., and Levine, S. **Octo: An open-source generalist robot policy**. *CoRR*, abs/2405.12213, 2024. doi: 10.48550/ARXIV.2405.12213.
- Ha, D. and Schmidhuber, J. **World models**. *CoRR*, abs/1803.10122, 2018.
- Haarnoja, T., Zhou, A., Abbeel, P., and Levine, S. **Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor**. In Dy, J. and Krause, A. (eds.), *Proceedings of the 35th International Conference on Machine Learning*, volume 80 of *Proceedings of Machine Learning Research*, pp. 1861–1870. PMLR, 10–15 Jul 2018.
- Haldar, S., Mathur, V., Yarats, D., and Pinto, L. **Watch and match: Supercharging imitation with regularized optimal transport**. In Liu, K., Kulic, D., and Ichnowski, J. (eds.), *Conference on Robot Learning, CoRL 2022, 14-18 December 2022, Auckland, New Zealand*, volume 205 of *Proceedings of Machine Learning Research*, pp. 32–43. PMLR, 2022.
- Hansen, N., Su, H., and Wang, X. **TD-MPC2: scalable, robust world models for continuous control**. In *The Twelfth International Conference on Learning Representations, ICLR 2024, Vienna, Austria, May 7-11, 2024*. OpenReview.net, 2024.
- Hao, P., Lu, T., Cui, S., Wei, J., Cai, Y., and Wang, S. **Sozil: Self-optimal zero-shot imitation learning**. *IEEE Transactions on Cognitive and Developmental Systems*, 15(4): 2077–2088, 2023. doi: 10.1109/TCDS.2021.3116604.
- Ho, J. and Ermon, S. **Generative adversarial imitation learning**. In Lee, D., Sugiyama, M., Luxburg, U., Guyon, I., and Garnett, R. (eds.), *Advances in Neural Information Processing Systems*, volume 29. Curran Associates, Inc., 2016.
- Jang, E., Irpan, A., Khansari, M., Kappler, D., Ebert, F., Lynch, C., Levine, S., and Finn, C. **BC-Z: Zero-Shot Task Generalization with Robotic Imitation Learning**. In *Proceedings of the 5th Conference on Robot Learning*, pp. 991–1002. PMLR, 2022.

- Jeen, S., Bewley, T., and Cullen, J. M. [Zero-shot reinforcement learning from low quality data](#). *Advances in Neural Information Processing Systems* 38, 2024.
- Kim, G., Seo, S., Lee, J., Jeon, W., Hwang, H., Yang, H., and Kim, K. [Demodice: Offline imitation learning with supplementary imperfect demonstrations](#). In *The Tenth International Conference on Learning Representations, ICLR 2022, Virtual Event, April 25-29, 2022*. OpenReview.net, 2022.
- Kim, M. J., Pertsch, K., Karamcheti, S., Xiao, T., Balakrishna, A., Nair, S., Rafailov, R., Foster, E. P., Lam, G., Sanketi, P., Vuong, Q., Kollar, T., Burchfiel, B., Tedrake, R., Sadigh, D., Levine, S., Liang, P., and Finn, C. [Openvla: An open-source vision-language-action model](#). *CoRR*, abs/2406.09246, 2024. doi: 10.48550/ARXIV.2406.09246.
- Kojima, T., Gu, S. S., Reid, M., Matsuo, Y., and Iwasawa, Y. [Large language models are zero-shot reasoners](#). In Koyejo, S., Mohamed, S., Agarwal, A., Belgrave, D., Cho, K., and Oh, A. (eds.), *Advances in Neural Information Processing Systems*, volume 35, pp. 22199–22213. Curran Associates, Inc., 2022.
- Laskin, M., Yarats, D., Liu, H., Lee, K., Zhan, A., Lu, K., Cang, C., Pinto, L., and Abbeel, P. [URLB: unsupervised reinforcement learning benchmark](#). In Vanschoren, J. and Yeung, S. (eds.), *Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks 1, NeurIPS Datasets and Benchmarks 2021, December 2021, virtual*, 2021.
- Li, C., Vlastelica, M., Blaes, S., Frey, J., Grimminger, F., and Martius, G. [Learning agile skills via adversarial imitation of rough partial demonstrations](#). In *Conference on Robot Learning*, pp. 342–352. PMLR, 2023.
- Liero, M., Mielke, A., and Savaré, G. [Optimal entropy-transport problems and a new hellinger-kantorovich distance between positive measures](#). *Inventiones mathematicae*, 211, 03 2018. doi: 10.1007/s00222-017-0759-8.
- Liu, J., He, L., Kang, Y., Zhuang, Z., Wang, D., and Xu, H. [CEIL: generalized contextual imitation learning](#). In Oh, A., Naumann, T., Globerson, A., Saenko, K., Hardt, M., and Levine, S. (eds.), *Advances in Neural Information Processing Systems 36: Annual Conference on Neural Information Processing Systems 2023, NeurIPS 2023, New Orleans, LA, USA, December 10 - 16, 2023*, 2023.
- Luo, Y., Jiang, Z., Cohen, S., Grefenstette, E., and Deisenroth, M. P. [Optimal transport for offline imitation learning](#). In *The Eleventh International Conference on Learning Representations, ICLR 2023, Kigali, Rwanda, May 1-5, 2023*. OpenReview.net, 2023.
- Ma, Y. J., Shen, A., Jayaraman, D., and Bastani, O. [Versatile offline imitation from observations and examples via regularized state-occupancy matching](#). In Chaudhuri, K., Jegelka, S., Song, L., Szepesvári, C., Niu, G., and Sabato, S. (eds.), *International Conference on Machine Learning, ICML 2022, 17-23 July 2022, Baltimore, Maryland, USA*, volume 162 of *Proceedings of Machine Learning Research*, pp. 14639–14663. PMLR, 2022.
- Mendonça, R., Rybkin, O., Daniilidis, K., Hafner, D., and Pathak, D. [Discovering and achieving goals via world models](#). In Ranzato, M., Beygelzimer, A., Dauphin, Y. N., Liang, P., and Vaughan, J. W. (eds.), *Advances in Neural Information Processing Systems 34: Annual Conference on Neural Information Processing Systems 2021, NeurIPS 2021, December 6-14, 2021, virtual*, pp. 24379–24391, 2021.
- O’Neill, A., Rehman, A., and et. al. [Open X-Embodiment: Robotic learning datasets and RT-X models](#). <https://arxiv.org/abs/2310.08864>, 2023.
- P., M. V., Blaes, S., Pinneri, C., and Martius, G. [Risk-averse zero-order trajectory optimization](#). In Faust, A., Hsu, D., and Neumann, G. (eds.), *Conference on Robot Learning, 8-11 November 2021, London, UK*, volume 164 of *Proceedings of Machine Learning Research*, pp. 444–454. PMLR, 2021.
- Pan, X., Zhang, T., Ichter, B., Faust, A., Tan, J., and Ha, S. [Zero-shot imitation learning from demonstrations for legged robot visual navigation](#). In *2020 IEEE International Conference on Robotics and Automation, ICRA 2020, Paris, France, May 31 - August 31, 2020*, pp. 679–685. IEEE, 2020. doi: 10.1109/ICRA40945.2020.9196602.
- Pathak, D., Mahmoudieh, P., Luo, G., Agrawal, P., Chen, D., Shentu, Y., Shelhamer, E., Malik, J., Efros, A. A., and Darrell, T. [Zero-shot visual imitation](#). In *2018 IEEE Conference on Computer Vision and Pattern Recognition Workshops, CVPR Workshops 2018, Salt Lake City, UT, USA, June 18-22, 2018*, pp. 2050–2053. Computer Vision Foundation / IEEE Computer Society, 2018. doi: 10.1109/CVPRW.2018.00278.
- Pathak, D., Gandhi, D., and Gupta, A. [Self-supervised exploration via disagreement](#). In *ICML*, 2019.
- Peyré, G. and Cuturi, M. [Computational optimal transport](#). *Found. Trends Mach. Learn.*, 11(5-6):355–607, 2019. doi: 10.1561/22000000073.
- Pineda, L., Amos, B., Zhang, A., Lambert, N. O., and Cailandra, R. [Mbrl-lib: A modular library for model-based reinforcement learning](#). *Arxiv*, 2021.

- Pinneri, C., Sawant, S., Blaes, S., Achterhold, J., Stueckler, J., Rolínek, M., and Martius, G. [Sample-efficient cross-entropy method for real-time planning](#). In Kober, J., Ramos, F., and Tomlin, C. J. (eds.), *4th Conference on Robot Learning, CoRL 2020, 16-18 November 2020, Virtual Event / Cambridge, MA, USA*, volume 155 of *Proceedings of Machine Learning Research*, pp. 1049–1065. PMLR, 2020.
- Pirotta, M., Tirinzoni, A., Touati, A., Lazaric, A., and Ollivier, Y. [Fast imitation via behavior foundation models](#). In *The Twelfth International Conference on Learning Representations, ICLR 2024, Vienna, Austria, May 7-11, 2024*. OpenReview.net, 2024.
- Plappert, M., Andrychowicz, M., Ray, A., McGrew, B., Baker, B., Powell, G., Schneider, J., Tobin, J., Chociej, M., Welinder, P., Kumar, V., and Zaremba, W. [Multi-goal reinforcement learning: Challenging robotics environments and request for research](#), 2018.
- Pooladian, A., Domingo-Enrich, C., Chen, R. T. Q., and Amos, B. [Neural optimal transport with lagrangian costs](#). *CoRR*, abs/2406.00288, 2024. doi: 10.48550/ARXIV.2406.00288.
- Reddy, S., Dragan, A. D., and Levine, S. [SQL: imitation learning via reinforcement learning with sparse rewards](#). In *8th International Conference on Learning Representations, ICLR 2020, Addis Ababa, Ethiopia, April 26-30, 2020*. OpenReview.net, 2020.
- Reed, S. E., Zolna, K., Parisotto, E., Colmenarejo, S. G., Novikov, A., Barth-Maron, G., Gimenez, M., Sulsky, Y., Kay, J., Springenberg, J. T., Eccles, T., Bruce, J., Razavi, A., Edwards, A., Heess, N., Chen, Y., Hadsell, R., Vinyals, O., Bordbar, M., and de Freitas, N. [A generalist agent](#). *Trans. Mach. Learn. Res.*, 2022, 2022.
- Rubinstein, R. Y. and Kroese, D. P. *The Cross Entropy Method: A Unified Approach To Combinatorial Optimization, Monte-carlo Simulation (Information Science and Statistics)*. Springer-Verlag, 2004. ISBN 978-0-387-21240-1.
- Sancaktar, C., Blaes, S., and Martius, G. [Curious exploration via structured world models yields zero-shot object manipulation](#). In Koyejo, S., Mohamed, S., Agarwal, A., Belgrave, D., Cho, K., and Oh, A. (eds.), *Advances in Neural Information Processing Systems 35: Annual Conference on Neural Information Processing Systems 2022, NeurIPS 2022, New Orleans, LA, USA, November 28 - December 9, 2022*, 2022.
- Santi, R. D., Prajapat, M., and Krause, A. [Global reinforcement learning : Beyond linear and convex rewards via submodular semi-gradient methods](#). In *Forty-first International Conference on Machine Learning, ICML 2024, Vienna, Austria, July 21-27, 2024*. OpenReview.net, 2024.
- Schaul, T., Horgan, D., Gregor, K., and Silver, D. [Universal value function approximators](#). In Bach, F. R. and Blei, D. M. (eds.), *Proceedings of the 32nd International Conference on Machine Learning, ICML 2015, Lille, France, 6-11 July 2015*, volume 37 of *JMLR Workshop and Conference Proceedings*, pp. 1312–1320. JMLR.org, 2015.
- Séjourné, T., Feydy, J., Vialard, F., Trounev, A., and Peyré, G. [Sinkhorn divergences for unbalanced optimal transport](#). *CoRR*, abs/1910.12958, 2019.
- Shafiuallah, N. M., Cui, Z. J., Altanzaya, A., and Pinto, L. [Behavior transformers: Cloning \\$k\\$ modes with one stone](#). In Koyejo, S., Mohamed, S., Agarwal, A., Belgrave, D., Cho, K., and Oh, A. (eds.), *Advances in Neural Information Processing Systems 35: Annual Conference on Neural Information Processing Systems 2022, NeurIPS 2022, New Orleans, LA, USA, November 28 - December 9, 2022*, 2022.
- Sinkhorn, R. and Knopp, P. [Concerning nonnegative matrices and doubly stochastic matrices](#). *Pacific Journal of Mathematics*, 21:343–348, 1967.
- Sutton, R. S. and Barto, A. G. *Reinforcement Learning: An Introduction*. A Bradford Book, Cambridge, MA, USA, 2018. ISBN 0262039249.
- Tassa, Y., Doron, Y., Muldal, A., Erez, T., Li, Y., de Las Casas, D., Budden, D., Abdolmaleki, A., Merel, J., Lefrancq, A., Lillicrap, T., and Riedmiller, M. [Deepmind control suite](#), 2018.
- Tian, S., Nair, S., Ebert, F., Dasari, S., Eysenbach, B., Finn, C., and Levine, S. [Model-based visual planning with self-supervised functional distances](#). In *9th International Conference on Learning Representations, ICLR 2021, Virtual Event, Austria, May 3-7, 2021*. OpenReview.net, 2021.
- Torabi, F., Warnell, G., and Stone, P. [Behavioral cloning from observation](#). In Lang, J. (ed.), *Proceedings of the Twenty-Seventh International Joint Conference on Artificial Intelligence, IJCAI 2018, July 13-19, 2018, Stockholm, Sweden*, pp. 4950–4957. ijcai.org, 2018. doi: 10.24963/IJCAI.2018/687.
- Touati, A. and Ollivier, Y. [Learning one representation to optimize all rewards](#). In Ranzato, M., Beygelzimer, A., Dauphin, Y. N., Liang, P., and Vaughan, J. W. (eds.), *Advances in Neural Information Processing Systems 34: Annual Conference on Neural Information Processing Systems 2021, NeurIPS 2021, December 6-14, 2021, virtual*, pp. 13–23, 2021.

- Touati, A., Rapin, J., and Ollivier, Y. [Does zero-shot reinforcement learning exist?](#) In *The Eleventh International Conference on Learning Representations, ICLR 2023, Kigali, Rwanda, May 1-5, 2023*. OpenReview.net, 2023.
- Wang, T., Torralba, A., Isola, P., and Zhang, A. [Optimal goal-reaching reinforcement learning via quasimetric learning](#), 2023.
- Wawrzyński, P. A cat-like robot real-time learning to run. In Kolehmainen, M., Toivanen, P., and Beliczynski, B. (eds.), *Adaptive and Natural Computing Algorithms*, pp. 380–390, Berlin, Heidelberg, 2009. Springer Berlin Heidelberg. ISBN 978-3-642-04921-7.
- Wei, J., Bosma, M., Zhao, V. Y., Guu, K., Yu, A. W., Lester, B., Du, N., Dai, A. M., and Le, Q. V. [Finetuned language models are zero-shot learners](#). In *The Tenth International Conference on Learning Representations, ICLR 2022, Virtual Event, April 25-29, 2022*. OpenReview.net, 2022.
- Williams, G., Aldrich, A., and Theodorou, E. A. [Model predictive path integral control using covariance variable importance sampling](#). *CoRR*, abs/1509.01149, 2015.
- Yang, R., Lu, Y., Li, W., Sun, H., Fang, M., Du, Y., Li, X., Han, L., and Zhang, C. [Rethinking goal-conditioned supervised learning and its connection to offline RL](#). In *International Conference on Learning Representations, 2022*.
- Zhang, X., Becker-Ehmck, P., van der Smagt, P., and Karl, M. [Action inference by maximising evidence: Zero-shot imitation from observation with world models](#). In Oh, A., Naumann, T., Globerson, A., Saenko, K., Hardt, M., and Levine, S. (eds.), *Advances in Neural Information Processing Systems 36: Annual Conference on Neural Information Processing Systems 2023, NeurIPS 2023, New Orleans, LA, USA, December 10 - 16, 2023*, 2023.
- Zolna, K., Novikov, A., Konyushkova, K., Gülçehre, Ç., Wang, Z., Aytaç, Y., Denil, M., de Freitas, N., and Reed, S. E. [Offline learning from demonstrations and unlabeled experience](#). *CoRR*, abs/2011.13885, 2020.

A. 补充结果

A.1. 主要结果详情

表 1 和表 2 给出了图 5 和图 6 的详细结果。图 7 汇总了本文评估的所有规划器。




图 7. 所有讨论规划器的性能汇总。详细结果见表 1 和表 2。

表 1. Pi+Cls、MPC+Cls 与 ZILOT（本文方法）在所有环境和任务中的性能。每个度量均为 20 次试验的均值，随后报告这些度量在 5 个随机种子上的均值和标准差。我们进行 Welch t 检验，以 $p = 0.05$ 区分最佳值并将其加粗。数值分别四舍五入至 3 位和 2 位小数。

Task	$W_{\min} \downarrow$					GoalFraction $\uparrow$				
	ER _{FB}	RER _{FB}	Pi+Cls	MPC+Cls	ZILOT (ours)	ER _{FB}	RER _{FB}	Pi+Cls	MPC+Cls	ZILOT (ours)
fetch_pick_and_place-L-dense	0.233±0.017	0.233±0.017	0.089±0.027	0.109±0.024	0.049±0.019	0.17±0.03	0.17±0.03	0.65±0.11	0.58±0.07	0.88±0.07
fetch_pick_and_place-L-sparse	0.170±0.011	0.170±0.011	0.112±0.014	0.127±0.022	0.092±0.015	0.35±0.04	0.35±0.04	0.62±0.05	0.43±0.04	0.65±0.05
fetch_pick_and_place-S-dense	0.183±0.019	0.183±0.019	0.113±0.022	0.101±0.022	0.049±0.014	0.16±0.04	0.16±0.04	0.41±0.07	0.62±0.08	0.85±0.08
fetch_pick_and_place-S-sparse	0.098±0.008	0.098±0.008	0.081±0.017	0.091±0.007	0.067±0.006	0.33±0.08	0.33±0.08	0.57±0.06	0.50±0.04	0.70±0.06
fetch_pick_and_place-U-dense	0.124±0.021	0.124±0.021	0.127±0.007	0.116±0.015	0.068±0.005	0.21±0.08	0.21±0.08	0.47±0.10	0.60±0.03	0.70±0.02
fetch_pick_and_place-U-sparse	0.163±0.028	0.163±0.028	0.142±0.005	0.160±0.008	0.098±0.003	0.30±0.07	0.30±0.07	0.51±0.02	0.38±0.03	0.55±0.05
fetch_pick_and_place-all	0.162±0.010	0.162±0.010	0.111±0.007	0.117±0.012	0.070±0.009	0.25±0.04	0.25±0.04	0.54±0.02	0.52±0.02	0.72±0.04
fetch_push-L-dense	0.246±0.001	0.246±0.001	0.056±0.001	0.085±0.018	0.041±0.015	0.15±0.00	0.15±0.00	0.96±0.03	0.72±0.09	0.91±0.06
fetch_push-L-sparse	0.184±0.014	0.184±0.014	0.101±0.011	0.103±0.010	0.082±0.004	0.35±0.04	0.35±0.04	0.65±0.09	0.44±0.04	0.69±0.06
fetch_push-S-dense	0.182±0.019	0.182±0.019	0.077±0.024	0.104±0.026	0.049±0.010	0.25±0.05	0.25±0.05	0.83±0.09	0.70±0.08	0.87±0.08
fetch_push-S-sparse	0.123±0.010	0.123±0.010	0.062±0.004	0.077±0.004	0.064±0.006	0.36±0.08	0.36±0.08	0.90±0.07	0.65±0.04	0.72±0.06
fetch_push-U-dense	0.141±0.011	0.141±0.011	0.102±0.044	0.091±0.009	0.065±0.004	0.28±0.07	0.28±0.07	0.72±0.18	0.67±0.08	0.77±0.02
fetch_push-U-sparse	0.195±0.024	0.195±0.024	0.106±0.044	0.131±0.012	0.109±0.007	0.32±0.03	0.32±0.03	0.70±0.12	0.45±0.05	0.53±0.03
fetch_push-all	0.178±0.008	0.178±0.008	0.084±0.007	0.098±0.010	0.068±0.005	0.29±0.02	0.29±0.02	0.79±0.05	0.61±0.03	0.75±0.03
fetch_slide_large_2D-L-dense	0.282±0.014	0.282±0.014	0.258±0.022	0.217±0.034	0.074±0.011	0.17±0.04	0.17±0.04	0.26±0.06	0.40±0.11	0.76±0.03
fetch_slide_large_2D-L-sparse	0.255±0.007	0.255±0.007	0.223±0.014	0.185±0.027	0.120±0.011	0.38±0.05	0.38±0.05	0.47±0.10	0.70±0.05	0.73±0.04
fetch_slide_large_2D-S-dense	0.232±0.029	0.232±0.029	0.299±0.006	0.254±0.022	0.111±0.010	0.19±0.05	0.19±0.05	0.21±0.10	0.31±0.06	0.51±0.07
fetch_slide_large_2D-S-sparse	0.215±0.014	0.215±0.014	0.266±0.006	0.230±0.021	0.086±0.015	0.28±0.04	0.28±0.04	0.31±0.02	0.43±0.02	0.74±0.04
fetch_slide_large_2D-U-dense	0.225±0.051	0.226±0.051	0.214±0.029	0.191±0.045	0.076±0.009	0.14±0.03	0.14±0.03	0.30±0.07	0.35±0.10	0.76±0.04
fetch_slide_large_2D-U-sparse	0.291±0.049	0.294±0.048	0.169±0.043	0.150±0.012	0.120±0.005	0.30±0.04	0.29±0.04	0.36±0.09	0.53±0.04	0.70±0.06
fetch_slide_large_2D-all	0.250±0.012	0.251±0.012	0.238±0.008	0.205±0.020	0.098±0.007	0.24±0.02	0.24±0.02	0.32±0.04	0.45±0.04	0.70±0.02
halfcheetah-backflip	2.002±0.149	2.002±0.149	3.089±0.588	4.281±0.371	2.625±0.780	0.44±0.08	0.44±0.08	0.28±0.13	0.12±0.12	0.57±0.17
halfcheetah-backflip-running	2.853±0.104	2.853±0.104	2.879±0.427	3.044±0.752	2.171±0.454	0.06±0.05	0.06±0.05	0.44±0.10	0.46±0.18	0.58±0.11
halfcheetah-frontflip	1.286±0.059	1.286±0.059	1.544±0.127	1.695±0.147	1.295±0.094	0.73±0.22	0.73±0.22	0.77±0.09	0.79±0.12	1.00±0.00
halfcheetah-frontflip-running	2.137±0.204	2.137±0.204	2.086±0.133	2.083±0.104	1.955±0.057	0.27±0.08	0.27±0.08	0.70±0.08	0.81±0.07	0.85±0.03
halfcheetah-hop-backward	0.910±0.316	0.910±0.316	0.806±0.110	0.950±0.075	0.589±0.107	0.65±0.19	0.65±0.19	0.96±0.03	0.90±0.02	0.96±0.03
halfcheetah-hop-forward	1.418±0.332	1.418±0.332	1.580±0.069	1.392±0.206	1.101±0.152	0.43±0.09	0.43±0.09	0.51±0.07	0.62±0.14	0.58±0.12
halfcheetah-run-backward	0.667±0.079	0.667±0.079	0.897±0.092	0.679±0.035	0.489±0.167	0.81±0.09	0.81±0.09	0.96±0.04	1.00±0.00	0.99±0.01
halfcheetah-run-forward	0.712±0.064	0.712±0.064	0.857±0.044	0.822±0.206	0.376±0.019	0.76±0.07	0.76±0.07	1.00±0.01	0.94±0.08	1.00±0.00
halfcheetah-all	1.498±0.105	1.498±0.105	1.717±0.101	1.868±0.079	1.325±0.123	0.52±0.03	0.52±0.03	0.70±0.05	0.71±0.02	0.82±0.02
pointmaze_medium-circle-dense	1.128±0.250	1.128±0.250	0.243±0.038	0.221±0.021	0.156±0.010	0.18±0.06	0.18±0.06	1.00±0.00	1.00±0.00	1.00±0.00
pointmaze_medium-circle-sparse	1.483±0.410	1.483±0.410	0.385±0.015	0.404±0.025	0.466±0.024	0.22±0.00	0.22±0.00	1.00±0.00	1.00±0.00	0.81±0.11
pointmaze_medium-path-dense	0.900±0.317	0.900±0.317	0.275±0.063	0.235±0.023	0.199±0.013	0.56±0.11	0.56±0.11	1.00±0.00	1.00±0.00	1.00±0.00
pointmaze_medium-path-sparse	1.086±0.505	1.086±0.505	0.555±0.080	0.511±0.035	0.459±0.015	0.48±0.10	0.48±0.10	1.00±0.00	1.00±0.00	0.97±0.03
pointmaze_medium-all	1.149±0.163	1.149±0.163	0.365±0.021	0.343±0.023	0.320±0.009	0.36±0.02	0.36±0.02	1.00±0.00	1.00±0.00	0.94±0.04

表 2. 本文方法及其消融在所有环境和任务中的性能。每个度量均为 20 次试验的均值，随后报告这些度量在 5 个随机种子上的均值和标准差。我们进行 Welch t 检验，以 $p = 0.05$ 区分最佳值并将其加粗。数值分别四舍五入至 3 位和 2 位小数。

Task	$W_{\min} \downarrow$				GoalFraction $\uparrow$			
	ZILOT+ h	ZILOT+Cls	ZILOT+Unbalanced	ZILOT (ours)	ZILOT+ h	ZILOT+Cls	ZILOT+Unbalanced	ZILOT (ours)
fetch.pick.and.place-L-dense	0.214±0.033	0.091±0.011	0.052±0.018	0.049±0.019	0.26±0.10	0.68±0.04	0.84±0.07	0.88±0.07
fetch.pick.and.place-L-sparse	0.188±0.014	0.158±0.004	0.095±0.016	0.092±0.015	0.40±0.01	0.35±0.02	0.65±0.08	0.65±0.05
fetch.pick.and.place-S-dense	0.198±0.042	0.089±0.019	0.045±0.006	0.049±0.014	0.36±0.15	0.71±0.07	0.86±0.03	0.85±0.08
fetch.pick.and.place-S-sparse	0.174±0.029	0.115±0.009	0.056±0.008	0.067±0.006	0.42±0.08	0.57±0.02	0.76±0.08	0.70±0.06
fetch.pick.and.place-U-dense	0.237±0.043	0.071±0.006	0.060±0.008	0.068±0.005	0.17±0.10	0.74±0.04	0.75±0.04	0.70±0.02
fetch.pick.and.place-U-sparse	0.229±0.034	0.167±0.004	0.101±0.008	0.098±0.003	0.34±0.04	0.33±0.05	0.54±0.05	0.55±0.05
fetch.pick.and.place-all	0.207±0.026	0.115±0.007	0.068±0.008	0.070±0.009	0.32±0.06	0.56±0.02	0.73±0.05	0.72±0.04
fetch.push-L-dense	0.211±0.020	0.071±0.006	0.040±0.004	0.041±0.015	0.27±0.06	0.73±0.02	0.91±0.03	0.91±0.06
fetch.push-L-sparse	0.200±0.022	0.150±0.005	0.101±0.014	0.082±0.004	0.39±0.06	0.36±0.03	0.65±0.07	0.69±0.06
fetch.push-S-dense	0.203±0.046	0.077±0.008	0.049±0.010	0.049±0.010	0.32±0.14	0.72±0.05	0.86±0.05	0.87±0.08
fetch.push-S-sparse	0.197±0.055	0.097±0.006	0.060±0.009	0.064±0.006	0.40±0.17	0.56±0.02	0.78±0.06	0.72±0.06
fetch.push-U-dense	0.228±0.045	0.068±0.007	0.058±0.009	0.065±0.004	0.20±0.10	0.78±0.04	0.81±0.03	0.77±0.02
fetch.push-U-sparse	0.224±0.047	0.136±0.017	0.100±0.007	0.109±0.007	0.36±0.07	0.39±0.05	0.61±0.05	0.53±0.03
fetch.push-all	0.211±0.033	0.100±0.006	0.068±0.005	0.068±0.005	0.32±0.08	0.59±0.02	0.77±0.03	0.75±0.03
fetch.slide.large.2D-L-dense	0.255±0.022	0.098±0.027	0.060±0.009	0.074±0.011	0.26±0.08	0.69±0.08	0.81±0.07	0.76±0.03
fetch.slide.large.2D-L-sparse	0.236±0.020	0.181±0.039	0.112±0.016	0.120±0.011	0.41±0.04	0.45±0.08	0.83±0.08	0.73±0.04
fetch.slide.large.2D-S-dense	0.256±0.035	0.105±0.011	0.091±0.009	0.111±0.010	0.23±0.10	0.63±0.03	0.59±0.10	0.51±0.07
fetch.slide.large.2D-S-sparse	0.272±0.045	0.132±0.033	0.084±0.010	0.086±0.015	0.28±0.07	0.52±0.08	0.79±0.04	0.74±0.04
fetch.slide.large.2D-U-dense	0.315±0.051	0.087±0.009	0.074±0.011	0.076±0.009	0.12±0.08	0.75±0.07	0.75±0.04	0.76±0.04
fetch.slide.large.2D-U-sparse	0.288±0.058	0.147±0.009	0.117±0.008	0.120±0.005	0.30±0.04	0.41±0.04	0.68±0.07	0.70±0.06
fetch.slide.large.2D-all	0.270±0.025	0.125±0.011	0.090±0.005	0.098±0.007	0.27±0.04	0.57±0.04	0.74±0.02	0.70±0.02
halfcheetah-backflip	1.947±0.312	3.170±0.730	2.710±0.742	2.625±0.780	0.50±0.18	0.43±0.14	0.55±0.20	0.57±0.17
halfcheetah-backflip-running	2.537±0.810	2.479±0.284	2.297±0.525	2.171±0.454	0.47±0.27	0.50±0.11	0.58±0.16	0.58±0.11
halfcheetah-frontflip	1.172±0.091	1.796±0.173	1.330±0.168	1.295±0.094	0.96±0.03	0.52±0.03	0.98±0.03	1.00±0.00
halfcheetah-frontflip-running	2.526±0.110	2.091±0.210	1.969±0.075	1.955±0.057	0.13±0.07	0.60±0.06	0.88±0.09	0.85±0.03
halfcheetah-hop-backward	0.739±0.736	0.889±0.103	0.548±0.056	0.589±0.107	0.84±0.33	0.82±0.07	0.96±0.04	0.96±0.03
halfcheetah-hop-forward	0.682±0.120	1.070±0.086	1.007±0.094	1.101±0.152	0.78±0.12	0.63±0.08	0.67±0.07	0.58±0.12
halfcheetah-run-backward	0.555±0.415	0.838±0.139	0.473±0.162	0.489±0.167	0.92±0.11	0.68±0.03	0.99±0.01	0.99±0.01
halfcheetah-run-forward	0.372±0.156	0.742±0.044	0.381±0.026	0.376±0.019	0.93±0.09	0.72±0.05	1.00±0.01	1.00±0.00
halfcheetah-all	1.316±0.181	1.634±0.089	1.339±0.090	1.325±0.123	0.69±0.06	0.61±0.02	0.83±0.02	0.82±0.02
pointmaze.medium.circle-dense	0.252±0.032	0.651±0.377	0.168±0.015	0.156±0.010	0.91±0.04	0.62±0.25	1.00±0.00	1.00±0.00
pointmaze.medium.circle-sparse	0.465±0.056	1.074±0.115	0.465±0.028	0.466±0.024	0.87±0.03	0.41±0.10	0.83±0.10	0.81±0.11
pointmaze.medium.path-dense	0.495±0.130	1.835±1.064	0.192±0.008	0.199±0.013	0.95±0.03	0.45±0.29	1.00±0.00	1.00±0.00
pointmaze.medium.path-sparse	0.716±0.119	1.416±0.828	0.444±0.010	0.459±0.015	0.89±0.10	0.61±0.24	0.99±0.01	0.97±0.03
pointmaze.medium-all	0.482±0.055	1.244±0.463	0.317±0.008	0.320±0.009	0.91±0.02	0.52±0.15	0.95±0.03	0.94±0.04

A.2. 有限时域消融

如第 4 节所述，由于学习到的动力学模型存在缺陷以及计算约束，我们不得不在有限时域 H 上优化目标。因此，只要模型保持准确，超参数 H 应尽可能大。我们在图 8 中针对环境 fetch slide large 2D 展示了这一权衡。可以清楚地看到，当时域小于 16（我们实验所选值）时，性能迅速恶化至近视规划器的水平。然而，当时域超过 16 时，性能并未提升，这表明模型不够准确，无法在该时域之外进行规划。

A.3. 单目标性能

当专家轨迹仅包含单个目标时，近视规划自然足以模仿专家。为验证这一点，我们在环境的标准单目标任务中评估所有规划器的性能。图 9 展示了所有规划器在该任务中的成功率，验证了非近视规划在此情况下既不阻碍也无帮助。

A.4. 环境相似性

我们在 walker 环境（Tassa 等人，2018）中评估 ZILOT 以及近视基线 Pi+Cls 和 MPC+Cls，

表 3. 由于该环境与我们在主要评估中使用的半猎豹（halfcheetah）环境非常相似，因此可以复用相同的目标空间、任务和数据收集方法。这些相似性也体现在三种方法的性能上。




图 8. 在抓取滑动大型二维 (fetch slide large 2D) 环境中, 不同规划时域下五个随机种子的平均性能。




图 9. 各环境标准单目标任务中的单目标成功率。我们报告了 20 次试验的平均性能以及 5 个随机种子的标准差。

表 3. 在步行者 (walker) 环境上的评估, 并重复列出半猎豹结果以供比较。

Task	$W_{\min} \downarrow$			GoalFraction $\uparrow$		
	Pi+Cls	MPC+Cls	ZILOT (ours)	Pi+Cls	MPC+Cls	ZILOT (ours)
walker-backflip	2.804±0.056	1.737±0.146	1.273±0.205	0.34±0.07	0.89±0.03	0.92±0.06
walker-backflip-running	3.039±0.292	2.444±0.189	1.709±0.093	0.49±0.07	0.70±0.08	0.81±0.09
walker-frontflip	2.688±0.400	1.830±0.185	1.551±0.086	0.57±0.16	0.94±0.04	0.95±0.07
walker-frontflip-running	2.597±0.265	1.937±0.172	1.921±0.149	0.55±0.03	0.63±0.16	0.76±0.11
walker-hop-backward	1.447±0.076	0.872±0.032	0.836±0.100	0.64±0.11	0.78±0.06	0.84±0.07
walker-hop-forward	0.932±0.098	0.663±0.071	0.467±0.044	0.95±0.05	0.99±0.01	1.00±0.01
walker-run-backward	1.290±0.148	1.050±0.086	0.957±0.111	0.81±0.08	0.83±0.14	0.84±0.09
walker-run-forward	1.180±0.105	0.954±0.079	0.672±0.058	0.86±0.07	0.97±0.03	0.99±0.01
walker-all	1.997±0.047	1.436±0.049	1.174±0.061	0.65±0.03	0.84±0.02	0.89±0.04
halfcheetah-backflip	3.089±0.588	4.281±0.371	2.625±0.780	0.28±0.13	0.12±0.12	0.57±0.17
halfcheetah-backflip-running	2.879±0.427	3.044±0.752	2.171±0.454	0.44±0.10	0.46±0.18	0.58±0.11
halfcheetah-frontflip	1.544±0.127	1.695±0.147	1.295±0.094	0.77±0.09	0.79±0.12	1.00±0.00
halfcheetah-frontflip-running	2.086±0.133	2.083±0.104	1.955±0.057	0.70±0.08	0.81±0.07	0.85±0.03
halfcheetah-hop-backward	0.806±0.110	0.950±0.075	0.589±0.107	0.96±0.03	0.90±0.02	0.96±0.03
halfcheetah-hop-forward	1.580±0.069	1.392±0.206	1.101±0.152	0.51±0.07	0.62±0.14	0.58±0.12
halfcheetah-run-backward	0.897±0.092	0.679±0.035	0.489±0.167	0.96±0.04	1.00±0.00	0.99±0.01
halfcheetah-run-forward	0.857±0.044	0.822±0.206	0.376±0.019	1.00±0.01	0.94±0.08	1.00±0.00
halfcheetah-all	1.717±0.101	1.868±0.079	1.325±0.123	0.70±0.05	0.71±0.02	0.82±0.02

B. 前向-后向表示与模仿学习

在零样本、无模型模仿学习 (IL) 的一篇奠基性论文中, (Pirotta 等人, 2024) 基于前向-后向 (FB) 框架 (Touati 与 Ollivier, 2021) 提出了若干方法。FB 训练两个函数 F 和 B , 它们恢复后继测度的低秩近似, 以及一个参数化策略 $(\pi_z)_{z \in \mathbb{R}^d}$ 。这些函数可以离线、无监督地训练, 使得对于每个奖励 r , 都能恢复出最优策略 π_{z_r} 。这一特性催生了一系列基于奖励和基于占用匹配的零样本模仿学习方法。接下来我们将逐一介绍每种方法, 并

讨论它们在目标上与 ZILOT 的差异。我们将重点说明若干方法为何不能直接适用于我们的设定，该设定涉及无动作、粗糙且部分的专家演示。关于基于 FB 的基线的实现细节，请读者参阅第 C.10 节。

B.1. 基于 FB 的模仿学习方法

行为克隆 Pirotta 等人 (2024) 提出的第一种方法基于对潜在 z 进行梯度下降，以找到最大化专家动作似然的策略 π_z 。由于该方法严格要求专家动作，因此不适用于本文场景。

基于奖励的模仿学习 (Pirotta 等人, 2024) 推导出两种基于奖励的零样本模仿学习方法，分别最大化奖励 $r(\cdot) = \rho^E(\cdot)/\rho^{D_\beta}(\cdot)$ (ERFB) (Ma et al., 2022; (Kim 等人, 2022) 及其正则化对应项 $r(\cdot) = \rho^E(\cdot)/(\rho^E(\cdot) + \rho^{D_\beta}(\cdot))$ (RERFB) (Reddy 等人, 2020; Zolna 等人, 2020)。ZILOT 的目标基于 Wasserstein 距离，而这些奖励源自正则化 f -散度目标。幸运的是，这些目标可计算，并可通过求解具有加性奖励的强化学习问题来最小化。实践中，这相当于为专家访问的每个状态分配一个标量奖励，而不考虑专家轨迹中状态的顺序。然而，正如 Pirotta 等人 (2024) 第 4.2 节所述，这种正则化会带来代价，尤其是当状态不包含动力学信息或处于遍历马尔可夫决策过程时。此时，策略可能通过停留在最可能的专家状态来最大化奖励，目标可能被退化解优化。另一方面，ZILOT 使用非正则化目标，会排除此类解。

尽管如此，这两种实例化完全兼容部分和粗略演示。因此，本文在第 5 节提供实证比较。

分布匹配 Pirotta 等人 (2024) 的另一种方法寻找策略 π_z ，使其占用度量在测度空间的不同距离下与专家占用度量匹配。ZILOT 也进行占用匹配，但基于 Wasserstein 距离。然而，ZILOT 设计用于处理状态抽象，即部分状态。据本文理解，基于前向-后向表示的分布匹配和特征匹配变体要求演示包含完整状态，除非训练额外的前向-后向表示来近似抽象状态上的后继测度。虽然分布匹配前向-后向模仿学习的标准实现无法模仿粗略演示，但本文认为朝此方向的扩展可能是未来工作的有趣方向。

基于目标的模仿 皮罗塔等人 (2024) 也实例化了一种分层的、基于目标的模仿方法，其中前向-后向框架仅用于目标达成。这一思想与我们的一个基线（策略加分类器）密切相关。然而，他们的框架假设待模仿的轨迹并不粗糙，并且不使用分类器，而是可以在每个时间步以固定的时间偏移量选择目标。无论如何，根据命题 3.1，他们的方法仍然是短视的。在实证上，皮罗塔等人 (2024) 观察到，这种前向-后向模仿学习的实例化并未显著优于依赖 TD3 加事后经验回放的等效方法。由于后一种方法与我们的策略加分类器基线非常相似，本文不再进一步研究该方法。

C. 实现细节

C.1. ZILOT

所提出的方法在第 4 节中进行了动机阐述和解释。现在补充更多细节。

辛霍恩算法 首先，在运行辛霍恩算法之前，将矩阵 C 按 $T_{\max}$ 重新缩放，并将其截断到范围 $[0, 1]$ 。执行的具体操作是

$$C \leftarrow \min(1, \max(0, C/T_{\max})). \quad (19)$$

这样做是为了在所有环境中使用相同的熵正则化 ϵ ，并确保没有异常值阻碍辛霍恩算法的收敛。对于算法本身，我们使用了一个受 (弗拉马里等人, 2021) 和 (库图里等人, 2022) 启发的自定义批量最优传输计算实现。我们运行辛霍恩算法 $r = 500$ 次迭代，正则化因子为 $\epsilon = 0.02$ 。

截断 当智能体接近专家轨迹的终点时，我们可能有 $t_K < k + H$ ，即规划时域大于所需。因此，我们将规划时域截断为估计的剩余步数（且至少为 1），即我们设置

$$H_{\text{actual}} \leftarrow \max(1, \min(t_K - k, H)). \quad (20)$$

非平衡最优传输 如正文第 5.3 节所述，我们可以使用非平衡最优传输（Liero 等人，2018；Séjourné 等人，2019）来解决目标占用近似中的均匀边缘分布可能不可行的问题。非平衡最优传输将 $\mathbf{T}^\top \cdot \mathbf{1}_N = \mathbf{1}_M$ 的硬约束替换为目标函数中的 $\xi_b \text{KL}(\mathbf{T}^\top \cdot \mathbf{1}_N, \mathbf{1}_M)$ 项。在我们的实验中，我们选择了 $\xi_b = 1$ 。

C.2. TD-MPC2 修改

由于 TD-MPC2（Hansen 等人，2024）已经是一个以学习到的任务嵌入 t （来自任务标识 i ）为条件的多任务算法，我们只需将这种条件切换为目标潜在变量 z_g ，即可得到如表 4 所述的目标条件算法。我们完全移除了对编码器和动力学模型 f 的条件化，因为目标条件强化学习的目标条件仅改变奖励，而不改变底层马尔可夫决策过程 $\mathcal{M}$ （假设在达到目标后截断，见第 2.3 节）。在训练中，我们直接采用所有 TD-MPC2 超参数（见表 7）。如正文所述，我们还训练一个小型多层感知机来预测 W ，该预测对 V 进行回归。

表 4. 我们对 TD-MPC2 所做的修改，使其成为目标条件而非任务条件。

	TD-MPC2 (Hansen et al., 2024)	“GC”-TD-MPC2 (our changes)
Task/Goal Embedding	$t = E(i)$	$z_g = h_g(g)$
Encoder	$z = h(s, t)$	$z = h(s)$
Dynamics	$z' = f(z, a, t)$	$z' = f(z, a)$
Reward Prediction	$r = R(z, a, t)$	$r = R(z, a, z_g)$
Q-function	$q = Q(z, a, t)$	$q = Q(z, a, z_g)$
Policy	$a \sim \pi(z, t)$	$a \sim \pi(z, z_g)$

我们发现成对距离 d 的计算是我们方法中的主要计算瓶颈，因为 TD-MPC2 将其计算为 $d = -V^\pi(s, g) = -Q(z, \pi(z, z_g), z_g)$ ，其中 $z = h(s), z_g = h_g(g)$ 。为了加速计算，我们训练一个单独的网络直接估计价值函数。它采用双流架构（Schaul 等人，2015；Eysenbach 等人，2022），形式为 $V^\pi(z, z_g) = \phi(z)^\top \psi(z_g)$ ，其中 ϕ 和 ψ 是用于快速推断成对距离的小型多层感知机。

我们的 GC-TD-MPC2 的训练方式与原始 TD-MPC2 相同，但额外使用了后见经验回放（Andrychowicz 等人，2017）来采样目标 g ，我们在附录 C.4 中详细讨论了这一点。第一个损失结合了 d 和 h 的多步损失与 R 和 Q 的单步 TD 步损失。

$$\mathcal{L} = \mathbb{E}_{\substack{(s, a, s')_{0:H} \sim \mathcal{D} \\ g_{0:H} \sim \text{HER}_\gamma(s_{0:H})}} \left[\sum_{t=0}^H \lambda^t (\|z'_t - \text{sg}(h(s'_t))\|_2^2 + \text{CE}(R(z_t, a_t, z_{g_t}), r_t) + \text{CE}(Q(z_t, a_t, z_{g_t}), q_t)) \right] \quad (21)$$

其中 sg 是“停止梯度”算子， z_t, z_{g_t} ， z'_t 在表 4 中定义，奖励为 $r_t = \mathbb{1}_{s_t=g_t} - 1$ ，且（无折扣）TD 目标为 $q_t = \max(r_t + \mathbb{1}_{s_t \neq g_t} \cdot \bar{Q}(z'_t, \pi(z'_t, z_{g_t}), z_{g_t}), -T_{\max})$ 。第二个损失是用于 π 的 SAC 风格损失（Haarnoja 等人，2018）

$$\mathcal{L}_\pi = \mathbb{E}_{\substack{(s, a, s')_{0:H} \sim \mathcal{D} \\ g_{0:H} \sim \text{HER}_\gamma(s_{0:H})}} \left[\sum_{t=0}^H \lambda^t (\alpha Q(z_t, \pi(z_t, z_{g_t}), z_{g_t}) + \beta \mathcal{H}(\pi(\cdot | z_t, z_{g_t}))) \right], z_t = d(z_t, a_t), z_0 = h(s_0). \quad (22)$$

除了 GC-TD-MPC2 之外，我们还使用与方程 (21) 中相同的 TD 目标来训练我们的目标条件价值函数 $V^\pi(z, z_g) = \phi(z)^\top \psi(z_g)$

$$\mathcal{L}_{\phi, \psi} = \mathbb{E}_{\substack{s_{0:H} \sim \mathcal{D} \\ g_{0:H} \sim \text{HER}_\gamma(s_{0:H})}} \left[\sum_{t=0}^H \lambda^t (\phi(z_t)^\top \psi(z_{g_t}) - q_t)^2 \right]. \quad (23)$$

C.3. 运行时间

ZILOT 在 Nvidia RTX 4090 GPU 上以 2 到 4Hz 的频率运行，具体取决于 H 的大小和 OT 问题的规模。鉴于 MPC+Cls 方法在相同网络和相同硬件上以约 25 到 72Hz 的频率运行，显然大部分计算都花费在准备成本矩阵 C 和运行 Sinkhorn 求解器上。可以采取若干进一步措施来加速 Sinkhorn 算法本身，包括 η 调度和/或 Anderson 加速 (Cuturi 等人, 2022)，以及使用势能进行热启动，例如来自先前 (优化器) 步骤或来自训练网络 (Amos 等人, 2023)。

C.4. 目标采样

如正文所述，我们遵循先前的工作 (Andrychowicz 等人, 2017; Bagatella & Martius, 2023; Tian 等人, 2021)，从 $\mathcal{D}_\beta$ 中轨迹的未来部分采样目标，以便在无监督的情况下合成奖励。具体过程如下：• 以概率 $p_{\text{future}} = 0.6$ ，我们从轨迹的未来部分采样一个目标，时间偏移为 $t \Delta \sim \text{Geom}(1-\gamma)$ 。• 以概率 $p_{\text{next}} = 0.2$ ，我们采样轨迹中的下一个目标。• 以概率 $p_{\text{rand}} = 0.2$ ，我们从数据集中采样一个随机目标。

C.5. 训练

我们使用表 5 中详细列出的数据集离线训练我们的 TD-MPC2 版本，共 600k 步。在单个 Nvidia A100 GPU 上训练大约需要 8 到 9 小时。请注意，由于 TD-MPC2 为每个元素采样 3 个转移的批次，我们实际上每个批次采样 $3 \cdot 256 = 768$ 个转移。所得模型随后用于所有规划器和实验。

表 5. 环境描述。我们详细列出了用于训练的数据集。环境 数据集 转换次数

Environment	Dataset	#Transitions
fetch_push	WGCSL (Yang et al., 2022) (expert+random)	400k + 400k
fetch_pick_and_place	WGCSL (Yang et al., 2022) (expert+random)	400k + 400k
fetch_slide_large_2D	custom (curious exploration (Pathak et al., 2019))	500k
halfcheetah	custom (curious exploration (Pathak et al., 2019))	500k
pointmaze_medium	D4RL (Fu et al., 2021) (expert)	1M

C.6. 环境

我们在表 6 中提供了环境细节。注意，虽然我们考虑的是无折扣设置，但我们在上述目标采样过程中指定了 γ 。

表 6. 环境细节。我们详细说明了每个环境使用的目标抽象 ϕ 、度量 h 、阈值 ϵ 、时间范围 H 、最大回合长度 $T_{\max}$ 和折扣因子 γ 。

Environment	Goal Abstraction ϕ	Metric h	Threshold ϵ	Horizon H	$T_{\max}$	γ
fetch_push	$(x, y, z)_{\text{cube}}$	$\ \cdot\ _2$	0.05	16	50	0.975
fetch_pick_and_place	$(x, y, z)_{\text{cube}}$	$\ \cdot\ _2$	0.05	16	50	0.975
fetch_slide_large_2D	$(x, y, z)_{\text{cube}}$	$\ \cdot\ _2$	0.05	16	50	0.975
halfcheetah	(x, θ_y)	$\ \cdot\ _2$	0.50	32	200	0.990
pointmaze_medium	(x, y)	$\ \cdot\ _2$	0.45	64	600	0.995

环境 fetch push、fetch pick and place 和 pointmaze medium 按原样使用。由于 halfcheetah 默认不是目标条件的，我们定义自己的目标范围为 $(x, \theta_y) \in [-5, 5] \times [-4\pi, 4\pi]^3$ 。fetch slide large 2D 是 fetch slide 环境的一个变体，其中桌面尺寸超过了机械臂的范围，并且机械臂被限制在接触桌面的二维运动。

3 注意，halfcheetah 环境不会通过任何模运算来减少 θ ，即具有 $\theta = 0$ 和 $\theta = 2\pi$ 的状态是不同的。

C.7. 任务

fetch 和 pointmaze 环境的任务在环境的正常目标空间中指定。它们的形状可以在附录 E 的图中看到。为了使 halfcheetah 的任务更清晰，我们在图 10、11、12、13、14 和 15 中可视化了我们方法的一些执行过程。




图 10. ZILOT（本文方法）在半猎豹后空翻奔跑任务中的示例轨迹。




图 11. ZILOT（本文方法）在半猎豹后空翻任务中的示例轨迹。




图 12. ZILOT（本文方法）在半猎豹前空翻奔跑任务中的示例轨迹。




图 15. ZILOT (本文方法) 在半猎豹向前跳跃任务中的示例轨迹。




图 13. ZILOT (本文方法) 在半猎豹前空翻任务中的示例轨迹。




图 14. ZILOT (本文方法) 在半猎豹向后跳跃任务中的示例轨迹。


C.8. 任务难度

本节研究 ZILOT 模仿其训练所用离线数据集中未出现轨迹的能力。由于 ZILOT 使用学习到的动力学模型和离线策略价值函数，理论上它能够将数据集中任意数量的轨迹拼接起来。为了获得一些定性直觉，我们叠加以下内容：首先，离线数据集中数据分布的核密度估计；其次，一条待模仿的专家轨迹；最后，在目标度量 h 下与专家轨迹的 Wasserstein 距离最近的五条轨迹。我们在图 16、18、19、17 和 20 中展示了每个环境的若干任务。

比较密度估计与专家轨迹，可以看出基本上所有专家轨迹都位于分布内。尽管特别是在半猎豹（halfcheetah）任务中，有些任务如向前跳跃（hop-forward）和后空翻奔跑（backflip-running）的覆盖非常少，这可能解释了所有规划器在这些任务中表现不佳的原因（见表 1）。将所选轨迹与专家轨迹进行比较，也明显看出专家演示并未直接出现在数据集中。因此，ZILOT 能够模仿未见过的状态序列，只要每个单独状态都在训练数据的支持范围内。换句话说，ZILOT 具备离线策略学习或轨迹拼接的能力。



图 16. 在不同半猎豹任务中，数据集中与专家轨迹（橙色）最接近的 5 条轨迹（蓝色），叠加在全训练数据集目标占用核密度估计之上。




(a) L-dense

(b) U-dense

(c) S-dense

图 17. 在不同取物滑动大型二维任务中，数据集中与专家轨迹（橙色）最接近的 5 条轨迹（蓝色），叠加在全训练数据集目标占用核密度估计之上。




(a) L-dense

(b) U-dense

(c) S-dense

图 18. 在不同取物推动任务中，数据集中与专家轨迹（橙色）最接近的 5 条轨迹（蓝色），叠加在全训练数据集目标占用核密度估计之上。




(a) L-dense


(b) U-dense

(c) S-dense

图 19. 在不同取物拾取与放置任务中，数据集中与专家轨迹（橙色）最接近的 5 条轨迹（蓝色），叠加在全训练数据集目标占用核密度估计之上。



(a) circle-dense



(b) path-dense

图 20. 在不同点迷宫中等任务中，数据集中与专家轨迹（橙色）最接近的 5 条轨迹（蓝色），叠加在全训练数据集目标占用核密度估计之上。

C.9. 超参数

表 7. TD-MPC2 超参数。我们原样采用了 Hansen 等人（2024）的设置。

Name	Value	Name	Value
lr	3e-4	num_bins	101
batch_size	256	vmin	-10
n_steps("horizon")	3	vmax	10
rho	0.5	num_enc_layers	2
grad_clip_norm	20	enc_dim	256
enc_lr_scale	0.3	num_channels	32
value_coef	0.1	mlp_dim	512
reward_coef	0.1	latent_dim	512
consistency_coef	20	bin_dim	12
tau	0.01	num_q	5
log_stdmin	-10	dropout	0.01
log_stdmax	2	simnorm_dim	8
entropy_coef	1e-4		

表 8. iCEM (Pinneri 等, 2020) 使用的超参数。我们采用 Pineda 等 (2021) 的实现。(a) 所有 MPC 规划器的 ICEM 超参数。

Name	Value
num_iterations	4
population_size	512
elite_ratio	0.01
population_decay_factor	1.0
colored_noise_exponent	2.0
keep_elite_frac	1.0
alpha	0.1

(b) 用于好奇探索的 ICEM 超参数。

Name	Value
num_iterations	3
population_size	512
elite_ratio	0.02
population_decay_factor	0.5
colored_noise_exponent	2.0
keep_elite_frac	1.0
alpha	0.1
horizon	20

C.10. FB 实现细节

由于没有直接可用的 FB-IL 实现, 我们根据 FB-IL (Pirotta 等, 2024) 附录 D.3 中的架构细节和附录 D.4 中的超参数, 采用了 FB (Touati 与 Ollivier, 2021) 的代码。主要架构改动包括将 B 网络的状态输入改为仅目标输入, 如 (Touati 与 Ollivier, 2021) 所建议, 并在 B 网络中添加最后一层, 用于 L2 投影、批归一化或不添加任何操作, 具体取决于环境。

我们尽可能遵循 Pirotta 等 (2024) 的规范。由于 halfcheetah 和 maze 也在他们的评估中使用, 我们采用了这些环境的超参数。对于我们的 fetch 环境, 我们使用了这些环境中最常见的超参数, 但将折扣 γ 调整为 0.95, 以考虑较短的回合长度。最后, 我们发现 FB 框架似乎不适合在比原始实验 (Touati 与 Ollivier, 2021; Pirotta 等, 2024) 少一个数量级的数据上进行训练。对于某些环境, 性能开始迅速恶化, 因此我们在每 50k 步评估时报告训练期间遇到的最佳性能 (见 D.2)。我们在表 9 中提供了完整的超参数集。

表 9. 用于 FB-IL 训练的超参数。对于 halfcheetah 和 maze, 紧密遵循 (Pirotta 等, 2024) 附录 D.4 中表 1。

Environment	fetch	halfcheetah	maze
Representation dimension	50	50	100
Batch size	2048	2048	1024
Discount factor γ	0.95	0.98	0.99
Optimizer	Adam	Adam	Adam
learning rate of F	10^{-4}	10^{-4}	10^{-4}
learning rate of B	10^{-4}	10^{-4}	10^{-6}
learning rate of π	10^{-4}	10^{-4}	10^{-6}
Normalization of B	L2	None	Batchnorm
Momentum for target networks	0.99	0.99	0.99
Stddev for policy smoothing	0.2	0.2	0.2
Truncation level for policy smoothing	0.3	0.3	0.3
Regularization weight for orthonormality	1	1	1
Numer of training steps	$2 \cdot 10^6$	$2 \cdot 10^6$	$2 \cdot 10^6$

D. 超参数搜索

D.1. 分类器阈值

如正文所述，我们对目标分类器的阈值进行了广泛的超参数搜索

(Cls) 针对短视方法 Pi+Cls 和 MPC+Cls 以及我们方法 ZILOT+Cls 的消融。在图 22 和图 21 中，我们展示了三种规划器在所有五个环境中的性能，并标出了每个环境中产生最佳性能的阈值。有趣的是，在一些抓取环境中，并非所有任务都在相同阈值下达到最大性能，这表明该超参数相当难以调整。




图 21. ZILOT+Cls 对 Cls 阈值的超参数搜索。




图 22. Pi+Cl 和 MPC+Cl 在每个环境中对 Cl 阈值的超参数搜索。

D.2. FB-IL 训练步骤。

如 C.10 节所述，我们报告了所有 FB 方法在训练过程中出现的最佳评估结果。在图 23 和图 24 中，我们报告了不同训练时长下的评估性能。




图 23. ERFB 在训练过程中的评估性能。




图 24. RERFB 在训练过程中的评估性能。

E. 附加定性结果

在下文中，我们展示了本工作中所有规划器、任务和随机种子下的全部目标空间轨迹。请注意，由于抓取环境中的任务表现出一些自然对称性，我们决定在所有四个对称版本之间拆分评估。此外，我们想快速强调，这些轨迹是在目标空间中展示的。这意味着，如果在抓取任务中立方体未被触碰（如 ZILOT+ h 在某些情况下的表现），那么轨迹本质上会变成起始位置上的一个单点。还需注意，Pi+Clis 是完全确定性的，因此其可视化结果看起来轨迹较少。




图 25. 抓取与放置




图 26. 抓取与放置




图 27. 抓取与放置




图 28. 抓取滑动大型二维




图 29. 抓取滑动大型二维




图 30. 抓取滑动大型二维




图 31. 抓取推动




图 32. 抓取推动




图 33. 抓取推动




图 34. 点迷宫中等




图 35. 半猎豹 第一部分




图 36. 半猎豹 第二部分