

基于时序最优传输奖励的机器人策略学习

Yuwei Fu¹ Haichao Zhang² Di Wu¹ Wei Xu² Benoit Boulet¹

¹McGill University

²Horizon Robotics

yuwei.fu@mail.mcgill.ca

haichao.zhang@horizon.cc

摘要

奖励设定是强化学习中最棘手的问题之一，通常需要在实际中繁琐的手工设计。应对这一挑战的一种有前景的方法是采用现有的专家视频演示进行策略学习。最近的一些工作研究了如何仅从单个或少数专家视频演示中学习机器人策略。例如，通过最优传输（Optimal Transport, OT）进行奖励标记已被证明是一种有效的策略，通过衡量机器人轨迹与专家演示之间的对齐程度来生成代理奖励。然而，以往的工作大多忽略了 OT 奖励对时序顺序信息的不变性，这可能给奖励信号带来额外噪声。为了解决这一问题，本文引入了时序最优传输（Temporal Optimal Transport, TemporalOT）奖励，以融入时序顺序信息，从而学习更准确的基于 OT 的代理奖励。在 Meta-world 基准任务上的大量实验验证了所提方法的有效性。代码可在以下地址获取：<https://github.com/fuyw/TemporalOT>。

1 引言

强化学习（Reinforcement Learning, RL）[51] 在广泛的应用中取得了巨大成功 [40]。然而，它通常需要与环境进行大量交互 [26, 35]，这限制了其在机器人控制中的实际应用 [9, 49]。大量工作从不同方面解决了这一问题 [52]，例如使用基于好奇心的内在奖励来鼓励探索 [2, 47]，利用在大规模机器人数据集上预训练的更好表示 [33, 38]，融入来自视觉语言模型（Vision-Language Models, VLMs）的外部知识 [13, 32]，以及模仿预先收集的专家演示的行为 [50, 62]。

奖励规范在强化学习（RL）中扮演着核心角色 [6]。由于强化学习智能体的目标是最大化期望累积奖励，奖励信号直接影响所学习的行为 [8]。将强化学习应用于实际问题时的一个主要挑战是如何设计奖励函数 [10]。设计良好的奖励函数能够更高效地引导智能体表现出期望行为，而设计不佳的奖励函数则可能导致次优行为 [25]。然而，设计良好的奖励函数并非易事 [11]，需要相关领域专业知识以及（或）耗时的手工奖励工程 [48]。缺乏良好的奖励函数是强化学习中低样本效率问题的主要瓶颈之一 [58]。

模仿学习（Imitation Learning, IL）已被证明是一种无需任务真实奖励即可学习控制策略的有效技术 [24]。给定专家演示数据集，模仿学习将策略学习形式化为监督学习范式 [27]。模仿学习的目标是通过最小化所学策略与近似专家策略之间的距离测度，学习一个模仿专家行为的策略 [23, 28]。根据强化学习智能体是否能够从进一步的在线交互中学习，模仿学习可粗略分为离线模仿学习和在线模仿学习 [29]。在离线模仿学习中，强化学习智能体仅从

收集的专家经验固定数据集。在在线模仿学习中，强化学习智能体通常学习一个代理奖励函数，以根据专家演示重新标记收集的在线轨迹 [53]。

模仿学习的一个显著不足在于，其通常需要多样且高质量的示范数据集才能达到期望的性能 [5]。近期，一些研究者发现最优传输

基于最优传输（**Optimal Transport, OT**）[18, 44] 的代理奖励函数使我们能够仅用少量专家演示 [30, 31] 学习有效的机器人策略。本文遵循这一研究方向，将基于最优传输的代理奖励应用于在线模仿学习，且不使用任何任务奖励信息。具体而言，我们首先重新审视基于最优传输的代理奖励在强化学习中的有效性，然后讨论现有方法因忽视时间顺序信息而面临的一些挑战。为缓解这一问题，我们提出了时序最优传输（**Temporal Optimal Transport, TemporalOT**）奖励，通过使用上下文嵌入和掩码机制，将时间顺序信息融入基于最优传输的代理奖励中。

本文的主要贡献可概括如下：

- 我们指出了现有基于最优传输的代理奖励方法在模仿学习中因忽视时间顺序信息而存在的不足；
- 我们设计了一种简单而有效的算法，通过使用上下文嵌入和掩码机制将时间顺序信息融入基于最优传输的代理奖励中；
- 实验表明，所提方法优于其他最先进的算法。

2 背景

2.1 强化学习

本文考虑标准马尔可夫决策过程（Markov Decision Process, MDP）[46] 设定 $\mathcal{M} = (\mathcal{S}, \mathcal{A}, R, P, \rho_0, \gamma)$ ，其中 $\mathcal{S}$ 和 $\mathcal{A}$ 分别为状态空间和动作空间， $R : \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ 为奖励函数， $P : \mathcal{S} \times \mathcal{A} \rightarrow \Delta(\mathcal{S})$ 为状态转移概率函数， $\rho_0 : \mathcal{S} \rightarrow \mathbb{R}_+$ 为初始状态分布， $\gamma \in [0, 1)$ 为折扣因子。目标是学习一个策略 $\pi(a|s) : \mathcal{S} \rightarrow \Delta(\mathcal{A})$ ，以最大化期望累积折扣奖励 $\mathbb{E}_\pi[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t)]$ ，其中 $s_0 \sim \rho_0$ ， $s_{t+1} \sim P(\cdot|s_t, a_t)$ 且 $a_t \sim \pi(\cdot|s_t)$ 。在部分可观测马尔可夫决策过程（Partially Observable MDP, POMDP）[19] 中，只能获得当前状态 s_i 的观测 $o_i \in \mathcal{O}$, i.e.，即图像观测。

为解决该优化问题，基于值的强化学习方法通常学习状态-动作值函数 $Q^\pi(s, a) := \mathbb{E}_\pi[\sum_{t=0}^{\infty} \gamma^t r_t | s_0 = s, a_0 = a]$ ，其定义为策略 π 下的期望回报。为方便起见，采用向量记号 $Q \in \mathbb{R}^{\mathcal{S} \times \mathcal{A}}$ ，并定义一步贝尔曼算子，使得 Q -函数 Q^π 为 $\mathcal{T}^\pi$ 的不动点，即 $Q^\pi = \mathcal{T}^\pi Q^\pi$ [51]。类似地，定义

$$\mathcal{T}^\pi : \mathbb{R}^{\mathcal{S} \times \mathcal{A}} \rightarrow \mathbb{R}^{\mathcal{S} \times \mathcal{A}} \quad \mathcal{T}^\pi Q(s, a) = R(s, a) + \gamma \mathbb{E}_{s' \sim P, a' \sim \pi}[Q(s', a')]. \quad \text{The}$$

最优贝尔曼算子如下 $\mathcal{T}Q^*(s, a) = R(s, a) + \gamma \mathbb{E}_{s' \sim P}[\max_{a'} Q(s', a')]$ 且最优 Q -值函数 Q^* 是 $\mathcal{T}Q^* = Q^*$ 的不动点。

在深度强化学习中，我们使用神经网络 $Q_\theta(s, a)$ 通过最小化经验贝尔曼误差来近似 Q 函数：

$$\mathbb{E}_{(s, a, r, s')} \left[(r + \gamma \max_{a'} Q_\theta^\pi(s', a') - Q_\theta^\pi(s, a))^2 \right], \quad (1)$$

其中我们从回放缓冲区采样转移 (s, a, r, s') ， $Q_\theta^\pi(s, a)$ 是目标网络。

2.2 逆强化学习

逆强化学习（Inverse Reinforcement Learning）旨在从专家演示 [39] 中推断底层奖励函数，从而进一步促进强化学习智能体学习策略。逆强化学习的一个关键假设是观察到的行为是最优的，使得观察到的轨迹最大化累积奖励 [17]。由于能够避免人工指定奖励，逆强化学习有望在实际的现实世界强化学习应用中得到应用。将 $\mathcal{M}$ 表示为马尔可夫决策过程， π^E 表示为专家策略，逆强化学习问题是找到一个最优奖励函数 R^* ，使得：

$$\mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t R^*(s_t) | \pi^E \right] \geq \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t R^*(s_t) | \pi \right], \forall \pi \in \Pi, \quad (2)$$

其中 Π 是可行的策略集。也就是说，专家策略 π^E 将比任何其他策略获得最大的期望累积折扣奖励。




图 1：在强化学习中应用基于最优传输的奖励的流程示意图。在这个玩具示例中，我们为两个智能体展开了五步转移。两个智能体都从初始状态开始，并在前两个状态采取相同的动作 a_0 和 a_1 。然后两个智能体采取不同的动作 a_2^a 和 a_2^b ，生成不同的轨迹 $\tau_a = (o_0, a_0, o_1, a_1, o_2, a_2^a, o_3^a, a_3^a, o_4^a, a_4^a, o_5^a)$ 和 $\tau_b = (o_0, a_0, o_1, a_1, o_2, a_2^b, o_3^b, a_3^b, o_4^b, a_4^b, o_5^b)$ 。即使状态-动作对完全相同， (o_0, a_0) 和 (o_1, a_1) 在 τ^a 和 τ^b 中的最优传输奖励也是不同的。

2.3 最优传输

最优传输 (Optimal Transport) 是一个优化问题，旨在寻找一个最优映射，以最小代价将一个概率分布变换为另一个概率分布。最优传输在经济学 [14]、物理学 [15] 和机器学习 [1] 等多个领域有着广泛的应用。考虑两个概率分布 $p \in \mathbb{R}^n, q \in \mathbb{R}^m$ 和乘积空间 $\mathcal{X} \times \mathcal{Y}$ 上的联合分布 $\mu(p, q)$ ， p 与 q 之间的 Wasserstein 距离 [54] 定义为：

$$\mathcal{W}(p, q) = \inf_{\mu} \int_{\mathcal{X} \times \mathcal{Y}} c(x, y) d\mu, \quad (3)$$

其中 $c(x, y)$ 是将质量从 x 移动到 y 的代价函数。在强化学习场景中， p 和 q 通常位于状态空间 $\mathcal{S}$ 或观测空间 $\mathcal{O}$ [21] 中。例如，给定专家轨迹 $\tau^E = (o_1^E, \dots, o_T^E)$ 和智能体轨迹 $\tau = \{o_1, \dots, o_T\}$ ，其中 o_i 是第 i 步的图像观测， τ^E 与 τ 之间的 Wasserstein 距离定义为以下离散形式：

$$\begin{aligned} \mathcal{W}(\tau, \tau^E) &= \min_{\mu \in \mathbb{R}^{T \times T}} \sum_{i=1}^T \sum_{j=1}^T c(o_i, o_j^E) \mu(i, j), \\ \text{s.t. } \sum_{i=1}^T \mu(i, j) &= \sum_{j=1}^T \mu(i, j) = \frac{1}{T}. \end{aligned} \quad (4)$$

其中 $\mu \in \mathbb{R}^{T \times T}$ 被称为传输计划，我们将最优传输计划记为 μ^* 。

3 方法

在本节中，我们首先回顾基于最优传输的代理奖励在强化学习中的应用。特别地，我们指出时间顺序信息的影响，这在大多数先前工作中被忽视。接下来，基于这些观察，我们介绍所提方法的主要思想和公式化表述。

3.1 强化学习中最优传输奖励的回顾

3.1.1 最优传输奖励有助于对状态和动作进行排序

在强化学习中，我们通常采用 Wasserstein 距离来衡量两条轨迹的相似性 [31]，如图 1 所示。给定智能体轨迹 $\tau = \{o_1, \dots, o_T\}$ 和专家轨迹 $\tau^E = \{o_1^E, \dots, o_T^E\}$ ，我们首先使用某种迭代方法计算式 (4) 中的最优传输计划 μ^* 。




图 2：为何最优传输奖励可能有用？当最优传输奖励总体正确时，它有助于对不同状态的好坏进行排序，并引导策略采取更优动作。（左）在玩具示例中，两个智能体在 o_2 处及之后采取了不同的动作 a_2^a 和 a_2^b 。 a_2^a 和 a_2^b 的好坏通过相对于下一状态观测 o_3^a 和 o_3^b 计算的最优传输奖励来衡量。（右）轨迹 τ^a 和 τ^b 的真实最优传输奖励曲线比较，其中 $o_0/o_1/o_2/o_3/o_4/o_5$ 对应于第 0/20/40/60/80/100 步的观测。可以观察到轨迹 b 的最优传输奖励总体更大，这表明最优传输奖励总体上是正确的。

优化算法，即辛克霍恩算法 [4]。然后，第 i 步基于最优传输的代理奖励定义如下：

$$r_i^{OT} = - \sum_{j=1}^T c(o_i, o_j^E) \mu^*(i, j), \quad (5)$$

其中 $c(o_i, o_j^E)$ 是一个代价函数，用于衡量 o_i 与 o_j^E 之间的相似性。先前工作中一种流行的选择是基于余弦相似度的代价函数 $c(o_i, o_j^E)$ 其中 $c(o_i, o_j^E) = 1 - \frac{\langle f(o_i), f(o_j^E) \rangle}{\|f(o_i)\| \|f(o_j^E)\|}$ 。 $f(o_i)$ 是由视觉编码器 [3] 提取的观测 o_i 的潜在表示。

与基于好奇心的探索奖励 [2] 类似，最优传输奖励用于区分不同状态的好坏。我们考虑图 1 中的玩具示例，两个智能体从具有观测 o_2 的相同状态出发，分别采取不同的动作 a_2^a 和 a_2^b 。然后， a_2^a 和 a_2^b 在 o_2 处的好坏通过相对于下一步观测 o_3^a 和 o_3^b 计算的最优传输奖励来衡量。只要最优传输奖励能够正确地对 $r_3^{OT}(o_3^a, \tau^a)$ 和 $r_3^{OT}(o_3^b, \tau^b)$ 进行排序，策略就能在 o_2 处学到更好的动作。从图 2（右）可以观察到，较优轨迹 b 的最优传输奖励总体更大，这验证了先前的解释。

3.1.2 两个关键观察

值得注意的是，关于最优传输奖励有两个关键观察在先前工作中较少被讨论：

1. 最优传输奖励具有顺序不变性。2. 步骤 i 处的最优传输奖励受到后续步骤的影响，因此具有相同状态-动作对的两个转移可能获得不同的最优传输奖励。

我们的第一个观察是标准最优传输奖励具有顺序不变性。如公式 (5) 所示，顺序信息被丢弃，演示轨迹中的帧被视为时间上折叠的帧集合。我们认为，折叠时间轴丢弃了时间顺序信息这一最重要的特征之一。更具体地说，考虑一个演示轨迹 $\tau_1 = (o_1, o_1, o_2)$ ，意味着智能体首先停留在第一个状态，然后移动到第二个状态。我们的目标是模仿这种行为。然而，如果像公式 (5) 那样丢弃顺序信息，从最优传输奖励的角度来看，无法区分 τ_1 和其他不期望的轨迹 *i.e.*, $\tau_2 = (o_1, o_2, o_1)$ ，后者首先移动到第二个状态，然后返回第一个状态。因此，在奖励计算中丢弃时间顺序信息使得基于此的奖励约束不足，从而增加了收敛到不期望解的可能性。

我们的第二个观察是最优传输奖励在训练过程中是非平稳的。如公式 (5) 所示，最优传输奖励 r_i^{OT} 依赖于最优传输计划 $\mu^*(i, j)$ ，而该计划依赖于整个轨迹。因此，每个状态的最优传输奖励是整个智能体轨迹的函数。如图 1 所示，尽管轨迹 τ^a 和轨迹 τ^b 具有相同的前两个转移，但它们的最优传输奖励值不同。这与标准强化学习设置非常不同，在标准设置中，奖励通常由固定的状态-动作对决定。这种非平稳的最优传输奖励可能存在缺陷，使得公式 (1) 中强化学习目标的优化变得不稳定。

受这两个观察的启发，我们发现当前基于最优传输的强化学习方法通常忽略了轨迹的时间顺序信息。在本工作中，我们旨在研究如何通过引入时间顺序信息来改进当前基于最优传输的强化学习方法。

3.2 时间最优传输奖励 (TemporalOT)

在本小节中，我们提出时间最优传输 (TemporalOT) 奖励。我们首先解释模型设计的动机，然后介绍所提方法的细节。

3.2.1 模型设计的动机

基于最优传输的奖励计算的标准流程通常包含两个阶段：

(阶段一) 首先定义两个状态之间的传输代价函数 $c(\cdot, \cdot)$ ；(阶段二) 然后求解公式 (4) 中的最优传输优化问题，以近似最优传输计划 μ^* ，并针对轨迹 τ 中的每个状态计算公式 (5) 中的最优传输奖励 r^{OT} 。

在最优传输奖励计算步骤之后，将使用最优传输奖励对转移进行重新标记，以按照公式 (1) 训练强化学习智能体。本文方法旨在改进最优传输奖励计算的两个阶段。首先，以往方法在阶段一中通常使用基于成对余弦相似度的代价函数，这有时可能不准确且存在噪声。其次，如第 3.1.2 节所述，以往方法在阶段二中忽略了时间顺序信息。本文将分别介绍两种简单的解决方案来解决这两个问题。

3.2.2 基于上下文嵌入的代价矩阵以改进阶段一

为了学习更准确的传输代价函数，本文引入基于上下文嵌入的代价矩阵。与以往使用成对余弦相似度作为传输代价的方法不同，本文采用分组余弦相似度，将智能体观测 o_i 与专家观测 o^E 之间的传输代价 c_{ij} 定义如下：

$$\hat{c}(o_i, o_j^E) = \frac{1}{k_c} \sum_{h=0}^{k_c-1} \left(1 - \frac{\langle f(o_{i+h}), f(o_{j+h}^E) \rangle}{\|f(o_{i+h})\| \|f(o_{j+h}^E)\|} \right), \quad (6)$$

其中 k_c 是上下文长度参数， $f(\cdot)$ 是固定的视觉编码器。上下文代价矩阵 $\hat{C}$ 的目标是通过考虑邻近信息来促进专家进度估计。例如，在图 3 中使用 $k_c = 3$ ， o_1 与 o_2^E 之间的传输代价为

$$\hat{c}(o_1, o_2^E) = 1 - [\cos(f(o_1), f(o_2^E)) + \cos(f(o_2), f(o_3^E)) + \cos(f(o_3), f(o_4^E))]/3.$$

3.2.3 用于改进阶段二的时间掩码最优传输目标

主流的 OT 奖励忽略了时间顺序信息，并将轨迹中每一步的信息都纳入考虑，如公式 (5) 所示。正如一些先前工作所指出的，OT 奖励并非总是正确的，噪声 OT 奖励可能会分散智能体学习某些关键早期行为的注意力 [30]。为缓解这一问题，我们提出一种简洁的解决方案，即在成本矩阵上添加时间掩码。

对于智能体轨迹 $\tau = \{o_1, \dots, o_T\}$ 和专家轨迹 $\tau^E = \{o_1^E, \dots, o_T^E\}$ ，我们将上下文成本矩阵记为 $\hat{C} \in \mathbb{R}^{T \times T}$ ，传输计划记为 $\mu \in \mathbb{R}^{T \times T}$ 。 μ 的行和与列和等于约束 $\mathbf{s} = [\frac{1}{T}, \dots, \frac{1}{T}] \in \mathbb{R}^T$ 。我们提出在传输计划上引入时间掩码 $M \in \mathbb{R}^{T \times T}$ ，其中 $M(i, j) \in [0, 1]$ 。我们可以将掩码后的最优




图 3: 所提出的 TemporalOT 方法示意图。(左) 我们使用分组余弦相似度而非逐对余弦相似度作为传输成本, 以学习更准确的成本矩阵。(右) 我们使用时间掩码强制 OT 奖励聚焦于较窄的范围, 以避免掩码窗口之外观测带来的潜在干扰。

传输目标表示为以下向量形式 [16]:

$$\mu^* = \arg \min_{\mu} \langle M \odot \mu, \hat{C} \rangle_F - \epsilon \mathcal{H}(M \odot \mu), \text{ s.t. } \mu \mathbf{1} = \mu^T \mathbf{1} = \mathbf{s}, \quad (7)$$

其中 $\langle \cdot, \cdot \rangle_F$ 是 Frobenius 范数, 我们添加了掩码传输计划 $\mathcal{H}(\cdot)$ 的熵正则化项 $M \odot \mu$ 。我们可以通过拉格朗日方法求解公式 (7):

$$L(\mu, \alpha, \beta) = \langle M \odot \mu, \hat{C} \rangle_F + \epsilon \left(\langle M \odot \mu, \log(M \odot \mu) \rangle_F - \mathbf{1}^T (M \odot \mu) \mathbf{1} \right) - \langle \alpha, (M \odot \mu) \mathbf{1} - \mathbf{s} \rangle_F - \langle \beta, (M \odot \mu)^T \mathbf{1} - \mathbf{s} \rangle_F, \quad (8)$$

其中 α 和 β 是两个拉格朗日乘子。通过使用不同的时间掩码, 我们可以控制 OT 奖励中使用何种时间顺序信息。例如, $M = \mathbf{1}$ 退化为原始的无时间顺序信息的 OT 奖励, 而下三角矩阵对应于 Transformer 解码器中的因果掩码 [55], 这表明我们只关注过去步骤的观测。在我们的方法中, 我们使用对角矩阵的一种变体:

$$M(i, j) = \begin{cases} 1, & \text{if } j \in [i - k_m, i + k_m], \\ 0, & \text{otherwise,} \end{cases} \quad (9)$$

其中 k_m 是窗口大小参数, 控制掩码 OT 奖励中使用的范围。较小的掩码窗口大小 k_m 意味着与专家示范更紧密的匹配。我们选择类对角矩阵, 是因为我们遵循先前从示范中学习的文献假设, 即智能体与专家具有相似的运动速度 [30]。在此假设下, 我们采用时间步索引之间的距离来表示时间亲和信息。图 3 展示了所提出的 TemporalOT 方法的主要思想。

4 实验

在本节中, 我们旨在回答以下问题: (1) 所提出的时序最优传输方法与其他基线相比表现如何? (2) 所提出的基于上下文嵌入的代价函数和时序掩码是否有效? (3) 关键参数如何影响性能? (4) 时序最优传输在基于状态和基于像素的观测下是否都有效?

4.1 实验设置

我们在 PyTorch [42] 中基于官方 ADS 实现¹实现了时序最优传输强化学习。我们使用预训练的 ResNet50 [20] 网络作为固定的视觉编码器, 为每个像素观测提取图像嵌入。与原始 ADS 实验中每个任务使用固定目标不同, 我们采用了更具挑战性的设置, 即每个回合的目标位置都会变化。此外, 我们仅向强化学习智能体提供两个专家视频演示。对于实验结果, 我们每 20000 步评估强化学习智能体 100 条轨迹。我们报告了 5 个随机种子下评估成功率的均值和标准差。如果强化学习智能体在最后一步解决了任务, 我们定义该轨迹为成功。更多详细信息见附录 B。

¹https://github.com/dwjshift/IL_ADS

表 1: 元世界基准上成功率的实验结果。

Environment	TaskReward	BC	GAIfO	OT0.99	OT0.9	ADS	TemporalOT
Basketball	0.0 (0.0)	0.2 (0.4)	0.0 (0.0)	0.0 (0.0)	76.6 (27.4)	42.2 (44.5)	94.4 (4.7)
Button-press	14.0 (18.5)	1.7 (2.4)	1.0 (1.1)	88.8 (2.5)	85.2 (3.3)	89.0 (3.8)	92.4 (3.6)
Door-lock	86.2 (12.4)	4.6 (7.0)	8.8 (12.2)	3.0 (5.5)	2.8 (2.0)	3.2 (2.7)	33.4 (2.8)
Door-open	0.0 (0.0)	10.7 (10.3)	2.2 (1.7)	46.2 (33.6)	30.2 (34.5)	52.0 (42.7)	78.4 (12.4)
Hand-insert	0.8 (1.6)	2.3 (2.1)	8.6 (4.4)	29.0 (9.7)	11.2 (2.3)	35.0 (5.3)	36.8 (6.6)
Lever-pull	0.0 (0.0)	0.8 (1.6)	3.4 (1.9)	15.4 (15.5)	35.6 (12.8)	21.2 (12.0)	53.6 (7.7)
Push	1.0 (0.7)	0.4 (0.8)	0.0 (0.0)	14.2 (7.5)	7.0 (2.6)	17.2 (5.6)	8.4 (1.7)
Stick-push	0.0 (0.0)	0.0 (0.0)	18.8 (22.9)	0.0 (0.0)	48.8 (41.5)	20.0 (40.0)	97.6 (2.6)
Window-open	85.6 (12.2)	1.6 (2.7)	4.0 (4.7)	54.0 (28.0)	22.4 (22.9)	43.6 (20.5)	55.2 (2.3)
Average	20.8	2.5	5.2	27.8	35.5	35.9	61.1




图 4: 模型组件的消融。所提出的两个组件都是有用的。

4.2 基线

我们比较以下基线方法。(1) 任务奖励: 使用 DrQ-v2 [56] 训练骨干强化学习智能体, 并使用真实任务奖励 r_i^{task} 。当任务解决时奖励 $= \delta_{\text{success}}$ 奖励为 1, 否则奖励为 0。(2) 行为克隆: 一种朴素的行为克隆智能体, 可以访问专家动作。(3) 生成对抗模仿学习: 另一种模仿学习基线, 学习一个判别器来提供代理奖励 [53]。(4) OT: 我们使用在线版本的 OTR [31] 智能体, 首先展开强化学习智能体以收集在线轨迹, 然后用 OTR 重新标记奖励用于强化学习训练。(5) ADS: OT 基线的一个变体, 根据进度跟踪器 [30] 自适应调整折扣因子。

4.3 元世界基准任务上的结果

我们首先在九个元世界 [57] 任务上验证了 TemporalOT 的有效性。实验结果如表 1 所示。我们可以观察到, TemporalOT 通常优于其他不使用任务奖励的基线。此外, TaskReward 基线仅在门锁和开窗任务上表现良好。主要原因是强化学习智能体未能收集到第一条成功轨迹。例如, 如图 1 所示, 篮球任务的目标是捡起篮球并移动到篮筐上方的目标位置。使用稀疏任务奖励时, 强化学习智能体只有在首次成功解决任务时才会收到非零奖励。在这种情况下, 仅凭零任务奖励和随机动作探索来收集第一条成功轨迹尤其具有挑战性。另一方面, 我们可以观察到两个模仿学习基线 BC 和 GAIfO [53] 的表现远差于其他基于 OT 奖励的基线。这是因为我们只提供了两个专家视频演示, 样本量只有几百个, 模仿学习方法存在过拟合问题。我们进一步比较了两个 OT 智能体基线, 其中 OT0.99 使用 $\gamma = 0.99$, OT0.9 使用 $\gamma = 0.9$ 。我们得出了与 ADS 中类似的结论: 在某些强烈依赖进度依赖性的任务 (如篮球) 中, 使用较小的折扣因子有助于学习早期行为。TemporalOT 在 9 个任务中的 8 个上优于最新的 SOTA 基线 ADS, 证明了所提方法的有效性。

4.4 不同模型组件的消融研究

我们进一步进行了消融研究, 以验证 TemporalOT 中提出的上下文成本矩阵和时间掩码的有效性。在图 4 中, no-mask 指的是没有掩码的 TemporalOT 变体, no-context 指的是没有上下文成本矩阵的 TemporalOT 变体。我们可以




图 5：关键参数的影响。中等数量的上下文长度 k_c 或掩码长度 k_m 表现最佳。智能体在更多专家演示下表现更好。




图 6：基于像素输入的结果。TemporalOT 在基于像素输入的情况下同样有效。

观察到移除这两个组件中的任何一个都会导致性能下降。此外，更重要的组件因任务而异。例如，时间掩码在开门任务中更为重要，而上下文代价矩阵在推杆任务中更为重要。

4.5 不同关键参数的消融研究

随后，我们验证了不同关键参数的有效性，即上下文嵌入的上下文长度 k_c 、时间掩码的窗口大小 k_m 以及演示数量 N_E 。从图 5 中可以观察到，中等数量的 k_c 和 k_m 表现最佳，而较大的 N_E 能提升性能。较大的上下文长度 k_c 表现不佳，因为它会分散当前步骤的最优传输奖励注意力并引入额外的奖励噪声。较小的掩码窗口大小 k_m 使学习更加困难，因为它只能接收来自邻近观测的信息，而较大的 k_c 会逐渐退化为朴素的最优传输奖励。此外，拥有更多的专家演示有助于缓解潜在的过拟合问题并提升最终性能。

4.6 基于像素观测的结果

我们还评估了所提方法在基于像素观测下的表现，其中我们遵循与 ADS 基线相同的 DrQv2 模型设置。图 6 展示了 TemporalOT 与 ADS 的比较结果。我们可以观察到与表 1 类似的结论，即我们提出的 TemporalOT 方法在基于像素输入的情况下也优于 ADS 基线，其中 TemporalOT 通常比 ADS 收敛更快，并且（或）达到更高的最终成功率。此外，我们观察到有时基于像素的智能体比其基于稠密状态的对应方法学习得更快，这表明智能体能够从像素输入中提取更有效的表示。

4.7 不良案例的可视化

在本小节中，我们可视化了一些基于最优传输（OT）的强化学习智能体的失败案例，以便读者更深入地了解基于最优传输的强化学习智能体在何种情况下效果较差。图 7 展示了在插手任务中，最优传输/自适应演示采样/时序最优传输智能体的一个典型失败案例。第一行是专家轨迹，第二行是智能体轨迹。插手任务的目标是将棕色方块移动到孔中的目标位置。我们可以观察到，强化学习智能体主要专注于模仿手臂行为，最终到达目标位置，但忽略了棕色方块。造成这一失败案例的主要原因是棕色盒子的颜色与桌面背景非常接近，有时




图 7：失败案例分析。与专家轨迹（上）相比，智能体专注于模仿手臂行为（下），遗漏了抓取方块等细节。

这使得预训练的视觉编码器难以捕捉到细微信息。更多失败案例分析见附录 A.2。

5 相关工作

少量演示下的学习。利用演示进行策略学习已有大量工作，从基本的行为克隆（Behavior Cloning）[12, 45] 到演示辅助的强化学习（RL）[43]。此外，还有利用演示数据进行离线预训练的工作 [60, 36, 61]，用于热启动策略 [36] 或辅助探索 [61, 37, 22]。然而，高质量预训练通常需要大量演示。本文关注仅提供少量演示的设置 [5]，从而大大减轻了生成演示的负担。基于最优传输的模仿是这一方向上新近出现的方法，将在后续章节中回顾。

基于最优传输的模仿与强化学习奖励。最优传输（Optimal Transport, OT）已被证明对模仿学习有效 [18, 31]。最优传输奖励标注（Optimal Transport Reward Labeling, OTR）[31] 使用辛克霍恩距离（Sinkhorn distance）[4] 来计算轨迹相对于专家演示的相似性度量，并将该度量用作无奖励离线强化学习数据集的奖励 [31]。自动折扣调度（Automatic Discount Scheduling, ADS）[30] 采用类似的基于最优传输的方法进行奖励计算。自动折扣调度的核心思想是在线强化学习中引入折扣因子的调度，以减轻来自时间上较远状态的最优传输奖励可能带来的干扰。本文工作与该类别中的先前工作保持一致，并解决了先前方法共有的一些常见问题。

6 局限性

由于本文工作与模仿学习密切相关，本文方法具有模仿学习的一些常见局限性。例如，本文方法的成功在很大程度上依赖于高质量的专家视频演示。如果面对一个没有任何可用专家演示的新任务，本文方法的作用将较小。此外，如果给定的演示是次优的或有偏的，学习到的策略也会继承这些缺陷。此外，所提方法的性能依赖于预训练视觉编码器的质量。如果预训练视觉编码器未能捕获像素观测中的某些关键信息，本文方法也将无法考虑这些关键细节。本文工作的另一个局限性是所提方法的计算成本与给定专家视频演示的数量相关。当计算最优传输计划时，专家演示数量越多，计算成本越高。

7 结论

本文研究利用专家视频演示学习有效机器人策略的问题。我们关注一个具有挑战性的场景：仅有两次演示可用，且环境不提供任何任务奖励。遵循基于最优传输的代理奖励研究路线，我们首先讨论了现有方法因忽视时间信息而面临的一些挑战。进一步地，我们提出了一种名为时间最优传输的新方法，该方法通过使用基于上下文嵌入的代价矩阵和掩码机制，将时间信息融入现有基线。在九个元世界基准任务上的实验展示了所提方法的有效性。一个有趣的未来方向是将当前方法扩展到相机视角不变的智能体，从而能够针对不同相机视角的专家视频演示学习策略。

参考文献

- [1] M. Arjovsky, S. Chintala, and L. Bottou. Wasserstein generative adversarial networks. In *International Conference on Machine Learning*, 2017.
- [2] Y. Burda, H. Edwards, A. Storkey, and O. Klimov. Exploration by random network distillation. In *International Conference on Learning Representations*, 2019.
- [3] S. Cohen, B. Amos, M. P. Deisenroth, M. Henaff, E. Vinitzky, and D. Yarats. Imitation learning from pixel observations for continuous control. 2021.
- [4] M. Cuturi. Sinkhorn distances: Lightspeed computation of optimal transport. In *Advances in Neural Information Processing Systems*, 2013.
- [5] C. R. Dance, J. Perez, and T. Cachet. Demonstration-conditioned reinforcement learning for few-shot imitation. In *International Conference on Machine Learning*, 2021.
- [6] P. Dayan and B. W. Balleine. Reward, motivation, and reinforcement learning. *Neuron*, 36(2):285–298, 2002.
- [7] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei. Imagenet: A large-scale hierarchical image database. In *IEEE Conference on Computer Vision and Pattern Recognition*, 2009.
- [8] R. Devidze, G. Radanovic, P. Kamalaruban, and A. Singla. Explicable reward design for reinforcement learning agents. In *Advances in Neural Information Processing Systems*, 2021.
- [9] P. D’Oro, M. Schwarzer, E. Nikishin, P.-L. Bacon, M. G. Bellemare, and A. Courville. Sample-efficient reinforcement learning by breaking the replay ratio barrier. In *International Conference on Learning Representations*, 2023.
- [10] G. Dulac-Arnold, N. Levine, D. J. Mankowitz, J. Li, C. Paduraru, S. Gowal, and T. Hester. Challenges of real-world reinforcement learning: definitions, benchmarks and analysis. *Machine Learning*, 110(9):2419–2468, 2021.
- [11] J. Eschmann. Reward function design in reinforcement learning. *Reinforcement learning algorithms: Analysis and Applications*, pages 25–33, 2021.
- [12] P. Florence, C. Lynch, A. Zeng, O. A. Ramirez, A. Wahid, L. Downs, A. Wong, J. Lee, I. Mordatch, and J. Tompson. Implicit behavioral cloning. In *Annual Conference on Robot Learning*, 2022.
- [13] Y. Fu, H. Zhang, D. Wu, W. Xu, and B. Boulet. FuRL: Visual-language models as fuzzy rewards for reinforcement learning. In *International Conference on Machine Learning*, 2024.
- [14] A. Galichon. *Optimal transport methods in economics*. Princeton University Press, 2018.
- [15] W. Gangbo, W. Li, S. Osher, and M. Puthawala. Unnormalized optimal transport. *Journal of Computational Physics*, 399:108940, 2019.
- [16] X. Gu, Y. Yang, W. Zeng, J. Sun, and Z. Xu. Keypoint-guided optimal transport with applications in heterogeneous domain adaptation. In *Advances in Neural Information Processing Systems*, 2022.
- [17] D. Hadfield-Menell, S. J. Russell, P. Abbeel, and A. Dragan. Cooperative inverse reinforcement learning. In *Advances in Neural Information Processing Systems*, 2016.
- [18] S. Haldar, V. Mathur, D. Yarats, and L. Pinto. Watch and match: Supercharging imitation with regularized optimal transport. In *Annual Conference on Robot Learning*, 2022.
- [19] M. Hausknecht and P. Stone. Deep recurrent q-learning for partially observable MDPs. In *2015 AAAI fall symposium series*, 2015.
- [20] K. He, X. Zhang, S. Ren, and J. Sun. Deep residual learning for image recognition. In *IEEE Conference on Computer Vision and Pattern Recognition*, 2016.
- [21] S. He, Y. Jiang, H. Zhang, J. Shao, and X. Ji. Wasserstein unsupervised reinforcement learning. In *AAAI Conference on Artificial Intelligence*, 2022.
- [22] T. Hester, M. Vecerík, O. Pietquin, M. Lanctot, T. Schaul, B. Piot, A. Sendonaris, G. Dulac-Arnold, I. Osband, J. P. Agapiou, J. Z. Leibo, and A. Gruslys. Deep q-learning from demonstrations. *CoRR*, abs/1704.03732, 2017.
- [23] J. Ho and S. Ermon. Generative adversarial imitation learning. In *Advances in neural information processing systems*, 2016.

- [24] A. Hussein, M. M. Gaber, E. Elyan, and C. Jayne. Imitation learning: A survey of learning methods. *ACM Computing Surveys (CSUR)*, 50(2):1–35, 2017.
- [25] R. T. Icarte, T. Q. Klassen, R. Valenzano, and S. A. McIlraith. Reward machines: Exploiting reward function structure in reinforcement learning. *Journal of Artificial Intelligence Research*, 73:173–208, 2022.
- [26] S. Kapturowski, V. Campos, R. Jiang, N. Rakicevic, H. van Hasselt, C. Blundell, and A. P. Badia. Human-level Atari 200x faster. In *International Conference on Learning Representations*, 2023.
- [27] B. Kim, A.-m. Farahmand, J. Pineau, and D. Precup. Learning from limited demonstrations. In *Advances in Neural Information Processing Systems*, 2013.
- [28] A. Li, B. Boots, and C.-A. Cheng. Mahalo: Unifying offline reinforcement learning and imitation learning from observations. In *International Conference on Machine Learning*, 2023.
- [29] J. Liu, L. He, Y. Kang, Z. Zhuang, D. Wang, and H. Xu. Ceil: Generalized contextual imitation learning. In *Advances in Neural Information Processing Systems*, 2024.
- [30] Y. Liu, W. Dong, Y. Hu, C. Wen, Z.-H. Yin, C. Zhang, and Y. Gao. Imitation learning from observation with automatic discount scheduling. In *International Conference on Learning Representations*, 2024.
- [31] Y. Luo, Z. Jiang, S. Cohen, E. Grefenstette, and M. P. Deisenroth. Optimal transport for offline imitation learning. *arXiv preprint arXiv:2303.13971*, 2023.
- [32] Y. J. Ma, W. Liang, V. Som, V. Kumar, A. Zhang, O. Bastani, and D. Jayaraman. LIV: Language-image representations and rewards for robotic control. In *International Conference on Machine Learning*, 2023.
- [33] Y. J. Ma, S. Sodhani, D. Jayaraman, O. Bastani, V. Kumar, and A. Zhang. VIP: Towards universal visual reward and representation via value-implicit pre-training. In *International Conference on Learning Representations*, 2023.
- [34] S. Marcel and Y. Rodriguez. Torchvision the machine-vision package of torch. In *ACM international conference on Multimedia*, 2010.
- [35] V. Micheli, E. Alonso, and F. Fleuret. Transformers are sample-efficient world models. In *International Conference on Learning Representations*, 2023.
- [36] A. Nair, M. Dalal, A. Gupta, and S. Levine. {AWAC}: Accelerating online reinforcement learning with offline datasets. *CoRR*, abs/2006.09359, 2020.
- [37] A. Nair, B. McGrew, M. Andrychowicz, W. Zaremba, and P. Abbeel. Overcoming exploration in reinforcement learning with demonstrations. *CoRR*, abs/1709.10089, 2017.
- [38] S. Nair, A. Rajeswaran, V. Kumar, C. Finn, and A. Gupta. R3M: A universal visual representation for robot manipulation. In *Conference on Robot Learning*, 2023.
- [39] A. Y. Ng, S. Russell, et al. Algorithms for inverse reinforcement learning. In *International Conference on Machine Learning*, 2000.
- [40] L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray, et al. Training language models to follow instructions with human feedback. In *Advances in Neural Information Processing Systems*, 2022.
- [41] A. Paszke, S. Gross, S. Chintala, G. Chanan, E. Yang, Z. DeVito, Z. Lin, A. Desmaison, L. Antiga, and A. Lerer. Automatic differentiation in pytorch. 2017.
- [42] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimelshein, L. Antiga, et al. PyTorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems*, 2019.
- [43] K. Pertsch, Y. Lee, Y. Wu, and J. J. Lim. Demonstration-guided reinforcement learning with learned skills. In *Annual Conference on Robot Learning*, 2021.
- [44] G. Peyré, M. Cuturi, et al. Computational optimal transport: With applications to data science. *Foundations and Trends® in Machine Learning*, 11(5-6):355–607, 2019.
- [45] D. A. Pomerleau. ALVINN: An autonomous land vehicle in a neural network. In *Advances in Neural Information Processing Systems*, 1988.
- [46] M. L. Puterman. *Markov decision processes: discrete stochastic dynamic programming*. John Wiley & Sons, 2014.

- [47] Y. Seo, L. Chen, J. Shin, H. Lee, P. Abbeel, and K. Lee. State entropy maximization with random encoders for efficient exploration. In *International Conference on Machine Learning*, 2021.
- [48] A. Singh, L. Yang, K. Hartikainen, C. Finn, and S. Levine. End-to-end robotic reinforcement learning without reward engineering. *arXiv preprint arXiv:1904.07854*, 2019.
- [49] L. Smith, I. Kostrikov, and S. Levine. A walk in the park: Learning to walk in 20 minutes with model-free reinforcement learning. *arXiv preprint arXiv:2208.07860*, 2022.
- [50] S. Sontakke, J. Zhang, S. Arnold, K. Pertsch, E. Bıyık, D. Sadigh, C. Finn, and L. Itti. Roboclip: One demonstration is enough to learn robot policies. In *Advances in Neural Information Processing Systems*, 2024.
- [51] R. S. Sutton and A. G. Barto. *Reinforcement learning: An introduction*. MIT press, 2018.
- [52] D. Tiapkin, D. Belomestny, D. Calandriello, E. Moulines, R. Munos, A. Naumov, P. Perrault, Y. Tang, M. Valko, and P. Menard. Fast rates for maximum entropy exploration. *arXiv preprint arXiv:2303.08059*, 2023.
- [53] F. Torabi, G. Warnell, and P. Stone. Generative adversarial imitation from observation. *arXiv preprint arXiv:1807.06158*, 2018.
- [54] L. C. Torres, L. M. Pereira, and M. H. Amini. A survey on optimal transport for machine learning: Theory and applications. *arXiv preprint arXiv:2106.01963*, 2021.
- [55] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, 2017.
- [56] D. Yarats, R. Fergus, A. Lazaric, and L. Pinto. Mastering visual continuous control: Improved data-augmented reinforcement learning. *arXiv preprint arXiv:2107.09645*, 2021.
- [57] T. Yu, D. Quillen, Z. He, R. Julian, K. Hausman, C. Finn, and S. Levine. Meta-world: A benchmark and evaluation for multi-task and meta reinforcement learning. In *Conference on robot learning*, 2020.
- [58] Y. Yu. Towards sample efficient reinforcement learning. In *International Joint Conference on Artificial Intelligence*, 2018.
- [59] Z. Yu and X. Zhang. Actor-critic alignment for offline-to-online reinforcement learning. In *International Conference on Machine Learning*, 2023.
- [60] H. Zhang, W. Xu, and H. Yu. Policy expansion for bridging offline-to-online reinforcement learning. In *International Conference on Learning Representations*, 2023.
- [61] B. Zhou, K. Li, J. Jiang, and Z. Lu. Learning from visual observation via offline pretrained state-to-go transformer. In *Advances in Neural Information Processing Systems*, 2023.
- [62] Z. Zhu, K. Lin, B. Dai, and J. Zhou. Self-adaptive imitation learning: Learning tasks with delayed rewards from sub-optimal demonstrations. In *AAAI Conference on Artificial Intelligence*, 2022.

附录

A 附加实验结果

A.1 评估曲线

图 8 展示了与表 1 结果对应的评估曲线。我们可以观察到，时间最优传输总体上优于其他不使用任务奖励的基线方法。




图 8: 元世界基准任务上的评估曲线。

A.2 不良案例分析

在本小节中，我们分析了不同任务中的更多失败案例。与图 7 类似，我们可视化了不同任务中一些典型失败案例的专家轨迹（顶部）和智能体轨迹（底部）。我们可以观察到，机械臂通常表现出与专家轨迹中演示的相似行为。智能体未能解决这些任务的原因是——（A）在开门任务中未能抓住把手；（B）在开锁任务中未能触碰旋钮；（C）在推物任务中未能拾取红色方块；（D）在推棍任务中未能拾起蓝色棍子。

A.3 使用专家数据进行预训练

在本小节中，我们验证了使用模仿学习（Imitation Learning），即行为克隆（Behavior Cloning, BC），先初始化机器人策略，然后用 TemporalOT 进行微调的有效性。在本实验中，我们使用包含动作的专家演示，以行为克隆损失对机器人策略进行预训练。表 2 展示了开门任务上的结果。BC 基线是一种纯离线方法，其参数在预训练后固定不变。TemporalOT-P 是使用 TemporalOT 对预训练的 BC 策略进行微调的变体。我们可以观察到，引入预训练有助于提高样本效率。此外，我们注意到在从离线训练过渡到在线训练的初始阶段（从第 0 步到第 $4e4$ 步），成功率有小幅下降（随后恢复）。这是一种初始下降




图 9: 更多失败案例的可视化: (A) 开门任务, (B) 开锁任务, (C) 推物任务和 (D) 推棍任务。

现象, 在之前的离线强化学习文献中也有报道, 并且可以通过设计更具体的离线到在线强化学习方法来改善 [59, 60]。

A.4 不同速度专家演示的消融研究

我们的工作继承了从演示中学习文献中的一个隐含假设, 即智能体与专家智能体具有相似的运动速度。在此假设下, 我们使用时间步索引之间的距离来表示时间掩码中的时间亲和信息。如果专家与智能体运动速度之间的差异很大, 那么该假设将被打破。

表 2: 使用包含动作的演示进行预训练是有帮助的。

	0	2e4	4e4	6e4	8e4	1e5	5e5	1e6
BC	10.8	-	-	-	-	-	-	-
TemporalOT	0	2.0	0	0	5.0	16.6	57.8	78.4
TemporalOT-P	10.8	6.8	25.0	42.8	48.6	55.4	70.8	82.0

表 3: 不同速度演示下成功率的实验结果。

	1x	2x	3x	4x
Basketball	94.4 (4.7)	91.8 (8.9)	77.2 (8.4)	43.8 (29.5)
Button-press	89.0 (3.8)	72.4 (3.0)	65.6 (5.4)	57.8 (7.4)
Door-open	78.4 (12.4)	76.2 (10.4)	49.4 (20.3)	20.4 (9.2)

为验证这种差异如何影响模型性能，我们使用不同速度的专家演示进行实验。通过每隔 N 步对原始专家轨迹进行采样，生成 N 倍速的专家演示。表 3 展示了使用不同速度专家演示的结果。可以观察到，随着专家与智能体移动速度差异的增大，最终成功率下降。在篮球任务和开门任务中使用双倍速演示，性能略逊于原始演示。然而，使用三倍速或四倍速的专家演示表现相当差。这是因为更快的专家轨迹对应更短的演示帧序列，重要信息更可能被丢弃。

A.5 不同视觉编码器的消融研究

本小节比较 TemporalOT 中使用不同视觉编码器的有效性。具体而言，我们使用 torchvision[34] 中的检查点，比较了三种不同的 ResNet 变体（ResNet18、ResNet50、ResNet152）。从图 10（左）可以观察到，ResNet50 和 ResNet152 编码器表现出相似的最终性能。其中，ResNet18 表现不如其他两个编码器，因为它相当弱，有时无法捕捉图像的关键信息。图 10（左）的结果表明，一个合理良好的视觉编码器通常足以提取有效的视觉嵌入，用于在强化学习中计算 OT 奖励。

A.6 不同掩码设计的消融研究

本小节尝试 TemporalOT 的一种变体，在计算 OT 奖励时使用动态掩码。与公式 (9) 中掩码位置 $M(i, j)$ 始终遵循固定规则 $j \in [i - k_m, i + k_m]$ 不同，我们引入以下动态对应形式，

$$M(i, j) = \begin{cases} 1, & \text{if } j \in [c - k_m, c + k_m], \\ 0, & \text{otherwise,} \end{cases} \quad (10)$$

其中掩码窗口中心为 $c = \arg \min_j \hat{C}(i, j)$ 和 $j \in [0, i]$ 。公式 (10) 表示我们在专家轨迹中选择一个索引 j ，该索引相对于当前观测 o_i 具有最低的传输代价。此外，我们添加了一个约束 $j \in [0, i]$ ，以避免如第 3.2.3 节所述查看过于遥远的未来步骤。图 10（右）的实验结果表明，公式 (10) 中基于学习的时序掩码略优于我们之前公式 (9) 中基于规则的时序掩码。由于本工作的主要焦点是使用简单易懂的设计来说明在强化学习中将时序信息纳入最优传输奖励的好处，我们将更复杂的动态时序掩码的研究留待未来工作。

B 实验设置

B.1 评估环境

在实验中，我们专注于元世界基准任务 [57]。图 11 展示了我们在实验中使用的九个选定环境。在每个环境中，机械臂旨在




图 10: 更多消融研究。(左) 不同视觉编码器的比较。(右) 使用动态时序掩码略微提升了性能。

解决特定任务。我们使用 ADS 论文 [30] 中相同的任务长度参数。篮球任务和拉杆任务的任务长度为 175 步，其他任务的任务长度为 125 步。九个选定任务的目标如下：

- 篮球任务：机械臂旨在抓取橙色篮球并移动到篮筐上方的目标位置。
- 按钮按压任务：机械臂旨在按下红色按钮。
- 门锁任务：机械臂旨在将旋钮旋转至目标角度。
- 开门任务：机械臂旨在将门打开至目标位置。
- 手插入任务：机械臂旨在将棕色块移动至孔中的目标位置。
- 拉杆任务：机械臂旨在将拉杆移动至目标高度。
- 推动任务：机械臂旨在将红色圆柱体移动至桌面上的目标位置。
- 棍推任务：机械臂旨在抓取蓝色棍子并将瓶子推至目标位置。
- 开窗任务：机械臂旨在将窗户打开至目标位置。

B.2 实现细节

我们的代码基于 ADS 在 PyTorch 中的官方实现 [41]。我们还使用了 ADS 代码库中提供的 Metaworld 环境 [57]。对于固定的预训练视觉编码器，我们使用在 ImageNet 数据集 [7] 上训练的 Resnet50[20] 网络。特别地，我们采用了 Torchvision[34] 提供的官方 Resnet50 检查点。对于其他主要软件，我们使用以下包版本：

1. Python 3.9.19
2. numpy 1.26.4
3. torch 2.2.2
4. torchvision 0.17.2
5. pot 0.9.3
6. dm-control 1.0.17
7. dm_env 1.6
8. mujoco-py 2.1.2.14
9. cython 3.0.0a10
10. gym 0.22.0

TemporalOT 的伪代码总结在算法 1 中。

B.3 参数设置

在实验中，我们主要遵循 ADS 基线的参数设置。一些关键参数总结在表 4 中。




图 11: 实验中九个评估任务的可视化。

Algorithm 1 Temporal Optimal Transport Reward (TemporalOT)

Input: a fixed pretrained visual encoder f , N_E expert video demonstrations, temporal mask window size k_m , context embedding length k_c , trajectory length T , total trajectory number N , experience replay buffer $\mathcal{D}$.

Output: trained RL agent $\pi(a|s)$.

for $i = 1$ **to** N **do**

 Unroll policy $\pi(a|s)$ to collect a trajectory $\tau = \{o_1, \dots, o_T\}$.

 Compute visual embeddings using of the trajectory $\{f(o_1), \dots, f(o_T)\}$.

for $j = 1$ **to** N_E **do**

 Compute the context cost matrix $\hat{C}$ as in Eqn.(6) for the j -th expert demonstration.

 Compute the masked OT reward $R_\tau^j = \{r_0^j, \dots, r_T^j\}$ with Eqn.(9).

end for

 Select the expert demonstration with the largest trajectory OT reward sum as the final OT reward $r_\tau^{OT} = \{r_0^{OT}, \dots, r_T^{OT}\}$.

 Save the labeled transition $(o_i, a_i, r_i^{OT}, o_{i+1})$ to the replay buffer.

 Update the RL agent with sampled transitions as in Eqn.(1).

end for

B.4 计算资源

我们在配备 NVIDIA GeForce RTX 3090 图形处理器 (GPU) 和第十二代英特尔酷睿 i9-12900KF 中央处理器 (CPU) 的工作站上开展实验。TemporalOT 在基于状态的实验和基于像素的实验中的平均实际运行时间分别为 1 小时和 3 小时。

表 4: 超参数汇总。

Parameter	Value
Total environment step	1e6
Adam learning rate	1e-4
Batch size	512
Target network τ	0.005
Discount factor γ	0.9
Expert demo number N_E	2
Context length k_c	3
Mask window size k_m	10
DrQ buffer size	1.5e5
DrQ action repeat	2
DrQ frame stack	3
DrQ image size	(84, 84, 3)
DrQ embedding dimension	50
DrQ CNN features	(32, 32, 32, 32)
DrQ CNN kernels	(3, 3, 3, 3)
DrQ CNN strides	(2, 1, 1, 1)
DrQ CNN padding	VALID
DrQ actor network	(1024, 1024, 1024)
DrQ critic network	(1024, 1024, 1024)

C 掩码最优传输目标的求解

本节给出公式 (7) 中掩码最优传输目标的求解过程。

$$\mu^* = \arg \min_{\mu} \langle M \odot \mu, C \rangle_F - \epsilon \mathcal{H}(M \odot \mu), \text{ s.t. } \mu \mathbf{1} = \mu^T \mathbf{1} = \mathbf{s},$$

为计算最优传输计划 μ^* ，首先写出其拉格朗日函数如下：

$$L(\mu, \alpha, \beta) = \langle M \odot \mu, C \rangle_F + \epsilon \left(\langle M \odot \mu, \log(M \odot \mu) \rangle_F - \mathbf{1}^T (M \odot \mu) \mathbf{1} \right) - \langle \alpha, (M \odot \mu) \mathbf{1} - \mathbf{s} \rangle_F - \langle \beta, (M \odot \mu)^T \mathbf{1} - \mathbf{s} \rangle_F.$$

令拉格朗日函数的偏导数为零：

$$\frac{\partial L}{\partial \mu_{i,j}} = M_{i,j} C_{i,j} + \epsilon M_{i,j} \log(M_{i,j} \mu_{i,j}) - M_{i,j} \alpha_i - M_{i,j} \beta_j = 0.$$

若 $M_{i,j} = 1$ ，则有： $\log(\mu_{i,j}) = \frac{\alpha_i}{\epsilon}$ 可将其表示为矩阵形式：

$$+ \frac{\beta_j}{\epsilon} - \frac{C_{i,j}}{\epsilon}.$$

$$M \odot \mu = \text{diag}(\mathbf{u}) K \text{diag}(\mathbf{v}),$$

其中 $\mathbf{u} = e^{\alpha/\epsilon}$, $K = M \odot e^{-C/\epsilon}$ ，且 $\mathbf{v} = e^{\beta/\epsilon}$ 。约束条件可表示为：

$$\text{diag}(\mathbf{u}) K \text{diag}(\mathbf{v}) \mathbf{1} = (\text{diag}(\mathbf{u}) K \text{diag}(\mathbf{v}))^T \mathbf{1} = \mathbf{s}.$$

随后可利用辛克霍恩算法 (Sinkhorn Algorithm) [4] 迭代计算 $\mathbf{u}$ 与 $\mathbf{v}$ ：

$$\begin{aligned} \mathbf{u}^{(l+1)} &= \frac{\mathbf{s}}{K \mathbf{v}^{(l)}}, \\ \mathbf{v}^{(l+1)} &= \frac{\mathbf{s}}{K^T \mathbf{u}^{(l+1)}}. \end{aligned}$$

D 更广泛的社会影响

本文研究基于最优传输 (Optimal Transport) 的代理奖励在少量专家视频演示下学习有效机器人策略的应用。由于现实场景中通常缺乏可用的任务奖励，

本文方法有望推动现实世界强化学习（Reinforcement Learning）应用的发展。另一方面，所提方法旨在学习与给定演示行为相似的策略。一旦给定的专家演示包含危险行为，本文方法也可能学习到这些危险行为，从而带来负面社会影响。为缓解此类潜在负面社会影响，可引入额外的安全奖励以防止智能体学习危险行为。