

伴随采样：通过伴随匹配实现高度可扩展的扩散采样器

Aaron Havens^{2,†,*}, Benjamin Kurt Miller^{1,*}, Bing Yan^{1,3,*}, Carles Domingo-Enrich⁴, Anuroop Sriram¹, Brandon Wood¹, Daniel Levine¹, Bin Hu², Brandon Amos¹, Brian Karrer¹, Xiang Fu^{1,*}, Guan-Hong Liu^{1,*}, Ricky T. Q. Chen^{1,*}

¹FAIR at Meta, ²University of Illinois, ³New York University, ⁴Microsoft Research New England

*Core contributors, [†]Work done during internship at FAIR

本文提出伴随采样（Adjoint Sampling），一种高度可扩展且高效的算法，用于学习从非归一化密度或能量函数中采样的扩散过程。这是首个在线策略方法，允许梯度更新次数显著多于能量评估和模型采样次数，使我们能够扩展到比类似方法此前探索的更大问题规模。我们的框架在理论上基于随机最优控制，并具有与伴随匹配（Adjoint Matching）相同的理论保证，无需采取将样本推向目标分布的校正措施即可进行训练。我们展示了如何结合关键对称性以及周期性边界条件，在笛卡尔坐标和扭转坐标下对分子进行建模。我们通过在经典能量函数上的大量实验证明了方法的有效性，并进一步扩展到基于神经网络的能量模型，在多个分子系统上执行摊销构象生成。为鼓励进一步研究高度可扩展的采样方法，我们计划开源这些具有挑战性的基准，成功的方法可直接推动计算化学的进展。

Code & benchmark: https://github.com/facebookresearch/adjoint_sampling

Models: https://huggingface.co/facebook/adjoint_sampling



1 引言

从复杂的高维分布中采样是计算科学中许多重要问题的基础，其应用涵盖分子建模、贝叶斯推断和生成建模。我们特别关注仅能访问非归一化能量函数 E 的目标分布采样，该函数定义了玻尔兹曼分布

$$\mu(x) = \frac{\exp\left(-\frac{1}{\tau}E(x)\right)}{Z}, \quad (1)$$

where $Z = \int_{\mathbb{R}^d} \exp\left(-\frac{1}{\tau}E(x)\right) dx < \infty$ 是未知的归一化常数。玻尔兹曼分布描述了许多物理系统的平衡态，其中 $E(x)$ 表示构型 x 的能量， $\tau > 0$ 是温度参数。从这类分布中高效采样仍然具有挑战性，尤其是对于具有复杂能量景观的高维系统。此外，许多能量函数的计算代价极其高昂，例如需要物理仿真。

传统方法，如马尔可夫链蒙特卡洛（Markov Chain Monte Carlo, MCMC）和序贯蒙特卡洛（Sequential Monte Carlo, SMC），利用精心设计的马尔可夫链（Neal, 2001; Neal et al., 2011; Del Moral et al., 2006），能够提供渐近无偏的样本，但往往存在混合速度慢、对高维设置可扩展性差的问题。这需要设计更好的转移密度和更智能的建议分布。近期工作尝试通过归一化流（Chen et al., 2018; Rezende and Mohamed, 2015）学习建议分布（Albergo et al., 2019; Arbel et al., 2021; Gabríel et al., 2022）来增强采样，以解决这一问题。

人们可能自然地将目光投向近期涌现的基于扩散和流的生成模型（Song and Ermon, 2019; Ho et al., 2020; Lipman et al., 2023; Albergo et al., 2023）。然而，直接套用这些数据驱动的生成建模框架需要获取真实数据。




图 1 从不受控的扩散过程 p_1^{base} （最左侧面板）开始，伴随采样（Adjoint Sampling）利用当前受控随机微分方程的互逆投影 $(X_t, X_1) \sim p_{t|1}^{\text{base}} p_1^u$ 来近似联合轨迹分布 p_t^u ，从而允许在每个评估样本和能量梯度 $(X_1, \nabla g(X_1))$ 上对 RAM 目标执行若干梯度步骤。经过多次迭代后，伴随采样收敛到目标玻尔兹曼分布 μ （最右侧面板）。

这些数据驱动的生成建模框架需要访问真实数据。这一局限性在分子仿真和基于物理的推断等应用中尤为显著，因为在这些应用中通常无法直接获取目标分布的样本。因此，先前的尝试往往需要借助序贯蒙特卡洛或重要性采样进行增强（Phillips 等，2024；De Bortoli 等，2024；Akhound-Sadegh 等，2024），这使得这些方法在能量函数评估方面效率极低。

采样与扩散过程之间的联系由 Tzen 和 Raginsky（2019b）通过使用随机最优控制（SOC）和薛定谔桥问题（Pavon, 1989; Dai Pra, 1991; Föllmer, 2005; Chen et al., 2016）的经典结果建立。利用这一表述，Zhang 和 Chen（2022）表明，通过直接参数化受控过程的漂移，可以在给定未归一化密度的情况下解决采样任务的 SOC 问题。这一概念被 Berner 等人（2023）以及 Richter 和 Berner（2024）进一步推广；然而，所有这些方法都需要在每次梯度更新时对扩散过程进行昂贵的仿真。此外，它们每次梯度更新至少需要一次——有时是多次——能量评估。

为了克服这些挑战，我们引入了伴随采样（Adjoint Sampling），这是一种基于扩散过程随机控制的新颖且极其高效的变分推断框架，我们将其应用于比以往方法大得多的规模。我们的方法建立在伴随匹配（Adjoint Matching）（Domingo-Enrich 等人，2024）之上，这是一种最近开发的用于解决一般随机控制问题的方法，我们对其进行了专门化和改进，以高效地学习采样。

我们的贡献如下：

- **效率：**我们的方法是第一个允许每次模型采样和能量评估进行更多梯度更新的在线策略方法。这对于扩展到困难的摊销设置极为重要。
- **理论依据：**我们的方法基于随机控制，遵循伴随匹配（Domingo-Enrich 等人，2024）的近期工作。我们通过提出一个新的目标函数来改进伴随匹配，该目标函数隐式地将模型投影到一组最优控制上。我们的理论保证不需要重要性采样或序贯蒙特卡洛等纠正措施。
- **结构：**图和欧几里得对称性可以很容易地纳入。我们还采用该方法处理周期性边界条件，以建模分子系统的扭转角表示。
- **新基准：**我们引入了摊销分子采样基准，这些基准挑战新方法在大规模上的适用性。在这些基准上取得成功直接推动化学领域的进展。

2 预备知识

在本节中，我们简要介绍一类随机过程上的优化问题，该问题在最优解处于固定时间 $t = 1$ 从 μ 采样。这种样本生成的控制视角由 Tzen 和 Raginsky (2019b) 观察到，类似公式见 Zhang 和 Chen (2022); Berner 等人 (2023)。关于用于采样的随机控制的更深入介绍见附录 A.1。

2.1 优化用于采样的扩散过程

考虑随机微分方程 (SDE)

$$dX_t = \sigma(t)u(X_t, t) dt + \sigma(t) dB_t, \quad X_0 = 0, \quad (2)$$

其中 $\sigma : [0, 1] \rightarrow \mathbb{R}$ 是标量噪声函数， $u : \mathbb{R}^d \times [0, 1] \rightarrow \mathbb{R}^d$ 是可学习的控制， $(B_t)_t$ is a d 维布朗运动。在

σ 和 u 的温和条件下，该受控过程 (2) 唯一地定义了所有 $t \in \mathbb{R}$ 的时间边缘分布 $p_t^u(X_t)$ ，我们寻求一个漂移 u 使得 $p_1^u(X_1) = \mu(X_1)$ 。我们记 $\mathbf{X} = \{X_t : 0 \leq t \leq 1\}$ 为一条样本轨迹， $p^u(\mathbf{X})$ 和 $p^{\text{base}}(\mathbf{X})$ 分别为由受控过程 (2) 和基础过程 $dX_t = \sigma(t) dB_t$ (即在 (2) 中设置 $u \equiv 0$) 生成的轨迹 1 上的分布。将狄拉克分布传输到目标密度 μ (在时间 $t = 1$) 的漂移并不唯一；然而，我们可以选择一条特定的目标路径密度，它是狄拉克分布与目标分布之间的薛定谔桥 (Pavon, 1989; Chen 等人, 2016)，由下式给出

$$p^*(\mathbf{X}) = p^{\text{base}}(\mathbf{X} | X_1) \mu(X_1), \quad (3)$$

其中 $p^{\text{base}}(\mathbf{X} | X_1)$ 是基过程在到达 X_1 条件下的后验分布。该薛定谔桥在所有于 $t = 1$ 处与 μ 重合的过程中，是与基过程在 KL 散度意义上偏离最小的过程。值得注意的是，相对于控制 u 的轨迹到 p^* 的路径 KL 散度可以通过分解 $p^*(\mathbf{X}) = p^{\text{base}}(\mathbf{X}) \frac{\mu(X_1)}{p_1^{\text{base}}(X_1)}$ 并应用吉尔萨诺夫定理 (Protter and Protter, 2005) 来解析表达。

$$\mathcal{L}_{\text{SOC}}(u) = D_{\text{KL}}(p^u(\mathbf{X}) \| p^*(\mathbf{X})) = D_{\text{KL}}(p^u(\mathbf{X}) \| p^{\text{base}}(\mathbf{X})) + \mathbb{E}_{p^u} \log \left(\frac{p_1^{\text{base}}(X_1)}{\mu(X_1)} \right) \quad (4)$$

$$= \mathbb{E}_{p^u} \left[\int_0^1 \frac{1}{2} \|u(X_t, t)\|^2 dt + \log \left(\frac{p_1^{\text{base}}(X_1)}{\mu(X_1)} \right) \right]. \quad (5)$$

为此，本文提出最小化目标函数 (5)，直观上，该目标最小化将粒子输运至 μ 所需的控制能量。事实上，该准则恰好对应于一个具有终端代价函数 $\log \frac{p_1^{\text{base}}(x)}{\mu(x)}$ 的最小能量随机最优控制问题。该特定随机最优控制问题在文献中已被深入研究，并存在唯一最优解 u^* ，满足 (Kappen, 2005; Tzen and Raginsky, 2019a) (详见附录 A.1)。

$$D_{\text{KL}}(p^{u^*}(\mathbf{X}) \| p^*(\mathbf{X})) = -\log \mathbb{E}_{p^{\text{base}}} \left[\frac{\mu(X_1)}{p_1^{\text{base}}(X_1)} \right] = 0. \quad (6)$$

因此， p^* 确实可以通过 u^* 实现，我们的问题便归结为尽可能高效地优化随机最优控制目标 (5)。这正是本文所提出的伴随采样方法所要解决的问题。

3 伴随采样

既然我们已经将采样问题等价为随机最优控制问题的解，接下来将提出一种高效的方法来求解如下形式的随机最优控制问题

$$\min_u \mathbb{E}_{\mathbf{X} \sim p^u} \left[\int_0^1 \frac{1}{2} \|u(X_t, t)\|^2 dt + g(X_1) \right] \quad (7a)$$

$$\text{s.t. } dX_t = \sigma(t)u(X_t, t) dt + \sigma(t) dB_t, \quad X_0 = 0 \quad (7b)$$

1 形式上，随机过程的路径测度及其 KL 散度由 Radon-Nikodym 导数定义，例如 $\frac{d p^u}{d p^{\text{base}}}(\mathbf{X}) = \exp(\int_0^1 \frac{1}{2} \|u_t\|^2 dt + \int_0^1 u_t \cdot dB_t)$ ，其中 $\mathbf{X} \sim \mathbb{P}^u$ 。

我们将利用该方法学习一个随机过程，该过程仅根据未归一化的能量函数 (1) 从目标分布中采样，其中

$$g(x) = \log p_1^{\text{base}}(x) + \frac{1}{\tau} E(x), \quad (8)$$

即 (5) 式去掉归一化常数后的形式，因为该常数不影响最优解。朴素的做法是模拟随机微分方程 (7b)，然后对目标 (7a) 进行微分，这通常被称为伴随方法 (Bryson and Ho, 1969)，也是先前工作的首选方法 (Chen et al., 2018; Zhang and Chen, 2022)。然而，这种方法非常缓慢，因为每次迭代需要两次模拟：一次用于状态 X_t ，另一次用于通过随机微分方程进行反向传播。

3.1 伴随匹配

伴随匹配 (Adjoint Matching, Domingo-Enrich 等人, 2024) 是一种旨在解决更一般随机最优控制问题族的算法，能够利用具有任意漂移的基础过程 $dX_t = b(X_t, t) dt + \sigma(t) dB_t$ 。与使用基于梯度的方法并对目标 (7a) 进行微分的标准伴随方法 (Bryson 和 Ho, 1969) 不同，伴随匹配将问题转化为移动回归形式。具体而言，它求解不动点 u ，使得 $u(x, t) = -\sigma(t) \nabla J(u; x, t)$ ，其中 J 为值函数。我们在附录 A 中详细讨论伴随匹配。对于我们的目标，伴随匹配损失为

$$\mathcal{L}_{\text{AM}}(u) := \mathbb{E}_{p^{\bar{u}}} \left[\frac{1}{2} \int_0^1 \|u(X_t, t) + \sigma(t)^\top \tilde{a}(t; \mathbf{X})\|^2 dt \right], \quad \mathbf{X} \sim p^{\bar{u}}, \quad \bar{u} = \text{stopgrad}(u), \quad (9)$$

$$\text{s.t.} \quad \frac{d}{dt} \tilde{a}(t; \mathbf{X}) = -\tilde{a}(t; \mathbf{X})^\top \nabla b(X_t, t), \quad \tilde{a}(1; \mathbf{X}) = \nabla g(X_1). \quad (10)$$

其中 $\tilde{a}$ 被称为精简伴随状态， $\bar{u} = \text{stopgrad}(u)$ 表示对 u 的停止梯度操作，即尽管 $\mathbf{X} \sim p^{\bar{u}}$ 是根据受控过程采样的。

我们的第一个关键观察是，原始的伴随匹配算法在我们的采样公式 (7) 情形下可以显著简化。特别地，如果我们设 $b \equiv 0$ ，则精简伴随状态方程 $\frac{d}{dt} \tilde{a}(t; \mathbf{X}) = 0$ ， $\tilde{a}(1; \mathbf{X}) = \nabla g(X_1)$ 对所有 $t \in [0, 1]$ 存在唯一解析解 $\tilde{a}(t; \mathbf{X}) = \nabla g(X_1)$ 。这导致回归损失大幅简化，无需额外仿真精简伴随状态。

$$\mathcal{L}_{\text{AM}}(u) = \mathbb{E}_{\mathbf{X} \sim p^{\bar{u}}} \left[\int_0^1 \frac{1}{2} \|u(X_t, t) + \sigma(t) \nabla g(X_1)\|^2 dt \right] \quad (11)$$

粗略地说，伴随匹配提供了一种简单的解释：对于每个中间状态 X_t ，只需将控制回归到终端代价的负梯度 $-\nabla g(X_1)$ 上，针对所有可能从 X_t 到达的 X_1 。由于这是一个移动目标，在优化过程中，它将缓慢地将过程移向终端代价较小的区域 g 。

3.2 互易伴随匹配

伴随匹配在每次迭代中仍需要两个计算开销大的操作：(i) 受控过程的仿真和 (ii) 终端代价的评估。随机微分方程的仿真是一个缓慢的迭代过程，终端代价也可能代价高昂。例如，在我们的公式中，终端代价涉及能量模型 E ，在许多实际场景中该模型的计算开销极大。理想情况下，这两个操作都不应频繁执行。在本节中，我们提出对伴随匹配算法的修改，使其高度可扩展，从而消除这两个要求。

首先，注意到训练损失仅依赖于采样 $(X_t, X_1) \sim p_{t,1}^u$ ，而非完整轨迹。因此，(11) 等价于从随机过程 p^u 定义的联合分布中采样对 (X_t, X_1) ：

$$\mathcal{L}_{\text{AM}}(u) = \int_0^1 \mathbb{E}_{(X_t, X_1) \sim p_{t,1}^u} \left[\frac{1}{2} \|u(X_t, t) + \sigma(t) \nabla g(X_1)\|^2 \right] dt. \quad (12)$$

这尚未带来任何效率提升，因为采样 $(X_t, X_1) \sim p^u$ 的唯一途径是通过模拟受控过程。我们的核心洞见在于利用以下知识：在最优解 u^* 处，由于 (3)，我们有 $p_{t|1}^{u^*}(X_t, X_1) = p_{t|1}^{\text{base}}(X_t|X_1)\mu(X_1)$ 。尽管当前控制 u 未必满足这一性质，我们可以将路径测度——即互反投影，我们将在第 3.3 节中正式定义——投影到由 $p_{t|1}^{\text{base}}(X_t|X_1)p_1^u(X_1)$ 给出的、生成 p_1^u 的薛定谔桥上。基于此，我们提出互反伴随匹配 (Reciprocal Adjoint Matching, RAM) 目标：

$$\mathcal{L}_{\text{RAM}}(u) = \int_0^1 \lambda(t) \mathbb{E}_{X_t \sim p_{t|1}^{\text{base}}, X_1 \sim p_1^u} \left[\frac{1}{2} \|u(X_t, t) + \sigma(t) \nabla g(X_1)\|^2 \right] dt. \quad (13)$$

也就是说，我们根据受控过程采样 X_1 ，然后利用由基础过程定义的后验分布在给定 X_1 的条件下采样 X_t 。由于基础过程是一个零漂移的随机微分方程（等价于 (2) 式中 $u \equiv 0$ 的情形），条件分布 $p_{t|1}^{\text{base}}(X_t|X_1)$ 具有闭式表达，易于采样。这同时具有跨时间解相关的效果，因为对于不同的 t 值， X_t 样本在给定 X_1 的条件下是条件独立的，而在 (12) 式中， X_t 是从同一条轨迹中采样的。此外，我们应用了 $\lambda(t) = 1/\sigma(t)^2$ 的时间缩放，这不影响最优解，但能提升数值稳定性。

我们注意到，(13) 式与 PDDS (Phillips 等人, 2024) 和 TSM (De Bortoli 等人, 2024) 中出现的训练目标相关，其中相同的公式出现在期望内部；然而，期望的不同带来了显著差异。具体而言，PDDS 和 TSM 对最优控制取期望，而我们对当前控制取期望。也就是说，它们需要从目标分布中采样，而这是不可行的。与 PDDS 和 TSM 这种具有固定回归目标的简单回归形式不同，我们的形式具有移动的回归目标，旨在求解一个不动点（见附录 A）。

我们可以通过固定回归目标并延迟其更新来进一步提高计算效率（我们将在第 3.3 节中从理论上证明其合理性）。为了设计一个高效的算法，我们进一步将 $p(X_1)$ 与学习 u 的回归问题解耦，延迟对 $p(X_1)$ 的更新，并执行多次迭代来训练 u 。实际上，这导致了以下交替算法，我们称之为伴随采样：1. 使用当前控制 u_i ，构建一个缓冲区 $\mathcal{B} = (X^{(i)})$

$$\nabla g^{(i)} = \nabla g(X_1^{(i)}). \quad \nabla g^{(i)} \text{ 包含样本 } \{X_1^{(i)}\} \stackrel{iid}{\sim} p_1^u(X_1) \text{ 及}$$

2. 利用样本 $\{X_1^{(i)}\}$ 优化 (13) 式，得到更新后的控制 u_{i+1} 。1. $\{\nabla g^{(i)}\} \sim \mathcal{B}$. 我们在下一节从理论上证明，这种交替方案隐式地执行了向更优控制的投影，有助于降低随机最优控制目标。注意，由于前向基础过程具有解析形式，上述第 2 步中的优化极为廉价。 p_1^{base} 与后验分布 $p_{t|1}^{\text{base}}$ 均可设计为闭式高斯分布，详见附录 B。这意味着无需模拟受控过程或评估能量模型，即可执行大量梯度更新。算法 1 给出了详细的伪代码。

3.3 伴随采样理论

在本节中，我们为所提出的算法 1 提供理论依据。首先，定义控制 u 在 p_1^u 为目标分布时的二阶锥 (SOC) 解上的投影 $\mathcal{P}$ ：

$$\mathcal{P}(u) = \arg \min_v D_{\text{KL}}(p^v(\mathbf{X}) \| p^{\text{base}}(\mathbf{X}|X_1)p_1^u(X_1)). \quad (14)$$

这是对共享相同终端分布 $p_1^u(X_1)$ 的薛定谔桥 (Schrödinger bridge) 的投影步骤。与现有文献相联系，这可以理解 Shi 等人 (2023) 的互反投影与马尔可夫投影的结合。就最小化目标而言，所得控制过程始终与原始控制同样有效，甚至更优。本文在以下命题中对此进行形式化：

命题 3.1. 在投影 (14) 之后，互逆伴随匹配等价于伴随匹配，

$$\mathcal{L}_{\text{RAM}}(\mathcal{P}(u)) = \mathcal{L}_{\text{AM}}(\mathcal{P}(u)), \quad (15)$$

Algorithm 1 Adjoint Sampling

```
1: Input: Terminal Cost:  $g = \log p^{\text{base}} + \frac{1}{\tau}E$ , base process:  $p_t^{\text{base}}$  given by  $dX_t = \sigma(t)dB_t$ , outer-loop batch size:  $n$ , inner-loop batch size  $m$ , SDE drift network:  $u_\theta$ , Replay buffer  $\mathcal{B}$ .
2:  $\mathcal{B} \leftarrow \emptyset$ 
3: while Outer-Loop do
4:   # Euler-Maruyama with no gradient
5:    $\{X_1^{(i)}\}_{i=1}^n \sim p_1^{\bar{u}}$ ,  $\bar{u} = \text{stopgrad}(u_\theta)$ 
6:   # gradient of energy is evaluated once per sample
7:    $\nabla g^{(i)} \leftarrow \nabla g(X_1^{(i)})$ 
8:    $\mathcal{B} \leftarrow \mathcal{B} \cup \{(X_1^{(i)}, \nabla g^{(i)})\}_{i=1}^n$ 
9:   while Inner-Loop do
10:     $\{(X_1^{(j)}, \nabla g^{(j)})\}_{j=1}^m \sim \mathcal{U}(\mathcal{B})$ 
11:     $t^{(j)} \sim \mathcal{U}([0, 1])$ ,  $X_t^{(j)} \sim p_{t^{(j)}|1}^{\text{base}}(x|X_1^{(j)})$ 
12:     $\mathcal{L}_{\text{RAM}}^{(j)} \leftarrow \frac{\lambda(t)}{2} \|u_\theta(X_t^{(j)}, t^{(j)}) + \sigma(t)\nabla g^{(j)}\|^2$ 
13:     $\theta \leftarrow \text{optimizer\_step}(\theta, \nabla_\theta \frac{1}{m} \sum_j \mathcal{L}_{\text{RAM}}^{(j)})$ 
14:   end while
15: end while
16: Output: SDE sampler drift  $u_\theta$ .
```

此外，该投影改进了 SOC 目标函数，

$$J(u) \geq J(\mathcal{P}(u)), \quad \text{其中 } J(u) := \mathbb{E}_{\mathbf{X} \sim p^u} \left[\int_0^1 \frac{1}{2} \|u(X_t, t)\|^2 dt + g(X_1) \right]. \quad (16)$$

我们将证明推迟到附录 C.1。命题 3.1 的结果提示，如果我们在每次迭代中显式执行该投影（14），那么我们实际上是在以更优的控制执行伴随匹配迭代。然而，执行投影需要额外的计算步骤，例如使用桥匹配（Bridge Matching）等算法（Shi 等，2023），这是我们希望避免的。幸运的是，仅使用 RAM 损失就足够了，并且会隐式地包含这一精确投影。

我们的主要理论结果是观察到交替方案——其中 X_1 样本的分布固定（步骤 1），并通过完全收敛 RAM 损失来更新控制（步骤 2）——在针对 SOC 目标（5）执行伴随匹配的同时，隐式地执行了投影（14）。这一对应关系在以下定理中非正式地陈述。

定理 3.2（伴随采样的理论保证（非正式））。从任意控制

u_i ,

开始，执行步骤 1 和步骤 2 以获得 u_{i+1} 等价地满足

$$u_{i+1} = \mathcal{P}(u_i) - \frac{\delta \mathcal{L}_{AM}}{\delta u}(\mathcal{P}(u_i)), \quad (17)$$

—其中 $\frac{\delta \mathcal{L}}{\delta u}$ 表示关于控制 u 的泛函导数。此外，不动点 $u = \mathcal{P}(u)$ 和 $u = u - \frac{\delta \mathcal{L}_{AM}}{\delta u}(u)$ 是 (7) 的最优控制 u^* 。

更精确的陈述和证明见附录 C.1。这一结果为本文提出的算法（算法 1）提供了理论依据。在实践中，我们略有不同：使用包含多个先前步骤样本的重放缓冲区，并且不将步骤 2 执行至收敛。我们发现这有助于平滑优化并提高计算效率。

3.4 几何扩展

对称性对于高效地从定义物理系统的基于能量的模型中采样至关重要。分子在原子置换、旋转、平移和宇称（反射）方面具有对称性。我们通过在受控过程模型中强制对称性来降低维度并提高数据效率。

我们的模型要么由 $E(n)$ 等变图神经网络 (EGNN) (Satorras 等, 2021) 参数化, 要么由张量场网络 (Thomas 等, 2018) 参数化, 并在 e3nn (Geiger 等, 2022; Jing 等, 2022) 中实现, 这些网络在尊重对称性约束的同时融合图特征 (Kondor 等, 2018; Weiler 等, 2018; Miller 等, 2020; Geiger 和 Smidt, 2022)。我们实验了两种受控过程: 一种使用 EGNN 采样原子位置, 另一种使用 e3nn 采样扭转角。详见附录 F。

3.4.1 图条件 $SE(3)$ 不变采样

考虑图 $\mathcal{G}(\mathcal{V}, \mathcal{E})$ 。每个节点 $v_i \in \mathcal{V}$ 和边 $e_{ij} \in \mathcal{E}$ 具有与数据拓扑结构相关的特征属性 (例如原子类型和键序), 包括空间坐标 $x_i \in \mathbb{R}^d$ 。我们可以将等变漂移 u_θ 条件化在图特征上, 使其对由群 $g \in G := \text{Aut}(\mathcal{G}) \times SO(d)$ 通过 $g \cdot x = (P \otimes R)x$ (i.e. $u_\theta(g \cdot X_t, t; \mathcal{G}) = g \cdot u_\theta(X_t, t; \mathcal{G})$) 作用给出的空间对称性等变。这里 $P \in \text{Aut}(\mathcal{G})$ 是图自同构——表示为置换矩阵, 在保持图结构的同时重新排序图节点——而 $R \in SO(d)$ 是一个 d 维旋转矩阵。

平移不变性 为了强制平移不变性, 系统被限制在零质心子空间 $\mathcal{X}^{\text{CoM}} = \{x \mid \sum_{i=1}^k x^i = 0\} \subset \mathbb{R}^{kd}$ 。这通过使用投影算子将粒子位置 $y \in \mathbb{R}^{kd}$ 投影到零质心子空间来实现:

$$x = \mathcal{A}y, \quad \mathcal{A} = \left(I_k - \frac{1}{k} \mathbf{1}_k \mathbf{1}_k^\top \right) \otimes I_d, \quad (18)$$

其中 I_k 是单位矩阵, $\mathbf{1}_k$ 是全 1 向量。由此我们可以定义一个零质心过程。

$$dX_t = \sigma(t) \mathcal{A} u_\theta(X_t, t; \mathcal{G}) dt + \sigma(t) \mathcal{A} dB_t, \quad X_0 = 0$$

现在 p^{base} 是一个奇异高斯 $p_t^{\text{base}}(x) = \mathcal{N}(x; 0, \nu_t \mathcal{A} \mathcal{A}^\top)$, 可以通过先采样各向同性高斯 $\mathcal{N}(x; 0, \nu_t)$, 然后通过 $\mathcal{A}$ 投影来采样。我们有 $p_t^{\text{base}}(x) \propto \mathcal{N}(x; 0, \nu_t)$ 对所有 $x \in \mathcal{X}^{\text{CoM}}$ 成立, 且后验 $p_{t|1}^{\text{base}}$ 也投影到 $\mathcal{X}^{\text{CoM}}$ 上。

几何伴随采样 通过确保漂移是 G -等变的且零质心, 我们确保模型分布对所有 $t \in [0, 1]$ 是 G -不变的 (Köhler 等, 2020; Xu 等, 2022)。综合起来, 我们的 RAM 损失 (13) 可以修改以支持所提出的对称性。

$$\mathcal{L}_{\text{GeoRAM}}(\theta) = \int_0^1 \lambda(t) \mathbb{E}_{p_{t|1}^{\text{base}} p_1^{\text{base}}} \left[\frac{1}{2} \|\mathcal{A}(u_\theta(X_t, t; \mathcal{G}) + \sigma(t) \nabla g(X_1))\|^2 \right] dt \quad (19)$$

假设能量 E 和 p_1^{base} 是 G -不变的, 则我们学习漂移的目标 $-\sigma(t) \mathcal{A} \nabla g(X_1)$ 将是 G -等变的且零质心。

3.4.2 周期性边界条件 在许多情况下, 我们可能希望对具有周期性边界条件的状态空间进行建模。具体来说, 我们考虑一个状态空间, 它是 n 维中的平坦环面, 记为 $\mathbb{T}^n = \mathbb{R}^n / \mathbb{Z}^n$ 。它是一个商空间, 由将所有 $i \in [n]$ 的点 $x = (x^1, \dots, x^i, \dots, x^n)$ 与 $(x^1, \dots, x^i + 1, \dots, x^n)$ 等同而得到。 $\mathbb{R}^n$ (5) 中 SOC 目标的推导可以直接扩展到该商空间以及一般黎曼流形 (De Bortoli 等, 2022; Thornton 等, 2022; Huang 等, 2022)。我们用 $\bar{p}^{\text{base}}$ 表示对基础过程建模的 SDE 的分布, 即 (2) 中 $u_t = 0$, 它位于 $\mathbb{T}^n$ 上。RAM 目标 (13) 需要计算 $\nabla \log \bar{p}_1^{\text{base}}(\cdot)$ 作为终端代价的一部分, 并从 $\bar{p}_{t|1}^{\text{base}}(\cdot | X_1)$ 中采样 X_t 。在 $\mathbb{T}^n$ 中模拟基础过程会产生一个因子化的包裹高斯分布,

$$\bar{p}_t^{\text{base}}(x) = \prod_{i=1}^n \sum_{k=-\infty}^{\infty} p_t^{\text{base}}(x^i + k), \quad (20)$$

其中 $\bar{p}^{\text{base}}$ 是 $\mathbb{R}$ 中基础过程的分布。实际上, 通过截断 (20) 中的求和, 我们可以轻松地以高数值精度计算该分布。此外, 我们可以从后向

表 1 合成能量函数实验的结果。我们报告了基于 Klein 等人 (2024b) 的几何 $\mathcal{W}_2$ 度量以及相对于真实 MCMC 样本的一维能量直方图 $E(\cdot)\mathcal{W}_2$ 度量（可视化见附录 H.1）。在适用的情况下，我们还报告了路径测度有效样本量。更多细节见附录 E.4。† 报告的数值为每个样本（即除以批大小），并依据 LJ-55 实验超参数。

Method	DW-4 ($d = 8$)			LJ-13 ($d = 39$)				LJ-55 ($d = 165$)				# $E(\cdot)$ evals	# $u_\theta(\cdot)$ evals
	path-ESS $\uparrow$	$\mathcal{W}_2 \downarrow$	$E(\cdot)\mathcal{W}_2 \downarrow$	path-ESS $\uparrow$	$\mathcal{W}_2 \downarrow$	$E(\cdot)\mathcal{W}_2 \downarrow$		path-ESS $\uparrow$	$\mathcal{W}_2 \downarrow$	$E(\cdot)\mathcal{W}_2 \downarrow$		per gradient update†	per gradient update†
PIS (Zhang and Chen, 2022)	0.462 ± 0.081	0.68 ± 0.23	0.65 ± 0.25	0.012 ± 0.011	1.93 ± 0.07	18.02 ± 1.12		0.001 ± 0.000	4.79 ± 0.45	228.70 ± 131.27		1	1000
DDS (Vargas et al., 2023)	0.461 ± 0.076	0.92 ± 0.11	0.90 ± 0.37	0.010 ± 0.011	1.99 ± 0.13	24.61 ± 8.99		0.001 ± 0.000	4.60 ± 0.09	173.09 ± 18.01		1	1000
LogVariance (Richter and Berner, 2023)	0.025 ± 0.042	1.04 ± 0.29	1.89 ± 0.89	—	—	—		—	—	—		1	1000
iDEM (Akhoond-Sadeh et al., 2024)	—	0.70 ± 0.06	0.55 ± 0.14	—	1.61 ± 0.01	30.78 ± 24.46		—	4.69 ± 1.52	93.53 ± 16.31		512	3
iDEM w/ 1 MC sample	—	1.21 ± 0.02	2.70 ± 0.18	—	2.03 ± 0.02	22.41 ± 0.18		—	5.79 ± 1.60	1e32 $\pm 1e32$		1	3
Adjoint Sampling w/o RP (Ablation)	0.448 ± 0.110	0.63 ± 0.11	1.03 ± 0.23	0.159 ± 0.068	1.68 ± 0.01	2.91 ± 1.39		0.094 ± 0.025	4.50 ± 0.10	94.48 ± 76.12		0.002	3
Adjoint Sampling (Ours)	0.627 ± 0.037	0.62 ± 0.06	0.55 ± 0.12	0.220 ± 0.041	1.67 ± 0.01	2.40 ± 1.25		0.066 ± 0.037	4.50 ± 0.05	58.04 ± 20.98		0.002	3

独立地为每个维度 $i \in [n]$ 转移分布：

$$k^i \sim p(k^i), \quad p(k^i) \propto p_1^{\text{base}}(X_1^i + k^i), \quad X_t^i = Y_t^i \bmod 1.0, \quad Y_t^i \sim p_{t|1}^{\text{base}}(Y_t^i | X_1^i + k^i). \quad (21)$$

实际上，我们仅考虑 k 在某个截断集合 $\{-k_{\text{trunc}}, \dots, k_{\text{trunc}}\}$ 内的取值，其中 k_{trunc} 足够大以覆盖 $p_1^{\text{base}}(X_1^i + k)$ 实际上非零的区域。推导细节见附录 B.2。

4 相关工作

学习增强的 MCMC 马尔可夫链蒙特卡洛 (MCMC) 和序贯蒙特卡洛 (SMC) 方法一直是使用设计良好的马尔可夫链从复杂分布中采样的标准方法。由于混合时间过长且在高维下扩展性差，现有工作已将 MCMC 和 SMC 技术与深度学习相结合。Albergo 等人 (2019)、Arbel 等人 (2021) 和 Gabrié 等人 (2022) 通过归一化流 (Chen 等人, 2018) 利用变分推断学习更好的 MCMC 提议分布。Matthews 等人 (2022) 提出使用随机归一化流 (Wu 等人, 2020) 学习提议分布以改进 SMC。Albergo 和 Vanden-Eijnden (2024) 以及 Holderrieth 等人 (2025) 从 MCMC 过程出发，通过最小化柯尔莫哥洛夫方程来优化可学习组件。

依赖马尔可夫链蒙特卡洛的扩散采样器 许多工作学习扩散过程，但依赖辅助采样机制来获得正确的训练信号。近期进展利用基于分数的扩散模型 (Song 和 Ermon, 2019; Ho 等, 2020) 在非归一化采样任务中提升样本效率和可扩展性。Phillips 等 (2024) 和 De Bortoli 等 (2024) 展示了简单回归目标 (如分数匹配) 的有效性，而 Akhoond-Sadeh 等 (2024) 提出迭代去噪能量匹配 (iDEM)，这是一种离线但有偏的算法，从回放缓冲区学习分数，从而克服了仿真的可扩展性问题。Phillips 等 (2024) 和 De Bortoli 等 (2024) 使用与本文相似的损失，但依赖从目标分布采样，利用序贯蒙特卡洛 (SMC) 获得训练样本。总体而言，这些方法要么需要通过辅助采样算法 (如马尔可夫链蒙特卡洛) 获得真实样本，要么依赖重要性加权估计或重采样，所有这些都需要对能量函数进行大量评估，且尚不清楚这些方法是否优于简单的数据驱动学习算法 (附录 D)。

基于随机最优控制的扩散采样器 相比之下，基于随机最优控制 (SOC) 的采样器将采样任务重新表述为优化问题。Zhang 和 Chen (2022) 以及 Vargas 等 (2023) 展示了直接优化受控过程以匹配期望目标分布。该框架已被以多种方式推广 (Berner 等, 2023; Richter 和 Berner, 2024; Vargas 等, 2024; Chen 等, 2024a)。然而，所有这些方法都受限于其计算需求，包括采样过程中计算代价高昂的微分、构建训练目标时高阶导数的计算，或重要性采样的需要 (即多次能量评估)。伴随采样通过能够在每个生成样本和能量评估中进行显著更多的梯度更新来克服这些挑战。




图 2 伴随采样在摊销分子构象生成中的迭代过程。简化分子线性输入规范（SMILES）字符串将随机微分方程（SDE）条件化于特定分子图 $\mathcal{G}^{(i)}$ ，其中最终状态、能量梯度及条件信息 $(\nabla g^{(i)}, X_1^{(i)}, \mathcal{G}^{(i)})$ 被存储至重放缓冲区。模型通过使用样本缓冲区最小化 RAM 损失进行训练，逐步将样本转化为真实的分子构象。

离策略方法 离策略方法（Malkin 等，2023；Richter 和 Berner，2023；Akhound-Sadegh 等，2024；Hua 等，2024）是指无需使用当前模型样本的方法。因此，离策略方法本质上不利用能量函数的梯度，因为它们不对模型样本进行微分。为缓解这一问题，通常使用能量函数的梯度对模型进行参数化，且已发现性能强烈依赖于这一技巧（He 等，2025）。由于本文所关注的是计算代价高昂的能量函数，这种参数化方式不再可行。此外，离策略并不意味着更高效。许多离策略方法仍需要完整轨迹来评估其损失，仅当时间边缘分布被额外学习（Bengio 等，2023；Lahlou 等，2023；Zhang 等，2024）或预先指定（Albergo 和 Vanden-Eijnden，2024；Chen 等，2024a；Holderrieth 等，2025）时，才能使用子轨迹。相比之下，伴随采样是一种在策略训练方法，显式利用能量函数的梯度，但显著受益于仅需 (X_t, X_1) 对，能够使用重放缓冲区和互反投影以显著降低的计算成本进行训练。

分子构象生成模型 据我们所知，尚无基于深度学习的采样方法能够在不依赖数据的情况下，直接从能量函数大规模生成分子构象。玻尔兹曼生成器利用重要性采样，借助能量信息提升性能，但需要离线分子动力学数据来学习初始模型（Noé 等人，2019）。通过退火重要性采样方法，玻尔兹曼生成器已能在无数据条件下采样小型单粒子系统，但其结果不可摊销，且需要大量能量评估（Midgley 等人，2024）。若干基于流的生成模型工作通过在真实数据上训练，学习生成构象和玻尔兹曼分布（Köhler 等人，2020；Jing 等人，2022；Xu 等人，2022；Hassan 等人，2024；Köhler 等人，2023；Klein 等人，2024a；Diez 等人，2024）。这些工作并非仅从现有能量模型学习。

5 实验

本文现在在多个多粒子系统的能量函数上评估伴随采样方法。我们在合成能量基准上与先前工作（Zhang 和 Chen，2022；Akhound-Sadegh 等人，2024）进行比较，这些基准的能量函数具有解析形式且评估成本极低。随后，本文提出一个具有挑战性的分子构象生成基准，在该基准中训练摊销模型，为大规模有机分子数据集采样构象。对于此任务，本文采用 eSEN 能量模型（Fu 等人，2025）。

互反投影消融 本文对伴随采样进行消融实验，其中不使用互反投影（RP）来采样 X_t 给定 X_1 ，而是简单地将样本对 (X_1, X_t) 存储在缓冲区中

并在伴随匹配目标 (12) 上进行训练。本文将此方法称为无互反投影的伴随采样，有助于证明互反投影的有效性。构象生成的消融结果见附录 H.4 表 5。

5.1 合成能量函数

先前工作提出并基准测试了若干 n 粒子体系的合成能量函数 (Köhler 等人, 2020; Midgley 等人, 2023; Klein 等人, 2024b; Akhound-Sadegh 等人, 2024)。本文考虑三种能量函数：二维四粒子双阱势 (DW-4)、三维十三粒子伦纳德-琼斯势 (LJ-13) 以及五十五粒子伦纳德-琼斯能量 (LJ-55)。详见附录 E。

基线 除了伴随采样消融实验外，我们与最新最先进的采样器 iDEM (Akhound-Sadegh 等人, 2024) 进行比较，该采样器声称是首个成功扩展到 LJ-55 的学习型采样器。我们还与 PIS (Zhang 和 Chen, 2022) 和 DDS (Vargas 等人, 2023) 进行比较，它们是在其 SOC / 反向 KL 公式中与伴随采样最具可比性的方法。最后，为了完整性，我们提出了 PIS 损失的一个离线变体，称为 LogVariance (Richter 和 Berner, 2023)，它实际上是无梯度的。所有方法在所有实验设置中都使用 EGNN (Satorras 等人, 2021) 架构，其中 PIS 和 DDS 使用更少的层数，使得通过 SDE 的反向传播可行。

表 2 大规模摊销构象生成的召回率和精确率指标。覆盖率针对 $1.25\text{\AA}$ 的阈值。标准差在测试集中的分子上计算。按可旋转键数量划分的结果见图 12。

Method	SPICE				GEOM-DRUGS				
	Recall		Precision		Recall		Precision		
	Cov. $\uparrow$	AMR $\downarrow$	Cov. $\uparrow$	AMR $\downarrow$	Cov. $\uparrow$	AMR $\downarrow$	Cov. $\uparrow$	AMR $\downarrow$	
RDKit ETKDG	72.74 $\pm$ 33.18	1.04 $\pm$ 0.52	69.68 $\pm$ 37.11	1.14 $\pm$ 0.64	63.51 $\pm$ 34.74	1.15 $\pm$ 0.61	69.77 $\pm$ 38.23	1.09 $\pm$ 0.66	
Torsional AdjSampling	85.06 $\pm$ 24.61	0.86 $\pm$ 0.30	70.42 $\pm$ 34.54	1.06 $\pm$ 0.54	72.91 $\pm$ 31.17	0.98 $\pm$ 0.40	67.85 $\pm$ 36.01	1.09 $\pm$ 0.55	
Cartesian AdjSampling	82.22 $\pm$ 25.72	0.96 $\pm$ 0.26	49.13 $\pm$ 33.01	1.26 $\pm$ 0.38	60.93 $\pm$ 35.15	1.20 $\pm$ 0.43	28.44 $\pm$ 27.77	1.86 $\pm$ 0.64	
Cartesian AdjSampling (+pretrain)	89.42 $\pm$ 17.48	0.84 $\pm$ 0.24	65.93 $\pm$ 29.53	1.12 $\pm$ 0.34	72.98 $\pm$ 30.82	1.02 $\pm$ 0.34	45.14 $\pm$ 31.46	1.47 $\pm$ 0.52	
w/ relaxation	RDKit ETKDG	81.61 $\pm$ 27.58	0.79 $\pm$ 0.44	74.51 $\pm$ 35.07	0.97 $\pm$ 0.64	71.72 $\pm$ 29.73	0.93 $\pm$ 0.53	75.37 $\pm$ 32.76	0.89 $\pm$ 0.60
	Torsional AdjSampling	88.25 $\pm$ 21.17	0.72 $\pm$ 0.33	74.66 $\pm$ 32.96	0.94 $\pm$ 0.59	76.62 $\pm$ 27.73	0.87 $\pm$ 0.40	71.85 $\pm$ 32.34	0.97 $\pm$ 0.54
	Cartesian AdjSampling	94.10 $\pm$ 15.67	0.68 $\pm$ 0.28	62.80 $\pm$ 29.63	1.02 $\pm$ 0.37	79.08 $\pm$ 29.44	0.89 $\pm$ 0.45	47.88 $\pm$ 30.92	1.40 $\pm$ 0.61
	Cartesian AdjSampling (+pretrain)	96.65 $\pm$ 7.51	0.60 $\pm$ 0.23	77.20 $\pm$ 25.76	0.92 $\pm$ 0.35	87.01 $\pm$ 22.79	0.76 $\pm$ 0.34	61.96 $\pm$ 31.55	1.10 $\pm$ 0.46




图 3 该图描绘了来自训练好的伴随采样模型的两条采样轨迹，这些模型使用笛卡尔或扭转表示。它们针对保留的 SMILES 字符串 COCSc1sc2cccc2[n+1][O-] 的构象。左帧 X_0 来自初始狄拉克分布，右帧 X_1 是一个采样构象。

评估 在表 1 中，我们报告了我们的指标，包括 $\mathcal{W}_2$ ：几何 2-Wasserstein 距离（通过首先优化模型生成样本与真实 MCMC 数据之间的刚性变换来考虑对称性 (Klein 等人, 2024b)）和 $E(\cdot)\mathcal{W}_2$ ：生成样本产生的能量值分布与真实值之间的一维 $\mathcal{W}_2$ 距离，以及路径有效样本量 (ESS)：大致




图 4 伴随采样变体和 RDKit 的召回覆盖率与 RMSD 阈值的关系。我们展示了有和没有松弛的性能。

衡量相对于每个算法目标 SDE 过程的信息性样本轨迹的比例。由于 iDEM 不是基于反向 KL 目标构建的，路径 ESS 指标没有意义，因此被省略。更多细节请参见附录 E.4。为了展示伴随采样的能量样本效率，我们报告了每次梯度更新所需的能量函数评估次数。

结果 从表 1 中可以清楚地看到，伴随采样在粒子 $\mathcal{W}_2$ 距离方面与 iDEM 相当，然而 iDEM 难以保持在低能量区域，这从 LJ-13 和 LJ-55 实验（在附录 H.1 中可视化能量直方图）中更大的 $E(\cdot)\mathcal{W}_2$ 可以看出。此外，由于 iDEM 依赖于对真实得分函数的蒙特卡洛（MC）估计，每次梯度更新使用的能量评估次数比伴随采样多 $\mathcal{O}(100,000)$ 。这使得将 iDEM 扩展到更复杂的能量函数变得不可行。为了测试更高效的 iDEM 版本，我们还使用单个 MC 样本来估计其目标函数来运行 iDEM，但结果表明其整体度量不稳定，这很可能是由于其有偏的 MC 得分目标估计器所致。关于基于 SOC 的方法，PIS 和 DDS 难以在 LJ13 之外表现良好，而离线方法 LogVariance 无法扩展到 DW-4 之外。这些结果表明，伴随采样是处理大型复杂能量模型的首选方法。

5.2 从能量函数中采样构象

我们提供了一个新的基准，以鼓励研究高度可扩展的采样方法，这些方法能够从分子能量模型中找到构象。这些构象是分子势能面上的局部极小值，即固定的分子拓扑结构具有一组由围绕其键的旋转的局部稳定构型决定的构象。根据分子的柔性，一个分子可以有一个或多个不同的构象。

基于量子力学能量函数（如密度泛函理论）采样构象

（DFT）是一项重要但具有挑战性的任务。由于 DFT 计算的高成本，我们使用了一个在 SPICE-MACE-OFF 数据集（Eastman 等人，2023；Kovács 等人，2023）上预训练的能量模型，称为 eSEN（Fu 等人，2025）。它在预测 DFT 能量方面表现出非常高的准确率。eSEN 是一个可迁移的消息传递神经网络模型，可以预测包含 {H, C, N, O, F, P, S, Cl, Br, I} 元素的分子的给定分子构象的能量。它使用稀疏图表示来特征化分子，在节点特征中编码化学元素，在边特征中编码笛卡尔位移。SPICE-MACE-OFF 数据集全面采样了高能量和低能量区域的能量面，使 eSEN 能够普遍适用于小分子的许多构象。

利用伴随采样框架，我们可以通过以分子的连接图为条件，采样特定分子的原子坐标。这些原子坐标即为提议构象。图条件方法具有吸引力，因为它支持摊销，即学习一个适用于由任意有机元素和键组合而成的分子的采样器。我们设计了两种方法：1. 笛卡尔伴随采样（附录 E.1）：以元素（节点）和键类型（边）为条件，采样每个原子的全部三维笛卡尔坐标。

2. 扭转伴随采样 (附录 F.2) : 以元素、键长和键角 (三元组) 为条件, 仅采样分子中的扭转角。

此外, 我们评估了在 RDKit 样本上使用桥匹配 (Shi 等人, 2023) 的预训练步骤, 该步骤有助于初始探索低能量区域 (详见附录 D)。在我们的实验中, 我们通过玻尔兹曼常数和低温来缩放 eSEN 能量。在笛卡尔伴随采样中, 我们引入了额外的能量项来正则化键长, 确保我们根据连接性针对正确的分子。这些项在扭转伴随采样中不出现; 它们是不必要的, 因为扭转随机微分方程在设计上不会破坏键。

数据集 我们考虑两个分子结构数据集: SPICE (Eastman 等人, 2023) 和 GEOM-DRUGS (Axelrod 和 Gomez-Bombarelli, 2022)。SPICE 枚举了超过 23,000 种多样的类药物分子及其性质; 它被设计用于机器学习。我们所有的模型都在 SPICE 上训练; 然而, 我们仅利用 SMILES 字符串来提取分子拓扑。这是可能的, 因为伴随采样在训练期间不需要任何数据, 即我们不使用原子构型! 我们通过在 GEOM-DRUGS 的一个子集上计算精确率和召回率来评估泛化能力, 见附录 G.2。这是最大的数据集之一, 与药物设计最为相关。

我们将 SPICE 分子划分为训练集和一个包含 80 个分子的测试集, 以验证采样器对未见分子的外推能力。我们使用 RDKit (Landrum, 2013)、CREST (Pracht 等, 2020) 和 ORCA (Neese, 2012) 生成参考构象用于评估, 其中 CREST 被视为分子化学领域的黄金标准。由于该过程计算成本高昂, 我们仅对 SPICE 测试集执行此操作。GEOM-DRUGS 为我们提供构象。有关数据集的详细信息, 请参见附录 G。

基线 我们将所提方法与 RDKit ETKDG (Riniker 和 Landrum, 2015) 进行比较, 后者是一种基于化学的构象生成方法。RDKit 结合了基于规则的距离矩阵方法、迭代优化算法、三维嵌入以及实验扭转偏好来生成构象, 使其成为合适的领域特定基线。

评估 我们的评估侧重于参考构象覆盖率召回率, 该指标衡量生成样本恢复的参考 CREST 构象的百分比, 以及覆盖率精确率, 该指标评估生成的构象与低能参考结构紧密匹配的频率。特别是, 召回率对于分子设计而言是一项非常重要的度量, 因为探索通常具有挑战性, 且存在良好的候选过滤机制。所考虑分子的参考构象数量差异显著, 从数十到数千不等。我们还报告绝对平均均方根偏差 (AMR) 作为误差度量, 其值越低表示结构保真度越高。更多细节请参见附录 F.3。表 2 中给出了经过和未经过弛豫的结果, 其中生成后优化有助于细化分子构象。未经过弛豫的样本检验了采样算法的性能, 而经过弛豫的测试最终为计算化学带来最大价值, 因为弛豫是一种标准的细化过程 (见附录 F)。

结果 如表 2 所示, 在 SPICE 和 GEOM-DRUGS 两个数据集上, 伴随采样 (包括笛卡尔和扭转两种变体) 在召回率上均优于 RDKit 基线。在泛化到 GEOM-DRUGS 数据集时, 我们的精确率低于 RDKit, 但召回率显著提升。如图 4 所示, 笛卡尔伴随采样在几乎所有阈值下均优于 RDKit, 无论是否进行松弛。虽然松弛提高了所有方法的覆盖率, 但它尤其有利于伴随采样的性能, 使得与 RDKit-ETKDG 之间的差距进一步拉大。我们认为这是因为伴随采样初始化为噪声随机过程, 从而自然地探索了更多的构型空间。

在没有松弛或预训练的情况下, 扭转伴随采样变体在两个数据集上的精确率和召回率均显著优于笛卡尔变体。然而, 经过预训练后, 笛卡尔伴随采样超越了扭转变体, 并且在松弛后 (无论是否预训练) 性能进一步提升。这可能是因为扭转表示在受限空间上演化 (如图 3 所示), 而笛卡尔表示在能量正则化项 (见附录 F.1) 下演化但不受约束。这种状态表示会影响受控过程探索构型空间的方式, 表明无约束的笛卡尔表示采样更具多样性。

最后，在图 12 中，我们还比较了不同可旋转键数量的情况——构象数量随可旋转键数量急剧增加（见图 8）——可以看到，随着难度增加，我们的模型与 RDKit 之间的差距也在增大。

6 结论

我们提出了伴随采样，这是一种从能量函数学习基于扩散的采样器的高度可扩展方法。利用互逆伴随匹配目标和回放缓冲区，我们的方法通过少量能量评估和模型样本即可进行多次梯度更新，从而实现高效训练。基于连续时间扩散过程，我们的框架自然地整合了对称性和周期性边界条件，使其适用于分子建模和构象生成。我们在合成能量函数上取得了最先进的性能，并且是首个扩展到更困难的构象生成任务的方法。我们开源了基准测试，以促进高度可扩展采样方法的进一步发展。

参考文献

- Tara Akhound-Sadegh, Jarrod Rector-Brooks, Joey Bose, Sarthak Mittal, Pablo Lemos, Cheng-Hao Liu, Marcin Sendera, Siamak Ravanbakhsh, Gauthier Gidel, Yoshua Bengio, et al. Iterated denoising energy matching for sampling from boltzmann densities. In *Forty-first International Conference on Machine Learning*, 2024.
- Michael S Albergo and Eric Vanden-Eijnden. Nets: A non-equilibrium transport sampler. *arXiv preprint arXiv:2410.02711*, 2024.
- Michael S Albergo, Gurtej Kanwar, and Phiala E Shanahan. Flow-based generative models for markov chain monte carlo in lattice field theory. *Physical Review D*, 100(3):034515, 2019.
- Michael S Albergo, Nicholas M Boffi, and Eric Vanden-Eijnden. Stochastic interpolants: A unifying framework for flows and diffusions. *arXiv preprint arXiv:2303.08797*, 2023.
- Michael Arbel, Alex Matthews, and Arnaud Doucet. Annealed flow transport monte carlo. In *International Conference on Machine Learning*, pages 318–330. PMLR, 2021.
- Simon Axelrod and Rafael Gomez-Bombarelli. Geom, energy-annotated molecular conformations for property prediction and molecular generation. *Scientific Data*, 9(1):185, 2022.
- Ilyes Batatia, David P Kovacs, Gregor Simm, Christoph Ortner, and Gábor Csányi. Mace: Higher order equivariant message passing neural networks for fast and accurate force fields. *Advances in neural information processing systems*, 35:11423–11436, 2022.
- Richard Bellman. *Dynamic programming*. Princeton Landmarks in Mathematics. Princeton University Press, Princeton, NJ, 2010., 1957.
- Yoshua Bengio, Salem Lahlou, Tristan Deleu, Edward J Hu, Mo Tiwari, and Emmanuel Bengio. Gflownet foundations. *Journal of Machine Learning Research*, 24(210):1–55, 2023.
- Julius Berner, Lorenz Richter, and Karen Ullrich. An optimal control perspective on diffusion-based generative modeling. *arXiv preprint arXiv:2211.01364*, 2023.
- A. E. Bryson and Y. C. Ho. *Applied Optimal Control*. Blaisdell, 1969.
- Junhua Chen, Lorenz Richter, Julius Berner, Denis Blessing, Gerhard Neumann, and Anima Anandkumar. Sequential controlled langevin diffusions. *arXiv preprint arXiv:2412.07081*, 2024a.
- Ricky T. Q. Chen, Yulia Rubanova, Jesse Bettencourt, and David K Duvenaud. Neural ordinary differential equations. In *Advances in Neural Information Processing Systems*, volume 31. Curran Associates, Inc., 2018.
- Yifan Chen, Mark Goldstein, Mengjian Hua, Michael S Albergo, Nicholas M Boffi, and Eric Vanden-Eijnden. Probabilistic forecasting with stochastic interpolants and follmer processes. *arXiv preprint arXiv:2403.13724*, 2024b.
- Yongxin Chen, Tryphon T Georgiou, and Michele Pavon. On the relation between optimal transport and schrödinger bridges: A stochastic control viewpoint. *Journal of Optimization Theory and Applications*, 169:671–691, 2016.
- Paolo Dai Pra. A stochastic control approach to reciprocal diffusion processes. *Applied mathematics and Optimization*, 23(1):313–329, 1991.

- Valentin De Bortoli, Emile Mathieu, Michael Hutchinson, James Thornton, Yee Whye Teh, and Arnaud Doucet. Riemannian score-based generative modelling. *Advances in Neural Information Processing Systems*, 35:2406–2422, 2022.
- Valentin De Bortoli, Michael Hutchinson, Peter Wirnsberger, and Arnaud Doucet. Target score matching. *arXiv preprint arXiv:2402.08667*, 2024.
- Pierre Del Moral, Arnaud Doucet, and Ajay Jasra. Sequential monte carlo samplers. *Journal of the Royal Statistical Society Series B: Statistical Methodology*, 68(3):411–436, 2006.
- Juan Viguera Diez, Sara Romeo Atance, Ola Engkvist, and Simon Olsson. Generation of conformational ensembles of small molecules via surrogate model-assisted molecular dynamics. *Machine Learning: Science and Technology*, 5(2): 025010, 2024.
- Carles Domingo-Enrich, Michal Drozdal, Brian Karrer, and Ricky T. Q. Chen. Adjoint matching: Fine-tuning flow and diffusion generative models with memoryless stochastic optimal control, 2024. <https://arxiv.org/abs/2409.08861>.
- Peter Eastman, Pavan Kumar Behara, David L Dotson, Raimondas Galvelis, John E Herr, Josh T Horton, Yuezhi Mao, John D Chodera, Benjamin P Pritchard, Yuanqing Wang, et al. Spice, a dataset of drug-like molecules and peptides for training machine learning potentials. *Scientific Data*, 10(1):11, 2023.
- W.H. Fleming and R.W. Rishel. *Deterministic and Stochastic Optimal Control*. Stochastic Modelling and Applied Probability. Springer New York, 2012.
- Hans Föllmer. An entropy approach to the time reversal of diffusion processes. In *Stochastic Differential Systems Filtering and Control: Proceedings of the IFIP-WG 7/1 Working Conference Marseille-Luminy, France, March 12–17, 1984*, pages 156–163. Springer, 2005.
- Marvin Friede, Christian Hölzer, Sebastian Ehlert, and Stefan Grimme. dxtb—an efficient and fully differentiable framework for extended tight-binding. *The Journal of Chemical Physics*, 161(6), 2024.
- Xiang Fu, Brandon M Wood, Luis Barroso-Luque, Daniel S Levine, Meng Gao, Misko Dzamba, and C Lawrence Zitnick. Learning smooth and expressive interatomic potentials for physical property prediction. *arXiv preprint arXiv:2502.12147*, 2025.
- Marylou Gabrié, Grant M. Rotskoff, and Eric Vanden-Eijnden. Adaptive monte carlo augmented with normalizing flows. *Proceedings of the National Academy of Sciences*, 119(10), mar 2022.
- Octavian Ganea, Lagnajit Pattanaik, Connor Coley, Regina Barzilay, Klavs Jensen, William Green, and Tommi Jaakkola. Geomol: Torsional geometric generation of molecular 3d conformer ensembles. *Advances in Neural Information Processing Systems*, 34:13757–13769, 2021.
- Mario Geiger and Tess Smidt. e3nn: Euclidean neural networks, 2022. <https://arxiv.org/abs/2207.09453>.
- Mario Geiger, Tess Smidt, Alby M., Benjamin Kurt Miller, Wouter Boomsma, Bradley Dice, Kostiantyn Lapchevskyi, Maurice Weiler, Michał Tyszkiewicz, Simon Bätzner, Dylan Madiseti, Martin Uhrin, Jes Frellsen, Nuri Jung, Sophia Sanborn, Mingjian Wen, Josh Rackers, Marcel Rød, and Michael Bailey. Euclidean neural networks: e3nn, April 2022. <https://doi.org/10.5281/zenodo.6459381>.
- Stefan Grimme, Christoph Bannwarth, and Philip Shushkov. A robust and accurate tight-binding quantum chemical method for structures, vibrational frequencies, and noncovalent interactions of large molecular systems parametrized for all spd-block elements (z= 1–86). *Journal of chemical theory and computation*, 13(5):1989–2009, 2017.
- Majdi Hassan, Nikhil Shenoy, Jungyoon Lee, Hannes Stark, Stephan Thaler, and Dominique Beaini. Et-flow: Equivariant flow-matching for molecular conformer generation. In *The Thirty-eighth Annual Conference on Neural Information Processing Systems*, 2024.
- Jiajun He, Yuanqi Du, Francisco Vargas, Dinghuai Zhang, Shreyas Padhy, RuiKang OuYang, Carla Gomes, and José Miguel Hernández-Lobato. No trick, no treat: Pursuits and challenges towards simulation-free training of neural samplers. *arXiv preprint arXiv:2502.06685*, 2025.
- Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. In *Advances in Neural Information Processing Systems*, volume 33. Curran Associates, Inc., 2020.
- Peter Holderrieth, Michael S Albergo, and Tommi Jaakkola. LEAPS: A discrete neural sampler via locally equivariant networks. *arXiv preprint arXiv:2502.10843*, 2025.

- Mengjian Hua, Matthieu Laurière, and Eric Vanden-Eijnden. A simulation-free deep learning approach to stochastic optimal control. *arXiv preprint arXiv:2410.05163*, 2024.
- Chin-Wei Huang, Milad Aghajohari, Joey Bose, Prakash Panangaden, and Aaron C Courville. Riemannian diffusion models. *Advances in Neural Information Processing Systems*, 35:2750–2761, 2022.
- Bowen Jing, Gabriele Corso, Jeffrey Chang, Regina Barzilay, and Tommi Jaakkola. Torsional diffusion for molecular conformer generation. *Advances in Neural Information Processing Systems*, 35:24240–24253, 2022.
- H J Kappen. Path integrals and symmetry breaking for optimal control theory. *Journal of Statistical Mechanics: Theory and Experiment*, 2005(11), nov 2005.
- Tero Karras, Miika Aittala, Timo Aila, and Samuli Laine. Elucidating the design space of diffusion-based generative models. *Advances in neural information processing systems*, 35:26565–26577, 2022.
- Leon Klein, Andrew Foong, Tor Fjelde, Bruno Mlodozienec, Marc Brockschmidt, Sebastian Nowozin, Frank Noé, and Ryota Tomioka. Timewarp: Transferable acceleration of molecular dynamics by learning time-coarsened dynamics. *Advances in Neural Information Processing Systems*, 36, 2024a.
- Leon Klein, Andreas Krämer, and Frank Noé. Equivariant flow matching. *Advances in Neural Information Processing Systems*, 36, 2024b.
- Jonas Köhler, Leon Klein, and Frank Noé. Equivariant flows: exact likelihood generative learning for symmetric densities. In *International conference on machine learning*, pages 5361–5370. PMLR, 2020.
- Jonas Köhler, Michele Invernizzi, Pim De Haan, and Frank Noé. Rigid body flows for sampling molecular crystal structures. In *International Conference on Machine Learning*, pages 17301–17326. PMLR, 2023.
- Risi Kondor, Zhen Lin, and Shubhendu Trivedi. Clebsch-gordan nets: a fully fourier space spherical convolutional neural network, 2018. <https://arxiv.org/abs/1806.09231>.
- Dávid Péter Kovács, J Harry Moore, Nicholas J Browning, Ilyes Batatia, Joshua T Horton, Venkat Kapil, William C Witt, Ioan-Bogdan Magdău, Daniel J Cole, and Gábor Csányi. Mace-off23: Transferable machine learning force fields for organic molecules. *arXiv preprint arXiv:2312.15211*, 2023.
- Salem Lahlou, Tristan Deleu, Pablo Lemos, Dinghuai Zhang, Alexandra Volokhova, Alex Hernández-Garcia, Léna Néhale Ezzine, Yoshua Bengio, and Nikolay Malkin. A theory of continuous generative flow networks. In *International Conference on Machine Learning*, pages 18269–18300. PMLR, 2023.
- Greg Landrum. Rdkit documentation. *Release*, 1(1-79):4, 2013.
- Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matthew Le. Flow matching for generative modeling. In *The Eleventh International Conference on Learning Representations*, 2023.
- Guan-Hong Liu, Arash Vahdat, De-An Huang, Evangelos A Theodorou, Weili Nie, and Anima Anandkumar. I²sb: Image-to-image schrödinger bridge. *arXiv preprint arXiv:2302.05872*, 2023.
- Guan-Hong Liu, Yaron Lipman, Maximilian Nickel, Brian Karrer, Evangelos Theodorou, and Ricky T. Q. Chen. Generalized schrödinger bridge matching. In *The Twelfth International Conference on Learning Representations*, 2024.
- Nanye Ma, Mark Goldstein, Michael S Albergo, Nicholas M Boffi, Eric Vanden-Eijnden, and Saining Xie. Sit: Exploring flow and diffusion-based generative models with scalable interpolant transformers. In *European Conference on Computer Vision*, pages 23–40. Springer, 2024.
- Nikolay Malkin, Moksh Jain, Emmanuel Bengio, Chen Sun, and Yoshua Bengio. Trajectory balance: Improved credit assignment in gflownets. *arXiv preprint arXiv:2201.13259*, 2023.
- Alex Matthews, Michael Arbel, Danilo Jimenez Rezende, and Arnaud Doucet. Continual repeated annealed flow transport monte carlo. In *International Conference on Machine Learning*, pages 15196–15219. PMLR, 2022.
- Laurence Midgley, Vincent Stimper, Javier Antorán, Emile Mathieu, Bernhard Schölkopf, and José Miguel Hernández-Lobato. SE(3) equivariant augmented coupling flows. *Advances in Neural Information Processing Systems*, 36, 2024.
- Laurence Illing Midgley, Vincent Stimper, Gregor NC Simm, Bernhard Schölkopf, and José Miguel Hernández-Lobato. Flow annealed importance sampling bootstrap. In *The Twelfth International Conference on Learning Representations: ICLR 2024*, 2023.

- Benjamin Kurt Miller, Mario Geiger, Tess E Smidt, and Frank Noé. Relevance of rotationally equivariant convolutions for predicting molecular properties. *arXiv preprint arXiv:2008.08461*, 2020.
- Radford M Neal. Annealed importance sampling. *Statistics and computing*, 11:125–139, 2001.
- Radford M Neal et al. MCMC using Hamiltonian dynamics. *Handbook of Markov Chain Monte Carlo*, 2(11):2, 2011.
- F. Neese. The orca program system. *WIREs Comput. Molec. Sci.*, 2(1):73–78, 2012. doi: 10.1002/wcms.81.
- Frank Noé, Simon Olsson, Jonas Köhler, and Hao Wu. Boltzmann generators: Sampling equilibrium states of many-body systems with deep learning. *Science*, 365(6457):eaaw1147, 2019.
- Michele Pavon. Stochastic control and nonequilibrium thermodynamical systems. *Applied Mathematics and Optimization*, 19:187–202, 1989.
- Stefano Peluchetti. Diffusion bridge mixture transports, schrödinger bridge problems and generative modeling. *Journal of Machine Learning Research*, 24(374):1–51, 2023a.
- Stefano Peluchetti. Non-denoising forward-time diffusions. *arXiv preprint arXiv:2312.14589*, 2023b.
- Angus Phillips, Hai-Dang Dau, Michael John Hutchinson, Valentin De Bortoli, George Deligiannidis, and Arnaud Doucet. Particle denoising diffusion sampler. *arXiv preprint arXiv:2402.06320*, 2024.
- Philipp Pracht, Fabian Bohle, and Stefan Grimme. Automated exploration of the low-energy chemical space with fast quantum chemical methods. *Physical Chemistry Chemical Physics*, 22(14):7169–7192, 2020.
- Philipp Pracht, Stefan Grimme, Christoph Bannwarth, Fabian Bohle, Sebastian Ehlert, Gereon Feldmann, Johannes Gorges, Marcel Müller, Tim Neudecker, Christoph Plett, et al. Crest—a program for the exploration of low-energy molecular chemical space. *The Journal of Chemical Physics*, 160(11), 2024.
- Philip E Protter and Philip E Protter. *Stochastic differential equations*. Springer, 2005.
- Danilo Rezende and Shakir Mohamed. Variational inference with normalizing flows. In *Proceedings of the 32nd International Conference on Machine Learning*, 2015.
- Lorenz Richter and Julius Berner. Improved sampling via learned diffusions. *arXiv preprint arXiv:2307.01198*, 2023.
- Lorenz Richter and Julius Berner. Improved sampling via learned diffusions. In *The Twelfth International Conference on Learning Representations*, 2024.
- Sereina Riniker and Gregory A Landrum. Better informed distance geometry: using what we know to improve conformation generation. *Journal of chemical information and modeling*, 55(12):2562–2574, 2015.
- Victor Garcia Satorras, Emiel Hoogeboom, and Max Welling. E (n) equivariant graph neural networks. In *International conference on machine learning*, pages 9323–9332. PMLR, 2021.
- S.P. Sethi. *Optimal Control Theory: Applications to Management Science and Economics*. Springer International Publishing, 2018.
- Yuyang Shi, Valentin De Bortoli, Andrew Campbell, and Arnaud Doucet. Diffusion schrödinger bridge matching. *Advances in Neural Information Processing Systems*, 36, 2023.
- Vignesh Ram Somnath, Matteo Pariset, Ya-Ping Hsieh, Maria Rodriguez Martinez, Andreas Krause, and Charlotte Bunne. Aligned diffusion schrödinger bridges. In *Uncertainty in Artificial Intelligence*, pages 1985–1995. PMLR, 2023.
- Yang Song and Stefano Ermon. Generative modeling by estimating gradients of the data distribution. *arXiv preprint arXiv:1907.05600*, 2019.
- Yang Song, Jascha Sohl-Dickstein, Diederik P. Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole. Score-based generative modeling through stochastic differential equations. In *International Conference on Learning Representations (ICLR 2021)*, 2021.
- Nathaniel Thomas, Tess Smidt, Steven Kearnes, Lusann Yang, Li Li, Kai Kohlhoff, and Patrick Riley. Tensor field networks: Rotation- and translation-equivariant neural networks for 3d point clouds, 2018. <https://arxiv.org/abs/1802.08219>.
- James Thornton, Michael Hutchinson, Emile Mathieu, Valentin De Bortoli, Yee Whye Teh, and Arnaud Doucet. Riemannian diffusion schrödinger bridge. *arXiv preprint arXiv:2207.03024*, 2022.

- Belinda Tzen and Maxim Raginsky. Neural stochastic differential equations: Deep latent Gaussian models in the diffusion limit. *arXiv:1905.09883*, 2019a.
- Belinda Tzen and Maxim Raginsky. Theoretical guarantees for sampling and inference in generative models with latent diffusions. *arXiv:1903.01608*, 2019b.
- Francisco Vargas, Will Sussman Grathwohl, and Arnaud Doucet. Denoising diffusion samplers. In *The Eleventh International Conference on Learning Representations*, 2023.
- Francisco Vargas, Shreyas Padhy, Denis Blessing, and Nikolas Nusken. Transport meets variational inference: Controlled monte carlo diffusions. In *The Twelfth International Conference on Learning Representations: ICLR 2024*, 2024.
- Daniel F Veber, Stephen R Johnson, Hung-Yuan Cheng, Brian R Smith, Keith W Ward, and Kenneth D Kopple. Molecular properties that influence the oral bioavailability of drug candidates. *Journal of medicinal chemistry*, 45(12):2615–2623, 2002.
- Maurice Weiler, Mario Geiger, Max Welling, Wouter Boomsma, and Taco Cohen. 3d steerable cnns: Learning rotationally equivariant features in volumetric data, 2018. <https://arxiv.org/abs/1807.02547>.
- Hao Wu, Jonas Köhler, and Frank Noé. Stochastic normalizing flows. *Advances in Neural Information Processing Systems*, 33:5933–5944, 2020.
- Minkai Xu, Lantao Yu, Yang Song, Chence Shi, Stefano Ermon, and Jian Tang. Geodiff: A geometric diffusion model for molecular conformation generation. *arXiv preprint arXiv:2203.02923*, 2022.
- Dinghuai Zhang, Ricky T. Q. Chen, Cheng-Hao Liu, Aaron Courville, and Yoshua Bengio. Diffusion generative flow samplers: Improving learning signals through partial trajectory optimization. In *The Twelfth International Conference on Learning Representations*, 2024. <https://openreview.net/forum?id=Olsahq1UYC>.
- Qinsheng Zhang and Yongxin Chen. Path integral sampler: A stochastic control approach for sampling. In *International Conference on Learning Representations*, 2022.

A 补充预备知识

A.1 随机最优控制 随机最优控制 (Stochastic Optimal Control, SOC; Bellman (1957); Fleming 和 Rishel (2012); Sethi (2018)) 考虑随机微分方程上的一般优化问题。具体而言, 一类 SOC 问题可表示为以下优化问题:

$$\min_{u \in \mathcal{U}} \mathbb{E} \left[\int_0^1 \left(\frac{1}{2} \|u(X_t^u, t)\|^2 + f(X_t^u, t) \right) dt + g(X_1^u) \right], \quad (22)$$

$$\text{s.t. } dX_t^u = (b(X_t^u, t) + \sigma(t)u(X_t^u, t)) dt + \sigma(t)dB_t, \quad X_0^u \sim p_0 \quad (23)$$

其中 (23), $X_t^u \in \mathbb{R}^d$ 是随机过程的状态, $u: \mathbb{R}^d \times [0, 1] \rightarrow \mathbb{R}^d$ 通常称为控制, $b: \mathbb{R}^d \times [0, 1] \rightarrow \mathbb{R}^d$ 是基础漂移项, $g: [0, 1] \rightarrow \mathbb{R}^{d \times d}$ 是扩散系数。这些共同定义了我们感兴趣的受控过程 $\mathbf{X}^u \sim p^u$; 通常 b 和 g 都是固定的, 我们只对控制 u 进行优化。

在以下命题中, 证明对于 $b \equiv 0, f \equiv 0$ 和 $X_0 = 0$ 的情形, 薛定谔桥 $p^*(\mathbf{X}) = p^{\text{base}}(\mathbf{X}|X_1)\mu(X_1)$ 实际上可以通过 $p^u(\mathbf{X})$ 实现。

命题 A.1. 对于随机过程 (2), 存在唯一极小化子 u^* 满足以下 optimization problem

$$\min_u D_{KL}(p^u(\mathbf{X})||p^*(\mathbf{X})) = 0, \quad (24)$$

and the optimal controlled distribution p^{u^*} satisfies:

$$p_{t,1}^{u^*}(X_t, X_1) = p_{t,1}^*(X_t, X_1) = p_{t|1}^{\text{base}}(X_t|X_1)\mu(X_1), \quad (25)$$

where $p_{t|1}^*(X_t|X_1)$ 是基础过程在 X_1 条件下的后验分布。

证明。利用路径测度 KL 散度的定义， $p^*(\mathbf{X}) = p^{\text{base}}(\mathbf{X}|\mathbf{X}_1)\mu(\mathbf{X}_1)$ 可以分解为

$$D_{\text{KL}}(p^u(\mathbf{X})||p^*(\mathbf{X})) = D_{\text{KL}}\left(p^u(\mathbf{X})||p^{\text{base}}(\mathbf{X})\frac{\mu(\mathbf{X}_1)}{p_1^{\text{base}}(\mathbf{X}_1)}\right) = D_{\text{KL}}(p^u(\mathbf{X})||p^{\text{base}}(\mathbf{X})) + \mathbb{E}_{\mathbf{X}\sim p^u} \log\left(\frac{p^{\text{base}}(\mathbf{X}_1)}{\mu(\mathbf{X}_1)}\right). \quad (26)$$

根据吉尔萨诺夫定理 (Girsanov's Theorem) (Protter 和 Protter, 2005)，进一步计算右侧为

$$D_{\text{KL}}(p^u(\mathbf{X})||p^{\text{base}}(\mathbf{X})) + \mathbb{E}_{\mathbf{X}\sim p^u} \log\left(\frac{p^{\text{base}}(\mathbf{X}_1)}{p^*(\mathbf{X}_1)}\right) = \mathbb{E}_{\mathbf{X}\sim p^u} \left[\int_0^1 \frac{1}{2} \|u(X_t, t)\|^2 dt + \log\left(\frac{p^{\text{base}}(\mathbf{X}_1)}{p^*(\mathbf{X}_1)}\right) \right].$$

该准则恰好对应于一个最小能量随机最优控制 (SOC) 问题，其阶段代价为 $\frac{1}{2} \|u(X_t, t)\|^2$ ，终端代价函数为 $g(\mathbf{X}_1) = \log\left(\frac{p^{\text{base}}(\mathbf{X}_1)}{p^*(\mathbf{X}_1)}\right)$ 。

$$\min_u \mathbb{E}_{\mathbf{X}\sim p^u} \left[\int_0^1 \frac{1}{2} \|u(X_t, t)\|^2 dt + g(\mathbf{X}_1) \right] \quad (27)$$

$$\text{s.t. } dX_t = \sigma(t)u(X_t, t) dt + \sigma(t) dB_t, \quad X_0 = 0 \quad (28)$$

我们可以定义问题在特定状态和时间 t 下的代价函数为

$$J(u; x, t) := \mathbb{E}_{\mathbf{X}\sim p^u} \left[\int_t^1 \frac{1}{2} \|u(X_s, s)\|^2 ds + g(\mathbf{X}_1) \mid X_t = x \right] \quad (29)$$

那么我们知道（在 g 的温和条件下）最优控制下的值函数或代价函数具有相当令人惊讶的形式，并且最优控制 u^* 是唯一的，且表现为当前状态的时变函数 (Kappen, 2005)：

$$V(x, t) := \min_u J(u; x, t) = -\log \mathbb{E}_{p^{\text{base}}} [\exp(-g(\mathbf{X}_1)) \mid X_t = x], \quad u^*(x, t) = -\sigma(t)\nabla_x V(x, t) \quad (30)$$

利用随机最优控制问题最优解的这一事实，我们可以将最优控制过程与目标薛定谔桥之间的路径 KL 散度上界为

$$D_{\text{KL}}(p^{u^*}(\mathbf{X})||p^*(\mathbf{X})) = V(X_0, 0) = -\log \mathbb{E}_{\mathbf{X}\sim p^{\text{base}}} [\exp(-g(\mathbf{X}_1))] \quad (31)$$

$$= -\log \int_{\mathbb{R}^d} \mu(x) dx = 0, \quad (32)$$

根据数据处理不等式，我们有

$$D_{\text{KL}}(p_{t,1}^{u^*}(X_t, X_1)||p_{t,1}^*(X_t, X_1)) \leq D_{\text{KL}}(p^{u^*}(\mathbf{X})||p^*(\mathbf{X})) = 0, \quad \forall t \in [0, 1] \quad (33)$$

这意味着对于所有 $t \in [0, 1]$ ， $p_{t,1}^{u^*}(X_t, X_1) = p_{1|t}^{\text{base}}(X_t|\mathbf{X}_1)\mu(\mathbf{X}_1)$ 。这正是我们的结论，证明完成。 $\square$

A.2 伴随匹配

伴随匹配 (Adjoint Matching, Domingo-Enrich 等人, 2024) 是一种旨在求解形式为 (22) 的随机最优控制问题的算法。与标准伴随方法 (Bryson 和 Ho, 1969) 通过对目标函数求导并执行梯度下降不同，伴随匹配直接尝试寻找不动点

$$u(x, t) = -\sigma(t)\nabla J(u; x, t) \quad (34)$$

其中 J 是根据控制 u 得到的期望未来成本，

$$J(u; x, t) = \mathbb{E}_{p^u} \left[\int_t^1 \frac{1}{2} \|u(X_s, s)\|^2 ds + f(X_s, s) ds + g(\mathbf{X}_1^u) \mid X_t = x \right]. \quad (35)$$

伴随匹配随后通过用随机估计器替换 $\nabla_x J$ 来求解该不动点 (34)。该随机估计器是 Domingo-Enrich 等人 (2024) 所定义的“精简伴随” (lean adjoint)，记为 $\tilde{\alpha}$ 。Domingo-Enrich 等人 (2024) 随后证明了该不动点的唯一解

$$u(x, t) = -\sigma(t) \mathbb{E}_{\mathbf{X} \sim p^u} [\tilde{\alpha}(x, t) | X_t = x] \quad (36)$$

即是最优控制 u^* 。这进而启发了以下目标函数，作为求解该不动点问题的一种手段。

$$\mathcal{L}_{\text{AM}}(u) := \mathbb{E}_{p^{\bar{u}}} \left[\frac{1}{2} \int_0^1 \|u(X_t, t) + \sigma(t)^\top \tilde{a}(t; \mathbf{X})\|^2 dt \right], \quad \mathbf{X} \sim p^{\bar{u}}, \quad \bar{u} = \text{stopgrad}(u), \quad (37)$$

$$\text{where } \frac{d}{dt} \tilde{a}(t; \mathbf{X}) = -(\tilde{a}(t; \mathbf{X})^\top \nabla_x b(X_t, t) + \nabla_x f(X_t, t)), \quad (38)$$

$$\tilde{a}(1; \mathbf{X}) = \nabla_{X_1} g(X_1). \quad (39)$$

其中 $\tilde{a}$ 被称为“精简伴随”状态， $\text{stopgrad}(\cdot)$ 表示停止梯度操作，即尽管 $\mathbf{X} \sim p^{\bar{u}}$ 是根据受控过程采样的，伴随匹配并不对采样过程求导。

注意，对于一般问题表述 (22)，伴随匹配需要两次仿真：一次从随机过程 $\mathbf{X} \sim p^u$ 中采样一条轨迹，另一次从 $t = 1$ (39) 处的终端条件出发，在时间上向后求解精简伴随状态 (38)。

对于简单的基础过程，伴随匹配会大大简化。我们的一个关键观察是，当 $b = 0$ 和 $f = 0$ 时，伴随匹配算法会大大简化，因为此时 (38) 为零。这意味着对于所有 t ，精简伴随状态 $\tilde{a}(t, \mathbf{X}) = \nabla g(X_1)$ 。因此，伴随匹配算法简化为

$$\mathcal{L}_{\text{AM}}(u) := \mathbb{E}_{p^{\bar{u}}} \left[\frac{1}{2} \int_0^1 \|u(X_t, t) + \sigma(t)^\top \nabla_{X_1} g(X_1)\|^2 dt \right], \quad \mathbf{X} \sim p^{\bar{u}}, \quad \bar{u} = \text{stopgrad}(u). \quad (40)$$

B 基础过程推导

B.1 欧几里得空间

我们的基础过程由一个随机微分方程建模 ($X_t \in \mathbb{R}^n$ 和 $\sigma : \mathbb{R} \rightarrow \mathbb{R}^+$):

$$dX_t = \sigma(t) dB_t, \quad X_0 = 0 \quad (41)$$

对应于 (2) 中控制设为零的情况，*i.e.*, $u_t = 0$ 。由此，前向转移分布 $\text{are } (t > s)$:

$$p_{t|s}^{\text{base}}(x|X_s) = \mathcal{N}(x|X_s, \nu_{t|s} I), \quad \text{其中 } \nu_{t|s} = \int_s^t \sigma(s)^2 ds. \quad (42)$$

利用 $s = 0$ 和 $X_0 = 0$ ，我们得到 (41) 的时间边缘分布:

$$p_t^{\text{base}}(x) = \mathcal{N}(x|0, \nu_t I), \quad \text{where } \nu_t = \int_0^t \sigma(s)^2 ds. \quad (43)$$

此外，后向转移分布为 ($t > s$):

$$p_{s|t}^{\text{base}}(x|X_t) = \frac{p_s^{\text{base}}(x) p_{t|s}^{\text{base}}(X_t|x)}{p_t^{\text{base}}(X_t)} = \mathcal{N}(x|\alpha_{s|t} X_t, \tilde{\nu}_{s|t} I), \quad (44)$$

$$\text{其中 } \alpha_{s|t} = \frac{\nu_s}{\nu_s + \nu_{t|s}}, \quad \tilde{\nu}_{s|t} = \left(\frac{1}{\nu_s} + \frac{1}{\nu_{t|s}} \right)^{-1} = \alpha_{s|t} \nu_{t|s} \quad (45)$$

因此，当 $\nu_{t|s}$ 可以以闭式形式推导时，互易伴随匹配目标 (13) 变得可处理。

恒定噪声调度。将扩散系数设为常数 $\sigma(t) = \sigma$ 得到

$$\nu_{t|s} = \sigma^2(t - s), \quad \alpha_{s|t} = \frac{s}{t} \quad (46)$$

因此得到以下终端和后向转移分布：

$$p_1^{\text{base}}(X_1) = \mathcal{N}(X_1; 0, \sigma^2 I), \quad p_{t|1}^{\text{base}}(x|X_1) = \mathcal{N}(x; tX_1, \sigma^2(1-t)tI). \quad (47)$$

几何噪声调度。Song 等人 (2021) ; Karras 等人 (2022) 提出以下几何调度（此处以逆时间形式表述）

$$\sigma(t) = \sigma_{\min} \left(\frac{\sigma_{\max}}{\sigma_{\min}} \right)^{1-t} \sqrt{2 \log \frac{\sigma_{\max}}{\sigma_{\min}}} \quad (48)$$

得到

$$\nu_{t|s} = \sigma_{\max}^2 \left(\left(\frac{\sigma_{\min}}{\sigma_{\max}} \right)^{2s} - \left(\frac{\sigma_{\min}}{\sigma_{\max}} \right)^{2t} \right), \quad \alpha_{s|t} = \frac{\left(\frac{\sigma_{\min}}{\sigma_{\max}} \right)^{2s} - 1}{\left(\frac{\sigma_{\min}}{\sigma_{\max}} \right)^{2t} - 1} \quad (49)$$

因此得到以下终端和后向转移分布：

$$p_1^{\text{base}}(X_1) = \mathcal{N}(X_1; 0, \sigma_{\max}^2 \left(1 - \left(\frac{\sigma_{\min}}{\sigma_{\max}} \right)^2 \right) I), \quad p_{t|1}^{\text{base}}(X_t|X_1) = \mathcal{N}(X_t; \alpha_{t|1}X_1, \alpha_{t|1}\nu_{t|1}I). \quad (50)$$

B.2 平坦环面

在 $\mathbb{T} = \mathbb{R}/\mathbb{Z}$ 中模拟基础过程 (41) 会产生一个环绕高斯分布 $\bar{p}_t^{\text{base}}$

$$\bar{p}_t^{\text{base}}(x) = \sum_{k \in \mathbb{Z}} p_t^{\text{base}}(x + k), \quad (51)$$

其中 p_t^{base} 是基础过程在 $\mathbb{R}$ 上的时间边缘分布，定义于 (43)，而 $\mathbb{Z}$ 是整数集。我们也可以等价地将 (51) 解释为对随机变量 k 进行边缘化。也就是说，我们将 $p_t^{\text{base}}(x + k)$ as a 视为在 $x \in \mathbb{T}$ 和 $k \in \mathbb{Z}$ 上的联合分布 $p_t(x, k)$ ，

$$p_t(x, k) := \underbrace{\frac{p_t^{\text{base}}(x + k)}{\int_{x' \in \mathbb{T}} p_t^{\text{base}}(x' + k)}}_{:= p_t(x|k)} \underbrace{\int_{x' \in \mathbb{T}} p_t^{\text{base}}(x' + k)}_{:= p_t(k)}. \quad (52)$$

直观上，变量 k 表示在 $\mathbb{R}$ 上哪个子区间被折叠以获得 x 。此外，我们可以在时间 t 由 x 推断 k ：

$$p_t(k|x) = \frac{p_t(x, k)}{\sum_{k'} p_t(x, k')}, \quad (53)$$

因此得到以下反向转移分布（ $s < t$ ），其中我们对 k 进行边缘化：

$$\bar{p}_{s|t}^{\text{base}}(x|X_t) = \sum_{k \in \mathbb{Z}} p_{s|t}(x|k, X_t) p_t(k|X_t) = \sum_{k \in \mathbb{Z}} \left(\sum_{k' \in \mathbb{Z}} p_{s|t}^{\text{base}}(x + k'|X_t + k) \right) \frac{p_t^{\text{base}}(X_t + k)}{\sum_{k' \in \mathbb{Z}} p_t^{\text{base}}(X_t + k')}, \quad (54)$$

where $p_{s|t}(x|X_t + k)$ 是 $\mathbb{R}$ 中的反向转移概率，定义于 (44)。因此，从 (54) 中给出的 $\bar{p}_{t|1}^{\text{base}}(x|X_1)$ 采样可以通过以下采样过程完成，其中

1. Sample $k \sim p(k)$ $p(k) \propto p_1^{\text{base}}(X_1 + k)$.
2. Sample $Y_t \sim p_{t|1}^{\text{base}}(\cdot|X_1 + k)$.
3. Project $X_t = Y_t \bmod 1.0$.

对于 n 维 $\mathbb{T}^n$ ，由于基础过程是因子化的，我们只需对每个维度独立采样。

C 互惠伴随匹配理论 作为预备，首先精确定义互惠投影的含义。我们采用 Shi 等人 (2023) 中的一些术语和结果，用 $\mathcal{M}$ 表示与形式为 $dX_t = v(X_t, t)dt + \sigma(t)dB_t$ 的随机微分方程相关的马尔可夫路径测度子集，其中 σ, v 局部利普希茨。

定义 C.1 (互惠类, Shi 等人 (2023) 定义 3)。博雷尔概率测度 $\Pi \in \mathbf{P}(C)$ 属于 $\mathbb{Q} \in M$ 的互惠类 $\mathcal{R}(\mathbb{Q})$ ，如果 $\Pi = \Pi_{0,T} \mathbb{Q}_{(0,T)|0,T}$ 。 $\mathbb{P} \in \mathbf{P}(C)$ 的互惠投影定义为 $\Pi^* = \mathcal{P}_{\mathcal{R}(\mathbb{Q})}(\mathbb{P}) = \mathbb{P}_{0,T} \mathbb{Q}_{(0,T)|0,T}$ 。根据构造， Π^* 属于互惠类 $\mathcal{R}(\mathbb{Q})$ 。以下刻画表明互惠投影确实是一个投影，即 $\mathcal{P}_{\mathcal{R}(\mathbb{Q})}^2 = \mathcal{P}_{\mathcal{R}(\mathbb{Q})}$ 。

引理 C.2 (互惠投影刻画, Shi 等人 (2023) 命题 4)。设 $\mathbb{P} \in \mathbf{P}(C)$ ， $\Pi^* = \mathcal{P}_{\mathcal{R}(\mathbb{Q})}(\mathbb{P})$ 。则 $\Pi^* = \arg \min_{\Pi \in \mathcal{R}(\mathbb{Q})} \{\text{KL}(\mathbb{P}|\mathbb{Q}) : \Pi \in \mathcal{R}(\mathbb{Q})\}$ 。

在整篇论文中，我们设 $\mathbb{Q} = \mathbb{B}_\nu$ ，i.e. $\mathbb{Q}$ 是过程 $(\int_0^t \sigma(s)dB_s)_{t \in [0,T]}$ 的概率测度，记作 $\mathcal{P}_{\mathcal{R}(\mathbb{Q})}$ 。

尽管该投影正是所提出的互惠伴随匹配目标 (方程 (13)) 所使用的，但我们现在将定义一个以漂移表示的类似投影，以便分析伴随采样算法的理想化版本。

C.1 互反投影降低 SOC 目标值 在 $p^u = \mathbb{P}$ 由某个漂移函数 u 生成的情况下，我们可以将互反投影视为定理 3.2 中提出的漂移 $\mathcal{P}$ 的投影，注意到生成 $\mathcal{P}_{\mathcal{R}}(p^u)$ 的唯一漂移是以下薛定谔桥问题的解

$$\mathcal{P}(u) := \arg \min_w \mathbb{E}_{\mathbf{X} \sim p^w} \left[\int_0^1 \frac{1}{2} \|w(X_t, t)\|^2 dt + \log \left(\frac{p^{\text{base}}(X_1)}{p^u(X_1)} \right) \right]. \quad (55)$$

这种漂移投影使我们能够根据命题 3.1 中描述的 AM 和 SOC 泛函来推理 RAM 损失。

命题 3.1 的证明。设 $v = \mathcal{P}(u)$ 。因为 $\mathcal{P}^2(u) = \mathcal{P}(u)$ ，RAM 中引入的互反投影“近似”恰好是由 v 诱导的分布，因此 $\mathcal{L}_{\text{AM}}(v) = \mathcal{L}_{\text{RAM}}(v)$ 。为了证明 $J(u) \geq J(\mathcal{P}(u))$ ，我们只需应用 $\mathcal{P}(u)$ (55) 的定义，得到

$$\begin{aligned} J(u) &= \mathbb{E}_{\mathbf{X} \sim p^u} \left[\int_0^1 \frac{1}{2} \|u(X_t, t)\|^2 dt + \left(\log \frac{p^{\text{base}}}{\mu} \right) (X_1) \right] \\ &= \mathbb{E}_{\mathbf{X} \sim p^u} \left[\int_0^1 \frac{1}{2} \|u(X_t, t)\|^2 dt + \left(\log \frac{p^{\text{base}}}{p^u} + \log \frac{p^u}{\mu} \right) (X_1) \right] \\ &\geq \mathbb{E}_{\mathbf{X} \sim p^v} \left[\int_0^1 \frac{1}{2} \|v(X_t, t)\|^2 dt + \left(\log \frac{p^{\text{base}}}{p^u} \right) (X_1) \right] + \mathbb{E}_{X_1 \sim p^u} \left[\log \frac{p^u}{\mu} (X_1) \right] \quad \text{by (55)} \\ &= \mathbb{E}_{\mathbf{X} \sim p^v} \left[\int_0^1 \frac{1}{2} \|v(X_t, t)\|^2 dt + \left(\log \frac{p^{\text{base}}}{p^u} + \log \frac{p^u}{\mu} \right) (X_1) \right] \quad p_1^v(X_1) = p_1^u(X_1) \\ &= J(v) = J(\mathcal{P}(u)). \end{aligned}$$

□

C.2 伴随采样保持伴随匹配的临界点

考虑具有任意固定参考漂移 v 的互反伴随匹配 (RAM) 目标的一个稍一般化的版本,

$$\mathcal{L}(u; v) = \mathbb{E}_{\mathbf{X} \sim p^v} \left[\int_0^1 \frac{1}{2} \|u(X_t, t) + \sigma(t) \nabla g(X_1)\|^2 dt \right] \quad (56)$$

$$s.t. \quad dX_t = \sigma(t)u(X_t, t) dt + \sigma(t) dB_t, \quad X_0 = 0 \quad (57)$$

那么 RAM 和 AM 损失都可以等价地用 $\mathcal{L}$, $\bar{u} = \text{stopgrad}(u)$ 重新表述,

$$\mathcal{L}_{\text{RAM}}(u) = \mathcal{L}(u; \bar{u}), \quad \mathcal{L}_{\text{AM}}(u) = \mathcal{L}(u, \bar{u}) \quad s.t. \quad \bar{u} = \mathcal{P}(\bar{u}),$$

其中 RAM 通过首先经由 $\mathcal{P}$ 投影, 然后将其设置为应用了停止梯度的参考漂移来展示。

如果在我们的主算法中考虑从某个漂移 v_i 开始顺序最小化 RAM 损失, 并且仅用来自 p^{v_i} 的样本填充缓冲区 $\mathcal{B}$, 则可以通过以下更新过程对伴随采样进行建模:

$$v_{i+1} = \arg \min_u \mathcal{L}(u; \bar{v}_i), \quad s.t. \quad \bar{v}_i = \mathcal{P}(v_i) \quad (58)$$

借助这种迭代形式, 实际上可以将伴随采样重新表述为 Domingo-Enrich 等人 (2024) 推导的伴随匹配损失的平稳条件。为证明这一点, 首先考虑 $\mathcal{L}$ 关于第一个自变量的一阶变分, 其定义为

$$\delta \mathcal{L}(u; v)(\eta) := \frac{d}{d\varepsilon} \mathcal{L}(u + \varepsilon \eta; v)|_{\varepsilon=0} = \mathbb{E}_{\mathbf{X} \sim p^v} \left[\int_0^1 \langle u(X_t, t) + \sigma(t) \nabla g(X_1), \eta(X_t, t) \rangle dt \right]$$

该代价泛函极值的一阶必要条件为 $\delta \mathcal{L}(u; v) \equiv 0$, 即

$$\delta \mathcal{L}(u; v)(\eta) = \mathbb{E}_{\mathbf{X} \sim p^v} \left[\int_0^1 \langle u(X_t, t) + \sigma(t) \mathbb{E}_{p^v} [\nabla g(X_1) \mid X_t], \eta(X_t, t) \rangle dt \right] = 0, \quad \forall \eta \in \mathcal{C}(\mathbb{R}^d \times [0, 1], \mathbb{R}) \quad (59)$$

已知若 p^v 在 $\mathbb{R}^d$ 上具有支撑且 $\mathbb{E}_{p^v} \left[\int_0^1 \langle \frac{\delta \mathcal{L}}{\delta u}(u; v)(x, t), \eta(X_t, t) \rangle dt \right] = 0$ 几乎处处成立, 则 $\frac{\delta \mathcal{L}}{\delta u}(u; v)(x, t) = 0$ 。这是关于 u 的泛函导数, 满足

$$\frac{\delta \mathcal{L}}{\delta u}(u; v)(x, t) := u(x, t) + \sigma(t) \mathbb{E}_{p^v} [\nabla g(X_1) \mid X_t = x] = 0, \quad a.e. \quad (60)$$

鉴于这一一般必要条件, 可以确定 $\mathcal{L}_{\text{AM}}(u)$ 的相应必要条件。

$$\frac{\delta \mathcal{L}_{\text{AM}}}{\delta u}(u)(x, t) := \frac{\delta \mathcal{L}}{\delta u}(u; \bar{u})(x, t) = u(x, t) + \sigma(t) \mathbb{E}_{p^{\bar{u}}} [\nabla g(X_1) \mid X_t = x] = 0, \quad a.e. \quad (61)$$

这与 Domingo-Enrich 等人 (2024) 推导的泛函导数一致, 其中观察到伴随匹配的临界点恰好是 (61) 为零的点。此外, 已确定唯一临界点是 SOC 问题 (7) 的最优控制 u^* 。现在可以更精确地陈述定理 3.2, 并在以下定理中给出证明。

定理 C.3 (伴随采样)。假设我们有一个反馈 u_i 。那么执行迭代 (58) 以获得 u_{i+1} 等价于该迭代

$$u_{i+1} = \mathcal{P}(u_i) - \frac{\delta \mathcal{L}_{\text{AM}}}{\delta u}(\mathcal{P}(u_i)), \quad (62)$$

此外, u^* 是一个满足 $u^* = \mathcal{P}(u^*)$ 和 $u^* = u^* - \frac{\delta \mathcal{L}_{\text{AM}}}{\delta u}(u^*)$ 的不动点, 当且仅当 u^* 是 $\mathcal{L}_{\text{AM}}$ 的临界点 (即它是 (7) 的最优控制 u^*)。

证明。通过对固定的 $\tilde{u}_i = \mathcal{P}(u_i)$ 逐点最小化 $\mathcal{L}(u; \tilde{u}_i)$ ，我们知道最优迭代具有以下形式

$$u_{i+1}(x, t) = -\sigma(t) \mathbb{E}_{p^{\tilde{u}_i}} [\nabla g(X_1) \mid X_t = x]. \quad (63)$$

回顾伴随匹配损失 $\mathcal{L}_{AM}(u) = \mathcal{L}(u; \bar{u})$ ，我们可以识别其在 $\mathcal{P}(u_i)$ 处由一阶变分产生的泛函导数为

$$\frac{\delta \mathcal{L}_{AM}}{\delta u}(\mathcal{P}(u_i)) = \mathcal{P}(u_i) + \sigma(t) \mathbb{E}_{p^{\mathcal{P}(u_i)}} [\nabla g(X_1) \mid X_t = x]. \quad (64)$$

通过简单的代数操作，我们可以得到迭代的新表达式

$$u_{i+1}(x, t) = \mathcal{P}(u_i)(x, t) - \frac{\delta \mathcal{L}_{AM}}{\delta u}(\mathcal{P}(u_i))(x, t).$$

我们现在将证明 v 是伴随采样迭代的不动点，且 $\mathcal{P}(v) = v$ 当且仅当 v 是 $\mathcal{L}_{AM}$ 的临界点（因此 $v = u^*$ ）。首先，如果 v 是 $\mathcal{L}_{AM}$ 的临界点，那么它必须是 $v = u^*$ （Domingo-Enrich 等人，2024）且 $\frac{\delta \mathcal{L}_{AM}}{\delta u}(v) = 0$ 。因为 $v = u^*$ 是 SOC 损失的最优解，它是自身的投影，所以 $\mathcal{P}(u^*) - \frac{\delta \mathcal{L}_{AM}}{\delta u}(\mathcal{P}(u_i))(u^*) = u^*$ 。因此 v 是伴随采样迭代的不动点。

另一方面，如果 v 是伴随采样迭代的不动点且 $\mathcal{P}(v) = v$ ，我们的迭代公式告诉我们 $\frac{\delta \mathcal{L}_{AM}}{\delta u}(v) = 0$ ，因此 v 是 $\mathcal{L}_{AM}$ 的临界点，且 $v = u^*$ 必然成立。□

该陈述与我们在实践中的做法之间存在一些重要的实际差异。在实践中，我们在有限大小的缓冲区 $\mathcal{B}$ 上进行优化，而定理 C.3 中讨论的迭代假设我们从 $p_1^{u_i}$ 中采样。此外，在实践中我们不需要精确地将 RAM 步骤求解至收敛，只需在收集 $\mathcal{B}$ 的新样本之前进行固定次数的部分优化。这可能是有益的，因为它会对定理 C.3 中的泛函梯度下降产生平滑效应，该下降跟踪一个大的单位步长梯度更新。

D 桥匹配与预训练

可能存在这样的情况：我们拥有某个初始数据分布 p^{data} ，但希望利用能量函数进一步改进生成的样本。实际上，我们可以使用桥匹配（Bridge Matching）（Peluchetti, 2023a,b; Shi et al., 2023; Liu et al., 2024, 2023; Somnath et al., 2023; Ma et al., 2024; Chen et al., 2024b）在该数据上预训练控制漂移 u_θ ，这同样可以表述为从 $X_0 = 0$ 扩散的受控随机微分方程，并在不改变最优分布的情况下切换到伴随采样。

具体而言，给定受控随机过程方程 (2)，我们可以写出以下桥匹配损失来回归到

$$\int_0^1 \lambda(t) \mathbb{E}_{p_{t|1}^{\text{base}}(X_t|X_1)p^{\text{data}}(X_1)} \|\sigma(t)u_\theta(X_t, t) - \sigma(t)^2 \nabla_{X_t} \log p_{1|t}^{\text{base}}(X_1|X_t)\|^2 dt, \quad (65)$$

其中对于一般基础过程 $dX_t = \sigma(t) dB_t$ ，我们有

$$p_{1|t}^{\text{base}}(x|X_t) = \mathcal{N}(x|X_t, \nu_{1|t}I), \quad \nu_{1|t} = \int_t^1 \sigma(s)^2 ds.$$

因此我们的得分目标是

$$\sigma(t)^2 \nabla_{X_t} \log p_{1|t}^{\text{base}}(X_1|X_t) = \sigma(t)^2 \nabla_{X_t} \left(-\frac{1}{2} \frac{(X_1 - X_t)^2}{\nu_{1|t}} + \text{const} \right) = \sigma(t)^2 \frac{X_1 - X_t}{\nu_{1|t}}.$$

此外，我们对损失应用缩放 $\lambda(t) := \frac{\sqrt{\alpha(t)}}{\sigma(t)}$ 目标为 $(X_1 - X_t)$ ，这提高了数值稳定性，从而得到以下桥匹配目标。

$$\mathcal{L}_{BM}(\theta) = \int_0^1 \mathbb{E}_{p_{t|1}^{\text{base}}(X_t|X_1)p^{\text{data}}(X_1)} \left\| \frac{\nu_{1|t}}{\sigma(t)} u_\theta(X_t, t) - (X_1 - X_t) \right\|^2 dt \quad (66)$$

E 合成能量实验细节

E.1 双阱势能 (DW-4)

我们采用与 iDEM (Akhound-Sadegh 等人, 2024) 相同的双阱势, 该势最初由 Köhler 等人 (2020) 提出。DW-4 描述了一个由 4 个粒子组成的系统的成对距离势能 $\{x_1, x_2, x_3, x_4\}$, 其中每个粒子具有 2 个空间维度 $x_i \in \mathbb{R}^2$ ($d = 8$)。该势的解析形式为:

$$E(x) = \frac{1}{\tau} \sum_{ij} a(d_{ij} - d_0) + b(d_{ij} - d_0)^2 + c(d_{ij} - d_0)^4, \quad d_{ij} = \|x_i - x_j\|_2 \quad (67)$$

其中我们设定 $a = 0, b = -4, c = 0.9$ 和温度 $\tau = 1$ 。

E.2 伦纳德-琼斯势 (LJ-13, LJ-55)

与 DW-4 类似, 伦纳德-琼斯势也基于具有 n 个粒子的系统的成对距离, 但每个粒子具有 3 个空间维度。其解析形式为

$$E^{\text{LJ}}(x) = \frac{\epsilon}{\tau} \sum_{ij} \left(\left(\frac{r_m}{d_{ij}} \right)^6 - \left(\frac{r_m}{d_{ij}} \right)^{12} \right), \quad d_{ij} = \|x_i - x_j\|_2 \quad (68)$$

其中 r_m, τ, ϵ 和 c 是物理常数。与 Köhler 等人 (2020) 和 Akhound-Sadegh 等人 (2024) 一样, 我们添加了额外的谐振子势:

$$E^{\text{osc}}(x) = \frac{1}{2} \sum_i \|x_i - x_{\text{COM}}\|^2 \quad (69)$$

其中 x_{COM} 指系统的质心。因此, 最终能量为 $E^{\text{Tot}} = E^{\text{LJ}}(x) + cE^{\text{osc}}(x)$, 其中 c 为振子尺度。与先前工作一致, 我们使用 $r_m = 1, \tau = 1, \epsilon = 1$ 和 $c = 1.0$ 。

E.3 架构与超参数

本节简要概述了在合成能量函数上训练伴随采样所使用的参数。在所有实验中, 我们采用与 Akhound-Sadegh 等人 (2024) 相似的 EGNN 架构。所有实验中 iDEM 的结果均使用 Akhound-Sadegh 等人 (2024) 中的相同配置复现。

DW-4: 对于 DW-4 能量, 我们使用具有 3 层和 128 个隐藏特征的等变图神经网络 (EGNN)。我们训练伴随采样 (Adjoint Sampling) 进行 1000 次外层迭代, 每次迭代生成 512 个新样本和能量评估, 存入最大容量为 10000 的缓冲区。在每次迭代中, 我们从回放缓冲区中优化 500 个批次, 批大小为 512, 学习率为 3×10^{-4} 。我们使用几何噪声调度, 参数为 $\sigma_{\min} = 10^{-4}$ 和 $\sigma_{\max} = 3.0$ 。

LJ-13: 对于 LJ-13 能量, 我们使用具有 5 层和 128 个隐藏特征的等变图神经网络 (EGNN)。我们训练伴随采样 (Adjoint Sampling) 进行 1000 次外层迭代, 每次迭代生成 1024 个新样本和能量评估, 存入最大容量为 10000 的缓冲区。在每次迭代中, 我们从回放缓冲区中优化 500 个批次, 批大小为 512, 学习率为 3×10^{-4} 。我们使用几何噪声调度, 参数为 $\sigma_{\min} = 10^{-3}$ 和 $\sigma_{\max} = 3.0$ 。

LJ-55: 对于 LJ-55 能量, 我们使用具有 5 层和 128 个隐藏特征的等变图神经网络 (EGNN)。我们训练伴随采样 (Adjoint Sampling) 进行 1000 次外层迭代, 每次迭代生成 128 个新样本和能量评估, 存入最大容量为 10000 的缓冲区。在每次迭代中, 我们从回放缓冲区中优化 500 个批次, 批大小为 512, 学习率为 3×10^{-4} 。我们使用几何噪声调度, 参数为 $\sigma_{\min} = 0.5$ 和 $\sigma_{\max} = 3.0$ 。

E.4 报告的度量

几何度量：由于我们的能量和扩散过程对旋转和置换对称性具有不变性，因此在测量生成点云与真实点云（例如来自长时间运行的马尔可夫链蒙特卡洛（MCMC））之间的距离时，我们也考虑了这些对称性。注意，此 $\mathcal{W}_2$ 度量与 Akhound-Sadegh 等人（2024）中报告的度量不同，后者使用欧几里得度量。

$$\mathcal{W}_2(\mu, \nu) = \left(\inf_{\pi} \int \pi(x, y) d(x, y)^2 dx dy \right)^{\frac{1}{2}} \quad (70)$$

其中 π 是传输计划，其边缘分布分别约束为 μ 和 ν 。这里的距离度量 d 考虑了所有点云对称性，通过在所有可能的旋转、反射（ $O(d)$ ）和排列（ $\mathbb{S}(k)$ ）组合上最小化平方欧氏距离得到，适用于空间维度为 d 的 k 个粒子。

$$d(x_0, x_1) = \min_{R \in O(d), P \in \mathbb{S}(k)} \|x_0 - (R \otimes P)x_1\|_2^2. \quad (71)$$

然而，在实际中计算精确的最小平方距离在计算上是不可行的。因此，我们采用 Köhler 等人（2020）的方法，通过执行顺序搜索来近似最小化器。

$$d(x_0, x_1) \approx \min_{R \in SO(d)} \|x_0 - (R \otimes \tilde{P})x_1\|_2^2, \quad \tilde{P} = \arg \min_{P \in \mathbb{S}(k)} \|x_0 - Px_1\|_2^2. \quad (72)$$

Energy ($E(\cdot)$) 评估生成样本质量的一种有信息量的方法是查看它们相对于由长时间运行的 MCMC 仿真能量得到的真实分布的能量分布。这显示了生成样本在多大程度上避免了高能量区域。具体来说，我们在 $\mathbb{R}$ 上的一维能量分布上使用 Wasserstein-2（ $\mathcal{W}_2$ ）距离。这导致了标准的欧氏 $\mathcal{W}_2$ 度量。

$$\mathcal{W}_2(E_\mu, E_\nu) = \left(\inf_{\pi} \int \pi(x, y) |x - y|^2 dx dy \right)^{\frac{1}{2}}, \quad (73)$$

路径有效样本量（path-ESS）。我们使用路径上的重要性权重 $\mathbf{X} \sim p^u$ （Zhang 和 Chen, 2022），

$$w(\mathbf{X}) = \frac{dp^*(\mathbf{X})}{dp^u(\mathbf{X})} = \frac{\mu(X_1)}{p_1^{\text{base}}(X_1)} \frac{dp^{\text{base}}(\mathbf{X})}{dp^u(\mathbf{X})} = \exp \left(-\frac{1}{2} \int_0^1 \|u(X_t, t)\|^2 dt - \int_0^1 u_t(X_t, t)^\top dB_t - g(X_1) \right). \quad (74)$$

由于这些是未归一化的权重，我们使用归一化的有效样本量：

$$\text{ESS} = \frac{1}{n \mathbb{E}_{\mathbf{X} \sim p^u} [w(\mathbf{X})]} \approx \frac{(\sum_{i=1}^n w_i)^2}{n \sum_{i=1}^n w_i^2}, \quad (75)$$

在 n 个样本 $\mathbf{X}_i \stackrel{iid}{\sim} p^u$ 上估计，权重为 $w_i = w(\mathbf{X}_i)$ 。此外，该 ESS 按样本数 n 归一化，取值在 $[0, 1]$ 范围内。

F 分子构象采样

构象生成是计算化学中的一项基本任务，其应用范围从药物发现到催化特定感兴趣的反应。在本文的背景下，构象代表同一分子的不同稳定状态，即势能面上的局部极小值。构象的数量

分子中可旋转键的数量通常与分子中存在的可旋转键数目成正比。例如，含有大量可旋转键的大分子具有许多构象异构体。若旋转能垒足够低且该键连接非末端重原子，则该键被视为可旋转键（Veber 等，2002）。我们在附录 F.2 中定义了一个特定的子结构以匹配此定义，并利用它来确定扭转模型采样的扭转角。然而，我们采用了一种略有不同且更具限制性的定义，基于附录 G 中 RDKit 的标准定义将分子划分为不同层级。

在许多分子和聚合物中，扭转角是采样构象时尤为重要的自由度。一个分子具有 $3k - 6$ 个与相关原子运动对应的自由度。该数量减去了全局平移（3 个自由度）和空间取向（3 个自由度），这两者均与分子内禀性质无关。剩余的自由度可分解为键长（原子对）、键角（包含两个与同一中心原子成键的原子的三元组）以及扭转角（包含一个中心键和两端各连接一个原子的四元组）。拉伸键或扭曲键角所需的能量通常远高于旋转扭转角。因此，扭转角是决定可能分子状态分布（即玻尔兹曼分布）的最重要自由度，而仅允许扭转角旋转是许多算法中常用的近似。

弛豫构象代表能量景观中的局部极小值；因此，我们关注下降算法以细化由伴随采样或 RDKit 生成的结构，使其达到这些极小值。我们应用与训练漂移估计器时相同的能量模型 eSEN 来定义优化目标。利用力对能量进行梯度下降称为弛豫。在我们的弛豫过程中，我们使用 LBFGS 算法，并限制任何原子上的最大力范数 $F_{\max} := \max_i \|\nabla_{x_i} E(\tilde{X}_1)\|$ 原子作为停止准则，其中 $\tilde{X}_1$ 是下降序列中的最新结构。当 $F_{\max} \leq 0.0154$ eV/Å 或达到 200 次下降迭代时停止，以先到者为准。

F.1 在笛卡尔坐标系中对目标分子进行采样 键结构 能量正则化 尽管我们以分子图为条件，但我们的漂移控制估计器旨在近似能量函数的梯度。在随机轨迹的演化过程中，我们可能会穿越能量低谷，这些低谷具有与目标分子不同的连接性。由于我们的目标是生成特定目标分子的构象，因此需要避免这种情况。我们通过添加正则化项来实现这一点。该正则化项根据经验已知的原子间半径和排斥性范德华半径，为原子分配特定的成键/不成键距离。

$$\tilde{E}(x) = \frac{1}{\tau} E(x) + \alpha E^{\text{reg}}(x) \quad (76)$$

其中 $\alpha > 0$ 是正则化缩放常数。正则化能量函数 $E^{\text{reg}} : \mathbb{R}^d \rightarrow [0, \infty)$ 被设计为具有以下性质的“平底”势能：

$$E^{\text{reg}}(x) = 0 \iff x \in \mathcal{S} \quad (77)$$

其中 $\mathcal{S}$ 是期望的分子结构类别。在实践中，为了训练稳定性以及由于我们无法精确刻画 $\mathcal{S}$ ，我们将其略微放宽为 $x \in \mathcal{S} \implies E^{\text{reg}}(x) = 0$ 。

在实践中，我们利用成熟的原子间经验共价半径确定有键原子间的上界距离，并利用范德华半径确定无键原子间的下界距离。然后，我们对任何违反这些界限的成对距离进行惩罚，并考虑松弛因子 $\gamma \geq 1$ 。借助邻接矩阵 $A = (a_{ij})$ 和原子类型属性向量 $H = (h_i)$ ，我们可以确定分子结构类别 $\mathcal{S}(A, H)$ 。利用相应的原子间键极限函数 $d_{\text{bond}}(h_i, h_j)$ 和 $d_{\text{no-bond}}(h_i, h_j)$ ，我们按如下方式遍历所有边来计算正则化项：

$$E^{\text{reg}}(x, A, H; \gamma) = \sum_{i,j \in I_{\text{bond}}} \max\{\|x_i - x_j\|_2 - \gamma \cdot d_{\text{bond}}(h_i, h_j), 0\} \quad (78)$$

$$+ \sum_{k,l \in I_{\text{no-bond}}} \max\left\{\frac{1}{\gamma} \cdot d_{\text{no-bond}}(h_k, h_l) - \|x_k - x_l\|_2, 0\right\} \quad (79)$$

其中 I_{bond} 和 $I_{\text{no-bond}}$ 分别是 A 中对应于原子间成键或不成键的索引对。假设原子间半径准确，我们的正则化项对所有 $\gamma \geq 1$ 满足 $x \in S(A, H) \implies E^{\text{reg}}(x, A, H; \gamma) = 0$ 。

F.2 扭转角与扭矩



图 5 二碘乙烷分子的多重表示，其简化分子线性输入规范字符串为 **ICCI**。（左）分子图表示。（右）三维坐标表示。我们选择扭转角为 I-C-C-I，其中 I 表示紫色碘原子，C 表示灰色碳原子。我们用四元组索引标识扭转，选择中心键两侧最重的原子作为首末成员。若出现并列，则按任意原子索引打破平局。我们规定当四元组的首末成员靠近时，即所谓的顺式异构体，二面角为零。遵循 Jing 等人（2022）的方法，我们通过绕键轴旋转扭转一端的所有原子来调整二面角，其余原子保持不动。这可以描述为沿键轴方向的力矩。当力矩对分子的作用不对称时，我们定义正方向指向分子中原子更多的一侧。

扭转角与力矩的表示 给定键周围的取向可以用扭转角来量化。具体而言，扭转角定义在四个原子 (a, b, c, d) 之间，其中扭转角是由 a, b, c 和 b, c, d 形成的平面之间的夹角，这两个平面绕中心 bc 键旋转。原子 a 和 d 的选择通常不唯一，因此选择不同的 a 或 d 可能导致描述同一分子构象的扭转角不同。我们的约定是 a 和 d 对应中心键 bc 两侧最重的原子。若出现并列，则按任意现有原子索引打破平局。接下来，我们以符号方式表示扭转角。……假设原子 $a, b, c, d \in \mathbb{R}^3$ 是笛卡尔空间中的位置，我们定义几个沿无向键轴的向量：

$$dx_1 := \overrightarrow{ab} := b - a, \quad dx_2 := \overrightarrow{bc} := c - b, \quad dx_3 := \overrightarrow{cd} := d - c. \quad (80)$$

这些向量使我们能够如下定义扭转角：

$$\varphi(dx_1, dx_2, dx_3) := \text{atan2}(dx_2 \cdot ((dx_1 \times dx_2) \times (dx_2 \times dx_3)), |dx_2| (dx_1 \times dx_2) \cdot (dx_2 \times dx_3)). \quad (81)$$

我们定义函数 $\mathcal{T}: \mathbb{R}^{4 \times 3} \rightarrow \mathbb{R}$ ，它接受四个原子位置

We define the function that takes in four column vectors of atomic outputs a torsion angle

$(a, b, c, d) \mapsto \varphi(dx_1(a, b), dx_2(b, c), dx_3(c, d))$.

遵循 Jing 等人（2022）的方法，我们可以通过绕键轴 $\overrightarrow{bc}$ 旋转 bc 键一侧的所有原子来调整扭转角。这可以描述为标准角轴表示中的扭矩 $\mathbf{t}$ ，其中轴指向 $\overrightarrow{bc}$ 。正号表示根据右手定则的正旋转，幅度表示旋转对现有扭转角的影响。旋转 $R(\mathbf{t})$ 对具有组成原子 $x_i \in \mathbb{R}^3$ 的系统 X_t 的作用可以写成如下形式：

$$R(\mathbf{t})x_i = \begin{cases} R'(\mathbf{t})(x_i - b) + b & \text{if } i \in \mathfrak{C}(c) \\ x_i & \text{otherwise} \end{cases}, \quad (82)$$

其中 $R'(t)$ 是由 t 的轴角表示定义的旋转矩阵， $\mathcal{C}(c)$ 表示与分子相同的图中 c 的连通分量，只是去除了键 bc ！因此， $\mathcal{C}(c)$ 表示当假设在键 bc 处分割时分子的一个“半”或“侧”。

由于每个扭矩都沿 $\vec{bc}$ bc 设计指向，我们需要一个约定来排序扭转角四元组以确定旋转方向。我们选择原子 c 位于 bc 键的具有更多原子的一侧 (Jing 等人, 2022)。更具体地说，如果断开键 bc ，将有两个连通分量 $\mathcal{C}(b)$ 和 $\mathcal{C}(c)$ 。我们选择 c 使得 $|\mathcal{C}(c)| > |\mathcal{C}(b)|$ 。（这与 Jing 等人 (2022) 在论文中写的定义相反，但与其代码中的相同。）在并列的情况下，我们使用当前的任意索引。

使用 RDKit 查找扭转自由度 通过采样扭转角来采样构象需要识别目标分子中的扭转自由度。我们使用 RDKit 包 (Landrum, 2013) 来查找和表示这些自由度的四元组。我们寻找与以下子结构匹配的模式：（1）两个原子必须通过键连接，（2）该键的两端都不能是芳香性的，（3）该键的两端都不能仅连接到一个氢原子，（3）该键只有一端可以是环的一部分。这样的子结构可以用 SMARTS 字符串编码，具体为 [!\$(*#*)&!D1]-。这种匹配可以直接在分子的 SMILES 字符串上进行。

&!@!\$(*#*)&!D1]

子结构匹配通过包含每个位置原子的四元组列表来识别扭转自由度。回想一下，如上所述，这种表示不是唯一的！此外，这种搜索技术通常找到的扭转自由度比 RDKit 在查询可旋转键数量时返回的要多。RDKit 对可旋转键有特定的定义，该定义隐含在 `CalcNumRotatableBonds` 中。

扭转角几何的考量 我们在扭转角空间中建模一个随机微分方程，这样能更实际地处理基础分布，并降低维度。然而，这带来了一些额外的考量。本节考虑一个具有 d_{rot} 个扭转自由度的分子。由于扭转角的周期性边界条件，该空间被建模为一个平坦环面 $\mathbb{D} := [-\pi, \pi)^{d_{\text{rot}}}$ ，其中极值因环面距离函数（即所谓的对数映射）而被视为零位移。令 $D_{\text{rot}} = \{1, \dots, d_{\text{rot}}\}$ 表示每个扭转角的指标集。

我们使用以 $\varphi = 0$ 为中心、 $\varphi \in \mathbb{D}$ 位于 $t = 0$ 处的狄拉克源分布。在 $\mathbb{D}$ 中选择原点必须在笛卡尔空间中具有唯一对应的位置。给定构成扭转角 $\varphi_i \in [-\pi, \pi)$ 的原子 (a_i, b_i, c_i, d_i) ，其中 $i \in D_{\text{rot}}$ ，我们选择 $\varphi_i = 0$ 为笛卡尔空间中 a_i, d_i 在欧氏距离上最接近的状态，即：

$$\mathcal{T}(a_i, b_i, c_i, d_i) = 0 \iff d_i = \arg \min \|a_i - d_i\|_2. \quad (83)$$

该定义对所有 $i \in D_{\text{rot}}$ 相同。我们依赖直觉，忽略证明该选择唯一性的细节，并认为 a_i 与 d_i 之间的距离是确定扭转角 φ_i 所需的唯一要素。

我们现在在笛卡尔空间中构建具有所有 $i \in D_{\text{rot}}$ 的 $\varphi_i = 0$ 的分子 X_0 。首先，使用 RDKit 的 `EmbedMolecule`（或 `EmbedMultipleConfs`，参数为 `numConfs=1`）将分子图嵌入笛卡尔空间，得到一个任意的近似构象。嵌入后，我们可以使用 `GetSubstructMatches` 识别构成扭转角的原子 (a_i, b_i, c_i, d_i) （其中 $i \in D_{\text{rot}}$ ），并使用 $\mathcal{T}$ 确定当前的扭转角。对于通过此方法生成的任何原子构型 X ，我们可以通过迭代地对每个 i 应用 $R(-\mathcal{T}(a_i, b_i, c_i, d_i))X$ 来变换 X ，从而到达 X_0 。这种变换的迭代应用在其他工作中很常见 (Jing 等人, 2022)，并将使所有扭转角达到 $\varphi_i = 0$ 。这就是扭转伴随采样的起点！通过将扭转角设为零，但保留原子类型、分子拓扑、键长和键角，我们得到了一个初始样本，可用随机控制进行变换。

我们的随机微分方程在 $\mathbb{D}$ 中演化，起始于 $\varphi_0 = 0$ ，终止于 φ_1 ，具有平坦环面上随机微分方程的标准行为。然而，我们的扭矩漂移估计器是 X_t 的函数，这意味着当 φ_t 在随机微分方程下演化时，我们需要更新 X_t 的位置。给定来自模型的漂移估计 $\hat{\mathbf{t}}(X_t)$ ，我们利用 $\epsilon_i \sim \mathcal{N}(0, \sigma(t)^2 \Delta t)$ ， Δt 更新位置 $X_{t+1} = \prod_{i \in D_{\text{rot}}} R_{X_t}^i(t_i + \epsilon_i) X_t$ ，其中步间增量与 $\sigma(t)$ 由 (48) 中的几何噪声调度作为时间的函数确定。

回归目标

$$\frac{1}{\tau} g(X_1) \text{ 其中梯度为}$$

在笛卡尔空间中获取。对于我们的问题，需要计算回归目标 $\frac{1}{\tau} \nabla_{\varphi} g(X_1)$ 。这两个量通过雅可比矩阵 $\frac{d\varphi}{dX}$ 相关联，即 $\nabla_{\varphi} g(X_1) = \frac{d\varphi}{dX} \nabla_X g(X_1)$ 。我们利用函数 $R(\varphi_1)X_0 = X_1$ 的自动微分来计算该向量-雅可比乘积，该函数应用于由能量模型确定的 $\nabla_X g(X_1)$ 向量。需要说明的是，当对扭转模型进行梯度裁剪时，我们裁剪的是 $\nabla_{\varphi} g(X_1)$ 。

扭转空间后验伴随采样的创新之处在于利用后验沿控制轨迹快速采样点。在扭转情形下，本文从后验 $\bar{p}_t^{base}$ 中采样 $\varphi_t \mid \varphi_1$ 。具体做法是将 B.2 节中平坦环面分布的坐标 $[0, 1]$ 仿射变换至 $[-\pi, \pi)$ 。

扭矩的变换 当我们发送 $X \mapsto -X$ 时，扭矩被变换 $t \mapsto -t$ ，这类量被称为赝向量，其带符号的大小被称为赝标量。遵循 Jing 等人 (2022) 以及 Geiger 等人 (2022) 的实现，我们的网络在不进行数据增强的情况下预测 d_{rot} 个赝标量。

F.3 覆盖率召回率与精确率度量

均方根偏差 (Root Mean Square Deviation, RMSD) 与 Ganea 等人 (2021) 和 Jing 等人 (2022) 类似，我们测量所谓的平均最小均方根偏差 (AMR) 以及精确率 (P) 和召回率 (R) 的覆盖率 (COV)。在测量这些指标时，我们生成的构象数量是 CREST 参考构象提供的两倍。对于 $K = 2L$ ，令 $\{C_l^*\}_{l \in [1, L]}$ 和 $\{C_k\}_{k \in [1, K]}$ 分别为真实构象集和生成构象集。在我们的评估中，我们使用 $L = \max(L', 128)$ ，其中 L' 是 CREST 给出的参考构象数量，取能量最低的构象作为子集。均方根偏差度量在考虑所有可能对称性的情况下，找到分子原子相对于参考分子的最佳平均距离。

覆盖率召回率

$$\text{COV-R}(\delta) := \frac{1}{L} |\{l \in \{1, \dots, L\} : \exists k \in \{1, \dots, K\}, \text{RMSD}(C_k, C_l^*) < \delta\}| \quad (84)$$

$$\text{AMR-R} := \frac{1}{L} \sum_{l \in \{1, \dots, L\}} \min_{k \in \{1, \dots, K\}} \text{RMSD}(C_k, C_l^*) \quad (85)$$

覆盖率精确率

$$\text{COV-P}(\delta) := \frac{1}{K} |\{k \in \{1, \dots, K\} : \exists l \in \{1, \dots, L\}, \text{RMSD}(C_k, C_l^*) < \delta\}| \quad (86)$$

$$\text{AMR-P} := \frac{1}{K} \sum_{k \in \{1, \dots, K\}} \min_{l \in \{1, \dots, L\}} \text{RMSD}(C_k, C_l^*) \quad (87)$$

其中 $\delta > 0$ 是覆盖率阈值。

F.4 SPICE 和 GEOM-DRUGS 的超参数与架构细节

笛卡尔伴随采样：我们使用一个等变图神经网络 (EGNN, Satorras 等人 2021)，具有 12 层和 128 的隐藏特征维度。模型训练 5000 次外循环迭代，每次迭代从回放缓冲区采样 100 个批次。每个 GPU 维护自己的缓冲区，最大大小为 64000 个样本，每次迭代我们在 8 个 GPU 上为缓冲区生成 128×8 个新分子和能量评估。模型以每 GPU 64 的批大小进行训练，并遵循几何噪声调度，其中 $\sigma_{\min} = 10^{-3}$ 和 $\sigma_{\max} = 1$ 。应用权重梯度裁剪 10^{20} 。此外，我们使用温度 $\tau = 5 \times 10^{-3}$ 和正则化常数 $\alpha = 100.0$ 用于正则化能量函数。回归目标，即能量函数的温度缩放梯度，在 ℓ^2 范数 150 处被裁剪。在训练和评估期间，我们使用步长 $dt = 0.001$ (i.e. 1000 (nfe)) 进行欧拉-丸山随机微分方程积分。

扭转伴随采样：我们使用了一种不同的等变图神经网络，称为 e3nn (Geiger 和 Smidt, 2022; Geiger 等人, 2022)，该网络具有 6 个卷积层，每层包含 32 个标量特征和 8 个向量特征。此外，还有一个由 Jing 等人 (2022) 提出的专门层，称为伪扭矩层，我们在输出端使用该层来预测伪标量扭矩量。我们的边和节点嵌入具有

32 个标量特征。截断半径为 5.0，我们构建了 50 个高斯径向基函数来嵌入原子间的距离。我们使用 8 个 GPU，初始分子数为 1024×8 ，每次迭代生成 128×8 个新分子并评估其能量（梯度），然后将这些分子添加到 GPU 缓冲区中。模型训练 3000 次外循环迭代，每次迭代从最大大小为 64000 的重放缓冲区中采样 100 个批次。模型以 64 的批大小进行训练，并遵循几何噪声调度，参数为 $\sigma_{\min} = \pi \times 10^{-2}$, $\sigma_{\max} = \pi$ ，以及“瓦片数”截断参数 6，用于在平坦环面上近似 p^{base} （附录 F.2）。应用了权重梯度裁剪 10^{20} 。此外，我们使用温度 $\tau = 5 \times 10^{-3}$ 和直接能量函数，不进行任何正则化。回归目标，即能量函数相对于扭转角的温度缩放梯度，被裁剪在 ℓ^2 范数 200 处。在训练和评估期间，我们使用步长 $dt = 0.01$ (i.e. 100 (nfe) 进行欧拉-丸山随机微分方程积分。

G 构象基准的数据准备

在此背景下，伴随采样接受 SMILES 字符串并输出构象。这里我们解释输入 SMILES 字符串的划分以及构象的代表性坐标样本。此外，我们解释了我们使用 RDKit (Landrum, 2013)、CREST (Pracht 等人, 2024) 和 ORCA (Neese, 2012) 生成、松弛和去重参考原子构象的过程，该过程与 GEOM-DRUGS (Axelrod 和 Gomez-Bombarelli, 2022) 的过程极为相似。

我们发布本文中使用的数据，作为一个具有挑战性的构象基准，旨在促进可扩展的、摊销采样算法的发展。数据包含三个部分：

- 来自 SPICE (Eastman 等人, 2023) 的 24,477 个 SMILES 字符串的训练划分。这些字符串定义了目标分子的分子拓扑结构，但不包含任何原子坐标信息。这些分子具有不同程度的灵活性，可旋转键数量在 0 到 18 之间²。

- 一个测试分割³，包含来自 SPICE 的 80 个 SMILES 字符串，分为 10 组，每组具有 3 到 10 个可旋转键。我们还发布了 44,448 个经 DFT 标注并几何优化的构象。
- 一个测试分割，包含来自 GEOM-DRUGS 的 80 个 SMILES 字符串，分为 10 组，每组具有 3 到 10 个可旋转键。我们识别出与这些 SMILES 字符串对应的 7024 个构象。

详细内容在附录 G.1 中描述如下。由于我们重新打包了来自 SPICE 和 GEOM-DRUGS 的数据，我们的主要贡献包括 (a) 基准的组织以及 (b) 使用与 GEOM-DRUGS 类似的程序，从我们的 SPICE 测试分割中找到 44,448 个构象的计算工作。

使用该基准的方法是应用采样算法来寻找给定分子拓扑的构象，并确定该算法是否恢复了我们提供的样本。在图 4 中，我们将其报告为覆盖率召回率 (Coverage Recall %) 与 RMSD 的关系。我们还在表 2 中提供了表格化的数值。我们提供的构象应被视为使用有效且昂贵的标准方法生成的保留数据。我们不声称已全面采样这些分子的构象空间，但我们认为它们代表了现代方法下的代表性样本。此外，由于我们仅发布局部极小值，样本并非来自固定温度下的玻尔兹曼分布，即样本并非从概率分布中抽取。在我们的数据中，不存在某个构象在概率意义上比另一个更“可能”的概念。相反，该基准代表了一种宽松定义的采样概念，即通过寻找许多低能量构象来尝试覆盖构型空间。

G.1 SPICE 数据集

我们使用 SPICE 数据集的 PubChem 子集 (Eastman 等, 2023) 来训练和评估模型。该子集包含由 18 至 50 个原子组成的小型类药分子，元素包括溴、碳、氯、氟、氢、碘、氮、氧、磷和硫。我们关注分子的构象，这意味着我们关心旋转自由度。我们确定了两组描述这些自由度的集合：可旋转键数和扭转自由度，简称扭转。在我们的情况中，可旋转键 $\subseteq$ 扭转自由度。我们使用 RDKit 包计算可旋转键数。2 可旋转键由 RDKit 的 `CalcNumRotatableBonds` 函数定义 (Landrum, 2013)。3 测试集与训练集不相交，它们的并集是整个 SPICE 数据集。




图 6 SPICE 训练集中可旋转键和扭转自由度的直方图。左：使用 RDKit 的 CalcNumRotatableBonds 确定的可旋转键数。右：使用 SMARTS 字符串 !\$(***)&!D1]-&!@!\$(***)&!D1] 通过 GetSubstructMatches 确定的扭转自由度数。

CalcNumRotatableBonds。我们使用 SMARTS 字符串 !\$(***)&!D1]-&!@!\$(***)&!D1] 和同样来自 RDKit 的 GetSubstructMatches 来计算扭转自由度数。我们根据可旋转键数将分子分组，但将扭转自由度提供伴随采样扭转模型。可旋转键的分布以及两组扭转自由度之间的比较见图 6 和图 7。我们发现可旋转键数少于与子结构查询匹配的扭转数，这是预期的。关于扭转模型的更多信息见附录 F。

我们从每个具有固定可旋转键数（3 至 10 范围内）的分子类别中随机抽取 10 个分子，以创建测试集。我们对得到的 80 个分子进行了预处理和 CREST (Pracht 等, 2024)。我们还从训练集中移除了 30 个额外分子；每个可旋转键数在 0 至 2 之间的类别各移除 10 个。这些分子不出现在测试集中，因为它们相当简单。我们的流程遵循 GEOM-DRUGS (Axelrod 和 Gomez-Bombarelli, 2022)。

在预处理阶段，我们首先使用 RDKit 通过 EmbedMultipleConfs 生成 50 个构象，参数为 pruneRmsThresh=0.01, maxAttempts=5, useRandomCoords=False，分别对应相似构象的剪枝阈值为 0.01 Å、每个构象最多五次嵌入尝试、从距离矩阵的特征值初始化坐标以及随机种子。如果未能成功生成任何构象，则将 numConfs 增加到 500。随后，在 RDKit 默认的 MMFF 力场中对构象进行优化。我们使用 RDKit 的 GetBestRMS 对构象进行去重，除非计算时间超过 48 小时，此时改用 RDKit 的 AlignMol。（97 个使用了 GetBestRMS，3 个使用了 AlignMol。）在移除 RMSD < 0.1 Å 的重复构象后，能量最低的十个构象进一步使用扩展紧束缚 (xTB) 近似能量模型进行优化 (Grimme 等, 2017; Friede 等, 2024)。xTB 能量最低的构象被用作 CREST 仿真的输入。我们使用了 CREST 3.0.2 版本的默认超参数，包括对最终构象的 6 kcal/mol 截断。任何包含斜杠或反斜杠的 SMILES 字符串表示顺反异构，由于在上述过程中其 SMILES 字符串无法保留，因此被跳过。

上述过程的输出按照现代方法的标准对势能面进行了充分采样；然而，结构是在 xTB 精度水平上优化的。我们进一步使用 ORCA 对测试集中的每个构象进行密度泛函理论 (DFT) 几何优化。具体来说，我们取 CREST 的输出并运行 ORCA 弛豫，设置如下：

```
Opt wb97M-V def2-tzvpd RIJCOSX def2/J NoUseSym DIIS NOSOSCF NormalConv DEFGRID2 NormalPrint AllPop
%scf Convergence Tight maxiter 300 end %elpop Dipole true Quadrupole true end %output
Print[P_ReducedOrbPopMO_L] 1 Print[P_ReducedOrbPopMO_M] 1
```

Print[P_BondOrder_L] 1 Print[P_BondOrder_M] 1 Print[P_Fockian] 1 Print[P_OrbEn] 2 end %geom MaxIter 100 end %scf THRESH 1e-12 TCUT 1e-13 end 由于篇幅限制，上述代码片段在 LaTeX 版本中部分行被断开。这些结果是在非常高的 DFT 理论水平上运行的。进一步几何优化可能需要在 DEFGRID3 和 TightOpt 下进行；然而，鉴于当时可用的资源，如此极端的精度是难以实现的。

几何优化后，本文利用 RDKit 的 GetAllConformerBestRMS 函数及 0.1 Å 阈值识别成对重复构象，并将其从数据集中移除。不同可旋转键数量对应的参考构象平均数量如图 8 左侧所示。

本文探究了 SPICE 数据集中 80 个分子测试集产生的构象数量比 GEOM-DRUGS 数据集中 80 个分子测试集多一个数量级的原因。在复现 GEOM-DRUGS 构象后，发现 SPICE 测试集中的分子本质上比 GEOM-DRUGS 测试集中的分子更具柔性。GEOM-DRUGS 分子倾向于含有更多环和氢键，导致构象数量较少。换言之，SPICE 分子往往具有更平坦的势能面。由于遵循 GEOM-DRUGS 流程，本文在 CREST 中应用了相同的 6 kcal/mol 截断值，从而保留了更多来自 SPICE 的构象。对于覆盖率召回率指标，本文将每个分子的参考构象数量上限设为 512。




图 7 SPICE 训练集与测试集合并后，扭转自由度（纵轴）与可旋转键数量（横轴）之间的相关性热图。扭转自由度通过 GetSubstructMatches 函数识别，可旋转键通过 CalcNumRotatableBonds 函数识别。扭转自由度数量始终大于或等于可旋转键数量。颜色表示条件概率：对于每个可旋转键数量（横轴），颜色显示具有给定扭转自由度数量（纵轴）的分子所占比例。单元格中的数字表示原始计数。

G.2 GEOM-DRUGS 数据集

本文还在 GEOM-DRUGS 数据集 (Axelrod 和 Gomez-Bombarelli, 2022) 上评估了模型。测试集取自 Torsional Diffusion (Jing 等人, 2022)，并排除了含有除 Br、C、Cl、F、H、I、N、O、P 和 S 以外元素的分子。从剩余分子中，针对 3 至 10 范围内每个可旋转键数量（由 RDKit 的 CalcNumRotatableBonds 函数计算），随机抽取 10 个分子。最小分子包含 19 个原子，最大分子包含 65 个原子，因此略大于 SPICE 数据集中的分子。

本文使用 GEOM-DRUGS 数据集中的构象作为评估参考。这些构象是




图 8 SPICE (左) 和 GEOM-DRUGS (右) 测试集中构象平均数量与可旋转键数量 (由 RDKit 的 CalcNumRotatableBonds 函数计算) 的关系。注意两图纵轴刻度不同。




图 9 SPICE (训练+测试) 数据集中出现的原子计数: (左) 总原子频率。(右) 仅重原子 (不包括氢) 的频率。我们的构象生成预测所有原子的位置。

表示为 RDKit 分子对象。为了使用与 SPICE 数据集相同的格式, 我们从 RDKit 分子中提取笛卡尔坐标, 并为每个分子写入 .xyz 文件。每个可旋转键数量的参考构象平均数量如图 8 右侧所示。

H 附加实验结果

H.1 合成能量实验的能量直方图

在本节中，我们提供了由合成能量基准生成的能量分布与通过真实 MCMC 采样获得的能量分布之间的额外定性比较。附录 H.1 展示了三个不同系统——DW4、LJ13 和 LJ55——的直方图。这些结果清楚地表明，伴随采样在避免高能区域方面更有效，尤其是在具有最高维能量表面的 LJ55 情况下。




图 10 合成能量基准的能量直方图叠加在真实 MCMC 生成的样本上。

H.2 分子构象生成的运行时间分析

本节通过分子构象生成任务的详细运行时间分析，进一步检验了我们提出的伴随采样技术的计算效率。

如图 11 所示，伴随采样克服了先前方法中的两个显著计算瓶颈，即密集随机微分方程仿真和昂贵的能量评估步骤。通过缓解这些挑战，本文方法能够在相同的执行时间内进行更多的梯度更新，从而在能量函数评估代价高昂的任务（如构象生成）中提升整体性能。




图 11 构象生成运行时间：在梯度更新层面，伴随采样与选定基线的运行时间分析分解。伴随采样克服了先前方法的两个主要瓶颈：随机微分方程仿真和能量评估，使伴随采样在相同运行时间内能够执行更多的梯度更新。

表 3 在 SPICE-MACE-OFF 测试数据集上, eSEN-900k 和 MACE-OFF-23-M 的测试集平均绝对误差。能量 (E) 平均绝对误差单位为毫电子伏特每原子。力 (F) 平均绝对误差单位为毫电子伏特每埃。

Model	PubChem		DES370K M.		DES370K D.		Dipeptides		Sol. AA		Water		QMugs	
	E	F	E	F	E	F	E	F	E	F	E	F	E	F
eSEN-900k	0.66	14.37	0.50	5.32	0.52	5.62	0.37	8.52	1.41	17.16	0.71	12.66	0.44	14.56
MACE-OFF-23-M	0.91	20.57	0.63	9.36	0.58	9.02	0.52	14.27	1.21	23.26	0.76	15.27	0.69	23.58

H.3 能量函数的选择 本文使用的 eSEN 能量模型 (Fu 等人, 2025) 已被证明能够在 SPICE 数据集上准确预测密度泛函理论能量和力。本文使用具有 2 层、 $L_{\max} = 2, M_{\max} = 0, 64$ 个通道和 4.5 埃半径截断的 eSEN 网络。该模型约有 90 万个可训练参数。为了证明伴随匹配算法对能量函数选择的鲁棒性, 本文使用预训练的 MACE-OFF-23 能量模型 (Batatia 等人, 2022; Kovács 等人, 2023) 进行了额外的分子构象采样实验。eSEN-900k 和 MACE-OFF-23-M (Kovács 等人, 2023) 模型的测试集预测误差报告于表 3。在适用的情况下, 弛豫和伴随采样优化使用相同的能量模型。表 4 显示, 使用 MACE-OFF-M 和 eSEN 的伴随匹配在生成分子构象方面取得了相似的性能。

表 4 使用不同能量模型进行构象生成的召回率和精确率度量。覆盖率阈值为 1.25 埃。标准差在测试集中的分子间计算。(这些实验使用早期版本的代码完成。)

		SPICE			
		Recall		Precision	
Method		Cov. $\uparrow$	AMR $\downarrow$	Cov. $\uparrow$	AMR $\downarrow$
eSEN		80.28 $\pm$ 27.68	0.96 $\pm$ 0.28	47.97 $\pm$ 32.24	1.25 $\pm$ 0.37
MACE		74.93 $\pm$ 30.36	1.02 $\pm$ 0.27	50.22 $\pm$ 32.22	1.28 $\pm$ 0.39
eSEN (+pretrain)		88.58 $\pm$ 19.96	0.85 $\pm$ 0.25	65.12 $\pm$ 29.90	1.13 $\pm$ 0.34
MACE (+pretrain)		89.62 $\pm$ 19.25	0.84 $\pm$ 0.25	67.07 $\pm$ 29.48	1.11 $\pm$ 0.34
w/ relaxation	eSEN	91.49 $\pm$ 18.27	0.71 $\pm$ 0.29	60.00 $\pm$ 29.97	1.02 $\pm$ 0.38
	MACE	91.06 $\pm$ 17.94	0.72 $\pm$ 0.28	65.19 $\pm$ 28.27	1.05 $\pm$ 0.37
	eSEN (+pretrain)	96.36 $\pm$ 8.92	0.60 $\pm$ 0.25	76.46 $\pm$ 26.22	0.92 $\pm$ 0.35
	MACE (+pretrain)	95.73 $\pm$ 11.32	0.61 $\pm$ 0.25	77.08 $\pm$ 25.73	0.92 $\pm$ 0.34

H.4 消融互反投影

这里我们展示了与表 1 中合成实验相同的互反投影消融，但针对分子构象生成任务。回顾一下，我们不是使用互反投影 (RP) 来采样 X_t 给定 X_1 ，而是简单地将样本对 (X_1, X_t) 存储在缓冲区中，并在伴随匹配目标 (12) 上进行训练。我们称之为无 RP 的伴随采样，这有助于证明互反投影的有效性。为了本次消融的目的，我们只考虑 MACE 能量，不进行任何生成后的弛豫。

表 5 使用和不使用互反投影 (RP) 的伴随采样的召回率和精确率度量。覆盖率值针对 1.25Å 的阈值。标准差是在测试集中的分子上计算的。我们看到互反投影在所有度量上都带来了显著的改进，尤其是在泛化到未见数据集 GEOM-DRUGS 时。生成后不进行预训练和弛豫。（这些实验是用代码的早期版本完成的。）

Method	SPICE				GEOM-DRUGS			
	Recall		Precision		Recall		Precision	
	Cov. $\uparrow$	AMR $\downarrow$	Cov. $\uparrow$	AMR $\downarrow$	Cov. $\uparrow$	AMR $\downarrow$	Cov. $\uparrow$	AMR $\downarrow$
Adjoint Sampling w/o RP (Ablation)	78.25 $\pm$ 30.06	0.98 $\pm$ 0.34	57.64 $\pm$ 32.00	1.23 $\pm$ 0.43	53.46 $\pm$ 36.17	1.30 $\pm$ 0.48	35.16 $\pm$ 33.60	1.74 $\pm$ 0.68
Adjoint Sampling (Ours)	80.28 $\pm$ 27.68	0.96 $\pm$ 0.28	47.97 $\pm$ 32.24	1.25 $\pm$ 0.37	61.36 $\pm$ 38.74	1.17 $\pm$ 0.60	41.19 $\pm$ 35.93	1.46 $\pm$ 0.67

H.5 分子构象生成的阈值消融




图 12 不同可旋转键数量的分子在弛豫后的覆盖率召回率 (%)。我们看到我们的模型与 RDKit 之间的差距随着可旋转键数量的增加而增大。