

动量多边际薛定谔桥匹配

Panagiotis Theodoropoulos¹, Augustinos D. Saravanos¹,
Evangelos A. Theodorou^{1,*}, Guan-Hong Liu^{2,*}

¹Georgia Institute of Technology, ²FAIR at Meta, *Equal advising

摘要

从稀疏样本快照推断轨迹以理解复杂系统，是单细胞生物学、气象学和经济学等广泛领域中的一项根本性挑战。尽管桥匹配和流匹配框架取得了进展，但当前方法依赖于相邻快照之间的成对插值。这阻碍了它们捕捉长程时间依赖性的能力，并可能影响所推断轨迹的连贯性。为了解决这些问题，我们提出了动量多边际薛定谔

桥接匹配 (3MSBM)，一种学习平滑匹配的新颖框架

用于满足多重位置约束的随机系统的测度值样条。通过将动力学提升至相空间，并将随机桥推广为以多个点为条件，形成多边际条件随机最优控制问题。随后，在固定由多边际条件桥诱导的路径后，通过最小化变分目标来学习底层动力学。作为一种匹配方法，3MSBM 学习在训练过程中保持中间边际的传输映射，显著提升了收敛性和可扩展性。在一系列实际应用中的大量实验验证了 3MSBM 在捕捉具有时间依赖性的复杂动力学方面优于现有方法，为在多边际环境中训练匹配框架开辟了新途径。

1 引言

在概率分布之间传输样本是机器学习中的一个基本问题。扩散模型 (Diffusion Models, DMs; [Ho et al., 2020, Song et al., 2020]) 是生成建模中的一项重要技术，它通过随机微分方程 (Stochastic Differential Equations, SDEs) 的随机映射将数据样本传输到一个易于处理的先验分布，然后学习逆转这一过程 [Anderson, 1982, Vincent, 2011]。然而，扩散模型存在一些局限性，例如，其生成的轨迹在动能方面缺乏最优性保证 [Shi et al., 2023]。为了解决这些不足，源于最优传输 (Optimal Transport) [Villani et al., 2009] 的原则性方法应运而生，旨在最小化在两个边缘分布之间映射样本的传输能量， π_0 和 π_1 。在这一脉络下，薛定谔桥 (Schrödinger Bridge, SB; [Schrödinger, 1931]) ——等价于熵正则化最优传输 (Entropic Optimal Transport, EOT; [Cuturi, 2013, Peyré et al., 2019]) ——已成为生成建模中最突出的方法之一 [Vargas et al., 2021]。这种流行得益于匹配方法近期显著的进展 [Lipman et al., 2022, Liu et al., 2022a]。至关重要的是，这些基于匹配的框架避免了缓存前向和后向 SDE 的完整轨迹的需要，减轻了早期 SB 技术中遇到的时间离散化和“遗忘”问题，并在整个训练过程中保持可行的传输映射。这使得它们成为训练 SB 的高度可扩展且稳定的方法 [Shi et al., 2023, Gushchin et al., 2024a, Peluchetti, 2023, Liu et al., 2024, Rapakoulias et al., 2024]。代码可在 <https://github.com/panostheo98/3MSBM> 获取

表 1: 我们的 3MSBM 与最先进的多边缘算法在 1) 无仿真训练、2) 平滑且连贯的轨迹以及 3) 全局最优耦合方面的比较。

	Simulation-Free Training	Smooth Trajectories	Global Coupling
DMSB [Chen et al., 2023a]	✗	✓	✓
MMFM [Rohbeck et al., 2024]	✓	✓	✗
SBIRR [Shen et al., 2024]	✓	✗	✗
MMSFM [Lee et al., 2025]	✓	✗	✗
Smooth SB [Hong et al., 2025]	✗	✓	✓
3MSBM (Ours)	✓	✓	✓

然而, 许多复杂的现实场景在粗时间间隔下提供独立的测量值 [Chen 等人, 2023a]。在这种情况下, 在相邻边缘分布之间求解多个不同的薛定谔桥问题并连接所得的桥, 会导致次优轨迹, 无法考虑时间依赖性, 也无法在不连续的情况下对动态进行建模 [Lavenant 等人, 2024]。为了解决这一问题, 考虑薛定谔桥问题的一种推广: 多边缘薛定谔桥 (mmSB) [Chen 等人, 2019], 其中动态被扩充到相空间。将速度纳入并与位置耦合, 可以得到在位置空间中穿越多个时间索引边缘分布的平滑轨迹 [Dockhorn et al., 2021, Chen 等人, 2023a], 如图 1 所示。这种方法使我们能够捕捉底层动态, 并更好地利用复杂系统 (如细胞动力学 [Yeo 等人, 2021; Zhang 等人, 2024a]、气象演化 [Franzke 等人, 2015] 和经济学 [Kazakevičius 等人, 2021]) 中信息丰富的数据。多边缘系统在现实应用中的广泛适用性, 激发了人们对开发解决这些问题的算法的浓厚兴趣。然而, 现有方法要么牺牲最优性以换取可扩展性, 要么反之。




图 1: 普通 SB 与我们的 3MSBM 之间的轨迹比较。

在方法谱系的一端, 许多近期方法在相邻边缘分布之间进行局部优化, 通常展现出显著的可扩展性, 但无法恢复全局耦合。例如, Shen 等人 [2024] 提出了一种免仿真的迭代方案, 通过成对桥优化进行轨迹推断来求解 mmSB。然而, 这种成对形式无法强制全局轨迹一致性, 因此依赖于信息丰富的先验, 限制了在实际场景中的实用性。类似地, 多边缘流匹配 [MMFM; Rohbeck 等人 [2024]] 使用确定性三次样条插值与预先计算的成对耦合, 损害了时间连贯性和动力学保真度。此外, MMFM 的随机对应方法 [多边缘随机流匹配 (MMSFM); Lee 等人 [2025]] 在重叠的边缘三元组上优化测度值样条, 改进了 MMFM 的成对方案; 然而, 缺乏全局耦合和一阶动力学仍然限制了平滑、时间连贯的轨迹。另一方面, 无需局部近似求解 mmSB 的方法可以恢复全局耦合, 但通常扩展性较差。深度动量多边缘薛定谔桥 [DMSB; Chen 等人 [2023a]] 使用 Bregman 迭代在相空间中求解全局 mmSB 耦合。然而, 由于需要缓存完整的 SDE 轨迹, 它面临可扩展性限制, 导致计算瓶颈、误差累积和潜在的不稳定性。最后, 将参考动力学建模为平滑高斯路径实现了时间连贯且平滑的轨迹 [Hong 等人, 2025], 尽管置信传播限制了在高维中的扩展。表 1 总结了这些方法的关键属性以及我们提出的方法论。

本文提出动量多边缘薛定谔桥匹配 (3MSBM), 一种新颖的可扩展匹配算法, 在相空间中求解多边缘薛定谔桥 (mmSB)。我们将动力学提升至相空间并最小化路径加速度, 从而得到平滑的低曲率轨迹。这保留了一阶模型中常丢失的趋势——在稀疏或不规则观测下尤为关键——并捕捉非线性转变和拐点, 实现更真实的插值。我们首先推导动量布朗桥, 得到遍历任意数量边缘的条件桥的闭式表达式。这消除了昂贵的数值积分需求, 提高了效率并避免了误差累积。所得条件路径——在随机最优控制下最优且满足所有位置边际约束——随后保持固定, 同时

我们将参数化漂移与预设轨迹进行匹配，从而实现无仿真的漂移学习。迭代这些步骤会收敛到全局最优的多边缘薛定谔桥耦合。在算法上，我们的 3MSBM 与其他匹配框架 [刘等人, 2024 年] 具有相似的属性，因为在整个优化过程中，模型诱导的边缘分布始终接近真实值，这与仅在收敛时才对齐目标的先前多边缘薛定谔桥求解器不同。实证结果验证了我们框架的效率和可扩展性，能够处理高维问题，并优于为处理多边缘设置而定制的最先进方法。我们的贡献总结如下：

- 我们提出 3MSBM，一种新颖的匹配算法，用于学习平滑插值，同时保持多个边际约束。
- 我们提出理论分析，将布朗桥的概念扩展到二阶系统，具备处理任意数量边际的能力。
- 与先前的多边缘薛定谔桥方法（例如 [陈等人, 2023a]）不同，我们的方法具有可证明的稳定收敛性，并给出一个在整个训练过程中满足边缘约束的映射。
- 大量实验表明，3MSBM 在输入数据维度和边际数量方面具有增强的可扩展性。

2 预备知识

2.1 薛定谔桥

薛定谔桥可以通过以下随机最优控制（SOC）公式获得，该公式试图在边缘分布 π_0, π_T 之间找到唯一的非线性随机过程 $x_t \in \mathbb{R}^d$ ，以最小化动能 [陈等人, 2016年]。

$$\min_{u_t, p_t} \int_0^T \mathbb{E}_{p_t} [\|u_t\|^2] dt \quad \text{s.t.} \quad dx_t = u_t dt + \sigma dW_t, \quad x_0 \sim \pi_0, \quad x_T \sim \pi_T \quad (1)$$

从而得到最优运输（Optimal Transport）中流体动力学表述的随机等价形式 [让蒂尔等人, 2017] [贝纳穆和布勒尼耶, 2000]。具体而言，式（1）的最优漂移生成了边缘分布 π_0 与 π_T 之间动态薛定谔桥（dynamic Schrödinger Bridge）的最优概率路径 p_t 。近年来，匹配算法的发展 [古什钦等人, 2024b, 德博尔托利等人, 2023] 促成了高效且可扩展的薛定谔桥匹配算法的诞生。将边缘概率路径 p_t 表示为端点条件桥的混合 $p_t = \int p_{t|0,T} d\pi_{0,T}(x_0, x_T)$ [莱昂纳尔, 2013]，启发了一种两步交替训练方案 [西奥多罗普洛斯等人, 2024]。第一步固定耦合 $\pi_{0,T}$ ，通过抽取样本对 (x_0, x_T) 并优化所抽取样本对之间的中间桥。随后，在给定的上一步规定的边缘路径下匹配参数化漂移 u_t^θ ，逐步细化由 u_t^θ 诱导的耦合。收敛时，这些步骤旨在构造一个随机过程，其耦合与薛定谔桥的静态解一致，即 $\pi_{0,T}^*$ ，并最优地插值耦合 $(x_0, x_1) \sim \pi_{0,T}^*$ 。

2.2 动量多边缘薛定谔桥

动量多边缘薛定谔桥（mmSB）扩展了式（1）中的目标，以穿越多个边缘约束。此外，动力学被提升为二阶，纳入速度（记为 $v_t \in \mathbb{R}^d$ ）以及位置 x_t 。因此，边缘分布也被增广 $\pi_n := \pi_n(x, v)$ ，对于 $n = \{0, 1, \dots, N\}$ ，因为它们同时依赖于位置 x_t 和速度 v_t 。我们定义联合边缘概率路径 $p_t(x_t, v_t)$ （对于 $t \in [0, T]$ ），以及位置和速度边缘分别为 $q_t(x) = \int p_t(x, v) dv$ 和 $\xi_t(v) = \int p_t(x, v) dx$ 。在相空间中应用吉尔萨诺夫定理（Girsanov theorem）得到相应的多边缘相空间随机最优控制公式 [Chen et al., 2019]

$$u_t^* = \begin{bmatrix} 0 \\ a_t^* \end{bmatrix} \in \arg \min_{u_t} \int \mathbb{E}_{p_t} [\|a_t\|^2] dt$$

$$dm_t = A m_t dt + u_t dt + g dW_t, \quad x_n \sim q_n = \int \pi_n(x, v) dv, \quad n = \{0, 1, \dots, N\}, \quad (2)$$

其中 $m_t = [x_t, v_t]^\top \in \mathbb{R}^{2d}$, $A = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}$, and $g = \begin{bmatrix} 0 & 0 \\ 0 & \sigma \end{bmatrix}$.

3 动量多边缘薛定谔桥匹配

我们提出了动量多边缘薛定谔桥匹配 (Momentum Multi-Marginal Schrödinger Bridge Matching, 3MSBM)，这是一种新颖的匹配框架，将速度纳入动力学中，为满足时间上位置边缘约束的随机系统学习光滑的测度值样条。遵循匹配框架的最新进展，我们的算法求解方程 (2)，将问题分解为两个部分：1) 以多边缘耦合为条件的中间路径优化，以及 2) 参数化漂移的优化，以细化耦合。

3.1 中间路径优化

我们的分析首先构建一个多边缘条件路径，该路径在稀疏区间上满足众多约束。具体而言，我们首先推导出相空间条件桥的最优控制表达式，该桥在 $\{\bar{m}_n\}$ 处被条件化，对于 $n \in \{0, 1, \dots, N\}$ 。基于这一最优控制表达式，我们随后得到一个递归公式，用于计算通过一组指定位置 $\bar{x}_n \sim q_n(x_n)$ 进行插值的条件加速度。我们将这组固定点记为 $\{\bar{x}_n\} := \{\bar{x}_0, \bar{x}_1, \dots, \bar{x}_N\}$ ，并将耦合记为 $q(\{x_n\})$ 。

定理 3.1 (多边缘动量布朗桥 (3MBB) 的 SOC 表示)。考虑以下在多个边缘之间进行插值的动量系统

$$\min_{a_t} \int_0^1 \frac{1}{2} \|a_t\|^2 dt + \sum_{n=1}^N (m_n - \bar{m}_n)^\top R (m_n - \bar{m}_n) \quad (3)$$

$$s.t. \quad dm_t = A m_t dt + u_t dt + g dW_t, \quad m_0 = \bar{m}_0 \quad (4)$$

We define the value function as $V_t(m_t) := \frac{1}{2} m_t^\top P^{-1} m_t + m_t^\top P^{-1} r_t$ 其中 P_t, r_t 分别是二阶和一阶近似。该公式允许以下最优控制表达式 $u_t^*(m_t) = -g g^\top P_t^{-1} (m_t + r_t)$ 。对于在 $\{t_n\}$ 处固定 $\{\bar{m}_n\}$ (对于 $n \in \{0, 1, \dots, N\}$) 的多边缘桥， P_t 和 r_t 的动力学满足以下后向常微分方程，且

$$\begin{aligned} \dot{P}_t &= A P_t + P_t A^\top - \sigma_t \sigma_t^\top, & P_n &= (P_{n+}^{-1} + R)^{-1}, & P_{N+} &= 0 \\ \dot{r}_t &= -A r_t, & r_n &= P_n (P_{n+}^{-1} r_{n+} - R \bar{m}_n) \end{aligned} \quad (5)$$

where $P_{n+} := \lim_{t \rightarrow t_n^+} P_t$, and $r_{n+} := \lim_{t \rightarrow t_n^+} r_t$, for $t \in \{s : s \in (t_1, t_2) \vee (t_2, t_3), \dots\}$.

本文提出的 3MBB 是对成熟的动量布朗桥概念的自然推广 [陈与乔治乌 (Chen and Georgiou), 2015]。对于多边缘桥的推导，我们应用动态规划原理，在每个分段中递归优化加速度，同时通过中间约束考虑后续分段，如图 2 所示。项 P_{n+} 和 r_{n+} 通过中间约束 P_n, r_n 捕捉后续分段的影响，这些约束作为下一分段相应常微分方程的终端条件。重要的是，从式 (5) 中的终端条件可以推出 r_t ——因此最优控制 u_t^* ——将依赖于 $t \in \{t_n : t_n \geq t\}$ 之后的所有后续固定点，如下一个命题中推导的加速度公式所明确展示。

Proposition 3.2. Let $R = \begin{bmatrix} \frac{1}{c} & 0 \\ 0 & c \end{bmatrix}$. At the limit when $c \rightarrow 0$, the solution of 3MBB (Th. 3.1) admits a closed-form expression on every segment; in particular, for $t \in [t_n, t_{n+1})$:

$$a_t^*(m_t | \{\bar{x}_{n+1} : t_{n+1} \geq t\}) = C_1^n(t)(x_t - \bar{x}_{n+1}) + C_2^n(t)v_t + C_3^n(t) \sum_{j=n+1}^N \lambda_j \bar{x}_j, \quad (6)$$

其中 $\{\bar{x}_{n+1} : t_{n+1} \geq t\}$ 表示桥接以随后点集为条件， λ_j 为静态系数， $C_1^n(t), C_2^n(t), C_3^n(t)$ 为各段特有的时变系数。证明、这些函数的定义以及 λ_j 系数值留待附录 B.2。

式 (6) 中的表达式提供了计算段 $t \in [t_n, t_{n+1})$ 最优条件桥接的递推公式。注意线性组合 $\sum_{j=n+1}^N \lambda_j \bar{x}_j$ 刻画了每段对 $t \in [t_n, t_{n+1})$ 之后所有后续固定点的依赖。




图 2: 动态原理的可视化。式 (5) 中的 P_t, r_t 向后求解, 通过中间约束将未来固定点的影响传播到前面的段中。

注 3.3. 重要的是, 式 (6) 中加速度的表达式明确表明, 最优桥接无需在中间边缘处收敛到预定义速度 $\bar{v}_n$ 。

随着中间状态代价中 $c \rightarrow 0$ 的变化, 联合变量 $\bar{m}_n$ 上的约束发生偏移, 以确保轨迹在时间 t_n 到达条件 $\bar{x}_n$, 而无需在中间点显式规定任何速度, 这与桥接匹配的原理一致。

Example - Bridge for 3 marginals To obtain the stochastic bridge of Eq. (3) between two marginals, i.e., $N = 2$, we consider the same value function approximation as in Th. 3.1, admitting the same optimal control law $u_t^*(m_t) = -\mathbf{g}\mathbf{g}^\top P_t^{-1}(m_t + r_t)$. For simplicity, let us assume $t_0 = 0, t_1 = 1$, and $t_2 = 2$. From Prop. 3.2, we obtain the following solution for conditional acceleration.

$$\begin{cases} a^*(m_t | \bar{x}_2) &= \frac{3}{(t-2)^2}(\bar{x}_2 - x_t) - \frac{3}{2-t}v_t, & t \in [1, 2) \\ a^*(m_t | \bar{x}_1, \bar{x}_2) &= \frac{30-18t}{(t-1)^2(3t-7)}(x_t - \bar{x}_1) + \frac{12(t-2)}{(t-1)(3t-7)}v_t + \frac{6}{(3t-7)}(\bar{x}_2 - \bar{x}_1), & t \in [0, 1) \end{cases} \quad (7)$$

注意在段 $t \in [0, 1)$ 中, 式 (6) 中线性组合 $\sum_{n=1}^2 \bar{x}_j$ 的 λ 系数为: $\lambda_1 = -1, \lambda_2 = 1$, 而对于 $t \in [1, 2]$, 唯一系数为 $\lambda = 0$ 。附录 B.2 给出了更多边缘条件下条件加速度的示例, 展示了函数 $C_1^n(t), C_2^n(t), C_3^n(t)$ 的依赖性以及 λ_j 系数值对后续边缘数量的依赖。图 3 描绘了 3 个固定点之间的不同实现, 说明了桥接向条件点的收敛。




图 3: 3 个固定点之间的桥接实现。

3.2 动量系统的桥接匹配

随后, 在对三维最小包围盒 (3MBB) 进行优化之后, 我们根据给定的条件概率路径 $p(m_t | \{\bar{x}_n : t_n \geq t\})$ (由加速度 $a^*(m_t | \{\bar{x}_n : t_n \geq t\})$ 诱导) 来匹配参数化加速度 a_t^θ 。鉴于三维最小包围盒是针对每一组点 $\{x_n\}$ 求解的, 我们可以通过边缘化来构建边缘路径 p_t 。

命题 3.4. 将边际路径 p_t 定义为桥的混合 $p_t(m_t) = \int p(m_t | \{\bar{x}_n : t_n \geq t\}) dq(\{x_n\})$, 其中 $p(m_t | \{\bar{x}_n : t_n \geq t\})$ 是与式 6 中 3MBB 路径的解相关联的条件概率路径。满足由

p_t 规定的福克-普朗克方程的参数化加速度由下式给出

$$a_t(t, m_t) = \frac{1}{p_t} \int a_t | \{\bar{x}_n\} p_t | \{\bar{x}_n\} (m_t | \{\bar{x}_n : t_n \geq t\}) dq(\{x_n\}) \quad (8)$$

这表明, 在给定 p_t 的情况下, 通过最小化变分间隙以匹配 a_t^θ , 可得到

$$\min_{\theta} \mathbb{E}_{q(\{x_n\})} \mathbb{E}_{p_t | \{\bar{x}_n\}} \left[\int_0^1 \|a_t | \{\bar{x}_n\} - a_t^\theta\|^2 dt \right] \quad (9)$$

将参数化漂移与给定路径 p_t 进行匹配, 可得到更精细的耦合 $q(\{x_n\})$, 该耦合将用于下一次迭代中的条件路径优化。系统的线性特性意味着我们可以高效地从条件中采样 $m_t = [x_t, v_t], \forall t \in [0, T]$ 。

Algorithm 1 Momentum Multi-Marginal Schrödinger Bridge Matching (3MSBM)

```

1: Input: Marginals  $q(x_0), q(x_1), \dots, q(x_N), R, \sigma, K, T$ 
2: Initialize  $a_t^\theta, q(\{x_n\}) := q(x_0) \otimes q(x_1) \otimes \dots \otimes q(x_N)$ , and  $v_0 \sim \mathcal{N}(0, I)$ 
3: repeat
4:   for  $j = 0$  to  $J$  do
5:     Calculate  $a_{t|\{\bar{x}_n\}}$  using Eq. (6) for  $t$  from 0 to  $T$ 
6:      $v_N \leftarrow \text{sdeint}(x_0, v_0, a_{t|\{x_n\}}, \sigma, K, T)$ 
7:     Calculate  $a_{t|\{\bar{x}_n\}}$  using Eq. (6) for  $t$  from  $T$  to 0
8:      $v_0 \leftarrow \text{sdeint}(x_N, v_N, a_{t|\{\bar{x}_n\}}, \sigma, K, T)$ 
9:   end for
10:  Update  $a_t^\theta$ , from Eq. (9) using  $a_{t|\{\bar{x}_n\}}$ 
11:  Sample new  $x_0, x_1, \dots, x_N$  from  $a_t^\theta$ 
12: until converges

```

概率路径 $p_{t|\{\bar{x}_n\}} = \mathcal{N}(\mu_t, \Sigma_t)$ ，因为均值向量 μ_t 和协方差矩阵 Σ_t 具有解析解 [Särkkä 与 Solin, 2019]。更明确地说，我们可以通过以下方式构造 m_t

$$m_t = \begin{bmatrix} X_t \\ V_t \end{bmatrix} = \begin{bmatrix} \mu_t^x \\ \mu_t^v \end{bmatrix} + \begin{bmatrix} L_t^{xx} \epsilon_0 \\ L_t^{xv} \epsilon_0 + L_t^{vv} \epsilon_1 \end{bmatrix}, \quad \text{其中 } \epsilon_0, \epsilon_1 \sim \mathcal{N}(0, \mathbf{I}_d) \text{ 和 } L_t = \begin{bmatrix} L_t^{xx} & L_t^{xv} \\ L_t^{xv} & L_t^{vv} \end{bmatrix} \quad (10)$$

其中 L_t 是根据协方差矩阵的 Cholesky 分解计算得到的。均值向量和协方差矩阵的表达式见附录 C。在本节末尾，我们对本文方法论进行理论分析，通过迭代优化式 (3) 和式 (9)，收敛到唯一的边际薛定谔桥解。




图 4: 利用最优条件加速度迭代传播动力学，以近似中间边缘处的速度剖面 $\pi_n(v_n|x_n)$ 。

收敛 我们建立了交替方案——在插值路径优化与耦合细化之间——到唯一 mmSB 解的收敛性。令 $\mathbb{P}$ 表示与学习动力学相关的路径测度， $\mathbb{P}^i$ 表示算法第 i^{th} 次迭代时学习动力学的路径测度。

定理 3.5. 在温和假设下，本文的迭代格式存在不动点解 $\mathbb{P}^*$, i.e., $\text{KL}(\mathbb{P}|\mathbb{P})$ ，特别地，该不动点与唯一的 $\mathbb{P}^*$ 重合。

本文针对文献 [史等人, 2023] 中的收敛性证明提出了一种替代性论断。基于最优控制原理和 KL 散度的单调性，本文将式 (2) 表示为 KL 散度，并借助吉尔萨诺夫定理 (Girsanov Theorem) [陈等人, 2019] 建立了向全局极小值的收敛性。

3.3 训练方案

我们的训练流程总结见算法 1。交替匹配算法的第一步是计算条件多边际桥，固定参数化耦合 $q^\theta(\{x_n\})$ 并采样点集 $\{x_n\} \sim q^\theta(\{x_n\})$ 。此外，需要初始速度分布 $v_0 \sim \xi_0(v) = \int \pi_0(x, v) dx$ ，这在大多数应用中实际上是未知的。为解决此问题，遵循 [陈等人, 2023a]，我们初始化速度 $v_0 \sim \mathcal{N}(0, I)$ ，并利用式 (6) 中的条件加速度对给定样本迭代传播动力学 (算法 1 第 4-9 行)。这通过类朗之万动力学近似真实条件分布 $\pi_n(v_n|x_n)$ 。值得注意的是，该过程仅需少量迭代 (实验中至多 ~ 10 次)，且不涉及反向传播，因此即使在高维情况下也几乎不增加计算成本。这种迭代传播得到式 (6) 中的最优条件加速度，从而诱导出最优条件路径。对每组 $\{\bar{x}_n\}$ 求解 3MBB 使我们能够边缘化并构建边缘路径 p_t 。随后，我们固定边缘路径，匹配参数化加速度 $a_t^\theta(t, m_t)$ ，最小化式 (9) 中的变分目标。该优化通过式 (2) 中的增广 SDE 传播动力学，诱导出精化的联合分布 $q^\theta(\{x_n\})$ ，该分布将用于下一次训练迭代的第一步。




图 5: SBIRR、MMFM、平滑 SB 与本文 3MSBM 在 LV 上的轨迹比较。




图 6: SBIRR、MMFM、平滑 SB 与本文 3MSBM 在 GoM 上的轨迹比较。

表 2: 在 5 个随机种子下，留出边缘分布上的切片沃瑟斯坦距离 (SWD) 的均值和标准差，以及来自训练集其余点的平均 SWD，针对 LV 数据，比较 MIOFlow、SBIRR、MMFM、平滑 SB 和 3MSBM (越低越好)。

Method	SWD t_1	SWD t_3	SWD t_5	SWD t_7	Rest SWD
MIOFlow	1.53 ± 0.13	1.49 ± 0.09	1.22 ± 0.07	1.46 ± 0.06	0.93 ± 0.04
SBIRR	0.17 ± 0.03	0.16 ± 0.03	0.24 ± 0.03	0.48 ± 0.05	0.18 ± 0.02
MMFM	0.21 ± 0.02	0.25 ± 0.02	0.39 ± 0.03	0.57 ± 0.05	0.22 ± 0.01
DMSB	0.64 ± 0.06	0.67 ± 0.06	0.98 ± 0.07	0.63 ± 0.04	0.43 ± 0.04
Smooth SB	0.29 ± 0.03	0.18 ± 0.02	0.11 ± 0.02	0.37 ± 0.03	0.23 ± 0.02
3MSBM	0.23 ± 0.02	0.13 ± 0.01	0.15 ± 0.02	0.36 ± 0.03	0.18 ± 0.02

4 实验

我们通过实验验证了所提方法在计算和性能上的优势。本文算法的免仿真训练方案避免了昂贵的数值仿真和近似误差，这与先前匹配方法所观察到的优势一致 [史等人, 2023, 刘等人, 2024]。因此，本文算法能够在保持准确率的同时具备高可扩展性，如下述实验所示。我们在合成和真实世界的轨迹推断任务上评估了 3MSBM 的性能，包括 Lotka-Volterra (第 4.1 节)、墨西哥湾洋流 (第 4.2 节)、单细胞测序 (第 4.4 节) 以及北京空气质量数据 (第 4.3 节)。我们将所提方法与专门设计用于处理多边际设置的最先进方法进行了比较，例如深度动量多边际薛定谔桥 (DMSB; Chen et al. [2023a])、迭代参考精化薛定谔桥 (SBIRR; Shen et al. [2024])、平滑薛定谔桥 (smoothSB; Hong et al. [2025]) 和多边际流匹配 (MMFM; Rohbeck et al. [2024])，并与一种额外的基于神经微分方程的方法 MIOFlow [于盖等人, 2022] 进行了比较，在所有数据集上使用相同的度量：切片 Wasserstein 距离 (SWD)。这些任务的额外结果——包括更多度量和基线——见附录 E。

4.1 Lotka-Volterra

我们首先考虑由洛特卡-沃尔泰拉 (Lotka - Volterra, LV) 方程 [戈尔等人, 1971年] 生成的合成数据集，该方程通过耦合非线性动力学对捕食者-猎物相互作用进行建模。生成的数据集总共包含 9 个边际分布；偶数索引用于训练模型 (即 t_0, t_2, t_4, t_6, t_8)，其余时间点用于评估模型对缺失时间点进行插补和推断的有效性。在本实验中，我们将 3MSBM 与 MIOFlow、SBIRR、MMFM、DMSB 和 Smooth SB 进行了基准比较。性能通过验证边际分布的 SWD 距离来衡量插补准确率，并通过训练边际分布的 SWD 距离来评估各方法在生成过程中保持观测数据的程度。表 2 和图 5 的结果表明，3MSBM 在推断缺失点处的边际分布方面优于基线模型，对大多数留出边际分布的偏差最小，同时生成的轨迹更忠实地保持了训练边际分布，这体现在训练集剩余点上更低的平均 SWD 距离。更多结果 (包含更多度量和基线) 见附录 E.2。

表 3: 在 GoM 数据集上, MIOFlow、SBIRR、MMFM、DMSB、Smooth SB 和 3MSBM 的 SWD 距离在 5 个随机种子上的均值和标准差 (越低越好)。

Method	SWD t_1	SWD t_3	SWD t_5	SWD t_7	Rest SWD
MIOFlow	0.83 $\pm$ 0.06	0.34 $\pm$ 0.03	1.23 $\pm$ 0.09	0.96 $\pm$ 0.06	0.19 $\pm$ 0.03
SBIRR	0.15 $\pm$ 0.03	0.11 $\pm$ 0.02	0.11 $\pm$ 0.03	0.09 $\pm$ 0.04	0.13 $\pm$ 0.04
MMFM	0.23 $\pm$ 0.04	0.25 $\pm$ 0.08	0.10 $\pm$ 0.03	0.19 $\pm$ 0.04	0.14 $\pm$ 0.03
DMSB	0.22 $\pm$ 0.02	0.54 $\pm$ 0.04	0.39 $\pm$ 0.02	0.28 $\pm$ 0.04	0.09 $\pm$ 0.03
Smooth SB	0.17 $\pm$ 0.02	0.14 $\pm$ 0.04	0.10 $\pm$ 0.02	0.13 $\pm$ 0.02	0.08 $\pm$ 0.01
3MSBM	0.14 $\pm$ 0.02	0.14 $\pm$ 0.02	0.08 $\pm$ 0.01	0.06 $\pm$ 0.01	0.05 $\pm$ 0.01

表 4: 在北京空气质量数据集上, MMFM、DMSB 和 3MSBM 的 SWD 距离在 5 个随机种子上的均值和标准差 (越低越好)。

Method	SWD t_2	SWD t_5	SWD t_8	SWD t_{11}	Rest SWD
MMFM	17.51 $\pm$ 2.41	23.94 $\pm$ 1.97	32.56 $\pm$ 2.96	39.98 $\pm$ 3.59	30.25 $\pm$ 2.17
DMSB	21.10 $\pm$ 2.65	21.92 $\pm$ 1.78	35.53 $\pm$ 3.82	35.75 $\pm$ 4.13	33.42 $\pm$ 2.42
3MSBM(ours)	17.70 $\pm$ 1.93	9.78 $\pm$ 1.58	22.23 $\pm$ 3.64	32.23 $\pm$ 3.76	21.25 $\pm$ 1.63

表 5: 在拟胚体 (Embryoid Body, EB) 数据集上, SBIRR、MMFM、DMSB 和 3MSBM 的 MMD 和 SWD 在 5 个随机种子上的均值和标准差 (越低越好)。

Method	MMD t_1	SWD t_1	MMD t_3	SWD t_3	Rest MMD	Rest SWD
SBIRR	0.71 $\pm$ 0.08	0.80 $\pm$ 0.06	0.73 $\pm$ 0.06	0.91 $\pm$ 0.05	0.47 $\pm$ 0.05	0.66 $\pm$ 0.07
MMFM	0.37 $\pm$ 0.02	0.59 $\pm$ 0.04	0.35 $\pm$ 0.04	0.76 $\pm$ 0.04	0.22 $\pm$ 0.02	0.52 $\pm$ 0.07
DMSB	0.38 $\pm$ 0.04	0.58 $\pm$ 0.06	0.36 $\pm$ 0.07	0.54 $\pm$ 0.06	0.14 $\pm$ 0.03	0.45 $\pm$ 0.04
3MSBM(ours)	0.18 $\pm$ 0.01	0.48 $\pm$ 0.04	0.14 $\pm$ 0.04	0.38 $\pm$ 0.03	0.11 $\pm$ 0.02	0.36 $\pm$ 0.05

4.2 墨西哥湾

随后, 我们评估了模型在真实世界多边际数据集中推断缺失时间点的有效性。该数据集包含墨西哥湾 (Gulf of Mexico, GoM) 涡旋周围速度场的洋流快照。它总共包含 9 个边际, 其中偶数索引的时间点 (i.e., t_0, t_2, t_4, t_6, t_8 用于训练, 其余时间点被留出以评估模型填补和推断缺失时间状态的能力。在本实验中, 我们将 3MSBM 与 MIOFlow、SBIRR、MMFM、DMSB 和 Smooth SB 进行了比较。用于评估性能的度量包括: 与留出点的 SWD 距离, 以及与训练点的 SWD 距离均值, 用以衡量各算法生成的轨迹在多大程度上保持了构成训练集的边际。图 6 显示, 3MSBM 生成了更平滑的轨迹, 并且更准确地恢复了留出的边际。相比之下, SBIRR 产生的轨迹噪声更大且存在弯折; MMFM 难以捕捉动态, 导致与留出边际的偏差更大; 而 Smooth SB 在基线方法中实现了最平滑的轨迹。表 3 进一步证实了这些观察结果, 其中 3MSBM 在大多数验证点上取得了最低的 SWD 距离, 并且更好地保持了训练边际。更多结果见附录 E.3。

4.3 北京空气质量

为进一步研究 3MSBM 有效推断缺失值的能力, 本文还在北京多站点空气质量数据集 [Chen, 2017] 上进行了测试。该数据集包含北京市 12 个空气质量监测站点的逐时空气污染物数据。本文关注 PM2.5 数据, 该指标监测直径小于 2.5 微米的颗粒物密度, 时间范围为 2013 年 1 月至 2015 年 1 月, 覆盖 12 个监测站点。本文采用了与 Rohbeck 等人 [2024] 略有不同的设置。本文聚焦于单一监测站点, 并将同月内收集的测量值进行聚合。为在观测之间引入时间分离, 本文每隔一个月选取测量值, 得到 13 个时间快照。对于插补任务, 本文省略了 t_2, t_5, t_8 和 t_{11} 处的数据, 其余快照构成训练集。本文将 3MSBM 方法与使用三次样条的 MMFM 以及 DMSB 进行了基准比较。表 4 显示, 3MSBM 总体上取得了更好的插补准确率, 产生了最小的切片 Wasserstein 距离 (SWD), 同时与基线相比, 更好地保留了由训练快照构成的边缘分布。更多度量指标的额外细节和结果见附录 E.4。




图 7: 在 100 维 PCA 特征空间上, SBIRR、MMFM、DMSB 和 3MSBM 之间 EB 数据集演化的比较。




图 8: 基于 GoM 流的条件桥, 左: 1 个固定点, 右: 4 个固定点。




图 9: 不同固定点数量下, 留出边缘分布的平均 W_2 距离。




图 10: 固定点数量增加时 $|\lambda_j|$ 系数的指数衰减。

4.4 单细胞测序

最后, 我们展示了 3MSBM 在高维空间中推断轨迹的有效性。具体而言, 我们使用了拟胚体 (Embryoid Body, EB) 干细胞分化追踪数据集, 该数据集在 27 天的时间内追踪了细胞经过 5 个阶段的过程。细胞快照在五个离散的时间间隔收集: $t_0 \in [0, 3]$, $t_1 \in [6, 9]$, $t_2 \in [12, 15]$, $t_3 \in [18, 21]$, $t_4 \in [24, 27]$ 。训练集由偶数索引的时间步组成 (即 t_0, t_2, t_4) , 其余用作验证集。我们使用了由 [Tong 等人, 2020, Moon 等人, 2019] 提供的预处理数据集, 该数据集嵌入在 100 维主成分分析 (PCA) 特征空间中。我们将 3MSBM 与 SBIRR、MMFM 和 DMSB 进行比较, 使用切片瓦瑟斯坦距离 (Sliced Wasserstein Distance, SWD) ——与先前任务相同——以及额外的最大均值差异 (Maximum Mean Discrepancy, MMD) 来评估性能。与之前的实验一样, 我们评估了插补边缘分布的质量以及训练边缘分布的保持情况。如表 5 所示, 3MSBM 在所有度量上始终优于现有方法, 实现了显著更准确的缺失时间点插补, 并恢复了与真实情况紧密匹配的群体动态, 如图 7 所示。虽然 DMSB 也生成了准确的 PCA 重建 (图 7), 但值得注意的是, 它所需的训练时间大约是 3MSBM 的 2.5 倍。DMSB 与 3MSBM 之间资源需求差异的详细比较在第 4.6 节中给出。进一步的单细胞测序设置和扩展结果, 包括额外的基线和更多度量, 推迟到附录 E.5。

4.5 关于固定点数量的消融研究

我们通过修改线性组合来消融式 (6) 中使用的固定点数量, 如下所示: $\sum_{j=n}^K \lambda_j \bar{x}_j$, 从 $K = n + 1$ 开始, 即仅包含最近的固定点, 并逐步增加至 $K = N$ 。图 14 表明, 与仅使用下一个点相比, 纳入多个固定点能显著提升在 GoM 数据集上的性能, 从而更好地推断底层动态, 如图 8 所示, 尽管这些收益在超过 $K = n + 3$ 后趋于平稳。这一现象进一步由图 10 中系数 $|\lambda_j|$ 随数量增加呈指数衰减所解释, 因此远处的点可忽略不计。注意, 对于使用接下来 2 个固定点的桥, 如第 3.1 节所述, 有 $|\lambda_1| = |\lambda_2| = 1$ 成立。因此, 实际实现可以采用截断的条件策略, 仅考虑接下来的 k 个固定点, 从而在不牺牲准确率的情况下显著提高效率。




图 11: 3MSBM 与 DMSB 的训练时间百分比 (%) 比较




图 12: 3MSBM 与 DMSB 的已分配内存百分比 (%) 比较

表 6: 增加边缘分布 N 时的每轮训练时间 (秒) 及百分比变化 [%]。

Num. of marginals	3	4	5
Time [s]	773	789	812
Percent Increase [%]	–	2.1	5.1

表 7: 3MSBM 与桥匹配所花费的时间百分比。

Dataset	Cond. Bridge	Bridge Matching
EB-100	3.3%	96.7%
GoM	7.4%	92.6%

4.6 3MSBM 的可扩展性

我们通过实验证明了 3MSBM 的可扩展性。值得注意的是，基于匹配的训练利用 3MSBM (式 6) 的闭式条件桥——无需数值积分——消除了计算开销和近似误差。

计算资源 由于三维薛定谔桥匹配 (3MSBM) 与动态薛定谔桥 (DMSB) 解决的是同一问题，即公式 2 中的多边际薛定谔桥 (mmSB) 问题，但采用了不同的训练方案（分别为基于匹配的方案和基于迭代比例拟合的方案），我们报告了每种方法所需的资源。具体而言，图 11 和图 12 表明，我们的 3MSBM 在每个数据集上的实际运行时间都更快，同时所需内存也显著更少——能够轻松处理高维单细胞测序任务。

关于边际数量的消融研究 接下来，在 EB-100 和 GoM 上对边际数量进行消融，即在保持所有其他超参数（如函数评估次数、批大小、模型规模）不变的情况下，增加边际总数 N ，并报告每轮训练时间。表 6 显示，改变 N 对每轮训练时间的影响可以忽略不计，这表明 3MSBM 在边际数量方面具有良好的可扩展性。这种不敏感性源于我们的算法设计，因为条件桥步骤的解析形式与 N 无关，这一点至关重要。

三维边际桥 (3MSBM) 与匹配方法的比较 最后，我们展示了在 EB-100 任务中，算法两个步骤各自所占时间百分比的分解：i) 条件动力学的迭代传播（算法 1 第 4-9 行）和 ii) 桥匹配步骤（算法 1 第 10 行）。表 7 表明，由条件动力学迭代传播引入的计算复杂度与桥匹配步骤相比仍然可以忽略不计。

5 结论与局限性

在这项工作中，我们开发了 3MSBM，这是一种新颖的匹配算法，能够从多快照数据集中推断出时间上连贯的轨迹，在高维设置和大量边际条件下表现出强大的性能。我们的工作为从稀疏时间观测中学习动态过程开辟了新途径，解决了跨多个学科的普遍挑战。例如，在单细胞生物学中，我们只能获得数据快照，而我们的 3MSBM 提供了一种有原则的方法来重建未观测到的轨迹，从而为基因调控、分化和药物反应提供洞见。虽然 3MSBM 在可扩展性方面显著优于现有的多边际方法，但仍存在一些局限性。特别是，它在密集采样的高维图像空间（如视频插值中遇到的空间）中的有效性尚未得到探索。作为未来工作，我们旨在扩展该方法以捕捉大规模图像设置中的长期依赖关系。

致谢

作者谨向陈天荣 (Tianrong Chen) 致以诚挚谢意, 感谢其富有成效的讨论与深刻见解, 这些交流为本文研究方向的确定提供了重要帮助。本研究部分由美国国防高级研究计划局 (DARPA) 人工智能量子 (AIQ) 项目资助, 合同编号为 HR00112520010。感谢 AIQ 项目经理帕特·沙夫托 (Pat Shafto) 博士提出的宝贵技术讨论。奥古斯丁诺斯·萨拉瓦诺斯 (Augustinos Saravanos) 感谢奥纳西斯基基金会 (A. Onassis Foundation) 奖学金提供的经济支持。

参考文献

- Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. *Advances in neural information processing systems*, 33:6840–6851, 2020.
- Yang Song, Jascha Sohl-Dickstein, Diederik P Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole. Score-based generative modeling through stochastic differential equations. *arXiv preprint arXiv:2011.13456*, 2020.
- Brian DO Anderson. Reverse-time diffusion equation models. *Stochastic Processes and their Applications*, 12(3):313–326, 1982.
- Pascal Vincent. A connection between score matching and denoising autoencoders. *Neural computation*, 23(7):1661–1674, 2011.
- Yuyang Shi, Valentin De Bortoli, Andrew Campbell, and Arnaud Doucet. Diffusion schrödinger bridge matching, 2023.
- Cédric Villani et al. *Optimal transport: old and new*, volume 338. Springer, 2009.
- Erwin Schrödinger. *Über die umkehrung der naturgesetze*. Verlag der Akademie der Wissenschaften in Kommission bei Walter De Gruyter u . . . , 1931.
- Marco Cuturi. Sinkhorn distances: Lightspeed computation of optimal transport. *Advances in neural information processing systems*, 26, 2013.
- Gabriel Peyré, Marco Cuturi, et al. Computational optimal transport: With applications to data science. *Foundations and Trends® in Machine Learning*, 11(5-6):355–607, 2019.
- Francisco Vargas, Pierre Thodoroff, Austen Lamacraft, and Neil Lawrence. Solving schrödinger bridges via maximum likelihood. *Entropy*, 23(9):1134, 2021.
- Yaron Lipman, Ricky TQ Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow matching for generative modeling. *arXiv preprint arXiv:2210.02747*, 2022.
- Xingchao Liu, Lemeng Wu, Mao Ye, and Qiang Liu. Let us build bridges: Understanding and extending diffusion generative models, 2022a.
- Nikita Gushchin, Sergei Kholkin, Evgeny Burnaev, and Alexander Korotin. Light and optimal schrödinger bridge matching. In *Forty-first International Conference on Machine Learning*, 2024a.
- Stefano Peluchetti. Diffusion bridge mixture transports, schrödinger bridge problems and generative modeling. *Journal of Machine Learning Research*, 24(374):1–51, 2023.
- Guan-Horng Liu, Yaron Lipman, Maximilian Nickel, Brian Karrer, Evangelos A Theodorou, and Ricky TQ Chen. Generalized Schrödinger bridge matching. In *International Conference on Learning Representations*, 2024.
- George Papakoulias, Ali Reza Pedram, Fengjiao Liu, Lingjiong Zhu, and Panagiotis Tsiotras. Go with the flow: Fast diffusion for gaussian mixture models. *arXiv preprint arXiv:2412.09059*, 2024.
- Tianrong Chen, Guan-Horng Liu, Molei Tao, and Evangelos Theodorou. Deep momentum multi-marginal schrödinger bridge. *Advances in Neural Information Processing Systems*, 36:57058–57086, 2023a.

- Hugo Lavenant, Stephen Zhang, Young-Heon Kim, Geoffrey Schiebinger, et al. Toward a mathematical theory of trajectory inference. *The Annals of Applied Probability*, 34(1A):428–500, 2024.
- Yongxin Chen, Giovanni Conforti, Tryphon T Georgiou, and Luigia Ripani. Multi-marginal schrödinger bridges. In *International Conference on Geometric Science of Information*, pages 725–732. Springer, 2019.
- Tim Dockhorn, Arash Vahdat, and Karsten Kreis. Score-based generative modeling with critically-damped langevin diffusion. *arXiv preprint arXiv:2112.07068*, 2021.
- Grace Hui Ting Yeo, Sachit D Saksena, and David K Gifford. Generative modeling of single-cell time series with prescient enables prediction of cell trajectories with interventions. *Nature communications*, 12(1):3222, 2021.
- Jiaqi Zhang, Erica Larschan, Jeremy Bigness, and Ritambhara Singh. scnode: generative model for temporal single cell transcriptomic data prediction. *Bioinformatics*, 40(Supplement_2):ii146–ii154, 2024a.
- Christian LE Franzke, Terence J O’Kane, Judith Berner, Paul D Williams, and Valerio Lucarini. Stochastic climate theory and modeling. *Wiley Interdisciplinary Reviews: Climate Change*, 6(1): 63–78, 2015.
- Rytis Kazakevičius, Aleksejus Kononovicius, Bronislovas Kaulakys, and Vygintas Gontis. Understanding the nature of the long-range memory phenomenon in socioeconomic systems. *Entropy*, 23(9):1125, 2021.
- Yunyi Shen, Renato Berlinghieri, and Tamara Broderick. Multi-marginal schrödinger bridges with iterative reference refinement. *arXiv preprint arXiv:2408.06277*, 2024.
- Martin Rohbeck, Edward De Brouwer, Charlotte Bunne, Jan-Christian Huetter, Anne Biton, Kelvin Y Chen, Aviv Regev, and Romain Lopez. Modeling complex system dynamics with flow matching across time and conditions. In *The Thirteenth International Conference on Learning Representations*, 2024.
- Justin Lee, Behnaz Moradijamei, and Heman Shakeri. Multi-marginal stochastic flow matching for high-dimensional snapshot data at irregular time points. *arXiv preprint arXiv:2508.04351*, 2025.
- Wanli Hong, Yuliang Shi, and Jonathan Niles-Weed. Trajectory inference with smooth schrödinger bridges. *arXiv preprint arXiv:2503.00530*, 2025.
- Yongxin Chen, Tryphon T Georgiou, and Michele Pavon. On the relation between optimal transport and schrödinger bridges: A stochastic control viewpoint. *Journal of Optimization Theory and Applications*, 169:671–691, 2016.
- Ivan Gentil, Christian Léonard, and Luigia Ripani. About the analogy between optimal transport and minimal entropy. In *Annales de la Faculté des sciences de Toulouse: Mathématiques*, volume 26, pages 569–600, 2017.
- Jean-David Benamou and Yann Brenier. A computational fluid mechanics solution to the monge-kantorovich mass transfer problem. *Numerische Mathematik*, 84(3):375–393, 2000.
- Nikita Gushchin, Daniil Selikhanovych, Sergei Kholkin, Evgeny Burnaev, and Alexander Korotin. Adversarial schrödinger bridge matching. *arXiv preprint arXiv:2405.14449*, 2024b.
- Valentin De Bortoli, Guan-Horng Liu, Tianrong Chen, Evangelos A Theodorou, and Weillie Nie. Augmented bridge matching. *arXiv preprint arXiv:2311.06978*, 2023.
- Christian Léonard. A survey of the schrödinger problem and some of its connections with optimal transport. *arXiv preprint arXiv:1308.0215*, 2013.
- Panagiotis Theodoropoulos, Nikolaos Komianos, Vincent Pacelli, Guan-Horng Liu, and Evangelos A Theodorou. Feedback schrödinger bridge matching. *arXiv preprint arXiv:2410.14055*, 2024.

- Yongxin Chen and Tryphon Georgiou. Stochastic bridges of linear systems. *IEEE Transactions on Automatic Control*, 61(2):526–531, 2015.
- Simo Särkkä and Arno Solin. *Applied stochastic differential equations*, volume 10. Cambridge University Press, 2019.
- Guillaume Huguët, Daniel Sumner Magruder, Alexander Tong, Oluwadamilola Fasina, Manik Kuchroo, Guy Wolf, and Smita Krishnaswamy. Manifold interpolating optimal-transport flows for trajectory inference. *Advances in neural information processing systems*, 35:29705–29718, 2022.
- Narendra S Goel, Samaresh C Maitra, and Elliott W Montroll. On the volterra and other nonlinear models of interacting populations. *Reviews of modern physics*, 43(2):231, 1971.
- S Chen. Beijing multi-site air quality. uci machine learning repository, 2017.
- Alexander Tong, Jessie Huang, Guy Wolf, David Van Dijk, and Smita Krishnaswamy. Trajectorynet: A dynamic optimal transport network for modeling cellular dynamics. In *International conference on machine learning*, pages 9526–9536. PMLR, 2020.
- Kevin R Moon, David Van Dijk, Zheng Wang, Scott Gigante, Daniel B Burkhardt, William S Chen, Kristina Yim, Antonia van den Elzen, Matthew J Hirn, Ronald R Coifman, et al. Visualizing structure and transitions in high-dimensional biological data. *Nature biotechnology*, 37(12):1482–1492, 2019.
- Valentin De Bortoli, James Thornton, Jeremy Heng, and Arnaud Doucet. Diffusion schrödinger bridge with applications to score-based generative modeling. *Advances in Neural Information Processing Systems*, 34:17695–17709, 2021.
- Tianrong Chen, Guan-Horng Liu, and Evangelos A Theodorou. Likelihood training of schrödinger bridge using forward-backward sdes theory. *arXiv preprint arXiv:2110.11291*, 2021.
- Michele Pavon, Giulio Trigila, and Esteban G Tabak. The data-driven schrödinger bridge. *Communications on Pure and Applied Mathematics*, 74(7):1545–1573, 2021.
- Marcel Nutz. Introduction to entropic optimal transport. *Lecture notes, Columbia University*, 2021.
- Promit Ghosal, Marcel Nutz, and Espen Bernton. Stability of entropic optimal transport and schrödinger bridges. *Journal of Functional Analysis*, 283(9):109622, 2022.
- Flavien Léger. A gradient descent perspective on sinkhorn. *Applied Mathematics & Optimization*, 84(2):1843–1855, 2021.
- Kirill Neklyudov, Rob Brekelmans, Daniel Severo, and Alireza Makhzani. Action matching: Learning stochastic dynamics from samples. In *International conference on machine learning*, pages 25858–25889. PMLR, 2023.
- Linqi Zhou, Aaron Lou, Samar Khanna, and Stefano Ermon. Denoising diffusion bridge models. *arXiv preprint arXiv:2309.16948*, 2023.
- Michael S. Albergo, Nicholas M. Boffi, and Eric Vanden-Eijnden. Stochastic interpolants: A unifying framework for flows and diffusions, 2023.
- Alexander Tong, Nikolay Malkin, Kilian Fatras, Lazar Atanackovic, Yanlei Zhang, Guillaume Huguët, Guy Wolf, and Yoshua Bengio. Simulation-free schrödinger bridges via score and flow matching. *arXiv preprint arXiv:2307.03672*, 2023a.
- Vignesh Ram Somnath, Matteo Pariset, Ya-Ping Hsieh, Maria Rodriguez Martinez, Andreas Krause, and Charlotte Bunne. Aligned diffusion schrödinger bridges. In *Uncertainty in Artificial Intelligence*, pages 1985–1995. PMLR, 2023.
- Guan-Horng Liu, Arash Vahdat, De-An Huang, Evangelos A Theodorou, Weili Nie, and Anima Anandkumar. I²SB: Image-to-Image Schrödinger bridge. 2023.
- Ricky TQ Chen, Yulia Rubanova, Jesse Bettencourt, and David K Duvenaud. Neural ordinary differential equations. *Advances in neural information processing systems*, 31, 2018.

- Alexander Tong, Kilian Fatras, Nikolay Malkin, Guillaume Huguët, Yanlei Zhang, Jarrid Rector-Brooks, Guy Wolf, and Yoshua Bengio. Improving and generalizing flow-based generative models with minibatch optimal transport. *arXiv preprint arXiv:2302.00482*, 2023b.
- Kacper Kapusniak, Peter Potaptchik, Teodora Reu, Leo Zhang, Alexander Tong, Michael Bronstein, Joey Bose, and Francesco Di Giovanni. Metric flow matching for smooth interpolations on the data manifold. *Advances in Neural Information Processing Systems*, 37:135011–135042, 2024.
- Quan Dao, Hao Phung, Binh Nguyen, and Anh Tran. Flow matching in latent space. *arXiv preprint arXiv:2307.08698*, 2023.
- Xingchao Liu, Chengyue Gong, and Qiang Liu. Flow straight and fast: Learning to generate and transfer data with rectified flow. *arXiv preprint arXiv:2209.03003*, 2022b.
- Amartya Banerjee, Harlin Lee, Nir Sharon, and Caroline Moosmüller. Efficient trajectory inference in wasserstein space using consecutive averaging. *arXiv preprint arXiv:2405.19679*, 2024.
- Zhenyi Zhang, Tiejun Li, and Peijie Zhou. Learning stochastic dynamics from snapshots through regularized unbalanced optimal transport. *arXiv preprint arXiv:2410.00844*, 2024b.
- Tianrong Chen, Jiatao Gu, Laurent Dinh, Evangelos A Theodorou, Joshua Susskind, and Shuangfei Zhai. Generative modeling with phase stochastic bridges. *arXiv preprint arXiv:2310.07805*, 2023b.
- Evangelos Theodorou, Jonas Buchli, and Stefan Schaal. A generalized path integral control approach to reinforcement learning. *The Journal of Machine Learning Research*, 11:3137–3181, 2010.

目录

A 符号说明 15

B 证明 16

B.1 定理 3.1 的证明	16
B.2 命题 3.2 的证明	18
B.3 命题 3.4 的证明	21
B.4 定理 3.5 的证明	22

C 高斯路径 24

D 扩展相关工作 26

E 实验的额外细节 27

E.1 一般信息	27
E.2 洛特卡-沃尔泰拉	27
E.3 墨西哥湾	28
E.4 北京空气质量	28
E.5 单序列	29
E.6 关于 σ	的消融实验 30

A 符号总结

表 8: 符号 t 时间坐标 x_t 位置 v_t 速度 a_t 加速度 m_t 增广变量 R 软边缘约束 $q_n(x_n)$ n^{th} 位置边际 $\xi_n(v_n)$ n^{th} 速度边际 $\pi_n(x_n, v_n)$ n^{th} 增广边际 $\lambda^{(n)}$ 未来固定点对 n^{th} 段的影响系数 $C^{(n)}(t)$ 塑造 n^{th} 段条件桥的函数 $\{x_n\}$ 在 n 边际上的耦合 $V_t(m_t)$ 值函数 P_t, r_t 值函数的二阶与一阶近似 μ_t 高斯路径均值向量 Σ_t 高斯路径协方差矩阵 L_t 协方差矩阵的 Cholesky 分解

t	Time coordinate
x_t	Position
v_t	Velocity
a_t	Acceleration
m_t	Augmented Variable
R	Soft marginal constraint
$q_n(x_n)$	n^{th} Positional marginal
$\xi_n(v_n)$	n^{th} Velocity marginal
$\pi_n(x_n, v_n)$	n^{th} Augmented marginal
$p_t(x_t, v_t)$	Augmented probability path
$\lambda^{(n)}$	Coefficients of impact of future pinned points of the n^{th} segment
$C^{(n)}(t)$	Functions shaping the cond. bridge of the n^{th} segment
$\{x_n\}$	Coupling over n marginals
$V_t(m_t)$	Value Function
P_t, r_t	Value function second and first order approximations
μ_t	Gaussian path mean vector
Σ_t	Gaussian path covariance matrix
L_t	Cholesky decomposition on the cov. matrix

B 证明

B.1 定理 3.1 的证明

定理 B.1 (多边际动量布朗桥 (3MBB) 的 SOC 表示)。考虑以下在多个边际之间插值的动量系统

$$u_t^* = \begin{bmatrix} 0 \\ a_t^* \end{bmatrix} \in \arg \min_{a_t} \int_0^1 \frac{1}{2} \|a_t\|^2 dt + \sum_{n=1}^N (m_n - \bar{m}_n)^\top R (m_n - \bar{m}_n) \quad (11)$$

$$s.t \quad dm_t = A m_t dt + u_t + g dW_t, \quad m_0 = \bar{m}_0. \quad (12)$$

我们将值函数定义为 $V_t(m_t) := \frac{1}{2} m_t^\top P^{-1} m_t + m_t^\top P^{-1} r_t$ 其中 P_t, r_t 分别是二阶

以及一阶近似。该公式允许以下最优控制表达式 $u_t^*(m_t) = -g g^\top P_t^{-1} (m_t + r_t)$ 。对于在 $n \in \{0, 1, \dots, N\}$ 处固定 $\{\bar{m}_n\}$ 为 $\{t_n\}$ 的多边际桥, P_t 和 r_t 的动力学服从以下反向常微分方程

$$\dot{P}_t = A P_t + P_t A^\top - \sigma_t \sigma_t^\top, \quad P_n = (P_{n+}^{-1} + R)^{-1}, \text{ with } P_{N+} = 0 \quad (13)$$

$$\dot{r}_t = -A r_t, \quad r_n = P_n (P_{n+}^{-1} r_{n+} - R \bar{m}_n) \quad (14)$$

where $P_{n+} := \lim_{t \rightarrow t_n^+} P_t$, and $r_{n+} := \lim_{t \rightarrow t_n^+} r_t$, for $t \in \{s : s \in (t_1, t_2) \cup (t_2, t_3), \dots\}$.

证明。我们首先考虑值函数的二阶近似:

$$V(t, m_t) = \frac{1}{2} m_t^\top Q_t m_t + r_t^\top Q_t m_t \quad (15)$$

其中 Q_t 和 r_t 分别作为二阶和一阶近似。根据贝尔曼原理和对值函数应用伊藤引理, 我们得到哈密顿-雅可比-贝尔曼 (HJB) 方程:

$$V_t + \min_u \left[\frac{1}{2} \mathbb{E} [\|u_t\|^2 dt] + V_m^\top (A m_t + u_t) \right] + \frac{1}{2} \text{Tr}(V_{mm} g g^\top) = 0 \quad (16)$$

求解最优控制 u_t^* , 我们得到:

$$u_t^* = -g g^\top V_m = -g g^\top Q (m_t + r_t) \quad (17)$$

因此将其代回 HJB 方程, 我们可以将其重写为

$$V_t - \frac{1}{2} V_m g g^\top V_m + V_m^\top A m + \frac{1}{2} \text{Tr}(V_{mm} g g^\top) = 0 \quad (18)$$

回顾价值函数的定义

$$V(t, m_t) = \frac{1}{2} m_t^\top Q m_t + r_t^\top Q m_t$$

将价值函数的定义代入哈密顿-雅可比-贝尔曼方程, 得到如下偏微分方程

$$\frac{1}{2} m_t^\top \dot{Q} m_t + \dot{r}_t^\top Q m_t + r_t^\top \dot{Q} m_t - \frac{1}{2} m_t^\top Q g g^\top Q m_t - r_t^\top Q g g^\top Q m_t + m_t^\top Q A m_t + r_t^\top Q A m_t + \frac{1}{2} \text{Tr}(V_{mm} g g^\top) = 0 \quad (19)$$

将偏微分方程中关于 m_t 的二次项分组, 得到关于 Q_t 的黎卡提方程

$$-\dot{Q} = A^\top Q + Q A - Q g g^\top Q \quad (20)$$

然后, 将线性项分组, 得到

$$\dot{r}_t^\top Q + r_t^\top \dot{Q} - r_t^\top Q g g^\top Q + r_t^\top Q A = 0 \quad (21)$$

现在, 注意到将方程 20 中的黎卡提方程代入方程 21, 可以得到

$$\dot{r}_t = -A r_t \quad (22)$$

该常微分方程的解为

$$r_t = \Phi(t, s) r_s \quad (23)$$

其中 $\Phi(t, s)$ 是以下动力学 $dm_t = A(t)m_t dt$ 从 t 到 s 的状态转移函数, 定义为 $\Phi(t, s) =$ 。最后, 我们定义 $\begin{bmatrix} 1 & t-s \\ 0 & 1 \end{bmatrix} P(t) := Q(t)^{-1}$, 并将方程 20 中的黎卡提方程修改如下

$$\begin{aligned} -\dot{Q} &= A^\top Q + Q^{-1}QAQ^{-1} - Q\mathbf{g}\mathbf{g}^\top Q \\ -Q^{-1}\dot{Q}Q^{-1} &= Q^{-1}A^\top QQ^{-1} + Q^{-1}QAQ^{-1} - Q^{-1}Q\mathbf{g}\mathbf{g}^\top QQ^{-1} \\ \dot{P} &= AP + PA^\top - \mathbf{g}\mathbf{g}^\top \end{aligned} \quad (24)$$

yielding the Lyapunov equation

$$\dot{P} = AP + PA^\top - \mathbf{g}\mathbf{g}^\top \quad (25)$$

因此, 我们证明了价值函数的一阶和二阶近似 r_t, P_t 所需的常微分方程。现在, 我们需要确定每个分段中常微分方程终端条件的表达式。

注意, 根据动力学原理, 这些常微分方程是向后的, 因此后续段会影响前一段。这些终端条件携带了来自后续段的信息。更具体地说, 假设一个多边际过程, 其中 $\{\bar{m}_{n+1}\}$ 固定在 $\{t_{n+1}\}$ 。现在让我们考虑来自两侧的两个段:

- Segment n : 对于 $t \in [t_n, t_{n+1}]$
- Segment $n+1$: 对于 $t \in [t_{n+1}, t_{n+2}]$

为了解段 n 的 P_t, r_t , 我们必须考虑段 $n+1$ 的影响。为了计算在 t_{n+1} 处的值函数, 考虑来自段 $n+1$ 的影响

$$V_{n+1} = V_{n+1+} + \frac{1}{2}(m_{n+1} - \bar{m}_{n+1})^T R_{n+1}(m_{n+1} - \bar{m}_{n+1}) \quad (26)$$

其中第一项概括了来自段 $n+1$ 的影响。更明确地说, 对于段 $n+1$, 在 $t = t_{n+1}$ 处, 我们将值函数定义为

$$\begin{aligned} V_{n+1+} &= \frac{1}{2}m_{n+1+}^T Q_{n+1+} m_{n+1+} + r_{n+1+} Q_{n+1+} m_{n+2+} \\ &= \frac{1}{2}m_{n+1+}^T Q_{n+1+} m_{n+1+} + \Phi(n+1, n+2)\bar{m}_{n+2} Q_{n+1+} m_{n+2+} \end{aligned} \quad (27)$$

因此, 对于段 n , 在终端时间 t_{n+1} 处的值函数由下式给出

$$\begin{aligned} V_{n+1} &= V_{n+1+} + \frac{1}{2}(m_{n+1} - \bar{m}_{n+1})^T R_{n+1}(m_{n+1} - \bar{m}_{n+1}) \\ &= \frac{1}{2}m_{n+1}^\top (Q_{n+1+} + R_{n+1})m_{n+1} + (\Phi(n+1, T)\bar{m}_T Q_{n+1+} \\ &\quad - \bar{m}_{n+1} R_{n+1})m_{n+1} + \text{const.} \\ &= \frac{1}{2}m_{n+1}^T Q_{n+1+} m_{n+1} + r_{n+1+} Q_{n+1+} m_{n+1} + \text{const.} \end{aligned} \quad (28)$$

这表明, 对于里卡蒂方程 Q_t 和参考动力学向量 r_t , 终端约束由下式给出

$$Q_{n+1} := Q_{n+1+} + R_{n+1} \quad (29)$$

$$r_{n+1} := (\Phi(t_{n+1}, T)\bar{m}_T Q_{n+1+} - \bar{m}_{n+1} R_{n+1})Q_{n+1}^{-1} \quad (30)$$

最后, 回想一下, 李雅普诺夫函数定义为 $P_t = Q_t^{-1}$, 因此关于李雅普诺夫函数的终端约束由下式给出

$$P_{n+1} = (P_{n+1+}^{-1} + R_{n+1})^{-1}, \quad r_{n+1} = P_{n+1}(P_{n+1+}^{-1} r_{n+1+} - R_{n+1} \bar{m}_{n+1}) \quad (31)$$

这意味着 r_t ——因此最优控制 u_t^* ——将依赖于 $t \{\bar{m}_j : t_j \geq t\}$ 之后的所有先前固定点。最后, 注意对于最后一段 $t \in [t_{N-1}, t_N]$, 由于没有来自任何后续段的影响, 因此 $P_{N+} = 0$, 成立, 从而 $P_{t_N} = R_{t_N}^{-1}$, 并且 r_{t_N} 简化为 $-m_{t_N}$ 。 $\square$

B.2 命题 3.2 的证明

Proposition B.2. Let $R = \begin{bmatrix} \frac{1}{c} & 0 \\ 0 & c \end{bmatrix}$. At the limit when $c \rightarrow 0$, the conditional acceleration in Eq. 3 具有解析形式:

$$a_t^*(m_t | \{\bar{x}_{n+1} : t_{n+1} \geq t\}) = C_1^n(t)(x_t - \bar{x}_{n+1}) + C_2^n(t)v_t + C_3^n(t) \sum_{j=n+1}^N \lambda_j \bar{x}_j, \quad t \in [t_n, t_{n+1}) \quad (32)$$

其中 $\{\bar{x}_{n+1} : t_{n+1} \geq t\}$ 表示桥过程以随后点集为条件, λ_j 为静态系数, $C_1^n(t), C_2^n(t), C_3^n(t)$ 为各段特有的时变系数。

证明。我们从最后一段 $N-1$ 开始分析, 然后推导任意前一段 n 的公式。

段 $N-1$: $t \in [t_{N-1}, T]$ 对于最后一段, 终端约束 $t \in [t_{N-1}, T]$ 由 $P_N = R_N^{-1}$ 给出, 因此 r_N 简化为 $-m_N$ 。求解后向微分方程 P_t , 对于 $t \in [t_{N-1}, T]$, 以 $P_T = P_N = R_N^{-1}$ 为条件, 得到

$$P(t) = \begin{bmatrix} -\frac{\sigma^2}{2}(t-T)^3 + \frac{(t-T)^2}{c} + c & -\frac{\sigma^2}{2}(t-T)^2 + \frac{(t-T)}{c} \\ -\frac{\sigma^2}{2}(t-T)^2 + \frac{(t-T)}{c} & -\sigma^2(t-T) + \frac{1}{c} \end{bmatrix} \quad (33)$$

此外, 对于 $t \in [t_{N-1}, T]$ 求解 r_t , 以 $r_T = -\bar{m}_T$ 为条件, 得到:

$$r_t = \Phi(t, T)\bar{m}_T \quad (34)$$

其中 $\Phi(t, s)$ 是以下动力学的转移矩阵 $dm_t = A(t)m_t dt$, 定义为 $\Phi(t, s) = \begin{bmatrix} 1 & t-s & 0 & 1 \end{bmatrix}$ 。将式 33 和式 34 代入式 17, 得到

$$u_t^* = \begin{bmatrix} 0 \\ \frac{3}{(t-T)^2}(\bar{x}_T - x_t) - \frac{3}{T-t}v_t \end{bmatrix}, \quad \forall t \in [t_{N-1}, T] \quad (35)$$

因此, 无论边缘分布的总数如何, 最后一段的 C 函数为
always: $C_1^{(N-1)}(t) = -\frac{3}{(T-t)^2}$, $C_2^{(N-1)}(t) = \frac{3}{T-t}$, $C_3^{(N-1)}(t) = 0$ 。

Segment n : $t \in [t_n, t_{n+1}]$

Now, we move to derive the conditional acceleration, for an arbitrary segment n , with $n < N-1$ i.e. n is not the last segment. Let us recall the optimal control formulation from Eq. (17)

$$u_t^*(m_t) = -\mathbf{g}\mathbf{g}^\top P_t^{-1}(m_t + \Phi(t, t_{n+1})r_{n+1}) \quad (36)$$

为方便起见, 我们定义与 n^{th} 段对应的以下函数: $t \in [t_n, t_{n+1})$

$$\begin{aligned} z_1^{(n)}(t) &= 3t - 3t_{n+1} - 3 & z_2^{(n)}(t) &= 3t - 4 - 3t_{n+1} \\ z_3^{(n)}(t) &= 6t - 6t_{n+1} - 3 & z_4^{(n)}(t) &= 6t - 6t_{n+1} - 4 \\ z_5^{(n)}(t) &= 4t - 4t_{n+1} - 3 & z_6^{(n)}(t) &= 4t - 4 - 4t_{n+1} \\ z_7^{(n)}(t) &= 6t - 6t_{n+1} + 3 & z_8^{(n)}(t) &= 6t - 6t_{n+1} + 4 \end{aligned} \quad (37)$$

对于任意段 n , 我们使用常微分方程求解软件, 求解具有相应终端条件的反向常微分方程 P_t 。

$$\dot{P}_t = AP_t + P_t A^\top - \sigma_t \sigma_t^\top, \quad P_n = (P_{n+}^{-1} + R)^{-1}, \text{ with } P_{N+} = 0 \quad (38)$$

Given the structure of $R = \begin{bmatrix} \frac{1}{c} & 0 \\ 0 & c \end{bmatrix}$, 结合 $c \rightarrow 0$, 我们得到 P_t 的如下表达式, 对于 $t \in [t_n, t_{n+1})$

$$P_t = \begin{bmatrix} \sigma^2 \frac{(t-t_{n+1})^3 (\alpha^{(n)} z_1^{(n)}(t) + \beta^{(n)} z_2^{(n)}(t))}{2(\alpha^{(n)} z_5^{(n)}(t) + \beta^{(n)} z_6^{(n)}(t))} & \sigma^2 \frac{(t-t_{n+1})^2 (\alpha^{(n)} z_1^{(n)}(t) + \beta^{(n)} z_2^{(n)}(t))}{2(\alpha^{(n)} z_3^{(n)}(t) + \beta^{(n)} z_4^{(n)}(t))} \\ \sigma^2 \frac{(t-t_{n+1})^2 (\alpha^{(n)} z_1^{(n)}(t) + \beta^{(n)} z_2^{(n)}(t))}{2(\alpha^{(n)} z_3^{(n)}(t) + \beta^{(n)} z_4^{(n)}(t))} & 2\sigma^2 \frac{(t-t_{n+1}) (\alpha^{(n)} z_1^{(n)}(t) + \beta^{(n)} z_2^{(n)}(t))}{(\alpha^{(n)} z_7^{(n)}(t) + \beta^{(n)} z_8^{(n)}(t))} \end{bmatrix} \quad (39)$$

其中 $\alpha^{(n)}, \beta^{(n)}$ 是段特定系数，用于塑造给定段 n 的条件桥。这些系数使用后续段 $n+1$ 的系数递归计算如下：

$$\begin{aligned}\alpha^{(n)} &= \alpha^{(n+1)} z_1^{(n)}(t_{n+1}) + \beta^{(n+1)} z_2^{(n)}(t_{n+1}) \\ \beta^{(n)} &= 4(\alpha^{(n+1)} + \beta^{(n+1)})\end{aligned}\quad (40)$$

从 P_t 的表达式中，我们可以得到其逆矩阵

$$P_t^{-1} = \frac{1}{\sigma^2} \begin{bmatrix} \frac{6(\alpha^{(n)} z_7^{(n)}(t) + \beta^{(n)} z_8^{(n)}(t))}{(t-t_{n+1})^3 * (\alpha^{(n)} z_1^{(n)}(t) + \beta^{(n)} z_2^{(n)}(t))} & \frac{-3(\alpha^{(n)} z_3^{(n)}(t) + \beta^{(n)} z_4^{(n)}(t))}{(t-t_{n+1})^2 * (\alpha^{(n)} z_1^{(n)}(t) + \beta^{(n)} z_2^{(n)}(t))} \\ \frac{-3(\alpha^{(n)} z_3^{(n)}(t) + \beta^{(n)} z_4^{(n)}(t))}{(t-t_{n+1})^2 * (\alpha^{(n)} z_1^{(n)}(t) + \beta^{(n)} z_2^{(n)}(t))} & \frac{3(\alpha^{(n)} z_5^{(n)}(t) + \beta^{(n)} z_6^{(n)}(t))}{(t-t_{n+1}) * (\alpha^{(n)} z_1^{(n)}(t) + \beta^{(n)} z_2^{(n)}(t))} \end{bmatrix} \quad (41)$$

因此，我们可以计算以下项：i) $\mathbf{g}\mathbf{g}^\top P_t^{-1}$, ii) $\mathbf{g}\mathbf{g}^\top P_t^{-1} \Phi(t, t_{n+1})$ 在最优控制公式中如下：

$$\mathbf{g}\mathbf{g}^\top P_t^{-1} = \begin{bmatrix} 0 & 0 \\ \frac{-3(\alpha^{(n)} z_3^{(n)}(t) + \beta^{(n)} z_4^{(n)}(t))}{(t-t_{n+1})^2 * (\alpha^{(n)} z_1^{(n)}(t) + \beta^{(n)} z_2^{(n)}(t))} & \frac{3(\alpha^{(n)} z_5^{(n)}(t) + \beta^{(n)} z_6^{(n)}(t))}{(t-t_{n+1}) * (\alpha^{(n)} z_1^{(n)}(t) + \beta^{(n)} z_2^{(n)}(t))} \end{bmatrix} \quad (42)$$

$$\mathbf{g}\mathbf{g}^\top P_t^{-1} \Phi(t, t_{n+1}) = \begin{bmatrix} 0 & 0 \\ \frac{-3(\alpha^{(n)} z_3^{(n)}(t) + \beta^{(n)} z_4^{(n)}(t))}{(t-t_{n+1})^2 * (\alpha^{(n)} z_1^{(n)}(t) + \beta^{(n)} z_2^{(n)}(t))} & \frac{6(\alpha^{(n)} + \beta^{(n)})}{(\alpha^{(n)} z_1^{(n)}(t) + \beta^{(n)} z_2^{(n)}(t))} \end{bmatrix} \quad (43)$$

Therefore, we can rewrite the optimal control in Eq. (17) as

$$u_t^* = \begin{bmatrix} 0 & 0 \\ C_1^{(n)}(t) & C_2^{(n)}(t) \end{bmatrix} \begin{bmatrix} \mathbf{x}_t \\ \mathbf{v}_t \end{bmatrix} + \begin{bmatrix} 0 & 0 \\ C_1^{(n)}(t) & C_3^{(n)}(t) \end{bmatrix} r_{n+1}, \forall t \in [t_n, t_{n+1}] \quad (44)$$

其中我们有

$$\begin{aligned}C_1^{(n)}(t) &= \frac{-3(\alpha^{(n)} z_3^{(n)}(t) + \beta^{(n)} z_4^{(n)}(t))}{(t-t_{n+1})^2 * (\alpha^{(n)} z_1^{(n)}(t) + \beta^{(n)} z_2^{(n)}(t))} \\ C_2^{(n)}(t) &= \frac{3(\alpha^{(n)} z_5^{(n)}(t) + \beta^{(n)} z_6^{(n)}(t))}{(t-t_{n+1}) * (\alpha^{(n)} z_1^{(n)}(t) + \beta^{(n)} z_2^{(n)}(t))} \\ C_3^{(n)}(t) &= \frac{6(\alpha^{(n)} + \beta^{(n)})}{(\alpha^{(n)} z_1^{(n)}(t) + \beta^{(n)} z_2^{(n)}(t))}\end{aligned} \quad (45)$$

现在我们来计算项 r_{n+1} ，根据式 (13) 可得

$$r_{n+1} = P_{n+1}(P_{n+1}^{-1} r_{n+1+} - R\bar{m}_{n+1}) \quad (46)$$

其中项 $r_{n+1+} = \Phi(t_{n+1}, t_{n+2})r_{n+2}$ 承载了来自未来分段的影响。因此，第一项通过以下方式递归地引入更远未来固定点的影响

$$P_{n+1}P_{n+1+}^{-1}r_{n+1+} = P_{n+1}P_{n+1+}^{-1}\Phi(t_{n+1}, t_{n+2})r_{n+2} \quad (47)$$

Since P_{n+1} $_{n+1+}\Phi(t_{n+1}, t_{n+2})$ 也与时间无关，我们有

$$P_{n+1}P_{n+1+}^{-1}\Phi(t_{n+1}, t_{n+2}) = \begin{bmatrix} 0 & 0 \\ \lambda^{(n)} & 0 \end{bmatrix} \quad (48)$$

其中 λ 是某个静态系数，特定于 n^{th} 分段，即不同分段由不同的 λ 系数表征。

式 (48) 中该矩阵的结构表明，当与 $\bar{m}_j$ 相乘（对于 $j = \{n+2, \dots, N\}$ ）时， r_t 将仅依赖于位置约束。最后，鉴于 r_t 动力学的线性性质，我们可以递归地加入更多固定点的影响

$$P_{n+1}P_{n+1+}^{-1}\Phi(t_{n+1}, t_{n+2})r_{n+2} = P_{n+1}P_{n+1+}^{-1}\Phi(t_{n+1}, t_{n+2})(P_{n+2}(P_{n+2+}^{-1}r_{n+2+} - R\bar{m}_{n+2})) \quad (49)$$

这种递归导致 r_t 通过以下表达式表示为那些未来固定点的线性组合

$$P_{n+1}P_{n+1}^{-1}r_{n+1} = \begin{bmatrix} 0 \\ \sum_{j=n+2}^N \lambda_j^{(n)} \bar{x}_j \end{bmatrix} \quad (50)$$

随后, 从 $P_{n+1} = (P_{n+1} + R)^{-1}$ 计算 P_{n+1} 以及 R 的对角结构也导致

$$P_{n+1} R \bar{m}_{n+1} = \begin{bmatrix} -x_{n+1} \\ \kappa^{(n)} x_{n+1} \end{bmatrix} \quad (51)$$

其中 $\kappa^{(n)}$ 也是某个静态系数, 特定于 n^{th} 分段。因此, 这导致 r_{n+1} 的以下表达式

$$r_{n+1} = \begin{bmatrix} -\bar{x}_{n+1} \\ \kappa^{(n)} \bar{x}_{n+1} + \sum_{j=n+2}^N \lambda_j^{(n)} \bar{x}_j \end{bmatrix} \quad (52)$$

或等价地

$$r_{n+1} = \begin{bmatrix} -\bar{x}_{n+1} \\ \sum_{j=n+1}^N \lambda_j^{(n)} \bar{x}_j \end{bmatrix} \quad (53)$$

其中我们定义了 $\kappa^{(n)} = \lambda_{n+1}^{(n)}$ 。这意味着 r_t —— 因此最优控制 u_t^* —— 依赖于 $t \{\bar{m}_{n+1} : t_{n+1} \geq t\}$ 之后所有先前的固定点, 作为这些点的线性组合。研究发现, 向量 $\lambda^{(n)} = [\lambda_{n+1}, \lambda_{n+2}, \dots, \lambda_N]$ 的元素仅依赖于所考虑的固定点数量 $\bar{x}_j$, 并随着该数量的增加呈指数衰减, 如图 10 所示。换言之, $\lambda_i^{(n)}$ 的值随着相应 $\bar{x}_j$ 距离我们所计算桥梁的区段越远而减小。注 B.3。需要强调的是, 系数 $\alpha^{(n)}, \beta^{(n)}, \lambda^{(n)}$ 的唯一依赖是未来边缘分布的数量。

□

B.2.1 多边缘桥梁的示例

此时, 我们给出多边缘条件桥梁的示例, 阐明每个区段的结构由未来边缘分布的数量决定。为简单起见, 我们用 $\alpha^{(n)}, \beta^{(n)}, \lambda^{(n)}$ 表示对应于 n^{th} 区段的区段特定系数: $t \in [t_n, t_{n+1})$ 。

2-边缘桥梁 当 $N = 2$ 且 $T = 1$ 时, 双边缘桥梁的公式与多边缘桥梁的区段 $N - 1$ 一致。更具体地, 我们有:

$$a^*(m_t | \bar{x}_1) = \frac{3}{(t-1)^2}(\bar{x}_T - x_t) - \frac{3}{1-t}v_t, \forall t \in [0, 1) \quad (54)$$

3-marginal Bridge

3-边缘桥梁的公式由下式给出

$$\begin{cases} a^*(m_t | \bar{x}_2) = \frac{3}{(T-t)^2}(\bar{x}_2 - x_t) - \frac{3}{T-t}v_t, & t \in [t_1, T) \\ a^*(m_t | \bar{x}_1, \bar{x}_2) = \frac{-18t - 18t_1 - 12}{(t-1)^2(3t - 3t_1 - 4)}(x_t - \bar{x}_1) + \frac{12t - 12t_1 - 12}{(t-1)(3t - 3t_1 - 4)}v_t \\ \quad + \frac{6}{(3t - 3t_1 - 4)}(\bar{x}_2 - \bar{x}_1), & t \in [t_0, t_1) \end{cases} \quad (55)$$

注意, 对于 $t_1 = 1$ 和 $t_2 = 2$, 我们得到与第 3 节示例中相同的表达式。此外, 我们看到区段 $t \in [t_0, t_1)$ 由我们的广义公式 $\alpha = 0, \beta = 1$ 得到, 并与 $N - 2$ 区段的表达式一致。最后, 验证了最后区段与双边缘情况下的桥梁具有相同的公式和相同的系数。

4-边际桥 The 4-marginal bridge further illustrates how the structure of each segment $t \in [t_1, t_2]$ 取决于未来边际的数量。特别地，根据注记 B.3，最后两个分段 $t \in [t_2, T]$ 和 $t \in [t_1, t_2]$ 与 3-边际桥中的表述相同，因为它们分别以 1 个和 2 个未来边际为条件。为了计算第一个分段 $t \in [t_0, t_1]$ ，我们发现 $\alpha^{(0)} = 4$ ，为： $\lambda^{(0)} = [-1.25, 1.5, -0.25]^\top$ 。由此得到如下桥的 $\beta^{(0)} = 4$, and the $\lambda^{(0)}$ 表述：

$$\left\{ \begin{array}{ll} a^*(m_t | \bar{x}_3) = \frac{3}{(T-2)^2}(\bar{x}_3 - x_t) - \frac{3}{T-t}v_t, & t \in [t_2, T) \\ a^*(m_t | \bar{x}_2, \bar{x}_3) = \frac{-18t - 18t_2 - 12}{(t-t_2)^2(3t-3t_2-4)}(x_t - \bar{x}_2) \\ \quad + \frac{12t - 12t_2 - 12}{(t-t_2)(3t-3t_2-4)}v_t + \frac{6}{(3t-3t_2-4)}(\bar{x}_3 - \bar{x}_2), & t \in [t_1, t_2) \\ a^*(m_t | \bar{x}_1, \bar{x}_2, \bar{x}_3) = \frac{-36t + 36t_1 - 21}{(t-t_1)^2(6t-6t_1-7)}(x_t - \bar{x}_1) + \frac{24t - 24t_1 - 21}{(t-t_1)(6t-6t_1-7)}v_t \\ \quad + \frac{12}{(6t-6t_1-7)}(-0.25\bar{x}_3 + 1.5\bar{x}_2 - 1.25\bar{x}_1) & t \in [t_0, t_1) \end{array} \right. \quad (56)$$

5-边际桥 容易看出，5-边际桥的最后三个分段与 4-边际情形具有相同的结构。例如，根据注记 B.3，倒数第三个分段 $t \in [t_1, t_2]$ 的系数为 $\alpha_1 = \beta_1 = 4$ ，且对应于分段 $t \in [t_2, t_3]$ 和 $t \in [t_1, t_2]$ 的向量 $\lambda^{(2)}$ 和 $\lambda^{(1)}$ 分别与 4-边际桥中倒数第三个和倒数第二个分段的向量一致。最后，对于第一个分段 $t \in [0, t_1]$ ，我们计算得到： $\alpha^{(0)} = 28$, $\beta^{(0)} = 32$ ，以及 $\lambda^{(0)} = [-1.267, 1.6, -0.4, 0.067]^\top$ 。将这些系数代入式 (45) 即可得到相应的桥的表述。

$$\left\{ \begin{array}{ll} a^*(m_t | \bar{x}_4) = \frac{3}{(T-t)^2}(\bar{x}_4 - x_t) - \frac{3}{T-t}v_t, & t \in [t_3, T) \\ a^*(m_t | \bar{x}_3, \bar{x}_4) = \frac{-18t - 18t_3 - 12}{(t-t_3)^2(3t-3t_3-4)}(x_t - \bar{x}_3) \\ \quad + \frac{12t - 12t_3 - 12}{(t-t_3)(3t-3t_3-4)}v_t + \frac{6}{3t-3t_3-4}(\bar{x}_4 - \bar{x}_3), & t \in [t_2, t_3) \\ a^*(m_t | \bar{x}_2, \bar{x}_3, \bar{x}_4) = \frac{-36t + 36t_2 - 21}{(t-t_2)^2(6t-6t_2-7)}(x_t - \bar{x}_2) + \frac{24t - 24t_2 - 21}{(t-t_2)(6t-6t_2-7)}v_t \\ \quad + \frac{12}{(6t-6t_2-7)}(-0.25\bar{x}_4 + 1.5\bar{x}_3 - 1.25\bar{x}_2), & t \in [t_1, t_2) \\ a^*(m_t | \bar{x}_1, \bar{x}_2, \bar{x}_3, \bar{x}_4) = -\frac{6(45t - 45t_1 - 26)}{(t-t_1)^2(45t-45t_1-52)}(x_t - \bar{x}_1) + \frac{12(15t - 15t_1 - 13)}{(t-t_1)(45t-45t_1-52)}v_t \\ \quad + \frac{90}{45t-45t_1-52}(-1.267\bar{x}_1 + 1.6\bar{x}_2 - 0.4\bar{x}_3 + 0.067\bar{x}_4), & t \in [t_0, t_1) \end{array} \right. \quad (57)$$

B.3 命题 3.4 的证明

命题 B.4. 将边际路径 p_t 定义为桥的混合 $p_t(m_t) = \int p_{t|\{\bar{x}_n\}}(m_t|\{\bar{x}_n : t_n \geq t\})dq(\{x_n\})$ ，其中 $p_{t|\{\bar{x}_n\}}(m_t|\{\bar{x}_n : t_n \geq t\})$ 是与式 6 中 3MBB 路径的解相关联的条件概率路径。参数化加速度

满足由 p_t 规定的 FPE 的加速度为

$$a_t(t, m_t) = \frac{\int a_t|\{\bar{x}_n\} p_t|\{\bar{x}_n\}(m_t|\{\bar{x}_n : t_n \geq t\}) dq(\{x_n\})}{p_t} \quad (58)$$

这表明，在给定 p_t 的情况下，通过最小化变分间隙以匹配 a_t^θ ，可得到

$$\min_{\theta} \mathbb{E}_{q(\{x_n\})} \mathbb{E}_{p_t|\{\bar{x}_n\}} \left[\int_0^1 \|a_t|\{\bar{x}_n\} - a_t^\theta\|^2 dt \right] \quad (59)$$

证明。我们希望证明方程 (9) 中的加速度保持所规定的路径 p_t 。动量福克-普朗克方程 (Fokker Plank Equation, FPE) 为

$$\partial_t p_t(m_t) = -v_t \nabla_x p_t(m_t) - \nabla_v (a_t(m_t) p_t(m_t)) + \frac{1}{2} \sigma^2 \Delta_v p_t(m_t) \quad (60)$$

我们令边缘分布构造为以一组固定点为条件的条件概率路径的混合 $\{\bar{x}_n\}_{n \in [0, N]}$, $p_t = \int p_t(m_t|\{\bar{x}_n\}) q(\{\bar{x}_n\}) dx_0 dx_1 \dots dx_N$ 。利用该边缘路径的定义，可得

$$\begin{aligned} \partial_t p_t(m_t) &= \partial_t \int q(\{\bar{x}_n\}) p_t(m_t|\{\bar{x}_n\}) d\{\bar{x}_n\} = \int q(\{\bar{x}_n\}) \partial_t p_t(m_t|\{\bar{x}_n\}) d\{\bar{x}_n\} \\ v_t \nabla_x p_t(m_t) &= v_t \nabla_x \int q(\{\bar{x}_n\}) p_t(m_t|\{\bar{x}_n\}) d\{\bar{x}_n\} = \int q(\{\bar{x}_n\}) [v_t \nabla_x p_t(m_t|\{\bar{x}_n\})] d\{\bar{x}_n\} \\ \Delta_v p_t(m_t) &= \nabla_v \cdot (\nabla_v p_t(m_t)) = \nabla_v \cdot \left(\nabla_v \int q(\{\bar{x}_n\}) p_t(m_t|\{\bar{x}_n\}) d\{\bar{x}_n\} \right) \\ &= \int q(\{\bar{x}_n\}) \left[\nabla_v \cdot (\nabla_v \int p_t(m_t|\{\bar{x}_n\}) d\{\bar{x}_n\}) \right] d\{\bar{x}_n\} \\ &= \int q(\{\bar{x}_n\}) \Delta_v p_t(m_t|\{\bar{x}_n\}) d\{\bar{x}_n\} \end{aligned} \quad (61)$$

因此，仍需检验以下等式是否成立

$$a_t(m_t) p_t(m_t) = \int q(\{\bar{x}_n\}) [a_t|\{\bar{x}_n\}(m_t|\{\bar{x}_n\}) p_t(m_t|\{\bar{x}_n\})] d\{\bar{x}_n\} \quad (62)$$

这表明参数化漂移最小化以下最小化问题

$$a_t^{\theta^*}(m_t) = \arg \min_{\theta} \mathbb{E}_{q(\{\bar{x}_n\}) p_t(m_t|\{\bar{x}_n\})} [\|a_t^\theta(m_t) - a_t|\{\bar{x}_n\}(m_t|\{\bar{x}_n\})\|^2] \quad (63)$$

preserves the prescribed p_t . $\square$

B.4 定理 3.5 的证明

定义 B.5 (路径测度的马尔可夫投影)。 $\mathbb{P}$ 的马尔可夫投影定义为 $\mathbb{P}^{\mathcal{M}} = \arg \min_{\mathbb{V} \in \mathcal{M}} KL(\mathbb{P}|\mathbb{V})$ 。

直观上，马尔可夫投影寻求使与 $\mathbb{P}$ 的变分距离最小的路径测度。换言之，它寻求在 KL 意义下最接近的马尔可夫路径测度。定义 B.6 (互易类与投影)。对于多边际路径测度，我们称 $\mathbb{P}$ 属于 $\mathbb{Q} \in \mathcal{M}$ 的互易类 $\mathcal{R}(\mathbb{Q})$ ，如果

$$\mathbb{P} = \int \mathbb{Q}_{\{x_n\}} dq(\{x_n\})$$

即，它与 $\mathbb{Q}$ 共享相同的桥。我们将 $\mathbb{P}$ 的互反投影定义为

$$\mathbb{P}^* = \text{proj}_{\mathcal{R}(\mathbb{Q})}(\mathbb{P}) := \arg \min_{\mathbb{T} \in \mathcal{R}(\mathbb{Q})} KL(\mathbb{P} \| \mathbb{T}).$$

类似地，互反投影在 KL 意义下产生最接近的互反路径测度。

引理 B.7. 设 $\mathbb{P}$ 是 $\mathbb{Q} \in \mathcal{M}$ 的互反类中的一个马尔可夫测度，使得 $\int \mathbb{P}_n dv_n = q_n(x_n)$ ，对于 $n \in \{0, \dots, N\}$ 。那么，在 $\mathbb{Q}, q_n$ 的一些温和正则性假设下，发现 $\mathbb{P}$ 等于唯一的多边际薛定谔桥 $\mathbb{P}^{mmSB}$ 。

证明。首先假设 $\text{KL}(\mathbb{P}|\mathbb{Q}) < \infty$ ，并且 $\text{KL}(q_n | \cdot)$ 对于假设 $\mathbb{Q}_n dv_n < \infty$ $n \in \{0, \dots, N\}$ 。
 $\mathbb{Q} \in \mathcal{M}$ ，那么根据（定理 2.10，定理 2.12 Léonard [2013]），动

态薛定谔桥 $\mathbb{P}$ 的解也必须是马尔可夫测度。最后，从 KL 的分解来看，成立

$$\text{KL}(\mathbb{P}|\mathbb{Q}) = \text{KL}(\mathbb{P}_{\{x_n\}}|\mathbb{Q}_{\{x_n\}}) + \int \text{KL}(\mathbb{P}_{\{x_n\}}|\mathbb{Q}_{\{x_n\}}) d\mathbb{P}_{\{x_n\}} \quad (64)$$

这意味着 $\text{KL}(\mathbb{P}_{\{x_n\}}|\mathbb{Q}_{\{x_n\}}) \leq \text{KL}(\mathbb{P}|\mathbb{Q})$ 具有等式（当 $\text{KL}(\mathbb{P}|\mathbb{Q}) < \infty$ 时）当且仅当 $\mathbb{P}_{\{x_n\}} = \mathbb{Q}_{\{x_n\}}$ 。因此， $\mathbb{P}^*$ 是（唯一的）解 mmSB 当且仅当它如上所述分解（命题 2.3 Léonard [2013]）。

引理 B.8. [命题 6，见 [Shi 等人，2023]] 设 $\mathbb{V} \in \mathcal{M}$ 与 $\mathbb{T} \in \mathcal{R}(\mathbb{Q})$ 且。若 $\text{KL}(\mathbb{P}|\mathbb{V}) < \infty$ ，且若 $\text{KL}(\text{proj}_{\mathcal{M}}(\mathbb{P})|\mathbb{V}) < \infty$ 我们有

$$\text{KL}(\mathbb{P}|\mathbb{V}) = \text{KL}(\mathbb{P}|\text{proj}_{\mathcal{M}}(\mathbb{P})) + \text{KL}(\text{proj}_{\mathcal{M}}(\mathbb{P})|\mathbb{V}). \quad (65)$$

and if $\text{KL}(\mathbb{P}|\mathbb{T}) < \infty$, then

$$\text{KL}(\mathbb{P}|\mathbb{T}) = \text{KL}(\mathbb{P}|\text{proj}_{\mathcal{R}(\mathbb{Q})}(\mathbb{P})) + \text{KL}(\text{proj}_{\mathcal{R}(\mathbb{Q})}(\mathbb{P})|\mathbb{T}). \quad (66)$$

定理 B.9. 假设引理 B.7 与 B.8 的条件成立。则我们的迭代格式存在不动点解 $\mathbb{P}^*$, i.e., $\text{KL}(\mathbb{P}^i|\mathbb{P}^*) \rightarrow 0$ ，特别地，该不动点与唯一的 $\mathbb{P}^{mmSB}$ 重合。

证明。我们定义如下路径测度 $\mathbb{V} = \text{proj}_{\mathcal{M}}(\mathbb{P})$ ，以及 $\mathbb{T} = \text{proj}_{\mathcal{R}(\mathbb{Q})}(\mathbb{V})$ 。假设引理 B.8 的条件对 $\mathbb{P}, \mathbb{V}$ 与 $\mathbb{T}$ 成立。则对任意不动点 $\mathbb{V}'$ ，我们可以写出

$$\text{KL}(\mathbb{V}^0|\mathbb{V}') = \text{KL}(\mathbb{V}^0|\mathbb{V}^1) + \text{KL}(\mathbb{V}^1|\mathbb{V}') = \sum_{i=0}^N \text{KL}(\mathbb{V}^i|\mathbb{V}') + \text{KL}(\mathbb{V}^i|\mathbb{V}') \quad (67)$$

因此，对每次迭代 $i \in \mathbb{N}$ ，有 $\text{KL}(\mathbb{V}^i|\mathbb{V}') < \infty$ 成立。类似地，对 $\mathbb{P}$ 与 $\mathbb{T}$ ，我们得到 $\text{KL}(\mathbb{P}^i|\mathbb{P}') < \infty$ 与 $\text{KL}(\mathbb{T}^i|\mathbb{T}') < \infty$ 对每个 $i \in \mathbb{N}$ 以及任意固定的 $\mathbb{P}'$ 与 $\mathbb{T}'$ 成立。据此，我们定义如下函数

$$\Psi^i := \text{KL}(\mathbb{V}^i|\mathbb{V}') + \text{KL}(\mathbb{T}^i|\mathbb{T}') + \text{KL}(\mathbb{P}^i|\mathbb{P}'). \quad (68)$$

对于两个连续迭代 i 与 $i+1$ ，我们有

- $\Psi^i := \text{KL}(\mathbb{V}^i|\mathbb{V}') + \text{KL}(\mathbb{T}^i|\mathbb{T}') + \text{KL}(\mathbb{P}^i|\mathbb{P}')$
- $\Psi^{i+1} := \text{KL}(\mathbb{V}^{i+1}|\mathbb{V}') + \text{KL}(\mathbb{T}^{i+1}|\mathbb{T}') + \text{KL}(\mathbb{P}^{i+1}|\mathbb{P}')$

Using Lemma B.8, we can rewrite Ψ^i as

$$\begin{aligned} \Psi^i &:= \text{KL}(\mathbb{V}^i|\mathbb{V}') + \text{KL}(\mathbb{T}^i|\mathbb{T}') + \text{KL}(\mathbb{P}^i|\mathbb{P}') \\ &= \text{KL}(\mathbb{V}^i|\mathbb{V}^{i+1}) + \text{KL}(\mathbb{T}^i|\mathbb{T}^{i+1}) + \text{KL}(\mathbb{P}^i|\mathbb{P}^{i+1}) + \text{KL}(\mathbb{V}^{i+1}|\mathbb{V}') + \text{KL}(\mathbb{T}^{i+1}|\mathbb{T}') + \text{KL}(\mathbb{P}^{i+1}|\mathbb{P}') \\ &= \text{KL}(\mathbb{V}^i|\mathbb{V}^{i+1}) + \text{KL}(\mathbb{T}^i|\mathbb{T}^{i+1}) + \text{KL}(\mathbb{P}^i|\mathbb{P}^{i+1}) + \Psi^{i+1} \end{aligned}$$

现在，我们对这个望远镜级数求和，得到

$$\Psi^0 - \Psi^\infty \geq \sum_{i=0}^{\infty} \text{KL}(\mathbb{V}^i|\mathbb{V}^{i+1}) + \text{KL}(\mathbb{T}^i|\mathbb{T}^{i+1}) + \text{KL}(\mathbb{P}^i|\mathbb{P}^{i+1}) \quad (69)$$

注意 Ψ^0 与 Ψ^∞ 是有限的（其中 $\Psi^0 \geq \Psi^\infty$ ），因为 $\text{KL}(\mathbb{P}^i|\mathbb{P}') < \infty$, $\text{KL}(\mathbb{V}^i|\mathbb{V}') < \infty$ 与 $\text{KL}(\mathbb{T}^i|\mathbb{T}') < \infty$ 对每次迭代 $i \in \mathbb{N}$ 成立。因此，由于我们还有

$$\text{KL}(\mathbb{P}^i|\mathbb{P}^{i+1}) \geq 0, \text{ 与}$$

- $\lim_{i \rightarrow \infty} \text{KL}(\mathbb{P}^i | \mathbb{P}^{i+1}) \rightarrow 0$,
- $\lim_{i \rightarrow \infty} \text{KL}(\mathbb{V}^i | \mathbb{V}^{i+1}) \rightarrow 0$,
- $\lim_{i \rightarrow \infty} \text{KL}(\mathbb{T}^i | \mathbb{T}^{i+1}) \rightarrow 0$.

因此迭代 $\mathbb{P}^i$, $\mathbb{V}^i$ 和 $\mathbb{T}^i$ 收敛到某些不动点 $\mathbb{P}^i \rightarrow \mathbb{P}^*$, $\mathbb{V}^i \rightarrow \mathbb{V}^*$ 和 $\mathbb{T}^i \rightarrow \mathbb{T}^*$, , 当 $i \rightarrow \infty$.

从 KL 散度的分解中, 我们得到算法连续投影的以下关系:

$$\begin{aligned} \text{KL}(\mathbb{T}^{(i)} | \mathbb{P}^*) &= \text{KL}(\mathbb{T}_{\{x_n\}}^{(i)} | \mathbb{P}_{\{x_n\}}^*) + \mathbb{E}_{\mathbb{T}_{\{x_n\}}^{(i)}} \left[\text{KL}(\mathbb{T}_{\{x_n\}}^{(i)} | \mathbb{P}_{\{x_n\}}^*) \right] \\ &= \text{KL}(\mathbb{T}_{\{x_n\}}^{(i)} | \mathbb{P}_{\{x_n\}}^*) \end{aligned} \quad (70)$$

since the bridges of $\mathbb{T}$ are the same with $\mathbb{P}$, and $\mathbb{Q}$, i.e., $\mathbb{T}_{\{x_n\}}^{(i)} = \mathbb{P}_{\{x_n\}}^* = \mathbb{Q}_{\{x_n\}}$. Then,

$$\begin{aligned} \text{KL}(\mathbb{V}^i | \mathbb{P}^*) &= \text{KL}(\mathbb{V}_{\{x_n\}}^i | \mathbb{P}_{\{x_n\}}^*) + \mathbb{E}_{\mathbb{V}_{\{x_n\}}^i} \left[\text{KL}(\mathbb{V}_{\{x_n\}}^i | \mathbb{P}_{\{x_n\}}^*) \right] \\ &\geq \text{KL}(\mathbb{T}_{\{x_n\}}^{(i+1)} | \mathbb{P}_{\{x_n\}}^*) \end{aligned} \quad (71)$$

因为在第 i 次迭代的马尔可夫投影之后, 耦合对于第 $i+1$ 次迭代的互反路径测度保持不变, 即 $\mathbb{V}_{\{x_n\}}^{(i)} = \mathbb{T}_{\{x_n\}}^{(i+1)}$ 。因此, 我们可以推导出

$$\text{KL}(\mathbb{V}^i | \mathbb{P}^*) \geq \text{KL}(\mathbb{T}^{i+1} | \mathbb{P}^*). \quad (72)$$

我们进一步假设 $\text{KL}(\mathbb{T}^0 | \mathbb{P}^*) < \infty$, $\text{KL}(\mathbb{V}^0 | \mathbb{P}^*) < \infty$ 。因此, 式 70 和 71 的迭代产生

$\text{KL}(\mathbb{T}^{(i)} | \mathbb{P}^*) \geq \text{KL}(\mathbb{V}^i | \mathbb{P}^*) \geq \text{KL}(\mathbb{T}^{i+1} | \mathbb{P}^*)$, 对于 $i \geq 0$, 这意味着收敛, 因为它非递增且有下界。应用引理 B.8, 我们得到 $\lim_{i \rightarrow \infty} (\text{KL}(\mathbb{T}^{(i)} | \mathbb{P}^*) - \text{KL}(\mathbb{V}^i | \mathbb{P}^*)) = \lim_{i \rightarrow \infty} \text{KL}(\mathbb{T}^{(i)} | \mathbb{V}^i) = 0$ 。根据 KL 散度的下半连续性定义, 我们有 $\text{KL}(\mathbb{V}^* | \mathbb{T}^*) \leq \liminf_{k \rightarrow \infty} \text{KL}(\mathbb{V}^{i_{j^k}} | \mathbb{T}^{i_{j^k}})$ 。此外, 根据 KL 散度的定义, 我们有 $0 \leq \text{KL}(\mathbb{V}^* | \mathbb{T}^*)$ 。最后, 还成立 $\liminf_{k \rightarrow \infty} \text{KL}(\mathbb{V}^{i_{j^k}} | \mathbb{T}^{i_{j^k}}) = 0$ 。结合这三个结论, 我们得到

$$0 \leq \text{KL}(\mathbb{V}^* | \mathbb{T}^*) \leq \liminf_{k \rightarrow \infty} \text{KL}(\mathbb{V}^{i_{j^k}} | \mathbb{T}^{i_{j^k}}) = 0.$$

因此, $\mathbb{V}^* = \mathbb{T}^*$, 这也意味着 $\mathbb{P}^* \in \mathcal{M} \cap \mathcal{R}(\mathbb{Q})$ [Shi 等人,

2023]。此外, 通过构造, $\mathbb{P}^i$ 的所有迭代都满足位置边缘约

束 $\int \mathbb{P}_n^i dv_n = q_n$, 因此也满足 $\int \mathbb{P}_n^* dv_n = q_n$ 。因此, 根据引理 B.7, $\mathbb{P}^*$, 它是唯一的多边缘薛定谔桥 $\mathbb{P}^{\text{mmSB}}$ 。□

C 高斯路径

我们框架的可扩展性基于高效地从由式 6 中 3MBB 路径的解所诱导的条件高斯路径中采样的能力。让我们将边缘路径 p_t 定义为桥的混合 $p_t(m_t) = \int p_t(\{\bar{x}_n\} | m_t | \{\bar{x}_n : t_n \geq t\}) dq(\{x_n\})$, 其中 $p_t(\{\bar{x}_n\} | m_t | \{\bar{x}_n : t_n \geq t\})$ 是与式 6 中 3MBB 路径的解相关联的条件概率路径。系统的线性意味着我们可以高效地从条件概率路径 $p_t(\{x_n\}) = \mathcal{N}(\mu_t, \Sigma_t)$ 中采样 $m_t = [x_t, v_t]$, $\forall t \in [0, T]$, 因为均值向量 μ_t 和协方差矩阵 Σ_t 具有解析解 [Särkkä and Solin, 2019]。

让我们回顾最优控制公式中关于 n^{th} 段的部分。

$$u_t^* = \begin{bmatrix} 0 & 0 \\ C_1^{(n)}(t) & C_2^{(n)}(t) \end{bmatrix} \begin{bmatrix} \mathbf{x}_t \\ \mathbf{v}_t \end{bmatrix} + \begin{bmatrix} 0 & 0 \\ C_1^{(n)}(t) & C_3^{(n)}(t) \end{bmatrix} \left[\sum_{j=n+1}^N \lambda_j \bar{x}_j \right], \forall t \in [t_n, t_{n+1}] \quad (73)$$

因此，相应的增广随机微分方程写为

$$dm_t = \left(\begin{bmatrix} 0 & 1 \\ C_1^{(n)}(t) & C_2^{(n)}(t) \end{bmatrix} \begin{bmatrix} \mathbf{x}_t \\ \mathbf{v}_t \end{bmatrix} + \begin{bmatrix} 0 \\ -C_1^{(n)}(t)\bar{x}_{n+1} + (C_3^{(n)}(t)) \sum_{j=n+1}^N \lambda_j^{(n)} \bar{x}_j \end{bmatrix} \right) dt + \mathbf{g} dW_t \quad (74)$$

$C_1^{(n)}(t), C_2^{(n)}(t), C_3^{(n)}$ 其中 (t) 是段特定函数， $\lambda_j^{(n)}$ 是未来固定点的系数。为了找到均值和协方差的表达式，我们遵循 [Särkkä和 Solin, 2019]，并分别考虑关于

μ_t 和 Σ_t 的以下常微分方程：

$$\begin{aligned} \dot{\mu}_t &= \begin{bmatrix} 0 & 1 \\ C_1^{(n)}(t) & C_2^{(n)}(t) \end{bmatrix} \mu_t + \begin{bmatrix} 0 \\ -C_1^{(n)}(t)\bar{x}_{n+1} + C_3^{(n)}(t) \sum_{j=n+1}^N \lambda_j^{(n)} \bar{x}_j \end{bmatrix} \\ \dot{\Sigma}_t &= \begin{bmatrix} 0 & 1 \\ C_1^{(n)}(t) & C_2^{(n)}(t) \end{bmatrix} \Sigma_t + \begin{bmatrix} 0 & 1 \\ C_1^{(n)}(t) & C_2^{(n)}(t) \end{bmatrix} \Sigma_t^\top + \mathbf{g} \mathbf{g}^\top \end{aligned} \quad (75)$$

均值常微分方程 如果我们显式地写出均值常微分方程系统，我们得到以下两个常微分方程

$$\begin{aligned} \dot{\mu}_x &= \mu_v \\ \dot{\mu}_v &= C_1^{(n)}(t)\mu_x + C_2^{(n)}(t)\mu_v - C_1^{(n)}(t)\bar{x}_{n+1} + C_3^{(n)}(t) \sum_{j=n+1}^N \lambda_j^{(n)} \bar{x}_j \end{aligned} \quad (76)$$

这对应于以下二阶常微分方程

$$\ddot{\mu}_x - C_2^{(n)}(t)\dot{\mu}_x + C_1^{(n)}(t)\mu_x = C_1^{(n)}(t)\bar{x}_{n+1} + C_3^{(n)}(t) \sum_{j=n+1}^N \lambda_j^{(n)} \bar{x}_j \quad (77)$$

然后使用常微分方程求解软件针对相应段的函数 $C^{(n)}$ 求解该常微分方程
 $n: t \in [t_n, t_{n+1})$.

协方差常微分方程 如果我们显式地写出均值常微分方程系统，我们得到以下两个常微分方程

$$\begin{aligned} \dot{\Sigma}_{xx} &= 2\Sigma_{xv} \\ \dot{\Sigma}_{xv} &= C_1^{(n)}(t)\Sigma_{xx} + C_2^{(n)}(t)\Sigma_{xv} + \Sigma_{vv} \\ \dot{\Sigma}_{vv} &= 2C_1^{(n)}(t)\Sigma_{xv} + 2C_2^{(n)}(t)\Sigma_{vv} + \sigma^2 \end{aligned} \quad (78)$$

这对应于以下三阶常微分方程

$$\frac{1}{2} \ddot{\Sigma}_{xx} - \frac{3}{2} C_2^{(n)}(t) \ddot{\Sigma}_{xx} + (C_2^{(n)}(t)^2 - 2C_1^{(n)}(t) - \frac{1}{2} \dot{C}_2^{(n)}(t)) \dot{\Sigma}_{xx} + (2C_2^{(n)}(t)C_1^{(n)}(t) - \dot{C}_1^{(n)}(t)) \Sigma_{xx} = 0 \quad (79)$$

然而，该方程即使使用软件包也难以求解。因此，我们在训练开始时使用欧拉积分对协方差常微分方程进行一次积分。该过程只需求解一次，并且可应用于任何固定耦合，在匹配过程中使用，因为方程 (78) 中的常微分方程组不依赖于任何点 $\bar{m}_n$ ，其唯一依赖是时间。这表明模拟协方差常微分方程的计算开销可以忽略不计。

Given the expressions of $\mu_t = \begin{bmatrix} \mu_t^x \\ \mu_t^v \end{bmatrix}$, and $\Sigma_t = \begin{bmatrix} \Sigma_t^{xx} & \Sigma_t^{xv} \\ \Sigma_t^{xv} & \Sigma_t^{vv} \end{bmatrix}$, one can obtain m_t through

$$m_t = \begin{bmatrix} X_t \\ V_t \end{bmatrix} = \begin{bmatrix} \mu_t^x \\ \mu_t^v \end{bmatrix} + \begin{bmatrix} L_t^{xx} \epsilon_0 \\ L_t^{xv} \epsilon_0 + L_t^{vv} \epsilon_1 \end{bmatrix} \quad (80)$$

其中矩阵 $L_t = \begin{bmatrix} L_t^{xx} & L_t^{xv} \\ L_t^{xv} & L_t^{vv} \end{bmatrix}$ 按照 Cholesky 分解计算得到 covariance matrix, and $\epsilon = \begin{bmatrix} \epsilon_0 \\ \epsilon_1 \end{bmatrix} \sim \mathcal{N}(0, \mathbf{I}_{2d})$.

D 扩展相关工作

薛定谔桥 近年来, 生成建模领域涌现出一批基于最优传输 (Optimal Transport) [Villani et al., 2009] 的原则性方法。其中最突出的问题表述是薛定谔桥 (Schrödinger Bridge, SB; Schrödinger [1931])。特别是, 在提出基于迭代比例拟合 (Iterative Proportional Fitting, IPF) 的训练方案之后, SB 在生成建模领域获得了显著关注, 该方案是 Sinkhorn 算法的连续状态空间扩展, 用于求解动态 SB 问题 [De Bortoli et al., 2021, Vargas et al., 2021]。值得注意的是, SB 推广了标准扩散模型, 在任意分布 π_0, π_1 之间传输数据, 采用完全非线性的随机过程, 寻求最小化动能的唯一路径测度。薛定谔桥 [Schrödinger, 1931] 在路径测度意义下关注寻找最优测度 $\mathbb{P}^*$, 该测度最小化以下优化问题

$$\min_{\mathbb{P}} \text{KL}(\mathbb{P}|\mathbb{Q}), \quad \mathbb{P}_0 = \pi_0, \mathbb{P}_1 = \pi_1 \quad (81)$$

其中 $\mathbb{Q}$ 是马尔可夫参考测度。因此, 动态薛定谔桥的解 $\mathbb{P}^*$ 被认为是与 $\mathbb{Q}$ 最接近的路径测度。动态薛定谔桥的另一种表述通过应用 Girsanov 定理将问题框架化为随机最优控制 (Stochastic Optimal Control, SOC) 问题而关键性地出现 [Chen 等人, 2016, 2021]。

$$\min_{u_t, p_t} \int_0^1 \mathbb{E}_{p_t} [\|u_t\|^2] dt \quad \text{s.t.} \quad \frac{\partial p_t}{\partial t} = -\nabla \cdot (u_t p_t) + \frac{\sigma^2}{2} \Delta p_t, \quad \text{and} \quad p_0 = \pi_0, \quad p_1 = \pi_1 \quad (82)$$

最后, 注意静态薛定谔桥等价于熵正则化的最优传输表述 [Pavon 等人, 2021, Nutz, 2021, Cuturi, 2013]。

$$\min_{\pi \in \Pi(\pi_0, \pi_1)} \int_{\mathbb{R}^d \times \mathbb{R}^d} \|x_0 - x_1\|^2 d\pi(x_0, x_1) + \epsilon \text{KL}(\pi | \pi_0 \otimes \pi_1) \quad (83)$$

这个正则化项通过 Sinkhorn 算法实现了高效求解, 并带来了诸多好处, 如平滑性和其他统计性质 [戈萨尔等人, 2022 年, 莱热, 2021 年, 佩雷等人, 2019 年]。

桥匹配 Peluchetti [2023] 首次提出马尔可夫投影以提出桥匹配 (Bridge matching), 而 Liu 等人 [2022a] 利用其在受限域中学习表示。桥匹配目标提供了一种计算高效的替代方案, 但需要额外的假设。对此, 动作匹配 (Action Matching) Neklyudov 等人 [2023] 提出了一种假设最少的一般匹配方法, 但代价是不利于可扩展性。此外, 近期进展引入了更通用的条件生成建模框架。去噪扩散桥模型 (Denoising Diffusion Bridge Models, DDBMs) 通过学习扩散桥的得分, 将传统扩散模型扩展以处理任意源分布和目标分布, 从而统一并推广了基于得分的扩散和流匹配等方法 [Zhou 等人, 2023]。类似地, 随机插值框架 [Albergo 等人, 2023] 通过定义在分布之间插值的连续时间随机过程, 整合了基于流和基于扩散的方法。这些插值通过引入辅助隐变量, 在有限时间内实现精确桥接, 为插值路径提供了灵活的控制。

近期, 这些匹配框架已被用于求解薛定谔桥 (Schrödinger Bridge, SB) 问题。DSBM (Shi 等人, 2023) 采用迭代马尔可夫拟合 (Iterative Markovian Fitting, IMF) 来获得薛定谔桥的解, 而 De Bortoli 等人 [2023] 探索了流匹配与桥匹配过程, 提出了一种保留耦合信息的修正方法, 展示了在学习图像翻译任务混合模型中的高效性。 $SF^2 - M$ [Tong 等人, 2023a] 提供了一个无需仿真的目标函数来推断随机动力学, 展示了在求解薛定谔桥问题中的高效性。GSBM Liu 等人 [2024] 提出了一个求解分布匹配的框架, 以考虑任务特定的状态代价。虽然这些方法旨在识别最优耦合, 但 [Somnath 等人, 2023] 和 [Liu 等人, 2023] 提出了在先验耦合数据之间的桥匹配算法, 即来自静态薛定谔桥的干净图像与损坏图像之间的配对或生物数据对。最后, 还有一些工作旨在通过引入一个轻量求解器, 利用高斯混合参数化实现最优匹配, 从而提高这些匹配框架的效率 [Gushchin 等人, 2024a]。

流匹配 与此同时，也出现了一些采用确定性动力学的方法。Lipman 等人 [2022] 引入了桥匹配的确定性对应方法；流匹配

(FM) 用于训练连续归一化流 (Continuous Normalizing Flows, CNFs; Chen 等人 [2018])，使用固定的条件概率路径。进一步的发展包括条件流匹配 (Conditional Flow Matching, CFM)，它为训练 CNFs 提供了一个稳定的回归目标，无需高斯源分布或密度评估 [Tong 等人, 2023b]；度量流匹配 (Metric Flow Matching, MFM)，学习数据流形上的近似测地线 [Kapusniak 等人, 2024]；以及潜空间流匹配，提高了高分辨率图像合成的计算效率 [Dao 等人, 2023]。最后，CFM 精确地恢复了修正流 (Rectified Flow) 的第一次迭代 [Liu 等人, 2022b]，这是一种学习常微分方程模型以在分布之间进行传输的迭代方法。

多边际 流匹配模型的进展之一是引入了多边际流匹配框架 [Rohbeck et al., 2024]。与本文方法类似，他们提出了一种免仿真的训练方法，利用基于三次样条的流插值以及跨时间和条件的无分类器引导。TrajectoryNet [Tong et al., 2020] 和 MIOFlow [Huguet et al., 2022] 分别将最优传输与连续归一化流 [Chen et al., 2018] 和流形嵌入相结合，以建模通过多个点的非线性连续轨迹。在随机领域，近期工作提出了通过将迭代比例拟合 (Iterative Proportional Fitting) ——Sinkhorn 算法的连续扩展，用于求解动态薛定谔桥问题 [De Bortoli et al., 2021]——扩展到相空间并适配 Bregman 迭代来训练 mmSB [Chen et al., 2023a]。另一种方法交替学习未观测轨迹上的分段薛定谔桥，并在指定参考类内细化动力学的最佳猜测 [Shen et al., 2024]。更近期，将参考动力学建模为一类特殊的光滑高斯路径被证明能获得更规则且可解释的轨迹 [Hong et al., 2025]。此外，多边际问题最近通过深度动量多边际薛定谔桥 [DMSB; Chen et al. [2023a]] 得到解决，该方法提出通过适配 Bregman 迭代在相空间中求解 mmSB。更近期，一种求解 mmSB 的迭代方法提出在预选参考类内学习分段薛定谔桥动力学 [Shen et al., 2024]。相比之下，将参考动力学建模为光滑高斯路径被证明能获得时间上更连贯且平滑的轨迹 [Hong et al., 2025]，但置信传播限制了其在高维空间中的扩展。最后，Wasserstein Lane – Riesenfeld (WLR) 是一种几何感知方法，用于从点云重建平滑轨迹。它在 Wasserstein 空间中执行连续测地平均，生成样条状曲线，能够处理质量分裂/分叉，在细胞数据集上取得了优异结果 [Banerjee et al., 2024]。

E 实验补充细节

E.1 一般信息

在本节中，我们重新审视实验结果，以评估 3MSBM 在多种轨迹推断任务上的性能，例如 Lotka-Volterra、墨西哥湾洋流、单细胞测序和北京空气质量数据。我们与专门设计用于多边际设置的最先进方法进行了比较，例如深度动量多边际薛定谔桥 (DMSB; Chen 等人 [2023a])、带迭代参考精化的薛定谔桥 (SBIRR; Shen 等人 [2024])、平滑薛定谔桥 (SmoothSB; Hong 等人 [2025]) 和多边际流匹配 (MMFM; Rohbeck 等人 [2024])，以及两种基于 NeuralODE 的方法：MIOFlow [Huguet 等人, 2022] 和 DeepRUOT [Zhang 等人, 2024b]。我们使用了所有比较方法的官方实现，采用默认超参数。对于 3MSBM 的所有实验，我们采用了 Chen 等人 [2023b]、Dockhorn 等人 [2021] 的 ResNet 架构。我们使用 AdamW 优化器，并应用衰减率为 0.999 的指数移动平均。所有结果均在 5 个随机种子上取平均，均值和标准差在第 4 节和下面的表格中报告。实验在配备 24 GB 显存的 RTX 4090 GPU 上运行。

E.2 Lotka-Volterra

我们首先考虑由 Lotka – Volterra (LV) 方程 [Goel 等人, 1971] 生成的合成数据集，该方程通过耦合非线性动力学模拟捕食者-猎物相互作用。我们使用了 [Shen 等人, 2024] 的数据集，包含 5 个训练时间点和 4 个验证时间点，每个时间点有 50 个观测值

表 9: 在 LV 数据集上, DeepRUOT、MIOFlow、SBIRR、MMFM、Smooth SB 和 3MSBM 在留出边界上的 SWD、MMD、 $\mathcal{W}_1$ 和 $\mathcal{W}_2$ 的 5 个种子平均值 (越低越好)。(a) SWD (b) MMD

Method	t_1	t_3	t_5	t_7
DeepRUOT	0.30	0.16	0.22	0.44
SBIRR	0.17	0.18	0.24	0.48
MIOFlow	1.53	1.49	1.23	1.46
Smooth SB	0.49	0.18	0.13	0.37
DMSB	0.64	0.67	0.98	0.63
MMFM	0.21	0.25	0.39	0.57
3MSBM	0.29	0.13	0.11	0.37

Method	t_1	t_3	t_5	t_7
DeepRUOT	3.02	0.20	0.39	0.48
SBIRR	0.44	0.53	0.46	0.50
MIOFlow	7.09	6.52	6.29	5.28
Smooth SB	3.23	1.21	0.32	0.42
DMSB	3.46	3.43	1.16	1.74
MMFM	0.52	0.60	0.63	0.77
3MSBM	4.33	0.72	0.40	0.40

Method	t_1	t_3	t_5	t_7
DeepRUOT	0.40	0.17	0.29	0.62
MIOFlow	2.53	2.12	1.76	1.53
SBIRR	0.19	0.20	0.30	0.48
Smooth SB	0.29	0.27	0.22	0.68
DMSB	0.99	0.74	0.60	0.98
MMFM	0.24	0.43	0.57	0.75
3MSBM	0.23	0.18	0.12	0.35

Method	t_1	t_3	t_5	t_7
DeepRUOT	0.44	0.19	0.31	0.65
MIOFlow	2.77	2.34	1.76	1.55
SBIRR	0.19	0.25	0.45	0.74
Smooth SB	0.27	0.27	0.22	0.68
DMSB	0.84	0.98	0.71	1.24
MMFM	0.22	0.43	0.77	1.23
3MSBM	0.24	0.17	0.15	0.36

每个时间点。具体来说,生成的数据集总共包含 9 个边界;偶数索引用于训练模型 (即 t_0, t_2, t_4, t_6, t_8),其余时间点用于评估模型插补和推断缺失时间点的有效性。在本实验中,我们将 3MSBM 与 DeepRUOT、MIOFlow、DMSB、SBIRR、MMFM 和 Smooth SB 进行了基准测试。表 9 报告了每种方法在 5 个种子上的平均性能,涉及与验证点的 SWD、MMD、 $\mathcal{W}_1$ 和 $\mathcal{W}_2$ 距离。我们方法在 LV 上的超参数选择为:扩散系数设为 $\sigma = 0.3$,学习率设为 10^{-4} 。

E.3 墨西哥湾

随后,我们评估了模型在真实世界多边界数据集中推断缺失时间点的有效性。该数据集包含墨西哥湾 (Gulf of Mexico, GoM) 涡旋周围速度场的洋流快照。与 LV 数据集类似,我们使用了 [沈等人, 2024a] 中提供的大涡旋数据集,该数据集包含 300 个样本,分布在 5 个训练时间和 4 个验证时间上。更具体地说,在总共 9 个边界中,偶数索引的时间点 (即 t_0, t_2, t_4, t_6, t_8) 用于训练,其余时间点被留出以评估模型填补和推断缺失时间状态的能力。在本实验中,我们将 3MSBM 与 DeepRUOT、MIOFlow、DMSB、SBIRR、MMFM 和 Smooth SB 进行了比较。表 10a 展示了每种方法在 5 个随机种子上的平均性能,评估指标为与验证点的 SWD、MMD、 $\mathcal{W}_1$ 和 $\mathcal{W}_2$ 距离。我们的方法在 GoM 实验中使用的超参数为:匹配的批大小为 32,扩散系数设为 $\sigma = 0.3$,学习率设为 $2 \cdot 10^{-4}$ 。

E.4 北京空气质量

我们使用北京多站点空气质量数据集 [Chen, 2017] 重新审视了实验。该数据集包含北京 12 个空气质量监测站点的每小时空气污染物数据。我们重点关注 PM2.5 数据,该指标监测直径小于 2.5 微米的颗粒物密度,时间范围为 2013 年 1 月至 2015 年 1 月。我们聚焦于单个监测站点,并将同一个月内收集的测量值进行聚合。为了在观测之间引入时间间隔,我们每隔一个月选取一次测量值,最终得到 13 个时间快照。对于填补任务,我们省略了 t_2, t_5, t_8 和 t_{11} 处的数据,其余快照构成训练集。表 11a 展示了每种方法在 5 个随机种子上的平均性能,指标为与验证时间点之间的 SWD、MMD、 $\mathcal{W}_1$ 和 $\mathcal{W}_2$ 距离,将我们的 3MSBM 方法与以下方法进行基准比较:

表 10: 在 GoM 数据集上, DeepRUOT、MIOFlow、SBIRR、MMFM、Smooth SB 和 3MSBM 在留出边缘分布上的 SWD、MMD、 $\mathcal{W}_1$ 和 $\mathcal{W}_2$ 在 5 个随机种子上的平均值 (越低越好)。(a) SWD (b) MMD

Method	t_1	t_3	t_5	t_7
DeepRUOT	0.21	0.33	0.23	0.21
MIOFlow	0.83	0.34	1.23	0.97
SBIRR	0.15	0.11	0.11	0.09
Smooth SB	0.17	0.14	0.10	0.13
DMSB	0.23	0.54	0.39	0.28
MMFM	0.23	0.25	0.10	0.19
3MSBM	0.14	0.14	0.08	0.06

Method	t_1	t_3	t_5	t_7
DeepRUOT	2.35	1.75	1.30	1.10
MIOFlow	6.52	4.13	6.88	6.11
SBIRR	4.65	0.82	1.15	0.35
Smooth SB	4.98	4.02	0.84	0.28
DMSB	4.50	4.40	4.57	3.37
MMFM	0.91	1.20	0.49	0.51
3MSBM	3.99	2.92	0.87	0.52

(c) $\mathcal{W}_1$				
Method	t_1	t_3	t_5	t_7
DeepRUOT	0.29	0.29	0.20	0.25
MIOFlow	1.10	0.55	1.67	1.69
SBIRR	0.28	0.15	0.11	0.15
Smooth SB	0.16	0.27	0.21	0.56
DMSB	0.24	0.31	0.70	0.46
MMFM	0.33	0.38	0.22	0.29
3MSBM	0.17	0.21	0.09	0.12

(d) $\mathcal{W}_2$				
Method	t_1	t_3	t_5	t_7
DeepRUOT	0.32	0.43	0.36	0.33
MIOFlow	1.11	0.48	1.68	1.70
SBIRR	0.24	0.13	0.21	0.17
Smooth SB	0.22	0.27	0.21	0.16
DMSB	0.28	0.30	0.72	0.46
MMFM	0.33	0.32	0.19	0.31
3MSBM	0.20	0.18	0.07	0.09

表 11: 在北京空气质量数据集上, DeepRUOT、MIOFlow、MMFM、Smooth SB 和 3MSBM 在留出边缘分布上的 SWD、MMD、 $\mathcal{W}_1$ 和 $\mathcal{W}_2$ 在 5 个随机种子上的平均值 (越低越好)。(a) SWD (b) MMD

Method	t_1	t_3	t_5	t_7
DeepRUOT	13.67	52.60	71.34	84.67
MIOFlow	46.64	79.06	76.06	60.87
Smooth SB	28.61	28.81	35.79	32.90
DMSB	21.10	21.92	35.53	35.75
MMFM	17.51	23.94	32.56	39.98
3MSBM	17.70	9.78	22.23	32.23

(c) $\mathcal{W}_1$				
Method	t_1	t_3	t_5	t_7
DeepRUOT	10.49	39.82	51.00	68.97
MIOFlow	31.79	56.35	57.89	45.36
Smooth SB	23.73	23.88	24.70	28.61
DMSB	58.79	32.70	40.22	42.06
MMFM	28.08	26.40	37.73	51.12
3MSBM	12.71	57.44	26.02	29.61

Method	t_1	t_3	t_5	t_7
DeepRUOT	0.36	0.34	0.99	1.67
MIOFlow	0.58	0.92	0.38	0.51
Smooth SB	0.41	0.43	0.39	0.48
DMSB	0.76	0.79	0.54	0.47
MMFM	0.44	0.56	0.59	0.55
3MSBM	0.35	0.85	0.28	0.32

(d) $\mathcal{W}_2$				
Method	t_1	t_3	t_5	t_7
DeepRUOT	13.67	52.59	71.35	84.67
MIOFlow	46.64	79.06	76.06	60.87
Smooth SB	28.61	28.81	35.79	32.90
DMSB	60.19	38.77	41.38	43.25
MMFM	26.42	29.95	43.49	49.96
3MSBM	12.87	79.36	27.89	32.26

MMFM (使用三次样条)、DeepRUOT、MIOFlow 和 Smooth SB。注意, 本实验未与 SBIRR 进行基准对比, 因为缺少相应的信息先验测度。北京空气质量实验中, 本文方法使用的超参数为: 总样本数 1000, 匹配批大小为 64, 扩散系数设为 $\sigma = 0.2$, 学习率设为 $5 \cdot 10^{-5}$ 。

E.5 单次测序

最后, 我们重新审视了在拟胚体 (Embryoid Body, EB) 干细胞分化数据集上的实验, 该数据集记录了细胞在 27 天周期内 5 个阶段的进展。按照第 4.4 节的设置, 我们使用了来自 [Tong 等人, 2020; Moon 等人, 2019] 的预处理数据, 并进行了嵌入

在 100 维主成分分析特征空间中。细胞快照在五个离散时间间隔采集： $t_0 \in [0, 3]$, $t_1 \in [6, 9]$, $t_2 \in [12, 15]$, $t_3 \in [18, 21]$, $t_4 \in [24, 27]$ 。下面，我们展示我们的 3MSBM 与 DeepRUOT、MIOFlow、DMSB、SBIRR、MMFM 的比较结果。表 10a 展示了每种方法在 5 个随机种子上的平均性能，指标包括 SWD、MMD、 $\mathcal{W}_1$ 和 $\mathcal{W}_2$ 距离，这些距离是从验证点（即快照 t_1 和 t_3 处）计算得到的。观察表 12 的结果，很明显我们的 3MSBM 在高维 EB-100 任务中在所有指标上始终优于最先进的算法。我们方法在每个 EB 实验中使用的超参数为：总样本数 1000，匹配的批大小为 64，扩散系数设为 $\sigma = 0.1$ ，学习率设为 10^{-4} 。

表 12: 在 EB-100 数据上，针对 DeepRUOT、MIOFlow、SBIRR、MMFM、Smooth SB 和 3MSBM，在留出边际分布上 5 个随机种子下的 SWD、MMD、 $\mathcal{W}_1$ 和 $\mathcal{W}_2$ 的均值（越低越好）。(a) SWD (b) MMD

Method	t_1	t_3
DeepRUOT	0.73	0.67
MIOFlow	0.84	0.94
SBIRR	0.80	0.91
DMSB	0.58	0.54
MMFM	0.59	0.76
3MSBM	0.48	0.38

(c) $\mathcal{W}_1$

Method	t_1	t_3
DeepRUOT	13.45	14.90
MIOFlow	13.20	13.57
SBIRR	15.09	20.39
DMSB	14.08	15.22
MMFM	13.61	14.64
3MSBM	13.89	13.11

Method	t_1	t_3
DeepRUOT	0.43	0.36
MIOFlow	1.01	0.92
SBIRR	0.71	0.73
DMSB	0.38	0.36
MMFM	0.37	0.35
3MSBM	0.18	0.14

(d) $\mathcal{W}_2$

Method	t_1	t_3
DeepRUOT	13.64	15.10
MIOFlow	13.66	14.05
SBIRR	15.42	20.98
DMSB	14.83	15.49
MMFM	14.68	14.83
3MSBM	14.51	13.26

E.6 关于 σ 的消融实验

在随机最优控制（Stochastic Optimal Control）[Theodorou 等人，2010] 中， σ 的值在表示环境不确定性或控制应用误差方面起着关键作用。因此，最优控制策略会随着噪声程度的不同而显著变化。图 14 展示了我们的 3MSBM 在 EB 和 GoM 数据集上相对于不同噪声的性能。我们观察到在所有测试的 σ 值下，训练边际的性能保持一致，而对于验证集中的点，将 σ 增加到一定程度被认为是有益的，因为它能提升性能。图 13 中 GoM 的样本轨迹进一步验证了这一趋势。低噪声值（例如 $\sigma = 0.05$ ）导致轨迹过于紧凑，而在高噪声（例如 $\sigma = 1.0$ ）下，轨迹变得过于分散。另一方面，适度的噪声值（例如 $\sigma = 0.4$ ）达到了良好的平衡，使得轨迹能够充分展开并与验证边际相匹配。




图 13: 不同 σ 值下在墨西哥湾流数据集上推断的轨迹比较




图 14: 在 EB 和 GoM 上, 不同 sigma 值下验证集和训练集边际的 SWD