

Adjoint Schrödinger Bridge Sampler

Guan-Horng Liu^{1,*}, Jaemoo Choi^{2,*}, Yongxin Chen², Benjamin Kurt Miller¹, Ricky T. Q. Chen^{1,*}

¹FAIR at Meta, ²Georgia Institute of Technology

*Core contributors

用于学习从玻尔兹曼分布（Boltzmann distribution）采样的计算方法——其中目标分布仅通过未归一化的能量函数已知——近期取得了显著进展。然而，由于缺乏显式的目标样本，先前基于扩散的方法（称为扩散采样器）通常需要重要性加权估计或复杂的学习过程。两者都在可扩展性与对能量和模型的大量评估之间进行权衡，从而限制了它们的实际应用。本文提出伴随薛定谔桥采样器（Adjoint Schrödinger Bridge Sampler, ASBS），这是一种新颖的扩散采样器，采用简单且可扩展的基于匹配的目标，同时在训练过程中无需估计目标样本。ASBS 建立在薛定谔桥（Schrödinger Bridge）这一数学模型之上，通过动力学最优传输提升采样效率。借助随机最优控制理论的新视角，我们展示了基于薛定谔桥的扩散采样器如何通过伴随匹配（Adjoint Matching）在大规模下学习，并证明其收敛到全局解。值得注意的是，ASBS 通过放宽在很大程度上限制设计空间的无记忆条件，将最近的伴随采样（Adjoint Sampling, Havens 等人，2025）推广到任意源分布。通过大量实验，我们证明了 ASBS 在从经典能量函数、摊销构象生成和分子玻尔兹曼分布采样方面的有效性。

Date: November 26, 2025

Correspondence: ghliu@meta.com

Code: https://github.com/facebookresearch/adjoint_samplers



1 引言

从玻尔兹曼分布采样是计算科学中的一个基本问题，在贝叶斯推断、统计物理和化学中有着广泛的应用（Box 和 Tiao, 2011; Binder 等人，1992; Tuckerman, 2023）。数学上，我们的目标是从一个目标分布 $\nu(x)$ 中采样，该分布通过一个未归一化的、通常是可微的能量函数 $E(x) : \mathcal{X} \subseteq \mathbb{R}^d \rightarrow \mathbb{R}$ 已知，

$$\nu(x) := \frac{e^{-E(x)}}{Z}, \quad \text{where } Z := \int_{\mathcal{X}} e^{-E(x)} dx \quad (1)$$

是一个难以处理的归一化常数。例如，分子系统的能量函数 $E(x)$ 根据粒子的三维位置量化化学结构的稳定性。较低的能量表示结构更稳定，因此其出现的可能性更高，*i.e.*, $\nu(x) \propto e^{-E(x)}$ 。

从 $\nu(x)$ 生成样本的经典方法依赖于马尔可夫链蒙特卡洛算法，该算法运行一条马尔可夫链，其平稳分布为 $\nu(x)$ （Metropolis 等，1953; Neal, 2001; Del Moral 等，2006）。然而，这些方法往往混合时间较慢，且需要大量评估能量函数，由于复杂度极高，限制了其实际应用。

为了提高采样效率，现代采样器专注于学习更好的提议分布（Noé等，2019; Midgley 等，2023）。其中，基于扩散的生成模型（Song 等，2021; Ho 等，2020）的最新进展催生了一类扩散采样器，它们考虑以下形式的随机微分方程：

$$dX_t = [f_t(X_t) + \sigma_t u_t^\theta(X_t)] dt + \sigma_t dW_t, \quad X_0 \sim \mu(X_0), \quad (2)$$

表 1 与先前的扩散采样器相比，伴随薛定谔桥采样器（ASBS）为扩散采样器（2）提供了最灵活的设计，同时通过可扩展的匹配目标学习漂移 u_t^θ ，这些目标不依赖于重要性权重的计算。

Method	Design condition for (2)		Learning method for u_t^θ	
	Non-memoryless	Arbitrary prior	Matching objective ¹	No reliance on IWs
PIS (Zhang and Chen, 2022) DDS (Vargas et al., 2023)	✗	✗	✗	✓
LV-PIS & LV-DDS (Richter and Berner, 2024)	✗	✗	✗	✗
PDDS (Phillips et al., 2024) iDEM (Akhound-Sadegh et al., 2024)	✗	✗	✓	✗
AS (Havens et al., 2025)	✗	✗	✓	✓
Sequential SB (Bernton et al., 2019)	✓	✓	✗	✗
Adjoint Schrödinger Bridge Sampler (Ours)	✓	✓	✓	✓

其中 $f_t(x) : [0, 1] \times \mathcal{X} \rightarrow \mathcal{X}$ 为基础漂移， $\sigma_t : [0, 1] \rightarrow \mathbb{R}_{>0}$ 为噪声调度， $\mu(x)$ 为初始源分布。给定 (f_t, σ_t, μ) ，扩散采样器学习一个参数化漂移 $u_t^\theta(x)$ ，在终端时间 $t = 1$ 将样本传输到目标分布 $\nu(x)$ 。

近年来，学习扩散采样器的计算方法显著增长（Zhang 和 Chen, 2022；Vargas 等, 2023；Berner 等, 2024；Chen 等, 2025）。由于（1）中问题设置的特殊性，目标分布仅由其能量 $E(x)$ 定义，而非显式的目标样本。这一特性使得现代生成建模技术——尤其是得分匹配目标¹——难以直接应用。因此，先前基于匹配的扩散采样器（Phillips 等, 2024；Akhound-Sadegh 等, 2024；De Bortoli 等, 2024）通常需要通过重要性权重对目标样本进行计算密集型的估计。

最近，Havens 等（2025）引入了伴随采样（AS），这是一类新的扩散采样器，其匹配目标仅依赖于策略内样本，从而大大提高了可扩展性。通过结合随机最优控制理论（Kappen, 2005；Todorov, 2007），AS 促进了伴随匹配（Domingo-Enrich 等, 2025）的使用，这是一种新颖的匹配目标，对生成样本施加自治性，有效消除了对目标样本的需求。

然而，AS 的效率是通过将 SDE (2) 的特定实例化来实现的，以满足所谓的无记忆条件。该条件——在第 2 节中正式讨论——将其源分布限制为 Dirac delta $\mu(x) := \delta$ ，排除了使用常见先验（如高斯先验）或领域特定先验（如分子系统中的谐振子）的可能性（Jing 等人, 2023）。值得注意的是，无记忆条件构成了所有先前基于匹配的扩散采样器的基础，限制了 (2) 的设计空间，使其无法采用其他已知能提升传输效率的选择（Shaul 等人, 2023）。尽管在非基于匹配的方法中，该条件已被放宽，但代价是极高的计算复杂度（Richter 和 Berner, 2024；Bernton 等人, 2019），然而据我们所知，目前尚无任何扩散采样器成功地将匹配目标与非无记忆条件相结合。表 1 总结了先前扩散采样器之间的比较。

本文提出伴随薛定谔桥采样器（ASBS），这是一种新颖的基于伴随匹配的扩散采样器，完全消除了对无记忆条件的要求。形式上，ASBS 将学习扩散采样器重新表述为分布约束优化问题，即薛定谔桥（SB）问题（Schrödinger, 1931, 1932；Léonard, 2013；Chen 等人, 2016）：

$$\min_u D_{\text{KL}}(p^u \| p^{\text{base}}) = \mathbb{E}_{X \sim p^u} \left[\int_0^1 \frac{1}{2} \|u_t^\theta(X_t)\|^2 dt \right], \quad (3a)$$

$$\text{s.t. } dX_t = [f_t(X_t) + \sigma_t u_t^\theta(X_t)] dt + \sigma_t dW_t, \quad X_0 \sim \mu(X_0), \quad X_1 \sim \nu(X_1). \quad (3b)$$

这里， p^u 表示由 (3b) 中的 SDE 诱导的路径分布，而 $p^{\text{base}} := p^{u:=0}$ 表示当 $u_t := 0$ 时由“基础”SDE 诱导的路径分布。通过最小化它们的 KL 散度，SB 问题 (3) 寻求动力学最优漂移 u_t^* ——这种最优性结构与采样效率高度相关，见

¹ 匹配目标是一个简单的回归损失， $\mathbb{E} \|u^\theta$

$(X_t) - v_t(X_t, X_1)\|^2$ ，相对于某个可处理的 v_t 。

生成建模 (Generative Modeling) (Finlay 等, 2020; Liu 等, 2023)。由于 AS 中的 SOC 问题对应于 SB 问题在 $(f_t, \mu) := (0, \delta)$ 时的特例, ASBS 通过求解更一般的 SB 问题将 AS 扩展到处理非无记忆条件 (见定理 3.1)。在计算上, ASBS 通过利用伴随匹配目标消除了估计目标样本的需要, 从而保留了 AS 的所有可扩展性优势。它还引入了校正匹配目标, 以校正由非无记忆条件引起的非平凡偏差。我们证明在两个匹配目标之间交替优化等价于执行迭代比例拟合算法 (Kullback, 1968), 确保 ASBS 的全局收敛 t (见定理 3.2)。通过大量实验, 我们展示了 ASBS 在采样多粒子能量函数的各种基准上优于先前扩散采样器的性能。

to

总之, 我们提出以下贡献:

- 我们引入 ASBS, 一种基于 SB 的扩散采样器, 通过求解具有任意先验的一般 SB 问题, 能够仅使用未归一化能量函数采样目标分布。
- 我们将 ASBS 建立在一个新的 SOC 框架上, 该框架移除了限制性的无记忆条件, 开发了一种可扩展的基于匹配的算法, 并证明了理论收敛到全局解。
- 我们展示了 ASBS 在采样经典能量函数的玻尔兹曼分布、丙氨酸二肽分子和摊销构象生成方面优于先前方法的性能。

2 预备知识

我们重新审视 Domingo-Enrich 等 (2025) 引入的无记忆条件, 并考察其对基于 SOC 的扩散采样器 (Zhang 和 Chen, 2022; Havens 等, 2025) 构造的影响, 这些采样器与我们的 ASBS 密切相关。更多回顾见 A 节。

随机最优控制 (Stochastic Optimal Control, SOC) SOC 问题 (4) 研究的是一个优化问题:

$$\min_u \mathbb{E}_{X \sim p^u} \left[\int_0^1 \frac{1}{2} \|u_t(X_t)\|^2 dt + g(X_1) \right] \quad \text{s.t. (2)}, \quad (4)$$

与 SB 问题 (3) 不同, 它在终端时刻 $t = 1$ 处包含一个额外的终端代价 $g(x) : \mathcal{X} \rightarrow \mathbb{R}$, 并且考虑的是没有终端约束 $X_1 \sim \nu$ 的随机微分方程。研究这个特定优化问题的主要原因是, 最优分布可以通过 2 解析地得到

$$p^*(X_0, X_1) = p^{\text{base}}(X_0, X_1) e^{-g(X_1) + V_0(X_0)}, \quad \text{其中} \quad V_0(x) = -\log \int p_{1|0}^{\text{base}}(y|x) e^{-g(y)} dy \quad (5)$$

是初始值函数。也就是说, 最优分布 p^* 是基础分布 $p^{\text{base}} := p^{u:=0}$ 的指数倾斜版本。具体来说, p^{base} 被终端代价 $-g(X_1)$ 和初始值函数 $V_0(X_0)$ 所倾斜, 而初始值函数是难以处理的。因此, 为了确保其边缘分布 $p^*(X_1)$ 遵循目标分布 $\nu(X_1)$, 我们必须从 $V_0(X_0)$ 中消除初始值函数偏差。

无记忆条件与基于随机最优控制 (SOC) 的扩散采样器 消除上述初始值函数偏差的一种常见方法 (被大多数扩散采样器采用) 是将基础过程类别限制为无记忆的。形式上, 无记忆条件假设基础分布中 X_0 与 X_1 之间统计独立: 无记忆

$$p^{\text{base}}(X_0, X_1) := p^{\text{base}}(X_0) p^{\text{base}}(X_1). \quad (6)$$

这个无记忆条件 (6) 简化了终端时刻 $t = 1$ 处的最优分布, 并且在选择适当的终端代价 $g(x)$ 后, 可以恢复目标分布 ν ,

$$p^*(X_1) \stackrel{\text{memoryless}}{=} \int p^{\text{base}}(X_0) p^{\text{base}}(X_1) e^{-g(X_1) + V_0(X_0)} dX_0 \propto p^{\text{base}}(X_1) e^{-g(X_1)} = \nu(X_1),$$

方程 (5) 可通过将 (4) 重写为 $D_{\text{KL}}(p^u || p^{\text{base}}) + \mathbb{E}_{p_1^u}[g(X_1)]$, 然后计算解析解和归一化得到。详见第 A.1 节。
 $p^*(X_1|X_0) \propto p^{\text{base}}(X_1|X_0) e^{-g(X_1)}$ $\int p^{\text{base}}(X_1|X_0) e^{-g(X_1)} dX_1 = e^{-V_0(X_0)}$




图 1 无记忆条件对基于 SOC 的扩散采样器学习的影响。我们考虑高斯先验 $\mu(x) := \mathcal{N}(x; 0, 1)$ ，其中 (f_t, σ_t) 在第一幅图中设为 VP-SDE，其余图中设为 $(0, 0.2)$ ；详见第 A.1 节。无记忆条件注入显著噪声（左）以修正原本有偏的优化（中），而 ASBS 能够成功去除任何非无记忆过程的偏差（右）。

其中最后一个等式是由于将终端代价设为 $g(x) := \log \frac{p_1}{\nu(x)} \text{ base } 1$ 。通常，无记忆条件 (6) 通过精心设计基础分布 p^{base} 或等价地 (2) 中的参数 (f_t, σ_t, μ) 来强制满足。例如，方差保持过程 (VP; Song 等, 2021) 考虑线性基础漂移 f_t 、随时间显著增长的噪声调度 σ_t 以及高斯先验 μ ；见图 1。或者，可以通过狄拉克 δ 先验 $\mu(x) := \delta_0(x)$ 和 $f_t := 0$ 来实现 (6)，从而得到以下 SOC 问题 (Zhang 和 Chen, 2022)：

$$\min_u \mathbb{E}_{X \sim p^u} \left[\int_0^1 \frac{1}{2} \|u_t(X_t)\|^2 dt + \log \frac{p_1^{\text{base}}(X_1)}{\nu(X_1)} \right] \quad \text{s.t.} \quad dX_t = \sigma_t u_t(X_t) dt + \sigma_t dW_t, \quad X_0 = 0. \quad (7)$$

基于上述推理，求解 (7) 可得到一个扩散采样器，在 $t=1$ 处将样本传输到目标分布，其中伴随采样 (Havens 等, 2025) 是该类方法中唯一可扩展的方法。尽管令人鼓舞，但 (7) 中的 SOC 问题仍受限于其平凡的源分布，排除了采样玻尔兹曼分布时可能更有效的选项。

3 伴随薛定谔桥采样器

我们通过求解 SB 问题 (3) 引入一种新的扩散采样器，其中目标分布 $\nu(x)$ 由其能量函数 $E(x)$ 给出，而非显式样本。所有证明见第 B 节。

3.1 SB 问题的 SOC 特性

SB 问题 (3) ——作为带分布约束的优化问题——在最优传输、随机控制以及近期的机器学习领域得到广泛研究 (Léonard, 2012; Chen 等, 2021; De Bortoli 等, 2021)。其动能最优漂移 u^* 满足以下最优性方程：

$$u_t^*(x) = \sigma_t \nabla \log \varphi_t(x), \quad \text{其中} \quad \begin{cases} \varphi_t(x) = \int p_{1|t}^{\text{base}}(y|x) \varphi_1(y) dy, & \varphi_0(x) \hat{\varphi}_0(x) = \mu(x) \\ \hat{\varphi}_t(x) = \int p_{t|0}^{\text{base}}(x|y) \hat{\varphi}_0(y) dy, & \varphi_1(x) \hat{\varphi}_1(x) = \nu(x) \end{cases} \quad (8a) \quad (8b)$$

且 $p_{t|s}^{\text{base}}(y|x) := p^{\text{base}}(X_t=y|X_s=x)$ 是基础过程的转移核，用于在给定 x 于时刻 s 的条件下观测 y 于时刻 t 。薛定谔桥势 $\varphi_t(x), \hat{\varphi}_t(x) \in C^{1,2}([0, 1], \mathbb{R}^d)$ 随后被定义（至多相差一个乘法常数）为关于 $p_{t|s}^{\text{base}}$ 的前向与后向时间积分的解。

方程 (8) 在计算上具有挑战性——即使 $p_{t|s}^{\text{base}}$ 具有解析解——由于难以处理的积分以及在 $t=0$ 和 1 处的耦合边界。我们的关键观察是，第一个方程 (8a) 类似于随机最优控制问题 (4) 的最优性条件 (见 A.1 节)。这意味着薛定谔桥的最优性条件暗示了一种随机最优控制的重新解释，正如我们将展示的，这比直接求解 (8) 更易处理。我们在下面正式阐述这一发现。

定理 3.1（薛定谔桥的随机最优控制特征）。动能最优漂移

u_t^* in (8) solves an SOC problem

$$\min_u \mathbb{E}_{X \sim p^u} \left[\int_0^1 \frac{1}{2} \|u_t(X_t)\|^2 dt + \log \frac{\hat{\varphi}_1(X_1)}{\nu(X_1)} \right] \quad \text{s.t. (2)}. \quad (9)$$

定理 3.1 表明，每个薛定谔桥问题 (3) 都可以像随机最优控制问题 (4) 一样求解，其终端代价为 $g(x) := \log \frac{\hat{\varphi}_1(x)}{\nu(x)}$ 。与伴随采样 (Havens 等人, 2025) 中的公式相比，两个随机最优控制问题，即 (7) 和 (9)，在终端代价上有所不同——其中 p_1^{base} 被替换为 $\hat{\varphi}_1$ ——并且源分布从狄拉克 $\delta_{X_0=0}$ 放宽到一般源 $\mu(X_0)$ 。

$\hat{\varphi}_1(\cdot)$ 如何消除非无记忆随机最优控制问题的偏差 仔细考察 $\hat{\varphi}_1$ 的影响，注意到根据定理 3.1 和 (5)，薛定谔桥问题的最优分布遵循

$$p^*(X_0, X_1) = p^{\text{base}}(X_0, X_1) \exp \left(-\log \frac{\hat{\varphi}_1(X_1)}{\nu(X_1)} - \log \varphi_0(X_0) \right), \quad (10)$$

其中“ $-\log \varphi_0$ ”是等效初始值函数。可以验证终端时刻 $t=1$ 的边际分布确实满足目标分布，

$$\begin{aligned} p^*(X_1) &= \int p^*(X_0, X_1) dX_0 \stackrel{(10)}{=} \frac{\nu(X_1)}{\hat{\varphi}_1(X_1)} \int p^{\text{base}}(X_0, X_1) \frac{1}{\varphi_0(X_0)} dX_0 \\ &\stackrel{(8a)}{=} \frac{\nu(X_1)}{\hat{\varphi}_1(X_1)} \int p^{\text{base}}(X_1|X_0) \hat{\varphi}_0(X_0) dX_0 \stackrel{(8b)}{=} \nu(X_1). \end{aligned} \quad (11)$$

也就是说，(8) 中的最优性方程本质上构造了一个特定函数 $\hat{\varphi}_1(\cdot)$ ，该函数消除了与任何非无记忆过程相关的初始值函数偏差，从而确保最优分布在 $t=1$ 处满足目标 ν 。

3.2 具有一般源分布的伴随采样

现在我们将定理 3.1 专门用于采样玻尔兹曼分布 (1)，其中

$\nu(x) \propto e^{-E(x)}$ ，因此 (9) 中新 SOC 问题的终端代价变为 $g(x) = E(x) + \log \hat{\varphi}_1(x)$

$\log \frac{\hat{\varphi}_1(x)}{\nu(x)}$ 。为了鼓励最小运输代价 (Chen 和 Georgiou, 2015; Peyré 和 Cuturi, 2019)，我们考虑具有退化基础漂移 $f_t := 0$ 的布朗运动基础过程。将伴随匹配 (AM; Domingo-Enrich 等人, 2025) 应用于所得的 SOC 问题，得到

$$u^* = \arg \min_u \mathbb{E}_{p_{t|0,1}^{\text{base}} p_{0,1}^{\bar{u}}} \left[\|u_t(X_t) + \sigma_t (\nabla E + \nabla \log \hat{\varphi}_1)(X_1)\|^2 \right], \quad \bar{u} = \text{stopgrad}(u). \quad (12)$$

注意，(12) 中的 AM 目标函数充当自洽性损失——因为回归及其期望都依赖于优化变量 u 。这使得 (12) 特别适合学习基于 SB 的扩散采样器，不同于之前基于匹配的 SB 方法 (Shi 等人, 2023; Liu 等人, 2024)，这些方法都需要来自 $X_1 \sim \nu$ 的真实目标样本。

计算 (12) 中的 AM 目标需要知道 $\nabla \log \hat{\varphi}_1(x)$ ，正如我们在 (11) 中讨论的，它作为一个校正器，使优化偏向期望的目标。值得注意的是，这个校正函数 $\nabla \log \hat{\varphi}_1(x)$ 也承认变分形式 (Peluchetti, 2022, 2023; Shi 等人, 2023):³

$$\nabla \log \hat{\varphi}_1 = \arg \min_h \mathbb{E}_{p_{0,1}^{u^*}} \left[\|h(X_1) - \nabla_{x_1} \log p^{\text{base}}(X_1|X_0)\|^2 \right]. \quad (13)$$

总结来说，方程 (12) 和 (13) 刻画了 SB 的任何动力学最优漂移 u_t^* 必须满足的两个不同的匹配目标。当源分布退化为狄拉克 $\delta_{X_0:=0}$ ，(13) 在 $\nabla \log p_1^{\text{base}}$ 处最小化时，(12) 简单地恢复了伴随采样 (Havens 等人, 2025) 中使用的目标。换句话说，(12) 和 (13) 应被理解为伴随采样的推广，以处理任意——包括非无记忆的——源分布。

³ 形式上， $\nabla \log \hat{\varphi}_t(x)$ 是沿反向时间坐标 $s := 1 - t$ 的动力学最优漂移，而 (13) 是其变分表述，即在 $s=0$ 处的马尔可夫投影；详见 A.2 节。

Algorithm 1 Adjoint Schrödinger Bridge Sampler (ASBS)

Require: Sampleable source $X_0 \sim \mu$, differentiable energy $E(x)$, parametrized $u_\theta(t, x)$ and $h_\phi(x)$

- 1: Initialize $h_\phi^{(0)} := 0$
 - 2: **for** stage k **in** $1, 2, \dots$ **do**
 - 3: Update drift $u_\theta^{(k)}$ by solving (14) ▷ adjoint matching
 - 4: Update corrector $h_\phi^{(k)}$ by solving (15) ▷ corrector matching
 - 5: **end for**
-




图 2 在二维示例上对 ASBS 的说明。通过交替最小化伴随匹配 (AM) 目标 (14) 和校正器匹配 (CM) 目标 (15)，ASBS 逐步学习更好的校正器 $h_\phi^{(k)}$ ，该校正器为控制 $u_\theta^{(k)}$ 的 SOC 问题去偏。注意，由于校正器初始化为 $h_\phi^{(0)} := 0$ ，第一个 AM 阶段简单地将 $u_\theta^{(1)}$ 回归到能量梯度 ∇E 。

3.3 伴随匹配与校正器匹配的交替优化

基于第 3.2 节的理论刻画，本文旨在设计一种学习算法，以寻找满足 (12) 和 (13) 的扩散采样器，这两个条件对应两个简单的基于匹配的目标。然而，由于这两个匹配目标相互依赖，无法直接实现：求解 (12) 中的动能最优漂移 u^* 需要已知 $\nabla \log \hat{\varphi}_1$ 。同样，求解 (13) 中的校正函数 $\nabla \log \hat{\varphi}_1$ 需要来自 u^* 的样本。本文通过交替优化方案来放松这种相互依赖关系。具体而言，给定上一阶段 $k-1$ 对 $\nabla \log \hat{\varphi}_1 \approx h^{(k-1)}$ 的近似，首先利用 AM 目标更新漂移 $u^{(k)}$ ：

$$u^{(k)} := \arg \min_u \mathbb{E}_{p_{t|0,1}^{\text{base}} p_{0,1}^{\bar{u}}} \left[\|u_t(X_t) + \sigma_t(\nabla E + h^{(k-1)})(X_1)\|^2 \right], \quad \bar{u} = \text{stopgrad}(u). \quad (14)$$

然后，利用得到的漂移 $u^{(k)}$ 通过最小化以下匹配目标来更新 $h^{(k)}$ ，鉴于 $\nabla \log \hat{\varphi}_1$ 的校正作用，本文将其称为校正匹配目标：

$$h^{(k)} := \arg \min_h \mathbb{E}_{p_{0,1}^{u^{(k)}}} \left[\|h(X_1) - \nabla_{x_1} \log p^{\text{base}}(X_1|X_0)\|^2 \right]. \quad (15)$$

方程 (15) 应与数据驱动的薛定谔桥方法 (Shi et al., 2023; Somnath et al., 2023) 中的桥匹配目标区分开来，后者要求 X_1 必须从目标分布 ν 中抽取。相比之下，(14) 和 (15) 中的匹配目标仅依赖于当前阶段 $X_1 \sim p_{\theta}^{u^{(k)}}(X_1|X_0)$ 的模型样本，因此可用于大规模学习基于薛定谔桥的扩散采样器。

(14) 和 (15) 之间的交替优化产生一系列更新， $(u^{(0)}, h^{(0)}) \rightarrow \dots (u^{(k)}, h^{(k)}) \rightarrow \dots$ ，可视为在控制 u 与校正 h 之间执行坐标下降。直观上，在每个阶段 k ，首先找到与上一阶段校正 $h^{(k-1)}$ 最一致的控制 $u^{(k)}$ ，然后相应更新校正 $h^{(k)}$ ，以反映当前控制 $u^{(k)}$ 的“无记忆性”。

本文在算法 1 中总结了所提出的方法——伴随薛定谔桥采样器 (ASBS)，并在第 C 节中给出包含重放缓冲区等附加组件的完整细节。最后，本文证明该交替优化确实收敛于 (8) 中的动能最优漂移 u^* 。

定理 3.2 (ASBS 的全局收敛性)。若所有匹配阶段均达到其临界点，即：

$$\lim_{k \rightarrow \infty} u^{(k)} = u^*.$$

4 理论分析

本文给出定理 3.2 的证明，并贯穿全文强调理论洞见。虽然 ASBS 专门针对退化基础漂移 $f_t := 0$ ，但此处所有理论结果均适用于一般 f_t 。为简化记号，省略参数 θ, ϕ ，并通过 $h^{(k)} = \nabla \log \bar{h}^{(k)}$ 重新参数化校正项。所有证明见第 B 节。

我们的第一个结果给出了 (14) 中伴随匹配目标解的一个变分特征。

定理 4.1 (伴随匹配求解前向半桥)。设 $p^{u^{(k)}}$ 为由 (14) 中的漂移 $u^{(k)}$ 在阶段 k 诱导的路径分布。则 $p^{u^{(k)}}$ 求解以下变分问题：

$$p^{u^{(k)}} = \arg \min_p \{D_{\text{KL}}(p || q^{\bar{h}^{(k-1)}}) : p_0 = \mu\}, \quad (16)$$

其中 $q^{\bar{h}^{(k-1)}}$ 是由在反向时间坐标 $s := 1 - t$ ，上定义的“后向”随机微分方程诱导的路径分布，该方程由前一阶段的校正器 $\bar{h}^{(k-1)}$ 定义：

$$dY_s = [-f_s(Y_s) + \sigma_s^2 \nabla \log \phi_s(Y_s)] ds + \sigma_s dW_s, \quad \phi_s(y) = \int p_{1-s|0}^{\text{base}}(y|z) \phi_1(z) dz, \quad (17)$$

边界条件为 $Y_0 \sim \nu$ 和 $\phi_0(y) = \bar{h}^{(k-1)}(y)$ 。

定理 4.1 表明，任何具有终端代价 $g(x) := \log \frac{\bar{h}^{(k)}(x)}{\nu(x)}$ 的随机最优控制问题都可以重新解释为相对于特定后向随机微分方程 (17) 的 KL 最小化，该方程完全由 ν (作为其源分布) 和 $\bar{h}^{(k)}$ (通过函数 $\phi_s(y)$ 定义其漂移) 刻画。(16) 中的目标与原始薛定谔桥问题 (3) 中的目标不同，因为它忽略了目标边界约束 $X_1 \sim \nu$ 。因此，(16) 只求解前向半桥。

接下来，我们证明校正器匹配目标 (15) 具有类似的变分形式，只是时间方向相反。

定理 4.2 (校正器匹配求解后向半桥)。设 $\bar{h}^{(k)}$ 为阶段 (15) 中的校正器。则路径分布 $q^{\bar{h}^{(k)}}$ 求解以下变分问题：

$$q^{\bar{h}^{(k)}} = \arg \min_q \{D_{\text{KL}}(p^{u^{(k)}} || q) : q_1 = \nu\} \quad (18)$$

与 (16) 不同，(18) 中的目标忽略了源边界约束 μ ，从而求解后向半桥。定理 4.1 和 4.2 表明，算法 1 中的交替薛定谔桥采样器隐式地采用了一种优化方案，该方案交替求解前向和后向半桥，从而实例化了著名的迭代比例拟合算法 (IPF; Fortet, 1940; Kullback, 1968)。结合 (De Bortoli 等人, 2021) 的分析，我们得到定理 3.2 中的最终结果。

5 相关工作

数据驱动的薛定谔桥 薛定谔桥问题因其与基于扩散的生成模型的联系，在机器学习领域引起了显著关注 (Wang 等, 2021)。早期方法实现了经典的迭代比例拟合算法 (De Bortoli 等, 2021; Vargas 等, 2021; Chen 等, 2022)，随后基于桥匹配的方法进一步提升了可扩展性 (Shi 等, 2023; Liu 等, 2024)。与 ASBS 不同，上述所有方法

都专注于生成建模，并假设在训练期间能够获得大量目标样本，这使得它们不适用于从玻尔兹曼分布中采样。

受薛定谔桥启发的扩散采样器 值得注意的是，在扩散采样器的背景下，薛定谔桥公式一直被强调为一种在数学上具有吸引力的框架，既可用于理论分析，也可用于方法动机的阐述（Zhang 和 Chen, 2022; Vargas 等, 2024; Richter 和 Berner, 2024; Havens 等, 2025）。然而，此前的方法均未提供学习基于薛定谔桥的扩散采样器的通用解决方案，而是专门针对无记忆条件或非匹配目标进行设计，这在很大程度上使学习过程复杂化（见表 1）。从概念上讲，我们的 ASBS 与 SSB（Bernton 等, 2019）最为接近，二者都学习通用的薛定谔桥采样器。然而，两种方法在可扩展性上存在根本差异：SSB 是一种基于序贯蒙特卡洛的方法（Chopin, 2002），并通过高斯近似的薛定谔桥势函数增强了学习到的转移核。与许多经过 MCMC 增强的采样器一样（Gabri  等, 2022; Matthews 等, 2022），SSB 需要对能量 $E(x)$ 进行大量评估，而 ASBS 则更加节能。

学习增强的 MCMC 这类方法可以视为经典采样方法的扩展——例如 MCMC（Metropolis 等, 1953; HASTINGS, 1970）、序贯蒙特卡洛（SMC; Del Moral 等, 2006）和退火重要性采样（AIS; Neal, 2001）——其中传统的提议分布被现代机器学习模型所取代。例如，Arbel 等（2021）和 Gabri  等（2022）使用归一化流（Chen 等, 2018）作为学习到的提议分布，而 Matthews 等（2022）则采用随机归一化流（Wu 等, 2020）。最近，Chen 等（2025）探索了扩散模型的使用（Song 等, 2021; Ho 等, 2020）。然而，训练这些模型通常需要计算重要性权重，这需要大量的能量评估。

马尔可夫链蒙特卡洛增强的扩散采样器 或者，此类方法采用现代生成模型对玻尔兹曼分布进行采样，并结合马尔可夫链蒙特卡洛技术以缓解缺乏显式目标样本的问题。例如，Phillips 等人（2024）、De Bortoli 等人（2024）和 Akhound-Sadegh 等人（2024）采用基于分数的扩散模型（Song 等人, 2021; Ho 等人, 2020）的分数匹配目标。相比之下，Albergo 和 Vanden-Eijnden（2025）的方法基于动作匹配目标（Neklyudov 等人, 2023）。然而，估计目标样本需要计算重要性权重，这使得这些方法在能量函数评估方面计算成本高昂。

6 实验

基准 我们在三类多粒子能量函数上评估我们的退火得分基采样器（ASBS） $E(x)$ 。

- **合成能量函数** 这些是基于 n 粒子系统成对距离的经典势能，其中 $E(x)$ 可解析求得。遵循（Akhound-Sadegh 等人, 2024; Chen 等人, 2025），我们考虑二维四粒子双阱势（DW-4）、一维五粒子多阱势（MW-5）、三维十三粒子伦纳德-琼斯势（LJ-13）和三维五十五粒子伦纳德-琼斯势（LJ-55）。对于真实样本，我们从 MW-5 解析采样，其余三种势能使用（Klein 等人, 2023）的马尔可夫链蒙特卡洛样本。
- **丙氨酸二肽** 这是一个由 22 个原子组成的三维分子。具体而言，我们考虑隐式溶剂中的丙氨酸二肽，并旨在从温度为 $300K$ 的玻尔兹曼分布中采样。遵循先前方法（Zhang 和 Chen, 2022; Wu 等人, 2020），我们使用 OpenMM 库（Eastman 等人, 2017）中的能量函数 $E(x)$ ，并考虑维度为 $d = 60$ 的更结构化内坐标。真实样本包含 10^7 个构型，由分子动力学模拟生成（Midgley 等人, 2023）。
- **摊销式构象生成** 最后，我们考虑（Havens 等人, 2025）提出的用于大规模构象生成的新基准。构象是位于分子势能面局部极小值处的局部稳定构型（Hawkins, 2017）。采样构象本质上是一个条件生成任务，目标是在低温 $\tau \ll 1$ 下，以分子拓扑 $g \in \mathcal{G}$ 为条件，采样玻尔兹曼分布 $\nu(x|g) \propto e^{-\frac{1}{\tau}E(x|g)}$ 。训练集 $\mathcal{G}_{\text{train}}$ 包含来自 SPICE（Eastman 等人, 2023）的 24,477 个分子拓扑，用 SMILES 字符串（Weininger, 1988）表示；测试集 $\mathcal{G}_{\text{test}}$ 包含来自 SPICE 的 80 个拓扑和来自 GEOM-DRUGS（Axelrod 和 Gomez-Bombarelli, 2022）的另外 80 个拓扑。与（Havens 等人, 2025）一致，我们将 $E(x|g)$ 视为基础模型

表 2 在 n 粒子体及其对应维度 d 的合成能量函数上的结果。遵循 (Chen 等人, 2025; Havens 等人, 2025), 对于 MW-5 报告 Sinkhorn 距离, 对于其余部分报告样本的 Wasserstein-2 距离 $\mathcal{W}_2$ 和能量 $E(\cdot)\mathcal{W}_2$ 。所有值均为三次随机试验的平均值。最佳结果已突出显示。

Method	MW-5 ($d=5$)	DW-4 ($d=8$)		LJ-13 ($d=39$)		LJ-55 ($d=165$)	
	Sinkhorn $\downarrow$	$\mathcal{W}_2 \downarrow$	$E(\cdot)\mathcal{W}_2 \downarrow$	$\mathcal{W}_2 \downarrow$	$E(\cdot)\mathcal{W}_2 \downarrow$	$\mathcal{W}_2 \downarrow$	$E(\cdot)\mathcal{W}_2 \downarrow$
PDDS (Phillips et al., 2024)	—	0.92 $\pm$ 0.08	0.58 $\pm$ 0.25	4.66 $\pm$ 0.87	56.01 $\pm$ 10.80	—	—
SCLD (Chen et al., 2025)	0.44 $\pm$ 0.06	1.30 $\pm$ 0.64	0.40 $\pm$ 0.19	2.93 $\pm$ 0.19	27.98 $\pm$ 1.26	—	—
PIS (Zhang and Chen, 2022)	0.65 $\pm$ 0.25	0.68 $\pm$ 0.28	0.65 $\pm$ 0.25	1.93 $\pm$ 0.07	18.02 $\pm$ 1.12	4.79 $\pm$ 0.45	228.70 $\pm$ 131.27
DDS (Vargas et al., 2023)	0.63 $\pm$ 0.24	0.92 $\pm$ 0.11	0.90 $\pm$ 0.37	1.99 $\pm$ 0.13	24.61 $\pm$ 8.99	4.60 $\pm$ 0.09	173.09 $\pm$ 18.01
LV-PIS (Richter and Berner, 2024)	—	1.04 $\pm$ 0.29	1.89 $\pm$ 0.89	—	—	—	—
iDEM (Akhound-Sadegh et al., 2024)	—	0.70 $\pm$ 0.06	0.55 $\pm$ 0.14	1.61 $\pm$ 0.01	30.78 $\pm$ 24.46	4.69 $\pm$ 1.52	93.53 $\pm$ 16.31
AS (Havens et al., 2025)	0.32 $\pm$ 0.06	0.62 $\pm$ 0.06	0.55 $\pm$ 0.12	1.67 $\pm$ 0.01	2.40 $\pm$ 1.25	4.04 $\pm$ 0.05	30.83 $\pm$ 8.19
ASBS (Ours)	0.15 $\pm$ 0.02	0.43 $\pm$ 0.05	0.20 $\pm$ 0.11	1.59 $\pm$ 0.03	1.99 $\pm$ 1.01	4.00 $\pm$ 0.03	28.10 $\pm$ 8.15




图 3 表 2 中 DW-4 和 LJ-13 的能量直方图。ASBS 生成的样本能量分布与真实样本高度吻合。




图 4 在 LJ-13 势上, 复杂度与函数评估次数 (NFE) 的关系。

来自 (Fu 等人, 2025) 的 eSEN, 以低得多的计算成本预测具有密度泛函理论精度的能量。我们使用 CREST 构象 (Pracht 等人, 2024) 作为真实样本。

基线与评估 我们将 ASBS 与多种扩散采样器进行比较, 包括 PIS (Zhang 和 Chen, 2022)、DDS (Vargas 等人, 2023)、PDDS (Phillips 等人, 2024)、SCLD (Chen 等人, 2025)、LV (Richter 和 Berner, 2024)、iDEM (Akhound-Sadegh 等人, 2024) 以及 Adjoint Sampling (AS; Havens 等人, 2025)。对于构象生成任务, 我们还加入了一个领域特定基线 RDKit ETKDG (Riniker 和 Landrum, 2015), 它基于化学启发式规则。评估流程与先前方法一致: MW-5 采用 SCLD 设置, 丙氨酸二肽采用 PIS 设置, 其余采用 AS 设置; 详见 D 节。

ASBS 模型 对于所有任务, 我们考虑一个退化的基础漂移 $f_t := 0$, 如第 3.2 节所述, 并设置 σ_t 一个几何噪声调度。对于直接以粒子系统为输入的能量函数——如 DW、LJ 和 eSEN——我们用两个等变图神经网络 (Equivariant Graph Neural Networks) (Satorras 等人, 2021) 参数化模型 u_θ, h_ϕ , 并考虑一个领域特定的源分布——调和先验 (harmonic prior) (Jing 等人, 2023)。形式上, 对于一个 n 粒子系统 $x = \{x_i\}_{i=0}^n$, 调和先验 $\mu_{\text{harmonic}}(x)$ 是一个二次势, 可以从各向异性高斯分布中解析采样:

$$\mu_{\text{harmonic}}(x) \propto \exp\left(-\frac{\alpha}{2} \sum_{i,j} \|x_i - x_j\|^2\right). \quad (19)$$

对于其他能量函数, 我们使用标准的全连接神经网络, 并考虑高斯先验。所有模型均使用 Adam (Kingma 和 Ba, 2015) 进行训练, 并遵循标准做法 (Havens 等人, 2025; Akhound-Sadegh 等人, 2024), 利用重放缓冲区; 详见第 C 节。

结果 表 2 展示了在合成能量函数上的结果。值得注意的是, ASBS 在所有能量函数上均一致地优于先前的扩散采样器。在图 3 中, 我们比较了 DW-4 和 LJ-13 势在真实 MCMC 样本与 ASBS 样本之间的能量直方图。显然, ASBS 生成的样本与目标玻尔兹曼分布 $\nu(x) \propto e^{-E(x)}$ 非常接近, 产生的能量分布 $E(x)$ 与真实情况几乎无法区分。在计算方面, 图 4

表 3 扩散采样器在采样丙氨酸二肽分子玻尔兹曼分布上的比较。我们报告了五个扭转角的一维边缘分布的 KL 散度 D_{KL} ，以及联合 (ϕ, ψ) 上的 Wasserstein-2 $\mathcal{W}_2$ ，即拉马钱德兰图（见图 5）。最佳结果已突出显示。

Method	D_{KL} on each torsion's marginal ↓					$\mathcal{W}_2$ on joint ↓
	ϕ	ψ	γ_1	γ_2	γ_3	(ϕ, ψ)
PIS (Zhang and Chen, 2022)	0.05±0.03	0.38±0.49	5.61±1.24	4.49±0.03	4.60±0.03	1.27±1.19
DDS (Vargas et al., 2023)	0.03±0.01	0.16±0.07	2.44±0.96	0.03±0.00	0.03±0.00	0.68±0.09
AS (Havens et al., 2025)	0.09±0.09	0.04±0.04	0.17±0.17	0.56±0.09	0.51±0.06	0.65±0.52
ASBS (Ours)	0.02±0.00	0.01±0.00	0.03±0.01	0.02±0.00	0.02±0.00	0.25±0.01

表 4 大规模摊销构象生成的结果，在两个测试集 SPICE 和 GEOM-DRUGS 上评估，均包含和不包含后处理松弛。我们报告了在阈值 1.0Å 下召回率的覆盖率 (%) 和绝对平均 RMSD (AMR)。注意，“+RDKit 预热”指的是使用 RDKit 构象对模型 u_θ 进行热启动；详见第 D 节。不包含和包含 RDKit 预热的最佳结果分别突出显示。

Method	without relaxation				with relaxation			
	SPICE		GEOM-DRUGS		SPICE		GEOM-DRUGS	
	Coverage ↑	AMR ↓	Coverage ↑	AMR ↓	Coverage ↑	AMR ↓	Coverage ↑	AMR ↓
RDKit ETKDG (Riniker and Landrum, 2015)	56.94±35.82	1.04±0.52	50.81±34.69	1.15±0.61	70.21±31.70	0.79±0.44	62.55±31.67	0.93±0.53
AS (Havens et al., 2025)	56.75±38.15	0.96±0.26	36.23±33.42	1.20±0.43	82.41±25.85	0.68±0.28	64.26±34.57	0.89±0.45
ASBS w/ Gaussian prior (Ours)	73.04±31.95	0.83±0.24	50.23±35.98	1.05±0.43	88.26±20.57	0.60±0.24	72.32±29.68	0.77±0.35
ASBS w/ harmonic prior (Ours)	74.05±31.61	0.82±0.23	53.14±35.69	1.03±0.42	88.71±18.63	0.59±0.24	72.77±29.94	0.78±0.35
AS + RDKit warmup (Havens et al., 2025)	72.21±30.22	0.84±0.24	52.19±35.20	1.02±0.34	87.84±19.20	0.60±0.23	73.88±28.63	0.76±0.34
ASBS + RDKit warmup (Ours)	77.84±28.37	0.79±0.23	57.19±35.14	0.98±0.40	88.08±18.84	0.58±0.24	73.18±30.09	0.76±0.37




图 5 丙氨酸二肽在真实样本与 ASBS 样本之间的拉马钱德兰图。




图 6 ASBS 在摊销构象生成上的生成过程示例。给定一个来自测试集的未见分子拓扑 $g \in \mathcal{G}_{\text{test}}$ ——本例中为 COCSc1sc2ccccc2[n+][1][O-]——ASBS 从调和先验 $X_0 \sim \mu_{\text{harmonic}}$ 传输样本以生成构象 X_1 。

展示了每次梯度更新在能量 $E(x)$ 和模型 $u_\theta(t, x)$ 上所需的平均评估次数。ASBS 比大多数扩散采样器高效得多，与 AS 相比仅有轻微开销，这源于额外的网络 $h_\phi(x)$ 。

表 3 总结了丙氨酸二肽的结果。遵循标准流程 (Zhang 和 Chen, 2022)，我们生成模型样本 $X_1 \in \mathbb{R}^{60}$ 并提取五个扭转角——包括骨架角 ϕ, ψ 和甲基旋转角 $\gamma_1, \gamma_2, \gamma_3$ ——它们均呈现多模态分布。值得注意的是，ASBS 在所有五个扭转角上实现了与真实边缘分布最低的 KL 散度。图 5 进一步比较了 (ϕ, ψ) 的联合分布，即拉氏图 (Spencer 等, 2019)，在真实分布与 ASBS 之间。虽然 ASBS 识别了区域 $\phi \in [-\pi, 0]$ 中的所有高密度模式，但遗漏了少数低密度模式。这种模式寻求行为是所有基于 SOC 的扩散采样器固有的，可通过重要性加权加以改进。我们在 D.4 节中提供了进一步讨论。

表 4 展示了与真实样本相比，摊销构象生成的召回率。对于先前的扩散采样器，由于基准的规模，我们主要与 AS (Havens 等, 2025) 进行比较。遵循 AS，我们消融了使用 RDKit 构象的热启动阶段，这些构象接近但不完全等同于真实构象。




图 7 在 SPICE 和 GEOM-DRUGS 测试集上，无 RDKit 热启动的摊销构象生成的召回覆盖率曲线。注意，表 4 报告了阈值为 1.0Å 时的召回覆盖率。

样本，并包含用于生成后优化的松弛结果。由于 AS 是 ASBS 在狄拉克 δ 先验下的特例——如第 3.2 节所述——从 AS 到 ASBS 的任何性能提升都凸显了处理任意先验以及非无记忆过程的额外能力。值得注意的是，在没有任何热启动的情况下，具有调和先验 (19) 的 ASBS 已经达到，并且在许多情况下超过了 RDKit 热启动的 AS。通过热启动，ASBS 在大多数指标上取得了最佳性能。这凸显了领域特定先验的重要性，其辅助探索的效果与使用额外数据的热启动相当，而额外数据并非总是可用。最后，我们在图 6 中可视化了具有调和先验 (19) 的 ASBS 的生成过程，并在图 7 中报告了召回率曲线。在实践中，我们观察到 ASBS 使用调和先验比高斯先验取得略好的结果，两者均显著优于 AS (Havens 等人, 2025)。更多消融研究见第 D.4 节。

7 结论与局限性

我们提出了伴随薛定谔桥采样器 (ASBS)，这是一种用于玻尔兹曼分布的新型扩散采样器，仅给定目标能量函数即可求解一般薛定谔桥问题。ASBS 基于可扩展的匹配框架，理论上收敛到全局解，并在各种基准测试中表现优异。尽管取得了这些令人鼓舞的结果，但进一步利用重要性采样技术来缓解受随机最优控制启发的扩散采样器中固有的模式崩塌问题仍值得研究。探索其在采样摊销玻尔兹曼分布中的有效性也将是有价值的。

致谢

作者感谢 Aaron Havens、Juno Nam、Xiang Fu、Bing Yan、Brandon Amos 和 Brian Karrer 的有益讨论和评论。

参考文献

- Tara Akhond-Sadegh, Jarrod Rector-Brooks, Avishek Joey Bose, Sarthak Mittal, Pablo Lemos, Cheng-Hao Liu, Marcin Sendera, Siamak Ravanbakhsh, Gauthier Gidel, Yoshua Bengio, Nikolay Malkin, and Alexander Tong. Iterated denoising energy matching for sampling from Boltzmann densities. In *International Conference on Machine Learning (ICML)*, 2024.
- Michael S Albergo and Eric Vanden-Eijnden. NETS: A non-equilibrium transport sampler. In *International Conference on Machine Learning (ICML)*, 2025.
- Michael Arbel, Alex Matthews, and Arnaud Doucet. Annealed flow transport monte carlo. In *International Conference on Machine Learning (ICML)*, 2021.
- Simon Axelrod and Rafael Gomez-Bombarelli. GEOM: energy-annotated molecular conformations for property prediction and molecular generation. *Scientific Data*, 9(1):185, 2022.
- Richard Bellman. The theory of dynamic programming. Technical report, Rand corp santa monica ca, 1954.

- Julius Berner, Lorenz Richter, and Karen Ullrich. An optimal control perspective on diffusion-based generative modeling. *Transactions on Machine Learning Research (TMLR)*, 2024.
- Espen Bernton, Jeremy Heng, Arnaud Doucet, and Pierre E Jacob. Schrödinger bridge samplers. *arXiv preprint arXiv:1912.13170*, 2019.
- Kurt Binder, Dieter W Heermann, and K Binder. *Monte Carlo simulation in statistical physics*, volume 8. Springer, 1992.
- Denis Blessing, Xiaogang Jia, Johannes Esslinger, Francisco Vargas, and Gerhard Neumann. Beyond ELBOs: a large-scale evaluation of variational methods for sampling. In *International Conference on Machine Learning (ICML)*, 2024.
- George EP Box and George C Tiao. *Bayesian inference in statistical analysis*. John Wiley & Sons, 2011.
- James Bradbury, Roy Frostig, Peter Hawkins, Matthew James Johnson, Chris Leary, Dougal Maclaurin, George Necula, Adam Paszke, Jake VanderPlas, Skye Wanderman-Milne, and Qiao Zhang. JAX: composable transformations of Python+NumPy programs, 2018. <http://github.com/google/jax>.
- Junhua Chen, Lorenz Richter, Julius Berner, Denis Blessing, Gerhard Neumann, and Anima Anandkumar. Sequential controlled langevin diffusions. In *International Conference on Learning Representations (ICLR)*, 2025.
- Ricky T. Q. Chen, Yulia Rubanova, Jesse Bettencourt, and David K Duvenaud. Neural ordinary differential equations. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2018.
- Tianrong Chen, Guan-Horng Liu, and Evangelos A Theodorou. Likelihood training of Schrödinger bridge using forward-backward SDEs theory. In *International Conference on Learning Representations (ICLR)*, 2022.
- Yongxin Chen and Tryphon Georgiou. Stochastic bridges of linear systems. *IEEE Transactions on Automatic Control*, 61(2):526–531, 2015.
- Yongxin Chen, Tryphon T Georgiou, and Michele Pavon. On the relation between optimal transport and Schrödinger bridges: A stochastic control viewpoint. *Journal of Optimization Theory and Applications*, 169:671–691, 2016.
- Yongxin Chen, Tryphon T Georgiou, and Michele Pavon. Stochastic control liaisons: Richard sinkhorn meets gaspard monge on a schrödinger bridge. *SIAM Review*, 63(2):249–313, 2021.
- Nicolas Chopin. A sequential particle filter method for static models. *Biometrika*, 89(3):539–552, 2002.
- Valentin De Bortoli, James Thornton, Jeremy Heng, and Arnaud Doucet. Diffusion Schrödinger bridge with applications to score-based generative modeling. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.
- Valentin De Bortoli, Michael Hutchinson, Peter Wirsberger, and Arnaud Doucet. Target score matching. *arXiv preprint arXiv:2402.08667*, 2024.
- Pierre Del Moral, Arnaud Doucet, and Ajay Jasra. Sequential monte carlo samplers. *Journal of the Royal Statistical Society Series B: Statistical Methodology*, 68(3):411–436, 2006.
- Carles Domingo-Enrich, Michal Drozdal, Brian Karrer, and Ricky T. Q. Chen. Adjoint Matching: Fine-tuning flow and diffusion generative models with memoryless stochastic optimal control. In *International Conference on Learning Representations (ICLR)*, 2025.
- Peter Eastman, Jason Swails, John D Chodera, Robert T McGibbon, Yutong Zhao, Kyle A Beauchamp, Lee-Ping Wang, Andrew C Simmonett, Matthew P Harrigan, Chaya D Stern, Rafal P. Wiewiora, Bernard R. Brooks, and Vijay S. Pande. OpenMM 7: Rapid development of high performance algorithms for molecular dynamics. *PLoS computational biology*, 13(7):e1005659, 2017.
- Peter Eastman, Pavan Kumar Behara, David L Dotson, Raimondas Galvelis, John E Herr, Josh T Horton, Yuezhi Mao, John D Chodera, Benjamin P Pritchard, Yuanqing Wang, Gianni De Fabritiis, and Thomas E. Markland. SPICE, a dataset of drug-like molecules and peptides for training machine learning potentials. *Scientific Data*, 10(1):11, 2023.
- Chris Finlay, Jörn-Henrik Jacobsen, Levon Nurbekyan, and Adam Oberman. How to train your neural ODE: The world of jacobian and kinetic regularization. In *International Conference on Machine Learning (ICML)*, 2020.
- Robert Fortet. Résolution d’un système d’équations de M. Schrödinger. *Journal de Mathématiques Pures et Appliquées*, 19(1-4):83–105, 1940.

- Xiang Fu, Brandon M Wood, Luis Barroso-Luque, Daniel S Levine, Meng Gao, Misko Dzamba, and C Lawrence Zitnick. Learning smooth and expressive interatomic potentials for physical property prediction. In *International Conference on Machine Learning (ICML)*, 2025.
- Marylou Gabri  , Grant M Rotskoff, and Eric Vanden-Eijnden. Adaptive monte carlo augmented with normalizing flows. *Proceedings of the National Academy of Sciences*, 119(10):e2109420119, 2022.
- WK HASTINGS. Monte carlo sampling methods using markov chains and their applications. *Biometrika*, 57(1): 97–109, 1970.
- Aaron Havens, Benjamin Kurt Miller, Bing Yan, Carles Domingo-Enrich, Anuroop Sriram, Brandon Wood, Daniel Levine, Bin Hu, Brandon Amos, Brian Karrer, Xiang Fu, Guan-Horng Liu, and Ricky T. Q. Chen. Adjoint Sampling: Highly scalable diffusion samplers via Adjoint Matching. In *International Conference on Machine Learning (ICML)*, 2025.
- Paul CD Hawkins. Conformation generation: The state of the art. *Journal of chemical information and modeling*, 57(8):1747–1756, 2017.
- Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.
- Kiyosi It  . *On stochastic differential equations*, volume 4. American Mathematical Soc., 1951.
- Bowen Jing, Ezra Erives, Peter Pao-Huang, Gabriele Corso, Bonnie Berger, and Tommi S Jaakkola. EigenFold: Generative protein structure prediction with diffusion models. In *International Conference on Learning Representations (ICLR), Workshop Track*, 2023.
- Hilbert J Kappen. Path integrals and symmetry breaking for optimal control theory. *Journal of Statistical Mechanics: Theory and Experiment*, 2005(11):P11011, 2005.
- Tero Karras, Miika Aittala, Timo Aila, and Samuli Laine. Elucidating the design space of diffusion-based generative models. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.
- Diederik P Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *International Conference on Learning Representations (ICLR)*, 2015.
- Leon Klein, Andrew Foong, Tor Fjelde, Bruno Mlodozieniec, Marc Brockschmidt, Sebastian Nowozin, Frank No  , and Ryota Tomioka. Timewarp: Transferable acceleration of molecular dynamics by learning time-coarsened dynamics. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.
- Jonas K  hler, Leon Klein, and Frank No  . Equivariant Flows: Exact likelihood generative learning for symmetric densities. In *International Conference on Machine Learning (ICML)*, 2020.
- Solomon Kullback. Probability densities with given marginals. *The Annals of Mathematical Statistics*, 39(4):1236–1243, 1968.
- Greg Landrum. Rdkit: Open-source cheminformatics. <https://www.rdkit.org>, 2006.
- Jean-Fran  ois Le Gall. *Brownian motion, martingales, and stochastic calculus*. Springer, 2016.
- Christian L  onard. From the Schr  dinger problem to the Monge–Kantorovich problem. *Journal of Functional Analysis*, 262(4):1879–1920, 2012.
- Christian L  onard. A survey of the Schr  dinger problem and some of its connections with optimal transport. *Discrete and Continuous Dynamical Systems*, 2013.
- Christian L  onard, Sylvie Roelly, and Jean-Claude Zambrini. Reciprocal processes. A measure-theoretical point of view. *Probability Surveys*, 2014.
- Daniel S Levine, Muhammed Shuaibi, Evan Walter Clark Spotte-Smith, Michael G Taylor, Muhammad R Hasyim, Kyle Michel, Ilyes Batatia, G  bor Cs  nyi, Misko Dzamba, Peter Eastman, Nathan C. Frey, Xiang Fu, Vahe Gharakhanyan, Aditi S. Krishnapriyan, Joshua A. Rackers, Sanjeev Raja, Ammar Rizvi, Andrew S. Rosen, Zachary Ulissi, Santiago Vargas, C. Lawrence Zitnick, Samuel M. Blau, and Brandon M. Wood. The Open Molecules 2025 (OMol25) dataset, evaluations, and models. *arXiv preprint arXiv:2505.08762*, 2025.
- Guan-Horng Liu, Arash Vahdat, De-An Huang, Evangelos A Theodorou, Weili Nie, and Anima Anandkumar. I²SB: Image-to-Image Schr  dinger bridge. In *International Conference on Machine Learning (ICML)*, 2023.

- Guan-Horng Liu, Yaron Lipman, Maximilian Nickel, Brian Karrer, Evangelos A Theodorou, and Ricky T. Q. Chen. Generalized Schrödinger bridge matching. In *International Conference on Learning Representations (ICLR)*, 2024.
- Alex Matthews, Michael Arbel, Danilo Jimenez Rezende, and Arnaud Doucet. Continual repeated annealed flow transport monte carlo. In *International Conference on Machine Learning (ICML)*, 2022.
- Nicholas Metropolis, Arianna W Rosenbluth, Marshall N Rosenbluth, Augusta H Teller, and Edward Teller. Equation of state calculations by fast computing machines. *The journal of chemical physics*, 21(6):1087–1092, 1953.
- Laurence Illing Midgley, Vincent Stimper, Gregor NC Simm, Bernhard Schölkopf, and José Miguel Hernández-Lobato. Flow annealed importance sampling bootstrap. In *International Conference on Learning Representations (ICLR)*, 2023.
- Radford M Neal. Annealed importance sampling. *Statistics and computing*, 11:125–139, 2001.
- F. Neese. The orca program system. *WIRES Comput. Molec. Sci.*, 2(1):73–78, 2012. doi: 10.1002/wcms.81.
- Kirill Neklyudov, Daniel Severo, and Alireza Makhzani. Action matching: A variational method for learning stochastic dynamics from samples. In *International Conference on Machine Learning (ICML)*, 2023.
- Edward Nelson. *Dynamical theories of Brownian motion*, volume 106. Princeton university press, 2020.
- Frank Noé, Simon Olsson, Jonas Köhler, and Hao Wu. Boltzmann generators: Sampling equilibrium states of many-body systems with deep learning. *Science*, 365(6457):eaaw1147, 2019.
- Bernt Øksendal. Stochastic differential equations. In *Stochastic Differential Equations*, pages 65–84. Springer, 2003.
- Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, Alban Desmaison, Andreas Kopf, Edward Yang, Zachary DeVito, Martin Raison, Alykhan Tejani, Sasank Chilamkurthy, Benoit Steiner, Lu Fang, Junjie Bai, and Soumith Chintala. Pytorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2019.
- Stefano Peluchetti. Non-Denoising forward-time diffusions, 2022. <https://openreview.net/forum?id=oVfIKuhqfC>.
- Stefano Peluchetti. Diffusion bridge mixture transports, Schrödinger bridge problems and generative modeling. *arXiv preprint arXiv:2304.00917*, 2023.
- Gabriel Peyré and Marco Cuturi. Computational optimal transport: With applications to data science. *Foundations and Trends® in Machine Learning*, 11(5-6):355–607, 2019.
- Angus Phillips, Hai-Dang Dau, Michael John Hutchinson, Valentin De Bortoli, George Deligiannidis, and Arnaud Doucet. Particle denoising diffusion sampler. In *International Conference on Machine Learning (ICML)*, 2024.
- Philipp Pracht, Stefan Grimme, Christoph Bannwarth, Fabian Bohle, Sebastian Ehlert, Gereon Feldmann, Johannes Gorges, Marcel Müller, Tim Neudecker, Christoph Plett, Sebastian Spicher, Pit Steinbach, Patryk A. Wesolowski, and Felix Zeller. CREST—A program for the exploration of low-energy molecular chemical space. *The Journal of Chemical Physics*, 160(11), 2024.
- Lorenz Richter and Julius Berner. Improved sampling via learned diffusions. In *International Conference on Learning Representations (ICLR)*, 2024.
- Sereina Riniker and Gregory A Landrum. Better informed distance geometry: using what we know to improve conformation generation. *Journal of chemical information and modeling*, 55(12):2562–2574, 2015.
- Simo Särkkä and Arno Solin. *Applied stochastic differential equations*, volume 10. Cambridge University Press, 2019.
- Victor Garcia Satorras, Emiel Hoogeboom, and Max Welling. $E(n)$ equivariant graph neural networks. In *International Conference on Machine Learning (ICML)*, 2021.
- Erwin Schrödinger. *Über die Umkehrung der Naturgesetze*, volume IX. Sitzungsberichte der Preuss Akad. Wissen. Phys. Math. Klasse, Sonderausgabe, 1931.
- Erwin Schrödinger. Sur la théorie relativiste de l’électron et l’interprétation de la mécanique quantique. In *Annales de l’institut Henri Poincaré*, 1932.
- Neta Shaul, Ricky T. Q. Chen, Maximilian Nickel, Matthew Le, and Yaron Lipman. On kinetic optimal probability paths for generative models. In *International Conference on Machine Learning (ICML)*, 2023.

- Yuyang Shi, Valentin De Bortoli, Andrew Campbell, and Arnaud Doucet. Diffusion Schrödinger bridge matching. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.
- Vignesh Ram Somnath, Matteo Pariset, Ya-Ping Hsieh, Maria Rodriguez Martinez, Andreas Krause, and Charlotte Bunne. Aligned diffusion Schrödinger bridges. In *Conference on Uncertainty in Artificial Intelligence (UAI)*, 2023.
- Yang Song, Jascha Sohl-Dickstein, Diederik P Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole. Score-based generative modeling through stochastic differential equations. In *International Conference on Learning Representations (ICLR)*, 2021.
- Ryan K Spencer, Glenn L Butterfoss, John R Edison, James R Eastwood, Stephen Whitelam, Kent Kirshenbaum, and Ronald N Zuckermann. Stereochemistry of polypeptoid chain configurations. *Biopolymers*, 110(6):e23266, 2019.
- Vincent Stimper, Bernhard Schölkopf, and José Miguel Hernández-Lobato. Resampling base distributions of normalizing flows. In *International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2022.
- Emanuel Todorov. Linearly-solvable Markov decision problems. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2007.
- Mark E Tuckerman. *Statistical mechanics: theory and molecular simulation*. Oxford university press, 2023.
- Francisco Vargas, Pierre Thodoroff, Neil D Lawrence, and Austen Lamacraft. Solving Schrödinger bridges via maximum likelihood. *Entropy*, 2021.
- Francisco Vargas, Will Grathwohl, and Arnaud Doucet. Denoising diffusion samplers. In *International Conference on Learning Representations (ICLR)*, 2023.
- Francisco Vargas, Shreyas Padhy, Denis Blessing, and Nikolas Nüsken. Transport meets variational inference: Controlled monte carlo diffusions. In *International Conference on Learning Representations (ICLR)*, 2024.
- Gefei Wang, Yuling Jiao, Qian Xu, Yang Wang, and Can Yang. Deep generative learning via Schrödinger bridge. In *International Conference on Machine Learning (ICML)*, 2021.
- David Weininger. Smiles, a chemical language and information system. 1. introduction to methodology and encoding rules. *Journal of chemical information and computer sciences*, 28(1):31–36, 1988.
- Hao Wu, Jonas Köhler, and Frank Noé. Stochastic normalizing flows. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.
- Qinsheng Zhang and Yongxin Chen. Path integral sampler: A stochastic control approach for sampling. In *International Conference on Learning Representations (ICLR)*, 2022.

目录

A 附加预备知识 16

- A.1 随机最优控制 (SOC) 16
- A.2 薛定谔桥 (SB) 18

B 证明 19 B.1 预备与附加理论结果 19 B.2 正文中缺失的证明 20

C ASBS 的实用实现 22

D 实验细节 25

- D.1 合成能量函数 25
- D.2 丙氨酸二肽 27
- D.3 摊销构象生成 28
- D.4 附加实验与讨论 29

A 附加预备知识

A.1 随机最优控制 (Stochastic Optimal Control, SOC)

在本小节中，我们扩展第 2 节的内容并补充细节。回顾 (4) 中的随机最优控制问题：

$$\min_u \mathbb{E}_{X \sim p^u} \left[\int \frac{1}{2} \|u_t(X_t)\|^2 dt + g(X_1) \right] \quad (20a)$$

$$\text{s.t. } dX_t = [f_t(X_t) + \sigma_t u_t(X_t)] dt + \sigma_t dW_t, \quad X_0 \sim \mu. \quad (20b)$$

与 (8) 类似，(20) 的最优控制可以通过最优性方程来刻画：

$$u_t^*(x) = -\sigma_t \nabla V_t(x), \quad \text{where} \quad V_t(x) = -\log \int p_{1|t}^{\text{base}}(y|x) e^{-V_1(y)} dy, \quad V_1(x) = g(x) \quad (21)$$

是已知满足哈密顿 - 雅可比 - 贝尔曼 (Hamilton - Jacobi - Bellman, HJB) 方程 (Bellman, 1954) 的值函数。我们在下文中给出进一步刻画。

最优分布 优化问题 (20) 具有解析解。具体而言，注意到 (20) 中的熵正则化目标可重新表述为：

$$\begin{aligned} & D_{\text{KL}}(p(X) \| p^{\text{base}}(X)) + \mathbb{E}_{p(X)} [g(X_1)] \\ &= D_{\text{KL}}(p(X_0) \| p^{\text{base}}(X_0)) + \mathbb{E}_{p(X_0)} \left[D_{\text{KL}}(p(X|X_0) \| p^{\text{base}}(X|X_0)) + \mathbb{E}_{p(X|X_0)} [g(X_1)] \right] \\ &= D_{\text{KL}}(p(X_0) \| p^{\text{base}}(X_0)) + \mathbb{E}_{p(X_0)} \left[D_{\text{KL}}(p(X|X_0) \| p^{\text{base}}(X|X_0) e^{-g(X_1)}) \right] \end{aligned} \quad (22)$$

其中我们简写 $X \equiv X[0, 1]$ ，并用 p^{base} 表示由 (20b) 诱导的基础分布，其中 $u := 0$, *i.e.*, 为无控制分布。最小化 (22) w.r.t. p 得到

$$p^*(X|X_0) = \frac{1}{Z(X_0)} p^{\text{base}}(X|X_0) e^{-g(X_1)}, \quad p^*(X_0) = p^{\text{base}}(X_0) \quad (23)$$

其中 $Z(X_0)$ 是由下式定义的归一化项：

$$Z(X_0) := \int p^{\text{base}}(X|X_0) e^{-g(X_1)} dX = \int p^{\text{base}}(X_1|X_0) e^{-g(X_1)} dX_1 \quad (24)$$

根据 (21)，这恰好是 $e^{-V(X_0)}$ 。结合 (23) 和 (24) 可得到 (5) 中的最优分布，为完整起见，我们将其重述如下：

$$p^*(X) = p^{\text{base}}(X) e^{-g(X_1) + V_0(X_0)} \implies p^*(X_0, X_1) = p^{\text{base}}(X_0, X_1) e^{-g(X_1) + V_0(X_0)} \quad (25)$$

伴随匹配 (AM) 求解 (20) 的可扩展计算方法一直具有挑战性, 因为直接对 (20) 进行反向传播会导致极高的计算成本。相反, 伴随匹配 (Domingo-Enrich 等, 2025) 采用基于匹配的目标, 称为伴随匹配 (AM) :

$$u^* = \arg \min_u \mathbb{E}_{X \sim p^{\bar{u}}} [\|u_t(X_t) + \sigma_t a_t\|^2], \quad \bar{u} = \text{stopgrad}(u), \quad (26a)$$

$$\text{where } -da_t = a_t \cdot \nabla f_t(X_t)dt, \quad a_1 = \nabla g(X_1) \quad (26b)$$

是 (精简) 伴随状态 $a_t \equiv a(t; X_{[t,1]})$ 的后向动力学。已证明 (26) 的唯一临界点是最优控制 u^* , 这揭示了利用伴随状态的最优控制 u^* 的新特征:

$$u_t^*(x) = -\sigma_t \mathbb{E}_{p^*}[a_t | X_t = x]. \quad (27)$$

Adjoint Sampling (AS) 最近, Havens 等 (2025) 引入了一种针对采样玻尔兹曼分布 $\nu(x) \propto e^{-E(x)}$ 的 AM 变体, 通过考虑

$$f_t := 0, \quad \mu(x) := \delta_0(x), \quad g(x) := \log \frac{p_1^{\text{base}}(x)}{\nu(x)}. \quad (28)$$

也就是说, 伴随采样考虑以下随机最优控制问题: 具有退化的基础漂移、狄拉克 δ 先验以及终端代价的特定实例化 $g(x) := \log \frac{p_1^{\text{base}}(x)}{\nu(x)}$:

$$\min_u \mathbb{E}_{X \sim p^u} \left[\int_0^1 \frac{1}{2} \|u_t(X_t)\|^2 dt + \log \frac{p_1^{\text{base}}(X_1)}{\nu(X_1)} \right] \text{ s.t. } dX_t = \sigma_t u_t(X_t)dt + \sigma_t dW_t, \quad X_0 = 0. \quad (29)$$

值得注意的是, 该随机最优控制问题 (29) 允许简化的伴随状态 a_t 和退化的初始值函数 $V_0(x)$:

$$a_t \stackrel{(26b)}{=} \nabla g(X_1) \stackrel{(28)}{=} \nabla \log p_1^{\text{base}}(X_1) + \nabla E(X_1) \quad \forall t \in [0, 1] \quad (30)$$

$$V_0(x) \stackrel{(28)}{=} -\log \int p_1^{\text{base}}(y) \frac{\nu(y)}{p_1^{\text{base}}(y)} dy = -\log 1 = 0, \quad (31)$$

这进一步意味着最优分布 p^* 是一个互反过程 (Léonard 等, 2014) :

$$p^*(X) \stackrel{(31)}{=} p^{\text{base}}(X) e^{-V_1(X_1)} \stackrel{(28)}{=} p^{\text{base}}(X) \frac{\nu(X_1)}{p_1^{\text{base}}(X_1)} = p^{\text{base}}(X|X_1) p^*(X_1). \quad (32)$$

将最优控制 (27) 的伴随特征与 (30) 中简化的伴随状态 a_t 以及最优分布 p^* (32) 相结合, 可导出伴随采样中使用的互反伴随匹配目标, 其中唯一临界点仍为 (21) 中的最优控制 u^* 。

$$u^* = \arg \min_u \mathbb{E}_{p_{t|1}^{\text{base}} p_1^{\bar{u}}} [\|u_t(X_t) + \sigma_t (\nabla E + \nabla \log p_1^{\text{base}})(X_1)\|^2], \quad \bar{u} = \text{stopgrad}(u). \quad (33)$$

关于互反表示的说明 (32) 中最优受控分布 p^* 的互反表示可推广到具有非平凡基础漂移和源分布的一般随机最优控制问题 (20)。具体而言, 任何求解 (20) 的最优受控分布都可以分解为

$$p^*(X) = p^{\text{base}}(X|X_0, X_1) p^*(X_0, X_1). \quad (34)$$

我们在定理 B.3 和推论 B.4 中给出正式陈述。

具有线性基础漂移和高斯先验的伴随采样 (AS) 图 1) 此处, 我们讨论一种替代的 AM 实例化方法, 用于具有线性基础漂移和高斯先验的采样, 该方法重现了图 1 中最左侧的图。考虑

$$f_t(x) := -\frac{1}{2} \beta_t x, \quad \mu(x) := \mathcal{N}(x; 0, I), \quad \sigma_t := \sqrt{\beta_t}, \quad g(x) := \log \frac{p_1^{\text{base}}(x)}{\nu(x)}. \quad (35)$$

其中 β_t 的选择使得 (f_t, μ, σ_t) 满足无记忆条件。例如，图 1 采用了 VPSDE (Song 等人, 2021) 的设置：

$$\beta_t = (1-t)\beta_{\max} + t\beta_{\min}, \quad \beta_{\max} = 20, \quad \beta_{\min} = 0.1. \quad (36)$$

与 (30) 类似，所得的 SOC 问题允许一个简化的伴随状态 a_t ：

$$a_t \stackrel{(26b)}{=} \kappa_t \cdot \nabla g(X_1) \stackrel{(35)}{=} \kappa_t \cdot (\nabla \log p_1^{\text{base}}(X_1) + \nabla E(X_1)), \quad \kappa_t := e^{-\frac{1}{2} \int_t^1 \beta_\tau d\tau} \stackrel{(36)}{=} e^{-\frac{1}{4}(1-t)(\beta_t + \beta_1)} \quad (37)$$

并且 RAM 目标变为

$$u^* = \arg \min_u \mathbb{E}_{p_{t|0,1}^{\text{base}} p_{0,1}^{\bar{u}}} [\|u_t(X_t) + \sigma_t \kappa_t (\nabla E + \nabla \log p_1^{\text{base}})(X_1)\|^2], \quad \bar{u} = \text{stopgrad}(u). \quad (38)$$

Note that $p_{t|0,1}^{\text{base}}$ 可以解析地采样：

$$p_{t|0,1}^{\text{base}}(X_t|X_0, X_1) \stackrel{(35)}{=} \mathcal{N}(X_t; \frac{\bar{\kappa}_t(1-\kappa_t^2)}{1-\bar{\kappa}_1^2} X_0 + \frac{\kappa_t(1-\bar{\kappa}_t^2)}{1-\bar{\kappa}_1^2} X_1, \frac{(1-\kappa_t^2)(1-\bar{\kappa}_t^2)}{1-\bar{\kappa}_1^2} I), \quad (39)$$

其中 κ_t 在 (37) 中定义，且 $\bar{\kappa}_t := e^{-\frac{1}{2} \int_0^t \beta_\tau d\tau} \stackrel{(36)}{=} e^{-\frac{1}{4}t(\beta_t + \beta_0)}$ 。

A.2 薛定谔桥 (SB)

在本小节中，我们提供关于 SB 的额外澄清，特别是 (13) 的推导。回顾 (8) 中 SB 的最优性方程：

$$u_t^*(x) = \sigma_t \nabla \log \varphi_t(x), \quad \text{其中} \quad \begin{cases} \varphi_t(x) = \int p_{1|t}^{\text{base}}(y|x) \varphi_1(y) dy, & \varphi_0(x) \hat{\varphi}_0(x) = \mu(x) \\ \hat{\varphi}_t(x) = \int p_{t|0}^{\text{base}}(x|y) \hat{\varphi}_0(y) dy, & \varphi_1(x) \hat{\varphi}_1(x) = \nu(x) \end{cases} \quad (40a)$$

$$(40b)$$

正如随机最优控制 (SOC) 问题的价值函数完全刻画了最优控制及其对应的最优分布，薛定谔桥 (SB) 势 $\varphi_t(x)$ 也是如此：

$$p^*(X) = p^{\text{base}}(X) \frac{\varphi_1(X_1)}{\varphi_0(X_0)} = p^{\text{base}}(X|X_0) \varphi_1(X_1) \hat{\varphi}_0(X_0), \quad (41)$$

其中最后一个等式由 $p^{\text{base}}(X) = p^{\text{base}}(X|X_0) \mu(X_0)$ 得到，然后调用 (40a)。注意，(41) 通过对 $t \in (0, 1)$ 进行边缘化恢复了 (10)。由于 (40) 中 $\varphi_t(x)$ 和 $\hat{\varphi}_t(x)$ 的构造，边缘最优分布具有一个极其简单的分解：

$$\begin{aligned} p_t^*(x) &= \int p^{\text{base}}(X, X_t = x|X_0) \varphi_1(X_1) \hat{\varphi}_0(X_0) dX \\ &= \int \int p^{\text{base}}(X_1|X_t = x) p^{\text{base}}(X_t = x|X_0) \varphi_1(X_1) \hat{\varphi}_0(X_0) dX_0 dX_1 \\ &= \left(\int p^{\text{base}}(X_t = x|X_0) \hat{\varphi}_0(X_0) dX_0 \right) \left(\int p^{\text{base}}(X_1|X_t = x) \varphi_1(X_1) dX_1 \right) \\ &= \hat{\varphi}_t(x) \varphi_t(x), \end{aligned} \quad (42)$$

or, more generally,

$$p_{s,t}^*(y, x) = p_{t|s}^{\text{base}}(x|y) \hat{\varphi}_s(y) \varphi_t(x), \quad s \leq t. \quad (43)$$

推导 (13) 我们现在给出 (13) 的一个更简单的推导，相比其最初基于路径测度理论的推导 (Shi 等人, 2023)：

$$\begin{aligned} \nabla \log \hat{\varphi}_t(x) &\stackrel{(40b)}{=} \frac{1}{\hat{\varphi}_t(x)} \nabla_x \int p_{t|0}^{\text{base}}(x|y) \hat{\varphi}_0(y) dy \\ &= \frac{1}{\hat{\varphi}_t(x)} \int \nabla_x \log p_{t|0}^{\text{base}}(x|y) p_{t|0}^{\text{base}}(x|y) \hat{\varphi}_0(y) dy \\ &= \int \nabla_x \log p_{t|0}^{\text{base}}(x|y) p_{0|t}^*(y|x) dy, \end{aligned} \quad (44)$$

其中最后一个等式由以下得出

$$p_{0|t}^*(y|x) \stackrel{(42)}{=} \frac{p_{0,t}^*(y,x)}{\hat{\varphi}_t(x)\varphi_t(x)} \stackrel{(43)}{=} \frac{p_{t|0}^{\text{base}}(x|y)\hat{\varphi}_0(y)\varphi_t(x)}{\hat{\varphi}_t(x)\varphi_t(x)} = \frac{p_{t|0}^{\text{base}}(x|y)\hat{\varphi}_0(y)}{\hat{\varphi}_t(x)}.$$

方程 (44) 暗示了 $\nabla \log \hat{\varphi}_t(\cdot)$ 的基于匹配的变分公式——在数据驱动的薛定谔桥中也称为桥匹配目标 (Shi 等人, 2023; Liu 等人, 2023)。

$$\nabla \log \hat{\varphi}_t = \arg \min_h \mathbb{E}_{p_{0,t}^*} [\|h_t(X_t) - \nabla_{x_t} \log p^{\text{base}}(X_t|X_0)\|^2]. \quad (45)$$

Equation (45) recovers (13) at $t = 1$.

B 证明

B.1 预备知识与附加理论结果

引理 B.1 (伊藤引理 (Itô, 1951))。设 X_t 为伊藤随机微分方程的解:

$$dX_t = f_t(X_t)dt + \sigma_t dW_t.$$

则随机过程 $v_t(X_t)$ (其中 $v \in C^{1,2}([0, 1], \mathbb{R}^d)$) 也是一个伊藤过程:

$$dv_t(X_t) = \left[\partial_t v_t(X_t) + \nabla v_t(X_t) \cdot f + \frac{1}{2} \sigma_t^2 \Delta v_t(X_t) \right] dt + \sigma_t \nabla v_t(X_t) \cdot dW_t. \quad (46)$$

引理 B.2 (拉普拉斯算子技巧)。对于任意二次可微函数 π , 若 $\pi(x) \neq 0$, 则有

$$\frac{1}{\pi(x)} \Delta \pi(x) = \|\nabla \log \pi(x)\|^2 + \Delta \log \pi(x) \quad (47)$$

证明。

$$\begin{aligned} \Delta \pi(x) &= \nabla \cdot \nabla \pi(x) \\ &= \nabla \cdot (\pi(x) \nabla \log \pi(x)) \\ &= \nabla \pi(x) \cdot \nabla \log \pi(x) + \pi(x) \Delta \log \pi(x) \\ &= \pi(x) (\|\nabla \log \pi(x)\|^2 + \Delta \log \pi(x)) \end{aligned}$$

□

定理 B.3 (SOC 的薛定谔桥特征)。SOC 问题 (20) 的最优分布 p^* 也是以下薛定谔桥问题的解:

$$\min_p \{D_{\text{KL}}(p||p^{\text{base}}) : p_0 = \mu, \quad p_1 = p_1^*\}. \quad (48)$$

证明。本文旨在证明存在一种变换, 使得随机最优控制的最优性方程 (21) 可重新解释为薛定谔桥问题的最优性方程 (40)。为此, 考虑

$$\varphi_t(x) := e^{-V_t(x)}, \quad \hat{\varphi}_t(x) := e^{V_t(x)} p_t^*(x). \quad (49)$$

可以验证, 定义于 (21) 中的值函数 $V_t(x)$ 可改写为

$$\varphi_t(x) = \int p_{1|t}^{\text{base}}(y|x) \varphi_1(y) dy.$$

另一方面, 可将 $\hat{\varphi}_t(x)$ 展开为

$$\begin{aligned}
\hat{\varphi}_t(x) &= e^{V_t(x)} \int p^*(X|X_t=x) dX \\
&= e^{V_t(x)} \int p^{\text{base}}(X_1|X_t=x) p^{\text{base}}(X_t=x, X_0) e^{-V_1(X_1)+V_0(X_0)} dX_1 dX_0 && \text{by (25)} \\
&= e^{V_t(x)} \int p^{\text{base}}(X_t=x, X_0) e^{-V_t(x)+V_0(X_0)} dX_0 && \text{by (21)} \\
&= \int p^{\text{base}}(X_t=x|X_0) \mu(X_0) e^{V_0(X_0)} dX_0 \\
&= \int p_{t|0}^{\text{base}}(x|y) \hat{\varphi}_0(y) dy. && \text{by (49)}
\end{aligned}$$

综合上述结果, 随机最优控制问题的最优性方程 (21) 可等价地改写为

$$u_t^*(x) = \sigma_t \nabla \log \varphi_t(x), \quad \text{其中} \quad \begin{cases} \varphi_t(x) = \int p_{1|t}^{\text{base}}(y|x) \varphi_1(y) dy, & \varphi_0(x) \hat{\varphi}_0(x) = \mu(x), \\ \hat{\varphi}_t(x) = \int p_{t|0}^{\text{base}}(x|y) \hat{\varphi}_0(y) dy, & \varphi_1(x) \hat{\varphi}_1(x) = p_1^*(x). \end{cases}$$

We conclude that p^* indeed solves (48). □

推论 B.4 (随机最优控制问题的互反过程)。随机最优控制问题 (20) 的最优分布 p^* 是一个互反过程, 即

$$p^*(X) = p^{\text{base}}(X|X_0, X_1) p^*(X_0, X_1). \quad (51)$$

B.2 正文中缺失的证明

证明: 定理 3.1 将式 (8a) 与式 (21) 比较, 可将 $\varphi_t(x)$ 重新解释为值函数 $V_t(x)$, 即 reinterpreting

$$V_t(x) := -\log \varphi_t(x), \quad g(x) := -\log \varphi_1(x) \stackrel{(8b)}{=} \log \frac{\hat{\varphi}_1(x)}{\nu(x)}.$$

即, 薛定谔桥的动能最优漂移求解了一个具有终端代价 $g(x) := \frac{\hat{\varphi}_1(x)}{\nu(x)}$ 的随机最优控制问题 (4). □

证明: 定理 4.1 为记号简便, 证明中通篇记 $q \equiv q^{\bar{h}^{(k-1)}}$ 。首先将倒向随机微分方程 (17) 改写为正向形式 (Nelson, 2020) :

$$dX_t = [f_t - \sigma_t^2 \nabla \log \phi_t + \sigma_t^2 \nabla \log q_t] dt + \sigma_t dW_t, \quad X_1 \sim \nu,$$

其中将 $\phi_t(x)$ 改写为关于正向时间坐标的形式:

$$\phi_t(x) = \int p_{t|0}^{\text{base}}(x|y) \phi_0(y) dy, \quad \phi_1(x) = \bar{h}^{(k-1)}(x). \quad (52)$$

注意到式 (52) 借助费曼-卡茨公式 (Le Gall, 2016) 可等价表示为偏微分方程形式:

$$\partial_t \phi_t(x) = -\nabla \cdot (f_t \phi_t) + \frac{\sigma_t^2}{2} \Delta \phi_t(x), \quad \phi_1(x) = \bar{h}^{(k-1)}(x). \quad (53)$$

另一方面, $\partial_t q$ 的动力学遵循福克-普朗克方程 (Øksendal, 2003) :

$$\begin{aligned}
\partial_t q_t &= -\nabla \cdot ((f_t - \sigma_t^2 \nabla \log \phi_t + \sigma_t^2 \nabla \log q_t) q_t) + \frac{1}{2} \sigma_t^2 \Delta q_t \\
&= \nabla \cdot ((\sigma_t^2 \nabla \log \phi_t - f_t) q_t) - \frac{1}{2} \sigma_t^2 \Delta q_t,
\end{aligned}$$

直接计算可得

$$\partial_t \log q_t = \sigma_t^2 \Delta \log \phi_t - \nabla \cdot f_t + (\sigma_t^2 \nabla \log \phi_t - f_t) \cdot \nabla \log q_t - \frac{1}{2} \sigma_t^2 \|\nabla \log q_t\|^2 - \frac{1}{2} \sigma_t^2 \Delta \log q_t, \quad (54)$$

其中我们对 $\log q_t$ 应用拉普拉斯技巧 (47)。现 $\Delta q = \|\nabla \log q_t\|^2 + \Delta \log q_t$ 。

在，回顾 p 是由以下随机微分方程诱导的路径

分布：

$$dX_t = [f_t(X_t) + \sigma_t u_t(X_t)] dt + \sigma_t dW_t, \quad X_0 \sim \mu. \quad (55)$$

对 $\log q_t(X_t)$ 调用伊藤引理 (46)，其中 X_t 遵循 (55)：

$$\begin{aligned} d \log q_t &= \left[\partial_t \log q_t + \nabla \log q_t \cdot (f_t + \sigma_t u_t) + \frac{1}{2} \sigma_t^2 \Delta \log q_t \right] dt + \sigma_t \nabla \log q_t \cdot dW_t \\ &\stackrel{(54)}{=} \left[\sigma_t^2 \Delta \log \phi_t - \nabla \cdot f_t + \sigma_t^2 \nabla \log \phi_t \cdot \nabla \log q_t - \frac{1}{2} \sigma_t^2 \|\nabla \log q_t\|^2 + \nabla \log q_t \cdot (\sigma_t u_t) \right] dt \\ &\quad + \sigma_t \nabla \log q_t \cdot dW_t \end{aligned} \quad (56)$$

同样地，对 $\log \phi_t(X_t)$ 调用伊藤引理 (46)，其中 X_t 遵循 (55)：

$$\begin{aligned} d \log \phi_t &= \left[\partial_t \log \phi_t + \nabla \log \phi_t \cdot (f_t + \sigma_t u_t) + \frac{1}{2} \sigma_t^2 \Delta \log \phi_t \right] dt + \sigma_t \nabla \log \phi_t \cdot dW_t \\ &\stackrel{(53)}{=} \left[-\nabla \cdot f_t + \frac{\sigma_t^2}{2} \frac{\Delta \phi_t}{\phi_t} + \nabla \log \phi_t \cdot (\sigma_t u_t) + \frac{1}{2} \sigma_t^2 \Delta \log \phi_t \right] dt + \sigma_t \nabla \log \phi_t \cdot dW_t \\ &\stackrel{(47)}{=} \left[-\nabla \cdot f_t + \frac{\sigma_t^2}{2} (\|\nabla \log \phi_t\|^2 + \Delta \log \phi_t) + \nabla \log \phi_t \cdot (\sigma_t u_t) + \frac{1}{2} \sigma_t^2 \Delta \log \phi_t \right] dt + \sigma_t \nabla \log \phi_t \cdot dW_t \\ &= \left[-\nabla \cdot f_t + \frac{\sigma_t^2}{2} \|\nabla \log \phi_t\|^2 + \nabla \log \phi_t \cdot (\sigma_t u_t) + \sigma_t^2 \Delta \log \phi_t \right] dt + \sigma_t \nabla \log \phi_t \cdot dW_t \end{aligned} \quad (57)$$

从 (56) 中减去 (57) 得到

$$d \log \phi_t - d \log q_t = \left[\frac{1}{2} \|u_t + \sigma_t \nabla \log \phi_t - \sigma_t \nabla \log q_t\|^2 - \frac{1}{2} \|u_t\|^2 \right] dt + \sigma_t \nabla \log \frac{\phi_t}{q_t} \cdot dW_t. \quad (58)$$

最后，我们准备计算 (16) 中的变分目标：

$$\begin{aligned} D_{\text{KL}}(p \| q^{\bar{h}^{(k-1)}}) &= \mathbb{E}_{X \sim p^u} \left[\int_0^1 \frac{1}{2} \|u_t(X_t) + \sigma_t \nabla \log \phi_t(X_t) - \sigma_t \nabla \log q_t(X_t)\|^2 dt \right] \\ &\stackrel{(58)}{=} \mathbb{E}_{X \sim p^u} \left[\int_0^1 \left(\frac{1}{2} \|u_t(X_t)\|^2 + d \log \phi_t(X_t) - d \log q_t(X_t) \right) dt \right] \\ &= \mathbb{E}_{X \sim p^u} \left[\int_0^1 \frac{1}{2} \|u_t(X_t)\|^2 dt + \log \frac{\phi_1(X_1)}{q_1(X_1)} - \log \frac{\phi_0(X_0)}{q_0(X_0)} \right] \end{aligned} \quad (59)$$

$$\propto \mathbb{E}_{X \sim p^u} \left[\int_0^1 \frac{1}{2} \|u_t(X_t)\|^2 dt + \log \frac{\bar{h}^{(k-1)}(X_1)}{\nu(X_1)} \right]. \quad (60)$$

也就是说，我们已经证明变分目标 $D_{\text{KL}}(p \| q^{\bar{h}^{(k-1)}})$ 等价于（相差一个加性常数）一个随机最优控制问题 (60)。应用互惠伴随匹配 (Havens 等人, 2025) 以及推论 B.4 中的互惠过程，可以得出 $D_{\text{KL}}(p \| q^{\bar{h}^{(k-1)}})$ 由 $p^{u^{(k)}}$ 最小化 $\square$

证明： 定理 4.2 为了记号简便，在整个证明过程中我们将记 $p^{(k)} \equiv p^{u^{(k)}}$ 。设 q 为由一个反向随机微分方程诱导的路径分布，沿时间坐标 $s := 1 - t$ 传播：

$$dY_s = [-f_s(Y_s) + \sigma_s v_s(Y_s)] ds + \sigma_s dW_s, \quad Y_0 \sim \nu.$$

接下来，将正向随机微分方程 $p^{(k)}$ 改写为反向形式：

$$dY_s = \left[-f_s - \sigma_s u_s^{(k)} + \sigma_s^2 \nabla \log p_s^{(k)} \right] ds + \sigma_s dW_s, \quad Y_0 \sim p_t^{(k)}|_{t=1}.$$

根据定理 B.3，可知 $p^{(k)}$ 是薛定谔桥（SB）解，因此满足

$$u_t^{(k)}(x) = \sigma_t \nabla \log \varphi_t(x), \quad \text{其中} \quad \begin{cases} \varphi_t(x) = \int p_{1|t}^{\text{base}}(y|x) \varphi_1(y) dy, & \varphi_0(x) \hat{\varphi}_0(x) = \mu(x) \\ \hat{\varphi}_t(x) = \int p_{t|0}^{\text{base}}(x|y) \hat{\varphi}_0(y) dy, & \varphi_1(x) \hat{\varphi}_1(x) = p_1^{(k)}(x) \end{cases} \quad (61a)$$

$$(61b)$$

由于我们使用反向时间坐标 s ，为方便起见定义 $\phi_s := \hat{\varphi}_{1-t}$ 并重写 (61b) by

$$\phi_s(y) = \int p_{1-s|0}^{\text{base}}(y|z) \phi_1(z) dz, \quad \phi_0(y) = \frac{p_1^{(k)}(y)}{\varphi_1(y)}. \quad (62)$$

现在，利用吉尔萨诺夫定理展开变分目标，得到（Särkkä 和 Solin，2019）

$$D_{\text{KL}}(p^{(k)}||q) = \mathbb{E}_{Y \sim p^{(k)}} \left[\int_0^1 \frac{1}{2} \| -\sigma_s \nabla \log \varphi_s(Y_s) + \sigma_s \nabla \log p_s^{(k)}(Y_s) - v_s(Y_s) \|^2 ds \right], \quad (63)$$

该目标在以下点处逐点最小化

$$v_s^*(y) = \sigma_s \nabla \log \frac{p_s^{(k)}(y)}{\varphi_s(y)} \stackrel{(42)}{=} \sigma_s \nabla \log \hat{\varphi}_s(y).$$

换言之，使 (63) 式最小化的反向随机微分方程必须满足

$$dY_s = \left[-f_s(Y_s) + \sigma_s^2 \nabla \log \phi_s(Y_s) \right] ds + \sigma_s dW_s, \quad Y_0 \sim \nu,$$

其中 ϕ_s 在 (62) 式中定义。也就是说，到目前为止我们已得出结论

$$q^{p_1^{(k)}/\varphi_1} = \arg \min_q \{ D_{\text{KL}}(p^{(k)}||q) : q_1 = \nu \}. \quad (64)$$

因此，仍需证明阶段 k 的条件均值（CM）目标的极小化子 $\bar{h}_1^{(k)}$ 等于 $\frac{p_1^{(k)}}{\varphi_1}$ 。这确实成立，因为 $p^{(k)}$ 是薛定谔桥（SB）解：

$$\nabla \log \bar{h}^{(k)} \stackrel{(15)}{:=} \arg \min_h \mathbb{E}_{p_{0,1}^{(k)}} [\|h(X_1) - \nabla_{x_1} \log p^{\text{base}}(X_1|X_0)\|^2] \stackrel{(45)}{=} \nabla \log \hat{\varphi}_1 \stackrel{(42)}{=} \nabla \log \frac{p_1^{(k)}}{\varphi_1}.$$

□

C ASBS 的实用实现

算法 2 总结了 ASBS 的实用实现，其中我们将伴随匹配和校正匹配步骤（即算法 1 中的第 3 行和第 4 行）展开为完整细节。表 5 提供了每个任务的超参数。我们将每个组成部分分解如下：

调和先验 μ_{harmonic} 回顾 (19) 中的调和先验：

$$\mu_{\text{harmonic}}(x) \propto \exp(-\frac{1}{2} \sum_{i,j} \|x_i - x_j\|^2). \quad (65)$$

在实践中，我们设 $\alpha = 1$ 并将 (65) 实现为各向异性高斯分布。例如，对于 2 粒子系统在 3D, *i.e.*, $x = [x_1; x_2] \in \mathbb{R}^6$ ，我们可以将 (65) 重写为二次势能，

$$\exp(-\frac{1}{2} \|x_1 - x_2\|^2) = \exp(x^\top R x), \quad \text{where } R = \begin{bmatrix} 1 & 0 & 0 & -\frac{1}{2} & 0 & 0 \\ 0 & 1 & 0 & 0 & -\frac{1}{2} & 0 \\ 0 & 0 & 1 & 0 & 0 & -\frac{1}{2} \\ -\frac{1}{2} & 0 & 0 & 1 & 0 & 0 \\ 0 & -\frac{1}{2} & 0 & 0 & 1 & 0 \\ 0 & 0 & -\frac{1}{2} & 0 & 0 & 1 \end{bmatrix}, \quad (66)$$

Algorithm 2 Adjoint Schrödinger Bridge Sampler (ASBS)

Require: Sampleable source $X_0 \sim \mu$, differentiable energy $E(x)$, parametrized drift $u_\theta(t, x)$ and corrector $h_\phi(x)$, replay buffers $\mathcal{B}_{\text{adj}}$ and $\mathcal{B}_{\text{crt}}$, number of stages K , numbers of AM and CM epochs M_{adj} and M_{crt} , number of resamples N , number of gradient steps L , time scaling λ_t , maximum energy gradient norm α_{max} .

```

1: Initialize  $h_\phi^{(0)} := 0$  ▷ IPF initialization
2: for stage  $k$  in  $1, 2, \dots, K$  do
3:   for epoch in  $1, 2, \dots, M_{\text{adj}}$  do ▷ adjoint matching
4:     Sample from model  $\{(X_0^{(i)}, X_1^{(i)})\}_{i=1}^N \sim p^{\bar{u}^{(k)}}$ , where  $\bar{u}^{(k)} = \text{stopgrad}(u_\theta^{(k)})$ 
5:     Compute adjoint target  $a_t^{(i)} := \text{stopgrad}(\text{clip}(\nabla E(X_1^{(i)}), \alpha_{\text{max}}) + h_\phi^{(k)}(X_1^{(i)}))$ 
6:     Update replay buffer  $\mathcal{B}_{\text{adj}} \leftarrow \mathcal{B}_{\text{adj}} \cup \{(X_0^{(i)}, X_1^{(i)}, a_t^{(i)})\}_{i=1}^N$ 
7:     Take  $L$  gradient steps  $\nabla_\theta \mathcal{L}_{\text{AM}}$  w.r.t. the AM objective:

$$\mathcal{L}_{\text{AM}}(\theta) := \mathbb{E}_{t \sim \mathcal{U}[0,1], (X_0, X_1, a_t) \sim \mathcal{B}_{\text{adj}}, X_t \sim p^{\text{base}}(\cdot | X_0, X_1)} \left[ \lambda_t \|u_\theta^{(k)}(t, X_t) + \sigma_t a_t\|^2 \right]$$

8:   end for
9:   for epoch in  $1, 2, \dots, M_{\text{crt}}$  do ▷ corrector matching
10:    Sample from model  $\{(X_0^{(i)}, X_1^{(i)})\}_{i=1}^N \sim p^{\bar{u}^{(k)}}$ , where  $\bar{u}^{(k)} = \text{stopgrad}(u_\theta^{(k)})$ 
11:    Update replay buffer  $\mathcal{B}_{\text{crt}} \leftarrow \mathcal{B}_{\text{crt}} \cup \{(X_0^{(i)}, X_1^{(i)})\}_{i=1}^N$ 
12:    Take  $L$  gradient steps  $\nabla_\phi \mathcal{L}_{\text{CM}}$  w.r.t. the CM objective:

$$\mathcal{L}_{\text{CM}}(\phi) := \mathbb{E}_{(X_0, X_1) \sim \mathcal{B}_{\text{crt}}} \left[ \|h_\phi^{(k)}(X_1) - \nabla_{x_1} \log p^{\text{base}}(X_1 | X_0)\|^2 \right]$$

13:   end for
14: end for
15: return Kinetic-optimal drift  $u^* \approx u_\theta(t, x)$ 

```

然后从高斯 $\mathcal{N}(x; 0, (R + \epsilon I)^{-1})$ 中采样 x ，其中我们设置 $\epsilon = 10^{-4}$ 。

噪声调度 σ_t 我们考虑两种类型的噪声调度。

- 几何噪声调度 (Geometric Noise Schedule) (Song 等人, 2021; Karras 等人, 2022) 根据预设的 $\beta_{\min}$ 和 $\beta_{\max}$ ，从 $t = 0$ 单调衰减至 1:

$$\sigma_t^{\text{geometric}} := \beta_{\min} \left(\frac{\beta_{\max}}{\beta_{\min}} \right)^{1-t} \sqrt{2 \log \frac{\beta_{\max}}{\beta_{\min}}}. \quad (67)$$

为方便起见，进一步定义

$$\kappa_{t|s} := \int_s^t \sigma_\tau^2 d\tau \stackrel{\text{geometric}}{=} \beta_{\max}^2 \cdot \left(\left(\frac{\beta_{\min}}{\beta_{\max}} \right)^{2s} - \left(\frac{\beta_{\min}}{\beta_{\max}} \right)^{2t} \right), \quad \bar{\beta}^2 := \beta_{\max}^2 - \beta_{\min}^2, \quad \gamma_t := \frac{\kappa_{t|0}}{\bar{\beta}^2}. \quad (68)$$

借助它们，当 $f := 0$ 时的条件基分布可紧凑地表示为

$$p^{\text{base}}(X_t | X_0) = \mathcal{N}(X_t; X_0, \kappa_{t|0} I) \quad (69a)$$

$$p^{\text{base}}(X_t | X_0, X_1) = \mathcal{N}(X_t; (1 - \gamma_t)X_0 + \gamma_t X_1, \bar{\beta}^2 \gamma_t (1 - \gamma_t) I) \quad (69b)$$

- 恒定噪声调度直接设定

$$\sigma_t \stackrel{\text{常数}}{=} \sigma. \quad (70)$$

当 $f := 0$ 时，基础随机微分方程 (SDE) 实际上是一个标准布朗运动，其条件分布服从

$$p^{\text{base}}(X_t | X_0) = \mathcal{N}(X_t; X_0, \sigma^2 t I) \quad (71a)$$

$$p^{\text{base}}(X_t | X_0, X_1) = \mathcal{N}(X_t; (1 - t)X_0 + tX_1, \sigma^2 t(1 - t)I) \quad (71b)$$

回放缓冲区 $\mathcal{B}_{\text{adj}}$ 和 $\mathcal{B}_{\text{crt}}$ 与许多先前的扩散采样器类似 (Havens 等人, 2025; Akhound-Sadegh 等人, 2024; Chen 等人, 2025), 我们在计算伴随 (14) 和校正器 (15) 匹配目标时采用了回放缓冲区 $\mathcal{B}$ 。具体而言, 我们将模型样本 $p^{u^{(k)}}$ 上的期望重新基于回放缓冲区 $\mathcal{B}$, 该缓冲区存储最新的 $|\mathcal{B}|$ 个样本。我们每 L 个梯度步用 N 个新样本更新缓冲区。注意, 回放缓冲区的使用实际上使 ASBS 成为在线策略与离线策略之间的混合方法。

参数化方法 u_θ 与 h_ϕ 对于每个能量函数, 我们使用两个架构相同的神经网络 $v_\theta(t, x)$ 和 $v_\phi(t, x)$ 来参数化漂移项 $u_\theta(t, x)$ 和校正项 $h_\phi(x)$ 。

具体而言, 我们将漂移项参数化为 $u_\theta(t, x) := \sigma_t v_\theta(t, x)$, 这有效地消除了匹配目标中的噪声调度“ σ_t ” (见式 (14)), 使其对于每条采样轨迹都是时不变的。唯一的例外是构象生成任务, 我们保留原始参数化 $u_\theta(t, x) := v_\theta(t, x)$, 因为它在经验上能取得更好的结果。另一方面, 由于 $h_\phi(x)$ 与时间无关, 我们只需设置一个固定的时间输入 $t = 1$, *i.e.*, $h_\phi(x) := v_\phi(1, x)$ 。

每个任务所采用的具体参数化 $v(t, x)$ 详述如下。

- MW-5: 我们将 $v(t, x)$ 视为一个标准的全连接网络, 具有 4 层、64 个隐藏特征, 形式如下:

$$\text{输出} = \text{第 } n \text{ 层} \circ \cdots \circ \text{第 } 1 \text{ 层} \circ (\text{x_嵌入}(x) + \text{t_嵌入}(t))$$

- DW-4、LJ-13、LJ-55: 我们将 $v(t, x)$ 视为一个等变图神经网络 (EGNN; Satorras 等人, 2021), 具有 5 层和 128 个隐藏特征。EGNN 的架构与先前方法一致 (Akhound-Sadegh 等人, 2024; Havens 等人, 2025)。
- 丙氨酸二肽: 我们使用与 MW-5 相同的架构, 但改为 8 层、256 个隐藏特征。
- 构象生成: 我们考虑 $v(t, x)$ 一个与伴随采样 (Havens 等人, 2025) 中使用的类似等变图神经网络 (EGNN), 但具有 20 层。关于相同 EGNN 架构的消融实验见第 D.4 节。

裁剪 α_{max} 我们裁剪能量梯度, 以防止其最大范数超过 α_{max} 。

时间缩放 λ_t 遵循 AM 目标的标准做法, 我们采用时间缩放 λ_t 以提高数值稳定性。注意, 这不会影响 AM 目标的最小值。我们为所有任务设置 $\lambda_t := 1/\sigma_t^2$ 。

平移不变性 对于 DW-4、LJ-13、LJ-55 和构象生成任务, 我们遵循先前方法 (Akhound-Sadegh 等人, 2024; Havens 等人, 2025), 将状态空间限制在零质心 (ZCOM) 子空间, 从而强制平移不变性。

对于 n 粒子 k 维系统, *i.e.*, $x = [x_1; \cdots; x_n]$ 其中 $x_i \in \mathbb{R}^k$, ZCOM 子空间定义为 $\mathcal{X}^{\text{ZCOM}} = \{x \in \mathbb{R}^{nk} : \sum_{i=1}^n x_i = 0\}$ 。实际上, 这是通过将初始样本 $X_0 \sim \mu$ 、随机微分方程的噪声 dW_t 和能量梯度 $\nabla E(\cdot)$ 投影到 $\mathcal{X}^{\text{ZCOM}}$ 上来实现的。注意, EGNN 的输出按构造属于 ZCOM。

形式上, 该适配等价于用投影矩阵 $A \in \mathbb{R}^{nk \times nk}$ 增强随机微分方程:

$$dX_t = \sigma_t A u_t(X_t) dt + \sigma_t A dW_t, \quad X_0 = A Y_0, \quad Y_0 \sim \mu, \quad A = \left(I_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top \right) \otimes I_k, \quad (72)$$

其中 $\otimes$ 是克罗内克积, $I_n \in \mathbb{R}^{n \times n}$ 是单位矩阵, $\mathbf{1}_n \in \mathbb{R}^n$ 是全一向量。

初始化与交替过程 由于 ASBS 是 IPF 算法的一个实例 (见定理 3.2), 它必须遵循 IPF 初始化协议以确保理论收敛到全局解。具体而言, IPF 初始化可以通过两种方式实现: • 用 $h_\phi^{(0)} := 0$ 初始化, 并运行 AM、CM 等直到收敛。我们在所有任务中采用此设置。

$u_\theta^{(0)}$ 用 $:= 0$ 初始化，并运行 CM、AM 等直到收敛。由于此设置中 $p^{u^{(0)}} = p^{\text{base}}$ ，第一个 CM 阶段的最优校正器可解析求得：

$$\begin{aligned}
h^{(1)}(x) &\stackrel{(15)}{=} \int p_{0|1}^{\text{base}}(y|x) \nabla_x \log p_{1|0}^{\text{base}}(x|y) dy \\
&= \int \frac{p_{0|1}^{\text{base}}(y|x)}{p_{1|0}^{\text{base}}(x|y)} \nabla_x p_{1|0}^{\text{base}}(x|y) dy \\
&= \frac{1}{p_1^{\text{base}}(x)} \nabla_x \int p_0^{\text{base}}(y) p_{1|0}^{\text{base}}(x|y) dy \\
&= \nabla \log p_1^{\text{base}}(x)
\end{aligned} \tag{73}$$

在实践中，我们发现两种设置性能相近。

RDKit 热启动 这利用 RDKit 样本对漂移 u_θ 进行热启动。该过程受以下事实启发：(Shi et al., 2023; Liu et al., 2023)：

$$\begin{aligned}
u_t^* &= \sigma_t \nabla \log \varphi_t \\
&= \arg \min_{u_t} \mathbb{E}_{p_{t,1}^*} [\|u_t(X_t) - \sigma_t \nabla_{x_t} \log p^{\text{base}}(X_1|X_t)\|^2] \\
&= \arg \min_{u_t} \mathbb{E}_{(X_0, X_1) \sim p_{0,1}^*, X_t \sim p^{\text{base}}(\cdot|X_0, X_1)} [\|u_t(X_t) - \sigma_t \nabla_{x_t} \log p^{\text{base}}(X_1|X_t)\|^2].
\end{aligned} \tag{74}$$

其中最后一个等式成立的原因是

$$\begin{aligned}
p_{0,t,1}^*(x, y, z) &\stackrel{(41)}{=} p_{t,1|0}^{\text{base}}(y, z|x) \hat{\varphi}_0(x) \varphi_1(z) \\
&= p_{t|0,1}^{\text{base}}(y|x, z) p_{1|t}^{\text{base}}(z|y) \hat{\varphi}_0(x) \varphi_1(z) && \text{by Markov property} \\
&\stackrel{(43)}{=} p_{t|0,1}^{\text{base}}(y|x, z) p_{0,1}^*(x, z).
\end{aligned} \tag{75}$$

方程 (74) 可以理解为 (45) 针对另一个薛定谔桥势 φ_t 的类比。在实践中，给定 RDKit 样本 $X_1 \sim q^{\text{RDKit}}$ ，我们通过最小化以下目标来热启动 ASBS：

$$\begin{aligned}
\mathcal{L}_{\text{warmup}}(\theta) &= \mathbb{E}_{t \sim \mathcal{U}[0,1], X_0 \sim \mu, X_1 \sim q^{\text{RDKit}}, X_t \sim p^{\text{base}}(\cdot|X_0, X_1)} [\tilde{\lambda}_t \|u_t(X_t) - \sigma_t \nabla_{x_t} \log p^{\text{base}}(X_1|X_t)\|^2] \\
&\stackrel{(69a)}{=} \mathbb{E}_{t \sim \mathcal{U}[0,1], X_0 \sim \mu, X_1 \sim q^{\text{RDKit}}, X_t \sim p^{\text{base}}(\cdot|X_0, X_1)} \left[\tilde{\lambda}_t \left\| u_t(X_t) - \frac{\sigma_t}{\kappa_{1|t}} (X_1 - X_t) \right\|^2 \right],
\end{aligned} \tag{76}$$

其中 $\kappa_{1|t}$ 在 (68) 中针对几何噪声调度定义。我们设置时间缩放 $\tilde{\lambda}_t := \frac{\sigma_t}{\kappa_{1|t}}$ ，与 AS 不同，(76) 的最小 $\sqrt{\frac{\sigma_t}{\kappa_{1|t}}}$ 。Note 化器不等于 u^* ，因为 $(X_0, X_1) \sim \mu \otimes q^{\text{RDKit}} \neq p_{0,1}^*$ 是独立采样的。

D 实验细节

D.1 合成能量函数

D.1.1 能量函数

在本节中，我们提供了表 2 中合成能量实验的确切设置。我们考虑了四个合成能量函数，这些函数在近期文献中被广泛用于基准测试采样和生成算法：MW-5、DW-4、LJ-13 和 LJ-55。

MW-5 MW-5（五维多井）能量是一个从 Chen 等人（2025）采用的五粒子一维系统，其中 $x = [x_1; \dots; x_5] \in \mathbb{R}^5$ 且 $x_i \in \mathbb{R}$ 。能量函数定义如下：

$$E(x) = \sum_{i=1}^5 (x_i^2 - \delta)^2 \tag{77}$$

表 5 各任务中 ASBS 的超参数。

	Synthetic energy functions				Alanine dipeptide	Conformer generation
	MW-5	DW-4	LJ-13	LJ-55		
μ	$\mathcal{N}(0, 1)$	μ_{harmonic}	in (19) with $\alpha=2, 2, 1$		$\mathcal{N}(0, 0.25)$	μ_{harmonic}
$\beta_{\min}$	—	0.001	0.001	0.001	0.001	0.001
$\beta_{\max}$	—	1	1	2	0.5	1
σ	0.2	—	—	—	—	—
K	5	20	15	15	15	3
M_{adj}	100	200	300	300	4000	2500
M_{crt}	20	20	20	20	2000	2000
N	1000	1000	1000	1000	1000	128
L	200	100	100	100	100	100
$ \mathcal{B} $	10^4	10^4	10^4	10^4	10^4	6.4×10^4
$\alpha_{\max}$	—	100	100	100	100	150
λ_t	$\frac{1}{\sigma_t^2}$	$\frac{1}{\sigma_t^2}$	$\frac{1}{\sigma_t^2}$	$\frac{1}{\sigma_t^2}$	$\frac{1}{\sigma_t^2}$	$\frac{1}{\sigma_t^2}$

其中我们设定 $\delta = 4$ 。这在 d 个维度的每个维度中，以 $\pm$ 、 σ 、 δ 的组合为中心创建了不同的模式。

DW-4 **DW-4**（二维四粒子双井）能量是一种物理驱动的成对势，最初由 Köhler 等人（2020）提出，随后在 Akhound-Sadegh 等人（2024）；Havens 等人（2025）中使用。它定义了一个由四个粒子组成的系统，每个粒子位于 $\mathbb{R}^2$ 中，从而得到一个八维状态向量 $x = [x_1; x_2; x_3; x_4] \in \mathbb{R}^8$ ，其中 $x_i \in \mathbb{R}^2$ 。能量函数为

$$E(x) = \exp \left[\frac{1}{2\tau} \sum_{i < j} (a(d_{ij} - d_0) + b(d_{ij} - d_0)^2 + c(d_{ij} - d_0)^4) \right], \quad (78)$$

其中 $d_{ij} = \|x_i - x_j\|_2$ 是粒子 i 与 j 之间的欧氏距离。我们遵循标准配置，其中 $a = 0, b = -4, c = 0.9, d_0 = 1$ ，温度为 $\tau = 1$ 。

Lennard Jones (LJ)-13 和 LJ-55 Lennard-Jones (LJ) 势是物理学中常用于模拟原子相互作用的经典分子间势。这些势定义在三维空间中由 n 个粒子组成的系统上，其中 $x = [x_1; \dots; x_n] \in \mathbb{R}^{3n}$ 且 $x_i \in \mathbb{R}^3$ 。“LJ-”后面的索引表示粒子数（例如，13 或 55）。未归一化的能量函数形式为：

$$E(x) = \frac{\epsilon}{2\tau} \sum_{i < j} \left[\left(\frac{r_m}{d_{ij}} \right)^6 - \left(\frac{r_m}{d_{ij}} \right)^{12} \right] + \frac{c}{2} \sum_i \|x_i - C(x)\|^2, \quad (79)$$

其中 $d_{ij} = \|x_i - x_j\|_2$ 是成对距离， $C(x)$ 表示粒子的质心。我们沿用先前工作的参数值 $r_m = 1, \epsilon = 1, c = 0.5$ 和 $\tau = 1$ 。LJ-13 和 LJ-55 系统分别对应 39 维和 165 维。

D.1.2 基线

此处，我们概述用于获得表 2 中基线方法数值的过程。

对于 PIS（Zhang 和 Chen，2022）、DDS（Vargas 等人，2023）、LV-PIS（Richter 和 Berner，2024）、iDEM（Akhound-Sadegh 等人，2024）和 AS（Havens 等人，2025），我们直接采用 AS（Havens 等人，2025，表 1）中针对 DW-4、LJ-13 和 LJ-55 能量函数报告的数值。至于未包含在 AS 中的 MW-5，我们使用 iDEM 的官方实现运行，其余基线方法则使用我们在 PyTorch（Paszke 等人，2019）中的自有实现运行。对于该能量函数，我们无法获得 LV-PIS 和 iDEM 的可报告结果。

对于 PDDS (Phillips 等人, 2024) 和 SCLD (Chen 等人, 2025), 我们使用其各自论文中针对对数高斯考克斯过程实验指定的默认超参数设置, 在 JAX (Bradbury 等人, 2018) 中运行其官方实现。为增强合成能量函数上的稳定性和收敛性, 我们调整了梯度裁剪参数。对于 PDDS, 我们对能量函数的梯度应用裁剪。对于 SCLD, 我们同时裁剪能量梯度和朗之万范数。在两种情况下, 裁剪幅度均根据最佳验证性能从集合 $\{1, 10, 100, 1000\}$ 中选取。所有运行均训练 100,000 次迭代。对于 SCLD, 我们使用默认值为 4 的子轨迹分割, 以避免退化为 CMCD (Vargas 等人, 2024)。实践中, 我们发现使用子轨迹能获得更好的结果。

D.1.3 评估度量

在本小节中, 我们概述用于定量评估合成能量函数生成样本质量的评估标准。我们采用三个主要度量: 辛克霍恩距离、几何 $\mathcal{W}_2$ 和能量 $\mathcal{W}_2$, 每个度量旨在捕捉生成样本与真实样本之间分布相似性的不同方面。

辛克霍恩距离 为评估生成样本与参考样本经验分布之间的相似性, 本文采用熵正则化最优传输公式 (Peyré 和 Cuturi, 2019) 计算 Sinkhorn 距离, 遵循 Blessing 等人 (2024) 和 Chen 等人 (2025) 的实现。Sinkhorn 正则化系数全程设为 10^{-3} 。本文从生成分布和真实分布中各取 2,000 个样本计算该度量。

几何 $\mathcal{W}_2$ 对于 DW 和 LJ 任务, 势能函数——以及由此得到的样本分布——对粒子置换和刚体变换 (如旋转和反射) 具有不变性。为恰当考虑这些对称性, 本文采用 Akhond-Sadegh 等人 (2024) 和 Havens 等人 (2025) 定义的几何 $\mathcal{W}_2$ 距离。形式上, 2-Wasserstein 距离计算如下:

$$\mathcal{W}_2^2(\hat{\nu}, \nu) = \inf_{\pi \in \Pi(\hat{\nu}, \nu)} \int D(x, y)^2 \pi(x, y) dx dy, \quad (80)$$

其中 $\Pi(\hat{\nu}, \nu)$ 表示具有指定边缘分布 $\hat{\nu}$ (生成) 和 ν (真实) 的联合耦合集合, $D(x, y)$ 是样本间对称性感知的距离, 定义为:

$$D(x, y) = \min_{R \in O(s), P \in S(n)} \|x - (R \otimes P)y\|_2. \quad (81)$$

此处, $O(s)$ 表示 s 维空间中的正交变换群 (旋转和反射), $S(n)$ 表示 n 个粒子上的对称群。由于在这些对称群上进行精确最小化在计算上不可行, 本文采用 Köhler 等人 (2020) 的近似方案。本文从每个生成分布和真实分布中各取 2000 个样本计算该度量。

能量 $\mathcal{W}_2$ 为评估生成样本对目标能量景观的保真度, 本文还计算生成样本能量值与真实样本能量值之间的 2-Wasserstein 距离。对于每个目标分布, 本文从模型和参考分布中各生成 2,000 个样本, 并比较它们各自的能量直方图。该基于标量的 Wasserstein 度量可作为生成模型捕捉目标分布能量直方图能力的代理指标。

D.2 丙氨酸二肽

基准描述 我们主要采用 (Midgley 等人, 2023) 的实验设置。给定丙氨酸二肽的构型, 该构型由三维空间中的 22 个粒子组成, *i.e.*, $x = [x_1; \dots; x_{22}] \in \mathbb{R}^{66}$ 其中 $x_i \in \mathbb{R}^3$, 我们应用 Midgley 等人 (2023) 提出的相同坐标变换 $\mathcal{T}$ 。该坐标变换将笛卡尔坐标映射到内坐标, $\mathcal{T}(x) =: z \in \mathbb{R}^{60}$, 包括键长、键角和二面角 (Stimper 等人, 2022)。这一过程有效地消除了六个自由度——三个平动自由度和三个转动自由度——从而强制了结构不变性。非角度坐标进一步使用能量最小的样本进行归一化。我们请读者参考 (Midgley 等人,

2023, 附录 F.1) 以获取更多细节。注意内部坐标变换是双射的。因此, 本文可以通过以下方式计算能量

$$E(x) = E(\mathcal{T}^{-1}(z)) \quad (82)$$

评估与基线 对于每个样本 $x = \mathcal{T}^{-1}(z) \in \mathbb{R}^{66}$, 本文提取五个扭转角, 包括主链角 ϕ, ψ 和甲基旋转角 $\gamma_1, \gamma_2, \gamma_3$ 。本文报告相对于真实分布的两个散度量, 该真实分布包含由分子动力学模拟的 10^7 个样本。本文使用 PyTorch (Paszke et al., 2019) 实现基线方法, 包括 PIS (Zhang and Chen, 2022)、DDS (Vargas et al., 2023) 和 AS (Havens et al., 2025)。

对于 KL 散度, 本文采用 (Wu et al., 2020) 的设置, 并计算每个扭转角的真实边缘分布到模型边缘分布的散度:

$$D_{\text{KL}}(p^*(\cdot) || p^{u_\theta}(\cdot)) \approx \sum P^*(\cdot) \log \frac{P^*(\cdot) + \epsilon}{P^{u_\theta}(\cdot) + \epsilon}, \quad \epsilon = 10^{-5}, \quad (83)$$

其中 P^* 和 P^{u_θ} 是 10^7 个样本的直方图, 在 $[-\pi, \pi]$ 之间离散化为 200 个区间。

对于 Wasserstein-2 距离, 本文使用 (80) 中的几何 $\mathcal{W}_2$, 其中每个样本现在位于二维空间, $x = [\phi, \psi] \in \mathbb{R}^2$ 。由于计算成本较高, 本文使用测试集真实样本的一个子集 10^4 来计算该值, 该子集对所有方法固定。

最后, 图 5 中的两个拉氏图 (Ramachandran Plot) 均使用 10^7 个样本生成。

D.3 摊销构象生成 本小节为表 4 中关于构象生成的实验结果提供一些背景。

基准描述 构象是分子在笛卡尔空间中的原子表示, 其组成原子排列在势能面上的局部极小值处。分子被定义为由键 (边) 连接的原子 (节点) 图; 构象是该分子的几何实现。扭转角 (或可旋转键) 是定义构象特别重要的自由度, 因为键长和键角通常由于扰动高度敏感而更加稳定。通常认为键长和键角固定, 而扭转自由度定义构象。

该基准中的任务是获取分子图的表示 (通常是简化分子线性输入规范 (SMILES) 字符串 (Weininger, 1988)), 并全面采样构象配置空间。在柔性分子中, 可能存在大量构象, 在 $3n-6$ 维空间中具有许多分离的模式。(其中 n 表示原子数, 6 来自构象旋转和平移的无关性。) 我们通过将生成的结构与使用昂贵的标准搜索技术 (Pracht et al., 2024) 采样、并使用极其精确的基于密度泛函理论的量子化学方法 (Neese, 2012; Levine et al., 2025) 进一步弛豫的一组构象进行比较, 来量化全面采样空间的概念。该基准的详细描述见其来源 (Havens et al., 2025, 附录 F)。

评估与基线 所提结构与参考构象之间的比较方法是使用 RDKit (Landrum, 2006) 实现的均方根位移 (RMSD), 这是一种对平移和旋转不变的原子结构间距离度量。我们设定一个 RMSD 阈值来判断两个结构是否匹配, 并计算召回覆盖率 (Recall Coverage) 和召回平均最小 RMSD (AMR)。实验分别使用生成的结构以及经过所谓弛豫 (即使用 eSEN (Fu et al., 2025) 进行能量几何优化) 后的生成结构进行。计算这些度量的公式为:

$$\text{COV-R}(\delta) := \frac{1}{L} |\{l \in \{1, \dots, L\} : \exists k \in \{1, \dots, K\}, \text{RMSD}(C_k, C_l^*) < \delta\}| \quad (84)$$

$$\text{AMR-R} := \frac{1}{L} \sum_{l \in \{1, \dots, L\}} \min_{k \in \{1, \dots, K\}} \text{RMSD}(C_k, C_l^*) \quad (85)$$

表 6 使用与 AS (Havens 等人, 2025) 相同的等变图神经网络架构, 对摊销构象生成进行的消融实验。我们报告了在阈值 1.0Å 和 1.25Å 处的召回率, 其中后者在 AS 中报告。

Method	without relaxation				with relaxation				
	SPICE		GEOM-DRUGS		SPICE		GEOM-DRUGS		
	Coverage $\uparrow$	AMR $\downarrow$	Coverage $\uparrow$	AMR $\downarrow$	Coverage $\uparrow$	AMR $\downarrow$	Coverage $\uparrow$	AMR $\downarrow$	
Threshold 1.0Å	RDKit ETKDG (Riniker and Landrum, 2015)	56.94 $\pm$ 35.82	1.04 $\pm$ 0.52	50.81 $\pm$ 34.69	1.15 $\pm$ 0.61	70.21 $\pm$ 31.70	0.79 $\pm$ 0.44	62.55 $\pm$ 31.67	0.93 $\pm$ 0.53
	AS (Havens et al., 2025)	56.75 $\pm$ 38.15	0.96 $\pm$ 0.26	36.23 $\pm$ 33.42	1.20 $\pm$ 0.43	82.41 $\pm$ 25.85	0.68 $\pm$ 0.28	64.26 $\pm$ 34.57	0.89 $\pm$ 0.45
	ASBS w/ Gaussian prior (Ours)	68.61 $\pm$ 33.48	0.88 $\pm$ 0.25	46.03 $\pm$ 35.99	1.08 $\pm$ 0.36	84.77 $\pm$ 22.65	0.64 $\pm$ 0.25	68.83 $\pm$ 31.53	0.80 $\pm$ 0.37
	ASBS w/ Harmonic prior (Ours)	70.70 $\pm$ 33.21	0.86 $\pm$ 0.24	52.19 $\pm$ 35.93	1.05 $\pm$ 0.41	86.79 $\pm$ 22.86	0.61 $\pm$ 0.24	70.08 $\pm$ 31.60	0.80 $\pm$ 0.37
	AS +RDKit warmup (Havens et al., 2025)	72.21 $\pm$ 30.22	0.84 $\pm$ 0.24	52.19 $\pm$ 35.20	1.02 $\pm$ 0.34	87.84 $\pm$ 19.20	0.60 $\pm$ 0.23	73.88 $\pm$ 28.63	0.76 $\pm$ 0.34
	ASBS +RDKit warmup (Ours)	74.29 $\pm$ 31.25	0.82 $\pm$ 0.24	55.88 $\pm$ 36.51	0.98 $\pm$ 0.34	87.25 $\pm$ 20.77	0.60 $\pm$ 0.24	74.11 $\pm$ 30.16	0.75 $\pm$ 0.34
Threshold 1.25Å	RDKit ETKDG (Riniker and Landrum, 2015)	72.74 $\pm$ 33.18	1.04 $\pm$ 0.52	63.51 $\pm$ 34.74	1.15 $\pm$ 0.61	81.61 $\pm$ 27.58	0.79 $\pm$ 0.44	71.72 $\pm$ 29.73	0.93 $\pm$ 0.53
	AS (Havens et al., 2025)	82.22 $\pm$ 25.72	0.96 $\pm$ 0.26	60.93 $\pm$ 35.15	1.20 $\pm$ 0.43	94.10 $\pm$ 15.67	0.68 $\pm$ 0.28	79.08 $\pm$ 29.44	0.89 $\pm$ 0.45
	ASBS w/ Gaussian prior (Ours)	87.20 $\pm$ 21.88	0.88 $\pm$ 0.25	70.86 $\pm$ 31.98	1.08 $\pm$ 0.36	95.19 $\pm$ 10.29	0.64 $\pm$ 0.25	84.66 $\pm$ 25.03	0.80 $\pm$ 0.37
	ASBS w/ Harmonic prior (Ours)	89.66 $\pm$ 19.42	0.86 $\pm$ 0.24	74.50 $\pm$ 32.32	1.05 $\pm$ 0.41	96.64 $\pm$ 10.15	0.61 $\pm$ 0.24	83.76 $\pm$ 24.77	0.80 $\pm$ 0.37
	AS +RDKit warmup (Havens et al., 2025)	89.42 $\pm$ 17.48	0.84 $\pm$ 0.24	72.98 $\pm$ 30.82	1.02 $\pm$ 0.34	96.65 $\pm$ 7.51	0.60 $\pm$ 0.23	87.01 $\pm$ 22.79	0.76 $\pm$ 0.34
	ASBS +RDKit warmup (Ours)	90.85 $\pm$ 17.74	0.82 $\pm$ 0.24	77.86 $\pm$ 30.37	0.98 $\pm$ 0.34	97.28 $\pm$ 6.55	0.60 $\pm$ 0.24	87.81 $\pm$ 22.75	0.75 $\pm$ 0.34




图 8 使用与 AS (Havens 等人, 2025) 相同的等变图神经网络架构, 对完整召回率覆盖曲线 (无 RDKit 热启动) 进行的消融实验。注意表 6 报告了阈值 1.0Å 和 1.25Å 处的值。

其中 $\delta = 0.75$ Å 是覆盖阈值, $L = \max(L', 128)$, 其中 L' 是参考构象的数量, $K = 2L$, 并令 $\{C_l^*\}_{l \in [1, L]}$ 和 $\{C_k\}_{k \in [1, K]}$ 分别为真实构象和生成构象的集合。我们在 COV-R 中将每个分子的参考构象上限设为 512。

基线的值取自 AS (Havens 等人, 2025)。

D.4 附加实验与讨论

使用相同等变图神经网络的伴随采样与 ASBS 之间的消融实验 对于表 4 中的摊销构象生成任务, 我们使用 20 层的等变图神经网络架构, 而 AS 采用 12 层的相同架构。在表 6 中, 我们报告了 ASBS 使用与 AS 相同的 12 层等变图神经网络的结果。值得注意的是, 我们的 ASBS 在所有设置的所有度量上均一致优于 AS, 除了在 GEOM-DRUGS 上使用松弛和 RDKit 热启动时的覆盖率, ASBS 仅落后 AS 1.0%。最后, 图 8 报告了复现表 4 的完整召回率覆盖曲线。

ASBS 发现模式的能力 我们在二维 40 模式高斯混合模型上进行了额外实验。具体而言, 我们以零均值的单一方差高斯源分布实例化 ASBS, 这实际上假设了对目标模式没有任何先验知识, 因为初始分布与任何目标模式都不重合。我们还从相同的源分布出发, 运行了一个普通朗之万基线 100 万步。

图 9 展示了定量结果。值得注意的是, ASBS 能够识别几乎所有模式。相比之下, 普通朗之万基线似乎受到慢混合速率的困扰, 恢复的模式不到总数的一半。




图 9 与普通朗之万基线相比，我们的 ASBS——以标准单一方差高斯实例化——能够在没有任何目标模式位置先验知识的情况下识别几乎所有模式。

即使在 100 万步之后。我们将这一区别强调为从随机控制和薛定谔桥框架构建扩散采样器的一个优势，该框架允许在有限时间范围内理论上收敛到目标分布。最后，我们相信通过适当调整 ASBS 的噪声调度，其性能可以进一步提升。

关于重要性权重的讨论 最后，我们讨论 ASBS 与重要性权重的潜在整合，强调我们的理论和算法框架并不排除使用重要性权重来进一步提升性能或鲁棒性。形式上，模型路径上的重要性权重 $X \sim p^u$ 具有以下表示：

$$w(X) := \frac{dp^*(X)}{dp^u(X)} = \exp \left(\int_0^1 -\frac{1}{2} \|u_t(X_t)\|^2 dt - \int_0^1 u_t(X_t) \cdot dW_t - \log \frac{\hat{\varphi}_1(X_1)}{\nu(X_1)} + \log \frac{\hat{\varphi}_0(X_0)}{\mu(X_0)} \right), \quad (86)$$

这可以通过在 (59) 中设置 $\bar{h} := \hat{\varphi}_1$ 使得 $q^{\bar{h}} = p^*$ 是 SB 的最优分布来获得。

注意，当源分布退化为狄拉克 δ $\mu(X_0) = \delta_0(X_0)$ 时，最后一项 $\log \frac{\hat{\varphi}_0(X_0)}{\mu(X_0)}$ 变为常数，并且——如第 3.2 节所讨论的—— $\hat{\varphi}_1 = p_1^{\text{base}}$ ，从而恢复了先前基于 SOC 的方法中使用的权重（Zhang 和 Chen, 2022; Havens 等人, 2025）。

方程 (86) 也是比（Richter 和 Berner, 2024）中推导出的更简洁的表示，通过应用伊藤引理 (46) 到 $\log \hat{\varphi}_t(X_t)$ ，识别出以下关系：

$$\frac{\log \hat{\varphi}_1(X_1)}{\log \hat{\varphi}_0(X_0)} = \int_0^1 \left[\frac{1}{2} \|v_t(X_t)\|^2 + (u_t \cdot v_t)(X_t) + \nabla \cdot (\sigma_t v_t(X_t) - f_t(X_t)) \right] dt + \int_0^1 v_t(X_t) \cdot dW_t, \quad (87)$$

$v_t(x) := \sigma_t \nabla \log \hat{\varphi}_t(x)$ 。其中我们简写为估计 (86) 中的权重需要知道比率 $\frac{\hat{\varphi}_1(x)}{\mu(x)}$ 和 $\frac{\hat{\varphi}_0(x)}{\mu(x)}$ ，这些在当前参数化下不是立即可用的， $u_\theta(t, x) \approx \sigma_t \nabla \log \varphi_t(x)$ 和 $h_\phi(x) \approx \nabla \log \hat{\varphi}_1(x)$ 。一种调整是用潜在网络 $v(t, x) : [0, 1] \times \mathcal{X} \rightarrow \mathbb{R}$ 重新参数化这些函数，

$$u_\theta(t, x) := \sigma_t \nabla v_\theta(t, x), \quad h_\phi(x) := \nabla v_\phi(1, x) \quad (88)$$

然后将它们的梯度回归到伴随和校正目标上。这样，对数比率可以很容易地估计：

$$\log \frac{\hat{\varphi}_1(x)}{\nu(x)} = v_\phi(1, x) + E(x), \quad \log \frac{\hat{\varphi}_0(x)}{\mu(x)} \stackrel{(42)}{=} -\log \varphi_0(x) = v_\theta(0, x). \quad (89)$$

对这种重要性采样方案的更详细研究留待未来工作。