

仿真与真实策略协同训练的 可泛化领域自适应

Shuo Cheng^{1*} Liqian Ma^{1*} Zhenyang Chen¹
Ajay Mandlekar^{2†} Caelan Garrett^{2†} Danfei Xu¹

¹ Georgia Institute of Technology ² NVIDIA Corporation

* and † denote equal contribution

{shuocheng, mlq}@gatech.edu

摘要

行为克隆在机器人操作领域展现出潜力，但真实世界的演示数据在大规模获取上成本高昂。仿真数据提供了可扩展的替代方案，尤其是在自动化演示生成技术取得进展的背景下，然而将策略迁移到真实世界受到多种仿真与真实领域差距的阻碍。本文提出一种统一的仿真与真实协同训练框架，用于学习可泛化的操作策略，该框架主要利用仿真数据，仅需少量真实世界演示。本方法的核心是学习一个领域不变且任务相关的特征空间。关键洞见在于，跨领域对齐观测及其对应动作的联合分布，比仅对齐观测（边缘分布）能提供更丰富的信号。通过在协同训练框架中嵌入受最优传输（Optimal Transport, OT）启发的损失函数来实现这一目标，并将其扩展至非平衡最优传输框架，以处理丰富的仿真数据与有限的真实世界样本之间的不平衡问题。在具有挑战性的操作任务上验证了本方法，结果表明其能够利用丰富的仿真数据，将真实世界成功率提升高达 30%，甚至能泛化到仅在仿真中见过的场景。项目网页：<https://ot-sim2real.github.io/>。

1 引言

行为克隆 [1] 因其在模仿专家演示 [2, 3] 方面的简洁性和有效性，成为直接在真实世界中获取机器人操作技能的一种有前景的方法。然而，要实现稳健且可泛化的性能，需要跨多样化环境、物体配置和任务收集大规模数据集 [4, 5]。这一数据收集过程劳动密集、耗时且成本高昂，对真实世界应用的可扩展性构成重大挑战。

近年来，随着物理仿真器 [6, 7]、程序化场景生成 [8, 9] 以及运动综合技术 [10, 11] 的快速发展，利用仿真作为训练数据替代来源的兴趣日益增长。这些基于仿真的方法能够实现可扩展且可控的数据生成，以远低于真实世界的成本提供多样且丰富的监督。然而，将仿真中训练的策略迁移到物理世界仍然是一个不小的挑战，原因在于仿真到现实的差距——即策略在执行过程中所遇到的仿真环境与真实环境之间的差异。这些差异可以表现为多种形式，例如视觉外观的变化、传感器噪声以及动作动力学 [12, 13]。特别是，学习在真实世界部署期间不断变化的感知条件下仍保持鲁棒的视觉运动控制策略，仍然是一个开放的研究领域。

弥合这一领域差距的常见策略包括领域随机化 [12, 13] 和数据增强 [14, 15]，尽管这些方法通常需要仔细调参。领域自适应（Domain Adaptation, DA）技术




图 1：基于最优传输的仿真与真实协同训练。我们使用行为克隆从稀疏的真实世界演示和密集的仿真演示中训练真实世界策略。利用最优传输对齐特征空间，我们的方法能够泛化到仅在仿真中见过的场景。

旨在显式地对齐分布，无论是在像素 [16, 17] 层面还是特征 [18, 19, 20] 层面。然而，许多特征级方法仅对齐边缘观测分布（例如，MMD[18, 19]），这对于细粒度操作对齐可能不够，因为它可能无法保留跨领域中与动作相关的结构。最近，仿真与真实协同训练——简单地在来自两个领域的混合数据上训练单一策略 [21, 22]——已显示出令人惊讶的有效性。我们认为，虽然这种协同训练方法有利于数据多样性，但通常缺乏跨领域特征空间对齐的显式约束，可能阻碍最优迁移和泛化，因为它们没有强制任务相关结构的一致映射。

我们提出一个统一的仿真与现实协同训练框架，显式学习一个共享潜空间，使来自仿真和真实世界的观测对齐并保留与动作相关的信息。我们的核心洞见是，跨域对齐观测及其对应动作或任务相关状态的联合分布，为学习可迁移特征提供了直接信号。具体而言，我们利用最优传输（Optimal Transport, OT）[23] 作为对齐目标，学习表示，使对动作预测至关重要的几何关系保持一致，无论输入来自仿真还是真实世界。此外，为稳健处理协同训练中仿真数据丰富而真实数据有限的数据不平衡问题，我们进一步扩展为不平衡最优传输（Unbalanced OT, UOT）公式 [24, 25]，并开发了一种时间感知采样策略，以在小批量最优传输设置中改进域对齐学习。

我们的贡献如下：（1）一个仿真与现实协同训练框架，学习域不变且任务显著的潜空间，以利用丰富的仿真数据提升真实世界性能；（2）一个不平衡最优传输框架和时间感知采样策略，以缓解数据不平衡并提升小批量最优传输训练中的对齐质量；（3）使用图像和点云两种模态的综合实验，评估多种操作任务中的仿真到仿真和仿真到现实迁移，展示了平均成功率最高提升 30%，并实现了对训练数据仅出现在仿真中的真实世界场景的泛化。

2 相关工作

机器人操作的行为克隆。行为克隆（Behavior Cloning, BC）通过模仿专家演示来训练策略将观测映射到动作 [2, 26, 27, 28]，为获得类人操作技能提供了有效途径。泛化能力在很大程度上取决于数据集的多样性。虽然一些工作专注于大规模真实世界数据收集 [5, 4] 或更高效的数据收集技术 [29, 30, 31]，但这仍然成本高昂且耗时。物理仿真器提供了一种低成本替代方案，利用特权信息自动合成运动以生成大规模仿真演示 [10, 32, 33]。我们的工作结合丰富的仿真数据和少量真实世界演示来训练稳健的行为克隆策略。

仿真到现实迁移与协同训练。仅在仿真中训练的策略在现实世界中往往表现不佳，原因在于仿真到现实的差距——视觉外观和动力学上的差异。对于准静态操作，视觉领域差距通常是主要瓶颈。领域

随机化使策略暴露于多样化的仿真视觉条件，以增强对现实世界变化的鲁棒性 [13, 34, 35]。然而，其成功取决于随机化参数在多大程度上覆盖真实世界的分布，这通常需要手动调参。领域自适应 (DA) 显式地对齐源域 (仿真) 和目标域 (真实) [36, 37]。像素级 DA 利用图像翻译使仿真图像更接近真实图像 [16, 17, 38]。特征级 DA 通常对端到端学习更具可扩展性，专注于学习领域不变表示 [19, 20, 18, 39, 40]。仿真与真实联合训练，即在混合数据上联合训练策略 [21, 22]，提供了一种简单有效的替代方案。虽然联合训练通过数据多样性增强泛化能力，但通常缺乏显式约束来对齐跨领域的已学习特征空间。我们在联合训练的基础上，通过最优传输引入特征级领域自适应，以促进潜在空间对齐，从而提升现实世界中的策略性能。

用于领域自适应的最优传输。最优传输 (OT) 为对齐分布提供了一个有原则的框架，被广泛用于领域自适应 [23, 41, 42, 43, 44, 45, 46]。传统 OT 方法计算源样本和目标样本之间的传输计划，然后在传输后的源数据上训练新模型。与我们最相关的是 DeepJDOT [47]，它基于 JDOT [44]，在无监督领域自适应中对齐特征和 (伪) 标签的联合分布，其中目标标签不可用。我们的工作基于这些原则，用于仿真与真实联合训练的模仿学习。与无监督 DA 不同，我们利用来自有限真实世界演示的可用动作或状态标签作为“软”监督，以引导跨领域观测-标签联合分布的任务相关性对齐。为了稳健地处理丰富的仿真数据与稀缺的真实数据之间固有的数据不平衡，我们将不平衡 OT (UOT) 损失 [24] 纳入联合训练框架，并开发了一种时间感知采样策略以改进小批量 UOT 训练。

3 预备知识与问题设定 本文方法基于最优传输 (Optimal Transport, OT) 原理对齐两个经验分布。设 $\mathbf{U} = \{u_i\}_{i=1}^n$ 与 $\mathbf{V} = \{v_j\}_{j=1}^m$ 分别表示来自源域与目标域的数据点，其对应的经验分布为 $\mathbf{p} = \sum_{i=1}^n p_i \delta_{u_i}$ 与 $\mathbf{q} = \sum_{j=1}^m q_j \delta_{v_j}$ 。定义地面代价矩阵 $C = (C_{i,j}) \in \mathbb{R}^{n \times m}$ ，其中 $C_{i,j} = c(u_i, v_j)$ ， $c(\cdot, \cdot)$ 为代价函数，通常取平方欧氏距离。最优传输 (OT) 旨在寻找最优计划 Π ，将分布 $\mathbf{p}$ 映射到 $\mathbf{q}$ ，以最小化位移代价 $W_c(\mathbf{p}, \mathbf{q})$ ：

$$W_c(\mathbf{p}, \mathbf{q}) = \min_{\Pi \in \mathbb{R}_+^{n \times m}} \langle \Pi, C \rangle_F, \text{ s.t. } \Pi \mathbf{1}_m = \mathbf{p}, \Pi^\top \mathbf{1}_n = \mathbf{q}. \quad (1)$$

3.1 问题设定：仿真与真实策略协同训练

本文解决学习鲁棒的真实世界机器人操作策略的挑战 π 。本文方法通过主要利用丰富的仿真数据以及少量真实世界演示，最小化对大量真实世界数据收集的需求。这被构建为仿真与真实协同训练问题 [22, 48]，其中单一策略在来自两个域的数据上进行训练。具体而言，考虑源域 (仿真，记为 src) 与目标域 (真实世界，记为 tgt)。将域建模为部分可观测马尔可夫决策过程 (Partially Observable Markov Decision Processes, POMDPs)，它们共享一个通常不可观测的底层状态空间 $\mathcal{S}$ 与动作空间 $\mathcal{A}$ 。策略接收的观测包括由发射函数 $E: \mathcal{S} \mapsto \mathcal{O}$ 生成的高维视觉输入 $o \in \mathcal{O}$ (例如，RGB 图像、三维点云)，以及低维本体感知信息 $x \in \mathcal{X}$ (例如，机器人关节角度、末端执行器位姿)。

域间隙。核心挑战在于领域差距，尤其是视觉观测差距。对于相同的底层机器人与环境状态 $s \in \mathcal{S}$ ，仿真中生成的视觉观测 $o_{src} = E_{src}(s)$ 可能与真实世界中的观测 $o_{tgt} = E_{tgt}(s)$ 存在显著差异。这种差异源于视觉外观 (纹理、光照)、传感器噪声以及渲染伪影 (例如，仿真光线投射与真实光传输之间的差异) 等因素的变化。因此，两个领域之间的边缘观测分布不同，即 $P_{src}(o_{src}) \neq P_{tgt}(o_{tgt})$ 。相比之下，由于一致的数据生成策略 (下文讨论) 和精确的机器人状态估计，对于给定的 s ，动作 a 和本体感受状态 x 被假定为基本一致。虽然动力学差异也会导致领域差距，但我们专注于从人类来源的演示中学习准静态抓取操作任务，这意味着动力学差距通常不如观测差距显著。




图 2：方法概览。 我们的仿真与真实联合训练框架学习一个领域不变的潜空间，以利用丰富的仿真演示和少量真实世界演示来提升真实世界性能。它利用非平衡最优传输损失和时间采样策略来解决数据不平衡问题，并提高小批量训练期间的对齐质量。

数据来源与数据不平衡。

In the source (simulation) domain, we leverage the ability to automatically generate a large dataset of N_{src} trajectories, $D_{src} = \{(o_{src}^i, x_{src}^i, a_{src}^i)\}_{i=1}^{N_{src}}$. 具体而言，我们利用自动化演示生成工具 MimicGen [10]，该工具利用仿真中可用的特权信息来创建覆盖广泛底层状态空间的多样化经验集， S_{src} 。MimicGen 基于少量人类演示生成合成演示，这确保了生成的数据在行为上与人类演示一致。我们收集有限数量的 N_{tgt} 演示， $D_{tgt} = \{(o_{tgt}^j, x_{tgt}^j, a_{tgt}^j)\}_{j=1}^{N_{tgt}}$ （其中 $N_{src} \gg N_{tgt}$ ），通常通过人类遥操作完成。这些真实世界演示自然覆盖更小且可能不同的状态子集， S_{tgt} 。这种数据覆盖差异导致了部分数据重叠的挑战。虽然我们假设存在一个同时属于 S_{src} 和 S_{tgt} 的状态区域，在该区域中可以直接对齐，但 S_{src} （我们丰富的仿真数据）的很大一部分在 S_{tgt} 中没有对应的真实世界演示。相反， S_{tgt} 可能包含真实世界特有的细节（例如演示行为）。有效利用 D_{src} 的全部数据以提升真实世界性能，尤其是针对演示中直接仿真-真实重叠之外的状态，是我们所要解决的问题。

目标：可泛化的领域自适应。 我们的目标是学习一个单一、可泛化的策略 $\pi_\theta(a|z, x)$ 和一个观测编码器 $f_\phi: \mathcal{O}_{src} \cup \mathcal{O}_{tgt} \rightarrow \mathcal{Z}$ 。该编码器将来自源域和目标域的高维视觉观测 o 映射到共享潜空间 $\mathcal{Z}$ 。主要目标是在目标（真实世界）域中实现高策略性能，尤其是在有限真实世界演示 D_{tgt} 未明确覆盖的场景中。这包含两个目标。首先，对于 S_{src} 和 S_{tgt} 重叠区域内的状态，我们旨在学习跨域良好对齐的高质量嵌入 $z = f_\phi(o)$ ，使得在对应状态下 $f_\phi(o_{src}) \approx f_\phi(o_{tgt})$ ，从而促进有效的策略学习。这也是大多数协同训练方法的假设 [21, 22]。其次，对于 S_{src} 中覆盖但 S_{tgt} 中未覆盖的状态，编码器 f_ϕ 必须为新的目标观测生成嵌入 $f_\phi(o_{tgt})$ ，这些嵌入与其仿真对应物 $f_\phi(o_{src})$ 的嵌入保持一致。这要求学习到的表示能够捕获域不变、任务相关的特征，使策略能够泛化到仅在源（仿真）域中有训练数据的目标（真实世界）场景。

4 方法

为了从仿真与真实数据不平衡的数据集 ($|D_{src}| \gg |D_{tgt}|$) 中学习具有鲁棒特征 f_ϕ 的可泛化策略 π_θ ，如第 3 节所述，本文提出一种协同训练框架，通过最优传输 (Optimal Transport, OT) 显式对齐潜表示。核心策略是利用动作信息引导学习到的视觉潜特征对齐 ($z = f_\phi(o)$)。该对齐目标同时促使编码器 f_ϕ 发现域不变表示，同时保留动作预测所需的细节信息。具体而言，本文提出基于最优传输的公式，对齐联合观测-动作分布 (第 4.1 节)。进一步通过非平衡最优传输 (Unbalanced Optimal Transport, UOT) (第 4.2 节) 和时序感知采样策略 (第 4.3 节) 解决数据不平衡问题，并将这些方法整合到统一的协同训练框架中 (第 4.4 节)。

4.1 基于动作感知特征对齐的最优传输

标准协同训练方法 [21, 22] 提供隐式特征对齐，而边缘分布匹配（如最大均值差异 [18]）可能忽略细粒度对应关系，因此本文寻求更具结构化的方法。为学习既具有域不变性又能预测动作 $a \in \mathcal{A}$ 的视觉特征 $z = f_\phi(o)$ ，本文提出利用最优传输对齐联合分布 $P_{src}(f_\phi(o_{src}), a_{src})$ 和 $P_{tgt}(f_\phi(o_{tgt}), a_{tgt})$ 。这促使编码器 f_ϕ 学习表示，使得（视觉特征，动作）对之间的几何关系在域间得以保留。通过最小化基于最优传输的损失，编码器 f_ϕ 被训练以塑造嵌入空间 $\mathcal{Z}$ ，使与动作预测相关的结构在仿真与真实世界之间保持一致。

形式上，给定源域样本 $\{(o_{src}^i, a_{src}^i)\}_{i=1}^{N_{src}}$ 和目标域样本 $\{(o_{tgt}^j, a_{tgt}^j)\}_{j=1}^{N_{tgt}}$ ，本文旨在寻找最优传输计划 Π^* 和最优编码器 f_ϕ^* 以最小化它们在 (z, a) 空间

中联合分布之间的传输代价。基于式 1 中的一般最优传输公式，编码器 f_ϕ 的学习目标以及隐式的传输计划 Π 可表示为寻找 f_ϕ ，使 $P_{src}(f_\phi(o_{src}), a_{src})$ 与 $P_{tgt}(f_\phi(o_{tgt}), a_{tgt})$ 之间的 Wasserstein 距离最小化：

$\min_{f_\phi} W_C(P_{src}(f_\phi(o_{src}), a_{src}), P_{tgt}(f_\phi(o_{tgt}), a_{tgt}))$ 地面代价 c 理想情况下应结合学习到的视觉潜在空间 $\mathcal{Z}$ 和动作空间 $\mathcal{A}$ 中的距离，例如：

$$C_\phi((f_\phi(o_{src}^i), a_{src}^i), (f_\phi(o_{tgt}^j), a_{tgt}^j)) = \alpha_1 \cdot d_{\mathcal{Z}}(f_\phi(o_{src}^i), f_\phi(o_{tgt}^j)) + \alpha_2 \cdot d_{\mathcal{A}}(a_{src}^i, a_{tgt}^j). \quad (2)$$

使用迭代算法（如辛霍恩算法（Sinkhorn）[49]）最小化该目标会形成一个双层优化问题。在内层循环中，对于固定的 f_ϕ ，计算一个近似最优的传输计划 Π 。在外层循环中，更新 f_ϕ 以降低该计划所产生的代价。这一过程有效地训练编码器 f_ϕ ，使其生成嵌入 z ，从而使源分布与目标分布的联合分布 (z, a) 更容易对齐。最优传输的一个关键优势在于其保持几何结构的能力；通过利用动作相似性（经由 $d_{\mathcal{A}}$ ）引导对齐，我们塑造嵌入函数 f_ϕ ，使导致相似动作的视觉观测聚集在一起，无论它们来自哪个域。

实用实现：以本体感知作为引导。 虽然直接对齐 (z, a) 在原则上是可行的，但仿真与真实世界遥操作之间控制器特性或动作表示的差异，可能使 $d_{\mathcal{A}}(a_{src}, a_{tgt})$ 成为行为相似性的不可靠指标。作为一种稳健的实用折衷方案，我们利用本体感知信息 $x \in \mathcal{X}$ （例如末端执行器位姿），该信息在不同域间具有更一致的表示（第 3.1 节），并且与机器人行为高度相关。因此，我们实现的基础代价 c 用本体感知状态 x 替换动作 a ，并将其用于我们的非平衡最优传输公式中（详见第 4.2 节）。

4.2 用于稳健对齐的非平衡最优传输

标准最优传输公式（公式 1）施加严格的边缘约束，要求源分布的所有质量都传输到目标分布，反之亦然。这在我们的仿真到真实环境中存在问题，主要原因是显著的数据不平衡（ $|D_{src}| \gg |D_{tgt}|$ ）以及 D_{src} 和 D_{tgt} 所覆盖的状态空间之间的部分重叠（第 3.1 节）。标准最优传输要么通过强制多对少映射来扭曲潜空间，要么在不对应的状态之间产生虚假对齐。为了应对这些挑战，我们采用非平衡最优传输（Unbalanced Optimal Transport, UOT）[25, 24]。UOT 通过引入惩罚偏差的正则化项来放宽最优传输的硬边缘约束，从而允许部分质量传输。这使得 UOT 能够根据基础代价选择性地对齐分布中最相似的子集，同时有效地降低或忽略不相似或不匹配部分的传输。

非平衡最优传输损失公式。 考虑一个小批量，包含 N_{batch} 个源样本和 $\{(o^i, x^i)\}_{i=1}^{N_{batch}}$ 个目标样本。设它们在 $r_{rc}, x_{src}^i\}_{i=1}^{N_{batch}}$ and N_{batch} $\{(o_{tgt}^j, x_{tgt}^j)\}_{j=1}^{N_{batch}}$ 联合 $(f_\phi(o), x)$ 空间中的经验分布分别为 $\hat{\mu}_{src}$ 和 $\hat{\mu}_{tgt}$ 。我们的非平衡最优传输（UOT）损失 $L_{UOT}(f_\phi)$ 基于康托罗维奇形式（Kantorovich Formulation），并引入熵正则化和用于边缘松弛的 KL 散度惩罚：

$$L_{UOT}(f_\phi) = \min_{\Pi \in \mathbb{R}_+^{N_{batch} \times N_{batch}}} \langle \Pi, \hat{C}_\phi \rangle_F + \epsilon \cdot \Omega(\Pi) + \tau \cdot \text{KL}(\Pi \mathbf{1} \| \mathbf{p}) + \tau \cdot \text{KL}(\Pi^\top \mathbf{1} \| \mathbf{q}). \quad (3)$$

这里， $\hat{C}_\phi$ 是 $N_{batch} \times N_{batch}$ 地面成本矩阵，其中每个元素 $(\hat{C}_\phi)_{ij}$ 使用第 4.1 节描述的联合地面成本计算。项 Π 是传输计划； $\epsilon > 0$ 是熵正则化强度，其中 $\Omega(\Pi) = \sum_{i,j} \Pi_{ij} \log \Pi_{ij}$ 为熵，便于高效求解

通过类似 Sinkhorn-Knopp 的算法 [49]; $\tau > 0$ 控制偏离批量边缘分布 $\mathbf{p}$ 和 $\mathbf{q}$ (通常为均匀分布) 的惩罚; $\text{KL}(\cdot||\cdot)$ 表示 Kullback-Leibler 散度。

4.3 用于有效小批量学习的时间对齐采样

小批量最优传输 (包括 UOT) 的有效性, 关键在于每个批次内向求解器提供可比较的源样本和目标样本。对于序列机器人数据, 从 D_{src} 和 D_{tgt} 中天真地随机采样单个转移可能产生来自任务不同阶段的配对, 导致噪声传输计划和 f_ϕ 的次优特征对齐。增大最小批量大小可能提高采样到对齐配对的概率, 但需要更多计算资源。

为解决这一问题, 我们引入一种时间对齐采样策略, 旨在构建具有更高密度有意义对应状态对的小批量。该策略利用轨迹级相似性作为启发式。我们首先使用动态时间规整 (DTW) [50] 在各自的 proprioceptive 状态序列 $\{x_t\}$ 上量化源轨迹 $\{\xi_{src}^k\} \subset D_{src}$ 与目标轨迹 $\{\xi_{tgt}^l\} \subset D_{tgt}$ 之间的相似性。得到的归一化 DTW 距离 $\bar{d}(\xi_{src}^k, \xi_{tgt}^l) = d_{\text{DTW}}(\xi_{src}^k, \xi_{tgt}^l) / \max(|\xi_{src}^k|, |\xi_{tgt}^l|)$ 反映整体行为相似性。为将这些距离转化为采样权重, 我们应用基于 softplus 的变换: $w(\xi_{src}^k, \xi_{tgt}^l) = 1 / (1 + e^{10 \cdot (\bar{d}(\xi_{src}^k, \xi_{tgt}^l) - 0.01)})$ 。小批量构建随后按以下步骤进行: (1) 以偏向高相似性 (即低 DTW 距离) 轨迹对的概率采样一对轨迹 (ξ_{src}, ξ_{tgt}) ; (2) 随后从所选的行为相似轨迹对中采样单个转移元组 $(o_{src}, x_{src}, a_{src})$ 和 $(o_{tgt}, x_{tgt}, a_{tgt})$ 。

此处可选地采用细粒度时间对齐, 例如在 DTW 匹配的时间步附近采样。我们在附录中描述如何将 UOT 损失 (式 3) 适配到这一新的采样过程。

这种两阶段过程显著提高了小批量内源样本和目标样本具有相似本体感受状态的可能性 x 。因此, 非平衡最优传输优化 (方程 3) 能够更有效地专注于对齐这些相关状态对的视觉潜在特征 $f_\phi(o_{src})$ 和 $f_\phi(o_{tgt})$ 。我们在附录中通过实验验证了这种采样策略的重要性。

4.4 联合协同训练框架

将所有组件整合在一起, 我们的最终方法是一个联合协同训练框架, 其中视觉特征编码器 f_ϕ 和策略 $\pi_\theta(a|z, x)$ 被同时优化。非平衡最优传输损失 (L_{UOT}) 作为正则化项, 引导 f_ϕ 学习领域不变且与动作相关的潜在表示 $z = f_\phi(o)$, 而标准行为克隆损失驱动策略学习。总体训练目标 $L(f_\phi, \pi_\theta) = L_{\text{BC}}(f_\phi, \pi_\theta) + \lambda \cdot L_{\text{UOT}}(f_\phi)$ 结合了这些组件, 其中 L_{BC} 表示在源数据集 (D_{src}) 和目标数据集 (D_{tgt}) 上使用标准模仿损失 (例如均方误差) 计算得到的组合行为克隆损失。超参数 $\lambda > 0$ 平衡特征对齐与策略模仿。 $L_{\text{UOT}}(f_\phi)$ 项按照方程 3 的定义计算, 小批量采样采用第 4.3 节描述的策略。整体训练过程详见附录。

5 实验

我们旨在验证以下核心假设。假设 1: 我们的方法能够在仿真和现实世界中有效学习复杂的操作任务。假设 2: 我们的方法能够泛化到仅在仿真中见过的目标领域。假设 3: 我们的方法广泛适用于多种观测模态。假设 4: 扩大仿真数据覆盖范围能够提升泛化性能。

5.1 实验设置

为了评估我们方法的有效性, 我们在仿真到仿真和仿真到现实迁移场景下, 对一系列机器人桌面操作任务进行了全面实验: 提升、箱中装箱、堆叠、方块、挂杯和抽屉。这些任务旨在测试系统处理机器人操作中关键挑战的能力, 包括密集物体交互、长时程推理和高精度控制。




图 3：评估任务套件。我们在现实世界（上）和仿真（下）中对 6 个不同任务评估我们的方法，以展示仿真到现实迁移的有效性。

环境设置。在真实世界实验中，我们将方法部署于 Franka Emika Panda 机械臂上，以 20Hz 频率通过关节阻抗控制进行操控。视觉与点云观测由 Intel RealSense D435 深度相机采集。仿真环境采用 Robosuite [51] 仿真框架。我们标定仿真中的相机位姿与内参，使其与真实世界设置一致，以缩小领域差距。

仿真数据。在仿真实验中，我们首先为每个任务收集 10 条人类演示。利用 MimicGen [10]，在源域合成 200 至 1000 条轨迹，覆盖全部初始状态范围（记为 Source）。在目标域中，将重置区域划分为两个子区域：一个子区域包含 10 条训练轨迹（记为 Target），另一个子区域完全未参与训练（记为 Target-OOD）。该未参与训练的子区域用于评估各方法在分布外（Out-Of-Distribution, OOD）条件下的泛化能力。

真实数据。在真实世界实验中，我们采用类似策略，将重置区域划分为两个子区域，与仿真设置保持一致。根据任务复杂度，在一个子区域内收集 10 至 25 条人类演示，并生成 1000 条仿真轨迹。为评估 OOD 场景下的泛化能力，我们在真实世界中考虑以下设置：形状（Shape），测试物体在真实数据收集期间未曾出现；重置（Reset），初始物体位姿超出演示覆盖范围；纹理（Texture），物体包裹全新纹理，未出现在任何真实世界训练数据中。各任务及重置配置的详细可视化见附录。

观测模态与领域差距。我们使用两种观测模态评估方法：点云与 RGB 图像。对于点云观测，我们的方法与基线均采用 3D 扩散策略（3D Diffusion Policy）[28]，并配备 PointNet 编码器 [52]。对于 RGB 图像观测，采用扩散策略（Diffusion Policy）[53]，并配备 ResNet-18 编码器 [54]。为评估不同方法在仿真中视觉领域偏移下的泛化能力，我们引入多种目标域变化：视角 1-点云（Viewpoint1-Point）、视角 3-点云（Viewpoint3-Point）、扰动-点云（Perturbation-Point）、视角-图像（Viewpoint-Image）和纹理-图像（Texture-Image）。各领域偏移的描述见附录。

基线。我们将所提方法与以下基线进行对比：最大均值差异（MMD）——最小化源域与目标域数据均值嵌入之间的距离 [18]；协同训练（Co-training）——采用 [21, 22] 提出的策略，使用源域与目标域数据的混合批次训练模型；仅源域（Source-only）——仅使用源域数据训练模型，在仿真到真实实验中对应该仅使用仿真数据；仅目标域（Target-only）——仅使用目标域数据训练模型，在仿真到真实实验中对应该仅使用真实世界数据训练。

5.2 跨域泛化结果

	堆叠（视角）			方块（视角）			盒中盒（视角）			堆叠（纹理）			方块（纹理）			盒中盒（纹理）			平均目标域
	目标域-分布外	目标域	目标域-分布外	目标域-分布外	目标域	目标域-分布外	目标域-分布外	目标域	目标域-分布外	目标域-分布外	目标域	目标域-分布外	目标域-分布外	目标域	目标域-分布外	目标域-分布外	目标域	目标域-分布外	目标域
仅源域	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
仅目标域	0.30	0.00	0.20	0.00	0.82	0.00	0.42	0.00	0.48	0.00	0.64	0.00	0.48	0.00	0.38	0.00	0.18	0.04	0.82
协同训练	0.44	0.04	0.76	0.00	0.90	0.14	0.54	0.34	0.66	0.46	0.98	0.72	0.71	0.28	本文方法	0.65	0.04	0.86	0.02
最大均值差异	0.88	0.26	0.66	0.52	0.68	0.54	0.96	0.82	0.78	0.36									

表 1：基于图像策略的仿真到仿真成功率。视角（V）和纹理（T）分别表示视角图像和纹理图像的域偏移。目标域（T）和目标域-分布外（T-O）分别对应目标域和目标域在分布外（OOD）场景下的情况。

	Stack (R)		Square (R)		BoxInBin (T)		Average
	grasp	full	grasp	full	grasp	full	full
Source-only	0.0	0.0	0.0	0.0	0.0	0.0	0.00
Target-only	0.0	0.0	0.1	0.0	0.0	0.0	0.00
Co-training	0.0	0.0	0.3	0.0	0.4	0.3	0.10
Ours	0.4	0.4	0.5	0.1	0.7	0.7	0.40

表 2: 真实世界基于图像策略的分布外成功率。重置分布外 (R) 和纹理分布外 (T) 分别表示重置分布外和纹理分布外。平均表示所有任务的平均完整任务成功率。

	BoxInBin (V3)		BoxInBin (P)		Lift (V1)		Stack (V1)		Square (V1)		MugHang (V1)		Average	
	T	T-O	T	T-O	T	T-O	T	T-O	T	T-O	T	T-O	T	T-O
S.-only	0.08	0.10	0.52	0.60	0.32	0.40	0.52	0.64	0.10	0.08	0.12	0.10	0.28	0.32
T.-only	0.42	0.00	0.58	0.00	0.60	0.00	0.32	0.00	0.16	0.00	0.18	0.00	0.38	0.00
MMD	0.50	0.38	0.66	0.50	0.56	0.52	0.70	0.66	0.18	0.12	0.18	0.20	0.46	0.40
Co-train.	0.76	0.52	0.70	0.66	0.92	0.48	0.86	0.72	0.24	0.24	0.26	0.22	0.62	0.47
Ours	0.84	0.58	0.80	0.76	0.80	0.60	0.82	0.86	0.42	0.38	0.40	0.34	0.68	0.59

表 3: 基于点云策略的仿真到仿真成功率。视角 1-点云 (V1)、视角 3-点云 (V3) 和扰动-点云 (P) 分别表示由视角 1-点云、视角 3-点云和扰动-点云引起的域偏移。目标域 (T) 和目标域-分布外 (T-O) 分别表示目标域和目标域在分布外 (OOD) 条件下的情况。

本文报告了在仿真与真实环境中使用点云和基于图像观测的策略结果。仿真中，基于图像和基于点云的性能分别见表 1 和表 3。真实世界实验中，分布内结果见附录表 7 和表 8，分布外性能见表 2 和表 4。

这些结果支持以下关键假设：

本文方法在仿真和真实世界中均能有效学习复杂操作任务 (H1)。实验结果表明，在仿真和真实环境的源域与目标域中，本文方法在成功率上始终匹配或优于所有基线。在真实世界任务中，基于图像和基于点云的策略平均成功率分别达到 0.73 和 0.77。仅目标域基线在分布内表现良好，但在域偏移下无法泛化。MMD 基线 [18] 通过对齐全局特征统计量提供了有限改进，但其粗粒度对齐常破坏任务相关结构并损害源域性能。相比之下，本文方法利用非平衡最优传输进行选择性和结构感知的对齐，避免了虚假匹配。

本文方法能泛化到仅在仿真中见过的目标域 (H2)。在目标域分布外场景中，本文方法优于所有基线，凸显了学习域不变表示的价值（见表 2 和表 4）。协同训练基线 [21, 22] 在目标域训练数据与评估区域重叠时表现良好，但在无重叠时难以泛化。这一局限性在大域偏移下尤为明显。例如，在具有新纹理或重置姿态的真实世界装箱和堆叠任务中，本文方法使用基于图像观测的成功率分别为 0.7 和 0.4，而协同训练基线仅为 0.3 和 0.0。这些结果凸显了仅依赖有监督目标域数据而未显式处理域偏移的不足。

本文方法广泛适用于多种观测模态 (H3)。我们观察到在基于图像和点云的输入上均有一致的性能提升。在仿真中，使用任一模态训练的策略都优于所有基线，表明我们的方法能有效学习域不变特征，从而在多种感官模态上捕获任务相关信息。

仿真数据为增强现实世界训练提供了一种可扩展且有效的方式。在现实世界任务中，我们的方法和联合训练基线都从用仿真数据增强有限的现实世界演示中显著受益。使用这种增强数据训练的策略始终优于仅用目标域数据的基线，尤其是在现实世界覆盖稀疏的分布外 (OOD) 设置中。这凸显了利用低成本仿真数据填补现实世界数据集空白的价值，从而实现更可扩展、更泛化的行为克隆。

扩大仿真数据覆盖范围可提升现实世界性能 (H4)。为分析仿真数据扩展性，我们考虑现实世界中以点云为观测的堆叠任务。我们生成了 100、300、500 和 1000 条仿真轨迹，将其与 25 条现实世界轨迹结合，

	Stack (R)		Square (R)		BoxInBin (R)		Lift (R)		Lift (S)		Lift (R+S)		Average
	grasp	full	grasp	full	grasp	full	reach	full	reach	full	reach	full	full
S.-only	0.6	0.3	0.1	0.1	0.3	0.2	0.8	0.8	0.6	0.6	0.9	0.9	0.48
T.-only	0.0	0.0	0.3	0.0	0.0	0.0	0.0	0.0	1.0	1.0	0.0	0.0	0.17
Co-train.	0.4	0.1	0.6	0.2	0.2	0.0	0.8	0.8	1.0	1.0	0.9	0.9	0.50
Ours	0.8	0.4	0.6	0.1	0.7	0.5	1.0	1.0	1.0	1.0	1.0	1.0	0.67

表 4: 基于点云的现实世界策略 OOD 成功率。R 和 S 分别表示重置 OOD 和形状 OOD。平均值表示所有任务的平均完整任务成功率。

演示，并训练了我们的方法和联合训练基线。如图 4(b) 所示，增加仿真数据量显著提升了我们的方法在缺乏现实世界覆盖的目标域区域中的性能，凸显了学习域不变潜空间的重要性，该空间使策略能够泛化到观测分布之外。

我们的方法学习对齐仿真和真实数据的共享潜空间。为了更好地理解学习到的嵌入如何促进泛化，我们使用 t-分布随机邻域嵌入 (t-SNE) [55] 对其进行可视化，如图 4(a) 所示。蓝色和红色分别对应从源域和目标域观测中提取的特征。左图展示了使用协同训练基线训练的编码器得到的嵌入，右图展示了本文方法得到的嵌入。可视化结果表明，本文方法显著改善了源分布与目标分布之间的对齐，凸显了其学习域不变表示以促进鲁棒泛化的能力。我们还对随机采样的批次以及源域和目标域对应的图像观测进行了传输计划的可视化。如附录中图 10 所示，传输计划有效地对齐了跨域中具有相似状态的数据点。




图 4: (a) 潜空间可视化。本文的最优传输对齐将源域样本（蓝色）和目标域样本（红色）在潜空间中映射到相近位置，形成单一且充分混合的簇。这种重叠表明最优传输对齐有效地同步了跨域特征分布，从而改善了仿真到现实迁移。(b) 分布外性能。增加仿真演示的数量可显著提升分布外成功率。

6 局限性与结论

本文工作的主要局限性在于仅解决了仿真到现实的视觉观测差距。解决动作动力学差距仍是未来工作。由于我们使用 MimicGen [10] 自动生成仿真演示，因此继承了其局限性，即本文方法主要适用于具有抓取和准静态交互的任务。我们需要少量与仿真演示对齐的真实世界任务演示。未来工作包括放宽这一要求，例如改为利用非结构化的真实世界数据，如自由玩耍数据。

总之，本文提出了一种框架，通过特征一致性协同训练，将大规模仿真演示数据集有效融入现实世界策略学习流程。本文提出利用最优传输 (Optimal Transport, OT) 对齐编码器特征，使其对观测来自仿真还是现实世界保持不变，从而提升仿真数据的可迁移性。由于仿真数据远多于现实世界数据，本文在训练目标中引入非平衡最优传输损失，并设计了一种数据采样方案，显式生成相似的仿真与现实世界演示对。最后，本文在仿真到仿真测试平台以及现实世界任务中，展示了仿真演示带来的学习性能提升。

7 致谢

本研究部分由国家科学基金会资助，项目编号为 2409016 和 2442393。本文所表达的任何观点、发现、结论或建议均为作者个人观点，并不一定反映国家科学基金会的立场。

参考文献

- [1] Dean A Pomerleau. Alvin: An autonomous land vehicle in a neural network. *Advances in neural information processing systems*, 1, 1988.
- [2] Ajay Mandlekar, Danfei Xu, Josiah Wong, Soroush Nasiriany, Chen Wang, Rohun Kulkarni, Li Fei-Fei, Silvio Savarese, Yuke Zhu, and Roberto Martín-Martín. What matters in learning from offline human demonstrations for robot manipulation. In *5th Annual Conference on Robot Learning*, 2021.
- [3] Pete Florence, Corey Lynch, Andy Zeng, Oscar A Ramirez, Ayzaan Wahid, Laura Downs, Adrian Wong, Johnny Lee, Igor Mordatch, and Jonathan Tompson. Implicit behavioral cloning. In *Conference on robot learning*, pages 158–168. PMLR, 2022.
- [4] Alexander Khazatsky, Karl Pertsch, Suraj Nair, Ashwin Balakrishna, Sudeep Dasari, Siddharth Karamcheti, Soroush Nasiriany, Mohan Kumar Srirama, Lawrence Yunliang Chen, Kirsty Ellis, Peter David Fagan, Joey Hejna, Masha Itkina, Marion Lepert, Yecheng Jason Ma, Patrick Tree Miller, Jimmy Wu, Suneel Belkhale, Shivin Dass, Huy Ha, Arhan Jain, Abraham Lee, Youngwoon Lee, Marius Memmel, Sungjae Park, Ilija Radosavovic, Kaiyuan Wang, Albert Zhan, Kevin Black, Cheng Chi, Kyle Beltran Hatch, Shan Lin, Jingpei Lu, Jean Mercat, Abdul Rehman, Pannag R Sanketi, Archit Sharma, Cody Simpson, Quan Vuong, Homer Rich Walke, Blake Wulfe, Ted Xiao, Jonathan Heewon Yang, Arefeh Yavary, Tony Z. Zhao, Christopher Agia, Rohan Baijal, Mateo Guaman Castro, Daphne Chen, Qiuyu Chen, Trinity Chung, Jaimyn Drake, Ethan Paul Foster, Jensen Gao, David Antonio Herrera, Minh Heo, Kyle Hsu, Jiaheng Hu, Donovan Jackson, Charlotte Le, Yunshuang Li, Kevin Lin, Roy Lin, Zehan Ma, Abhiram Maddukuri, Suvir Mirchandani, Daniel Morton, Tony Nguyen, Abigail O’Neill, Rosario Scalise, Derick Seale, Victor Son, Stephen Tian, Emi Tran, Andrew E. Wang, Yilin Wu, Annie Xie, Jingyun Yang, Patrick Yin, Yunchu Zhang, Osbert Bastani, Glen Berseth, Jeannette Bohg, Ken Goldberg, Abhinav Gupta, Abhishek Gupta, Dinesh Jayaraman, Joseph J Lim, Jitendra Malik, Roberto Martín-Martín, Subramanian Ramamoorthy, Dorsa Sadigh, Shuran Song, Jiajun Wu, Michael C. Yip, Yuke Zhu, Thomas Kollar, Sergey Levine, and Chelsea Finn. Droid: A large-scale in-the-wild robot manipulation dataset. 2024.
- [5] Open X-Embodiment Collaboration, Abby O’Neill, Abdul Rehman, Abhinav Gupta, Abhiram Maddukuri, Abhishek Gupta, Abhishek Padalkar, Abraham Lee, Acorn Pooley, Agrim Gupta, Ajay Mandlekar, Ajinkya Jain, Albert Tung, Alex Bewley, Alex Herzog, Alex Irpan, Alexander Khazatsky, Anant Rai, Ankit Gupta, Andrew Wang, Andrey Kolobov, Anikait Singh, Animesh Garg, Aniruddha Kembhavi, Annie Xie, Anthony Brohan, Antonin Raffin, Archit Sharma, Arefeh Yavary, Arhan Jain, Ashwin Balakrishna, Ayzaan Wahid, Ben Burgess-Limerick, Beomjoon Kim, Bernhard Schölkopf, Blake Wulfe, Brian Ichter, Cewu Lu, Charles Xu, Charlotte Le, Chelsea Finn, Chen Wang, Chenfeng Xu, Cheng Chi, Chenguang Huang, Christine Chan, Christopher Agia, Chuer Pan, Chuyuan Fu, Coline Devin, Danfei Xu, Daniel Morton, Danny Driess, Daphne Chen, Deepak Pathak, Dhruv Shah, Dieter Buechler, Dinesh Jayaraman, Dmitry Kalashnikov, Dorsa Sadigh, Edward Johns, Ethan Foster, Fangchen Liu, Federico Ceola, Fei Xia, Feiyu Zhao, Felipe Vieira Frujeri, Freek Stulp, Gaoyue Zhou, Gaurav S. Sukhatme, Gautam Salhotra, Ge Yan, Gilbert Feng, Giulio Schiavi, Glen Berseth, Gregory Kahn, Guangwen Yang, Guanzhi Wang, Hao Su, Hao-Shu Fang, Haochen Shi, Henghui Bao, Heni Ben Amor, Henrik I Christensen, Hiroki Furuta, Homanga Bharadhwaj, Homer Walke, Hongjie Fang, Huy Ha, Igor Mordatch, Ilija Radosavovic, Isabel Leal, Jacky Liang, Jad Abou-Chakra, Jaehyung Kim, Jaimyn Drake, Jan Peters, Jan Schneider, Jasmine Hsu, Jay Vakil, Jeannette Bohg, Jeffrey Bingham, Jeffrey Wu, Jensen Gao, Jiaheng Hu, Jiajun Wu, Jialin Wu, Jiankai Sun, Jianlan Luo, Jiayuan Gu, Jie Tan, Jihoon Oh, Jimmy Wu, Jingpei Lu, Jingyun Yang, Jitendra Malik, João Silvério, Joey Hejna, Jonathan Booher, Jonathan Tompson, Jonathan Yang, Jordi Salvador, Joseph J. Lim, Junhyek Han, Kaiyuan Wang, Kanishka Rao, Karl Pertsch, Karol Hausman, Keegan Go, Keerthana Gopalakrishnan, Ken Goldberg, Kendra Byrne, Kenneth Oslund, Kento Kawaharazuka, Kevin Black, Kevin Lin, Kevin Zhang, Kiana Ehsani, Kiran Lekkala, Kirsty Ellis, Krishan Rana, Krishnan Srinivasan, Kuan Fang, Kunal Pratap Singh, Kuo-Hao Zeng, Kyle Hatch, Kyle Hsu, Laurent Itti, Lawrence Yunliang Chen, Lerrel Pinto, Li Fei-Fei, Liam Tan, Linxi "Jim" Fan, Lionel Ott, Lisa Lee, Luca Weihs, Magnum Chen, Marion Lepert, Marius Memmel, Masayoshi Tomizuka, Masha Itkina, Mateo Guaman Castro, Max Spero, Maximilian Du, Michael Ahn, Michael C. Yip, Mingtong Zhang, Mingyu Ding,

- Minho Heo, Mohan Kumar Srirama, Mohit Sharma, Moo Jin Kim, Naoaki Kanazawa, Nicklas Hansen, Nicolas Heess, Nikhil J Joshi, Niko Suenderhauf, Ning Liu, Norman Di Palo, Nur Muhammad Mahi Shafiullah, Oier Mees, Oliver Kroemer, Osbert Bastani, Pannag R Sanketi, Patrick "Tree" Miller, Patrick Yin, Paul Wohlhart, Peng Xu, Peter David Fagan, Peter Mitrano, Pierre Sermanet, Pieter Abbeel, Priya Sundareshan, Qiuyu Chen, Quan Vuong, Rafael Rafailov, Ran Tian, Ria Doshi, Roberto Mart'ın-Mart'ın, Rohan Baijal, Rosario Scalise, Rose Hendrix, Roy Lin, Runjia Qian, Ruohan Zhang, Russell Mendonca, Rutav Shah, Ryan Hoque, Ryan Julian, Samuel Bustamante, Sean Kirmani, Sergey Levine, Shan Lin, Sherry Moore, Shikhar Bahl, Shivin Dass, Shubham Sonawani, Shubham Tulsiani, Shuran Song, Sichun Xu, Siddhant Halder, Siddharth Karamcheti, Simeon Adebola, Simon Guist, Soroush Nasiriany, Stefan Schaal, Stefan Welker, Stephen Tian, Subramanian Ramamoorthy, Sudeep Dasari, Suneel Belkhale, Sungjae Park, Suraj Nair, Suvir Mirchandani, Takayuki Osa, Tanmay Gupta, Tatsuya Harada, Tatsuya Matsushima, Ted Xiao, Thomas Kollar, Tianhe Yu, Tianli Ding, Todor Davchev, Tony Z. Zhao, Travis Armstrong, Trevor Darrell, Trinity Chung, Vidhi Jain, Vikash Kumar, Vincent Vanhoucke, Wei Zhan, Wenxuan Zhou, Wolfram Burgard, Xi Chen, Xiangyu Chen, Xiaolong Wang, Xinghao Zhu, Xinyang Geng, Xiyuan Liu, Xu Liangwei, Xuanlin Li, Yansong Pang, Yao Lu, Yecheng Jason Ma, Yejin Kim, Yevgen Chebotar, Yifan Zhou, Yifeng Zhu, Yilin Wu, Ying Xu, Yixuan Wang, Yonatan Bisk, Yongqiang Dou, Yoonyoung Cho, Youngwoon Lee, Yuchen Cui, Yue Cao, Yueh-Hua Wu, Yujin Tang, Yuke Zhu, Yunchu Zhang, Yunfan Jiang, Yunshuang Li, Yunzhu Li, Yusuke Iwasawa, Yutaka Matsuo, Zehan Ma, Zhuo Xu, Zichen Jeff Cui, Zichen Zhang, Zipeng Fu, and Zipeng Lin. Open X-Embodiment: Robotic learning datasets and RT-X models. <https://arxiv.org/abs/2310.08864>, 2023.
- [6] Genesis Authors. Genesis: A universal and generative physics engine for robotics and beyond, December 2024.
- [7] Fanbo Xiang, Yuzhe Qin, Kaichun Mo, Yikuan Xia, Hao Zhu, Fangchen Liu, Minghua Liu, Hanxiao Jiang, Yifu Yuan, He Wang, Li Yi, Angel X. Chang, Leonidas J. Guibas, and Hao Su. SAPIEN: A simulated part-based interactive environment. In *The IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2020.
- [8] Alexander Raistrick, Lingjie Mei, Karhan Kayan, David Yan, Yiming Zuo, Beining Han, Hongyu Wen, Meenal Parakh, Stamatis Alexandropoulos, Lahav Lipson, et al. Infinigen indoors: Photorealistic indoor scenes using procedural generation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 21783–21794, 2024.
- [9] Matt Deitke, Eli VanderBilt, Alvaro Herrasti, Luca Weihs, Kiana Ehsani, Jordi Salvador, Winson Han, Eric Kolve, Aniruddha Kembhavi, and Roozbeh Mottaghi. Proctor: Large-scale embodied ai using procedural generation. *Advances in Neural Information Processing Systems*, 35:5982–5994, 2022.
- [10] Ajay Mandlekar, Soroush Nasiriany, Bowen Wen, Ireteayo Akinola, Yashraj Narang, Linxi Fan, Yuke Zhu, and Dieter Fox. Mimicgen: A data generation system for scalable robot learning using human demonstrations. In *7th Annual Conference on Robot Learning*, 2023.
- [11] Shuo Cheng, Caelan Garrett, Ajay Mandlekar, and Danfei Xu. Nod-tamp: Multi-step manipulation planning with neural object descriptors. *arXiv preprint arXiv:2311.01530*, 2023.
- [12] OpenAI: Marcin Andrychowicz, Bowen Baker, Maciek Chociej, Rafal Jozefowicz, Bob McGrew, Jakub Pachocki, Arthur Petron, Matthias Plappert, Glenn Powell, Alex Ray, et al. Learning dexterous in-hand manipulation. *The International Journal of Robotics Research*, 39(1):3–20, 2020.
- [13] Josh Tobin, Rachel Fong, Alex Ray, Jonas Schneider, Wojciech Zaremba, and Pieter Abbeel. Domain randomization for transferring deep neural networks from simulation to the real world. In *2017 IEEE/RSJ international conference on intelligent robots and systems (IROS)*, pages 23–30. IEEE, 2017.
- [14] Nicklas Hansen, Rishabh Jangir, Yu Sun, Guillem Alenyà, Pieter Abbeel, Alexei A Efros, Lerrel Pinto, and Xiaolong Wang. Self-supervised policy adaptation during deployment. *arXiv preprint arXiv:2007.04309*, 2020.

- [15] Denis Yarats, Rob Fergus, Alessandro Lazaric, and Lerrel Pinto. Mastering visual continuous control: Improved data-augmented reinforcement learning. *arXiv preprint arXiv:2107.09645*, 2021.
- [16] Konstantinos Bousmalis, Nathan Silberman, David Dohan, Dumitru Erhan, and Dilip Krishnan. Unsupervised pixel-level domain adaptation with generative adversarial networks. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 3722–3731, 2017.
- [17] Stephen James, Paul Wohlhart, Mrinal Kalakrishnan, Dmitry Kalashnikov, Alex Irpan, Julian Ibarz, Sergey Levine, Raia Hadsell, and Konstantinos Bousmalis. Sim-to-real via sim-to-sim: Data-efficient robotic grasping via randomized-to-canonical adaptation networks. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 12627–12637, 2019.
- [18] Eric Tzeng, Judy Hoffman, Ning Zhang, Kate Saenko, and Trevor Darrell. Deep domain confusion: Maximizing for domain invariance. *arXiv preprint arXiv:1412.3474*, 2014.
- [19] Mingsheng Long, Yue Cao, Jianmin Wang, and Michael Jordan. Learning transferable features with deep adaptation networks. In *International conference on machine learning*, pages 97–105. PMLR, 2015.
- [20] Han Zhao, Remi Tachet Des Combes, Kun Zhang, and Geoffrey Gordon. On learning invariant representations for domain adaptation. In *International conference on machine learning*, pages 7523–7532. PMLR, 2019.
- [21] Adam Wei, Abhinav Agarwal, Boyuan Chen, Rohan Bosworth, Nicholas Pfaff, and Russ Tedrake. Empirical analysis of sim-and-real cotraining of diffusion policies for planar pushing from pixels. *arXiv preprint arXiv:2503.22634*, 2025.
- [22] Abhiram Maddukuri, Zhenyu Jiang, Lawrence Yunliang Chen, Soroush Nasiriany, Yuqi Xie, Yu Fang, Wenqi Huang, Zu Wang, Zhenjia Xu, Nikita Chernyadev, et al. Sim-and-real co-training: A simple recipe for vision-based robotic manipulation. *arXiv preprint arXiv:2503.24361*, 2025.
- [23] Nicolas Courty, Rémi Flamary, Devis Tuia, and Alain Rakotomamonjy. Optimal transport for domain adaptation. *IEEE transactions on pattern analysis and machine intelligence*, 39(9):1853–1865, 2016.
- [24] Kilian Fatras, Thibault Séjourné, Rémi Flamary, and Nicolas Courty. Unbalanced minibatch optimal transport; applications to domain adaptation. In *International Conference on Machine Learning*, pages 3186–3197. PMLR, 2021.
- [25] Lenaïc Chizat, Gabriel Peyré, Bernhard Schmitzer, and François-Xavier Vialard. Scaling algorithms for unbalanced optimal transport problems. *Mathematics of computation*, 87(314):2563–2609, 2018.
- [26] Tony Z Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. *arXiv preprint arXiv:2304.13705*, 2023.
- [27] Cheng Chi, Zhenjia Xu, Siyuan Feng, Eric Cousineau, Yilun Du, Benjamin Burchfiel, Russ Tedrake, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. *The International Journal of Robotics Research*, page 02783649241273668, 2023.
- [28] Yanjie Ze, Gu Zhang, Kangning Zhang, Chenyuan Hu, Muhan Wang, and Huazhe Xu. 3d diffusion policy: Generalizable visuomotor policy learning via simple 3d representations. In *Proceedings of Robotics: Science and Systems (RSS)*, 2024.
- [29] Philipp Wu, Yide Shentu, Zhongke Yi, Xingyu Lin, and Pieter Abbeel. Gello: A general, low-cost, and intuitive teleoperation framework for robot manipulators. In *2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 12156–12163. IEEE, 2024.

- [30] Cheng Chi, Zhenjia Xu, Chuer Pan, Eric Cousineau, Benjamin Burchfiel, Siyuan Feng, Russ Tedrake, and Shuran Song. Universal manipulation interface: In-the-wild robot teaching without in-the-wild robots. *arXiv preprint arXiv:2402.10329*, 2024.
- [31] Simar Kareer, Dhruv Patel, Ryan Punamiya, Pranay Mathur, Shuo Cheng, Chen Wang, Judy Hoffman, and Danfei Xu. Egomimic: Scaling imitation learning via egocentric video. *arXiv preprint arXiv:2410.24221*, 2024.
- [32] Zhenyu Jiang, Yuqi Xie, Kevin Lin, Zhenjia Xu, Weikang Wan, Ajay Mandlekar, Linxi Fan, and Yuke Zhu. Dexmimicgen: Automated data generation for bimanual dexterous manipulation via imitation learning. *arXiv preprint arXiv:2410.24185*, 2024.
- [33] Shuo Cheng, Caelan Reed Garrett, Ajay Mandlekar, and Danfei Xu. NOD-TAMP: Generalizable long-horizon planning with neural object descriptors. In *8th Annual Conference on Robot Learning*, 2024.
- [34] Stephen James, Andrew J Davison, and Edward Johns. Transferring end-to-end visuomotor control from simulation to real world for a multi-stage task. In *Conference on Robot Learning*, pages 334–343. PMLR, 2017.
- [35] Zhecheng Yuan, Tianming Wei, Shuiqi Cheng, Gu Zhang, Yuanpei Chen, and Huazhe Xu. Learning to manipulate anywhere: A visual generalizable framework for reinforcement learning. *arXiv preprint arXiv:2407.15815*, 2024.
- [36] Abolfazl Farahani, Sahar Voghoei, Khaled Rasheed, and Hamid R Arabnia. A brief review of domain adaptation. *Advances in data science and information engineering: proceedings from ICDATA 2020 and IKE 2020*, pages 877–894, 2021.
- [37] Prithwish Dan, Kushal Kedia, Angela Chao, Edward Weiye Duan, Maximus Adrian Pace, Wei-Chiu Ma, and Sanjiban Choudhury. X-sim: Cross-embodiment learning via real-to-sim-to-real. *arXiv preprint arXiv:2505.07096*, 2025.
- [38] Daniel Ho, Kanishka Rao, Zhuo Xu, Eric Jang, Mohi Khansari, and Yunfei Bai. Retinagan: An object-aware approach to sim-to-real transfer. In *2021 IEEE International Conference on Robotics and Automation (ICRA)*, pages 10920–10926. IEEE, 2021.
- [39] Dripta S Raychaudhuri, Sujoy Paul, Jeroen Vanbaars, and Amit K Roy-Chowdhury. Cross-domain imitation from observations. In *International conference on machine learning*, pages 8902–8912. PMLR, 2021.
- [40] Kuno Kim, Yihong Gu, Jiaming Song, Shengjia Zhao, and Stefano Ermon. Domain adaptive imitation learning. In *International Conference on Machine Learning*, pages 5286–5295. PMLR, 2020.
- [41] Nicolas Courty, Rémi Flamary, and Devis Tuia. Domain adaptation with regularized optimal transport. In *Machine Learning and Knowledge Discovery in Databases: European Conference, ECML PKDD 2014, Nancy, France, September 15-19, 2014. Proceedings, Part I 14*, pages 274–289. Springer, 2014.
- [42] Michaël Perrot, Nicolas Courty, Rémi Flamary, and Amaury Habrard. Mapping estimation for discrete optimal transport. *Advances in Neural Information Processing Systems*, 29, 2016.
- [43] Ievgen Redko, Amaury Habrard, and Marc Sebban. Theoretical analysis of domain adaptation with optimal transport. In *Machine Learning and Knowledge Discovery in Databases: European Conference, ECML PKDD 2017, Skopje, Macedonia, September 18–22, 2017, Proceedings, Part II 10*, pages 737–753. Springer, 2017.
- [44] Nicolas Courty, Rémi Flamary, Amaury Habrard, and Alain Rakotomamonjy. Joint distribution optimal transportation for domain adaptation. *Advances in neural information processing systems*, 30, 2017.
- [45] Duy MH Nguyen, An T Le, Trung Q Nguyen, Nghiem T Diep, Tai Nguyen, Duy Duong-Tran, Jan Peters, Li Shen, Mathias Niepert, and Daniel Sonntag. Dude: Dual distribution-aware context prompt learning for large vision-language model. *arXiv preprint arXiv:2407.04489*, 2024.

- [46] Kushal Kedia, Prithwish Dan, Angela Chao, Maximus A Pace, and Sanjiban Choudhury. One-shot imitation under mismatched execution. In *2025 IEEE International Conference on Robotics and Automation (ICRA)*, pages 15649–15656. IEEE, 2025.
- [47] Bharath Bhushan Damodaran, Benjamin Kellenberger, Rémi Flamary, Devis Tuia, and Nicolas Courty. Deepjdot: Deep joint distribution optimal transport for unsupervised domain adaptation. In *Proceedings of the European conference on computer vision (ECCV)*, pages 447–463, 2018.
- [48] Jan Matas, Stephen James, and Andrew J Davison. Sim-to-real reinforcement learning for deformable object manipulation. In *Conference on Robot Learning*, pages 734–743. PMLR, 2018.
- [49] Marco Cuturi. Sinkhorn distances: Lightspeed computation of optimal transport. *Advances in neural information processing systems*, 26, 2013.
- [50] Omer Gold and Micha Sharir. Dynamic time warping and geometric edit distance: Breaking the quadratic barrier. *ACM Transactions On Algorithms (TALG)*, 14(4):1–17, 2018.
- [51] Yuke Zhu, Josiah Wong, Ajay Mandlekar, Roberto Martín-Martín, Abhishek Joshi, Soroush Nasiriany, and Yifeng Zhu. robosuite: A modular simulation framework and benchmark for robot learning. *arXiv preprint arXiv:2009.12293*, 2020.
- [52] Charles R Qi, Hao Su, Kaichun Mo, and Leonidas J Guibas. Pointnet: Deep learning on point sets for 3d classification and segmentation. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 652–660, 2017.
- [53] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin Burchfiel, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. In *Proceedings of Robotics: Science and Systems (RSS)*, 2023.
- [54] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778, 2016.
- [55] Laurens Van der Maaten and Geoffrey Hinton. Visualizing data using t-sne. *Journal of machine learning research*, 9(11), 2008.
- [56] Neville Hogan. Impedance control: An approach to manipulation: Part ii—implementation. 1985.
- [57] Roger Y Tsai, Reimar K Lenz, et al. A new technique for fully autonomous and efficient 3 d robotics hand/eye calibration. *IEEE Transactions on robotics and automation*, 5(3):345–358, 1989.
- [58] Meng Han, Liang Wang, Limin Xiao, Hao Zhang, Chenhao Zhang, Xiangrong Xu, and Jianfeng Zhu. Quickfps: Architecture and algorithm co-design for farthest point sampling in large-scale point clouds. *IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems*, 2023.

神经信息处理系统大会论文清单

1. 权利要求

问题：摘要和引言中的主要主张是否准确反映了论文的贡献和范围？答案：[是] 理由：论文在引言和摘要中明确陈述了其主张和贡献。指南：

- 答案“不适用”表示摘要和引言未包含论文中提出的主张。
- 摘要和/或引言应清晰陈述所提出的主张，包括论文的贡献以及重要的假设和局限性。对此问题回答“否”或“不适用”将不会给审稿人留下良好印象。
- 所提出的主张应与理论和实验结果相符，并反映结果在多大程度上可推广到其他场景。
- 可以将理想化目标作为动机，但需明确这些目标并未在论文中实现。

2. 局限性

问题：论文是否讨论了作者所做工作的局限性？回答：[是] 理由：我们方法的局限性已在结论部分讨论。指南：

- 答案“不适用”表示论文没有局限性，而答案“否”表示论文存在局限性，但文中未讨论这些局限性。
 - 鼓励作者在论文中单独设立“局限性”一节。
 - 论文应指出任何强假设，以及结果对这些假设违反的稳健性（例如，独立性假设、无噪声设置、模型设定良好、渐近近似仅在局部成立）。作者应反思这些假设在实践中可能如何被违反，以及其启示是什么。
 - 作者应反思所提出主张的范围，例如，该方法是否仅在少数数据集或少数运行上进行了测试。一般而言，实证结果往往依赖于隐含假设，这些假设应予以明确阐述。
 - 作者应反思影响方法性能的因素。例如，人脸识别算法在图像分辨率低或光线不足时可能表现不佳。或者，语音转文本系统可能无法可靠地为在线讲座提供闭路字幕，因为它无法处理技术术语。
 - 作者应讨论所提出算法的计算效率以及它们如何随数据集规模扩展。
 - 如果适用，作者应讨论其方法在解决隐私和公平性问题方面的可能局限性。
 - 虽然作者可能担心完全诚实地说明局限性会被审稿人用作拒稿理由，但更糟糕的结果可能是审稿人发现论文中未承认的局限性。作者应运用自己的最佳判断，并认识到支持透明度的个人行为在制定维护社区诚信的规范方面发挥着重要作用。审稿人将被明确指示不要因局限性方面的诚实而惩罚作者。
3. 理论假设与证明 问题：对于每个理论结果，论文是否提供了完整的假设集和完整（且正确）的证明？答案：[不适用]

理由：指南：

- 答案“不适用”表示论文不包含理论结果。• 论文中所有的定理、公式和证明都应编号并交叉引用。
- 所有假设都应在任何定理的陈述中明确说明或引用。
- 证明可以出现在正文或补充材料中，但如果出现在补充材料中，鼓励作者提供简短的证明思路以提供直觉。
- 反之，论文核心部分提供的任何非正式证明都应辅以附录或补充材料中给出的正式证明。
- 证明所依赖的定理和引理应当适当引用。

4. 实验结果可复现性

问题：论文是否充分披露了复现主要实验结果所需的所有信息，以至于影响论文的主要主张和/或结论（无论是否提供代码和数据）？答案：[是] 理由：完整的实现细节包含在附录指南中：

• 答案“不适用”表示论文未包含实验。• 若论文包含实验，对此问题回答“否”将不会被审稿人看好：无论是否提供代码和数据，使论文可复现都至关重要。• 若贡献为数据集和/或模型，作者应描述为使结果可复现或可验证所采取的步骤。• 根据贡献的不同，可复现性可通过多种方式实现。例如，若贡献为新颖的架构，完整描述该架构可能已足够；若贡献为特定模型及实证评估，则可能需要使他人能够使用相同数据集复现该模型，或提供模型访问权限。一般而言，发布代码和数据通常是实现此目标的良好途径之一，但也可通过提供复现结果的详细说明、访问托管模型（例如大语言模型）、发布模型检查点或其他适合所开展研究的方式来实现可复现性。• 虽然神经信息处理系统大会（NeurIPS）不要求发布代码，但会议确实要求所有投稿提供合理的可复现途径，具体取决于贡献的性质。例如：(a) 若贡献主要为新算法，论文应明确说明如何复现该算法。(b) 若贡献主要为新模型架构，论文应清晰完整地描述该架构。(c) 若贡献为新模型（例如大语言模型），则应提供访问该模型以复现结果的方式，或提供复现该模型的方法（例如使用开源数据集或构建数据集的说明）。(d) 我们认识到在某些情况下可复现性可能较为棘手，此时欢迎作者描述其提供的特定可复现方式。对于闭源模型，模型访问可能受到某种限制（例如仅限注册用户），但应使其他研究人员有途径复现或验证结果。

5. 数据与代码的开放获取 问题：论文是否提供了数据和代码的开放获取，并附有足够的说明，以便按照补充材料中的描述忠实复现主要实验结果？

答案: [是] 理由: 代码和数据可在我们的项目网页上获取。指南:

- 答案“不适用”表示论文不包含需要代码的实验。• 更多细节请参阅神经信息处理系统大会 (NeurIPS) 代码和数据提交指南 (<https://nips.cc/public/guides/CodeSubmissionPolicy>)。• 虽然我们鼓励发布代码和数据,但我们理解这可能无法实现,因此“否”是一个可接受的答案。论文不能仅仅因为未包含代码而被拒绝,除非代码对贡献至关重要(例如,对于一个全新的开源基准)。
 - 说明应包含运行以复现结果所需的确切命令和环境。更多细节请参阅神经信息处理系统大会 (NeurIPS) 代码和数据提交指南 (<https://nips.cc/public/guides/CodeSubmissionPolicy>)。
 - 作者应提供数据访问和准备的说明,包括如何访问原始数据、预处理数据、中间数据和生成数据等。
 - 作者应提供脚本以复现所提新方法和基线的所有实验结果。如果只有部分实验可复现,应说明哪些实验从脚本中省略及其原因。
 - 在提交时,为保持匿名性,作者应发布匿名版本(如适用)。
 - 建议在补充材料(附于论文后)中提供尽可能多的信息,但允许包含数据和代码的网址。
6. 实验设置/细节问题: 论文是否详细说明了所有训练和测试细节(例如,数据划分、超参数、其选择方式、优化器类型等),以便理解结果? 答案: [是] 理由: 我们在附录中包含了完整细节。指南:

- 答案“不适用”表示论文不包含实验。
- 实验设置应在论文正文中呈现,其详细程度应足以理解结果并使其有意义。
- 完整细节可随代码、附录或作为补充材料提供。

7. 实验统计显著性

问题: 论文是否报告了恰当且正确定义的误差线,或提供了关于实验统计显著性的其他适当信息? 答案: [否] 理由: 本文的主要结果需要大量努力来执行每次真实世界评估试验。因此,生成误差线是不切实际的。我们提供了实验评估条件的详细描述。指南:

- 答案 NA 表示论文不包含实验。• 如果结果附有误差线、置信区间或统计显著性检验,至少对于支持论文主要主张的实验,作者应回答“是”。
- 误差线所捕捉的变异性因素应明确说明(例如,训练/测试划分、初始化、某些参数的随机抽取,或在给定实验条件下的整体运行)。
- 计算误差线的方法应予以解释(闭式公式、调用库函数、自助法等)。
- 应给出所做的假设(例如,误差服从正态分布)。

• 应明确误差线是标准差还是均值的标准误。• 报告 1σ 误差线是可以的，但应说明。如果误差的正态性假设未经验证，作者最好报告 2σ 误差线，而不是声称具有 96% 置信区间。• 对于非对称分布，作者应注意不要在表格或图中显示对称误差线，以免产生超出范围的结果（例如负错误率）。• 如果在表格或图中报告了误差线，作者应在正文中解释其计算方法，并在正文中引用相应的图或表。

8. 实验计算资源 问题：对于每个实验，论文是否提供了复现实验所需的计算机资源（计算工作者类型、内存、执行时间）的充分信息？答案：[是] 理由：我们提供了实验所需计算资源的完整细节。指南：

- 答案“不适用”表示论文不包含实验。
- 论文应指明计算工作者的类型（CPU 或 GPU、内部集群或云提供商），包括相关的内存和存储。
- 论文应提供每个单独实验运行所需的计算量，并估算总计算量。
- 论文应披露整个研究项目所需的计算量是否超过论文中报告实验的计算量（例如，未纳入论文的初步或失败实验）。

9. 伦理准则

问题：论文中开展的研究是否在各方面均符合神经信息处理系统大会伦理准则 <https://neurips.cc/public/EthicsGuidelines>？回答：[是] 理由：我们的实验不涉及正式的人体研究。演示数据由作者在明确同意的情况下收集。指南：

- 回答“不适用”表示作者未审阅神经信息处理系统大会伦理准则。
- 如果作者回答“否”，应解释需要偏离伦理准则的特殊情况。• 作者应确保匿名性（例如，若因所在司法管辖区的法律或法规而有特殊考虑）。

10. 更广泛影响

问题：论文是否讨论了所开展工作的潜在积极社会影响和消极社会影响？回答：[不适用] 理由：我们的工作主要是一种利用仿真数据提升机器人性能算法。我们预计该工作不会产生直接的社会影响。指南：

- 答案“不适用”表示所进行的工作没有社会影响。
- 如果作者回答“不适用”或“否”，他们应解释为什么他们的工作没有社会影响，或者为什么论文没有涉及社会影响。
- 负面社会影响的例子包括潜在的恶意或非预期用途（例如，虚假信息、生成虚假个人资料、监控）、公平性考量（例如，部署可能做出不公平影响特定群体的决策的技术）、隐私考量以及安全考量。

- 会议预期许多论文将是基础性研究，不涉及特定应用，更不用说部署。然而，如果存在通往任何负面应用的直接路径，作者应指出。例如，指出生成模型质量的提升可能被用于生成用于虚假信息的深度伪造是合理的。另一方面，不需要指出用于优化神经网络的通用算法可能使人们能够更快地训练生成深度伪造的模型。
- 作者应考虑技术按预期使用且功能正常时可能产生的危害，技术按预期使用但给出错误结果时可能产生的危害，以及技术被（有意或无意）滥用后产生的危害。
- 如果存在负面社会影响，作者还可以讨论可能的缓解策略（例如，模型的分级发布、在攻击之外提供防御、监控滥用的机制、监控系统如何随时间从反馈中学习的机制、提高机器学习的效率和可及性）。

11. 保障措施

问题：论文是否描述了为负责任地发布具有高滥用风险的数据或模型（例如，预训练语言模型、图像生成器或抓取的数据集）而设置的保障措施？

答案：[不适用] 理由：指南：

- 答案“不适用”表示本文不存在此类风险。
- 对于存在高误用或双重用途风险的已发布模型，应附带必要的安全防护措施，以便在受控条件下使用模型，例如要求用户遵守使用指南或访问限制，或实施安全过滤机制。
- 从互联网抓取的数据集可能带来安全风险。作者应说明如何避免发布不安全的图像。
- 我们认识到提供有效的安全防护具有挑战性，且许多论文并不要求如此，但我们鼓励作者考虑这一点并尽最大努力。

12. 现有资产的许可证 问题：论文中所使用的资产（如代码、数据、模型）的创建者或原始所有者是否得到了适当的署名，并且许可证和使用条款是否被明确提及并得到适当遵守？

答案：[是] 理由：我们的工作基于现有的开源代码库，并对其进行了充分的引用和致谢。

指南：

- 答案“不适用”表示本文未使用现有资产。
- 作者应引用生成代码包或数据集的原始论文。
- 作者应说明所用资产的版本，并在可能的情况下提供网址。
- 每个资产应包含许可证名称（例如 CC-BY 4.0）。
- 对于从特定来源（例如网站）抓取的数据，应提供该来源的版权和服务条款。
- 如果资产已发布，应提供包中的许可证、版权信息和使用条款。对于流行的数据集，paperswithcode.com/datasets 已为部分数据集整理了许可证。其许可指南可帮助确定数据集的许可证。
- 对于重新打包的现有数据集，应同时提供原始许可证和衍生产物（如有变更）的许可证。

- 若该信息无法在线获取，建议作者主动联系资产创建者。

13. 新资产

问题：论文中引入的新资产是否得到了充分记录，且文档是否与资产一同提供？答案：[不适用] 理由：该论文未发布新资产。指南：

- 答案不适用意味着论文未发布新资产。
- 研究人员应通过结构化模板，在提交材料中说明数据集/代码/模型的详细信息，包括训练、许可证、局限性等。
- 论文应讨论是否以及如何获得资产所有者的同意。
- 提交时，请记得对资产进行匿名化处理（如适用）。您可以创建匿名链接或包含匿名压缩文件。

问题：对于众包实验和涉及人类受试者的研究，论文是否包含提供给参与者的完整说明文本和截图（如适用），以及有关报酬（如有）的详细信息？答案：[不适用] 理由：指南：

- 答案不适用意味着论文不涉及众包或人类受试者研究。
 - 在补充材料中包含这些信息是可以的，但如果论文的主要贡献涉及人类受试者，则应在正文中尽可能详细地说明。
 - 根据 NeurIPS 伦理准则，参与数据收集、整理或其他劳动的工作人员应获得不低于数据收集者所在国家最低工资的报酬。
15. 机构审查委员会（IRB）或同等机构对人类受试者研究的批准 问题：论文是否描述了研究参与者可能面临的风险、这些风险是否已告知受试者，以及是否获得了机构审查委员会（IRB）的批准（或根据您所在国家或机构要求进行的同等批准/审查）？答案：[不适用] 理由：指南：

- 答案不适用意味着论文不涉及众包或人类受试者研究。
- 根据研究开展所在的国家，任何人类受试者研究都需要 IRB 批准（或同等批准）。如果您获得了 IRB 批准，应在论文中明确说明。
- 我们认识到不同机构和地区的相关程序可能存在显著差异，我们期望作者遵守 NeurIPS 伦理准则及其所在机构的指南。
- 对于初次提交，请勿包含任何可能破坏匿名性的信息（如适用），例如进行评审的机构。

16. 大语言模型使用声明

问题：如果大语言模型是本研究核心方法中的重要、原创或非标准组成部分，论文是否描述了其使用情况？请注意，如果大语言模型仅用于写作、编辑或格式调整，且不影响核心方法论、科学严谨性或研究原创性，则无需声明。答案：[不适用] 理由：指南：

- 答案“不适用”意味着本研究的核心方法开发未将大语言模型作为任何重要、原创或非标准组成部分。
- 请参阅我们的大语言模型政策 (<https://neurips.cc/Conferences/2025/LLM>)，了解应描述或不应描述的内容。

目录

补充材料包含以下内容：

- **任务与硬件设置**（第 B 节）：硬件配置、数据集和任务设置的详细描述。
- **模型与训练细节**（第 C 节）：实验中使用的神经网络架构描述及相应的训练过程。
- **采样策略的消融实验**（第 D 节）：不同采样策略的评估与分析。
- **补充结果**（第 F 节）：真实世界中基于图像和基于点云策略的分布内评估结果。
- **传输计划可视化**（第 H 节）：随机采样训练批次的最优传输计划可视化。
- **潜空间可视化**（第 I 节）：我们的方法与协同训练基线在额外任务上学习到的潜空间视觉比较。

更多视频结果和分析可在我们的网站上找到：<https://ot-sim2real.github.io/>

B 任务与硬件设置

为评估所提方法的有效性，我们在多个机器人桌面操作任务上进行了全面实验，涵盖仿真到仿真和仿真到现实迁移场景。这些任务旨在测试系统处理机器人操作中关键挑战的能力，包括密集物体交互、长时程推理和高精度控制：

- 提起：抓住杯子的边缘并垂直提起；
- 盒入箱：抓住一个高盒子并将其放入箱中；
- 堆叠：抓取一个小立方体，并将其堆叠在一个较长的长方体上；
- 方形：抓取一个方形物体的手柄，并将其插入到销钉上；
- 挂杯：抓取杯子的边缘，并利用手柄将其挂在杯架上；
- 抽屉：打开抽屉，从桌上抓取一个咖啡胶囊，将其放入抽屉中，然后关闭抽屉。

B.1 硬件设置

系统设置如图 5 所示。我们使用 Franka Emika Panda 机器人，通过关节阻抗控制器 [56] 以 20 Hz 的频率运行以执行策略。在数据收集过程中，机器人通过 Meta Quest 3 头显进行遥操作，跟踪的笛卡尔位姿通过逆运动学转换为关节配置。RGB 图像和深度信息由 Intel RealSense D435 深度相机捕获。

B.2 域偏移与观测缺口

我们通过设计以下目标域偏移，在仿真中评估视觉域偏移下的泛化能力：

- 视角 1-点云：相机绕 z 轴旋转约 30° ，使得目标域中呈现侧视图，而源域中为正面视图。使用点云观测。
- 视角 3-点云：相机绕 z 轴旋转约 90° ，引入更极端的视角偏移。使用点云观测。
- 扰动-点云：从范围 $[-0.01, 0.01]$ 均匀采样的随机噪声被添加到点云中的每个点，以模拟传感器噪声或域偏移。




图 5：硬件设置。我们的硬件平台使用 Franka Emika Panda 机器人，配备 Intel RealSense D435 相机用于捕获图像和深度，以及 Meta Quest 3 头显用于遥操作。




图 6：跨域观测差距。顶部：Stack 任务在源域、视角 1-图像、纹理-图像和真实世界域中的图像观测。底部：BoxInBin 任务在源域、视角 3-点云、扰动-点云和真实世界域中的点云观测。点云颜色仅用于可视化，不作为策略输入。

- 视角 1-图像：A 20° 绕 z 轴的相机旋转被应用。使用 RGB 图像观测。
- 纹理-图像：目标域中的桌面纹理被修改。使用 RGB 图像观测。

我们在图 6 中展示了所有域之间的观测差距。第一行显示了 Stack 任务在源域、视角 1-图像、纹理-图像和真实世界中的图像观测。第二行显示了 BoxInBin 任务在源域、视角 3-点云、扰动-点云和真实世界中的点云观测。点云颜色仅用于可视化，不作为策略输入。

B.3 任务数据集、重置范围与分布外变体

本文主要关注在仅由源域演示覆盖的区域中评估策略性能。为进行受控实验，我们为每项任务定义了三个不同的重置区域——源区域、目标区域和目标分布外区域——如图 7 所示。具体而言：

	Lift	Stack	BoxInBin	MugHang	Square	Drawer
Number of real demos	10	25	20	15	25	25

表 5：真实世界演示数量。我们为每项任务收集 10 至 25 个演示，varying with task difficulty.




图 7：各任务的重置范围。第一行展示了源区域，其中收集了密集的源域演示。第二行展示了仿真到仿真迁移实验中使用的目标区域和目标分布外重置范围。在此设置下，目标区域由演示稀疏覆盖，而目标分布外区域不包含任何演示，仅用于策略评估。第三行类似地展示了仿真到现实迁移实验中的目标区域和目标分布外区域。

- 源区域：一个在源域中被演示密集覆盖的大区域。我们使用 MimicGen[10] 在源区域内生成 1000 个演示。
- 目标区域：源区域的一个小子集。该区域在目标域中被演示稀疏覆盖，因此在评估期间被视为分布内。对于仿真到仿真迁移，我们在该区域内收集 10 个演示。对于仿真到现实迁移，在目标区域收集的真实世界演示数量根据任务难度进行调整，详见表 5。
- 目标分布外区域：在目标分布外区域不收集任何演示，该区域仅用于评估，并被视为分布外。

对于仿真到现实迁移实验，除了重置范围分布外（记为重置），我们还考虑了两种额外的分布外变体。在纹理变体中，物体的纹理被修改为真实世界演示中未出现过的纹理。在形状变体中，物体被替换为真实世界演示中未遇到的新形状。这些变体如图 8 所示。




图 8：仿真到现实实验中的纹理和形状分布外。展示了 BoxInBin 任务在纹理分布外条件下，以及 Lift 任务在形状分布外和形状+重置分布外条件下的重置范围可视化。

C 模型与训练细节

对于基于点云的实验，我们采用带有 PointNet 编码器 [52] 的 3D 扩散策略架构 [28]。扩散头接收从点云观测中提取的特征以及机器人本体感知输入（关节和夹爪位置），并输出 7 自由度目标关节位置和夹爪动作。我们将深度图投影到机器人基坐标系以生成场景点云。对于坐标为 (u, v) 且深度为 d 的像素，对应的三维位置可通过以下公式恢复：

$$p^w = R \cdot K^{-1} \cdot I + t$$

其中 $I = (u \cdot d, v \cdot d, d)$, $[R | t]$ 表示通过手眼标定 [57] 获得的相机位姿， K 表示相机内参矩阵。我们使用由 $x \in [-0.2, 0.1]$, $y \in [-0.2, 0.2]$ 和 $z \in [0.008, 0.588]$ 定义的边界框裁剪重建的场景点云，以排除无关背景信息。裁剪后的点云随后使用最远点采样 (FPS) [58] 下采样至 2048 个点。

对于基于图像的策略实验，我们采用带有基于 ResNet [54] 视觉编码器的扩散策略 [27]。原始图像由相机以 480×640 的分辨率捕获。在预处理过程中，图像被下采样至 120×160 ，随后在训练期间随机裁剪至 108×144 ，在测试期间进行中心裁剪。该策略以堆叠的历史图像和机器人本体感知输入（关节和夹爪位置）作为输入，并输出 7 自由度目标关节位置以及夹爪动作。

我们的整体训练流程总结于算法 1。对于行为克隆损失 L_{BC} ，我们使用 256 的批大小，并按照 Maddukuri 等人 [22] 的方法设置 0.9 的协同训练比例。对于最优传输损失 L_{OT} ，批大小设置为 128，加权系数为 $\lambda = 0.1$ 。我们在实验中使用 $\epsilon = 0.0005$ 和 $\tau = 0.01$ 。

Algorithm 1 Joint Policy Training with OT

Require: Source dataset D_{src} , Target dataset D_{tgt}

- 1: Initialize encoder f_ϕ , and policy π_θ
 - 2: Compute DTW distances for all trajectories pairs in D_{src} and D_{tgt}
 - 3: **for** iteration $t = 1$ to T **do**
 - 4: Sample a paired batch $\{(o_{src}^i, x_{src}^i, a_{src}^i, o_{tgt}^j, x_{tgt}^j, a_{tgt}^j)\}$ with size N from D_{src} and D_{tgt} using strategy described in Sec. 4.3
 - 5: Compute features $\{z_{src}^i\}$ and $\{z_{tgt}^j\}$ using encoder f_ϕ
 - 6: Construct ground cost matrix $\hat{C}_\phi$ as described in Sec. 4.1
 - 7: Compute optimal transport plan $\Pi^* = \arg \min_{\Pi \in \mathbb{R}_+^{N \times N}} (\langle \Pi, \hat{C}_\phi \rangle_F + \epsilon \cdot \Omega(\Pi) + \tau \cdot \text{KL}(\Pi \mathbf{1} || \mathbf{p}) + \tau \cdot \text{KL}(\Pi^\top \mathbf{1} || \mathbf{q}))$ via Sinkhorn-Knopp algorithm [49]
 - 8: Compute OT loss $L_{\text{UOT}}(f_\phi) = \langle \Pi^*, \hat{C}_\phi \rangle_F$
 - 9: Sample $\{(o_{src}^i, x_{src}^i, a_{src}^i)\}$ from D_{src} and sample $\{(o_{tgt}^j, x_{tgt}^j, a_{tgt}^j)\}$ from D_{tgt}
 - 10: Compute BC loss $L_{BC}(f_\phi, \pi_\theta)$
 - 11: Update f_ϕ and π_θ with gradients of $L_{BC}(f_\phi, \pi_\theta) + \lambda \cdot L_{\text{UOT}}(f_\phi)$
 - 12: **end for**
-

D 采样策略消融研究

为评估采样策略的有效性，我们将完整方法与一个不应用任何轨迹级采样的变体（记为 Ours w/o Sampler）进行比较。在该基线中，源数据和目标数据在轨迹和时间步上随机采样，没有协调。我们还加入了一个预言机变体（记为 UOT-Oracle），它构建完美配对的批次——每个状态在源域和目标域中都被观测到，以确保批次数据来自相同的底层状态。我们在 Viewpoint1-Point 变化下的 Stack 任务上评估策略性能，结果如图 9 所示。




图 9：采样策略比较。本文提出的采样策略（Ours）在视角 1-点的堆叠任务上提升了策略成功率，优于无采样器的本文方法，并达到了与理想配对上限（UOT-Oracle）相当的性能。

时间感知策略提升了配对质量和下游性能。理想基线表明，在数据完全对齐的情况下，非平衡最优传输损失通过使编码器学习域不变表示，显著增强了泛化能力。相比之下，无采样变体（Ours w/o Sampler）在目标分布外设置中表现出较差的泛化性。这种退化可能源于小批量中遇到对齐状态对的概率较低——尤其是在长时程任务中，不协调的采样很少产生时间对齐的数据。

E 超参数敏感性分析

本文进行了消融实验，以评估方法对关键超参数的敏感性，包括熵正则化系数（ ϵ ）、KL 散度惩罚项（ τ ）以及时间对齐采样中使用的窗口大小。在每组实验中，仅改变一个超参数而保持其他不变，训练策略并通过回放评估其性能。结果报告于表 6，涵盖视角-图像设置下的装箱任务和纹理-图像设置下的提升任务。结果表明，在合理范围内，本文方法对超参数变化具有鲁棒性。具体而言，当 ϵ 和 τ 设置在 0.001 至 0.1 之间，窗口大小在 5 至 20 之间变化时，性能保持稳定。在分布外场景中，本文方法始终优于协同训练基线，基线在装箱任务上的成功率为 0.14，在提升任务上为 0.6。这些发现表明，尽管本文方法引入了额外组件，但无需大量调参，并在泛化方面具有明显优势。

F 额外的真实世界评估结果

本文进行了广泛的真实世界评估，以验证方法的有效性。分布内场景的仿真到现实迁移结果分别报告于表 7（基于图像策略）和表 8（基于点云策略）。分布外（OOD）场景的结果见正文。

实验结果表明，本文方法在真实世界分布内场景中始终优于所有基线。对于基于图像和基于点云的策略，本文方法分别达到了 0.73 和 0.77 的平均成功率，证明了其在学习复杂真实世界操作任务中的有效性。

G 目标域数据稀缺时的性能

为评估本文方法在目标域数据有限情况下的有效性，我们在 BoxInBin 任务的 Viewpoint3-Point 设置下，将本文方法与多个基线在低数据场景中进行比较。

ϵ							ϵ						
	0.0001	0.001	0.005	0.01	0.04	1		0.0001	0.001	0.01	0.04	0.1	1
T	0.90	0.94	0.92	0.88	0.90	0.88	T	0.84	0.88	0.80	0.76	0.78	0.76
T-O	0.18	0.16	0.26	0.22	0.18	0.20	T-O	0.60	0.74	0.62	0.66	0.68	0.54

τ							τ						
	0.0001	0.001	0.005	0.02	0.04	1		0.0001	0.005	0.02	0.04	0.1	1
T	0.88	0.96	0.94	0.94	0.92	0.94	T	0.78	0.70	0.76	0.76	0.78	0.74
T-O	0.28	0.26	0.20	0.28	0.22	0.22	T-O	0.56	0.67	0.64	0.66	0.62	0.66

winsize							winsize						
	1	5	10	20	40	120		1	5	10	20	40	120
T	0.82	0.92	0.86	0.90	0.94	0.84	T	0.86	0.80	0.70	0.78	0.74	0.82
T-O	0.20	0.22	0.22	0.24	0.16	0.14	T-O	0.66	0.60	0.67	0.58	0.56	0.60

(a) BoxInBin
(b) Lift

表 6: 超参数敏感性。在每组实验中，我们仅改变一个超参数并保持其他超参数不变，训练策略并通过 rollout 评估其成功率。T 和 T-O 分别表示目标域和分布外条件下的目标域。

	Stack		Square		BoxInBin		Average
	grasp	full	grasp	full	grasp	full	
Source-only	0.1	0.0	0.0	0.0	0.0	0.0	0.00
Target-only	0.7	0.7	0.8	0.0	0.7	0.7	0.47
Co-training	0.8	0.7	0.8	0.1	0.9	0.8	0.53
Ours	0.9	0.9	0.9	0.4	0.9	0.9	0.73

表 7: 真实世界基于图像策略的分布内成功率。平均值表示所有任务的平均完整任务成功率。

	Stack		Square		BoxInBin		Lift		MugHang		Drawer				Average
	grasp	full	grasp	full	grasp	full	reach	full	grasp	full	open	grasp	place	full	
S.-only	0.3	0.0	0.1	0.1	0.4	0.3	0.5	0.5	0.1	0.0	0.0	0.0	0.0	0.0	0.15
T.-only	0.7	0.4	0.6	0.1	0.9	0.8	1.0	1.0	0.8	0.8	0.9	0.5	0.5	0.5	0.60
Co-train.	0.7	0.7	1.0	0.5	0.8	0.8	0.8	0.8	1.0	0.8	1.0	0.7	0.7	0.4	0.67
Ours	0.8	0.8	1.0	0.4	0.9	0.9	1.0	1.0	1.0	0.8	1.0	0.7	0.7	0.7	0.77

表 8: 真实世界基于点云策略的分布内成功率。平均值 denotes the average full task success rates over all tasks.

	1 Demo		5 Demo	
	Target	Target-OOD	Target	Target-OOD
Ours	0.56	0.28	0.70	0.32
Co-training	0.46	0.00	0.38	0.22
MMD	0.42	0.16	0.34	0.22
Target-only	0.00	0.00	0.46	0.00

表 9: 目标域数据有限时的性能。我们报告了在目标域数据极其有限的场景下，各种方法在 BoxInBin 任务 Viewpoint3-Point 设置中的成功率。

如表 9 所示，本文方法始终优于基线，突显了即使在监督极其有限的情况下也具有鲁棒性。




图 10：传输方案可视化。我们可视化了在训练基于图像的策略时随机采样批次的传输方案，以及来自两个域的相应观测。左图展示了仿真到仿真实验，右图展示了仿真到真实实验。可视化结果表明，传输方案有效地对齐了跨域的相似状态，这由高传输概率所指示。

H 传输方案可视化

为了理解最优传输如何促进域不变特征学习并增强跨域泛化，我们可视化了在训练基于图像的策略时随机采样批次的传输方案，以及来自两个域的相应观测（见图 10）。左图展示了仿真到仿真迁移实验的结果，右图描绘了仿真到真实设置。结果表明，传输方案有效地对齐了跨域的相似状态，促进了域不变表示。

I 潜空间可视化




图 11：潜空间可视化。联合训练基线与本文方法的潜空间比较。在本文方法中，源域点（蓝色）和目标域点（红色）形成充分混合的簇，说明最优传输对齐如何协调跨域特征分布并增强可迁移性和泛化性。

除了针对视点 1-点目标域的堆叠任务的特征可视化外，我们还在图 11 中展示了针对扰动-点目标域的装箱任务和视点 1-点目标域的方形任务的额外 t-分布随机邻域嵌入 [55] 可视化。我们比较了联合训练基线和本文方法产生的潜空间。在本文方法中，源域点（蓝色）和目标域点（红色）形成充分混合的簇，突出了最优传输对齐如何协调跨域特征分布并提升可迁移性和泛化性。