

函数伴随采样器：无限维空间上的可扩展采样

Byoungwoo Park¹ Juho Lee¹ Guan-Horng Liu²

摘要

基于学习的方法在有限维空间中从吉布斯分布采样已取得快速进展，然而针对无限维函数空间的理论与算法设计仍然有限。尽管它们在采样条件扩散过程的路径方面具有巨大潜力，能够高效模拟满足稀有事件或边界约束的扩散过程轨迹，这一空白依然存在。本文提出了面向无限维函数空间的伴随采样器，这是一种基于随机最优控制的扩散采样器，在函数空间中运行，并针对无限维希尔伯特空间上的吉布斯型分布。我们的函数伴随采样器（Functional Adjoint Sampler, FAS）基于称为随机最大值原理的随机最优控制理论，将伴随采样（Havens et al., 2025）推广到希尔伯特空间，为函数表示提供了一个简单且可扩展的匹配型目标。我们证明，FAS 在合成势能和真实分子系统（包括丙氨酸二肽和 Chignolin）上均取得了优越的过渡路径采样性能。

1. 引言

在特定条件下（如稀有事件和规定的终端分布）构造马尔可夫扩散过程的研究，长期以来一直是概率论与统计物理学的核心主题（Doob and Doob, 1984; Chetrite and Touchette, 2015）。随着近期生成建模的爆发式关注（Song et al., 2021; Lipman et al., 2023），该框架已出现在许多其他机器学习应用中，包括数据同化（Chopin et al., 2023; Park et al., 2025）、群体建模（Liu et al., 2022; Chen et al., 2023）、分子动力学模拟（Plainer et al., 2023; Holdijk et al., 2022），以及——本文特别关注的——从吉布斯分布采样（Tzen and Raginsky, 2019）。

具体而言，我们关注从吉布斯分布 $\pi(\mathbf{x}) \propto e^{-U(\mathbf{x})}$ 中生成样本，给定其未归一化的能量函数 $U(\mathbf{x})$ 。现代计算方法——称为扩散采样器——通过学习扩散过程来实现这一目标，其终端分布与 π 的规律相匹配。其中，基于伴随的扩散采样器（Havens 等人, 2025; Liu 等人, 2025; Choi 等人, 2025）形成了一个独特的家族，它们将采样问题重新表述为随机最优控制问题（SOC）（Fleming 和 Soner, 1993; Kappen, 2005），并由此采用伴随匹配（AM）（Domingo-Enrich 等人, 2025）。例如，伴随采样（AS）（Havens 等人, 2025）学习一个无记忆随机微分方程的漂移项，其伴随匹配目标仅依赖于在线策略样本和无仿真的目标。与依赖基于仿真目标的普通 SOC 方法（Zhang 和 Chen, 2022）以及需要重要性加权样本的方法（Phillips 等人, 2024; Akhound-Sadegh 等人, 2024）相比，这产生了一种高度可扩展的方法。

尽管这些伴随采样器在实际应用中取得了成功，但所有上述方法仅在有限维状态空间中生成样本，e.g., $\mathbf{x} \in \mathbb{R}^d$ 。这本质上排除了它们在更一般的轨迹空间上定义的吉布斯分布采样中的应用——这类分布普遍出现在计算化学中，一个代表性例子是过渡路径采样（TPS）（Bolhuis 等人, 2002; Vanden-Eijnden 等人, 2010）。TPS 的核心目标是通过采样由随机涨落或外部强迫驱动的亚稳态之间动力学轨迹的系综来识别稀有反应路径（Dürr 和 Bach, 1978）。研究这些转变能够准确估计反应速率和机制，解释分子如何在亚稳态之间转变，从而有益于蛋白质折叠（Dobson, 2003; Noé 等人, 2009）、酶催化（Basner 和 Schwartz, 2005）、药物设计（Tiwary 等人, 2015）和成核（Sosso 等人, 2016）等多种应用。

由于 TPS 旨在生成遵循特定能量结构的轨迹的吉布斯分布，自然要考虑直接在这些无限维空间中构建的采样器。

¹ 韩国科学技术院 2Meta 基础人工智能研究部。通讯作者：Byoungwoo Park <bw.park@kaist.ac.kr>, Guan-Horng Liu <ghliu@meta.com>。

预印本。

¹ 实际上，AS（Havens 等人, 2025）通过固定初始条件满足无记忆条件。

维函数空间。实际上， $\mathbb{R}^d$ 值扩散过程的轨迹通常被视为随机函数（Hairer 等，2009），其相关概率律通常位于诸如 $\mathcal{H} := L^2(\mathbf{L}, \mathbb{R}^d)$ 的函数空间上，其中 $\mathbf{L} \subseteq \mathbb{R}$ 表示时间区间。在这种情况下，基于朗之万型无穷维随机微分方程的经典采样方法已被研究（Stuart 等，2004；Beskos 等，2008），尽管它们主要停留在理论兴趣而非实际效用。另一方面，现有的针对 TPS 的扩散采样器（Holdijk 等，2022；Seong 等，2025）仍局限于有限维状态空间，因为它们依赖于由局部能量梯度驱动的参数动力学，这排除了可扩展的 AM 目标。

在本文中，我们引入了函数伴随采样器（Functional Adjoint Sampler, FAS），这是一种可扩展的匹配算法，将 AS 扩展到无穷维函数空间。形式上，我们在无穷维公式中重新表述从吉布斯型分布采样，并在函数空间中构建扩散采样器。利用无穷维 SOC，我们将非平衡采样（NES）表述为（Tzen 和 Raginsky, 2019；Zhang 和 Chen, 2022）的函数空间推广。此外，在标准正则性条件下，我们证明通过应用随机最大值原理（Bensoussan, 1983；Du 和 Meng, 2013），伴随匹配（AM）也可以扩展到函数空间，从而提供简单且可扩展的训练目标。

在实践中，我们特别关注 TPS 问题，我们的方法在多种设置下生成条件路径，从合成势到分子系统，如丙氨酸二肽和 Chignolin。具体来说，FAS 直接在无穷维函数空间中操作，选择满足模拟路径规定边界条件（i.e., 狄利克雷边界）的基，从而在亚稳态之间产生完美过渡，无需额外的投影或惩罚项。这种原则性公式确保了条件扩散的适定性，并支持稳定的离散化，同时优于基于有限维动力学的先前工作。

我们将贡献总结如下：

- 本文提出了一种函数空间扩散采样器，从无限维路径空间上的吉布斯型分布中抽取样本。以无限维奥恩斯坦-乌伦贝克半群作为参考动力学，本文将 NES 表述为无限维随机最优控制问题。
- 基于称为随机最大值原理的随机最优控制理论，本文提出 FAS，这是 AS（Havens 等人，2025 年）基于匹配的 AM 训练目标在希尔伯特空间中的推广，并产生了一种适用于函数表示的可扩展训练算法。

- 本文展示了 FAS 在 TPS 上的优越性能，在合成势能和具有挑战性的真实分子系统（包括丙氨酸二肽和 Chignolin）上优于先前的有限维方法，同时保持了对目标状态的完美转移命中率。

符号说明。在整篇论文中，本文考虑一个实可分希尔伯特空间 $\mathcal{H}$ ，配备范数 $\|\cdot\|_{\mathcal{H}}$ 和内积 $\langle \cdot, \cdot \rangle_{\mathcal{H}}$ 。本文用 $\mathbb{P}^{(\cdot)}$ 表示所有连续映射 $\Omega = C([0, T], \mathcal{H})$ 空间上的路径测度，用 $\mathbf{X}^{(\cdot)} \in \mathcal{H}$ 表示与该路径测度相关的随机过程。本文将（随机）函数 $\mathbf{X}[\cdot] : \mathbb{R}^n \rightarrow \mathbb{R}^d$ 在域空间 $u \in \mathbb{R}^n$ 中的点 $\mathbb{R}^n$ 处的取值记为 $\mathbf{X}[u] \in \mathbb{R}^d$ ，除非为了清晰起见，否则将省略。对于函数 $\mathcal{V} : [0, T] \times \mathcal{H} \rightarrow \mathbb{R}$ ，本文定义 $D_{\mathbf{x}}\mathcal{V}, D_{\mathbf{xx}}\mathcal{V}$ 为关于变量 $\mathbf{x} \in \mathcal{H}$ 的一阶和二阶弗雷歇导数，定义 $\partial_t \mathcal{V}$ 为关于时间变量 $t \in [0, T]$ 的导数。埃尔米特伴随记为 $\dagger$ 。

2. 预备知识

这里，本文简要概述了研究无限维状态空间中扩散采样器所需的概率概念。更多回顾见第 A 节。

希尔伯特空间中的高斯测度 设 $(\Omega, \mathcal{F}, \mathbb{Q})$ 与 $(\mathcal{H}, \mathcal{B}(\mathcal{H}))$ 为可测状态空间，其中 $\mathcal{H}$ 值随机变量 $\mathbf{X} : \Omega \rightarrow \mathcal{H}$ 定义前推测度 $\nu := \mathbf{X} \# \mathbb{Q}$ 。则当每个 ν 值随机变量 $\mathbb{R}$ 对所有 $\langle u, \mathbf{X} \rangle_{\mathcal{H}}$ 均为高斯时，测度 $u \in \mathcal{H}$ 称为高斯测度。此时存在唯一的均值函数 $\mathbf{m} \in \mathcal{H}$ 满足 $\langle \mathbf{m}, u \rangle_{\mathcal{H}} = \mathbb{E}_{\nu}[\langle \mathbf{X}, u \rangle_{\mathcal{H}}]$ ，以及唯一的非负自伴协方差算子 $Q : \mathcal{H} \rightarrow \mathcal{H}$ ，其定义为对所有 $\langle u, Qv \rangle_{\mathcal{H}} = \mathbb{E}_{\nu}[\langle \mathbf{X} - \mathbf{m}, u \rangle_{\mathcal{H}} \langle \mathbf{X} - \mathbf{m}, v \rangle_{\mathcal{H}}]$ 有 $u, v \in \mathcal{H}$ ，其中该算子为迹类算子 i.e., $\text{Tr}(Q) < \infty$ 。记作 $\nu = \mathcal{N}(\mathbf{m}, Q)$ ，并称当 $\mathbf{m} = 0$ 时 $\mathbf{X}$ 为中心化的。现假设 $\mathbf{X}$ 为中心化且分布为 $\mathcal{N}(0, Q)$ 。则存在特征系统 $\{(\lambda^{(k)}, \phi^{(k)}) \in \mathbb{R} \times \mathcal{H} : k \in \mathbb{N}\}$ 使得 $Q\phi^{(k)} = \lambda^{(k)}\phi^{(k)}$ 且 $\text{Tr}(Q) = \sum_{k=1}^{\infty} \langle Q\phi^{(k)}, \phi^{(k)} \rangle_{\mathcal{H}} = \sum_{k=1}^{\infty} \lambda^{(k)} < \infty$ 。

Q-维纳过程与卡梅伦-马丁空间 在无穷维空间中，我们区分两种高斯驱动噪声。设 $\mathcal{U}$ 为具有标准正交基 $\{\phi^{(k)}\}_{k \geq 1}$ 的实可分希尔伯特空间。柱面维纳过程是 $\mathbb{R}$ 值维纳过程的自然推广，其形式级数为 $\mathbf{W}_t = \sum_{k=1}^{\infty} \mathbf{W}_t^{(k)} \phi^{(k)}$ ，其中 $\{\mathbf{W}_t^{(k)}\}_{k \geq 1}$ 为独立布朗运动集合。它满足独立增量 $\mathbf{W}_{t+\Delta t} - \mathbf{W}_t \sim \mathcal{N}(0, \Delta t \mathbf{I}_{\mathcal{U}})$ ，但当 $\dim \mathcal{U} = \infty$ 时协方差 $\mathbf{I}_{\mathcal{U}}$ 不是迹类的。换言之， $\mathcal{N}(0, \Delta t \mathbf{I}_{\mathcal{U}})$ 仅支撑于更大的分布空间中，而非 $\mathcal{U}$ 本身，因此 $\mathbf{W}_t$ 不是 $\mathcal{U}$ 值随机变-

量。此处，我们将 $\mathcal{U}$ 嵌入更大的希尔伯特空间 $\mathcal{H}$ ，并定义希尔伯特-施密特算子 $Q^{1/2} : \mathcal{U} \rightarrow \mathcal{H}$ ，使得 $Q = Q^{1/2}(Q^{1/2})^\dagger$ 在 $\mathcal{H}$ 上为迹类。于是可引入如下 $\mathcal{H}$ 值协变噪声过程：

$$\mathbf{W}_t^Q := Q^{1/2} \mathbf{W}_t = \sum_{k=1}^{\infty} \sqrt{\lambda^{(k)}} \mathbf{W}_t^{(k)} \phi^{(k)} \in \mathcal{H}, \quad (1)$$

其中 $\lambda^{(k)}$ 为 Q 的特征值。因此，我们得到 $\mathbf{W}_{t+\Delta t}^Q - \mathbf{W}_t^Q \sim \mathcal{N}(0, \Delta t Q)$ ，其中迹类算子 Q 。我们称 $\mathbf{W}_t^Q$ 为 Q -维纳过程，它现在是 $\mathcal{H}$ 值随机变量。此处，我们将 $\mathcal{H}$ 的嵌入子空间 $\mathcal{U}$ 称为 Q 的卡梅伦-马丁空间，其范数定义为：

$$\langle u, v \rangle_{\mathcal{U}} = \langle Q^{-1/2} u, Q^{-1/2} v \rangle_{\mathcal{H}}, \quad \forall u, v \in \mathcal{U}. \quad (2)$$

无穷维随机微分方程 利用 (1) 中定义的无穷维维纳过程，我们引入如下无穷维随机微分方程 (Da Prato 和 Zabczyk, 2014)：

$$d\mathbf{X}_t = A\mathbf{X}_t dt + \sigma_t d\mathbf{W}_t^Q, \quad \mathbf{X}_0 = \mathbf{x}_0 \in \mathcal{H}, \quad (3)$$

其中 $A : \mathcal{H} \rightarrow \mathcal{H}$ 为线性算子， $\sigma_t : \mathbb{R}_{>0} \rightarrow \mathbb{R}_{>0}$ 为噪声调度。在定理 B.1 的温和条件下，(3) 中的动力学生成奥恩斯坦-乌伦贝克 C_0 半群 (Da Prato 和 Zabczyk, 2002)，并存在唯一温和解。所得随机过程 $\{\mathbf{X}_t\}_{t \geq 0}$ 为具有迹类协方差算子的 $\mathcal{H}$ 值高斯过程：

$$\mathbf{X}_t \sim \nu_t^{\mathbf{x}_0} := \mathcal{N}(e^{tA} \mathbf{x}_0, Q_t), \quad (4)$$

where $Q_t = \int_0^t e^{(t-s)A} \sigma_s^2 Q e^{(t-s)A^\dagger} ds \quad t \rightarrow \infty$,

最后，随着 $\mathbf{X}_\infty$ 的定律收敛到高斯不变定律

$$\nu_\infty = \mathcal{N}(0, Q_\infty), \text{ 与 } Q_\infty = -\frac{1}{2} \sigma_\infty A^{-1} Q \quad (5)$$

3. 函数伴随采样器

在本节中，我们提出一种可扩展的扩散采样器，它直接在无限维希尔伯特空间中运行，针对函数分布进行采样。完整的证明和必要的推导在 B 节中提供。

3.1. 函数空间中的非平衡采样

从吉布斯分布中采样是一项基本任务。目标是从仅通过未归一化能量 $U : \mathcal{H} \rightarrow \mathbb{R}$ 已知的目标分布 π 中抽取样本：

$$d\pi(\mathbf{x}) = \frac{1}{\mathcal{Z}} e^{-U(\mathbf{x})} d\nu(\mathbf{x}), \quad \mathcal{Z} = \int_{\mathcal{H}} e^{-U(\mathbf{x})} d\nu(\mathbf{x}), \quad (6)$$

其中 ν 是定义在某个空间 $\mathcal{H}$ 上的测度。在有限维中，*e.g.*, $\mathcal{H} = \mathbb{R}^d$ ，吉布斯密度可以相对于勒贝格测度 *i.e.*, $d\pi(\mathbf{x}) \propto e^{-U(\mathbf{x})} d\mathbf{x}$ 来表示。

然而，由于希尔伯特空间缺乏勒贝格测度的等价表述，式 (6) 中的表达式只有在指定适当的参考测度 ν 之后才有意义。以下引理给出了目标定律在任意希尔伯特空间上良定义的条件。

引理 1 (有限归一化常数)。假设 $U(\mathbf{x}) \geq \beta \|\mathbf{x}\|_{\mathcal{H}}^2 - C$ 且常数为 $\beta, C > 0$ 。那么，对于任意 $\text{Tr}(Q) < \infty$ ，在 (6) 中选择 $\nu = \mathcal{N}(0, Q)$ 会得到有限的归一化常数 $\mathcal{Z} < \infty$ 。

由引理 1，我们得到参考测度 ν 的一个简单而有效的选择，即具有迹类协方差 Q 的中心高斯测度 $\mathcal{N}(0, Q)$ 。这确保了 $\mathcal{Z} < \infty$ ，因此 (6) 中的目标 π 在 $\mathcal{H}$ 上有良好定义。

为了在 $\mathcal{H}$ 上采样 (6)，自然考虑一个 $\mathcal{H}$ 值随机过程，它遵循 U 的梯度流 (Da Prato 等, 1996; Bréhier, 2017; Suzuki, 2020) ——与有限维过阻尼朗之万动力学精神一致。具体地，可以考虑

$$d\mathbf{X}_t = [A\mathbf{X}_t - Q D_{\mathbf{x}} U(\mathbf{x})] dt + \sigma_t d\mathbf{W}_t^Q, \quad (7)$$

当 $\sigma_t := \sigma$ 时，动力学 (7) 向目标测度 (6) 的收敛得到保证，并且通过对 $\mathcal{H}$ 值动力学进行时空离散化的直接仿真是标准的 (Bréhier, 2017)。然而，所得链的实际用途有限，因为混合仅在平衡附近有效，这依赖于对 (5) 中定义的不变参考测度 ν_∞ 的渐近收敛，而该参考测度是良好定义的归一化常数 $\mathcal{Z}$ 所必需的。

非平衡采样 (NES) 因此，为了在有限时间范围 $T < \infty$ ，内达到目标分布 (6)，我们将采样问题重新表述为 NES 问题。与 (7) 中的朗之万型过程不同，后者仅在平衡时渐近逼近目标，参考为 ν_∞ ，我们采用通过测度变换的重要性采样 (IS)，以在有限时间内高效地采样目标：

$$\begin{aligned} d\pi(\mathbf{x}) &\propto e^{-U(\mathbf{x})} \frac{d\nu_\infty(\mathbf{x})}{d\nu_T^{\mathbf{x}_0}(\mathbf{x})} d\nu_T^{\mathbf{x}_0}(\mathbf{x}) \\ &= e^{-U(\mathbf{x}) - \log \frac{d\nu_T^{\mathbf{x}_0}(\mathbf{x})}{d\nu_\infty(\mathbf{x})}} d\nu_T^{\mathbf{x}_0}(\mathbf{x}), \end{aligned} \quad (8)$$

其中 $\nu_T^{\mathbf{x}_0}$ 是参考动力学 (3) 在时刻 T 的边缘律。因此，对于无限维中的 NES，我们需要在重要性权重中加入一个额外的修正项，该修正项由 Radon-Nikodým 导数 (RND) 给出。它修正了两个高斯测度之间的不匹配，使得在重新加权后，从 $\nu_T^{\mathbf{x}_0}$ 抽取的样本具有期望的目标 π ，同时保证 π 是良定义的。然而，与有限维情形相比，无限维 RND 仅当两个测度完全相容时才存在，因为缺少 Lebesgue 测度。

在那种狭窄的相容性之外，测度是奇异的，无法写出密度。幸运的是，我们可以在由 (3) 生成的 Ornstein – Uhlenbeck 半群下推导出 RND。于是， $\nu_T^{\mathbf{x}_0}$ 和 ν_∞ 成为相互绝对连续的高斯测度 (Da Prato 和 Zabczyk, 2002)：

定理 2 (显式 RND)。设定理 B.1 成立。则对于任意 $0 < t < \infty$ 和初始条件 $\mathbf{x}_0 \in \mathcal{H}$ ， $\nu_t^{\mathbf{x}_0} = \mathcal{N}(e^{tA}\mathbf{x}_0, Q_t)$ 与 $\nu_\infty = \mathcal{N}(0, Q_\infty)$ 是相互绝对连续的。此外，对于任意 $\mathbf{x} \in \mathcal{H}$ ，我们得到如下定义的显式 RND

$$q_t(\mathbf{x}_0, \mathbf{x}) := \frac{d\nu_t^{\mathbf{x}_0}}{d\nu_\infty}(\mathbf{x}) :$$

$$q_t(\mathbf{x}_0, \mathbf{x}) = \det(\Theta_t)^{-\frac{1}{2}} \exp \left[-\frac{1}{2} \langle \Theta_t^{-1} \mathbf{m}_t^{\mathbf{x}_0}, \mathbf{m}_t^{\mathbf{x}_0} \rangle_\infty + \langle \Theta_t^{-1} \mathbf{m}_t^{\mathbf{x}_0}, \mathbf{x} \rangle_\infty - \frac{1}{2} \langle e^{2tA} \Theta_t^{-1} \mathbf{x}, \mathbf{x} \rangle_\infty \right], \quad (9)$$

where we define $\mathbf{m}_t^{\mathbf{x}_0} = e^{tA}\mathbf{x}_0$, $\Theta_t = 1 - e^{2tA}$ and Q_∞ norm $\langle u, v \rangle_\infty := \langle Q_\infty^{-\frac{1}{2}} u, Q_\infty^{-\frac{1}{2}} v \rangle_{\mathcal{H}}$.

定理 2 给出了显式 RND，因此原则上 IS 可以从 (6) 中的 π 生成样本。然而，在实践中，重要性权重是在有限维离散化上计算的，当离散化被细化时，所需样本数量随离散化程度呈指数增长。因此，IS 可能变得不切实际。

3.2. 无限维随机最优控制

受扩散采样器最新进展的启发 (Zhang 和 Chen, 2022; Vargas 等人, 2023; Berner 等人, 2024; Liu 等人, 2025; Choi 等人, 2025)，我们将 NES 问题重新表述为路径空间 $\Omega = C([0, T], \mathcal{H})$ 上的变分推断问题，通过引入可学习的控制来引导过程 (3) 在有限时间范围 $T < \infty$ 内到达 π ，从而构建高效的采样器。让我们引入目标路径测度 $\mathbb{P}^*$ ，它是 (6) 中目标 π 到 Ω 的扩展：

$$d\mathbb{P}^*(\mathbf{X}) \propto e^{-U(\mathbf{X}_T) - \log q_T(\mathbf{x}_0, \mathbf{X}_T)} d\mathbb{P}(\mathbf{X}), \quad (10)$$

其中 $\mathbb{P}$ 是由 (3) 中的过程诱导的路径测度。现在，我们考虑由带控制的无限维 SDE 诱导的变分路径测度 $\mathbb{P}^{\alpha}$ (Fabbri 等人, 2017)：

$$d\mathbf{X}_t^\alpha = [\mathcal{A}\mathbf{X}_t^\alpha + \sigma_t Q^{1/2} \alpha(\mathbf{X}_t^\alpha, t)] dt + \sigma_t d\mathbf{W}_t^Q \quad (11)$$

其中 $\alpha(\cdot) : \mathcal{H} \times [0, T] \rightarrow \mathcal{U}$ 是无限维马尔可夫控制。研究这种路径测度公式的主要原因是，(6) 中的 Gibbs 型目标分布 π 可以通过在 (11) 中选择最优控制 α_t^* 来有效诱导。通过调用广义 Girsanov 定理 (Da Prato 和 Zabczyk, 2014,

定理 10.14)，此类最优控制可通过求解以下无穷维优化问题得到 (Fuhrman, 2003; Theodorou et al., 2018)：

$$\min_{\alpha} \mathbb{E}_{\mathbb{P}^\alpha} \left[\int_0^T \frac{1}{2} \|Q^{1/2} \alpha_s\|_{\mathcal{U}}^2 ds + g(\mathbf{X}_T^\alpha) \right] \text{ s.t. (11),} \quad (12)$$

where $g(\mathbf{x}) = U(\mathbf{x}) + \log q_T(\mathbf{x}_0, \mathbf{x})$. Accordingly, the 最优控制 α_t^* 最小化 (11) 中的目标等价于与目标路径测度 $\mathbb{P}^*$ 的 Kullback-Liebler 发散

i.e., $\alpha^* = \min_{\alpha} D_{\text{KL}}(\mathbb{P}^\alpha | \mathbb{P}^*)$ 的最小化子

在 (10) 中。换言之，该公式使我们能够在有限时间 $T < \infty$ 内从目标 π 精确采样，即 $\mathbf{X}_T^{\alpha^*} \sim \pi$ 。这成功地将 (Tzen and Raginsky, 2019; Zhang and Chen, 2022) 中发现的有限维基于控制的 NES 扩展到了 Hilbert 空间 $\mathcal{H}$ 。

3.3. 无穷维伴随匹配

(12) 中的 SOC 问题遵循路径空间中的最小作用量原理，其目标是找到全局最优控制，在最小化终端代价 $g(\mathbf{x})$ 的同时最小化作用量。在实践中，通过直接的路径最小化来求解该全局问题代价高昂，因为每次更新都需要通过完整轨迹的梯度 (Havens et al., 2025)。一种实用的替代方案是转向对偶公式。伴随匹配 (AM; Domingo-Enrich et al., 2025) 通过将全局 SOC 问题重新表述为局部匹配问题，提供了一条可扩展的途径。

将 AM 扩展到无穷维需要对出现在相应无穷维 SOC 公式中的一阶伴随过程进行严格定义。下面，我们将证明 SOC 中一个称为随机最大值原理 (SMP; Bensoussan, 1983) 的特定数学概念通过耦合的正倒向随机微分方程 (FBSDEs; Du and Meng, 2013) 系统提供了伴随过程的存在性和唯一性，并给出了一个必要条件。

引理 3 (随机最大值原理)。考虑一般无穷维 SOC 问题：

$$\min_{\alpha \in \mathcal{A}} \mathbb{E}_{\mathbb{P}^\alpha} \left[\int_0^T l(t, \mathbf{X}_t^\alpha, \alpha_t) ds + h(\mathbf{X}_T^\alpha) \right], \quad (13)$$

$$\text{s.t. } d\mathbf{X}_t^\alpha = [\mathcal{A}\mathbf{X}_t^\alpha + f(t, \mathbf{X}_t^\alpha, \alpha_t)] dt + g(t, \mathbf{X}_t^\alpha) d\mathbf{W}_t^Q.$$

在固定初始条件 $\mathbf{X}_0^\alpha = \mathbf{x}_0$ 下。现在，令假设 B.1-B.2 成立，并定义哈密顿泛函

$$H : [0, T] \times \mathcal{H} \times \mathcal{H} \times \mathcal{H} \times \mathcal{H} \rightarrow \mathbb{R} :$$

$$H(t, \mathbf{X}, \alpha, \mathbf{Y}, \mathbf{Z}) := l(t, \mathbf{X}, \alpha) + \langle \mathbf{Y}, f(t, \mathbf{X}, \alpha) \rangle_{\mathcal{H}} + \langle \mathbf{Z}, g(t, \mathbf{X}) \rangle_{\mathcal{H}}. \quad (14)$$

假设 $\mathbf{X}^*$ 是由最优控制 α^* 驱动的最优受控过程。那么，以下一阶伴随无穷维倒向随机微分方程 (Backward SDE) 存在唯一解：

$$d\mathbf{Y}_t^* = -[\mathcal{A}^\dagger \mathbf{Y}_t^* + D_{\mathbf{x}} H(t, \mathbf{X}_t^*, \alpha_t^*, \mathbf{Y}_t^*, \mathbf{Z}_t^*)] dt + \mathbf{Z}_t^* d\mathbf{W}_t^Q, \quad \mathbf{Y}_T^* = D_{\mathbf{x}} h(\mathbf{X}_T^*) \quad (15)$$

此外，我们得到最优控制的必要条件
 $\alpha_t^* = \arg \min_{\alpha \in \mathbb{A}} H(t, \mathbf{X}_t^*, \alpha, \mathbf{Y}_t^*, \mathbf{Z}_t^*).$

引理 3 表明，对于一般随机最优控制 (SOC) 问题 (13)，存在一阶伴随对 $(\mathbf{Y}_t, \mathbf{Z}_t)$ ，满足 (15) 中的倒向随机微分方程。该结果提供了最优性的必要条件：任何违反 (15) 中倒向 BSDE 或对所有 $t \in [0, T]$ 不满足哈密顿量逐点最小化的控制，都不可能是最优控制。

换言之，随机最大值原理 (SMP) 提供了由相应哈密顿量 H ，确定的逐点最优性条件，使得最优控制 α_t^* 可以局部计算，而非逐路径计算。这一原理是有效的，因为求解 (12) 中的逐路径最小化通常在计算上不可行。基于这一局部刻画，我们现在根据 SMP 为无穷维 SOC 问题 (12) 推导合适的训练目标。将引理 3 应用于 (12) 中的 SOC 问题，相应的哈密顿量 H 定义为：

$$H(t, \mathbf{X}_t^{\bar{\alpha}}, \bar{\alpha}_t, \mathbf{Y}_t^{\bar{\alpha}}, \mathbf{Z}_t^{\bar{\alpha}}) := \frac{1}{2} \|\bar{\alpha}_t\|_{\mathcal{H}}^2 + \langle \mathbf{Y}_t^{\bar{\alpha}}, \sigma_t Q^{1/2} \bar{\alpha}_t \rangle_{\mathcal{H}} + \langle \mathbf{Z}_t^{\bar{\alpha}}, \sigma_t Q^{1/2} \rangle_{\mathcal{H}}, \quad (16)$$

在固定状态-控制对 $(\mathbf{X}^{\bar{\alpha}}, \bar{\alpha})$ 下。注意，(16) 中的哈密顿量 H 关于控制 $\bar{\alpha}_t$ ，是凸的，因此任何临界点都是全局最小值。这意味着，如果 $(\mathbf{X}^{\bar{\alpha}}, \bar{\alpha})$ 满足 (15) 中的倒向随机微分方程，则最优控制由 H 的一阶驻点条件刻画：

$$\begin{aligned} \nabla_{\alpha} H(t, \mathbf{X}_t^{\bar{\alpha}}, \alpha_t, \mathbf{Y}_t^{\bar{\alpha}}, \mathbf{Z}_t^{\bar{\alpha}}) &= \alpha_t + \langle \mathbf{Y}_t^{\bar{\alpha}}, \sigma_t Q^{1/2} \rangle_{\mathcal{H}} \quad (17) \\ &= \nabla_{\alpha} \frac{1}{2} \left\| \alpha_t + \sigma_t Q^{1/2} \mathbf{Y}_t^{\bar{\alpha}} \right\|_{\mathcal{H}}^2. \end{aligned}$$

由此可知，在状态变量 $(\mathbf{X}_t^{\bar{\alpha}}, \mathbf{Y}_t^{\bar{\alpha}}, \mathbf{Z}_t^{\bar{\alpha}})$ re- 对所选控制 $\bar{\alpha}_t$ 保持固定的情况下，对 α_t 的最小化归结为 (17) 中的凸二次型，其唯一极小值为 $\alpha_t = -\sigma_t Q^{1/2} \mathbf{Y}_t^{\bar{\alpha}}$ 。利用这一观察，我们现在陈述主要结果：

命题 4 (在 $\mathcal{H}$ 中的伴随匹配)
 考虑以下无限维匹配目标：

$$\mathcal{L}(\theta) = \int_0^T \mathbb{E}_{\mathbb{P}^{\bar{\alpha}}} \left[\frac{1}{2} \left\| \alpha^{\theta}(\mathbf{X}_t^{\bar{\alpha}}, t) + \sigma_t Q^{1/2} \mathbf{Y}_t^{\bar{\alpha}} \right\|_{\mathcal{H}}^2 \right] dt \quad (18)$$

$$d\mathbf{Y}_t^{\bar{\alpha}} = -\mathcal{A}^{\dagger} \mathbf{Y}_t^{\bar{\alpha}} dt + \mathbf{Z}_t^{\bar{\alpha}} d\mathbf{W}_t^Q, \quad \mathbf{Y}_T^{\bar{\alpha}} = D_{\mathbf{x}} g(\mathbf{X}_T^{\bar{\alpha}}). \quad (19)$$

其中 $\bar{\alpha} :=$ 停止梯度 (α^{θ}) 。则 $\mathcal{L}$ 的临界点即为 (12) 中随机最优控制问题的最优控制 α^* 。

与原始随机最优控制问题 (12) 相比，基于随机最大值原理的匹配目标 (18) 本质上具有可扩展性，因为它可以避免路径级反向传播，并将训练简化为在 $\mathbf{X}_t^{\bar{\alpha}}$ 固定条件下的逐点凸最小化。这种局部结构使得在时间维度上易于并行化。注意，当 $\mathcal{H} := \mathbb{R}^d$ 且 $Q = \mathbf{I}_d$ 时，

(18) 中的目标函数恢复了 (Domingo-Enrich et al., 2025) 中的精简伴随匹配目标。换言之，我们的公式将伴随匹配严格推广到了希尔伯特空间。

然而，对于 (18) 中的 $\mathcal{L}$ ，随机项 $\mathbf{Z}_t^{\bar{\alpha}}$ 可能带来计算负担，因为该项需要模拟 (19) 中的倒向随机微分方程以获得解 $\mathbf{Y}_t^{\bar{\alpha}}$ ，这显著增加了每一步优化的成本。由于该倒向随机微分方程适应于由同一 Q -维纳过程 $\mathbf{W}_t^Q$ 生成的滤子，我们将伴随过程 $\mathbf{Y}_t^{\bar{\alpha}}$ 替换为其条件期望 $\mathbb{E}_{\mathbb{P}^{\bar{\alpha}}}[\mathbf{Y}_t^{\bar{\alpha}} | \mathbf{X}_t^{\bar{\alpha}}]$ 。

命题 5 (无偏估计量)。定义具有条件期望的样本级伴随匹配目标

$$\tilde{\mathbf{Y}}_t^{\bar{\alpha}} := \mathbb{E}_{\mathbb{P}^{\bar{\alpha}}}[\mathbf{Y}_t^{\bar{\alpha}} | \mathbf{X}_t^{\bar{\alpha}}] \text{ 对于任意样本轨迹 } \mathbf{X}_t^{\bar{\alpha}} \sim \mathbb{P}^{\bar{\alpha}}.$$

$$\tilde{\mathcal{L}}(\theta) := \int_0^T \frac{1}{2} \left\| \alpha^{\theta}(\mathbf{X}_t^{\bar{\alpha}}, t) + \sigma_t Q^{1/2} \tilde{\mathbf{Y}}_t^{\bar{\alpha}} \right\|_{\mathcal{H}}^2 dt \quad (20)$$

然后，我们得到无偏梯度估计器 $d_{\theta} \mathbb{E}_{\mathbb{P}^{\bar{\alpha}}}[\tilde{\mathcal{L}}(\theta)] = \frac{d}{d\theta} \mathcal{L}(\theta)$ ，在 (18) 中具有相同的临界点

在实践中，我们可以从仿真 $\mathbf{X}_T^{\bar{\alpha}}$ 过程中保存的轨迹来估计 $\tilde{\mathbf{Y}}_t^{\bar{\alpha}}$ ，以实现高效计算。这为 (12) 中的 SOC 问题保留了相同的临界点 α^* ，同时由于替换产生了 BSDE 的闭式解而减轻了计算负担：

$$\begin{aligned} \tilde{\mathbf{Y}}_t^{\bar{\alpha}} &= \mathbb{E}_{\mathbb{P}^{\bar{\alpha}}}[\mathbf{Y}_T^{\bar{\alpha}} | \mathbf{X}_t^{\bar{\alpha}}] = e^{-(T-t)\mathcal{A}^{\dagger}} \mathbb{E}_{\mathbb{P}^{\bar{\alpha}}}[D_{\mathbf{x}} g(\mathbf{X}_T^{\bar{\alpha}}) | \mathbf{X}_t^{\bar{\alpha}}] \\ &\approx e^{-(T-t)\mathcal{A}^{\dagger}} D_{\mathbf{x}} g(\mathbf{X}_T^{\bar{\alpha}}). \end{aligned} \quad (21)$$

最后，由于 (6) 中的最优路径测度 $\mathbb{P}^*$ 允许 $\mathbb{P}^*(\mathbf{X}_t) = \mathbb{P}^*(\mathbf{X}_T) \mathbb{P}_{t|T}(\mathbf{X}_t | \mathbf{X}_T)$ ；端点分解 详见 B.7 节。将这些关系代入 (18) 得到我们提出的用于函数空间中高效且可扩展采样的训练目标：

$$\mathcal{L}_{\text{FAS}} = \int_0^T \mathbb{E}_{\mathbb{P}_{t|T} \mathbb{P}_T^{\bar{\alpha}}} \left[\frac{1}{2} \left\| \alpha^{\theta}(\mathbf{X}_t, t) + \sigma_t D_{\mathbf{x}} g(\mathbf{X}_T^{\bar{\alpha}}) \right\|_{\mathcal{H}}^2 \right] dt, \quad (22)$$

其中 $\mathcal{C}_t := \sigma_t Q^{1/2} e^{-(T-t)\mathcal{A}^{\dagger}}$ 注意，由当前控制 $\bar{\alpha}$ 诱导的路径测度 $\mathbb{P}^{\bar{\alpha}}$ 可能不满足端点分解。在这种情况下，我们可以将路径测度投影到确实满足分解的条件路径测度 (Havens 等人, 2025)。

3.4. 数值计算

由于 FAS 在无限维路径空间上运行，训练和采样都需要适当的离散化和仿真方案。它需要定义指定算子 $\mathcal{A}$ 和 Q ，这也是反映给定任务领域结构的关键建模选择。对于 NES，我们采用定理 B.1，确保参考动力学适定，并在定理 2 中产生显式 RND。因此，我们限制在特定类别的算子 $(\mathcal{A}, Q)$ 。

命题 6 (拉普拉斯算子)。对于有界域上具有狄利克雷边界条件的负拉普拉斯算子 $\mathcal{A} = -\Delta$ ，取 $Q = \mathcal{A}^{-s}$ ，其中 $s > \frac{d}{2}$ ， A and Q satisfies the Theorem B.1.

2. 然后，

边界条件 由于拉普拉斯算子 (Laplacian) Δ admits 在不同边界条件 (BCs) 下有不同的实现 (Evans, 2022)，本研究仅限于狄利克雷边界条件。虽然诺伊曼边界条件在其他领域很常见 (Rissanen et al., 2023; Lim et al., 2023b; Park et al., 2024)，但我们的目标是条件路径采样，其中狄利克雷边界条件是自然的，因为它固定了边界值。例如，在 TPS 中，当亚稳态 $\mathbf{A}$ 和 $\mathbf{B}$ 作为路径 $\mathbf{X}_t[\cdot] : \mathbb{R}_{0>} \rightarrow \mathbb{R}^d$ 的边界条件 *i.e.*, $\mathbf{X}_t[0] = \mathbf{A}, \mathbf{X}_t[L] = \mathbf{B}$ 被固定时，它们之间的过渡路径才有意义，对于所有 $t \in [0, T]$ 。我们在附录 C.1 中详细说明了为 TPS 施加边界条件的细节。

数值仿真 模拟无限维随机微分方程是一个研究成熟的领域 (Lord et al., 2014)。由于通常需要有限维近似，我们采用伽辽金截断方案 (Shardlow, 1999)，通过用 $|K|$ 个基函数 $\{\phi^{(k)}\}_{k=1}^K$ 来近似函数：

$$\mathbf{X}_t \approx \sum_{k=1}^K \mathbf{X}_t^{(k)} \phi^{(k)}, \text{ 与 } \mathbf{X}_t^{(k)} := \langle \mathbf{X}_t, \phi^{(k)} \rangle_{\mathcal{H}} = \int_0^L \mathbf{X}_t[u] \phi^{(k)}[u] du. \quad (23)$$

因此，利用狄利克雷拉普拉斯算子 Δ 的有限特征系统 $\{(\lambda^{(k)}, \phi^{(k)}) \in \mathbb{R} \times \mathcal{H} : k \in [1, \dots, K]\}$ ， $\mathcal{H}$ 值受控随机微分方程 (3) 简化为 $|K|$ 维系数随机微分方程：

$$d\mathbf{X}_t^{(k)} = \left[-\lambda^{(k)} \mathbf{X}_t^{(k)} + \sigma_t(\lambda^{(k)})^{-s/2} \langle \alpha(\mathbf{X}_t, t), \phi^{(k)} \rangle_{\mathcal{H}} \right] dt + \sigma_t(\lambda^{(k)})^{-s/2} d\mathbf{W}_t^{(k)}, \quad (24)$$

$\mathbf{W}_t^{(k)}$ 其中是标准维纳过程。特别地，由于 (24) 是一个有限维的模式对角系统，我们可以用任何标准的数值随机微分方程积分器来模拟每个模式。值得注意的是，特征系统 $\{(\lambda^{(k)}, \phi^{(k)}) \in \mathbb{R} \times \mathcal{H} : k = 1, \dots, K\}$ 取决于拉普拉斯算子 Δ 的选择。在这项工作中，我们选择一个满足命题 6 的特征系统，以确保在一维域 ($u \in [0, L]$) 上我们的 TPS 理论的适定动力学。其他参数化策略可以应用于不同的域，如图像或偏微分方程生成 (矩形域) 或分子构象 (图域)，如附录 C.2 中所讨论的。

4. 相关工作

我们在第 A.3 节简要介绍过渡路径采样及相关工作。

无限维生成模型 许多近期工作将有限维生成模型扩展到无限维函数空间。基于分数的扩散模型 (Song et al., 2021) 已被扩展到函数空间 (Lim et al., 2023a;b; Pidstrigach et al., 2023; Franzese et al., 2024)。随后，基于匹配的生成模型也沿相同方向发展。例如，流匹配 (Lipman et al., 2023) 已被推广到函数空间 (Kerrigan et al., 2024)，薛定谔桥匹配 (Shi et al., 2024) 也已被适配 (Park et al., 2024)。然而，这些算法在样本到样本的设置下运行，其中来自两个分布的配对样本可用于训练。据我们所知，针对样本到能量 (例如从 (6) 中的吉布斯分布 $\pi(\mathbf{x}) \propto e^{-U(\mathbf{x})}$ 进行目标采样) 的可扩展函数空间生成建模，尚未被研究。

扩散采样器 扩散采样器解决样本到能量设置，其目标是从吉布斯分布 $\pi(\mathbf{x}) \propto e^{-U(\mathbf{x})}$ 中抽取样本。基于随机最优控制 (SOC) 理论，这一研究方向将采样重新表述为优化问题，学习此类采样器的方法已迅速发展 (Zhang 和 Chen, 2022; Vargas 等, 2023; Berner 等, 2024)。由于目标仅通过可能复杂的能量泛函 U 指定，优化往往计算量大。这一挑战推动了基于伴随方法的采样器 (Havens 等, 2025; Liu 等, 2025)，它们避免了基于仿真的目标，并产生比普通 SOC 方法更具可扩展性的方法。现有方法仅限于有限维设置，尽管函数空间扩展具有吸引力和实际重要性，但仍未被探索。

5. 实验

5.1. 实验设置

我们在三个过渡路径采样 (TPS) 基准上评估 FAS。首先使用一个合成势能，然后转向两个分子系统。对于合成情况，遵循 (Du 等, 2024)，我们使用标准 TPS 基准——Müller-Brown 势能。对于分子系统，我们考虑丙氨酸二肽和 chignolin，分别在三维空间中包含 22 和 138 个原子。所有分子模拟均使用笛卡尔坐标，我们使用 OpenMM (Eastman 等, 2023) 计算势能。更多实验细节见第 C 节。

基线与评估 本文将 FAS 与以下方法进行比较：高温下的无偏分子动力学 (UMD)、对选定集体变量施加力的引导分子动力学

(SMD)，以及

表 1: 合成势能上的比较。本文报告 64 条路径上的平均度量。最佳结果已高亮显示。

Methods	THP (% $\uparrow$)	ETS ($\downarrow$)	LLK ($\uparrow$)
MCMC	-	-13.77 ± 16.43	-
DL (Du et al., 2024)	82	-14.93 ± 12.61	10.42 ± 0.42
FAS (Ours)	100	-36.70 ± 3.09	11.48 ± 0.05




图 1: 合成势能的 TPS。能量景观上的采样过渡路径。

深度学习方法 PIPS (Holdijk 等, 2022)、TPS-DPS (Seong 等, 2025)、TR-LV (Blessing 等, 2025) 和 DL (Du 等, 2024)。注意 DL 使用不同的训练环境, 因此本文仅在合成基准上报告其结果。本文采用捕捉可靠性和概率保真度的度量进行评估。具体而言, 过渡命中概率 (THP) 捕捉在终止时刻到达目标过渡态 **B** 的轨迹比例, 而过渡态能量 (ETS) 是路径上的最大势能。在合成势能上, 本文遵循 (Du 等, 2024) 并额外报告 (25) 中定义的过渡路径分布 (TPD) 的对数似然

(LLK)。

能量 我们采用 (Holdijk 等人, 2022; Du 等人, 2024) 中描述的 TPD 来处理 Müller-Brown 势:

$$\mathbb{P}(\mathbf{X}) = \mathbf{1}_A(\mathbf{X}[0])\mathbf{1}_B(\mathbf{X}[L]) \quad (25)$$

$$\prod_{u=0}^{L-1} \mathcal{N}(\mathbf{X}[N+1]|\mathbf{X}[N] - \frac{1}{\gamma\mathbf{m}}\nabla_{\mathbf{X}}V(\mathbf{X}[u])\delta_u, \frac{2k_B T}{\gamma\mathbf{m}}\mathbf{I}_{3N}\delta_u),$$

其中 $\mathbf{1}_A$ 和 $\mathbf{1}_B$ 均为指示函数, V 为势函数。对于分子系统, 我们观察到 (25) 中的 TPS 由于依赖局部势梯度而导致训练不稳定。因此, 我们基于 **Feynman-Kac** 公式 (Del Moral, 2011) 推导出一种 TPD, 消除了对局部梯度的依赖:

$$\mathbb{P}(\mathbf{X}) = \mathbf{1}_A(\mathbf{X}[0])\mathbf{1}_B(\mathbf{X}[L]) \quad (26)$$

$$\prod_{u=0}^{L-1} e^{-\frac{1}{k_B T}V(\mathbf{X}[u])} \mathcal{N}(\mathbf{X}[u+1]|\mathbf{X}[u], \frac{2k_B T}{\gamma\mathbf{m}}\mathbf{I}_{3N}\delta_u).$$

关于 TPD 选择的进一步讨论见附录 A.6。




图 2: 丙氨酸二肽上的 TPS。(a) 采样的过渡路径投影到作为 CV 函数的构象景观上。分隔两个亚稳态的鞍点表示为 $\star$, 从 FAS 采样的路径上的最高能量表示为 $\bullet$ 。(b) 势能图。灰色框突出显示了路径达到 ETS 的过渡态区域。(c) 给定亚稳态 C5 (最左) 和 C7ax (最右) 的构象可视化。

5.2. 实验结果

Müller-Brown 势 表 1 报告了合成 Müller-Brown 势上的结果, 目标是采样连接左上和右下最小值的路径。FAS 获得了比基线更低的 ETS 和更高的 LLK, 表明其产生的可靠路径保持在低能量谷中, 如图 1 所示, 且方差较小。

丙氨酸二肽 我们在丙氨酸二肽 (一种具有两个丙氨酸残基的肽) 上评估 FAS, 目标是亚稳态 C5 和 C7ax 之间的转变。我们使用扭转角 ϕ 和 ψ 作为来自原子坐标的集体变量 (CV)。表 2 总结了丙氨酸二肽的结果。值得注意的是, 我们的函数空间方法由于 Dirichlet 边界公式在构造上强制了这些端点, 因此实现了完美的 THP 和零 RMSD。完美的 THP 意味着所有采样的路径都是反应性的, 这最大化了计算利用率, 并防止了转变速率和机制估计中的偏差, 从而降低了路径统计的方差。此外, FAS 还获得了比基线显著更低的 ETS, 表明 FAS 生成的路径是可靠的。

此外, 如图 2a 所示, 这些集体变量上的自由能面呈现出一个具有鞍点的高势垒。可靠的活性路径预期会在此鞍点附近穿越, 因为这是势垒最低的路径。从 FAS 采样的路径中最高能量出现在鞍点附近, 这支持了所采样路径是物理上有意义的过渡路径。图 2c 展示了分子转变的构型可视化。

表 2: 在丙氨酸二肽和 chignolin 的分子过渡路径采样上基线的比较。我们报告了 64 条路径的平均度量。最佳结果已高亮。

Method	Alanine Dipeptide			Chignolin		
	RMSD (Å ↓)	THP (%) ↑	ETS (kJ/mol ↓)	RMSD (Å ↓)	THP (%) ↑	ETS (kJ/mol ↓)
UMD	1.19±0.03	6.25	812.47±148.80	7.23±0.93	1.56	388.17
SMD (Izrailev et al., 1999)	0.56±0.27	54.69	78.40±12.76	0.85±0.24	34.38	179.52±138.87
PIPS (Holdijk et al., 2022)	0.66±0.15	43.75	28.17±10.86	4.66±0.17	0.00	-
TPS-DPS (Seong et al., 2025)	0.47±0.18	39.58±28.13	46.34±10.16	1.06±0.08	25.00±10.69	-189.81±23.01
TR-LV (Blessing et al., 2025)	0.29±0.03	61.25±4.05	49.11±5.84	0.90±0.01	43.95±5.64	-303.98±28.65
FAS (Ours)	0.00±0.00	100.00±0.00	-29.46±3.87	0.00±0.00	100.00±0.00	-360.85±53.71




图 3: Chignolin 上的 TPS。 (a) 势能图。 (b) 从展开态 (最左) 到折叠态 (最右) 的蛋白质折叠轨迹可视化。灰色框突出显示了轨迹达到 ETS 的过渡态区域。

Chignolin 最后, 我们评估了小蛋白 **Chignolin** 折叠动力学的采样。如表 2 所示, FAS 实现了最低的 ETS。由于 **chignolin** 具有更高维且更崎岖的景观, 具有狭窄的折叠漏斗和多个中间体盆地, 基线在丙氨酸二肽上表现出更大的 RMSD 和更低的 THP。依赖梯度驱动或引导更新的基线通常会穿越应变构象。即使在 Kabsch 对齐后, 这也会增大 RMSD, 并降低在时间范围内到达折叠盆地的机会。相比之下, FAS 始终强制执行端点, 并且仅在可接受路径内搜索。这种边界强制执行消除了端点漂移, 并避免了后期校正性拉动。因此, 转变更平滑, 并导致更低的 ETS。我们在图 3b 中展示了折叠动力学的可视化。

表 3: 不同未见离散化水平下的 ETS。Disc 表示生成路径的精细程度, 其中 $\times r$ 将基础离散化数量乘以 r 。

Müller Brown	丙氨酸二肽	Disc	ETS(kJ/mol ↓)	LLK (↑)	Disc
ETS(kJ/mol ↓)					
$\times 1$	-36.70±3.09	11.48±0.05	$\times 1$	-29.46±3.87	
$\times 10$	-38.55±1.41	11.65±0.02	$\times 2$	-28.72±41.52	
$\times 100$	-37.83±3.17	11.72±0.09	$\times 4$	-33.58±35.59	

势能, 丙氨酸二肽在未见离散化上表现出更高的 ETS 变异性, 因为分子势能对构型高度敏感。关于离散化不变性采样和进一步消融研究的更多讨论见第 C.6 节。

5.3. 讨论

离散化不变性采样 无限维公式化使得能够在任意时间离散化下对路径进行推断。表 3 报告了不同分辨率下的 ETS。具体来说, 我们训练 α^θ , 将隐式时间区间 $[0, 1]$ 离散化为 100 个均匀时间步 (记为 $\times 1$), 并在未见过的、更精细的时间离散化 (记为 $\times 2 - 100$) 上进行评估。在两种势能上, FAS 在未见过的分辨率上保持了几乎不变的 ETS, 这表明其行为与离散化无关。特别是, 对于合成的 Müller Brown 势能, 即使分辨率增加 $\times 100$, 其中 $[0, 1]$ 被离散化为 10^4 步, ETS 和 LLK 仍保持稳定。与合成相比

6. 结论

本文提出了泛函数伴随采样器 (Functional Adjoint Sampler, FAS), 一种用于希尔伯特空间上吉布斯型分布的可扩展扩散采样器。FAS 将伴随匹配算法 (Domingo-Enrich 等, 2025; Havens 等, 2025) 推广到无限维希尔伯特空间, 能够对函数表示 (例如在一维时间网格上评估的路径) 进行高效采样, 并在路径采样任务上展现出优越的性能。尽管这些结果令人鼓舞, 本文仅关注一维域。然而, FAS 可以轻松扩展到其他任务, 如偏微分方程生成和基于图的域, 我们将全面的研究留作未来工作。

致谢

作者感谢 Benjamin Kurt Miller、Juno Nam、Yuanqi Du 和 Ricky T. Q. Chen 的有益讨论和意见。

参考文献

- Tara Akhound-Sadeh, Jarrod Rector-Brooks, Avishek Joey Bose, Sarthak Mittal, Pablo Lemos, Cheng-Hao Liu, Marcin Sendera, Siamak Ravanbakhsh, Gauthier Gidel, Yoshua Bengio, et al. Iterated denoising energy matching for sampling from boltzmann densities. *arXiv preprint arXiv:2402.06121*, 2024.
- Jodi E Basner and Steven D Schwartz. How enzyme dynamics helps catalyze a reaction in atomic detail: a transition path sampling study. *Journal of the American Chemical Society*, 127(40):13822–13831, 2005.
- Alain Bensoussan. Stochastic maximum principle for distributed parameter systems. *Journal of the Franklin Institute*, 315(5-6):387–406, 1983.
- Julius Berner, Lorenz Richter, and Karen Ullrich. An optimal control perspective on diffusion-based generative modeling. *Transactions on Machine Learning Research*, 2024. ISSN 2835-8856. URL <https://openreview.net/forum?id=oYIjw37pTP>.
- Alexandros Beskos, Gareth Roberts, Andrew Stuart, and Jochen Voss. Mcmc methods for diffusion bridges. *Stochastics and Dynamics*, 8(03):319–350, 2008.
- Denis Blessing, Julius Berner, Lorenz Richter, Carles Domingo-Enrich, Yuanqi Du, Arash Vahdat, and Gerhard Neumann. Trust region constrained measure transport in path space for stochastic optimal control and inference. *arXiv preprint arXiv:2508.12511*, 2025.
- Peter G Bolhuis, David Chandler, Christoph Dellago, and Phillip L Geissler. Transition path sampling: Throwing ropes over rough mountain passes, in the dark. *Annual review of physical chemistry*, 53(1):291–318, 2002.
- Charles-Edouard Bréhier. Lecture notes: Invariant distributions for parabolic spdes and their numerical approximations. 2017.
- René Carmona. *Lectures on BSDEs, stochastic control, and stochastic differential games with financial applications*. SIAM, 2016.
- Tianrong Chen, Guan-Horng Liu, Molei Tao, and Evangelos Theodorou. Deep momentum multi-marginal schrödinger bridge. *Advances in Neural Information Processing Systems*, 36:57058–57086, 2023.
- Raphaël Chetrite and Hugo Touchette. Nonequilibrium markov processes conditioned on large deviations. In *Annales Henri Poincaré*, volume 16, pages 2005–2057. Springer, 2015.
- Jaemoo Choi, Yongxin Chen, Molei Tao, and Guan-Horng Liu. Non-equilibrium annealed adjoint sampler. *arXiv preprint arXiv:2506.18165*, 2025.
- Nicolas Chopin, Andras Fulop, Jeremy Heng, and Alexandre H. Thiery. Computational doob’s h-transforms for online filtering of discretely observed diffusions, 2023.
- G. Da Prato and J. Zabczyk. Differentiability of the feynman-kac semigroup and a control application. *Atti della Accademia Nazionale dei Lincei. Classe di Scienze Fisiche, Matematiche e Naturali. Rendiconti Lincei. Matematica e Applicazioni*, 8(3):183–188, 10 1997. URL <http://eudml.org/doc/244107>.
- G. Da Prato and J. Zabczyk. *Second Order Partial Differential Equations in Hilbert Spaces*. London Mathematical Society Lecture Note Series. Cambridge University Press, 2002. ISBN 9780521777292. URL <https://books.google.co.kr/books?id=TUUt-SAYofVMC>.
- G. Da Prato and J. Zabczyk. *Stochastic Equations in Infinite Dimensions*. Encyclopedia of Mathematics and its Applications. Cambridge University Press, 2014. ISBN 9781107055841. URL <https://books.google.co.kr/books?id=bxkmAwAAQBAJ>.
- G. Da Prato, J. Zabczyk, P.J. Zabczyk, J.W.S. Cassels, and S.P.G.N.J. Hitchin. *Ergodicity for Infinite Dimensional Systems*. Cambridge Monographs on Particle Physics, Nuclear Physics and Cosmology. Cambridge University Press, 1996. ISBN 9781107362499. URL <https://books.google.co.kr/books?id=gEe2oQEACAAJ>.
- P. Del Moral. *Feynman-Kac Formulae: Genealogical and Interacting Particle Systems with Applications*. Probability and Its Applications. Springer New York, 2011. ISBN 9781441919021. URL <https://books.google.co.kr/books?id=JN9NcgAACAAJ>.
- Christoph Dellago, Peter G Bolhuis, Félix S Csajka, and David Chandler. Transition path sampling and the calculation of rate constants. *The Journal of chemical physics*, 108(5):1964–1977, 1998.
- Christopher M Dobson. Protein folding and misfolding. *Nature*, 426(6968):884–890, 2003.
- Carles Domingo-Enrich, Michal Drozdal, Brian Karrer, and Ricky T. Q. Chen. Adjoint matching: Fine-tuning

- flow and diffusion generative models with memory-less stochastic optimal control. In *The Thirteenth International Conference on Learning Representations*, 2025. URL <https://openreview.net/forum?id=xQBRrtQM8u>.
- Joseph L Doob and JI Doob. *Classical potential theory and its probabilistic counterpart*, volume 262. Springer, 1984.
- Kai Du and Qingxin Meng. A maximum principle for optimal control of stochastic evolution equations. *SIAM Journal on Control and Optimization*, 51(6):4343–4362, 2013.
- Yuanqi Du, Michael Plainer, Rob Brekelmans, Chenru Duan, Frank Noe, Carla P Gomes, Alan Aspuru-Guzik, and Kirill Neklyudov. Doob’s lagrangian: A sample-efficient variational approach to transition path sampling. *Advances in Neural Information Processing Systems*, 37: 65791–65822, 2024.
- Detlef Dürr and Alexander Bach. The onsager-machlup function as lagrangian for the most probable path of a diffusion process. *Communications in Mathematical Physics*, 60(2):153–170, 1978.
- Peter Eastman, Raimondas Galvelis, Raúl P. Peláez, Charles R. A. Abreu, Stephen E. Farr, Emilio Gallicchio, Anton Gorenko, Michael M. Henry, Frank Hu, Jing Huang, Andreas Krämer, Julien Michel, Joshua A. Mitchell, Vijay S. Pande, João PGLM Rodrigues, Jaime Rodriguez-Guerra, Andrew C. Simmonett, Sukrit Singh, Jason Swails, Philip Turner, Yuanqing Wang, Ivy Zhang, John D. Chodera, Gianni De Fabritiis, and Thomas E. Markland. Openmm 8: Molecular dynamics simulation with machine learning potentials. *arXiv preprint arXiv:2310.03121*, 2023.
- Lawrence C Evans. *Partial differential equations*, volume 19. American mathematical society, 2022.
- Giorgio Fabbri, Fausto Gozzi, and Andrzej Swiech. Stochastic optimal control in infinite dimension. *Probability and Stochastic Modelling*. Springer, 2017.
- W.H. Fleming and H.M. Soner. *Controlled Markov Processes and Viscosity Solutions*. Applications of mathematics. Springer-Verlag, 1993. ISBN 9780387979274. URL https://books.google.co.kr/books?id=5k4_AQAAIAAJ.
- Giulio Franzese, Giulio Corallo, Simone Rossi, Markus Heinonen, Maurizio Filippone, and Pietro Michiardi. Continuous-time functional diffusion processes. *Advances in Neural Information Processing Systems*, 36, 2024.
- Marco Fuhrman. A class of stochastic optimal control problems in hilbert spaces: Bsd’s and optimal control laws, state constraints, conditioned processes. *Stochastic processes and their applications*, 108(2):263–298, 2003.
- Martin Hairer, Andrew M Stuart, and Jochen Voss. Sampling conditioned diffusions. *Trends in stochastic analysis*, 353:159–186, 2009.
- Aaron Havens, Benjamin Kurt Miller, Bing Yan, Carles Domingo-Enrich, Anuroop Sriram, Brandon Wood, Daniel Levine, Bin Hu, Brandon Amos, Brian Karrer, Xiang Fu, Guan-Hong Liu, and Ricky T. Q. Chen. Adjoint Sampling: Highly scalable diffusion samplers via Adjoint Matching. *International Conference on Machine Learning*, 2025.
- Lars Holdijk, Yuanqi Du, Priyank Jaini, Ferry Hooft, Bernd Ensing, and Max Welling. Path integral stochastic optimal control for sampling transition paths. In *ICML 2022 2nd AI for Science Workshop*, 2022.
- Sergei Izrailev, Sergey Stepaniants, Barry Isralewitz, Dorina Kosztin, Hui Lu, Ferenc Molnar, Willy Wriggers, and Klaus Schulten. Steered molecular dynamics. In *Computational Molecular Dynamics: Challenges, Methods, Ideas: Proceedings of the 2nd International Symposium on Algorithms for Macromolecular Modelling, Berlin, May 21–24, 1997*, pages 39–65. Springer, 1999.
- Hannes Jónsson, Greg Mills, and Karsten W. Jacobsen. Nudged elastic band method for finding minimum energy paths of transitions, pages 385–404. 1998. doi: 10.1142/9789812839664_0016. URL https://www.worldscientific.com/doi/abs/10.1142/9789812839664_0016.
- Wolfgang Kabsch. A solution for the best rotation to relate two sets of vectors. *Foundations of Crystallography*, 32(5):922–923, 1976.
- Hilbert J Kappen. Path integrals and symmetry breaking for optimal control theory. *Journal of statistical mechanics: theory and experiment*, 2005(11):P11011, 2005.
- Tero Karras, Miika Aittala, Timo Aila, and Samuli Laine. Elucidating the design space of diffusion-based generative models. *Advances in neural information processing systems*, 35:26565–26577, 2022.
- Gavin Kerrigan, Giosue Migliorini, and Padhraic Smyth. Functional flow matching. In *International Conference on Artificial Intelligence and Statistics*, pages 3934–3942. PMLR, 2024.
- Jae Hyun Lim, Nikola B Kovachki, Ricardo Baptista, Christopher Beckham, Kamyar Azizzadenesheli, Jean Kossaifi, Vikram Voleti, Jiaming Song, Karsten Kreis,

- Jan Kautz, et al. Score-based diffusion models in function space. *arXiv preprint arXiv:2302.07400*, 2023a.
- Sungbin Lim, Eunbi Yoon, Taehyun Byun, Taewon Kang, Seungwoo Kim, Kyungjae Lee, and Sungjoon Choi. Score-based generative modeling through stochastic evolution equations in hilbert spaces. In *Thirty-seventh Conference on Neural Information Processing Systems*, 2023b. URL <https://openreview.net/forum?id=GrElRvXnEj>.
- Kresten Lindorff-Larsen, Stefano Piana, Kim Palmo, Paul Maragakis, John L Klepeis, Ron O Dror, and David E Shaw. Improved side-chain torsion potentials for the amber ff99sb protein force field. *Proteins: Structure, Function, and Bioinformatics*, 78(8):1950–1958, 2010.
- Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matthew Le. Flow matching for generative modeling. In *The Eleventh International Conference on Learning Representations*, 2023. URL <https://openreview.net/forum?id=PqvMRDCJT9t>.
- Guan-Horng Liu, Tianrong Chen, Oswin So, and Evangelos Theodorou. Deep generalized schrödinger bridge. In Alice H. Oh, Alekh Agarwal, Danielle Belgrave, and Kyunghyun Cho, editors, *Advances in Neural Information Processing Systems*, 2022. URL <https://openreview.net/forum?id=fp33Nsh005>.
- Guan-Horng Liu, Jaemoo Choi, Yongxin Chen, Benjamin Kurt Miller, and Ricky TQ Chen. Adjoint schrödinger bridge sampler. *arXiv preprint arXiv:2506.22565*, 2025.
- Gabriel J Lord, Catherine E Powell, and Tony Shardlow. *An introduction to computational stochastic PDEs*, volume 50. Cambridge University Press, 2014.
- James A Maier, Carmenza Martinez, Koushik Kasavajhala, Lauren Wickstrom, Kevin E Hauser, and Carlos Simmerling. ff14sb: improving the accuracy of protein side chain and backbone parameters from ff99sb. *Journal of chemical theory and computation*, 11(8):3696–3713, 2015.
- Hai Nguyen, Daniel R Roe, and Carlos Simmerling. Improved generalized born solvent model parameters for protein simulations. *Journal of chemical theory and computation*, 9(4):2020–2034, 2013.
- Frank Noé, Christof Schütte, Eric Vanden-Eijnden, Lothar Reich, and Thomas R Weikl. Constructing the equilibrium ensemble of folding pathways from short off-equilibrium simulations. *Proceedings of the National Academy of Sciences*, 106(45):19011–19016, 2009.
- Byoungwoo Park, Jungwon Choi, Sungbin Lim, and Juho Lee. Stochastic optimal control for diffusion bridges in function spaces. In *The Thirty-eighth Annual Conference on Neural Information Processing Systems*, 2024. URL <https://openreview.net/forum?id=WyQW4G57Zd>.
- Byoungwoo Park, Hyungi Lee, and Juho Lee. Amortized control of continuous state space feynman-kac model for irregular time series. In *The Thirteenth International Conference on Learning Representations*, 2025. URL <https://openreview.net/forum?id=8zJR0n6k5v>.
- Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, et al. Pytorch: An imperative style, high-performance deep learning library. *Advances in neural information processing systems*, 32, 2019.
- Magnus Petersen and Roberto Covino. PINN-MEP: Continuous neural representations for minimum energy path discovery in molecular systems. In *Frontiers in Probabilistic Inference: Learning meets Sampling*, 2025. URL <https://openreview.net/forum?id=5DbwuFklk0>.
- Angus Phillips, Hai-Dang Dau, Michael John Hutchinson, Valentin De Bortoli, George Deligiannidis, and Arnaud Doucet. Particle denoising diffusion sampler. *arXiv preprint arXiv:2402.06320*, 2024.
- Jakiw Pidstrigach, Youssef Marzouk, Sebastian Reich, and Sven Wang. Infinite-dimensional diffusion models for function spaces. *arXiv e-prints*, pages arXiv–2302, 2023.
- Michael Plainer, Hannes Stärk, Charlotte Bunne, and Stephan Günnemann. Transition path sampling with boltzmann generator-based mcmc moves. *arXiv preprint arXiv:2312.05340*, 2023.
- Md Ashiqur Rahman, Zachary E Ross, and Kamyar Azizzadenesheli. U-no: U-shaped neural operators. *arXiv preprint arXiv:2204.11127*, 2022.
- Kalyan Ramakrishnan, Lars L. Schaaf, Chen Lin, Guanrun Wang, and Philip Torr. Implicit neural representations for chemical reaction paths. *The Journal of Chemical Physics*, 163(3):034109, 07 2025. ISSN 0021-9606. doi: 10.1063/5.0267023. URL <https://doi.org/10.1063/5.0267023>.
- Severi Rissanen, Markus Heinonen, and Arno Solin. Generative modelling with inverse heat dissipation. In *The Eleventh International Conference on Learning Representations*, 2023. URL <https://openreview.net/forum?id=4PJUBT9f20l>.

- Kiyoung Seong, Seonghyun Park, Seonghwan Kim, Woo Youn Kim, and Sungsoo Ahn. Transition path sampling with improved off-policy training of diffusion path samplers. In *The Thirteenth International Conference on Learning Representations*, 2025. URL <https://openreview.net/forum?id=WQV9kB1qSU>.
- Tony Shardlow. Numerical methods for stochastic parabolic pdes. *Numerical functional analysis and optimization*, 20(1-2):121–145, 1999.
- Yuyang Shi, Valentin De Bortoli, Andrew Campbell, and Arnaud Doucet. Diffusion schrödinger bridge matching. *Advances in Neural Information Processing Systems*, 36, 2024.
- Søren Smidstrup, Andreas Pedersen, Kurt Stokbro, and Hannes Jónsson. Improved initial guess for minimum energy path calculations. *The Journal of chemical physics*, 140(21), 2014.
- Yang Song, Jascha Sohl-Dickstein, Diederik P Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole. Score-based generative modeling through stochastic differential equations. In *International Conference on Learning Representations*, 2021. URL <https://openreview.net/forum?id=PXTIG12RRHS>.
- Gabriele C Sosso, Ji Chen, Stephen J Cox, Martin Fitzner, Philipp Pedevilla, Andrea Zen, and Angelos Michaelides. Crystal nucleation in liquids: Open questions and future challenges in molecular dynamics simulations. *Chemical reviews*, 116(12):7078–7116, 2016.
- Andrew M Stuart, Jochen Voss, and Petter Wilberg. Conditional path sampling of sdes and the langevin mcmc method. *Communications in Mathematical Sciences*, 2004.
- Taiji Suzuki. Generalization bound of globally optimal non-convex neural network training: Transportation map estimation by infinite dimensional langevin dynamics. *Advances in Neural Information Processing Systems*, 33: 19224–19237, 2020.
- Evangelos A. Theodorou, George I. Boutselis, and Kaivalya Bakshi. Linearly solvable stochastic optimal control for infinite-dimensional systems. In *2018 IEEE Conference on Decision and Control (CDC)*, pages 4110–4116, 2018. doi: 10.1109/CDC.2018.8618948.
- Pratyush Tiwary, Vittorio Limongelli, Matteo Salvalaglio, and Michele Parrinello. Kinetics of protein–ligand unbinding: Predicting pathways, rates, and rate-limiting steps. *Proceedings of the National Academy of Sciences*, 112(5):E386–E391, 2015.
- Belinda Tzen and Maxim Raginsky. Theoretical guarantees for sampling and inference in generative models with latent diffusions. In Alina Beygelzimer and Daniel Hsu, editors, *Proceedings of the Thirty-Second Conference on Learning Theory*, volume 99 of *Proceedings of Machine Learning Research*, pages 3084–3114. PMLR, 25–28 Jun 2019. URL <https://proceedings.mlr.press/v99/tzen19a.html>.
- Eric Vanden-Eijnden et al. Transition-path theory and path-finding algorithms for the study of rare events. *Annual review of physical chemistry*, 61:391–420, 2010.
- Francisco Vargas, Andrius Ovsianas, David Fernandes, Mark Girolami, Neil D Lawrence, and Nikolas Nüsken. Bayesian learning via neural Schrödinger–Föllmer flows. *Statistics and Computing*, 33(1):3, 2023.
- Yuyang Wang, Ahmed AA Elhag, Navdeep Jaitly, Joshua M Susskind, and Miguel Ángel Bautista. Swallowing the bitter pill: Simplified scalable conformer generation. In *International Conference on Machine Learning*, pages 50400–50418. PMLR, 2024.
- Qinsheng Zhang and Yongxin Chen. Path integral sampler: A stochastic control approach for sampling. In *International Conference on Learning Representations*, 2022. URL https://openreview.net/forum?id=_uCb2ynRu7Y.

A. 相关概念概述

本文首先简要概述无限维空间中核心的概率概念，然后描述希尔伯特空间上的随机微分方程（Da Prato 和 Zabczyk, 2002; 2014）。

A.1. 高斯测度与广义维纳过程。

高斯测度至关重要，因为无限维环境缺乏勒贝格参考测度，而具有迹类协方差的高斯分布提供了一个自然基线，使随机积分保持平方可积，并提供显式的 RND，这两者对于我们的框架都是必不可少的。

高斯测度。 设 $(\Omega, \mathcal{F}, \mathbb{Q})$ 是一个概率空间， $(\mathcal{H}, B(\mathcal{H}))$ 是一个可测状态空间，其中 $\mathcal{H}$ 是一个可分希尔伯特空间，具有内积 $\langle \cdot, \cdot \rangle_{\mathcal{H}}$ 和范数 $\|\cdot\|_{\mathcal{H}}$ ，且 $B(\mathcal{H})$ 是 $\mathcal{H}$ 上的博雷尔测度。我们考虑 $\mathcal{H}$ 值随机变量 $\mathbf{X}: \Omega \rightarrow \mathcal{H}$ 。现在，通过 $\nu := \mathbf{X}$ 定义前推测度 $\mathbb{Q} \# \nu(B) = \mathbb{Q}(\mathbf{X}^{-1}(B))$ ，对于每个博雷尔集 $B \subset B(\mathcal{H})$ 。如果每个 ν 值投影 $\mathbb{R}$ 对于所有 $\langle u, \mathbf{X} \rangle_{\mathcal{H}}$ 都是高斯随机变量，则称 $u \in \mathcal{H}$ 为高斯测度。当 $\mathcal{H} = \mathbb{R}^d$ 具有标准内积时，此定义重现通常的高斯分布。

对于高斯测度 ν ，存在唯一的均值函数 $\mathbf{m} \in \mathcal{H}$ ，满足：

$$\mathbf{m} = \int_{\mathcal{H}} \mathbf{X} d\nu, \quad \langle \mathbf{m}, u \rangle_{\mathcal{H}} = \mathbb{E}_{\nu} [\langle \mathbf{X}, u \rangle_{\mathcal{H}}], \quad \forall u \in \mathcal{H}. \quad (27)$$

此外，存在唯一的有限线性算子 $Q: \mathcal{H} \rightarrow \mathcal{H}$ ，使得

$$Qu = \int_{\mathcal{H}} \langle \mathbf{X}, u \rangle_{\mathcal{H}} \mathbf{X} d\nu - \langle \mathbf{m}, u \rangle_{\mathcal{H}} \mathbf{m}, \quad \forall u \in \mathcal{H}. \quad (28)$$

高斯测度由其均值和协方差算子完全确定。若均值为零，即 $\nu = \mathcal{N}(0, Q)$ ，则称 ν 为中心化的。费尔尼克可积性定理（Fernique's Integrability Theorem）（Da Prato 和 Zabczyk, 2014, 定理 2.7）指出，对于可分巴拿赫空间 $\mathcal{B}$ （特别是在 $\mathcal{H}$ 上）上的任意中心化高斯测度 ν ，存在 $r > 0$ 使得 $\int_{\mathcal{H}} \exp(r \|\mathbf{X}\|_{\mathcal{H}}^2) d\nu < \infty$ 。因此，该定理蕴含每个多项式矩都是有限的 *i.e.*, $\mathbb{E}_{\nu} [\|\mathbf{X}\|_{\mathcal{H}}^2] < \infty$ 。利用定义 (28) 和 $\mathcal{H}, \{\phi^{(k)}\}_{k \geq 1}$ 的任意标准正交基，对于每个 $\phi^{(k)} \in \mathcal{H}$ ，对于每个 $k \in \mathbb{N}$ ：

$$\text{Tr}(Q) = \sum_{k \geq 1} \langle Q\phi^{(k)}, \phi^{(k)} \rangle_{\mathcal{H}} = \sum_{k \geq 1} \mathbb{E}_{\nu} [\langle \mathbf{X}, \phi^{(k)} \rangle_{\mathcal{H}}^2] = \mathbb{E}_{\nu} [\|\mathbf{X}\|_{\mathcal{H}}^2] < \infty. \quad (29)$$

这意味着对称且非负的协方差算子 Q 是迹类算子，*i.e.*, $\text{Tr}(Q) < \infty$ ，因此蕴含 Q 是紧算子。因此，存在特征系统 $\{(\lambda^{(k)}, \phi^{(k)}) \in \mathbb{R} \times \mathcal{H} : k \in \mathbb{N}\}$ ，其中 $\{\phi^{(k)}\}_{k \geq 1}$ 是标准正交特征基， $\{\lambda^{(k)}\}_{k \geq 1}$ 是正特征值，使得

$$Q\phi^{(k)} = \lambda^{(k)}\phi^{(k)}, \quad \text{及} \quad \text{Tr}(Q) = \sum_{k \geq 1} \langle Q\phi^{(k)}, \phi^{(k)} \rangle_{\mathcal{H}} = \sum_{k \geq 1} \lambda^{(k)} < \infty. \quad (30)$$

我们现在将维纳过程的概念推广到无穷维随机微分方程。

希尔伯特空间上的维纳过程。 将维纳过程推广到希尔伯特空间 $\mathcal{H}$ 的一种自然方式是通过柱面维纳过程。它被引入为沿标准正交基 $\{\phi^{(k)}\}_{k \geq 1}$ 的独立 $\mathbb{R}$ 值维纳过程 $\{\mathbf{W}^{(k)}\}_{k \geq 1}$ 的形式级数：

$$\mathbf{W}_t = \sum_{k \geq 1} \mathbf{W}_t^{(k)} \phi^{(k)}, \quad t \geq 0. \quad (31)$$

然而，级数 $\mathbf{W}_t$ 在 $\mathcal{H}$ 中不收敛，因为

$$\mathbb{E} [\|\mathbf{W}_t\|_{\mathcal{H}}^2] = \sum_{k \geq 1} \mathbb{E} [(\mathbf{W}_t^{(k)})^2] = t \sum_{k \geq 1} 1 = \infty, \quad (32)$$

因此 $\mathbf{W}_t$ 不能成为 $\mathcal{H}$ 值随机变量。因此，只有在额外平滑处理下才能使用它来获得 $\mathcal{H}$ 值噪声过程。这种平滑处理通过迹类算子 Q 完成。定义 $\mathbf{W}_t^Q = Q^{1/2} \mathbf{W}_t =$

$\sum_{k \geq 1} \sqrt{\lambda^{(k)}} \mathbf{W}_t^{(k)} \phi^{(k)}$. Then, we have

$$\mathbb{E} \left[\left\| \mathbf{W}_t^Q \right\|_{\mathcal{H}}^2 \right] = \sum_{k \geq 1} \mathbb{E} \left[\lambda^{(k)} (\mathbf{W}_t^{(k)})^2 \right] = t \sum_{k \geq 1} \lambda^{(k)} < \infty, \quad (33)$$

其中 $\{(\lambda^{(k)}, \phi^{(k)}) \in \mathbb{R} \times \mathcal{H} : k \in \mathbb{N}\}$ 是 Q 的特征系统。因此 $\mathbf{W}_t^Q$ 是 $\mathcal{H}$ 值过程。这种平滑过程被称为 Q -维纳过程或彩色噪声，因为噪声协方差算子 Q 引入了空间相关性。

A.2. 希尔伯特空间中的随机微分方程

在无穷维维纳过程 $\mathbf{W}_t^Q$ 定义良好 $\mathcal{H}$ 的基础上，我们定义无穷维随机微分方程如下：

$$d\mathbf{X}_t = A\mathbf{X}_t dt + \sigma_t d\mathbf{W}_t^Q, \quad \mathbf{X}_0 = \mathbf{x}_0 \in \mathcal{H}, \quad (34)$$

其中 $A : \mathcal{H} \rightarrow \mathcal{H}$ 是线性算子， $\sigma_t > 0$ 。我们回顾由 $\mathcal{H}$ 上一般 Q -维纳过程驱动的经典温和公式。然后我们将注意力限制在 $\mathcal{H}_0$ 上的柱面维纳过程，引入一个合适的希尔伯特-施密特嵌入，该嵌入可以自然地与我们的框架对齐，并概述在柱面维纳过程选择下仍能保证无穷维随机微分方程解存在的最小假设。

温和解。 设线性算子 $A : \mathcal{H} \rightarrow \mathcal{H}$ 在 $\mathcal{H}$ 上生成强连续 C_0 半群 $\{e^{tA}\}_{t \geq 0}$ 。假设 $\mathbf{W}^Q$ 是中心化的 Q -维纳过程，具有迹类协方差算子 Q ，且对于任意 $t > 0$ ， $e^{tA}Q^{1/2}$ 是希尔伯特-施密特算子。在这些条件下，方程 (3) 中的无穷维随机微分方程（或随机偏微分方程）存在唯一的温和解：

$$\mathbf{X}_t = e^{tA}\mathbf{x}_0 + \sigma_t \int_0^t e^{(t-s)A} d\mathbf{W}_s^Q, \quad t \geq 0. \quad (35)$$

由此产生的随机过程 $\{\mathbf{X}_t\}_{t \geq 0}$ 是 $\mathcal{H}$ 值随机变量，因为随机卷积 $\int_0^t e^{(t-s)A} d\mathbf{W}_s^Q = \int_0^t e^{(t-s)A} Q^{1/2} d\mathbf{W}_s$ 位于 $\mathcal{H}$ 上，这是由于 $e^{(t-s)A} Q^{1/2}$ 是希尔伯特-施密特算子。我们可以计算其均值 $\mathbf{m}_t$ 和协方差算子 Q_t ，对于任意 $t > 0$ 如下：

$$\mathbf{m}_t = e^{tA}\mathbf{x}_0, \quad Q_t = \sigma_t^2 \int_0^t e^{(t-s)A} Q e^{(t-s)A^\dagger} ds. \quad (36)$$

根据希勒-约西达定理 (Da Prato 和 Zabczyk, 2014, 定理 A.3)， A 满足 $e^{tA} \leq M e^{-wt}$ ，对于某个 $M \geq 1, w \geq 0$ 。因此，对于每个 $0 \leq s \leq t, T_{st} := e^{(t-s)A} Q e^{(t-s)A^\dagger}$ 满足：

$$\text{Tr}(T_{st}) \leq \left\| e^{(t-s)A} \right\| \left\| \text{Tr}(Q) \right\| \left\| e^{(t-s)A^\dagger} \right\| \leq M^2 e^{-2w(t-s)} \text{Tr}(Q) < \infty. \quad (37)$$

这意味着 T_{st} 是一个迹类算子。因此，由于该界在 $[0, t]$ 上可积，

$$\text{Tr}(Q_t) = \text{Tr}(\sigma_t^2 \int_0^t T_{st} ds) \leq \sigma_t^2 \int_0^t \text{Tr}(T_{st}) ds < \infty. \quad (38)$$

因此，对于每个 $t < \infty$ ， Q_t 是一个迹类算子。因此，我们可以确认 $\mathcal{H}$ 值随机过程 $\mathbf{X}_t$ 具有高斯律

$$\nu_t = \mathcal{N}(\mathbf{m}_t, Q_t).$$

不变测度。 Let A i.e., $\langle A\mathbf{x}, \mathbf{x} \rangle_{\mathcal{H}} \leq -\lambda \|\mathbf{x}\|_{\mathcal{H}}^2$ 是耗散的（对某个 $\lambda > 0$ 有 $\mathcal{H}$ ），积分在 $t \rightarrow \infty$ 时收敛，并且我们定义噪声调度使得 $\sup_t \sigma_t < \infty, \sigma_t \rightarrow \sigma_\infty$ 。那么，算子 Q_t 求解以下微分李雅普诺夫方程：

$$\dot{Q}_t = A Q_t + Q_t A^\dagger + \sigma_t^2 Q, \quad Q_t = e^{tA} Q_0 e^{tA^\dagger} + \int_0^t \sigma_{t-r}^2 e^{rA} Q e^{rA^\dagger} dr. \quad (39)$$

由于 $Q_0 = 0$ ，因为我们假设 (3) 中的狄拉克 δ 初始条件 $\mathbf{x}_0$ ，我们得到

$$Q_t \xrightarrow{t \rightarrow \infty} Q_\infty := \sigma_\infty^2 \int_0^\infty e^{tA} Q e^{tA^\dagger} dt \quad (40)$$

现在, 令 $F(t) = \sigma_\infty^2 e^{t\mathcal{A}} Q e^{t\mathcal{A}^\dagger}$ 。那么, 我们得到:

$$\frac{d}{dt} F(t) = \mathcal{A}F(t) + F(t)\mathcal{A}^\dagger = \mathcal{A}\sigma_\infty^2 e^{t\mathcal{A}} Q e^{t\mathcal{A}^\dagger} + \sigma_\infty^2 e^{t\mathcal{A}} Q e^{t\mathcal{A}^\dagger} \mathcal{A}^\dagger. \quad (41)$$

Since $F(t) \xrightarrow{t \rightarrow \infty} 0$ 及 $F(0) = \sigma_\infty^2 Q$, 通过对 (41) 从 0 到 ∞ 进行积分, 我们得到:

$$\mathcal{A}Q_\infty + Q_\infty \mathcal{A}^\dagger = \int_0^\infty \frac{d}{dt} F(t) dt = \lim_{t \rightarrow \infty} F(t) - F(0) = -\sigma_\infty^2 Q \quad (42)$$

因此, 我们得到算子李雅普诺夫方程 (Da Prato 和 Zabczyk, 2002, 命题 10.1.4) :

$$\mathcal{A}Q_\infty + Q_\infty \mathcal{A}^\dagger + \sigma_\infty^2 Q = 0, \quad (43)$$

其中 Q_∞ 是迹类算子。因此 $\mathcal{N}(0, \infty)$ 是 (3) 中过程的唯一不变高斯测度。最后, 如果 $\mathcal{A}$ 是迹类自伴算子 (i.e., $\mathcal{A} = \mathcal{A}^\dagger$) 且 $\mathcal{A}$ 与 Q 可交换 (i.e., $Q\mathcal{A} = \mathcal{A}Q$), 我们得到 $Q_\infty = -\frac{1}{2}\sigma_\infty^2 \mathcal{A}^{-1}Q$ (Da Prato 和 Zabczyk, 2002, 命题 10.1.6)。

A.3. 转移路径理论简介

在本节中, 我们介绍经典的转移路径理论 (TPT; Vanden-Eijnden 等, 2010), 这是一种在复杂系统中采样和量化 $\mathbf{A}$ 与 $\mathbf{B}$ 之间亚稳态反应路径的方法。这里, 我们简要介绍两种代表性的 TPT 方法: 转移路径采样 (TPS) 和状态链 (CoS) 方法 (e.g., NEB, 弦方法)。然后, 我们将明确这两种观点之间的联系, 并展示我们的无限维公式如何通过费曼-卡茨公式 (Del Moral, 2011) 为它们之间提供原则性的桥梁。

遵循 (Dellago 等, 1998) 的记号, 我们记一个离散时空路径 $\mathbf{P} := \{\mathbf{p}_0, \mathbf{p}_1, \dots, \mathbf{p}_L\}$, 其中 $\mathbf{p}_u = (\mathbf{r}_u, \mathbf{v}_u) \in \mathbb{R}^{6N}$ 是构型, $\mathbf{r}_u \in \mathbb{R}^{3N}$ 是原子位置, $\mathbf{v}_u \in \mathbb{R}^{3N}$ 是原子速度, N 是时间区间 $\mathbf{L} = [0, L]$ 上的原子数。我们假设连续的构型状态遵循马尔可夫转移 $p(\mathbf{p}_u \rightarrow \mathbf{p}_{u+1})$, 则路径概率由转移概率的乘积给出, 如下所示:

$$\mathbb{P}(\mathbf{P}) = e^{-\frac{1}{k_B T} V(\mathbf{p}_0)} \prod_{u=0}^{L-1} p(\mathbf{p}_u \rightarrow \mathbf{p}_{u+1}), \quad (44)$$

其中 $V: \mathbb{R}^{6N} \rightarrow \mathbb{R}$ 是能量函数。在此设定下, 我们的目标是从转移路径分布中采样连接边界约束 $\pi_{\mathbf{A}}(\mathbf{p}_0)$ 和 $\pi_{\mathbf{B}}(\mathbf{p}_L)$ 的转移路径:

$$\mathbb{P}^*(\mathbf{P}) := e^{-S(\mathbf{P})} = \pi_{\mathbf{A}}(\mathbf{p}_0) \pi_{\mathbf{B}}(\mathbf{p}_L) \mathbb{P}(\mathbf{P}), \quad (45)$$

其中 $\pi_{\mathbf{A}}(\mathbf{p}_0)$ 和 $\pi_{\mathbf{B}}(\mathbf{p}_L)$ 分别强制路径以指定的 $\mathbf{A}$ 和 $\mathbf{B}$ 开始和结束。注意, 我们可以自由选择马尔可夫转移 $p(\mathbf{p}_u \rightarrow \mathbf{p}_{u+1})$, 只要它保持归一化的吉布斯分布 (Dellago 等, 1998)。接下来, 我们展示马尔可夫转移的选择如何区分 TPS 与基于 CoS 的最大能量路径 (MEP) 优化。

A.4. 过渡路径采样

经典的过渡路径采样通常针对欠阻尼状态下的朗之万动力学进行表述。然而, 我们关注过阻尼情形, 因为其形式简单, 且向欠阻尼情形的扩展是直接的。由过阻尼朗之万动力学控制的分子系统由下式给出:

$$d\mathbf{p}_t = -\frac{1}{\gamma \mathbf{m}} \nabla_{\mathbf{p}} V(\mathbf{p}_t) dt + \sqrt{\frac{2k_B T}{\gamma \mathbf{m}}} d\mathbf{W}_t, \quad (46)$$

其中我们将 γ 表示为摩擦系数, $\mathbf{m}$ 表示质量。在这种情况下, (46) 中过阻尼动力学的离散马尔可夫转移核由欧拉-丸山离散化得到, 因为 δ_t 上的增量服从均值为 $\mu_t = \mathbf{p}_t - \frac{1}{\gamma \mathbf{m}} \nabla_{\mathbf{p}} V(\mathbf{p}_t) \delta_t$ 、协方差为 $\Sigma_t = \frac{2k_B T}{\gamma \mathbf{m}} \delta_t \mathbf{I}_{3N}$ 的高斯分布:

$$\mathbf{p}_{u+1} = \mathbf{p}_u - \frac{1}{\gamma \mathbf{m}} \nabla_{\mathbf{p}} V(\mathbf{p}_t) \delta_t + \sqrt{\frac{2k_B T}{\gamma \mathbf{m}}} \zeta, \quad \zeta \sim \mathcal{N}(0, \mathbf{I}_{3N}). \quad (47)$$

$$\text{Hence, } p(\mathbf{p}_u \rightarrow \mathbf{p}_{u+1}) = \mathcal{N}(\mathbf{p}_{u+1} | \mu_t, \Sigma_t). \quad (48)$$

因此，将 (47) 代入 (44) 得到过渡路径采样转移路径分布，该分布在近期文献中被广泛使用 (Holdijk 等, 2022; Seong 等, 2025; Blessing 等, 2025)。具体而言，从 (46) 中的过阻尼动力学出发，这一系列工作通过用基于神经网络的控制 α^θ 偏置势能 V ，建立了一个有限维随机最优控制问题：

$$d\mathbf{p}_t^\alpha = -\frac{1}{\gamma\mathbf{m}}\nabla_{\mathbf{p}}[V(\mathbf{p}_t^\alpha) + \alpha^\theta(t, \mathbf{p}_t^\alpha)]dt + \sqrt{\frac{2k_B T}{\gamma\mathbf{m}}}d\mathbf{W}_t, \quad \mathbf{p}_0^\alpha = \mathbf{A}. \quad (49)$$

现在，优化的目标是学习 α^θ ，通过最大化关于 (45) 中过渡路径密度的对数似然，引导先验动力学从给定的亚稳态 $\mathbf{A}$ 出发，进入另一个目标亚稳态 $\mathbf{B}$ 。

A.5. 状态链方法

如果给定系统具有光滑的能量景观，过渡路径采样能够充分描述过渡过程。在这种情况下，主要目标是过渡态，即势能景观上的鞍点 (Vanden-Eijnden 等, 2010)。然而，对于复杂的能量景观，当初态和目标态被中间盆地分隔时，通过一系列过渡态连接相关极小值的最小能量路径更为可取，这促使了状态链方法的发展。状态链方法的目标是将几何路径参数化为固定边界网格上的离散链 $\mathbf{P}^\theta := \{\mathbf{p}_0 = \mathbf{A}, \mathbf{p}_1^\theta, \dots, \mathbf{p}_{L-1}^\theta, \mathbf{p}_L = \mathbf{B}\}$ ，并优化一个几何泛函。例如，弹性带方法 (Jonsson 等, 1998) 的目标由下式给出：

$$S(\mathbf{P}^\theta) = \sum_{u=0}^{L-1} \left[V(\mathbf{p}_u^\theta) + \frac{\kappa}{2} \|\mathbf{p}_{u+1}^\theta - \mathbf{p}_u^\theta\|^2 \right], \quad (50)$$

其中 $\kappa > 0$ 为常数。近期研究 (Petersen 和 Covino, 2025; Ramakrishnan 等, 2025) 通过最小化 (50) 中类似形式的目标来优化连续路径 $\mathbf{P}^\theta$ 的神经网络参数化，以找到最小能量路径。然而，状态链方法缺乏概率基础，因此在不进行额外建模的情况下，无法针对反应路径系综或不确定性。

A.6. (12) 中终端代价的选择

此前，TPS 的转移路径分布通常通过将朗之万转移核 (47) 代入分解形式 (44) 得到，如下所示：

$$\mathbb{P}(\mathbf{P}) = e^{-\frac{1}{k_B T} V(\mathbf{p}_0)} \prod_{u=0}^{L-1} p(\mathbf{p}_u \rightarrow \mathbf{p}_{u+1}), \quad (51a)$$

$$\text{其中 } p(\mathbf{p}_u \rightarrow \mathbf{p}_{u+1}) = \mathcal{N}(\mathbf{p}_{u+1} | \mathbf{p}_u - \frac{1}{\gamma\mathbf{m}} \nabla_{\mathbf{p}} V(\mathbf{p}_u) \delta_u, \frac{2k_B T}{\gamma\mathbf{m}} \mathbf{I}_{3N} \delta_u). \quad (51b)$$

直观上，(51a) 给出了在温度 T 下过阻尼朗之万动力学 (46) 的离散轨迹的路径对数似然。然后，为了对 TPS 施加端点条件 $\pi_{\mathbf{B}}(\mathbf{p}_L)$ ：

$$\mathbb{P}_{\text{TPS}}^*(\mathbf{P}) = e^{-S(\mathbf{P})} = \pi_{\mathbf{A}}(\mathbf{p}_0) \pi_{\mathbf{B}}(\mathbf{p}_L) \mathbb{P}(\mathbf{P}), \quad (52)$$

对于 (12) 中的终端代价 U ，可以将 (52) 中的 TPS 能量作为负对数似然 (NLL) *i.e.* $U(\mathbf{X}) = -\log \mathbb{P}_{\text{TPS}}^*(\mathbf{X})$ ，然后优化控制 α^θ 以采样转移路径。然而，在实践中，我们观察到这种选择导致 FAS 训练不稳定。实际上，(46) 中朗之万动力学的仿真根据局部梯度 $-\nabla V$ 移动，这有助于稳定轨迹，因为该力引导路径沿势能下降方向移动并抑制大幅上坡移动。相比之下，我们在 (11) 中的无限维 SDE 注入噪声并在固定训练网格上演化，没有明确使路径与 $-\nabla V$ 的几何对齐，因此路径的微小扰动可能导致 V 沿网格出现大幅振荡，从而使 U 在梯度步骤间波动。

因此，我们转而推导一个适合我们路径参数化的有原则的路径目标。与 TPS 相比，通过采用马尔可夫过程的著名重加权原理，即费曼-卡茨公式 (Del Moral, 2011)，我们可以将路径分布重写为倾斜马尔可夫链：

$$\tilde{\mathbb{P}}(\mathbf{P}) = \prod_{u=0}^{L-1} e^{-\frac{1}{k_B T} V(\mathbf{p}_u)} \tilde{p}(\mathbf{p}_u \rightarrow \mathbf{p}_{u+1}), \quad (53a)$$

$$\text{其中 } \tilde{p}(\mathbf{p}_u \rightarrow \mathbf{p}_{u+1}) = \mathcal{N}(\mathbf{p}_{u+1} | \mathbf{p}_u, \frac{2k_B T}{\gamma\mathbf{m}} \mathbf{I}_{3N} \delta_u). \quad (53b)$$

注意，势能 $V(\mathbf{p}_u)$ 由路径分布承载，而非由动力学承载。尽管 (53) 的目标与 (51) 相同，即让所得路径测度集中在高势能区域，但这种构造与 (51) 不同，高势能可以通过直接重加权实现，而非来自局部梯度 $-\nabla V$ 。这一观点使我们能够推导出适合我们路径参数化的 CoS 型目标 (50)，从而得到转移路径分布：

$$\mathbb{P}_{\text{CoS}}^*(\mathbf{P}) \propto e^{-\tilde{S}(\mathbf{P})} = \pi_{\mathbf{A}}(\mathbf{P}_0)\pi_{\mathbf{B}}(\mathbf{P}_L)\tilde{\mathbb{P}}(\mathbf{P}), \quad (54)$$

利用该转移路径分布，NLL $U(\mathbf{X}) = -\log \mathbb{P}^*$ 可以写成如下 $s(\mathbf{X})$ 形式：

$$U(\mathbf{X}) = -[\log \pi_{\mathbf{A}}(\mathbf{X}[0]) + \pi_{\mathbf{B}}(\mathbf{X}[L])] + \frac{1}{k_B T} \sum_{u=0}^{L-1} \left[V(\mathbf{X}[u]) + \frac{\kappa}{2} \|\mathbf{X}[u+1] - \mathbf{X}[u]\|^2 \right] \quad (55)$$

$$\stackrel{(i)}{=} C + \underbrace{\frac{1}{k_B T} \sum_{u=0}^{L-1} \left[V(\mathbf{X}[u]) + \frac{\kappa}{2} \|\mathbf{X}[u+1] - \mathbf{X}[u]\|^2 \right]}_{\text{CoS objective described in (50)}} \quad (56)$$

where $\kappa = \frac{1}{2} \frac{\gamma_m}{\delta_u}$ 与 (i) 由我们方法的固定端点得出。注意，右侧第二项等于 (50) 中的 CoS 目标。因此，(54) 可视为经典弹性带方法的概率解释。与基于 (52) 的 NLL 相比，(55) 更符合路径参数化。它将每个网格点 $\mathbf{X}[u]$ (对所有 $u \in \mathbf{L}$) 推向 V 的低值，并惩罚粗糙增量，从而抑制 V 的振荡并产生更平滑的梯度，因此在尖锐势能（如分子系统）上训练更稳定。

B. 证明与推导

假设 B.1. 我们假设一个线性算子 $\mathcal{A} : \mathcal{H} \rightarrow \mathcal{H}$ 生成一个 C_0 -半群，且指数稳定、对某个 $i.e., \langle \mathcal{A}\mathbf{x}, \mathbf{x} \rangle_{\mathcal{H}} \leq -\lambda \|\mathbf{x}\|_{\mathcal{H}}^2$ 耗散 $\lambda > 0$ 、迹类 $i.e., \text{Tr}(\mathcal{A}) < \infty$ 且自伴 $i.e., \mathcal{A} = \mathcal{A}^\dagger$ 。我们还取一个 Q -维纳过程，其自伴迹类算子 Q 与 $\mathcal{A}$ $i.e., Q\mathcal{A} = \mathcal{A}Q$ 可交换。

假设 B.2. 对每个 $(\mathbf{x}, \alpha) \in \mathcal{H} \times \mathcal{U}$ ，映射 $t \mapsto f(t, \mathbf{x}, \alpha)$, $t \mapsto g(t, \mathbf{x}, \alpha)$ 和 $t \mapsto l(t, \mathbf{x}, \alpha)$ 是可预测的。函数 $h(\mathbf{x})$ 是 $\mathcal{F}_T$ -可测的。对每个 $(t, \alpha, \omega) \in [0, T] \times \mathcal{U} \times \Omega$ ，函数 f, g, l 和 h 关于 $\mathbf{x}$ 全局二次弗雷歇可微。导数 $D_{\mathbf{x}}f, D_{\mathbf{x}}g, D_{\mathbf{x}\mathbf{x}}f, D_{\mathbf{x}\mathbf{x}}g, D_{\mathbf{x}\mathbf{x}}l$ 和 $D_{\mathbf{x}\mathbf{x}}h$ 关于 $\mathbf{x}$ 连续且被常数 K 一致有界。此外，我们假设增长界：

$$|f(t, \mathbf{x}, \alpha)| + \|g(t, \mathbf{x}, \alpha)\| + \|D_{\mathbf{x}}l(t, \mathbf{x}, \alpha)\| + \|D_{\mathbf{x}}h(\mathbf{x})\| \leq K(1 + \|\mathbf{x}\|_{\mathcal{H}} + |\alpha|_{\mathcal{U}}), \quad (57)$$

$$|l(t, \mathbf{x}, \alpha)| + |h(\mathbf{x})| \leq K(1 + \|\mathbf{x}\|_{\mathcal{H}} + |\alpha|_{\mathcal{U}}^2). \quad (58)$$

假设 B.3. 函数 $\mathcal{V} : [0, T] \times \mathcal{H} \rightarrow \mathbb{R}$ 及其导数 $D_{\mathbf{x}}\mathcal{V}, D_{\mathbf{x}\mathbf{x}}\mathcal{V}, \partial_t \mathcal{V}$ 分别在 $[0, T] \times \mathcal{H}$ 和 $(0, T) \times \mathcal{H}$ 的有界子集上一致连续。此外，对所有 $(t, \mathbf{x}) \in (0, T) \times \mathcal{H}$ ，存在 $C_1, C_2 > 0$ 使得

$$|\mathcal{V}(t, \mathbf{x})| + |D_{\mathbf{x}}\mathcal{V}(t, \mathbf{x})| + |\partial_t \mathcal{V}(t, \mathbf{x})| + \|D_{\mathbf{x}\mathbf{x}}\mathcal{V}(t, \mathbf{x})\| + |\mathcal{A}^\dagger D_{\mathbf{x}}\mathcal{V}(t, \mathbf{x})| \leq C_1(1 + |\mathbf{x}|)^{C_2}. \quad (59)$$

B.1. 预备知识

本文回顾两个关键要素。第一个是希尔伯特空间半鞅的乘积法则，也称为随机分部积分。本文利用该法则推导伴随匹配目标。第二个是用于建立最优性的验证定理。

引理 B.4 (Stochastic integration). *Let $\mathcal{H}$ be a Hilbert space. Assume A, C are $\mathcal{H}$ -valued predictable processes, and $\int_0^T \mathbb{E} \|A_s\|^2 ds < \infty$ and $\int_0^T \mathbb{E} \|C_s\|^2 ds < \infty$ for every $T > 0$ and B, D are predictable processes with values in the Hilbert-Schmidt space $\mathcal{L}_2(U_Q, \mathcal{H})$ and $\int_0^T \mathbb{E} \|B_s\|_{\mathcal{L}_2}^2 ds < \infty$, $\int_0^T \mathbb{E} \|D_s\|_{\mathcal{L}_2}^2 ds < \infty$ for every $T > 0$. Then, let us define two stochastic convolutions:*

$$\mathbf{X}_t = \mathbf{X}_0 + \int_0^t A_s ds + \int_0^t B_s d\mathbf{W}_s^Q, \quad \mathbf{Y}_t = \mathbf{Y}_0 + \int_0^t C_s ds + \int_0^t D_s d\mathbf{W}_s^Q \quad (60)$$

则对所有 $t \geq 0$ ，几乎必然有：

$$\langle \mathbf{X}_t, \mathbf{Y}_t \rangle_{\mathcal{H}} = \langle \mathbf{X}_0, \mathbf{Y}_0 \rangle_{\mathcal{H}} + \int_0^t \langle \mathbf{Y}_s, A_s \rangle_{\mathcal{H}} ds + \int_0^t \langle \mathbf{X}_s, C_s \rangle_{\mathcal{H}} ds \quad (61)$$

$$+ \int_0^t \langle \mathbf{Y}_s, B_s d\mathbf{W}_s^Q \rangle_{\mathcal{H}} + \int_0^t \langle \mathbf{X}_s, D_s d\mathbf{W}_s^Q \rangle_{\mathcal{H}} + \int_0^t \text{Tr} [B_s Q D_s^\dagger] ds. \quad (62)$$

等价地，在微分形式下，

$$d\langle \mathbf{X}_t, \mathbf{Y}_t \rangle_{\mathcal{H}} = \langle \mathbf{Y}_t, A_t \rangle_{\mathcal{H}} dt + \langle \mathbf{X}_t, C_t \rangle_{\mathcal{H}} dt + \langle \mathbf{Y}_t, B_t d\mathbf{W}_t^Q \rangle_{\mathcal{H}} + \langle \mathbf{X}_t, D_t d\mathbf{W}_t^Q \rangle_{\mathcal{H}} + \text{Tr} [B_t Q D_t^\dagger] dt.$$

证明。定义 $\mathbb{R}$ -值过程 $\mathbf{Z}_t := \langle \mathbf{X}_t, \mathbf{Y}_t \rangle_{\mathcal{H}}$ 和 C^2 映射 $f: \mathcal{H} \times \mathcal{H} \rightarrow \mathbb{R}$ ，使得对任意 $f(\mathbf{x}, \mathbf{y}) = \langle \mathbf{x}, \mathbf{y} \rangle_{\mathcal{H}}$ 有 $\mathbf{x}, \mathbf{y} \in \mathcal{H}$ 。由于

$$D_{\mathbf{x}} f(\mathbf{x}, \mathbf{y}) = \mathbf{y}, D_{\mathbf{y}} f(\mathbf{x}, \mathbf{y}) = \mathbf{x}, D_{\mathbf{xx}} f(\mathbf{x}, \mathbf{y}) = 0, D_{\mathbf{yy}} f(\mathbf{x}, \mathbf{y}) = 0, \quad (63)$$

and $D_{\mathbf{xy}} f(\mathbf{x}, \mathbf{y})$ is the continuous bilinear form $(h, k) \rightarrow \langle h, k \rangle_{\mathcal{H}}$. Now, write the semi-martingale decomposition on $\mathcal{H} \times \mathcal{H}$:

$$(\mathbf{X}_t, \mathbf{Y}_t) = (\mathbf{X}_0, \mathbf{Y}_0) + \int_0^t (A_s, B_s) ds + \int_0^t \tilde{B}_s d\mathbf{W}_s^Q, \quad (64)$$

其中 $\tilde{B}_s: \mathcal{U} \rightarrow \mathcal{H} \times \mathcal{H}$ 满足 $\tilde{B}_s u = (B_s u, D_s u)$ 。通过对 f 在 $\mathcal{H} \times \mathcal{H}$ 上应用无穷维伊藤公式 (Da Prato 和 Zabczyk, 2014, 第 4.4 章)，得到：

$$d\mathbf{Z}_t = \langle D_{\mathbf{x}} f(\mathbf{X}_t, \mathbf{Y}_t), d\mathbf{X}_t \rangle_{\mathcal{H}} + \langle D_{\mathbf{y}} f(\mathbf{X}_t, \mathbf{Y}_t), d\mathbf{Y}_t \rangle_{\mathcal{H}} + \frac{1}{2} \text{Tr} \left[D_{\mathbf{xy}} f(\mathbf{X}_t, \mathbf{Y}_t) (\tilde{B}_t Q \tilde{B}_t^\dagger) \right] dt, \quad (65)$$

其中我们通过在 $\mathcal{U}$ 的任意标准正交基 $\{\phi^{(k)}\}_{k \geq 1}$ 上展开函数来计算迹：

$$\frac{1}{2} \text{Tr} \left[D_{\mathbf{xy}} f(\mathbf{X}_t, \mathbf{Y}_t) (\tilde{B}_t Q \tilde{B}_t^\dagger) \right] = \sum_{k \geq 1} \lambda^{(k)} \left(\langle B_t, \phi^{(k)} \rangle_{\mathcal{H}} + \langle D_t, \phi^{(k)} \rangle_{\mathcal{H}} \right) = \text{Tr} \left[B_t Q D_t^\dagger \right], \quad (66)$$

其中 $\lambda^{(k)}$ 是对应于特征基 $\phi^{(k)}$ 的特征值，使得 $Q\phi^{(k)} = \lambda^{(k)}\phi^{(k)}$ 。因此，

$$d\langle \mathbf{X}_t, \mathbf{Y}_t \rangle_{\mathcal{H}} = \langle \mathbf{Y}_t, d\mathbf{X}_t \rangle_{\mathcal{H}} + \langle \mathbf{X}_t, d\mathbf{Y}_t \rangle_{\mathcal{H}} + \text{Tr} \left[B_t Q D_t^\dagger \right] dt. \quad (67)$$

通过代入 $d\mathbf{X}_t = A_t dt + B_t d\mathbf{W}_t^Q$ 及 $d\mathbf{Y}_t = C_t dt + D_t d\mathbf{W}_t^Q$, we get the desired results. $\square$

引理 B.5 (验证定理)。设 $\mathcal{V}$ 为哈密顿-雅可比-贝尔曼 (HJB) 方程的解：

$$\partial_t \mathcal{V}_t + \mathcal{A} \mathcal{V}_t + \inf_{\alpha \in \mathbb{A}} \left[\langle \alpha, \sigma_t Q^{1/2} D_{\mathbf{x}} \mathcal{V}_t \rangle + \frac{1}{2} \|\alpha\|_{\mathcal{H}}^2 \right] = 0, \quad \mathcal{V}(T, \mathbf{x}) = g(\mathbf{x}) \quad (68)$$

且满足定理 B.3。则对每个 $\alpha \in \mathbb{A}$ ，有 $\mathcal{V}(0, \mathbf{x}_0) \leq \mathcal{J}(\alpha, \mathbb{P}^\alpha)$ 。现设 $(\alpha^*, \mathbf{X}^*)$ 为容许对，使得

$$\alpha_t^*(t, \mathbf{X}_t^*) = \arg \inf_{\alpha \in \mathbb{A}} \left[\langle \alpha_t, \sigma_t Q^{1/2} D_{\mathbf{x}} \mathcal{V}_t \rangle + \frac{1}{2} \|\alpha_t\|_{\mathcal{H}}^2 \right] = -\sigma_t Q^{1/2} D_{\mathbf{x}} \mathcal{V}(t, \mathbf{X}_t^*) \quad (69)$$

对几乎每个 $t \in [0, T]$ 且 $\mathbb{P}$ -几乎必然成立。则 $(\alpha^*, \mathbf{X}^*)$ 满足 $\mathcal{V}(0, \mathbf{x}_0) = \mathcal{J}(\alpha^*, \mathbb{P}^*)$ 。

证明。开始证明时，我们形式化地最小化 $F(D_{\mathbf{x}} \mathcal{V})$ 。利用 (Da Prato 和 Zabczyk, 1997) 的结果，得到候选极小化子并相应进行：

$$F(\mathbf{x}) = \inf_{\alpha \in \mathbb{A}} \left[\langle \mathbf{x}, \alpha \rangle + \frac{1}{2} \|\alpha\|_{\mathcal{H}}^2 \right] = -\frac{1}{2} \|\mathbf{x}\|_{\mathcal{H}}^2. \quad (70)$$

因此， $F(\sigma_t Q^{1/2} D_{\mathbf{x}} \mathcal{V})$ 在 $\alpha^* = -\sigma_t Q^{1/2} D_{\mathbf{x}} \mathcal{V}$ 处取得最小值。接下来，对 $\mathcal{V}$ 应用伊藤公式 (Da Prato 和 Zabczyk, 2014, 第 4.4 章)，并在两边取期望，得到

$$\mathbb{E}_{\mathbb{P}^\alpha} [\mathcal{V}(T, \mathbf{X}_T^\alpha)] = \mathbb{E}_{\mathbb{P}^\alpha} [g(\mathbf{X}_T^\alpha)] = \quad (71)$$

$$= \mathcal{V}(0, \mathbf{x}_0) + \mathbb{E}_{\mathbb{P}^\alpha} \left[\int_0^T \left(\partial_t \mathcal{V}(t, \mathbf{X}_t^\alpha) + \mathcal{A}\mathcal{V}(t, \mathbf{X}_t^\alpha) + \langle \sigma_t Q^{1/2} D_{\mathbf{x}} \mathcal{V}(t, \mathbf{X}_t^\alpha), \alpha_t \rangle_{\mathcal{H}} \right) dt \right], \quad (72)$$

利用 $\mathcal{V}$ 满足 (69)，将 $\mathbb{E}_{\mathbb{P}^\alpha} \left[\int_0^T \frac{1}{2} \|\alpha_t\|_{\mathcal{H}}^2 dt \right]$ 加到 $\frac{1}{2} \|\alpha_t\|_{\mathcal{H}}^2 dt$ 两边。则 (71) 的左边变为：

$$\mathbb{E}_{\mathbb{P}^\alpha} \left[g(\mathbf{X}_T^\alpha) + \int_0^T \frac{1}{2} \|\alpha_t\|_{\mathcal{H}}^2 dt \right] = \mathcal{J}(\alpha, \mathbb{P}^\alpha). \quad (73)$$

现在处理方程 (71) 的右边：

$$\mathcal{V}(0, \mathbf{x}_0) + \mathbb{E}_{\mathbb{P}^\alpha} \left[\int_0^T \left(\frac{1}{2} \|\alpha_t\|_{\mathcal{H}}^2 + \partial_t \mathcal{V}(t, \mathbf{X}_t^\alpha) + \mathcal{A}\mathcal{V}(t, \mathbf{X}_t^\alpha) + \langle \sigma_t Q^{1/2} D_{\mathbf{x}} \mathcal{V}(t, \mathbf{X}_t^\alpha), \alpha_t \rangle_{\mathcal{H}} \right) dt \right] \quad (74)$$

$$\stackrel{(i)}{=} \mathcal{V}(0, \mathbf{x}_0) + \mathbb{E}_{\mathbb{P}^\alpha} \left[\int_0^T \left(\langle \sigma_t Q^{1/2} D_{\mathbf{x}} \mathcal{V}(t, \mathbf{X}_t^\alpha), \alpha_t \rangle_{\mathcal{H}} + \frac{1}{2} \|\alpha_t\|_{\mathcal{H}}^2 - F(\sigma_t Q^{1/2} D_{\mathbf{x}} \mathcal{V}(t, \mathbf{X}_t^\alpha)) \right) dt \right]. \quad (75)$$

这里 (i) 成立，因为我们加上并减去 $\mathbb{E}_{\mathbb{P}^\alpha} \left[\int_0^T F(D_{\mathbf{x}} \mathcal{V}(t, \mathbf{X}_t^\alpha)) dt \right]$ ，并再次利用 $\mathcal{V}$ 满足 (69)。因此，我们得到以下方程：

$$\mathcal{J}(\alpha, \mathbb{P}^\alpha) = \mathcal{V}(0, \mathbf{x}_0) \quad (76)$$

$$+ \mathbb{E}_{\mathbb{P}^\alpha} \left[\int_0^T \left(\langle \sigma_t Q^{1/2} D_{\mathbf{x}} \mathcal{V}(t, \mathbf{X}_t^\alpha), \alpha_t \rangle_{\mathcal{H}} + \frac{1}{2} \|\alpha_t\|_{\mathcal{H}}^2 - F(\sigma_t Q^{1/2} D_{\mathbf{x}} \mathcal{V}(t, \mathbf{X}_t^\alpha)) \right) dt \right]. \quad (77)$$

By definition, $\left[\langle \sigma_t Q^{1/2} D_{\mathbf{x}} \mathcal{V}(t, \mathbf{X}_t^\alpha), \alpha_t \rangle_{\mathcal{H}} + \frac{1}{2} \|\alpha_t\|_{\mathcal{H}}^2 - F(\sigma_t Q^{1/2} D_{\mathbf{x}} \mathcal{V}(t, \mathbf{X}_t^\alpha)) \right]$ 在 $\alpha_t \in \mathcal{H}$ 上的下确界是 $F(\sigma_t Q^{1/2} D_{\mathbf{x}} \mathcal{V}(t, \mathbf{X}_t^\alpha))$ 。因此，在 (77) 的右边对 α_t 取上确界，得到 $\mathcal{J}(\alpha, \mathbb{P}^\alpha) \geq \mathcal{V}(0, \mathbf{x}_0)$ 。我们已经验证 $F(\sigma_t Q^{1/2} D_{\mathbf{x}} \mathcal{V})$ 在 $\alpha_t^* = -\sigma_t Q^{1/2} D_{\mathbf{x}} \mathcal{V}$ 处取得下确界，所以选择 $u = \alpha$ 。Then,

$$\left[\langle \sigma Q^{1/2} D_{\mathbf{x}} \mathcal{V}(s, \mathbf{X}_s^u), u_s \rangle_{\mathcal{H}} + \frac{1}{2} \|u_s\|_{\mathcal{H}}^2 \right] - F(\sigma Q^{1/2} D_{\mathbf{x}} \mathcal{V}(s, \mathbf{X}_s^u)) = 0. \quad (78)$$

因此，我们得到 $\mathcal{J}(u, \mathbb{P}^u) = \mathcal{V}(0, \mathbf{x}_0)$ 。结合 (76)，我们得出结论： $(\alpha^*, \mathbf{X}^{\alpha^*})$ 对于 $(t, \mathbf{x}) \in [0, T] \times \mathcal{H}$ 是最优的。证明完毕。□

B.2. 路径测度间发散的推导

本文给出吉萨诺夫定理 (Girsanov Theorem) 的无穷维推广 (Da Prato 和 Zabczyk, 2014, 定理 10.14)，该定理在估计两条路径之间的发散时起着关键作用。定理 B.6 (广义吉萨诺夫)。设 $\{\zeta_t\}_{0 \leq t \leq T}$ be a $\mathcal{U}$ 值可预测过程使得

$$\mathbb{P} \left(\int_0^T \|\zeta_t\|_{\mathcal{U}}^2 dt < \infty \right) = 1, \quad \mathbb{E} \left[\exp \left(\int_0^T \langle \zeta_t, d\mathbf{W}_t^Q \rangle_{\mathcal{U}} - \frac{1}{2} \int_0^T \|\zeta_t\|_{\mathcal{U}}^2 dt \right) \right] = 1. \quad (79)$$

则过程 $\tilde{\mathbf{W}}_t^Q = \mathbf{W}_t^Q - \int_0^t \zeta_s ds$ is a Q 关于概率空间 $(\Omega, \mathcal{F}, \mathbb{Q})$ 上的滤子是维纳过程 (Wiener Process)，其中

$$d\mathbb{Q} = \exp \left(\int_0^T \langle \zeta_t, d\mathbf{W}_t^Q \rangle_{\mathcal{U}} - \frac{1}{2} \int_0^T \|\zeta_t\|_{\mathcal{U}}^2 dt \right) d\mathbb{P}. \quad (80)$$

Or alternatively, by substituting $\mathbf{W}_t^Q = \tilde{\mathbf{W}}_t^Q + \int_0^t \zeta_s ds$ to (85), 我们得到

$$d\mathbb{Q} = \exp \left(\int_0^T \langle \zeta_t, d\tilde{\mathbf{W}}_t^Q \rangle_{\mathcal{U}} + \frac{1}{2} \int_0^T \|\zeta_t\|_{\mathcal{U}}^2 dt \right) d\mathbb{P}. \quad (81)$$

证明。证明可参见 (Da Prato 和 Zabczyk, 2014, 定理 10.14) $\square$

定义 $\zeta_t = Q^{1/2}\alpha_t$ 。对于 $\mathbb{P}^\alpha$ Q -维纳过程 $\tilde{\mathbf{W}}_t^Q, \mathbf{W}_t^Q = \tilde{\mathbf{W}}_t^Q + \int_0^t Q^{1/2}\alpha_s ds$ is a Q 上的维纳过程 $\mathbb{P}$
because

$$d\mathbf{X}_t = A\mathbf{X}_t dt + \sigma_t Q^{1/2}\alpha_t dt + \sigma_t d\tilde{\mathbf{W}}_t^Q \quad (82)$$

$$= A\mathbf{X}_t dt + \sigma_t Q^{1/2}\alpha_t dt + \sigma_t [d\mathbf{W}_t^Q - Q^{1/2}\alpha_t dt] \quad (83)$$

$$= A\mathbf{X}_t dt + \sigma_t dW_t^Q \quad (84)$$

因此, 我们得到

$$d\mathbb{P}^\alpha = \exp\left(\int_0^T \langle \zeta_s, d\tilde{\mathbf{W}}_s^Q \rangle_{\mathcal{U}} + \frac{1}{2} \int_0^T \|\zeta_s\|_{\mathcal{U}}^2 dt\right) d\mathbb{P}. \quad (85)$$

现在, 通过对 (10) 进行测度变换, 我们得到以下关系:

$$d\mathbb{P}^\star = \frac{1}{\tilde{\mathcal{Z}}} e^{-U(\mathbf{X}_T) - \log q_T(\mathbf{X}_T)} d\mathbb{P} \quad (86)$$

$$= \frac{1}{\tilde{\mathcal{Z}}} e^{-U(\mathbf{X}_T^\alpha) - \log q_T(\mathbf{X}_T^\alpha)} \frac{d\mathbb{P}}{d\mathbb{P}^\alpha} d\mathbb{P}^\alpha, \quad (87)$$

where $\tilde{\mathcal{Z}} = \mathbb{E}\left[\frac{1}{\tilde{\mathcal{Z}}} e^{-U(\mathbf{X}_T) - \log q_T(\mathbf{X}_T)}\right]$ 是归一化常数。结合 (85) 和 (87) 并在两边取对数, we get

$$\log \frac{d\mathbb{P}^\star}{d\mathbb{P}^\alpha} = \log \frac{1}{\tilde{\mathcal{Z}}} e^{-U(\mathbf{X}_T^\alpha) - \log q_T(\mathbf{X}_T^\alpha)} + \log \frac{d\mathbb{P}}{d\mathbb{P}^\alpha} \quad (88)$$

$$= -U(\mathbf{X}_T^\alpha) - \log q_T(\mathbf{X}_T^\alpha) - \int_0^T \langle \zeta_t, d\tilde{\mathbf{W}}_t^Q \rangle_{\mathcal{U}} - \frac{1}{2} \int_0^T \|Q^{1/2}\alpha_t\|_{\mathcal{U}}^2 dt - \log \tilde{\mathcal{Z}}. \quad (89)$$

Since $\mathbf{W}_t^Q$ 是 $\mathbb{P}^\alpha$ Q -维纳过程, 对 (89) 关于 $\mathbb{P}^\alpha$ 取期望, 我们得到

$$\mathbb{E}_{\mathbb{P}^\alpha} \left[\frac{d\mathbb{P}^\star}{d\mathbb{P}^\alpha} \right] = \mathbb{E}_{\mathbb{P}^\alpha} \left[\frac{1}{2} \int_0^T \|Q^{1/2}\alpha_t\|_{\mathcal{U}}^2 dt + (U(\mathbf{X}_T^\alpha) + \log q_T(\mathbf{X}_T^\alpha)) \right] + \log \tilde{\mathcal{Z}}. \quad (90)$$

那么, 由于 $\tilde{\mathcal{Z}}$ 是常数, 我们得到所需的 KL 散度最小化目标:

$$\min_{\alpha} D_{\text{KL}}(\mathbb{P}^\alpha | \mathbb{P}^\star) = \min_{\alpha} \mathbb{E}_{\mathbb{P}^\alpha} \left[\frac{1}{2} \int_0^T \|Q^{1/2}\alpha_t\|_{\mathcal{U}}^2 dt + (U(\mathbf{X}_T^\alpha) + \log q_T(\mathbf{X}_T^\alpha)) \right]. \quad (91)$$

B.3. 引理 1 的证明

引理 1 (有限归一化常数)。假设 $U(\mathbf{x}) \geq \beta \|\mathbf{x}\|_{\mathcal{H}}^2 - C$ 具有常数 $\beta, C > 0$ 。那么, 对于任意 $\text{Tr}(Q) < \infty$, 在 (6) 中选择 $\nu = \mathcal{N}(0, Q)$ 会得到有限的归一化常数 $\mathcal{Z} < \infty$ 。

证明。Fernique 可积性定理 (Da Prato 和 Zabczyk, 2014, 定理 2.7) 指出, 对于可分 Banach 空间 $\mathcal{B}$ (特别是在 $\mathcal{H}$ 上) 上的任意中心高斯测度 $\nu = \mathcal{N}(0, Q)$ 以及任意 $\text{Tr}(Q) < \infty$, 存在 $r > 0$ 使得 $\int_{\mathcal{H}} e^{r\|\mathbf{x}\|_{\mathcal{H}}^2} d\nu(\mathbf{x}) < \infty$ 。由于能量满足二次下界 $U(\mathbf{x}) \geq \beta \|\mathbf{x}\|_{\mathcal{H}}^2 - C$, 我们得到 $e^{-U(\mathbf{x})} \leq \tilde{C} e^{-\beta \|\mathbf{x}\|_{\mathcal{H}}^2}$, 其中 $\tilde{C} = e^C$ 。因此, 我们得到:

$$\mathcal{Z} = \int_{\mathcal{H}} e^{-U(\mathbf{x})} d\nu(\mathbf{x}) \leq \tilde{C} \int_{\mathcal{H}} e^{-\beta \|\mathbf{x}\|_{\mathcal{H}}^2} d\nu(\mathbf{x}) \leq \tilde{C} \int_{\mathcal{H}} e^{r\|\mathbf{x}\|_{\mathcal{H}}^2} d\nu(\mathbf{x}) < \infty, \quad (92)$$

这证实了配分函数 $\mathcal{Z}$ 是有限的。 $\square$

B.4. 定理 2 的证明

定理 2 (显式 RND)。设定理 B.1 成立。则对于任意 $0 < t < \infty$ 和初始条件 $\mathbf{x}_0 \in \mathcal{H}$, $\nu_t^{\mathbf{x}_0} = \mathcal{N}(e^{tA}\mathbf{x}_0, Q_t)$ 与 $\nu_\infty = \mathcal{N}(0, Q_\infty)$ 是相互绝对连续的。此外, 对于任意 $\mathbf{x} \in \mathcal{H}$, 我们得到如下定义的显式 RND $q_t(\mathbf{x}_0, \mathbf{x}) := \frac{d\nu_t^{\mathbf{x}_0}}{d\nu_\infty}(\mathbf{x})$:

$$q_t(\mathbf{x}_0, \mathbf{x}) = \det(\Theta_t)^{-\frac{1}{2}} \exp \left[-\frac{1}{2} \langle \Theta_t^{-1} \mathbf{m}_t^{\mathbf{x}_0}, \mathbf{m}_t^{\mathbf{x}_0} \rangle_\infty + \langle \Theta_t^{-1} \mathbf{m}_t^{\mathbf{x}_0}, \mathbf{x} \rangle_\infty - \frac{1}{2} \langle e^{2tA} \Theta_t^{-1} \mathbf{x}, \mathbf{x} \rangle_\infty \right], \quad (9)$$

where we define $\mathbf{m}_t^{\mathbf{x}_0} = e^{tA}\mathbf{x}_0$, $\Theta_t = 1 - e^{2tA}$ and Q_∞ norm $\langle u, v \rangle_\infty := \langle Q_\infty^{-\frac{1}{2}}u, Q_\infty^{-\frac{1}{2}}v \rangle_{\mathcal{H}}$.

证明。由式 (39), 我们得到协方差恒等式:

$$Q_t = \int_0^t \sigma_{t-r}^2 e^{rA} Q e^{rA^\dagger} dr \quad (93)$$

$$= \int_0^t \sigma_\infty^2 e^{rA} Q e^{rA^\dagger} dr + \int_0^t (\sigma_{t-r}^2 - \sigma_\infty^2) e^{rA} Q e^{rA^\dagger} dr \quad (94)$$

$$= Q_\infty - \int_t^\infty e^{rA} Q e^{rA^\dagger} dr + \int_0^t (\sigma_{t-r}^2 - \sigma_\infty^2) e^{rA} Q e^{rA^\dagger} dr \quad (95)$$

$$= Q_\infty - e^{tA} Q_\infty e^{tA^\dagger} + \int_0^t (\sigma_{t-r}^2 - \sigma_\infty^2) e^{rA} Q e^{rA^\dagger} dr. \quad (96)$$

由于 $\int_0^t (\sigma_{t-r}^2 - \sigma_\infty^2) e^{rA} Q e^{rA^\dagger} dr \rightarrow o(1)$ 当我们选择 $\sigma_t \rightarrow \sigma_\infty$ 时, 我们得到关系式:

$$Q_t \approx Q_\infty - e^{tA} Q_\infty e^{tA^\dagger} = Q_\infty^{1/2} \Theta_t Q_\infty^{1/2}. \quad (97)$$

因此, 通过应用 (Da Prato 和 Zabczyk, 2002, 命题 1.3.11), 对于两个中心高斯分布 $\mathcal{N}(0, Q_t)$ 和 $\mathcal{N}(0, Q_\infty)$,

$$q_t(0, \mathbf{x}) = \frac{d\mathcal{N}(0, Q_t)}{d\mathcal{N}(0, Q_\infty)}(\mathbf{x}) = \det(\Theta)^{-\frac{1}{2}} \exp \left[-\frac{1}{2} \langle e^{2tA} \Theta^{-1} \mathbf{x}, \mathbf{x} \rangle_\infty \right]. \quad (98)$$

现在, 对于从中心情形到一般均值函数 $e^{tA}\mathbf{x}_0$ 的平移, 我们利用卡梅隆-马丁定理 (Da Prato 和 Zabczyk, 2002, 定理 1.3.6)。该定理表明:

$$\frac{d\mathcal{N}(e^{tA}\mathbf{x}_0, Q_t)}{d\mathcal{N}(0, Q_t)}(\mathbf{x}) = \exp \left[\langle Q_t^{-\frac{1}{2}} e^{tA}\mathbf{x}_0, Q_t^{-\frac{1}{2}} \mathbf{x} \rangle_{\mathcal{H}} - \frac{1}{2} \langle Q_t^{-\frac{1}{2}} e^{tA}\mathbf{x}_0, Q_t^{-\frac{1}{2}} e^{tA}\mathbf{x}_0 \rangle_{\mathcal{H}} \right] \quad (99)$$

$$= \exp \left[\langle Q_\infty^{\frac{1}{2}} Q_t^{-1} e^{tA}\mathbf{x}_0, Q_\infty^{-\frac{1}{2}} \mathbf{x} \rangle_{\mathcal{H}} - \frac{1}{2} \langle Q_\infty^{\frac{1}{2}} Q_t^{-1} e^{tA}\mathbf{x}_0, Q_\infty^{-\frac{1}{2}} e^{tA}\mathbf{x}_0 \rangle_{\mathcal{H}} \right] \quad (100)$$

$$\stackrel{(i)}{=} \exp \left[\langle \Theta^{-1} Q_\infty^{-\frac{1}{2}} e^{tA}\mathbf{x}_0, Q_\infty^{-\frac{1}{2}} \mathbf{x} \rangle_{\mathcal{H}} - \frac{1}{2} \langle \Theta^{-1} Q_\infty^{-\frac{1}{2}} e^{tA}\mathbf{x}_0, Q_\infty^{-\frac{1}{2}} e^{tA}\mathbf{x}_0 \rangle_{\mathcal{H}} \right] \quad (101)$$

$$= \exp \left[\langle \Theta^{-1} \mathbf{m}_t^{\mathbf{x}_0}, \mathbf{x} \rangle_\infty - \frac{1}{2} \langle \Theta^{-1} \mathbf{m}_t^{\mathbf{x}_0}, \mathbf{m}_t^{\mathbf{x}_0} \rangle_\infty \right], \quad (102)$$

其中 (i) 由式 (97) 得出, 使得 $\Theta^{-1} Q_\infty^{-1/2}$ 。因 $(Q_t^{-1/2} Q_\infty^{1/2})^\dagger Q_t^{-1/2} = Q_\infty^{1/2} Q_t^{-1}$ 此, 通过链式法则, 我们得到所需结果:

$$q_t(\mathbf{x}_0, \mathbf{x}) := \frac{d\mathcal{N}(e^{tA}\mathbf{x}_0, Q_t)}{d\mathcal{N}(0, Q_t)} \frac{d\mathcal{N}(0, Q_t)}{d\mathcal{N}(0, Q_\infty)}(\mathbf{x}) \quad (103)$$

$$= \det(\Theta)^{-\frac{1}{2}} \exp \left[-\frac{1}{2} \langle \Theta^{-1} \mathbf{m}_t^{\mathbf{x}_0}, \mathbf{m}_t^{\mathbf{x}_0} \rangle_\infty + \langle \Theta^{-1} \mathbf{m}_t^{\mathbf{x}_0}, \mathbf{x} \rangle_\infty - \frac{1}{2} \langle e^{2tA} \Theta^{-1} \mathbf{x}, \mathbf{x} \rangle_\infty \right] \quad (104)$$

证明完毕。 $\square$

B.5. 命题 4 的证明

命题 4 (在 $\mathcal{H}$ 中的伴随匹配) 考虑以下无限维匹配目标:

$$\mathcal{L}(\theta) = \int_0^T \mathbb{E}_{\mathbb{P}^\alpha} \left[\frac{1}{2} \|\alpha^\theta(\mathbf{X}_t^\alpha, t) + \sigma_t Q^{1/2} \mathbf{Y}_t^\alpha\|_{\mathcal{H}}^2 \right] dt \quad (18)$$

$$d\mathbf{Y}_t^\alpha = -\mathcal{A}^\dagger \mathbf{Y}_t^\alpha dt + \mathbf{Z}_t^\alpha d\mathbf{W}_t^Q, \quad \mathbf{Y}_T^\alpha = D_{\mathbf{x}} g(\mathbf{X}_T^\alpha). \quad (19)$$

其中 $\bar{\alpha} :=$ 停止梯度 (α^θ) 。则 $\mathcal{L}$ 的临界点即为 (12) 中随机最优控制问题的最优控制 α^* 。

证明。设 $\mathbf{X}^\theta := \mathbf{X}^{\alpha^\theta}$ 为具有参数化控制策略 α^θ 的受控过程, 且 $\xi_t := \partial_\theta \mathbf{X}_t^\theta$ 为 $\mathbf{X}^\theta$ 关于 θ 的变分过程。由于扩散系数 σ_t 与 θ 无关, 通过对 (11) 关于 θ 求导, 我们得到变分过程的微分方程如下:

$$d\xi_t = \mathcal{A}\xi_t dt + \sigma_t Q^{1/2} (D_{\mathbf{x}} \alpha^\theta(\mathbf{X}_t^\theta, t) \xi_t + \partial_\theta \alpha^\theta(\mathbf{X}_t^\theta, t)) dt, \quad \xi_t = 0. \quad (105)$$

现在, 我们定义具有 $\mathbb{P}^\theta := \mathbb{P}^{\alpha^\theta}$ 的代价泛函:

$$\mathcal{J}(\alpha^\theta, \mathbb{P}^\theta) = \mathbb{E}_{\mathbb{P}^\theta} \left[\int_0^T \frac{1}{2} \|\alpha^\theta(t, \mathbf{X}_t^\theta)\|_{\mathcal{H}}^2 dt + g(\mathbf{X}_T^\theta) \right]. \quad (106)$$

然后, 对代价泛函 (106) 关于 θ 求导得到:

$$\frac{d}{d\theta} \mathcal{J}(\alpha^\theta, \mathbb{P}^\theta) = \mathbb{E}_{\mathbb{P}^\theta} \left[\int_0^T \langle \alpha^\theta(\mathbf{X}_t^\theta, t), D_{\mathbf{x}} \alpha^\theta(\mathbf{X}_t^\theta, t) \xi_t + \partial_\theta \alpha^\theta(\mathbf{X}_t^\theta, t) \rangle_{\mathcal{H}} dt + \langle D_{\mathbf{x}} g(\mathbf{X}_T^\theta), \xi_T \rangle_{\mathcal{H}} \right]. \quad (107)$$

接下来, 将定理 B.4 应用于 $\langle \mathbf{Y}^\theta, \xi_t \rangle_{\mathcal{H}}$, 我们得到:

$$d\langle \mathbf{Y}_t^\theta, \xi_t \rangle_{\mathcal{H}} = \langle d\mathbf{Y}_t^\theta, \xi_t \rangle_{\mathcal{H}} + \langle \mathbf{Y}_t^\theta, d\xi_t \rangle_{\mathcal{H}} \quad (108)$$

$$\stackrel{(i)}{=} \langle -\mathcal{A}^\dagger \mathbf{Y}_t^\theta, \xi_t \rangle_{\mathcal{H}} dt + \langle \mathbf{Z}_t^\theta d\mathbf{W}_t^Q, \xi_t \rangle_{\mathcal{H}} \quad (109)$$

$$+ \langle \mathbf{Y}_t^\theta, \mathcal{A}\xi_t + \sigma_t Q^{1/2} (D_{\mathbf{x}} \alpha^\theta(\mathbf{X}_t^\theta, t) \xi_t + \partial_\theta \alpha^\theta(\mathbf{X}_t^\theta, t)) \rangle_{\mathcal{H}} \quad (110)$$

$$\stackrel{(ii)}{=} \langle \mathbf{Y}_t^\theta, \sigma_t Q^{1/2} (D_{\mathbf{x}} \alpha^\theta(\mathbf{X}_t^\theta, t) \xi_t + \partial_\theta \alpha^\theta(\mathbf{X}_t^\theta, t)) \rangle_{\mathcal{H}} dt + \langle \mathbf{Z}_t^\theta d\mathbf{W}_t^Q, \xi_t \rangle_{\mathcal{H}} \quad (111)$$

其中 (i) 成立是因为二次协变 $[\xi, \mathbf{Y}^\theta]_t$ 被消去, 因为 ξ 没有鞅项, 而 (ii) 由 $\mathcal{A}$ 和 $Q^{1/2}$ 的伴随性得出, 使得 *i.e.*, $\langle \mathcal{A}^\dagger u, v \rangle_{\mathcal{H}} = \langle u, \mathcal{A}v \rangle_{\mathcal{H}}$ 。由于 $\xi_0 = 0$ 和 $\mathbf{Y}_T^\theta = D_{\mathbf{x}} g(\mathbf{X}_T^\theta)$, 通过对 (108) 积分并取期望, 我们得到:

$$\mathbb{E}_{\mathbb{P}^\theta} [\langle D_{\mathbf{x}} g(\mathbf{X}_T^\theta), \xi_T \rangle] = \mathbb{E}_{\mathbb{P}^\theta} \left[\int_0^T d\langle \mathbf{Y}_t^\theta, \xi_t \rangle_{\mathcal{H}} \right] \quad (112)$$

$$= \mathbb{E}_{\mathbb{P}^\theta} \left[\int_0^T \langle \mathbf{Y}_t^\theta, \sigma_t Q^{1/2} (D_{\mathbf{x}} \alpha^\theta(\mathbf{X}_t^\theta, t) \xi_t + \partial_\theta \alpha^\theta(\mathbf{X}_t^\theta, t)) \rangle_{\mathcal{H}} dt \right]. \quad (113)$$

最后, 将 (112) 代入 (107), 我们得到:

$$\frac{d}{d\theta} \mathcal{J}(\alpha^\theta, \mathbb{P}^\theta) \stackrel{(i)}{=} \mathbb{E}_{\mathbb{P}^\theta} \left[\int_0^T \langle \alpha^\theta(\mathbf{X}_t^\theta, t) + \sigma_t Q^{1/2} \mathbf{Y}_t^\theta, D_{\mathbf{x}} \alpha^\theta(\mathbf{X}_t^\theta, t) \xi_t + \partial_\theta \alpha^\theta(\mathbf{X}_t^\theta, t) \rangle_{\mathcal{H}} dt \right], \quad (114)$$

其中 (i) 由 $Q^{1/2}$ 的伴随性和标量 σ_t 得出。由于 $\bar{\alpha} =$ 停止梯度 (α^θ) 仅阻断梯度, $\bar{\alpha}(t, \mathbf{x}) =$

$\alpha^\theta(t, \mathbf{x})$ 以逐点方式。因此，前向定律满足 $\mathbb{P}^\theta = \mathbb{P}^{\bar{\alpha}}$ 。因此，由 (114)，我们可以定义

$$\frac{d}{d\theta} \mathcal{J}(\alpha^\theta, \mathbb{P}^{\bar{\alpha}}) \stackrel{(i)}{=} \mathbb{E}_{\mathbb{P}^{\bar{\alpha}}} \left[\int_0^T \langle \alpha^\theta(\mathbf{X}_t^{\bar{\alpha}}, t) + \sigma_t Q^{1/2} \mathbf{Y}_t^{\bar{\alpha}}, \partial_\theta \alpha^\theta(\mathbf{X}_t^{\bar{\alpha}}, t) \rangle_{\mathcal{H}} dt \right] \quad (115)$$

$$= \mathbb{E}_{\mathbb{P}^{\bar{\alpha}}} \left[\int_0^T \langle \alpha^\theta(\mathbf{X}_t^{\bar{\alpha}}, t), \partial_\theta \alpha^\theta(\mathbf{X}_t^{\bar{\alpha}}, t) \rangle_{\mathcal{H}} + \langle \sigma_t Q^{1/2} \mathbf{Y}_t^{\bar{\alpha}}, \partial_\theta \alpha^\theta(\mathbf{X}_t^{\bar{\alpha}}, t) \rangle_{\mathcal{H}} dt \right] \quad (116)$$

$$= \mathbb{E}_{\mathbb{P}^{\bar{\alpha}}} \left[\int_0^T \frac{1}{2} \partial_\theta \left\| \alpha^\theta(\mathbf{X}_t^{\bar{\alpha}}, t) + \sigma_t Q^{1/2} \mathbf{Y}_t^{\bar{\alpha}} \right\|_{\mathcal{H}}^2 dt \right] \quad (117)$$

$$\stackrel{(ii)}{=} \partial_\theta \int_0^T \mathbb{E}_{\mathbb{P}^{\bar{\alpha}}} \left[\frac{1}{2} \left\| \alpha^\theta(\mathbf{X}_t^{\bar{\alpha}}, t) + \sigma_t Q^{1/2} \mathbf{Y}_t^{\bar{\alpha}} \right\|_{\mathcal{H}}^2 \right] dt \quad (118)$$

$$= \frac{d}{d\theta} \mathcal{L}(\theta), \quad (119)$$

其中 (i) 通过将 $\mathbb{P}^{\bar{\alpha}}$ 代入 (114) 得到，而 $D_{\mathbf{x}} \alpha^\theta \xi_t$ 因停止梯度操作阻断了通过 $\mathbf{X}_t^{\bar{\alpha}}$ 的梯度而消失（在 105 (i.e., $\xi_t = 0$) 中），且 (ii) 由控制收敛得出。因此，由 SMP 平稳性：

$$\alpha^\theta(\mathbf{X}_t^\theta, t) + \sigma_t Q^{1/2} \mathbf{Y}_t^\theta = \alpha^\theta(\mathbf{X}_t^{\bar{\alpha}}, t) + \sigma_t Q^{1/2} \mathbf{Y}_t^{\bar{\alpha}} = 0, \quad t \in [0, T], \quad (120)$$

我们得到 $d_{d\theta} \mathcal{J}(\alpha^\theta, \mathbb{P}^{\bar{\alpha}}) = d_{d\theta} \mathcal{L}(\theta) = 0$ 。这意味着 (12) 中的 SOC 目标与 (18) 中的匹配目标具有相同的临界点。

现在，让我们验证 (120) 中的临界点 $\alpha^\theta(\mathbf{X}_t^{\bar{\alpha}}, t) = -\sigma_t Q^{1/2} \mathbf{Y}_t^{\bar{\alpha}}$ 是 (12) 中 SOC 问题的最优控制 α^* 。为此，假设存在 $\mathcal{V}$ 是满足定理 B.3 的 HJB 方程 (68) 的解。然后，应用伊藤公式，我们有：

$$d\mathcal{V}(t, \mathbf{X}_t^\theta) = [\partial_t \mathcal{V}_t + \langle \mathcal{A} \mathbf{X}_t^\theta, D_{\mathbf{x}} \mathcal{V}_t \rangle_{\mathcal{H}} \quad (121)$$

$$+ \frac{1}{2} \text{Tr}(\sigma_t^2 Q D_{\mathbf{xx}} \mathcal{V}_t) + \langle \sigma_t Q^{1/2} \alpha_t^\theta, D_{\mathbf{x}} \mathcal{V}_t \rangle_{\mathcal{H}}] dt + \langle D_{\mathbf{x}} \mathcal{V}, \sigma_t d\mathbf{W}_t^Q \rangle_{\mathcal{H}} \quad (122)$$

$$\stackrel{(i)}{=} [\langle \alpha_t^\theta, \sigma_t Q^{1/2} D_{\mathbf{x}} \mathcal{V}_t \rangle_{\mathcal{H}} - F(\sigma_t Q^{1/2} D_{\mathbf{x}} \mathcal{V}_t)] dt + \langle D_{\mathbf{x}} \mathcal{V}, \sigma_t d\mathbf{W}_t^Q \rangle_{\mathcal{H}}, \quad (123)$$

where (i) follows from the definition of HJB equation (68) and we define $F(\sigma_t Q^{1/2} D_{\mathbf{x}} \mathcal{V}_t) := \inf_{\alpha \in \mathbb{A}} [\langle \alpha_t, \sigma_t Q^{1/2} D_{\mathbf{x}} \mathcal{V}_t \rangle_{\mathcal{H}} + \frac{1}{2} \|\alpha_t\|_{\mathcal{H}}^2]$. Now, assume $\mathbf{Y}_t^\theta := D_{\mathbf{x}} \mathcal{V}_t$ and $\mathbf{Z}_t^\theta := D_{\mathbf{xx}} \mathcal{V}_t$ and apply the Itô formula, then we get

$$d\mathbf{Y}_t^\theta = [\partial_t D_{\mathbf{x}} \mathcal{V}_t + \langle \mathcal{A} \mathbf{X}_t^\theta, D_{\mathbf{xx}} \mathcal{V}_t \rangle_{\mathcal{H}} \quad (124)$$

$$+ \frac{1}{2} \text{Tr}(\sigma_t Q D_{\mathbf{xx}} (D_{\mathbf{x}} \mathcal{V}_t)) + \langle \sigma_t Q^{1/2} \alpha_t^\theta, D_{\mathbf{xx}} \mathcal{V}_t \rangle_{\mathcal{H}}] + \sigma_t \mathbf{Z}_t^\theta d\mathbf{W}_t^Q. \quad (125)$$

这里，通过对 (68) 中的 HJB 关于 $\mathbf{x}$ 求导，我们得到：

$$\partial_t D_{\mathbf{x}} \mathcal{V}_t + \mathcal{A}^\dagger D_{\mathbf{x}} \mathcal{V} + \langle \mathcal{A} \mathbf{X}_t^\theta, D_{\mathbf{xx}} \mathcal{V}_t \rangle_{\mathcal{H}} \quad (126)$$

$$+ \frac{1}{2} \text{Tr}(\sigma_t^2 Q D_{\mathbf{xx}} (D_{\mathbf{x}} \mathcal{V}_t)) + D_{\mathbf{xx}} \mathcal{V}_t \sigma_t Q^{1/2} D_{\mathbf{x}} F(\sigma_t Q^{1/2} D_{\mathbf{x}} \mathcal{V}) = 0. \quad (127)$$

现在，将 (126) 代入 (124)，我们得到以下结果：

$$d\mathbf{Y}_t^\theta = [-\mathcal{A}^\dagger \mathbf{Y}_t + \langle \sigma_t Q^{1/2} \alpha_t^\theta - \sigma_t Q^{1/2} D_{\mathbf{x}} F(\sigma_t Q^{1/2} \mathbf{Y}_t^\theta), D_{\mathbf{xx}} \mathcal{V} \rangle] dt + \sigma_t \mathbf{Z}_t^\theta d\mathbf{W}_t^Q \quad (128)$$

$$\stackrel{(i)}{=} [-\mathcal{A}^\dagger \mathbf{Y}_t^\theta + \langle \sigma_t Q^{1/2} \alpha_t^\theta + \sigma_t^2 Q \mathbf{Y}_t^\theta, D_{\mathbf{xx}} \mathcal{V} \rangle] dt + \sigma_t \mathbf{Z}_t^\theta d\mathbf{W}_t^Q \quad (129)$$

$$\stackrel{(ii)}{=} -\mathcal{A}^\dagger \mathbf{Y}_t^\theta dt + \sigma_t \mathbf{Z}_t^\theta d\mathbf{W}_t^Q, \quad (130)$$

其中 (i) $F(\sigma_t Q^{1/2} \mathbf{Y}_t^\theta) = -\frac{1}{2} \inf_{\alpha} \|\sigma_t Q^{1/2} \mathbf{Y}_t^\theta - \sigma_t Q^{1/2} \alpha\|_{\mathcal{H}}^2$ 根据 F 和 (ii) 的定义得出，且 α^θ 由此，如果 $\mathbf{Y}_t^\theta = D_{\mathbf{x}} \mathcal{V}(t, \mathbf{X}_t^\theta)$ ，则 $\mathbf{Y}_t^\theta$ 是 (19) 的解，且 (120) 中的临界点满足

$$\alpha_t^\theta = -\sigma_t Q^{1/2} \mathbf{Y}_t^{\bar{\alpha}} = -\sigma_t Q^{1/2} D_{\mathbf{x}} \mathcal{V}_t. \quad (131)$$

因此, 根据引理 B.5, 该控制满足 HJB 方程且为最优, 故 $\alpha^\theta = \alpha^*$ 。反之, 若假设临界点 $\alpha_t^\theta = -\sigma_t Q^{1/2} \mathbf{Y}_t^\alpha$ 为最优, 其中 $\mathbf{Y}_t^\alpha$ 是 (19) 的解, 则同样的验证立即得到 $\mathbf{Y}_t^\alpha = D_{\mathbf{x}} \mathcal{V}(t, \mathbf{X}_t^\alpha)$ 。这表明 (120) 中的临界点即为 (12) 中 SOC 问题的最优控制 α^* 。证毕。 $\square$

充分条件 事实上, 在特殊情形 *i.e.*, 中, 当 g 为凸时, 其逆命题成为充分条件。人们可能会问, 求解伴随方程并最小化哈密顿量是否能保证最优性。一般而言, SOC 采样需要非凸 g , 因此该条件常常不成立。故本文不采用此条件, 而是针对 (12) 中的特定 SOC 问题, 提出并证明一个量身定制的充分最优性条件。

命题 B.7 (随机最大值原理)。假设终端成本 g 为凸。固定一个容许控制 $\bar{\alpha} \in \mathbb{A}$, 考虑相应的无穷维耦合正倒向随机微分方程:

$$d\mathbf{X}_t^\alpha = [\mathcal{A}\mathbf{X}_t^\alpha + \sigma_t Q^{1/2} \bar{\alpha}_t] dt + \sigma_t d\mathbf{W}_t^Q, \quad \mathbf{X}_0^\alpha = \mathbf{x}_0, \quad (132)$$

$$d\mathbf{Y}_t^\alpha = -[\mathcal{A}^\dagger \mathbf{Y}_t^\alpha + D_{\mathbf{x}} H(t, \mathbf{X}_t^\alpha, \bar{\alpha}_t, \mathbf{Y}_t^\alpha, \mathbf{Z}_t^\alpha)] dt + \mathbf{Z}_t^\alpha d\mathbf{W}_t^Q, \quad \mathbf{Y}_T^\alpha = D_{\mathbf{x}} g(\mathbf{X}_T^\alpha). \quad (133)$$

那么, 在状态变量固定为 $(\mathbf{X}_t^\alpha, \mathbf{Y}_t^\alpha, \mathbf{Z}_t^\alpha)$ 且选定控制 $\bar{\alpha}$ 的条件下, 若以下条件成立:

$$H(t, \mathbf{X}_t^\alpha, \alpha_t^*, \mathbf{Y}_t^\alpha, \mathbf{Z}_t^\alpha) = \min_{\alpha \in \mathbb{A}} H(t, \mathbf{X}_t^\alpha, \alpha, \mathbf{Y}_t^\alpha, \mathbf{Z}_t^\alpha), \quad \forall t \in [0, T], \quad (134)$$

所得控制序列 $\{\alpha_t^*\}_{t \in [0, T]}$ 即为给定 SOC 问题 (12) 的最优控制 α^* 。

证明。我们将 (Carmona, 2016, 定理 4.14) 中充分条件的证明方法推广到无穷维控制问题。固定 $\beta \in \mathcal{U}$ 为容许控制, 记 $\mathbf{X}_t^* := \mathbf{X}_t^{\alpha^*}$, 并定义 $\Delta \mathbf{X}_t := \mathbf{X}_t^\beta - \mathbf{X}_t^*$ 。由 g 的凸性, 可得

$$g(\mathbf{X}_T^\beta) - g(\mathbf{X}_T^*) \geq \langle D_{\mathbf{x}} g(\mathbf{X}_T^\beta), \mathbf{X}_T^\beta - \mathbf{X}_T^* \rangle_{\mathcal{H}} = \langle \mathbf{Y}_T^*, \Delta \mathbf{X}_T \rangle_{\mathcal{H}}. \quad (135)$$

现在, 对 $\langle \mathbf{Y}_T^*, \Delta \mathbf{X}_T \rangle_{\mathcal{H}}$ 应用希尔伯特空间乘积法则 B.4。然后, 利用 $\mathbf{X}^\beta$ 和 $\mathbf{X}^*$ 的动力学以及 $\mathbf{Y}^*$ 的伴随方程, 我们得到:

$$\mathbb{E}[\langle \mathbf{Y}_T^*, \Delta \mathbf{X}_T \rangle_{\mathcal{H}}] = \mathbb{E} \int_0^T \langle -\mathcal{A}^\dagger \mathbf{Y}_t^* - D_{\mathbf{x}} H(t, \mathbf{X}_t^*, \alpha^*, \mathbf{Y}_t^*, \mathbf{Z}_t^*, \Delta \mathbf{X}_t) \rangle_{\mathcal{H}} dt \quad (136)$$

$$+ \mathbb{E} \int_0^T \langle \mathbf{Y}_t^*, \mathcal{A} \Delta \mathbf{X}_t + \sigma_t Q^{1/2} \beta_t - \sigma_t Q^{1/2} \alpha_t^* \rangle_{\mathcal{H}} dt \quad (137)$$

$$\stackrel{(i)}{=} -\mathbb{E} \int_0^T \langle D_{\mathbf{x}} H(t, \mathbf{X}_t^*, \alpha^*, \mathbf{Y}_t^*, \mathbf{Z}_t^*, \Delta \mathbf{X}_t) \rangle_{\mathcal{H}} dt \quad (138)$$

$$+ \mathbb{E} \int_0^T \langle \mathbf{Y}_t^*, \sigma_t Q^{1/2} \beta_t - \sigma_t Q^{1/2} \alpha_t^* \rangle_{\mathcal{H}} dt, \quad (139)$$

其中 (i) 由 $\mathcal{A}$ 的伴随性得出。另一方面, 利用 (106) 中 $\mathcal{J}$ 的定义:

$$\mathcal{J}(\beta) - \mathcal{J}(\alpha^*) = \mathbb{E} \left[\int_0^T \left(\frac{1}{2} \|\beta_t\|_{\mathcal{H}}^2 - \frac{1}{2} \|\alpha_t^*\|_{\mathcal{H}}^2 \right) dt + g(\mathbf{X}_T^\beta) - g(\mathbf{X}_T^*) \right] \quad (140)$$

$$\geq \mathbb{E} \left[\int_0^T \left(\frac{1}{2} \|\beta_t\|_{\mathcal{H}}^2 - \frac{1}{2} \|\alpha_t^*\|_{\mathcal{H}}^2 \right) + \langle \mathbf{Y}_t^*, \sigma_t Q^{1/2} \beta_t - \sigma_t Q^{1/2} \alpha_t^* \rangle_{\mathcal{H}} dt \right] \quad (141)$$

$$- \mathbb{E} \int_0^T \langle D_{\mathbf{x}} H(t, \mathbf{X}_t^*, \alpha^*, \mathbf{Y}_t^*, \mathbf{Z}_t^*, \Delta \mathbf{X}_t) \rangle_{\mathcal{H}} dt \quad (142)$$

$$\stackrel{(i)}{=} \mathbb{E} \int_0^T \left[H(t, \mathbf{X}_t^\beta, \beta_t, \mathbf{Y}_t^*, \mathbf{Z}_t^*) - H(t, \mathbf{X}_t^*, \alpha^*, \mathbf{Y}_t^*, \mathbf{Z}_t^*) - \langle D_{\mathbf{x}} H(t, \mathbf{X}_t^*, \alpha^*, \mathbf{Y}_t^*, \mathbf{Z}_t^*, \Delta \mathbf{X}_t) \rangle_{\mathcal{H}} \right] dt, \quad (143)$$

其中 (i) 由哈密顿量 (16) 的定义得出。由 $\mathcal{H}$ 关于 $(\mathbf{x}, \alpha)$ 的凸性,

$$H(t, \mathbf{X}_t^\beta, \beta_t, \mathbf{Y}_t^*, \mathbf{Z}_t^*) \geq H(t, \mathbf{X}_t^*, \alpha^*, \mathbf{Y}_t^*, \mathbf{Z}_t^*) \quad (144)$$

$$+ \langle D_{\mathbf{x}} H(t, \mathbf{X}_t^*, \alpha^*, \mathbf{Y}_t^*, \mathbf{Z}_t^*, \Delta \mathbf{X}_t) \rangle_{\mathcal{H}} + \langle D_{\alpha} H(t, \mathbf{X}_t^*, \alpha^*, \mathbf{Y}_t^*, \mathbf{Z}_t^*, \beta_t - \alpha_t^*) \rangle_{\mathcal{H}}. \quad (145)$$

那么, α^* 的逐点极小性意味着对于任意容许控制 $\langle D_{\alpha} H(t, \mathbf{X}_t^*, \alpha^*, \mathbf{Y}_t^*, \mathbf{Z}_t^*, \beta_t - \alpha_t^*) \rangle_{\mathcal{H}} \geq 0$ 有 β_t 。因此, 由 (134) 可知 $\mathcal{J}(\beta) \geq \mathcal{J}(\alpha^*)$ 。最后, 由于我们任意选取 β , 所得的 α^* 对所有 $t \in [0, T]$ 都是最优控制。证毕。 $\square$

B.6. 命题 5 的证明

命题 5 (无偏估计器)。定义具有条件期望的样本级伴随匹配目标

$\tilde{\mathbf{Y}}_t^{\bar{\alpha}} := \mathbb{E}_{\mathbb{P}^{\bar{\alpha}}}[\mathbf{Y}_t^{\bar{\alpha}} | \mathbf{X}_t^{\bar{\alpha}}]$ 对于任意样本轨迹 $\mathbf{X}_t^{\bar{\alpha}} \sim \mathbb{P}^{\bar{\alpha}}$:

$$\tilde{\mathcal{L}}(\theta) := \int_0^T \frac{1}{2} \|\alpha^\theta(\mathbf{X}_t^{\bar{\alpha}}, t) + \sigma_t Q^{1/2} \tilde{\mathbf{Y}}_t^{\bar{\alpha}}\|_{\mathcal{H}}^2 dt \quad (20)$$

然后, 我们得到无偏梯度估计器 $d_{d\theta} \mathbb{E}_{\mathbb{P}^{\bar{\alpha}}}[\tilde{\mathcal{L}}(\theta)] = d_{d\theta} \mathcal{L}(\theta)$, 其在 (18) 中具有相同的临界点

证明。在停止梯度操作下, 前向法则 $\mathbb{P}^{\bar{\alpha}}$ 不依赖于 θ 。由控制收敛定理, 我们将导数穿过期望和积分:

$$\frac{d}{d\theta} \mathbb{E}_{\mathbb{P}^{\bar{\alpha}}}[\tilde{\mathcal{L}}(\theta)] = \mathbb{E}_{\mathbb{P}^{\bar{\alpha}}} \left[\frac{d}{d\theta} \int_0^T \frac{1}{2} \|\alpha^\theta(\mathbf{X}_t^{\bar{\alpha}}, t) + \sigma_t Q^{1/2} \tilde{\mathbf{Y}}_t^{\bar{\alpha}}\|_{\mathcal{H}}^2 dt \right] \quad (146)$$

$$= \mathbb{E}_{\mathbb{P}^{\bar{\alpha}}} \left[\int_0^T \langle \alpha^\theta(\mathbf{X}_t^{\bar{\alpha}}, t) + \sigma_t Q^{1/2} \tilde{\mathbf{Y}}_t^{\bar{\alpha}}, \partial_\theta \alpha^\theta(\mathbf{X}_t^{\bar{\alpha}}, t) \rangle_{\mathcal{H}} dt \right] \quad (147)$$

$$= \int_0^T \left[\mathbb{E}_{\mathbb{P}^{\bar{\alpha}}} [\langle \alpha^\theta(\mathbf{X}_t^{\bar{\alpha}}, t), \partial_\theta \alpha^\theta(\mathbf{X}_t^{\bar{\alpha}}, t) \rangle_{\mathcal{H}}] + \mathbb{E}_{\mathbb{P}^{\bar{\alpha}}} [\langle \sigma_t Q^{1/2} \tilde{\mathbf{Y}}_t^{\bar{\alpha}}, \partial_\theta \alpha^\theta(\mathbf{X}_t^{\bar{\alpha}}, t) \rangle_{\mathcal{H}}] \right] dt \quad (148)$$

$$= \int_0^T \left[\mathbb{E}_{\mathbb{P}^{\bar{\alpha}}} [\langle \alpha^\theta(\mathbf{X}_t^{\bar{\alpha}}, t), \partial_\theta \alpha^\theta(\mathbf{X}_t^{\bar{\alpha}}, t) \rangle_{\mathcal{H}}] + \mathbb{E}_{\mathbb{P}^{\bar{\alpha}}} [\langle \sigma_t Q^{1/2} \mathbb{E}_{\mathbb{P}^{\bar{\alpha}}}[\mathbf{Y}_t^{\bar{\alpha}} | \mathbf{X}_t^{\bar{\alpha}}], \partial_\theta \alpha^\theta(\mathbf{X}_t^{\bar{\alpha}}, t) \rangle_{\mathcal{H}}] \right] dt \quad (149)$$

$$\stackrel{(i)}{=} \int_0^T \left[\mathbb{E}_{\mathbb{P}^{\bar{\alpha}}} [\langle \alpha^\theta(\mathbf{X}_t^{\bar{\alpha}}, t), \partial_\theta \alpha^\theta(\mathbf{X}_t^{\bar{\alpha}}, t) \rangle_{\mathcal{H}}] + \mathbb{E}_{\mathbb{P}^{\bar{\alpha}}} [\langle \sigma_t Q^{1/2} \mathbf{Y}_t^{\bar{\alpha}}, \partial_\theta \alpha^\theta(\mathbf{X}_t^{\bar{\alpha}}, t) \rangle_{\mathcal{H}}] \right] dt \quad (150)$$

$$= \mathbb{E}_{\mathbb{P}^{\bar{\alpha}}} \left[\int_0^T \langle \alpha^\theta(\mathbf{X}_t^{\bar{\alpha}}, t) + \sigma_t Q^{1/2} \mathbf{Y}_t^{\bar{\alpha}}, \partial_\theta \alpha^\theta(\mathbf{X}_t^{\bar{\alpha}}, t) \rangle_{\mathcal{H}} dt \right] \quad (151)$$

$$\stackrel{(ii)}{=} \frac{d}{d\theta} \mathcal{L}(\theta), \quad (152)$$

$$(153)$$

其中 (i) 由塔性质得出, (ii) 由 (115) 式得出。因此, 我们得到 $d_{d\theta} \mathbb{E}_{\mathbb{P}^{\bar{\alpha}}}[\tilde{\mathcal{L}}(\theta)] = d_{d\theta} \mathcal{L}(\theta) = 0$ 在 θ^* 处。这表明临界点 $\alpha^\theta(\mathbf{X}_t^{\bar{\alpha}}, t) = -\sigma_t Q^{1/2} \mathbf{Y}_t^{\bar{\alpha}}$ 保持不变, $\frac{d}{d\theta} \mathcal{L}(\theta)$ 证明完毕。 $\square$

B.7. 端点分解

由 (10) 式, 记 $\mathbf{X} := \{\mathbf{X}_t\}_{t \in [0, T]} \in \Omega$, 并定义重要性采样如下:

$$w(\mathbf{X}) = e^{-U(\mathbf{X}_T) - \log q_T(\mathbf{x}_0, \mathbf{X}_T)}. \quad (154)$$

则关于参考测度 $\mathbb{P}$ 的 $\mathbb{P}^*$ 的 RND 由下式给出:

$$\frac{d\mathbb{P}^*}{d\mathbb{P}}(\mathbf{X}) = \frac{w(\mathbf{X})}{\mathbb{E}_{\mathbb{P}}[w(\mathbf{X})]}. \quad (155)$$

则对于任意有界泛函 $F : \Omega \rightarrow \mathbb{R}$ ，我们有期望：

$$\mathbb{E}_{\mathbb{P}^*}[F(\mathbf{X}^*)] = \frac{\mathbb{E}_{\mathbb{P}}[F(\mathbf{X})w(\mathbf{X})]}{\mathbb{E}_{\mathbb{P}}[w(\mathbf{X})]}. \quad (156)$$

由于 $\mathbb{P}$ 的终端律关于 ν_∞ 具有密度 q_T （基于定理 2），我们可以关于 $\mathbf{X}_T$ 分解 $\mathbb{P}$ 得到：

$$\mathbb{E}_{\mathbb{P}}[F(\mathbf{X})w(\mathbf{x})] = \int_{\mathcal{H}} \left(\int_{\mathcal{H}} F(\mathbf{X}) \mathbb{P}_{\cdot|T}(d\mathbf{X}|\mathbf{X}_T = \mathbf{y}) \right) e^{-U(\mathbf{y}) - \log q_T(\mathbf{x}_0, \mathbf{x}_T)} q_T(\mathbf{x}_0, \mathbf{y}) d\nu_\infty(\mathbf{y}) \quad (157)$$

$$= \int_{\mathcal{H}} \left(\int_{\mathcal{H}} F(\mathbf{X}) \mathbb{P}_{\cdot|T}(d\mathbf{X}|\mathbf{X}_T = \mathbf{y}) \right) e^{-U(\mathbf{y})} d\nu_\infty(\mathbf{y}) \quad (158)$$

$$\stackrel{(i)}{=} \int_{\mathcal{H}} \left(\int_{\mathcal{H}} F(\mathbf{X}) \mathbb{P}_{\cdot|T}(d\mathbf{X}|\mathbf{X}_T = \mathbf{y}) \right) \mathbb{E}_{\mathbb{P}}[w(\mathbf{X})] d\pi(\mathbf{y}), \quad (159)$$

其中 (i) 由 (6) 式中目标分布 π 的定义得出。因此，我们得到

$$\mathbb{E}_{\mathbb{P}^*}[F(\mathbf{X}^*)] = \int \left(\int F(\mathbf{X}) \mathbb{P}_{\cdot|T}(d\mathbf{X}|\mathbf{X}_T = \mathbf{y}) \right) \pi(d\mathbf{y}) \quad (160)$$

$$= \mathbb{E}_{\mathbb{P}_{\cdot|T}\mathbb{P}_T^*}[F(\mathbf{X})]. \quad (161)$$

命题 6（拉普拉斯算子）。对于有界区域上带狄利克雷边界条件的负拉普拉斯算子 $\mathcal{A} = -\Delta$ ，取 $Q = \mathcal{A}^{-s}$ 且 $s > \frac{d}{2}$ 为 2。则 $\mathcal{A}$ 与 Q 满足定理 B.1。

Proof. **(A) Trace-class** Let $\{\phi^{(k)}\}_{k \geq 1}$ be an eigen-basis with $\mathcal{A}\phi^{(k)} = -\lambda^{(k)}\phi^{(k)}$. Then, we have

$$Q\mathbf{x} = \sum_{k \geq 1} (\lambda^{(k)})^{-s} \mathbf{x}^{(k)} \phi^{(k)}. \quad (162)$$

因此 Q 的特征值为 $(\lambda^{(k)})^{-s}$ ，这意味着 $Tr(Q) = \sum_{k \geq 1} (\lambda^{(k)})^{-s}$ 。根据外尔定律 $\lambda^{(k)} \asymp k$ 在 $\mathbb{R}^d$ 中的有界 C^∞ 区域，因此若 $s > \frac{d}{2}$ ，则 $Tr(Q) < \infty$ $\frac{2}{d}$ on a

(B) 自伴 由于拉普拉斯算子 Δ 是自伴的，我们直接得到 $\mathcal{A}$ 的自伴性，并且对于 Q ：

$$Q^\dagger = ((-\mathcal{A})^{-s})^\dagger = ((-\mathcal{A})^{-s}) = Q \quad (163)$$

(C) Dissipative Since $0 < \lambda_1 < \lambda_2, \dots < \lambda_k < \dots$ for $k \in \mathbb{N}$, we obtain:

$$\langle \mathcal{A}\mathbf{x}, \mathbf{x} \rangle_{\mathcal{H}} = - \sum_{k \geq 1} \lambda^{(k)} \left\| \langle \mathbf{x}, \phi^{(k)} \rangle_{\mathcal{H}} \right\|^2 \leq -\lambda^{(1)} \sum_{k \geq 1} \left\| \langle \mathbf{x}, \phi^{(k)} \rangle_{\mathcal{H}} \right\|^2 = -\lambda^{(1)} \|\mathbf{x}\|_{\mathcal{H}}^2. \quad (164)$$

(D) 交换 对于任意 $\mathbf{x} \in \mathcal{H}$ ，我们得到：

$$\mathcal{A}Q\mathbf{x} = \mathcal{A} \left(\sum_{k \geq 1} (\lambda^{(k)})^{-s} \mathbf{x}^{(k)} \phi^{(k)} \right) = \sum_{k \geq 1} (\lambda^{(k)})^{-s} \mathbf{x}^{(k)} (\mathcal{A}\phi^{(k)}) \quad (165)$$

$$= \sum_{k \geq 1} (\lambda^{(k)})^{-s} \mathbf{x}^{(k)} (-\lambda^{(k)} \phi^{(k)}) = - \sum_{k \geq 1} (\lambda^{(k)})^{1-s} \mathbf{x}^{(k)} \phi^{(k)} \quad (166)$$

并且

$$Q\mathcal{A}\mathbf{x} = -Q \left(\sum_{k \geq 1} \lambda^{(k)} \mathbf{x}^{(k)} \phi^{(k)} \right) = - \sum_{k \geq 1} \lambda^{(k)} \mathbf{x}^{(k)} (Q\phi^{(k)}) \quad (167)$$

$$= \sum_{k \geq 1} \lambda^{(k)} \mathbf{x}^{(k)} ((\lambda^{(k)})^{-s} \phi^{(k)}) = - \sum_{k \geq 1} (\lambda^{(k)})^{1-s} \mathbf{x}^{(k)} \phi^{(k)}. \quad (168)$$

因此，我们得到 $\mathcal{A}Q^{1/2}\mathbf{x} = Q^{1/2}\mathcal{A}\mathbf{x}$ 。证明完毕。 □

C. 实验细节

C.1. 数值计算

施加边界条件 为了恰当地定义两个亚稳态（例如 **A** 和 **B**）之间的过渡路径，我们必须将这些状态固定为所需路径的边界条件。本文方法通过将路径 $\mathbf{X}_t$ 分解为两部分来实现：固定的参考路径 $\mathbf{x}_0$ 和波动的残差路径 $\mathbf{R}_t$ 。然后，总路径由 $\mathbf{X}_t = \mathbf{x}_0 + \mathbf{R}_t$ 给出，其中 $\mathbf{x}_0$ 将残差路径（边界值为零）提升为具有所需边界值的路径。参考路径 $\mathbf{x}_0$ 提供从 **A** 到 **B** 的直接连接，而残差路径 $\mathbf{R}_t$ 被强制在边界处为零。这种构造保证了完整路径 $\mathbf{X}_t$ 始终始于 **A** 并终于 **B**。

对于残差路径 $\mathbf{R}_t$ ，我们通过选择狄利克雷特征基，将样本路径端点强制为吸收态 *i.e.*, $\mathbf{R}_t[0] = 0, \mathbf{R}_t[L] = 0$ ，对于函数 $\mathbf{R}_t : \mathbb{R}_{>0} \rightarrow \mathbb{R}^d$ ：

$$\phi^{(k)}[u] = \left(\frac{2}{L}\right)^{1/2} \sin\left(\frac{\pi k u}{L}\right), \quad \forall k \in \mathbb{N}, u \in \mathbf{L} := [0, L] \quad (169)$$

$$\mathbf{R}_t = \sum_{k \geq 1} \mathbf{R}_t^{(k)} \phi^{(k)}, \text{ 其中 } \mathbf{R}_t^{(k)} := \langle \mathbf{R}_t, \phi^{(k)} \rangle_{\mathcal{H}} = \int_{\mathbf{L}} \mathbf{R}_t[u] \phi^{(k)}[u] du. \quad (170)$$

因此，我们得到 $\mathbf{R}_t[0] = \mathbf{R}_t[L] = 0$ 对所有 $t \in [0, T]$ 成立，因为由 (170) 可得 $\phi^{(k)}[0] = \phi^{(k)}[L] = 0$ 。对于参考路径 $\mathbf{x}_0$ ，我们将其定义为连续函数 $\mathbf{x}_0 : \mathbf{L} \rightarrow \mathbb{R}^d$ ：

$$\mathbf{x}_0[u] = c_0[u]\mathbf{A} + c_1[u]\mathbf{B}, \text{ 与 } \begin{cases} c_0[0] = 1, c_0[L] = 0 \\ c_1[0] = 0, c_1[L] = 1 \end{cases} \quad (171)$$

这里，狄利克雷空间上的残差过程 $\mathbf{R}_t$ 由下式给出：

$$d\mathbf{R}_t = \left[\mathcal{A}\mathbf{R}_t + \sigma_t Q^{1/2} \alpha(t, \mathbf{x}_0 + \mathbf{R}_t) \right] dt + \sigma_t d\mathbf{W}_t^Q, \quad \mathbf{R}_0 = 0. \quad (172)$$

由此可得，由于 $\mathbf{X}_t = \mathbf{x}_0 + \mathbf{R}_t$ ，我们可以推导出以下 $\mathcal{H}$ 值随机微分方程：

$$d\mathbf{X}_t = \left[\mathcal{A}(\mathbf{X}_t - \mathbf{x}_0) + \sigma_t Q^{1/2} \alpha(t, \mathbf{X}_t) \right] dt + \sigma_t d\mathbf{W}_t^Q, \quad \mathbf{X}_0 = \mathbf{x}_0. \quad (173)$$

给定 (169) 中的狄利克雷特征基，我们可以将无穷维随机微分方程表示为每个坐标 k 的实值随机微分方程无穷系统：

$$d\mathbf{R}_t^{(k)} = \left[-\lambda^{(k)} \mathbf{R}_t^{(k)} + \sigma_t \langle \alpha(t, \mathbf{x}_0 + \mathbf{R}_t), (Q^{1/2})^\dagger \phi^{(k)} \rangle \right] dt + \sigma_t (\lambda^{(k)})^{-\frac{s}{2}} d\beta_t^{(k)}, \quad \mathbf{R}_t^{(k)} = 0, \quad (174)$$

$$= \left[-\lambda^{(k)} \mathbf{R}_t^{(k)} + \sigma_t (\lambda^{(k)})^{-\frac{s}{2}} \langle \alpha(t, \mathbf{X}_t), \phi^{(k)} \rangle \right] dt + \sigma_t (\lambda^{(k)})^{-\frac{s}{2}} d\beta_t^{(k)} \quad (175)$$

其中 $\{\beta_t^{(k)}\}_{k \geq 1}$ 是标准维纳过程。注意，为了计算 $(Q^{1/2})^\dagger \phi^{(k)}$ ，我们选择 $\mathcal{U} = \mathcal{H}$ ，即 $\mathbf{W}_t =$ 。尽管 $\sum_{k \geq 1} \phi_k \beta_t^{(k)} \mathbf{W}_t$ 不是 $\mathcal{H}$ 值随机变量，但它是由 $\mathcal{H}$ 索引的柱面过程，在随机积分前应用希尔伯特-施密特 $Q^{1/2}$ 可确保所得过程保持平方可积。

如果将有限路径评估视为均匀网格 $\mathbf{L} = [0, L]$ 上的样本，我们使用离散正弦变换 (**DST**) 投影到正弦基上。由于有限分辨率路径具有自然截止频率 K 作为评估点数，因此与正弦基之间的投影是精确的。具体而言，用 $\Delta \triangleq \mathbf{E} \mathbf{D} \mathbf{E}^\top$ 近似拉普拉斯算子，其中 $\mathbf{E}^\top$ 是由特征函数 $\{\phi^{(k)}\}_{k=1}^K$ 组成的 **DST** 投影，使得 $\tilde{\mathbf{R}}_t = \mathbf{E}^\top \mathbf{R}_t$ ，且 $\mathbf{D}$ 是包含特征值 $\{\lambda^{(k)}\}_{k=1}^K$ 的对角矩阵。因此，(172) 中的随机演化由有限维模型描述（配置到谱空间）：

$$d\tilde{\mathbf{R}}_t = \left[-\mathbf{D}\tilde{\mathbf{R}}_t + \sigma_t \mathbf{D}^{-\frac{s}{2}} \mathbf{E}^\top \alpha(t, \mathbf{X}_t) \right] dt + \sigma_t \mathbf{D}^{-\frac{s}{2}} d\tilde{\mathbf{W}}_t. \quad (176)$$

FAS 的仿真算法在算法 1 中详细给出。此外，我们在狄利克雷拉普拉斯算子上引入谱精度尺度 κ ，将 $\mathbf{D}$ 替换为 $\kappa^2 \mathbf{D}$ 以控制参考动力学的刚度和光滑性。

修正 RND 根据命题 6，我们可以如下计算定理 2 中的 RND：

$$\log q_t(\mathbf{x}_0, \mathbf{x}) = -\frac{1}{2} \sum_{k \geq 1} \frac{1}{q_\infty^{(k)}(e^{2t\lambda_k} - 1)} \left[\|\mathbf{x}_0^{(k)}\|^2 - 2e^{-t\lambda_k} \langle \mathbf{x}_0^{(k)}, \mathbf{x}^{(k)} \rangle + \|\mathbf{x}^{(k)}\|^2 \right], \quad (177)$$

其中 $q_\infty^{(k)}$ 是 Q_∞ 的对角分量，使得 $Q_\infty \phi^{(k)} = q_\infty^{(k)} \phi^{(k)}$ 。From (43), we get $Q_\infty = -\frac{1}{2} \sigma_\infty^2 \mathcal{A}^{-1}$ ，因此我们得到 $q_\infty^{(k)} = \frac{1}{2} \sigma_\infty^2 (\lambda^{(k)})^{(1+s)}$ 。

桥接采样 由于式 (3) 中参考过程的解定义了一个奥恩斯坦-乌伦贝格半群，因此在时间 T 给定的条件下，时间 t 的条件分布为：

$$\mathbb{P}_{t|T}(\mathbf{X}_t | \mathbf{x}_T) = \mathcal{N}(\mathbf{m}_{t|T}, Q_{t|T}), \quad (178)$$

其中条件均值函数与协方差算子由下式给出：

$$\mathbf{m}_{t|T} = \mathbf{x}_0 + Q_{t|T} Q_T^{-1} (\mathbf{x}_T - \mathbf{x}_0), \quad Q_{t|T} = Q_T - Q_{t|T} Q_T^{-1} Q_{T|t} \quad (179)$$

$$Q_t = \int_0^t e^{(t-s)\mathcal{A}} \sigma_s^2 Q e^{(t-s)\mathcal{A}^\dagger} ds, \quad (180)$$

$$Q_{t|T} = \int_0^t e^{(t-s)\mathcal{A}} \sigma_s^2 Q e^{(T-s)\mathcal{A}^\dagger} ds = Q_t e^{(T-t)\mathcal{A}^\dagger}, \quad Q_{T|t} = (Q_{t|T})^\dagger. \quad (181)$$

此外，奥恩斯坦-乌伦贝格半群在 (3) 中的坐标过程 $\mathbf{X}_t^{(k)} = \langle \mathbf{X}_t, \phi^{(k)} \rangle$ 也是高斯的，且各坐标相互独立。因此，我们可以逐坐标进行计算：

$$\mathbb{P}_{t|T}(\mathbf{X}_t^{(k)} | \mathbf{x}_T^{(k)}) = \mathcal{N}(\mathbf{m}_{t|T}^{(k)}, q_{t|T}^{(k)}) \quad (182)$$

where we denote $q_t^{(k)} = \langle Q_t, \phi^{(k)} \rangle$ 对于任意 $t \in [0, T]$ 及

$$\mathbf{m}_{t|T}^{(k)} = \mathbf{x}_0^{(k)} + \frac{q_t^{(k)}}{q_\infty^{(k)}} e^{-(T-t)\lambda^{(k)}} (\mathbf{x}_T^{(k)} - \mathbf{x}_0^{(k)}), \quad (183)$$

$$q_{t|T}^{(k)} = q_t^{(k)} - \frac{(q_t^{(k)})^2}{q_\infty^{(k)}} e^{-2(T-t)\lambda^{(k)}} \quad (184)$$

$$q_t^{(k)} = \int_0^t \sigma_s^2 e^{-2(t-s)\lambda^{(k)}} (\lambda^{(k)})^{-s} ds, \quad \forall t \in [0, T]. \quad (185)$$

噪声调度 σ_t 闭式仿真可能不可行，因为计算 $q_t^{(k)}$ 在 (185) 中需要对任意噪声调度 σ_t 进行数值积分。在这种情况下，针对伴随采样研究的两种噪声调度 (Havens 等人, 2025; Liu 等人, 2025) 可以适应我们的设置。

- 恒定噪声调度设置 $\sigma(t) := \sigma$ 。然后，我们可以计算 (185) 中的积分：

$$q_t^{(k)} = (\lambda^{(k)})^{-s} \frac{(1 - e^{-2t\lambda_k})}{2\lambda_k}. \quad (186)$$

- 几何噪声调度 (Song 等人, 2021; Karras 等人, 2022) 按预定义的 $\beta_{\min}$ 单调递减，并且 $\beta_{\max}$ ：

$$\sigma_t = \begin{cases} \beta_{\min} \left(\frac{\beta_{\max}}{\beta_{\min}} \right)^{T-t} \sqrt{2 \log \frac{\beta_{\max}}{\beta_{\min}}}, & t < T \\ \beta_{\min} \sqrt{2 \log \frac{\beta_{\max}}{\beta_{\min}}}, & t \geq T. \end{cases} \quad (187)$$

因为选择噪声调度 $\sigma_t = \beta e^{\alpha t}$ 为 (185) 中的积分提供了闭式形式，我们将其重新排列如下：

$$\sigma_t = \beta_{\min} \left(\frac{\beta_{\max}}{\beta_{\min}} \right)^{T-t} \sqrt{2 \log \frac{\beta_{\max}}{\beta_{\min}}} = \beta_{\min} \left(\frac{\beta_{\max}}{\beta_{\min}} \right)^T \sqrt{2 \log \frac{\beta_{\max}}{\beta_{\min}}} e^{-\log \left(\frac{\beta_{\max}}{\beta_{\min}} \right) t}. \quad (188)$$

表 4: 训练超参数

	Synthetic potential	Alanine dipeptide	Chignolin
$\beta_{\min}$	0.1	0.01	0.01
$\beta_{\max}$	10	15	5
κ	10^{-2}	10^{-5}	10^{-5}
M	10^3	10^4	10^4
L	100	100	100
N	512	16	16
$ \mathcal{B} $	10^4	10^3	10^3
$\alpha_{\max}$	100	10^4	10^4
$ \mathbf{U} $	100	100	100
Learning rate	10^{-4}	10^{-5}	10^{-4}
Base channel	32	64	128
Base mode	8	8	8
Embed dim	128	256	512

因此, 我们得到 $\beta = \beta_{\min}(\frac{\beta_{\max}}{\beta_{\min}})^T \sqrt{2 \log \frac{\beta_{\max}}{\beta_{\min}}}$, $\alpha = -\log\left(\frac{\beta_{\max}}{\beta_{\min}}\right)$ 。这种选择产生:

$$q_t^{(k)} = \beta^2 (\lambda^{(k)})^{-s} \frac{e^{2\alpha t} - e^{-2\lambda_k t}}{2(\alpha + \lambda_k)} \quad (189)$$

回放缓冲区 $\mathcal{B}$ 遵循先前的扩散采样器 (Havens 等人, 2025; Liu 等人, 2025; Choi 等人, 2025), 我们维护一个重放缓冲区 $\mathcal{B}$ 用于计算 (22) 中的目标。在这种情况下, $\mathbb{P}^{\mu^\alpha}$ 下的期望通过 $\mathcal{B}$ 上的平均值来近似, 该缓冲区保存最近的 $|\mathcal{B}|$ 个样本。我们每 L 个梯度步骤后插入 N 个新样本来刷新缓冲区 $\mathcal{B}$ 。

控制网络的参数化 我们用神经算子参数化控制 α^θ 以保持其函数形式。我们将控制参数化为 $\alpha^\theta(t, \mathbf{x}) := \sigma_t Q^{1/2} e^{-(T-t)A^\dagger} u^\theta(t, \mathbf{x})$, 它将噪声调度 σ_t 和拉普拉斯收缩 $Q^{1/2} e^{-(T-t)A^\dagger}$ 吸收到控制中, 并从 (22) 中的匹配目标中移除其显式出现, 从而产生更稳定的训练。对于所有实验, 我们取 u^θ 为针对扩散式条件调整的改进 U 形神经算子 (UNO) (Rahman 等人, 2022)。具体来说, 控制接收一维序列 $\mathbf{x} \in \mathbb{R}^{|\mathcal{L}| \times \mathbb{R}^d}$ 和时间输入 t 。我们用正弦多层感知机嵌入 t 并构建简单的傅里叶网格特征, 然后将它们压缩为单个条件向量。每个编码器和解码器块在低傅里叶模式上应用谱卷积与逐点路径, 然后使用由条件向量调制的自适应组归一化。条件仅通过归一化进入, 这使算子离散化无关且适合扩散训练。我们设置基础通道维度 $\mathbf{c}$ 并设置通道乘数 $[1, 2, 4]$ 。每个阶段使用两个谱残差块。相反, 我们设置基础傅里叶模式并设置通道乘数 $[1, 0.5, 0.25]$ 。时间步嵌入和条件向量使用等于最高通道的维度。

裁剪 $\alpha_{\max}$ 我们裁剪能量梯度, 使其最大范数不超过 $\alpha_{\max}$ 。

算法 FAS 实现的整体算法总结在算法 2 中。

C.2. 其他域的可能参数化策略

矩形域 设 $\mathbf{X} : \mathbb{R}^2 \rightarrow \mathbb{R}^d$ 是 $\mathbb{R}^2$ 的矩形子集上的一个场, 具有零诺伊曼边界条件, 余弦模态来自自然基。由于真实数据是在有限网格上采样的, 频谱已经包含了一个固有的截止频率。因此, 我们可以通过离散余弦变换 (DCT) 用有限特征分解来写出该算子 (Rissanen 等人, 2023; Lim 等人, 2023b; Park 等人, 2024)。具体来说, 我们可以将拉普拉斯算子近似为 $\mathcal{A} \triangleq \mathbf{E} \mathbf{D} \mathbf{E}^\top$, 其中余弦投影矩阵为 $\mathbf{E}^\top$, 对角特征值为 $\{\lambda^{(k)}\}_{k=1}^K$ 。

图域 对于离散图 $\mathbf{X} : \mathcal{G} \rightarrow \mathbb{R}^3$ 上的函数 $\mathcal{G} = \langle \mathbf{V}, \mathcal{E} \rangle$, 其中 $\mathbf{V} = \{v_i\}_{i=1}^n$ 是顶点集, $\mathcal{E} = \{e_{ij} \mid (i, j) \subseteq |\mathbf{V}| \times |\mathbf{V}|\}$ 是边集, 我们可以选择对称图拉普拉斯算子 $\mathcal{A}_{\text{sym}}$ 的特征向量

Algorithm 1 FAS Sampling with path lifting

Require: Initial condition $\mathbf{x}_0$, linear operator $\mathcal{A}$, trace-class operator Q , control α , discrete and inverse sine transforms DST , iDST , set of evaluation points $\mathbf{U} = \{u_i\}_{i=1}^K$.

- 1: Set initial condition $\mathbf{X}_0^\alpha = \mathbf{x}_0$ and $\mathbf{R}_0^\alpha = \mathbf{0}$
- 2: **for** time t **in range** $[0, T]$ **do**
- 3: Estimate control $\alpha_t = \alpha(\mathbf{X}_t^\alpha, t)$
- 4: Sample Gaussian noise $\varepsilon \sim \mathcal{N}(0, \mathbf{I}_K)$
- 5: Project state, control $\{\tilde{\mathbf{R}}_t^{(k)}\}_{k \in \mathbf{U}} = \text{DST}(\mathbf{R}_t^\alpha), \{\tilde{\alpha}_t^{(k)}\}_{k \in \mathbf{U}} = \text{DST}(\alpha_t)$
- 6: **for** $k = 1, \dots, |\mathbf{U}|$ **do in parallel**
- 7: $\tilde{\mathbf{R}}_{t+\delta_t}^{(k)} = \left[-\lambda^{(k)} \tilde{\mathbf{R}}_t^{(k)} + \sigma_t(\lambda^{(k)})^{-\frac{s}{2}} \tilde{\alpha}_t^{(k)} \right] \delta_t + \sigma_t(\lambda^{(k)})^{-\frac{s}{2}} \varepsilon \sqrt{\delta_t}$
- 8: **end for**
- 9: Get residual $\mathbf{R}_{t+\delta_t}^\alpha = \text{iDST}(\{\tilde{\mathbf{R}}_{t+\delta_t}^{(k)}\}_{k \in \mathbf{U}})$
- 10: Update $\mathbf{R}_t^\alpha = \mathbf{R}_{t+\delta_t}^\alpha$
- 11: Get path $\mathbf{X}_t^\alpha = \mathbf{x}_0 + \mathbf{R}_t^\alpha$
- 12: **end for**
- 13: **return** $\mathbf{X}_T^\alpha \sim \mathbb{P}_T^\alpha$

作为谱基。每个图信号已经是有限维的， $|\mathbf{V}|$ 个模态充当固有的谱截止。该算子允许图傅里叶分解 $\mathcal{A}_{\text{sym}} = \mathbf{U} \mathbf{\Lambda} \mathbf{U}^\top$ ，其中 $\mathbf{U}^\top$ 包含拉普拉斯特征向量， $\mathbf{\Lambda}$ 是对角矩阵，特征值为 $\{\lambda^{(k)}\}_{k=1}^{|\mathbf{V}|}$ 。具体来说，在分子构象生成中， $\mathbf{X} : \mathcal{G} \rightarrow \mathbb{R}^3$ 表示构象场 (Wang 等人, 2024)。注意，与矩形域或时间序列域不同，在那些域中每个函数共享一个公共基，每个分子 $\mathcal{G}_i$ 都有自己的图，因此我们应该为每个训练样本计算相应的特征系统。

C.3. 基线与评估指标

为保持一致性和公平比较，我们遵循基线方法建立的相应实验设置。对于米勒-布朗势，我们遵循 (Du 等人, 2024) 的实验设置和报告结果。对于分子势，我们遵循 (Seong 等人, 2025) 的实验设置，并报告 (Seong 等人, 2025; Blessing 等人, 2025) 的结果。

- **RMSD:** 我们首先用卡布施算法 (Kabsch, 1976) 将端点 $\mathbf{X}[L]$ 的重原子对齐到目标状态 $\mathbf{B}$ 。然后计算 $\mathbf{X}[L]$ 的重原子位置与 $\mathbf{B}$ 之间的均方根偏差 (RMSD)。

- **THP:** 是基于轨迹到达目标亚稳态 $\mathbf{B}$ 的指示性成功率。给定来自 N 条路径的端点 $i=1$ ，我们将 THP 定义为：

$$\text{THP} = 100 \times \frac{|\{i : \mathbf{X}^{(i)}[L] \in \mathcal{B}\}|}{N}, \quad \text{where } \mathcal{B} = \{\mathbf{X}[L] | \|\mathbf{X}[L] - \mathbf{B}\| < \epsilon\}. \quad (190)$$

我们按照 (Seong 等人, 2025) 选择 ϵ 。

- **ETS:** 我们衡量方法在跨越能量势垒时找到可能过渡态的能力。形式上，给定一条到达 $\mathbf{B}$ 的长度为 L 的过渡路径 $\mathbf{X}$ ，我们定义

$$\text{ETS}(\mathbf{X}) = \max_{u \in [0, L]} V(\mathbf{X}[u]). \quad (191)$$

C.4. 势函数与初始条件

- 实验中使用的合成 Muller-Brown 势 $V : \mathbb{R}^2 \rightarrow \mathbb{R}$ 由下式给出

$$V(x, y) = -200 \cdot \exp(-(x_1 - 1)^2 - 10y^2) - 100 \cdot \exp(-x^2 - 10 \cdot (y - 0.5)^2) \quad (192)$$

$$- 170 \cdot \exp(-6.5 \cdot (x + 0.5)^2 + 11 \cdot (x + 0.5) \cdot (y - 1.5) - 6.5 \cdot (y - 1.5)^2) \quad (193)$$

$$+ 15 \cdot \exp(0.7 \cdot (x + 1)^2 + 0.6 \cdot (x + 1) \cdot (y - 1) + 0.7 \cdot (y - 1)^2). \quad (194)$$

对于合成势，我们将初始条件 $\mathbf{x}_0$ 设为两个局部极小值 $\mathbf{A} = (-0.558, 1.442)$ 与 $\mathbf{B} = (0.624, 0.028)$ 之间的线性插值。

Algorithm 2 Function Space Adjoint Sampler (FAS)

Require: Initial condition $\mathbf{x}_0$, terminal cost $g(x)$, control network $\alpha^\theta(\mathbf{x}, t)$, replay buffer $\mathcal{B}$, total epoch M , resample sizes N , gradient steps L , maximum energy norm $\alpha_{\max}$.

```

1: for epoch  $m$  in  $1, 2, \dots, M$  do
2:   Sample  $N$  paths  $\mathbf{X}_T^{\bar{\alpha}^m}$  from Algorithm 1 with  $\bar{\alpha}^m = \text{stopgrad}(\alpha_{\theta^m}^{\bar{\alpha}^m})$ 
3:   Compute adjoint  $\mathbf{Y}_T^{\bar{\alpha}^m} = \text{clip}(\nabla g(\mathbf{X}_T^{\bar{\alpha}^m}), \alpha_{\max})$ 
4:   Update buffer  $\mathcal{B} \leftarrow \mathcal{B} \cup (\mathbf{X}_T^{\bar{\alpha}^m}, \mathbf{Y}_T^{\bar{\alpha}^m})$ 
5:   for step  $l$  in  $1, 2, \dots, L$  do
6:     Sample  $t \sim \mathcal{U}[0, T]$ ,  $(\mathbf{X}_T, \mathbf{Y}_T) \sim \mathcal{B}$  and  $\mathbf{X}_t \sim \mathbb{P}_{t|T}(\cdot | \mathbf{X}_T)$ 
7:     Compute the training objective:
    
```

$$\mathcal{L}_{\text{FAS}}(\theta) = \mathbb{E}_{t, (\mathbf{x}_T, \mathbf{y}_T), \mathbf{x}_t} \left[\left\| \alpha^{\theta_s}(\mathbf{X}_t, t) + \sigma_t Q^{1/2} e^{-(T-t)\mathbf{A}^\dagger} \mathbf{Y}_T \right\|_{\mathcal{H}}^2 \right]$$

```

8:     Update  $\theta_m^{l+1}$  with  $\nabla_{\theta} \mathcal{L}_{\text{FAS}}(\theta_m^l)$ .
9:   end for
10: end for
11: return Approximated optimal control  $\alpha^* \approx \alpha^{\theta_M}$ 
    
```

• 对于真实分子系统，我们使用 OpenMM 库 (Eastman 等人, 2023) 实现势能。由于 OpenMM 库不提供自动微分，我们将其封装在 PyTorch (Paszke 等人, 2019) 中，并高效地暴露批量能量和力调用。

我们对真空中的丙氨酸二肽使用 **amber99sbildn** (Lindorff-Larsen 等人, 2010)，并设置 $\mathbf{B} = \text{C7ax}$ $\mathbf{A} = \text{C5}$ 和。对于 Chignolin，我们使用 **ff14SBonlysc** (Maier 等人, 2015) 与 **gbn2** 溶剂 (Nguyen 等人, 2013)，并按照 (Seong 等人, 2025) 的设置将 $\mathbf{A}$ 设为未折叠蛋白， $\mathbf{B}$ 设为折叠蛋白。

C.5. 分子势能上的过渡路径采样

路径初始化 由于分子势能具有崎岖且刚性的特性，仅靠线性插值会在路径上产生冲突和高能量图像，这可能导致次优解。为避免此问题，我们为分子势能引入了额外的细化策略。

给定初始条件 $\mathbf{x}_0$ ，我们在端点 $\mathbf{A}$ 和 $\mathbf{B}$ 之间对笛卡尔坐标进行线性插值，然后在训练前使用图像依赖对势 (IDPP) (Smidstrup 等, 2014) 细化路径。设 $\mathbf{C} = (\mathbf{r}_1, \dots, \mathbf{r}_N)$ 表示原子位置为 $\mathbf{r}_i \in \mathbb{R}^3$ 的构型。给定端点 $\mathbf{A}$ 和 $\mathbf{B}$ ，以及具有图像 $\mathbf{x}[u] = \mathbf{0}_{N \times 3}$ 的路径，在时间 u 处对 (i, j) 的目标距离为给定端点间成对距离的线性插值：

$$\tilde{d}_{ij}[u] = (1 - u)d_{ij}(\mathbf{A}) + ud_{ij}(\mathbf{B}), \quad \text{where} \quad d_{ij}(\mathbf{C}) = |\mathbf{r}_i - \mathbf{r}_j|. \quad (195)$$

然后，IDPP 通过以下方式最小化当前距离与目标距离之间的不匹配：

$$\mathbf{E}_{\text{IDPP}}(\mathbf{x}[u]) = \sum_{i < j} w_{ij}^{(u)} (d_{ij}(\mathbf{x}[u]) - \tilde{d}_{ij}[u])^2, \quad (196)$$

其中 $w_{ij}^{(u)} = 1/(\tilde{d}_{ij}[u])^4$ 是所有图像 $u \in \mathbf{U}$ 上的权重。这种初始化以可忽略的时间成本 *e.g.*, (不到一分钟) 产生接近最小能量路径的路径。算法 3 总结了 IDPP 初始化。对于 chignolin，我们在 IDPP 初始化后，以较小的步长 $\epsilon = 10^{-6}$ 在能量 (26) 上额外执行梯度流步骤，以使初始路径更稳定：

$$\mathbf{x}_{t+\epsilon} = \mathbf{x}_t - \nabla U(\mathbf{x}_t)\epsilon. \quad (197)$$

正则化 IDPP 通过为丙氨酸二肽和 chignolin 生成逼真的图像来改进起始路径。然而，对于丙氨酸二肽，在笛卡尔坐标中的扩散可能会将路径移入能量槽中，从而拉伸或

Algorithm 3 IDPP initialization

Require: Transition states **A** and **B**, discretization $\mathbf{U} = \{u_i\}_{i=1}^K$ with $0 = u_1 < \dots < u_K = 1$.

- 1: Set initial condition $\mathbf{x}_0 = (1 - t)\mathbf{A} + t\mathbf{B}$
- 2: **for** implicit time u **in range** $[u_1, u_K]$ **do**
- 3: Compute target distance $\tilde{d}_{ij}[u]$ in (195) for all $(i, j) \in N \times N$.
- 4: Take L gradient steps $\nabla_{\mathbf{x}_0[u]} \mathbf{E}_{\text{IDPP}}(\mathbf{x}_0[u])$ w.r.t on IDPP energy (196).
- 5: **end for**
- 6: **return** Refined initial condition $\tilde{\mathbf{x}}_0$




图 4: 丙氨酸二肽在不同离散化步数下的采样过渡路径。

将键压缩至超出物理范围。因此，我们在终端代价中加入正则化项以限制键长偏差：

$$\tilde{U}(\mathbf{X}) = U(\mathbf{x}) + \lambda_{\text{reg}} \sum_{u \in \mathbf{L}} \mathbf{E}_{\text{IDPP}}(\mathbf{x}[u]), \quad (198)$$

其中 $\lambda_{\text{reg}} > 0$ 为常数。该正则化代价惩罚每个图像中成对距离与 IDPP 参考值的偏差，并抑制短程冲突和过度拉伸的键。对于丙氨酸二肽，我们设置 $\lambda_{\text{reg}} = 1$ 。

C.6. 附加实验

离散化不变性采样 除了有效的边界约束外，函数形式还提供了一个关键优势：离散化不变性。一旦模型在固定且通常较粗的网格上训练完成，它就能以任意分辨率采样路径。这一能力使得函数形式在科学领域中的关注度日益增加。

在本节中，我们评估 FAS 在 TPS 上的离散化不变性。对于 TPS，当需要在鞍点附近获得更精细的构型图像时，这一性质尤为重要。基于经典朗之万动力学的采样器可以通过减小步长来细化路径。然而，这种细化需要额外的力和能量评估，且评估次数随步数增加而增长，从而增加了计算成本和推理时间。相比之下，FAS 只需在较小的离散化上训练一次。在推理时，它可以在任意选定的细化网格上生成目标路径，而无需额外的能量评估，因为能量代价已在学习到的控制中被摊销。

图 5 展示了在合成势能上以极高分辨率进行的零样本 TPS。具体来说，我们在隐式时间区间 $[0, 1]$ 上以 100 个均匀离散化点进行训练，然后在细化因子为 $\times 10$ 和 $\times 100$ 的更细网格上评估，对应的离散化步数分别为 10^3 和 10^4 。尽管是零样本推理，FAS 仍能持续生成可靠的路径。注意，在高分辨率下采样需要比最初选择的 $(\beta_{\min}, \beta_{\max})$ 更大的扩散尺度才能获得理想性能，因此我们根据细化因子缩放 $(\beta_{\min}, \beta_{\max})$ 。具体而言，如果网格细化因子为 r ，则在高分辨率采样时使用 $\hat{\beta}_{\min} = (1 + 2\log_{10}(r))\beta_{\min}$ 和 $\hat{\beta}_{\max} = (1 + 2\log_{10}(r))\beta_{\max}$ 。




图 5: 合成势能上不同离散化步数下的采样过渡路径。




图 6: 丙氨酸二肽的消融实验。(左) 对 $\beta_{\max}$ 的消融实验。(右) 模型规模的消融实验。

图 4 展示了丙氨酸二肽上的相同行为。由于分子系统势能面的复杂性，我们观察到少数评估点可能出现短暂尖峰。我们通过应用如 (197) 中所述的 10 步后处理梯度流步骤（其中 $\epsilon = 10^{-6}$ ）来消除这些伪影。

消融实验 对于 FAS 训练，(22) 中的匹配目标依赖于对路径-能量景观 g 的充分探索。此外，早期阶段的广泛探索对于定位 $\mathcal{L}_{\text{FAS}}$ 的临界点至关重要，因为较高的早期扩散调度 σ_t 有效地扩大了 g 中采样路径的支撑集。因此，我们消融了扩散幅度 σ_t 的影响，通过增加 $\beta_{\max} \in [10, 15]$ 并固定 $\beta_{\min} = 0.01$ 来提升性能。如图 6 所示，我们观察到随着 $\beta_{\max}$ 的增加，所得 ETS 持续下降。

此外，我们消融了 FAS 随模型规模的扩展性。与 (12) 中原始的路径级 SOC 目标相比，(22) 中匹配型目标的逐点计算特性能够更好地扩展，而无需大量计算。我们通过将基础维度设置为 32 (UNO-S)、48 (UNO-M) 和 64 (UNO-L) 来改变网络规模。注意，尽管参数数量增加，内存使用几乎保持不变。图 6 显示，更大的模型产生更好的 ETS，这表明 FAS 随模型规模扩展。