

Discrete Adjoint Matching

Oswin So^{1,†,*}, Brian Karrer^{2,*}, Chuchu Fan¹, Ricky T. Q. Chen^{2,*}, Guan-Horng Liu^{2,*}

¹Massachusetts Institute of Technology, ²FAIR at Meta

† 工作完成于 FAIR, Meta

Computation methods for solving entropy-regularized reward optimization—a class of problems widely used for fine-tuning generative models—have advanced rapidly. Among those, Adjoint Matching (AM, [Domingo-Enrich et al., 2025](#)) has proven highly effective in continuous state spaces with differentiable rewards. Transferring these practical successes to *discrete* generative modeling, however, remains particularly challenging and largely unexplored, mainly due to the drastic shift in generative model classes to discrete state spaces, which are nowhere differentiable. In this work, we propose **Discrete Adjoint Matching (DAM)**—a discrete variant of AM for fine-tuning discrete generative models characterized by Continuous-Time Markov Chains, such as diffusion-based large language models. The core of DAM is the introduction of *discrete adjoint*—an estimator of the optimal solution to the original problem but formulated on discrete domains—from which standard matching frameworks can be applied. This is derived via a purely statistical standpoint, in contrast to the control-theoretic viewpoint in AM, thereby opening up new algorithmic opportunities for general adjoint-based estimators. We showcase DAM’s effectiveness on synthetic and mathematical reasoning tasks.

Date: February 17, 2026



1 引言

本文考虑在状态空间 $\mathcal{X}$ 上、有限时域 $t \in [0, 1]$ 内的熵正则化优化问题：

$$\min_u \mathbb{E}[g(X_1)] + D_{\text{KL}}(p^u(\mathbf{X}) || p^{\text{base}}(\mathbf{X})) \quad (1)$$

其中目标函数由终端损失 $g(\cdot)$ （在 $t = 1$ 处产生）和 Kullback – Leibler (KL) 散度 $D_{\text{KL}}(\cdot || \cdot)$ 组成，该散度将模型分布 p^u （定义在由 u 参数化的随机过程 $\mathbf{X} = (X_t)_{t \in [0, 1]}$ 上）正则化到由 u^{base} 参数化的基础分布 $p^{\text{base}} \equiv p^{u^{\text{base}}}$ 。

形式如（1）的优化问题在强化学习（Levine, 2018）、随机控制（Theodorou et al., 2010）和概率推断（Blei et al., 2017）的交叉领域普遍存在。在生成建模的背景下，研究（1）的主要动机源于以下事实：当基础分布满足无记忆条件 $p^{\text{base}}(X_1 | X_0) = p^{\text{base}}(X_1)^1$ 时，（1）的最优解具有解析表达式：

$$p^*(\mathbf{X}) \equiv p^{u^*}(\mathbf{X}) \propto p^{\text{base}}(\mathbf{X}) e^{-g(X_1)} \quad (2)$$

这种解析表达式对于生成模型的后训练（Ziegler et al., 2019; Ouyang et al., 2022; Fan et al., 2023b）尤为有用，其中我们希望根据给定的奖励函数 $r(x)$ 对预训练模型进行微调。具体而言，将 p^{base} 视为预训练模型，并将终端损失设为负奖励 *i.e.*, $g(x) := -r(x)$ ，则（1）中的优化问题可以最好地理解为变分推断，即寻求一个后验分布，使其接近先验的预训练分布，同时以指数方式向高奖励区域倾斜 *i.e.*, $p^*(X_1) \propto p^{\text{base}}(X_1) e^{r(X_1)}$ 。

近年来，求解（1）的计算方法发展迅速。其中，基于伴随匹配（AM, Domingo-Enrich et al., 2025）的方法在具有可微终端损失 *e.g.*, $\mathbf{X} = \mathbb{R}^d$ 和 $\nabla g: \mathbb{R}^d \rightarrow \mathbb{R}^d$ 的连续状态空间中表现出高效性，在图像微调（Domingo-Enrich et al., 2025）、分子生成（Havens et al., 2025）以及*这些作者是项目的核心贡献者。详见作者贡献部分。¹等应用中取得了显著成果。

¹无记忆条件对所有考虑的基础模型均自然成立。详见第 A.1 节。

玻尔兹曼分布采样器 (Liu et al., 2025a)。具体而言, 当 p^u 是由一类由 $dX_t = \sigma_t^2 u_t(X_t)dt + \sigma_t dW_t$ 参数化、具有某种扩散 σ_t 的随机微分方程 (SDEs) 所诱导的分布时, Domingo-Enrich et al. (2025) 观察到任何最优解都必须满足一个不动点方程, 其紧凑形式为

$$u_t^*(x) = u_t^{\text{base}}(x) - \mathbb{E}_{p^*(\mathbf{X}|X_t=x)} \left[\underbrace{\tilde{a}_1(\mathbf{X}) - \int_t^1 \nabla u_\tau^{\text{base}}(X_\tau) \cdot \tilde{a}_\tau(\mathbf{X}) d\tau}_{=: \tilde{a}_t(\mathbf{X})} \right], \quad \tilde{a}_1(\mathbf{X}) = \nabla g(X_1) \quad (3)$$

其中 u^{base} 定义了基础分布 $p^{\text{base}} \equiv p^{u^{\text{base}}}$, $\nabla u^{\text{base}} : \mathbb{R}^d \rightarrow \mathbb{R}^{d \times d}$ 表示其雅可比矩阵。伴随匹配的核心是引入 (精简的) 伴随 $\tilde{a}_t(\mathbf{X}) \in \mathbb{R}^d$ ——最优解 $u_t^*(x)$ 的估计量——它可以通过从终端条件 $\tilde{a}_1(\mathbf{X}) = \nabla g(X_1)$ (即终端损失的梯度) 进行反向积分来高效计算。

在本文中, 我们特别关注离散生成建模, 这是一个在工业界和学术界都备受关注的热门研究领域 (Touvron et al., 2023; Achiam et al., 2023; Kasneci et al., 2023), 其推动力来自大语言模型 (LLMs) 在语言理解 (Wei et al., 2022; Bai et al., 2023)、代码生成 (Chen et al., 2021; Team et al., 2023) 和数学推理 (Shao et al., 2024; Nie et al., 2025) 方面的变革性成功。在所有情况下, 状态空间都由离散有限集的乘积表示, $\mathcal{X}^{\text{discrete}} = \{1, \dots, M\}^N$ 。也就是说, 每个样本 $x = (x^1, \dots, x^N) \in \mathcal{X}^{\text{discrete}}$ 对应于一个由 N 个离散变量组成的序列, 其中每个变量 x^i 是词汇表中一个元素 (也称为标记) 的索引, 词汇表大小为 M 。

必须考虑离散状态空间, 这需要一族离散生成模型。值得注意的是, 其中大多数可以表述为连续时间马尔可夫链 (CTMC, Anderson, 2012) ——有限集上的随机跳跃过程, 由其转移速率,² 唯一刻画

$$u_t(y, x) := \lim_{\Delta t \rightarrow 0} \frac{p(X_{t+\Delta t} = y | X_t = x) - \delta_x(y)}{\Delta t} \quad (4)$$

它量化了在时间 t 从 x 到任意 $y \neq x$ 的无穷小转移概率。我们用 $\delta_x(y)$ 表示指示函数, 当 $y = x$ 时等于 1, 否则等于 0。CTMC 最初由离散扩散模型引入 (Austin et al., 2021; Campbell et al., 2022), 后来被证明可以推广掩码模型和自回归模型 (Sahoo et al., 2024; Shi et al., 2024)。

基于伴随匹配在连续域中的实际成功, 一个自然的问题随之而来:

Does a variant of Adjoint Matching exist for discrete generative modeling?

更具体地说, 我们感兴趣的是, 当 (1) 中的优化问题在离散状态空间 $\mathcal{X} = \mathcal{X}^{\text{discrete}}$ 上表述时, 其中 p^u 和 p^{base} , 是否存在类似于 (3) 的不动点方程

分别对应于微调与预训练的连续时间马尔可夫链 (CTMC) 模型的分布。这种离散扩展 (如果存在的话) 仍然特别具有挑战性, 因此很大程度上尚未被探索——主要原因是离散状态空间的不可微性以及所考虑分布类别的剧烈变化。这两者都阻碍了在离散域中对 (3) 式的直接改编, 因为 $g(x)$ 不再可微, 且 u_τ^{base} 现在表示基础 CTMC 的速率, 而非随机微分方程 (SDE) 的漂移项。甚至离散版本的 AM 是否存在都值得怀疑。

为此, 本文提出离散伴随匹配 (Discrete Adjoint Matching, DAM), 作为伴随匹配的离散类比, 解决与式 (1) 相同的优化问题, 但针对离散状态空间上的连续时间马尔可夫链 (CTMC) 模型。与仅基于控制论框架的原始伴随匹配不同 (Bellman, 1966; Fleming & Rishel, 2012), 本文从纯统计视角推导离散伴随匹配, 更易于理解, 同时为感兴趣的读者提供完整的控制论分析。这需要将伴随匹配提升到更抽象的设计空间, 并由此特化到其他模型类别, 如连续时间马尔可夫链。本文展示 Dynkin 公式 (Piunovskiy & Zhang, 2020) 如何通过提供任意随机过程的函数值估计器来实现这种泛化。应用该公式估计最优连续时间马尔可夫链速率 u^* , 其正式定义如下 在下一节中, 由连续时间马尔可夫链 (CTMC) 过程导出了伴随方程 (3) 的离散对应形式——离散伴随。

(y, x)

² 根据构造, (4) 中的 u 对所有 $y \neq x$ 和 $\sum_{y \in \mathcal{X}} u_t(y, x) = 0$ 满足速率条件: $u_t(y, x) \geq 0$ $y \in \mathcal{X}$ $u_t(y, x) = 0$ 。

我们在数学推理数据集上验证了 DAM 对基于扩散的大语言模型（LLM）的微调效果，特别是 LLaDA-8B-Instruct（Nie 等人，2025），其中微调方法已被证明对提升性能至关重要（Shao 等人，2024；Zhao 等人，2025）。为了应对可能阻碍离散伴随朴素实现的极大离散状态空间，我们利用了所有考虑的基础分布中嵌入的掩码结构（Sahoo 等人，2024），并提出了额外的方差缩减技术，这些技术共同增强了训练稳定性和采样效率。

综上所述，本文提出以下贡献：

- 本文提出离散伴随匹配（Discrete Adjoint Matching, DAM），作为伴随匹配（Adjoint Matching, AM）的离散对应方法，求解相同的熵正则化优化问题（1），但专门针对具有连续时间马尔可夫链（Continuous-Time Markov Chain, CTMC）的离散状态空间进行公式化。
- 本文通过纯粹的统计视角推导 DAM——将离散伴随解释为最优解的估计器——从而避免了原始 AM 中采用的复杂控制论推导，并为基于伴随的估计器提供了更通用的框架。
- 本文解决了在极大离散状态空间中实现 DAM 的实际挑战——这是现代离散生成建模的典型情况——通过应用重要性加权技术以提升训练稳定性，并探索通过掩码扩散模型进行进一步简化。
- 本文在数学推理任务上，针对给定的奖励函数，验证了 DAM 在微调离散生成模型（如基于扩散的大语言模型）方面的经验性能。

2 离散伴随匹配

本文提出离散伴随匹配（Discrete Adjoint Matching, DAM），一种用于学习 CTMC 模型 p^u 以求解（1）的计算方法。该方法通过将参数化速率 $u_t^\theta(y, x)$ 与通过离散伴随获得的最优速率 $u_t^*(y, x)$ 的估计器进行匹配来实现，类似于（3）中的连续对应方法。这种解释有助于采用纯粹的统计方法来估计 u^* ，并使我们能够绕过看似复杂的基于随机最优控制（SOC）的推导，不过为感兴趣的读者，我们仍在第 3 节中呈现该推导。从概念上讲，我们寻求以下形式的目标：

$$\mathcal{L}(\theta) = \mathbb{E}_{\mathbf{X}} [\mathbb{D}(u^\theta(\cdot), u^*(\cdot | \mathbf{X}))] \quad (5)$$

其中 $\mathbb{D}(\cdot, \cdot)$ 是某个匹配函数， $u^*(\cdot | \mathbf{X})$ 是给定轨迹 $\mathbf{X}$ 时 u^* 的基于伴随的估计器。例如，AM（Domingo-Enrich 等，2025）考虑 $\mathbb{D}(a, b) := \|a - b\|^2$ ，并且如（3）所暗示的，通过 $u_t^*(x | \mathbf{X}) := u_t^{\text{base}}(x) - \tilde{a}_t(\mathbf{X})$ 计算基于伴随的估计器，而 DAM 则为 CTMC 模型实例化匹配目标（5）。所有证明见第 B 节。

2.1 离散伴随作为最优速率的估计器

我们首先明确所关注的数学对象——问题（1）的最优速率 u^* ，离散伴随正是为估计该速率而设计。由（4）可知，该速率由连续时间马尔可夫链（CTMC）分布的一阶导数唯一确定。在 u^* 情形下，由于最优分布 p^* 具有解析形式（2），其最优速率也具有解析形式（Wang et al., 2025; Zhu et al., 2025）：

$$\forall y \neq x, \quad u_t^*(y, x) = u_t^{\text{base}}(y, x) e^{-V_t(y) + V_t(x)}, \quad \text{其中} \quad V_t(x) := -\log \sum_z p_{1|t}^{\text{base}}(z|x) e^{-g(z)} \quad (6)$$

是量化最优代价（Bellman, 1954）， $u_t^{\text{base}}(y, x)$ 的值函数，是定义基础连续时间马尔可夫链分布 p^{base} 的基础速率，而 $p_{1|t}^{\text{base}}$ 是其条件分布的简写。（6）的推导是标准的但略显繁琐；细节参见第 A 节。

借助（6）中的解析表达式，估计最优速率 u^* 归结为估计指数值差 $e^{-V_t(y) + V_t(x)}$ ，因为 u^{base} 是先验已知的。按照（5）中的解释，我们可以将离散伴随设计为给定连续时间马尔可夫链过程 $\mathbf{X}$ 下值差指数的估计量。这种方法——利用随机过程估计函数值——正是 Dynkin 公式（Piunovskiy & Zhang, 2020, Theorem 2.4.1）所提供的內容：

引理 2.1 (Dynkin 公式)。对于给定的函数 $f_t(x)$ 和连续时间马尔可夫链模型 p^u ，有

$$f_t(x) = \mathbb{E}_{p^u}(\mathbf{X}|X_t=x) \left[f_1(X_1) - \int_t^1 \left((\partial_\tau f_\tau)(X_\tau) + \sum_y u_\tau(y, X_\tau) f_\tau(y) \right) d\tau \right]. \quad (7)$$

形式上，Dynkin 公式适用于任何 Feller 过程 (Rogers & Williams, 2000)，它推广了随机微分方程 (SDE) 和连续时间马尔可夫链过程。在随机微分方程上，它产生了著名的 Itô 引理 (Itô, 1951)，这是先进扩散模型发展中的基本工具 (Liu et al., 2022; Skreta et al., 2024; Karczewski et al., 2024)。相比之下，引理 2.1 将该结果专门化到连续时间马尔可夫链，其本质是能够在给定任何连续时间马尔可夫链过程的情况下估计任何离散空间函数。

我们现在准备给出主要结果。通过对每个 $x \neq y$ 应用引理 2.1，取 $f_t(x; y) := e^{-V_t(y) + V_t(x)}$ ，并以最优速率作为 $u := u^*$ ，我们得到最优分布下指数值差的估计量——这与 (3) 中连续伴随在 p^* 下估计最优随机微分方程漂移的思路一致。由此得到以下结果：

定理 2.2 (离散伴随——连续时间马尔可夫链的伴随系统)。设 $u_t^*(y, x)$ 为连续时间马尔可夫链模型下熵正则化问题 (1) 的最优速率。则对所有 $y \neq x$ 成立

$$u_t^*(y, x) = u_t^{\text{base}}(y, x) \mathbb{E}_{p^*}(\mathbf{X}|X_t=x) \left[\underbrace{\tilde{a}_1(y; \mathbf{X}) + \int_t^1 \sum_z u_\tau^{\text{base}}(z, y) \tilde{a}_\tau(z; \mathbf{X}) d\tau}_{=: \tilde{a}_t(y; \mathbf{X})} \right], \quad \tilde{a}_1(y; \mathbf{X}) = e^{-g(y) + g(X_1)} \quad (8)$$

其中离散伴随 $\tilde{a}_t(y; \mathbf{X}) \in \mathbb{R}_{>0}$ 是在 p^* 下 $e^{-V_t(y) + V_t(x)}$ 的无偏估计量。

将式 (8) 与式 (3) 对比，本文提出的离散伴随与其连续对应物在结构上惊人地相似，但在若干重要方面存在差异。最显著的是，终端离散伴随 $\tilde{a}_1$ 变为终端损失差的指数，而非式 (3) 中的梯度。接下来，为更好地考察其动力学差异，可将式 (8) 改写为向量形式：

$$\tilde{\mathbf{a}}_t(\mathbf{X}) = \tilde{\mathbf{a}}_1(\mathbf{X}) + \int_t^1 U_\tau^{\text{base}} \cdot \tilde{\mathbf{a}}_\tau(\mathbf{X}) d\tau, \quad \text{where } \tilde{\mathbf{a}}_\tau(\mathbf{X}) \in \mathbb{R}^{|\mathcal{X}|} \text{ and } U_\tau^{\text{base}} \in \mathbb{R}^{|\mathcal{X}| \times |\mathcal{X}|} \quad (9)$$

分别是离散伴随向量（其第 y 个元素为 $\tilde{a}_\tau(y; \mathbf{X})$ ）和基础速率矩阵（其第 (z, y) 个元素为 $u_\tau^{\text{base}}(z, y)$ ）。也就是说，式 (3) 中的雅可比矩阵 $\nabla u_\tau^{\text{base}} \in \mathbb{R}^{d \times d}$ 实际上被替换为 $U_\tau^{\text{base}} \in \mathbb{R}^{|\mathcal{X}| \times |\mathcal{X}|}$ 。最后，离散伴随以乘法方式扰动基础速率， $u^{\text{base}} \llbracket \tilde{\mathbf{a}} \rrbracket$ ，而式 (3) 中的连续伴随采用加法扰动， $u^{\text{base}} - \llbracket \tilde{\mathbf{a}} \rrbracket$ 。

根据定理 2.2，设计匹配函数 $\mathbb{W}(\cdot, \cdot)$ 是匹配框架 (Lipman 等, 2024; Holderrith 等, 2024) 的直接应用。对于由凸函数 $\mathbb{W}_\phi(u, w) :=$ 定义的任意布雷格曼散度 $\phi(u) - \phi(w) - \langle u - w, \frac{d}{dw} \phi(w) \rangle$ ，有

$$u_t^*(y, x) = \arg \min_u \mathbb{E}_{p^*}(\mathbf{X}|X_t=x) [\mathbb{W}_\phi(u_t(y, x), u_t^{\text{base}}(y, x) \tilde{a}_t(y; \mathbf{X}))] \quad (10)$$

本文强调这些理论结果的显著性，它们为基于任意随机过程（包括连续时间马尔可夫链模型）推导伴随估计量提供了统计上严格的基础。

2.2 实践中的改进技术

在本小节中，本文解决直接匹配式 (8) 与式 (10) 中离散伴随的实际挑战，并提供改进技术，从而得到最终算法。

改进的离散伴随 尽管定理 2.2 在刻画连续时间马尔可夫链 (CTMC) 的伴随系统方面具有重要意义，但 (8) 和 (9) 中的离散伴随计算代价极其高昂，因为需要在每个时间步对整个状态空间 $z \in \mathcal{X}$ 求和。对于任何合理的离散生成问题——例如词汇量大小为 $M \approx 1000$ 、上下文长度为 $N \approx 100$ ，因此 $|\mathcal{X}| = M^N \approx 10^{300}$ ——这样的计算根本无法承受。这要求进一步简化以保证可处理性，下面我们给出其中一种简化方法：

Algorithm 1 Discrete Adjoint Matching (DAM)

Require: non-differentiable terminal loss $g(x)$, parametrized rate $u_t^\theta(y, x)$, and base rate $u_t^{\text{base}}(y, x)$

- 1: **repeat**
- 2: Sample from model $\{(X_0^{(i)}, X_1^{(i)})\} \sim p^{\bar{u}}$, where $\bar{u} = \text{stopgrad}(u^\theta)$
- 3: Update replay buffer $\mathcal{B} \leftarrow \mathcal{B} \cup \{(X_0^{(i)}, X_1^{(i)})\}$
- 4: **for** l in $1, 2, \dots, L$ **do**
- 5: Sample time $t \sim \mathcal{U}[0, 1]$ and state $X_t \sim p_{t|0,1}^{\text{base}}(\cdot | X_0, X_1)$ where $(X_0, X_1) \sim \mathcal{B}$
- 6: Sample K model trajectories $\{\mathbf{X}^{(k)}\} \sim p^{\bar{u}}(\cdot | X_t)$
- 7: Set (Y, Z) as the first and last jumps of one of the trajectory $\mathbf{X}^{(k)}$
- 8: Compute discrete adjoint $\hat{a}_t(Y, X_t) \equiv \hat{a}_t(Y; Z, \{X_1^{(k)}\})$ in (13)
- 9: Take a gradient step $\nabla \mathcal{L}_{\text{DAM}}(\theta)$ on the weighted matching objective

$$\mathcal{L}_{\text{DAM}}(\theta) := \frac{1}{p_t^{\bar{u}}(Y|X_t)} \cdot \mathbb{D}_{\text{gKL}}\left(u_t^\theta(Y, X_t), (u_t^{\text{base}} \hat{a}_t)(Y, X_t)\right) \quad (11)$$

- 10: **end for**
 - 11: **until** converge
-

命题 2.3（解析离散伴随）。(8) 中的离散伴随存在解析解：

$$\tilde{a}_t(y; X_1) = \sum_z p_{1|t}^{\text{base}}(z|y) e^{-g(z)+g(X_1)} \quad (12)$$

(12) 中的估计量 $\tilde{a}_t(y; X_1)$ 源于离散伴随动力学遵循线性常微分方程（ODE）这一事实——如 (9) 所示——因此存在解析解。尽管计算 $\tilde{a}_t(y; X_1)$ 仍需要对 $z \in \mathcal{X}$ 求和，但可以将其概率性地解释为对条件分布 $p_{1|t}^{\text{base}}(\cdot|y)$ 的期望，并通过 $Z \sim p_{1|t}^{\text{base}}(\cdot|y)$ 进行估计，这对应于从 $X_t = y$ 生成的基础 CTMC 样本。本质上，(12) 中的 $\tilde{a}_t(y; X_1)$ 为 (8) 中的原始离散伴随 $\tilde{a}_t(y; \mathbf{X})$ 提供了一个可处理的解。

根据定理 2.2，要使 $\tilde{a}_t(y; X_1)$ 作为最优速率 u^* 的无偏估计量，我们必须从最优分布中采样 $X_1 \sim p^*$ ——正如其连续版本 (3) 要求 $\mathbf{X} \sim p^*$ 一样。虽然可以遵循原始 AM 方法，通过模型样本 $X_1 \sim p^u$ 计算 $\tilde{a}_t(y; X_1)$ 并让偏差在训练过程中逐渐减小，但我们选择了一种更适合离散域的替代方案：使用模型样本 $X_1 \sim p^u$ 和重要性权重来近似 $X_1 \sim p^*$ 的期望。由此得到以下估计量，经验表明其偏差和方差都显著更低。

命题 2.4（重要性加权离散伴随）。考虑以下估计量

$$\hat{a}_t(y; Z, \{X_1^{(k)}\}) := \frac{p_{1|t}^{\text{base}}(Z|y)}{p_{1|t}^u(Z|y)} e^{-g(Z)} \cdot \left(\frac{1}{K} \sum_{k=1}^K \frac{p_{1|t}^{\text{base}}(X_1^{(k)}|x)}{p_{1|t}^u(X_1^{(k)}|x)} e^{-g(X_1^{(k)})} \right)^{-1} \quad (13)$$

其中 $\{X_1^{(k)}\} \sim p_{1|t}^u(\cdot|x)$ 和 $Z \sim p_{1|t}^u(\cdot|y)$ 是生成的模型样本。那么， $\hat{a}_t$ 是以下量的一致估计量
the discrete adjoint, i.e., $\lim_{K \rightarrow \infty} \mathbb{E}[\hat{a}_t(y; Z, \{X_1^{(k)}\})] = \mathbb{E}_{p_{1|t}^*(X_1|x)} [\tilde{a}_t(y; X_1)]$.

将 (13) 与 (12) 比较，估计量 $\hat{a}_t$ 实际上使用从 $X_t = y$ 生成的单个模型样本来估计 $e^{-g(z)}$ ，并使用自归一化重要性采样 (Neal, 2001) 从 $X_t = x$ 中抽取 K 个模型样本来估计 $e^{g(X_1)}$ 。由于这些重要性权重——即 $p_{1|t}^{\text{base}}$ 与 $p_{1|t}^u$ 的概率比——对于 CTMC 可以轻松估计（详见附录 A），我们采用 (13) 中的估计量 $\hat{a}_t(y; Z, \{X_1^{(k)}\})$ 作为离散伴随 $\tilde{a}_t(y; \mathbf{X})$ 的实用实现。

与广义 KL 散度的匹配 接下来，我们讨论从布雷格曼发散（Bregman divergence）族中选择匹配函数 $\mathbb{D}_\phi(\cdot, \cdot)$ ，遵循式 (10)。虽然可以使用朴素的 ℓ_2 -范数，但已知它会忽略离散域中必要的概率结构，例如非负性 (Lou 等人, 2023)。更

适用于离散建模的合适替代方案是广义 KL 散度 (gKL) :

$$\mathbb{D}_{\text{gKL}}(u, w) := \sum_{y \neq x} u(y, x) - w(y, x) + w(y, x) \log \frac{w(y, x)}{u(y, x)} \quad (14)$$

这对应于设置 $\phi(a) := \sum_i a(i) \log a(i)$.

采样模型输入 (y, x) 在确定了 (14) 中的匹配函数并建立了 (13) 中可处理的伴随估计器之后, 仍需讨论如何对模型输入 (y, x) 进行采样。直观上, 对于给定的 t , 我们希望从最优连续时间马尔可夫链 (CTMC) 所经过的高概率区域中采样 $x = X_t$ 。这通常通过互逆投影 $X_t \sim p_{t|0,1}^{\text{base}}(\cdot | X_0, X_1)$ 来实现, 其中 $(X_0, X_1) \sim \mathcal{B}$ 从重放缓冲区中采样 (Shi 等, 2023)。同时, 不同于 (14) 中建议的对 y 进行均匀采样, 我们从模型 $y \sim p_t^u(\cdot | x)$ 中采样 y , 并相应地用 $p_t^u(y|x)^{-1}$ 对目标进行去偏。这得到了 (11) 中呈现的最终匹配目标。

针对掩码扩散模型的适配 虽然我们的数据增强模型 (DAM) 旨在学习一个连续时间马尔可夫链 (CTMC) p^u , 以在给定任意基础 CTMC p^{base} 的情况下求解熵正则化优化问题 (1), 但在实践中, 大多数基础过程由掩码扩散模型 (Sahoo 等, 2024) 实例化。这些模型采用一个简化的 CTMC, 从完全掩码状态 $X_0 = (\mathbf{m}, \dots, \mathbf{m})$ 开始, 并具有基础速率:

$$\forall y \neq x, \quad u_t^{\text{base}}(y, x) := \lambda_t^{\text{base}}(x) Q^{\text{base}}(y|x), \quad Q^{\text{base}} \in \mathbb{Q}^{\text{mask}} \quad (15)$$

where $\lambda_t^{\text{base}}(x) \geq 0$ denotes the jump rate with $\lambda_0^{\text{base}}(x) = 0$ and $\lambda_1^{\text{base}}(x) \rightarrow \infty$, and $\mathbb{Q}^{\text{mask}}$ represents the class of the probabilities where $Q(y|x) \geq 0$ if and only if y unmasks exactly one token of x , *e.g.*, $y = (\dots, x^{n-1}, y^n, x^{n+1}, \dots)$ with $y^n \neq x^n = \mathbf{m}$; otherwise, $Q(y|x) = 0$.

对 (15) 式中基准速率 u^{base} 的简化带来了若干实用优势。最显著的是, 它大幅降低了 $Q(\cdot|x)$ 的建模复杂度³——从 $\mathcal{O}(M^N)$ 降至 $\mathcal{O}(MN)$ ——并支持基于大语言模型 (LLMs) 的现代参数化方法 (Vaswani et al., 2017)。此外, $Q^{\text{base}}(y|x)$ 与时间无关, 这意味着可以通过任意顺序去掩码实现更高效的采样过程 (Shi et al., 2024)。下文将证明, 所有这些优良特性均可迁移至最优速率 u^* :

命题 2.5 (掩码最优速率)。给定式 (15) 中的基础速率 u^{base} , 最优速率 u^* 满足

$$\forall y \neq x, \quad u_t^*(y, x) = \lambda_t^{\text{base}}(x) Q^*(y|x), \quad Q^* \in \mathbb{Q}^{\text{mask}} \quad (16)$$

实际上, 命题 2.5 表明, 我们可以在与 $\mathbb{Q}^{\text{mask}}$ 相同的模型类中参数化 $Q^\theta(y|x)$, 匹配 $Q^\theta(y|x)$ 与 $Q^{\text{base}}(y|x)$ 的 $\hat{a}(y, x)$, 然后以相同的任意顺序方式进行采样。

我们强调这些讨论, 它们引出了算法 1 中 DAM 的实用实现。

3 理论分析

我们通过从随机控制视角 (Bellman, 1966; Fleming & Rishel, 2012) 重新推导离散伴随 $\tilde{a}_t(y; \mathbf{X})$, 来突出额外的理论洞见, 这更贴近 AM 中的原始推导 (Domingo-Enrich et al., 2025)。所有证明见第 B 节。

3.1 最优速率的定点方程

我们首先引入一个新的数学对象 $J_t(x; u)$ ——在某个 CTMC 分布 $p^u(\mathbf{X})$ 下, 从状态 x 开始, 从时间 t 直到终止所累积的期望代价:

$$J_t(x; u) := \mathbb{E}_{\sim p^u(\mathbf{X} | X_t = x)} \left[\int_t^1 \sum_{y \neq X_\tau} \left(u_\tau^{\text{base}} - u_\tau + u_\tau \log \frac{u_\tau}{u_\tau^{\text{base}}} \right) (y, X_\tau) d\tau + g_1(X_1) \right] \quad (17)$$

³ 回顾 M 和 N 分别是离散状态空间 $\mathcal{X}$ 的词汇表大小和上下文长度。

由于式 (17) 中的积分对应于区间 $[t, 1]$ 上连续时间马尔可夫链 (CTMC) p^u 与 p^{base} 之间的 KL 散度 (详见附录 A)，因此代价函数 $J_t(x; u)$ 量化了式 (1) 中与优化 u_t 相关的目标。因此，最优速率满足 $u_t^* = \arg \min_u J_t(x; u)$ ，而值函数——作为最优代价函数泛函——可表示为 $V_t(x) = J_t(x; u^*)$ 。下面，我们通过一个不动点方程揭示 u 与 $J_t(x; u)$ 之间的这种紧密联系。

引理 3.1 (u^* 的不动点方程) 设 $\mathcal{F}$ 为所有满足速率条件的连续时间马尔可夫链速率空间之间的映射，即脚注 2。具体地，对于所有 $y \neq x$ ，我们有

$$\mathcal{F} : u_t(y, x) \mapsto u_t^{\text{base}}(y, x) e^{-J_t(y; u) + J_t(x; u)} \quad (18)$$

那么，映射 $\mathcal{F}$ 的唯一不动点即为最优速率 $u_t^*(y, x)$ ，i.e., $u^* = \mathcal{F}(u^*)$ 。

3.2 离散基本伴随

引理 3.1 的核心在于观察到最优速率 u^* 是关系 $u_t(y, x) = u_t^{\text{base}}(y, x) e^{-J_t(y; u) + J_t(x; u)}$ 的唯一不动点。因此，可以直接优化连续时间马尔可夫链 (CTMC) 的速率以拟合该关系。这正是基本伴随匹配 (Basic Adjoint Matching) (Domingo-Enrich 等人, 2025) 背后的动机，我们为其提供了适用于 CTMC 模型的离散类比：

定理 3.2 (离散基本伴随匹配)。对于任意布雷格曼散度 D_ϕ ，以下匹配目标的唯一临界点即为最优速率：

$$u_t^*(y, x) = \arg \min_u \mathbb{E}_{p^{\bar{u}}}(\mathbf{X} | X_t = x) [D_\phi(u_t(y, x), u_t^{\text{base}}(y, x) a_t(y; \mathbf{X}, \bar{u}))] \quad (19)$$

其中 $\bar{u} = \text{stopgrad}(u)$ ，且 $a_t(y; \mathbf{X}, u)$ 为满足后向常微分方程的离散基本伴随

$$\begin{aligned} -\frac{d}{dt} a_t(y; \mathbf{X}, u) = a_t(y; \mathbf{X}, u) & \left(\sum_{z \neq X_t} \left(u_t^{\text{base}} \left(1 - \frac{u_t}{\mathcal{F}(u_t)} \right) + u_t \log \frac{u_t}{\mathcal{F}(u_t)} \right) (z, X_t) \right. \\ & \left. - \sum_{z \neq y} \left(u_t^{\text{base}} - u_t + u_t \log \frac{u_t}{\mathcal{F}(u_t)} \right) (z, y) \right) \end{aligned} \quad (20)$$

$a_1(y; \mathbf{X}, u) = e^{-g(y) + g(X_1)}$ 其终端条件为。直观上，离散基本伴随 $a_t(y; \mathbf{X}, u)$ 在分布 p^u 下提供了 $e^{-J_t(y; u) + J_t(x; u)}$ 的无偏估计，当选择合适的匹配函数 D_ϕ 时，即可实例化映射 $\mathcal{F}(u) =$ 。换言之，(19) 中的优化可理解为引理 3.1 中不动点方程 $u^* = \mathcal{F}(u^*)$ 的变分形式。
 $\mathbb{E}_{p^u}[u_t^{\text{base}}(y, x) a_t(y; \mathbf{X}, u) | X_t = x]$ 。

然而在实践中， $a_t(y; \mathbf{X}, u)$ 在计算上是不可行的，因为 (20) 中的动力学涉及对映射 $\mathcal{F}(u)$ 的评估——因此由 (18) 可知也涉及 $J_t(\cdot; u)$ ——而这正是我们希望估计的对象。这与连续域中的基本伴随 (Domingo-Enrich 等人, 2025, 方程 30) 形成对比，后者尽管计算开销大，但仍然可行。尽管如此，观察到 (20) 中所有不可行项在 $u := u^*$ 处消失，最优分布 $a_t(y; \mathbf{X}, u^*)$ 上的离散基本伴随变得可行，并且如下所示，恢复了离散伴随 $\tilde{a}_t(y; \mathbf{X})$ 。

推论 3.3 (离散伴随)。在 $u := u^*$ 处，离散基本伴随的动力学简化为

$$-\frac{d}{dt} a_t(y; \mathbf{X}, u^*) = \sum_z u_t^{\text{base}}(z, y) a_t(z; \mathbf{X}, u^*), \quad a_1(y; \mathbf{X}, u^*) = e^{-g(y) + g(X_1)} \quad (21)$$

这与 (8) 中离散伴随的动力学一致。也就是说，由常微分方程解的唯一性，我们有 $a_t(y; \mathbf{X}, u^*) = \tilde{a}_t(y; \mathbf{X})$ 。

最后，通过设置 $\bar{u} := u^*$ ，可以很容易地从 (19) 中恢复 (10) 中的目标。




图 1 合成示例。我们比较了由基础模型 p_1^{base} 、真实最优模型 p_1^* 以及四种方法（包括使用 (12) 中离散伴随而非 (13) 训练的 DAM 消融）生成的 X_1 的经验分布。DAM 在视觉上与 p_1^* 最为接近。




图 2 在 Pinwheel 上收敛到最优 p^* 。 $D_{\text{KL}}(p_t^* || p_t^u)$ 在 (22) 中描述的每次跳跃处的收敛情况，其中与其他方法相比，DAM 表现出稳定的收敛（左图和中图）。与 (12) 相比，我们在 (13) 中改进的离散伴随表现出更低的偏差和方差（右图）。

4 实验

我们在两个基准上验证了 DAM 的性能：具有解析可求最优速率的二维合成示例 u^* ，以及针对基于扩散的大语言模型的高维推理数据集的微调。在所有情况下，我们考虑基于掩码的 CTMC 模型。更多细节见第 C 节。

4.1 合成示例

设置我们在离散状态空间 $\mathcal{X}^{\text{discrete}} = \{m, 1, \dots, 91\}^2$ 上考虑两个合成示例，其中每个样本 $x \in \mathcal{X}$ 表示 91×91 网格上的二维索引，因此边缘分布 $p(X_t)$ 可以可视化二维直方图。对于基于掩码的 CTMC 模型，生成过程简化为从掩码状态 $X_0 = (m, m)$ 出发的两次不同跳跃。

$$(m, m) \xrightarrow{\text{first jump}} (x_i, m) \text{ or } (m, x_j) \xrightarrow{\text{second jump}} (x_i, x_j), \quad x_i, x_j \in \{1, \dots, 91\} \quad (22)$$

为了模拟微调设置，我们设计了一个终端损失 $g(x)$ ，使得最优分布 $p_1^*(X_1) \propto p_1^{\text{base}}(X_1)e^{-g(X_1)}$ 对某些区域进行上加权或下加权，如图 1 所示。值得注意的是，这些问题的维度相对较低，使得我们可以精确计算最优速率 u^* 及其诱导的最优分布 p^* ，从而能够比较我们的 DAM 与其他基线方法（具体为 D1 (Zhao 等人, 2025) 和 SVDD (Li 等人, 2024)）之间的收敛性。

结果 图 1 展示了合成示例的结果，我们比较了由我们的 DAM、其消融版本以及其他基线方法生成的样本 $X_1 \sim p(X_1)$ 的二维直方图。在两个示例（即棋盘格和风车）上，DAM 在视觉上最接近最优分布，证明了其在求解 (1) 中的熵正则化优化问题方面的有效性。图 2 进一步从定量上证实了这一点，其中 DAM 对于 (22) 中描述的两个跳跃均稳定收敛到最优分布。相比之下，其他微调方法（如 D1 和 SVDD）往往趋于平台期，未能收敛到 p^* ，这可能是由于训练过程中施加了严重的近似。值得注意的是，虽然 (12) 和 (13) 都提供了理论上合理的

表 1 数学推理任务上的性能。我们使用不同方法对预训练的 LLaDA-8B-Instruct 模型进行微调，生成序列长度分别为 128 和 256。在几乎所有设置下，DAM 在测试时准确率（Accu，%）和 (23) 中的子奖励 r 方面均持续优于 D1。最佳结果已高亮显示。

Method	GSM8K			MATH500			Countdown			Sudoku	
	Accu.	r_{correct}	r_{format}	Accu.	r_{correct}	r_{format}	Accu.	r_{correct}	r_{format}	Accu.	r
Sequence Length 128											
LLaDA-8B-Instruct	68.6	1.37	1.46	28.8	0.58	0.72	34.8	0.31	0.10	11.5	0.11
with D1 (Zhao et al., 2025)	75.6	1.51	1.74	31.2	0.62	0.73	43.8	0.39	0.10	23.8	0.24
with DAM (Ours)	75.7	1.52	1.86	32.6	0.65	0.73	60.2	0.54	0.10	89.2	0.89
Sequence Length 256											
LLaDA-8B-Instruct	76.8	1.54	1.22	30.8	0.62	0.66	19.5	0.30	0.10	6.4	0.07
with D1 (Zhao et al., 2025) [†]	79.8	1.60	1.63	37.2	0.74	0.70	31.3	0.30	0.10	12.9	0.13
with DAM (Ours)	79.9	1.60	1.82	36.4	0.73	0.92	55.5	0.499	0.10	88.1	0.88

表 2 数学推理任务的测试时泛化。对于表 1 中的每个微调模型，我们报告了序列长度为 128、256 和 512 时的测试时准确率（%）。DAM 实现了与 D1 相当或更高的准确率。

		Method/Eval Seq Len	GSM8K			MATH500			Countdown			Sudoku		
			128	256	512	128	256	512	128	256	512	128	256	512
Train Seq Len	128	LLaDA-8B-Instruct	68.6	76.8	79.7	28.8	30.8	36.4	34.8	19.5	20.3	11.5	6.4	6.0
		with D1 (Zhao et al., 2025)	75.6	80.6	82.1	31.2	34.2	34.0	43.8	33.6	28.1	23.8	16.9	10.0
		with DAM (Ours)	75.7	77.7	77.0	32.6	30.4	37.2	60.2	59.8	59.0	89.2	88.6	84.9
	256	with D1 (Zhao et al., 2025) [†]	72.6	79.8	81.9	33.2	37.2	39.2	33.2	31.3	37.1	18.4	12.9	11.0
		with DAM (Ours)	74.5	79.9	80.0	30.8	36.4	36.8	58.6	55.5	49.6	87.0	88.1	87.1

离散伴随的估计量，后者表现出显著更低的偏差和方差。因此，本文采用 (13) 用于所有剩余任务。

4.2 数学推理任务

设置 本文考虑四个标准的数学推理任务：GSM8K (Cobbe 等, 2021)，一个包含 8.5K 道小学数学题的数据集；MATH500 (Lightman 等, 2023)，包含 500 道高中数学竞赛题；Countdown，一个在给定三个数字集合上的组合算术游戏；以及 4x4 数独谜题，要求用数字填充网格以满足约束。由于 D1 (Zhao 等, 2025) 代表了在这些推理任务上微调掩码 CTMC 模型的当前最先进方法，本文采用其实验设置。具体而言，本文使用 LLaDA-8B-Instruct (Nie 等, 2025) 作为基础 CTMC 模型，不进行监督微调，并考虑终端损失 $g(\cdot)$ ：

$$g(x) := -r(x) \quad \text{where } r(x) = r_{\text{correct}}(x) + r_{\text{format}}(x) \quad (23)$$

包含两个子奖励函数， r_{correct} 和 r_{format} ，分别奖励生成样本的正确性和格式。遵循 D1，本文使用零样本提示评估最终检查点，并采用 Nie 等 (2025) 的相同解码方案。对于每种方法，本文在每个任务上微调一个单独的 CTMC 模型，生成长度为 128 和 256，并在生成长度为 128、256 和 512 时评估每个结果模型。更多细节见第 C.2 节。

结果 表 1 和表 2 总结了推理任务上的结果。在几乎所有设置中，除了序列长度为 256 的 MATH500 外，DAM 达到了与 D1 相当或更高的测试时准确率，并且在每个子奖励上得分更高，展示了其在微调中等规模基于扩散的大语言模型方面的潜力。虽然 DAM 在 Countdown 和数独上明显优于 D1，但性能差距在

[†] 值取自 (Zhao 等, 2025)。

表 3 在相同未见提示下，基础模型和两个微调模型在 GSM8K（上）和 Countdown（下）上生成的样本。正确和错误的答案已着色。更多样本见第 C.3 节。

提示： 肯尼正在出售他的宝可梦卡牌，以购买一张游乐园门票，门票价格为 100 美元。他有一批卡牌，计划以每张 1.5 美元的价格出售。他保留了其中的 1/3，并带着 50 美元的零花钱去了游乐园。他最初有多少张卡牌？ 答案： 150		
Response: LLaDA-8B-Instruct	LLaDA-8B-Instruct w/ DAM	LLaDA-8B-Instruct w/ D1
<推理> 肯尼保留了 1/3 的卡牌，因此他出售了 2/3。他以每张 1.5 美元的价格出售 2/3 的卡牌，因此他通过出售赚得 $(2/3) * \\$1.5 = \\10。他还有 50 美元的零花钱，因此他总共有 $\\$10 + \\$50 = \\$60$。由于门票价格为 100 美元，他最初有 $60/2 = 30$ 张卡牌。 </推理> <答案> 30 </答案>	<reasoning> Kenny needs to raise $\\$100 + \\$50 = \\$150$. He keeps 1/3 of his cards, so he sells 2/3 of them. Each card sells for \$1.5, so he sells $\\$150 / \\$1.5 = 100$ cards. Therefore, he started with $100 / (2/3) = 150$ cards.</reasoning> <answer> 150 </answer>	<reasoning> Kenny needs $\\$100 - \\$50 = \\$50$. At \$1.5 per card, he needs to sell $\\$50 / \\$1.5 = 33$ cards. Since he keeps 1/3 of them, he sells $1/3 * 33 = 11$ cards to make the necessary amount.</reasoning> <answer> 33 </answer>
Prompt 仅使用数字 [67, 39, 70]，创建一个算术表达式，使其结果恰好为 98。你必须使用列表中的所有数字，且每个数字只能使用一次。你可以根据需要运用 +、-、* 和 / 运算。答案： 70 - 39 + 67		
Response: LLaDA-8B-Instruct	LLaDA-8B-Instruct w/ DAM	LLaDA-8B-Instruct w/ D1
<推理> 为了使用数字 [67, 39, 70] 创建一个结果为 98 的算术表达式，我们需要找到正确的运算组合，并在可能的情况下使用括号。鉴于问题的约束条件，我们可以从考虑数字的性质和可用运算入手。</推理> <答案> 67*70 - 39 </答案>	<reasoning> To create an arithmetic expression that evaluates to exactly 98 using the numbers [67, 39, 70], we need to find a combination of the operations +, -, *, and / that results in 98.</reasoning> <answer> 70 - 39 + 67 </answer>	<reasoning> To create an arithmetic expression that evaluates to 98 using the numbers [67, 39, 70], we need to consider the operations of addition, subtraction, multiplication, and division. We can start by trying to combine the numbers in a way that leads us to 98. One possible approach is to use the numbers and their operations to a close that sums up to 98. We can also try using the and operations to get to 98.</reasoning> <answer> 67+39-770/70 </answer>

GSM8K 和 MATH500，这表明 D1 所做的假设对于这些任务可能相当有效。将此类近似方法适配到 DAM——后者专为更一般的问题而设计——仍是一个有前景的未来方向。最后，表 3 比较了不同模型在相同未见提示下生成的样本，其中经 DAM 微调的模型（中间列）成功推理并生成了正确答案。总体而言，这些结果凸显了 DAM 在求解熵正则化奖励优化问题上的有效性，并且可能对更广泛的 CTMC 模型类别有益，这可能有利于先进的 CTMC 模型（Havasi 等人，2025）。

5 相关工作

熵正则化奖励优化。 DDPO（Black 等，2023）和 DPoK（Fan 等，2023a）将离散时间扩散模型中的推理视为马尔可夫决策过程，并对（1）应用策略梯度方法。DRaFT（Clark 等，2023）和 AlignProp（Prabhudesai 等，2024）利用重参数化在离散时间中进行直接反向传播。伴随匹配（AM，Domingo-Enrich 等，2025）和 ELEGANT

(Uehara 等, 2024b) 考虑连续时间扩散模型的熵正则化优化, 并采用路径级 KL 正则化。与 AM 不同, ELEGANT 同时学习改变的漂移项和改变的初始噪声分布。

离散模型微调。离散扩散模型微调在 (Uehara 等, 2024a) 中有所综述, 尽管是在离散时间设置下。包括 D1 (Zhao 等, 2025)、DiffuCoder (Gong 等, 2025)、DRAKES (Wang 等, 2025) 和 SEPO (Zekri & Boullé, 2025) 在内的多种方法采用策略梯度方法 (Shao 等, 2024; Liu 等, 2025b), 但由于似然不可解或奖励不可微, 许多方法需要近似。相比之下, 基于价值的方法 SVDD (Li 等, 2024) 通过模型轨迹上的奖励回归估计价值函数, 而 Q^π (Zhou 等, 2025) 学习轨迹上的参数化奖励分布。我们的 DAM 不直接估计价值函数, 而是利用指数价值差的估计量。

6 结论与局限性

本文提出了离散伴随匹配 (DAM), 一种基于伴随方法的离散生成模型微调方法, 该模型由连续时间马尔可夫链 (CTMC) 表述。DAM 通过严格的统计框架推导得出, 可轻松应用于其他模型类别。我们证明了 DAM 在解决各种熵正则化优化问题中的有效性。将 DAM 应用于非掩码 CTMC 是一个有趣的未来工作方向。

作者贡献与致谢

该项目由 Guan 发起并领导。Guan 是主论文的主要作者, Oswin 协助撰写第 4 节。Guan 和 Oswin 共同发展理论、共同设计算法 (Ricky 和 Brian 亦有贡献), 并共同撰写附录。所有实验由 Oswin 完成。Chuchu 在项目探索初期提供了宝贵的讨论。作者感谢 Jaemoo Choi 的有益讨论和意见。

参考文献

- Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altenschmidt, Sam Altman, Shyamal Anadkat, et al. Gpt-4 technical report. *arXiv preprint arXiv:2303.08774*, 2023.
- William J Anderson. *Continuous-time Markov chains: An applications-oriented approach*. Springer Science & Business Media, 2012.
- Jacob Austin, Daniel D Johnson, Jonathan Ho, Daniel Tarlow, and Rianne Van Den Berg. Structured denoising diffusion models in discrete state-spaces. *Advances in neural information processing systems*, 34:17981–17993, 2021.
- Jinze Bai, Shuai Bai, Yunfei Chu, Zeyu Cui, Kai Dang, Xiaodong Deng, Yang Fan, Wenbin Ge, Yu Han, Fei Huang, et al. Qwen technical report. *arXiv preprint arXiv:2309.16609*, 2023.
- Richard Bellman. The theory of dynamic programming. Technical report, Rand corp santa monica ca, 1954.
- Richard Bellman. Dynamic programming. *science*, 153(3731):34–37, 1966.
- Kevin Black, Michael Janner, Yilun Du, Ilya Kostrikov, and Sergey Levine. Training diffusion models with reinforcement learning. *arXiv preprint arXiv:2305.13301*, 2023.
- David M Blei, Alp Kucukelbir, and Jon D McAuliffe. Variational inference: A review for statisticians. *Journal of the American statistical Association*, 112(518):859–877, 2017.
- Andrew Campbell, Joe Benton, Valentin De Bortoli, Thomas Rainforth, George Deligiannidis, and Arnaud Doucet. A continuous time framework for discrete denoising models. *Advances in Neural Information Processing Systems*, 35: 28266–28279, 2022.
- Mark Chen, Jerry Tworek, Heewoo Jun, Qiming Yuan, Henrique Ponde De Oliveira Pinto, Jared Kaplan, Harri Edwards, Yuri Burda, Nicholas Joseph, Greg Brockman, et al. Evaluating large language models trained on code. *arXiv preprint arXiv:2107.03374*, 2021.

- Kevin Clark, Paul Vicol, Kevin Swersky, and David J Fleet. Directly fine-tuning diffusion models on differentiable rewards. *arXiv preprint arXiv:2309.17400*, 2023.
- Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser, Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, et al. Training verifiers to solve math word problems. *arXiv preprint arXiv:2110.14168*, 2021.
- Carles Domingo-Enrich, Michal Drozdal, Brian Karrer, and Ricky T. Q. Chen. Adjoint Matching: Fine-tuning flow and diffusion generative models with memoryless stochastic optimal control. In *International Conference on Learning Representations (ICLR)*, 2025.
- Ying Fan, Olivia Watkins, Yuqing Du, Hao Liu, Moonkyung Ryu, Craig Boutilier, Pieter Abbeel, Mohammad Ghavamzadeh, Kangwook Lee, and Kimin Lee. Dpok: Reinforcement learning for fine-tuning text-to-image diffusion models. *Advances in Neural Information Processing Systems*, 36:79858–79885, 2023a.
- Ying Fan, Olivia Watkins, Yuqing Du, Hao Liu, Moonkyung Ryu, Craig Boutilier, Pieter Abbeel, Mohammad Ghavamzadeh, Kangwook Lee, and Kimin Lee. Reinforcement learning for fine-tuning text-to-image diffusion models. In *Thirty-seventh Conference on Neural Information Processing Systems (NeurIPS) 2023*. Neural Information Processing Systems Foundation, 2023b.
- Wendell H Fleming and Raymond W Rishel. *Deterministic and stochastic optimal control*, volume 1. Springer Science & Business Media, 2012.
- Shansan Gong, Ruixiang Zhang, Huangjie Zheng, Jiatao Gu, Navdeep Jaitly, Lingpeng Kong, and Yizhe Zhang. Diffu-coder: Understanding and improving masked diffusion models for code generation. *arXiv preprint arXiv:2506.20639*, 2025.
- Marton Havasi, Brian Karrer, Itai Gat, and Ricky TQ Chen. Edit flows: Flow matching with edit operations. *arXiv preprint arXiv:2506.09018*, 2025.
- Aaron Havens, Benjamin Kurt Miller, Bing Yan, Carles Domingo-Enrich, Anuroop Sriram, Brandon Wood, Daniel Levine, Bin Hu, Brandon Amos, Brian Karrer, Xiang Fu, Guan-Hong Liu, and Ricky T. Q. Chen. Adjoint Sampling: Highly scalable diffusion samplers via Adjoint Matching. In *International Conference on Machine Learning (ICML)*, 2025.
- Peter Holderrieth, Marton Havasi, Jason Yim, Neta Shaul, Itai Gat, Tommi Jaakkola, Brian Karrer, Ricky TQ Chen, and Yaron Lipman. Generator matching: Generative modeling with arbitrary markov processes. *arXiv preprint arXiv:2410.20587*, 2024.
- Edward J Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, Weizhu Chen, et al. Lora: Low-rank adaptation of large language models. *ICLR*, 1(2):3, 2022.
- Kiyosi Itô. *On stochastic differential equations*, volume 4. American Mathematical Soc., 1951.
- Rafał Karczewski, Markus Heinonen, and Vikas Garg. Diffusion models as cartoonists: The curious case of high density regions. *arXiv preprint arXiv:2411.01293*, 2024.
- Enkelejd Kasneci, Kathrin Sekler, Stefan Küchemann, Maria Bannert, Daryna Dementieva, Frank Fischer, Urs Gasser, Georg Groh, Stephan Günnemann, Eyke Hüllermeier, et al. Chatgpt for good? on opportunities and challenges of large language models for education. *Learning and individual differences*, 103:102274, 2023.
- Jun Hyeong Kim, Seonghwan Kim, Seokhyun Moon, Hyeongwoo Kim, Jeheon Woo, and Woo Youn Kim. Discrete Diffusion Schrödinger Bridge Matching for Graph Transformation, October 2024. URL <http://arxiv.org/abs/2410.01500>. arXiv:2410.01500 [cs].
- Diederik P Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *International Conference on Learning Representations (ICLR)*, 2015.
- Sergey Levine. Reinforcement learning and control as probabilistic inference: Tutorial and review. *arXiv preprint arXiv:1805.00909*, 2018.
- Xiner Li, Yulai Zhao, Chenyu Wang, Gabriele Scalia, Gokcen Eraslan, Surag Nair, Tommaso Biancalani, Shuiwang Ji, Aviv Regev, Sergey Levine, and Masatoshi Uehara. Derivative-Free Guidance in Continuous and Discrete Diffusion Models with Soft Value-Based Decoding, October 2024. URL <http://arxiv.org/abs/2408.08252>. arXiv:2408.08252 [cs].

- Hunter Lightman, Vineet Kosaraju, Yuri Burda, Harrison Edwards, Bowen Baker, Teddy Lee, Jan Leike, John Schulman, Ilya Sutskever, and Karl Cobbe. Let’s verify step by step. In *The Twelfth International Conference on Learning Representations*, 2023.
- Yaron Lipman, Marton Havasi, Peter Holderrieth, Neta Shaul, Matt Le, Brian Karrer, Ricky TQ Chen, David Lopez-Paz, Heli Ben-Hamu, and Itai Gat. Flow matching guide and code. *arXiv preprint arXiv:2412.06264*, 2024.
- Guan-Hong Liu, Tianrong Chen, Oswin So, and Evangelos A Theodorou. Deep generalized Schrödinger bridge. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.
- Guan-Hong Liu, Jaemoo Choi, Yongxin Chen, Benjamin Kurt Miller, and Ricky TQ Chen. Adjoint Schrödinger Bridge Sampler. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2025a.
- Zichen Liu, Changyu Chen, Wenjun Li, Penghui Qi, Tianyu Pang, Chao Du, Wee Sun Lee, and Min Lin. Understanding r1-zero-like training: A critical perspective, 2025b. URL <https://arxiv.org/abs/2503.20783>.
- Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations (ICLR)*, 2019.
- Aaron Lou, Chenlin Meng, and Stefano Ermon. Discrete diffusion modeling by estimating the ratios of the data distribution. *arXiv preprint arXiv:2310.16834*, 2023.
- Radford M Neal. Annealed importance sampling. *Statistics and computing*, 11:125–139, 2001.
- Shen Nie, Fengqi Zhu, Zebin You, Xiaolu Zhang, Jingyang Ou, Jun Hu, Jun Zhou, Yankai Lin, Ji-Rong Wen, and Chongxuan Li. Large language diffusion models. *arXiv preprint arXiv:2502.09992*, 2025.
- Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, et al. Training language models to follow instructions with human feedback. *Advances in neural information processing systems*, 35:27730–27744, 2022.
- Jiayi Pan, Junjie Zhang, Xingyao Wang, Lifan Yuan, Hao Peng, and Alane Suhr. Tinyzero. <https://github.com/Jiayi-Pan/TinyZero>, 2025. Accessed: 2025-01-24.
- Le-Tuyet-Nhi Pham, Dario Shariatian, Antonio Ocello, Giovanni Conforti, and Alain Olivier Durmus. Discrete Markov probabilistic models: An improved discrete score-based framework with sharp convergence bounds under minimal assumptions. In Aarti Singh, Maryam Fazel, Daniel Hsu, Simon Lacoste-Julien, Felix Berkenkamp, Tegan Maharaj, Kiri Wagstaff, and Jerry Zhu (eds.), *Proceedings of the 42nd International Conference on Machine Learning*, volume 267 of *Proceedings of Machine Learning Research*, pp. 49195–49258. PMLR, 13–19 Jul 2025. URL <https://proceedings.mlr.press/v267/pham25a.html>.
- Alexey Piunovskiy and Yi Zhang. Continuous-time markov decision processes. *Probability Theory and Stochastic Modelling*, 2020.
- Mihir Prabhudesai, Anirudh Goyal, Deepak Pathak, and Katerina Fragkiadaki. Aligning text-to-image diffusion models with reward backpropagation, 2024. URL <https://arxiv.org/abs/2310.03739>.
- L Chris G Rogers and David Williams. *Diffusions, Markov processes and martingales: Volume 2, Itô calculus*, volume 2. Cambridge university press, 2000.
- Subham Sahoo, Marianne Arriola, Yair Schiff, Aaron Gokaslan, Edgar Marroquin, Justin Chiu, Alexander Rush, and Volodymyr Kuleshov. Simple and effective masked diffusion language models. *Advances in Neural Information Processing Systems*, 37:130136–130184, 2024.
- Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, YK Li, Yang Wu, et al. Deepseekmath: Pushing the limits of mathematical reasoning in open language models. *arXiv preprint arXiv:2402.03300*, 2024.
- Neta Shaul, Itai Gat, Marton Havasi, Daniel Severo, Anuroop Sriram, Peter Holderrieth, Brian Karrer, Yaron Lipman, and Ricky T. Q. Chen. Flow Matching with General Discrete Paths: A Kinetic-Optimal Perspective, December 2024. URL <http://arxiv.org/abs/2412.03487>. arXiv:2412.03487 [cs].
- Jiaxin Shi, Kehang Han, Zhe Wang, Arnaud Doucet, and Michalis Titsias. Simplified and generalized masked diffusion for discrete data. *Advances in neural information processing systems*, 37:103131–103167, 2024.
- Yuyang Shi, Valentin De Bortoli, Andrew Campbell, and Arnaud Doucet. Diffusion Schrödinger bridge matching. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.

- Marta Skreta, Lazar Atanackovic, Avishek Joey Bose, Alexander Tong, and Kirill Neklyudov. The superposition of diffusion models using the it^o density estimator. *arXiv preprint arXiv:2412.17762*, 2024.
- Gemini Team, Rohan Anil, Sebastian Borgeaud, Jean-Baptiste Alayrac, Jiahui Yu, Radu Soricut, Johan Schalkwyk, Andrew M Dai, Anja Hauth, Katie Millican, et al. Gemini: a family of highly capable multimodal models. *arXiv preprint arXiv:2312.11805*, 2023.
- Evangelos Theodorou, Jonas Buchli, and Stefan Schaal. A generalized path integral control approach to reinforcement learning. *Journal of Machine Learning Research (JMLR)*, 11(Nov):3137–3181, 2010.
- Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar, et al. Llama: Open and efficient foundation language models. *arXiv preprint arXiv:2302.13971*, 2023.
- Masatoshi Uehara, Yulai Zhao, Tommaso Biancalani, and Sergey Levine. Understanding reinforcement learning-based fine-tuning of diffusion models: A tutorial and review. *arXiv preprint arXiv:2407.13734*, 2024a.
- Masatoshi Uehara, Yulai Zhao, Kevin Black, Ehsan Hajiramezanali, Gabriele Scalia, Nathaniel Lee Diamant, Alex M Tseng, Tommaso Biancalani, and Sergey Levine. Fine-tuning of continuous-time diffusion models as entropy-regularized control. *arXiv preprint arXiv:2402.15194*, 2024b.
- Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in neural information processing systems*, pp. 5998–6008, 2017.
- Leandro von Werra, Younes Belkada, Lewis Tunstall, Edward Beeching, Tristan Thrush, Nathan Lambert, Shengyi Huang, Kashif Rasul, and Quentin Gallouédec. Trl: Transformer reinforcement learning. <https://github.com/huggingface/trl>, 2020.
- Chenyu Wang, Masatoshi Uehara, Yichun He, Amy Wang, Avantika Lal, Tommi Jaakkola, Sergey Levine, Aviv Regev, Tommaso Biancalani, et al. Fine-tuning discrete diffusion models via reward optimization with applications to dna and protein design. In *International Conference on Learning Representations (ICLR)*, 2025.
- Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Fei Xia, Ed Chi, Quoc V Le, Denny Zhou, et al. Chain-of-thought prompting elicits reasoning in large language models. *Advances in neural information processing systems*, 35:24824–24837, 2022.
- Oussama Zekri and Nicolas Boullé. Fine-tuning discrete diffusion models with policy gradient methods, 2025. URL <https://arxiv.org/abs/2502.01384>.
- Siyan Zhao, Devaansh Gupta, Qinqing Zheng, and Aditya Grover. d1: Scaling reasoning in diffusion large language models via reinforcement learning. *arXiv preprint arXiv:2504.12216*, 2025.
- Jin Peng Zhou, Kaiwen Wang, Jonathan Chang, Zhaolin Gao, Nathan Kallus, Kilian Q. Weinberger, Kianté Brantley, and Wen Sun. q#: Provably optimal distributional rl for llm post-training, 2025. URL <https://arxiv.org/abs/2502.20548>.
- Yuchen Zhu, Wei Guo, Jaemoo Choi, Guan-Horng Liu, Yongxin Chen, and Molei Tao. Mdns: Masked diffusion neural sampler via stochastic optimal control. *arXiv preprint arXiv:2508.10684*, 2025.
- Daniel M Ziegler, Nisan Stiennon, Jeffrey Wu, Tom B Brown, Alec Radford, Dario Amodei, Paul Christiano, and Geoffrey Irving. Fine-tuning language models from human preferences. *arXiv preprint arXiv:1909.08593*, 2019.

附录 A 补充讨论与推导

A.1 熵正则化优化

本文进一步阐明 (24) 中的无记忆条件如何导出 (2) 中最优解的解析表达式。

$$p^{\text{base}}(X_1|X_0) \stackrel{\text{memoryless}}{:=} p^{\text{base}}(X_1) \quad (24)$$

首先, 注意到 (1) 中的熵正则化目标可重新表述为:

$$\begin{aligned} & D_{\text{KL}}(p^u(\mathbf{X}) || p^{\text{base}}(\mathbf{X})) + \mathbb{E}_{p(\mathbf{X})} [g(X_1)] \\ &= D_{\text{KL}}(p(X_0) || p^{\text{base}}(X_0)) + \mathbb{E}_{p(X_0)} \left[D_{\text{KL}}(p(\mathbf{X}|X_0) || p^{\text{base}}(\mathbf{X}|X_0)) + \mathbb{E}_{p(\mathbf{X}|X_0)} [g(X_1)] \right] \\ &= D_{\text{KL}}(p(X_0) || p^{\text{base}}(X_0)) + \mathbb{E}_{p(X_0)} \left[D_{\text{KL}}(p(\mathbf{X}|X_0) || p^{\text{base}}(\mathbf{X}|X_0) e^{-g(X_1)}) \right] \end{aligned} \quad (25)$$

Minimizing (25) w.r.t. p yields

$$p^*(\mathbf{X}|X_0) = \frac{1}{Z(X_0)} p^{\text{base}}(\mathbf{X}|X_0) e^{-g(X_1)}, \quad p^*(X_0) = p^{\text{base}}(X_0) \quad (26)$$

其中 $Z(X_0)$ 是由下式定义的归一化项

$$Z(X_0) := \int p^{\text{base}}(\mathbf{X}|X_0) e^{-g(X_1)} d\mathbf{X} = \int p^{\text{base}}(X_1|X_0) e^{-g(X_1)} dX_1 \quad (27)$$

即, 最优解 $p^*(\mathbf{X}) = p^*(\mathbf{X}|X_0)p^*(X_0)$ 具有如下形式

$$p^*(\mathbf{X}) = p^{\text{base}}(\mathbf{X}) e^{-g(X_1) - \log Z(X_0)} \quad (28)$$

在 (24) 中的无记忆条件下, 归一化项变为常数 $Z(X_0) = Z$, 因此 (28) 简化为 (2) 中给出的解析最优解。

A.2 连续时间马尔可夫链 (Continuous-time Markov Chain, CTMC)

解释转移速率 回顾 (4), 连续时间马尔可夫链过程完全由其转移速率刻画:

$$u_t(y, x) := \lim_{\Delta t \rightarrow 0} \frac{p(X_{t+\Delta t} = y | X_t = x) - \delta_x(y)}{\Delta t} \quad (29)$$

其构造满足速率条件:

$$u_t(y, x) \geq 0 \text{ 对所有 } y \neq x, \text{ 且 } u_t(x, x) = - \sum_{y \neq x} u_t(y, x) \quad (30)$$

为方便起见, 进一步从转移速率 $u_t(y, x)$ 定义两个数学对象, 即跳跃速率 $\lambda_t(x)$ 和跳跃目标概率 $Q_t(y|x)$:

$$\lambda_t(x) := \sum_{y \neq x} u_t(y, x) = -u_t(x, x), \quad Q_t(y|x) := \frac{u_t(y, x)}{\lambda_t(x)} \quad \forall y \neq x \quad (31)$$

Intuitively, $\lambda_t(x) = \lim_{\Delta t \rightarrow 0} \frac{\Pr[\text{jump occurs at } t+\Delta t | X_t=x]}{\Delta t}$ 其中

$Q_t(y|x)$ 是从 x 跳到 $y \neq x$ 的概率。注意 $\sum_{y \neq x} Q_t(y|x) = 1$ 在构造上已归一化。这引出以下解释:

$$u_t(y, x) = \underbrace{\lambda_t(x)}_{\text{how often to jump}} \underbrace{Q_t(y|x)}_{\text{where to jump}} \quad \forall y \neq x, \quad u_t(x, x) = -\lambda_t(x) \quad (32)$$

速率条件 (30) 产生一个有用的结果，将在后续推导中发挥作用：

引理 A.1. 给定满足 (30) 的有效转移速率 $u_t(y, x)$ ，对所有 $f(x)$ 成立

$$\sum_y u_t(y, x) f(y) = \sum_{y \neq x} u_t(y, x) (f(y) - f(x)) \quad (33)$$

证明。

$$\sum_y u_t(y, x) f(y) = \sum_{y \neq x} u_t(y, x) f(y) + u_t(x, x) f(x) = \sum_{y \neq x} u_t(y, x) f(y) - \sum_{y \neq x} u_t(y, x) f(x)$$

□

连续时间马尔可夫链 (Continuous Time Markov Chain, CTMC) 的柯尔莫哥洛夫方程 刻画 CTMC 过程概率演化的两个最重要的方程分别是柯尔莫哥洛夫前向方程 (Kolmogorov Forward Equation, KFE)，它描述了对任意 $t > s$ 条件分布的前向动态，

$$\partial_t p_{t|s}(y|x) = \sum_{z \in \mathcal{X}} u_t(y, z) p_{t|s}(z|x) \quad (34)$$

以及柯尔莫哥洛夫后向方程 (Kolmogorov Backward Equation, KBE)，该方程描述了后向动力学：

$$-\partial_s p_{t|s}(y|x) = \sum_{z \in \mathcal{X}} p_{t|s}(y|z) u_s(z, x) \quad (35)$$

注意，通过对 KFE (34) 中的 $p_s(x)$ 取期望，可以恢复连续性方程——即边际分布的动力学：

$$\partial_t p_t(y) = \partial_t \left(\int p_{t|s}(y|x) p_s(x) dx \right) = \sum_z u_t(y, z) \left(\int p_{t|s}(z|x) p_s(x) dx \right) = \sum_z u_t(y, z) p_t(z)$$

连续时间马尔可夫链 (Continuous Time Markov Chain, CTMC) 之间的 KL 散度 给定两个具有相同初始分布的 CTMC 过程 $p^u(\mathbf{X})$ 和 $p^{\text{base}}(\mathbf{X})$ ，它们的 KL 散度可以用其转移速率表示 (Kim 等, 2024; Shaul 等, 2024)：

$$D_{\text{KL}}(p^u(\mathbf{X}) || p^{\text{base}}(\mathbf{X})) = \int_0^1 \mathbb{E}_{p_t^u(X_t)} \left[\sum_{y \neq X_t} \left(u_t^{\text{base}} - u_t + u_t \log \frac{u_t}{u_t^{\text{base}}} \right) (y, X_t) \right] dt \quad (36)$$

尽管该表达式形式紧凑，但仍难以解释。以下引理通过将 (36) 分解为两个部分，提供了另一种视角，类似于 (32)：一部分对应于决定跳跃频率，另一部分对应于选择跳跃目标。

引理 A.2 (CTMC 的 KL 散度解释)。设 p^u 和 p^{base} 为两个 CTMC 分布，分别由其转移速率 $u_t(y, x)$ 和 $u_t^{\text{base}}(y, x)$ 刻画：

$$\forall y \neq x, \quad u_t(y, x) = \lambda_t^u(x) Q_t^u(y|x), \quad u_t^{\text{base}}(y, x) = \lambda_t^{\text{base}}(x) Q_t^{\text{base}}(y|x)$$

其中 $\lambda_t(x)$ 和 $Q_t(y|x)$ 分别是它们的跳跃速率和跳跃目标概率，参见 (31)。那么，(36) 中的 KL 散度可以分解为

$$D_{\text{KL}}(p^u(\mathbf{X}) || p^{\text{base}}(\mathbf{X})) = \int_0^1 \mathbb{E}_{p_t^u(X_t)} [\lambda_t^u (D_{\text{KL}}(\lambda_t^u || \lambda_t^{\text{base}}) + D_{\text{KL}}(Q_t^u || Q_t^{\text{base}}))] dt \quad (37)$$

where $D_{\text{KL}}(\lambda_t^u || \lambda_t^{\text{base}})$ and $D_{\text{KL}}(Q_t^u || Q_t^{\text{base}})$ are, respectively, standard KL divergences for exponential and discrete distributions:

$$D_{\text{KL}}(\lambda_t^u(x) || \lambda_t^{\text{base}}(x)) = \log \frac{\lambda_t^u(x)}{\lambda_t^{\text{base}}(x)} + \frac{\lambda_t^{\text{base}}(x)}{\lambda_t^u(x)} - 1,$$

$$D_{\text{KL}}(Q_t^u(\cdot|x)||Q_t^{\text{base}}(\cdot|x)) = \sum_{y \neq x} Q_t^u(y|x) \log \frac{Q_t^u(y|x)}{Q_t^{\text{base}}(y|x)}.$$

证明。首先将式 (36) 中的最后一项更明确地表示为

$$\begin{aligned} \sum_{y \neq x} u_t(y, x) \log \frac{u_t(y, x)}{u_t^{\text{base}}(y, x)} &= \sum_{y \neq x} \lambda_t^u(x) Q_t^u(y|x) \log \frac{\lambda_t^u(x) Q_t^u(y|x)}{\lambda_t^{\text{base}}(x) Q_t^{\text{base}}(y|x)} \\ &= \lambda_t^u(x) \log \frac{\lambda_t^u(x)}{\lambda_t^{\text{base}}(x)} + \lambda_t^u(x) \sum_{y \neq x} Q_t^u(y|x) \log \frac{Q_t^u(y|x)}{Q_t^{\text{base}}(y|x)} \\ &= \lambda_t^u(x) \log \frac{\lambda_t^u(x)}{\lambda_t^{\text{base}}(x)} + \lambda_t^u(x) D_{\text{KL}}(Q_t^u(\cdot|x)||Q_t^{\text{base}}(\cdot|x)) \end{aligned} \quad (38)$$

将式 (38) 中的前两项与式 (36) 中剩余的项合并,

$$\sum_{y \neq x} u_t^{\text{base}}(y, x) - u_t(y, x) + \lambda_t^u(x) \log \frac{\lambda_t^u(x)}{\lambda_t^{\text{base}}(x)} = \lambda_t^u(x) D_{\text{KL}}(\lambda_t^u(x)||\lambda_t^{\text{base}}(x)) \quad (39)$$

即得所需结果。 $\square$

注 (式 (17) 中代价函数 J_t 的解释)。由式 (36), 式 (17) 中 $J_t(x; u)$ 的积分恰为连续时间马尔可夫链的 p^u 与 p^{base} 在区间 $[t, 1]$ 上的 KL 散度。

$$J_t(x; u) = D_{\text{KL}}(p^u(\mathbf{X}_{[t,1]}|X_t = x)||p^{\text{base}}(\mathbf{X}_{[t,1]}|X_t = x)) + \mathbb{E}_{p^u(X_1|X_t=x)}[g(X_1)]$$

估计连续时间马尔可夫链 (CTMC) 之间的概率比 为估计连续时间马尔可夫链之间的概率比, 我们调用其对应的 Radon-Nikodým 导数, 例如 (Zhu et al., 2025) :

$$\log \frac{p^u(\mathbf{X})}{p^{\text{base}}(\mathbf{X})} = \int_0^1 \sum_{y \neq X_t} (u_t(y, X_t) - u_t^{\text{base}}(y, X_t)) dt + \sum_{t: X_{t-} \neq X_t} \log \frac{u_t(X_t, X_{t-})}{u_t^{\text{base}}(X_t, X_{t-})} \quad (40)$$

给定轨迹 $\mathbf{X} \sim p^u$ 时该式仍可计算。注意, 当 p^u 和 p^{base} 特化为具有以下转移速率的掩码扩散模型时,

$$\forall y \neq x, \quad u_t(y, x) = \lambda_t^{\text{base}}(x) Q_t^u(y|x), \quad u_t^{\text{base}}(y, x) = \lambda_t^{\text{base}}(x) Q_t^{\text{base}}(y|x)$$

(40) 中的积分消失, 拉东-尼科迪姆导数简化为两个离散时间马尔可夫过程之间的对数概率比:

$$\log \frac{p^u(\mathbf{X})}{p^{\text{base}}(\mathbf{X})} = \sum_{t: X_{t-} \neq X_t} \log \frac{Q_t^u(X_t|X_{t-})}{Q_t^{\text{base}}(X_t|X_{t-})} \quad (41)$$

A.3 连续时间马尔可夫链的熵正则化优化

价值函数的动力学 价值函数——作为最优代价泛函——在定理 2.2 中离散伴随的推导过程中起着关键作用。为了便于后续推导, 我们在以下引理中给出其动力学。

引理 A.3 (价值函数的动力学)。考虑 (1) 中的熵正则化优化。将价值函数定义为 $V_t(x) := -\log \nabla$

$$p_{1|t}^{\text{base}}(z|x) e^{-g(z)}, \quad V_1(x) = g(x) \quad (42)$$

价值函数的动力学如下:

$$\partial_t V_t(x) = \sum_z u_t^{\text{base}}(z, x) e^{-V_t(z) + V_t(x)} \implies \partial_t e^{-V_t(x)} = - \sum_z u_t^{\text{base}}(z, x) e^{-V_t(z)} \quad (43)$$

证明。直接计算可得

$$\begin{aligned}
\partial_t V_t(x) &= -\frac{\sum_z \partial_t p_{1|t}^{\text{base}}(z|x) e^{-g(z)}}{\sum_z p_{1|t}^{\text{base}}(z|x) e^{-g(z)}} \\
&= e^{V_t(x)} \sum_z \sum_y u_t^{\text{base}}(y, x) p_{1|t}^{\text{base}}(z|y) e^{-g(z)} \quad \text{by (35)} \\
&= e^{V_t(x)} \sum_y u_t^{\text{base}}(y, x) e^{-V_t(y)} \\
\implies \partial_t e^{-V_t(x)} &= -e^{-V_t(x)} \partial_t V_t(x) = -\sum_y u_t^{\text{base}}(y, x) e^{-V_t(y)}
\end{aligned}$$

□

为了方便起见，进一步用跳跃率改写动力学 $\partial_t V_t(x)$ 。利用对所有 $z \neq x$ 都有 $u_t^*(z, x) = u_t^{\text{base}}(z, x) e^{-V_t(z) + V_t(x)}$ 这一事实，我们可以将 (43) 改写为

$$\partial_t V_t(x) = \sum_z u_t^{\text{base}}(z, x) e^{-V_t(z) + V_t(x)} = \sum_{z \neq x} u_t^*(z, x) + u_t^{\text{base}}(x, x)$$

也就是说，价值函数的动力学可以紧凑地表示为跳跃率之差：

$$\partial_t V_t(x) = \lambda_t^*(x) - \lambda_t^{\text{base}}(x) \quad (44)$$

此外，以下结果表明，价值函数的动力学 (43) 可以改写为与 Pham 等人 (2025, 方程 85) 中的 Hamilton-Jacobi-Bellman 相同的形式。

推论 A.4. 价值函数的动力学 $V_t(x)$ 可以写为

$$\partial_t V_t(x) = \lambda^{\text{base}}(x) \left(\sum_{z \neq x} Q_t^{\text{base}}(z|x) e^{-V_t(z) + V_t(x)} - 1 \right). \quad (45)$$

证明。从 (43) 开始：

$$\begin{aligned}
\partial_t V_t(x) &= \sum_z u_t^{\text{base}}(z, x) e^{-V_t(z) + V_t(x)}, \\
&= u_t^{\text{base}}(x, x) + \sum_{z \neq x} u_t^{\text{base}}(z, x) e^{-V_t(z) + V_t(x)}, \\
&= u_t^{\text{base}}(x, x) + u_t^{\text{base}}(x, x) \sum_{z \neq x} Q_t^{\text{base}}(z|x) e^{-V_t(z) + V_t(x)}, \\
&= u_t^{\text{base}}(x, x) + u_t^{\text{base}}(x, x) \sum_{z \neq x} Q_t^{\text{base}}(z|x) e^{-V_t(z) + V_t(x)}, \\
&= \lambda_t^{\text{base}}(x) \left(\sum_{z \neq x} Q_t^{\text{base}}(z|x) e^{-V_t(z) + V_t(x)} - 1 \right).
\end{aligned}$$

□

最优转移率 我们给出最优转移率 $u_t^*(y, x)$ 在 (6) 中的推导。以下引理将 (26) 中的初始点条件分布 $p_{1|0}$ 推广到任意时间步 $p_{t|s}$, $s < t$, , 由此可以容易地得到最优转移率。

引理 A.5 (最优条件分布)。对于任意不同的时间步 (s, t) , 使得 $0 \leq s < t \leq 1$, 熵正则化优化问题 (1) 的最优条件分布满足

$$p_{t|s}^*(y|x) = p_{t|s}^{\text{base}}(y|x) e^{-V_t(y) + V_t(x)} \quad (46)$$

证明。首先计算最优联合分布 $p^*(X_t = y, X_s = x)$:

$$\begin{aligned}
& p^*(X_t = y, X_s = x) \\
&= \sum_{\mathbf{X}} p^*(\mathbf{X}, X_t = y, X_s = x) \\
&= \sum_{\mathbf{X}} p^{\text{base}}(\mathbf{X}, X_t = y, X_s = x) e^{-g(X_1) - \log Z(X_0)} \quad \text{by (28)} \\
&= \sum_{X_0, X_1} p_{1|t}^{\text{base}}(X_1|y) p_{t|s}^{\text{base}}(y|x) p_{s,0}^{\text{base}}(x, X_0) e^{-g(X_1)} e^{-\log Z(X_0)} \quad \text{by Markoviana of } p^{\text{base}} \\
&= e^{-V_t(y)} p_{t|s}^{\text{base}}(y|x) \sum_{X_0} p_{s,0}^{\text{base}}(x, X_0) \quad (47)
\end{aligned}$$

同理，最优边缘分布 p^* 可由下式得到 (x)

$$\begin{aligned}
p_s^*(x) &= \sum_{\mathbf{X}} p^*(\mathbf{X}, X_s = x) \\
&= \sum_{\mathbf{X}} p^{\text{base}}(\mathbf{X}, X_s = x) e^{-g(X_1) - \log Z(X_0)} \quad \text{by (28)} \\
&= \sum_{X_0, X_1} p_{1|s}^{\text{base}}(X_1|x) p_{s,0}^{\text{base}}(x, X_0) e^{-g(X_1)} e^{-\log Z(X_0)} \quad \text{by Markoviana of } p^{\text{base}} \\
&= e^{-V_s(x)} \sum_{X_0} p_{s,0}^{\text{base}}(x, X_0) \quad (48)
\end{aligned}$$

结合方程 (47) 和 (48) 即可得到所需结果。 $\square$

根据引理 A.5，应用 (29) 可推导出最优转移速率 u^* :

$$\begin{aligned}
u_s^*(y, x) &:= \left[\partial_t p_{t|s}^*(y|x) \right]_{t=s} \\
&= \left[\partial_t \left(p_{t|s}^{\text{base}}(y|x) e^{-V_t(y) + V_s(x)} \right) \right]_{t=s} \quad \text{by (46)} \\
&= \left[\partial_t \left(p_{t|s}^{\text{base}}(y|x) \right) e^{-V_t(y) + V_s(x)} \right]_{t=s} + \left[p_{t|s}^{\text{base}}(y|x) e^{-V_t(y) + V_s(x)} \partial_t (-V_t(y)) \right]_{t=s} \\
&= u_s^{\text{base}}(y, x) e^{-V_s(y) + V_s(x)} - \delta_x(y) \cdot e^{-V_s(x) + V_s(x)} \partial_t V_s(x) \quad \text{by (34)} \\
&= u_s^{\text{base}}(y, x) e^{-V_s(y) + V_s(x)} - \delta_x(y) \cdot \sum_y u_s^{\text{base}}(y, x) e^{-V_s(y) + V_s(x)} \quad \text{by (43)}
\end{aligned}$$

which recovers the same expression in (6), *i.e.*,

$$\forall y \neq x, \quad u_t^*(y, x) = u_t^{\text{base}}(y, x) e^{-V_t(y) + V_t(x)} \quad (49)$$

注意，正如预期，最优转移速率 $u^*(y, x)$ satisfies the rate conditions (30)

$$u_t^*(y, x) \geq 0 \text{ 对所有 } y \neq x, \text{ 且 } \sum_y u_t^*(y, x) = 0 \quad (50)$$

价值函数关于最优转移速率的动力学 众所周知，价值函数的动力学依赖于基础转移速率 u^{base} ，如引理 A.3 所示。对于连续时间马尔可夫链 (CTMC) 过程，这些动力学可以等价地重新表述为关于最优速率 u^* 的形式。这一点在 (44) 中已有直接提示，其中 $\partial_t V_t(x) = \lambda_t^*(x) - \lambda_t^{\text{base}}(x)$ 正是最优跳跃速率与基础跳跃速率之差。以下引理正式阐述了这一观察。

引理 A.6 (价值函数关于 u^* 的动力学) 设 $V_t(x)$ 为 (42) 中相同的价值函数。给定 (49) 中的最优转移速率 u^* ， $V_t(x)$ 的动力学满足：

$$\partial_t V_t(x) = - \sum_z u_t^*(z, x) e^{V_t(z) - V_t(x)} \implies \partial_t e^{V_t(x)} = - \sum_z u_t^*(z, x) e^{V_t(z)} \quad (51)$$

证明。

$$\begin{aligned} \partial_t V_t(x) &= \lambda_t^*(x) - \lambda_t^{\text{base}}(x) \\ &= -u_t^*(x, x) - \sum_{z \neq x} u_t^{\text{base}}(z, x) \\ &= -u_t^*(x, x) - \sum_{z \neq x} u_t^*(z, x) e^{V_t(z) - V_t(x)} \\ &= - \sum_z u_t^*(z, x) e^{V_t(z) - V_t(x)} \end{aligned}$$

这意味着

$$\partial_t e^{V_t(x)} = e^{V_t(x)} \partial_t V_t(x) = -e^{V_t(x)} \sum_z u_t^*(z, x) e^{V_t(z) - V_t(x)} = - \sum_z u_t^*(z, x) e^{V_t(z)}$$

□

引理 A.7 离散伴随的分母是 $\cdot e^{V_t(x)}$, i.e., 的一个估计量

$$e^{V_t(x)} = \mathbb{E}_{p_{1|t}^*(X_1|x)}[e^{g(X_1)}]. \quad (52)$$

证明：对 $f_t(x) = e^{V_t(x)}$ 和 $u := u^*$ 应用引理 2.1 中的 Dynkin 公式，被积函数简化为

$$\begin{aligned} (\partial_t f_t)(X_t) + \sum_z u_t^*(z, X_t) f_t(z) &= \partial_t e^{-V_t(y)} + \sum_z u_t^*(z, X_t) e^{V_t(z)} \\ &= 0. \end{aligned} \quad \text{by (51)}$$

由于 $V_1(x) = g(x)$ ，从而 $f_1(x) = e^{g(x)}$ ，我们已推导出

$$e^{V_t(x)} = \mathbb{E}_{p^*(X_1|X_t=x)}[e^{g(X_1)}]. \quad (53)$$

□

A.4 玩具示例中 (12) 与 (13) 的偏差与方差比较

我们现在量化原始离散伴随 (12) 与使用重要性加权的改进离散伴随 (13) 之间偏差与方差的差异。

我们考虑序列长度为 $N = 1$ ，词汇表大小为 $M = 3$ ，且 $\mathcal{X} = \{\mathbf{m}, z_{\text{correct}}, z_{\text{wrong}}\}$ 。我们考虑一个指示函数损失，用于惩罚错误答案，即

$$g(z) = -50\mathbb{I}\{z = z_{\text{correct}}\}. \quad (54)$$

设基础分布为 $p_{1|t}^{\text{base}}$

be

$$p_{1|t}^{\text{base}}(z) = \begin{cases} \theta, & z = z_{\text{correct}}, \\ 1 - \theta, & z = z_{\text{wrong}} \end{cases} \quad (55)$$

那么，最优分布 $p_{1|t}^*$ 为

$$p_{1|t}^*(z|\mathbf{m}) = \frac{p_{1|t}^{\text{base}}(z|\mathbf{m})e^{-g(z)}}{\sum_{z'} p_{1|t}^{\text{base}}(z'|\mathbf{m})e^{-g(z')}} \quad (56)$$

$$= \begin{cases} \frac{\theta e^{50}}{\theta e^{50} + (1 - \theta)}, & z = z_{\text{correct}}, \\ \frac{1 - \theta}{\theta e^{50} + (1 - \theta)}, & z = z_{\text{wrong}}. \end{cases} \quad (57)$$

如果 θ 不是太小, 则 $p_{1|t}^*(z_{\text{correct}}|\mathbf{m}) \approx 1$ 。

我们仅考虑 (12) 和 (13) 的“分母”部分, 因为“分子”在两种情况下相同。在我们的设定中, 分母的真实值为

$$\mathbb{E}_{p_{1|t}^*(X_1|X_t=\mathbf{m})}[e^{g(X_1)}] = p_{1|t}^*(z_{\text{correct}}|\mathbf{m})e^{-g(z_{\text{correct}})} + p_{1|t}^*(z_{\text{wrong}}|\mathbf{m})e^{-g(z_{\text{wrong}})}, \quad (58)$$

$$= \frac{1}{\theta e^{50} + (1 - \theta)}. \quad (59)$$

设当前模型分布 $p_{1|t}^u(z|\mathbf{m})$ 为

$$p_{1|t}^u(z|\mathbf{m}) = \begin{cases} \phi, & z = z_{\text{correct}}, \\ 1 - \phi, & z = z_{\text{wrong}} \end{cases} \quad (60)$$

原始离散伴随的偏差与方差 设 $X_1^{(1)}, \dots, X_1^{(N)} \sim p_{1|t}^*(X_1|X_t=\mathbf{m})$ 为来自模型分布 $p_{1|t}^u$ 的 N 个独立同分布样本。本文遵循原始 AM 方法, 利用这些模型样本计算 (12)。由此得到 (12) 式分母的如下 N 样本蒙特卡洛估计量:

$$\mathbb{E}_{p_{1|t}^*(X_1|X_t=\mathbf{m})}[e^{g(X_1)}] \approx \mathbb{E}_{p_{1|t}^u(X_1|X_t=\mathbf{m})}[e^{g(X_1)}] \quad (61)$$

$$\approx \frac{1}{N} \sum_{i=1}^N e^{g(X_1^{(i)})}. \quad (62)$$

本文首先计算均值

$$\begin{aligned} \mathbb{E} \left[\frac{1}{N} \sum_{i=1}^N e^{g(X_1^{(i)})} \right] &= \mathbb{E}_{p_{1|t}^u(X_1|\mathbf{m})}[e^{g(X_1)}] \\ &= \phi e^{-50} + (1 - \phi) \end{aligned}$$

以及方差

$$\begin{aligned} \text{Var} \left[\frac{1}{N} \sum_{i=1}^N e^{g(X_1^{(i)})} \right] &= \frac{1}{N} \text{Var}_{p_{1|t}^u(X_1|\mathbf{m})}[e^{g(X_1)}] \\ &= \frac{1}{N} \left(\mathbb{E}_{p_{1|t}^u(X_1|\mathbf{m})}[e^{2g(X_1)}] - \mathbb{E}_{p_{1|t}^u(X_1|\mathbf{m})}[e^{g(X_1)}]^2 \right) \\ &= \frac{1}{N} \left(\phi e^{-100} + (1 - \phi) - (\phi e^{-50} + (1 - \phi))^2 \right), \\ &= \frac{1}{N} \phi(1 - \phi)(e^{-50} - 1)^2. \end{aligned}$$

则偏差为

$$\begin{aligned} \text{Bias of (12)} &= \mathbb{E} \left[\frac{1}{N} \sum_{i=1}^N e^{g(X_1^{(i)})} \right] - \mathbb{E}_{p_{1|t}^*(X_1|X_t=\mathbf{m})}[e^{g(X_1)}], \\ &= (\phi e^{-50} + (1 - \phi)) - \frac{1}{\theta e^{50} + (1 - \theta)}, \\ &\approx (1 - \phi) - \frac{1}{\theta e^{50}}, \\ &\approx 1 - \phi. \end{aligned} \quad (63)$$

方差可近似为

$$\begin{aligned}\text{Var}\left[\frac{1}{N}\sum_{i=1}^N e^{g(X_1^{(i)})}\right] &= \frac{1}{N}\phi(1-\phi)(e^{-50}-1)^2, \\ &\approx \frac{1}{N}\phi(1-\phi)(e^{-50})^2.\end{aligned}\quad (64)$$

其中本文使用了近似 $\phi e^{-50} + (1-\phi) \approx 1-\phi$ 与 $\frac{1}{\theta e^{50} + (1-\theta)} \approx \frac{1}{\theta e^{50}}$ ，这些近似在 ϕ 不太大且 θ 不太小时成立。

重要性加权离散伴随的偏差与方差 式 (13) 的分母部分具有如下形式

$$\begin{aligned}\left(\mathbb{E}_{p_{1|t}^u(X_1|X_t=\mathbf{m})}\left[\frac{p_{1|t}^{\text{base}}(X_1|X_t=\mathbf{m})}{p_{1|t}^u(X_1|X_t=\mathbf{m})}e^{-g(X_1)}\right]\right)^{-1} &= \left(\mathbb{E}_{p_{1|t}^u(X_1|X_t=\mathbf{m})}[w(X_1)]\right)^{-1} \\ &\approx \underbrace{\left(\frac{1}{N}\sum_{i=1}^N w(X_1^{(i)})\right)^{-1}}_{:=S_N}.\end{aligned}$$

为方便起见，我们定义了

$$w(X_1) := \frac{p_{1|t}^{\text{base}}(X_1|X_t=\mathbf{m})}{p_{1|t}^u(X_1|X_t=\mathbf{m})}e^{-g(X_1)}.\quad (65)$$

首先评估 S_N 的均值与方差，

$$\begin{aligned}\mathbb{E}[S_N] &= \mathbb{E}_{p_{1|t}^u(X_1|\mathbf{m})}[w(X_1)] \\ &= \mathbb{E}_{p_{1|t}^{\text{base}}(X_1|\mathbf{m})}[e^{-g(X_1)}] \\ &= \theta e^{50} + (1-\theta).\end{aligned}$$

和

$$\begin{aligned}\text{Var}[S_N] &= \frac{1}{N}\text{Var}_{p_{1|t}^u(X_1|\mathbf{m})}[w(X_1)] \\ &= \frac{1}{N}\left(\mathbb{E}_{p_{1|t}^u(X_1|\mathbf{m})}[w(X_1)^2] - \mathbb{E}_{p_{1|t}^u(X_1|\mathbf{m})}[w(X_1)]^2\right) \\ &= \frac{1}{N}\left(\mathbb{E}_{p_{1|t}^{\text{base}}(X_1|\mathbf{m})}\left[\frac{p_{1|t}^{\text{base}}(X_1|X_t=\mathbf{m})}{p_{1|t}^u(X_1|X_t=\mathbf{m})}e^{-2g(X_1)}\right] - \mathbb{E}_{p_{1|t}^{\text{base}}(X_1|\mathbf{m})}[e^{-g(X_1)}]^2\right) \\ &= \frac{1}{N}\left(\theta\frac{\theta}{\phi}e^{100} + (1-\theta)\frac{1-\theta}{1-\phi} - (\theta e^{50} + (1-\theta))^2\right), \\ &= \frac{1}{N}\left(\theta^2 e^{100}\left(\frac{1}{\phi} - 1\right) + (1-\theta)^2\left(\frac{1}{1-\phi} - 1\right) - 2\theta(1-\theta)e^{50}\right).\end{aligned}$$

然后，利用德尔塔方法，我们可以将 S_N^{-1} 的均值与方差近似为

$$\begin{aligned}\mathbb{E}[S_N^{-1}] &\approx \mathbb{E}[S_N]^{-1} + \frac{\text{Var}[S_N]}{\mathbb{E}[S_N]^3}, \\ &= \frac{1}{\theta e^{50} + (1-\theta)} + \frac{1}{N} \frac{\theta^2 e^{100}(\frac{1}{\phi} - 1) + (1-\theta)^2(\frac{1}{1-\phi} - 1) - 2\theta(1-\theta)e^{50}}{(\theta e^{50} + (1-\theta))^3}.\end{aligned}$$

和

$$\text{Var}[S_N^{-1}] \approx \frac{\text{Var}[S_N]}{\mathbb{E}[S_N]^4},$$

$$= \frac{1}{N} \frac{\theta^2 e^{100}(\frac{1}{\phi} - 1) + (1 - \theta)^2(\frac{1}{1-\phi} - 1) - 2\theta(1 - \theta)e^{50}}{(\theta e^{50} + (1 - \theta))^4}.$$

则偏差为

$$\begin{aligned} \text{Bias of (13)} &= \mathbb{E}[S_N^{-1}] - \mathbb{E}_{p_{1|t}^*(X_1|X_t=\mathbf{m})}[e^{g(X_1)}], \\ &= \frac{1}{N} \frac{\theta^2 e^{100}(\frac{1}{\phi} - 1) + (1 - \theta)^2(\frac{1}{1-\phi} - 1) - 2\theta(1 - \theta)e^{50}}{(\theta e^{50} + (1 - \theta))^3}, \\ &\approx \frac{1}{N} \frac{\theta^2 e^{100}(\frac{1}{\phi} - 1)}{\theta^3 (e^{50})^3}, \\ &= \frac{1}{N} \frac{1 - \phi}{\phi \theta} e^{-50}. \end{aligned} \tag{66}$$

同时我们可以将方差近似为

$$\begin{aligned} \text{Var}[S_N] &\approx \frac{1}{N} \frac{\theta^2 e^{100}(\frac{1}{\phi} - 1) + (1 - \theta)^2(\frac{1}{1-\phi} - 1) - 2\theta(1 - \theta)e^{50}}{(\theta e^{50} + (1 - \theta))^4}, \\ &\approx \frac{1}{N} \frac{\theta^2 e^{100}(\frac{1}{\phi} - 1)}{\theta^4 (e^{50})^4}, \\ &= \frac{1}{N} \frac{1 - \phi}{\phi \theta^2} (e^{-50})^2. \end{aligned} \tag{67}$$

比较偏差 (63) 与 (66)，我们发现重要性加权离散伴随的偏差远小于原始离散伴随的偏差，因为 (66) 中的偏差被 e^{-50} 缩放。对于方差，两个方差 (64) 与 (67) 相似。这与图 2 中的经验结果一致。

B 证明

引理 2.1 (Dynkin 公式)。对于给定的函数 $f_t(x)$ 和连续时间马尔可夫链模型 p^u ，有

$$f_t(x) = \mathbb{E}_{p^u(\mathbf{X}|X_t=x)} \left[f_1(X_1) - \int_t^1 \left((\partial_\tau f_\tau)(X_\tau) + \sum_y u_\tau(y, X_\tau) f_\tau(y) \right) d\tau \right]. \tag{7}$$

证明。戴恩金公式 (Piunovskiy & Zhang, 2020, 定理 2.4.1) 指出，给定函数 $f(t, x) \equiv f_t(x)$ ，有

$$\mathbb{E}_{\mathbf{X}} [f_1(X_1)] = f_0(X_0) + \mathbb{E}_{\mathbf{X}} \left[\int_0^1 (\mathcal{A}f)(t, X_t) dt \right] \tag{68}$$

其中 $\mathcal{A}$ 是费勒过程 $\mathbf{X} = (X_t)_{t \in [0, 1]}$ 的无穷小生成元，定义为

$$(\mathcal{A}f)(s, x) = \lim_{t \downarrow s} \frac{\mathbb{E}_{\mathbf{X}} [f_t(X_t) | X_s = x] - f_s(x)}{t - s} \tag{69}$$

对于具有速率 $u_t(y, x)$ 的连续时间马尔可夫链 $\mathbf{X} \sim p^u$ ，我们有

$$\begin{aligned} &(\mathcal{A}f)(s, x) \\ &= \lim_{t \downarrow s} \frac{\mathbb{E}_{\mathbf{X}} [f_t(X_t) | X_s = x] - f_s(x)}{t - s} \\ &= \lim_{t \downarrow s} \frac{\sum_y p_{t|s}(y|x) (f_t(y) - f_s(x))}{t - s} \\ &= \lim_{t \downarrow s} \frac{\sum_y p_{t|s}(y|x) (f_t(y) - f_s(y))}{t - s} + \lim_{t \downarrow s} \frac{\sum_y p_{t|s}(y|x) (f_s(y) - f_s(x))}{t - s} \end{aligned}$$

$$= \lim_{t \downarrow s} \frac{\sum_y p_{t|s}(y|x) (f_t(y) - f_s(y))}{t - s} + \frac{d}{dt} \sum_y p_{t|s}(y|x) f_s(y) - \frac{d}{dt} \sum_y p_{t|s}(y|x) f_s(x) \quad (70)$$

第一项简化为

$$\lim_{t \downarrow s} \frac{\sum_y p_{t|s}(y|x) (f_t(y) - f_s(y))}{t - s} = \sum_y \delta_x(y) \partial_t f_s(y) = \partial_t f_s(x)$$

The second term simplifies as

$$\frac{d}{dt} \sum_y p_{t|s}(y|x) f_s(y) = \sum_y u_s(y, x) f_s(y)$$

第三项简化为

$$\frac{d}{dt} \sum_y p_{t|s}(y|x) f_s(x) = f_s(x) \sum_y u_s(y, x) = 0$$

Combined, (70) simplifies as

$$(\mathcal{A}f)(s, x) = \partial_t f_s(x) + \sum_y u_s(y, x) f_s(y) \quad (71)$$

将 (68) 与上述结果 (71) 重新整理, 得到所需结果:

$$f_0(X_0) = \mathbb{E}_{p^u(\mathbf{X}|X_0)} \left[f_1(X_1) - \int_0^1 \left(\partial_t f_t(X_t) + \sum_y u_t(y, X_t) f_t(y) \right) dt \right]$$

□

定理 2.2 (离散伴随——连续时间马尔可夫链的伴随系统)。设
化问题 (1) 的最优速率。则对所有

$u_t^*(y, x)$ 为连续时间马尔可夫链模型下熵正则
 $y \neq x$ 成立

$$u_t^*(y, x) = u_t^{\text{base}}(y, x) \mathbb{E}_{p^*}(\mathbf{X}|X_t=x) \underbrace{\left[\tilde{a}_1(y; \mathbf{X}) + \int_t^1 \sum_z u_\tau^{\text{base}}(z, y) \tilde{a}_\tau(z; \mathbf{X}) d\tau \right]}_{=: \tilde{a}_t(y; \mathbf{X})}, \quad \tilde{a}_1(y; \mathbf{X}) = e^{-g(y)+g(X_1)} \quad (8)$$

其中离散伴随 $\tilde{a}_t(y; \mathbf{X}) \in \mathbb{R}_{>0}$ 是在 p^* 下 $e^{-V_t(y)+V_t(x)}$ 的无偏估计量。

证明。利用引理 2.1, 其中 $f_t(x; y) := e^{-V_t(y)+V_t(x)}$ 和 $u := u^*$, 被积函数简化为

$$\begin{aligned} & (\partial_t f_t)(X_t) + \sum_z u_t^*(z, X_t) f_t(z; y) \\ &= e^{V_t(X_t)} \partial_t e^{-V_t(y)} + e^{-V_t(y)} \left(\partial_t e^{V_t(X_t)} + \sum_z u_t^*(z, X_t) e^{V_t(z)} \right) \\ &= e^{V_t(X_t)} \partial_t e^{-V_t(y)} \quad \text{by (51)} \\ &= - \sum_z u_t^{\text{base}}(z, y) e^{-V_t(z)+V_t(X_t)} \quad \text{by (43)} \end{aligned}$$

由于 $V_1(x) = g(x)$, 从而 $f_1(x; y) = e^{-g(y)+g(x)}$, 我们已推导出

$$e^{-V_t(y)+V_t(x)} = \mathbb{E}_{p^*}(\mathbf{X}|X_t=x) \left[e^{-g(y)+g(X_1)} + \int_t^1 \left(\sum_z u_\tau^{\text{base}}(z, y) e^{-V_\tau(z)+V_\tau(X_\tau)} \right) d\tau \right] \quad (72)$$

给定从时间 t 的 x 出发的最优轨迹 $\mathbf{X} \sim p^*(\cdot | X_t = x)$ ，可以通过求解以下反向常微分方程来估计期望：

$$\frac{d}{dt} \tilde{a}_t(y; \mathbf{X}) = - \sum_z u_t^{\text{base}}(z, y) e^{-V_t(z) + V_t(X_t)}, \quad \tilde{a}_1(y; \mathbf{X}) = e^{-g(y) + g(X_1)} \quad (73)$$

这意味着

$$\begin{aligned} e^{-V_t(y) + V_t(x)} &= \mathbb{E}_{p^*(\mathbf{X} | X_t = x)} [\tilde{a}_t(y; \mathbf{X})] && \text{by (72)} \\ &= \mathbb{E}_{p^*(\mathbf{X} | X_t = x)} \left[\tilde{a}_1(y; \mathbf{X}) + \int_t^1 \sum_z u_\tau^{\text{base}}(z, y) e^{-V_\tau(z) + V_\tau(X_\tau)} d\tau \right] \\ &= \mathbb{E}_{p^*(\mathbf{X} | X_t = x)} \left[\tilde{a}_1(y; \mathbf{X}) + \int_t^1 \sum_z u_\tau^{\text{base}}(z, y) \mathbb{E}_{p^*(\bar{\mathbf{X}} | X_\tau)} [\tilde{a}_\tau(y; \bar{\mathbf{X}})] d\tau \right] && \text{by (72)} \\ &= \mathbb{E}_{p^*(\mathbf{X} | X_t = x)} \left[\tilde{a}_1(y; \mathbf{X}) + \int_t^1 \sum_z u_\tau^{\text{base}}(z, y) \tilde{a}_\tau(y; \mathbf{X}) d\tau \right] && (74) \end{aligned}$$

这意味着以下常微分方程在期望意义上与 (73) 中的方程等价：

$$\frac{d}{dt} \tilde{a}_t(y; \mathbf{X}) = - \sum_z u_t^{\text{base}}(z, y) \tilde{a}_t(z; \mathbf{X}), \quad \tilde{a}_1(y; \mathbf{X}) = e^{-g(y) + g(X_1)} \quad (75)$$

最后，将 (74) 代入 (49) 得到所需结果。 $\square$

命题 2.3（解析离散伴随）。(8) 中的离散伴随存在解析解：

$$\tilde{a}_t(y; X_1) = \sum_z p_{1|t}^{\text{base}}(z|y) e^{-g(z) + g(X_1)} \quad (12)$$

证明。将柯尔莫哥洛夫反向方程 (35) 改写为矩阵形式：

$$\frac{d}{dt} P_{1|t}^{\text{base}} = -U_t^{\text{base}} P_{1|t}^{\text{base}} \implies P_{1|t}^{\text{base}} = \exp \left(\int_t^1 U_\tau^{\text{base}} d\tau \right) P_{1|1}^{\text{base}} = \exp \left(\int_t^1 U_\tau^{\text{base}} d\tau \right) \quad (76)$$

其中 $U_t^{\text{base}}, P_{1|t}^{\text{base}} \in \mathbb{R}^{|\mathcal{X}| \times |\mathcal{X}|}$ 是以 $u_t^{\text{base}}(z, y)$ 和 $p_{1|t}^{\text{base}}(z, y)$ 作为其 (z, y) 元素的矩阵。同样，将离散伴随方程 (75) 的动力学改写为向量形式：

$$\frac{d}{dt} \tilde{\mathbf{a}}_t(\mathbf{X}) = -U_t^{\text{base}} \cdot \tilde{\mathbf{a}}_t(\mathbf{X}) \quad (77)$$

其中 $\tilde{\mathbf{a}}_t(\mathbf{X}) \in \mathbb{R}^{|\mathcal{X}|}$ 是离散伴随向量，以 $\tilde{a}_t(y; \mathbf{X})$ 作为其 y 元素。由于 (77) 是线性常微分方程，它存在解析解：

$$\tilde{\mathbf{a}}_t(\mathbf{X}) = \exp \left(\int_t^1 U_\tau^{\text{base}} d\tau \right) \tilde{\mathbf{a}}_1(\mathbf{X}) = P_{1|t}^{\text{base}} \cdot \tilde{\mathbf{a}}_1(\mathbf{X}) \quad (78)$$

其中最后一个等式由 (76) 得出。对每个元素 y 展开 (78) 即可得到所需结果。 $\square$

命题 2.4（重要性加权离散伴随）。考虑以下估计量

$$\hat{a}_t(y; Z, \{X_1^{(k)}\}) := \frac{p_{1|t}^{\text{base}}(Z|y)}{p_{1|t}^u(Z|y)} e^{-g(Z)} \cdot \left(\frac{1}{K} \sum_{k=1}^K \frac{p_{1|t}^{\text{base}}(X_1^{(k)}|x)}{p_{1|t}^u(X_1^{(k)}|x)} e^{-g(X_1^{(k)})} \right)^{-1} \quad (13)$$

其中 $\{X_1^{(k)}\} \sim p_{1|t}^u(\cdot|x)$ 和 $Z \sim p_{1|t}^u(\cdot|y)$ 是生成的模型样本。那么， $\hat{a}_t$ 是以下量的一致估计量
the discrete adjoint, i.e., $\lim_{K \rightarrow \infty} \mathbb{E}[\hat{a}_t(y; Z, \{X_1^{(k)}\})] = \mathbb{E}_{p_{1|t}^*(X_1|x)}[\tilde{a}_t(y; X_1)]$.

证明。给定 (12) 中的解析离散伴随，我们可以将离散伴随的期望分解为两个独立的期望：

$$\begin{aligned} \mathbb{E}_{p^*(X_1|X_t=x)}[\tilde{a}_t(y; X_1)] &= \mathbb{E}_{p^*(X_1|X_t=x)} \left[\sum_z p_{1|t}^{\text{base}}(z|y) e^{-g(z)+g(X_1)} \right] \\ &= \mathbb{E}_{p_{1|t}^{\text{base}}(Z|y)} \left[e^{-g(Z)} \right] \mathbb{E}_{p^*(X_1|X_t=x)} \left[e^{g(X_1)} \right] \end{aligned} \quad \text{by (12)}$$

两个期望都可以使用模型样本 $\mathbf{X} \sim p^u$ 进行估计。具体而言，对第一个期望应用重要性采样得到

$$\mathbb{E}_{p_{1|t}^{\text{base}}(Z|y)} \left[e^{-g(Z)} \right] = \mathbb{E}_{p_{1|t}^u(Z|y)} \left[\frac{p_{1|t}^{\text{base}}(Z|y)}{p_{1|t}^u(Z|y)} e^{-g(Z)} \right] \quad (79)$$

对于第二个期望，我们应用自归一化重要性采样

$$\mathbb{E}_{p_{1|t}^{\text{base}}(Z|y)} \left[e^{g(X_1)} \right] = \lim_{K \rightarrow \infty} \mathbb{E}_{p_{1|t}^u(\{X_1^{(k)}\}|x)} \left[\frac{\sum_{k=1}^K \frac{w(X_1^{(k)}, x)}{\sum_j w(X_1^{(j)}, x)} e^{g(X_1^{(k)})} \right], \quad (80)$$

使用未归一化的重要性权重 $w(z, x) := \frac{p_{1|t}^*(z|x)}{p_{1|t}^u(z|x)} = \frac{p_{1|t}^{\text{base}}(z|x)}{p_{1|t}^u(z|x)} e^{-g(z)+V_t(x)}$ 。这将 (80) 中的估计量简化为

$$\begin{aligned} \sum_{k=1}^K \frac{w(X_1^{(k)}, x)}{\sum_j w(X_1^{(j)}, x)} e^{g(X_1^{(k)})} &= \sum_{k=1}^K \frac{\frac{p_{1|t}^{\text{base}}(X_1^{(k)}|x)}{p^u(X_1^{(k)}|x)} e^{-g(X_1^{(k)})}}{\sum_{j=1}^K \frac{p_{1|t}^{\text{base}}(X_1^{(j)}|x)}{p^u(X_1^{(j)}|x)} e^{-g(X_1^{(j)})}} e^{g(X_1^{(k)})} \\ &= \frac{\sum_{k=1}^K \frac{p_{1|t}^{\text{base}}(X_1^{(k)}|x)}{p^u(X_1^{(k)}|x)}}{\sum_{j=1}^K \frac{p_{1|t}^{\text{base}}(X_1^{(j)}|x)}{p^u(X_1^{(j)}|x)} e^{-g(X_1^{(j)})}} \\ &\approx \frac{1}{\frac{1}{K} \sum_{j=1}^K \frac{p_{1|t}^{\text{base}}(X_1^{(j)}|x)}{p^u(X_1^{(j)}|x)} e^{-g(X_1^{(j)})}} \end{aligned} \quad (81)$$

其中我们利用了分子期望为 1 的事实，即

$$\mathbb{E}_{p_{1|t}^u(\{X_1^{(k)}\}|x)} \left[\frac{p_{1|t}^{\text{base}}(X_1^{(k)}|x)}{p^u(X_1^{(k)}|x)} \right] = 1$$

结合 (79) 和 (81) 即可得到所需结果。 $\square$

命题 2.5 (掩码最优速率)。给定式 (15) 中的基础速率 u^{base} ，最优速率 u^* 满足

$$\forall y \neq x, \quad u_t^*(y, x) = \lambda_t^{\text{base}}(x) Q^*(y|x), \quad Q^* \in \mathbb{Q}^{\text{mask}} \quad (16)$$

证明。该证明基于以下事实：由式 (15) 定义的基础速率 u^{base} 将其对应的连续时间马尔可夫链 (CTMC) 简化为一个离散时间马尔可夫过程，其中在从 0 到 1 的时间区间内恰好发生 N 次跳跃，每次跳跃揭示 $X_0 = (\mathbf{m}, \dots, \mathbf{m})$ 中的一个掩码标记。这一解释表明，只需定义 N 个边际分布 $(q_n)_{n=1}^N$ 即可，其中每个 $q_n(\cdot)$ 对应于恰好有 n 个标记被揭示的样本分布，且条件分布变为时间不变的；即，

$$p_{t|s}^{\text{base}}(y|x) = q_{\varphi(y)|\varphi(x)}^{\text{base}}(y|x) \quad (82)$$

其中我们引入函数 $\varphi: \mathcal{X} \rightarrow \mathbb{Z}_{\geq 0}$ ，用于统计 x 中未被掩码的标记数量。借助 $\varphi(\cdot)$ ，我们可以将基础跳跃目标概率 Q^{base} 重写为

$$Q^{\text{base}}(y|x) = q_{\varphi(x)+1|\varphi(x)}^{\text{base}}(y|x) \quad (83)$$

基于上述推理，式 (42) 中定义的价值函数变为时间不变的：

$$\begin{aligned} V_t(x) &= -\log \sum_z p_{1|t}^{\text{base}}(z|x) e^{-g(z)} \\ &= -\log \sum_z q_{N|\varphi(x)}^{\text{base}}(z|x) e^{-g(z)} = V(x) \end{aligned} \quad (84)$$

其负指数变换 $e^{-V(x)}$ 呈现出动态规划结构：

$$\begin{aligned} e^{-V(x)} &= \sum_z q_{N|\varphi(x)}^{\text{base}}(z|x) e^{-g(z)} && \text{by (84)} \\ &= \sum_z \sum_y q_{N|\varphi(x)+1}^{\text{base}}(z|y) q_{\varphi(x)+1|\varphi(x)}^{\text{base}}(y|x) e^{-g(z)} \\ &= \sum_y Q^{\text{base}}(y|x) \sum_z q_{N|\varphi(x)+1}^{\text{base}}(z|y) e^{-g(z)} && \text{by (83)} \\ &= \sum_y Q^{\text{base}}(y|x) e^{-V(y)} \end{aligned} \quad (85)$$

这意味着最优速率保持与基础速率相同的跳跃速率 $\lambda_t^{\text{base}}(x)$ ，且最优跳跃目标概率也是时间不变的，即，

$$\forall y \neq x, \quad u_t^*(y, x) = u_t^{\text{base}}(y, x) e^{-V(y)+V(x)} = \lambda_t^{\text{base}}(x) \underbrace{Q^{\text{base}}(y|x) e^{-V(y)+V(x)}}_{=: Q^*(y|x)}$$

由于最优跳跃目标概率 $Q^*(y|x)$ 是基础跳跃目标概率 $Q^{\text{base}} \in \mathbb{Q}^{\text{mask}}$ ， $Q^*(y|x) \geq 0$ 的重新加权，当且仅当 y 恰好揭示 x 中的一个标记。此外， $Q^*(y|x)$ 通过构造是归一化的， $\sum_y$

$$\begin{aligned} Q^*(y|x) &= \sum_y Q^{\text{base}}(y|x) e^{-V(y)+V(x)} \\ &= \frac{\sum_y Q^{\text{base}}(y|x) e^{-V(y)}}{e^{-V(x)}} \\ &= 1 \end{aligned} \quad \text{by (85)}$$

即， $Q^* \in \mathbb{Q}^{\text{mask}}$ ，我们完成了证明。 $\square$

引理 3.1 (u^* 的不动点方程) 设 $\mathcal{F}$ 为所有满足速率条件的连续时间马尔可夫链速率空间之间的映射，即脚注 2。具体地，对于所有 $y \neq x$ ，我们有

$$\mathcal{F}: u_t(y, x) \mapsto u_t^{\text{base}}(y, x) e^{-J_t(y; u) + J_t(x; u)} \quad (18)$$

那么，映射 $\mathcal{F}$ 的唯一不动点即为最优速率 $u_t^*(y, x)$ ，i.e., $u^* = \mathcal{F}(u^*)$ 。

证明。回顾关于连续时间马尔可夫链 (CTMC) 及其速率 $u_t(y, x)$ 定义的成本函数 $J_t(x; u)$ ：

$$J_t(x; u) := \mathbb{E}_{p^u(\mathbf{X}|X_t=x)} \left[\int_t^1 \sum_{y \neq X_\tau} \left(u_\tau^{\text{base}} - u_\tau + u_\tau \log \frac{u_\tau}{u_\tau^{\text{base}}} \right) (y, X_\tau) d\tau + g_1(X_1) \right] \quad (86)$$

我们可以将 J_t 改写为动态规划形式：

$$\begin{aligned}
J_t(x; u) &= \mathbb{E} \left[\int_t^{t+\Delta t} \sum_{y \neq X_\tau} \left(u_\tau^{\text{base}} - u_\tau + u_\tau \log \frac{u_\tau}{u_\tau^{\text{base}}} \right) (y, X_\tau) d\tau \mid X_t = x \right] \\
&\quad + \mathbb{E}[J_{t+\Delta t}(X_{t+\Delta t}; u) \mid X_t = x] \\
\Rightarrow 0 &= \frac{\mathbb{E} \left[\int_t^{t+\Delta t} \sum_{y \neq X_\tau} \left(u_\tau^{\text{base}} - u_\tau + u_\tau \log \frac{u_\tau}{u_\tau^{\text{base}}} \right) (y, X_\tau) d\tau \mid X_t = x \right]}{\Delta t} \\
&\quad + \frac{\mathbb{E}[J_{t+\Delta t}(X_{t+\Delta t}; u) \mid X_t = x] - J_t(x; u)}{\Delta t}
\end{aligned}$$

Taking $\Delta t \rightarrow 0$ yields

$$\begin{aligned}
0 &= (\mathcal{A}J)(t, x) + \sum_{y \neq x} \left(u_t^{\text{base}} - u_t + u_t \log \frac{u_t}{u_t^{\text{base}}} \right) (y, x) && \text{by (69)} \\
-\partial_t J_t(x; u) &= \sum_y u_t(y, x) J_t(y; u) + \sum_{y \neq x} \left(u_t^{\text{base}} - u_t + u_t \log \frac{u_t}{u_t^{\text{base}}} \right) (y, x) && \text{by (71)} \\
-\partial_t J_t(x; u) &= \sum_{y \neq x} u_t(y, x) (J_t(y; u) - J_t(x; u)) + \sum_{y \neq x} \left(u_t^{\text{base}} - u_t + u_t \log \frac{u_t}{u_t^{\text{base}}} \right) (y, x) && \text{by (33)} \\
-\partial_t J_t(x; u) &= \sum_{y \neq x} \left(u_t^{\text{base}} - u_t + u_t \log \frac{u_t}{\mathcal{F}(u_t)} \right) (y, x) && (87)
\end{aligned}$$

现在，考虑一个满足自洽性关系的连续时间马尔可夫链速率 $\bar{u}_t(y, x)$

$$\forall y \neq x, \quad \bar{u}_t(y, x) = u_t^{\text{base}}(y, x) e^{-J_t(y; \bar{u}) + J_t(x; \bar{u})} \implies \bar{u}_t = \mathcal{F}(\bar{u}_t) \quad (88)$$

可以验证，当 $u := \bar{u}$ 时，代价函数 $J_t(x; u)$ 在式 (87) 中的动态退化为式 (43) 中值函数的动态。

$$\begin{aligned}
-\partial_t J_t(x; \bar{u}) &= \sum_{y \neq x} \left(u_t^{\text{base}} - \bar{u}_t + \bar{u}_t \log \frac{\bar{u}_t}{\mathcal{F}(\bar{u}_t)} \right) (y, x) \\
&= \sum_{y \neq x} (u_t^{\text{base}}(y, x) - \bar{u}_t(y, x)) && \text{by (88)} \\
&= -u_t^{\text{base}}(x, x) - \sum_{y \neq x} u_t^{\text{base}}(y, x) e^{-J_t(y; \bar{u}) + J_t(x; \bar{u})} && \text{由 (30) 和 (88) 可得} \\
&= -\sum_y u_t^{\text{base}}(y, x) e^{-J_t(y; \bar{u}) + J_t(x; \bar{u})}
\end{aligned}$$

也就是说，我们已经证明任何满足 (88) 中自洽性关系的策略 $\bar{u}$ ，其代价函数 $J_t(x; \bar{u})$ 对应于值函数 $V_t(x)$ 。这意味着 $\bar{u} = u^*$ 是最优速率，并且由唯一性可知，它是 (88) 的唯一不动点。 $\square$

定理 3.2（离散基本伴随匹配）。对于任意布雷格曼散度点即为最优速率：

D_ϕ ，以下匹配目标的唯一临界

$$u_t^*(y, x) = \arg \min_u \mathbb{E}_{p^{\bar{u}}(\mathbf{X} \mid X_t = x)} [D_\phi(u_t(y, x), u_t^{\text{base}}(y, x) a_t(y; \mathbf{X}, \bar{u}))] \quad (19)$$

其中 $\bar{u} = \text{stopgrad}(u)$ ，且 $a_t(y; \mathbf{X}, u)$ 为满足后向常微分方程的离散基本伴随

$$-\frac{d}{dt} a_t(y; \mathbf{X}, u) = a_t(y; \mathbf{X}, u) \left(\sum_{z \neq X_t} \left(u_t^{\text{base}} \left(1 - \frac{u_t}{\mathcal{F}(u_t)} \right) + u_t \log \frac{u_t}{\mathcal{F}(u_t)} \right) (z, X_t) \right)$$

$$-\sum_{z \neq y} \left(u_t^{\text{base}} - u_t + u_t \log \frac{u_t}{\mathcal{F}(u_t)} \right) (z, y) \quad (20)$$

带有终端条件

$$a_1(y; \mathbf{X}, u) = e^{-g(y)+g(X_1)}.$$

证明：利用引理 2.1，其中

$$f_t(x; y, u) := e^{-J_t(y; u) + J_t(x; u)}$$

$$e^{-J_t(y; u) + J_t(x; u)} = \mathbb{E}_{p^u(\mathbf{X} | X_t = x)} \left[e^{-g(y) + g(X_1)} - \int_t^1 \left(\partial_t e^{-J_t(y; u) + J_t(X_t; u)} + \sum_z u_t(z, X_t) e^{-J_t(y; u) + J_t(z; u)} \right) d\tau \right] \quad (89)$$

展开 (89) 中被积函数的第一项得到

$$\begin{aligned} & \partial_t e^{-J_t(y; u) + J_t(X_t; u)} \\ &= e^{-J_t(y; u) + J_t(X_t; u)} (-\partial_t J_t(y; u) + \partial_t J_t(X_t; u)) \\ &= e^{-J_t(y; u) + J_t(X_t; u)} \left(\sum_{z \neq y} \left(u_t^{\text{base}} - u_t + u_t \log \frac{u_t}{\mathcal{F}(u_t)} \right) (z, y) \right. \\ & \quad \left. - \sum_{z \neq X_t} \left(u_t^{\text{base}} - u_t + u_t \log \frac{u_t}{\mathcal{F}(u_t)} \right) (z, X_t) \right) \end{aligned} \quad \text{by (87)}$$

同样地，展开 (89) 中被积函数的第二项可得

$$\begin{aligned} & \sum_z u_t(z, X_t) e^{-J_t(y; u) + J_t(z; u)} \\ &= e^{-J_t(y; u) + J_t(X_t; u)} \sum_z u_t(z, X_t) e^{-J_t(X_t; u) + J_t(z; u)} \\ &= e^{-J_t(y; u) + J_t(X_t; u)} \sum_{z \neq X_t} u_t(z, X_t) \left(e^{-J_t(X_t; u) + J_t(z; u)} - e^{-J_t(X_t; u) + J_t(X_t; u)} \right) \quad \text{by (33)} \\ &= e^{-J_t(y; u) + J_t(X_t; u)} \sum_{z \neq X_t} \left(u_t \frac{u_t^{\text{base}}}{\mathcal{F}(u_t)} - u_t \right) (z, X_t) \quad \text{by (18)} \end{aligned}$$

综合起来，(89) 中的被积函数可以通过以下方式得到

$$\begin{aligned} & \partial_t e^{-J_t(y; u) + J_t(X_t; u)} + \sum_z u_t(z, X_t) e^{-J_t(y; u) + J_t(z; u)} \\ &= e^{-J_t(y; u) + J_t(X_t; u)} \left(\sum_{z \neq y} \left(u_t^{\text{base}} - u_t + u_t \log \frac{u_t}{\mathcal{F}(u_t)} \right) (z, y) \right. \\ & \quad \left. - \sum_{z \neq X_t} \left(u_t^{\text{base}} \left(1 - \frac{u_t}{\mathcal{F}(u_t)} \right) + u_t \log \frac{u_t}{\mathcal{F}(u_t)} \right) (z, X_t) \right) \\ &= e^{-J_t(y; u) + J_t(X_t; u)} \mathcal{G}_t(y, X_t; u) \end{aligned}$$

其中我们简写为

$$\mathcal{G}_t(y, X_t; u) := \sum_{z \neq y} \left(u_t^{\text{base}} - u_t + u_t \log \frac{u_t}{\mathcal{F}(u_t)} \right) (z, y)$$

$$- \sum_{z \neq X_t} \left(u_t^{\text{base}} \left(1 - \frac{u_t}{\mathcal{F}(u_t)} \right) + u_t \log \frac{u_t}{\mathcal{F}(u_t)} \right) (z, X_t) \quad (90)$$

也就是说，我们可以将 (89) 重新表述为

$$e^{-J_t(y;u)+J_t(x;u)} = \mathbb{E}_{p^u(\mathbf{X}|X_t=x)} \left[e^{-g(y)+g(X_1)} - \int_t^1 e^{-J_\tau(y;u)+J_\tau(X_\tau;u)} \mathcal{G}_\tau(y, X_\tau; u) d\tau \right]$$

因此，给定一条从时间 t 的 x 出发的模型轨迹 $\mathbf{X} \sim p^u(\cdot|X_t=x)$ ，可以通过求解以下反向常微分方程来估计期望：

$$\frac{d}{dt} a_t(y; \mathbf{X}, u) = e^{-J_t(y;u)+J_t(X_t;u)} \mathcal{G}(y, X_t; u) \quad a_1(y; \mathbf{X}, u) = e^{-g(y)+g(X_1)} \quad (91)$$

这意味着

$$\begin{aligned} e^{-J_t(y;u)+J_t(x;u)} &= \mathbb{E}_{p^u(\mathbf{X}|X_t=x)} [a_t(y; \mathbf{X}, u)] \\ &= \mathbb{E}_{p^u(\mathbf{X}|X_t=x)} \left[a_1(y; \mathbf{X}, u) - \int_t^1 e^{-J_\tau(y;u)+J_\tau(X_\tau;u)} \mathcal{G}_\tau(y, X_\tau; u) d\tau \right] \\ &= \mathbb{E}_{p^u(\mathbf{X}|X_t=x)} \left[a_1(y; \mathbf{X}, u) - \int_t^1 \mathbb{E}_{p^u(\bar{\mathbf{X}}|X_\tau)} [a_\tau(y; \bar{\mathbf{X}}, u)] \mathcal{G}_\tau(y, X_\tau; u) d\tau \right] \\ &= \mathbb{E}_{p^u(\mathbf{X}|X_t=x)} \left[a_1(y; \mathbf{X}, u) - \int_t^1 a_\tau(y; \mathbf{X}, u) \mathcal{G}_\tau(y, X_\tau; u) d\tau \right] \end{aligned} \quad (92)$$

也就是说，以下常微分方程在期望意义上与 (91) 中的方程等价：

$$\frac{d}{dt} a_t(y; \mathbf{X}, u) = a_t(y; \mathbf{X}, u) \mathcal{G}(y, X_t; u) \quad a_1(y; \mathbf{X}, u) = e^{-g(y)+g(X_1)} \quad (93)$$

这立即恢复了 (20) 中的动力学。

最后，令 $\bar{u}_t(y, x)$ 为匹配目标 (19) 对所有 $y \neq x$ 的解，

$$\bar{u}_t(y, x) = \arg \min_u \mathbb{E}_{p^u(\mathbf{X}|X_t=x)} [D_\phi(u_t(y, x), u_t^{\text{base}}(y, x) a_t(y; \mathbf{X}, u))]$$

直接应用匹配框架 (Lipman et al., 2024) 表明

$$\begin{aligned} \bar{u}_t(y, x) &= \mathbb{E}_{p^{\bar{u}}(\mathbf{X}|X_t=x)} [u_t^{\text{base}}(y, x) a_t(y; \mathbf{X}, \bar{u})] \\ &= u_t^{\text{base}}(y, x) e^{-J_t(y; \bar{u})+J_t(x; \bar{u})} \end{aligned} \quad \text{by (92)}$$

引用引理 3.1，我们推断 $\bar{u} = u^*$ 是最优速率。 $\square$

推论 3.3 (离散伴随)。在 $u := u^*$ 处，离散基本伴随的动力学简化为

$$-\frac{d}{dt} a_t(y; \mathbf{X}, u^*) = \sum_z u_t^{\text{base}}(z, y) a_t(z; \mathbf{X}, u^*), \quad a_1(y; \mathbf{X}, u^*) = e^{-g(y)+g(X_1)} \quad (21)$$

这与 (8) 中离散伴随的动力学一致。也就是说，由常微分方程解的唯一性，我们有 $a_t(y; \mathbf{X}, u^*) = \bar{u}_t(y; \mathbf{X})$ 。

证明。注意到当 $u := u^*$ 时，式 (90) 中定义的 $\mathcal{G}_t(y, x; u)$ 大大简化，

$$\mathcal{G}_t(y, x; u^*) = \sum_{z \neq y} (u_t^{\text{base}}(z, y) - u_t^*(z, y))$$

因此，离散基本伴随方程 (93) 的动力学简化为

$$\begin{aligned}
\frac{d}{dt}a_t(y; \mathbf{X}, u^*) &= a_t(y; \mathbf{X}, u^*)\mathcal{G}_t(y, x; u^*) \\
&= a_t(y; \mathbf{X}, u^*) \sum_{z \neq y} (u_t^{\text{base}}(z, y) - u_t^*(z, y)) \\
&= -a_t(y; \mathbf{X}, u^*)u_t^{\text{base}}(y, y) - \sum_{z \neq y} u_t^{\text{base}}(z, y)a_t(z; \mathbf{X}, u^*) \\
&= - \sum_z u_t^{\text{base}}(z, y)a_t(z; \mathbf{X}, u^*)
\end{aligned}$$

其中第三个等式是由于对所有 $z \neq y$,

$$\begin{aligned}
&\mathbb{E}_{p^*}(\mathbf{X}|X_t=x) [u_t^*(z, y)a_t(y; \mathbf{X}, u^*)] \\
&= u_t^*(z, y)e^{-J_t(y; u^*)+J_t(x; u^*)} \quad \text{by (92)} \\
&= u_t^{\text{base}}(z, y)e^{-J_t(z; u^*)+J_t(y; u^*)-J_t(y; u^*)+J_t(x; u^*)} \quad \text{by (49)} \\
&= u_t^{\text{base}}(z, y)e^{-J_t(z; u^*)+J_t(x; u^*)} \\
&= \mathbb{E}_{p^*}(\mathbf{X}|X_t=x) [u_t^{\text{base}}(z, y)a_t(z; \mathbf{X}, u^*)] \quad \text{by (92)}
\end{aligned}$$

即, u^* 之间存在细致平衡 $(z, y)a_t(y; \mathbf{X}, u^*)$ 和 $u_t^{\text{base}}(z, y)a_t(z; \mathbf{X}, u^*)$ w.r.t. optimal distribution, i.e.,

$$\mathbb{E}_{p^*}(\mathbf{X}|X_t=x) [u_t^*(z, y)a_t(y; \mathbf{X}, u^*)] = \mathbb{E}_{p^*}(\mathbf{X}|X_t=x) [u_t^{\text{base}}(z, y)a_t(z; \mathbf{X}, u^*)] \quad (94)$$

□

C 实验细节

C.1 合成示例

实现 对于 DAM 和 D1, 我们将 u^θ 参数化为大小为 (y, x) $92 \times 92 \times 91 \times 2$ 的张量的对数几率。

前两个维度对应所有可能的 $x \in X^{\text{discrete}} = \{\mathbf{m}, 1, \dots, 91\}^2$, 第三个维度对应给定 x 条件下所有可能的 $y \in \mathcal{X}^{\text{discrete}}$, 最后一个维度对应 (22) 中刻画的两类不同跳跃。对于 DAM, 我们使用 $K = 16$ 个样本估计 Checkerboard 中 (13) 式的离散伴随 $\hat{a}_t$, 使用 $K = 64$ 个样本估计 Pinwheel 中的离散伴随。由于这些问题维度较低, 我们始终使用在线策略样本计算 $\hat{a}_t$; 也就是说, 对于合成示例, 我们不维护重放缓冲区 $\mathcal{B}$ 。由于 D1 和 SVDD 的代码库分别针对推理和分子应用进行了专门化, 我们自行实现了它们在合成示例上的方法。所有方法均在 CPU 上使用 Adam (Kingma & Ba, 2015) 进行训练, 学习率为 1×10^{-2} 。

奖励函数 对于 Checkerboard, 我们考虑如下奖励函数: 将对角块加权 4.6, 超对角和次对角块加权 4.0, 其他非对角块加权 3.4。对于 Pinwheel, 我们将三个圆分别重新加权为 0.5, -1 和 -20。

C.2 数学推理任务

推理 我们采用与赵等人 (Zhao et al., 2025) 相同的解码策略。为解码 N 个标记的序列, 我们使用 $N/2$ 个去噪步骤, 并在每一步中揭示 2 个标记。他们采用半自回归解码策略 (Nie et al., 2025) 从左到右按块解码, 发现该策略能带来略优的性能。具体而言, 序列被划分为长度为 32 的块。在每一步中, 当前块内置信度最高的 2 个标记被揭示。一旦当前块中的所有标记均被揭示, 我们便移至下一个 32 标记的块。

实现 对于 D1，我们使用其官方实现⁴，该实现基于 TRL 库 (von Werra et al., 2020)。我们在相同的代码库之上构建了 DAM 实现。两种微调方法均采用低秩适配 (Low-Rank Adaptation, LoRA) (Hu et al., 2022)，秩为 $r = 128$ ，缩放因子为 $\alpha = 64$ 。对于全部四个任务，DAM 使用 $K = 12$ 个样本来估计 (13) 式中的离散伴随 $\hat{a}_t$ 。

训练 所有方法均在 8 块 Nvidia H100 GPU 上训练，序列长度为 128 个标记，每 GPU 批大小为 12，梯度累积步数为 2。我们使用 AdamW 优化器 (Loshchilov & Hutter, 2019)，参数为 $\beta_1 = 0.9$, $\beta_2 = 0.99$ ，权重衰减为 0.1，学习率为 3×10^{-6} ，梯度裁剪阈值为 0.2。对于两种方法，我们分别在 GSM8K 和 MATH500 上微调 3000、3500 和 4000 步 (梯度更新次数)。

奖励函数 我们采用与赵等人 (Zhao et al., 2025) 相同的奖励函数，为完整性起见，下文对其进行描述。

• **GSM8K** 我们在 GSM8K 数据集的训练划分⁵上进行强化学习，并在测试划分上评估。我们采用由五个分量组成的复合奖励函数，遵循 unsloth 的奖励函数实现：⁶

- **XML 结构奖励**：奖励具有推理和答案标签的正确格式。每个正确放置的开始和结束标签奖励 +0.125。结束标签之后每个多余标记给予 -0.001 的小惩罚。
- **软格式奖励**：对符合以下模式的响应给予 0.5 分奖励：`<reasoning>...(内容)...</reasoning> <answer>...(内容)...</answer>`
- **严格式奖励**：对严格遵守规定格式并包含适当换行的响应给予 0.5 分奖励。
- **整数答案奖励**：若提取的答案为有效整数，则给予 0.5 分奖励。
- **正确性奖励**：若提取的答案与标准答案完全一致，则给予 2.0 分奖励。

在表 2 中，格式奖励 $r_{\text{format}}(x)$ 对应于前三个前述奖励的总和。

• **MATH500** 我们在 MATH 数据集的训练划分上进行训练。⁷与 GSM8K 类似，我们采用一个复合奖励函数，包括

- **格式奖励**：我们奖励 `<answer></answer>` 标签的存在以及 `\boxed`，如下：如果答案标签存在且内部有 `\boxed`，1.00 如果答案标签存在但内部没有 `\boxed`，0.75 如果答案标签不存在，但 `\boxed` 存在，以及 0.25 如果既没有答案标签，也没有 `\boxed` 存在
- **正确性奖励**：如果正确答案在 `\boxed` 中，我们奖励 2.0
- **倒计时** 我们在来自 TinyZero 项目 (Pan 等人, 2025) 的数据集⁸的训练划分上进行训练，限制为仅使用三个数字的实例。并且我们在 256 个合成生成的、包含 3 个数字的倒计时问题上进行评估。我们实现了一个奖励函数，检查由给定数字构造的算术表达式是否达到目标值：
- **格式奖励**：当方程使用了正确的数字但未达到目标时，给予 0.1 分
- **正确性奖励**：当方程等于目标且恰好使用了可用数字时，给予 1.0 分

⁴ <https://github.com/dllm-reasoning/d1> ⁵ <https://huggingface.co/datasets/openai/gsm8k> ⁶ <https://unsloth.ai/blog/r1-reasoning> ⁷ <https://huggingface.co/datasets/ankner/math-500> ⁸ <https://huggingface.co/datasets/Jiayi-Pan/Countdown-Tasks-3to4>

• 数独 我们使用与 (Zhao 等人, 2025) 相同的 4x4 数独示例生成数据集, 保留最后 500 个示例用于评估, 其余用于训练。我们采用一种奖励函数, 对正确填入单元格给予奖励。

- **正确性奖励:** 奖励计算为正确填入单元格的平均数量。

C.3 附加实验




图 3 在合成示例上改变 K 。我们研究了在合成示例上改变样本数量 K 的影响。较大的 K 值由于 (13) 中重要性加权离散伴随的低偏差和低方差而带来更快的收敛。




图 4 GSM8k 和 Countdown 上的奖励曲线。DAM 在最大化 (23) 中的奖励 r 方面比 D1 更有效。




图 5 数独上的准确率与墙钟时间。我们比较 D1 和 DAM, 但将墙钟时间 (小时) 绘制在 x 轴上。

表 4 来自基础模型和两个微调模型的 GSM8K 生成样本，均以相同未见提示为条件。正确和错误答案已着色。

提示: Jaime 是一家目前雇有 100 名员工的公司的计算机程序员。高级程序员比初级程序员每月多 400 美元。如果初级程序员人数占总员工数的 2/5，且每人每月工资为 2000 美元，请计算公司每月支付给所有程序员的总金额。答案: 224000		
Response: LLaDA-8B-Instruct	LLaDA-8B-Instruct w/ DAM	LLaDA-8B-Instruct w/ D1
<推理> 初级程序员的数量是 $2/5 * 100 = 40$。高级程序员的数量是 $100 - 40 = 60$。初级程序员的总工资是 $40 * \\$2000 = \\80000。高级程序员的总工资是 $60 * (\\$2000 +$ $\\$400) = \\144000.</reasoning> <answer> 2240000000 </answer>	<reasoning> The number of junior programmers is $2/5 * 100 = 40$. The number of senior programmers is $100 - 40 = 60$. Each senior programmer is paid $\\$2000 + \\$400 = \\$2400$ per month. The total amount paid to all programmers per month is $40 * \\$2000 + 60 * \\$2400 = \\$224000$. </reasoning> <answer> 224000 </answer>	<reasoning> The number of Junior programmers is $2/5 * 100 = 40$. The number of Senior programmers is $100 - 40 = 60$。公司每月支付给所有程序员的总金额是 $40*2000$ $+ 60*2400$.</reasoning> <answer> 94000 </answer>
提示: 约翰雇佣一家驾驶服务公司每天送他去上班。他的工作地点距离 30 英里，他每天必须往返。他每周工作 5 天，每年工作 50 周。每英里收费 2 美元，他还每月给司机 150 美元的奖金。他每年支付多少驾驶费用? 答案: 31800		
Response: LLaDA-8B-Instruct	LLaDA-8B-Instruct w/ DAM	LLaDA-8B-Instruct w/ D1
<推理> 约翰单程驾驶 30 英里，所以他每天总共驾驶 30 英里。他每周驾驶 5 天，每天 30 英里，所以他每周驾驶 150 英里。每年有 50 周，所以他每年驾驶 7500 英里。每英里收费 2 美元，所以他每年支付 15000 美元。他还每月给司机 150 美元的奖金。<推理> <答案> 15000 </答案>	<reasoning> John drives $30 * 2 = 60$ miles per day. He drives $60 * 5 = 300$ miles per week. He drives $300 * 50 = 15000$ miles per year. He pays $15000 * 2 = \\$30000$ for the miles. He pays $30000 + 150 * 12 = \\$31800$ per year.</reasoning> <answer> 31800 </answer>	<reasoning> John drives 60 miles each way so he drives 120 miles per day He drives 600 miles per week * 50 weeks = 30,000 miles per year He pays 30,000 miles * \$2/mile = \$60,000 per year.</reasoning> <answer> 60000 </answer>
提示: 鲍勃负责一家大型酒店的洗衣工作。每个房间有两张床单、一条被子、枕套数量是床单的两倍，毛巾数量是枕套的两倍。80 个房间里总共有多少件衣物? 答案: 1200		
Response: LLaDA-8B-Instruct	LLaDA-8B-Instruct w/ DAM	LLaDA-8B-Instruct w/ D1
<reasoning> Each room has - 2 sheets - 1 comforter - 枕套数量是床单的两倍: $2 * 2 = 4$ 个枕套 - 毛巾数量是枕套的两倍: $4 * 2 = 8$ 条毛巾 所以，每个房间总共有 $2 + 1 + 4 + 8 = 15$ 件衣物。 对于 80 个房间，衣物总数为 $80 * 15 = 1200$。 </推理> <答案> 720	<reasoning> Each room has 2 sheets + 1 comforter + 2 * 2 pillow cases + 2 * 2 * 2 towels = 3 + 4 + 8 = 15 pieces of laundry. </reasoning> <answer> 1200 </answer>	<reasoning> Each room has 2 sheets, 1 comforter, $2*2 = 4$ pillow cases, and $2*4 = 8$ towels. That, each room has $2+1+4+8 = 15$ pieces of laundry. So, 80 rooms have $15*80 = 1200$ </reasoning> <answer> 1200 </answer>

表 5 基础模型与两个微调模型在 MATH500 上生成的样本，所有样本均基于相同的未见提示。正确与错误答案已着色。

提示: 1992 年，在意大利可以用 1200 里拉购买一勺冰淇淋。同样的冰淇淋在美国售价为 1.50 美元。按照里拉与美元之间的等价汇率，1,000,000 里拉相当于多少美元？ 答案: 1250		
Response: LLaDA-8B-Instruct	LLaDA-8B-Instruct w/ DAM	LLaDA-8B-Instruct w/ D1
<推理> 要找出 1,000,000 里拉相当于多少美元，我们需要知道 1 里拉与 1 美元之间的汇率。根据已知信息，1200 里拉相当于 1.50 美元。因此，1,000,000 里拉相当于 $1,000,000 / 1200 = 833$ 美元。 </re 推理> <答案> 833 </答案>	<reasoning> To determine how many dollars are equivalent to 1,000,000 lire, we need to know the exchange rate between 1 lire and 1 dollar. Since 1200 lire is equivalent to \$1.50, the equivalent exchange rate is 1 lire = \$1.50 / 1200 = \$0.0125. Therefore, 1,000,000 lire is equivalent to: </reasoning> <answer> 1250 </answer>	<reasoning> To find how many dollars are equivalent to 1,000,000 lire, we need to know the exchange rate between 1 lire and 1 dollar. Given that 1200 lire is equivalent to \$1.50, we can deduce that 1 lire is equivalent to \$1.50 / 1200 = \$0.00125. </reasoning> <answer> 125 </answer>
Prompt: If $y = \frac{27x^2+9x+3}{27x^3+9x^2+3x+1}$, 在 y 取何值时会出现水平渐近线? Answer: 0		
Response: LLaDA-8B-Instruct	LLaDA-8B-Instruct w/ DAM	LLaDA-8B-Instruct w/ D1
<reasoning> 要找出函数的水平渐近线，我们需要比较分子和分母的次数。多项式的次数是多项式中 x 的最高次幂。在此情况中，分子的次数为 2，分母的次数为 3。由于分子的次数小于分母的次数，水平渐近线位于 $y = 0$。因此，y 的值为 0 时会出现水平渐近线。 </推理> <答案> 0 </答案>	<reasoning> To determine the horizontal asymptote of the function $y = \frac{27x^2+9x+3}{27x^3+9x^2+3x+1}$, we need to analyze the degrees of the numerator and the denominator. The degree of a polynomial is the highest power of x in the polynomial. In this case, the degree of the numerator is 2 and the degree of the denominator is 3. Since the degree of the numerator is less than the degree of the denominator, there is no horizontal asymptote. </reasoning> <answer> 0 </answer>	<reasoning> To find the horizontal asymptote of the function, we need to compare the degrees of the numerator and the denominator. The degree of a polynomial is the highest power of x in the polynomial. Here, the degree of the numerator is 2 and the degree of the denominator is 3. When the degrees of the numerator and the denominator are different, the horizontal asymptote is determined by the ratio of the leading coefficients. Therefore, the horizontal asymptote is $\frac{27}{27}$. </reasoning> <answer> $\frac{1}{3}$ </answer>
Prompt: Find the sum of the real roots of $x^4 - 80x - 36 = 0$. Answer: 4		
Response: LLaDA-8B-Instruct	LLaDA-8B-Instruct w/ DAM	LLaDA-8B-Instruct w/ D1
<reasoning> We can rewrite the given equation as $x^4 - 80x - 36 = (x^2 - 41)(x + 1) = 0$。由此，我们得到 $x^2 = 41$ 或 $x = -1$。由于 $x^2 = 41$ 没有实数解，唯一的实数根是 $x = -1$。因此，实数根之和为 </reasoning> $-1 + -1 = -2$。 <answer> -2 </answer>	<reasoning> The given equation is $x^4 - 80x - 36 = 0$. We can rewrite this as $(x^2 - 20)^2 = 0$. Solving $x^2 - 20 = 0$, we get $x^2 = 20$, which gives $x = \pm 5$. Therefore, the sum of the real roots is $5 + (-2 - 5) = 0$. </reasoning> <answer> 0 </answer>	<reasoning> The quartic equation $x^4 - 80x - 36 = 0$ can be rewritten as $(x^2 - 20x - 36)(x^2 + 20x + 36) = 0$. 这两个因式各有两个实根，所以实根之和为各因式根之和，即 20。因此，该四次方程的实根之和为 0。 </reasoning> <answer> 0 </answer>

表 6 基础模型与两个微调模型在倒计时任务上生成的样本，均以相同未见提示为条件。正确与错误答案已着色。

Prompt: Using only the numbers [15, 78, 62], create an arithmetic expression that evaluates to exactly 1. You must use all numbers from the list, and each number must be used exactly once. You may use the operations +, -, *, and / as needed. Answer: 78 - 62 - 15		
Response: LLaDA-8B-Instruct	LLaDA-8B-Instruct w/ DAM	LLaDA-8B-Instruct w/ D1
<reasoning> 要使用数字 [15, 78, 62] 构造一个恰好等于 1 的算术表达式，需要考虑加、减、乘、除运算。我们可以先尝试以某种方式组合这些数字，以便达到 1。一种可能的方法是直接使用这些数字形成其他数字，再进一步操作以达到 1。另一种方法是组合使用这些数字的运算来得到所需的 1。</reasoning> To create an arithmetic expression that evaluates to exactly 1 using the numbers [15, 78, 62], we need to find the correct combination of the operations +, -, *, and /. One possible approach is to use the numbers in a combination of operations to achieve the desired 1. </reasoning>	<reasoning> To create an arithmetic expression that evaluates to exactly 1 using the numbers [15, 78, 62], we need to find the correct combination of the operations +, -, *, and /. </reasoning> <answer> 78 / 62 - 15 </answer>	<reasoning> To create an arithmetic expression that evaluates to exactly 1 using the numbers [15, 78, 62], we need to consider the operations of addition, subtraction, multiplication, and division. We can start by trying to combine the numbers in a way that leads us to the target value. One possible approach is to use the operations strategically to break down the problem into smaller parts. can we find a combination of operations that will allow us to reach the target value of 1? </reasoning> <answer> 78/15-62/15 </answer>
Prompt 仅使用数字 [19, 3, 5]，创建一个恰好等于 52 的算术表达式。必须使用列表中的所有数字，且每个数字恰好使用一次。可根据需要使用 +、-、*、/ 运算。答案：19 * 3 - 5		
Response: LLaDA-8B-Instruct	LLaDA-8B-Instruct w/ DAM	LLaDA-8B-Instruct w/ D1
<reasoning> 要使用数字 [19, 3, 5] 构造一个恰好等于 52 的算术表达式，需要考虑加、减、乘、除运算。我们可以先将 19 和 3 相乘，得到 57。然后从 57 中减去 5，得到 52。该表达式恰好使用三个数字各一次，并等于 52。</reasoning> <answer> 19 * 3 - 5 </answer>	<reasoning> To create an arithmetic expression that evaluates to exactly 52 using the numbers [19, 3, 5], we need to consider how to combine these numbers using the operations +, -, *, and / to achieve 52. </reasoning> <answer> 19 * 3 - 5 </answer>	<reasoning> To create an arithmetic expression that evaluates to 52 using the numbers [19, 3, 5], we need to consider the operations of addition, subtraction, multiplication, and division. We can start by trying to combine the numbers in a way that leads us to reach 52. One way could be to use multiplication and addition to We can try to 95-5=90 90-3=87 87-19=68 </reasoning> <answer> 195-3-5-9 </answer>