

离散伴随薛定谔桥采样器

Wei Guo^{1*} Yuchen Zhu^{1‡} Xiaochen Du^{2‡} Juno Nam^{2‡} Yongxin Chen^{1†} 拉斐尔·戈麦斯-邦巴雷利^{2‡}
Guan-Horng Liu^{3†} Molei Tao^{1†} Jaemoo Choi^{1*}

摘要

学习离散神经采样器因缺乏梯度与组合复杂度而颇具挑战。尽管随机最优控制（SOC）与薛定谔桥（SB）提供了原则性解决方案，但诸如伴随匹配（AM）这类在连续域中表现出色的高效随机最优控制求解器，在离散空间中仍未得到探索。本文通过揭示伴随匹配的核心机制与状态空间无关，弥合了这一差距，并提出了离散伴随薛定谔桥采样器（Discrete ASBS），一个将伴随匹配与伴随薛定谔桥采样器（ASBS）扩展到离散空间的统一框架。理论上，本文分析了离散薛定谔桥问题的最优性条件及其与随机最优控制的联系，识别出状态空间上实现该扩展所必需的循环群结构。实验上，离散伴随薛定谔桥采样器在训练效率与可扩展性方面具有显著优势，同时取得了有竞争力的样本质量。

1. 引言

从未归一化分布中采样是计算统计学（Liu, 2008; Brooks et al., 2011）、贝叶斯推断（Gelman et al., 2013）以及统计力学（Landau & Binder, 2014）中的基本问题。目标是从状态空间 $\mathcal{X}$ 上的目标分布 ν 中抽取样本，其中 $\nu(x) \propto e^{-\beta E(x)}$ 通过能量函数 $E: \mathcal{X} \rightarrow \mathbb{R}$ 和逆温度 $\beta > 0$ 指定。在具有复杂能量景观的高维环境中，马尔可夫链蒙特卡洛（MCMC）等传统方法存在混合缓慢和可扩展性差的问题。神经采样器的最新进展通过用深度神经网络参数化采样动力学来应对这些挑战，即使没有来自目标的独立同分布样本也能实现高效学习。关键在于，这些方法提供了摊销推断，用预训练模型的快速生成取代了昂贵的马尔可夫链蒙特卡洛迭代。

对于连续状态空间 $\mathcal{X} = \mathbb{R}^D$ ，神经采样器通过多种方法取得了显著成功（He 等, 2025; Sanokowski 等, 2025b），包括序贯蒙特卡洛（Phillips 等, 2024）、护航传输（Vargas 等, 2024; Albergo 与 Vanden-Eijnden, 2025; Chen 等, 2025; Blessing 等, 2025b; Du 等, 2025）、随机最优控制（SOC, Zhang 与 Chen (2022); Vargas 等 (2023); Richter 与 Berner (2024)）、并行回火（Rissanen 等, 2025; Akhound-Sadegh 等, 2025; Zhang 等, 2026）等。在 SOC 方法中，伴随匹配（**AM**, Domingo-Enrich 等 (2025a); Havens 等 (2025)）已成为一种强大的求解器，支撑了伴随薛定谔桥采样器（ASBS, Liu 等 (2025a)）框架，该框架具有快速收敛、可扩展性和参考动力学灵活性。然而，**AM** 从根本上依赖于连续微积分，使其向离散状态空间的扩展极具挑战性。

受这些成功的启发，近期工作探索了基于连续时间马尔可夫链（CTMC）的离散神经采样器，提出了基于护航传输（Holderrieth 等, 2025; Ou 等, 2025b）和 SOC 公式（Zhu 等, 2025a; Guo 等, 2026）的类似方法。尽管取得了这些进展，薛定谔桥（SB）问题——一个对最优传输（Léonard, 2014; Chen 等, 2016b; 2021）和连续扩散模型（Chen 等, 2021; De Bortoli 等, 2021; Chen 等, 2022; Liu 等, 2022; Shi 等, 2023）至关重要的分布约束优化框架——在离散空间中仍未得到充分发展（Ksenofontov 与 Korotin, 2025; Kim 等, 2025）。离散 SB 与 SOC 之间的理论联系尚未完全建立，且没有离散 SOC 求解器能达到 * 核心贡献者，同等贡献 ‡ 共同第二作者，同等贡献 † 同等指导，按字母顺序排列 1 佐治亚理工学院 2 麻省理工学院 3 Meta 的 FAIR。通讯作者：郭伟 <wei.guo@gatech.edu>，崔在武 <jchoi843@gatech.edu> 的效率。

表 1. 连续和离散状态空间中去噪匹配与伴随匹配的概念比较。去噪匹配适用于一般参考动力学，而伴随匹配需要加性噪声。

	Continuous state space $\mathcal{X} = \mathbb{R}^D$	Discrete state space $\mathcal{X} = \mathbb{Z}_N^D$
Ref. dyn. p^r	$dX_t = b_t(X_t)dt + \sigma_t dW_t, X_0 \sim \mu$	CTMC (X_t) with transition rate $(r_t), X_0 \sim \mu$
Ctrl. dyn. p^u	$dX_t = (b_t + \sigma_t u_t)(X_t)dt + \sigma_t dW_t, X_0 \sim \mu$	CTMC (X_t) with transition rate $(u_t), X_0 \sim \mu$
SB Prob.	$\min_{u \text{ s.t. } X_1 \sim \nu} \mathbb{E} \left[\int_0^1 \frac{1}{2} \ u_t(X_t)\ ^2 dt \right]$	$\min_{u \text{ s.t. } X_1 \sim \nu} \mathbb{E} \left[\int_0^1 \sum_{y \neq X_t} (u_t \log \frac{u_t}{r_t} + r_t - u_t)(y, X_t) dt \right]$
SOC Prob.	$\min_u \mathbb{E} \left[\int_0^1 \frac{1}{2} \ u_t(X_t)\ ^2 dt + \log \frac{\hat{\varphi}_1}{\nu}(X_1) \right]$	$\min_u \mathbb{E} \left[\int_0^1 \sum_{y \neq X_t} (u_t \log \frac{u_t}{r_t} + r_t - u_t)(y, X_t) dt + \log \frac{\hat{\varphi}_1}{\nu}(X_1) \right]$
Opt. Ctrl.	$u_t^*(x) = \sigma_t \nabla \log \varphi_t(x)$	$u_t^*(y, x) = r_t(y, x) \frac{\varphi_t(y)}{\varphi_t(x)}$
Corrector	$\nabla \log \hat{\varphi}_1(x)$	$\frac{\hat{\varphi}_1(y)}{\hat{\varphi}_1(x)}$
Example of Additive Noise	$b_t \equiv 0 \Rightarrow \begin{cases} p_{1 t}^r(x_1 x) = q_t(x_1 - x) \\ q_t(\varepsilon) = \mathcal{N}(\varepsilon; 0, \tilde{\sigma}_t^2 I) \end{cases}$	$r_t(y, x) = \frac{\gamma_t}{N} 1_{d_H(x,y)=1} \Rightarrow \begin{cases} p_{1 t}^r(x_1 x) = q_t(x_1 - x) \\ q_t(\varepsilon) = A(t, 1)^{d_H(\varepsilon, 0)} B(t, 1)^{D-d_H(\varepsilon, 0)} \end{cases}$
Denoising Matching	$\begin{aligned} \nabla \log \varphi_t(x) &= \mathbb{E}_{p_{1 t}^*(x_1 x)} \nabla_x \log p_{1 t}^r(x_1 x) \quad (1) \\ \nabla \log \hat{\varphi}_1(x) &= \mathbb{E}_{p_{0 1}^*(x_0 x)} \nabla_x \log p_{1 0}^r(x x_0) \quad (2) \end{aligned}$	$\begin{aligned} \frac{\varphi_t(y)}{\varphi_t(x)} &= \mathbb{E}_{p_{1 t}^*(x_1 x)} \frac{p_{1 t}^r(x_1 y)}{p_{1 t}^r(x_1 x)} \\ \frac{\hat{\varphi}_1(y)}{\hat{\varphi}_1(x)} &= \mathbb{E}_{p_{0 1}^*(x_0 x)} \frac{p_{1 0}^r(y x_0)}{p_{1 0}^r(x x_0)} \end{aligned}$
Adjoint Matching	$\begin{aligned} \nabla \log \varphi_t(x) &= \mathbb{E}_{p_{1 t}^*(x_1 x)} \nabla \log \varphi_1(x_1) \quad (3) \\ \nabla \log \hat{\varphi}_1(x) &= \mathbb{E}_{p_{0 1}^*(x_0 x)} \nabla \log \hat{\varphi}_0(x_0) \quad (4) \end{aligned}$	$\begin{aligned} \frac{\varphi_t(y)}{\varphi_t(x)} &= \mathbb{E}_{p_{1 t}^*(x_1 x)} \frac{\varphi_1(y+x_1-x)}{\varphi_1(x_1)} \\ \frac{\hat{\varphi}_1(y)}{\hat{\varphi}_1(x)} &= \mathbb{E}_{p_{0 1}^*(x_0 x)} \frac{\hat{\varphi}_0(y+x_0-x)}{\hat{\varphi}_0(x_0)} \end{aligned}$

连续 AM。尽管近期工作 So 等人 (2026) 尝试将 AM 适配到掩码离散扩散，但其方法产生了复杂的训练目标，使得一个原理化且高效的离散 AM 框架仍是一个开放性挑战。

本文为离散状态空间上的薛定谔桥 (SB) 与随机最优控制 (SOC) 建立了统一的理论框架，提出了离散伴随薛定谔桥采样器 (DASBS)。我们推导了离散 SB 问题的最优性条件，其在结构上与连续情形相对应，并通过新颖的控制器与校正器学习目标将 AM 扩展到离散域。我们的方法揭示了状态空间上的群结构与均匀参考动态是必要条件——这些要求与连续 AM 中的加性噪声假设相对应。本文的主要贡献如下：

一、统一的离散框架： 本文将离散神经采样形式化为连续时间马尔可夫链 (CTMC) 的 SB 问题，并建立了其等价的 SOC 表述。

二、推广伴随匹配： 本文识别了 AM 背后与状态空间无关的原理，为超越连续空间的扩展提供了概念上的清晰性。

三、离散 ASBS： 本文提出了离散 ASBS，这是一种原理化的算法，在伴随匹配与校正器匹配之间交替进行，其推导基于学习目标的变分刻画。

四、实证验证： 本文在高维离散基准上验证了 DASBS，展示了具有竞争力的性能和效率。

2. 预备知识

连续状态空间上的扩散采样器 $\mathcal{X} = \mathbb{R}^D$ 基于平衡动力学的 MCMC 采样，例如朗之万蒙特卡洛，在目标分布复杂时通常混合缓慢。生成建模中非平衡测度传输的最新进展，如扩散模型 (Song 等人, 2021)，推动了基于受控随机微分方程 (SDE) 的采样方法，通常称为扩散神经采样器。采样动力学由 SDE 描述：

$$p^u : dX_t = (b_t + \sigma_t u_t)(X_t)dt + \sigma_t dW_t, X_0 \sim \mu, \quad (5)$$

其中 $b : [0, 1] \times \mathcal{X} \rightarrow \mathcal{X}$ 是基础漂移， $\sigma : [0, 1] \rightarrow \mathbb{R}_{>0}$ 是噪声调度， μ 是初始源分布。给定 (b, σ, μ) ，目标是学习参数化控制 $u : [0, 1] \times \mathcal{X} \rightarrow \mathcal{X}$ ，使得 X_1 的边缘分布与目标分布 ν 匹配。本文使用 p^u 表示由该 SDE 在控制 u 下诱导的路径测度。形式上， $p^u(X[0, 1])$ 可以视为当划分 $0 = t_0 < t_1 < \dots < t_K$ 时 $(X_{t_0}, X_{t_1}, \dots, X_{t_K})$ 的联合分布的极限

$t_K = 1$ 变得越来越细，严格的定义通过 Radon-Nikodym 导数 (RND) 给出。

连续状态空间上的薛定谔桥问题 一种制定扩散采样器学习的方法是通过分布约束的最优传输问题，称为薛定谔桥 (SB) 问题 (Léonard, 2014; Chen 等人, 2016b) :

$$\min_{u \text{ s.t. } X_1 \sim \nu} \left\{ \text{KL}(p^u \| p^r) = \mathbb{E}_{X \sim p^u} \int_0^1 \frac{1}{2} \|u_t(X_t)\|^2 dt \right\}, \quad (6)$$

其中 p^u 为受控路径测度 (5)，而 p^r 为零控制参考动力学的路径测度 ($u \equiv 0$)。最优控制可由以下方式刻画

$$u_t^*(x) = \sigma_t \nabla \log \varphi_t(x), \quad (7)$$

其中薛定谔桥 (Schrödinger Bridge) 势函数 $(\varphi_t, \hat{\varphi}_t)$ (在乘法常数范围内) 通过关于参考转移核函数 p^r 的时间积分 $\int_0^t p_{t|s}^r(y|x)$ 来定义:

$$\begin{aligned} \varphi_t(x) &= \int p_{1|t}^r(y|x) \varphi_1(y) dy, & \varphi_0(x) \hat{\varphi}_0(x) &= \mu(x); \\ \hat{\varphi}_t(x) &= \int p_{t|0}^r(x|y) \hat{\varphi}_0(y) dy, & \varphi_1(x) \hat{\varphi}_1(x) &= \nu(x). \end{aligned}$$

SB 的随机最优控制特性 薛定谔桥 (SB) 公式与随机最优控制 (SOC) 之间的一个有趣联系通过最优控制的刻画得以揭示 u^* 。如 Dai Pra (1991); Chen 等人 (2016b); Liu 等人 (2025a), u^* (7) 所示，它也是以下随机最优控制问题的解:

$$\min_u \mathbb{E}_{X \sim p^u} \left[\int_0^1 \frac{1}{2} \|u_t(X_t)\|^2 dt + \log \frac{\hat{\varphi}_1(X_1)}{\nu(X_1)} \right]. \quad (8)$$

(8) 强调 SB (6) 允许一种 SOC 解释，其中终端边际约束通过终端成本 $\log \frac{\hat{\varphi}_1}{\nu}$ 进行编码。这一视角为随机分支理论与自组织临界性表述之间搭建了有益的桥梁。

伴随薛定谔 薛定谔桥采样器 (ASBS, Liu 等人 (2025a)) 当 $b_t \equiv 0$ 时，参考动力学退化为布朗运动。在此设定下，参考转移核具有可加性，即从 $p_{1|t}^r(\cdot|x)$ 采样可通过在 x , i.e., 上添加噪声 $\epsilon \sim q_t$ 来实现

$$p_{1|t}^r(y|x) = q_t(y - x), \quad q_t = \mathcal{N}(0, \tilde{\sigma}_t^2 I), \quad (9)$$

其中 $\tilde{\sigma}_t^2 = \int_t^1 \sigma_s^2 ds$ 。重要的是，这种可加性质在简化相关的随机最优控制 (SOC) 问题中起着核心作用 (8)；它产生了易于处理的条件下分布 $p_{1|t}^r$ ，并使得最优性条件中出现的量能够有显式表达式 (Havens 等, 2025)。利用这一结构，Liu 等 (2025a) 推导了伴随匹配 (AM) 恒等式 (3) 和 (4)，以及相应的去噪匹配 (DM) 恒等式 (1) 和 (2)，并提出了一种基于 (2) 和 (3) 的交替过程来学习控制器和校正器，该过程在适当的正则性条件下收敛。详见表格 1 的左侧部分。

与无记忆情形的联系 (伴随采样) 早期工作伴随采样 (Havens 等, 2025) 考虑了一种特殊情况，其中参考路径测度 p^r 是无记忆的，i.e. $p_{0,1}^r(x, y) = p_0^r(x) p_1^r(y)$ ，在此情况下可以证明 $\hat{\varphi}_1 \propto p^r$ 。因此，校正器 $\nabla \log \hat{\varphi}_1$ 是已知的，学习问题简化为控制器的单一回归目标。从这个角度看，ASBS 是伴随采样的推广，它放宽了无记忆假设，允许非平凡的边界耦合。Liu 等 (2025a) 还观察到，与无记忆参考动态相比，非无记忆参考动态能够降低噪声水平，从而提供更好的性能。

3. 连续时间马尔可夫链的薛定谔桥与随机最优控制理论

在本节中，我们介绍连续时间马尔可夫链 (CTMC) 的薛定谔桥 (SB) 问题，作为 (6) 的离散类比。然后，我们将相应的 SB 和 SOC 理论从连续状态空间扩展到离散 CTMC (Léonard, 2014)。特别地，我们推导出最优转移速率 u^* 的最优性条件，类似于 (7)，并按照 (8) 的精神构建一个相关的 SOC 问题。

3.1. 问题设定

连续时间马尔可夫链 在本文中，我们将离散状态空间 $\mathcal{X}$ 视为长度为 D 的序列集合，其中每个位置有 N 种可能状态 $[N] := \{1, 2, \dots, N\}$, i.e., $\mathcal{X} = [N]^D$. $\mathbf{A}$ 。连续时间马尔可夫链 (CTMC) $(X_t)_{t \in [0, 1]}$ 是一个取值于 $\mathcal{X}$ 的随机过程，其特征由其转移速率 $r = (r_t(y, x))_{t \in [0, 1]}^{x, y \in \mathcal{X}}$ 定义，定义为

$$r_t(y, x) = \lim_{h \rightarrow 0} \frac{\Pr(X_{t+h} = y | X_t = x) - 1_{y=x}}{h},$$

其中 $1_A \in \{0, 1\}$ 是命题 A 的指示函数。

离散状态空间上的薛定谔桥问题 沿用第 2 节，我们通过为连续时间马尔可夫链 (CTMC) 构建薛定谔桥问题来解决采样问题，其最优路径测度 p^* 满足边界边缘约束 $p_0^* = \mu$ 和 $p_1^* = \nu$ 。令 $r_t(y, x)$ 和 $u_t(y, x)$ 分别表示参考转移速率和受控转移速率，并记 p^r 和 p^u 为它们诱导的路径测度。我们假设共同的初始分布 $p_0^r = p_0^u = \mu$ 。考虑以下连续时间马尔可夫链的薛定谔桥问题：

$$\min_{u \text{ s.t. } p_1^u = \nu} \left\{ \text{KL}(p^u \| p^r) = \mathbb{E}_{X \sim p^u} \int_0^1 \sum_{y \neq X_t} \left(u_t \log \frac{u_t}{r_t} + r_t - u_t \right) (y, X_t) dt \right\}. \quad (\text{SB})$$

接下来，我们将明确该薛定谔桥问题与相应的随机最优控制 (SOC) 表述之间的联系，与式 (8) 直接类比。

3.2. 连续时间马尔可夫链的薛定谔桥与随机最优控制理论

最优转移速率的刻画 我们现在刻画求解 (SB) 的最优转移速率。以下结果通过一对时间依赖的势函数给出了最优转移速率的显式描述，这对势函数的作用类似于连续状态空间中的薛定谔桥势函数。证明见附录 B.2。

定理 3.1. 最优转移速率 u^* 对于 (SB) 可表示为

$$u_t^*(y, x) = \frac{\varphi_t(y)}{\varphi_t(x)} r_t(y, x), \quad \forall y \neq x, \quad (10)$$

其中 SB 势函数 $(\varphi_t, \hat{\varphi}_t)$ 满足

$$\forall 0 \leq s < t \leq 1 : \begin{cases} \varphi_s(x) = \sum_y p_{t|s}^r(y|x) \varphi_t(y), & (11) \\ \hat{\varphi}_t(x) = \sum_y p_{t|s}^r(x|y) \hat{\varphi}_s(y), & (12) \end{cases}$$

and the optimal path measure p^* satisfies

$$p_t^*(x) = \varphi_t(x) \hat{\varphi}_t(x), \quad \frac{p_{t|s}^*(x|y)}{p_{t|s}^r(x|y)} = \frac{\varphi_t(x)}{\varphi_s(y)}, \quad \frac{p_{s|t}^*(y|x)}{p_{s|t}^r(y|x)} = \frac{\hat{\varphi}_s(y)}{\hat{\varphi}_t(x)}. \quad (13)$$

(11) 和 (12) 是关于参考转移核的正向-反向表示，边界边缘约束通过边界时刻的耦合条件编码： $\varphi_0 \hat{\varphi}_0 = \mu, \varphi_1 \hat{\varphi}_1 = \nu$ 。

离散状态空间上的随机最优控制问题 具有终端代价 $g: \mathcal{X} \rightarrow \mathbb{R}$ 的连续时间马尔可夫链随机最优控制问题为

$$\min_{u \text{ s.t. } p_0^u = \mu} \left\{ \text{KL}(p^u \| p^r) + \mathbb{E}_{X \sim p^u} g(X_1) \right\} \quad (\text{SOC})$$

薛定谔桥的随机最优控制特征 虽然 (10) 中的最优性条件给出了 u^* 的显式刻画，但在实际中求解具有挑战性。主要困难有两方面：时刻 $t = 0$ 和 $t = 1$ 处的耦合边界约束，以及需要计算关于参考转移核的期望。随机最优控制公式

通过避免直接求解耦合方程来规避这些问题。以下定理建立了薛定谔桥问题的随机最优控制重解释：

定理 3.2. 最优转移率 u_t^* (10) 对于 (6) 求解 (SOC)，终端成本为 $g \leftarrow \log \frac{\hat{\varphi}_1}{\nu}$ 。

证明概要。(SB) 和 (SOC) 的最优路径测度可分别写为

$$\frac{p_{\text{SB}}^*(X_{[0,1]})}{p^r(X_{[0,1]})} = \frac{\hat{\varphi}_0(X_0)}{\mu(X_0)} \frac{\nu(X_1)}{\hat{\varphi}_1(X_1)}, \quad (14)$$

$$\frac{p_{\text{SOC}}^*(X_{[0,1]})}{p^r(X_{[0,1]})} = \frac{e^{-g(X_1)}}{Z(X_0)}, \quad Z(x) = \mathbb{E}_{p_{1|0}^r(y|x)} e^{-g(y)}. \quad (15)$$

完整证明见附录 B.4。定理 3.2 表明，(SB) 允许一个等价的 SOC 表述，其中终端边际约束 $p_1^u = \nu$ 通过终端成本 $g = \log \frac{\hat{\varphi}_1}{\nu}$ 被纳入。这一 SOC 视角对于在离散设置中开发可处理的学习目标将至关重要。

与无记忆参考动力学的联系 若进一步假设 p^r 是无记忆的，则 (11) 式蕴含 $\varphi_0(x) = \mathbb{E}_{p_1^r} e^{-g} = \text{常数}$ ，且 (12) 式蕴含 $\hat{\varphi}_1(x) = p_1^r(x) \sum_y \hat{\varphi}_0(y) \propto p_1^r(x)$ 。因此， $g = \log \frac{p_1^r}{\nu} + \text{常数}$ 。

与连续状态空间的关系 最后，我们指出，上述针对离散状态空间发展的 SOC 和 SB 理论与第 2 节介绍的连续对应理论紧密平行。详细比较见表 1 上半部分。

4. 离散伴随薛定谔桥采样器 (DASBS)

在本节中，我们引入一种有原则的理论和算法，用于学习离散薛定谔桥 (SB) 问题中的最优转移率。基于前一节为连续时间马尔可夫链 (CTMC) 发展的随机最优控制 (SOC) 和 SB 公式，我们通过为控制器和校正器开发伴随匹配和去噪匹配的离散版本，提出了 ASBS (Liu et al., 2025a) 的离散类比。

离散环境中的一个关键挑战是缺乏加性噪声结构 (9)，该结构在开发 AM 框架中起着核心作用。为解决这一问题，我们将在离散状态空间上采用循环群结构，这使得离散转移能够以加性形式解释。在这种视角下，均匀参考转移率自然成为诱导可处理且对称转移核的选择。

参考路径测度的选择 (10) 意味着只需在所有满足 $r_t(y, x) > 0$ 的 $x, y \in \mathcal{X}$ 对上学习 φ_t 的比率。我们遵循离散扩散模型 (Campbell et al., 2022; Lou et al., 2024; Schiff et al., 2025) 中的典型策略，将转移限制在汉明距离为 $d_H(x, y) = 1$, i.e., x 且 y 恰好在一条边上不同的 x, y 对上。在本文中，我们考虑参考路径测度 p^r ，它从任意可处理的初始分布 $p_0^r = \mu$ 开始，并由以下均匀转移率 r 诱导，该转移率保持 $\mathcal{X}$ 上的均匀分布 ($p_{\text{unif}} = 1/N$) 不变：

$$r_t(y, x) = \begin{cases} \frac{\gamma_t}{N}, & \text{if } d_H(y, x) = 1, \\ -\gamma_t D \left(1 - \frac{1}{N}\right), & \text{if } y = x, \\ 0, & \text{if otherwise,} \end{cases} \quad (16)$$

其中 $\gamma : [0, 1] \rightarrow \mathbb{R}_+$ 是噪声调度。我们指出，对于两个给定的时间步 $0 \leq s < t \leq 1$ 和状态 $x, y \in \mathcal{X}$ ， $p_{t|s}^r(y|x)$ 可以写成闭式形式 (命题 B.5)， $p_{t|0,1}^r(x|x_0, x_1)$ 也是如此 (命题 B.6)。详见附录 B.5。

因此，只需学习 $\varphi_t(y)$ 对于所有 $d_H(x, y) = 1$ ， $\varphi_t(x)$ 。定义控制器矩阵 $\Phi^* : (x) \in \mathbb{R}^{D \times N}$ whose (d, n) 第 n 个元素 is $\Phi_t^*(x)_{d,n} = \frac{\varphi_t(x^{d \leftarrow n})}{\varphi_t(x)}$ ，其中 $x^{d \leftarrow n}$ 表示将 x 的第 d 个元素替换为 n 后得到的向量。

控制器伴随匹配 在存在加性噪声的情况下，我们可以考虑一个类似于连续伴随匹配（AM）的目标得分匹配（De Bortoli 等，2024；Zhang 等，2025）目标。应用式（17），我们可以将式（11）重构如下：

校正器去噪匹配 式 (22) 与式 (24) 的一个局限性在于，它们要求 μ 的显式密度处处为正。为规避此问题，可利用如下恒等式：

$$\frac{\hat{\varphi}_1(z)}{\hat{\varphi}_1(y)} \stackrel{(12)}{=} \sum_x p_{1|t}^r(z|x) \frac{\hat{\varphi}_t(x)}{\hat{\varphi}_1(y)} \stackrel{(13)}{=} \sum_x \frac{p_{1|t}^r(z|x)}{p_{1|t}^r(y|x)} p_{t|1}^*(x|y). \quad (25)$$

值得注意的是，虽然式 (22) 依赖于加性噪声 (17)，但式 (25) 在一般 $p_{t|1}^r$ 下成立。因此，可以得到类似的变分 通过将 (23) 中的回归目标（即比值）替换为 $p_{1|t}^r(x_1^{d \leftarrow n})$ ，对校正子 Φ^* 进行表征。由于这与转移核函数（Transition Kernel） $p_{1|t}^r(\cdot|x)$ 的离散得分相关，本文借用连续域中的术语，将其称为去噪匹配（Denoising Matching, DM）。

交替更新 因此，遵循 ASBS 中交替更新学习 $\Phi \approx \Phi^*$ 和 $\Phi \approx \Phi^*$ 的做法，我们可以得到离散 ASBS 的核心算法。按照 Liu 等人 (2025a) 的做法，我们将 $\Phi^{(0)}$ 初始化为全一，对于阶段 $k = 1, 2, \dots$ ，我们依次求解以下两个问题：

$$\Phi^{(k)} := \operatorname{argmin}_{\Phi} \mathbb{E}_t w_t \mathbb{E}_{p_{0,1}^{\operatorname{sg}(r\Phi)}(x_0, x_1)} \sum_{d=1}^D \sum_{n \neq x_1^d} D_f \left(\frac{\varphi_1(x_1^{d \leftarrow x_1^d + n - x_1^d})}{\varphi_1(x_1)} \left\| \Phi_t(x)_{d,n} \right\| \right), \quad (\text{ctrl-AM})$$

$$\hat{\Phi}^{(k)} := \operatorname{argmin}_{\hat{\Phi}} \mathbb{E}_{p_{0,1}^{\operatorname{sg}(r\Phi^{(k)})}(x_0, x_1)} \sum_{d=1}^D \sum_{n \neq x_1^d} D_f \left(\frac{\hat{\varphi}_0(x_0^{d \leftarrow x_0^d + n - x_1^d})}{\hat{\varphi}_0(x_0)} \left\| \hat{\Phi}(x_1)_{d,n} \right\| \right), \quad (\text{corr-AM})$$

$$\text{or } \hat{\Phi}^{(k)} := \operatorname{argmin}_{\hat{\Phi}} \mathbb{E}_t w_t \mathbb{E}_{p_{0,1}^{\operatorname{sg}(r\Phi^{(k)})}(x_0, x_1)} \sum_{d=1}^D \sum_{n \neq x_1^d} D_f \left(\frac{p_{1|t}^r(x_1^{d \leftarrow n}|x)}{p_{1|t}^r(x_1|x)} \left\| \hat{\Phi}(x_1)_{d,n} \right\| \right). \quad (\text{corr-DM})$$

将停止梯度算子 $\operatorname{sg}(\cdot)$ 应用于模型意味着在查询模型时不跟踪梯度。在 (ctrl-AM) 和 (corr-DM), $t \sim$ 均匀分布 $(0, 1)$, $w: [0, 1] \rightarrow \mathbb{R}_+$ 是一个时间权重函数。对于两个 AM 损失，(ctrl-AM) 中的比率通过 (21) 计算，将 Φ^* 替换为当前的 $\operatorname{sg}(\Phi^{(k-1)})$ ，而 (corr-AM) 中的比率通过 (24) 计算，将 Φ^* 替换为当前的 $\operatorname{sg}(\Phi^{(k)})$ 。在所有三个损失中， $p^{\operatorname{sg}(r\Phi)}$ 表示从具有转移速率 $u_t(x^{d \leftarrow n}, x) = r_t(x^{d \leftarrow n}, x) \operatorname{sg}(\Phi_t(x)_{d,n}, n \neq x_1^d)$ 的 CTMC 中采样，该采样用分离的非最优路径测度替换期望中的 $p_{0,1}^*$ 。这种替换有效性的理论论证将在定理 5.2 中讨论，并且在实践中，可以使用 RND $p^*(x| [0, 1]) / p^{\operatorname{sg}(r\Phi)}(x| [0, 1])$ 进行可选的轨迹重要性重加权（附录 B.9）。

初始化 遵循 ASBS (Liu 等人, 2025a)，可以将控制器或校正器初始化为无信息（即输出全 1）。在命题 B.12 中，我们证明在参考转移速率 (16) 和均匀初始化 $\mu = p_{\text{unif}}$ 下，这两种方法是等价的，因此我们始终从全 1 校正器开始。

推理 我们使用 τ -跳跃方法 (Gillespie, 2001; Campbell et al., 2022; Lou et al., 2024) 来独立采样每个维度的转移。由于 $u_t(x^{d \leftarrow n}, x) = \frac{\gamma_t}{N} \Phi_t(x)_{d,n}, n \neq x_1^d$ ，这意味着我们在区间 $\tau \in [t, t+h]$ 上固定 $\Phi_\tau(X_\tau)_{d,n}$ ，步长 $h > 0$ 较小，并假设每个维度独立演化。我们将细节推迟到附录 B.6。

5. DASBS 的附加理论与洞见

在本节中，我们为 DASBS 框架提供进一步的理论与洞见。

校正器的 AM 与 DM 对比 回顾我们推导 AM 损失 (ctrl-AM) 和 (corr-AM) 时利用了关系 (19) 和 (22)，这些关系明确依赖于参考转移核 p^r 的可加性。相比之下，DM 损失 $t(\cdot|x)$ (17) 失（修正去噪匹配）不依赖此条件。

控制器：伴随匹配与去噪匹配对比 控制器存在 平行关系，通过将（控制器伴随匹配）中的比值替换为，可得到交替更新的另一种方式 $\frac{p_{1|t}^r(x_1|x^{d \leftarrow n})}{p_{1|t}^r(x_1|x)}$ （详见附录 B.8 及（控制器去噪匹配））。然而，尽管

表 2. 学习从格点伊辛模型中采样， $L = 24$ 。所有基于均匀的离散神经采样器中最佳与次佳结果已高亮。*：在单块 A6000 GPU 上以最大可行批大小测得。 β_{high} ，†：对于 β_{critical} 和 β_{low} ，采用 PDNS 中的预热策略（Guo 等人，2026）。‡：即使在预热下，在 β_{critical} 和 β_{low} 处也未能收敛到有意义的分布。

	Inv. Temp.			$\beta_{\text{high}} = 0.28$			$\beta_{\text{critical}} = 0.4407$			$\beta_{\text{low}} = 0.6$		
Type	Metrics ↓	Steps (×1e3)*	Runtime (h)*	ΔMag.	ΔCorr.	EW ₂	ΔMag.	ΔCorr.	EW ₂	ΔMag.	ΔCorr.	EW ₂
Uniform	DASBS	3.75	0.5	2.7e−3	1.8e−3	8.6	5.7e−2	4.7e−2	12.1	2.0e−2	1.8e−3	2.0
	LEAPS	<u>30</u>	8.4	1.8e−3	9.2e−4	3.1	<u>5.9e−2</u>	<u>2.8e−1</u>	<u>96.5</u>	<u>3.0e−2</u>	<u>5.5e−1</u>	<u>176.6</u>
	UDNS‡	50	11.9	9.0e−3	8.7e−3	23.6	−	−	−	−	−	−
	DFNS‡	50	<u>2.1</u>	9.3e−1	8.0e−1	661.6	−	−	−	−	−	−
Masked	MDNS†	50	16.8	3.9e−3	7.4e−4	0.1	1.1e−2	5.6e−3	5.1	9.0e−3	4.7e−3	5.3
MCMC	MH	−	−	8.9e−4	2.9e−4	1.2	2.5e−2	3.7e−3	293.3	4.0e−2	6.6e−4	109.9

理论上虽有依据，但该公式在交替更新过程中可能面临互监督信号较弱的问题：我们依赖训练好的 $\Phi^{(k-1)}$ 来监督 $\Phi^{(k)}$ 的训练，但此类监督信息仅来自隐式边界关系 $\Phi_1(x)_{d,n}\Phi(x)_{d,n} = \frac{\nu(x^{d \leftarrow n})}{\nu(x)}$ ，而该关系并未在损失中被显式强制。即使参考动力学无记忆且无需学习校正器，我们在图 1 中发现伴随匹配（控制器伴随匹配）的表现显著优于其去噪匹配对应方法（控制器去噪匹配）。

与目标匹配的进一步联系 这种对比类似于连续概率分布得分学习文献中目标匹配（TM）与去噪匹配（DM）之间的区别（De Bortoli 等人，2024；Kahouli 等人，2025）：对于两个连续随机向量 $x, y \sim p(x, y)$ ，我们可以将得分表示为 $\mathbb{E}_{p(x|y)} \nabla_x \log p(x)$ （加性情形） $\nabla_y \log p(y) = \mathbb{E}_{p(x|y)} \nabla_y \log p(y|x)$ （一般情形） $\nabla_y \log p(y|x)$ ，其中加性意味着对某个分布 q 有 $p(y|x) = q(y - x)$ 。换言之，目标匹配回归到目标得分，而去噪匹配回归到转移核的得分。目标匹配利用了更有意义的学习信号，并避免了去噪匹配在噪声水平极小时（此时 $\nabla_y \log p(y|x)$ 变得奇异）的数值不稳定性，从而提供更快的训练收敛，这一优势我们在离散实验中直接观察到（图 1）。

伴随匹配的统一视角 伴随匹配（Adjoint Matching, **AM**, Domingo-Enrich 等人（2025a））最初是通过分析伴随状态的常微分方程推导得出的，即从 $X_t = x$ 到 x 的代价函数梯度的常微分方程。该公式将伴随状态与目标函数关于控制参数的梯度联系起来，产生一个学习目标，其唯一的不动点对应于最优控制。然而，这种基于梯度的视角不能直接推广到离散域。最近，So 等人（2026）首次尝试通过将最优控制表示为最优路径测度下的期望；然而，由于缺乏可加性，他们对掩蔽转移率的依赖导致了复杂的训练目标。相比之下，我们的推导发现，可加参考噪声是在离散域中实现类似 TM 损失的关键结构要求。我们请读者参考表 1 的下半部分，了解连续和离散设置下 DM 和 **AM** 公式的并排比较，并以对 **AM** 内在本质的统一描述作为总结：

伴随匹配：由目标匹配目标驱动的不动点迭代，收敛到最优 p^* 。

DASBS 统一了现有的无记忆 SOC 求解器 我们进一步建立了 DASBS 与用于解决无记忆 SOC 问题的加权去噪交叉熵（WDCE）损失之间的联系（Zhu 等人，2025a；b）（完整陈述和证明见命题 B.9 和 B.10）：

命题 5.1. 在无记忆参考路径测度 p^r （涵盖均匀（16）和掩蔽（39）离散扩散）下，控制器（ctrl-DM）的去噪损失，结合轨迹重要性重加权、广义 KL 散度、²和时间权重 $w_t \leftarrow \frac{\gamma_t}{N}$ ，等价于 WDCE 损失。

收敛性分析 最后，遵循连续论证（Liu 等人，2025a，定理 4），我们建立了 DASBS 的以下收敛保证。

² $f(t) = t \log t \implies D_f(a||b) = a \log \frac{a}{b} - a + b$.

表 3. 使用 $L = 16$ 和 $N = 4$. 从晶格 Potts 模型中学习采样。所有基于均匀的离散神经采样器中的最佳结果已突出显示。† : 对于 β_{critical} 和 β_{low} , 在 PDNS 中使用预热策略 (Guo 等人, 2026)。

Inv. Temp.		$\beta_{\text{high}} = 0.9$		$\beta_{\text{critical}} = 1.0986$				$\beta_{\text{low}} = 1.3$			
类型度量 ↓ Δ 幅值 · Δ 相关性 · EW2 Δ 幅值 · Δ 相关性 · EW2 Δ 幅值 · Δ 相关性 · EW2											
Uniform	DASBS	8.7e − 3	6.6e − 3	5.3	4.1e − 3	2.9e − 2	20.0	4.2e − 3	7.3e − 3	3.6	
	LEAPS	5.7e − 3	5.0e − 3	8.2	3.2e − 1	2.6e − 1	79.9	3.6e − 1	3.5e − 1	90.5	
Mask	MDNS	6.5e − 3	5.1e − 3	6.4	5.2e − 3	4.6e − 3	1.9	8.4e − 4	6.1e − 4	0.7	
MCMC	MH	5.2e − 2	4.7e − 2	98.6	4.9e − 1	4.0e − 1	273.2	6.8e − 1	6.4e − 1	313.1	

定理 5.2. (1) 由 (ctrl-AM) ($\Phi^{(k)}$) 的唯一不动点诱导的路径测度解决了前向半桥问题 $\min_{p \text{ s.t. } p_0 = \mu} \text{KL}(p \| q^{\hat{\varphi}^{(k-1)}} \mathbf{1})$, 对于由 $\hat{\varphi}_1^{(k-1)}$ 诱导的某个路径测度 $q^{\hat{\varphi}_1^{(k-1)}}$ (定义 B.11)。

a path measure $q^{\hat{\varphi}_1^{(k)}}$ that solves a **backward half bridge problem** $\min_{q \text{ s.t. } q_1 = \nu} \text{KL}(p^{r\Phi^{(k)}} \| q)$.

(2) (corr-DM) 的唯一不动点与 (corr-DM) 的唯一不动点相同。将其记为 $\Phi^{(k)}$, 它诱导

因此, 收敛性由迭代比例拟合理论保证 (Ruschendorf, 1995; Chen et al., 2016a; De Bortoli et al., 2021)。证明见附录 B.11。

6. 实验

在本节中, 我们评估所提出的 DASBS 算法的有效性和效率。我们证明它在标准基准上达到了有竞争力的样本质量, 同时在训练速度上具有显著优势。我们进一步通过消融研究探讨了 AM 和非无记忆参考动态的益处。更多细节和结果见附录 C。

实验设置 我们在统计物理中的两个离散分布上测试我们的方法: **方格子上的伊辛模型和波茨模型**。它们以作为逆温度函数表现出相变而闻名 (Onsager, 1944; Boffarda & Duminil-Copin, 2012), 并作为离散采样的标准基准。对于伊辛模型, 我们使用大小为 $L = 24$ (i.e., seq 的格子, 序列长度 $D = L^2 = 576$, 状态 $\{\pm 1\}$, 并考虑逆温度 $\beta_{\text{high}} = 0.28, \beta_{\text{critical}} = \log(1 + \sqrt{2})/2 \approx 0.4407$ 和 $\beta_{\text{low}} = 0.6$ 。对于波茨模型, 我们使用

$L = 16$ ($D = L^2 = 256$), 具有 $N = 4$ 个状态, 并考虑 $\beta_{\text{high}} = 0.9, \beta_{\text{critical}} = \log(1 + \sqrt{q}) \approx 1.0986$ 和 $\beta = 1.3$ 。我们将 DASBS 与领先的离散神经采样器进行基准比较, 包括 LEAPS (Holderrith et al., 2025)、DFNS (Ou et al., 2025b)、UDNS (Zhu et al., 2025a, 附录 F) 和 MDNS (Zhu et al., 2025a), 以及经典的 Metropolis-Hastings (MH) 算法。

结果与讨论 伊辛模型和波茨模型的定量结果分别汇总于表 2 和表 3。我们使用三个度量评估样本质量: 磁化强度偏差 ($\Delta \text{Mag.}$)、两点相关函数偏差 ($\Delta \text{Corr.}$) 以及能量沃瑟斯坦-2 距离 (EW2), 均相对于来自斯文森-王 (SW, Swendsen & Wang (1986; 1987)) 算法的真实样本。对于高温伊辛模型, 我们还报告了在单块 A6000 GPU 上使用最大可行批大小的训练步数和运行时间。在所有区域中, DASBS 提供了令人满意的样本保真度, 与最先进的基于均匀分布的离散神经采样器相比具有很强的竞争力。值得注意的是, DASBS 在训练效率方面具有明显优势。我们将这种加速归因于三个因素:

(1) 使用离散分数作为信息量丰富的一阶预言; (2) 内存高效的设计, 避免存储完整的展开轨迹或计算完整轨迹上的损失; (3) 匹配损失目标的简洁性。

消融研究: 控制器学习中的 AM 与 DM 对比 在图 2 中, 我们通过实验验证了 AM 比 DM 更高效的说法。我们关注一个 8×8 波茨模型 ($N = 3, \beta_{\text{high}} = 0.5$)。我们选择标准无记忆噪声调度 $\gamma_t = \frac{1}{t}$ (Ou et al., 2025a; Zhu 等人, 2025a) 来隔离训练目标 (ctrl-AM) 与 (ctrl-DM) 的影响。图 1 显示, 虽然三种方法最终都收敛, 但在启用轨迹重要性重加权时, AM 的收敛速度显著快于 DM。此外, 我们观察到重要性重加权可能由于有效样本量小 (即使在收敛后) 而无意中减慢收敛速度, 这很可能源于估计 RND 的方差。




图 1. 无记忆噪声调度 $\gamma_t = \frac{1}{t}$ 下，伴随匹配 (AM) 和去噪匹配 (DM) 训练损失在 $L = 8, N = 3, \beta_{\text{high}} = 0.5$ 波茨模型上的消融研究。重加权意味着在训练损失中使用轨迹重要性权重 $p^*/p^{\text{sg}(u)}$ 。带加权重的 DM 对应于 UDNS (Zhu 等人, 2025a, 附录 F)。左图：与 SW 算法真实样本之间的能量沃斯坦-2 距离。右图：根据轨迹重要性权重计算的有效样本量。

消融研究：无记忆与有记忆对比 本文在图 2 中研究了噪声调度 γ_t 的影响，特别地，我们证明了非无记忆噪声调度比无记忆噪声调度表现更好。我们在 24×24 伊辛模型上采用改进的对数线性调度 $\gamma_t = \frac{\gamma}{t + \alpha}$ ，其中 $\beta_{\text{high}} = 0.28$ ，当 $\alpha = 0$ 时是无记忆的。图 2 显示，当任一超参数固定为 1 时，误差度量作为另一参数的函数呈现出明显的 U 形曲线。偏离最优区域会导致样本质量下降：小的 γ 或大的 α 会降低转移率幅度并可能阻碍探索，而大的 γ 或小的 α （特别是无记忆情况 $\alpha = 0$ ）会在生成过程中引起过度跳跃，同样降低性能。值得注意的是，这些趋势在不同的计算预算下保持一致，证明了最优配置的鲁棒性。关于恒定噪声调度 $\gamma_t \equiv \gamma$ 的类似研究见附录 C.3。

7. 结论与未来工作

本文提出了一个统一的离散薛定谔桥 (Schrödinger Bridge) 与随机最优控制 (Stochastic Optimal Control) 框架，并提出 DASBS 作为最优策略的不动点迭代方法。通过利用基于群结构的加性噪声方案，DASBS 有效地将交替最小化 (Alternating Minimization) 扩展到离散域。仍存在若干局限性：目前的评估仅限于合成基准，在更复杂分布上的性能尚不明确。此外，DASBS 的一阶特性在能量计算昂贵或不可并行化时可能实现成本较高。未来方向包括：将该框架扩展到带运行成本的离散随机最优控制 (Domingo-Enrich 等, 2025a)，探索非均匀参考动力学如埃伦费斯特过程 (Ehrenfest process) (Winkler 等, 2024)，以及将交替最小化的理论洞见推广到一般状态 (例如 Park 等 (2024)；Woo 等 (2025)；Park 等 (2025))。

参考文献

- Akhound-Sadeh, T., Lee, J., Bose, J., Bortoli, V. D., Doucet, A., Bronstein, M. M., Beaini, D., Ravanbakhsh, S., Neklyudov, K., and Tong, A. Progressive inference-time annealing of diffusion models for sampling from Boltzmann densities. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*, 2025. URL <https://openreview.net/forum?id=vf2GHcxzMV>.
- Albergo, M. S. and Vanden-Eijnden, E. NETS: A non-equilibrium transport sampler. In *Forty-second International Conference on Machine Learning*, 2025. URL <https://openreview.net/forum?id=QqGw9StPbQ>.
- Beffara, V. and Duminil-Copin, H. The self-dual point of the two-dimensional random-cluster model is critical for $q \geq 1$. *Probability Theory and Related Fields*, 153(3):511–542, 2012. doi: 10.1007/s00440-011-0353-8.
- Blessing, D., Berner, J., Richter, L., Domingo-Enrich, C., Du, Y., Vahdat, A., and Neumann, G. Trust region constrained




图 2. 针对修正对数线性噪声调度 α 与 γ 的超参数消融实验 $\gamma_t = \frac{\gamma}{t+\alpha}$ ，在伊辛模型上，其中 $L = 24$ 与 $\beta_{\text{high}} = 0.28$ 。 $\alpha = 0$ 的情形是无记忆的。NFE 为训练与推理过程中生成时的函数评估次数。上：固定 $\gamma = 1$ 并改变 α 。下：固定 $\alpha = 1$ 并改变 γ 。左：生成过程中每一维度的平均跳变次数。右：两点相关误差及与从 SW 算法抽取的真实样本之间的能量 Wasserstein-2 距离。

measure transport in path space for stochastic optimal control and inference. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*, 2025a. URL <https://openreview.net/forum?id=6Rlb0EcOS4>.

Blessing, D., Berner, J., Richter, L., and Neumann, G. Underdamped diffusion bridges with applications to sampling. In *The Thirteenth International Conference on Learning Representations*, 2025b. URL <https://openreview.net/forum?id=Q1QTxFm0Is>.

Brooks, S., Gelman, A., Jones, G., and Meng, X.-L. *Handbook of Markov chain Monte Carlo*. CRC press, 2011.

Campbell, A., Benton, J., De Bortoli, V., Rainforth, T., Deligiannidis, G., and Doucet, A. A continuous time framework for discrete denoising models. In Koyejo, S., Mohamed, S., Agarwal, A., Belgrave, D., Cho, K., and Oh, A. (eds.), *Advances in Neural Information Processing Systems*, volume 35, pp. 28266–28279. Curran Associates, Inc., 2022. URL https://proceedings.neurips.cc/paper_files/paper/2022/file/b5b528767aa35f5b1a60fe0aaeca0563-Paper-Conference.pdf.

Chen, H. and Ying, L. Convergence analysis of discrete diffusion model: Exact implementation through uniformization. *Journal of Machine Learning*, 2025. doi: 10.4208/jml.240812.

Chen, J., Richter, L., Berner, J., Blessing, D., Neumann, G., and Anandkumar, A. Sequential controlled Langevin diffusions. In *The Thirteenth International Conference on Learning Representations*, 2025. URL <https://openreview.net/forum?id=dImD2sgy86>.

Chen, R. T. Q., Rubanova, Y., Bettencourt, J., and Duvenaud, D. K. Neural ordinary differential equations. In Bengio, S., Wallach, H., Larochelle, H., Grauman, K., Cesa-Bianchi, N., and Garnett, R. (eds.), *Advances in Neural Information Processing Systems*, volume 31. Curran Associates, Inc., 2018. URL https://proceedings.neurips.cc/paper_files/paper/2018/file/69386f6bb1dfed68692a24c8686939b9-Paper.pdf.

- Chen, T., Liu, G.-H., and Theodorou, E. Likelihood training of Schrödinger bridge using forward-backward SDEs theory. In *International Conference on Learning Representations*, 2022. URL <https://openreview.net/forum?id=nioAdKCEdXB>.
- Chen, Y., Georgiou, T., and Pavon, M. Entropic and displacement interpolation: a computational approach using the Hilbert metric. *SIAM Journal on Applied Mathematics*, 76(6):2375–2396, 2016a. doi: 10.1137/16M1061382. URL <https://doi.org/10.1137/16M1061382>.
- Chen, Y., Georgiou, T. T., and Pavon, M. On the relation between optimal transport and Schrödinger bridges: A stochastic control viewpoint. *Journal of Optimization Theory and Applications*, 169:671–691, 2016b. doi: 10.1007/s10957-015-0803-z.
- Chen, Y., Georgiou, T. T., and Pavon, M. Stochastic control liaisons: Richard Sinkhorn meets Gaspard Monge on a Schrödinger bridge. *SIAM Review*, 63(2):249–313, 2021. doi: 10.1137/20M1339982. URL <https://doi.org/10.1137/20M1339982>.
- Choi, J., Chen, Y., Tao, M., and Liu, G.-H. Non-equilibrium annealed adjoint sampler. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*, 2025. URL <https://openreview.net/forum?id=ay7WDSq0Kb>.
- Dai Pra, P. A stochastic control approach to reciprocal diffusion processes. *Applied mathematics and Optimization*, 23(1): 313–329, 1991. doi: 10.1007/BF01442404.
- De Bortoli, V., Thornton, J., Heng, J., and Doucet, A. Diffusion Schrödinger bridge with applications to score-based generative modeling. In Beygelzimer, A., Dauphin, Y., Liang, P., and Vaughan, J. W. (eds.), *Advances in Neural Information Processing Systems*, 2021. URL <https://openreview.net/forum?id=9BnCwiXB0ty>.
- De Bortoli, V., Hutchinson, M., Wirnsberger, P., and Doucet, A. Target score matching. *arXiv preprint arXiv:2402.08667*, 2024.
- Domingo-Enrich, C., Han, J., Amos, B., Bruna, J., and Chen, R. T. Q. Stochastic optimal control matching. In *The Thirty-eighth Annual Conference on Neural Information Processing Systems*, 2024. URL <https://openreview.net/forum?id=wFU2CdgmWt>.
- Domingo-Enrich, C., Drozdal, M., Karrer, B., and Chen, R. T. Q. Adjoint matching: Fine-tuning flow and diffusion generative models with memoryless stochastic optimal control. In *The Thirteenth International Conference on Learning Representations*, 2025a. URL <https://openreview.net/forum?id=xQBRrtQM8u>.
- Domingo-Enrich, C., Du, Y., and Albergo, M. S. A unified perspective on fine-tuning and sampling with diffusion and flow models, 2025b. URL <https://openreview.net/forum?id=SEv6F8hxMC>.
- Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., and Houslsby, N. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations*, 2021. URL <https://openreview.net/forum?id=YicbFdNTTy>.
- Du, Y., He, J., Vargas, F., Wang, Y., Gomes, C. P., Hernández-Lobato, J. M., and Vanden-Eijnden, E. FEAT: Free energy estimators with adaptive transport. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*, 2025. URL <https://openreview.net/forum?id=GQXeLGYMda>.
- Flamary, R., Courty, N., Gramfort, A., Alaya, M. Z., Boisbunon, A., Chambon, S., Chapel, L., Corenflos, A., Fatras, K., Fournier, N., Gautheron, L., Gayraud, N. T., Janati, H., Rakotomamonjy, A., Redko, I., Rolet, A., Schutz, A., Seguy, V., Sutherland, D. J., Tavenard, R., Tong, A., and Vayer, T. Pot: Python optimal transport. *Journal of Machine Learning Research*, 22(78):1–8, 2021. URL <http://jmlr.org/papers/v22/20-451.html>.
- Gelman, A., Carlin, J. B., Stern, H. S., and Rubin, D. B. *Bayesian data analysis*. Chapman and Hall/CRC, 3 edition, 2013.
- Gillespie, D. T. Approximate accelerated stochastic simulation of chemically reacting systems. *The Journal of Chemical Physics*, 115(4):1716–1733, 07 2001. ISSN 0021-9606. doi: 10.1063/1.1378322. URL <https://doi.org/10.1063/1.1378322>.

- Guo, W., Choi, J., Zhu, Y., Tao, M., and Chen, Y. Proximal diffusion neural sampler. In *The Fourteenth International Conference on Learning Representations*, 2026. URL <https://openreview.net/forum?id=XTHQqS7ObC>.
- Han, J. and E, W. Deep learning approximation for stochastic control problems. *arXiv preprint arXiv:1611.07422*, 2016.
- Havens, A. J., Miller, B. K., Yan, B., Domingo-Enrich, C., Sriram, A., Levine, D. S., Wood, B. M., Hu, B., Amos, B., Karrer, B., Fu, X., Liu, G.-H., and Chen, R. T. Q. Adjoint sampling: Highly scalable diffusion samplers via adjoint matching. In *Forty-second International Conference on Machine Learning*, 2025. URL <https://openreview.net/forum?id=6EglOrHmg2>.
- He, J., Du, Y., Vargas, F., Zhang, D., Padhy, S., OuYang, R., Gomes, C., and Hernández-Lobato, J. M. No trick, no treat: Pursuits and challenges towards simulation-free training of neural samplers. *arXiv preprint arXiv:2502.06685*, 2025.
- Heo, B., Park, S., Han, D., and Yun, S. Rotary position embedding for vision transformer. In Leonardis, A., Ricci, E., Roth, S., Russakovsky, O., Sattler, T., and Varol, G. (eds.), *Computer Vision – ECCV 2024*, pp. 289–305, Cham, 2025. Springer Nature Switzerland. ISBN 978-3-031-72684-2.
- Holderrieth, P., Albergo, M. S., and Jaakkola, T. LEAPS: A discrete neural sampler via locally equivariant networks. In *Forty-second International Conference on Machine Learning*, 2025. URL <https://openreview.net/forum?id=Hq2RniQAET>.
- Howard, S., Nüsken, N., and Pidstrigach, J. Control consistency losses for diffusion bridges. *arXiv preprint arXiv:2512.05070*, 2025.
- Kahouli, K., Elie, R., Müller, K.-R., Berthet, Q., Unke, O. T., and Doucet, A. Control variate score matching for diffusion models. *arXiv preprint arXiv:2512.20003*, 2025.
- Kelly, F. P. *Reversibility and stochastic networks*. Cambridge University Press, 2011.
- Kholkin, S., Vargas, F., and Korotin, A. Sampling from energy distributions with target concrete score identity. *arXiv preprint arXiv:2510.23106*, 2025.
- Kim, J. H., Kim, S., Moon, S., Kim, H., Woo, J., and Kim, W. Y. Discrete diffusion Schrödinger bridge matching for graph transformation. In *The Thirteenth International Conference on Learning Representations*, 2025. URL <https://openreview.net/forum?id=tQyh0gnfqW>.
- Ksenofontov, G. and Korotin, A. Categorical Schrödinger bridge matching. In *Forty-second International Conference on Machine Learning*, 2025. URL <https://openreview.net/forum?id=RBly0nOr2h>.
- Landau, D. P. and Binder, K. *A Guide to Monte Carlo Simulations in Statistical Physics*. Cambridge University Press, 4 edition, 2014.
- Léonard, C. A survey of the Schrödinger problem and some of its connections with optimal transport. *Discrete and Continuous Dynamical Systems*, 34(4):1533–1574, 2014. ISSN 1078-0947. doi: 10.3934/dcds.2014.34.1533. URL <https://www.aims sciences.org/article/id/d5bcf817-901d-4104-b7da-eade7847c53e>.
- Li, X., Wong, T.-K. L., Chen, R. T. Q., and Duvenaud, D. Scalable gradients for stochastic differential equations. In Chiappa, S. and Calandra, R. (eds.), *Proceedings of the Twenty Third International Conference on Artificial Intelligence and Statistics*, volume 108 of *Proceedings of Machine Learning Research*, pp. 3870–3882. PMLR, 26–28 Aug 2020. URL <https://proceedings.mlr.press/v108/li20i.html>.
- Liu, G.-H., Chen, T., So, O., and Theodorou, E. Deep generalized Schrödinger bridge. In Oh, A. H., Agarwal, A., Belgrave, D., and Cho, K. (eds.), *Advances in Neural Information Processing Systems*, 2022. URL <https://openreview.net/forum?id=fp33Nsh005>.
- Liu, G.-H., Choi, J., Chen, Y., Miller, B. K., and Chen, R. T. Q. Adjoint Schrödinger bridge sampler. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*, 2025a. URL <https://openreview.net/forum?id=rMhQBlhh4c>.

- Liu, J. S. *Monte Carlo Strategies in Scientific Computing*. Springer Publishing Company, Incorporated, 2008. ISBN 0387763694.
- Liu, Z., Xiao, T. Z., Domingo-Enrich, C., Liu, W., and Zhang, D. Value gradient guidance for flow matching alignment. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*, 2025b. URL <https://openreview.net/forum?id=6MmOy2Ji8V>.
- Loshchilov, I. and Hutter, F. Decoupled weight decay regularization. In *International Conference on Learning Representations*, 2019. URL <https://openreview.net/forum?id=Bkg6RiCqY7>.
- Lou, A., Meng, C., and Ermon, S. Discrete diffusion modeling by estimating the ratios of the data distribution. In Salakhutdinov, R., Kolter, Z., Heller, K., Weller, A., Oliver, N., Scarlett, J., and Berkenkamp, F. (eds.), *Proceedings of the 41st International Conference on Machine Learning*, volume 235 of *Proceedings of Machine Learning Research*, pp. 32819–32848. PMLR, 21–27 Jul 2024. URL <https://proceedings.mlr.press/v235/lou24a.html>.
- Ma, N., Goldstein, M., Albergo, M. S., Boffi, N. M., Vanden-Eijnden, E., and Xie, S. SiT: Exploring flow and diffusion-based generative models with scalable interpolant transformers. In *European Conference on Computer Vision*, pp. 23–40. Springer, 2024. doi: 10.1007/978-3-031-72980-5_2.
- Onsager, L. Crystal statistics. I. A two-dimensional model with an order-disorder transition. *Phys. Rev.*, 65:117–149, Feb 1944. doi: 10.1103/PhysRev.65.117. URL <https://link.aps.org/doi/10.1103/PhysRev.65.117>.
- Ou, J., Nie, S., Xue, K., Zhu, F., Sun, J., Li, Z., and Li, C. Your absorbing discrete diffusion secretly models the conditional distributions of clean data. In *The Thirteenth International Conference on Learning Representations*, 2025a. URL <https://openreview.net/forum?id=sMyXP8Tanm>.
- Ou, Z., Zhang, R., and Li, Y. Discrete neural flow samplers with locally equivariant transformer. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*, 2025b. URL <https://openreview.net/forum?id=Wk65okms3T>.
- Park, B., Choi, J., Lim, S., and Lee, J. Stochastic optimal control for diffusion bridges in function spaces. In *The Thirty-eighth Annual Conference on Neural Information Processing Systems*, 2024. URL <https://openreview.net/forum?id=WyQW4G57Zd>.
- Park, B., Lee, J., and Liu, G.-H. Functional adjoint sampler: Scalable sampling on infinite dimensional spaces. *arXiv preprint arXiv:2511.06239*, 2025.
- Peebles, W. and Xie, S. Scalable diffusion models with transformers. In *2023 IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 4172–4182, 2023. doi: 10.1109/ICCV51070.2023.00387.
- Phillips, A., Dau, H.-D., Hutchinson, M. J., Bortoli, V. D., Deligiannidis, G., and Doucet, A. Particle denoising diffusion sampler. In *Forty-first International Conference on Machine Learning*, 2024. URL <https://openreview.net/forum?id=vMUnnS4OWC>.
- Pidstrigach, J., Baker, E. L., Domingo-Enrich, C., Deligiannidis, G., and Nüsken, N. Conditioning diffusions using Malliavin calculus. In *Forty-second International Conference on Machine Learning*, 2025. URL <https://openreview.net/forum?id=0A4JSAU3FD>.
- Pontryagin, L. S. *Mathematical theory of optimal processes*. Routledge, 1987. doi: 10.1201/9780203749319.
- Ren, Y., Chen, H., Rotskoff, G. M., and Ying, L. How discrete and continuous diffusion meet: Comprehensive analysis of discrete diffusion models via a stochastic integral framework. In *The Thirteenth International Conference on Learning Representations*, 2025a. URL <https://openreview.net/forum?id=6awxwQEI82>.
- Ren, Y., Chen, H., Zhu, Y., Guo, W., Chen, Y., Rotskoff, G. M., Tao, M., and Ying, L. Fast solvers for discrete diffusion models: Theory and applications of high-order algorithms. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*, 2025b. URL <https://openreview.net/forum?id=OuklL6Q3sO>.
- Richter, L. and Berner, J. Improved sampling via learned diffusions. In *The Twelfth International Conference on Learning Representations*, 2024. URL <https://openreview.net/forum?id=h4pNROsO06>.

- Rissanen, S., OuYang, R., He, J., Chen, W., Heinonen, M., Solin, A., and Hernández-Lobato, J. M. Progressive tempering sampler with diffusion. In *Forty-second International Conference on Machine Learning*, 2025. URL <https://openreview.net/forum?id=uBMnbCBetZ>.
- Rüschendorf, L. Convergence of the iterative proportional fitting procedure. *The Annals of Statistics*, 23(4):1160 – 1174, 1995. doi: 10.1214/aos/1176324703. URL <https://doi.org/10.1214/aos/1176324703>.
- Sanokowski, S., Berghammer, W. F., Hochreiter, S., and Lehner, S. Variational annealing on graphs for combinatorial optimization. In *Thirty-seventh Conference on Neural Information Processing Systems*, 2023. URL <https://openreview.net/forum?id=SLx7paoaTU>.
- Sanokowski, S., Hochreiter, S., and Lehner, S. A diffusion model framework for unsupervised neural combinatorial optimization. In Salakhutdinov, R., Kolter, Z., Heller, K., Weller, A., Oliver, N., Scarlett, J., and Berkenkamp, F. (eds.), *Proceedings of the 41st International Conference on Machine Learning*, volume 235 of *Proceedings of Machine Learning Research*, pp. 43346–43367. PMLR, 21–27 Jul 2024. URL <https://proceedings.mlr.press/v235/sanokowski24a.html>.
- Sanokowski, S., Berghammer, W. F., Wang, H. P., Ennemoser, M., Hochreiter, S., and Lehner, S. Scalable discrete diffusion samplers: Combinatorial optimization and statistical physics. In *The Thirteenth International Conference on Learning Representations*, 2025a. URL <https://openreview.net/forum?id=peNgxpbdxB>.
- Sanokowski, S., Gruber, L., Bartmann, C., Hochreiter, S., and Lehner, S. Rethinking losses for diffusion bridge samplers. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*, 2025b. URL <https://openreview.net/forum?id=O58KDUfB4x>.
- Schiff, Y., Sahoo, S. S., Phung, H., Wang, G., Boshar, S., Dalla-torre, H., de Almeida, B. P., Rush, A. M., PIERROT, T., and Kuleshov, V. Simple guidance mechanisms for discrete diffusion models. In *The Thirteenth International Conference on Learning Representations*, 2025. URL <https://openreview.net/forum?id=i5MrJ6g5G1>.
- Shi, Y., De Bortoli, V., Campbell, A., and Doucet, A. Diffusion schrödinger bridge matching. In *Thirty-seventh Conference on Neural Information Processing Systems*, 2023. URL <https://openreview.net/forum?id=qy07OHsJT5>.
- So, O., Karrer, B., Fan, C., Chen, R. T. Q., and Liu, G.-H. Discrete adjoint matching. In *The Fourteenth International Conference on Learning Representations*, 2026. URL <https://openreview.net/forum?id=VXB4xxAgOf>.
- Song, Y., Sohl-Dickstein, J., Kingma, D. P., Kumar, A., Ermon, S., and Poole, B. Score-based generative modeling through stochastic differential equations. In *International Conference on Learning Representations*, 2021. URL <https://openreview.net/forum?id=PxTIG12RRHS>.
- Swendsen, R. H. and Wang, J.-S. Replica Monte Carlo simulation of spin-glasses. *Phys. Rev. Lett.*, 57:2607–2609, Nov 1986. doi: 10.1103/PhysRevLett.57.2607. URL <https://link.aps.org/doi/10.1103/PhysRevLett.57.2607>.
- Swendsen, R. H. and Wang, J.-S. Nonuniversal critical dynamics in Monte Carlo simulations. *Phys. Rev. Lett.*, 58:86–88, Jan 1987. doi: 10.1103/PhysRevLett.58.86. URL <https://link.aps.org/doi/10.1103/PhysRevLett.58.86>.
- Touvron, H., Cord, M., Douze, M., Massa, F., Sablayrolles, A., and Jegou, H. Training data-efficient image transformers & distillation through attention. In Meila, M. and Zhang, T. (eds.), *Proceedings of the 38th International Conference on Machine Learning*, volume 139 of *Proceedings of Machine Learning Research*, pp. 10347–10357. PMLR, 18–24 Jul 2021. URL <https://proceedings.mlr.press/v139/touvron21a.html>.
- Vargas, F., Grathwohl, W. S., and Doucet, A. Denoising diffusion samplers. In *The Eleventh International Conference on Learning Representations*, 2023. URL <https://openreview.net/forum?id=8pvnfTABulf>.
- Vargas, F., Padhy, S., Blessing, D., and Nüsken, N. Transport meets variational inference: Controlled Monte Carlo diffusions. In *The Twelfth International Conference on Learning Representations*, 2024. URL <https://openreview.net/forum?id=PP1rudnxiW>.

- Winkler, L., Richter, L., and Oppel, M. Bridging discrete and continuous state spaces: Exploring the Ehrenfest process in time-continuous diffusion models. In Salakhutdinov, R., Kolter, Z., Heller, K., Weller, A., Oliver, N., Scarlett, J., and Berkenkamp, F. (eds.), *Proceedings of the 41st International Conference on Machine Learning*, volume 235 of *Proceedings of Machine Learning Research*, pp. 53017–53038. PMLR, 21–27 Jul 2024. URL <https://proceedings.mlr.press/v235/winkler24a.html>.
- Woo, D., Kim, M., Kim, M., Seong, K., and Ahn, S. Energy-based generator matching: A neural sampler for general state space. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*, 2025. URL <https://openreview.net/forum?id=UKJkad8aUF>.
- Zhang, L., Potapchik, P., He, J., Du, Y., Doucet, A., Vargas, F., Dau, H.-D., and Syed, S. Accelerated parallel tempering via neural transports. In *The Fourteenth International Conference on Learning Representations*, 2026. URL <https://openreview.net/forum?id=CODnlyYUli>.
- Zhang, Q. and Chen, Y. Path integral sampler: A stochastic control approach for sampling. In *International Conference on Learning Representations*, 2022. URL https://openreview.net/forum?id=_uCb2ynRu7Y.
- Zhang, R., Zhai, S., Zhang, Y., Thornton, J., Ou, Z., Susskind, J. M., and Jaitly, N. Target concrete score matching: A holistic framework for discrete diffusion. In *Forty-second International Conference on Machine Learning*, 2025. URL <https://openreview.net/forum?id=ZMrdvSm7xi>.
- Zhu, Y., Guo, W., Choi, J., Liu, G.-H., Chen, Y., and Tao, M. MDNS: Masked diffusion neural sampler via stochastic optimal control. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*, 2025a. URL <https://openreview.net/forum?id=xIH95kXNR2>.
- Zhu, Y., Guo, W., Choi, J., Molodyk, P., Yuan, B., Tao, M., and Chen, Y. Enhancing reasoning for diffusion LLMs via distribution matching policy optimization. *arXiv preprint arXiv:2510.08233*, 2025b.

A. 相关工作

1. 伴随匹配 伴随方法 (AM, Domingo-Enrich 等人, 2025a) 的思想可追溯至最优控制理论中的伴随方法 (Pontryagin, 1987), 及其在机器学习中的若干早期应用 (Han 与 E, 2016; Chen 等人, 2018; Li 等人, 2020; Domingo-Enrich 等人, 2024)。其核心思想是, 针对控制 u 与轨迹 $X = (X_t)_{t \in [0, 1]}$, 定义伴随状态 $a_t(X; u)$ 为 $\nabla_{X_t} J_t(X)$, 其中 $J_t(X)$ 表示从 X_t 出发沿轨迹的剩余代价。随后, 可将伴随状态的动态建立为从 a_1 (即终端代价的梯度) 开始的时间反向常微分方程。此外, 初始时刻 $t = 0$ 处完整剩余代价关于控制参数的梯度可表示为与伴随状态相关的积分, 从而利用停止梯度算子导出匹配目标。Domingo-Enrich 等人 (2025a) 证明, 最优控制是该学习目标的唯一不动点。基于伴随方法的方法已应用于多项任务, 包括连续神经采样器训练 (Havens 等人, 2025; Liu 等人, 2025a; Choi 等人, 2025; Blessing 等人, 2025a)、扩散/流模型的微调 (Blessing 等人, 2025a; Liu 等人, 2025b; Domingo-Enrich 等人, 2025b) 以及过渡路径采样 (Pidstrigach 等人, 2025; Howard 等人, 2025), 展现出具有竞争力的性能。

虽然伴随方法在连续状态空间中应用广泛, 但其在离散状态空间中的泛化仍未得到探索。最近, So et al. (2026) 首次尝试将离散伴随状态定义为价值差指数的估计量, 并建立其与最优转移率的联系, 从而得到一个匹配目标, 其唯一不动点即为最优转移率。然而, 他们的训练损失需要从缓冲区样本中的中间状态进行行输出, 这较为复杂。

2. 离散扩散神经采样器 连续神经采样器的研究启发了用于学习离散分布的类似算法的构建。对于基于均匀分布的离散扩散, Holderrieth 等人 (2025) 采用了离散 Jarzynski 等式, 并通过局部等变神经网络学习传输过程; Ou 等人 (2025b) 延续并完善了这一研究方向, 提出了不同的损失公式; Kholkin 等人 (2025) 则基于目标具体分数恒等式提出了一种神经采样器。对于基于掩码的离散扩散, Zhu 等人 (2025a) 将采样问题表述为与 Zhang 和 Chen (2022) 类似的最优控制问题, 并提出了基于掩码和均匀离散扩散的采样器。最后, 离散扩散神经采样器也被用于通过从低温目标分布中采样来解决组合优化问题, 例如 Sanokowski 等人 (2023; 2024; 2025a)、Ou 等人 (2025b)、Guo 等人 (2026) 的工作。

B. 理论推导

B.1. 连续时间马尔可夫链的柯尔莫哥洛夫方程

命题 B.1. 假设 $p_{t|s}(y|x), 0 \leq s < t \leq 1$ 是转移速率为 r 的连续时间马尔可夫链的转移核。则以下方程成立:

- 柯尔莫哥洛夫前向方程:

$$\partial_t p_{t|s}(y|x) = \sum_z r_t(y, z) p_{t|s}(z|x), \quad (\text{KFE})$$

- 柯尔莫哥洛夫后向方程:

$$\partial_s p_{t|s}(y|x) = - \sum_z r_s(z, x) p_{t|s}(y|z). \quad (\text{KBE})$$

这些是连续时间马尔可夫链理论中的标准结果, 可通过利用转移速率的定义加以证明。

B.2. 薛定谔桥: 定理 3.1 的证明

我们建议读者参考 Léonard (2014) 对薛定谔桥理论的全面综述。为保持完整性, 本文在此提供一个自包含的证明。

引理 B.2. 存在某些非负函数 ϕ, φ_1 ，使得最优路径测度 p^* 满足

$$p_{(0,1)|0,1}^* = p_{(0,1)|0,1}^r, \quad (26)$$

$$p_{0,1}^*(x, y) = p_{0,1}^r(x, y)\phi(x)\varphi_1(y), \quad \text{s.t. } p_0^* = \mu, p_1^* = \nu. \quad (27)$$

换言之， $p^*(X_{[0,1]}) = p^r(X_{[0,1]})\phi(X_0)\varphi_1(X_1)$.

证明。根据 KL 散度的链式法则，可得

$$\text{KL}(p^u \| p^r) = \text{KL}(p_{0,1}^u \| p_{0,1}^r) + \mathbb{E}_{p_{0,1}^u(x_0, x_1)} \text{KL}(p_{(0,1)|0,1}^u(\cdot | x_0, x_1) \| p_{(0,1)|0,1}^r(\cdot | x_0, x_1)).$$

因此，最优 $p_{(0,1)|0,1}^u$ 为 $p_{(0,1)|0,1}^r$ ，并且我们只需解决以下静态薛定谔桥问题：

$$\begin{aligned} \min_{p_{0,1}} \text{KL}(p_{0,1} \| p_{0,1}^r) \\ \text{s.t. } p_0 = \mu, p_1 = \nu \iff \sum_y p_{0,1}(x, y) = \mu(x), \sum_x p_{0,1}(x, y) = \nu(y). \end{aligned}$$

设上述约束的拉格朗日乘子函数分别为 $\alpha(x)$ 和 $\beta(y)$ 。拉格朗日函数为

$$\begin{aligned} L(p_{0,1}, \alpha, \beta) = \sum_{x,y} p_{0,1}(x, y) \log \frac{p_{0,1}(x, y)}{p_{0,1}^r(x, y)} \\ + \sum_x \alpha(x) \left(\sum_y p_{0,1}(x, y) - \mu(x) \right) + \sum_y \beta(y) \left(\sum_x p_{0,1}(x, y) - \nu(y) \right). \end{aligned}$$

令关于 $p_{0,1}(x, y)$ 的偏导数为零，可得

$$\log \frac{p_{0,1}(x, y)}{p_{0,1}^r(x, y)} + 1 + \alpha(x) + \beta(y) = 0 \implies p_{0,1}^*(x, y) = p_{0,1}^r(x, y)e^{-1-\alpha(x)-\beta(y)}.$$

因此，通过定义 $\phi(x) := e^{-1-\alpha(x)}$ 和 $\varphi_1(y) := e^{-\beta(y)}$ ，证明完成。注意 ϕ 和 φ_1 的定义可相差一个常数缩放因子。 $\square$

引理 B.3. 定义 $\hat{\varphi}_0 := \phi p_0^r$ ，并通过以下关系定义 SB 势 φ_t 和 $\hat{\varphi}_t$ ：

$$\varphi_t(x) = \sum_y p_{1|t}^r(y|x)\varphi_1(y), \quad \hat{\varphi}_t(x) = \sum_y p_{t|0}^r(x|y)\hat{\varphi}_0(y). \quad (28)$$

则

$$\partial_t \varphi_t(x) = - \sum_y \varphi_t(y) r_t(y, x), \quad (29)$$

$$\partial_t \hat{\varphi}_t(x) = \sum_y \hat{\varphi}_t(y) r_t(x, y), \quad (30)$$

并且进一步，(11) 和 (12) 成立。

证明。首先，证明 (29) 和 (30)：

$$\begin{aligned} \partial_t \varphi_t(x) &= \sum_y \partial_t p_{1|t}^r(y|x)\varphi_1(y) \stackrel{(\text{KBE})}{=} - \sum_y \sum_z r_t(z, x) p_{1|t}^r(y|z)\varphi_1(y) = - \sum_z r_t(z, x) \varphi_t(z), \\ \partial_t \hat{\varphi}_t(x) &= \sum_y \partial_t p_{t|0}^r(x|y)\hat{\varphi}_0(y) \stackrel{(\text{KFE})}{=} \sum_y \sum_z r_t(x, z) p_{t|0}^r(z|y)\hat{\varphi}_0(y) = \sum_z r_t(x, z) \hat{\varphi}_t(z). \end{aligned}$$

接下来，我们通过验证 (11) 中对 t 的偏导数以及 (12) 中对 s 的偏导数为零来证明 (11) 和 (12)：

$$\begin{aligned}\sum_y \partial_t (p_{t|s}^r(y|x) \varphi_t(y)) &= \sum_y \sum_z r_t(y, z) p_{t|s}^r(z|x) \varphi_t(y) - \sum_y \sum_z p_{t|s}^r(y|x) r_t(z, y) \varphi_t(z) = 0, \\ \sum_y \partial_s (p_{t|s}^r(x|y) \hat{\varphi}_s(y)) &= - \sum_y \sum_z r_s(z, y) p_{t|s}^r(x|z) \hat{\varphi}_s(y) + \sum_y \sum_z p_{t|s}^r(x|y) r_s(y, z) \hat{\varphi}_s(z) = 0.\end{aligned}$$

□

(13) 的证明。我们首先研究任意时间点 $t \in [0, 1]$ 处的边缘分布：

$$\begin{aligned}p_t^*(x) &= \sum_{x_0, x_1} p_{0,1}^*(x_0, x_1) p_{t|0,1}^*(x|x_0, x_1) \stackrel{(26) \text{ and } (27)}{=} \sum_{x_0, x_1} p_{0,1}^r(x_0, x_1) \phi(x_0) \varphi_1(x_1) p_{t|0,1}^r(x|x_0, x_1) \\ &= \sum_{x_0} p_0^r(x_0) p_{t|0}^r(x|x_0) \phi(x_0) \sum_{x_1} p_{t|1}^r(x_1|x) \varphi_1(x_1) \stackrel{(28)}{=} \hat{\varphi}_t(x) \varphi_t(x).\end{aligned}$$

接下来，我们研究两个任意时间点 $0 \leq s < t \leq 1$ 处的联合分布：

$$\begin{aligned}p_{s,t}^*(x, y) &= \sum_{x_0, x_1} p_{0,1}^*(x_0, x_1) p_{s,t|0,1}^*(x, y|x_0, x_1) \\ &\stackrel{(26) \text{ and } (27)}{=} \sum_{x_0, x_1} p_{0,1}^r(x_0, x_1) \phi(x_0) \varphi_1(x_1) p_{s,t|0,1}^r(x, y|x_0, x_1) \\ &= \sum_{x_0} p_{0,s,t,1}^r(x_0, x, y, x_1) \phi(x_0) \varphi_1(x_1) \\ &= \sum_{x_0} p_0^r(x_0) p_{s|0}^r(x|x_0) \phi(x_0) \sum_{x_1} p_{t|s}^r(y|x) p_{1|t}^r(x_1|y) \varphi_1(x_1) \\ &\stackrel{(28)}{=} \hat{\varphi}_s(x) p_{t|s}^r(y|x) \varphi_t(y).\end{aligned}$$

因此，(13) 中的第二个和第三个等式立即成立。

(14) 的证明。这由引理 B.2 和 (13) 显然可得：

$$p^*(X_{[0,1]}) = p^r(X_{[0,1]}) \phi(X_0) \varphi_1(X_1) = p^r(X_{[0,1]}) \frac{\hat{\varphi}_0(X_0)}{\mu(X_0)} \varphi_1(X_1) = p^r(X_{[0,1]}) \frac{\hat{\varphi}_0(X_0)}{\mu(X_0)} \frac{\nu(X_1)}{\hat{\varphi}_1(X_1)}.$$

□

(10) 的证明。由 (13)，对于 $y \neq x$ ，

$$u_t^*(y, x) = \lim_{h \rightarrow 0} \frac{p_{t+h|t}^*(y|x)}{h} = \lim_{h \rightarrow 0} \frac{p_{t+h|t}^r(y|x)}{h} \frac{\varphi_{t+h}(y)}{\varphi_t(x)} = \frac{\varphi_t(y)}{\varphi_t(x)} \lim_{h \rightarrow 0} \frac{p_{t+h|t}^r(y|x)}{h} = \frac{\varphi_t(y)}{\varphi_t(x)} r_t(y, x).$$

□

B.3. 随机最优控制：(15) 的证明

证明。利用 KL 散度的链式法则，且由于 $p_0^u = p^r = \mu$ ，我们有

$$\text{KL}(p^u \| p^r) + \mathbb{E}_{X \sim p^u} g(X_1) = \mathbb{E}_{\mu(X_0)} \left[\mathbb{E}_{p^u(X_{(0,1]}|X_0)} \log \frac{p^u(X_{(0,1]}|X_0)}{p^r(X_{(0,1]}|X_0) e^{-g(X_1)}} \right].$$

因此，对于任意 X_0 ，最优 $p^u(X_{(0,1]}|X_0)$ 为

$$p^*(X_{(0,1]}|X_0) = \frac{1}{Z(X_0)} p^r(X_{(0,1]}|X_0) e^{-g(X_1)},$$

其中

$$Z(X_0) = \mathbb{E}_{p^r(X_{(0,1]}|X_0)} e^{-g(X_1)} = \mathbb{E}_{p_{1|0}^r(y|X_0)} e^{-g(y)}.$$

最后，将此与 $p_0^* = p^r$ 结合，完成 $= \mu$ 证明。

□

B.4. 定理 3.2 的证明

证明。参见附录 B.2 和 B.3 分别对 (14) 和 (15) 的证明。为完成证明，只需证明

当以下条件成立时的等价性 $g \leftarrow \log \frac{\hat{\varphi}_1}{\nu}$:

$$Z(x) \stackrel{(15)}{=} \sum_y \frac{p_{1|0}^r(y|x)}{\hat{\varphi}_1(y)} \nu(y) \stackrel{(13)}{=} \sum_y \frac{p_{0|1}^*(x|y)}{\hat{\varphi}_0(x)} \nu(y) = \sum_y \frac{p_{0,1}^*(x,y)}{\hat{\varphi}_0(x)} = \frac{\mu(x)}{\hat{\varphi}_0(x)}.$$

□

推论 B.4. 具有终端代价的问题 (SOC) g 等价于具有终端分布的问题 (SB)

$$\nu(x) = e^{-g(x)} \sum_y p_{1|0}^r(x|y) \frac{\mu(y)}{Z(y)}, \quad \text{其中 } Z(y) = \mathbb{E}_{p_{1|0}^r(\cdot|y)} e^{-g}.$$

证明。只需通过比较 (14) 和 (15)，用 g 表示 ν 。我们有 $\mu = \hat{\varphi}_0 Z$ 和 $\nu = \hat{\varphi}_1 e^{-g}$ 。由 (12)， $\hat{\varphi}_1(x) = \sum_y p_{1|0}^r(x|y) \hat{\varphi}_0(y)$ 。结合这三个方程即可完成证明。 □

B.5. 均匀参考动力学

我们写 $r_t(y, x) = \gamma_t r(y, x)$ 其中

$$r(y, x) = \begin{cases} \frac{1}{N}, & \text{if } d_H(y, x) = 1, \\ -D \left(1 - \frac{1}{N}\right), & \text{if } y = x, \\ 0, & \text{if otherwise.} \end{cases}$$

通过验证细致平衡条件，容易看出该转移率保持 $p_{\text{unif}} = \text{Unif}(\mathcal{X})$ 不变： $p_{\text{unif}}(x) r_t(y, x) = p_{\text{unif}}(y) r_t(x, y) = \frac{\gamma_t}{N^{D+1}} \mathbf{1}_{d_H(y,x)=1}, \forall x \neq y$.

命题 B.5. 定义 $\bar{\gamma}_{s,t} := \int_s^t \gamma_u du$ 。则对于 $x, y \in \mathcal{X}$ 和 $0 \leq s < t \leq 1$ ，参考转移概率为

$$p_{t|s}^r(y|x) = A(s, t)^{d_H(x,y)} B(s, t)^{D-d_H(x,y)}, \text{ 其中 } A(s, t) := \frac{1 - e^{-\bar{\gamma}_{s,t}}}{N}, B(s, t) := \frac{1 + (N-1)e^{-\bar{\gamma}_{s,t}}}{N}. \quad (31)$$

注：作为推论， $p_{t|s}^r(y|x) = q_t(y-x)$ where $q_t(\varepsilon) = A(t, 1)^{d_H(\varepsilon,0)} B(t, 1)^{D-d_H(\varepsilon,0)}$.

证明：注意到每个维度独立演化，其转移速率矩阵为 $\gamma_t \mathbf{R}$ ，其中 $\mathbf{R} \in \mathbb{R}^{N \times N}$ 的非对角元素为 $\frac{1}{N}$ ，对角元素为 $\frac{1}{N} - 1$, i.e., $\mathbf{R} = \frac{1}{N} \mathbf{1}\mathbf{1}^T - \mathbf{I}$ 。对于 $x \in [N]$ ，向量 $\mathbf{p}_{t|s}^r(\cdot|x) := (p_{t|s}^r(y|x))_{y \in [N]}$ 满足柯尔莫哥洛夫前向方程 $\partial_t \mathbf{p}_{t|s}^r(\cdot|x) = \gamma_t \mathbf{R} \mathbf{p}_{t|s}^r(\cdot|x)$ ，初始条件为 $\mathbf{p}_{s|s}^r(\cdot|x) = \mathbf{e}^x$ ，即第 x 个元素为 1 的独热向量。因此，我们有 $\mathbf{p}_{t|s}^r(\cdot|x) = e^{\bar{\gamma}_{s,t} \mathbf{R}} \mathbf{e}^x$ 。

矩阵指数可按如下方式计算：

$$\begin{aligned} e^{s \mathbf{1}\mathbf{1}^T} &= \sum_{k=0}^{\infty} \frac{s^k}{k!} (\mathbf{1}\mathbf{1}^T)^k = \mathbf{I} + \sum_{k=1}^{\infty} \frac{s^k}{k!} N^{k-1} \mathbf{1}\mathbf{1}^T = \mathbf{I} + \frac{e^{sN} - 1}{N} \mathbf{1}\mathbf{1}^T, \\ \implies e^{\lambda \mathbf{R}} &= e^{\frac{\lambda}{N} \mathbf{1}\mathbf{1}^T - \lambda \mathbf{I}} = e^{-\lambda} e^{\frac{\lambda}{N} \mathbf{1}\mathbf{1}^T} = e^{-\lambda} \left(\mathbf{I} + \frac{e^{\lambda} - 1}{N} \mathbf{1}\mathbf{1}^T \right) = e^{-\lambda} \mathbf{I} + \frac{1 - e^{-\lambda}}{N} \mathbf{1}\mathbf{1}^T. \end{aligned}$$

因此， $x, y \in [N]$ 的逐维转移概率为

$$p_{t|s}^r(y|x) = \begin{cases} \frac{1 - e^{-\bar{\gamma}_{s,t}}}{N} =: A(s, t) & \text{if } y \neq x, \\ \frac{1 + (N-1)e^{-\bar{\gamma}_{s,t}}}{N} =: B(s, t) & \text{if } y = x, \end{cases} \quad (32)$$

这意味着 $x, y \in \mathcal{X}$ 的完整转移概率为 (31)。

□

注：注意到当 $\bar{\gamma}_{0,1} = \infty$ 时，对所有 $x, y \in \mathcal{X}$ 有 $p_{1|0}^r(y|x) = \bar{N}^D$ ，即参考动态是无记忆的。在 $p_0^r = p_{\text{unif}}, p_t^r = p_{\text{unif}}$ 的假设下， $p_{t|1}^r(\cdot|y)$ 可按如下方式实现：对 y 的每个元素独立地，以概率 $1 - e^{-\bar{\gamma}_{t,1}}$ 将其替换为来自均匀分布 $[N]$ 的随机状态。

命题 B.6. 在参考动力学 p^r 下， $p_{t|0,1}^r(x|x_0, x_1)$ 的每个维度对于 $x, x_0, x_1 \in \mathcal{X}$ 是独立的，且每个维度的分布由下式给出

$$p_{t|0,1}^r(x|x_0, x_1) = \begin{cases} \text{if } x_0 \neq x_1 : & \begin{cases} \frac{A(0,t)A(t,1)}{A(0,1)}, & \text{if } x \notin \{x_0, x_1\}, \\ \frac{B(0,t)A(t,1)}{A(0,1)}, & \text{if } x = x_0, \\ \frac{A(0,t)B(t,1)}{A(0,1)}, & \text{if } x = x_1, \end{cases} \\ \text{if } x_0 = x_1 : & \begin{cases} \frac{A(0,t)A(t,1)}{B(0,1)}, & \text{if } x \neq x_0 = x_1, \\ \frac{B(0,t)B(t,1)}{B(0,1)}, & \text{if } x = x_0 = x_1, \end{cases} \end{cases} \quad (33)$$

对 $x, x_0, x_1 \in [N]$.

证明。由于 p^r 的马尔可夫性质，我们有

$$p_{t|0,1}^r(x|x_0, x_1) = \frac{p_{0,t,1}^r(x_0, x, x_1)}{p_{0,1}^r(x_0, x_1)} = \frac{p_{t|0}^r(x|x_0)p_{1|t}^r(x_1|x)}{p_{1|0}^r(x_1|x_0)}.$$

再次注意，在 p^r 下每个维度是独立的。利用每个维度的转移概率 (32)，可以容易地得到所需结果。 $\square$

噪声调度的选择 γ_t 我们考虑以下噪声调度：

- Constant schedule: $\gamma_t \equiv \gamma > 0, \bar{\gamma}_{s,t} = \gamma(t-s)$.
- 修正的对数线性调度: $\gamma_t = \frac{\gamma}{t+\alpha}$ 对于某个 $\gamma, \alpha > 0, \bar{\gamma}_{s,t} = \gamma \log \frac{t+\alpha}{s+\alpha}$ 。较大的 α 意味着更强的记忆效应，而 $\alpha = 0$ 恢复无记忆情形。

噪声调度的消融研究可见于图 2 和图 3。

B.6. 基于 τ -跳跃的推理

命题 B.7. 利用 τ -跳跃对受控连续时间马尔可夫链进行离散化，任意维度 d 的转移概率近似为

$$\Pr(X_{t+h}^d = n | X_t = x) \approx \begin{cases} \frac{\bar{\gamma}_{t,t+h}}{N} \Phi_t(x)_{d,n}, & \text{if } n \neq x^d, \\ 1 - \frac{\bar{\gamma}_{t,t+h}}{N} \sum_{n' \neq x^d} \Phi_t(x)_{d,n'}, & \text{if } n = x^d. \end{cases}$$

近似转移概率可计算为

$$\begin{aligned} p_{t+h|t}^u(y|x) &\approx \prod_{d=1}^D \Pr(X_{t+h}^d = y^d | X_t = x) \\ &= \prod_{d=1}^D \left(\frac{\bar{\gamma}_{t,t+h}}{N} \Phi_t(x)_{d,y^d} \right)^{1_{y^d \neq x^d}} \left(1 - \frac{\bar{\gamma}_{t,t+h}}{N} \sum_{n' \neq x^d} \Phi_t(x)_{d,n'} \right)^{1_{y^d = x^d}}. \end{aligned} \quad (34)$$

我们在算法 1 中总结了采样过程。注意，对于均匀离散扩散模型，也可以应用其他采样器，如均匀化 (Chen & Ying, 2025; Ren et al., 2025a) 和高阶 τ -跳跃 (Ren et al., 2025b)，我们将其留作未来工作。

Algorithm 1 Sampling of discrete adjoint Schrödinger bridge sampler (DASBS) via τ -leaping

Require: Model Φ , initial distribution μ , time discretization $0 = t_0 < t_1 < \dots < t_M = 1$.

- 1: Sample initial state $x_0 \sim \mu$.
- 2: **for** $i = 0$ **to** $M - 1$ **do**
- 3: Query $\Phi_{t_i}(x_i) \in \mathbb{R}_+^{D \times N}$ and compute $\bar{\gamma}_{t_i, t_{i+1}}$.
- 4: For each $d \in [D]$ (in parallel), independently sample

$$\Pr(x_{i+1}^d = n) = \begin{cases} \frac{\bar{\gamma}_{t_i, t_{i+1}} \Phi_{t_i}(x_i)_{d,n}}{N}, & \text{if } n \neq x_i^d, \\ 1 - \frac{\bar{\gamma}_{t_i, t_{i+1}}}{N} \sum_{n' \neq x_i^d} \Phi_{t_i}(x_i)_{d,n'}, & \text{if } n = x_i^d. \end{cases}$$

5: **end for**

output x_M as the generated sample.

B.7. 目标匹配损失

(23) 的证明。

$$\begin{aligned} \hat{\varphi}_1(z) &\stackrel{(12)}{=} \sum_{x \in \mathbb{Z}_N^D} p_{1|t}^r(z|x) \hat{\varphi}_t(x) \stackrel{(17)}{=} \sum_{x \in \mathbb{Z}_N^D} p_{1|t}^r(z + \Delta|x + \Delta) \hat{\varphi}_t(x) \\ &\stackrel{x' \leftarrow x + \Delta}{=} \sum_{x' \in \mathbb{Z}_N^D} p_{1|t}^r(z + \Delta|x') \hat{\varphi}_t(x' - \Delta) \stackrel{\Delta \leftarrow y - z}{=} \sum_{x' \in \mathbb{Z}_N^D} p_{1|t}^r(y|x') \hat{\varphi}_t(x' - y + z), \\ \Rightarrow \frac{\hat{\varphi}_1(z)}{\hat{\varphi}_1(y)} &= \sum_x p_{1|t}^r(y|x) \frac{\hat{\varphi}_t(x - y + z)}{\hat{\varphi}_1(y)} \stackrel{(13)}{=} \sum_x p_{t|1}^*(x|y) \frac{\hat{\varphi}_t(x - y + z)}{\hat{\varphi}_t(x)}. \end{aligned}$$

□

B.8. 去噪匹配损失

我们首先证明控制器的去噪匹配刻画：

$$\frac{\varphi_t(y)}{\varphi_t(x)} \stackrel{(11)}{=} \sum_z p_{1|t}^r(z|y) \frac{\varphi_1(z)}{\varphi_t(x)} = \sum_z \frac{p_{1|t}^r(z|y)}{p_{1|t}^r(z|x)} \frac{p_{1|t}^r(z|x) \varphi_1(z)}{\varphi_t(x)} \stackrel{(13)}{=} \sum_z \frac{p_{1|t}^r(z|y)}{p_{1|t}^r(z|x)} p_{1|t}^*(z|x), \quad (35)$$

$$\Rightarrow \Phi^* = \underset{\Phi}{\operatorname{argmin}} \mathbb{E}_t \mathbb{E}_{p_{t,1}^*(x, x_1)} \sum_{d=1}^D \sum_{n \neq x^d} D_f \left(\frac{p_{1|t}^r(x_1 | x^{d \leftarrow n})}{p_{1|t}^r(x_1 | x)} \left\| \Phi_t(x)_{d,n} \right\| \right). \quad (36)$$

因此，控制器的去噪匹配损失为

$$\Phi^{(k)} := \underset{\Phi}{\operatorname{argmin}} \mathbb{E}_t w_t \mathbb{E}_{\substack{p_{0,1}^{\operatorname{sg}(r\Phi)}(x_0, x_1) \\ p_{t|0,1}^r(x|x_0, x_1)}} \sum_{d=1}^D \sum_{n \neq x^d} D_f \left(\frac{p_{1|t}^r(x_1 | x^{d \leftarrow n})}{p_{1|t}^r(x_1 | x)} \left\| \Phi_t(x)_{d,n} \right\| \right). \quad (\text{ctrl-DM})$$

此外， Φ^* 在去噪匹配风格下的变分刻画如下：

$$\hat{\Phi}^* = \underset{\hat{\Phi}}{\operatorname{argmin}} \mathbb{E}_t \mathbb{E}_{p_{t,1}^*(x, x_1)} \sum_{d=1}^D \sum_{n \neq x^d} D_f \left(\frac{p_{1|t}^r(x_1^{d \leftarrow n} | x)}{p_{1|t}^r(x_1 | x)} \left\| \hat{\Phi}(x_1)_{d,n} \right\| \right).$$

B.9. 轨迹重要性重加权

所谓轨迹重要性重加权，是指在计算损失（ctrl-AM）至（corr-DM）时，使用 $\text{RND } p^*(x|0, 1) \frac{p^u(x|0, 1)}{p^{sg(r\Phi)}(x|0, 1)}$ 的做法。例如，（corr-AM）变为如下形式：

$$\Phi^{(k)} := \underset{\Phi}{\operatorname{argmin}} \mathbb{E}_t w_t \left[\frac{\mathbb{E}_{p^{sg(r\Phi)}(x|0, 1)} \frac{p^*(x|0, 1)}{p^{sg(r\Phi)}(x|0, 1)}}{\mathbb{E}_{p_{t|0, 1}^r(x|x_0, x_1)} \sum_{d=1}^D \sum_{n \neq x^d} D_f \left(\frac{\varphi_1(x_1^{d \leftarrow x_1^d + n - x^d})}{\varphi_1(x_1)} \right) \left\| \Phi_t(x)_{d, n} \right\|} \right].$$

在实践中，为了稳定性，在获得一批轨迹上相差一个加性常数的对数 $\text{RND } \log p^*(x|0, 1) \frac{p^u(x|0, 1)}{p^{sg(r\Phi)}(x|0, 1)}$ 之后，通常应用 Softmax 函数将权重之和归一化为 1。

利用命题 B.5 和 B.7，我们可以近似计算 $\log p^u(x|0, 1)$

$\frac{p^r(x|0, 1)}{p^u(x|0, 1)}$ 。采用以下近似

引理 B.8，我们可以近似重要性采样的对数权重， $\log p^*(x|0, 1)$

$\frac{1}{p^u(x|0, 1)}$ 。

引理 B.8. 当参考动力学无记忆时， $\log p^*(x|0, 1) \frac{p^u(x|0, 1)}{p^{sg(r\Phi)}(x|0, 1)} \approx \log \frac{\nu(x_1)}{p_1^r(x_1)} + \text{常数}$ ；否则，对数 RND 可按如下方式计算和近似：

$$\log \frac{p^*(x|0, 1)}{p^r(x|0, 1)} = \int_0^1 \sum_{y \neq x_t} \left(1 - \frac{\varphi_t(y)}{\varphi_t(x_t)} \right) r_t(y, x_t) dt + \sum_{t: x_{t-} \neq x_t} \log \frac{\varphi_t(x_t)}{\varphi_t(x_{t-})} \quad (37)$$

$$\approx \sum_{i=0}^{M-1} \left[\sum_{d=1}^D \sum_{n \neq x_{t_i}^d} \frac{\bar{\gamma}_{t_i, t_{i+1}}}{N} (1 - \Phi_{t_i}(x_{t_i})_{d, n}) + \sum_{d: x_{t_i}^d \neq x_{t_{i+1}}^d} \log \Phi_{t_i}(x_{t_i})_{d, x_{t_{i+1}}^d} \right], \quad (38)$$

其中 $0 = t_0 < \dots < t_M = 1$ 是离散化的时间点。

证明。由 (14) 式，可得 $\log p^*(x|0, 1) \frac{p^u(x|0, 1)}{p^{sg(r\Phi)}(x|0, 1)} = \log \frac{\varphi_1(x_1)}{\varphi_0(x_0)}$ 。当无记忆时，按照第 3, φ_0 节的论证， $\varphi_0 = \text{常数}$ ， $\log \varphi_1 = \log \frac{\nu}{\varphi_1} = \log \frac{\nu}{p_1^r} + \text{常数}$ ，即得所需结果。

对于一般情况，受 Liu 等人 (2025a, 附录 D.4) 中讨论的启发：(29) 式意味着

$$\partial_t \varphi_t(x) = \sum_{y \neq x} (\varphi_t(x) - \varphi_t(y)) r_t(y, x) \implies \partial_t \log \varphi_t(x) = \sum_{y \neq x} \left(1 - \frac{\varphi_t(y)}{\varphi_t(x)} \right) r_t(y, x).$$

因此，我们有

$$\begin{aligned} \log \frac{\varphi_1(x_1)}{\varphi_0(x_0)} &= \int_0^1 \partial_t \log \varphi_t(x_t) dt + \sum_{t: x_{t-} \neq x_t} \log \frac{\varphi_t(x_t)}{\varphi_t(x_{t-})} \\ &= \int_0^1 \sum_{y \neq x_t} \left(1 - \frac{\varphi_t(y)}{\varphi_t(x_t)} \right) r_t(y, x_t) dt + \sum_{t: x_{t-} \neq x_t} \log \frac{\varphi_t(x_t)}{\varphi_t(x_{t-})}. \end{aligned}$$

在我们的设定下，第一项中的求和可以很容易地计算：

$$\sum_{y \neq x_t} \left(1 - \frac{\varphi_t(y)}{\varphi_t(x_t)} \right) r_t(y, x_t) = \sum_{d=1}^D \sum_{n \neq x_t^d} \left(1 - \frac{\varphi_t(x_t^{d \leftarrow n})}{\varphi_t(x_t)} \right) r_t(x_t^{d \leftarrow n}, x_t) = \sum_{d=1}^D \sum_{n \neq x_t^d} (1 - \Phi_t^*(x_t)_{d, n}) \frac{\gamma_t}{N}.$$

对于第二项，理论上， x_{t-} 和 x_t 仅相差一个维度，但在离散化过程中，多个维度可能同时改变。一种启发式近似是将其分解为多个单维度变化：

$$\log \frac{\varphi_t(x_t)}{\varphi_t(x_{t-})} \approx \sum_{d: x_{t-}^d \neq x_t^d} \log \frac{\varphi_t(x_{t-}^{d \leftarrow x_t^d})}{\varphi_t(x_{t-})} = \sum_{d: x_{t-}^d \neq x_t^d} \log \Phi_t^*(x_{t-})_{d, x_t^d}.$$

因此，我们可以将时间离散轨迹上 $p^*(x_{[0,1]})$ 的近似计算总结如下：在时间离散轨迹上

$$\overline{p^r(x_{[0,1]})} = \frac{\varphi_1(x_1)}{\varphi_0(x_0)}$$

$(x_{t_0}, x_{t_1}, \dots, x_{t_M})$ 如下：

$$\log \frac{\varphi_1(x_1)}{\varphi_0(x_0)} \approx \sum_{i=0}^{M-1} \left[\sum_{d=1}^D \sum_{n \neq x_{t_i}^d} \frac{\bar{\gamma}_{t_i, t_{i+1}}}{N} (1 - \Phi_{t_i}^*(x_{t_i})_{d,n}) + \sum_{d: x_{t_i}^d \neq x_{t_{i+1}}^d} \log \Phi_{t_i}^*(x_{t_i})_{d, x_{t_{i+1}}^d} \right].$$

最后，由于真实值 Φ^* 不可得，我们使用 Φ 来近似其值。证明完毕。

□

注：与刘等人 (2025a, 附录 D.4) 提出的方法不同，这里我们无需沿轨迹训练 $\frac{\hat{\varphi}_t(y)}{\hat{\varphi}_0(y)}$ 。沿轨迹。

这是因为这里我们通过 $\varphi_1(x_1)$ 进行推导 $\frac{\hat{\varphi}_1(x_1)}{\hat{\varphi}_0(x_0)}$ 而不是

注：在掩码扩散的情况下，路径测度 p^u 可以被精确采样，并且给定轨迹上的对数相对归一化密度 (log RND) 可以精确计算；然而，这里估计的对数 $p^*(x_{[0,1]})$ 涉及时间离散化误差 $p^u(x_{[0,1]})$ 差，此外，在非无记忆情况下使用 (38) 还会引入学习误差。这可能解释了即使在 convergence.

B.10. DASBS 与 WDCE 之间的联系

命题 B.9. 假设 $\bar{\gamma}_{0,1} = \infty$ ，即参考路径测度 p^r 是无记忆的。那么用于训练控制器 (ctrl-DM) 的去噪损失，结合轨迹重要性重加权， D_f 为广义 KL 发散， γ_t 和时间权重 $w_t \leftarrow \frac{\gamma_t}{N}$ ，可简化为 UDNS 中的去噪交叉熵 (WDCE) 损失 (Zhu 等人, 2025a, 附录 F)，其等于 $\text{KL}(p^* \| p^u) + \text{常数}$ 。

证明。Zhu 等人 (2025a, 第 39 页) 的第一个方程 (使用本文的符号) 为

$$\text{KL}(p^* \| p^u) = \mathbb{E}_{p^{\text{sg}}(u)(\bar{x}_{[0,1]})} \frac{p^*(\bar{x}_{[0,1]})}{p^{\text{sg}}(u)(\bar{x}_{[0,1]})} \mathbb{E}_t \frac{\gamma_t}{N} \mathbb{E}_{p_{t|1}^*(x|\bar{x}_1)} \sum_{d=1}^D \sum_{n \neq x^d} D_f \left(\frac{p_{t|1}^*(x^{d \leftarrow n} | \bar{x}_1)}{p_{t|1}^*(x | \bar{x}_1)} \middle| \Phi_t(x)_{d,n} \right) + \text{const},$$

其中 D_f 是广义 KL 发散。在无记忆假设下，我们有 $p_{t|1}^*(x|x_1) = p_{t|1}^r(x|x_1)$ 。由于对称性 $p_{t|1}^r(x|x_1) = p_{t|1}^r(x_1|x)$ ，与 (ctrl-DM) 的等价性是显然的。

□

命题 B.10. 考虑掩码增强状态空间

$\mathcal{X} = \{1, \dots, N, \mathbf{M}\}^D$ 。设参考转移速率为

$$r_t(y, x) = \begin{cases} \frac{\gamma_t}{N}, & \text{if } y = x^{d \leftarrow n}, x^d = \mathbf{M}, n \in [N], \\ -\gamma_t |\{d : x^d = \mathbf{M}\}|, & \text{if } y = x, \\ 0, & \text{otherwise,} \end{cases} \quad (39)$$

对于某个噪声调度 $\gamma : [0, 1] \rightarrow \mathbb{R}_+$ 。令 $\bar{\gamma}_{s,t} := \int_s^t \gamma_u du$ 对于 $0 \leq s < t \leq 1$ ，并假设 $\bar{\gamma}_{t,1} = \infty$ 对于任意 $0 \leq t < 1$ 。那么，用于训练控制器 (ctrl-DM) 的去噪损失，结合轨迹重要性加权， D_f 为广义 KL 散度， γ_t 以及时间权重 $\frac{\gamma_t}{N}$ ，简化为 MDNS 中的 WDCE 损失 (Zhu 等人, 2025a)，这也等于 $\text{KL}(p^* \| p^u) + \text{常数}$ 。

证明。在整个证明过程中，我们始终假设 $n \in [N]$ 是非掩码状态。根据 Zhu 等人 (2025a)，我们有以下结果：

$$\begin{aligned}
 u_t^*(x^{d \leftarrow n}, x) &= \gamma_t \Pr_{X \sim \nu} (X^d = n | X^{\text{UM}} = x^{\text{UM}}) 1_{x^d = \mathbf{M}} \\
 \Phi_t^*(x)_{d,n} &= \frac{\varphi_t(x^{d \leftarrow n})}{\varphi_t(x)} = N \Pr_{X \sim \nu} (X^d = n | X^{\text{UM}} = x^{\text{UM}}) 1_{x^d = \mathbf{M}} \\
 p_{t|s}^r(y|x) &= \prod_{d: x^d = \mathbf{M}} \left(\frac{1 - e^{-\bar{\gamma}_{s,t}}}{N} \right)^{1_{y^d \neq \mathbf{M}}} (e^{-\bar{\gamma}_{s,t}})^{1_{y^d = \mathbf{M}}} \cdot \prod_{d: x^d \neq \mathbf{M}} 1_{x^d = y^d}, \quad 0 \leq s < t \leq 1 \\
 \implies \frac{p_{1|t}^r(x_1 | x^{d \leftarrow n})}{p_{1|t}^r(x_1 | x)} &= N 1_{x_1^d = n} 1_{x^d = \mathbf{M}} \text{ (suppose } \forall d \text{ s.t. } x^d \neq \mathbf{M}, x_1^d = x^d)
 \end{aligned}$$

Let $s_\theta : \mathcal{X} \rightarrow \mathbb{R}_{\geq 0}^{D \times N}$ 是用于学习 ν , i.e., $s_\theta(x)_{d,n} \approx \Pr_{X \sim \nu}(X^d = n | X^{\text{UM}} = x^{\text{UM}})$ 对 $x^d = \mathbf{M}$, 并且 $s_\theta(x)_{d,n} = 1_{x^d = n}$ 对 $x^d \neq \mathbf{M}$ 。我们假设 $\sum_{n=1}^N s_\theta(x)_{d,n} = 1$ 对于所有 d 。因此, 采用广义 KL 散度, 结合轨迹重要性重新加权的损失 (ctrl-DM) 变为

$$\begin{aligned}
 &\mathbb{E}_t w_t \mathbb{E}_{p^{\text{sg}(\theta)}(x_{[0,1]})} \frac{dp^*}{dp^{\text{sg}(\theta)}}(x_{[0,1]}) \mathbb{E}_{p_{t|1}^r(x|x_0, x_1)} \sum_{d=1}^D \sum_{n \neq x^d} D_f(N 1_{x_1^d = n} 1_{x^d = \mathbf{M}} \| N s_\theta(x)_{d,n} 1_{x^d = \mathbf{M}} + 1_{x^d = n}) \\
 &= \mathbb{E}_t w_t \mathbb{E}_{p^{\text{sg}(\theta)}(x_{[0,1]})} \frac{dp^*}{dp^{\text{sg}(\theta)}}(x_{[0,1]}) \mathbb{E}_{p_{t|1}^r(x|x_1)} \sum_{d: x^d = \mathbf{M}} \sum_{n=1}^N D_f(N 1_{x_1^d = n} \| N s_\theta(x)_{d,n}) \\
 &= \mathbb{E}_t w_t \mathbb{E}_{p^{\text{sg}(\theta)}(x_{[0,1]})} \frac{dp^*}{dp^{\text{sg}(\theta)}}(x_{[0,1]}) \mathbb{E}_{p_{t|1}^r(x|x_1)} \sum_{d: x^d = \mathbf{M}} \sum_{n=1}^N \left(N 1_{x_1^d = n} \log \frac{1_{x_1^d = n}}{s_\theta(x)_{d,n}} - N 1_{x_1^d = n} + N s_\theta(x)_{d,n} \right) \\
 &= \mathbb{E}_t w_t \mathbb{E}_{p^{\text{sg}(\theta)}(x_{[0,1]})} \frac{dp^*}{dp^{\text{sg}(\theta)}}(x_{[0,1]}) \mathbb{E}_{p_{t|1}^r(x|x_1)} \sum_{d: x^d = \mathbf{M}} -N \log s_\theta(x)_{d, x_1^d} + \text{const.}
 \end{aligned}$$

因此, 当 $t \sim$ 均匀分布于 $(0, 1)$ 且时间权重为 $\frac{\gamma_t}{N}$ 时, 损失

$$\min_{\theta} \mathbb{E}_{p^{\text{sg}(\theta)}(x_{[0,1]})} \frac{dp^*}{dp^{\text{sg}(\theta)}}(x_{[0,1]}) \mathbb{E}_{t \sim \text{Unif}(0,1)} \gamma_t \mathbb{E}_{p_{t|1}^r(x|x_1)} \sum_{d: x^d = \mathbf{M}} -\log s_\theta(x)_{d, x_1^d},$$

若在掩码扩散模型中选择规范噪声调度, 则其与 Zhu 等人 (2025a) 中的 WDCE 损失完全一致: $\gamma_t = \frac{1}{t}$ 。 $\square$

B.11. 交替更新的收敛性: 定理 5.2 的证明

定义 B.11. 对于函数 $\psi : \mathcal{X} \rightarrow \mathbb{R}_+$, 本文使用 q^ψ 表示由后向转移速率 $u_t^\leftarrow(y, x) = \frac{\psi_t(y)}{\psi_t(x)}$ 诱导的 CTMC $(Y_t)_{t \in [0, 1]}$ 的路径测度。
 $r_t(x, y)$, $y \neq x$ and initialized at $Y_1 \sim \nu$, where ψ_t satisfies $\psi_t(x) = \sum_y p_{t|0}^r(x|y) \psi_0(y)$, $\psi_1 = \psi$. In other words,

$$u_t^\leftarrow(y, x) = \lim_{h \rightarrow 0} \frac{\Pr(Y_{t-h} = y | Y_t = x) - 1_{x=y}}{h}.$$

注: 根据贝叶斯公式, 可以得到其等价的前向转移速率 (Kelly, 2011): 对于 $y \neq x$,

$$\begin{aligned}
 u_t^\rightarrow(y, x) &= \lim_{h \rightarrow 0} \frac{1}{h} \Pr(Y_{t+h} = y | Y_t = x) = \lim_{h \rightarrow 0} \frac{1}{h} \frac{\Pr(Y_t = x | Y_{t+h} = y) \Pr(Y_{t+h} = y)}{\Pr(Y_t = x)} \\
 &= \lim_{h \rightarrow 0} \frac{1}{h} \frac{q_{t+h}^\psi(y)}{q_t^\psi(x)} (u_{t+h}^\leftarrow(x, y) h + o(h)) = \frac{q_t^\psi(y)}{q_t^\psi(x)} u_t^\leftarrow(x, y) = \frac{(q_t^\psi / \psi_t)(y)}{(q_t^\psi / \psi_t)(x)} r_t(y, x).
 \end{aligned}$$

B.11.1. 定理 5.2 第 (1) 部分的证明

Proof. Let $(Y_t)_{t \in [0,1]} \sim q^{\widehat{\varphi}_1^{(k-1)}} =: q$. By (KFE),

$$\begin{aligned} \partial_t q_t(x) &= \sum_y q_t(y) u_t^{\rightarrow}(x, y) = \sum_{y \neq x} (q_t(y) u_t^{\rightarrow}(x, y) - q_t(x) u_t^{\rightarrow}(y, x)) \\ &= \sum_{y \neq x} \left(\frac{(q_t/\psi_t)(x)}{(q_t/\psi_t)(y)} r_t(x, y) q_t(y) - \frac{(q_t/\psi_t)(y)}{(q_t/\psi_t)(x)} r_t(y, x) q_t(x) \right), \\ \implies \partial_t \log q_t(x) &= \sum_{y \neq x} \left(\frac{\psi_t(y)}{\psi_t(x)} r_t(x, y) - \frac{(q_t/\psi_t)(y)}{(q_t/\psi_t)(x)} r_t(y, x) \right). \end{aligned}$$

另一方面，再次利用 (KFE)，

$$\begin{aligned} \partial_t \psi_t(x) &= \sum_y \partial_t p_{t|0}^r(x|y) \psi_0(y) = \sum_y \sum_z r_t(x, z) p_{t|0}^r(z|y) \psi_0(y) = \sum_z r_t(x, z) \psi_t(z) \\ &= \sum_{y \neq x} (r_t(x, y) \psi_t(y) - r_t(y, x) \psi_t(x)), \\ \implies \partial_t \log \psi_t(x) &= \sum_{y \neq x} \left(r_t(x, y) \frac{\psi_t(y)}{\psi_t(x)} - r_t(y, x) \right). \end{aligned}$$

现在计算 $\text{KL}(p^u \| q)$ ，其中 p^u 是由转移速率 u_t 和初始分布诱导的 CTMC $(X_t)_{t \in [0, 1]}$ 的路径测度。
 μ :

$$\begin{aligned} \text{KL}(p^u \| q) &= \text{KL}(\mu \| q_0) + \mathbb{E}_{p^u(X)} \int_0^1 \sum_{y \neq X_t} \left(u_t \log \frac{u_t}{u_t^{\rightarrow}} + u_t^{\rightarrow} - u_t \right) (y, X_t) dt \\ &= \text{KL}(\mu \| q_0) + \mathbb{E}_{p^u(X)} \int_0^1 \sum_{y \neq X_t} \left[\left(u_t \log \frac{u_t}{r_t} + r_t - u_t \right) (y, X_t) \right. \\ &\quad \left. + \left(-u_t(y, X_t) \log \frac{(q_t/\psi_t)(y)}{(q_t/\psi_t)(X_t)} + \frac{(q_t/\psi_t)(y)}{(q_t/\psi_t)(X_t)} r_t(y, X_t) - r_t(y, X_t) \right) \right] dt. \end{aligned}$$

第二项为 $\text{KL}(p^u \| p^r)$ 。为处理第三项，本文利用引理 B.13:

$$\begin{aligned} \mathbb{E}_{p^u(X)} \log \frac{(\psi_1/q_1)(X_1)}{(\psi_0/q_0)(X_0)} &= \mathbb{E}_{p^u(X)} \left[\int_0^1 (\partial_t \log \psi_t(X_t) - \partial_t \log q_t(X_t)) dt + \sum_{t: X_{t-} \neq X_t} \log \frac{(\psi_t/q_t)(X_t)}{(\psi_t/q_t)(X_{t-})} \right] \\ &= \mathbb{E}_{p^u(X)} \int_0^1 \sum_{y \neq X_t} \left(\frac{(q_t/\psi_t)(y)}{(q_t/\psi_t)(X_t)} r_t(y, X_t) - r_t(y, X_t) \right) dt \\ &\quad + \mathbb{E}_{p^u(X)} \int_0^1 \sum_{y \neq X_t} u_t(y, X_t) \log \frac{(\psi_t/q_t)(y)}{(\psi_t/q_t)(X_t)} dt. \end{aligned}$$

因此，本文得出结论:

$$\begin{aligned} \text{KL}(p^u \| q) &= \text{KL}(p^u \| p^r) + \mathbb{E}_{p^u(X)} \log \frac{(\psi_1/q_1)(X_1)}{(\psi_0/q_0)(X_0)} + \text{const} \\ &= \text{KL}(p^u \| p^r) + \mathbb{E}_{p^u(X)} \log \frac{\psi_1}{q_1}(X_1) + \text{const} \\ &= \text{KL}(p^u \| p^r) + \mathbb{E}_{p^u(X)} \log \frac{\widehat{\varphi}_1^{(k-1)}}{\nu}(X_1) + \text{const}, \end{aligned}$$

其中常数不依赖于 u 。因此，这是一个具有终端代价 $g \leftarrow \log \frac{\widehat{\varphi}_1^{(k-1)}}{\nu}$ 的最优控制问题。设该最优控制问题的最优路径测度为 $p^{(k)}$ ，并通过将该最优控制问题与等价的薛定谔桥问题相关联，

推论 B.4, 设该问题的薛定谔桥位势为 $(\varphi_t^{(k)}, \hat{\varphi}_t^{(k)} = e^{-g} = \frac{\nu}{\hat{\varphi}_1^{(k-1)}})$ 。则根据推论 B.4, $\varphi_1^{(k)}$ 。由与式 (19) 类似的论证, 本文可利用加性噪声得到 附录 B.2 及

$$\frac{\varphi_t^{(k)}(y)}{\varphi_t^{(k)}(x)} = \mathbb{E}_{p_{1|t}^{(k)}(x_1|x)} \frac{\varphi_1^{(k)}(x_1 + y - x)}{\varphi_1^{(k)}(x_1)} = \mathbb{E}_{p_{1|t}^{(k)}(x_1|x)} \frac{(\nu/\hat{\varphi}_1^{(k-1)})(x_1 + y - x)}{(\nu/\hat{\varphi}_1^{(k-1)})(x_1)}.$$

另一方面, 根据布雷格曼散度的性质, 控制平均场 $\Phi^{(k)}$ 的唯一不动点满足

$$\Phi_t^{(k)}(x)_{d,n} = \mathbb{E}_{p_{1|t}^{r\Phi^{(k)}}(x_1|x)} \frac{(\nu/\hat{\varphi}_1^{(k-1)})(x^{d \leftarrow x_1^d + n - x^d})}{(\nu/\hat{\varphi}_1^{(k-1)})(x)}.$$

Thus, we conclude that $\Phi_t^{(k)}(x)_{d,n} = \frac{\varphi_t^{(k)}(x^{d \leftarrow n})}{\varphi_t^{(k)}(x)}$. □

B.11.2. 定理 5.2 第 (2) 部分的证明

证明。通过使用贝叶斯公式的类似论证, 我们可以将 $p^{r\Phi^{(k)}} =: p$ 写成一个从 p_1 初始化的后向连续时间马尔可夫链, 其后向转移速率为

$$u_t^{\leftarrow(k)}(y, x) = \frac{(p_t^{(k)}/\varphi_t^{(k)})(y)}{(p_t^{(k)}/\varphi_t^{(k)})(x)} r_t(x, y) = \frac{\hat{\varphi}_t^{(k)}(y)}{\hat{\varphi}_t^{(k)}(x)} r_t(x, y),$$

其中 $\varphi_t^{(k)}$ 和 $\hat{\varphi}_t^{(k)}$ 是第一部分证明中 SOC 问题的薛定谔桥势。那么, 对于任何从 $Y_1 \sim \nu$ 初始化、后向转移速率为 $u_t^{\leftarrow(k)}$ 的后向连续时间马尔可夫链 $(Y_t)_{t \in [0, 1]} \sim q$, 我们有

$$\text{KL}(p\|q) = \text{KL}(p_1\|\nu) + \mathbb{E}_{X \sim p} \int_0^1 \sum_{y \neq X_t} \left(u_t^{\leftarrow(k)} \log \frac{u_t^{\leftarrow(k)}}{u_t^{\leftarrow}} + u_t^{\leftarrow} - u_t^{\leftarrow(k)} \right) (y, X_t) dt.$$

因此, 显然最优的 $u_t^{\leftarrow}(y, x)$ 等于 $u_t^{\leftarrow(k)}$, 即最优 (定义 B.11)。 $(y, x) = \frac{\hat{\varphi}_t^{(k)}(y)}{\hat{\varphi}_t^{(k)}(x)} r_t(x, y)$ q is $q^{\hat{\varphi}_1^{(k)}}$
通过与 (12) 证明中类似的论证, 我们有 $\hat{\varphi}_t(x) = \sum_y p_{t|0}^r(x|y) \hat{\varphi}_0(y)$

半桥问题的最优 q 是 $q^{\hat{\varphi}_1^{(k)}}$ 。另一方面, 通过与 (22) 和 (25) 类似的论证,

$$\frac{\hat{\varphi}_1^{(k)}(z)}{\hat{\varphi}_1^{(k)}(y)} = \mathbb{E}_{p_{t|1}^{(k)}(x|y)} \frac{p_{1|t}^r(z|x)}{p_{1|t}^r(y|x)} = \mathbb{E}_{p_{t|1}^{(k)}(x|y)} \frac{\hat{\varphi}_0^{(k)}(x - y + z)}{\hat{\varphi}_0^{(k)}(x)} = \frac{(\mu/\varphi_0^{(k)})(x - y + z)}{(\mu/\varphi_0^{(k)})(x)}.$$

另一方面, 利用布雷格曼散度的性质, (corr-DM) 的唯一不动点满足

$$\frac{\hat{\varphi}_1^{(k)}(x^{d \leftarrow n})}{\hat{\varphi}_1^{(k)}(x)} = \mathbb{E}_{p_{t|1}^{(k)}(x_0|x)} \frac{p_{1|t}^r(x_1^{d \leftarrow n}|x)}{p_{1|t}^r(x_1|x)},$$

而 (corr-AM) 的唯一不动点满足

$$\frac{\hat{\varphi}_1^{(k)}(x^{d \leftarrow n})}{\hat{\varphi}_1^{(k)}(x)} = \mathbb{E}_{p_{t|1}^{(k)}(x_0|x)} \frac{(\mu/\varphi_0^{(k)})(x_0^{d \leftarrow x_0^d + n - x_1^d})}{(\mu/\varphi_0^{(k)})(x_0)}.$$

通过比较上述三个方程, 证明完成。 □

B.12. 其他省略的结果与证明

命题 B.12. 假设 $\mu = p_{\text{unif}}$ 。利用参考转移率 (16), 将控制器初始化为 1 (即令 $\Phi_t^{(0)}(x)_{d,n} = 1$ 对所有 $n \neq x^d$), 并交替训练校正器和控制器, 等价于将校正器初始化为 1 (即令 $\Phi_t^{(0)}(x)_{d,n} = 1$ 对所有 $n \neq x^d$), 并交替训练控制器和校正器。

证明。假设令 $\Phi_t^{(0)}(x)_{d,n} = 1$ 对所有 $n \neq x^d$ 。则最优校正器可计算如下：

$$\begin{aligned}\widehat{\Phi}^{(1)}(x_1)_{d,n} &= \mathbb{E}_{p_{t|1}^r(x|x_1)} \frac{p_{1|t}^r(x_1^{d \leftarrow n}|x)}{p_{1|t}^r(x_1|x)} = \sum_x \frac{p_{t|1}^r(x|x_1)}{p_{1|t}^r(x_1|x)} p_{1|t}^r(x_1^{d \leftarrow n}|x) \\ &= \sum_x \frac{p_t^r(x)}{p_1^r(x_1)} p_{1|t}^r(x_1^{d \leftarrow n}|x) = \frac{1}{p_1^r(x_1)} \sum_x p_t^r(x) p_{1|t}^r(x_1^{d \leftarrow n}|x) = \frac{p_1^r(x_1^{d \leftarrow n})}{p_1^r(x_1)}.\end{aligned}$$

因此，在 (16) 下，当 $p_0^r = \mu = p_{\text{unif}}$ ，有 $p_1^r = p_{\text{unif}}$ ，so $\widehat{\Phi}^{(1)}(x_1)_{d,n} = 1$ 对于所有 $n \neq x_1^d$ 。 $\square$

注：我们指出，该选择与假设 p^r 无记忆时的最优校正器一致，因为在无记忆条件下 $\widehat{\varphi}_1 \propto p_1^r$ 。

引理 B.13. 对于具有转移速率 u_t 的连续时间马尔可夫链 (CTMC) $(X_t)_{t \in [0, 1]} \sim p^u$ 以及任意函数 $g : [0, 1] \times \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ ，我们有

$$\mathbb{E}_{p^u(X)} \sum_{t: X_{t-} \neq X_t} g(t, X_{t-}, X_t) = \mathbb{E}_{p^u(X)} \int_0^1 \sum_{y \neq X_t} g(t, X_t, y) u_t(y, X_t) dt.$$

证明。考虑时间离散化： $\Delta t = \frac{1}{N}$ 和 $t_n = n\Delta t$ 。则，

$$\begin{aligned}\mathbb{E}_{p^u(X)} \sum_{t: X_{t-} \neq X_t} g(t, X_{t-}, X_t) &= \mathbb{E}_{p^u(X)} \sum_{n=0}^{N-1} 1_{X_{t_n} \neq X_{t_{n+1}}} g(t_n, X_{t_n}, X_{t_{n+1}}) + O(\Delta t) \\ &= \sum_{n=0}^{N-1} \sum_{x, y} p_{t_n}^u(x) p_{t_{n+1}|t_n}^u(y|x) 1_{x \neq y} g(t_n, x, y) + O(\Delta t) \\ &= \sum_{n=0}^{N-1} \sum_x p_{t_n}^u(x) \sum_{y \neq x} u_{t_n}(y, x) g(t_n, x, y) \Delta t + O(\Delta t) \\ &= \mathbb{E}_{p^u(X)} \int_0^1 \sum_{y \neq X_t} g(t, X_t, y) u_t(y, X_t) dt.\end{aligned}$$

$\square$

C. 实验细节与补充结果

C.1. 目标分布

我们考虑在方形晶格 $\Lambda = [L]^2$ 上的伊辛模型和波茨模型，每个维度有 L 个格点。若 $i, j \in \Lambda$ 在晶格上相邻，则记作 $i \sim j$ 。为简单起见，我们在水平和垂直方向均施加周期性边界条件。两种目标分布均可写成如下形式

$$\nu(x) = \frac{1}{Z} e^{-\beta E(x)},$$

其中 E 为能量函数（哈密顿量）， $\beta > 0$ 为逆温度， $Z = \sum_{x \in \mathcal{X}} e^{-\beta E(x)}$ 为配分函数。

对于具有相互作用参数 $J \in \mathbb{R}$ 和外磁场 $h \in \mathbb{R}$ 的伊辛模型，能量为

$$E_{\text{Ising}}(x) = -J \sum_{i \sim j} x^i x^j - h \sum_i x^i, \quad x \in \{\pm 1\}^\Lambda.$$

在整个实验过程中，我们保持 $J = 1$ 和 $h = 0$ 不变。对于具有 N 个状态和相互作用参数 $J \in \mathbb{R}$ 的波茨模型，能量为

$$H_{\text{Potts}}(x) = -J \sum_{i \sim j} 1_{x^i = x^j}, \quad x \in [N]^\Lambda.$$

我们在整个实验过程中保持 $J = 1$ 。最后，我们可以如下计算这两个分布的离散得分：

$$\frac{\nu(x^{i \leftarrow n})}{\nu(x)} = \begin{cases} \exp\left(\beta(n - x^i) \left(J \sum_{j: j \sim i} x^j + h\right)\right), & \forall n \in \{\pm 1\}, \text{ Ising}; \\ \exp\left(\beta J \left(\sum_{j: j \sim i} (1_{x^j=n} - 1_{x^j=x^i})\right)\right), & \forall n \in [N], \text{ Potts}. \end{cases}$$

C.2. 实现细节

模型骨干 我们遵循 MDNS (Zhu 等人, 2025a) 的实现, 使用视觉变换器 (ViT, Dosovitskiy 等人, 2021) 作为离散扩散模型的骨干。特别地, 我们使用 DeiT (数据高效图像变换器) 框架 (Touvron 等人, 2021), 并采用二维旋转位置嵌入 (Heo 等人, 2025), 以更好地捕捉伊辛模型和波茨模型的二维空间结构。虽然 MDNS 的模型只需要位置输入 $x \in [N]^D$, 但在我们的学习目标中, 控制器还接收时间输入 $t \in [0, 1]$ 。因此, 我们采用 DiT (Peebles & Xie, 2023) 和 SiT (Ma 等人, 2024) 中的自适应层归一化 (adaLN) 机制来处理时间条件。对于学习 24×24 伊辛模型和 16×16 具有 4 个状态的波茨模型, 我们使用具有 6 个块、隐藏维度 32 和 4 个头的模型。模型中的参数总数约为 144k (控制器, 带时间条件) 或 95k (校正器, 不带时间条件)。

训练 在所有训练任务中, 我们使用 AdamW 优化器 (Loshchilov & Hutter, 2019), 恒定学习率为 $1e-3$ (β_{high}) 和 $5e-4$ ($\beta_{\text{critical}}, \beta_{\text{low}}$)。我们始终使用指数移动平均 (EMA) 来稳定训练, 衰减率为 0.9999。所有实验均在 NVIDIA RTX A6000 GPU 上训练。对于所有分布, 我们始终使用广义 KL 发散 $\mathcal{D}_{\text{KL}}$ 作为布雷格曼发散, 始终使用均匀时间权重 $w_t \equiv 1$, 并采用修改后的对数线性噪声调度, 其中 $\gamma = 1$ 和 $\alpha = 0.5$ 。我们训练 5 个阶段, 控制器 500 步, 校正器 250 步。我们保持一个大小为 512 (β_{high}) 或 4096 ($\beta_{\text{critical}}, \beta_{\text{low}}$) 的运行缓冲区, 并每 20 (β_{high}) 或 10 ($\beta_{\text{critical}}, \beta_{\text{low}}$) 次梯度更新使用当前控制器重新采样一批 **128** 对 (x_0, x_1) 。最后, 对于 β_{high} , 我们使用 $\mu = p_{\text{unif}}$ 作为初始化, 并对校正器采用 AM 损失 (corr-AM); 对于 $\beta_{\text{critical}}, \beta_{\text{low}}$, 我们观察到均匀初始化不会带来良好性能, 因此将 μ 初始化为零温度分布 (即, 对于伊辛模型为 $\text{Unif}\{\pm 1\}$, 对于波茨模型为 $\text{Unif}\{1, 2, \dots, N\}$, 其中 **1** 是全一向量)。我们使用 DM 损失 (corr-DM) 来训练校正器, 因为 μ 并非处处为正。

生成基线和真实样本 我们遵循现有文献 (Guo 等, 2026) 中的实现来构建基线。对于基于学习的基线, 我们在 24×24 伊辛模型和 16×16 波茨模型上训练 LEAPS 和 MDNS, 每个温度最多训练 150k 步。对于 MDNS, 我们采用预热策略 (Zhu 等, 2025a), 从 β_{high} 的预训练检查点初始化 β_{critical} 下的训练, 并从 β_{critical} 的预训练检查点初始化 β_{low} 下的训练。Metropolis-Hastings (MH) 和 Swendsen-Wang (SW) 采样严格遵循 Guo 等 (2026) 中的实现, 以确保充分混合。

评估 我们遵循 Zhu 等 (2025a, 附录 D.3, E.2) 中详述的程序来计算磁化强度和两点相关误差。为了计算两组样本 $\{x_i\}$ 和 $\{y_j\}$ 的经验能量 Wasserstein-2 距离, 我们获取数据集 $\mathcal{E}_1 = \{E(x_i)\}$ 和 $\mathcal{E}_2 = \{E(y_j)\}$ 的能量, 并使用 POT 包 (Flamary 等, 2021) 中的函数 `np.sqrt(ot.wasserstein1d( $\mathcal{E}_1, \mathcal{E}_2, p=2$ ))`。

有效样本量 (ESS) 我们遵循现有神经采样文献中的做法 (Zhang 和 Chen, 2022; Holderrieth 等, 2025; Zhu 等, 2025a)。对于来自 p 的一批独立同分布样本 $\{x_i\}_{i \in [B]}$, 假设我们将每个样本 x_i 与权重 $w_i = \frac{\hat{q}(x_i)}{p(x_i)}$ 相关联, 其中 $\hat{q}$ 是概率分布 q 的未归一化概率密度/质量函数, 则样本相对于 q 的 (归一化) 有效样本量 (ESS) 定义为 $\frac{1}{\frac{1}{B} \sum_i w_i^2} \in [\frac{1}{B}, 1]$ 。

关于 TM 与 DM 的消融研究 (图 1) 我们使用具有 4 个块、隐藏维度 32 和 4 个头的模型。我们使用批大小 256, 在 (ctrl-DM) 和 (ctrl-AM) 中, 我们为每对 (x_0, x_1) 从 $\text{Unif}[0, 1]$ 中采样 $32t$ 。所有三种情况都在相同的随机种子下训练 5000 步, 缓冲区大小为 **1024**, 重采样频率为 20, 生成 NFE 为 **100**。

关于噪声调度的消融研究 (图 2 和 3) 我们使用具有 4 个块、隐藏维度 **32** 和 4 个头的模型。我们使用 64 的批大小, 并且在 (ctrl-AM) 中, 我们为每对 (x_0, x_1) 采样遵循 $\text{Unif}[0, 1]$ 的 $8t$ 。所有运行均

在相同的随机种子下训练 5 个阶段，包含 200 个控制器更新步骤和 200 个校正器更新步骤。缓冲区大小为 256，重采样频率为 20。

C.3. 进一步实验结果

消融实验：噪声调度 我们在图 3 中提供了恒定噪声调度 $\gamma_t \equiv \gamma$ 的进一步消融实验。与修改后的对数线性调度类似，出现了相同的趋势：生成的样本在 $\gamma \in [0.5, 1]$ 附近达到最佳质量。




图 3. 在具有 $L = 24$ 和 $\beta_{\text{high}} = 0.28$ 的伊辛模型上，恒定噪声调度 $\gamma_t \equiv \gamma$ 的超参数 γ 的消融实验。NFE 是训练和推理期间生成过程中的函数评估次数。左：生成过程中每个维度的平均跳跃次数。右：与从 SW 算法抽取的真实样本之间的 2 点相关误差和能量 Wasserstein-2 距离。