

通过扩散薛定谔桥弥合动力学差距以实现跨域强化学习

Hanping Zhang, Yuhong Guo

School of Computer Science, Carleton University, Ottawa, Canada

摘要

跨域强化学习旨在源域与目标域之间存在动力学偏移的情况下学习可迁移策略。一个关键挑战在于缺乏目标域环境交互和奖励监督，这阻碍了直接进行策略学习。为应对这一挑战，本文提出弥合跨域强化学习动力学差距（BDGxRL）框架，该框架利用扩散薛定谔桥（DSB）将源转移与离线演示中编码的目标域动力学对齐。此外，本文引入一种奖励调制机制，基于状态转移估计奖励，并应用于经 DSB 对齐的样本，以确保奖励与目标域动力学之间的一致性。BDGxRL 完全在源域内执行面向目标的策略学习，无需访问目标环境或其奖励。在 MuJoCo 跨域基准上的实验表明，BDGxRL 优于最先进的基线方法，并在转移动力学偏移下表现出强大的适应性。

1 引言

强化学习（RL）作为现代序贯决策的基石，已成功应用于众多领域，包括机器人学（Kober, Bagnell, and Peters 2013）、游戏博弈（Berner et al. 2019）、推荐系统（Afsar, Crump, and Far 2022）以及自动驾驶（Aradi 2020）。通过与环境的交互以最大化长期累积奖励，强化学习智能体能够从经验中学习复杂策略。然而，由于数据可用性、环境可访问性和再训练灵活性方面的限制，在真实场景中直接训练强化学习智能体往往不切实际。这一挑战在跨域设置中尤为突出，例如在仿真与真实世界之间迁移策略，或在相关任务或环境之间快速适应。弥合跨域差距对于提升强化学习在现实世界中的适用性至关重要。为解决这一问题，强化学习中的跨域自适应已引起越来越多的关注。在此类设置中，智能体通常在源域（例如仿真器）中训练，然后部署到目标域（例如真实世界）。在许多实际应用中，源域和目标域通常共享相同的状态空间和动作空间，因为仿真

智能体通常被设计为模拟其物理对应物。然而，两个领域之间的转移动力学往往因重力、质量或摩擦等物理属性的细微不匹配而存在差异。这些差异被称为动力学差距，在从仿真迁移到现实时可能导致策略性能显著下降。解决这些动力学差距并非易事，尤其是在无法或受限地直接与真实环境交互的情况下。一种有前景的替代方案是从目标领域收集有限的离线专家演示。然而，这些演示通常稀疏且缺乏奖励标注，使得直接应用传统强化学习目标变得困难。此外，重用源领域的奖励函数往往不合适，因为即使名义奖励函数保持不变，动力学差距也可能导致源领域与目标领域奖励实现之间的不匹配。这种奖励不一致进一步加剧了学习可迁移策略的挑战。因此，有效的跨领域自适应方法必须同时解决转移动力学的发散以及目标领域中显式监督的稀缺问题，包括奖励信号的缺失。为了弥合跨域强化学习中的动力学差距，我们考虑了扩散薛定谔桥（Diffusion Schrödinger Bridge, DSB）（De Bortoli 等人，2021），这是一种最近发展的用于分布对齐的概率框架。DSB 将两个概率分布之间的插值表述为随机最优传输（Optimal Transport, OT）问题，通过时间依赖的扩散过程求解。与传统最优传输（Peyré, Cuturi 等人，2019）通常需要显式耦合或代价函数不同，DSB 学习一个连续流，将样本从源分布变换到目标分布，而无需配对数据。DSB 最初应用于生成建模任务，如非配对图像翻译和分布变形，在捕捉领域间复杂结构差异方面表现出强大能力。受 DSB 优势的启发，我们探索其在跨领域强化学习中用于转移动力学自适应的潜力。具体而言，通过学习一个 DSB 过程，将源领域转移传输到与目标领域离线专家转移分布相匹配，我们可以生成更好地反映目标环境的对齐轨迹。这种对齐无需在线交互即可实现。

或目标域中的奖励标注,使得 DSB 特别适用于监督有限的离线跨域强化学习场景。为解决强化学习中跨域适应的整体挑战,本文提出一种新颖的框架,名为跨域强化学习动态差距桥接(BDGxRL),该框架利用 DSB 在无需访问目标环境的情况下解决动态差距。本文方法包含三个关键部分:首先,仅利用目标域的离线专家演示和在线源环境采样的轨迹,学习基于 DSB 的转移桥接。这实现了以纯离线方式对转移动态的适应。其次,通过在源域上训练与动作无关的奖励模型进行奖励调制,该模型仅基于状态转移对估计奖励。利用 DSB 变换到目标域的转移对该奖励模型进行调制,从而在缺乏目标域奖励的情况下缓解由动态差异引起的奖励不匹配。第三,利用学习到的转移 DSB 将源域轨迹变换为目标风格的转移,并在其上应用调制后的奖励。这使本文能够完全在源域内学习面向目标的策略,无需任何在线交互或从目标环境直接收集带奖励的数据。本文在一组基于 MuJoCo 仿真套件(Todorov, Erez, and Tassa 2012)构建的跨域基准上评估 BDGxRL,并与多种最先进的跨域强化学习方法进行比较。实验结果表明,BDGxRL 始终优于现有基线,在具有挑战性的动态偏移下实现了卓越的适应性。本文贡献总结如下:

- 本文提出 BDGxRL,一种新颖的框架,能够在源环境中学习面向目标的策略,解决跨域强化学习中的动态差距。
- 本文首次将扩散薛定谔桥(DSB)引入跨域强化学习,实现从源域到目标域的转移动力学变换。
- 本文发现转移动力学的变化可能导致奖励函数不一致。为缓解这一问题,本文提出一种奖励调制机制,补充缺失的目标域奖励。
- 在多个基于物理仿真的基准上的实验结果表明,BDGxRL 始终优于最先进的跨域强化学习基线。

2 相关工作 **2.1 跨域强化学习** 跨域强化学习可追溯至领域自适应(DA)在强化学习中的早期应用(Lazaric 2012)。随着深度强化学习的兴起,Higgins 等人(2017)率先明确地将领域自适应引入强化学习。他们系统地识别了跨域可能不同的关键因素:观测、动作、奖励和转移,并提出了解耦表示学习智能体(DARLA)来处理此类域偏移。

在 DARLA 的基础上,Xing 等人(2021)提出了潜统一状态表示(Latent Unified State Representation, LUSR),该方法学习跨领域的共享潜空间以缓解观测层面的差异,从而在不显式处理动力学不匹配的情况下实现策略迁移。研究重点的显著转变出现在 Eysenbach 等人(2020)的工作中,他们提出了基于分类器奖励的领域自适应(Domain Adaptation with Rewards from Classifiers, DARC),这是一种考虑非动力学设定的现代方法。DARC 训练一个分类器来区分源领域转移与目标领域转移,并修改奖励函数以惩罚源领域转移。Liu、Zhang 和 Wang (2022)将这一思想扩展到离线设定,提出了动力学感知奖励增强(Dynamics-Aware Reward Augmentation, DARA)。DARA 不是仅基于奖励来区分转移,而是学习一个分类器来识别完整 (s, a, s') 元组上的领域差异,并修改奖励以惩罚在目标领域中看似不合理的转移。进一步推进这一研究方向,Guo 等人(2024)提出了领域自适应与奖励增强模仿学习(Domain Adaptation and Reward-Augmented Imitation Learning, DARAIL),该方法结合了基于观测的对抗性模仿学习来对齐源领域和目标领域的行为。他们还引入了一个奖励增强估计器(Reward-Augmented Estimator, RAE),以基于推断的动力学不匹配来细化奖励修改。最近,Niu 等人(2024)提出了跨领域轨迹编辑(Cross-Domain Trajectory Editing, xTED),该方法采用扩散模型将源领域轨迹转换为类似目标领域的轨迹。通过注入并随后去噪,xTED 学习生成合理的目标领域轨迹用于策略训练。Lyu 等人(2024a)提出了一种通过捕捉表示不匹配的跨领域策略自适应方法,该方法学习两个编码器:一个用于状态-动作对,另一个用于下一状态,仅在目标领域上训练。在这些编码器下具有较大表示偏差的转移通过奖励修改被惩罚,从而有效过滤掉不合理的转移。所有这些方法都共享非动力学设定,即领域之间的动力学不同,源领域数据/环境丰富,而对目标领域的访问有限。我们的工作专注于完全从在线源领域学习面向目标的策略,假设仅从目标领域获得有限的演示。最近的一些工作采用了相关但略有不同的设定。例如,有些假设离线源或离线目标数据集,同时仍需要有限的目标领域交互,而不是纯粹从源领域学习。Xu 等人(2023)专注于在线源领域,但允许在目标领域进行少量在线交互。他们提出了价值引导数据过滤(Value-Guided Data Filtering, VGDF),该方法利用跨领域的价值函数一致性来选择源领域转移,这些转移的估计值与目标领域中的值紧密匹配。Niu 等人(2022)研究了一种 Sim2Real 设定,其中既有有限的真实世界数据,也有不完美的模拟器。他们提出的动力学感知混合离线与在线强化学习(Dynamics-Aware Hybrid Offline-and-Online Reinforcement Learning, H2O)框架联合从真实世界离线数据和基于模拟器的在线推演中学习。H2O 通过动力学感知的 Q 函数调整,自适应地惩罚具有较大动力学差距的模拟转移。

2.2 扩散薛定谔桥 (Diffusion Schrödinger Bridge) 扩散模型 (Ho, Jain 和 Abbeel 2020; Song, Meng 和 Ermon 2020) 近期因其在图像生成等领域 (Rombach 等 2022) 展现出的强大生成能力而获得广泛认可。此外, 其条件变体 (Song 等 2020; Zhang 等 2023) 能够利用灵活的条件输入实现可控生成。更重要的是, 数据翻译这一尤为关键的挑战, 尤其是在涉及两个大型非配对数据集的场景中, 要求将扩散模型扩展到无条件生成之外。最优传输 (Optimal Transport, OT) 问题 (Peyré, Cuturi 等 2019; Santambrogio 2015) 旨在寻找将一个概率分布映射到另一个概率分布的最有效方式, 为数据翻译提供了基础框架。Li 等 (2023) 通过在去噪过程中计算半离散最优传输映射, 将最优传输理论融入扩散过程, 从而提升了采样效率和质量。为处理非配对或部分配对的数据集, Gu 等 (2023) 提出了最优传输引导的条件分数扩散模型。该方法利用最优传输耦合非配对数据分布, 并将该耦合融入条件分数扩散模型, 实现了出色的图像翻译。De Bortoli 等 (2021) 率先将薛定谔桥 (Schrödinger Bridge, SB) (Léonard 2013) 的概念应用于扩散模型, 提供了一个概率框架, 通过寻找连接两个分布的最优随机过程 (如布朗运动) 来求解最优传输问题。他们提出了扩散薛定谔桥 (Diffusion Schrödinger Bridge, DSB), 实现了不同域之间的数据翻译, 并通过迭代比例拟合 (Iterative Proportional Fitting, IPF) 进行求解。随后, Shi 等 (2023) 提出了迭代马尔可夫拟合 (Iterative Markovian Fitting, IMF) 及相应的扩散薛定谔桥匹配 (Diffusion Schrödinger Bridge Matching, DSBM) 算法, 以高效计算薛定谔桥解。在此基础上, De Bortoli 等 (2024) 引入了改进变体: α -IMF 和 α -DSBM, 专为更具挑战性的非配对数据翻译任务设计, 达到了最先进的性能。Somnath 等 (2023) 提出了 SBALIGN, 利用对齐数据集更高效地求解扩散薛定谔桥。同时, Kim, Yoon 和 Lee (2024) 提出了数据集成 (Data Ensemble, DE) 方法, 用于增强扩散薛定谔桥的神经骨干网络。尽管扩散薛定谔桥在非配对图像数据翻译方面取得了日益增长的成功, 但在其他领域的潜在应用仍未得到充分探索。本文研究了利用扩散薛定谔桥对齐源域和目标域之间的转移动力学, 从而促进在动力学不匹配的环境间进行有效的策略迁移。

3 预备知识

本节简要介绍扩散薛定谔桥 (Diffusion Schrödinger Bridge, DSB) 问题及其通过迭代马尔可夫拟合 (Iterative Markov Fitting, IMF) 过程的实用实现。这些工具为本文跨域转换过渡动态的方法奠定了基础。

扩散薛定谔桥 薛定谔桥

薛定谔桥 (SB) 问题旨在寻找一个随机过程, 将初始分布 Π_0 传输至终端分布 Π_1

时间, 同时在库尔贝克-莱布勒 (KL) 发散意义上尽可能接近给定的参考过程 $\mathbb{Q}$, 通常为布朗运动。在扩散薛定谔桥 (DSB) 中, 参考过程 $\mathbb{Q}$ 取为具有已知时间前向动态的扩散过程。给定边缘分布 Π_0 和 Π_1 , 目标是找到最优路径测度 $\mathbb{P}^*$, 使其与参考扩散过程的 KL 发散最小化:

$$\mathbb{P}^* = \arg \min_{\mathbb{P} \in \mathcal{M}(\Pi_0, \Pi_1)} \{ \text{KL}(\mathbb{P} \parallel \mathbb{Q}) \mid \mathbb{P}_0 = \Pi_0, \mathbb{P}_1 = \Pi_1 \} \quad (1)$$

其中 $\mathcal{M}(\Pi_0, \Pi_1)$ 表示具有指定初始和终端边缘分布的马尔可夫路径测度集合。一旦获得最优桥 $\mathbb{P}^*$, 它便定义了一个随机变换, 将 Π_0 与 Π_1 耦合起来, 使我们能够有效地在两个分布之间进行转换。

迭代式 马尔可夫拟合 迭代马尔可夫拟合 (IMF) (Shi 等人, 2023) 是求解薛定谔桥问题的一种高效方法。IMF 引入两个交替投影算子: 马尔可夫投影 $\text{proj}_{\mathcal{M}}$ (Gyöngy 1986) 和互反投影 $\text{proj}_{\mathcal{R}(\mathbb{Q})}$ (Léonard, Ræly 和 Zambrini 2014)。从初始路径测度出发, 迭代应用这些投影以生成路径测度序列 $\mathbb{P}^n$, 如下所示: $\mathbb{P}^{2n+1} = \text{proj}_{\mathcal{M}}(\mathbb{P}^{2n})$, $\mathbb{P}^{2n+2} = \text{proj}_{\mathcal{R}(\mathbb{Q})}(\mathbb{P}^{2n+1})$ 。 (2) 该交替过程确保在每个偶数步 $2n$, 路径测度 $\mathbb{P}^{2n}$ 满足边际约束 $\mathbb{P}_0^{2n} = \Pi_0$ 和 $\mathbb{P}_1^{2n} = \Pi_1$ 。经过足够迭代, 序列 $\mathbb{P}^n$ 收敛到薛定谔桥问题的最优解 $\mathbb{P}^*$: $\lim_{n \rightarrow \infty} \text{KL}(\mathbb{P}^n \parallel \mathbb{P}^*) = 0$ 。

4 方法

问题设定 强化学习 (RL) 通常被形式化为马尔可夫决策过程 (MDP), 由元组 $\mathcal{M} = (\mathcal{S}, \mathcal{A}, \mathcal{T}, \mathcal{R}, \gamma)$ 定义, 其中 $\mathcal{S}$ 是状态空间, $\mathcal{A}$ 是动作空间, $\mathcal{T}: \mathcal{S} \times \mathcal{A} \rightarrow \mathcal{P}(\mathcal{S})$ 表示转移动态, $\mathcal{R}: \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ 是奖励函数, $\gamma \in (0, 1)$ 是折扣因子。跨域强化学习设置涉及两个相关的 MDP: 源域 $\mathcal{M}_S$ 和目标域 $\mathcal{M}_T$ 。假设这两个域共享相同的状态和动作空间, 即 $\mathcal{S}_S = \mathcal{S}_T$ 和 $\mathcal{A}_S = \mathcal{A}_T$, 但它们的转移动态不同, $\mathcal{T}_S \neq \mathcal{T}_T$, 导致动态差距。在源域 $\mathcal{M}_S$ 中, 我们可以访问一个在线环境, 该环境允许无限交互并提供奖励信号。这使得智能体在训练期间可以自由采样转移 (s_t, a_t, r_t, s_{t+1}) 。相比之下, 目标域 $\mathcal{M}_T$ 是离线的且无奖励。具体来说, 我们仅获得在目标域中收集的离线轨迹静态数据集 $\mathcal{D}_T = \{(s_t, a_t, s_{t+1})\}$, 无法访问交互式环境或真实奖励。目标是学习一个策略 $\pi(a|s)$, 使其在 $\mathcal{M}_T$ 的转移动态下表现良好, 仅使用源域的在线数据和目标域的离线数据集 $\mathcal{D}_T$ 。该设置捕捉了实际场景, 其中目标域只能通过离线专家演示访问, 并且奖励函数难以指定或不可用。




图 1: 所提出的 BDGxRL 框架概览。智能体首先从源环境收集数据集 $\mathcal{D}_S$ ，用于训练转移感知奖励模型 $R(s_t, s_{t+1})$ 。结合离线目标演示 $\mathcal{D}_T$ ，该数据集还训练一个用于动力学对齐的 DSB 模型。在线交互期间，源转移通过 $\tilde{s}_{t+1} \sim \text{DSB}(s_t, a_t, s_{t+1})$ 转换为目标风格转移，以缓解决动力学不匹配。随后，调制后的奖励 $\tilde{r}_t = R(s_t, \tilde{s}_{t+1})$ 用于完全在源域内学习面向目标的策略，并通过 $\mathcal{D}_T$ 的模仿进行初始化。

为解决该问题设置中跨域的动力学差距，本文提出一种新颖的 BDGxRL 框架，用于面向目标的策略学习。该框架基于扩散薛定谔桥 (DSB) 对齐源域与目标域的转移动力学。由于目标域中的奖励函数不可用，设计了一种奖励调制策略，以适配在源域上训练的奖励模型，从而为 DSB 对齐的转移估计奖励。在动力学对齐和奖励调制的基础上，开发了面向目标的策略学习框架，使策略优化能够在源在线环境中针对目标域进行，而无需访问目标环境或奖励。本文还对所学目标策略的性能界进行了理论分析。BDGxRL 框架的概览如图 1 所示。

4.1 基于 DSB 的动力学对齐

在无法与目标环境进行在线交互的情况下，弥合源域与目标域之间的动力学差距尤为困难。仅能访问目标域中有限的离线专家演示（记为 $\mathcal{D}_T = \{(s_t, a_t, s_{t+1})\}$ ）时，虽然可以从 $\mathcal{D}_T$ 学习转移模型 T_T ，但将源域转移动力学 T_S 对齐或适配到目标域动力学仍然困难。域间缺乏配对转移或任何共享监督进一步使该对齐任务复杂化，并导致直接策略迁移不可行。为解决这一问题，本文从使用扩散薛定谔桥 (DSB) 进行非配对数据转换的最新进展中获得启发，该方法已在图像领域自适应等任务中证明有效。在本文的背景下，将源域转移动力学表述为

源边缘分布 $\Pi_0 = T_S(s_{t+1}|s_t, a_t)$ 与目标域转移动态作为目标边缘分布 $\Pi_1 = T_T(s_{t+1}|s_t, a_t)$ 。本文的目标是学习一个 DSB 来对齐这两个分布，从而能够将源域中采样的转移转换为与目标动态一致的转移。一旦建立了这种映射，我们就可以通过将相应的源转移转换到目标域，为任意给定的源域状态-动作对 (s_t, a_t) 预测目标域下一状态 s_{t+1} 。

转移表示 为了对转移进行建模，本文从源环境中收集轨迹以形成数据集 $\mathcal{D}_S$ 。然后采样转移 $\mathbf{p}^S \sim \mathcal{D}_S$ ，其中每个转移表示一个条件分布 $p^S(s_{t+1}|s_t, a_t)$ ，类似地，从目标演示中采样转移 $\mathbf{p}^T \sim \mathcal{D}_T$ 。每个转移被表示为状态、动作和下一状态的拼接向量：

$$\mathbf{p} = [s_t; a_t; s_{t+1}]. \quad (3)$$

这种统一的转移格式允许本文将转移样本视为共享表示空间中的点，从而能够应用 DSB 来学习源转移分布与目标转移分布之间的转换。

DSB 训练 为了训练用于转移动态对齐的 DSB 模型，本文遵循迭代马尔可夫拟合 (IMF) 过程 (Shi 等人, 2023)，并采用布朗运动 $\mathbb{B}$ 作为参考过程，通过避免额外的漂移项来简化公式。目标是学习两个最优漂移函数 v_{θ^*} 和 v_{ϕ^*} ，分别对应将源域转移分布 Π_0 传输到目标域分布 Π_1 ，以及反向传输的前向和后向速度场。

Forward Process In the forward direction, the process starts from a source-domain sample $\mathbf{p}_0^S \sim \Pi_0$ and evolves according to the following stochastic differential equation (SDE):

$$d\mathbf{p}_k^S = v_{\theta^*}(k, \mathbf{p}_k^S) dk + \sigma_0 d\mathbf{B}_k, \quad (4)$$

其中 σ_0 表示固定的扩散幅度， $\mathbf{B}_k$ 表示与 $\mathbf{p}_0^S$ 维度相同的标准布朗运动。由于布朗运动是高斯过程，将其条件化在固定端点上会得到布朗桥，其条件期望随时间线性演化。在 IMF 框架中，本文在采样的端点对之间构造这样的布朗桥，并将其漂移作为回归目标。具体而言，前向漂移函数 v_{θ} 被训练来近似这些端点条件布朗桥的漂移。参数 θ 通过求解获得

$$\theta^* = \arg \min_{\theta} \int_0^1 \mathbb{E}_{\Pi_{k,1}} \left[\left\| \frac{\mathbf{p}_1 - \mathbf{p}_k^+}{1-k} - v_{\theta}(k, \mathbf{p}_k^+) \right\|^2 \right] dk, \quad (5)$$

其中 $\mathbf{p}_k^+$ 表示从参考布朗桥中抽取的中间样本，该布朗桥以端点 $(\hat{\mathbf{p}}_0, \mathbf{p}_1)$ 为条件。此处， $\mathbf{p}_1 \sim \Pi_1$ 是真实目标域样本， $\hat{\mathbf{p}}_0$ 是由前一次反向迭代的反向过程生成的源域端点。在该参考桥下， $\mathbf{p}_k^+$ 具有闭式插值形式

$$\mathbf{p}_k^+ = (1-k)\hat{\mathbf{p}}_0 + k\mathbf{p}_1 + \sigma_0 \sqrt{k(1-k)} \mathbf{z}, \quad (6)$$

其中 $\mathbf{z} \sim \mathcal{N}(0, I)$ 。

反向过程 类似地，反向过程从目标域样本 $\mathbf{p}_0^T \sim \Pi_1$ 开始，并按照以下方式在时间上反向演化

$$d\mathbf{p}_k^T = v_{\phi^*}(1-k, \mathbf{p}_k^T) dk + \sigma_0 d\mathbf{B}_k. \quad (7)$$

正向和反向随机微分方程对应于同一薛定谔桥过程的两个时间方向参数化。在薛定谔桥定律下，它们的中间状态满足分布恒等式 $\mathbf{p}_k^S \stackrel{d}{=} \mathbf{p}_{1-k}^T$ 。因此，反向漂移函数 v_{ϕ} 通过回归到在采样端点对之间构造的布朗桥的漂移来训练，如下所示：

$$\phi^* = \arg \min_{\phi} \int_0^1 \mathbb{E}_{\Pi_{0,k}} \left[\left\| \frac{\mathbf{p}_0 - \mathbf{p}_k^-}{k} - v_{\phi}(k, \mathbf{p}_k^-) \right\|^2 \right] dk, \quad (8)$$

其中 $\mathbf{p}_k^-$ 从以端点 $(\mathbf{p}_0, \hat{\mathbf{p}}_1)$ 为条件的参考布朗桥中采样， $\mathbf{p}_0 \sim \Pi_0$ 和 $\hat{\mathbf{p}}_1$ 由前一次正向迭代的正向过程生成。在该参考桥下，中间样本具有闭式表达式

$$\mathbf{p}_k^- = (1-k)\mathbf{p}_0 + k\hat{\mathbf{p}}_1 + \sigma_0 \sqrt{k(1-k)} \mathbf{z}. \quad (9)$$

通过交替优化 θ 和 ϕ ，我们获得正向和反向漂移函数，它们共同逼近 Π_0 与 Π_1 之间的最优薛定谔桥，随后我们利用该桥执行两个域之间的转移动力学对齐。

动力学 对齐 一旦漂移函数被学习完成，我们便可通过部署正向过程将源域转移转化为目标域转移。然而，精确求解连续时间随机微分方程通常难以实现。在实践中，我们采用离散化的朗之万类方案来近似扩散过程，常用的是欧拉-丸山方法 (Shi 等人, 2023; Song 等人, 2020)。这使得我们能够在固定时间间隔 $\Delta k = 1$ 下，通过 K 个离散步骤进行去噪。在每个时间步 k ，转移向量按如下方式更新：

$$\mathbf{p}_{k+1} = \mathbf{p}_k + v_{\theta^*}(k \cdot \Delta k, \mathbf{p}_k) \Delta k + \sigma_0 \sqrt{\Delta k} \boldsymbol{\xi}_k, \quad (10)$$

其中 $\boldsymbol{\xi}_k \sim \mathcal{N}(0, I)$ 。经过 K 步后，我们得到模仿目标域的转移 $\mathbf{p}^T \approx \mathbf{p}_K$ 。类似的过程可利用反向漂移函数 v_{ϕ^*} 在反方向上应用。该过程使我们能够通过从学习到的桥分布 $\mathbb{P}^*$ 中采样，将源域转移转化为目标风格转移，而无需访问目标环境。为便于表示，我们将 $\text{DSB}_{S \rightarrow T}$ 定义为正向转移算子，将 $\text{DSB}_{T \rightarrow S}$ 定义为反向转移算子。因此，给定源转移 $\mathbf{p}^S = (s_t, a_t, s_{t+1})$ ，我们可通过正向转移生成相应的目标风格下一状态 $\tilde{s}_{t+1}$ ：

$$\tilde{s}_{t+1} \sim \text{DSB}_{S \rightarrow T}(s_t, a_t, s_{t+1}). \quad (11)$$

4.2 奖励调制 借助 DSB 对齐的转移动态，我们能够获得目标风格的转移，以缓解源域与目标域之间的动态差距。然而，由于离线目标数据集 $\mathcal{D}_T$ 不包含任何奖励信息，在没有目标环境奖励函数的情况下，学习目标域策略仍然不可行。在现代强化学习文献中，奖励通常被建模为状态-动作对的函数， $R(s_t, a_t)$ 。一种直接的方法是复用源环境的奖励函数。然而，在许多场景中，尤其是涉及目标达成或控制任务时，奖励更自然地与转移的结果相关联，即下一状态 s_{t+1} 。事实上，某些公式将奖励视为仅关于 s_{t+1} 的函数 (Sutton, Barto 等人, 1998)。因此，由于转移动态的不齐，直接在目标域应用源奖励函数可能会产生误导。

转移感知奖励 为解决该问题，本文提出一种转移感知奖励函数 $R(s_t, s_{t+1})$ ，该函数同时依赖于当前状态与产生的下一状态，而与所采取的动作无关。该公式刻画了转移结果的本质，且对引发转移的具体控制信号不敏感。本文利用从源域环境收集的数据集 $\mathcal{D}_S = \{(s_t, s_{t+1}, r_t)\}$ 训练转移感知奖励模型，该数据集包含转移与真实奖励。通过最小化以下均方误差 (MSE) 学习奖励模型：

$$\mathcal{L}_{\text{reward}} = \mathbb{E}_{(s_t, s_{t+1}, r_t) \sim \mathcal{D}_S} \left[(R(s_t, s_{t+1}) - r_t)^2 \right]. \quad (12)$$

随后，可将该奖励模型应用于转换后的目标风格转移，以生成面向目标的奖励。具体而言，对于每个源转移 (s_t, a_t, s_{t+1}, r_t) ，首先计算与目标对齐的下一状态 $\tilde{s}_{t+1} \sim \text{DSB}_{S \rightarrow T}(s_{t+1}|s_t, a_t)$ ，然后按如下方式调制奖励：

$$\tilde{r}_t = R(s_t, \tilde{s}_{t+1}). \quad (13)$$

该奖励调制机制确保了奖励与目标域动态之间的一致性，同时仅依赖源域交互与监督。

4.3 面向目标的策略学习

在跨领域强化学习中，离线目标数据集 $\mathcal{D}_T$ 通常规模有限且缺乏奖励监督，因此不适合直接进行策略优化。为克服这一挑战，本文提出的 BDGxRL 框架利用调制后的源环境交互来学习面向目标的策略，其基础是基于 DSB 的动力学对齐和转移感知奖励调制。目标是仅在源领域内训练一个策略，使其在动力学不匹配且缺乏目标奖励的情况下仍能很好地泛化到目标环境。具体而言，本文提出的 BDGxRL 框架包含两个阶段——离线预训练阶段和在线策略学习阶段。在离线预训练阶段，首先通过从源环境采样轨迹来收集数据集 $\mathcal{D}_S$ 。利用 $\mathcal{D}_S$ 和目标演示 $\mathcal{D}_T$ ，训练一个 DSB 模型以对齐源动力学和目标动力学，同时拟合一个转移感知奖励模型。在在线策略学习阶段，在源环境中每一步在线交互时，从当前策略 π 采样动作 a_t 。执行 a_t 在源动力学下产生下一状态 s_{t+1} 。然后应用学习到的 DSB 模型将该转移转换为目标风格的转移 $\tilde{s}_{t+1} \sim \text{DSB}_{S \rightarrow T}(s_{t+1}|s_t, a_t)$ 。给定转换后的下一状态，使用学习到的奖励模型计算调制奖励 $\tilde{r}_t = R(s_t, \tilde{s}_{t+1})$ 。将转移 $(s_t, a_t, \tilde{r}_t, \tilde{s}_{t+1})$ 添加到回放缓冲区 $\mathcal{B}$ 中。使用离线策略强化学习算法（如软演员-评论家（Soft Actor-Critic, SAC）（Haarnoja 等, 2018a,b））利用存储在 $\mathcal{B}$ 中的转移来优化策略。这使得能够学习一个在与源环境交互的同时最大化目标风格奖励的策略。为进一步提高样本效率并利用来自目标领域的专家演示，通过模仿学习（例如行为克隆（Behavior Cloning, BC）（Torabi, Warnell 和 Stone, 2018））初始化策略。模仿损失定义为：

$$\mathcal{L}_{\text{IL}} = \mathbb{E}_{(s,a) \sim \mathcal{D}_T} [-\log \pi(a|s)]. \quad (14)$$

随后，在在线强化学习优化过程中，将模仿损失作为正则化项纳入。最终策略目标变为：

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{RL}} + \alpha \cdot \mathcal{L}_{\text{IL}}, \quad (15)$$

其中 $\mathcal{L}_{\text{RL}}$ 表示标准强化学习损失， α 是探索与模仿之间的平衡系数。下面给出理论分析，表明在温和假设下，学习到的面向目标的策略能够紧密逼近最优策略。

定理 1（基于 DSB 平移的策略价值界）。假设奖励有界于 $R_{\max}$ ，且折扣因子满足 $\gamma \in [0, 1)$ 。设 π 为使用 BDGxRL 结合基于 DSB 的动力学平移和奖励调制所学得的策略，并设 π^* 表示目标环境中的最优策略。那么，当用于 DSB 训练的 IMF 迭代次数足够大时， π 与 π^* 在目标马尔可夫决策过程 $\mathcal{M}_T$ 中的价值差有界如下：

$$\Delta V := \left| V_{\mathcal{M}_T}^{\pi^*} - V_{\mathcal{M}_{\text{DSB}}}^{\pi} \right| \leq \frac{\sqrt{2}R_{\max}\gamma}{(1-\gamma)^2} \cdot \sqrt{\epsilon_m} + \frac{2}{(1-\gamma)^2} \sqrt{2}R_{\max} \cdot \sqrt{\epsilon_{\pi}}, \quad (16)$$

where $\epsilon_m = \mathcal{O}\left(\frac{1}{N_S} + \frac{1}{N_T}\right)$ 表示由使用 $N_S = |\mathcal{D}_S|$ 和 $N_T = |\mathcal{D}_T|$ 进行 DSB 训练所引入的动力学近似误差，而 ϵ_{π} 刻画了所学目标导向策略与最优目标导向策略之间的策略近似误差。该定理证明了所提方法在弥合动力学失配并在目标域中实现可靠策略学习方面的理论可靠性。

5 实验

5.1 实验设置

实验环境 我们在 MuJoCo (Todorov, Erez, and Tassa 2012) 基于物理的机器人仿真环境中评估我们的方法，离线演示数据集由 D4RL 基准 (Fu et al. 2020) 提供。源域通过修改原始 MuJoCo 环境的物理参数得到，引入三种类型的域差距：（1） $2 \times$ 重力，（2） $0.25 \times / 0.5 \times$ 摩擦，以及（3） $2 \times$ 机器人大腿尺寸。这些修改改变了源环境和目标环境之间的转移动力学，同时保持状态空间和动作空间不变。实验涉及两个任务（HalfCheetah 和 Walker2d）、三个级别的目标演示专业度（Medium、Medium-Replay、Medium-Expert）以及上述三种类型的域差距。

比较方法 我们将我们的方法与几种最先进的跨域强化学习基线进行比较，包括 xTED (Niu et al. 2024)（与 IQL (Kostrikov, Nair, and Levine 2021) 或 DARA (Liu, Zhang, and Wang 2022) 结合）、DARA (Liu, Zhang, and Wang 2022)、DARC (Eysenbach et al. 2020)、DARAIL (Guo et al. 2024)，以及来自 D4RL (Fu et al. 2020) 专家数据的源行为策略，和在目标域上训练的模仿学习策略（GAIL）(Ho and Ermon 2016)。

5.2 实验结果 本文报告了使用 D4RL 标准化分数 (Fu 等人, 2020 年) 的实验结果，其中回合回报经过缩放，使得随机策略得分为 0，专家策略得分为 100。该分数是跨不同任务和方法比较性能时广泛采用的度量。所有结果汇总于表 1。总体而言，本文提出的 BDGxRL 在所有任务和设置中均一致达到最高性能，展现出在各种动力学差距下强大的泛化能力和适应性。在 HalfCheetah 环境中，

Task	Expert	Domain Gap	D4RL	xTED (IL)	xTED (CD)	DARA	GAIL	DARC	DARAIL	BDGxRL (Ours)
HalfCheetah	Med	Gravity	39.5 $\pm$ 2.4	40.6 $\pm$ 2.0	41.1 $\pm$ 2.0	40.6 $\pm$ 1.9	39.0 $\pm$ 1.8	40.1 $\pm$ 1.6	42.6 $\pm$ 2.4	46.3 $\pm$ 2.7
		Friction	43.1 $\pm$ 1.5	43.2 $\pm$ 3.0	44.2 $\pm$ 1.8	42.3 $\pm$ 1.7	40.2 $\pm$ 2.0	41.7 $\pm$ 1.9	43.9 $\pm$ 2.3	47.8 $\pm$ 2.9
		Thigh Size	39.5 $\pm$ 2.4	40.7 $\pm$ 2.4	41.5 $\pm$ 1.6	40.4 $\pm$ 2.1	39.5 $\pm$ 2.2	40.9 $\pm$ 1.7	42.7 $\pm$ 2.1	46.5 $\pm$ 2.5
	Med-R	Gravity	26.2 $\pm$ 3.5	30.7 $\pm$ 1.9	30.7 $\pm$ 1.9	27.2 $\pm$ 3.2	28.2 $\pm$ 1.7	30.5 $\pm$ 2.2	33.6 $\pm$ 2.3	37.8 $\pm$ 2.8
		Friction	26.2 $\pm$ 3.5	31.8 $\pm$ 3.1	32.4 $\pm$ 2.9	23.2 $\pm$ 4.7	30.0 $\pm$ 1.9	31.3 $\pm$ 2.5	35.0 $\pm$ 2.4	39.5 $\pm$ 2.6
		Thigh Size	26.2 $\pm$ 3.5	30.3 $\pm$ 1.9	32.9 $\pm$ 2.7	29.1 $\pm$ 1.4	28.9 $\pm$ 2.1	30.7 $\pm$ 2.4	34.4 $\pm$ 2.1	38.6 $\pm$ 2.7
	Med-E	Gravity	40.1 $\pm$ 2.9	45.3 $\pm$ 3.8	45.3 $\pm$ 3.8	39.7 $\pm$ 3.8	40.7 $\pm$ 1.5	42.4 $\pm$ 8.9	47.7 $\pm$ 6.5	53.2 $\pm$ 3.0
		Friction	40.1 $\pm$ 2.9	45.0 $\pm$ 3.0	45.0 $\pm$ 3.0	41.4 $\pm$ 3.5	41.5 $\pm$ 1.7	44.1 $\pm$ 5.3	48.6 $\pm$ 4.1	55.1 $\pm$ 3.5
		Thigh Size	40.1 $\pm$ 2.9	43.0 $\pm$ 3.1	45.1 $\pm$ 3.3	37.9 $\pm$ 4.1	46.8 $\pm$ 2.3	48.2 $\pm$ 2.6	51.0 $\pm$ 2.9	55.6 $\pm$ 2.5
Walker2d	Med	Gravity	45.3 $\pm$ 15.9	58.2 $\pm$ 11.7	59.0 $\pm$ 10.5	53.2 $\pm$ 11.1	55.3 $\pm$ 2.1	56.6 $\pm$ 2.6	60.4 $\pm$ 3.0	63.9 $\pm$ 3.2
		Friction	45.3 $\pm$ 15.9	54.3 $\pm$ 10.6	54.3 $\pm$ 10.6	51.1 $\pm$ 11.4	52.2 $\pm$ 2.3	54.5 $\pm$ 2.4	58.0 $\pm$ 3.1	61.6 $\pm$ 3.4
		Thigh Size	45.3 $\pm$ 15.9	58.7 $\pm$ 9.5	58.3 $\pm$ 9.8	49.1 $\pm$ 10.6	53.1 $\pm$ 2.5	55.2 $\pm$ 2.7	59.2 $\pm$ 2.8	62.8 $\pm$ 3.0
	Med-R	Gravity	26.6 $\pm$ 5.9	31.8 $\pm$ 4.7	33.5 $\pm$ 3.3	13.2 $\pm$ 5.7	30.3 $\pm$ 2.0	32.8 $\pm$ 2.1	36.2 $\pm$ 2.5	39.8 $\pm$ 3.1
		Friction	26.6 $\pm$ 5.9	30.3 $\pm$ 2.4	30.3 $\pm$ 2.4	28.3 $\pm$ 9.0	28.7 $\pm$ 2.2	31.5 $\pm$ 2.0	34.8 $\pm$ 2.7	38.1 $\pm$ 3.2
		Thigh Size	26.6 $\pm$ 5.9	29.4 $\pm$ 3.3	29.4 $\pm$ 3.3	27.0 $\pm$ 6.6	28.0 $\pm$ 2.3	30.4 $\pm$ 2.1	33.9 $\pm$ 2.6	37.2 $\pm$ 2.9
	Med-E	Gravity	71.0 $\pm$ 21.0	82.9 $\pm$ 11.1	83.2 $\pm$ 11.6	73.4 $\pm$ 14.3	76.6 $\pm$ 2.9	79.9 $\pm$ 16.7	83.6 $\pm$ 11.5	87.0 $\pm$ 4.9
		Friction	71.0 $\pm$ 21.0	74.0 $\pm$ 24.5	74.0 $\pm$ 24.5	78.8 $\pm$ 20.2	77.2 $\pm$ 3.3	80.1 $\pm$ 17.9	85.4 $\pm$ 9.8	89.5 $\pm$ 5.0
		Thigh Size	71.0 $\pm$ 21.0	81.0 $\pm$ 11.1	81.0 $\pm$ 11.1	78.4 $\pm$ 14.3	75.3 $\pm$ 2.5	78.7 $\pm$ 2.8	83.0 $\pm$ 3.2	86.3 $\pm$ 3.4

表 1: 在两种 MuJoCo 环境中, 针对三种领域差距 (重力、摩擦、大腿尺寸) 和三种演示水平 (中等、中等回放、中等专家) 的实验结果, 取五次运行的平均值。

BDGxRL 在所有领域差距和专家级别上均超越所有基线。例如, 在重力差距下的中等专家设置中, BDGxRL 达到 53.2, 显著优于 DARC (47.7) 和 DARAIL (51.0)。即使在具有挑战性的中等回放设置下, BDGxRL 也表现出稳健的性能, 在摩擦差距下达到 39.5, 而 DARAIL 为 35.0, xTED (CD) 为 32.4。在 Walker2d 环境中观察到类似的趋势。BDGxRL 在所有领域差距设置中均优于先前方法。在摩擦差距下的中等专家设置中, 它达到 89.5, 优于 DARAIL (85.4) 和 GAIL (77.2)。值得注意的是, 即使基线方法在低质量演示中遭受高方差或性能下降 (例如, 中等回放设置下的 DARA), BDGxRL 在所有情况下都保持稳定且优越的结果。我们还在图 2 中可视化了每种方法在所有任务上的平均得分, 总结了跨不同任务、领域差距和演示水平的整体性能。BDGxRL 始终优于所有基线, 在所有方法中取得最高平均分。BDGxRL 与次优方法 (DARAIL) 之间的明显差距突显了其在动力学不匹配下的强大泛化能力。相比之下, 缺乏显式动力学对齐的基线方法 (如 D4RL 和 GAIL) 始终表现不佳。这些结果证明了我们提出的动力学对齐和奖励调制策略的有效性。通过联合利用在线源回滚和离线目标演示, BDGxRL 弥合了动力学差距, 同时保持了策略最优性, 在跨领域强化学习中建立了新的最先进水平。

5.3 消融实验

为进一步评估本文方法中各组件的贡献, 我们通过对比进行消融实验




图 2: 各方法在所有任务、领域差距及演示级别上的总体平均性能。

完整的 BDGxRL 框架及其三种消融变体: (1) 无模仿学习 (w/o IL), 移除用于策略初始化的模仿学习; (2) 无奖励模型 (w/o RM), 禁用奖励调制并直接使用源域奖励模型; (3) 无对齐 (w/o Alignment), 移除转移调制步骤, 仅依赖源域动态而不应用基于扩散的自适应。结果报告于表 2, 重点关注中等专家水平。

结果表明, 移除转移对齐会导致两个任务及所有领域差距下的性能下降最为显著, 凸显了其在解决动力学不匹配问题中的关键作用。排除模仿学习同样导致性能大幅下降, 尤其是在 Walker2d 上, 强调了利用离线目标演示的重要性。奖励调节对性能的影响相对较小但持续存在。总体而言, 这些发现证实了三个组成部分——转移对齐、模仿学习和奖励调节——在实现鲁棒的跨领域策略学习中发挥着不可或缺且互补的作用。

Task	Domain Gap	BDGxRL	w/o IL	w/o RM	w/o Alignment
HalfCheetah	Gravity	46.3 $\pm$ 2.7	39.5 $\pm$ 3.5	42.1 $\pm$ 3.1	33.8 $\pm$ 5.2
	Friction	47.8 $\pm$ 2.9	40.3 $\pm$ 3.3	43.2 $\pm$ 2.9	35.4 $\pm$ 4.8
	Thigh Size	46.5 $\pm$ 2.5	40.1 $\pm$ 3.0	42.8 $\pm$ 2.8	34.9 $\pm$ 5.1
Walker2d	Gravity	63.9 $\pm$ 3.2	55.5 $\pm$ 4.1	58.2 $\pm$ 3.3	44.7 $\pm$ 6.7
	Friction	61.6 $\pm$ 3.4	53.3 $\pm$ 3.9	56.1 $\pm$ 3.1	43.2 $\pm$ 5.8
	Thigh Size	62.8 $\pm$ 3.0	54.1 $\pm$ 4.0	56.8 $\pm$ 3.2	43.9 $\pm$ 6.0

表 2: 在两个 MuJoCo 环境中, 跨三个领域差距的中级专家水平下的消融结果。

6 结论

本文提出了一种新颖的框架 BDGxRL, 通过动态系统桥接 (DSB) 和奖励调制实现跨域强化学习中的转移动力学对齐。该框架仅利用目标域的离线专家演示, 无需目标域奖励信号, 即可在源环境中实现面向目标的在线策略学习。本文还给出了所学策略价值差距的理论上界。在 MuJoCo 基准上, 针对不同域差距和演示水平的实验结果表明, BDGxRL 始终优于先前最先进的方法, 证明了其在弥合跨域强化学习动力学差异方面的鲁棒性和有效性。

参考文献

- Afsar, M. M.; Crump, T.; and Far, B. 2022. Reinforcement learning based recommender systems: A survey. *ACM Computing Surveys*, 55(7): 1–38.
- Aradi, S. 2020. Survey of deep reinforcement learning for motion planning of autonomous vehicles. *IEEE Transactions on Intelligent Transportation Systems*, 23(2): 740–759.
- Berner, C.; Brockman, G.; Chan, B.; Cheung, V.; D biak, P.; Dennison, C.; Farhi, D.; Fischer, Q.; Hashme, S.; Hesse, C.; et al. 2019. Dota 2 with Large Scale Deep Reinforcement Learning. *arXiv preprint arXiv:1912.06680*.
- De Bortoli, V.; Korshunova, I.; Mnih, A.; and Doucet, A. 2024. Schrodinger bridge flow for unpaired data translation. *Advances in Neural Information Processing Systems*, 37: 103384–103441.
- De Bortoli, V.; Thornton, J.; Heng, J.; and Doucet, A. 2021. Diffusion schr dinger bridge with applications to score-based generative modeling. *Advances in Neural Information Processing Systems*, 34: 17695–17709.
- Eysenbach, B.; Asawa, S.; Chaudhari, S.; Levine, S.; and Salakhutdinov, R. 2020. Off-dynamics reinforcement learning: Training for transfer with domain classifiers. *arXiv preprint arXiv:2006.13916*.
- Fu, J.; Kumar, A.; Nachum, O.; Tucker, G.; and Levine, S. 2020. D4rl: Datasets for deep data-driven reinforcement learning. *arXiv preprint arXiv:2004.07219*.
- Gu, X.; Yang, L.; Sun, J.; and Xu, Z. 2023. Optimal transport-guided conditional score-based diffusion model. *Advances in Neural Information Processing Systems*, 36: 36540–36552.
- Guo, Y.; Wang, Y.; Shi, Y.; Xu, P.; and Liu, A. 2024. Off-Dynamics Reinforcement Learning via Domain Adaptation and Reward Augmented Imitation. *arXiv preprint arXiv:2411.09891*.
- Gy ngy, I. 1986. Mimicking the one-dimensional marginal distributions of processes having an It  differential. *Probability theory and related fields*, 71(4): 501–516.
- Haarnoja, T.; Zhou, A.; Abbeel, P.; and Levine, S. 2018a. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *International conference on machine learning*, 1861–1870. Pmlr.
- Haarnoja, T.; Zhou, A.; Hartikainen, K.; Tucker, G.; Ha, S.; Tan, J.; Kumar, V.; Zhu, H.; Gupta, A.; Abbeel, P.; et al. 2018b. Soft actor-critic algorithms and applications. *arXiv preprint arXiv:1812.05905*.
- Higgins, I.; Pal, A.; Rusu, A.; Matthey, L.; Burgess, C.; Pritzel, A.; Botvinick, M.; Blundell, C.; and Lerchner, A. 2017. Darla: Improving zero-shot transfer in reinforcement learning. In *International conference on machine learning*, 1480–1490. PMLR.
- Ho, J.; and Ermon, S. 2016. Generative adversarial imitation learning. *Advances in neural information processing systems*, 29.
- Ho, J.; Jain, A.; and Abbeel, P. 2020. Denoising diffusion probabilistic models. *Advances in neural information processing systems*, 33: 6840–6851.
- Kim, H.; Yoon, J.; and Lee, J. 2024. Fast Ensembling with Diffusion Schr dinger Bridge. *arXiv preprint arXiv:2404.15814*.
- Kober, J.; Bagnell, J. A.; and Peters, J. 2013. Reinforcement Learning in Robotics: A Survey. *The International Journal of Robotics Research*, 32(11): 1238–1274.
- Kostrikov, I.; Nair, A.; and Levine, S. 2021. Offline reinforcement learning with implicit q-learning. *arXiv preprint arXiv:2110.06169*.
- Lazaric, A. 2012. Transfer in reinforcement learning: a framework and a survey. In *Reinforcement Learning: State-of-the-Art*, 143–173. Springer.
- L onard, C. 2013. A survey of the schr dinger problem and some of its connections with optimal transport. *arXiv preprint arXiv:1308.0215*.
- L onard, C.; R elly, S.; and Zambrini, J.-C. 2014. Reciprocal processes. A measure-theoretical point of view. *Probability Surveys*, 11(none): 237 – 269.
- Li, Z.; Li, S.; Wang, Z.; Lei, N.; Luo, Z.; and Gu, D. X. 2023. DPM-OT: a new diffusion probabilistic model based on optimal transport. In *Proceedings of the IEEE/CVF international conference on computer vision*, 22624–22633.
- Liu, J.; Zhang, H.; and Wang, D. 2022. Dara: Dynamics-aware reward augmentation in offline reinforcement learning. *arXiv preprint arXiv:2203.06662*.
- Lyu, J.; Bai, C.; Yang, J.; Lu, Z.; and Li, X. 2024a. Cross-domain policy adaptation by capturing representation mismatch. *arXiv preprint arXiv:2405.15369*.

- Lyu, J.; Xu, K.; Xu, J.; Yan, M.; Yang, J.-W.; Zhang, Z.; Bai, C.; Lu, Z.; and Li, X. 2024b. ODRL: A Benchmark for Off-Dynamics Reinforcement Learning. In *The Thirty-eight Conference on Neural Information Processing Systems Datasets and Benchmarks Track*.
- Niu, H.; Chen, Q.; Liu, T.; Li, J.; Zhou, G.; Zhang, Y.; Hu, J.; and Zhan, X. 2024. xTED: Cross-Domain Adaptation via Diffusion-Based Trajectory Editing. *arXiv preprint arXiv:2409.08687*.
- Niu, H.; Qiu, Y.; Li, M.; Zhou, G.; Hu, J.; Zhan, X.; et al. 2022. When to trust your simulator: Dynamics-aware hybrid offline-and-online reinforcement learning. *Advances in Neural Information Processing Systems*, 35: 36599–36612.
- Peyré, G.; Cuturi, M.; et al. 2019. Computational optimal transport: With applications to data science. *Foundations and Trends® in Machine Learning*, 11(5-6): 355–607.
- Rombach, R.; Blattmann, A.; Lorenz, D.; Esser, P.; and Ommer, B. 2022. High-resolution image synthesis with latent diffusion models. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 10684–10695.
- Santambrogio, F. 2015. *Optimal transport for applied mathematicians*, volume 87. Springer.
- Shi, Y.; De Bortoli, V.; Campbell, A.; and Doucet, A. 2023. Diffusion schrödinger bridge matching. *Advances in Neural Information Processing Systems*, 36: 62183–62223.
- Somnath, V. R.; Pariset, M.; Hsieh, Y.-P.; Martinez, M. R.; Krause, A.; and Bunne, C. 2023. Aligned diffusion schrödinger bridges. In *Uncertainty in Artificial Intelligence*, 1985–1995. PMLR.
- Song, J.; Meng, C.; and Ermon, S. 2020. Denoising diffusion implicit models. *arXiv preprint arXiv:2010.02502*.
- Song, Y.; Sohl-Dickstein, J.; Kingma, D. P.; Kumar, A.; Ermon, S.; and Poole, B. 2020. Score-based generative modeling through stochastic differential equations. *arXiv preprint arXiv:2011.13456*.
- Sutton, R. S.; Barto, A. G.; et al. 1998. *Reinforcement Learning: An Introduction*. MIT press Cambridge.
- Todorov, E.; Erez, T.; and Tassa, Y. 2012. Mujoco: A physics engine for model-based control. In *2012 IEEE/RSJ international conference on intelligent robots and systems*, 5026–5033. IEEE.
- Torabi, F.; Warnell, G.; and Stone, P. 2018. Behavioral cloning from observation. *arXiv preprint arXiv:1805.01954*.
- Xing, J.; Nagata, T.; Chen, K.; Zou, X.; Neftci, E.; and Krichmar, J. L. 2021. Domain adaptation in reinforcement learning via latent unified state representation. In *Proceedings of the AAAI Conference on Artificial Intelligence (AAAI)*.
- Xu, K.; Bai, C.; Ma, X.; Wang, D.; Zhao, B.; Wang, Z.; Li, X.; and Li, W. 2023. Cross-domain policy adaptation via value-guided data filtering. *Advances in Neural Information Processing Systems*, 36: 73395–73421.
- Xu, T.; Li, Z.; and Yu, Y. 2020. Error bounds of imitating policies and environments. *Advances in Neural Information Processing Systems*, 33: 15737–15749.
- Zhang, C.; Zhang, C.; Zhang, M.; and Kweon, I. S. 2023. Text-to-image diffusion models in generative ai: A survey. *arXiv preprint arXiv:2303.07909*.
- Zhu, Z.; Locatello, F.; and Cevher, V. 2023. Sample complexity bounds for score-matching: Causal discovery and generative modeling. *Advances in Neural Information Processing Systems*, 36: 3325–3337.

Algorithm 1: Target-Oriented Policy Learning of BDGxRL

```

1: Input: Source environment  $E_S$ , offline target dataset  $\mathcal{D}_T$ , initial policy  $\pi(a_t|s_t)$ , replay buffer  $\mathcal{B}$ 
2: % Offline Pretraining Phase:
3: Collect source dataset  $\mathcal{D}_S$  by interacting with  $E_S$ .
4: Train the transition-aware reward model  $R(s_t, s_{t+1})$  on  $\mathcal{D}_S$  using Eq. (10).
5: Train the DSB model on  $\mathcal{D}_S$  and  $\mathcal{D}_T$  using Eq. (4)(5) and Eq.(6)(7).
6: Pretrain policy  $\pi(a_t|s_t)$  via behavior cloning on  $\mathcal{D}_T$ .
7: % Online Policy Learning Phase:
8: while not converged do
9:   Reset environment  $E_S$  and observe initial state  $s_0$ .
10:  for each timestep  $t$  do
11:    Sample action  $a_t \sim \pi(\cdot | s_t)$ .
12:    Execute  $a_t$  to obtain next state  $s_{t+1}$  and reward  $r_t$ .
13:    Translate state:  $\tilde{s}_{t+1} = \text{DSB}_{S \rightarrow T}(s_t, a_t, s_{t+1})$ .
14:    Compute modulated reward:  $\tilde{r}_t = R(s_t, \tilde{s}_{t+1})$ .
15:    Append  $(s_t, a_t, s_{t+1}, r_t)$  to  $\mathcal{D}_S$  for model update.
16:    Store transition  $(s_t, a_t, \tilde{r}_t, \tilde{s}_{t+1})$  in replay buffer  $\mathcal{B}$ .
17:    Set  $s_{t+1} = \tilde{s}_{t+1}$ .
18:  end for
19:  Update policy  $\pi(a_t|s_t)$  using SAC with buffer  $\mathcal{B}$ .
20:  Periodically update DSB and reward models using the augmented  $\mathcal{D}_S$ .
21: end while

```

BDGxRL 的训练算法

本文所提出的 BDGxRL 的完整训练流程概述于算法 1 中。

B 完整消融结果

表 3 报告了在所有专家水平（中等、中等回放和中等专家）和域差距（重力、摩擦和大腿尺寸）下，两个 MuJoCo 任务上的完整消融结果。结果一致地突出了 BDGxRL 中每个组件的重要性。在所有设置中，移除转移对齐（无对齐）导致最显著的性能下降，特别是在高性能场景中，例如 Walker2d（中等专家），分数从 87.0 降至 62.4（重力）和从 89.5 降至 64.2（摩擦）。这强调了基于 DSB 的转移对齐在处理动力学不匹配中的关键作用。排除模仿学习（无模仿学习）也会导致性能显著下降，尤其是在低质量数据场景中，例如 HalfCheetah（中等回放），从头开始训练限制了策略的有效性。这证明了在域偏移下利用离线目标演示进行策略初始化的价值。禁用奖励调制（无奖励调制）会导致中等但一致的性能下降。例如，在 Walker2d（中等回放）中，摩擦设置下的性能从 38.1 降至 32.1。尽管其效果不如其他组件显著，但奖励调制仍然有助于改善跨域奖励的对齐。

总之，完整的消融结果证实了其完备性

BDGxRL 三个关键组件的互补性。每个组件在广泛的领域差距和数据条件下，对实现稳健的跨领域策略学习发挥着独特作用。

BDGxRL 的理论分析 在本节中，我们基于策略评估误差界对 BDGxRL 进行理论分析，为通过 BDGxRL 所学策略的有效性建立理论保证。具体而言，我们证明定理 1，该定理表明在温和假设下，所学 BDGxRL 策略的性能被限制在特定误差范围内。为证明定理 1，我们首先分析策略学习中的总误差来源。这些误差主要源于两个因素：

- Transition model error: due to the inaccuracy of the learned transition model via DSB.
- Policy optimization error: resulting from the suboptimality of policy learning using deep neural networks.

Formally, let $\mathcal{M}_T$ denote the true target MDP, $\mathcal{M}_{\text{DSB}}$ the learned transition model obtained via DSB, π^* the optimal policy in the true MDP, and π the target-oriented policy learned by BDGxRL. Then the total policy evaluation error can be decomposed as:

$$\left| V_{\mathcal{M}_T}^{\pi^*} - V_{\mathcal{M}_{\text{DSB}}}^{\pi} \right| \leq \underbrace{\left| V_{\mathcal{M}_T}^{\pi^*} - V_{\mathcal{M}_{\text{DSB}}}^{\pi^*} \right|}_{\text{transition model error}} + \underbrace{\left| V_{\mathcal{M}_{\text{DSB}}}^{\pi^*} - V_{\mathcal{M}_{\text{DSB}}}^{\pi} \right|}_{\text{policy optimization error}}. \quad (17)$$

我们现在证明，在温和且合理的假设下，两个误差项都可以被显式地界定。

假设 1。 令 N_{DSB} 表示求解 DSB 时使用的 IMF 迭代次数， N_S 表示源域数据集的大小， N_T 表示目标域数据集的大小。奖励函数以 $R_{\max}$ 为界，折扣因子满足 $\gamma \in [0, 1)$ 。我们假设 DSB 通过基于分数的模型正确实现，并使用足够多的 IMF 迭代次数进行训练。目标数据集大小 $N_T = |\mathcal{D}_T|$ 由离线演示固定，而源数据集大小 $N_S = |\mathcal{D}_S|$ 在训练过程中通过在源域收集数据而增长。在假设 1 下，当 IMF 迭代次数 N_{DSB} 足够大且基于分数的模型使用源数据和目标数据进行训练时，基于 DSB 的动力学对齐被假定能产生准确的转移。我们现在给出转移模型误差的一个界。

引理 1（转移模型误差界）。在假设 1 下，转移模型误差的界为：

$$\left| V_{\mathcal{M}_T}^{\pi^*} - V_{\mathcal{M}_{\text{DSB}}}^{\pi^*} \right| \leq \frac{\sqrt{2} R_{\max} \gamma}{(1 - \gamma)^2} \cdot \sqrt{\epsilon_m}, \quad (18)$$

其中转移模型误差 ϵ_m 分解为：

$$\epsilon_m \approx \mathcal{O} \left(\frac{1}{N_S} + \frac{1}{N_T} \right). \quad (19)$$

转移模型误差 ϵ_m 随着策略训练期间源数据大小的增加而减小，并以目标域演示大小为下界，即 $\mathcal{O}(\frac{1}{N_T})$ 。

Task	Expert	Domain Gap	BDGxRL (Ours)	w/o IL	w/o RM	w/o Alignment
HalfCheetah	Med	Gravity	46.3 $\pm$ 2.7	39.5 $\pm$ 3.5	42.1 $\pm$ 3.1	33.8 $\pm$ 5.2
		Friction	47.8 $\pm$ 2.9	40.3 $\pm$ 3.3	43.2 $\pm$ 2.9	35.4 $\pm$ 4.8
		Thigh Size	46.5 $\pm$ 2.5	40.1 $\pm$ 3.0	42.8 $\pm$ 2.8	34.9 $\pm$ 5.1
	Med-R	Gravity	37.8 $\pm$ 2.8	31.0 $\pm$ 4.0	33.2 $\pm$ 3.7	25.6 $\pm$ 6.1
		Friction	39.5 $\pm$ 2.6	32.5 $\pm$ 3.2	34.4 $\pm$ 3.4	27.2 $\pm$ 5.3
		Thigh Size	38.6 $\pm$ 2.7	31.8 $\pm$ 3.0	33.9 $\pm$ 3.2	26.4 $\pm$ 5.0
	Med-E	Gravity	53.2 $\pm$ 3.0	45.2 $\pm$ 4.2	48.8 $\pm$ 3.6	37.5 $\pm$ 6.4
		Friction	55.1 $\pm$ 3.5	46.3 $\pm$ 4.0	50.1 $\pm$ 3.7	39.3 $\pm$ 6.0
		Thigh Size	55.6 $\pm$ 2.5	46.9 $\pm$ 3.8	50.4 $\pm$ 3.6	40.7 $\pm$ 5.8
Walker2d	Med	Gravity	63.9 $\pm$ 3.2	55.5 $\pm$ 4.1	58.2 $\pm$ 3.3	44.7 $\pm$ 6.7
		Friction	61.6 $\pm$ 3.4	53.3 $\pm$ 3.9	56.1 $\pm$ 3.1	43.2 $\pm$ 5.8
		Thigh Size	62.8 $\pm$ 3.0	54.1 $\pm$ 4.0	56.8 $\pm$ 3.2	43.9 $\pm$ 6.2
	Med-R	Gravity	39.8 $\pm$ 3.1	33.3 $\pm$ 3.8	35.5 $\pm$ 3.6	28.2 $\pm$ 5.4
		Friction	38.1 $\pm$ 3.2	32.1 $\pm$ 3.7	34.0 $\pm$ 3.3	27.0 $\pm$ 4.9
		Thigh Size	37.2 $\pm$ 2.9	31.3 $\pm$ 3.5	33.2 $\pm$ 3.2	26.2 $\pm$ 4.7
	Med-E	Gravity	87.0 $\pm$ 4.9	75.1 $\pm$ 5.6	80.3 $\pm$ 4.2	62.4 $\pm$ 7.5
		Friction	89.5 $\pm$ 5.0	77.3 $\pm$ 5.4	82.0 $\pm$ 4.3	64.2 $\pm$ 7.2
		Thigh Size	86.3 $\pm$ 3.4	74.8 $\pm$ 5.3	79.4 $\pm$ 4.1	61.8 $\pm$ 6.8

表 3: 在两个 MuJoCo 环境中, 跨三种域差距 (重力、摩擦、大腿尺寸) 和三种演示水平 (中等、中等回放、中等专家) 的完整消融结果, 取三次运行的平均值。

证明。基于 (Xu, Li, and Yu 2020) 的先前结论, 当在具有转移模型误差的模仿环境中学习策略时, 并假设学习到的转移模型在以下意义上接近真实转移动态:

$$\mathbb{E}_{(s,a) \sim \rho^\pi} [\text{KL}(\mathcal{T}_T(\cdot|s,a) \parallel \mathcal{T}_{\text{DSB}}(\cdot|s,a))] \leq \epsilon_m, \quad (20)$$

则转移模型误差有界为:

$$\left| V_{\mathcal{M}_T}^{\pi^*} - V_{\mathcal{M}_{\text{DSB}}}^{\pi^*} \right| \leq \frac{\sqrt{2}R_{\max}\gamma}{(1-\gamma)^2} \cdot \sqrt{\epsilon_m}. \quad (21)$$

的分解

ϵ_m 在我们的情境中, 学习转移模型的误差 ϵ_m 来源于两个方面: (1) DSB 中使用的基于分数的模型的近似误差, 以及 (2) 求解 DSB 问题的优化误差。我们写出:

$$\epsilon_m = \underbrace{\epsilon_{\text{sbm}}}_{\text{score-based model error}} + \underbrace{\epsilon_{\text{dsb}}}_{\text{DSB solver error}}. \quad (22)$$

基于分数的模型误差 ϵ_{sbm} 根据 (Zhu, Locatello, and Cevher 2023), 基于分数的模型的估计误差大致与训练数据量成反比。假设数据集大小为 N , 则估计误差有界为 $\mathcal{O}(\frac{1}{N})$ 。在我们的设置中, DSB 模型是双向训练的, 这实际上使学习误差加倍。令 N_S 表示从源域收集的转移数量, N_T 表示来自目标域的离线演示数量。则总的基于分数的模型误差有界为:

$$\epsilon_{\text{sbm}} = \mathcal{O}\left(\frac{1}{N_S} + \frac{1}{N_T}\right). \quad (23)$$

由于来自源域的转移在在线训练期间持续收集, 项 $\mathcal{O}(\frac{1}{N_S})$ 随时间不断减小。经过足够长的训练, 基于分数的模型误差 ϵ_{sbm} 将由来自目标域的固定大小的离线演示数据主导。

DSB 误差 ϵ_{dsb} DSB 求解器误差 ϵ_{dsb} 源于 DSB 目标相对于真实目标转移分布的不完美优化。令 $\mathcal{T}_T$ 表示目标环境中的真实转移分布, 令 $\mathcal{T}^n$ 表示经过 n 次 IPF 或 IMF 迭代后 DSB 诱导的转移分布。则:

$$\epsilon_{\text{dsb}} = \text{KL}(\mathcal{T}^n \parallel \mathcal{T}_T). \quad (24)$$

如预备章节所述, 随着 IPF/IMF 迭代次数的增加, DSB 的残差渐近消失。即,

$$\lim_{n \rightarrow \infty} \epsilon_{\text{dsb}} = \lim_{n \rightarrow \infty} \text{KL}(\mathcal{T}^n \parallel \mathcal{T}_T) = 0. \quad (25)$$

因此, 经过足够多的迭代, DSB 优化误差 ϵ_{dsb} 可以任意小。在假设 1 下, 我们证明了转移模型误差项 $|V_{\mathcal{M}_T}^{\pi^*} - V_{\mathcal{M}_{\text{DSB}}}^{\pi^*}|$ 由式 (18) 界定, 整体误差 ϵ_m 分解为两个分量, 两者均随充足的数据和训练而减小。 $\square$

定理 2 (基于 DSB 平移的策略价值界)。假设奖励有界于 $R_{\max}$, 且折扣因子满足 $\gamma \in [0, 1)$ 。设 π 为使用基于 DSB 的动力学平移与奖励调制的 BDGxRL 所学得的策略, 并设 π^* 表示目标环境中的最优策略。则当 DSB 训练的 IMF 迭代次数足够大时, 价值差

在目标马尔可夫决策过程 (MDP) $\mathcal{M}_T$ 中, π 与 π^* 之间的差距有界如下:

$$\Delta V := \left| V_{\mathcal{M}_T}^{\pi^*} - V_{\mathcal{M}_{DSB}}^{\pi} \right| \leq \frac{\sqrt{2}R_{\max}\gamma}{(1-\gamma)^2} \cdot \sqrt{\epsilon_m} + \frac{2\sqrt{2}R_{\max}}{(1-\gamma)^2} \cdot \sqrt{\epsilon_{\pi}}, \quad (26)$$

where $\epsilon_m = \mathcal{O}\left(\frac{1}{N_S} + \frac{1}{N_T}\right)$ 表示由使用 $N_S = |\mathcal{D}_S|$ 和 $N_T = |\mathcal{D}_T|$ 的 DSB 训练引起的动力学近似误差, 而 ϵ_{π} 刻画了学习到的目标导向策略与最优目标导向策略之间的策略近似误差。

证明。基于 (Xu, Li, and Yu 2020) 的定理 1, 在假设 1 下, 对于任意满足 $\text{KL}(\pi(\cdot|s) \parallel \pi^*(\cdot|s)) \leq \epsilon_{\pi}$ 的策略 π , 策略优化误差有界为:

$$\left| V_{\mathcal{M}_{DSB}}^{\pi^*} - V_{\mathcal{M}_{DSB}}^{\pi} \right| \leq \frac{2\sqrt{2}R_{\max}}{(1-\gamma)^2} \cdot \sqrt{\epsilon_{\pi}}. \quad (27)$$

Combining this with the transition model

difference betw

错误: 根据引理 1, 学习到的面向目标策略 π 与最优目标策略 π^* 之间的总价值差异有界为:

$$\Delta V := \left| V_{\mathcal{M}_T}^{\pi^*} - V_{\mathcal{M}_{DSB}}^{\pi} \right| \leq \frac{\sqrt{2}R_{\max}\gamma}{(1-\gamma)^2} \cdot \sqrt{\epsilon_m} + \frac{2\sqrt{2}R_{\max}}{(1-\gamma)^2} \cdot \sqrt{\epsilon_{\pi}}. \quad (28)$$

□

该结果表明, 所提出的 BDGxRL 框架能够有效学习面向目标的策略, 在目标环境中达到接近最优的性能。

C 实现细节 我们在 xTED 基准 (Niu 等人, 2024) 中的 **MuJoCo** (Todorov, Erez 和 Tassa, 2012) 环境上进行实验, 利用修改后的源域中的在线交互以及来自 D4RL (中等专家) 的离线数据作为目标域。每个任务包含来自目标域演示数据的 20,000 条离线转移。三个目标环境基于标准 **MuJoCo** 任务进行了以下修改: (1) 重力: 将重力加速度加倍以改变仿真动力学; (2) 摩擦: 将摩擦系数降低至 $0.25\times$ 或 $0.5\times$, 使智能体更难保持平衡; (3) 大腿尺寸: 将大腿尺寸增加 $2\times$, 以引入具身形态差异。对于动力学对齐, 我们采用 (Shi 等人, 2023) 中扩散薛定谔桥匹配 (DSBM) 和迭代马尔可夫拟合 (IMF) 的官方实现作为基于 DSB 方法的骨干。为了调节奖励, 我们使用源域回放数据训练一个三层多层感知机奖励模型。面向目标的策略学习使用 **SAC** 进行, 并通过在目标数据集上的行为克隆 (**BC**) 进行初始化。应用系数为 $\alpha = 0.1$ 的 KL 正则化项以鼓励与模仿策略的一致性。部分实验环境也部分采用了离动力学强化学习 (ODRL) (Lyu 等人, 2024b)。